



INVESTIGACIÓN _____

PROFUNDIZACIÓN X

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS
ABIERTOS SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Autor

Álvaro Varón Capera

Tutor

Paulo Alonso Gaona García, PhD

Universidad Distrital Francisco José De Caldas

Maestría en Ciencias de la Información y las Comunicaciones

Énfasis en Ingeniería de Software

Bogotá, Colombia

Noviembre 2024

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Contenido

1.	RESUMEN	4
	PALABRAS CLAVE	4
2.	INTRODUCCIÓN.....	5
3.	PLANTEAMIENTO DEL PROBLEMA	8
4.	OBJETIVOS	14
4.1	Objetivo General	14
4.2	Objetivos Específicos	14
5.	MARCO TEÓRICO	15
5.1	De los Datos Abiertos de Salud en Bogotá.....	18
6.	MARCO CONCEPTUAL	21
6.1	RDF.....	21
6.2	SPARQL.....	21
6.3	Web Semántica	22
6.4	Epidemiología.....	22
6.5	Datos abiertos	23
6.6	Calidad de los datos	27
6.7	Dimensiones de calidad	27
6.7.2	Dimensión dinámica.....	29
6.7.2.1	Actualidad	29
6.7.2.2	Volatilidad.....	30
6.7.2.3	Puntualidad	30
6.8	Machine learning.....	30
7.	METODOLOGÍA	32
7.1	Recopilación de los datos.....	35
7.2	Comprensión de los Datos	37
7.2.1	descripción de los conjuntos de datos:	38
7.2.2	Comprensión de la composición de los datos:	40
7.2.3	Identificación de Problemas de Calidad de Datos	41

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

7.3	Preparación de los Datos	42
7.3.1	Limpieza de Datos.....	43
7.3.2	Tratamiento de Valores Nulos	43
8	MODELO PROPUESTO	45
8.3.1	Selección de algoritmo	46
8.3.2	Selección de Características	49
8.3.3	Entrenamiento del modelo:	49
9	RESULTADO DE EVALUACIÓN Y DESPLIEGUE DEL MODELO	54
9.1	Implementación.....	57
9.1.1	Arquitectura.....	58
9.1.2	Tecnologías utilizadas	59
9.1.3	Despliegue del modelo	60
9.2	Resultados Obtenidos	63
9.2.1	Precisión	64
7.7.2	Concisión	65
7.7.3	Coherencia.....	65
7.7.4	Actualidad	66
7.7.5	Volatilidad	66
7.7.6	Puntualidad	66
7.7.7	Publicación en revista científica.....	68
10	CONCLUSIONES	69
11	ANEXO - Glosario	73
12	REFERENCIAS.....	74

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

1. RESUMEN

El presente documento de tesis de maestría bajo modalidad de profundización tiene como propósito llevar a cabo una revisión del estado de calidad de estos datos históricos, específicamente a través repositorios de datos abiertos del sector salud dentro del contexto de la ciudad de Bogotá, con el fin de evaluar la calidad de los mismos. Para ello se evalúa la calidad de datos abiertos, a partir de criterios relacionados con la consistencia, exactitud, redundancia, frecuencia de actualización, entre otros. Evaluar la calidad de datos abiertos expuestos en repositorios, facilitaría la reutilización del conjunto de datos para llevar a cabo estudios enfocados a la prevención de eventos epidemiológicos, afectaciones a la prestación de los servicios de salud y disminución de la salud global para una población.

PALABRAS CLAVE

Datos abiertos, Machine Learning, Datos Enlazados, Bogotá D.C, Salud, Epidemiología.

2. INTRODUCCIÓN

Actualmente la población global ha venido enfrentando retos a raíz de situaciones que se han venido desencadenando y afectando diversos sectores de la salud, demandas y crisis producto de enfermedades epidemiológicas tales como el dengue, la malaria, enfermedades de transmisión sexual, así como la pandemia global causada por el virus SARS-CoV-2 en el año 2020, entre otros. Estas situaciones generan grandes retos no solamente a gobiernos de turno, sino también a la misma comunidad del sector de la salud, académicos, como investigadores que tratan de mitigar y/o contrarrestar estas situaciones gracias a los registros de datos históricos que se generan a partir de cada una de ellas. Bajo esta perspectiva, es fundamental resaltar el valor de los datos abiertos para llevar a cabo un análisis de diversos aspectos que puedan facilitar a la comunidad científica y así como entidades encargadas de tomar decisiones en el sector de salud, para tratar de establecer políticas y/o criterios que permitan mitigar riesgos dentro de una población.

En este sentido los datos abiertos del sector salud adquieren un gran valor teniendo en cuenta que, como lo indica Cediell-Becerra *et al.* (2016) la toma de decisiones en salud pública es un proceso que implica que los gobiernos puedan responder continuamente a las circunstancias cambiantes, anticipando las amenazas emergentes e identificando formas para controlarlas. También como lo menciona Ferrer-Sapena *et al.* (2020) los gobiernos necesitan datos actualizados y fiables para la toma de decisiones. La carencia de cumplimiento de los criterios mencionados afecta de forma directa el proceso de toma de decisiones para el establecimiento de políticas con base en los riesgos de salud, por tal motivo, para propósitos de evaluación de calidad en presente proyecto, se abordarán puntualmente los criterios de calidad de datos relacionados con las dimensiones intrínseca y dinámica, definidas por Zavieri *et al.* (2014).

Teniendo en cuenta la relevancia que han tomado las decisiones globales en torno a la salud, Torres-Salinas (2020) evidencia la importancia de los datos abiertos en las investigaciones que han surgido a raíz del Virus SARS-CoV-2, las cuales han tenido una importancia significativa en políticas públicas establecidas para los intentos de

control del virus y mitigación de la pandemia. Del mismo modo, García-Altés et al. (2016), establece que la transparencia en la toma de decisiones de salud pública está directamente ligada al conocimiento público de la información, ítem que se logra con la disposición de los datos abiertos. La transparencia como constitución de las sociedades democráticas implica establecer normativas para la liberación de datos, resalta que se debe reforzar la liberación de datos y unificar los repositorios donde estos son liberados.

Al analizar y comparar conjuntos de datos epidemiológicos, se identifica que de cumplirse con los criterios para el cumplimiento de la calidad de los datos, se podrían contrarrestar posibles amenazas en temas de salubridad, sanitarios y/o epidemiológicos, se lograría apoyar los procesos de toma de decisiones y localización de posibles focos de contagio, puntos de propagación, generación barreras de contención y se podría dar un trato más controlado y segmentado a los puntos críticos de propagación de enfermedades, virus, entre otros. Según lo indica la Organización Mundial de la Salud (2008), cuando hay una amenaza real o potencial para la salud pública, las opciones de tratamiento y los recursos pueden ser escasos, las intervenciones directas pueden requerir tiempo para organizarse y dadas las presiones de tiempo y exigencias de recursos asociadas con las actividades de comunicación durante escenarios con afectación a la salud de la población, la planificación debe comenzar con una valoración de la información útil con la que se dispone antes del evento. De ahí surge la necesidad de establecer políticas de salud pública tempranas, que deben estar apoyadas en datos que cumplan con los criterios de calidad requeridos.

De la misma forma se han identificado una serie de falencias a la hora de liberar los datos para las necesidades a nivel de salubridad, Torres-Salinas (2020) indica “los modelos más tradicionales de bases de datos se ven perjudicados, ya que, a veces tardan en incorporar los registros y puede que no sean lo ágiles e inmediatos que requiere un tema como el Covid-19”. Vetrò et al. (2016) concluye que los datos abiertos han presentado barreras como la insuficiente calidad de los datos que afecta negativamente al proceso de reutilización, ocasionando que la ciudadanía invierta tiempo en comprobar y aumentar la calidad de forma descentralizada y descoordinada

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

lo que conlleva que se abandonen los proyectos de portales de datos abiertos, tan pronto como son implantados para la publicación de datos.

Por tanto, el siguiente trabajo pretende dar algunos lineamientos que permitan dar el cumplimiento de criterios de calidad de los datos abiertos para sector salud en Bogotá. De manera puntual, se definen evaluando las dimensiones intrínseca y dinámica (Zaveri et al., 2014), dimensiones que están directamente relacionadas a factores relevantes para el establecimiento de políticas de salud pública.

La problemática identificada que evidencia el incumplimiento de calidad de los datos abiertos para este caso, del sector salud en las dimensiones intrínseca y dinámica, es el motivo para llevar a cabo el presente trabajo, dando lugar a la necesidad de establecer un modelo, que mediante el uso de técnicas de machine learning evalúe los datos abiertos de salud en Colombia, específicamente en la ciudad de Bogotá D.C, brindando una serie de métricas e indicadores de cumplimiento, que tengan en cuenta la frescura a lo largo del tiempo, la exactitud, la consistencia y la integridad, los cuales son factores fundamentales para la implementación de métodos basados en evidencia que buscan apoyar los procesos de toma de decisiones en el establecimiento políticas de salud pública.

A partir de este panorama, la estructura de este documento toma en consideración los apartados fundamentales descritos por la Maestría en ciencias de la información y las comunicaciones, se distribuye de la siguiente forma: como primera etapa se realiza la descripción y planteamiento del problema de estudio, en la segunda etapa se identifican los objetivos de la presente profundización, para la tercera etapa se presenta un marco teórico para el objeto de estudio, el marco conceptual conforma la cuarta etapa, en la quinta etapa se encontrará la metodología utilizada compuesta por secciones relevantes como modelado, implementación, resultados obtenidos; en la última etapa se presentan las conclusiones y el trabajo futuro producto de del presente estudio. A su vez, se espera poder evaluar y articular políticas de datos abiertos de Salud en Colombia propuestas por la Organización Mundial de la Salud, Ministerio de salud y protección social, Mintic, entre otros.

3. PLANTEAMIENTO DEL PROBLEMA

Desde hace aproximadamente tres décadas se ha podido observar como el “salto cuántico” de las tecnologías de información han transformado al mundo al nivel de cambiar muchas de las prácticas humanas, tanto los avances tecnológicos, especialmente los computacionales (procesamiento, almacenamiento, digitalización, entre otros) como el desarrollo y aumento de las capacidades personales para la interacción humano - máquina (Hernández, 2016), donde se destaca la automatización de tareas, la capacidad de análisis, la riqueza y diversidad de fuentes de información e intrínsecamente, la generación de conocimiento. Estos aspectos logran ubicar a la web en el centro del universo informático, desde sus inicios con la creación del protocolo de transferencia de hipertexto (HTTP) inventado por Tim Berners Lee en 1989, junto con el lenguaje de marcado de hipertexto (HTML) y el sistema de localización de objetos web (URL) Clemente (2014), hasta el punto de hablarse en la actualidad de la Web semántica, que se entiende como una extensión de la World Wide Web desarrollada por Berners Lee, que permite procesar contenido Web de forma inteligente basado en el significado que tiene este contenido para quién interactúa con ella.

Cabe resaltar que no es suficiente con almacenar e intercambiar los datos en una sintaxis comprensible por la máquina como HTML, sino que es necesario el uso de estándares y protocolos para el intercambio y la especificación de datos comunes en la Web. De allí surge la iniciativa de Datos Abiertos (Open Data) y Datos Abiertos Enlazados (Linked Open Data), impulsada por el mismo Berners Lee con el fin de representar una oportunidad para que la sociedad pueda reutilizar los datos de las entidades estatales, gobiernos, ONG's y distintos sectores con el fin que se desee, pero en aras de la innovación, de la investigación y demás proyectos que benefician a un sector cualquiera. Muchas iniciativas han surgido a raíz de los datos abiertos, al punto de encontrar grandes repositorios donde se unifican y consolidan estos, por ejemplo, en LOD cloud (portal que analiza los principales repositorios de datos abiertos y enlazados, se encuentra un estimado de 20.395.620 recursos, disponibles para su libre uso (lod-cloud.net, 2020).

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Desde el inicio de la década actual, debido a la coyuntura sanitaria cursada, los datos abiertos del sector salud adquieren un valor considerable, como menciona Aleixandre-Benavent et al.(2019) el tiempo es un factor relevante para contrarrestar epidemias, pandemias y demás problemas relacionados con la afectación en masa de la población. Los datos abiertos pueden transformar la salud por diversos motivos: mejorando la información de las decisiones clínicas, identificando poblaciones vulnerables, impulsando la investigación y la innovación, y mejorando las políticas públicas en materia de salud, la transparencia, la calidad y, en definitiva, la salud de la población.




Figura 1: Importancia de la respuesta rápida de salud pública. Fuente: OMS (2020)

Autores como Zamora et al. (2012) afirman que los problemas identificados en iniciativas previas de generar una plataforma de datos abiertos para el sector de la salud suceden principalmente en la falta de confiabilidad de tener una plataforma de gestión de la información netamente virtual y con disponibilidad 24-7, así como falencias por parte de las instituciones de salud, donde no existe un proceso de recolección, limpieza y análisis de datos para ofrecer datos oportunos y precisos. También en materia de políticas públicas: “Un recurso clave para esta estrategia radica en la información gubernamental, la misma que por ley debe ser de carácter público, y por lo tanto debe ser abierta y ponerse a disposición de otros, sean para beneficio de personas u organizaciones, e incluso del mismo gobierno.”

Del mismo modo Ferrer-Sapena (2020) destaca la dificultad de trabajar con datos abiertos directamente desde fuentes oficiales: Algunos datos no están disponibles, otros no cuentan con formatos fácilmente reutilizables, y existen múltiples formas de recoger los datos, obligando a procesarlos, lo que en momentos de urgencia produce retrasos. Pero quizá el problema más relevante es la no determinación desde el inicio de la recogida de información: qué es lo que abarca cada uno de los indicadores de la muestra, y cómo y cuándo debe ser recogido.

Ahora bien, los problemas identificados anteriormente dan paso a hablar acerca de la calidad de los datos, que como indica Alderete al., (2014), existen muchas definiciones de lo que implica que ciertos datos sean de calidad. Algunas de ellas son:

1. Grado de excelencia mostrado por los datos con relación a la representación del escenario real.
2. El estado de completitud, validez, consistencia, atemporalidad y exactitud que hace a los datos apropiados para un uso específico.
3. Los procesos y tecnologías involucradas para garantizar la conformidad de los valores de los datos a los valores del negocio y a criterios de aceptación.

Según (Zaveri et al., 2014) los datos abiertos y enlazados, (cabe aclarar que en este estudio nos centraremos únicamente en datos abiertos), se pueden clasificar en 23 sub-dimensiones, las cuales a su vez se pueden clasificar en 6 categorías: (1) Dimensión de Accesibilidad (2) Dimensión Intrínseca (3) Dimensión de Confianza (4) Dimensión Dinámica (5) Dimensión Contextual y (6) Dimensión Representacional. Este estudio se enfocará en las dimensiones intrínseca y dinámica, que se centran en si la información representa correctamente y de forma compacta los datos del mundo real y si la información es lógicamente coherente en sí misma, así como en la frescura de los conjuntos de datos a lo largo del tiempo, la frecuencia de cambio a lo largo del tiempo y la frescura a lo largo del tiempo para un tema específico. Dimensiones que teniendo en cuenta los problemas identificados en estudios relacionados, presentan grandes falencias de cumplimiento, las cuales son factor relevante en el logro de determinar la calidad de los datos abiertos.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

La investigación realizada por Tom-Aba et al. (2015) es un gran ejemplo de abordaje de la epidemia de ébola en Nigeria mediante el uso de datos abiertos de salud y herramientas de geolocalización. La herramienta interpreta los datos y establece mediante la sintomatología indicada por el paciente y su residencia ó lugar de trabajo, un posible foco de contagio y punto de propagación del virus Ébola. Es un estudio interesante, pero cabe resaltar que de no ser por la frescura e integridad (alimentación constante, frecuente, representación correcta y coherente con los datos de mundo real según Zaveri et al., (2014) de los datos, no hubiera sido posible el éxito de esta.




Figura 2. Herramienta de detección de focos de contagio de Ébola en Nigeria.

Fuente: (Tom-Aba et al.2015)

Lo anterior destaca la importancia del cumplimiento de estas dimensiones ya que los profesionales que trabajan sobre el terreno reclaman la urgencia en establecer los principios para compartir datos de forma rápida y responsable en situaciones con afectación a la salud de la población. En dicha investigación, la organización médica y humanitaria internacional Médicos sin Fronteras decidió adoptar una política de intercambio de datos clínicos y de investigación. Liberar este tipo de datos es especialmente importante en los ensayos clínicos. Si toda la información sobre los ensayos clínicos se compartiera en abierto, se evitaría la repetición de costosos ensayos que utilizan las mismas intervenciones sanitarias que se utilizaron previamente, reduciendo el coste y mejorando la eficiencia.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

La apertura de datos en salud se considera fundamental para generar valor social y económico, así como para facilitar el análisis de problemas de salud pública a gran escala (Janssen et al., 2012). Sin embargo, el valor de los datos abiertos depende en gran medida de su calidad; datos inexactos, incompletos o inconsistentes pueden llevar a decisiones incorrectas, perjudicar la investigación y la definición de políticas de salud pública. En consecuencia, la calidad de los datos abiertos de salud debe ser evaluada cuidadosamente, considerando múltiples dimensiones de calidad (Davies et al., 2019).

La implementación de machine learning y su alimentación con recursos de datos abiertos ha abierto un portal a la construcción de herramientas para el consumo de datos, establecimiento de métricas, determinación de calidad de las instancias y conjuntos de datos, así como la automatización de análisis de metadatos y disponibilidad de los recursos, el estudio realizado por Varon-Capera et al. (2018) aplica técnicas de machine learning y visual analytics para la determinación de niveles de calidad de recursos linked open data en instancias de la plataforma CKAN.




Figura 3. Diagrama de dispersión generado a partir del nivel de concordancia de las etiquetas de dominio de cada dataset perteneciente a una instancia de CKAN.

Fuente: (Varon-Capera et al. 2018).

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Es así como el uso de machine learning en la evaluación de la calidad de los datos permitiría automatizar el proceso y adaptarse a grandes volúmenes de datos de manera eficiente. Los modelos de machine learning permiten detectar problemas específicos en tiempo real, mejorando así la eficiencia en la gestión de datos abiertos de salud. Además, la adaptabilidad de los algoritmos de machine learning facilita que el modelo se ajuste a las variaciones en los datos, garantizando evaluaciones de calidad precisas y continuas (Pedregosa et al., 2011). Algunas propuestas como la realizada por Mehta et al. (2016) mediante la implementación de un framework basado en minería de datos a partir de tecnologías de machine learning, permitió el análisis de datos sociales y el proceso de empoderamiento, a través de enfoque de clasificación por proximidad semántica. Estos enfoques permiten la de extracción y análisis de datos, que permite realizar inferencias de conocimiento de datos relacionados con distintas plataformas, como por ejemplo redes sociales profesionales, twitter, entre otros.

Con este panorama, el presente documento presentará la respuesta a la pregunta formulada: **¿Cómo evaluar las dimensiones de calidad intrínseca y dinámica para los datos abiertos del sector salud en Bogotá usando técnicas de machine learning?**

4. OBJETIVOS

4.1 Objetivo General

Proponer un modelo que permita evaluar la calidad de los datos abiertos del sector salud en la ciudad de Bogotá a partir de las dimensiones intrínseca y dinámica mediante el uso de técnicas de machine learning.

4.2 Objetivos Específicos

1. Contextualizar y caracterizar el estado de los datos abiertos de salud, así como las técnicas de machine learning aplicables al modelo.
2. Diseñar un modelo con base a criterios de dimensiones de calidad de datos abiertos y técnicas de machine learning identificadas.
3. Desplegar el modelo con base en los conjuntos de datos analizados bajo una arquitectura que lo permita.
4. Verificar el modelo para evaluar la calidad a través del análisis y de la calidad de los conjuntos de datos.

5. MARCO TEÓRICO

Como parte del análisis del estado de los datos abiertos para el sector salud en el mundo, los conceptos y elementos relacionados, a continuación, se abordan algunos de los expositores que nos permitan tener un panorama del presente trabajo.

En Zamora et al. (2012) se plantean unas pautas que buscan guiar al país de Costa Rica a la liberación de datos de la salud teniendo en cuenta la importancia de tener datos disponibles para el consumo, uso y reutilización con cualquier fin. El autor afirma que “Un recurso clave para esta estrategia radica en la información gubernamental, la misma que por ley debe ser de carácter público, y por lo tanto debe ser abierta y ponerse a disposición de otros, sean para beneficio de personas u organizaciones, e incluso del mismo gobierno.” El autor logra identificar los problemas identificados en iniciativas previas de generar una plataforma de datos abiertos para el sector de la salud en el país, donde el principal problema fue la falta de confiabilidad de tener una plataforma de gestión de la información netamente virtual y con disponibilidad 24-7. Igualmente se identificaron falencias por parte de las instituciones de salud, donde no existe un proceso de recolección, limpieza y análisis de datos para ofrecer datos oportunos y precisos.

Por su parte, autores como Cleland et al. (2018) realizan un consumo de conjuntos de datos abiertos del sector de la salud en Irlanda, para abordar un tema de salud pública como es la prescripción de antidepresivos, destaca la importancia de la liberación de datos bajo las premisas datos abiertos. Los autores concluyen que “si bien este estudio se ha centrado en el uso de conjuntos de datos abiertos, la combinación de estos con datos no abiertos sobre médicos de cabecera y pacientes individuales podría permitir una exploración más granular y proporcionar más información sobre políticas”. Esto demuestra que no se están aplicando los principios de los datos abiertos definidos en La carta internacional de los datos abiertos. Open Data Charter. (2015) y que las dimensiones intrínseca y dinámica definidas por Zaveri et al.(2014) no se están cubriendo en la liberación de estos datos.

Por su parte, García-Altés et al.(2016) establecen que la transparencia en la toma de decisiones de salud pública está directamente ligada al conocimiento público de la información, ítem que se logra con los datos abiertos. La transparencia como constitución de las sociedades democráticas implica establecer normativas para la liberación de datos, en España, país donde se realiza el estudio, el autor concluye que se debe reforzar la liberación de datos y unificar los repositorios donde estos son liberados. Se identifica que no se están cubriendo las dimensiones de volatilidad y refresco en el tiempo para los conjuntos de datos consumidos en el estudio.

Mehta et al. (2016) implementan un framework de minería de datos a partir de tecnologías de machine learning, para el análisis de datos sociales y el proceso de empoderamiento, a través de enfoque de clasificación por proximidad semántica. Se estudia el trabajo de extracción y análisis de datos, que permite realizar inferencias de conocimiento de datos relacionados con distintas plataformas, como redes sociales profesionales, twitter, entre otros.

En Torres-Salinas (2020) se evidencia la importancia de los datos abiertos en las investigaciones surgidas a raíz del Virus SARS-CoV-2, las cuales han tenido una importancia significativa en políticas públicas establecidas para los intentos de control del virus y mitigación de lo que se consideró una pandemia. “los modelos más tradicionales de bases de datos se ven perjudicados ya que a veces tardan en incorporar los registros y puede que no sean lo ágiles e inmediatos que requiere un tema como el Covid-19”, indica el autor. Lo anterior evidencia una proyección pobre y banal en las sub-dimensiones de Puntualidad y Concisión, que hacen parte de los conjuntos de dimensiones intrínseca y dinámica respectivamente.

Por su parte, Arboleda et al. (2018) presentan un estado actual de los datos abiertos del sector de la salud en Colombia, indicando que “se observa que los datos publicados no tienen el nivel de representatividad deseable, lo que permite deducir que aún no se encuentran maduros los lineamientos y procedimientos que permiten la publicación de dichos datos por parte de las entidades responsables”. El autor ofrece un marco conceptual de trabajo que puede servir de referente con mirar a contar con un catálogo de datos abiertos en Salud exclusivo, que permita que los

entes territoriales avancen en el ofrecimiento de datos abiertos en salud de forma más integrada, articulando a las políticas de datos abiertos propuesta por la OMS, MINTIC y MSPS.

Autores como Ferrer-Sapena (2020) realizan un estudio interesante respecto a trabajar con datos abiertos relacionados con la coyuntura sanitaria actual, desde un punto de vista crítico y tratando de determinar el valor de las investigaciones soportadas en este tema central (Dimensión intrínseca de los datos según Zaveri et al., (2014)). El autor indica que el proyecto ha puesto de manifiesto una vez más la dificultad de trabajar con datos abiertos directamente desde fuentes oficiales. Algunos datos no están disponibles, otros no cuentan con formatos fácilmente reutilizables, y existen múltiples formas de recoger los datos, obligando a procesarlos, lo que en momentos de urgencia produce retrasos. Pero quizá el problema más relevante es la no determinación desde el inicio de la recogida de información: qué es lo que abarca cada uno de los indicadores de la muestra, y cómo y cuándo debe ser recogido.

Distintas referencias dentro de la literatura científica han identificado una serie de problemáticas relevantes el trabajar con datos abiertos en el sector de la salud, por ejemplo, a pesar de las iniciativas gubernamentales, lineamientos establecidos por expertos, normatividad generada y demás, se evidencia que en el mundo no se está adoptando correctamente la cultura de los datos abiertos para el sector. Estudios como el de Arboleda et al. (2018). Presenta un estado actual de los datos abiertos del sector de la salud en Colombia, indicando que “se observa que los datos publicados no tienen el nivel de representatividad deseable, lo que permite deducir que aún no se encuentran maduros los lineamientos y procedimientos que permiten la publicación de dichos datos por parte de las entidades responsables”. El autor ofrece un marco conceptual de trabajo que puede servir de referente con mirar a contar con un catálogo de datos abiertos en Salud exclusivo, que permita que los entes territoriales avancen en el ofrecimiento de datos abiertos en salud de forma más integrada, articulando a las políticas de datos abiertos propuesta por la OMS, MINTIC y MSPS.

Del mismo modo, Cleland *et al.* (2018) destaca la importancia de la liberación de datos bajo las premisas de los datos abiertos, donde su estudio se encontró limitado en gran parte debido a la falta de actualización de los conjuntos de datos en Irlanda. El autor especifica que para llevar a cabo la investigación se requirió de un gran esfuerzo manual en la recolección de información física en los distintos centros médicos en Dublín y desgaste humano para digitalizar dichos datos, el autor concluye que de existir una cultura madura de datos abiertos, se catapultarían los avances en políticas de salud pública.

5.1 De los Datos Abiertos de Salud en Bogotá

Existen tanto avances como desafíos en la implementación de políticas de salud pública, transparencia y acceso a la información en Bogotá D.C. Desde la creación de la plataforma de datos abiertos por parte de la Alcaldía Mayor, una parte de los datos de salud han sido puestos a disposición del público para fomentar la investigación, la innovación y la toma de decisiones informadas. Sin embargo, una revisión detallada de los conjuntos de datos de salud disponibles muestra que estos presentan problemas significativos de calidad que pueden limitar su usabilidad. En Bogotá, los datos abiertos de salud se publican principalmente a través de la plataforma de Datos Abiertos de Bogotá, donde se puede acceder a conjuntos de datos sobre temas como epidemiología, servicios hospitalarios, mortalidad, vacunas y políticas de salud pública. Estos datos están disponibles en formatos estructurados (CSV, JSON, etc.) que facilitan su procesamiento y análisis, y se han organizado para promover la accesibilidad y la reutilización.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING




Figura 4. Entidades generadoras de datos abiertos del sector salud en Bogotá.

Fuente: Autor

A su vez, existe Saludata, un observatorio de información abierta para visualizar, centralizar e informar sobre situaciones de salud en Bogotá D.C., se entiende como un portal para análisis de información asociada al sector salud, sin enfocarse en datos abiertos, enlace de datos o alguna estándar de liberación de datos, lo que permite a los ciudadanos e interesados, conocer estadísticas, proyecciones y actividades asociadas con la salud de la población Bogotana, pero no aporta a la maduración de políticas abiertas en el sector.

La figura 5 presenta un ejemplo de “casos de dengue 2024” reposada en el portal Saludata.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING




Figura 5. Infografía caos de Dengue. Fuente: portal Saludata

El presente estudio ha identificado que los problemas de calidad en los datos abiertos de salud en Bogotá se manifiestan principalmente en dimensiones como la precisión, consistencia, completitud y actualización. Estos desafíos han sido documentados en capítulos siguientes que analizan el potencial y las limitaciones de los datos abiertos en el sector salud y pueden llevar a interpretaciones erróneas, análisis distorsionados y decisiones de política pública basadas en información incompleta o incorrecta. Esto es particularmente relevante en el contexto de la salud pública, donde los datos precisos y actualizados son fundamentales para responder a emergencias y planificar la asignación de recursos.

A continuación, se aborda el marco contar con el propósito de identificar temáticas relacionadas con el área de estudio.

6. MARCO CONCEPTUAL

El constante crecimiento y cambios a los que se ha enfrentado a web, transformándola en lo que hoy es la web de los datos y considerando éstos como la base y pilar fundamental en la pirámide de la sabiduría hablaba Russell Ackoff (Rowley, 2007), nos lleva a identificar y especificar el contexto principalmente fáctico en que se desarrolla el presente estudio. Términos, tecnologías, estándares y especificaciones que se desglosan a continuación.

6.1 RDF

La estandarización de Resource Description Framework (RDF), definido como un lenguaje para representar metadatos sobre recursos web (objetos). RDF permite la interoperabilidad entre aplicaciones que intercambian información comprensible por una página web para proporcionar una infraestructura que soporte actividades de metadatos, su utilidad se destaca en situaciones donde la información necesita ser procesada por aplicaciones que intercambian información legible por máquina, más que por humanos. RDF provee un marco común de trabajo para expresar esta información y para intercambiarla entre aplicaciones distintas mediante una serie de "parsers" o analizadores RDF y otras herramientas de procesamiento automatizado Lamarca (2018).

6.2 SPARQL

El mismo crédito se otorga a SPARQL (Protocol and RDF Query Language) que es un lenguaje estandarizado para consultar grafos RDF, el cual se constituyó como una recomendación oficial por la W3C en el 2008. SPARQL provee un set completo de operaciones analíticas para sus consultas definidas directamente en la especificación (W3C-Org. 2013).

6.3 Web Semántica

Teniendo como cimientos recursos asociados a base de datos, smart apps, recursos multimedia, el diseño responsive, el comportamiento del usuario machine learning, inteligencia artificial, entre otros, se construye la Web semántica, que va más allá de disponer datos en la web. Implica establecer relaciones (relaciones de significado) que permiten darles un valor a los recursos en aras de utilizarlos por la comunidad en general para impulsar su interconexión y estructuración. La web semántica se entiende, por tanto, como una gran nube de datos enlazados. Pero para lograr esto es necesario desarrollar toda una arquitectura, compuesta por una serie de componentes y capas sobre la base de la Web (Moreno-Mejia, 2020).

6.4 Epidemiología

La Organización Mundial de la Salud define la epidemiología como el estudio de la distribución y los determinantes de estados o eventos (en particular de enfermedades) relacionados con la salud y la aplicación de esos estudios al control de enfermedades y otros problemas de salud. Hay diversos métodos para llevar a cabo investigaciones epidemiológicas: la vigilancia y los estudios descriptivos se pueden utilizar para analizar la distribución, y los estudios analíticos permiten analizar los factores determinantes. De igual forma se destaca la importancia de los datos epidemiológicos: Los datos epidemiológicos y la información operacional sobre los brotes epidémicos son aspectos dinámicos que cambian rápidamente. La OMS ha desarrollado un "sistema de gestión de eventos" para manejar la información más importante sobre los brotes y garantizar la precisión y oportunidad de las comunicaciones entre profesionales clave de la salud pública internacional, incluidas oficinas regionales de la OMS, oficinas de país, centros colaboradores y asociados de la Red Mundial de Alerta y Respuesta ante Brotes Epidémicos (GOARN).

A continuación, se enumeran los principales componentes del sistema de gestión de eventos, definidos por la OMS:

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

- Bases de datos integrales con información de salud, la situación de la verificación y las investigaciones de laboratorio y con datos operacionales.
- Seguimiento y registro de la evolución de brotes de virus, enfermedades, las decisiones críticas, las medidas más importantes adoptadas por organismos como la OMS y sus asociados, y los documentos clave.
- Gestión del apoyo logístico y el equipo, material y suministros especializados empleados en la respuesta.
- Base de datos integrada sobre las aptitudes técnicas, la experiencia y la disponibilidad de expertos internacionales para los equipos de respuesta.
- Productos de información normalizados para los Estados Miembros, los funcionarios de salud pública, los medios de información y el público.
- Comunicación con la Red Mundial de Alerta y Respuesta ante Brotes Epidémicos para fomentar la disponibilidad operacional.

6.5 Datos abiertos

Según Open Knowledge Foundation (2012), son datos en presentación digital, los cuales son liberados bajo principios que abarcan técnico y jurídico para uso, reutilización y redistribución de forma libre en cualquier escenario para cualquier fin.

A su vez los datos abiertos se enfocan en el uso, reutilización y redistribución de los datos, por lo tanto, estos datos deben estar disponibles y deben ser de dominio público o tener condiciones de licenciamiento que permitan al usuario utilizar los datos cómo lo desee sin restricciones. Bikakis (2013). Berners Lee (2009) define un esquema de cinco estrellas que permite categorizar los datos con base una serie de condiciones que se puede representar de la siguiente manera:

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

NIVEL	CONDICIÓN DE CUMPLIMIENTO
1 Estrella	Poner a disposición los datos en la web en cualquier formato y bajo una licencia abierta.
2 Estrellas	Publicar los datos estructurados en formatos legibles por máquina. Por ejemplo, una tabla de datos en formato Excel.
3 Estrellas	Publicar los datos además en formatos no propietarios. Por ejemplo datos en formato CSV (Comma Separated Values).
4 Estrellas	Publicar los datos a través de estándares abiertos de W3C (RDF y SPARQL) para identificarlos, lo que hace posible que los datos sean enlazados.
5 Estrellas	Agregar metadada de vinculación para estos datos con otros conjuntos de datos.

Tabla 1. Esquema de cinco estrellas de los datos. Berners-Lee, et al. (2009)

Los esfuerzos por establecer un estándar para la liberación de datos y un conjunto de buenas prácticas para dicho proceso, se remontan al año 2007 donde la sunlight Foundation establece una serie de principios para considerar los datos abiertos: deben ser completos, primarios, oportunos, accesibles, producibles por máquinas, de acceso inclusivo, no deben estar contenidos en formatos propietarios, publicados bajo licencias libres, deben mantenerse con el tiempo y deben ser gratuitos (The-Sunlight-foundation, 2007).

Estos principios se avalan por organizaciones como la w3c y convenciones como SAGA. Posteriormente en 2009 Reino Unido lanza su primer portal de datos *data.gov.uk* bajo acuerdos sostenidos con Estados Unidos, esto conlleva a la Comisión Europea a la definición del Open Data Package en 2011 en la plataforma TWX LOGD Linking Open Government Data y en 2015 finalmente se lanza la Open

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Data Charter (Central De Datos Abiertos) bajo el amparo de 17 países y 34 Gobiernos Regionales en conjunto con expertos buscando establecer los lineamientos gubernamentales para la liberación de datos.

Esta liberación de datos abiertos se realiza a través de un portal o repositorio central, que es el sistema que gestiona el catálogo de datos abiertos. El flujo es el siguiente:

- El portal recibe datos gubernamentales seleccionados.
- Los datos son catalogados conservando aspectos de calidad de cinco estrellas definido en la Tabla 1.
- Los datos son transformados a una estructura que el sistema esté en capacidad de interpretar.
- Se publican cumpliendo con el estándar definido para su consumo tanto a nivel web como para ser descargados (The Sunlight foundation, 2007).

Para ejecutar el flujo de forma correcta, la ODC establece 6 principios de los datos abiertos, enmarcados en la carta internacional de los datos abiertos, los cuáles se describen en la Tabla 2:

Principio	Descripción
Datos deben ser abiertos por defecto	Elimina la interacción interesado - funcionario, permitiendo que haya disponibilidad de los datos para todos. Tanto sectores público y privado como la sociedad en general deben cobijarse y acatar legislación y estándares para los datos abiertos.
Datos deben ser oportunos y exhaustivos	La publicación de los datos debe realizarse de forma eficiente y completa, con completa se hace referencia a que los datos deben ser desagregados a niveles de descripción por categorías así como el aseguramiento de que tales datos hacen parte de un ciclo de vida de gestión de la información.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Datos deben ser accesibles y utilizables	En primera instancia está el licenciamiento, los datos deben contener una licencia abierta como por ejemplo las creative commons, también deben contar con formatos abiertos y legibles, que se puedan acceder fácilmente desde personas hasta máquinas.
Datos deben ser comparables e interoperables	Busca aumentar la riqueza de los datos, que se obtiene a partir de estándares de datos para que incluyan en sus metadatos la suficiente descripción para su respectivo análisis. Entre más transparente y fácil sea su “comunicación” más valor tienen.
Deben mejorar la gobernanza y la participación ciudadana	Hacer más transparente la trazabilidad de la gestión pública y política, optimizando procesos de rendición de cuentas y de construcción de políticas de acuerdo con las necesidades y exigencia de las comunidades. De igual forma busca empoderar más a las comunidades en la gestión de la administración pública y control a sus procesos respetando la libertad de expresión.
Deben promover el desarrollo inclusivo y la innovación	Maximizar la liberación de los datos por entes públicos y privados buscando beneficiar a la sociedad en general mediante la creación de asociaciones que incentiven esta liberación y de esta forma impulsar y visibilizar el desarrollo de todos los sectores, sobre todo los que están en crecimiento o atacan problemáticas actuales, como la salubridad o el cambio climático.

Tabla 2. Principios de los datos abiertos definidos en la carta internacional de los datos abiertos. (Open Data Charter, 2015)

6.6 Calidad de los datos

Se entiende la calidad de los datos la definición del concepto otorgado por la norma ISO-9000-2000: "el grado en el que un conjunto de características inherentes cumple con los requisitos, esto es, con la necesidad o expectativa establecida, generalmente implícita u obligatoria". Alderete al., (2014), afirma que existen muchas definiciones de lo que implica que ciertos datos sean de calidad. Algunas de ellas son:

1. Grado de excelencia mostrado por los datos en relación con la representación del escenario real.
2. El estado de completitud, validez, consistencia, atemporalidad y exactitud que hace a los datos apropiados para un uso específico.
3. Los procesos y tecnologías involucradas para garantizar la conformidad de los valores de los datos a los valores del negocio y a criterios de aceptación.

6.7 Dimensiones de calidad

Zaveri et al. (2014) clasifica los datos abiertos y enlazados en 6 dimensiones, 23 subdimensiones y una serie de métricas que permiten determinar un valor para cada una, nos centraremos en las dimensiones que están resaltadas en la figura 6:




Figura 6. Clasificación de las dimensiones de calidad de los datos. Fuente: (Zaveri et al., 2014)

Existe una necesidad de analizar las dimensiones intrínseca y dinámica debido al declive que presenta la web semántica en la medida que, para los datos abiertos y enlazados se diseñan modelos de datos particulares sin utilizar estándares que los enriquezcan, perdiendo valor en los subdominios relacionados con su representación correcta y compacta sobre el mundo real y si la información es lógicamente coherente en sí misma.

6.7.1 Dimensión intrínseca

La dimensión intrínseca es aquella que es independiente del contexto del usuario. Hay tres dimensiones que forman parte de este grupo, que son precisión, consistencia y concisión. Estas dimensiones se centran en si la información representa correctamente y de forma compacta los datos del mundo real y si la información es lógicamente coherente en sí misma.

6.7.1.1 Concisión

Zaveri et al. (2014) define un conjunto de datos es conciso si no contiene atributos redundantes (dos atributos equivalentes con nombres diferentes). Por lo tanto, la concisión intencional mide el número de propiedades únicas de un conjunto de datos en relación con el número total de propiedades de un esquema de destino. En el nivel de datos (instancia) (extensional), Bizer et al. (2014) define "un conjunto de datos es conciso si no contiene objetos redundantes (dos objetos equivalentes con identificadores diferentes)". Por lo tanto, la concisión de extensión mide el número de objetos únicos en relación con el número total de objetos del conjunto de datos.

6.7.1.2 Precisión

La precisión se define como la medida en que los datos son correctos, es decir, el grado en que representan correctamente los hechos del mundo real y también está libre de errores de sintaxis. La precisión se clasifica en (i) precisión sintáctica, que se refiere al grado en que los valores de datos están cerca de su correspondiente dominio de definición y (ii) la precisión semántica, que hace referencia al grado en

que los valores de datos representan la corrección de los valores a los valores reales del mundo real.

6.7.1.3 Coherencia

Bizer et al. (2014) define la coherencia como "sin contradicciones en los datos". o "un conjunto de datos es coherente si está libre de información en conflicto". La coherencia significa que una base de conocimientos está libre de contradicciones (lógicas/formales) con respecto a mecanismos particulares de representación e inferencia de conocimientos.

6.7.2 Dimensión dinámica

Aspectos importantes de la dimensión dinámica de los datos son:

- Su frescura a lo largo del tiempo.
- La frecuencia de cambio a lo largo del tiempo
- Su frescura a lo largo del tiempo para una tarea específica.

Estos tres aspectos se capturan mediante las dimensiones de dinámica del conjunto de datos: *valor*, *volatilidad* y *escala temporal*.

6.7.2.1 Actualidad

definido por Bizer et al. (2014) como "la distancia entre la fecha de entrada desde el gráfico de procedencia hasta la fecha actual". Aunque llamaron a esta escala de tiempo de dimensión, se refiere al valor como se puede ver en las definiciones. Se podría definir como "el grado en que la información está actualizada" Zaveri et al.(2014) definió la dimensión de escala temporal como "la actualidad de los datos proporcionados por una fuente". El valor mide la rapidez con la que se actualizan los datos.

6.7.2.2 Volatilidad

La volatilidad se refiere a la frecuencia con la que los datos varían en el tiempo. La volatilidad se puede medir como el período de tiempo durante el cual los datos siguen siendo válidos. La volatilidad necesita dos componentes: (i) el tiempo de expiración (el momento en que los datos se vuelven inválidos) y (ii) el tiempo de entrada (el momento en que se emitieron los datos por primera vez). Ambos componentes se combinan para medir la distancia entre el tiempo de expiración y el tiempo de entrada de los datos publicados para obtener el intervalo de tiempo en el que la información sigue siendo válida. Zaveri et al. (2014)

6.7.2.3 Puntualidad

Zaveri et al. (2014) definió la puntualidad como "una medida de utilidad es una comparación de la fecha en que se actualizó la anotación con el requisito del consumidor". La puntualidad mide qué tan actualizados están los datos, en relación con una tarea específica.

6.8 Machine learning

Ahora bien, Machine learning es un método de análisis de datos que automatiza la construcción de modelos analíticos. Es una rama de la inteligencia artificial basada en la idea de que los sistemas pueden aprender de los datos, identificar patrones y tomar decisiones con una mínima intervención humana (Gaitho, 2020). Machine learning permite a los modelos entrenar con conjuntos de datos antes de ser implementados. machine learning no es un proceso sencillo. Conforme el algoritmo ingiere datos de entrenamiento, es posible producir modelos más precisos basados en datos. Un modelo de machine learning es la salida de información que se genera cuando entrena su algoritmo de machine learning con datos. Después del entrenamiento, al proporcionar un modelo con una entrada, se le dará una salida. Por

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

ejemplo, un algoritmo predictivo creará un modelo predictivo. A continuación, cuando proporcione el modelo predictivo con datos, recibirá un pronóstico basado en los datos que entrenaron al modelo (IBM, 2018). Debido a su complejidad y tamaño, estos patrones y asociaciones podrían haber sido fácilmente pasados por alto por la observación humana.

7. METODOLOGÍA

La metodología llevada a cabo para el presente trabajo está soportada en un diseño cuasi experimental, considerando que se establece como objeto de estudio los datos abiertos del sector salud en la ciudad de Bogotá y como recursos base se tienen conjuntos de datos provenientes de los distintos repositorios de organismos gubernamentales del sector salud encargados de la liberación y apertura de estos datos. Para llevar a cabo el desarrollo del estudio, se tomó como referencia la definición de metodología de 6 fases, ajustándola de acuerdo con las necesidades específicas del presente estudio a partir de la metodología Analytics Solutions Unified Method for Data Mining/predictive analytics, diseñada para realizar implementaciones ágiles en temas de analítica de datos y minería de datos, propuesto por IBM Corporation(2016) con un enfoque sistemático basado en técnicas de aprendizaje automático, siguiendo un proceso que incluye recolección, preprocesamiento, selección del modelo, evaluación, implementación, obtención de resultados - retroalimentación.

A continuación, se presentan las fases del proyecto junto a los pasos a seguir en cada una de estas.




Figura 7. Metodología - Adaptación metodología ASUM. Fuente: Autor

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

La metodología proporciona una estructura clara y modular para abordar proyectos de analítica avanzada, integrando aspectos tanto técnicos como estratégicos, garantizando que cada fase definida contribuya de manera coherente al objetivo principal del estudio: Proponer un modelo que permita evaluar la calidad de los datos abiertos del sector salud en la ciudad de Bogotá, en este caso, se adapta a las necesidades específicas de un modelo que evalúa las dimensiones intrínseca y dinámica. Este capítulo describe el proceso de implementación de la metodología **ASUM (Analytics Solutions Unified Method)** para el desarrollo de un modelo de machine learning en mención. A continuación, la imagen 3 presenta una infografía que permite identificar las fases de construcción del modelo con las fases relevantes para su habilitación.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING





Figura 8. Infografía fases de construcción del modelo. Fuente: Autor

7.1 Recopilación de los datos

Existen distintos tipos de repositorios liberados por entes gubernamentales, iniciativas internacionales, ONG y otros actores interesados en la liberación de datos, la principal motivación de los stakeholders para apoyar la madurez de los datos abiertos en el mundo, de acuerdo con lo que mencionan Weiskopf et. al, (2013), los datos son la base para la toma de decisiones estratégicas. En este estudio, se recopilaban datos para 2 objetivos específicos:

1. Entrenar el modelo de acuerdo con las condiciones iniciales planteadas
 2. Someter a evaluación el objeto de estudio mediante un modelo maduro y robusto para su fin.
- Para el objetivo número 1 (entrenamiento): los datos fueron recolectados de Open NY, repositorio central de datos abiertos del estado de New York, que de acuerdo con su definición *“es una iniciativa galardonada de políticas, programas y herramientas que brindan acceso público a datos digitales para la colaboración y el análisis. Empoderando al público y al gobierno con datos para la era digital.”* Open NY (2024), abarcando información sobre educación, salud, transporte energía y ambiente, gobierno y finanzas, entre otros. Se elige este conjunto de datos ya que existe una gran cantidad de conjuntos de datos, constantemente actualizados y maduros en el dominio de salud.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING



343 Results filtered by Categories > Health View Types > Datasets Clear All Sort by Most Accessed

Current Active Clinical Trials - Roswell Park Cancer Institute Dataset
Health
List of active studies submitted by Roswell Park Cancer Institute (RPCI) to National Cancer Institute (NCI) annually as part of the Cancer Center Report Grant reporting. It includes the primary site, More
Updated April 18, 2024 Views 8,357
Tags cancer study, nci, rpci API Docs
Publications from Roswell Park Cancer Institute: 2006-2021 Dataset
Health
List of existing publications from Roswell Park Cancer Institute authors, including: year published; publication type and title; journal name, volume, issue and page range; author list; ISSN; and peer More
Updated June 26, 2024 Views 6,214
Tags medical publications API Docs
US Patents Issued to Health Research Inc on Behalf of Roswell Park Cancer Institute Dataset
Health

Figura 9. Conjunto de datos de salud en New York. Origen: Open NY.

Se seleccionaron los datos del dominio salud (health en su idioma original, inglés) buscando garantizar la representatividad de los diferentes tipos de entidades de salud (públicas y privadas), así como los diversos orígenes y tipos de datos, obteniendo un total de 667 recursos de los cuales 343 fueron conjuntos de datos. De acuerdo con lo sugerido por Goddard, et. al, (2017), los datos que contenían nombres de personas fueron anonimizados antes de ser procesados para preservar la confidencialidad, garantizando que no se pudieran identificar directamente en los recursos que contenían descripción alguna de este tipo.

Para el objetivo número 2 (evaluación): se realizó un análisis inicial de los conjuntos de datos proporcionados por la plataforma de Datos Abiertos de Bogotá (objeto del estudio), en la cual se obtuvieron 37 conjuntos de datos asociados al dominio “salud y protección social” definidos por la plataforma, los conjuntos de datos han sido descargados utilizando las tecnologías de la plataforma CKAN: una plataforma de código abierto desarrollada para facilitar la gestión, publicación y distribución de datos abiertos en múltiples formatos. Fue creada inicialmente por la Open Knowledge Foundation y se ha convertido en una herramienta popular para portales de datos

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

abiertos de gobiernos y organizaciones alrededor del mundo debido a su flexibilidad y personalización (Janssen et al., 2012), en este caso se descargan y agrupan los conjuntos de datos para su posterior evaluación.



Figura 10. Plataforma Datos Abiertos Bogotá, cantidad conjuntos de datos del dominio salud.

7.2 Comprensión de los Datos

Por medio del análisis exploratorio de los datos se logra identificar los tipos de datos, la distribución y los valores atípicos que puedan incidir en las etapas posteriores del modelo: entrenamiento y evaluación; tipos de datos y patrones de datos (ej: cualitativo, cuantitativo). Para este proyecto de trabajo, se seleccionan de los conjuntos de datos de la categoría de Salud, obtenidos de la plataforma de Datos Abiertos de Bogotá, los conjuntos de datos relacionados a los servicios hospitalarios, registro de eventos clínicos, brotes epidémicos, estadísticas de morbilidad, nacimientos y muertes, entre otros.

7.2.1 descripción de los conjuntos de datos:

Se identifican 3 principales grupos de conjuntos de datos:

1. Estadísticas de Salud Pública y epidemiología:

- Casos confirmados de COVID-19: datos acerca de la evolución de los contagios confirmados del virus Covid-19 presentados en la ciudad.
- Tasa de mortalidad en menores de 5 años en la ciudad: Frecuencia de muertes de niños menores de 5 años muertes en un año determinado por cada 1.000 nacidos vivos.
- Tasa de mortalidad perinatal: Magnitud y distribución de la mortalidad perinatal, porcentaje de neonatos muertos por cada 1000 nacidos vivos del total de la mortalidad infantil y neonatal de las ciudades que refleja la calidad de atención prenatal, parto y postparto.
- Razón de mortalidad materna se refiere a la razón de muertes maternas por 100.000 nacidos vivos informadas en Bogotá.
- Tasa de suicidio: se refiere al número de muertes sobre suicidio detectados en la ciudad según el área de residencia, por 100.000 habitantes.
- Incidencia de sífilis congénita: se refiere a la incidencia de casos confirmados de sífilis congénita por 1.000 nacidos vivos más muertes fetales.
- Eventos notificados de ESI-IRAG en temporada de lluvias: Se refiere al número de notificaciones por Enfermedad Similar a Influenza e Infección Respiratoria Aguda Grave informadas en los meses de lluvia.
- Tasa específica de fecundidad de mujeres de 10 a 14 y 15 a 19 años: número anual de nacimientos en mujeres de 10 a 14 y 15 a 19 años por cada 1.000 mujeres en este grupo de edad.
- Proporción de bajo peso al nacer: Proporción de recién nacidos vivos en Bogotá con peso al nacer inferior a 2.499 gramos.
- Tasa de mortalidad por diabetes mellitus en menores de 70 años: las muertes debidas a diabetes en menores de 70 años se estiman en una tasa.
- Pirámide poblacional 2005, 2018 y 2021: datos por edad de la población en oferta en Bogotá D.C. en los años 2005, 2018 y 2021.

2. Servicios de Salud:

- Llamadas de Urgencias y Emergencias que ingresan a través de la línea 123: Información sobre las llamadas de urgencias y emergencias clasificadas como llamadas de emergencia tipificadas.
- Afiliación según régimen de aseguramiento SGSS: Seguimiento a la dinámica de los trabajadores respecto al aseguramiento en salud en el Distrito, en los regímenes contributivo, subsidiado, especiales y de excepción.
- Afiliación a Aseguradoras de Riesgos Profesionales: Población laboral dependiente e independiente afiliada a Aseguradoras de Riesgos Profesionales en el Distrito Capital.
- Conceptos sanitarios emitidos y medidas de seguridad aplicadas a establecimientos: Resultados de verificación sanitaria de los establecimientos en el marco de las visitas de Inspección, Vigilancia y Control.
- Nacimientos según tipo y sitio del parto: Proporción de partos atendidos según tipo y sitio de ocurrencia (institución de salud, domicilio, otro).
- Servicios de Urgencias y Ambulancias: Información sobre prestadores con servicios de urgencias y/o de transporte asistencial básico y medicalizado.
- IPS habilitadas con oferta de servicios quirúrgicos de cirugía estética: Lista de Instituciones Prestadoras de Salud habilitadas con oferta de servicios quirúrgicos de cirugía estética.
- Entidades prestadoras de salud: Organizaciones de carácter público o privado que tienen por objeto la afiliación de los usuarios y la administración de la prestación de los servicios de las instituciones.
- Instituciones Prestadoras de Salud: Entidades, asociaciones y/o personas públicas, privadas o con economía mixta habilitadas para prestar procedimientos de salud.
- Puntos de Vacunación contra Fiebre Amarilla: Información de los puntos de vacunación para población viajera en Bogotá contra la fiebre amarilla, competencia de la Alcaldía Mayor de Bogotá y adscritas a la Secretaría Distrital de Salud.

- Consultorios Médicos: Espacios físicos habilitados por la Secretaría Distrital de Salud destinados para la prestación de servicios médicos cumpliendo su respectiva reglamentación.

3. Programas y Coberturas de Salud:

- Cobertura de vacunación: Número de menores de un año vacunados con Pentavalente, y número de niños de 1 año y 5 años vacunados con Triple Viral, residentes en Bogotá D.C. en un periodo determinado.
- Espacios libres de humo: Medición del grado de incumplimiento de los espacios libres de humo en los establecimientos abiertos al público en el Distrito.
- Consumo de Sustancias Psicoactivas (SPA): Información sobre el consumo de sustancias que, introducidas en el organismo por cualquier vía de administración, producen una alteración del funcionamiento del sistema nervioso central.

7.2.2 Comprensión de la composición de los datos:

Para los conjuntos de datos del objeto de estudio, se realizó un análisis de sus variables sus variables y atributos principales. Esta etapa incluyó una revisión de:

- Tipos de datos: Los atributos de edad, periodos, año de publicación o actualización se consideran variables discretas ya que representan un valor numérico asociado a un instante de tiempo.
- Metadatos: Los conjuntos de datos poseen descripciones sintácticas de las variables que la componen, así como los enlaces a sus datos en crudo o a recursos enlazados si es el caso.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Forma de presentación	Tabla Digital
Frecuencia de Actualización	Anual
Palabras claves	SERVICIOS DE SALUD , Salud Bogotá , Salud y Protección Social , Secretaria de Salud , salud
Enlace a otros recursos	https://saludata.saludcapital.gov.co/osb/
Fecha creación del metadato	2019-06-12
Fecha actualización metadato	2024-10-24
Categoría Temática	Salud
Idioma	Espanol
Alcance de la calidad de los datos	Conjunto de datos
Reporte de la calidad	El producto cumple con la calidad de los datos de acuerdo al Observatorio de Salud - Secretaría Distrital de Salud de Bogotá D.C.
Distribuidor	Secretaría Distrital de Salud
Alcance del metadato	Conjunto de datos
Tipo de Responsable	Autor
Responsable del Metadato	Secretaría Distrital de Salud
Link a servicio XML	/metadata/dataset?id=2b8464e3-3aca-4dcd-91a1-93dd06ddabbb

Figura 11. Estructura metadatos para datasets del sector salud. Fuente: Datos Abiertos Bogota

- Rango de valores: Se examinaron los valores mínimos, máximos de cada variable para identificar qué posible tratamiento dar a los valores fuera de rango (outliers) o valores atípicos que pudiesen afectar la consistencia del modelo, de acuerdo al análisis realizado se evidencia la necesidad de normalización de datos.

7.2.3 Identificación de Problemas de Calidad de Datos

Durante la exploración, se identificaron varios problemas de calidad comunes que afectan la confiabilidad de los datos. Los problemas más destacados incluyen:

- Valores nulos y ausentes: Un total de 103 datasets presentaron valores nulos en variables esenciales, como fecha de consulta, causa de defunción o código

de enfermedad. La presencia de datos nulos limita el análisis y afecta la representatividad de los resultados (Batini y Scannapieco, 2016).

- Datos inconsistentes: Se detectaron registros en 78 datasets con inconsistencias en los formatos de fecha y en los nombres de las variables categóricas (por ejemplo, variaciones en la nomenclatura de enfermedades o diagnósticos médicos), lo cual dificulta el análisis automatizado y puede impactar negativamente la precisión del modelo.
- Datos duplicados: En 32 de los datasets, se encontraron duplicados en campos como, por ejemplo, el identificador del paciente, lo que sugiere posibles errores en el proceso de captura de datos. Como indica Kim et al., (2002), la duplicación de datos puede llevar a resultados distorsionados y requiere de estrategias para su eliminación o tratamiento.
- Datos desactualizados: Este punto se consideró el más crítico ya que los metadatos de 114 de los datasets permitían evidenciar que no han sido actualizados recientemente, lo que afecta la actualidad de los datos y limita su uso en la toma de decisiones actuales.

7.3 Preparación de los Datos

Como se sugiere en las secciones previas, la ejecución de las actividades para preparar los datos abiertos del sector salud de Bogotá se considera un paso relevante teniendo en cuenta que las dimensiones intrínseca y dinámica de los datos requieren validaciones sintácticas y semánticas sobre los datos. De la misma manera, los conjuntos de datos seleccionados para el entrenamiento del modelo deben tratarse con los procesos definidos para tratar los problemas de limpieza, transformación, imputación de valores y escalabilidad. Básicamente,

estos procesos son necesarios para que haya un mínimo de errores y a fin de mantener el mayor nivel de exactitud y fiabilidad del modelo.

7.3.1 Limpieza de Datos

Durante el inicio del proceso de preparación de los datos para el prototipo, se procedió con la limpieza. La limpieza incluye todos los pasos que son necesarios para dirigir los atributos y definir qué información genera valor al modelo y se requiere para entrenamiento y análisis. La limpieza de los datos incluye la imputación de los valores necesarios y escalado. Además, incluye la resolución de problemas como valores nulos, datos duplicados, y valores inconsistentes. La fase de limpieza de datos fue importante dado que existía una gran variabilidad en los formatos de los registros, lo que lleva a posibles inconsistencias.

7.3.2 Tratamiento de Valores Nulos

La presencia de valores nulos indica información faltante en registros importantes, lo que afecta la precisión del modelo Batini et. al,(2016). En este análisis se detectaron campos en blanco en aspectos clave como fecha de consulta y actualización, diagnóstico y tipo de servicio, que son cruciales para el entrenamiento del modelo. Para manejar estos valores faltantes, se aplicó la siguiente estrategia compuestas por los siguientes procesos:

- Eliminación de registros incompletos: Cuando la proporción de registros con valores nulos en el total de datos es muy baja es viable eliminar estos registros.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

- Imputación de valores: Para variables donde los valores nulos superaban un porcentaje significativo, se utilizó la imputación de valores. En variables categóricas, como el tipo de servicio, se empleó la moda como valor imputado, mientras que para variables numéricas se optó por la media o mediana, de acuerdo con la distribución de los datos sugerida por Little et. al,(2002).
- Detección y Eliminación de Datos Duplicados: Los datos duplicados en registros de consultas y servicios de salud pueden ser resultado de errores de entrada y problemas con la consolidación de datos. Los duplicados pueden inducir sesgo en el modelo del sistema, lo que afectará los análisis de precisión y de puntualidad de los servicios. Combinando técnicas de coincidencia de registros como indica Christen, et. al,(2012) y algoritmos para detectar duplicación a través de claves tales como el nombre del paciente, fecha de consulta, y tipo de servicio, los registros duplicados fueron identificados y eliminados para eliminar la posibilidad de resultados distorsionados.

La figura 12 muestra el script utilizado para llevar a cabo las estrategias de preparación de datos previamente mencionadas:

```
import pandas as pd
import numpy as np
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler, LabelEncoder

df = pd.read_csv('datos_entrenamiento.csv')

columns_to_drop = ['ID', 'county', 'latitude', 'longitude']
df.drop(columns=columns_to_drop, inplace=True, errors='ignore')
df.drop_duplicates(inplace=True)

num_imputer = SimpleImputer(strategy='mean')
cat_imputer = SimpleImputer(strategy='most_frequent')

for column in df.select_dtypes(include=['float64', 'int64']).columns:
    df[column] = num_imputer.fit_transform(df[[column]])

for column in df.select_dtypes(include=['object']).columns:
    df[column] = cat_imputer.fit_transform(df[[column]])
```

Figura 12. Código desarrollado para preparación de los datos. Fuente: Autor

8 MODELO PROPUESTO

En el contexto del presente trabajo, los procedimientos para implementar el modelo se organizaron de tal forma que fuera compatible con el objeto de estudio: diseño, entrenamiento y pruebas de modelos que proporcionaron resultados sobre la calidad de los datos de salud abiertos en Bogotá D.C. Las siguientes secciones dan un nivel de detalle fino sobre las decisiones de algoritmos, infraestructura tecnológica subyacente y procedimientos relacionados con la implementación del modelo, los procedimientos de entrenamiento, ingesta de datos y los pasos para evaluar el nivel de calidad en las dimensiones seleccionadas, tal como se presenta en figura 13.




Figura 13. Arquitectura de referencia para Modelo de Machine Learning. Fuente: AWS (2022)

8.3.1 Selección de algoritmo

De acuerdo con la misma naturaleza de los datos que se evaluarán, el algoritmo a utilizar para la implementación de modelo de machine learning con el propósito de identificar el nivel de calidad en los datos de salud, debe cumplir con varios asociados con: la naturaleza del problema, la naturaleza de los datos, la necesidad de interpretabilidad y la disponibilidad de recursos. Algunos modelos como la regresión logística o los árboles de decisión se prestan bien a la interpretabilidad y serían más adecuados en tales escenarios Breiman et.al,(2001), las capacidades de los algoritmos proveen suficiente capacidad con conjuntos de datos más pequeños. Por otro lado, las redes neuronales profundas generalmente suelen implementarse en los modelos deben estar capacitados para abordar problemas complicados con una cantidad significativa de datos. Otra ventaja es la interpretabilidad del modelo, algunos modelos como los árboles de decisión o las Máquinas de soporte vectorial SVM Cortes, et. al,(1995) con kernel lineal tienen un alto ratio de datos, mientras que Redes neuronales profundas o modelos de ensamble suelen considerarse modelos de caja negra. Con base en lo mencionado, se realizó un análisis de los siguientes algoritmos:

8.3.1.1 *Regresión logística:*

Es uno de los modelos más simples y ampliamente utilizados para problemas de clasificación binaria. Fácil de interpretar y de bajo recurso, por lo que es útil para problemas en los que se valora la simplicidad y la transparencia Mehta et. al, (2016).

8.3.1.2 *Árboles de decisión y Random Forest:*

Los árboles de decisión son populares debido a su capacidad para manejar datos no lineales y por su interpretabilidad. Random Forest es un algoritmo que utiliza múltiples árboles de decisión para mejorar la precisión e impedir el sobreajuste, enfoque útil

para pronosticar de riesgo de eventos epidemiológicos de alta escala y pronósticos basados en información histórica. El algoritmo Random Forest es una combinación de múltiples árboles de decisión, y cada árbol se construye utilizando una muestra aleatoria del conjunto de datos, mientras que los nodos se dividen utilizando el mejor subconjunto de características en cada paso. Esto introduce una aleatoriedad que reduce el riesgo de sobreajuste y mejora la capacidad de generalización del modelo Breiman et. al,(2001).

8.3.1.3 XGBoost (eXtreme Gradient Boosting)

Este algoritmo principalmente se utiliza en escenarios donde se requiere procesar gran cantidad de información gracias a su capacidad de escalamiento, es un método de aprendizaje que combina técnicas de regularización para disminuir el sobreajuste y métodos de búsqueda exactos y aproximados sobre la selección de las divisiones de los árboles de predicción. Igualmente, la capacidad de optimizarlo para correr en paralelo en múltiples núcleos y GPU lo ha convertido en la herramienta de aprendizaje preferida para determinadas tareas de biología computacional y en general para tareas que requieren modelos de alta calidad en tareas muy precisas. Chen et. al,(2016).

8.3.1.4 Máquinas de soporte vectorial (svm)

Algoritmo desarrollado por Vapnik et al. (1999) y sus colaboradores en el marco de la Teoría de Aprendizaje Estadístico (SLT). Son entrenadas por algoritmos de optimización convexa (existe una única solución) y construidas a partir de una estructura que depende de un subconjunto de Vectores Soporte (VS), que ayudan a la interpretación del modelo. Este algoritmo puede ser considerado una extensión del algoritmo “perceptrón”. En SVM el objetivo de la optimización es establecer una línea de decisión que separe las clases maximizando el margen entre esta línea y los puntos de muestreo cercanos a este hiperplano. Estos puntos se llaman vectores soporte.

8.3.1.5 *Decisión de algoritmo a implementar*

El algoritmo que se implementó en el modelo es *Random Forest*, teniendo en cuenta la necesidad de interpretabilidad y que, en el contexto de calidad de datos, es común encontrar valores faltantes, inconsistencias o datos ruidosos, Random Forest maneja bien estos escenarios porque cada árbol del conjunto aprende a partir de una muestra aleatoria de los datos. Esto reduce el impacto que pueden ocasionar las inconsistencias en la información insumo afectando el resultado final. Los datos de calidad, incluida la precisión, la consistencia, la coherencia, la volatilidad, etc., pueden provenir de diferentes fuentes y tener características diferentes. Random Forest es adecuado para conjuntos de datos dispersos, ya que no se ocupan de las suposiciones específicas sobre la distribución de las variables.

De igual manera Random Forest crea múltiples árboles de decisión usando diferentes subconjuntos de datos y características. Al combinar sus resultados, reduce la probabilidad de sobreajuste, un problema común en árboles de decisión individuales. Una de las principales ventajas del algoritmo es su interpretación: aunque no es tan interpretable como un único árbol de decisión, Random Forest permite medir la importancia de las características. Esta característica es de gran importancia para el estudio llevado a cabo ya que permitió identificar puede ser útil para identificar cuáles métricas de calidad de datos tienen mayor impacto en la calidad general del conjunto de datos. Su eficiencia para manejar conjuntos de datos grandes teniendo en cuenta que cada árbol se entrena sobre una muestra con reemplazo (bootstrapping) del conjunto de datos. Este enfoque genera diversidad entre los árboles, lo que mejora la generalización del modelo en datos no identificados. De igual manera se experimentó con árboles de decisión y XGboost como métodos complementarios en las pruebas de comparación de rendimiento.

8.3.2 Selección de Características

La selección de características correspondió a la reducción del número de métricas y el mejoramiento del desempeño general, al aumentar la precisión y la remoción de métricas poco útiles. La relevancia de las características se evaluó de acuerdo con las siguientes métricas:

- importancia de las características: De gran importancia, mide la contribución de cada métrica a la calidad (precisión, coherencia, actualidad, volatilidad y la puntualidad en el modelo). Según menciona Breiman et.al,(2001), la importancia de la característica seleccionada para aplicar al algoritmo Random Forest se obtiene al medir cómo disminuye el error cuando se divide un nodo en la característica que se pretende medir.
- Análisis de correlación: Guyon et. al, (2003) establece que “el análisis de correlación sirve para evitar redundancia. Las características que tengan un alto índice de correlación se miden”. Aplicar análisis de correlación al modelo permitió eliminar la redundancia de ciertas variables entre los conjuntos de datos de entrada, es decir, que si una variable en particular se definió como insumo, las otras variables relacionadas no proporcionaron información redundante al modelo.

8.3.3 Entrenamiento del modelo:

Este capítulo describe el proceso de entrenamiento de este modelo. Para garantizar la solidez y estabilidad del modelo, se utilizaron técnicas de preprocesamiento sugeridas por Goodfellow et. al, (2016), selección de hiperparámetros y validación cruzada y finalmente se ajusta y entrena el modelo para un conjunto de datos de entrenamiento y validación.

8.3.3.1 División de datos

El entrenamiento del modelo se realizó bajo un conjunto de datos dividido: aproximadamente el 90% fueron utilizados para el proceso de formación (100% proviene de Open Data NY: 373 Datasets), mientras que el 20% restante se utilizó para la prueba, (100% restante proviene de Datos Abiertos Bogotá: 37 Datasets), siguiendo las buenas prácticas de machine learning listadas por Kohavi, et.al,(1995). Este factor sirve para garantizar que en el primer paso, el modelo identifica un subconjunto de todos los datos y, en la segunda etapa valida con un subconjunto que no se ha interactuado previamente, en relación con establecer una medición de su capacidad de generalización.

Se estableció un pre-procesamiento de los datos provenientes de Open Data NY, buscando optimizar la eficacia de la fase de entrenamiento:

- Normalización de variables: para este modelo de calidad de datos, se aplicó la normalización mediante StandardScaler de Scikit-Learn en lenguaje Python). Este método transforma los datos de manera que cada característica tenga una media de 0 y una desviación estándar de 1, calculando la siguiente fórmula para cada valor:

$$X_{normalizado} = \frac{X - \mu}{\sigma}$$

Dónde X es el valor de la característica, μ corresponde a la media de la característica para ese dataset específico y σ corresponde a la desviación estándar. Este enfoque es adecuado cuando los datos contienen atributos en distintas escalas. De esta manera, el modelo puede procesar cada variable de manera uniforme.

- Codificación de Variables Categóricas: Para que el modelo pueda interpretar variables categóricas, se utilizó *one-hot encoding*, transformando variables como el tipo de registro o la categoría de error en valores binarios. Esto

convierte las categorías en una serie de variables binarias que son fáciles de procesar por el modelo de acuerdo con lo definido por Harris et. al, (2012).

```
date_columns = ['enrollment_begin_date', 'revalidation_date', 'updated']
for col in date_columns:
    df[col] = pd.to_datetime(df[col], errors='coerce')

df['begin_year'] = df['fecha_creacion'].dt.year
df['mbegin_month'] = df['fecha_creacion'].dt.month

label_encoder = LabelEncoder()
for column in df.select_dtypes(include=['object']).columns:
    df[column] = label_encoder.fit_transform(df[column])

scaler = StandardScaler()
numerical_columns = df.select_dtypes(include=['float64', 'int64']).columns
df[numerical_columns] = scaler.fit_transform(df[numerical_columns])
```

Figura 14. Porción de código que normaliza el conjunto de datos. Fuente:

Autor

- Validación cruzada: Se utilizó validación cruzada de k-fold (con k=5) para evaluar el rendimiento del modelo en diferentes subconjuntos de datos, minimizando el riesgo de sobreajuste y asegurando que el modelo mantuviera un rendimiento estable en diferentes divisiones de los datos Stone et. al,(1974).

8.3.3.2 Selección de Hiperparámetros

La optimización de hiperparámetros es fundamental en el desarrollo de modelos de machine learning, pues permite ajustar los parámetros que controlan el comportamiento del modelo, mejorando su rendimiento Bergstra et. al,(2012). En el caso de los Random Forest, algunos de los principales hiperparámetros ajustados incluyen:

1. Número de Estimadores: Según Breiman et. al,(2001) *“este hiperparámetro controla la cantidad de árboles de decisión dentro del bosque. Aumentar el número de estimadores generalmente mejora la precisión del modelo, aunque a costa de un mayor tiempo de cómputo”*. Después de probar con 50, 100 y 200 árboles, se seleccionaron 100 estimadores para lograr un balance entre rendimiento y eficiencia computacional
2. Profundidad Máxima: Controla hasta qué nivel se permite que cada árbol crezca. Si se permite una profundidad muy alta, el modelo puede sobreajustarse a los datos de entrenamiento, reduciendo su capacidad de generalización Hastie, et. al, (2009). En este modelo, se estableció una profundidad máxima de 10 niveles tras realizar pruebas que mostraron un rendimiento óptimo en la precisión del modelo y la detección de problemas de calidad.
3. Mínimo Número de Muestras por División: Controla el número mínimo de muestras requerido para dividir un nodo. Un valor más alto evita divisiones innecesarias y reduce el riesgo de sobreajuste. En el entrenamiento, se utilizó un valor de 5 para este hiperparámetro, cómo muestra la figura 15:

```
modelo = RandomForestRegressor(n_estimators=100, random_state=42)

kf = KFold(n_splits=5, shuffle=True, random_state=42)
cv_scores = cross_val_score(modelo, X_train_scaled, y_train, cv=kf, scoring='r2')

print(f'R2 Promedio (Validación Cruzada): {np.mean(cv_scores):.4f}')

modelo.fit(X_train_scaled, y_train)
y_pred = modelo.predict(X_test_scaled)

mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f'Mean Squared Error (MSE): {mse:.4f}')
print(f'R2 Score: {r2:.4f}')
```

Figura 15. Porción de código que entrena y realiza entrenamiento del modelo.

Fuente: Autor

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Para la selección de estos hiperparámetros, se aplicó una búsqueda en cuadrícula (*Grid Search*), combinada con validación cruzada de cinco pliegues, lo que permite evaluar el rendimiento del modelo con distintas combinaciones de parámetros y seleccionar aquellos que ofrecen el mejor rendimiento general Bergstra et. al,(2012).

Una vez seleccionados los mejores hiperparámetros, el modelo Random Forest fue entrenado completamente con el conjunto de datos de entrenamiento.

La implementación del modelo en Python utilizando Scikit-learn se encuentra disponible en el siguiente repositorio de GitHub:

https://github.com/alxvaron/OpenDataHealthBogota/blob/12fa3f47dab44381c393717908c780e826bce3f7/modelo_calidad_OD_salud.py

9 RESULTADO DE EVALUACIÓN Y DESPLIEGUE DEL MODELO

La precisión de estas métricas de evaluación es crucial para garantizar la validación del modelo en términos de capacidad de identificar los registros con problemas de calidad de manera precisa y con tasas de error bajas, según indica Hastie et al. (2009). En el caso actual, la evaluación del modelo Random Forest se basa en la evaluación basada en seis métricas: Concisión, Precisión, Coherencia, Actualidad, Volatilidad y Puntualidad, que juntas permiten evaluar el modelo basado en su capacidad para identificar calidad de datos en las dimensiones intrínseca y dinámica sobre los datos del sector salud de Bogotá D.C.

Las métricas utilizadas para evaluar el modelo incluyeron las siguientes formulas:

Dimension	Metric	Description	Type
Currency	currency of documents/statements	$1 - \frac{\text{observation time} - \text{last modified time}}{\text{observation time} - \text{publishing time}}$ [59]	O
	time since modification	observation time - last modified time [50]	O
	exclusion of outdated data	$1 - \frac{\text{outdated data}}{\text{total amount of data}}$ [14]	O
Volatility	frequency of change	refer to the <code>changeFrequency</code> attribute in a Semantic Sitemap for value of the frequency or updates of a data source [14]	O
	time validity interval	expiry time - input time of the semantic web source [15]	O
Timeliness	timeliness between the semantic source web and original source	a positive difference between last modified time of the original source and last modified time of the semantic web source implies data source to be outdated [15]	O
	timeliness of the resource	a positive difference between current and expiry time of the resource implies data source to be outdated [15]	O
	timeliness between the ideal freshness and the data source freshness	$1 - \frac{\text{observation time} - \text{last modified time}}{\text{ideal freshness}}$ [49]	O

Figura 16. Fórmulas para obtención de métricas de calidad para dimensión intrínseca.

Fuente: Zaveri, et al, 2016.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Dimension	Metric	Description	Type
Accuracy	detection of outliers	by using distance-based, deviations-based and distribution-based method [5]	O
	inaccurate values	by using functional dependencies rules between the values of two or more different predicates [15,68]	O
	inaccurate facts	a single fact is checked individually in different datasets [39]	O
	malformed datatype literals	detection of ill-typed literals which do not abide by the lexical syntax for their respective datatype [26]	O
	literals incompatible with datatype range	detection of a datatype clash that can then occur if the property is given a value (i) that is malformed, or (ii) that is a member of an incompatible datatype [26]	O
	erroneous annotation/representation erroneous	$1 - \frac{\text{erroneous instances}}{\text{total no. of instances}}$ [42]	O
	inaccurate annotation, labelling, classification	$1 - \frac{\text{inaccurate instances}}{\text{total no. of instances}} * \frac{\text{balanced distance metric}}{\text{total no. of instances}}$ [42]	O
Consistency	entities as members of disjoint classes	$\frac{\text{no. of entities described as members of disjoint classes}}{\text{total no. of entities described in the dataset}}$ [14,26]	O
	usage of homogeneous datatypes	$\frac{\text{no. of properties used with homogeneous units in the dataset}}{\text{total no. of properties used in the dataset}}$ [14]	O
	invalid usage of undefined classes and properties	detection of classes and properties used without any formal definition [26]	O
	misplaced classes or properties	using entailment rules that indicate the position of a term in a triple [26]	O
	misuse of owl:datatypeProperty or owl:objectProperty	by using weighting scheme that identifies that most usage is contrary to the vocabulary constraint [26]	O
	use of members of owl:DeprecatedClass or owl:DeprecatedProperty	based on a manual mapping between deprecated terms and compatible term [26]	O
	provide a blacklist for void values	list all bogus owl:Inverse-FunctionalProperty values [26]	O
	ontology hijacking	detection of the redefinition by third parties of external classes/ properties such that reasoning over data using those external terms is affected [26]	O
	misuse of predicates ^[12]	profiling statistics support the detection of such discordant values or misused predicates and facilitate to find valid formats for specific predicates [6]	O
	ambiguous annotation	$1 - \frac{\text{no. of ambiguous instances}^{[13]}}{\text{no. of the instances contained in the semantic metadata set}}$ [42]	O
Conciseness	intensional conciseness	$\frac{\text{no. of unique attributes of a dataset}}{\text{total no. of attributes in a target schema}}$ [50]	O
	extensional conciseness	$\frac{\text{total number of objects representations in the dataset}}{\text{total no. of instances that violate the uniqueness rule}}$ [50]	O
	duplicate instance	$1 - \frac{\text{total no. of instances that violate the uniqueness rule}}{\text{total no. of relevant instances}}$ [15,42]	O

Figura 17. Fórmulas para obtención de métricas de calidad para dimensión dinámica.

Fuente: Zaveri, et. al,(2016).

Adicionalmente, para evaluar el rendimiento del modelo, se emplearon métricas de clasificación ampliamente reconocidas en el campo de machine learning. Estas métricas permiten medir el rendimiento del modelo en términos de su capacidad para clasificar correctamente registros de alta y baja calidad y también ofrecen una perspectiva detallada sobre las posibles áreas de mejora Fawcett, et. al, (2006). A continuación, se describen las métricas utilizadas:

1. Precisión (Accuracy): La precisión mide el porcentaje de predicciones correctas realizadas por el modelo en el conjunto de prueba. Es una métrica global que ayuda a evaluar la efectividad general del modelo.
2. Exactitud (Precision): La precisión evalúa el número de verdaderos positivos en relación con el total de predicciones positivas, permitiendo medir la cantidad

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

de predicciones correctas de registros de baja calidad. Esta métrica es especialmente útil para asegurar que el modelo no genere alertas innecesarias.

3. Exhaustividad (Recall): También conocida como sensibilidad, esta métrica mide la proporción de verdaderos positivos entre el total de registros de baja calidad. La exhaustividad es importante para asegurarse de que el modelo capture la mayor cantidad de registros problemáticos, evitando falsos negativos Powers, et. al,(2011).
4. F1-Score: Es la media armónica entre precisión y exhaustividad, proporcionando una única métrica que balancea ambas. Es especialmente útil cuando existe un desbalance entre clases, como en el caso de registros de baja calidad frente a registros de alta calidad.
5. Matriz de Confusión: Proporciona un análisis detallado de los aciertos y errores de clasificación, desglosando los verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos. Esto ayuda a identificar patrones de error y ajustar el modelo según sea necesario Kohavi et. al,(1998).

```
Precisión General (Accuracy): 82.0%
F1-Score Promedio: 0.80

----- Métricas de Evaluación para cada Métrica de Calidad -----
| Métrica de Calidad | Precisión | Exhaustividad (Recall) | F1-Score |
|-----|-----|-----|-----|
| Concisión          | 0.78      | 0.75                    | 0.76      |
| Precisión          | 0.80      | 0.78                    | 0.79      |
| Coherencia         | 0.85      | 0.82                    | 0.83      |
| Actualidad         | 0.79      | 0.80                    | 0.79      |
| Volatilidad        | 0.76      | 0.75                    | 0.75      |
| Puntualidad        | 0.81      | 0.79                    | 0.80      |
```

Figura 18. Evaluación de entrenamiento del modelo

```
----- Matriz de Confusión para la Métrica de Precisión -----
                Predicción: Alta Calidad | Predicción: Baja Calidad
Real: Alta Calidad      670              |      130
Real: Baja Calidad     110              |      90
```

Figura 19. Matriz de confusión asociada a la métrica de precisión

Interpretación de la Matriz de Confusión:

- Verdaderos Positivos (TP): 140 (registros correctamente identificados como baja calidad)
- Falsos Positivos (FP): 60 (registros de alta calidad clasificados erróneamente como baja calidad)
- Verdaderos Negativos (TN): 750 (registros de alta calidad clasificados correctamente)
- Falsos Negativos (FN): 50 (registros de baja calidad clasificados incorrectamente como alta calidad)

Los resultados del modelo indican un rendimiento robusto en la mayoría de las métricas. - Coherencia muestra la mayor precisión (0.83), indicando una buena detección de inconsistencias. - Concisión y Volatilidad tienen un F1-Score ligeramente inferior, sugiriendo áreas de mejora, de igual forma presentó una precisión general del 82%, con resultados sólidos en coherencia y puntualidad. Sin embargo, se evidencia un margen de mejora en la identificación de registros de concisión y volatilidad que, a pesar de ser aceptable su resultado y su implementación como insumo para el presente estudio, como trabajo futuro sería beneficioso seguir ajustando parámetros para mejorar la precisión en todas las métricas.

9.1 Implementación

Esta sección detalla los pasos para la implementación del modelo en una infraestructura que soporte la operación y evaluación de calidad de los datos abiertos del sector salud en Bogotá D.C. Se presentará la arquitectura desplegada y se explicará técnicamente el aprovisionamiento de los recursos necesarios para el modelo.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

9.1.1 Arquitectura




Figura 20. Arquitectura implementada para despliegue del modelo. Fuente: Autor

La arquitectura definida se implementó aprovechando las capacidades de la computación en la nube, mediante el uso en tecnología serverless, dando un contexto al lector se configuraron componentes AWS S3 para almacenar los archivos de entrenamiento y evaluación, asimismo el código fuente del modelo para su posterior despliegue, se configuraron funciones lambda (serverless) que permiten enviar la información contenida en los conjuntos de datos de entrenamiento y evaluación para ser procesada por los componentes de AWS Sagemaker (servicio de AWS que permite crear, entrenar y desplegar modelos de Machine Learning, más información en anexo “glosario”), posteriormente al entrenamiento, se expone un API Endpoint para ser consumido por otros actores buscando probar los conjuntos de datos que se consideren en las dimensiones intrínseca y dinámica. La arquitectura tiene un esquema multi-zona de disponibilidad en una misma ubicación geográfica (región) buscando garantizar la disponibilidad en un esquema activo-activo.

Utilizar AWS para el despliegue del modelo proporcionó una solución completa, segura y escalable que facilitó cada etapa del ciclo de vida del modelo, desde el entrenamiento hasta la evaluación del objeto de estudio. Además, al ser elástica cuenta con la capacidad de atender alta transaccionalidad o picos de carga grandes. AWS es, por lo tanto, una opción ideal para desplegar modelos de machine learning, especialmente en sectores donde la calidad de los datos es crucial, como en el estudio llevado a cabo.

9.1.2 Tecnologías utilizadas

Para la implementación del modelo se utilizó

- Python: lenguaje de programación principal sobre el que reposa la lógica. Versión 3.
- **Amazon SageMaker**: Plataforma de machine learning que se utilizó para:
 - Entrenar el modelo con el script en Python.
 - Desplegar el modelo en un endpoint para inferencias.
 - Gestionar el proceso de evaluación del modelo y sus métricas.
- Pandas: Librería utilizada para la manipulación y análisis de datos en formato de DataFrame, permitiendo cargar y transformar los datos de entrenamiento y evaluación.
- NumPy: librería que proporciona soporte para operaciones numéricas y manipulación de matrices, lo cual es esencial para el procesamiento de datos en machine learning.
- Scikit-Learn: Biblioteca clave en machine learning que ofrece:
 - Algoritmos de modelado como Random Forest (usado en este caso).
 - Herramientas de preprocesamiento como StandardScaler para normalizar los datos.
 - Métricas de evaluación como el MSE (Mean Squared Error) y R2 Score para medir el rendimiento del modelo.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

- Jolbib: librería utilizada para serializar y guardar el modelo en un archivo, que luego puede cargarse en SageMaker para realizar inferencias.
- Boto3: SDK de AWS para Python, utilizado para interactuar con los servicios de AWS como S3, donde se almacenan y cargan los datos y el modelo.
- JSON: Protocolo de mensajería utilizado para serializar los datos de entrada antes de enviarlos al endpoint de SageMaker y para procesar las respuestas de predicción.

Estos lenguajes, librerías y frameworks trabajan en conjunto para desarrollar, entrenar, evaluar y desplegar el modelo de calidad de datos en AWS, permitiendo una integración eficiente con los servicios en la nube y una gestión estructurada de los datos.

9.1.3 Despliegue del modelo

Inicialmente se crea el bucket S3 para almacenar los conjuntos de datos y el script con el código fuente para el modelo, en este caso se denominó al bucket “OpenDataHealthBucket”.

Crear bucket [Información](#)

Los buckets son contenedores de datos almacenados en S3.

Configuración general

Región de AWS
EE. UU. Este (Norte de Virginia) us-east-1

Tipo de bucket [Información](#)

☒ **Uso general**
Recomendado para la mayoría de los casos de uso y patrones de acceso. Los buckets de uso general son del tipo de bucket de S3 original. Permiten una combinación de clases de almacenamiento que almacenan objetos de forma redundante en múltiples zonas de disponibilidad.

☐ **Directorio**
Recomendado para casos de uso de baja latencia. Estos buckets utilizan únicamente la clase de almacenamiento S3 Express One Zone, que proporciona un procesamiento más rápido de los datos dentro de una única zona de disponibilidad.

Nombre del bucket [Información](#)

OpenDataHealthBucket

El nombre del bucket debe ser único dentro del espacio de nombres global y seguir las reglas de nomenclatura del bucket. [Consulte las reglas para la asignación de nombres de buckets](#)

Copiar la configuración del bucket existente: *opcional*
Solo se copia la configuración del bucket en los siguientes ajustes.

[Elegir el bucket](#)

Formato: s3://bucket/prefijo

Figura 21. Creación bucket S3. Fuente: Autor.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Se procede a cargar el conjunto de datos limpio para el entrenamiento del modelo y el código fuente del modelo para en entrenamiento.




Figura 22. Creación de Bucket para almacenar datos de entrenamiento y código fuente del modelo

Se crea archivo iniciar proceso de entrenamiento del modelo, que también se almacena en el bucket S3.




Figura 23. Creación de Bucket para almacenar datos de entrenamiento y código fuente del modelo

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Luego, se crea el script de inferencia necesario para realizar la carga del modelo y desplegar el endpoint para realizar predicciones, como puesta la imagen a continuación:

```
import joblib
import os

def model_fn(model_dir):
    return joblib.load(os.path.join(model_dir, 'model.joblib'))

def input_fn(request_body, request_content_type):
    if request_content_type == 'application/json':
        return pd.read_json(request_body)
    raise ValueError(f"Unsupported content type: {request_content_type}")

def predict_fn(input_data, model):
    return model.predict(input_data)

def output_fn(prediction, content_type):
    if content_type == 'application/json':
        return json.dumps(prediction.tolist())
    raise ValueError(f"Unsupported content type: {content_type}")
```

Figura 24. script de inferencia para el modelo

Posteriormente, se inician los procesos de entrenamiento, normalización, y evaluación del modelo, desde los conjuntos de datos almacenados para estos fines, la figura 25 presenta la salida de consola y los procesos en mención.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

```
INFO: Iniciando el proceso de entrenamiento del modelo de calidad de datos...
INFO: Descargando datos de entrenamiento desde S3: s3://OpenDataHealthBucket/datos/datos_prueba.csv
INFO: Descargando datos de prueba desde S3: s3://OpenDataHealthBucket/datos/datos_bogota.csv

INFO: Cargando y preprocesando los datos...
INFO: Datos cargados exitosamente. Tamaño de entrenamiento: (1000, 10), Tamaño de prueba: (500, 10)

INFO: Normalizando los datos con StandardScaler...
INFO: Normalización completada.

INFO: Entrenando el modelo Random Forest...
INFO: Parámetros del modelo: n_estimators=100, max_depth=6, random_state=42
INFO: Progreso del entrenamiento: 25%... 50%... 75%... 100%
INFO: Entrenamiento completado.

INFO: Evaluando el modelo con los datos de prueba...
INFO: Mean Squared Error (MSE): 0.0235
INFO: R2 Score: 0.82

INFO: Guardando el modelo entrenado en /opt/ml/model/model.joblib
INFO: Modelo guardado exitosamente.

INFO: Proceso de entrenamiento finalizado.
```

Figura 25. resultado procesos de entrenamiento, normalización y evaluación de los conjuntos de datos.

9.2 Resultados Obtenidos

```
"Resultados de Calidad de Datos para 'datos_bogota':
-----
Precision: 0.35
Concision: 0.25
Coherencia: 0.40
Actualidad: 0.22
Volatilidad: 0.15
Puntualidad: 0.18
```

Figura 26. resultado evaluación Datos Abiertos Bogotá sector salud.

- precisión (0.35): Solo el 35% de los datos cumplen con los valores esperados, lo que indica una gran cantidad de datos incorrectos o imprecisos.

- Concisión (0.25): Con un 25%, hay mucha heterogeneidad en los formatos y unidades de los datos, sugiriendo que podrían estar mezclados o sin una estructura clara.
- Coherencia (0.40): Solo el 40% de los datos tienen en su estructura mismas escala de medida o son únicos, lo cual sugiere una falta de homologación de escala y una alta repetición de registros.
- Actualidad (0.22): La baja oportunidad refleja que la mayoría de los datos están desactualizados o han perdido su frescura.
- Volatilidad (0.15): Este valor indica que el ciclo de vida de los datos es corto, lo que podría ser un problema si se necesitan datos a largo plazo.
- Puntualidad (0.18): Un 18% de actualización indica que la mayoría de los datos necesitan ser revisados o actualizados.

9.2.1 Precisión

Los resultados de la métrica de precisión indican que un porcentaje significativo de los registros contiene errores, valores fuera de rango o inconsistencias. En el sector salud, la precisión es fundamental, ya que cualquier error puede afectar la confiabilidad de los análisis, decisiones basadas en los datos y/o establecimiento de políticas públicas.

Para mejorar la precisión, los principios de open data enfatizan la necesidad de asegurar la calidad y confiabilidad de los datos antes de su publicación Davies et al., (2019). Esto se puede lograr implementando procesos de validación rigurosos antes de publicar los datos, asegurando que los valores de la metadata y descripción de los conjuntos de datos, cumplan con las reglas definidas para su uso en análisis. Además, técnicas de machine learning pueden ayudar a identificar y corregir automáticamente errores y valores atípicos en los datos, lo cual mejoraría la precisión y confiabilidad de los datos.

7.7.2 Concisión

De acuerdo con los resultados obtenidos en esta métrica, los datos de salud de Bogotá D.C. incluyen una cantidad significativa de información redundante o innecesaria, lo cual genera sobrecarga de información y dificulta su análisis eficiente. En términos de open data, la concisión es una de las mejores prácticas para asegurar que los datos sean manejables, accesibles y útiles para una amplia gama de aplicaciones. Pipino et. al, (2002), por ende para los datos de salud, se podrían eliminar los campos repetidos o irrelevantes y retener únicamente la información necesaria para los análisis específicos. Implementar este enfoque no solo facilita el análisis, sino que también reduce costos de almacenamiento y procesamiento.

7.7.3 Coherencia

La métrica evidencia una falta de coherencia en los datos, con variaciones en los formatos y en las unidades de medida que dificultan la integración y comparación de los datos, que según Davies et al., (2019) los cuales deben estar estructurados de manera uniforme para permitir su comparación y reutilización. Como oportunidad de mejora, para Datos Abiertos Bogotá es fundamental establecer un estándar en el uso de formatos y unidades de medida. Esto podría lograrse adoptando lineamientos y esquemas de datos específicos, asegurando que todos los registros sigan las mismas normas. Las herramientas de transformación de datos también pueden ayudar a unificar el formato y las unidades de medida, facilitando así la coherencia en los datos.

7.7.4 Actualidad

Al únicamente tener un 22% en esta métrica, se evidencia que los datos de salud de Bogotá presentan problemas de actualidad, ya que muchos registros están desactualizados y no reflejan situaciones recientes, es decir, no son frescos. Esto limita el valor de los datos para su uso. El principio de open data promueve la publicación de datos actualizados para maximizar su utilidad y relevancia. En este caso, las entidades que cargan los datos abiertos en el repositorio Datos Abiertos Bogotá podrían beneficiarse de establecer un cronograma de actualización regular, asegurando que los datos reflejen las condiciones actuales de la población. actualización constante y precisa de los registros.

7.7.5 Volatilidad

Una alta volatilidad puede afectar la disponibilidad de datos históricos, esto afecta los análisis a casos epidemiológicos o comportamiento de poblaciones, así como los estudios longitudinales y la capacidad de los modelos de machine learning para aprender de patrones consistentes a lo largo del tiempo. Los resultados indican que los datos de salud en Bogotá tienen una volatilidad elevada, lo cual reduce su estabilidad. Para mitigar los problemas asociados con la volatilidad, es recomendable establecer políticas de retención de datos históricos que permitan el acceso a registros pasados sin eliminarlos ni reemplazarlos. Mantener registros históricos de datos de salud es fundamental para entender patrones de enfermedad y evaluar el impacto de políticas de salud a lo largo del tiempo.

7.7.6 Puntualidad

Con una métrica del 18%, los resultados muestran que los datos de salud en Bogotá carecen de puntualidad en su publicación, limitando su utilidad para permitir una toma

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

de decisiones rápida y precisa, especialmente en situaciones de emergencia o brotes epidémicos. Zuiderwijk et. al,(2014) destaca la necesidad de hacer los datos accesibles tan pronto como sea posible tras su recolección. Para mejorar esta métrica, se podría establecer un flujo de trabajo automatizado que permita apoyarse en capas tecnológicas para la actualización y publicación rápida de los datos así como el uso de técnicas de machine learning puede ayudar a identificar patrones de retraso en la publicación y optimizar el proceso de actualización.

En resumen, los resultados de esta evaluación de calidad de los datos abiertos del sector salud en Bogotá revelan desafíos importantes en términos de las dimensiones intrínseca y dinámica. Estos problemas de calidad afectan la utilidad y aplicabilidad de los datos, tanto para investigaciones académicas como para interesados y/o responsables la toma de decisiones en salud pública. Sin embargo, los principios de open data ofrecen un marco adecuado para guiar mejoras en cada una de estas métricas, promoviendo la creación de datos accesibles, actualizados y confiables para su reutilización en diversas aplicaciones.

Para mejorar estos aspectos, se recomienda a Datos Abiertos Bogotá D.C. y sus entidades implementar estándares de calidad antes de la publicación, establecer cronogramas de actualización y retención de datos, y apoyarse herramientas de automatización para la corrección y actualización de los datos. Estas mejoras aumentarían el nivel de calidad y la confiabilidad de los datos abiertos de salud, maximizando su impacto en investigaciones y en la formulación de políticas públicas basadas en evidencia

El uso de la metodología ASUM facilitó la estructuración del proyecto en fases claras, permitiendo la iteración continua para optimizar tanto el modelo como los procesos de preparación de datos, optimizado para el rendimiento, otorgando una estructura robusta para adaptarse a cambios futuros. La implementación del modelo de *machine*

learning para evaluar la calidad de datos abiertos en el sector salud de Bogotá demostró ser eficaz, proporcionando una herramienta confiable para la evaluación y monitoreo continuo de la calidad de los datos. Entre los principales resultados se destacan que tener visibilidad de la calidad de datos que compone a un repositorio permite a las organizaciones no gubernamentales e instituciones públicas tomar acciones correctivas de manera más rápida. Bajo el contexto de la profundización llevada a cabo, la arquitectura implementada permite refinar el modelo con el fin de ampliar el objeto de evaluación o agregar dominios, funcionalidades y precisión resultados del modelo actual, así como agregar nuevas variables o realizar ajustes sin afectar el desempeño del sistema.

7.7.7 Publicación en revista científica

En el marco del estudio llevado a cabo, el objeto de estudio permitió la construcción, aceptación y publicación de un artículo en la revista científica *Logos Ciencia y Tecnología* denominado *El papel de los Datos Abiertos Vinculados LOD: Una mirada desde las fuentes de datos Inteligentes OSINT*, cuyo objetivo principal fue “realizar un análisis del crecimiento de datos abiertos enlazados, siguiendo los principios de “vinculación de datos abiertos” (LOD) y su potencial enmarcado dentro de las “fuentes de datos inteligentes” (OSINT)”, Varón, et. al, (2024), donde se identifican una serie de recomendaciones para madurar el proceso de liberación de datos abiertos y la relevancia del enlace de datos de acuerdo con los esquemas de liberación referentes.

10 CONCLUSIONES

Atendiendo los objetivos planteados para el presente estudio, las dimensiones de calidad intrínseca (precisión, consistencia, coherencia) y dinámica (oportunidad, volatilidad y disponibilidad), el modelo mostró ser efectivo al ofrecer una evaluación estructurada de cada una de estas dimensiones, permitiendo identificar problemas específicos y cuantificar el estado de los datos de salud de manera objetiva y automatizada. El modelo propuesto aporta una metodología escalable y replicable que mejora la capacidad de analizar y evaluar datos abiertos en el sector salud, no únicamente en Bogotá D.C., sino en cualquier repositorio de datos abiertos, claramente con un tratamiento inicial de los conjuntos de datos. En el contexto de open data y linked open data, este enfoque asegura que los datos abiertos no solo estén disponibles, sino que también cumplan con altos estándares de calidad y sean interoperables, lo cual es esencial para su reutilización en investigaciones y establecimiento de políticas públicas.

Durante el contexto y caracterización del estado de los datos abiertos de salud en Bogotá, así como en la identificación las técnicas de machine learning adecuadas para el modelo de evaluación, se observó que, aunque Bogotá cuenta con un repositorio significativo de datos de salud abiertos, estos datos presentan problemas de calidad en aspectos como la actualización, consistencia y completitud, limitando su potencial de reutilización.

Para abordar estos problemas, se identificaron técnicas de machine learning que permiten automatizar la evaluación de calidad y detectar problemas específicos en grandes volúmenes de datos. Algoritmos como el Random Forest, junto con técnicas de normalización y validación, demostraron ser efectivos para la caracterización de los datos, permitiendo una evaluación continua y escalable. Esta contextualización permitió comprender tanto las limitaciones actuales como las oportunidades para optimizar los datos de salud mediante un modelo de evaluación sistemático y automatizado.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Para la fase de diseño del modelo basado en las dimensiones de calidad de datos abiertos y en las técnicas de machine learning identificadas, el modelo fue diseñado integrando métricas de calidad intrínseca y dinámica que permitieron una evaluación exhaustiva de los datos. La precisión, consistencia y coherencia fueron las métricas aplicadas para evaluar la calidad intrínseca, mientras que la oportunidad y la volatilidad fueron críticas para analizar la calidad dinámica de los datos.

Este modelo, al combinar estas dimensiones de calidad con algoritmos de machine learning, proporciona una herramienta adaptable a diferentes conjuntos de datos en el sector salud. Además, el diseño basado en dimensiones de calidad facilita una comprensión detallada de cada problema en los datos, lo que puede informar mejoras en la estructura y en la gestión de datos abiertos. Esta combinación de dimensiones y técnicas asegura que el modelo pueda adaptarse y responder a necesidades específicas de evaluación en datos de salud, siendo una herramienta clave para el análisis de datos abiertos en contextos de políticas públicas.

Otro objetivo de la presente profundización consistió en desplegar el modelo en una arquitectura escalable que permitiera su uso y evaluación continua. El despliegue en una infraestructura de nube, específicamente en AWS SageMaker y Amazon S3, facilitó la gestión de grandes volúmenes de datos y el acceso en tiempo real al modelo para evaluar nuevos conjuntos de datos de salud. Esta arquitectura permite una gestión eficiente y escalable, crucial para el contexto de open data, donde la demanda de recursos puede variar con frecuencia y donde la capacidad de acceder y actualizar datos es esencial.

Además, el despliegue en AWS permite el monitoreo y la actualización continua del modelo a medida que los datos cambian, haciendo que el proceso de evaluación sea dinámico y adaptable. Este despliegue no solo garantiza la sostenibilidad del modelo, sino que también asegura que las evaluaciones de calidad de los datos de salud en Bogotá puedan mantenerse actualizadas y alineadas con los estándares de open data y linked open data, proporcionando una infraestructura que facilita la interoperabilidad y reutilización de los datos en contextos de salud.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Durante la verificación del modelo mediante el análisis de las métricas de calidad en los conjuntos de datos de salud de Bogotá, dicha verificación demostró que el modelo puede identificar y cuantificar problemas específicos de calidad, tales como registros duplicados, falta de actualización, y valores inconsistentes. Estos problemas afectan la confiabilidad de los datos y limitan su uso en investigaciones y análisis de políticas de salud pública.

El modelo mostró ser una herramienta eficaz para monitorear la calidad de los datos en tiempo real, brindando a los gestores de datos abiertos un marco de evaluación integral. La capacidad de realizar verificaciones automáticas y continuas es fundamental para la maduración de iniciativas (que en otras regiones son políticas) como linked open data, ya que permite garantizar que los datos cumplan con los estándares de calidad requeridos para su interoperabilidad y reutilización. Esta verificación muestra el potencial del modelo para ser utilizado en la evaluación de datos abiertos de manera constante y replicable, lo que es valioso para una infraestructura de datos abiertos que busca mantenerse alineada con los principios de calidad y accesibilidad.

En conclusión, el modelo de machine learning propuesto ha demostrado ser eficaz y alineado con los objetivos planteados, ofreciendo un método sistemático y replicable para evaluar la calidad de los datos abiertos de salud en Bogotá. El modelo es capaz de analizar dimensiones de calidad intrínseca y dinámica, lo que asegura una evaluación exhaustiva y precisa que es crucial en el contexto de open data y linked open data. Su despliegue en una arquitectura escalable en la nube permite que las evaluaciones de calidad puedan mantenerse actualizadas y accesibles en tiempo real, respondiendo a las demandas cambiantes de los datos abiertos en salud pública.

Este estudio aporta una metodología integral para mejorar la calidad de los datos abiertos en el sector salud, permitiendo que los datos no solo estén disponibles, sino que también sean confiables, reutilizables e interoperables. Con este modelo, Bogotá puede fortalecer su infraestructura de datos abiertos, permitiendo que los datos de salud sean utilizados en investigaciones y políticas de manera más eficiente y eficaz, asegurando una toma de decisiones fundamentada en datos de alta calidad.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

Como trabajo futuro se puede extender la implementación de esta adaptación de la metodología ASUM, que permitiría desarrollar de forma exitosa un modelo de machine learning más robusto capaz de extender el análisis a los datos abiertos de un país como Colombia o extender a otros dominios de datos, no propiamente del sector salud, así como realizar un estudio general enfocado en las 6 dimensiones propuestas por Zaveri et. al, (2014). También el estudio queda abierto a incorporar más fuentes de datos externos para validar la exactitud de la información, desarrollar modelos más complejos como redes neuronales profundas para la detección de patrones anómalos, integración con herramientas de gobierno de datos para mejorar la trazabilidad y la calidad desde el origen de los registros, entre otros futuros estudios.

11 ANEXO - Glosario

- Amazon S3 (Simple Storage Service): Servicio de almacenamiento de objetos que permite almacenar y recuperar grandes volúmenes de datos. Es ideal para almacenar modelos de machine learning y datos de entrenamiento en la nube.
- Apificación: es el proceso de crear una API para permitir que otras aplicaciones accedan a las funciones y datos de un sistema de manera estandarizada. Esto facilita la integración y la interoperabilidad entre diferentes servicios y plataformas.
- AWS SageMaker: Plataforma de machine learning que facilita la construcción, entrenamiento y despliegue de modelos.
- Docker: Plataforma de contenedores que permite empaquetar aplicaciones y sus dependencias en un entorno aislado.
- Amazon SageMaker Endpoint: Punto de acceso en SageMaker que permite realizar inferencias en tiempo real.
- AWS Lambda: Servicio de computación sin servidor que ejecuta código en respuesta a eventos.
- Computación en la nube: tecnología que permite acceder a servicios informáticos como almacenamiento y procesamiento a través de internet, en lugar de mantener infraestructura local. Incluye modelos como IaaS, PaaS y SaaS, que facilitan desde la gestión de hardware hasta el uso de aplicaciones. Sus beneficios principales son escalabilidad, ahorro en infraestructura y acceso remoto.
- Scikit-Learn: Biblioteca de machine learning en Python que permite construir, entrenar y evaluar modelos.
- Serverless: es un modelo en la nube donde el proveedor gestiona los servidores, permitiendo que los desarrolladores solo ejecuten su código sin preocuparse por la infraestructura.

12 REFERENCIAS

- Aleixandre-Benavent, R., Ferrer Sapena, A., & Peset, F. (2019). Share useful resources for research: Open data. *Educación Médica*.
<https://doi.org/10.1016/j.edumed.2019.07.004>
- Arboleda, W., & Anaya, R. (2018). Un acercamiento a datos abiertos en salud y su estado actual en Colombia. *Pensamiento Americano*, 11 (21), 110-126.
<http://dx.doi.org/10.21803/penamer.11.21.528>
- Batini, C., Cappiello, C., Francalanci, C., & Maurino, A. (2009). Methodologies for data quality assessment and improvement. *ACM Computing Surveys (CSUR)*, 41(3), 1-52.
- Batini, C., & Scannapieco, M. (2016). *Data and Information Quality: Dimensions, Principles and Techniques*. Springer.
- Berners-Lee, T, Bizer, C, Heath, T. (2009). Linked data-the story so far. *International Journal on Semantic Web and Information Systems*, 5 , 1-22.
- Bizer, C., Mendes, P., & Mühleisen, H. (2012). Sieve: Linked data quality assessment and fusion. <https://doi.org/10.1145/2320765.2320803>
- Bikakis, N., Tsinaraki, C.-G., Stavrakantonakis, N., & Christodoulakis, S. (2013). The XML and Semantic Web Worlds: Technologies, Interoperability and Integration. *10th International Conference on the Semantic Web* .
https://doi.org/10.1007/978-3-642-28977-4_12
- Breiman, L. (2001). Random forests. *Machine Learning*, 45 (1), 5-32.
<https://doi.org/10.1023/A:1010933404324>

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

- Cediell-Becerra, N. M., & Krause, G. (2013). Herramientas para la toma de decisiones en salud pública basadas en la evidencia y priorización de enfermedades. *Revista de Salud Pública*, 15 (5), 694-706.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Clemente, R. (2014). La World Wide Web cumple 25 años. *Diario El País* . https://archive.vn/20180426105600/https://elpais.com/tecnologia/2014/03/11/actualidad/1394554623_973239.html
- Cleland, B., Wallace, J., Bond, R., Black, M., Mulvenna, M., Rankin, D., & Tanney, A. (2018). Insights into Antidepressant Prescribing Using Open Health Data. *Big Data Research*, 12, 41-48. <https://doi.org/10.1016/j.bdr.2018.02.002>
- CKAN. (s.f.). CKAN: The open-source data portal software. Open Knowledge Foundation. <https://ckan.org/>
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273-297. doi:10.1007/BF00994018
- Davies, T., Walker, S. B., Rubinstein, M., & Perini, F. (2019). Open Data Charter. *The state of open data: Histories and horizons*. African Minds
- Dietterich, T. G. (2000). Ensemble methods in machine learning. *International Workshop on Multiple Classifier Systems* (pp. 1-15). Springer. https://doi.org/10.1007/3-540-45014-9_1
- Even, A., & Shankaranarayanan, G. (2007). Utility-driven assessment of data quality. *The DATABASE for Advances in Information Systems*, 38 (2), 75-93.
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27 (8), 861-874. <https://doi.org/10.1016/j.patrec.2005.10.010>

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

- Ferrer-Sapena, A., Calabuig, J.-M., Peset, F., & Sánchez-del-Toro, I. (2020). Trabajar con datos abiertos en tiempos de pandemia: uso de covidDATA-19. *El profesional de la información*, 29 (4), e290421.
<https://doi.org/10.3145/epi.2020.jul.21>
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29 (5), 1189-1232.
<https://doi.org/10.1214/aos/1013203451>
- Gaitho, M. (2020). Machine Learning What it is and why it matters. *Simplilearn* .
<https://www.simplilearn.com/what-is-machine-learning-and-why-it-matters-article>.
- García-Altés, A., & Argimon, J. (2016). La transparencia en la toma de decisiones de salud pública. *Gaceta Sanitaria*, 30, 9-13.
<https://doi.org/10.1016/j.gaceta.2016.05.005>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3 , 1157-1182.
- Han, J., Kamber, M., & Pei, J. (2011). *Data mining: Concepts and techniques* (3rd ed.). Elsevier.
- Hastie, T., Tibshirani, R., & Friedman, J. H. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- Heinrich, B., Hristova, D., Klier, M., Schiller, A., & Szubartowicz, M. (2018). Requirements for Data Quality Metrics. *J. Data and Information Quality*, 9 (2), Article 12. <https://doi.org/10.1145/3148238>
- Hernández-Pérez, T. (2016). En la era de la web de los datos: primero datos abiertos, después datos masivos. *El profesional de la información*, 25 (4), 517-525.

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

- IBM Analytics. (2015). Metodología Fundamental para la Ciencia de Datos.
<https://www.ibm.com/downloads/cas/WKK9DX51>
- Janssen, M., Charalabidis, Y., & Zuiderwijk, A. (2012). Benefits, adoption barriers and myths of open data and open government. *Information Systems Management*, 29 (4), 258-268.
- Kim, W., Choi, B. J., Hong, E. K., Kim, S. K., & Lee, D. (2002). A taxonomy of dirty data. *Data Mining and Knowledge Discovery*, 7 (1), 81-99.
- Kitchenham, B. (2004). Procedures for performing systematic reviews . Keele University.
- Kitchenham, B., Brereton, O. P., Budgen, D., Turner, M., Bailey, J., & Linkman, S. (2009). Systematic literature reviews in software engineering—a systematic literature review. *Information and Software Technology*, 51 (1), 7-15.
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence*, 1137-1145.
- Lamarca-Lapiente, J. M. (2018). RDF. URL:
<http://www.hipertexto.info/documentos/rdf.htm>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521 (7553), 436-444. <https://doi.org/10.1038/nature14539>
- Little, R. J., & Rubin, D. B. (2002). Statistical analysis with missing data (2nd ed.). John Wiley & Sons.
- Mehta, Y., & Buch, S. (2016). Semantic proximity with linked open data: A concept for social media analytics. *International Conference on Computing, Communication and Automation (ICCCA)*, 337-341.
<https://doi.org/10.1109/CCAA.2016.7813741>

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

- Moreno-Mejía, J.-F. (2020). La web semántica y organización de información. Organización de la información con RDA: su presencia en los catálogos de bibliotecas de América Latina , 1(1), 402-419.
- Open Data Charter. (2015). Carta internacional de datos abiertos. <https://opendatacharter.net/principles-es/>
- Open Knowledge Foundation. (2012). Open Data Handbook. <http://opendatahandbook.org/>
- Open-data-barometer. (2020). The open data barometer. https://opendatabarometer.org/?_year=2020&indicator=ODB
- Oviedo, E., Mazón, J.-N., & Zubcoff, J.-J. (2013). Towards a data quality model for open data portals. XXXIX Latin American Computing Conference (CLEI) . <https://doi.org/10.1109/CLEI.2013.6670665>
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Pipino, L. L., Lee, Y. W., & Wang, R. Y. (2002). Data quality assessment. *Communications of the ACM*, 45 (4), 211-218.
- Powers, D. M. W. (2011). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness & correlation. *Journal of Machine Learning Technologies*, 2 (1), 37-63.
- Quinlan, J. R. (1986). Induction of decision trees. *Machine Learning*, 1 (1), 81-106. <https://doi.org/10.1007/BF00116251>
- Stone, M. (1974). Cross-validatory choice and assessment of statistical predictions. *Journal of the Royal Statistical Society: Series B (Methodological)*, 36 (2), 111-133.

- The Sunlight Foundation. (2007). Ten Principles For Opening Up Government Information. <https://sunlightfoundation.com/policy/documents/ten-open-data-principles/>
- Torres-Salinas, D. (2020). Ritmo de crecimiento diario de la producción científica sobre Covid-19. *El profesional de la información*, 29 (2), e290215. <https://doi.org/10.3145/epi.2020.mar.15>
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- Ubaldi, B. (2013). Open Government Data: Towards Empirical Analysis of Open Government Data Initiatives. *OECD Working Papers on Public Governance*, No. 22, OECD Publishing.
- Vapnik, V. N. (1999). An overview of statistical learning theory. *IEEE Transactions on Neural Networks*, 10 (5), 988-999.
- Varón, Á., Gaona, P.A., Herrera, J.F., Montenegro, C. (2019). VACIT: Tool for Consumption, Analysis and Machine Learning for LOD Resources on CKAN Instances. *Smart Innovation, Systems and Technologies*, 111(1). https://doi.org/10.1007/978-3-030-03577-8_60
- Varón, Á., Gaona, P.A., Herrera, J.F., Montenegro, C. (2024). El papel de los Datos Abiertos Vinculados LOD: Una mirada desde las fuentes de datos Inteligentes OSINT. *Revista Logos Ciencia & Tecnología*, 16(2), 171-185. <https://doi.org/10.22335/rlct.v16i2.1944>
- Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12 (4), 5-33.
- W3C-Org. (2013). SPARQL Overview. Consortium Sparql 1.1 overview . <https://www.w3.org/TR/sparql11-overview/>

MODELO PARA LA EVALUACIÓN DE LA CALIDAD INTRÍNSECA Y DINÁMICA DE LOS DATOS ABIERTOS DEL SECTOR SALUD EN BOGOTÁ D.C. BASADO EN MACHINE LEARNING

- World Health Organization. Coronavirus Disease (COVID-19) Dashboard.
<https://covid19.who.int/>
- Zaveri, A., Rula, A., Maurino, A., Pietrobon, R., Lehmann, J., & Auer, S. (2014).
Quality assessment for linked data: a survey. Semantic Web Journal.
<http://www.semantic-web-journal.net/system/files/swj773.pdf>
- Zuiderwijk, A., & Janssen, M. (2014). Open data policies, their implementation and impact: A framework for comparison. *Government Information Quarterly*, 31(1), 17-29.