


MODELO DE INFERENCIA ONTOLÓGICA PARA CARACTERIZACIÓN DE OPCIONES DE CULTIVO A PARTIR DE VARIABLES CLIMÁTICAS



MADDYZETH ARIZA RIAÑO

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
MAESTRÍA EN CIENCIAS DE LA INFORMACIÓN Y LAS COMUNICACIONES
FACULTAD DE INGENIERÍA
BOGOTÁ, COLOMBIA
2022

MODELO DE INFERENCIA ONTOLÓGICA PARA CARACTERIZACIÓN DE OPCIONES DE CULTIVO A PARTIR DE VARIABLES CLIMÁTICAS



TRABAJO DE INVESTIGACIÓN PARA OPTAR POR EL TÍTULO DE:
MAGISTER EN CIENCIAS DE LA INFORMACIÓN Y LAS COMUNICACIONES

MADDYZETH ARIZA RIAÑO

DIRECTOR:

JULIO BARÓN VELANDIA, PhD.

GRUPO DE INVESTIGACIÓN:

INTEROPERABILIDAD TECNOLÓGICA Y SEMÁNTICA INTECSE

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
MAESTRÍA EN CIENCIAS DE LA INFORMACIÓN Y LAS COMUNICACIONES
BOGOTÁ, COLOMBIA
2022

Dedicatoria

*A mi madre y mis hermanos, a mi pareja, a mis amigos, a mis maestros y
compañeros que me han acompañado y apoyado en este proceso.*

Agradecimientos:

- Agradecimiento especial a la Universidad Distrital Francisco José de Caldas, mi Alma Máter, base fundamental de mi crecimiento personal, académico y profesional.
- A mi madre, mis hermanos y a mi pareja por el apoyo incondicional, la paciencia, el cariño y acompañamiento que me han brindado desde el inicio de este proceso.
- A los miembros de la Maestría en Ciencias de la Información y las Comunicaciones, docentes y administrativos, a quienes agradezco profundamente los conocimientos brindados, el apoyo y disposición. A mis compañeros de la maestría quienes siempre me dieron una mano cuando lo necesité.
- Especial agradecimiento al docente Julio Barón Velandia, por su apoyo, sus conocimientos, mentoría y acompañamiento en este proyecto y en mi crecimiento académico y profesional.
- A los docentes, Paulo Alonso Gaona García y Carlos Enrique Montenegro Marín, por su interés y apoyo en mi proyecto, y su gran disposición.

Resumen

Este documento presenta el desarrollo de una ontología en el dominio agrícola para la recomendación de cultivos y zonas cultivables en un periodo específico, a partir de variables climáticas que influyen en el buen desarrollo de los cultivos. Mediante Methontology se define un modelo conceptual relacionando los conceptos básicos de desarrollo efectivo de cultivos como lechuga, maíz, fresa, tomate, zanahoria, lulo y cacao, de acuerdo con las especificaciones y recomendaciones propuestas en la documentación del gobierno colombiano. El modelo de inferencia generado toma los resultados de pronóstico de variables climáticas y genera recomendaciones de zonas y cultivos con la aplicación de la lógica descriptiva que, a partir de reglas, genera inferencias para identificar las opciones de cultivo y áreas cultivables que presentan mayor rendimiento. La precisión del modelo se evalúa utilizando datos históricos de cultivos producidos anteriormente en zonas del país, haciendo una comparación entre los datos reales y los resultados obtenidos a través del modelo ontológico, proporcionando un alto nivel de confiabilidad.

Palabras Claves

Modelo ontológico, ontología, agricultura, lógica de predicados de primer orden, inferencia, variables climáticas, serie de tiempo, forecasting.

Índice general

Capítulo 1	14
Introducción	14
1.1 Problema de investigación	15
1.2 Objetivos	16
1.3 Marco referencial	17
1.4 Hipótesis	26
1.5 Metodología	26
Capítulo 2	30
Alcances y limitaciones	30
2.1 Alcances	30
2.2 Limitaciones	30
Capítulo 3	31
Desarrollo de la investigación	31
3.1 Definición del modelo conceptual	31
3.2 Proyección de datos climáticos	51
3.3 Integración del modelo ontológico y la predicción de variables climáticas 64	
3.4 Validación del modelo de inferencia	65
3.5 Resultados y análisis	68
3.6 Prototipo de software	74
Capítulo 4	78
Conclusiones	78
Capítulo 5	80
Prospectiva del trabajo de grado	80
5.1 Productos	80

5.2	Recomendaciones y trabajos futuros	80
Capítulo 6		82
Referencias		82

Índice de Figuras

Figura 1. Arquitectura general de ejecución del proyecto. Elaboración propia.....	27
Figura 2. Ciclo de vida Methontology. Basado en (M. Fernández et al., 1997).....	32
Figura 3. Actividades de conceptualización del modelo. Elaboración propia.....	34
Figura 4. Diagrama de relaciones binarias. Elaboración propia.....	35
Figura 5. Ejemplo de creación de clases con Owlready2. Elaboración propia.....	47
Figura 6. Ejemplos de creación de relaciones con Owlready2. Elaboración propia...	48
Figura 7. Ejemplos de creación de atributos con Owlready2. Elaboración propia.	48
Figura 8. Ejemplo de creación de individuos con Owlready2. Elaboración propia. ...	49
Figura 9. Ejemplo de creación de reglas con Owlready2. Elaboración propia.....	49
Figura 10. Visualización de la ontología con WebVOWL. Elaboración propia.....	50
Figura 11. Muestra del dataframe de la humedad. Elaboración propia.....	52
Figura 12. Muestra del dataframe de la temperatura. Elaboración propia.....	52
Figura 13. Ejemplo de conteo de datos por municipio para conjuntos de datos de Temperatura. Elaboración propia.....	53
Figura 14. Estadísticas descriptivas de los dataframes para Temperatura y Humedad. Elaboración propia.....	54
Figura 15. Conteo de los meses por año para los departamentos en la variable Temperatura. Elaboración propia.....	55
Figura 16. Series de tiempo para departamentos en la variable Temperatura. Elaboración propia.....	56
Figura 17. Conteo de los meses por año para los departamentos en la variable Humedad. Elaboración propia.....	57
Figura 18. Series de tiempo para departamentos en la variable Humedad. Elaboración propia.....	58
Figura 19. Rangos identificados para los conjuntos de datos por variable. Elaboración propia.....	59
Figura 20. Ejemplo de identificación de anómalos con pycaret.anomaly. Elaboración propia.....	60

Figura 21. Estacionariedad de las series de tiempo para Temperatura y Humedad. Elaboración propia.....	61
Figura 22. Integración del modelo ontológico con la predicción de variables climáticas. Elaboración propia.....	64
Figura 23. Muestra de los datos históricos. Elaboración propia.....	66
Figura 24. Muestra de datos históricos con los valores de predicción de humedad y temperatura	67
Figura 25. Visualización de individuos con Protégé. Elaboración propia.....	68
Figura 26. Porcentaje de registros por zona. Elaboración propia.....	69
Figura 27. Casos históricos y resultados inferidos por periodo para zonas. Elaboración propia.....	69
Figura 28. Porcentaje de registros por cultivo. Elaboración propia.	71
Figura 29. Casos históricos y resultados inferidos por periodo para cultivos. Elaboración propia.....	71
Figura 30. Arquitectura general de capas de la aplicación Web OntoAgri. Elaboración propia.....	75
Figura 31. Ejemplo de visualización de la aplicación web OntoAgri para ingreso de usuarios. Elaboración propia.	76
Figura 32. Ejemplo de visualización de la aplicación web OntoAgri para recomendaciones. Elaboración propia.....	76

Índice de Tablas

Tabla 1. Especificación del modelo ontológico	33
Tabla 2. Glosario de conceptos	34
Tabla 3. Diccionario de conceptos.....	36
Tabla 4. Definición de relaciones binarias	38
Tabla 5. Definición de atributos de clase e instancia.....	39
Tabla 6. Ejemplo de constantes del modelo	41
Tabla 7. Definición de reglas generales.....	43
Tabla 8. Definición de reglas de clasificación	44
Tabla 9. Definición de reglas de relación de cultivos.....	44
Tabla 10. Definición de reglas de recomendación	45
Tabla 11. Ejemplo de resultado de entrenamiento de modelos de Darts para Temperatura - Puerto Salgar	62
Tabla 12. Ejemplo de resultado de entrenamiento de modelos de Pycaret para Temperatura - Puerto Salgar	62
Tabla 13. Modelos seleccionados para el forecasting de series de tiempo	63
Tabla 14. Descripción de individuos adicionados a la ontología.....	67
Tabla 15. Resultado de recomendación de zonas	70
Tabla 16. Resultados de recomendación de cultivos.....	72
Tabla 17. Resultados de métricas de nivel de clases.	73

Capítulo 1

Introducción

El desarrollo agrícola en Colombia es una fuente de ingresos para los campesinos, las regiones y la nación. Una buena producción agrícola toma en cuenta características que no siempre son conocidas o consideradas por los cultivadores, tales como temperatura, topografía, humedad, ciclo del cultivo, plagas, etc. El Gobierno Nacional, la comunidad científica y organizaciones como el IDEAM se han esforzado en poner a disposición documentación relacionada a las distintas técnicas y requerimientos para el desarrollo efectivo de los cultivos que se dan en el país, y los cambios climáticos; sin embargo, esta información presenta dificultades de acceso para los cultivadores por su formato, estructura, lenguaje, dispersión, relación y extensión. Adicionalmente, la terminología usada en la agricultura no está estandarizada, principalmente porque el desarrollo agrícola ha sido en su mayoría local, por lo que los nombres utilizados para las técnicas, características, cultivos, entre otros, pueden variar.

Es importante identificar los aspectos de mayor pertinencia para un buen desarrollo agrícola y su integración, proporcionando herramientas que permitan el acceso a información relacionada con cultivos, zonas cultivables y comportamiento climático, para mejorar la elección de cultivos y el uso del suelo. En este estudio se presenta un modelo ontológico que relaciona características fisiológicas, geográficas y climatológicas, correspondientes a la producción de cultivos de hortalizas, frutos, granos y raíces, como un medio para centralizar la información básica y limitar la dispersión de documentos. Las inferencias lógicas utilizadas posibilitan realizar deducciones de los diferentes aspectos involucrados en la producción de cultivos agrícolas, permitiendo elaborar proyecciones y recomendaciones de tipos de cultivos que pueden plantarse en una determinada zona y período del año, de acuerdo con el comportamiento climático.

Este documento se divide en los siguientes capítulos: el capítulo 1 contiene el problema de investigación, conformado por el planteamiento, formulación y sistematización del problema, objetivos del proyecto, el marco referencial, la hipótesis investigativa y la metodología abordada; el capítulo 2 establece los alcances y limitaciones; el capítulo 3 presenta el desarrollo de la investigación, donde se aborda la identificación

de características en el dominio de la agricultura y diseño del modelo conceptual, la adquisición, preprocesamiento y análisis de los datos climáticos, la construcción y validación del modelo de inferencia, resultados y análisis, y su implementación en un prototipo software; el capítulo 4 presenta las conclusiones y principales aportes de la investigación; el capítulo 5 se presenta las perspectivas del trabajo realizado y finalmente, el capítulo 6 las referencias bibliográficas.

1.1 Problema de investigación

1.1.1 Planteamiento del problema

La agricultura en Colombia ha basado su desarrollo en el conocimiento adquirido por los campesinos de manera tradicional, a través de las prácticas llevadas a cabo de generación en generación. Una producción agrícola efectiva, toma en cuenta aspectos propios que corresponden a las características de la zona, del cultivo y su fisiología, del comportamiento climatológico y del período en que se efectúa el cultivo; esto se encuentra definido en manuales técnicos como (Gobernación de Antioquia, 2014, 2015) los cuales fomentan las buenas prácticas agrícolas y son establecidos por el Gobierno Nacional. Estos aspectos no siempre son considerados o conocidos formalmente por los cultivadores, lo que hace que ellos repitan los mismos ciclos y tipos de cultivo, ocasionando: sobreproducción, cansancio de los terrenos, erosión, mayor exposición a plagas y enfermedades, entre otros. Según (Maussa, 2018) la falta de buenas prácticas ha causado que aproximadamente el 40,5 % de los productos se pierdan durante la etapa de producción agrícola. Por otro lado, el Sistema de Información Ambiental de Colombia (SIAC, 2012) afirma que la degradación del suelo en el territorio nacional, se debe al desconocimiento de la importancia y de su funcionamiento.

Aunque existe un gran porcentaje de información disponible y abierta al público formalizada en manuales y fichas técnicas tales como (Beltrán & Zhindon, 2012; Cámara de comercio de Bogotá, 2015), que han sido desarrollados y aprobados por entidades gubernamentales, carece de accesibilidad para la comunidad campesina, debido al formato y especificidad del lenguaje técnico usado.

Por otra parte, la variabilidad climática hace que el comportamiento de los cultivos esté por fuera de las características esperadas. Como se plantea en (M. E. Fernández, 2013), dada la dependencia de la agricultura con el comportamiento climático y eventos como inundaciones, deslizamientos de terrenos, propagación de plagas y enfermedades, entre otros, generan un impacto negativo en el ámbito socioeconómico regional.

Las malas prácticas o el comportamiento inesperado de los cultivos pueden derivar en grandes daños en los mismos y pérdidas en la inversión realizada por el agricultor. Así mismo, se vería una disminución en la producción del sector local y la generación de

problemas económicos en la región y/o departamento, que afectaría directamente en la economía nacional, al representar la agricultura el 7,4 % del Producto Interno Bruto (PIB) en Colombia, de acuerdo con los datos sobre las cuentas nacionales del Banco Mundial¹ para el año 2021.

Partiendo de la documentación oficial dispuesta por las entidades gubernamentales del país, artículos relacionados, además de consultar con expertos, es posible establecer aquellos elementos clave en el desarrollo de un cultivo en una terminología común y entendible, representada en un modelo conceptual que especifique las relaciones entre los conceptos y facilite la generación de conocimiento.

Una vez establecidos los conceptos con sus relaciones y atributos, es posible generar deducciones respecto al comportamiento de un cultivo, a través de reglas establecidas con inferencias lógicas y el uso de técnicas que permitan proyectar el comportamiento climático de una región en un período específico, a través de la estimación de datos climáticos históricos, para así recomendar cuál cultivo podría desarrollarse apropiadamente de acuerdo con las condiciones de la zona y características del cultivo.

1.1.2 Formulación del problema

¿Cómo inferir información que permita a los agricultores establecer opciones de cultivos de mayor productividad a partir de caracterizaciones geográficas, fisiológicas y climatológicas?

1.2 Objetivos

1.2.1 Objetivo general

Diseñar un modelo de inferencia ontológica en el dominio de la agricultura que integre información proporcionada por diferentes fuentes y entidades a partir de razonamiento basado en lógica descriptiva para el establecimiento de recomendaciones de opciones de cultivo, períodos y zonas cultivables.

1.2.2 Objetivos específicos

- Determinar las características fundamentales para un desarrollo agrícola efectivo, a partir de las variables climáticas de mayor influencia, que permitan su descripción mediante un modelo conceptual.

¹ <https://datos.bancomundial.org/indicador/NV.AGR.TOTL.ZS?locations=CO>

- Establecer deducciones a nivel computacional con base en variables climáticas, para inferir los tipos de productos agrícolas que tienen mayor probabilidad en una determinada zona.
- Definir escenarios característicos que permitan evaluar la confiabilidad del modelo, seleccionando cultivos y zonas que cumplan con un conjunto de condiciones específicas en un período determinado del año.

1.3 Marco referencial

En este documento, el marco referencial se conforma por marco teórico, marco conceptual y marco espacial. El marco teórico presenta las teorías sobre las que se desarrolla esta investigación y los postulados de algunos autores que han presentado trabajos en el área de interés. El marco conceptual presenta aquellos términos técnicos que se emplean en el trabajo y se relacionan con las teorías definidas. Finalmente, el marco espacial define la población objetivo y la región geográfica del estudio.

1.3.1 Marco conceptual

1.3.1.1 Agricultura

La agricultura hace referencia a un conjunto de actividades que interfieren en el suelo, el medio natural y la producción vegetal para su transformación y uso en la alimentación y sustento de los seres humanos; el término *agricultura* se utiliza generalmente para referirse a la producción de cultivos (Organización de las Naciones Unidas para la Alimentación y la Agricultura, 2018).

1.3.1.2 Desarrollo agrícola

El desarrollo agrícola tiene en cuenta una serie de características que influyen en su buen desempeño:

- **Zona agrícola:** definida por la FAO como cualquier superficie de tierra arable, pradera o pastizal en las que se dan cultivos permanentes o huertos domésticos (Organización de las Naciones Unidas para la Alimentación y la Agricultura, 2009).
- **Suelo** definido como: *“cuerpo tridimensional que ocupa la parte superior de la corteza terrestre y que tiene propiedades diferentes de las del material rocoso subyacente debido a las interacciones del clima, los organismos vivos el material de roca madre y el relieve a lo largo de períodos de tiempo”*
- **Fenología:** *“las etapas del desarrollo y de los fenómenos biológicos periódicos, que son determinados por los factores atmosféricos y meteorológicos”* (Organización de las Naciones Unidas para la Alimentación y la Agricultura, 2018).
- **Topografía:** conjunto de características que representan un terreno en su configuración superficial (Real Academia Española, 2018).

- **pH:** es la medida de acidez o alcalinidad de una sustancia. El pH neutro es 7 y a medida que tiende a 0 es más ácido y a medida que tiende a 14 es básico (Cámara de comercio de Bogotá, 2015).
- **Humedad relativa:** es la relación entre la cantidad de vapor de agua que contiene el aire y la que tendría si estuviera 100% saturado (Cámara de comercio de Bogotá, 2015).

1.3.1.3 Cultivo

Un cultivo se define como una “planta que se cultiva para ser recolectada y usada por el agricultor o vendida” (Organización de las Naciones Unidas para la Alimentación y la Agricultura, 2018); el cultivo cuenta con unas características fisiológicas que lo representa y/o clasifica. Por ejemplo, se puede hablar de tipo de cultivo haciendo referencia a una clasificación por la especie de producto que se siembra tales como cereal, hortaliza, fruta, tubérculo, entre otros.

1.3.1.4 Condiciones agroclimatológicas en el desarrollo agrícola

- **Climatología:** trata la distribución geográfica o temporal de observaciones meteorológicas durante un período de tiempo determinado (Organización de las Naciones Unidas para la Alimentación y la Agricultura, 2018).
- El **cambio climático** se define (Organización de las Naciones Unidas para la Alimentación y la Agricultura, 2009) como el cambio del clima que altera la composición de la atmósfera y se suma a la variabilidad natural del clima por periodos.
- **Clima:** es una situación de la atmósfera en un lugar en una región específica durante un período prolongado; el clima puede ser la suma de elementos como (Organización de las Naciones Unidas para la Alimentación y la Agricultura, 2009) radiación solar, temperatura, humedad, frecuencia y volumen de precipitaciones, presión atmosférica, velocidad y dirección del viento y sus variaciones.

1.3.1.5 Ontologías

Las ontologías son un método de modelado conceptual que permite describir la estructura y comportamiento de los dominios modelados.

La definición que mejor describe el tipo de estudio en el contexto de las ciencias informáticas y de la información dada en (Liu & Tamer Özsu, 2009), plantea que una ontología define un conjunto de representaciones primitivas con las que modelar un dominio de conocimiento o discurso, que incluyen información sobre su significado y restricciones sobre su aplicación lógica consistente. Éstas son típicamente clases (o conjuntos), atributos (o propiedades) y relaciones (o relaciones entre los miembros de la clase).

1.3.1.6 Representación ontológica en el dominio agrícola

La representación de los conceptos geográficos, fisiológicos y climatológicos, se llevan a cabo ontológicamente. Según (Wache et al., 2002), para establecer una representación ontológica es necesario la identificación de conceptos, propiedades y axiomas que se interrelacionan; por lo tanto, la representación ontológica se refiere a la integración de datos que se basa en ontologías y usa una base de conocimientos para integrar información proveniente de variadas fuentes.

- La representación ontológica se puede lograr gráficamente a través de una **taxonomía** (Díaz Piraquive et al., 2009) que trata sobre principios, métodos y fines de clasificación, para procurar la organización jerárquica y sistemática, dando nombres a los grupos de elementos y a los elementos mismos.
- Desde el punto de vista de una *Ontología*, un **concepto** es una idea básica que se pretende formalizar, que puede ser una clase de objeto, métodos, planes, estrategias, procesos de razonamiento, entre otros (Díaz Piraquive et al., 2009).
- **Relaciones:** representan un tipo de asociación, interacción y enlace entre los conceptos del dominio, y suelen formar la taxonomía del dominio (Corcho et al., 2005; Díaz Piraquive et al., 2009)
- **Axiomas:** expresiones lógicas que suelen utilizarse para definir restricciones en la ontología (Corcho et al., 2005).
- **Reglas:** se utilizan para deducir conocimientos en la ontología construida, como pueden ser atributos, propiedades, instancias, entre otros (Corcho et al., 2005). Estas reglas pueden expresarse con **lógica de predicados** de primer orden ya que es un lenguaje formal que permite realizar deducciones al obtener conclusiones que son resultado de premisas lógicas evaluadas utilizando elementos tales como variables, constantes, funciones y cuantificadores, y conectores como negación y disyunción (Mylopoulos & Levesque, 1983; Ono et al., 1992).

1.3.1.7 Lenguajes para el desarrollo de ontologías

- **Web Ontology Language (OWL):** se define por World Wide Web Consortium como: *“lenguaje de Web Semántica diseñado para representar un conocimiento rico y complejo sobre cosas, grupos de cosas y relaciones entre cosas”* (World Wide Web Consortium, 2004). Este lenguaje describe y construye ontologías con una gran semántica basada en la lógica de descripción, y se basa en el Lenguaje de marcado extensible (XML) y el Marco de descripción de recursos (RDF) que hace posible definir los esquemas de las etiquetas definidas por el usuario y permite representación de datos (O'Connor, 2009; Tang et al., 2018).
- **OWL-DL (Description Logic):** lenguaje de descripción lógica para objetos de OWL diseñado para soportar el segmento de negocio existente de lógica descriptiva y tiene propiedades computacionales deseables para los sistemas de razonamiento; incluye todas las construcciones y restricciones de OWL (World Wide Web Consortium, 2004).

- **Semantic Web Rule Language (SWRL):** lenguaje de reglas que permite la expresión de inferencias lógicas computacionalmente de alto nivel, extendiendo la expresividad de OWL a la construcción de un modelo de razonamiento basado en el conocimiento descrito por OWL (O'Connor, 2009; Tang et al., 2018).

1.3.1.8 Series de tiempo

Una serie de tiempo es una secuencia de puntos de datos para una variable, típicamente medidos en momentos sucesivos, generalmente en intervalos de tiempo uniformes. El análisis de series de tiempo comprende métodos para comprender tales series de tiempo y hacer pronósticos (predicciones) de su patrón futuro (Brockwell, 2020).

1.3.1.8.1 Series de tiempo estacionarias

Una serie de tiempo estacionaria es aquella sin cambio sistemático en la tendencia, sin cambio sistemático en la varianza y eliminación de variaciones estrictamente periódicas (Brockwell, 2020).

1.3.1.8.2 Forecasting de series de tiempo y modelos

Es la predicción de valores futuros de una variable basada en los valores pasados observados (Ratna Prakarsha & Sharma, 2022). Los enfoques clásicos incluyen modelos estadísticos como ARIMA donde se asume que el valor actual de la serie temporal es una combinación lineal de observaciones históricas o choques aleatorios. Los métodos de aprendizaje automático, como la regresión lineal, la regresión de crestas y los modelos no lineales, por ejemplo, redes neuronales artificiales, se aplican a las tareas de pronóstico. Más recientemente, los modelos de aprendizaje profundo como Redes Neuronales Recurrentes (RNN) y Redes Neuronales Gráficas (GNN) han demostrado con éxito un rendimiento sobresaliente en la previsión de series temporales (Yin et al., 2019).

1.3.1.9 Medición del error en la predicción

Para la medición del error, se aplican métricas que permiten la evaluación del éxito de una predicción numérica mediante el establecimiento de diferentes medidas. Las métricas aplicadas en este estudio se presentan a continuación:

- **Error cuadrático medio (Mean-Squared error - MSE):** es una de las medidas más comunes; generalmente se acompaña del uso de la raíz cuadrada para expresar el error en las mismas dimensiones que los valores predichos, conocido como **RMSE**. Permite medir el promedio de los cuadrados de los errores obteniendo siempre valores positivos (Witten et al., 2017a).
- **Raíz del error cuadrático medio (Root mean square error – RMSE):** al igual que MAE, RMSE se usa comúnmente en la literatura. Si bien tanto MAE como RMSE son

indicadores adecuados para evaluar el rendimiento de un modelo, se debe preferir el RMSE cuando los errores del modelo siguen una distribución Gaussiana (González-Sopeña et al., 2021).

- **Error absoluto medio (Mean-Absolute Error - MAE):** es una medida que promedia la magnitud de los errores individuales sin tener en cuenta el signo mediante la distancia horizontal promedio entre cada punto y la línea de identidad. Los errores son tratados de acuerdo con su magnitud, por lo que no es muy sensible a los valores atípicos (Witten et al., 2017b).
- **Error logarítmico cuadrático medio de la raíz (Root Mean Squared Logarithmic Error - RMSLE):** es el valor logarítmico de la media de los residuos. Los errores de predicción pueden ocurrir en áreas con grandes valores atípicos, así como en áreas con pequeños valores atípicos. RMSLE calcula un error asignando penalizaciones a elementos con valores atípicos subestimados en lugar de elementos con valores atípicos sobreestimados (Jeong et al., 2020).
- **Error porcentual absoluto medio (Mean absolute percentage error - MAPE):** Cuantifica la precisión como un porcentaje del error. Sin embargo, el MAPE produce valores muy grandes cuando los valores reales son cercanos a cero y no está definido cuando el valor real es igual a cero (González-Sopeña et al., 2021).

1.3.1.10 Métricas a nivel de ontología y clases

El nivel de complejidad y dependencia de la ontología se evalúa con base en las métricas propuestas por (Zhang et al., 2010):

1.3.1.10.1 Métricas a nivel de ontología

- **Tamaño del vocabulario (Size of vocabulary - SOV).** Mide la cantidad de vocabulario definido en la ontología.
- **Proporción de los nodos de borde (Edge node ratio - ENR).** Mide la densidad de conectividad entre conceptos.
- **Impureza del árbol (Tree impurity - TIP).** Mide el punto en que la jerarquía de la ontología se desvía de ser una taxonomía.

1.3.1.10.2 Métricas a nivel de clases o conceptos

- **Número de hijos (Number of Children - NOC).** Mide el número de subconceptos que heredan directamente de un concepto dado.
- **Profundidad de herencia (Depth of inheritance - DIT).** Mide el número de conceptos ancestrales que pueden afectar otro concepto, esto para determinar la cantidad de dependencias que tiene un concepto a otro, en sentido de herencia.
- **Clases de entrada (Class in-degree - CID).** Mide el número de relaciones de entrada en un concepto o clase dada; es decir, señala el número de clases de las que depende la clase, por lo tanto, un cambio de cualquiera puede afectarle.

- **Clases de salida (Class out-degree - COD).** Mide el número de relaciones de salida en un concepto o clase dada; es decir, señala el número de clases que dependen de la misma, por lo tanto, un cambio puede afectar a las otras.

1.3.2 Marco teórico

1.3.2.1 *Las ontologías en diferentes dominios*

Las ontologías se han utilizado considerablemente en diferentes áreas como un medio para la representación del conocimiento del dominio y la integración de datos, organizándolos de manera lógica y estructurada (Y. Bin Kang et al., 2019). Esta estructura facilita el intercambio, agregación y recuperación de conocimiento, además de brindar capacidades de deducción y razonamiento para responder preguntas y generar nuevo conocimiento (Fox et al., 1996; Gruber, 1995). En estudios como (El Ghosh et al., 2017) exponen un sistema de peritajes jurídicos basado en reglas integrando una ontología en el dominio penal y reglas lógicas, con el objetivo de resolver problemas jurídicos. Por su parte, (Chou et al., 2018) desarrollaron un modelo ontológico con construcciones de lenguaje de reglas de web semántica para ayudar en el proceso de generación de guiones para terremotos en Taiwán, encontrando que el modelo ayudó a los socorristas a percibir el impacto del terremoto para poder progresar en la zona. Los autores de (Alkhamash, 2020), presentan un prototipo para el desarrollo de sistemas seguros y confiables en ciudades inteligentes utilizando ontologías con el fin de identificar los requisitos para el modelado, ayudando a reducir los esfuerzos de verificación. Los autores concluyeron que la mayoría de las pruebas del modelo se ejecutan automáticamente sin necesidad de intervención humana.

1.3.2.2 *Ontologías en el dominio de la agricultura*

Las ontologías en el dominio de la agricultura son herramientas que ayudan a que el conocimiento esté disponible en el dominio de una manera efectiva y organizada. Esto permite agrupar los conocimientos definidos a través de una serie de conceptos clave y estandarizar el lenguaje para apoyar su uso por parte de los agricultores. Los autores de (Ingram & Gaskell, 2019) reconocen la importancia de brindar herramientas para el acceso a datos en la agricultura, que permitan efectivamente la movilización de recursos de conocimiento y mejoren la innovación. En su estudio, presentaron un enfoque innovador para capturar una gran cantidad de conocimiento en agricultura y hacerlo accesible a través de una ontología similar a un motor de búsqueda que ayuda a los agricultores a encontrar resultados de investigación útiles. Los autores co-crearon una ontología con el apoyo de las partes interesadas para definir un lenguaje común para expresar preguntas y respuestas en el dominio específico. Por su parte, (Arnaud et al., 2020) discute el valor de la Comunidad de Práctica (CoP) de Ontologías para aprovechar

la experiencia relevante en el desarrollo de ontologías en el dominio de la agricultura e identificar soluciones innovadoras que apoyen la anotación de datos de calidad, para apoyar la interoperabilidad de los datos heterogéneos y multidisciplinarios generados por la investigación sobre la agricultura global sostenible y los sistemas agroalimentarios. Los autores concluyen que es importante que la CoP estimule la colaboración en el desarrollo de gráficos de conocimiento en agricultura que apoyen las bases de datos de gráficos, un dominio en el que la industria agroalimentaria ha progresado rápidamente.

En el dominio de la agricultura, se han desarrollado varios estudios donde se usan ontologías para la representación del conocimiento y su aporte para los agricultores. Autores como (Lacasta et al., 2018) se han centrado en el manejo de las plagas en los cultivos, presentando un sistema de recomendación de tratamientos para la protección de las siembras. Asimismo, (Lagos-Ortiz et al., 2020) presenta el desarrollo de una plataforma Web para el diagnóstico y manejo de plagas en los cultivos; los autores concluyeron que el sistema ha demostrado producir respuestas similares al asesoramiento profesional brindado por los expertos en entomología involucrados en el proceso de evaluación.

Otras investigaciones han profundizado en un cultivo específico: por ejemplo, (Vilma, 2014) presenta una ontología para papas mejoradas, donde se tienen en cuenta factores tales como la morfología, agronomía, fenología, entre otros, con el fin de facilitar el intercambio de información; (Wang & Wang, 2018) desarrolla una ontología sobre cultivos cítricos capturando los conceptos elementos clave en el desarrollo de un cultivo, relacionados con el suelo y los fertilizantes, reconociendo la importancia del suelo y sus minerales como parte del proceso de cultivo. Otros autores como (Bonacin et al., 2016), presentan una ontología que representa el conocimiento sobre los impactos de las actividades agrícolas y los cambios climáticos en los recursos hídricos, contando con más de 8000 conceptos relacionando la calidad del agua, ubicación y tiempo.

1.3.2.3 La lógica descriptiva en las ontologías

La generación de nuevo conocimiento puede lograrse con la aplicación de teoría lógica que permite el razonamiento automatizado en el modelamiento del mundo real (Gulyaeva & Artemieva, 2019). A nivel semántico, la lógica descriptiva permite la representación de la información en un alto nivel de expresividad y la obtención de inferencias con un alto nivel de precisión que se basan en un modelo descrito en lenguajes como Web Ontology Language (OWL) (Pinilla-García & Barón-Velandia, 2015). Para la expresión de reglas que permiten una mayor expresividad de la ontología, el lenguaje adecuado es OWL-DL (Description Logic) el cual fue diseñado para soportar el segmento de negocio existente de lógica descriptiva y tiene propiedades computacionales deseables para los sistemas de razonamiento (World Wide Web Consortium, 2004). Así mismo, el lenguaje de reglas Semantic Web Rule Language (SWRL) permite transformar las reglas en lógica de predicados a un lenguaje procesable computacionalmente, que incluye una

sintaxis abstracta de alto nivel para expresiones lógicas, expresadas en términos OWL, tales como clases, propiedades, individuos, etc. (O'Connor, 2009). Diferentes estudios (Chou et al., 2018; Y. Bin Kang et al., 2019; Lagos-Ortiz et al., 2020; Oliva-Felipe et al., 2017) han demostrado cómo la aplicación de lógica descriptiva ha permitido la generación de conocimiento a través de inferencias que mediante razonamiento generan deducciones sobre el conocimiento existente; cuanto más expresivo es el lenguaje ontológico, más preciso es el significado pretendido de un vocabulario y, en consecuencia, se pueden extraer conclusiones más precisas (Oliva-Felipe et al., 2017).

1.3.2.4 Gestión de la información en el dominio agrícola

En Colombia, la agricultura representa una de las actividades económicas más importantes, por lo que el Gobierno Nacional ha proporcionado a través de entidades oficiales diferente tipo de información tal como informes, manuales técnicos de cultivos, estudios de suelo, reportes de producción, etc. Las propiedades heterogéneas que presenta la información agrícola actualmente, hace que sea importante formalizar funciones para su adquisición, análisis, mantenimiento, almacenamiento, recuperación y posterior uso como un sistema de información; en (Weik, 2001), esto se define como gestión de la información. El modelado es una actividad muy importante en la gestión de la información, ya que permite describir aspectos del mundo físico para su comprensión e intervención (Carvalho et al., 2017; Verdonck et al., 2019). Por lo tanto, se definen los modelos conceptuales (Verdonck et al., 2019) para aumentar la comprensión y comunicación de un dominio entre las partes interesadas.

1.3.2.5 Características climatológicas y agricultura

El Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) de Colombia, ha reconocido el impacto del cambio climático en la agricultura y ha desarrollado diferentes escenarios para variables como precipitación y temperatura, basados en información de condiciones iniciales con diferentes modelos de baja resolución de otros países, descrito en (IDEAM, 2010). Sin embargo, y como lo afirma (M. E. Fernández, 2013), existen pocos estudios que exploran la influencia del cambio climático en la agricultura.

En el dominio del cambio climático y medio ambiente, se encuentran estudios como (Oprea, 2018), que proporciona un marco de modelado de conocimiento de sistemas inteligentes como soporte para decisiones ambientales, usando ontologías para representar el dominio y un algoritmo de reglas para el razonamiento. Así mismo, (Masmoudi et al., 2018) lleva a cabo una ontología modular para la representación del dominio del monitoreo ambiental, usando lógica descriptiva para la definición de reglas; a través de preguntas en lenguaje natural que se procesan como consultas, se obtienen resultados que pueden especificar si hubo mucha lluvia, lluvia moderada o poca lluvia en

un año específico. Aunque en estos estudios se reconoce que puede haber una aplicación en agricultura, no se enfoca en este dominio y no se relaciona directamente.

1.3.2.6 Herramientas para la implementación computacional de ontologías

La construcción de ontologías en términos de OWL y SWRL se puede realizar a través de diferentes herramientas y lenguajes de programación. En (Shishehchi & Banihashem, 2021) se construye una ontología para el diagnóstico de la enfermedad de PTI utilizando Protégé, un software de edición de ontologías basado en Java que admite OWL y reglas definidas con SWRL. Los autores implementaron una interfaz gráfica de usuario usando el marco web semántico de Jena, que proporciona API para aplicaciones Java. De esta forma, los usuarios podían agregar los síntomas y otras especificaciones a través de la interfaz gráfica local. Por su parte, los autores de (Jankovic et al., 2020) implementaron una ontología para la inferencia de captura de ADR utilizando Protégé como herramienta de edición. Los autores utilizaron Owlready2, la biblioteca de Python que permite cargar ontologías del lenguaje OWL como objetos de Python, para importar datos a la ontología creada. Por otro lado, en (Buoncompagni et al., 2022) se desarrolló OWLOOP, una API para utilizar OWL con programación orientada a objetos. Las entidades OWL se definieron utilizando el lenguaje de programación Java, para encapsular entidades OWL, basadas en aMOR, una biblioteca que permite el uso de OWL-API, una API Java para crear y manipular ontologías.

1.3.2.7 Métricas para medir cualidades de una ontología

En el campo de la agricultura, se encuentran autores como (Y. Bin Kang et al., 2019; Masmoudi et al., 2018; Wang & Wang, 2018) quienes de manera similar aplican métricas para medir cualidades como extensibilidad, interoperabilidad, complejidad, modularidad, entre otros, de tal forma que la ontología sea validada no solo en aspectos funcionales, sino también en aspectos estructurales. Por otro lado, autores como (Y.-B. Kang et al., 2012; Zhang et al., 2010), han presentado métricas que permiten medir el rendimiento de las inferencias lógicas y la complejidad de un modelo ontológico.

1.3.2.8 Forecasting en series de tiempo en variables climáticas

Las series de tiempo son un conjunto de datos que toman un valor cuantitativo a través del tiempo y generalmente se dividen en los mismos periodos. Las series de tiempo pueden ser una buena alternativa para forecasting a corto tiempo (Panaggio et al., 2022). Existen una variedad de aplicaciones de forecasting en series de tiempo como en economía (Alashari et al., 2022), señales cerebrales (Ratna Prakarsha & Sharma, 2022), geografía (Bolton et al., 2020), medicina (Panaggio et al., 2022), entre otros. Asimismo, existen variados estudios de forecasting en series de tiempo para variables climáticas. En (Yao et al., 2020) los autores establecieron un modelo de estructura de tendencias de series

temporales (TSTM) utilizando el análisis de patrones y reglas de series temporales, las tendencias de patrones y reglas, y tendencias en confianza y soporte, para las variables de lluvia y evaporación. El modelo propuesto logra obtener de manera efectiva la información hidrológica potencial contenida en los datos de series temporales. Por su parte (Karevan & Suykens, 2020) se presenta un modelo de pronóstico basado en datos para una aplicación de pronóstico del tiempo, evaluando el modelo en dos periodos de tiempo diferentes al año. Los autores muestran en sus resultados que su modelo presenta un mejor desempeño en la tarea de predicción. En el estudio de (Sanhudo et al., 2021) se presenta una metodología de aprendizaje automático que propone la aplicación de algoritmos de regresión para rectificar los valores erróneos en los conjuntos de datos y la agrupación de estaciones meteorológicas, en función de sus condiciones climáticas registradas, para mejorar los modelos de regresión. Los autores de (Hewage et al., 2020) realizan el desarrollo y la evaluación de un sistema de pronóstico del tiempo ligero y novedoso, que consta de estaciones meteorológicas locales y técnicas de aprendizaje automático para el pronóstico del tiempo utilizando datos de series temporales. El sistema explora la red convolucional temporal (TCN) y las redes de memoria a corto plazo (LSTM) de última generación mostrando que el modelo propuesto se puede utilizar como una herramienta eficiente de pronóstico del tiempo localizado.

1.3.3 Marco espacial

Teniendo en cuenta el problema planteado y los objetivos de la investigación, el marco espacial se circunscribe al departamento de Cundinamarca de Colombia, donde se pueda contar con una base de información lo suficientemente representativa para realizar el análisis. Esta investigación va dirigida a la población interesada en el proceso productivo de cultivos, en especial agrónomos y agricultores.

1.4 Hipótesis

La aplicación de lógica descriptiva sobre un modelo ontológico que integra variables geográficas, fisiológicas y climatológicas en el dominio de la agricultura, permite realizar recomendaciones sobre opciones de cultivo y zonas cultivables en un periodo específico.

1.5 Metodología

En este capítulo se plantean las fases de aplicación de este estudio, las cuales presentan unas actividades que van encaminadas al cumplimiento de los objetivos previamente planteados y se desarrollan mediante un proceso iterativo incremental. En la Figura 1 se presenta el flujo general de ejecución del proyecto, donde a partir de la identificación del conocimiento en el dominio de la agricultura, se identifican las

	Fuentes de información
--	------------------------




Figura 1. Arquitectura general de ejecución del proyecto. Elaboración propia.

Con base en las características básicas, se hace un diseño del modelo conceptual aplicando una metodología en la creación de ontologías y se implementa computacionalmente para realizar razonamiento ontológico. Por otro lado, las variables climáticas y sus datos en el tiempo asociados son usados para entrenar y obtener modelos de forecasting de series de tiempo que permiten hacer proyecciones de estas variables en un periodo específico. Estos resultados se usan como entrada para la obtención de los resultados del razonamiento del modelo, el cual brinda una recomendación de cultivos y zonas cultivables en un periodo.

La metodología aplicada se va a basar en tres etapas: definición del modelo conceptual, modelo de inferencia y evaluación del modelo.

1.5.1 Definición del modelo conceptual

El objetivo de esta fase es la identificación de las características de desarrollo agrícola efectivo, que serán representados mediante un modelo conceptual. Esta fase hace uso de métodos empíricos para el reconocimiento de los conceptos y métodos de modelado para la formalización del modelo conceptual.

1.5.1.1 Observación

- *Identificación de conceptos a partir de documentos especializados en el dominio agrícola:* partiendo de manuales técnicos dispuestos por el Gobierno Nacional, artículos relacionados, reportes del Ministerio de Agricultura y el IDEAM, se establecen las caracterizaciones principales que influyen en el buen desarrollo de un cultivo. Por ejemplo, a partir de manuales técnicos de diferentes cultivos, se identifican

las características en común, tales como el suelo y su acidez, topografía, ciclo de cultivo, precipitaciones, etc., definidos como los valores deseados para la producción efectiva del cultivo. Con lo anterior se obtiene un conjunto de conceptos base.

- *Trabajo de campo:* conocer los procesos y actividades de producción también es muy importante en la identificación de características relacionadas. La observación mediante trabajo de campo en una zona agrícola permite el reconocimiento de cómo se cultiva actualmente de manera que se identifiquen los procesos más importantes, las fallas y aspectos posibles a mejorar, lo que puede complementar los conceptos base reconocidos anteriormente, encontrar la relación entre ellos, así como la identificación de posibles reglas.
- *Reunión con expertos:* los expertos se refieren tanto a agricultores, personas que basan su sustento en la producción agrícola, y agrónomos que tienen un conocimiento científico de agricultura. En primera instancia, los expertos pueden ayudar a validar los conceptos ya identificados y la relación entre ellos, de manera que se puedan agregar o descartar conceptos según se requiera. En segunda instancia, el aporte de conocimiento tanto empírico como científico para la inclusión de más reglas y su aprobación.

1.5.1.2 Modelación

- *Planteamiento de taxonomía de conceptos:* con los conceptos previamente establecidos, se formaliza una organización jerárquica entre ellos, clasificados en fisiológicos, geográficos y climatológicos, obteniendo una taxonomía.
- *Planteamiento de diagrama de relaciones binarias:* a partir de la taxonomía previamente planteada, se relacionan los conceptos de acuerdo con su correspondencia, obteniendo una primera mirada al modelo conceptual.
- *Identificación de atributos:* cada concepto puede presentar un conjunto de atributos que lo representan y delimitan. A su vez, estos atributos tienen un formato, rango de valores y cardinalidad. Con lo anterior, se obtiene el modelo conceptual formalizado en el dominio de la agricultura.

1.5.2 Modelo de inferencia

Esta fase tiene como fin la definición de patrones en datos de comportamiento climático, para establecer el modelo de inferencia ontológica. Para esto, se utilizan métodos inductivos-deductivos que, a través de inferencias lógicas, permiten establecer razonamientos y deducciones.

1.5.2.1 Proyección de datos climáticos

- *Elección del conjunto de datos:* búsqueda y elección del conjunto de datos correspondientes al comportamiento climático de una zona, en un periodo de tiempo.

- *Identificación de patrones y proyección:* procesamiento de los datos para identificación de patrones que permitan proyectar el comportamiento climático en un periodo específico.

1.5.2.2 Integración

- *Definición de reglas lógicas:* planteamiento de inferencias lógicas utilizando lógica de predicados de primer orden; estas reglas representan el comportamiento de la producción agrícola, involucrando las propiedades fisiológicas de un cultivo, la zona donde se da, las características geográficas de la zona y el comportamiento climático identificado.
- *Razonamiento con ontología:* aplicación de las inferencias lógicas a la ontología mediante un lenguaje computacional que permita realizar deducciones y recomendaciones sobre: qué, dónde y cuándo cultivar.

1.5.3 Evaluación del modelo

En esta fase se hace la validación del modelo de inferencia a partir de escenarios basados en datos históricos de cultivos producidos en zonas del país, para establecer su nivel de precisión. En esta fase se aplican métodos comparativos que permiten validar los resultados de acuerdo con datos históricos en agricultura.

1.5.3.1 Validación

- *Definición de casos de prueba:* para evaluar la veracidad del modelo, se establecen distintos casos de prueba con determinados cultivos, en zonas y períodos específicos, a partir de datos históricos; estos casos deben cumplir con unas características específicas, por ejemplo, cultivos que se hayan dado bien bajo ciertas condiciones o, por el contrario, hayan presentado bajo rendimiento, daños, fallas, etc.
- *Aplicación de los casos de prueba:* con los casos de prueba previamente definidos, se realizan las pruebas del modelo, verificando que, al especificar ciertos datos para cada concepto, dé el resultado esperado según el comportamiento histórico.

1.5.3.2 Análisis de los resultados

- *Medición del nivel de precisión:* de acuerdo con los resultados de los casos de prueba aplicados, es posible determinar la precisión del modelo midiendo la cantidad de aciertos.

Capítulo 2

Alcances y limitaciones

2.1 Alcances

La especificación del modelo ontológico se define en términos de OWL, incluyendo reglas basadas en lógica de predicados de primer orden con el lenguaje SWRL, aplicando inferencias lógicas para obtener recomendaciones de cultivos y zonas cultivables. El modelo recibe como entradas valores pronosticados para variables climáticas de temperatura y la humedad en un periodo específico, asociados a los municipios de Cabrera, Mosquera, Nemocón, Puerto Salgar, Villapinzón y Villeta.

El diseño del modelo conceptual proporciona flexibilidad de: ampliación en términos de conceptos, relaciones y atributos, reutilización e integración de otros modelos definidos en OWL, e interoperabilidad con diferentes plataformas.

El prototipo software proporciona funcionalidades a nivel de usuario administrador, el cual registra nuevos cultivos con sus rangos recomendados para las propiedades definidas. El usuario agricultor puede registrar fincas con los valores de análisis de suelo asociados y solicitar recomendaciones de cultivos y zonas cultivables.

2.2 Limitaciones

Teniendo en cuenta la disponibilidad de información, para la versión de entrega, el modelo recibe como entradas valores pronosticados para variables climáticas de temperatura y humedad en un periodo específico, sin realizar estimaciones relacionadas con factores económicos, costos de producción, oferta y demanda.

Los conceptos considerados en el modelo ontológico se restringen a aquellos que se presentan como factores en común respecto a la información encontrada para el grupo de cultivos de la papa, fresa, café, lechuga, maíz y cacao. Dadas las restricciones de acceso y disponibilidad de información, los escenarios de prueba establecidos se consideran para Colombia en el departamento de Cundinamarca y los cultivos de maíz, tomate, tomate de árbol, lechuga, arveja, fresa, cacao, lulo y zanahoria.

Capítulo 3

Desarrollo de la investigación

3.1 Definición del modelo conceptual

En esta sección se describe el proceso de definición del modelo conceptual en el dominio de la agricultura y su representación computacional, que posteriormente se integra con la proyección de datos climáticos para la recomendación de opciones de cultivo.

3.1.1 Identificación de características base para cultivar

La identificación de las características base se realiza a partir de documentación oficial del gobierno de Colombia de prácticas recomendadas para los cultivos que se dan en el país (Beltrán & Zhindon, 2012; Cámara de comercio de Bogotá, 2015; Gobernación de Antioquia, 2015), tales como el café y la papa que históricamente representan aproximadamente el 70 % de la composición del PIB agrícola en el país (Ministerio de Agricultura y Desarrollo Rural, 2018). Por otro lado, se consideran artículos de investigación (Ingram & Gaskell, 2019; Lagos-Ortiz et al., 2020; Wang & Wang, 2018), donde se han desarrollado ontologías en el dominio de la agricultura. Estos documentos presentan las condiciones agroclimatológicas necesarias para el buen desempeño del producto. Al comparar los diferentes documentos oficiales del Ministerio de Agricultura y la Gobernación de diferentes departamentos de Colombia, adicionalmente con los artículos de investigación de diferentes autores, se encuentran unas características comunes en los cultivos que representan los elementos básicos necesarios para el buen rendimiento del cultivo y que identifican los productos. Estas características se pueden clasificar en:

- *Geográficos*: relacionados con las condiciones del lugar donde se siembra. Se pueden relacionar los conceptos del suelo y sus condiciones, tales como la topografía, la acidez del suelo y sus minerales.

- *Climáticos*: relacionados con las condiciones del ambiente donde se siembra, teniendo en cuenta la temperatura, la humedad del ambiente, las precipitaciones y horas de sol.
- *Fisiológicos*: relacionados con las características de los cultivos, como su ciclo, fenología, y también las posibles plagas y enfermedades.

Las características identificadas se consideran en las siguientes secciones para el diseño e implementación del modelo conceptual.

3.1.2 Diseño del modelo conceptual

El diseño del modelo conceptual se basa en la propuesta de Methontology, una metodología que define un conjunto de modelos de ciclo de vida, como cascada, incremental y un proceso de desarrollo que proporciona una descripción general de cómo se debe desarrollar una ontología, asegurándose que cada versión sea compatible con las anteriores. En el ciclo de vida de esta metodología se agrupan tres clases de actividades, como se muestra en la Figura 2; en primer lugar, las actividades de gestión: planificación, control y aseguramiento de la calidad; en segundo lugar, las actividades de desarrollo: especificación, conceptualización, formalización, implementación y mantenimiento, y, por último, las actividades de soporte: adquisición de conocimiento, integración, evaluación, documentación y gestión de la configuración (M. Fernández et al., 1997; Poveda-Villalón et al., 2022).




Figura 2. Ciclo de vida Methontology. Basado en (M. Fernández et al., 1997)

En las siguientes subsecciones se describen las actividades de desarrollo que ayudan en el análisis, diseño e implementación de la construcción de la ontología, correspondiente al proyecto.

3.1.2.1 Especificación del modelo

En la Tabla 1, se presenta la especificación del modelo, una actividad que ayuda a definir el dominio y alcance del modelo ontológico.

Tabla 1. Especificación del modelo ontológico

Característica	Definición
Dominio	Agricultura
Objetivo	Proporcionar recomendaciones de cultivos y zonas cultivables, según la época del año y los factores climáticos asociados
Alcance	Representación de conceptos asociados e inferencias basadas en reglas definidas con lógica de predicados.
Reutilización de ontología	Ontología base planteada en el estudio (Alfonso Casallas & Ariza Riaño, 2019), y extensión de las propiedades de esta ontología en términos de conceptos, relaciones, atributos, individuos y reglas.
Población objetivo	Comunidad agricultora.
Fuentes de conocimiento	Librería digital de la Cámara de Comercio de Bogotá, con las recomendaciones para el buen desarrollo de los cultivos. Guías y fichas técnicas del Ministerio de Agricultura y Gobernaciones municipales del país. Bases de datos de artículos científicos como IEEE, ScienceDirect, Springer, ACM, MDPI.
Herramientas y lenguajes	OWL, OWL-DL, SWRL, WebVOWL, SPARQL, Python (módulo Owlready2).

3.1.2.2 Diseño del modelo

El diseño del modelo se basa en las actividades de conceptualización presentadas por Methontology. En la Figura 3, se presentan las actividades que apoyan la organización, descripción y modelamiento de los conceptos identificados. Adicionalmente, estas actividades apoyan la formalización de las relaciones, atributos, reglas e instancias de la ontología.

El modelo diseñado en esta etapa se basa en Ontology Web Language (OWL), recomendado por el World Wide Web Consortium (W3C) como el lenguaje de ontología estándar (Abadi et al., 2018). Este lenguaje describe y construye ontologías con una gran semántica, se basa en el lenguaje de marcado extensible (Extensible Markup Language - XML) y el Marco de descripción de recursos (Resource Description Framework - RDF) que hace posible definir los esquemas de las etiquetas definidas por el usuario y permite la representación de la información (Mun & Ramani, 2011; Tang et al., 2018). La ontología OWL consta de clases (conceptos), propiedades (relaciones) e individuos (instancias de conceptos).



Figura 3. Actividades de conceptualización del modelo. Elaboración propia.

3.1.2.2.1 Definición y representación gráfica de los conceptos

Los conceptos identificados se basan en las características básicas que se deben considerar al cultivar, que se pueden clasificar en *geográficas*, *climáticas* y *fisiológicas*. La Tabla 2 muestra los conceptos identificados y una descripción; en total, se identificaron 22 conceptos.

Tabla 2. Glosario de conceptos

Clasificación	Nombre concepto	Descripción
Climático	Humedad	También conocida como humedad relativa. Cantidad de humedad en el aire.
	Luminosidad	Cantidad de horas de luz solar al día, que llega a una zona específica.
	Precipitación	Fenómenos asociados a la caída del agua del cielo en cualquier forma, como lluvia, llovizna, granizado.
	Temperatura	Nivel de noción calor de una zona específica medido en °C.
Geográfico	Acidez	Indica el grado de acidez de la tierra en un rango de 1 a 14.
	Altura	Distancia en metros entre el nivel del mar y la superficie a considerar de una zona.
	Área Cultivable	Terreno específico donde se desarrolla un cultivo.
	Composición Mineral	Conjunto de requerimientos nutricionales que componen el suelo

Los conceptos pueden corresponderse entre ellos a través de relaciones que indican las dependencias o correlaciones que tiene un concepto con otros. Cada pareja de concepto asociado presenta una relación en cada sentido, por ejemplo, el concepto *Cultivo* **esAfectadoPor** una *Plaga*, y una *Plaga* **afecta** a un *Cultivo*. En este diagrama, la relación representada se señala con una flecha y se ubica en el concepto de destino, así: *Zona* (concepto de origen) **seUbicaEn** *Altura* (concepto de destino). Asimismo, se puede observar que la relación entre conceptos no depende de la clasificación de estos, por ejemplo, un concepto como *Luminosidad* (climático), se relaciona con un concepto geográfico que es la *Zona*.

3.1.2.2.2 Diccionario de conceptos

En esta sección se presenta el diccionario de conceptos, donde se relaciona cada uno de los conceptos identificados con sus instancias y propiedades (atributos y relaciones). En este diccionario cada una de las propiedades se presenta con una convención de nombres específica: para los conceptos y las instancias las palabras empiezan con letra mayúscula los atributos y las relaciones empiezan con letra minúscula y las siguientes palabras con inicio en mayúscula; en todos los casos sin espacios ni caracteres especiales. Lo anterior permite identificar las diferentes propiedades.

Tabla 3. Diccionario de conceptos

Concepto	Instancias	Atributos de clase	Atributos de instancia	Relaciones
Acidez	AcidezVilletaSuelo1	descripcion	nivelPh identificador	tieneAcidez haceParteDe
Altura	AlturaVilletaZona1	descripcion unidad	altura identificador	seUbicaEn correspondeA
AreaCultivable	AreaCultVilletaZona1	descripcion	unidad descripcion extension identificador	tieneArea conformaZona crece creceEn
CicloCultivo	CicloCultivoFresa	descripcion	descripcion tipoCiclo numeroCosechas duracion	esCicloDe tieneCiclo
ComposicionMineral	CMineralVilletaSuelo1	descripcion	identificador	haceParteDe tieneComposicion forma formadaPor
Cultivo	Fresa, Papa, Lechuga	descripcion	descripcion nombre nombreRotacion	crece define afecta esCicloDe estadoDe proximoCultivo tieneFenologia tieneCiclo esAfectadoPor

				tieneTipo
Departamento	Cundinamarca	descripcion	nombre descripcion	conformaDepto tieneRegion
Enfermedad	MohoBlanco	descripcion	nombre descripcion manejo	afecta esAfectadoPor causa causadaPor
EtaFenologica	EtaVegetativaFresa	descripcion	descripcion duracion unidad identificador	tieneEta componeA
Fenologia	FenologiaCultivoLulo	descripcion	descripcion cantidadEtapas identificador	tieneEta componeA tieneFenologia caracteriza
Humedad	HumedadVilletaZona1	descripcion unidad	nivelHumedad identificador	tieneHumedad seEncuentraEn
Luminosidad	LumVilletaZona1	descripcion unidad	intensidad identificador	presenta sePresentaEn
Mineral	MateriaOrganicaSuelo1	descripcion	nombre descripcion unidad simbolo cantidadMineral identificador	forma formadaPor
Plaga	Nematodos, Acaro, Chiza	descripcion	nombre descripcion manejo	afecta esAfectadoPor causa causadaPor controla controladaPor
Plaguicida	Fungicida Citroemulsion	descripcion	nombre descripcion tipoControl administracion	controla controladaPor
Precipitacion	PrecipVilletaZona1	descripcion unidad	precipitaciones identificador	aparece tienePrecipitacion
Region	Villeta, Nemocon, Cabrera	descripcion	nombre descripcion	conformaDepto tieneRegion formaParteDe conformadaPor
Suelo	SueloVilletaZona1	descripcion	identificador	compone tieneSuelo haceParteDe tieneAcidez tieneComposicion
Temperatura	TempVilletaZona1	descripcion unidad	temperatura identificador	tieneTemperatura seAsociaA
TipoCultivo	Hortaliza, Frutal	descripcion	nombre descripcion	define tieneTipo
Topografia	TopVilletaZona1	descripcion	textura inclinacion relieve identificador	representaA seRepresentaPor

Zona	Zona1Villeta	descripcion	nombre descripcion identificador tipoEspacio extension	representaA seRepresentaPor tieneTemperatura seAsociaA formaParteDe conformadaPor compone tieneSuelo aparece tienePrecipitacion presenta sePresentaEn tieneHumedad seEncuentraEn tieneArea conformaZona seUbicaEn correspondeA
------	--------------	-------------	--	---

3.1.2.2.3 Descripción de relaciones binarias

La Tabla 4 muestra las relaciones que conectan los conceptos definidos anteriormente y representan la forma en la que dos conceptos se corresponden. Cada pareja de conceptos asociados presenta dos relaciones que los liga en ambos sentidos. Existen conceptos que no presentan una relación inversa; por ejemplo, el concepto Cultivo cuenta con la relación proximoCultivo que se une a sí mismo, queriendo decir que un cultivo es una opción de ser cultivado próximo a otro.

Tabla 4. Definición de relaciones binarias

Concepto de origen	Relación	Concepto de destino	Relación inversa
Altura	correspondeA	Zona	seUbicaEn
AreaCultivable	conformaZona	Zona	tieneArea
AreaCultivable	crece	Cultivo	creceEn
CicloCultivo	esCicloDe	Cultivo	tieneCiclo
Cultivo	proximoCultivo	Cultivo	-
Departamento	tieneRegion	Region	conformaDepto
Enfermedad	afecta	Cultivo	esAfectadoPor
Enfermedad	causadaPor	Plaga	causa
Etapafenologica	caracteriza	Fenologia	tieneEtapafenologica
Fenologia	estadoDe	Cultivo	tieneFenologia
Humedad	seEncuentraEn	Zona	tieneHumedad
Luminosidad	sePresentaEn	Zona	presenta
Mineral	forma	ComposicionMineral	formadaPor
Plaga	afecta	Cultivo	esAfectadoPor
Plaguicida	controla	Plaga	controladaPor

Precipitacion	aparece	Zona	tienePrecipitacion
Region	conformadaPor	Zona	formaParteDe
Suelo	compone	Zona	tieneSuelo
Suelo	tieneComposicion	ComposicionMineral	haceParteDe
Suelo	tieneAcidez	Acidez	haceParteDe
Temperatura	seAsociaA	Zona	tieneTemperatura
TipoCultivo	define	Cultivo	tieneTipo
Topografia	representaA	Zona	seRepresentaPor

3.1.2.2.4 Descripción de atributos

Los atributos también conocidos como propiedades de datos son características asociadas a los conceptos. Cada concepto, tiene asociado dos tipos de atributos: los de instancia, que son aquellos que toman su valor en la instancia o individuo y los de clase, que toman su valor en la clase o concepto en el que se definen (Corcho et al., 2005). Por ejemplo, el concepto *Altura*, tiene como atributos de clase *descripción* y *unidad*. Estos atributos se definen únicamente en el concepto, ya que son atributos invariables, es decir, sin importar el individuo que se defina, la descripción del concepto de altura y la unidad en que se va a medir la altura siempre serán los mismos (metros sobre el nivel del mar). En cuanto a los atributos de instancia, la *Altura* tiene el atributo *altura* el cual se refiere al valor numérico de distancia en m.s.n.m., y el atributo *identificador* el cual es un valor único que caracteriza al individuo. Estos dos atributos se asocian directamente con un individuo y depende de la zona relacionada. En la Tabla 5 se presentan los atributos relacionados a cada concepto y el tipo de valor para cada uno.

Tabla 5. Definición de atributos de clase e instancia

Concepto	Atributos de clase		Atributos de instancia	
	Atributo	Tipo	Atributo	Tipo
Acidez	descripcion	string	nivelPh	float
			identificador	string
Altura	descripcion	string	altura	integer
	unidad	string	identificador	string
AreaCultivable	descripcion	string	unidad	string
			descripcion	string
			extension	float
			identificador	string
CicloCultivo	descripcion	string	descripcion	string
			tipoCiclo	string
			numeroCosechas	integer
			unidad	integer
ComposicionMineral	descripcion	string	duracion	float
			identificador	string
Cultivo	descripcion	string	descripcion	string
			nombre	string
			nombreRotacion	string

Departamento	descripcion	string	nombre	string
			descripcion	string
Enfermedad	descripcion	string	nombre	string
			descripcion	string
			manejo	string
EtapaFenologica	descripcion	string	descripcion	string
			unidad	string
			duracion	float
			identificador	string
Fenologia	descripcion	string	descripcion	string
			cantidadEtapas	integer
			identificador	string
Humedad	descripcion	string	nivelHumedad	float
	unidad	string	identificador	string
Luminosidad	descripcion	string	intensidad	integer
	unidad	string	identificador	string
Mineral	descripcion	string	nombre	string
			descripcion	string
			unidad	string
			simbolo	string
			cantidadMineral	float
Plaga	descripcion	string	identificador	string
			nombre	string
			descripcion	string
Plaguicida	descripcion	string	manejo	string
			nombre	string
			descripcion	string
			tipoControl	string
Precipitacion	descripcion	string	administracion	string
			precipitaciones	float
			identificador	string
Region	descripcion	string	unidad	string
			nombre	string
Suelo	descripcion	string	descripcion	string
			identificador	string
Temperatura	descripcion	string	temperatura	float
	unidad	string	identificador	string
TipoCultivo	descripcion	string	nombre	string
			descripcion	string
Topograffa	descripcion	string	textura	string
			inclinacion	float
			relieve	string
			identificador	string
Zona	descripcion	string	nombre	string
			descripcion	string
			tipoEspacio	string
			extension	float
			unidad	string
			identificador	string

3.1.2.2.5 Descripción de constantes

Las constantes en este modelo tratan de todos los valores identificados como las condiciones agroclimatológicas apropiadas para un cultivo. Por ejemplo, para el cultivo de la lechuga la Cámara de Comercio de Bogotá dispone de una biblioteca digital² como una de las fuentes oficiales del Gobierno de Colombia donde se presentan las características consideradas como óptimas para el desarrollo del cultivo. En la Tabla 6 a continuación se presentan algunas de estas constantes tomando como ejemplo el cultivo de la lechuga. Adicionalmente, dentro de las constantes se incluyen términos que permiten clasificar y/o describir una característica, por ejemplo, que una topografía con pendiente de cero tiene un relieve plano.

Tabla 6. Ejemplo de constantes del modelo

Constante	Concepto	Tipo	Valor
acidezMinLechuga	Cultivo	float	5.7
acidezMaxLechuga	Cultivo	float	6.5
alturaMinLechuga	Cultivo	int	1800
alturaMaxLechuga	Cultivo	int	2800
relievePlano	Topografia	string	'plano'
temperaturaTemplada	Temperatura	string	'templada'
acidezNeutra	Acidez	string	'neutro'

3.1.2.2.6 Definición de reglas

Las reglas son definidas en lenguajes basados en lógica de predicados de primer orden, con el objetivo de generar recomendaciones de cultivos y áreas cultivables. Con lógica de predicados, es posible expresar relaciones a través de predicados representados en términos de entidades de OWL. Las reglas definidas en lógica de predicados se transcriben en el Lenguaje de Reglas de la Web Semántica (SWRL), un lenguaje de reglas que permite la expresión de inferencias lógicas computacionalmente a un alto nivel, extendiendo la expresividad de OWL para construir un modelo de razonamiento basado en el conocimiento descrito por OWL (O'Connor, 2009; Tang et al., 2018). SWRL se basa en una sintaxis de antecedente-consecuente, que son conjunciones de átomos, donde las condiciones especificadas en el consecuente deben cumplirse siempre que se cumplan las condiciones en el antecedente (Mun & Ramani, 2011). Por ejemplo, es posible definir las condiciones que debe cumplir un cultivo (antecedente) para identificar las áreas de cultivo donde se puede cultivar (consecuente).

En las tablas a continuación se presentan ejemplos de las reglas identificadas para el modelo; estas reglas se clasifican de acuerdo con su objetivo: *reglas generales*, para definir los conceptos en función de otros; por ejemplo, una zona se define por tener asociados

² <https://bibliotecadigital.ccb.org.co/>

conceptos como temperatura, topografía, altura, etc. *Reglas de clasificación*, para clasificar algunos términos de acuerdo con sus valores; por ejemplo, una temperatura mayor a 24 °C se puede definir como cálida. *Reglas de relación*, donde se relaciona un cultivo con otro de acuerdo con su tipo. *Reglas de recomendación*, donde se establece cuáles son los valores óptimos para que un cultivo crezca en una zona; estas reglas permiten hacer inferencias para determinar dónde cultivar y qué cultivar, de acuerdo con el objetivo establecido.

Tabla 7. Definición de reglas generales

Descripción regla	Expresión en SWRL	Conceptos	Relaciones	Variables
Toda entidad que tenga un área cultivable, se ubique en una altura, se represente por una topografía, tenga un suelo, presente una luminosidad, tenga una precipitación, tenga una temperatura y tenga humedad, es una zona.	AreaCultivable(?area) & tieneArea(?z, ?area) & Altura(?alt) & seUbicaEn(?z, ?alt) & Topografia(?top) & seRepresentaPor(?z, ?top) & Suelo(?s) & tieneSuelo(?z, ?s) & Luminosidad(?l) & presenta(?z, ?l) & Precipitacion(?p) & tienePrecipitacion(?z, ?p) & Temperatura(?t) & tieneTemperatura(?z, ?t) & Humedad(?h) & tieneHumedad(?z, ?h) → Zona(?z)	AreaCultivable Altura Topografia Suelo Luminosidad Precipitacion Temperatura Humedad Zona	tieneArea seUbicaEn seRepresentaPor tieneSuelo presenta tienePrecipitacion tieneTemperatura tieneHumedad	area alt top s l p t h z
Toda entidad que tenga una región y cuya región esté conformada por zonas, es un departamento.	Region(?r) & tieneRegion(?d, ?r) & Zona(?z) & conformadaPor(?r, ?z) → Departamento(?d)	Region Zona Departamento	tieneRegion conformadaPor	r z d
Toda entidad que tenga una acidez y una composición mineral, que a su vez está formada por minerales, es un suelo.	Acidez(?a) & haceParteDe(?a, ?s) & ComposicionMineral(?comp) & haceParteDe(?comp, ?s) & Mineral(?m) & forma(?m, ?comp) → Suelo(?s)	Acidez ComposicionMineral Mineral Suelo	haceParteDe forma	a comp m s
Toda entidad que tiene una fenología, tiene un ciclo, es afectado por una plaga y/o por una enfermedad y tiene un tipo, es un cultivo.	TipoCultivo(?tc) & tieneTipo(?c, ?tc) & Enfermedad(?e) & esAfectadoPor(?c, ?e) & Plaga(?p) & esAfectadoPor(?c, ?p) & CicloCultivo(?cc) & tieneCiclo(?c, ?cc) & Fenologia(?f) & tieneFenologia(?c, ?f) → Cultivo(?c)	TipoCultivo Enfermedad Plaga CicloCultivo Fenologia Cultivo	tieneTipo esAfectadoPor tieneCiclo tieneFenologia	tc e p cc f c
Toda entidad que tiene al menos una etapa fenológica es una fenología	EtapaFenologica(?e) & tieneEtapa(?f, ?e) → Fenologia(?f)	EtapaFenologica Fenologia	tieneEtapa	f e
Toda entidad que es controlada por un plaguicida es una plaga.	Plaguicida(?pl) & controla(?pl, ?plaga) → Plaga(?plaga)	Plaga Plaguicida	controla	plaga pl

Tabla 8. Definición de reglas de clasificación

Descripción regla	Expresión en SWRL	Conceptos	Propiedades	Variables
Acidez con nivel de ph mayor o igual a 3.5 y menor a 5.5 es de tipo “moderadamente ácido”.	Acidez(?a) & nivelPh(?a, ?phVal) & greaterThanOrEqualTo(?phVal, 3.5) & lessThan(?phVal, 5.5) → tipo(?a, “moderadamente ácido”)	Acidez	nivelPh tipo	a phVal
Acidez con nivel de ph igual a 7 es de tipo “neutro”.	Acidez(?a) & nivelPh(?a, ?phVal) & equal(?phVal, 7) → tipo(?a, “neutro”)	Acidez	nivelPh tipo	a phVal
Temperatura con valor menor a 10 °C se define de tipo “páramo”.	Temperatura(?t) & temperatura(?t, ?tempVal) & lessThan(?tempVal, 10) → tipo(?a, “paramo”)	Temperatura	temperatura tipo	t tempVal
Topografía con una inclinación entre 0 y 3 grados se considera con un relieve plano.	Topografia(?t), inclinacion(?t, ?in), greaterThanOrEqualTo(?in, 0), lessThanOrEqualTo(?in, 3) → relieve(?t, “plano”)	Topografia	inclinacion relieve	t in
Topografía con una inclinación mayor a 30 grados se considera con relieve pendiente.	Topografia(?t), inclinacion(?t, ?in), greaterThanOrEqualTo(?in, 30) → relieve(?t, “pendiente”)	Topografia	inclinacion relieve	t in

Tabla 9. Definición de reglas de relación de cultivos

Descripción regla	Expresión en SWRL	Conceptos	Propiedades	Variables
Un cultivo identificado como raíz tiene como cultivo próximo recomendado uno “hoja”	Cultivo(?c1) & nombreRotacion(?c1, "raiz") & Cultivo(?c2) & nombreRotacion(?c2, "hoja") → proximoCultivo(?c1, ?c2)	Cultivo	nombreRotacion proximoCultivo	c1 c2
Un cultivo identificado como fruto tiene como cultivo próximo recomendado uno “raíz”	Cultivo(?c1) & nombreRotacion(?c1, "fruto") & Cultivo(?c2) & nombreRotacion(?c2, "raiz") → proximoCultivo(?c1, ?c2)	Cultivo	nombreRotacion proximoCultivo	c1 c2
Un cultivo identificado como hoja tiene como cultivo próximo recomendado uno “flor”	Cultivo(?c1) & nombreRotacion(?c1, "hoja") & Cultivo(?c2) & nombreRotacion(?c2, "flor") → proximoCultivo(?c1, ?c2)	Cultivo	nombreRotacion proximoCultivo	c1 c2

Un cultivo identificado como flor tiene como cultivo próximo recomendado uno “fruto”	Cultivo(?c1) & nombreRotacion(?c1, "flor") & Cultivo(?c2) & nombreRotacion(?c2, "fruto") → proximoCultivo(?c1, ?c2)	Cultivo	nombreRotacion proximoCultivo	c1 c2
Todos los cultivos que tienen el mismo tipo están relacionados.	TipoCultivo(?tc) & Cultivo(?c1) & tieneTipo(?c1, ?tc) & Cultivo(?c2) & tieneTipo(?c2, ?tc) → cultivoRelacionado(?c1, ?c2)	TipoCultivo Cultivo	tieneTipo cultivoRelacionado	c1 c2 tc
Todos los cultivos que tienen el mismo ciclo están relacionados.	CicloCultivo(?cc) & Cultivo(?c1) & tieneCiclo(?c1, ?cc) & Cultivo(?c2) & tieneCiclo(?c2, ?cc) → cultivoRelacionado(?c1, ?c2)	CicloCultivo Cultivo	tieneCiclo cultivoRelacionado	c1 c2 cc

Tabla 10. Definición de reglas de recomendación

Descripción regla	Expresión en SWRL	Conceptos	Propiedades	Variables	Individuos
Las condiciones óptimas definidas para el cultivo del Maíz. Toda zona que contenga las características establecidas será considerada una zona recomendable para cultivar el maíz. Estas características incluyen los rangos máximos y mínimos.	Temperatura(?t), temperatura(?t, ?temp), greaterThanOrEqual(?temp, 17), lessThanOrEqual(?temp, 33.8), Topografia(?top), relieve(?top, ?rel), equal(?rel, 'ondulado'), Altura(?alt), altura(?alt, ?dist), greaterThanOrEqual(?dist, 100), lessThanOrEqual(?dist, 2100), Humedad(?hum), nivelHumedad(?hum, ?nivH), greaterThanOrEqual(?nivH, 47), lessThanOrEqual(?nivH, 91), Acidez(?ph), nivelPh(?ph, ?nivPh), greaterThanOrEqual(?nivPh, 5.2), lessThanOrEqual(?nivPh, 6.8), Zona(?z), AreaCultivable(?a), conformaZona(?a, ?z), presenta(?z, ?l), seRepresentaPor(?z, ?top), seUbicaEn(?z, ?alt), tieneHumedad(?z, ?hum), haceParteDe(?ph, ?s), Suelo(?s), tieneSuelo(?z, ?s),	Temperatura Topografia Altura Humedad Acidez Zona AreaCultivable Suelo	conformaZona presenta seRepresentaPor seUbicaEn tieneHumedad haceParteDe tieneSuelo tieneTemperatura crece	t temp top rel alt dist hum nivH nivPh ph z a s	Maiz

	tieneTemperatura(?z, ?t) → crece(?a, Maiz)				
Las condiciones óptimas definidas para el cultivo de la Zanahoria. Toda zona que contenga las características establecidas será considerada una zona recomendable para cultivar el zanahoria. Estas características incluyen los rangos máximos y mínimos.	Temperatura(?t), temperatura(?t, ?temp), greaterThanOrEqualTo(?temp, 8), lessThanOrEqualTo(?temp, 28), Topografia(?top), relieve(?top, ?rel), equal(?rel, ligeramente ondulado), Altura(?alt), altura(?alt, ?dist), greaterThanOrEqualTo(?dist, 0), lessThanOrEqualTo(?dist, 3400), Humedad(?hum), nivelHumedad(?hum, ?nivH), greaterThanOrEqualTo(?nivH, 65), lessThanOrEqualTo(?nivH, 85), Acidez(?ph), nivelPh(?ph, ?nivPh), greaterThanOrEqualTo(?nivPh, 5.5), lessThanOrEqualTo(?nivPh, 7.3), Zona(?z), AreaCultivable(?a), conformaZona(?a, ?z), presenta(?z, ?l), seRepresentaPor(?z, ?top), seUbicaEn(?z, ?alt), tieneHumedad(?z, ?hum), haceParteDe(?ph, ?s), Suelo(?s), tieneSuelo(?z, ?s), tieneTemperatura(?z, ?t) → crece(?a, Zanahoria)	Temperatura Topografia Altura Humedad Acidez Zona AreaCultivable Suelo	conformaZona presenta seRepresentaPor seUbicaEn tieneHumedad haceParteDe tieneSuelo tieneTemperatura crece	t temp top rel alt dist hum nivH nivPh ph z a s	Zanahoria

3.1.3 Implementación del modelo conceptual

La creación de la ontología se realiza utilizando el módulo Owlready2, un paquete para crear y modificar ontologías en términos de OWL con Python, siendo posible manipular objetos OWL como si fueran objetos de Python y agregar métodos de Python en propiedades de la ontología (Lamy, 2020). Este módulo proporciona los diferentes métodos para crear conceptos, relaciones, atributos y reglas en SWRL. Usando el método `save()`, es posible exportar la ontología creada como un archivo `.owl`, que puede ser consumido por otras aplicaciones de visualización y administración de ontologías como Protégé. La creación de una nueva ontología vacía se logra usando el método `get_ontology()` que recibe como parámetro el identificador único de la ontología en formato IRI.

3.1.3.1 Creación de conceptos

El atributo de clase de la ontología puede asociarse a un concepto para su creación. Al definir una nueva clase, es necesario especificar el espacio en que se va a crear, es decir, la nueva ontología creada en blanco (`onto`). Todos los conceptos se definen bajo la super clase *Thing*.

```
with onto:
    class Cultivo(Thing):
        pass
    class TipoCultivo(Thing):
        pass
    class Acidez(Thing):
        pass
```

Figura 5. Ejemplo de creación de clases con Owlready2. Elaboración propia.

3.1.3.2 Creación de relaciones

La creación de relaciones se realiza estableciendo subclases de la propiedad de objetos *ObjectProperty*. Para este tipo de entidades es necesario incluir un dominio y un rango. El dominio representa el concepto de origen y el rango el concepto de destino. Por ejemplo, para la relación *Plaga esControladaPor Plaguicida*, el concepto Plaga es el dominio y el concepto Plaguicida es el rango. Adicionalmente, para las relaciones que tienen inversas se adicionan con el parámetro *inverse_property* el cual se iguala a la relación inversa correspondiente (ver Figura 6).

```
with onto:
    class afecta(ObjectProperty):
        domain = [Enfermedad or Plaga]
        range = [Cultivo]

    class esAfectadoPor(ObjectProperty):
        domain = [Cultivo]
        range = [Enfermedad or Plaga]
        inverse_property = afecta

    class causa(ObjectProperty):
        domain = [Plaga]
        range = [Enfermedad]

    class esCausadaPor(ObjectProperty):
        domain = [Enfermedad]
        range = [Plaga]
        inverse_property = causes
```

Figura 6. Ejemplos de creación de relaciones con Owlready2. Elaboración propia.

3.1.3.3 Creación de atributos

La creación de atributos de clase y de instancia se realiza estableciendo subclases de la propiedad de objetos *DataProperty*. Para este tipo de entidades es necesario incluir un rango, el cual representa el tipo de dato del atributo; opcionalmente, es posible adicionar un dominio para aquellos atributos que solo corresponden a un concepto. Adicionalmente, para este tipo de propiedades también se añade el parámetro *FunctionalProperty*, el cual indica que ese atributo solo se puede establecer una vez para un concepto. Por ejemplo, la Luminosidad solo puede tener una intensidad; asimismo, cualquier concepto debe tener un único identificador.

```
with onto:
    class tipo(DataProperty, FunctionalProperty):
        range = [float]

    class relieve(DataProperty):
        domain = [Topografia]
        range = [str]

    class identificador(DataProperty, FunctionalProperty):
        range = [str]

    class intensidad(DataProperty, FunctionalProperty):
        domain = [Luminosidad]
        range = [int]
```

Figura 7. Ejemplos de creación de atributos con Owlready2. Elaboración propia.

3.1.3.4 Creación de individuos

Los individuos son instancias de las clases (conceptos) creadas previamente, las cuales se definen como cualquier otra instancia en Python. Al instanciar un nuevo objeto, se incluyen los parámetros asociados a ese individuo. El primer parámetro es el nombre que se le da al individuo; los siguientes parámetros son los atributos definidos previamente para cada concepto.

```
top_zona1 = Topografia('TopografiaVilletaZona1', textura='rocosa', inclinacion=12.5, relieve='ondulado')
zanahoria = Cultiv('Zanahoria', nombreRotacion='raiz')
villeta = Region('Villeta')
temp_zona1 = Temperatura('TemperaturaVilletaZona1', temperatura=25)
```

Figura 8. Ejemplo de creación de individuos con Owlready2. Elaboración propia.

3.1.3.5 Creación de reglas en SWRL y razonamiento

Las reglas se crean usando la clase `Imp` (Implica). El método `set_as_rule` permite la creación de la regla; este recibe como parámetro un dato tipo string con la regla escrita en lenguaje SWRL.

```
with onto:
    rule = Imp()
    rule.set_as_rule("""Cultivo(?x), nombreRotacion(?x, "raiz"),
                      Cultivo(?y), nombreRotacion(?y, "fruto") -> proximoCultivo(?x, ?y)""")
```

Figura 9. Ejemplo de creación de reglas con Owlready2. Elaboración propia.

Owlready2 incluye Pellet, un razonador de lógica descriptiva que verifica la consistencia de una base de la base de conocimiento. El razonador Pellet soporta completamente OWL y reglas definidas en SWRL, lo que permite ejecutar tareas de razonamiento en términos de restricciones de cardinalidad, propiedades complejas y ABox, es decir, recuperar las características de los individuos definidos por el concepto (Dentler et al., 2011). Ejecutando Pellet, es posible detectar inconsistencias en la Ontología y encontrar inferencias en base a las reglas definidas. La función `sync_reasoner_pellet()` se usa para iniciar el razonador y generar las inferencias en términos de entidades OWL.

3.1.3.6 Visualización de la ontología

La visualización de la ontología se realiza con WebOWL³, un visualizador de ontologías donde es posible cargar el archivo .owl generado previamente. Los nodos principales representan los Conceptos, que se relacionan entre sí a través de relaciones binarias. Algunas de las relaciones binarias tienen la característica funcional o funcional inversa, lo que establece que dicha relación sólo puede ser utilizada una vez para cada instancia. Esto se puede ver en la Figura 10.

³ <http://vowl.visualdataweb.org/webvowl.html>




Figura 10. Visualización de la ontología con WebVOWL. Elaboración propia.

3.2 Proyección de datos climáticos

En esta sección se presenta la identificación de patrones climáticos implementando *forecasting* en series de tiempo, una técnica que permite la estimación y previsión de comportamiento climático en las variables climáticas. Las variables climáticas identificadas en el modelo comprenden la temperatura, humedad, precipitación y luminosidad. Sin embargo, para la proyección de los datos climáticos se reduce a las variables de temperatura y humedad, debido a la limitación de conjuntos de datos disponibles para la variable de luminosidad y la variable de precipitación; esta última presenta información de precipitaciones anuales, lo cual difiere del comportamiento de las demás variables que serán estimadas con un periodo mensual.

3.2.1 Selección de conjuntos de datos

Los conjuntos de datos seleccionados para este estudio fueron proporcionados por el Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) a través de la plataforma de datos abiertos de Colombia⁴. Para la variable de humedad, se seleccionó el conjunto de datos *Humedad del Aire 2 metros*. Estos datos incluyen el valor de la humedad en porcentaje. Para la variable de la temperatura se seleccionaron dos conjuntos de datos: *Temperatura Máxima del Aire* y *Temperatura Mínima del Aire*, incluyendo el valor en °C. Estos datos fueron capturados a través de sensores de estaciones automáticas en diferentes municipios de los departamentos del país, desde el año 2001 hasta el año 2021. En las secciones a continuación se describe el procesamiento que se realiza a los datos.

3.2.2 Procesamiento de los datos

Para el procesamiento de los datos, inicialmente se escogió el departamento de Cundinamarca; esto debido a la disponibilidad de información de cultivos realizados en el departamento discriminado por municipios, además de ser un departamento donde se cultivan varios de los cultivos más producidos en el país. De esta forma, se filtró el departamento de Cundinamarca para los conjuntos de datos, antes de descargarlos de la plataforma de datos abiertos como un archivo .csv.

El procesamiento de los datos se realizó con Python. Los archivos fueron leídos como dataframes de pandas, librería para manipulación y análisis de datos con Python. En relación con la temperatura, se unieron los dos conjuntos de datos relacionados a temperatura máxima y mínima.

⁴ www.datos.gov.co

Para ambas variables, se eliminaron columnas no relevantes para el procesamiento, como el nombre de la estación, la descripción, códigos, unidad de medida, zona hidrográfica, latitud y longitud, obteniendo dataframes con la fecha, el valor, el departamento y el municipio. Adicionalmente, se realizó una normalización de los conjuntos de datos para eliminar caracteres especiales de los nombres de los municipios y dejando todos los nombres en minúsculas.

Teniendo en cuenta que las recomendaciones se van a hacer mensuales, los datos deben ser resumidos en sus promedios mensuales por año. Por ello, se hizo un promedio de todos los valores de un mismo mes, para cada mes de todos los años existentes en los conjuntos de datos, obteniendo un nuevo conjunto de datos con el valor promedio mensual.

	FechaObservacion	ValorObservado	Departamento	Municipio
0	2011-08-09	100.000	cundinamarca	villapinzon
1	2019-05-14	1.231	cundinamarca	villapinzon
2	2012-06-08	100.000	cundinamarca	cabrera
3	2007-11-29	63.000	cundinamarca	mosquera
4	2019-04-16	95.000	cundinamarca	mosquera

Figura 11. Muestra del dataframe de la humedad. Elaboración propia.

	FechaObservacion	ValorObservado	Departamento	Municipio
0	2015-10-03	11.8	cundinamarca	nemocon
1	2011-09-20	11.1	cundinamarca	mosquera
2	2017-11-03	12.3	cundinamarca	nemocon
3	2018-06-24	10.5	cundinamarca	nemocon
4	2009-09-07	11.0	cundinamarca	cabrera

Figura 12. Muestra del dataframe de la temperatura. Elaboración propia.

Posteriormente, se ha separado el dataframe obtenido para cada variable por departamento-municipio, es decir, se obtuvo un nuevo dataframe por cada municipio. Lo anterior debido a que las recomendaciones se van a hacer por zona, por lo que es necesario generar un modelo de pronóstico por zona para la humedad y la temperatura.

3.2.2.1 Elección de municipios

La elección de municipios finales para este estudio se realizó con base en la disponibilidad de información de datos históricos y en la completitud de los datos. Inicialmente, se realizó una intersección entre los municipios disponibles para ambas variables y los municipios disponibles en el conjunto de datos de datos históricos (ver sección Identificación de datos históricos). Con esta intersección, se realizó un conteo de datos faltantes y totales de cada dataframe. Para aquellos dataframes que tenían un número considerable de datos faltantes (más del 25 %) o que tuvieran muy pocos meses

para el análisis, fueron descartados. Finalmente, se obtuvo un total de 6 municipios: Cabrera, Mosquera, Nemocón, Puerto Salgar, Villapinzón y Villeta.

temperature_path		total	nan_count	percentage
	file			
0	cundinamarca-anapoima-temperature.csv	44	9	20
1	cundinamarca-bojaca-temperature.csv	35	4	11
2	cundinamarca-cabrera-temperature.csv	251	54	22
3	cundinamarca-carmen de carupa-temperature.csv	34	16	47
4	cundinamarca-chia-temperature.csv	31	0	0
5	cundinamarca-cogua-temperature.csv	31	0	0
6	cundinamarca-facatativa-temperature.csv	35	0	0
7	cundinamarca-fusagasuga-temperature.csv	150	44	29
8	cundinamarca-guaduas-temperature.csv	31	0	0
9	cundinamarca-guayabetal-temperature.csv	30	0	0
11	cundinamarca-la calera-temperature.csv	252	81	32
12	cundinamarca-medina-temperature.csv	24	0	0
13	cundinamarca-mosquera-temperature.csv	253	44	17
14	cundinamarca-nemocon-temperature.csv	197	17	9
15	cundinamarca-pasca-temperature.csv	219	74	34
16	cundinamarca-puerto salgar-temperature.csv	183	21	11
17	cundinamarca-quebradanegra-temperature.csv	253	94	37
18	cundinamarca-san cayetano-temperature.csv	243	87	36
19	cundinamarca-silvania-temperature.csv	187	88	47
20	cundinamarca-villapinzon-temperature.csv	200	17	8
21	cundinamarca-villeta-temperature.csv	252	46	18
22	cundinamarca-yacopi-temperature.csv	35	0	0

Figura 13. Ejemplo de conteo de datos por municipio para conjuntos de datos de Temperatura. Elaboración propia.

3.2.2.2 Análisis exploratorio de los datos (EDA)

Para obtener las series de tiempo por los conjuntos de datos generados, se realiza un análisis exploratorio de los datos (EDA) con el fin de asegurarse que los datos cronológicos estén completos en intervalos mensuales, establecer sus valores mayores-menores y los valores anómalos.

En la Figura 14 se presenta la descripción de las variables; teniendo en cuenta que las dos variables son numéricas, estas tablas presentan un resumen de las estadísticas para cada uno de los dataframes por variable. En este primer análisis se puede identificar los valores mínimos y máximos; en general, estos valores parecen estar en rangos normales teniendo en cuenta el comportamiento de las variables; sin embargo, los análisis más adelante ayudarán a identificar datos anómalos.

La Figura 15 presenta el conteo de meses por año para cada uno de los departamentos en la variable Temperatura. Esto permite identificar si se tiene información para todos los meses, considerando que la proyección de temperatura se hace mensual. De esta manera, se puede establecer el rango de fechas en la que se hará en análisis por conjunto de datos.

-----Temperature-----									
	mun	count	mean	std	min	25%	50%	75%	max
0	cabrera	197	10.7747	2.13054	-6.7078	10.6513	11.0018	11.3602	15.4368
1	mosquera	209	13.1037	2.25344	0	13.0627	13.512	13.9588	20.3
2	nemocon	180	13.2607	1.01032	7.73619	12.821	13.2342	13.7745	16.4808
3	puerto salgar	162	27.2147	3.80255	0.1	27.0796	27.4687	28.1253	33.5333
4	villapinzon	183	8.65271	0.915016	7.10759	8.16112	8.61084	8.98029	17.2387
5	villeta	206	21.5091	7.29823	0	23.4272	23.9936	24.6905	27.1408

-----Humidity-----									
	mun	count	mean	std	min	25%	50%	75%	max
0	cabrera	186	84.4224	11.956	0	80.8421	88.0239	91.4246	95.5107
1	mosquera	197	80.0322	14.0428	0	80.0225	82.4716	85.0581	89.5068
2	nemocon	180	76.8205	19.4859	0.157116	78.5774	82.276	84.2854	95.9646
3	puerto salgar	152	77.8937	12.3272	0.236084	76.8488	81.6759	83.9431	94.9253
4	villapinzon	196	68.703	28.2178	0.5435	60.326	67.853	92.9891	98.7964
5	villeta	190	64.8231	27.9036	0	62.0369	77.5696	82.2098	90.6415

Figura 14. Estadísticas descriptivas de los dataframes para Temperatura y Humedad. Elaboración propia.

A continuación, se describen los análisis asociados a cada departamento:

- Figura 15 (a): para el municipio de Cabrera, se encuentran datos entre el año 2001 hasta el 2022; sin embargo, para el año 2001 faltan algunos meses y para el año 2022 faltan la mayoría de los meses. En cuanto a los demás años se puede ver que existe información.
- Figura 15 (b): para el municipio de Nemocón, se encuentran datos entre el año 2005 hasta el 2021; sin embargo, es posible descartar el año 2021 porque no hay suficientes datos.
- Figura 15 (c): para el municipio Mosquera se encuentran datos completos entre los años 2001 y 2021, por lo que solo se descartarían los pocos datos que hay para el año 2022.
- Figura 15 (d): para el municipio Puerto Salgar se encuentran datos entre el 2005 y parte del 2020, pero no suficientes, por lo que se considerarían solo hasta el 2019.
- Figura 15 (e): para el municipio de Villapinzón se encuentran datos completos entre los años 2006 y 2021, por lo que solo se descartarían los pocos datos que hay para los años 2005 y 2022.
- Figura 15 (f): para el municipio Mosquera se encuentran datos completos entre los años 2002 y 2021, por lo que solo se descartarían los pocos datos que hay para el año 2022, y se podría incluir también el año 2001 que tiene la mayoría de los datos.




Figura 15. Conteo de los meses por año para los departamentos en la variable Temperatura. Elaboración propia.

En la Figura 16 se presentan las series de tiempo para los departamentos en la variable Temperatura. Al igual que las gráficas anteriores, estas gráficas permiten identificar la completitud de los datos a mayor detalle para determinar los rangos y faltantes. Por ejemplo, la Figura 16 (c) presenta la serie de tiempo para Mosquera, donde se puede ver que los datos iniciales, entre el año 2001 y 2004 presentan un comportamiento inusual y con bastantes vacíos; por esta razón, es posible descartar los

datos del año 2005 hacia atrás. Otro ejemplo es el caso de la Figura 16 (d), la cual presenta algunos vacíos entre los años 2007 al 2012; al ser una cantidad menor de faltantes, estos datos pueden ser tratados.




Figura 16. Series de tiempo para departamentos en la variable Temperatura. Elaboración propia.

Por otro lado, también es posible identificar comportamientos anómalos para estos conjuntos de datos; por ejemplo, para la Figura 16 (d) se pueden identificar algunos anómalos cerca al año 2009 y al año 2018.

Similarmente a lo anterior expuesto, en la Figura 17 presenta el conteo de meses por año para cada uno de los departamentos en la variable de la Humedad.




Figura 17. Conteo de los meses por año para los departamentos en la variable Humedad. Elaboración propia.

El análisis con estas figuras es el mismo que se realiza con la Temperatura; con estas podemos identificar los posibles rangos que serán considerados para los conjuntos de datos en la implementación de modelos de forecasting. Por ejemplo, la Figura 17 (a)

muestra que todos los datos están completos entre el año 2016 y el 2021; sin embargo, el año 2005 presenta solo la mitad de los meses y el año 2022 presenta solo un mes, por lo que estos meses pueden ser descartados.




Figura 18. Series de tiempo para departamentos en la variable Humedad. Elaboración propia.

La Figura 18 muestra las series de tiempo para los departamentos en la variable Humedad. Al igual que para la Temperatura, con estas gráficas es posible identificar los rangos, valores faltantes y anómalos. Tanto el análisis con las gráficas de barra como el análisis con las gráficas de series de tiempo permite concluir que todos los conjuntos de datos pueden ser considerados desde el año 2006. En cuanto a datos anómalos la Figura

18 (a) y (b) muestran algunos ejemplos de comportamientos anómalos entre los años 2014 y 2016.

En las secciones a continuación se describe el tratamiento a los datos anómalos y faltantes.

3.2.2.2.1 Delimitación de los conjuntos de datos por rangos identificados y manejo de datos faltantes

Antes de hacer tratamiento a los datos faltantes, los conjuntos de datos para cada variable y municipio son recortados eliminando los datos de inicio y de final del conjunto de datos que presenten un gran porcentaje de faltantes y/o anómalos. Estos rangos fueron identificados con el análisis de la sección anterior. En la Figura 19 se presenta para cada departamento y variable la cantidad de meses, el año de inicio y el año final de consideración.

-----Temperature-----				
	mun	count	min	max
0	cabrera	165	2005	2019
1	mosquera	185	2005	2020
2	nemocon	170	2005	2019
3	puerto salgar	138	2007	2019
4	villapinzon	160	2005	2019
5	villeta	181	2005	2020

-----Humidity-----				
	mun	count	min	max
0	cabrera	178	2005	2020
1	mosquera	184	2005	2020
2	nemocon	182	2005	2020
3	puerto salgar	162	2005	2019
4	villapinzon	187	2005	2020
5	villeta	181	2005	2020

Figura 19. Rangos identificados para los conjuntos de datos por variable. Elaboración propia.

Una vez se han cortado los conjuntos de datos, se procede a tratar los datos faltantes. Para tratar los datos faltantes, se usa la técnica de interpolación lineal, una técnica usada para identificar un valor desconocido entre dos valores conocidos y recomendada para series de tiempo (Park & Kim, 2020). La interpolación tiene como objetivo encontrar un valor faltante conectando los valores conocidos en una línea recta. Con esta técnica, se están considerando los promedios cercanos a los puntos faltantes, sin considerar el promedio total de los datos.

Para implementar la interpolación, se usa el método *interpolate()*, un método de la librería pandas para el relleno de datos faltantes en un dataframe. El resultado de esta tarea es un nuevo dataframe por variable y municipio, que será utilizado en los procesamientos posteriores.

3.2.2.2.2 Identificación de datos anómalos y tratamiento

La Figura 16 y Figura 18, dieron una visión general de posibles datos anómalos para los conjuntos de datos. En esta sección se hace una detección de los datos anómalos y su tratamiento. Para detectar los datos anómalos se usa la librería Pycaret de Python, una librería de código abierto de Machine Learning que permite implementar modelos de manera rápida y en pocas líneas⁵. Pycaret ofrece el módulo *anomaly*, un módulo de machine learning no supervisado que disponibiliza funciones pre-procesadas que pueden ser configuradas para tareas de detección de datos irregulares.

Para implementar la detección de datos anómalos se crea un modelo de detección con la función *create_model()*, con la cual se debe especificar el modelo que se va a crear, en este caso el modelo Isolation Forest (iforest) y la cual retorna el modelo entrenado. Isolation Forest es un método ampliamente utilizado para detección de datos atípicos, el cual se basa en la creación un conjunto de árboles de decisión aislados construidos aleatoriamente, donde cada árbol se establece sobre la base de una muestra tomada de forma independiente, que es un subconjunto del conjunto de datos analizado. La detección de valores atípicos se realiza pasando los datos al conjunto de árboles creado y produciendo una medida de anomalía para cada punto de datos (Tokovarov & Karczmarek, 2022). Con este modelo, se asignan etiquetas a cada fila del conjunto de datos que especifica si es un dato anómalo (1) o no (0), como se muestra en el ejemplo de la Figura 20.

	ValorObservado	Month	Year	Anomaly	Anomaly_Score
0	14.656186	7	2005	1	0.027616
1	10.940805	8	2005	1	0.000275
2	11.165056	9	2005	1	0.002035
3	10.793912	10	2005	1	0.003830
4	11.022718	11	2005	0	-0.004195

Figura 20. Ejemplo de identificación de anómalos con pycaret.anomaly. Elaboración propia.

Una vez identificados los datos anómalos, se pueden tratar uno a uno calculando el promedio entre los puntos anteriores al punto anómalo. Este procedimiento se hace para cada uno de los conjuntos de datos de cada variable y departamento. Finalmente, se obtienen los dataframes con los datos completos y tratados.

3.2.3 Entrenamiento de modelos de forecasting

En esta sección se describe el procedimiento para entrenar los modelos de forecasting en series de tiempo. Inicialmente, es importante definir la estacionariedad de

⁵ <https://pycaret.gitbook.io/docs/>

cada una de las series de tiempo. La estacionariedad (Brockwell, 2020) de una serie de tiempo indica si depende o no del tiempo. Una serie estacionaria se caracteriza por no tener efectos estacionales o de tendencia, contrario a las series no estacionarias que además pueden tener otras estructuras que dependen del índice de tiempo. Para determinar si la serie es estacionaria o no, se usa la prueba de Augmented Dickey-Fuller (Gerdtham & Jönsson, 2000), la cual ayuda a determinar qué tanto una serie de tiempo se define por una tendencia. La hipótesis nula de esta prueba establece que la serie de tiempo es no estacionaria, mientras que la hipótesis alternativa establece que sí lo es. Para este caso, si el *p-value* de esta prueba es menor que el valor de significancia (0.05), entonces se rechaza la hipótesis nula y se concluye que la serie de tiempo es estacionaria. En la Figura 21 se presentan los resultados de esta prueba; los resultados muestran que en ambas variables existen series de tiempo no estacionarias.

-----Temperature-----			
	municipio	pvalue	estacionaria
0	cabrera	5.914478e-09	True
1	mosquera	4.399539e-04	True
2	nemocon	7.607938e-13	True
3	puerto salgar	8.903187e-02	False
4	villapinzon	1.138550e-01	False
5	villeta	5.338251e-12	True
-----Humidity-----			
	municipio	pvalue	estacionaria
0	cabrera	7.647607e-02	False
1	mosquera	7.068362e-02	False
2	nemocon	5.451925e-13	True
3	puerto salgar	3.960654e-07	True
4	villapinzon	4.334962e-01	False
5	villeta	5.844276e-02	False

Figura 21. Estacionariedad de las series de tiempo para Temperatura y Humedad. Elaboración propia.

Para la proyección de datos climáticos, se utilizan 23 modelos distintos de Machine Learning por variable y municipio con diferentes configuraciones, para un total de 828 modelos entrenados. Esto se logra usando dos librerías de Python: Darts y Pycaret. Todos los conjuntos de datos fueron entrenados con cada uno de los modelos y sus resultados finales fueron comparados para obtener el mejor modelo de cada uno de ellos, basados en cinco métricas: Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), Mean Squared Error (MSE), Root Mean Squared Logarithmic Error (RMSLE) y Mean Absolute Percentage Error (MAPE). Por otro lado, para separar los datos de entrenamiento de los datos de prueba, se usa la fecha de referencia 2017-06-30, con lo cual, todos los datos menores a esa fecha se usan como entrenamiento, comprendiendo entre 126 y 136 meses,

y todos los datos mayores a esa fecha se establecen como datos de prueba, teniendo entre 21 y 30 meses, dependiendo de los rangos para cada conjunto de datos.

Darts⁶ es una librería para la manipulación de modelos de forecasting de series de tiempo, que contiene una variedad de modelos desde clásicos hasta de redes neuronales. En este estudio, se usaron los modelos AutoARIMA, Block Recurrent Neural Networks y Recurrent Neural Networks, esto considerando que existen varias series de tiempo no estacionarias y estos modelos son recomendados para estos casos. Para los modelos de redes neuronales se realizó una búsqueda de cuadrícula o grid search, el cual es un método para encontrar la mejor configuración de hiperparámetros para un modelo; cada uno se ejecutó con 24 configuraciones distintas para encontrar los hiperparámetros óptimos para el modelo en cada serie de tiempo. En la Tabla 11, se presenta un ejemplo de resultado de entrenamiento para la serie de tiempo correspondiente a Temperatura para el municipio Puerto Salgar. Los resultados muestran los hiperparámetros óptimos para los modelos RNN, y los valores asociados a las métricas aplicadas para cada modelo.

Tabla 11. Ejemplo de resultado de entrenamiento de modelos de Darts para Temperatura - Puerto Salgar

modelo	conf_modelo	mape	mse	rmse	rmsle	mae
AutoARIMA	AutoARIMA	2.1622	0.44491	0.66701	1.57957	0.58846
BlockRNNModel	model: 'LSTM', batch_size: 1, n_epochs: 200, input_chunk_length: 1, output_chunk_length: 1, dropout: 0.0	1.7019	0.00036	0.01916	0.01867	0.01367
RNNModel	model: 'RNN', batch_size: 1, n_epochs: 100, input_chunk_length: 1, output_chunk_length: 1, dropout: 0.25}	1.8664	0.35025	0.591826	1.083934	0.50900

Por otro lado, el módulo de regresión de Pycaret (*regression*) permite realizar estimaciones de relaciones entre variables dependientes e independientes, para predecir valores continuos. Con este módulo es posible entrenar 20 modelos de regresión para cada serie de tiempo y obtener los resultados de las métricas aplicadas para cada modelo. En la Tabla 12, se presenta un ejemplo de resultado de entrenamiento para Temperatura municipio Puerto Salgar.

Tabla 12. Ejemplo de resultado de entrenamiento de modelos de Pycaret para Temperatura - Puerto Salgar

ID	Model	MAE	MSE	RMSE	RMSLE	MAPE
lr	Linear Regression	0.6304	0.6937	0.7398	0.0255	0.0224
ridge	Ridge Regression	0.6351	0.694	0.7407	0.0255	0.0226
huber	Huber Regressor	0.6179	0.7135	0.7413	0.0255	0.0219
dummy	Dummy Regressor	0.6054	0.7984	0.7559	0.026	0.0213

⁶ <https://unit8co.github.io/darts/README.html>

ID	Model	MAE	MSE	RMSE	RMSLE	MAPE
llar	Lasso Least Angle Regression	0.6054	0.7984	0.7559	0.026	0.0213
br	Bayesian Ridge	0.6561	0.7226	0.7622	0.0263	0.0234
lasso	Lasso Regression	0.6427	0.781	0.7665	0.0264	0.0228
lightgbm	Light Gradient Boosting Machine	0.6434	0.7923	0.7709	0.0266	0.0228
par	Passive Aggressive Regressor	0.6197	0.7751	0.7711	0.0266	0.0219
en	Elastic Net	0.6597	0.7917	0.7783	0.0268	0.0235
omp	Orthogonal Matching Pursuit	0.666	0.8086	0.7851	0.0271	0.0237
gbr	Gradient Boosting Regressor	0.7022	0.8991	0.8085	0.0278	0.0251
rf	Random Forest Regressor	0.7	0.8968	0.811	0.0278	0.025
catboost	CatBoost Regressor	0.7127	0.871	0.8223	0.0282	0.0255
xgboost	Extreme Gradient Boosting	0.7353	1.0335	0.8443	0.029	0.0263
ada	AdaBoost Regressor	0.7302	1.0331	0.8451	0.0289	0.0261
et	Extra Trees Regressor	0.7254	0.922	0.8458	0.029	0.0259
knn	K Neighbors Regressor	0.7738	1.0696	0.9025	0.0311	0.0276
dt	Decision Tree Regressor	0.8248	1.2481	0.9378	0.0321	0.0297
lar	Least Angle Regression	15714450 3.9375	3.70415	157144 504.042 5	1.2405	576721 4.3995

3.2.4 Selección de modelos

La selección de los modelos para cada una de las series de tiempo se hace con base en los resultados de las métricas de error, entre más pequeño el valor de error, mejor el modelo; la métrica principal elegida para este estudio es la RMSE, la cual se usa como desempate en los casos en que los resultados de las métricas entre los modelos son muy cercanos. Por ejemplo, para la serie de tiempo de Temperatura con el municipio Puerto Salgar, se presentan los modelos entrenados en la Tabla 11 y la Tabla 12, donde los mejores modelos para cada una serían BlockRNNModel y Linear Regression, respectivamente, considerando que son los modelos que presentan los valores de error menores. Finalmente, es elegido el modelo BlockRNNModel considerando que para las métricas de mae, mse, rmse y rmsle su valor es menor que para el modelo Linear Regression. Este procedimiento se realiza para todos los resultados obtenidos de los modelos entrenados en cada serie de tiempo. En la Tabla 13 se presentan los modelos seleccionados para cada serie de tiempo por variable. Los modelos seleccionados fueron salvados y almacenados, y se encuentran disponibles en GitHub⁷.

Tabla 13. Modelos seleccionados para el forecasting de series de tiempo

Variable	Municipio	Modelo	MAE	MSE	RMSE	RMSLE	MAPE
Temperatura	Cabrera	RNNModel	0.14	0.04	0.20	0.017	1.31

⁷

<https://github.com/Maddyzeth/OntologicalModelInAgriculture/tree/main/Weather%20Forecasting>

	Mosquera	Gradient Boosting Regressor	0.63	0.90	0.75	0.053	0.046
	Nemocón	Ridge Regression	0.451	0.35	0.55	0.038	0.0338
	Puerto S.	BlockRNNModel	0.014	0.0003	0.019	0.019	1.70
	Villapinzón	AutoARIMA	0.32	0.15	0.38	0.041	3.94
	Villeta	Huber Regressor	0.72	1.38	0.94	0.039	0.031
Humedad	Cabrera	K Neighbors Regressor	4.51	38.11	5.35	0.063	0.055
	Mosquera	AutoARIMA	2,01	6.56	2.56	0.031	2.45
	Nemocón	Huber Regressor	2.82	22.85	3.86	0.051	0.039
	Puerto S.	RNNModel	2.87	17.86	4.23	0.054	3.73
	Villapinzón	Random Forest Regressor	6.90	109.55	8.26	0.11	0.09
	Villeta	Huber Regressor	4.92	41.04	5.98	0.081	0.068

3.3 Integración del modelo ontológico y la predicción de variables climáticas

En la Figura 22 se presenta cómo se realiza la integración del modelo ontológico con los modelos de forecasting. Al realizar la recomendación de un cultivo para un mes del año en una zona específica, se ingresa como valores de entrada el mes y año en el que se desea la recomendación para cada modelo asociado a las variables de temperatura y humedad de la zona determinada. Los resultados de cada modelo van a retornar un valor de predicción para la variable asociada. Este valor va a ser la entrada para el individuo de cada concepto; el valor de la humedad corresponde al atributo *nivelHumedad* que se asocia al concepto Humedad de la Zona, y el atributo *temperatura* va a tener el valor de predicción asociado al concepto Temperatura.




Figura 22. Integración del modelo ontológico con la predicción de variables climáticas. Elaboración propia.

3.4 Validación del modelo de inferencia

En esta sección se presenta la validación del modelo ontológico aplicando pruebas con datos históricos de cultivos realizados en periodos anteriores que tuvieron o no un buen desarrollo.

3.4.1 Identificación de datos históricos

Los conjuntos de datos identificados sobre datos históricos de cultivos que fueron desarrollados y análisis de suelo, se encontraron a través de la plataforma de datos abiertos de Colombia⁸, proporcionados por las entidades Unidad de Planificación de Tierras Rurales, Adecuación de Tierras y Usos Agropecuarios (UPRA) y por la Corporación Colombiana de Investigación Agropecuaria (Agrosavia). Estos conjuntos de datos presentan la producción de cultivos entre los años 2018 y 2020 en los diferentes municipios de Cundinamarca, y las condiciones del suelo de estas zonas. Adicionalmente, para la producción de cultivos se especifica un estado de la producción. Todo el procesamiento de los datos se hizo usando Python y la librería *pandas*.

Inicialmente, para ambos conjuntos de datos se filtraron los municipios de Cundinamarca elegidos previamente para el análisis: Cabrera, Mosquera, Nemocón, Puerto Salgar, Villapinzón y Villeta. Para el conjunto de datos de análisis de suelo fue necesario eliminar algunas columnas que no van a ser utilizadas para el análisis como el riego, el drenaje y los fertilizantes aplicados. Adicionalmente, también se descartaron las columnas asociadas a los minerales ya que no todos los minerales fueron encontrados en la documentación de condiciones óptimas y en los casos en que sí, la unidad de medida podía ser distinta. En el caso del conjunto de datos de producción de cultivos, se descartaron columnas asociadas al grupo de cultivo (la cual estaba vacía) y el nombre científico del cultivo.

Ambos conjuntos de datos fueron unidos en un solo dataframe por su municipio y cultivo, y para cada zona se adicionó la altura correspondiente. Para eliminar espacios y caracteres especiales se normalizaron los nombres de las columnas; en la Figura 23 se presenta una muestra del conjunto de datos que se usa para la validación.

⁸ www.datos.gov.co

	Departamento	Topografía	Municipio	Altura	Cultivo	pH	Ano	Periodo	CicloCultivo	EstadoProduccion
0	cundinamarca	ligeramente ondulado	villeta	850	tomate	6.06	2019	2019B	transitorio	hortaliza fresca
1	cundinamarca	ligeramente ondulado	villeta	850	tomate	6.06	2019	2019A	transitorio	hortaliza fresca
2	cundinamarca	ligeramente ondulado	villeta	850	tomate	6.06	2018	2018A	transitorio	hortaliza fresca
3	cundinamarca	plano	mosquera	2516	lechuga	6.38	2019	2019B	transitorio	hortaliza fresca
4	cundinamarca	plano	mosquera	2516	lechuga	6.38	2019	2019A	transitorio	hortaliza fresca
5	cundinamarca	plano	mosquera	2516	lechuga	6.38	2018	2018A	transitorio	hortaliza fresca
6	cundinamarca	moderadamente ondulado	mosquera	2516	lechuga	7.16	2019	2019B	transitorio	hortaliza fresca
7	cundinamarca	moderadamente ondulado	mosquera	2516	lechuga	7.16	2019	2019A	transitorio	hortaliza fresca
8	cundinamarca	moderadamente ondulado	mosquera	2516	lechuga	7.16	2018	2018A	transitorio	hortaliza fresca
9	cundinamarca	plano	mosquera	2516	lechuga	5.48	2019	2019B	transitorio	hortaliza fresca

Figura 23. Muestra de los datos históricos. Elaboración propia.

3.4.2 Definición de casos de prueba y generación de inferencias

Los casos de prueba se definen para zonas, cultivos y periodos. Como se ha mencionado anteriormente, se han seleccionado 6 municipios del departamento de Cundinamarca, y para cada municipio existen zonas con características específicas asociadas en las que se cultiva. Considerando que en el conjunto de datos no se especifica la zona, se asume que cada registro corresponde a una zona específica y se le asigna un ID generado.

Los cultivos seleccionados son lechuga, tomate de árbol, maíz, zanahoria, fresa, lulo, tomate, frijol, arveja y cacao. Esta selección se basa en la información disponible en el conjunto de datos históricos y también en la disponibilidad de información correspondiente a los valores óptimos para el buen desarrollo de los cultivos.

En cuanto al periodo de prueba, se tiene en cuenta un periodo entre 2018 y 2019 dividido en periodos de seis meses (por ejemplo: 2018A el primer semestre y 2018B para el segundo semestre). Este también se define en función de la disponibilidad de información histórica y de los datos de prueba definidos para los modelos de forecasting.

3.4.2.1 Proyección de variables climáticas para el caso de prueba

Es necesario realizar la predicción de las variables de temperatura y humedad para el conjunto de datos seleccionado para el caso de prueba. Teniendo en cuenta que cada registro es una zona en un periodo específico, es necesario hacer la predicción en cada fila, considerando el rango de seis meses; tanto para la temperatura como para la humedad se toma el valor de la mediana de los seis meses de predicción, esto con el objetivo de no afectar el cálculo para los casos en que los valores son muy diferentes entre sí. En la Figura 24 presenta un ejemplo de visualización del conjunto de datos adicionando las columnas temperatura y humedad con el valor de la predicción.

	Departamento	Topografía	Municipio	Altura	Cultivo	pH	Ano	Periodo	CicloCultivo	EstadoProduccion	Humedad	Temperatura
0	cundinamarca	ligeramente ondulado	villeta	850	tomate	6.06	2019	2019B	transitorio	hortaliza fresca	81.505783	13.374167
1	cundinamarca	ligeramente ondulado	villeta	850	tomate	6.06	2019	2019A	transitorio	hortaliza fresca	81.512161	13.374167
2	cundinamarca	ligeramente ondulado	villeta	850	tomate	6.06	2018	2018A	transitorio	hortaliza fresca	81.505783	13.374167
3	cundinamarca	plano	mosquera	2516	lechuga	6.38	2019	2019B	transitorio	hortaliza fresca	81.512161	13.374167
4	cundinamarca	plano	mosquera	2516	lechuga	6.38	2019	2019A	transitorio	hortaliza fresca	81.505783	13.374167
5	cundinamarca	plano	mosquera	2516	lechuga	6.38	2018	2018A	transitorio	hortaliza fresca	81.512161	13.374167
6	cundinamarca	moderadamente ondulado	mosquera	2516	lechuga	7.16	2019	2019B	transitorio	hortaliza fresca	93.469151	8.627745
7	cundinamarca	moderadamente ondulado	mosquera	2516	lechuga	7.16	2019	2019A	transitorio	hortaliza fresca	93.469151	8.627336
8	cundinamarca	moderadamente ondulado	mosquera	2516	lechuga	7.16	2018	2018A	transitorio	hortaliza fresca	88.974290	11.068109
9	cundinamarca	plano	mosquera	2516	lechuga	5.48	2019	2019B	transitorio	hortaliza fresca	88.974290	11.068703

Figura 24. Muestra de datos históricos con los valores de predicción de humedad y temperatura

3.4.3 Creación de individuos en la ontología

Los individuos se añaden a la ontología de manera automatizada usando Python con la librería Owlready2 (ver sección *Creación de individuos* en Implementación). Para esto, se recorre el dataframe de los datos históricos y por cada fila se crean los individuos asociados. En la Tabla 14 se describe el tipo de individuos creados.

Tabla 14. Descripción de individuos adicionados a la ontología

Concepto del individuo	Detalle
Acidez	Para cada zona (registro de la tabla) se crea un individuo de tipo Acidez que se relaciona con el suelo de la zona por la relación <i>haceParteDe</i> . Se asocia el atributo <i>nivelPh</i> con el valor correspondiente.
Altura	Para cada zona (registro de la tabla) se crea un individuo de tipo Altura que se relaciona con la zona por la relación <i>correspondeA</i> . Se asocia el atributo <i>altura</i> con el valor correspondiente.
Área Cultivable	Para cada zona (registro de la tabla) se crea un individuo de tipo Área Cultivable que se relaciona con la zona por la relación <i>conformaZona</i> . Se asocia con el cultivo correspondiente por la relación <i>crece</i> .
Cultivo	Para cada cultivo se crea un individuo único de tipo Cultivo.
Departamento	Este individuo se crea una única vez con Cundinamarca. Se relaciona con los municipios con la relación <i>tieneRegion</i> .
Humedad	Para cada zona (registro de la tabla) se crea un individuo de tipo Humedad que se relaciona con la zona por la relación <i>seEncuentraEn</i> . Se asocia el atributo <i>nivelHumedad</i> con el valor correspondiente.
Región	Para cada municipio se crea un individuo único de tipo Región. Se relaciona con las zonas por la relación <i>conformadaPor</i> .
Suelo	Para cada zona (registro de la tabla) se crea un individuo de tipo Suelo que se relaciona con la zona por la relación <i>compone</i> .
Temperatura	Para cada zona (registro de la tabla) se crea un individuo de tipo Temperatura que se relaciona con la zona por la relación <i>seAsociaA</i> . Se asocia el atributo <i>temperatura</i> con el valor correspondiente.
Topografía	Para cada zona (registro de la tabla) se crea un individuo de tipo Topografía que se relaciona con la zona por la relación <i>seAsociaA</i> . Se asocia el atributo <i>relieve</i> con el valor correspondiente.
Zona	Para cada registro de la tabla se crea un individuo de tipo Zona generando un ID único por cada uno.

En la Figura 25 se muestra un ejemplo de cómo se visualizan algunos individuos creados para el concepto Cultivo usando Protégé un software para creación y edición de ontologías en términos de OWL basado en Java. El modelo exportado desde Python de tipo OWL puede importarse en Protégé ya que facilita la exploración de las entidades del modelo ontológico mediante su interfaz gráfica.




Figura 25. Visualización de individuos con Protégé. Elaboración propia.

3.4.3.1 Razonamiento y generación de inferencias

La creación y ejecución del razonador para generación de inferencias se realiza en bloques de 50 registros de datos históricos. Una vez creados los individuos relacionados, se inicia el razonamiento de la ontología con la función `sync_reasoner_pellet()`. Las inferencias generadas por zona y cultivo se representan como objetos de Python. Los resultados obtenidos se adicionan a un dataframe y se guardan como una tabla en formato .CSV.

3.5 Resultados y análisis

En esta sección se presentan los resultados de las inferencias generadas por el modelo. Estos resultados se clasifican en dos: la recomendación de zonas cultivables en función de un cultivo concreto y la recomendación de cultivos en función de las características de una zona. Adicionalmente, también se presentan resultados de la consistencia de la ontología a través de métricas de medición que permiten determinar el nivel de complejidad y dependencia de las entidades de la ontología.

3.5.1 Recomendación de zonas

La recomendación de zonas se hace con base en las inferencias obtenidas sobre cuáles áreas cultivables están dentro de los rangos óptimos para que un cultivo pueda desarrollarse allí. Las recomendaciones se muestran en función de los municipios, donde cada municipio puede tener diferentes zonas que se denotan como *casos históricos*. Estas inferencias se basan en los individuos registrados como áreas cultivables de las diferentes

zonas, y mediante sus relaciones con las regiones se obtiene cuál es el municipio donde se recomienda el cultivo. En la Figura 26 se presenta el porcentaje de casos históricos que se tienen por municipio. El municipio con más información es el municipio de Cabrera, que abarca más de la mitad de los datos. Los municipios de Puerto Salgar y Villeta tienen pocos registros, es decir, pocas zonas para evaluación de casos históricos. Esta información es importante ya que, al tomar la precisión de las inferencias por municipio, los resultados con pocos datos no se pueden considerar representativos de la precisión del modelo.




Figura 26. Porcentaje de registros por zona. Elaboración propia.

En la Figura 27 se presentan la cantidad de datos históricos vs datos inferidos para las zonas por periodos de seis meses. El segundo semestre del año 2018 tiene considerablemente menos registros de datos históricos que el resto de los semestres, los cuales tienen valores con escasa diferencia entre ellos, teniendo que el año 2019 presenta la misma cantidad de datos históricos en ambos semestres. Todos los semestres presentan una precisión de aproximadamente 0.8 en función de los datos inferidos. De manera general, se puede ver que el modelo mantiene el mismo porcentaje de precisión en los periodos evaluados para la recomendación de zonas.




Figura 27. Casos históricos y resultados inferidos por periodo para zonas. Elaboración propia.

La Tabla 15 presenta los resultados obtenidos de las inferencias generadas por el modelo ontológico a nivel de zonas para los años 2018 y 2019. Para establecer la precisión se evalúa el total de datos históricos por zona y el total de resultados inferidos correctamente. En promedio, se obtuvo una precisión del 0.798 para la recomendación de zonas cultivables. Ambos periodos evaluados presentan una precisión muy cercana entre ellos teniendo una precisión de 0.798 para el 2018 y una precisión del 0.797 para el 2019. Las zonas de Nemocón y Villapinzón presentan un bajo porcentaje de datos inferidos en función de los datos históricos con un aproximado de 0.6 de precisión. Sin embargo, hay que considerar que los datos para estas zonas representan el 20 % de los datos totales. Para las demás zonas, todas presentan un aproximado de 0.8 de precisión; las zonas Puerto Salgar y Villeta tienen un número bajo de datos por lo que individualmente no es posible determinar el porcentaje de precisión aplicado a estas zonas. En general, el modelo presenta un buen resultado y rendimiento para la recomendación de zonas en diferentes periodos.

Tabla 15. Resultado de recomendación de zonas

Periodo	Municipio	Casos históricos	Resultados inferidos	Precisión
2018	Cabrera	21	17	0.7981
	Mosquera	63	54	
	Nemocón	12	7	
	Puerto Salgar	2	2	
	Villapinzón	10	6	
	Villeta	1	1	
2019	Cabrera	24	20	0.7968
	Mosquera	122	103	
	Nemocón	24	14	
	Puerto Salgar	2	2	
	Villapinzón	18	12	
	Villeta	2	2	

3.5.2 Recomendación de cultivos

La recomendación de cultivos se hace con base en las inferencias obtenidas sobre cuáles cultivos podrían desarrollarse bien en una zona de acuerdo con las características del área. Al igual que para la recomendación de zonas, para establecer la precisión se evalúa el total de datos históricos por zona y el total de resultados inferidos correctamente. Estas inferencias se basan en los individuos registrados como cultivos, y cuáles áreas cultivables se obtienen al hacer las inferencias; si alguno de los individuos de áreas cultivables que se encuentra dentro de los resultados obtenidos para un cultivo también se encuentra en los datos históricos con buenos resultados, se considera que la inferencia es correcta. En la Figura 28 se presenta el porcentaje de casos históricos que se tienen por cultivo. Se presenta el mismo caso de los municipios, donde un cultivo

(lechuga) tiene un porcentaje considerable mayor de información con respecto a los demás.




Figura 28. Porcentaje de registros por cultivo. Elaboración propia.

En la Figura 29 se presentan la cantidad de datos históricos vs datos inferidos para los cultivos por semestres. Los resultados son similares a los de las zonas; los datos tienen valores con escasa diferencia entre ellos para la mayoría de los semestres, y se tiene la misma cantidad que para las zonas, ya que los cultivos se evalúan en función de las mismas zonas registradas como individuos. Para recomendación de cultivos, el modelo presenta un aproximado de 0.8 de precisión por periodo.




Figura 29. Casos históricos y resultados inferidos por periodo para cultivos. Elaboración propia.

La Tabla 16 presenta los resultados obtenidos de las inferencias generadas por el modelo ontológico a nivel de cultivos resumido en los periodos 2018 y 2019. En promedio, se obtuvo una precisión del 0.785 para la recomendación de cultivos. Similarmente a los resultados de las zonas, los periodos evaluados presentan una precisión muy cercana con 0.779 para el 2018 y 0.791 para el 2019. El cultivo de la arveja presenta una baja precisión con 0.58, lo que podría indicar que es necesario revisar y ajustar los rangos de las reglas asociadas al cultivo. El resto de los cultivos presentan una precisión mayor al 0.75, por lo que de manera general tiene un buen resultado y desempeño.

Tabla 16. Resultados de recomendación de cultivos

Periodo	Cultivo	Casos históricos	Resultados inferidos	Precisión
2018	Arveja	12	7	0.7798
	Cacao	2	2	
	Fresa	8	6	
	Frijol	1	1	
	Lechuga	48	37	
	Lulo	2	2	
	Maíz	9	9	
	Tomate	1	1	
	Tomate de árbol	18	14	
	Zanahoria	8	6	
2019	Arveja	24	13	0.7916
	Cacao	2	2	
	Fresa	8	6	
	Frijol	2	2	
	Lechuga	96	77	
	Lulo	2	2	
	Maíz	20	20	
	Tomate	2	2	
	Tomate de árbol	18	14	
	Zanahoria	18	14	

Teniendo en cuenta los resultados para recomendación de cultivos y zonas en periodos específicos, se puede ver que el modelo presenta una precisión del 0,78. Sin embargo, para los casos de cultivos y zonas con pocos datos, es necesario tener más datos para poder evaluar efectivamente su precisión individual. Adicionalmente, también es necesario hacer una revisión de los rangos establecidos para el cultivo de la arveja ya que presenta un bajo nivel de precisión.

3.5.3 Métricas para la ontología

El nivel de complejidad y dependencia entre conceptos es medido a través de las métricas propuestas por (Zhang et al., 2010), clasificándolas como métricas a nivel de ontología, las cuales miden la complejidad del diseño de la ontología, y métricas a nivel de clases, que miden la complejidad de las clases. Esto permite mejorar el diseño de la ontología en función de su aplicabilidad computacional. La ontología cuenta con un total de 28 conceptos (contando la superclase *Thing*), 23 atributos, y 41 relaciones, contando también las relaciones inversas.

3.5.3.1 Resultados de métricas a nivel de ontología

A nivel de ontología, se aplican las métricas SOV, ENR y TIP. La métrica SOV mide la totalidad de la ontología que incluye conceptos, individuos, atributos tanto de clase, como

de instancia y la cantidad de reglas definidas. ENR mide la relación entre las relaciones y los conceptos y TIP mide la pureza de la jerarquía; estas tres métricas permiten interpretar qué tan compleja es la ontología.

Análisis SOV. Para la ontología propuesta se tiene un resultado de 12718; considerando los resultados mostrados por (Zhang et al., 2010) al comparar 21 ontologías, la ontología presentada en esta investigación tiene una complejidad promedio con respecto a otras ontologías planteadas. Sin embargo, se puede considerar de una complejidad alta debido a la cantidad de memoria computacional que necesita para procesar las inferencias; en el caso de esta ontología, es necesario contar con mínimo 8GB de memoria RAM. Al crecer el número de individuos, el tiempo de ejecución y los recursos requeridos también se incrementan.

Análisis ENR. Para esta métrica, se obtuvo un valor de 1.46. Este resultado muestra la correspondencia entre conceptos y relaciones, por lo tanto, entre mayor sea este número, más compleja es la ontología. En general, el valor de correspondencia es bajo, por lo que la complejidad de la ontología podría considerarse baja para esta métrica.

Análisis TIP. Este valor mide el grado de impureza de un árbol. La ontología resultante en esta investigación tiene un valor TIP = 0, lo que significa que no existen aristas adicionales y la jerarquía de herencia corresponde a un árbol, lo que puede significar un bajo nivel de complejidad.

3.5.3.2 6.2 Resultados de las métricas de nivel de clases

Teniendo en cuenta que las métricas de clases miden los niveles por cada uno de los conceptos, los resultados se resumen presentando el valor máximo, el valor mínimo y el promedio. En la Tabla 17, se muestran los resultados para las métricas *NOC*, *DIT*, *CID* y *COD*. Para obtener estas métricas, se tuvieron en cuenta los 28 conceptos que incluyen la superclase *Thing*.

Tabla 17. Resultados de métricas de nivel de clases.

	<i>NOC</i>	<i>DIT</i>	<i>CID</i>	<i>COD</i>
Máximo	23	2	23	10
Mínimo	4	1	0	0
Promedio	13,5	1,15	2,71	2,86

Análisis NOC. Esta métrica indica el número de reutilización de un concepto y el nivel de dependencia de un concepto a otro. El mayor valor de NOC es 23, el cual es considerablemente alto teniendo en cuenta que son 28 clases en total, por lo tanto, hay un alto nivel de reutilización. No obstante, esto indica que existen 23 clases dependientes de una clase, pero, considerando que es la superclase *Thing* y que esta no cambiará eventualmente, el resultado es bueno.

Análisis DIT. Esta métrica muestra la profundidad de la herencia y la reutilización que tiene cada clase. En general, el resultado para esta métrica es bajo; esto significa que las clases en su mayoría solo reusan información de una clase. Sin embargo, esto también significa que no existen mayores dependencias, es decir, clases que tengan muchos antecesores, lo que facilita mantener la ontología.

Análisis CID. Esta mide la cantidad de relaciones de entrada que tiene una clase, es decir, que entre más entradas tenga, depende de más conceptos. El resultado muestra que la superclase *Thing* tiene el mayor número de dependencias, siendo en total 23; sin embargo, esta clase no se modifica, por lo que no tiene dificultades cuando un concepto cambia. En promedio, un concepto depende de aproximadamente otros tres conceptos, por lo que no existe una alta dependencia.

Análisis COD. Mide la cantidad de relaciones de salida que tiene una clase, es decir, que entre más salidas tenga, más conceptos dependen de ella. El mayor número de dependencias corresponden a los conceptos *Zona* y *Cultivo* con 10 y 9 respectivamente, lo que significa que antes de hacer un cambio a alguno de estos conceptos, es necesario considerar que van a afectar a otros conceptos. Al igual que el anterior, en promedio, un concepto puede afectar aproximadamente a tres conceptos, lo que representa una baja dependencia.

3.6 Prototipo de software

En esta sección se presenta el prototipo de software OntoAgri, una aplicación web creada para consumir el modelo ontológico descrito anteriormente y presentar una interfaz gráfica para que los agricultores y expertos puedan interactuar con los elementos de la ontología. Esta aplicación se desarrolla utilizando el marco Flask, que se utiliza a través de una biblioteca de Python para crear aplicaciones web. Flask es un framework para desarrollo web para Python, ligero y fácil de usar que hace que la creación de aplicaciones web sea rápida y sencilla (Divya et al., 2021). Adicionalmente, al estar basado en Python, facilitó la integración con la ontología creada con Owlready2, de esta forma la aplicación Web tenía comunicación directa con las entidades de la ontología y podía poner recomendaciones a disposición de los usuarios. La Figura 30 muestra la arquitectura general de la aplicación que se basa en tres capas: la capa de presentación, la capa lógica y la capa de datos.

La comunicación entre la capa de presentación y la capa lógica se realiza a través de Ajax utilizando el formato JSON para el intercambio de mensajes. La capa lógica se comunica con la capa de datos a través del paquete Python *pymongo* que permite la interacción con la base de datos MongoDB utilizando el puerto 27017.




Figura 30. Arquitectura general de capas de la aplicación Web OntoAgri. Elaboración propia.

3.6.1 Capa de presentación

La capa de presentación se basa en archivos HTML, CSS y JavaScript para el funcionamiento de la aplicación web. La aplicación cuenta con vistas especializadas en dos usuarios: agricultores y administradores (Figura 31). Los agricultores pueden registrarse e iniciar sesión en OntoAgri y registrar fincas, ingresando las características geográficas. Los agricultores pueden seleccionar la finca en la que quieren cultivar y recibir recomendaciones sobre los cultivos que deben cultivar. El agricultor también puede seleccionar uno de los cultivos disponibles y recibir recomendaciones a través de un mapa sobre lugares de Colombia convenientes, con indicaciones sobre las ubicaciones recomendadas.

Un administrador experto en desarrollo agrícola puede ingresar y agregar un nuevo cultivo incluyendo las características agroclimáticas básicas para el óptimo desarrollo del cultivo. Los cultivos recién agregados estarán disponibles para las recomendaciones de los agricultores.



Figura 31. Ejemplo de visualización de la aplicación web OntoAgri para ingreso de usuarios. Elaboración propia.




Figura 32. Ejemplo de visualización de la aplicación web OntoAgri para recomendaciones. Elaboración propia.

3.6.2 Capa lógica

La comunicación entre la capa de presentación y la capa lógica se realiza a través de AJAX, enviando datos en una estructura JSON del tipo clave-valor. Los datos compartidos entre las capas son el insumo principal para activar las diferentes funcionalidades de la aplicación como lo son iniciar sesión, registrar fincas, solicitar recomendaciones de cultivos y zonas, visualizar las fincas y actualizar algunos datos.

La capa lógica se basa en el modelo ontológico desarrollado utilizando la biblioteca Python Owlready2. En esta capa se utiliza el razonador Pellet, el cual se basa en reglas

escritas en SWRL para generar las recomendaciones de zonas y cultivos. Este evalúa las características de los cultivos y las zonas para dar la inferencia. Cada vez que un administrador ingresa un nuevo cultivo, esta información se transcribe automáticamente a una nueva regla en lenguaje SWRL y se guarda en la base de datos MongoDB utilizando la biblioteca pymongo, un controlador dentro del código del software python que permite interactuar con las bases de datos MongoDB. De esta forma, cada vez que un usuario solicita una recomendación, las reglas se obtienen de la base de datos.

3.6.3 Capa de datos

Esta capa se refiere a la base de datos en MongoDB donde se registra información sobre agricultores, reglas, cultivos y ubicaciones. MongoDB es una base de datos orientada a documentos NoSQL donde la información se registra en documentos y colecciones de documentos. Un documento se basa en un conjunto de campos clave-valor representado como JSON. MongoDB proporciona consultas dinámicas y el aumento de la velocidad de las consultas gracias a la facilidad de dividir los datos de forma lógica (Abbes & Gargouri, 2016). Por ejemplo, en los documentos del agricultor, es posible incluir documentos relacionados con fincas que pertenecen a un agricultor. Las colecciones creadas se enumeran a continuación.

- **Agricultores:** se refiere a datos personales para el ingreso e información de las fincas, donde cada agricultor puede tener una o más fincas.
- **Cultivos:** rangos de características óptimas para el correcto desarrollo del cultivo.
- **Ubicaciones:** información sobre la longitud y latitud de las diferentes áreas para mostrar en el mapa.
- **Reglas:** reglas del lenguaje SWRL definidas para generar inferencias a través del motor de inferencia; hay reglas predefinidas, así como reglas que se agregan automáticamente cuando se agrega un nuevo cultivo como individuo.

Capítulo 4

Conclusiones

El modelo ontológico presentado en esta investigación relaciona los conceptos básicos para el desarrollo de un cultivo, apoya a los agricultores en la toma de decisiones sobre qué y dónde cultivar, teniendo en cuenta las características de las zonas y cultivos; los conceptos se obtuvieron de documentos especializados en producción agrícola emitidos por entidades gubernamentales colombianas. Las reglas definidas permiten que el razonamiento de la ontología genere deducciones a partir de inferencias lógicas. Este modelo se integra con modelos de forecasting de series de tiempo para las variables de temperatura y humedad, lo que permite proporcionar recomendaciones de cultivos o zonas cultivables en un periodo específico, basándose en las variables climáticas pronosticadas. Los resultados del caso de uso que contempla datos históricos de cultivos sembrados anteriormente en municipios del departamento de Cundinamarca muestran un porcentaje de confiabilidad del 80 % tanto para la recomendación de cultivos, como para la recomendación de zonas en periodos de seis meses comprendidos entre los años 2018 y 2019. Este modelo permite proyectar recomendaciones de qué cultivos se deben sembrar en una zona específica de Colombia, en un periodo determinado, considerando características climatológicas y geográficas de la zona.

Como parte de la proyección de datos climáticos, se obtiene un total de 12 modelos de forecasting de series de tiempo para las seis zonas consideradas en las variables de la temperatura y la humedad, cuyos resultados con respecto a los datos reales presentan una confiabilidad del 95 % para los periodos evaluados entre el 2017 y 2019. Estos modelos se usan en conjunto con el modelo conceptual para alcanzar mayores índices de confiabilidad en las recomendaciones de desarrollo de los cultivos para un periodo específico, considerando las condiciones climáticas de la zona donde se planea cultivar.

El modelo presenta un bajo nivel de precisión para el cultivo de la arveja. Esta situación puede ocurrir por una mala definición de los rangos en las reglas aplicadas. Dado que estos rangos se tomaron con base en la documentación oficial del Ministerio de Agricultura de Colombia, sería importante validarlos con expertos. Por lo tanto, es posible

considerar ajustar las reglas para este cultivo variando rangos, agregando o eliminando características. Otra posibilidad para este bajo nivel de precisión son los datos, ya que la evaluación se hizo con una cantidad limitada de datos y para el cultivo de la arveja se tiene el 12 % de los datos totales evaluados. Sería importante validar las reglas con nuevos registros de diferentes regiones de Colombia.

A partir de lenguajes de programación y paquetes especializados como Python y Owlready2, se facilita el proceso de creación y manipulación de ontologías y su integración con otras plataformas, como OntoAgri. Esta aplicación web apoya a los agricultores en su proceso de toma de decisiones sobre qué cultivar, consumiendo el modelo ontológico para generar inferencias basadas en las elecciones del usuario.

Principales aportes:

Considerando los resultados alcanzados con esta investigación y los objetivos propuestos, se presentan los siguientes aportes de este proyecto de grado:

- Se obtuvo un modelo ontológico en lenguaje OWL con reglas basadas en lógica de predicados de primer orden para la inferencia y recomendación de cultivos y zonas cultivables, considerando variables geográficas, climáticas y fisiológicas.
- Se obtuvo 12 modelos de forecasting para series de tiempo para las variables de temperatura y humedad, en las seis zonas elegidas, disponibles en GitHub.
- Integración del modelo ontológico con los resultados de forecasting de las series de tiempo para recomendaciones basadas en un periodo determinado, de acuerdo con las características climáticas de la zona, obteniendo un porcentaje de precisión del 80 % con las pruebas realizadas.
- El prototipo software desarrollado permite evidenciar la aplicación del modelo ontológico para recomendación de zonas y cultivos, y creación de nuevas reglas basadas en las características óptimas definidas para los cultivos. El acceso se realiza a través de una aplicación Web donde cada tipo de usuario puede ingresar con un usuario y una contraseña, y realizar acciones como registrar nuevos cultivos (administradores), registrar fincas, solicitar recomendación de zonas para cultivos disponibles, y solicitar recomendaciones de cultivos para las fincas ingresadas. Esto apoya a los agricultores a tomar decisiones sobre la siembra de los cultivos.

Capítulo 5

Prospectiva del trabajo de grado

5.1 Productos

Esta sección presenta los productos generados de esta investigación, especificando su estado: publicado, en revisión y en desarrollo. Se asocian artículos de investigación y un producto de software.

5.1.1 Artículos

- Design and application of an ontology to identify crop areas and improve land use. Acta Geophysica, Q2. <https://doi.org/10.1007/s11600-022-00808-5>. Publicado.
- Application and evaluation of time series forecasting models for weather variables in Colombia. En desarrollo.
- Ontological inference model for characterization of crop options based on weather variables. En desarrollo.

5.1.2 Software

- OntoAgri: sistema de recomendación de cultivos basado en ontologías. En proceso de registro.

5.2 Recomendaciones y trabajos futuros

El proceso investigativo desarrollado y los resultados alcanzados permiten proponer un conjunto de recomendaciones y posibilidades para la continuidad del proyecto desde diferentes enfoques.

5.2.1 Recomendaciones

Considerando la implementación del modelo ontológico en el dominio de la agricultura y su integración con modelos de forecasting de series de tiempo para variables climáticas, se postulan las siguientes recomendaciones:

- En este estudio se considera como casos de pruebas seis municipios del departamento de Cundinamarca y unos cultivos seleccionados. Para aplicar recomendaciones a nuevas zonas y cultivos es necesario agregarlos como nuevos individuos en el modelo ontológico con sus respectivas características asociadas, y crear nuevas reglas para los cultivos con sus rangos óptimos.
- Los modelos de forecasting de series de tiempo fueron entrenados con datos específicos de los municipios de Cundinamarca. Para reutilizarlos en nuevas zonas, es posible tomar las configuraciones de hiperparámetros de los modelos, inicializarlos y entrenarlos con los nuevos datos que se deseen entrenar.

5.2.2 Trabajos futuros

Como trabajos futuros, se postulan diferentes enfoques opcionales de continuidad de este proyecto:

- Adicionar nuevas variables climáticas como la luminosidad y la precipitación para proyección de datos climáticos en los modelos de forecasting y su integración con el modelo ontológico.
- Considerar series de tiempo multivariantes para las variables climáticas, ya que estas variables pueden tener dependencia no solo en el tiempo, sino también entre ellas; por ejemplo, la humedad y la precipitación puede considerarse para el pronóstico de la temperatura.
- Para validar la ontología es importante contar con un mayor volumen de datos que permita probar las diferentes reglas propuestas por lo que se propone el uso de técnicas de análisis de datos para la adquisición y organización de los registros necesarios, además del uso de dispositivos como sensores en las zonas de siembra para recolectar datos en tiempo real.
- A medida que se incluyen más zonas y cultivos, es necesario incluir más reglas; por esta razón, la implementación de métodos de aprendizaje automático y procesamiento del lenguaje natural es importante para descubrir patrones en la documentación oficial proporcionada por el gobierno colombiano que permitan generar nuevas reglas.

Capítulo 6

Referencias

- Abadi, A., Ben-Azza, H., & Sekkat, S. (2018). Improving integrated product design using SWRL rules expression and ontology-based reasoning. *Procedia Computer Science*, 127, 416–425. <https://doi.org/10.1016/j.procs.2018.01.139>
- Abbes, H., & Gargouri, F. (2016). Big Data Integration: A MongoDB Database and Modular Ontologies based Approach. *Procedia Computer Science*, 96(September), 446–455. <https://doi.org/10.1016/j.procs.2016.08.099>
- Alashari, M., El-Rayes, K., Attalla, M., & Al-Ghzawi, M. (2022). Multivariate time series and regression models for forecasting annual maintenance costs of EPDM roofing systems. *Journal of Building Engineering*, 54, 104618. <https://doi.org/10.1016/j.jobe.2022.104618>
- Alfonso Casallas, H. S., & Ariza Riaño, M. (2019). *PROTOTIPO ONTOLÓGICO PARA CARACTERIZACIÓN DE ZONAS Y OPCIONES DE CULTIVO MEDIANTE LA APLICACIÓN DE LÓGICA DE PREDICADOS* [Universidad Distrital Francisco José de Caldas]. [http://repository.udistrital.edu.co/bitstream/11349/15085/1/AlfonsoCasallasHein](http://repository.udistrital.edu.co/bitstream/11349/15085/1/AlfonsoCasallasHein%20erSantiago2019.pdf)
- Alkhamash, E. (2020). Formal modelling of OWL ontologies-based requirements for the development of safe and secure smart city systems. *Soft Computing*, 24(15), 11095–11108. <https://doi.org/10.1007/s00500-020-04688-z>
- Alonso, S., & Sicilia, M. (2007). Using an AGROVOC-based ontology for the description of learning resources on organic agriculture. In *Metadata and Semantics*. https://doi.org/10.1007/978-0-387-77745-0_47
- Arnaud, E., Laporte, M. A., Kim, S., Aubert, C., Leonelli, S., Miro, B., Cooper, L., Jaiswal, P., Kruseman, G., Shrestha, R., Buttigieg, P. L., Mungall, C. J., Pietragalla, J., Agbona, A., Muliro, J., Detras, J., Hualla, V., Rathore, A., Das, R. R., ... King, B. (2020). The Ontologies Community of Practice: A CGIAR Initiative for Big Data in Agrifood Systems. *Patterns*, 1(7). <https://doi.org/10.1016/j.patter.2020.100105>
- Beltrán, M., & Zhindon, C. (2012). *Guía técnica para el establecimiento y manejo del cultivo de cacao*. [http://www.corporacionpba.org/portal/sites/default/files/Guía técnica para el manejo del cultivo de cacao.pdf](http://www.corporacionpba.org/portal/sites/default/files/Guía%20técnica%20para%20el%20manejo%20del%20cultivo%20de%20cacao.pdf)
- Bolton, D. K., Tompalski, P., Coops, N. C., White, J. C., Wulder, M. A., Hermosilla, T., Queinnec, M., Luther, J. E., van Lier, O. R., Fournier, R. A., Woods, M., Treitz, P. M., van Ewijk, K. Y., Graham, G., & Quist, L. (2020). Optimizing Landsat time series length for

- regional mapping of lidar-derived forest structure. *Remote Sensing of Environment*, 239, 111645. <https://doi.org/10.1016/J.RSE.2020.111645>
- Bonacin, R., Nabuco, O. F., & Pierozzi Junior, I. (2016). Ontology models of the impacts of agriculture and climate changes on water resources: Scenarios on interoperability and information recovery. *Future Generation Computer Systems*, 54, 423–434. <https://doi.org/10.1016/j.future.2015.04.010>
- Brockwell, P. J. (2020). Time series analysis. In *International Encyclopedia of Education* (Second Edi, Vol. 13). Elsevier. <https://doi.org/10.1016/B978-0-08-044894-7.01372-5>
- Buoncompagni, L., Kareem, S. Y., & Mastrogiovanni, F. (2022). OWLOOP: A modular API to describe OWL axioms in OOP objects hierarchies. *SoftwareX*, 17, 100952. <https://doi.org/10.1016/j.softx.2021.100952>
- Cámara de comercio de Bogotá. (2015). *Manual de fresa*. <https://bibliotecadigital.ccb.org.co/handle/11520/14312>
- Carvalho, V. A., Almeida, J. P. A., Fonseca, C. M., & Guizzardi, G. (2017). Multi-level ontology-based conceptual modeling. *Data & Knowledge Engineering*, 109, 3–24. <https://doi.org/https://doi.org/10.1016/j.datak.2017.03.002>
- Chandrasekaran, B., Josephson, J., & Benjamins, V. R. (1999). What Are Ontologies, and Why Do We Need Them? *Intelligent Systems and Their Applications, IEEE*, 14, 20–26. <https://doi.org/10.1109/5254.747902>
- Chou, C. C., Jeng, A. P., Chu, C. P., Chang, C. H., & Wang, R. G. (2018). Generation and visualization of earthquake drill scripts for first responders using ontology and serious game platforms. *Advanced Engineering Informatics*, 38(September), 538–554. <https://doi.org/10.1016/j.aei.2018.09.003>
- Corcho, O., Fernández-López, M., Gómez-Pérez, A., & López-Cima, A. (2005). Construcción de ontologías legales con la metodología METHONTOLOGY y la herramienta WebODE. In *Law and the Semantic Web. Legal Ontologies, Methodologies, Legal Information Retrieval, and Applications* (pp. 142–157). Springer-Verlag. <http://oa.upm.es/5289/>
- de Preneuf, F. (2019). *Agricultura y alimentos*. Entendiendo a La Pobreza. <https://www.bancomundial.org/es/topic/agriculture/overview#1>
- Dentler, K., Cornet, R., Ten Teije, A., & De Keizer, N. (2011). Comparison of reasoners for large ontologies in the OWL 2 EL profile. *Semantic Web*, 2(2), 71–87. <https://doi.org/10.3233/SW-2011-0034>
- Díaz Piraquive, F. N., Joyanes Aguilar, L., & Medina García, V. H. (2009). Taxonomía, ontología y folksonomía, ¿qué son y qué beneficios u oportunidades presentan para los usuarios de la web? *Universidad & Empresa*, 8(16), 242–261. <https://www.redalyc.org/articulo.oa?id=187214803010>
- Divya, P., Varma, M., Ratna Mouli, U., Srinivas, Garima, Nikhil, & Vishistha. (2021). Web based optical character recognition application using flask and tesseract. *Materials Today: Proceedings*, xxxx. <https://doi.org/10.1016/j.matpr.2020.10.850>
- El Ghosh, M., Naja, H., Abdulrab, H., & Khalil, M. (2017). Towards a Legal Rule-Based System Grounded on the Integration of Criminal Domain Ontology and Rules. *Procedia Computer Science*, 112, 632–642. <https://doi.org/10.1016/j.procs.2017.08.109>

- Erasso Rodríguez, M. (2019). *El papel del agro en los planes de aumento de la productividad en Colombia*. En La Jugada. <https://sac.org.co/el-papel-del-agro-en-los-planes-de-aumento-de-la-productividad-en-colombia/>
- FAO, FIDA, & PMA. (2012). La contribución del crecimiento agrícola a la reducción de la pobreza, el hambre y la malnutrición. *El Estado de La Inseguridad Alimentaria En El Mundo 2012*, 30–39. <http://www.fao.org/docrep/017/i3027s/i3027s04.pdf>
- Fernández, M. E. (2013). *Efectos del cambio climático en la producción y rendimiento de cultivos por sectores*.
- Fernández, M., Gómez-Pérez, A., & Juristo, N. (1997). METHONTOLOGY: From Ontological Art Towards Ontological Engineering. *AAAI-97 Spring Symposium Series*, 33–40. <https://doi.org/10.1109/AXMEDIS.2007.19>
- Fox, M. S., Barbuceanu, M., & Gruninger, M. (1996). An organisation ontology for enterprise modeling: Preliminary concepts for linking structure and behaviour. *Computers in Industry*, 29(1-2 SPEC. ISS.), 123–134. [https://doi.org/10.1016/0166-3615\(95\)00079-8](https://doi.org/10.1016/0166-3615(95)00079-8)
- Gerdtham, U. G., & Jönsson, B. (2000). International Comparisons of Health Expenditure: Theory, Data and Econometric Analysis. *Handbook of Health Economics*, 1(PART A), 11–53. [https://doi.org/10.1016/S1574-0064\(00\)80160-2](https://doi.org/10.1016/S1574-0064(00)80160-2)
- Gobernación de Antioquia. (2014). *Manual Técnico del Cultivo de Fresa Bajo Buenas Prácticas Agrícolas*. <https://doi.org/978-958-8711-51-5>
- Gobernación de Antioquia. (2015). *Manual Técnico del Cultivo de Maíz Bajo Buenas Prácticas Agrícolas*.
- González-Sopeña, J. M., Pakrashi, V., & Ghosh, B. (2021). An overview of performance evaluation metrics for short-term statistical wind power forecasting. *Renewable and Sustainable Energy Reviews*, 138, 110515. <https://doi.org/10.1016/J.RSER.2020.110515>
- Gruber, T. R. (1995). *Principles for the design of Ontology*. 43, 907–928.
- Gulyaeva, K. A., & Artemieva, I. L. (2019). Applied Logics to Develop Ontology Model of the Complex-Structured Domains: Organic Chemistry and Biochemistry. *The World Thematic Conference - Biomedical Engineering and Computational Intelligence*, 71–81. https://doi.org/10.1007/978-3-030-21726-6_7
- Hewage, P., Behera, A., Trovati, M., Pereira, E., Ghahremani, M., Palmieri, F., & Liu, Y. (2020). Temporal convolutional neural (TCN) network for an effective weather forecasting using time-series data from the local weather station. *Soft Computing*, 24(21), 16453–16482. <https://doi.org/10.1007/s00500-020-04954-0>
- Ingram, J., & Gaskell, P. (2019). Searching for meaning: Co-constructing ontologies with stakeholders for smarter search engines in agriculture. *NJAS - Wageningen Journal of Life Sciences*, 90–91, 100300. <https://doi.org/10.1016/j.njas.2019.04.006>
- Jankovic, M., Yüksel, M., Babr, M. M., Letizia, F., & Braun, V. (2020). Space debris ontology for ADR capture methods selection. *Acta Astronautica*, 173(February), 56–68. <https://doi.org/10.1016/j.actaastro.2020.03.047>
- Jeong, J. H., Woo, J. H., & Park, J. G. (2020). Machine Learning Methodology for Management of Shipbuilding Master Data. *International Journal of Naval Architecture and Ocean Engineering*, 12, 428–439. <https://doi.org/10.1016/J.IJNAOE.2020.03.005>
- Kang, Y. Bin, Krishnaswamy, S., Sawangphol, W., Gao, L., & Li, Y. F. (2019). Understanding

- and improving ontology reasoning efficiency through learning and ranking. *Information Systems*, 87, 101412. <https://doi.org/10.1016/j.is.2019.07.002>
- Kang, Y.-B., Li, Y.-F., & Krishnaswamy, S. (2012). Predicting Reasoning Performance Using Ontology Metrics. *ISWC 2012*, 198–214. <http://www.seals-project.eu>
- Karevan, Z., & Suykens, J. A. K. (2020). Transductive LSTM for time-series prediction: An application to weather forecasting. *Neural Networks*, 125, 1–9. <https://doi.org/10.1016/j.NEUNET.2019.12.030>
- Kaushik, N., & Chatterjee, N. (2018). Automatic relationship extraction from agricultural text for ontology construction. *Information Processing in Agriculture*, 5(1), 60–73. <https://doi.org/10.1016/j.INPA.2017.11.003>
- Lacasta, J., Lopez-Pellicer, F. J., Espejo-García, B., Nogueras-Iso, J., & Zarazaga-Soria, F. J. (2018). Agricultural recommendation system for crop protection. *Computers and Electronics in Agriculture*, 152(December 2017), 82–89. <https://doi.org/10.1016/j.compag.2018.06.049>
- Lagos-Ortiz, K., del Pilar Salas-Zárate, M., Paredes-Valverde, M. A., García-Díaz, J. A., & Valencia-García, R. (2020). Agrient: A knowledge-based web platform for managing insect pests of field crops. *Applied Sciences (Switzerland)*, 10(3). <https://doi.org/10.3390/app10031040>
- Lamy, J.-B. (2020). Chapter 1. In *Owlready2 Documentation Release 0.23*.
- Liu, L., & Tamer Özsu, M. (2009). *Encyclopedia of Database Systems* (L. LIU & M. TAMER ÖZSU (eds.)). Springer. <https://doi.org/10.1007/978-0-387-39940-9>
- Masmoudi, M., Abdallah Ben Lamine, S. Ben, Zghal, H. B., Karray, M. H., & Archimede, B. (2018). An ontology-based monitoring System for multi-source environmental observations. *Procedia Computer Science*, 126, 1865–1874. <https://doi.org/10.1016/j.procs.2018.08.076>
- Masseroli, M. (2019). Biological and Medical Ontologies: Introduction. *Encyclopedia of Bioinformatics and Computational Biology*, 813–822. <https://doi.org/10.1016/b978-0-12-809633-8.20395-6>
- Maussa, A. (2018, December 5). Colombia pierde cerca del 40 % de los alimentos que produce. *El Espectador*. <https://www.elespectador.com/noticias/medio-ambiente/colombia-pierde-cerca-del-40-de-los-alimentos-que-produce-articulo-827495>
- Ministerio de Agricultura y Desarrollo Rural. (2018). *¿Cuáles cultivos tienen mayor potencial en Colombia?* Agronet. <https://www.agronet.gov.co/Noticias/Paginas/¿Cuáles-cultivos-tienen-mayor-potencial-en-Colombia.aspx>
- Ministerio de Agricultura y Desarrollo Rural. (2022). *Minagricultura*. Minagricultura.Gov.Co. <https://www.minagricultura.gov.co/atentos-clima/Paginas/home.aspx>
- Mun, D., & Ramani, K. (2011). Knowledge-based part similarity measurement utilizing ontology and multi-criteria decision making technique. *Advanced Engineering Informatics*, 25(2), 119–130. <https://doi.org/10.1016/j.aei.2010.07.003>
- Mylopoulos, J., & Levesque, H. (1983). An Overview of Knowledge Representation. In B. Neumann (Ed.), *GWAI-83* (pp. 143–157). Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-642-69391-5_13

- O'Connor, M. (2009). *The Semantic Web Rule Language*. Protégé. <https://protege.stanford.edu/conference/2009/slides/SWRL2009ProtegeConference.pdf>
- Oliva-Felipe, L., Gómez-Sebastià, I., Verdaguer, M., Sánchez-Marrè, M., Poch, M., & Cortés, U. (2017). Reasoning about river basins: WaWO+ revisited. *Environmental Modelling and Software*, 89, 106–119. <https://doi.org/10.1016/j.envsoft.2016.11.009>
- Ono, K., Kawano, S., Fukazawa, Y., & Kadokura, T. (1992). *A resolution method from predicate logic specification into executable code*. <https://doi.org/10.1109/HICSS.1992.183262>
- Oprea, M. (2018). A knowledge modelling framework for intelligent environmental decision support systems and its application to some environmental problems. *Environmental Modelling and Software*, 110(July), 72–94. <https://doi.org/10.1016/j.envsoft.2018.09.001>
- Organización de las Naciones Unidas para la Alimentación y la Agricultura. (2009). Glosario de agricultura orgánica. In *Plataforma de conocimientos sobre agricultura familiar*.
- Organización de las Naciones Unidas para la Alimentación y la Agricultura. (2018). *PORTAL TERMINOLÓGICO DE LA FAO*. <http://www.fao.org/faoterm/es/>
- Pan, J. Z., Staab, S., Aßmann, U., Ebert, J., & Zhao, Y. (2013). *Ontology-Driven Software Development*. Springer.
- Panaggio, M. J., Rainwater-Lovett, K., Nicholas, P. J., Fang, M., Bang, H., Freeman, J., Peterson, E., & Imbriale, S. (2022). Gecko: A time-series model for COVID-19 hospital admission forecasting. *Epidemics*, 39, 100580. <https://doi.org/10.1016/j.EPIDEM.2022.100580>
- Park, J. S., & Kim, S. (2020). Improved interpolation and anomaly detection for personal PM2.5 Measurement. *Applied Sciences (Switzerland)*, 10(2). <https://doi.org/10.3390/app10020543>
- Pelucha, M., Kourilova, J., Kasabov, E., & Feurich, M. (2021). Expanding the ontological horizons of rural resilience in the applied agricultural research policy: The case of the Czech Republic. *Journal of Rural Studies*, 82, 340–350. <https://doi.org/10.1016/j.jrurstud.2021.01.030>
- Pinilla-García, G. A., & Barón-Velandia, J. (2015). Obtención de inferencias en documentos de pasantía descritos a nivel ontológico. *Respuestas*, 20(2), 119. <https://doi.org/10.22463/0122820x.379>
- Poveda-Villalón, M., Fernández-Izquierdo, A., Fernández-López, M., & García-Castro, R. (2022). LOT: An industrial oriented ontology engineering framework. *Engineering Applications of Artificial Intelligence*, 111(January), 104755. <https://doi.org/10.1016/j.engappai.2022.104755>
- Ratna Prakarsha, K., & Sharma, G. (2022). Time series signal forecasting using artificial neural networks: An application on ECG signal. *Biomedical Signal Processing and Control*, 76, 103705. <https://doi.org/10.1016/J.BSPC.2022.103705>
- Real Academia Española. (2018). *Diccionario de la lengua española*. <http://dle.rae.es/>
- Sánchez-Alonso, S., Tello, J., Holm, A., Lieblein, G., Breland, T., Mills, R., & Manouselis, N. (2008). *Engineering an ontology on organic agriculture and agroecology: the case of the Organic.Edunet project*.

- Sanhudo, L., Rodrigues, J., & Filho, Ê. V. (2021). Multivariate time series clustering and forecasting for building energy analysis: Application to weather data quality control. *Journal of Building Engineering*, 35, 101996. <https://doi.org/10.1016/j.jobe.2020.101996>
- Shishehchi, S., & Banihashem, S. Y. (2021). A rule based expert system based on ontology for diagnosis of ITP disease. *Smart Health*, 21(May), 100192. <https://doi.org/10.1016/j.smhl.2021.100192>
- SIAC. (2012). *Sistema de Información Ambiental de Colombia*. Siac.Gov.Co. <http://www.siac.gov.co/sueloscolombia>
- Tang, X., Xiao, M., Hu, B., & Pan, D. (2018). Exchanging knowledge for test-based diagnosis using OWL Ontologies and SWRL Rules. *Procedia Computer Science*, 131, 847–854. <https://doi.org/10.1016/j.procs.2018.04.279>
- Tokovarov, M., & Karczmarek, P. (2022). A probabilistic generalization of isolation forest. *Information Sciences*, 584, 433–449. <https://doi.org/10.1016/j.ins.2021.10.075>
- Uschold, M., Gruninger, M., Uschold, M., & Gruninger, M. (1996). Ontologies : Principles , Methods and Applications. *Knowledge Engineering Review*, 11(2), 1–63.
- Verdonck, M., Gailly, F., Pergl, R., Guizzardi, G., Martins, B., & Pastor, O. (2019). Comparing traditional conceptual modeling with ontology-driven conceptual modeling: An empirical study. *Information Systems*, 81, 92–103. <https://doi.org/https://doi.org/10.1016/j.is.2018.11.009>
- Vilma, R. (2014). Desarrollo de Ontologías para papas mejoradas. *Asociacion Latinoamericana de La Papa*, 1, 187.
- Wache, H., Vögele, T., Visser, U., Stuckenschmidt, H., Schuster, G., Neumann, H., & Ubner, S. (2002). Ontology-Based Integration of Information - A Survey of Existing Approaches. *Proceedings of the IJCAI'01 Workshop on Ontologies and Information Sharing, Seattle, Washington, USA, Aug 4-5*.
- Wang, Y., & Wang, Y. (2018). Citrus ontology development based on the eight-point charter of agriculture. *Computers and Electronics in Agriculture*, 155(September 2017), 359–370. <https://doi.org/10.1016/j.compag.2018.10.034>
- Weik, M. H. (2001). Information management. In M. H. Weik (Ed.), *Computer Science and Communications Dictionary* (p. 775). Springer US. https://doi.org/10.1007/1-4020-0613-6_8938
- Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2017a). *Data Mining Practical Machine Learning Tools and Techniques* (I. H. Witten, E. Frank, M. A. Hall, & C. J. B. T.-D. M. (Fourth E. Pal (eds.); Elsevier I). Morgan Kaufmann. <https://doi.org/https://doi.org/10.1016/B978-0-12-804291-5.00004-0>
- Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2017b). *Data Mining Practical Machine Learning Tools and Techniques* (I. H. Witten, E. Frank, M. A. Hall, & C. J. B. T.-D. M. (Fourth E. Pal (eds.); Elsevier I). Morgan Kaufmann. <https://doi.org/https://doi.org/10.1016/B978-0-12-804291-5.00004-0>
- World Wide Web Consortium. (2004). *OWL Web Ontology Language*. Overview. <https://www.w3.org/TR/owl-features/>
- Yao, J., Wang, P., Wang, G., Shrestha, S., Xue, B., & Sun, W. (2020). Establishing a time series trend structure model to mine potential hydrological information from hydrometeorological time series data. *Science of The Total Environment*, 698,

134227. <https://doi.org/10.1016/J.SCITOTENV.2019.134227>

Yin, J., Rao, W., Zhao, K., Yuan, M., Zeng, J., Zhang, C., Li, J. F., & Zhao, Q. (2019). Experimental study of multivariate time series forecasting models. *International Conference on Information and Knowledge Management, Proceedings*, 2833–2839. <https://doi.org/10.1145/3357384.3357826>

Zhang, H., Li, Y. F., & Tan, H. B. K. (2010). Measuring design complexity of semantic web ontologies. *Journal of Systems and Software*, 83(5), 803–814. <https://doi.org/10.1016/j.jss.2009.11.735>