



PROFUNDIZACIÓN

SELECCIÓN DE PROVEEDORES DE TRANSPORTE INTERNACIONAL CON ORIGEN O DESTINO COLOMBIA MEDIANTE ALGORITMOS DE INTELIGENCIA ARTIFICIAL

Autor

Mayer Santiago Beltrán Romero

Director

Álvaro Enrique Ortiz Dávila

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
Maestría en Ciencias de la Información y las Comunicaciones
Énfasis en Inteligencia artificial
Bogotá, Colombia
Abril del 2024

Contenido

Grupo de Investigación NIDE.....	3
Director Alvaro Ortiz Davila.....	3
Resumen	4
Palabras Clave	5
Introducción	6
1. Marco de referencia.....	7
1.1 Cuerpo de conocimiento (teórico)	7
1.2 Investigaciones previas.....	23
2. Problema de investigación	26
2.1 Planteamiento del problema	26
2.2 Formulación del problema	27
2.3 Sistematización del problema	27
3. Objetivos.....	28
3.1 Objetivo general	28
3.2 Objetivos específicos.....	28
4. JUSTIFICACION.....	29
5. HIPÓTESIS	29
6. METODOLOGÍA.....	30
7. CRONOGRAMA	33
8. Resultados e impacto esperado.....	34
9. Comunicación y divulgación.....	35
10. REFERENCIAS.....	36

GRUPO DE INVESTIGACIÓN NIDE

El grupo de NIDE es uno de los grupos a nivel nacional reconocido por su trabajo y desarrollo investigativo en las ciencia de la información geográfica. Tiene relaciones con otros grupos de investigación a nivel nacional y con Instituciones técnico-científicas cómo la Asociación de Especialistas en Percepción Remota y SIG- SELPER Capítulo Colombia. A nivel internacional ha desarrollado proyectos conjuntamente con Instituciones como Kadaster de Holanda.

El grupo cuenta con profesores de los programas de Ingeniería Catastral y Geodesia y la Maestría en Ciencias de la Información y las comunicaciones conformando así un grupo de investigadores multidisciplinario, especialistas en los temas de las tecnologías Geoespaciales.

Igualmente el grupo NIDE actualmente soporta las actividades investigativas a nivel de pregrado, maestría y doctorado en la Facultad de Ingeniería de la Universidad Distrital Francisco José de Caldas.

Categoría A en Colciencias.

Línea de investigación: Dinámica de la tierra y de los objetos, paisajes y territorios geográficos

DIRECTOR ALVARO ENRIQUE ORTIZ DÁVILA

Doctor en Ingeniería, Universidad Distrital. Magister en Ingeniería de Sistemas (Universidad Nacional de Colombia) e Ingeniero de Sistemas (Universidad Central). Profesor de Fundamentos de Bases de Datos, Bases de Datos Espaciales, Bases de Datos Avanzadas y Fundamentos de Ingeniería de Software en la Maestría de CIC. e Ingeniería Catastral y Geodesia de la Universidad Distrital. Actualmente responsable de la línea investigativa “Dinámica de la tierra y de los objetos, paisajes y territorios geográficos”.

Temas de interés en temas de investigación en otras áreas se centra en: Bases de Datos Espaciales y Espacio-Temporales, Minería de Datos Espacial e Inteligencia Artificial sobre Información Espacial”.

RESUMEN

La selección de un proveedor de transporte internacional adecuado es un proceso crucial para las empresas de comercio exterior, especialmente en un país con una ubicación estratégica como Colombia, que sirve como un hub logístico en América Latina. Este proyecto propone el desarrollo de un algoritmo de IA capaz de analizar grandes volúmenes de datos históricos y actuales relacionados con el desempeño de los proveedores de servicios de transporte, incluyendo tiempos de tránsito y frecuencia de servicios. Utilizando técnicas de aprendizaje automático y análisis de datos, el algoritmo buscará identificar patrones, tendencias y correlaciones que permitan predecir el desempeño futuro de los proveedores y recomendar la mejor opción de acuerdo con los criterios específicos del usuario, como el menor costo, el menor tiempo de tránsito, o la mayor fiabilidad.

El proyecto se dividirá en varias fases, incluyendo la recopilación de datos de diversas fuentes, el preprocesamiento y limpieza de datos, el desarrollo del modelo de IA, y finalmente, la implementación de una herramienta o plataforma que permita a los usuarios acceder a las recomendaciones del algoritmo de manera fácil e intuitiva. También se contemplará la evaluación de la efectividad del sistema mediante pruebas con casos reales y la comparación de los resultados obtenidos con los métodos de selección tradicionales.

Además de facilitar la toma de decisiones en el ámbito del transporte internacional, este proyecto busca contribuir al avance de la logística y la gestión de la cadena de suministro en Colombia, mejorando la competitividad de las empresas locales en el mercado global.

PALABRAS CLAVE

Supply Chain, International Logistics, Artificial Intelligence (AI), Predictive Analytics

INTRODUCCIÓN

La globalización y el auge del comercio internacional han aumentado significativamente la necesidad de soluciones logísticas eficientes y efectivas, siendo el transporte internacional un componente crítico de este entramado, especialmente para países con una posición geográfica estratégica como Colombia. Este país, situado en el cruce de caminos entre América del Norte y del Sur, y con costas en dos océanos, se encuentra en una posición privilegiada para actuar como un eje central en el transporte internacional. Sin embargo, la selección de proveedores de transporte internacional representa un desafío considerable debido a la amplia gama de factores que deben considerarse, incluyendo costos, tiempos de tránsito, fiabilidad y capacidad de los distintos operadores logísticos.

Este proyecto de investigación se centra en la implementación de un algoritmo de inteligencia artificial (IA) destinado a simplificar la selección de proveedores de transporte internacional con origen o destino en Colombia. Mediante la aplicación de técnicas avanzadas de IA, como el aprendizaje automático y el análisis de grandes volúmenes de datos, este proyecto tiene como objetivo desarrollar una herramienta que pueda evaluar eficientemente datos históricos y en tiempo real, proporcionando recomendaciones precisas y adaptadas a las necesidades específicas de las empresas involucradas en el comercio internacional.

El principal objetivo de este proyecto no se limita únicamente a la mejora de la eficiencia operativa y la reducción de costos; también busca proporcionar un valor añadido a través de la mejora de la toma de decisiones en el ámbito del transporte internacional. Este enfoque se alinea con las necesidades actuales del sector logístico, donde la capacidad de adaptación y la respuesta rápida a las condiciones del mercado son fundamentales para mantener la competitividad y asegurar la cadena de suministro.

1. MARCO DE REFERENCIA

1.1 CUERPO DE CONOCIMIENTO (TEÓRICO)

¿Qué es Deep Learning?

El Deep Learning, también conocido como Aprendizaje Profundo, es una rama del Machine Learning que emplea redes neuronales artificiales con una estructura jerárquica. Estas redes se diseñan de manera similar a la estructura neuronal del cerebro humano, con nodos de neuronas interconectadas formando una especie de red. Gracias a esta arquitectura, es posible realizar análisis de datos de manera no lineal. (Centeno, 2019)

En los últimos diez años, se ha observado un significativo incremento en el uso de técnicas de «aprendizaje profundo» (deep learning, DL), que forman parte de la inteligencia artificial (IA) y el aprendizaje automático (machine learning, ML), logrando resultados extraordinarios en campos como la visión por ordenador (Krizhevsky, Sutskever, & Hinton, 2012), el procesamiento del lenguaje natural y los juegos (Young, Hazarika, Poria, & Cambria, 2018). El notable éxito del aprendizaje profundo se atribuye al aumento de la potencia computacional y a la disponibilidad de fuentes de big data, junto con las tecnologías asociadas para el almacenamiento y el intercambio de datos. Las ciencias de la Tierra y del medio ambiente están bien posicionadas para aprovechar el aprendizaje profundo, ya que los avances en las tecnologías de detección están facilitando el acceso a fuentes de macrodatos sobre diversas variables in situ y de teledetección (Reichstein, y otros, 2019). El aprendizaje profundo es una técnica que permite a los ordenadores aprender con ejemplos, similar a cómo los humanos aprenden. Es fundamental para tecnologías como los vehículos autónomos, ya que les permite reconocer señales de tráfico y distinguir entre peatones y objetos inanimados. También es crucial para el control por voz en dispositivos como teléfonos, tabletas y altavoces inteligentes.

Esta técnica ha ganado mucha atención recientemente debido a sus impresionantes resultados, logrando tareas de clasificación a partir de imágenes, texto o sonido con una precisión que a veces supera la del ser humano. Los modelos de aprendizaje profundo se

entrenan con grandes conjuntos de datos etiquetados y utilizan arquitecturas de redes neuronales con múltiples capas.

La precisión lograda por el aprendizaje profundo es clave para cumplir con las expectativas de los usuarios en productos electrónicos y es esencial en aplicaciones de seguridad crítica, como en los automóviles autónomos. Aunque se teorizó en los años 80, su importancia ha crecido recientemente debido a dos factores principales. (Centeno, 2019)

- El aprendizaje profundo requiere grandes cantidades de datos etiquetados. Por ejemplo, el desarrollo de automóviles sin conductor requiere millones de imágenes y miles de horas de vídeo. (Centeno, 2019)
- El aprendizaje profundo requiere una gran potencia de cálculo. Las GPU (Graphics Processing Unit) de alto rendimiento tienen una arquitectura paralela que es eficiente para el aprendizaje profundo. Cuando se combina con clústeres o computación en la nube, esto permite a los equipos de desarrollo reducir el tiempo de entrenamiento para una red de aprendizaje profundo de semanas a horas o menos. (Centeno, 2019)

Redes Neuronales Artificiales

Una Red Neuronal Artificial (RNA) es un modelo matemático que se basa en el comportamiento de las neuronas y la estructura del cerebro, y se utiliza para resolver diversos problemas. (Centeno, 2019)

La capacidad de las redes neuronales para extraer significado de datos imprecisos o complicados con el fin de descubrir patrones y discernir tendencias demasiado complicadas para el cerebro humano u otros métodos informáticos no tiene rival. (Thakur & Konde, 2021)

Las aplicaciones para compartir coche, la clasificación inteligente de Gmail y las recomendaciones de Amazon son sólo algunos ejemplos de cómo las redes neuronales nos han facilitado la vida. (Thakur & Konde, 2021)

Una de las características distintivas de las neuronas biológicas, que les permite procesar y ejecutar tareas muy complejas, es su amplia interconexión con otras neuronas. Reciben

estímulos de eventos a medida que ocurren o cientos de señales eléctricas con la información aprendida. Esta información, al llegar al cuerpo de la neurona, influye en su comportamiento y puede también afectar a neuronas o músculos vecinos. (Caicedo & Lopez, 2009)

(Caicedo & Lopez, 2009) también señalan que la comunicación entre neuronas pasa por las llamadas sinapsis. Una sinapsis es un espacio ocupado por unas sustancias químicas llamadas neurotransmisores. Estos neurotransmisores son los encargados de bloquear o transmitir las señales que provienen de otras neuronas. Las neuronas reciben señales eléctricas de otras neuronas con las que están en contacto. Estas señales se acumulan en el cuerpo de la neurona y determinan qué hacer. Si la señal eléctrica total recibida por la neurona es lo suficientemente grande, el potencial de acción puede superarse, lo que permite que la neurona se active o, por el contrario, se desactive. que permite a la neurona activarse o, por el contrario, permanecer inactiva.

Cuando una neurona se activa, es capaz de transmitir un impulso eléctrico a las neuronas con las que está en contacto (Montesinos, Montesinos, & Crossa, 2022). Gracias a su flexibilidad, una red neuronal puede llevar a cabo múltiples tareas. Al igual que en un sistema neuronal biológico, los elementos esenciales en un sistema neuronal artificial son las neuronas. Una neurona artificial es un sencillo dispositivo de cálculo que produce una única salida o respuesta a partir de un conjunto de datos de entrada. Las neuronas se agrupan dentro de la red formando niveles o capas. Dependiendo de su situación dentro de la red, se distinguen tres tipos de capas:


- La capa de entrada, que recibe directamente la información procedente del exterior, incorporándola a la red.
- Las capas ocultas, internas a la red y encargadas del procesamiento de los datos de entrada.
- La capa de salida, que transfiere información de la red hacia el exterior.

Las Redes Neuronales Artificiales (RNAs) pueden tener múltiples capas ocultas o no tener ninguna, como se muestra en la Figura 1. Los enlaces sinápticos (representados por flechas que entran o salen de una neurona) indican el flujo de señales a través de la red y están

asociados a un peso sináptico específico. Si la salida de una neurona se dirige a dos o más neuronas en la capa siguiente, cada una de estas neuronas recibe la salida neta de la neurona anterior. El número total de capas en una RNA se determina sumando las capas ocultas y la capa de salida (Centeno, 2019)

Figura 1

Red Artificial



Nota. Adaptado de *Deep Learning* (p. 7), por Centeno Franco A, 2019


Los elementos que intervienen en una neurona artificial como se observa en la **Figura 2**, son los siguientes:

- Conjunto de entradas x_i
- Pesos sinápticos w_i , $i = 1, \dots, m$.
- Regla de propagación s que combina las entradas y los pesos sinápticos.
Usualmente: $s(x_1, \dots, x_m, w_1, \dots, w_m) = \sum_{i=1}^m w_i x_i$

- Función de activación g , que es función de s y de una constante u (denominado umbral o sesgo), que proporciona la salida y de la neurona.

Figura 2

Red Neuronal Artificial




$$y = g(s - u) = g\left(\sum_{i=1}^m w_i x_i - u\right) = g\left(\sum_{i=0}^m w_i x_i\right)$$

Nota. Adaptado de *Deep Learning* (p. 7), por Centeno Franco A, 2019

Las funciones de activación más usuales se muestran en la Figura 3:

Figura 3

Funciones de Activación



Nota. Adaptado de *Deep Learning* (p. 8), por Centeno Franco A, 2019

Según el número de capas en las que se organizan las neuronas, las redes neuronales se dividen en dos grandes grupos (Centeno, 2019):

- Redes monocapa, compuestas por un solo nivel de neuronas que se unen mediante conexiones laterales.

- Redes multicapa, donde las neuronas se disponen en dos o más capas. Atendiendo al flujo de datos las redes neuronales se clasifican en dos grandes grupos: Redes unidireccionales (feedforward): sin ciclos.
- Redes recurrentes o realimentadas (feedback): presentan ciclos

En una Red Neuronal Artificial, se denomina algoritmo, método o regla de aprendizaje a cualquier procedimiento que permita asignar valores a los coeficientes sinápticos (pesos sinápticos y umbrales de activación). Existen diferentes tipos de aprendizaje en las Redes Neuronales Artificiales (Centeno, 2019):

- Aprendizaje supervisado: Se dispone de un conjunto de ejemplos que contiene tanto los datos de entrada como la salida correcta.
- Aprendizaje no supervisado: Los ejemplos sólo contienen los datos de entrada, pero no la salida.
- Aprendizaje híbrido: Unas capas tienen aprendizaje supervisado y otras no supervisado.
- Aprendizaje por refuerzo: No se dispone de las salidas correctas, aunque se indica a la red en cada caso si ha acertado o no.

Tipos de redes Deep Learning


Redes Neuronales Recurrentes (RNN)

Las RNN (Redes Neuronales Recurrentes) son una de las arquitecturas básicas sobre las que se construyen otras estructuras de aprendizaje profundo. La principal diferencia entre una red de múltiples capas típica y una red recurrente es que, en lugar de conexiones exclusivamente hacia adelante, una red recurrente puede tener conexiones hacia capas anteriores (o dentro de la misma capa). Esta retroalimentación permite a las RNN mantener la memoria de entradas pasadas y modelar problemas a lo largo del tiempo. Las RNN incluyen una variedad de arquitecturas (como la popular topología LSTM que se discutirá más adelante). El elemento clave distintivo es la retroalimentación dentro de la red, que puede provenir de una capa oculta, la capa de salida, o una combinación de ambas (Figura 4). Las RNN pueden desplegarse a lo largo del tiempo y entrenarse utilizando el algoritmo

de Backpropagation estándar o una variante conocida como propagación en el tiempo (BPTT) (Centeno, 2019).

Figura 4

RNN



Nota. Adaptado de *Deep Learning* (p. 29), por Centeno Franco A, 2019


Long Short-Term Memory (LSTM)

Uno de los avances más importantes en las Redes Neuronales Recurrentes (RNN) ha sido el desarrollo de las Redes de Memoria a Largo Corto Plazo (LSTM). Las LSTM fueron creadas para solucionar el problema del desvanecimiento del gradiente que frecuentemente afecta a las RNN estándar. Estas redes utilizan puertas de olvido, entrada y salida para regular el flujo de información, permitiendo que la red conserve información útil durante períodos prolongados sin perder detalles esenciales (Hochreiter & Schmidhuber, 1997)

Las redes LSTM (Long/Short Term Memory) fueron creadas en 1997 por Hochreiter y Schmidhuber, pero han crecido en popularidad en los últimos años como una arquitectura RNN para varias aplicaciones. Se encuentran en algunos productos que usamos diariamente como los teléfonos inteligentes. Las LSTM se desviaron de las arquitecturas tradicionales de redes neuronales basadas en neuronas y, en su lugar, introdujeron el concepto de una célula de memoria. Esta célula puede mantener su valor durante períodos cortos o largos según sus entradas, lo que le permite recordar información importante y no solo el último valor procesado. La célula de memoria LSTM incluye tres puertas que regulan el flujo de información dentro y fuera de la célula (ver Figura 5). La puerta de entrada controla cuándo puede ingresar nueva información a la memoria. La puerta de olvido determina cuándo se debe olvidar parte de la información existente, permitiendo a la célula recordar datos nuevos. Finalmente, la puerta de salida decide cuándo se utiliza la información contenida en la célula para generar una salida. Además, la célula contiene pesos que controlan cada una de estas puertas. (Centeno, 2019)

Figura 5

LSTM



Nota. Adaptado de *Deep Learning* (p. 29), por Centeno Franco A, 2019

Gated Recurrent Units (GRU)


Además de las LSTM, las Gated Recurrent Units (GRUs) son otra variación popular que simplifica la estructura de las LSTM, manteniendo un rendimiento similar en muchas tareas. Las GRUs combinan las puertas de olvido y entrada en una sola puerta de actualización, lo que las hace menos complejas y más rápidas de entrenar en comparación con las LSTM. Sin embargo, la elección entre LSTM y GRU puede depender del problema específico y del conjunto de datos utilizado (Cho, y otros, 2014)

Este modelo tiene solo dos puertas, eliminando la puerta de salida presente en el modelo LSTM. Para muchas aplicaciones, el GRU tiene un rendimiento similar al LSTM, pero, al ser más simple, involucra menos pesos y permite una ejecución más rápida. Como se observa la GRU en la **Figura 6** incluye dos puertas: una puerta de actualización y una puerta de restablecimiento. La puerta de actualización indica la cantidad de contenido de la celda anterior a mantener. La puerta de reinicio define cómo incorporar la nueva entrada al contenido de la celda anterior. Una GRU puede modelar un RNN estándar simplemente configurando la puerta de restablecimiento en 1 y la puerta de actualización en 0. La GRU es más simple que el LSTM, puede entrenarse más rápidamente y puede ser más eficiente en su ejecución. Sin embargo, el LSTM puede ser más expresivo y, con más datos, puede conducir a mejores resultados (Centeno, 2019).

En resumen, las RNN, especialmente con la incorporación de estructuras como LSTM y GRU, representan una herramienta poderosa para modelar secuencias de datos con dependencias temporales. El entrenamiento de estas redes, aunque computacionalmente intensivo, se beneficia enormemente de los avances en hardware y técnicas de optimización. (Goodfellow, Bengio, & Courville, 2018)

Figura 6

GRU



Nota. Adaptado de *Deep Learning* (p. 30), por Centeno Franco A, 2019

Redes Neuronales Convolucionales (CNN)

Las Redes Neuronales Convolucionales (CNN) revolucionaron el campo del aprendizaje profundo y la visión por computadora al introducir una forma eficiente de procesar imágenes de manera jerárquica. La estructura de las CNN permite la extracción automática y progresiva de características, desde niveles básicos (como bordes y texturas) hasta niveles más avanzados (como patrones complejos y reconocimiento de objetos). Las capas convolucionales aplican filtros que se mueven a lo largo de la imagen, capturando características locales, mientras que las capas de pooling ayudan a hacer la representación más abstracta y menos sensible a las variaciones de posición en las imágenes. Este diseño eficiente hace que las CNN sean especialmente adecuadas para tareas como la


clasificación de imágenes, el reconocimiento facial y el análisis de video (Lecun, Bottou, Bengio, & Haffner, 1998)

Una CNN es una red neuronal multicapa inspirada en la corteza visual de los animales, particularmente útil para el procesamiento de imágenes. Yann LeCun creó la primera CNN, enfocada en el reconocimiento de caracteres manuscritos, como la interpretación de códigos postales. En una red profunda, las primeras capas identifican características básicas (como bordes), mientras que las capas posteriores combinan estas características en atributos de nivel superior. La principal ventaja de estas redes es que cada parte está entrenada para realizar una tarea específica, lo que reduce significativamente el número de capas ocultas y acelera el entrenamiento. Además, son invariantes a la traslación de los patrones. Las CNN son extremadamente potentes para el análisis de imágenes, ya que pueden detectar características simples, como bordes y líneas, y combinarlas en estructuras más complejas para identificar lo que se busca. (Centeno, 2019)

Una red neuronal convolucional es una red multicapa que incluye capas convolucionales y de reducción alternadas, terminando con capas completamente conectadas, similar a una red perceptrón multicapa, como se muestra en la Figura 7 (Centeno, 2019).

Figura 7

CNN




Nota. Adaptado de *Deep Learning* (p. 31), por Centeno Franco A, 2019

En la convolución, se llevan a cabo operaciones de productos y sumas entre la capa de entrada y los n filtros (o núcleos), generando un mapa de características como se muestra en la Figura 8. Las características extraídas corresponden a cada posible ubicación del filtro en la imagen original. La ventaja de este enfoque es que la misma neurona se utiliza para extraer la misma característica en cualquier parte de la entrada, lo que reduce significativamente el número de conexiones y los parámetros a entrenar en comparación con una red multicapa completamente conectada. (Centeno, 2019).

Figura 8

Convolución CNN



Nota. Adaptado de *Deep Learning* (p. 32), por Centeno Franco A, 2019

Después de la convolución, se aplica una función de activación a los mapas de características. La función de activación recomendada es la ReLU (Rectified Linear Unit), ajustando la tasa de aprendizaje al monitorear la fracción de neuronas inactivas.

Alternativamente, se pueden usar Leaky ReLU o Maxout, pero no la función sigmoide logística. En la reducción (pooling), se disminuye la cantidad de parámetros conservando las características más comunes mediante la extracción de medidas estadísticas como el promedio o el máximo de una región fija del mapa de características, lo que reduce la precisión pero mejora la compatibilidad. Al final de las capas de convolución y reducción, se suelen utilizar capas completamente conectadas, donde cada píxel se considera una neurona separada, como en un perceptrón multicapa. La última capa de esta red es una capa clasificadora con tantas neuronas como clases a predecir. Además del procesamiento de imágenes, las CNN se han aplicado con éxito al reconocimiento de video y diversas tareas de procesamiento de lenguaje natural. Las aplicaciones recientes de CNN y LSTM han dado lugar a sistemas de subtítulos para imágenes y videos, donde una CNN procesa la imagen o video y una LSTM convierte la salida de la CNN a lenguaje natural. (Centeno, 2019)

Además de las capas convolucionales y de pooling, las CNN suelen incluir capas de normalización y capas completamente conectadas al final de su arquitectura, que ayudan a clasificar las imágenes en función de las características extraídas. Estas capas completamente conectadas actúan como un clasificador que interpreta los patrones detectados por las capas anteriores. La incorporación de técnicas como el abandono (dropout) y la normalización por lotes (batch normalization) ha mejorado el rendimiento de las CNN, reduciendo el sobreajuste y acelerando la convergencia durante el entrenamiento (Krizhevsky, Sutskever, & Hinton, 2012).

Redes de creencias profundas (DBN):

Las Redes de Creencias Profundas (DBN) han demostrado ser una técnica poderosa en el aprendizaje automático, especialmente en tareas que requieren una extracción profunda y jerárquica de características. Este método de entrenamiento en dos etapas, que comienza con un preentrenamiento no supervisado utilizando Máquinas de Boltzmann Restringidas (RBM) y se ajusta posteriormente con un enfoque supervisado, es fundamental para su éxito. El preentrenamiento ayuda a la red a establecer una buena representación inicial de los datos, lo que es beneficioso para evitar mínimos locales durante el ajuste supervisado. El ajuste fino supervisado refina estas características para tareas específicas como la

clasificación o la regresión. Esta metodología ha permitido que las DBN se apliquen con éxito en el reconocimiento de voz, la clasificación de imágenes y el análisis de datos biomédicos (Hinton, Osindero, & Teh, 2006).

Este método de apilamiento de RBM permite entrenar muchas capas de unidades ocultas de manera eficiente, añadiendo cada nueva capa para mejorar el modelo generativo principal. Así, un DBN se representa como una pila de RBM. Las RBM se asemejan en estructura a las máquinas de Boltzmann (BM), pero debido a su restricción, pueden ser entrenadas utilizando la propagación hacia atrás solo como feedforward. Las máquinas de Boltzmann son muy similares a las redes de Hopfield (HN), donde algunas celdas están marcadas como entradas y permanecen ocultas. Las celdas de entrada se convierten en salidas tan pronto como cada celda oculta actualiza su estado (durante el entrenamiento, las BM/HN actualizan las celdas una por una, y no en paralelo). En las DBN (Figura 9), la capa de entrada representa las entradas sensoriales en bruto, y cada capa oculta aprende representaciones abstractas de esta entrada. La capa de salida, que se maneja de manera algo diferente a las otras capas, implementa la clasificación de la red. El aprendizaje se realiza en dos etapas: un preentrenamiento no supervisado y un ajuste fino supervisado. (Centeno, 2019).


En el entrenamiento previo sin supervisión, cada RBM está entrenada para reconstruir su entrada (por ejemplo, la primera RBM reconstruye la capa de entrada a la primera capa oculta). La siguiente RBM se entrena de manera similar, pero la primera capa oculta se trata como la capa de entrada (o visible), y la RBM se entrena utilizando las salidas de la primera capa oculta como las entradas. Este proceso continúa hasta que cada capa está pre-entrenada. Cuando se completa el entrenamiento previo, comienza el ajuste fino. En esta fase, los nodos de salida son etiquetas aplicadas para darles un significado (lo que representan en el contexto de la red). Luego, se aplica el entrenamiento de la red completa mediante el aprendizaje de descenso de gradiente (SGD) o la propagación hacia atrás para completar el proceso de aprendizaje (Centeno, 2019).

Además, las DBN son notables por su capacidad para aprender distribuciones de probabilidad sobre los conjuntos de datos, una característica heredada de las máquinas de Boltzmann que las componen. Esto las hace adecuadas para tareas generativas como la

modelación de temas y la reducción de dimensionalidad. Por ejemplo, en la modelación de temas, las DBN pueden aprender temas subyacentes en grandes colecciones de documentos de manera eficiente. Este aspecto generativo también facilita la capacidad de las DBN para realizar tareas de imputación de datos faltantes y de predicción de series temporales (Salakhutdinov & Hinton, 2009)

Figura 9

DBN



Nota. Adaptado de *Deep Learning* (p. 33), por Centeno Franco A, 2019

Finalmente, el desempeño de las DBN en tareas específicas ha llevado a investigaciones que exploran su integración con otras arquitecturas neuronales, como las Redes Neuronales Convolucionales (CNN) para tareas de visión por computadora. La combinación de DBN para extracción de características y CNN para clasificación espacial ha mostrado ser una estrategia prometedora, especialmente en el procesamiento y análisis avanzado de imágenes médicas (Lee, Grosse, Ranganath, & Y. Ng, 2009)

Redes de apilamiento profundo (DSN)

La flexibilidad de las DSN para integrar distintos tipos de arquitecturas neuronales en sus módulos permite explorar combinaciones híbridas que pueden ser especialmente potentes para tareas específicas, como el procesamiento de lenguaje natural o la visión por computadora. Al combinar diferentes enfoques en cada módulo, las DSN pueden adaptarse mejor a las particularidades de cada tipo de datos y tarea, lo que resulta en un rendimiento mejorado y en una mayor adaptabilidad frente a nuevas clases de problemas (Ciresan, Meier, Gambardella, & Schmidhuber, 2012)).

Por otro lado, las DSN también facilitan la implementación de técnicas de aprendizaje profundo en hardware con recursos limitados. Al permitir el entrenamiento por módulos, es posible distribuir el proceso de aprendizaje a través de múltiples unidades de procesamiento, como GPUs o incluso diferentes máquinas, lo que es especialmente valioso en entornos de computación en la nube o distribuidos. Este enfoque distribuido no solo acelera el proceso de entrenamiento, sino que también permite escalar el tamaño y la complejidad de las redes de manera más efectiva que las arquitecturas tradicionales de aprendizaje profundo (Wang, Li, & Lazebnik, 2016)

1.2 INVESTIGACIONES PREVIAS

Se analiza el trabajo In Machine Learning To Solve Problems In Logistics, Procedia CIRP, (Singh, Wiktorsson, & Baalsrud, 2021) realizado en campos particulares que usan el aprendizaje automático (ML) y correlaciona las tendencias del aprendizaje supervisado, no supervisado y de refuerzo para resolver problemas logísticos. Esta correlación se desarrolla utilizando una tabla y se discute un diagrama que muestra las técnicas de ML y las tendencias en los campos de los problemas. La COVID-19 ha acelerado enormemente estas tendencias. Este trabajo de Amita Singh, Magnus Wiktorsson, Jannicke Baalsrud Hauge, Trends (2021) sirve como una suave introducción a las técnicas de aprendizaje automático en el campo de la logística para investigadores nuevos en el campo. Las limitantes de esta investigación In Machine Learning To Solve Problems In Logistics es que se aborda la aplicación de inteligencia artificial para la solución de problemas logísticos de una manera general. En el caso de la investigación que estamos desarrollando,

abordaremos como usar la inteligencia artificial específicamente para uno de los eslabones de la cadena de suministro, el transporte internacional con origen o destino Colombia.

Por otra parte, el estudio *The role of artificial intelligence in supply chain management: mapping the territory* (Sharma, Shishodia, Gunasekaran, Min, & Haque, 2022) tiene como objetivo identificar las tendencias, brechas y oportunidades de investigación actuales en la investigación relacionada con el campo disruptivo de las aplicaciones de inteligencia artificial (IA) en la gestión de la cadena de suministro (SCM). Dado que SCM representa innovación gerencial debido a su nueva forma de pensar en sistemas integrados, SCM se ha convertido en una de las disciplinas comerciales más fructíferas para las aplicaciones de IA. El estudio nos permite identificar oportunidades a manera general de la aplicación de la inteligencia artificial en la cadena de suministro, pero no tienen el énfasis requerido en la logística de transporte internacional y el detalle de las variables que pueden estar inmersas en ella. En el caso de la investigación que estamos desarrollando, busca analizar al detalle y encontrar por medio de inteligencia artificial patrones y variables que permitan tomar mejores decisiones en escenarios disruptivos y de incertidumbre.

El análisis presentado por Chávez Bravo, J. C. (2021). *La Inteligencia artificial y su sostenibilidad en las Pymes* (Chávez Bravo, 2021). Se centra en analizar cómo las pequeñas y medianas empresas (PYMES) pueden emplear la inteligencia artificial (IA) para apoyar su desarrollo empresarial hacia la sostenibilidad y viabilidad a largo plazo. Este estudio descriptivo revisa eventos y hechos sin hacer predicciones, basándose en una búsqueda en principales bases de datos relacionadas con el tema. Destaca el papel relevante de la IA en la mejora de la eficiencia, velocidad y reducción de costos para las PYMES, considerando sus posibilidades financieras.

Sin embargo, el artículo presenta limitaciones en cuanto a la implementación específica y detallada de la IA en las PYMES, particularmente en cómo estas empresas pueden superar los obstáculos financieros y de capacitación para adoptar eficazmente la IA. Mientras ofrece una visión general valiosa sobre el papel de la IA en las PYMES, falta una guía concreta o ejemplos específicos de implementación exitosa que puedan servir de modelo a las empresas interesadas en esta transformación tecnológica. En el caso de la investigación

que estamos desarrollando, se busca la aplicación de las diferentes herramientas de IA no solamente para PYMES sino para grandes empresas en Colombia.

El trabajo presentado por Yanqing Duan, John S. Edwards, Yogesh K Dwivedi, Artificial intelligence for decision making in the era of Big Data – evolution, challenges and research agenda (Duan, Edwards, & Dwivedi, 2019). Explora cómo la inteligencia artificial (IA) ha evolucionado y cómo las tecnologías de Big Data han potenciado recientemente a la IA, convirtiéndola nuevamente en un tema atractivo para la investigación. Este documento se enfoca en identificar los desafíos asociados con el uso y el impacto de los sistemas de IA revitalizados para la toma de decisiones y ofrece un conjunto de proposiciones de investigación para investigadores en sistemas de información. Proporciona una visión histórica de la IA a través de trabajos relevantes publicados y discute la IA para la toma de decisiones en general, así como cuestiones específicas sobre la interacción e integración de la IA para apoyar o reemplazar a los tomadores de decisiones humanos. El artículo avanza en la investigación sobre el uso de la IA para la toma de decisiones en la era del Big Data ofreciendo doce proposiciones de investigación en términos de desarrollo conceptual y teórico, interacción tecnología-humano e implementación de la IA.

Aunque proporciona fundamentos valiosos sobre cómo la IA puede influir en la toma de decisiones dentro de las organizaciones, no aborda específicamente la selección de proveedores de transporte internacional, que requiere un enfoque más enfocado en logística, cadenas de suministro y especificidades del sector.

Barua, Zou y Zhou presentan un estado del arte en el desarrollo de modelos de aprendizaje automático. Limon Barua, Bo Zou, Yan Zhou, Machine learning for international freight transportation management: A comprehensive review (Barua, Zou, & Zhou, 2020). Realiza una revisión exhaustiva del estado del arte en el desarrollo de modelos de aprendizaje automático (ML) para su aplicación en distintos aspectos de la gestión del transporte de carga internacional (IFTM). Se brinda una visión general de varios métodos fundamentales de ML y se discute cómo se han empleado, adaptado y aplicado distintos métodos de ML en una multitud de áreas temáticas en IFTM, incluyendo la previsión de la demanda, el mantenimiento de activos y operaciones, y la predicción de trayectorias y rendimiento puntual de vehículos. Además, se examinan las fuentes de datos potenciales que podrían

utilizarse para desarrollar modelos de ML y se realiza una síntesis del trabajo existente para identificar los temas específicos abordados, los métodos de ML utilizados, las tendencias de investigación y las oportunidades para futuras exploraciones. El artículo propone cuatro direcciones para futuras investigaciones en este campo.

Sin embargo, este artículo, aunque proporciona un marco extenso y detallado para entender cómo se puede aplicar el aprendizaje automático en la gestión del transporte de carga internacional, tiene limitaciones en cuanto al alcance de esta investigación sobre la implementación de un algoritmo de IA para facilitar la selección de proveedores de transporte internacional con origen o destino en Colombia. La revisión cubre una amplia gama de aplicaciones y métodos de ML, pero no se enfoca específicamente en la selección de proveedores de transporte, ni se centra en la aplicación particular de estas tecnologías en el contexto colombiano. Además, mientras el artículo sugiere direcciones para futuras investigaciones y aborda la importancia de las fuentes de datos para el desarrollo de modelos de ML, no proporciona una solución concreta ni un modelo específicamente diseñado para mejorar la selección de proveedores basándose en criterios como costos, tiempos de tránsito, y fiabilidad en un entorno específico como Colombia.

2. PROBLEMA DE INVESTIGACIÓN

2.1 PLANTEAMIENTO DEL PROBLEMA

En el ámbito del transporte internacional, incluyendo las operaciones con origen o destino en Colombia, las empresas enfrentan retos significativos al seleccionar proveedores de servicios de flete. Esta selección implica no solo considerar los costos, sino también evaluar la eficiencia, la fiabilidad, y los tiempos de tránsito de los diversos operadores logísticos disponibles. La complejidad de este proceso se ve agravada por la fluctuante dinámica del mercado, los cambios en las regulaciones internacionales, y la diversidad en la capacidad y oferta de los proveedores. Estos factores contribuyen a un entorno de toma de decisiones

altamente incierto y complejo para las empresas que dependen del comercio, impactando directamente la competitividad de las empresas en Colombia.

Actualmente, los procesos de selección de proveedores en su mayoría se llevan a cabo a través de métodos que dependen de la experiencia y el juicio humano, complementados con análisis de datos básicos. Esta aproximación, aunque valiosa, no siempre permite capturar la totalidad de las variables en juego ni procesar eficientemente la vasta cantidad de información disponible. Así, las decisiones tomadas pueden no mejorar los criterios de selección de manera integral, lo que potencialmente resulta en elecciones subóptimas que afectan la rentabilidad, la eficiencia operativa, y la competitividad de las empresas en el mercado global.

Este proyecto propone abordar dicha problemática mediante la implementación de un algoritmo de inteligencia artificial que sistematice y optimice la selección de proveedores de transporte internacional para Colombia.

2.2 FORMULACIÓN DEL PROBLEMA

¿Cómo se puede llevar a cabo la selección de proveedores de transporte internacional con origen o destino en Colombia, mediante algoritmos de inteligencia artificial?

2.3 SISTEMATIZACIÓN DEL PROBLEMA

¿Cuáles son los criterios más relevantes para las empresas al seleccionar proveedores de transporte internacional para operaciones con origen o destino en Colombia, y cómo pueden ser cuantificados y evaluados sistemáticamente por un algoritmo de Deep Learning?

¿Qué tipo de algoritmos de Deep Learning son apropiados para evaluar proveedores de transporte internacional, permitiendo procesar y analizar datos históricos relacionados con los criterios establecidos?

¿Cómo puede implementarse un modelo de algoritmos de Deep Learning para seleccionar proveedores de transporte internacional, mediante un prototipo con interfaz de usuario interactiva?

¿Cuán efectiva es la implementación de un modelo de Deep Learning para la selección de proveedores de transporte internacional en empresas involucradas en comercio con origen o destino en Colombia?

3. OBJETIVOS

3.1 OBJETIVO GENERAL

Definir un modelo de selección de proveedores de transporte internacional con origen o destino en Colombia, mediante algoritmos de Deep Learning.

3.2 OBJETIVOS ESPECÍFICOS

1. Identificar los criterios clave para la selección de proveedores de transporte internacional para empresas con operaciones de importación o exportación en Colombia.
2. Seleccionar algoritmos de Deep Learning apropiados para la evaluación de proveedores de transporte internacional, teniendo en cuenta los criterios clave establecidos.
3. Desarrollar un modelo de aplicación incluyendo los algoritmos seleccionados que recomiende los proveedores más convenientes.
4. Construir un prototipo basado en el modelo desarrollado, que permita validar su funcionamiento mediante casos de estudio con empresas que participan en el comercio internacional en operaciones con origen o destino Colombia.

4. JUSTIFICACION

La selección de proveedores de transporte internacional es fundamental para las operaciones comerciales en Colombia, un país que, por su ubicación geográfica, actúa como un eje central en el transporte en América Latina. Sin embargo, la complejidad de esta selección es alta debido a los múltiples factores que deben considerarse, tales como costos, tiempos de tránsito, fiabilidad, y la capacidad de los operadores logísticos. Actualmente, muchas de estas decisiones se basan en la experiencia y juicio humano complementado con análisis de datos básicos, lo que puede llevar a decisiones subóptimas que no aprovechan plenamente los datos disponibles.

Este proyecto propone utilizar algoritmos de inteligencia artificial para mejorar este proceso. Al implementar técnicas avanzadas de aprendizaje automático y análisis de datos, se espera desarrollar una herramienta que mejore la eficiencia operativa y reducción de costos, proporcionando recomendaciones precisas y adaptadas a las necesidades específicas del comercio internacional. Además, al mejorar la selección de proveedores, las empresas podrán mejorar su competitividad en el mercado global, aprovechando al máximo las oportunidades que su posición geográfica les ofrece.

5. HIPÓTESIS

La implementación de un modelo basado en algoritmos de inteligencia artificial que de acuerdo con ciertos criterios claves y junto al comportamiento, trayectoria del proveedor y probabilidad de cumplimiento en los tiempos establecidos, puede facilitar la toma de decisión respecto a la selección de los proveedores comparado con los métodos tradicionales basados en la experiencia y análisis manual de datos.

6. METODOLOGÍA

La metodología del proyecto se describe en detalle, destacando cómo cada fase del proyecto contribuirá a alcanzar los objetivos planteados y a verificar la hipótesis (Ver diagrama de actividades adjunto), a continuación, se describe cada una de las actividades inmersas en el diagrama de actividades:

Objetivo			1
Identificar los criterios clave para la selección de proveedores de transporte internacional para empresas con operaciones de importación o exportación en Colombia.			
Actividades	Herramientas	Resultados	
Identificar las variables más influyentes en la selección de proveedores de acuerdo con las necesidades particulares de las empresas.	Revisión Documental, estudio de empresas	Documento que describe los atributos y variables seleccionados, así como los datos que se necesitan medir para alcanzar los objetivos del estudio.	
Definir y recoger los datos relevantes necesarios para el análisis y modelado.	Consumos de APIs de las principales navieras, empresas de tracking de transporte internacional y agentes de carga	Conjunto de datos que contiene las variables más relevantes, obtenidos a través de APIs de navieras, empresas de tracking y agentes de carga.	
Implementar sistemas de almacenamiento seguros y eficientes para conservar los datos recopilados.	Sistemas Manejadores de bases de datos	Base de datos estructurada y organizada que almacena los datos recopilados de manera eficiente y segura.	
Realizar un análisis estadístico preliminar de los datos recopilados para entender su	Lenguajes de programación Python y R	Visualizaciones y análisis estadísticos iniciales que proporcionan una comprensión básica de la	

distribución y características básicas.		distribución y características de los datos.
Llevar a cabo la limpieza y transformación de los datos para eliminar inconsistencias y preparar los datos para el análisis avanzado.	Lenguaje de programación Python	Datos limpiados y transformados, corrección de errores, manejo de valores faltantes y la eliminación de datos atípicos o inusuales que podrían sesgar los resultados
Ejecutar un análisis estadístico detallado sobre los datos procesados para extraer insights significativos.	Lenguajes de programación Python y R	Graficas de los datos, estadísticas descriptivas y correlaciones
Objetivo 2 Seleccionar algoritmos de Deep Learning apropiados para la evaluación de proveedores de transporte internacional, teniendo en cuenta los criterios clave establecidos.		
Determinar y seleccionar los algoritmos de deep learning más adecuados para cumplir con los objetivos específicos del estudio.	Revisión documental	Lista de algoritmos de aprendizaje automático seleccionados y justificados, listos para ser implementados y modelados.
Objetivo 3 Desarrollar un modelo de aplicación incluyendo los algoritmos seleccionados que recomiende los proveedores más convenientes.		
Implementar los algoritmos de aprendizaje automático previamente definidos utilizando los datos recopilados y procesados.	Lenguaje de programación Python, TensorFlow, Librerías de Python para modelos de ML	Algoritmos de aprendizaje automático implementados y configurados, preparados para el proceso de entrenamiento.

Entrenar, evaluar y ajustar los algoritmos de aprendizaje automático con los datos recopilados para mejorar su desempeño.	Lenguaje de programación Python, TensorFlow y otras librerías de Python para modelos de ML	Modelo de aprendizaje automático mejorado, seleccionado por su rendimiento superior durante las evaluaciones.
Objetivo 4 Construir un prototipo basado en el modelo desarrollado, que permita validar su funcionamiento mediante casos de estudio con empresas que participan en el comercio internacional en operaciones con origen o destino Colombia.		
Desarrollar una interfaz gráfica de usuario para el prototipo del sistema, facilitando la interacción con los datos y resultados del modelo.	JavaScript, CSS, HTML	Prototipo de una interfaz gráfica de usuario funcional y estética, desarrollado para facilitar la interacción con el sistema.
Integrar la interfaz gráfica con el sistema de datos para asegurar el flujo de información y la funcionalidad del prototipo.	Python, Fast API	Sistema de transferencia de datos eficiente y seguro, que garantiza la comunicación fluida entre la interfaz gráfica y los algoritmos de aprendizaje automático.
Realizar pruebas de usabilidad para evaluar la eficacia y eficiencia de la interfaz gráfica y el sistema en general.	Prototipo desarrollado	Un prototipo funcional del sistema de selección de proveedores y un informe detallado de las pruebas de usabilidad, incluyendo feedback de los usuarios.
Contrastar los resultados obtenidos por los algoritmos con datos reales para validar la precisión y fiabilidad del modelo.	Casos de estudio	Métricas e indicadores que demuestran la efectividad del sistema para apoyar la toma de decisiones basadas en datos.

Analizar los resultados finales del estudio y formular conclusiones basadas en la efectividad de los algoritmos y la relevancia de los hallazgos obtenidos.	Ofimática	Documento que presenta los resultados del proyecto, análisis detallados y conclusiones basadas en los hallazgos obtenidos.
---	-----------	--

7. CRONOGRAMA

El proyecto se desarrollará en varias fases distribuidas durante 14 meses, como se observa a continuación.

CRONOGRAMA															
Objetivo	Actividades	MES 1	MES 2	MES 3	MES 4	MES 5	MES 6	MES 7	MES 8	MES 9	MES 10	MES 11	MES 12	MES 13	MES 14
Seleccionar algoritmos de Deep Learning apropiados para la evaluación de proveedores de transporte internacional, teniendo en cuenta los criterios clave establecidos.	Determinar y seleccionar los algoritmos de deep learning más adecuados para cumplir con los objetivos específicos del estudio.	x	x												
Identificar los criterios clave para la selección de proveedores de transporte internacional para empresas con operaciones de importación o exportación en Colombia.	Identificar las variables más influyentes en la selección de proveedores de acuerdo con las necesidades particulares de las empresas.		x	x											
	Definir y recoger los datos relevantes necesarios para el análisis y modelado.			x	x	x									
	Implementar sistemas de almacenamiento seguros y eficientes para conservar los datos recopilados.					x									
	Realizar un análisis estadístico preliminar de los datos recopilados para entender su distribución y características básicas.						x								
	Llevar a cabo la limpieza y transformación de los datos para eliminar inconsistencias y preparar los datos para el análisis avanzado.							x							
	Ejecutar un análisis estadístico detallado sobre los datos procesados para extraer insights significativos.							x							

Objetivo	Actividades	MES 1	MES 2	MES 3	MES 4	MES 5	MES 6	MES 7	MES 8	MES 9	MES 10	MES 11	MES 12	MES 13	MES 14
Desarrollar un modelo de aplicación incluyendo los algoritmos seleccionados que recomiende los proveedores más convenientes.	Implementar los algoritmos de aprendizaje automático previamente definidos utilizando los datos recopilados y procesados.								X						
	Entrenar, evaluar y ajustar los algoritmos de aprendizaje automático con los datos recopilados para optimizar su desempeño.									X	X				
Construir un prototipo basado en el modelo desarrollado, que permita validar su funcionamiento mediante casos de estudio con empresas que participan en el comercio internacional en operaciones con origen o destino Colombia.	Desarrollar una interfaz gráfica de usuario para el prototipo del sistema, facilitando la interacción con los datos y resultados del modelo.											X			
	Integrar la interfaz gráfica con el sistema de datos para asegurar el flujo de información y la funcionalidad del prototipo.											X			
	Realizar pruebas de usabilidad para evaluar la eficacia y eficiencia de la interfaz gráfica y el sistema en general.												X		
	Contrastar los resultados obtenidos por los algoritmos con datos reales para validar la precisión y fiabilidad del modelo.													X	
	Analizar los resultados finales del estudio y formular conclusiones basadas en la efectividad de los algoritmos y la relevancia de los hallazgos obtenidos.														X

8. RESULTADOS E IMPACTO ESPERADO

8.1 RESULTADOS ESPERADOS:

- Crear un algoritmo capaz de analizar grandes volúmenes de datos históricos y actuales relacionados con el desempeño de los proveedores de servicios de transporte, incluyendo tiempos de tránsito y frecuencia de servicios.
- Identificación de patrones, tendencias y correlaciones que permitan predecir el desempeño futuro de los proveedores y recomendar la mejor opción según los criterios específicos del usuario, como menor costo, menor tiempo de tránsito o mayor fiabilidad .
- Desarrollo de una herramienta o plataforma que permita a los usuarios acceder a las recomendaciones del algoritmo de manera fácil e intuitiva.
- Evaluación de la efectividad del sistema mediante pruebas con casos reales y comparación de los resultados obtenidos con los métodos de selección tradicionales.

8.2 IMPACTO ESPERADO

- Facilitar la toma de decisiones en el ámbito del transporte internacional, proporcionando recomendaciones precisas y adaptadas a las necesidades específicas del comercio internacional.
- Reducción de decisiones subóptimas que no aprovechan plenamente los datos disponibles, lo que puede llevar a una mayor eficiencia operativa y reducción de costos.
- Contribuir al avance de la logística y la gestión de la cadena de suministro en Colombia.
- Mejorar la competitividad de las empresas locales en el mercado global, aprovechando la posición geográfica estratégica de Colombia como un hub logístico en América Latina .
- Mejora en la selección de proveedores basándose en criterios de costos, tiempos de tránsito y fiabilidad de los operadores logísticos.
- Creación de un entorno de toma de decisiones más eficiente y menos incierto, impactando directamente en la competitividad de las empresas en Colombia.

9. COMUNICACIÓN Y DIVULGACIÓN

Se planea transmitir la información, resultados y conclusiones a la comunidad mediante un artículo científico que se publicará en una revista para su divulgación.

El proyecto se expondrá en un espacio dispuesto por la Universidad Distrital Francisco José de Caldas dirigido a la comunidad universitaria perteneciente a la misma.

El proyecto será publicado y almacenado en el repositorio de la Universidad Distrital Francisco José de Caldas para consulta por parte de la comunidad universitaria.

10. REFERENCIAS

- Barua, L., Zou, B., & Zhou, Y. (2020). Machine learning for international freight transportation management: A comprehensive review. *Research in Transportation Business & Management*.
- Caicedo, E., & Lopez, J. (2009). *Una aproximación práctica a las redes neuronales artificiales*. Cali: Programa Editorial Universidad del Valle.
- Centeno, F. (2019). *Deep Learning [Tesis de grado, Universidad de Sevilla]*. Depósito de Investigación Universidad de Sevilla. Obtenido de <https://idus.us.es/handle/11441/90004>
- Chávez Bravo, J. C. (2021). Artificial Intelligence And Sustainability In Small Businesses. *BIG BANG 2021 Vol. 10(2)* , 11-18.
- Cho, K., Merrienboer, B. v., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder–Decoder. *arXiv preprint arXiv*, 1078-1406.
- Ciresan, D. C., Meier, U., Gambardella, L. M., & Schmidhuber, J. (2012). Deep Big Multilayer Perceptrons for Digit. *IEEE Conference on Computer Vision and Pattern Recognition*.
- Duan, Y., Edwards, J. S., & Dwivedi, Y. (2019). Artificial intelligence for decision making in the era of Big Data – evolution, challenges and research agenda. *International Journal of Information Management*, volume 48, 63-71.
- Goodfellow, I., Bengio, Y., & Courville, A. (2018). Deep learning. *Genet Program Evolvable Mach* 19, 305–307.
- Hinton, G., Osindero, S., & Teh, Y.-W. (2006). A Fast Learning Algorithm for Deep Belief Nets. *Neural Comput*, 1527-54.

- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, vol. 9, 1735-1780.
- Infante, C. (2010). *Guía para la presentación de proyectos de investigación*. Bogotá, Colombia: Universidad Nacional de Colombia.
- Krizhevsky, A., Sutskever, I., & Hinton, G. (2012). ImageNet classification with deep convolutional neural networks. *In The Proceedings of the 25th International Conference on Neural Information Processing Systems*, 1097–1105.
- Lecun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, vol. 86, no. 11, 2278-2324.
- Lee, H., Grosse, R., Ranganath, R., & Y. Ng, A. (2009). Convolutional Deep Belief Networks. *Proceedings of the 26th International Conference On Machine Learning*, 77.
- Montesinos, O., Montesinos, A., & Crossa, J. (2022). *Multivariate Statistical Machine Learning Methods for Genomic Prediction [Internet]*. Cham: Springer.
- Reichstein, M., Camps-Valls, G., Stevens, B., Jung, M., Denzler, J., Carvalhais, N., & Prabhat. (2019). Deep learning and process understanding for data-driven Earth system science. *Nature* 566, 195–204.
- Salakhutdinov, R., & Hinton, G. (2009). Deep Boltzmann Machines. *Proceedings of Machine Learning Research*, 448-455.
- Sharma, R., Shishodia, A., Gunasekaran, A., Min, H., & Haque, Z. (2022). The role of artificial intelligence in supply chain management: mapping the territory. *International Journal of Production Research*, 60, 7527-7550.
- Singh, A., Wiktorsson, M., & Baalsrud, J. (2021). Trends In Machine Learning To Solve Problems In Logistics. *Procedia CIRP*, 67-72.
- Thakur, A., & Konde, A. (2021). Fundamentals of Neural Networks. *10.22214/ijraset.2021.37362*, 407-426.

Wang, L., Li, Y., & Lazebnik, S. (2016). Learning Deep Structure-Preserving Image-Text Embeddings.

Young, T., Hazarika, D., Poria, S., & Cambria, E. (2018). Recent Trends in Deep Learning Based. *IEEE Computational Intelligence Magazine*, 13.