

**MODELO DE ANÁLISIS DE DETECCIONES
PARA REGLAS DE MONITOREO DE
ACTIVIDAD SOSPECHOSA EN
TRANSACCIONES BANCARIAS DE GRUPOS
LÓGICOS DE ENTIDADES**

MODELO DE ANÁLISIS DE DETECCIONES PARA REGLAS DE MONITOREO DE ACTIVIDAD SOSPECHOSA EN TRANSACCIONES BANCARIAS DE GRUPOS LÓGICOS DE ENTIDADES



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**

PROPONENTE
Ing. Diego Armando Rey Vanegas

DIRECTOR
Msc. Jorge Enrique Rodríguez

Universidad Distrital Francisco José de Caldas
Maestría en Ciencias de la Información y las Comunicaciones
Énfasis en Ingeniería de Software
Modalidad Profundización
Mayo 2026

ÍNDICE GENERAL

Índice de figuras	III
Índice de cuadros	V
Introducción	1
1 Problema de Investigación	3
1.1 Planteamiento del problema de Investigación	3
1.2 Formulación del Problema	5
1.3 Sistematización del Problema.	5
2 Objetivos	7
2.1 Objetivo General	7
2.2 Objetivos Específicos	7
3 Justificación	9
3.1 Justificación Práctica	9
4 Marco de Referencia	11
4.1 Marco Teórico.	11
4.1.1 <i>Anti-Money Laundering (AML)</i> .	11
4.1.2 Inteligencia Artificial.	14
4.2 Marco Conceptual	16
4.2.1 Grupo Lógico de Entidades	16
4.2.2 Reglas de Monitoreo de Transacciones en AML	16
5 Metodología	19
5.1 Fase 1: Análisis de requerimientos	19
5.2 Fase 2: Diseño del modelo conceptual	19
5.3 Fase 3: Desarrollo del modelo final con la descripción estructural del sistema.	20
5.4 Fase 4: Validar y evaluar el desempeño del modelo propuesto.	20
6 Análisis de Datos	23
6.1 Antecedentes	24
6.2 Tipos de Análisis	24
6.3 Métodos de análisis.	24
6.3.1 Análisis factorial lineal	24
6.3.2 Análisis no lineal de los datos	24

6.4	Datos Sintéticos	25
6.4.1	Utilidad	25
6.4.2	Cálculos	26
6.4.3	Aplicación en Sistemas de detección de fraude y confidencialidad.	26
7	Diseño del Modelo Conceptual	29
7.1	Definición de los objetivos del modelo	29
7.1.1	Objetivos.	30
7.2	Definición de los límites del sistema	30
7.3	Clasificación de los componentes del sistema de interés	30
7.4	Identificación de las relaciones entre los componentes del sistema.	31
7.5	Representación formal del modelo	31
8	Modelo Final de Análisis de Detecciones	33
8.1	Arquitectura de Alto Nivel (Capas)	33
8.2	Componentes Clave del Software	33
8.2.1	Capa de Ingesta y Procesamiento en Tiempo Real	33
8.2.2	Capa de Almacenamiento Híbrido (Polyglot Persistence)	34
8.2.3	Motor de Análisis de Grupos Lógicos (El Cerebro)	34
8.3	Modelo de Datos del Grafo (Esquema Lógico).	34
8.4	Flujo de Trabajo del Sistema (Workflow de Detección)	35
8.4.1	Ingesta y Enriquecimiento	35
8.4.2	Actualización del Grafo	35
8.4.3	Evaluación de Reglas de Grupo	35
8.4.4	Generación de Alertas y Puntuación	35
8.4.5	Persistencia y Consumo	35
9	Validación de Resultados	37
9.1	El Proceso de Validación	37
9.1.1	Pruebas de Integridad y Consistencia del Grafo	37
9.1.2	Backtesting (Simulación Histórica)	37
9.1.3	Tuning de Umbrales y Benchmarking	37
9.1.4	Validación con Expertos (Shadow Testing)	38
9.2	Métricas Clave para la Validación	38
9.3	Toolkit de Herramientas	38
9.3.1	Herramientas de Validación y Perfilado de Datos	38
9.3.2	Herramientas de Machine Learning y Monitoreo de Modelos	38
9.3.3	Herramientas de Validación Visual y Feedback Humano.	39
10	Conclusiones	41
10.1	Conclusiones de Negocio y Mitigación de Riesgo	41
10.2	Conclusiones Operativas y de Eficiencia	41
10.3	Conclusiones Tecnológicas y de Datos	42
	Bibliografía	43

ÍNDICE DE FIGURAS

4.1	Flujo del Dinero en Sistema Bancario. <i>Tomado de Singh and Best (2019)</i> . .	12
4.2	Paradigmas de IA. <i>Tomado de Akshay Kulkarni (2021)</i>	14
4.3	Categorías Aprendizaje Automático. <i>Tomado de Akshay Kulkarni (2021)</i> . .	15

ÍNDICE DE CUADROS

INTRODUCCIÓN

El lavado de dinero consiste en ocultar deliberadamente a las autoridades financieras el origen del dinero obtenido. En general, el lavado de dinero consta de tres etapas: la colocación de dinero obtenido ilegalmente en el sistema financiero, la estratificación del dinero colocado dentro del sistema financiero para ocultar su origen y la integración del dinero limpio en activos financieros aparentemente legítimos.

Impulsadas por los requisitos regulatorios, las instituciones financieras suelen implementar diversos mecanismos de monitoreo para detectar actividades de lavado de dinero en las tres fases mencionadas (colocación, estratificación e integración) y reportarlas a las autoridades financieras pertinentes. Para automatizar la detección de posibles actividades de lavado de dinero, las instituciones financieras utilizan diversas herramientas. [Tertychnyi et al. \(2022\)](#)

Para detectar y prevenir el lavado de dinero, la creación de leyes específicas contra el lavado de dinero, como la Ley de Control del Lavado de Dinero, la Ley de Prevención del Lavado de Dinero y la Ley del Producto del Delito, por nombrar algunas, ha sido un método tradicional para los gobiernos de los últimos siglos. Sin embargo, si bien este método puede dificultar el lavado de dinero y proporcionar cierta prevención anticipada, no puede detectar el acto de lavado de dinero eficazmente. Por lo tanto, la lucha contra el lavado de dinero implica un gran esfuerzo manual por parte de especialistas en la materia, quienes requieren una formación continua. [Tai and Kan \(2019\)](#)

1

PROBLEMA DE INVESTIGACIÓN

1.1. PLANTEAMIENTO DEL PROBLEMA DE INVESTIGACIÓN

El lavado de dinero es un delito que intenta encubrir el origen del dinero e incorporarlo al sistema financiero legal. La rápida expansión de los sistemas y tecnologías financieras globales ha proporcionado una plataforma para actividades delictivas como el lavado de dinero y la financiación del terrorismo. Un componente crucial de las operaciones contra el lavado de dinero (AML) es el monitoreo de transacciones, que implica el análisis continuo de las transacciones financieras para detectar actividades sospechosas y reportarlas a las autoridades superiores.[Alkhalili et al. \(2021\)](#)

Las instituciones financieras enfrentan numerosos desafíos y complejidades en el monitoreo de transacciones, incluyendo altas tasas de falsos positivos, el desarrollo de escenarios de lavado de dinero y un proceso de detección eficaz y eficiente. Se necesita más investigación para desarrollar enfoques mejorados de monitoreo de transacciones que permitan prevenir el delito de manera más eficiente y mitigar los desafíos que enfrentan las instituciones financieras.[Oztas et al. \(2024\)](#)

Actualmente, la industria depende en gran medida de sistemas basados en reglas para detectar el lavado de dinero y la financiación del terrorismo. El enfoque basado en reglas se fundamenta en reglas basadas en escenarios que activan alertas cuando ocurre un evento específico.

Además de los métodos basados en reglas, se realizan numerosos análisis estadísticos para establecer umbrales para los sistemas, lo cual es una tarea muy compleja y que requiere mucho tiempo para las instituciones.[Chau and van Dijck Nemcsik \(2020\)](#)

Si bien algunos bancos agregan herramientas complementarias al método existente, la mayoría de las soluciones todavía dependen únicamente del método basado en reglas. Un problema clave en la monitorización de transacciones, que se encuentra con frecuencia, es la elevada cantidad de falsos positivos que se generan. Es difícil filtrarlos en grandes volúmenes de transacciones, especialmente cuando es necesario detectar

ciertos riesgos. El promedio de la industria para falsos positivos, que ha mejorado en los últimos años, se situó en torno al 90%–95%. [Ketenci et al. \(2021\)](#)

Una alta tasa de falsos positivos genera múltiples problemas en los bancos y es un problema importante que debe abordarse para mejorar la detección. Impacta negativamente en la institución al aumentar los costes operativos y la cantidad de recursos necesarios para investigar las alertas. Dado que las instituciones necesitan investigar cada alerta, un mayor número de falsos positivos implica que más empleados las analicen. Otro desafío que surge debido a la inversión de grandes cantidades de recursos en retrasos y falsos positivos es la falta de capacidad y tiempo para centrarse en los nuevos riesgos emergentes. Esto causará problemas en el futuro, ya que los bancos no podrán adaptarse a las técnicas en evolución de los delincuentes y no podrán detectar las transacciones fraudulentas. El problema de las alertas de falsos positivos también afecta la experiencia del cliente, ya que a menudo requieren información adicional. Esto puede afectar negativamente la satisfacción del cliente, especialmente cuando la alerta es un falso positivo. Otro problema que genera insatisfacción del cliente se produce durante la creación de reglas, eventos y escenarios para los métodos actuales basados en reglas, lo que puede resultar en la pérdida de clientes.

Identificar la efectividad y eficiencia de los métodos actuales de monitoreo de transacciones es otro desafío para las instituciones financieras. Es crucial comprender cómo y qué cubre su modelo de monitoreo de transacciones para desarrollarlo y mejorarlo. La incertidumbre sobre el tipo de riesgos que cubre la institución y la falta de claridad pueden ser muy problemáticas y costosas para las instituciones, considerando los altos estándares establecidos por los reguladores.

La lentitud en el procesamiento de transacciones de los métodos basados en reglas también se identifica como un problema. Este tiempo de procesamiento lento puede afectar la eficiencia y la eficacia en la identificación de riesgos potenciales, lo que puede resultar en un costo regulatorio para los bancos.

Otro problema con los métodos basados en reglas actuales que puede causar dificultades a los reguladores es la capacidad de mantenerse al día con los nuevos y emergentes tipos de lavado de dinero y financiamiento del terrorismo, lo cual también se menciona en la literatura. [Dill \(2021\)](#)

La incapacidad de los modelos basados en reglas para adaptarse a los cambios en el comportamiento de los clientes es una debilidad adicional, ya que se puede generar un mayor número de falsos positivos. Para agravar este problema, mantener las reglas y realizar pruebas efectivas es complejo y costoso para las instituciones. [Oztas et al. \(2024\)](#)

Se busca desarrollar un modelo de análisis de detecciones para reglas de monitoreo de actividad sospechosa en transacciones bancarias de grupos lógicos de entidades, para automatizar parte del proceso de consulta y análisis de resultados en bases de datos basados en la lógica de operación del modelo de detección de cada regla bajo análisis, y reducir el tiempo de solución de los casos de verificación por parte del equipo de especialistas técnicos de producto.

1.2. FORMULACIÓN DEL PROBLEMA

De acuerdo a lo planteado anteriormente nos formulamos la siguiente pregunta de Investigación:

¿Cómo mejorar el tiempo de verificación de detecciones para reglas de monitoreo de actividad sospechosa en transacciones bancarias de grupos lógicos de entidades?

1.3. SISTEMATIZACIÓN DEL PROBLEMA

A partir de la pregunta principal de investigación, desagregamos y subdividimos las siguientes preguntas:

- ¿Cuáles son los requerimientos del equipo técnico de analistas para mejorar el tiempo de solución de casos de investigación de reglas para grupos lógicos de entidades?
- ¿Cómo es el funcionamiento del proceso de verificación de detecciones en reglas de monitoreo de actividad sospechosa de transacciones bancarias?
- ¿Cuáles son los componentes del modelo propuesto?
- ¿Cómo evaluar el funcionamiento del modelo?

2

OBJETIVOS

2.1. OBJETIVO GENERAL

Desarrollar un Modelo de Análisis de Detecciones para Reglas de Monitoreo de Actividad Sospechosa en Transacciones Bancarias de Grupos Lógicos de Entidades, que permita a los analistas reducir el tiempo de solución de casos de verificación.

2.2. OBJETIVOS ESPECÍFICOS

- Realizar el análisis de requerimientos para la operación de un modelo para análisis de resultados de reglas de detección de actividad sospechosa en transacciones bancarias.
- Diseñar e implementar un modelo conceptual con la descripción funcional del sistema.
- Desarrollar la estructura del modelo de análisis de detecciones con el fin de articular los componentes relevantes en la solución del problema de interés.
- Validar el modelo propuesto mediante un prototipo de software.

3

JUSTIFICACIÓN

3.1. JUSTIFICACIÓN PRÁCTICA

El lavado de dinero se ha convertido en un tema controvertido. Coloquialmente, se podría definir como un medio para ocultar el origen de las ganancias obtenidas de actividades delictivas. Un ladrón de bancos, por ejemplo, necesita poder usar el dinero robado sin levantar sospechas. Necesita, de alguna manera, convertir el dinero sucio en dinero limpio. [Butgereit \(2021\)](#)

El lavado de dinero es una amenaza global para la sociedad actual. Los gobiernos y las autoridades gubernamentales lo combaten, en parte, regulando a los bancos y las instituciones financieras. Estas, a su vez, están obligadas a implementar mecanismos para prevenir el lavado de dinero. Por lo general, estos mecanismos de prevención incluyen sistemas de monitoreo automatizados. [Tertychnyi et al. \(2022\)](#)

Anualmente, las actividades de lavado de dinero amenazan la economía global. El producto de estas actividades puede utilizarse para financiar nuevas actividades delictivas y socavar la integridad de los sistemas financieros a nivel mundial. Por estas razones, el lavado de dinero se reconoce como un riesgo crítico en muchos países.

Existe un creciente interés, tanto por parte de investigadores como de profesionales, en el uso de herramientas de software para mejorar la detección de actividades de lavado de dinero.

En el entorno económico actual, los reguladores luchan por anticiparse a las últimas estafas, y las instituciones financieras se enfrentan al reto de identificar y detener las actividades delictivas, a la vez que garantizan un servicio más eficaz y eficiente a los clientes legítimos.

Las soluciones tecnológicas eficaces son un elemento esencial en la lucha contra el lavado de dinero. La mejora de los datos y los análisis es clave para ayudar a los investigadores a centrarse en las actividades sospechosas. La constante evolución de las regulaciones, junto con los recientes casos de infracciones de las normas de lavado de dinero por parte de algunas de las instituciones financieras más grandes, han puesto de relieve

la necesidad de una mejor tecnología para la gestión de las actividades contra el lavado de dinero. [Singh and Best \(2019\)](#)

Las instituciones financieras se enfrentan a importantes desafíos en sus esfuerzos por prevenir el blanqueo de capitales y la financiación del terrorismo debido a la constante evolución de las técnicas de los delincuentes y al gran volumen de transacciones que deben procesarse.

Los métodos tradicionales basados en reglas utilizados generan altas tasas de falsos positivos, lo que genera mayores costes e ineficiencias. [Oztas et al. \(2024\)](#)

En este proyecto se busca desarrollar un modelo de análisis de detecciones para reglas de monitoreo de actividad sospechosa en transacciones bancarias de grupos lógicos de entidades que permitirá a los analistas financieros reducir el tiempo de solución de casos de verificación de detecciones.

En la práctica este modelo propuesto podría ser implementado por la industria bancaria y así buscar reducir los tiempos de resolución de casos de investigación de su equipo de analistas de antilavado de dinero.

4

MARCO DE REFERENCIA

4.1. MARCO TEÓRICO

4.1.1. *Anti-Money Laundering (AML)*

La lucha contra el blanqueo de capitales - *Anti-Money Laundering (AML)* se refiere a una red internacional de leyes, regulaciones y procesos diseñados para prevenir la entrada de fondos ilícitos al sistema financiero. Sin embargo, para comprender completamente cómo funciona la AML, primero debemos tener claro qué significa el blanqueo de capitales.

El blanqueo de capitales consiste en disfrazar como legítimo el "dinero sucio" procedente de fuentes ilegales. Esto permite que dicho dinero se utilice libremente.

Debido a la naturaleza ilícita de los fondos blanqueados, el blanqueo de capitales se asocia con actividades delictivas, así como con la corrupción y el fraude. Por ejemplo, las grandes organizaciones criminales blanquean su dinero para ocultar vínculos con delitos como la trata de personas o el narcotráfico.


El blanqueo de capitales también suele asociarse con la financiación del terrorismo, ya que organizaciones terroristas como ISIS han utilizado estas prácticas para acceder a fondos. Por ello, las políticas AML suelen incluir medidas de lucha contra la financiación del terrorismo (CFT). En definitiva, la AML consiste en dificultar las operaciones de los delincuentes, razón por la cual existen obligaciones legales de cumplir con las leyes AML en jurisdicciones de todo el mundo. [Sumsuber \(2025b\)](#)

El objetivo de la lucha contra el lavado de dinero (AML, por sus siglas en inglés) es combatir el lavado de dinero evitando que fondos ilícitos se disfracen como legítimos. Por lo tanto, las regulaciones AML buscan detectar el lavado de dinero y prevenir que dinero ilícito ingrese al sistema financiero. Esto ayuda a combatir y reducir el crimen, así como la financiación del terrorismo, el incumplimiento de sanciones y la financiación de la proliferación.

El lavado de dinero puede implicar una multitud de transacciones, posiblemente realizadas por personas distintas, en múltiples cuentas con diferentes titulares en dis-

tintos bancos o instituciones financieras. El lavado de dinero consta de tres fases: colocación, estratificación e integración. El dinero puede depositarse en varias cuentas bancarias (colocación). Las transacciones pueden estructurarse para evitar su detección mediante normas de reporte. Se pueden utilizar múltiples etapas de transferencias para ocultar el verdadero origen y el destino final (estratificación). El dinero puede transferirse entre cuentas y dentro y fuera del país (Figura 4.1). En algunos casos, las transferencias se ocultan como pagos de bienes o servicios, dándoles así una apariencia legítima. En la etapa final (integración), el dinero reingresa a la economía legítima. [Singh and Best \(2019\)](#)

Figura 4.1: Flujo del Dinero en Sistema Bancario. Tomado de [Singh and Best \(2019\)](#)



Las leyes aplicables varían en todo el mundo, pero muchas empresas e instituciones financieras que tienen un mayor riesgo de ser utilizadas para el lavado de dinero y otros delitos financieros generalmente están legalmente obligadas a reportar actividades sospechosas y a implementar programas de cumplimiento AML. Estos pueden incluir capacitación, Diligencia Debida del Cliente (CDD), monitoreo y reportes. Las leyes AML son esenciales para combatir los delitos financieros. Más allá de las obligaciones morales, el incumplimiento de las regulaciones AML representa un riesgo importante y puede llevar a multas elevadas y sanciones legales. Por ejemplo, en 2024, TD Bank fue multado con 3 mil millones de dólares por no contar con controles adecuados contra el lavado de dinero relacionado con cárteles de droga y otros criminales. Actualmente, el incumplimiento es aún más riesgoso, ya que los regímenes AML se están endureciendo en todo el mundo mientras aumentan los reportes de lavado de dinero. [Sumsuber \(2025b\)](#)

AML Y APRENDIZAJE AUTOMÁTICO DE MÁQUINA

Impulsadas por los requisitos regulatorios, las instituciones financieras generalmente implementan diversos mecanismos de monitoreo para detectar actividades de lavado de dinero en las tres fases mencionadas (colocación, estratificación e integración) y reportarlas a las autoridades financieras pertinentes. Para automatizar la detección de posibles actividades de lavado de dinero, las instituciones financieras utilizan diversas herramientas, incluyendo sistemas de monitoreo basados en aprendizaje automático (ML). Estos sistemas emiten alertas cuando el comportamiento de un cliente sugiere una posible actividad ilícita. [Tertychnyi et al. \(2022\)](#)

La usabilidad de un sistema de monitoreo basado en aprendizaje automático (ML) para la prevención del lavado de dinero (AML) está definida por los usuarios empresariales y se sustenta en al menos tres requisitos. En primer lugar, el sistema de monitoreo debe generar alertas que probablemente permitan identificar comportamientos ilícitos no detectados previamente. Este requisito conlleva dos subrequisitos. En primer lugar, el sistema de monitoreo debe generar alertas precisas. Un alto número de alertas de falsos positivos supondrá una gran carga de trabajo para los expertos en la materia (es decir, los investigadores), quienes deben verificar manualmente cada alerta. Un alto número de falsos negativos, a su vez, inutiliza el sistema de monitoreo, ya que no detecta la mayor parte de la actividad ilícita. Un segundo subrequisito es que el sistema no debe generar alertas repetidamente para el mismo cliente si la nueva alerta no aporta información adicional a las anteriores. Las alertas redundantes consumen tiempo valioso de los investigadores. [Tertychnyi et al. \(2022\)](#)

En segundo lugar, un sistema de monitoreo debe generar alertas oportunas. De hecho, cuanto antes se detecte la actividad de lavado de dinero, antes podrá una institución financiera tomar las medidas de mitigación correspondientes, como reportar un caso a las autoridades, establecer límites en el uso de productos, etc. Las alertas tardías pueden ocasionar pérdidas monetarias y de reputación para la institución financiera, mientras que las alertas prematuras pueden resultar en evidencia insuficiente de lavado de dinero para proceder con una investigación. El requisito de puntualidad debe considerarse al evaluar la calidad de un sistema de monitoreo de lavado de dinero. Esto requiere ajustar la forma en que se evalúa la calidad del sistema de monitoreo basado en lavado de dinero, ya que los enfoques estándar para evaluar la calidad de los modelos de lavado de dinero no consideran el factor tiempo. [Tertychnyi et al. \(2022\)](#)

En tercer lugar, un sistema de monitoreo basado en aprendizaje automático (ML) debe generar alertas interpretables para que los investigadores puedan determinar qué alertas merecen mayor investigación y en qué dirección debe avanzar dicha investigación. Las alertas bien explicadas acortan el tiempo necesario para investigarlas y, por lo tanto, permiten verificar más alertas. En relación con lo anterior, un sistema de monitoreo basado en aprendizaje automático para la lucha contra el lavado de dinero (AML) debe proporcionar estimaciones precisas (calibradas) de la probabilidad de que un cliente determinado incurra en un comportamiento ilícito, de modo que los investigadores puedan utilizar esta información para evaluar los riesgos relacionados. [Tertychnyi et al. \(2022\)](#)


La IA puede transformar las iniciativas de lucha contra el blanqueo de capitales (AML) y ayudar a las instituciones financieras a detectar y prevenir este tipo de actividades. En la lucha contra el blanqueo de capitales, la IA puede utilizarse para facilitar procesos, examinar datos e identificar patrones que podrían indicar actividades delictivas. La IA puede ayudar a las instituciones financieras a cumplir con los requisitos regulatorios y a proteger sus negocios de daños a la reputación, sanciones legales y financieras, y la pérdida de confianza de los clientes. Sin embargo, es fundamental mencionar que la eficacia de la IA en la lucha contra el blanqueo de capitales depende de la calidad y la cantidad de datos disponibles, así como de los algoritmos utilizados, que deben actualizarse y perfeccionarse constantemente para adaptarse a la evolución de las tácticas de los delitos financieros. [Raj et al. \(2024\)](#)

4.1.2. INTELIGENCIA ARTIFICIAL

La inteligencia artificial se define como la rama de la informática que se ocupa de la automatización del comportamiento inteligente. Esta definición es apropiada, ya que enfatiza que la IA forma parte actualmente del estudio de la informática y, como tal, debe basarse en principios teóricos y aplicados sólidos de dicho campo. Estos principios incluyen las estructuras de datos utilizadas en la representación del conocimiento, los algoritmos necesarios para aplicar dicho conocimiento y los lenguajes y técnicas de programación empleados en su implementación. La inteligencia artificial siempre se ha preocupado más por expandir las capacidades de la informática que por definir sus límites. Para el presente propósito, el problema de la inteligencia artificial se define como lograr que una máquina se comporte de maneras que se considerarían inteligentes si un humano se comportara de esa manera. [Luger \(2024\)](#)

La Figura 4.2 muestra los paradigmas de Inteligencia Artificial.

Figura 4.2: Paradigmas de IA. Tomado de [Akshay Kulkarni \(2021\)](#)



APRENDIZAJE DE MÁQUINA


El aprendizaje automático se puede definir como la capacidad de la máquina para aprender de la experiencia (datos) y hacer predicciones significativas sin ser programada explícitamente. Es un subcampo de la Inteligencia Artificial que se ocupa de la construcción de sistemas que pueden aprender de los datos. El objetivo es hacer que las computadoras aprendan por sí mismas sin la intervención de humanos [Akshay Kulkarni \(2021\)](#).

Hay tres categorías principales en el aprendizaje automático.

- Aprendizaje supervisado
- Aprendizaje no supervisado
- Aprendizaje por refuerzo

La Figura 4.3 muestra las categorías de aprendizaje automático.

Figura 4.3: Categorías Aprendizaje Automático. Tomado de *Akshay Kulkarni (2021)*



APRENDIZAJE SUPERVISADO

El aprendizaje supervisado es una parte del aprendizaje automático en el que se aprovechan los datos de entrenamiento etiquetados para derivar el patrón o la función y crear modelos o aprendizaje automático. Los datos consisten en una variable dependiente (etiqueta objetivo) y las variables independientes o predictores. La máquina intenta aprender la función a partir de los datos etiquetados y predecir la salida a partir de datos no vistos [Akshay Kulkarni \(2021\)](#).

APRENDIZAJE NO SUPERVISADO

Aquí, la máquina aprende el patrón oculto sin aprovechar los datos etiquetados, por lo que no se produce el entrenamiento. En cambio, estos algoritmos aprenden en función de las similitudes o distancias entre las características para capturar los patrones [Akshay Kulkarni \(2021\)](#).

APRENDIZAJE POR REFUERZO

El aprendizaje por refuerzo es un proceso de maximizar la recompensa mediante la adopción de medidas. Estos son algoritmos orientados a objetivos que aprenden cómo alcanzar un objetivo a través de la experiencia. El aprendizaje profundo resuelve problemas de Procesamiento de Lenguaje Natural(NLP) [Akshay Kulkarni \(2021\)](#).

PROCESAMIENTO DE LANGUAGE NATURAL (NLP)

NLP combina la lingüística computacional (modelado basado en reglas del lenguaje humano) con modelos estadísticos, de aprendizaje automático y de aprendizaje profundo. Juntas, estas tecnologías permiten a las computadoras procesar el lenguaje humano

en forma de texto o datos de voz y comprender" su significado completo, con la intención y el sentimiento del hablante o escritor [IBM \(2020\)](#).

El procesamiento del lenguaje natural (o NLP, por sus siglas en inglés) es un campo que aborda varias formas en que las computadoras pueden manejar el lenguaje natural, es decir, el humano. Especialmente en los últimos años, los medios están cubriendo las impresionantes capacidades de las máquinas inteligentes que pueden comprender y producir lenguaje natural [Kochmar \(2022\)](#).

APRENDIZAJE PROFUNDO

El lenguaje es algo natural para los humanos, pero históricamente ha sido difícil de comprender para las computadoras. En la última década, el aprendizaje profundo se ha convertido en el vehículo de la última ola de inteligencia artificial (IA). Los resultados han redefinido consistentemente el estado del arte para una plétora de tareas de análisis de datos en una variedad de dominios. Para un número cada vez mayor de algoritmos de aprendizaje profundo, se ha informado un rendimiento mejor que el humano: por ejemplo, reconocimiento de voz en condiciones ruidosas y diagnóstico médico basado en imágenes [Saxena \(2021\)](#).

El procesamiento del lenguaje natural (NLP) basado en el aprendizaje profundo actual supera a todos los enfoques preexistentes por un amplio margen [Raaijmakers \(2022\)](#).

4.2. MARCO CONCEPTUAL

4.2.1. GRUPO LÓGICO DE ENTIDADES

Un grupo lógico de entidades es un conjunto de clientes, cuentas o relaciones que se agrupan no solo por pertenecer a una misma persona jurídica, sino también porque operan coordinadamente o presentan patrones de transacción que indican asociación económica o de control.

Ejemplos:

- Cuentas de una misma empresa (corporativo).
- Personas relacionadas (mismo beneficiario final).
- Cuentas que interactúan de manera recurrente sin justificación comercial clara.
- Cuentas abiertas por el mismo agente o asesor.

El monitoreo de grupos es importante porque el lavado de dinero suele fragmentar las operaciones en múltiples cuentas para evadir controles, y si se revisan individualmente pueden parecer normales. Por eso, hay reglas de monitoreo específicas que buscan patrones a nivel de grupo. [Visions \(2025\)](#)

4.2.2. REGLAS DE MONITOREO DE TRANSACCIONES EN AML

Las reglas de monitoreo de transacciones contra el lavado de dinero (AML) están diseñadas para ayudar a las instituciones financieras a detectar actividades sospechosas que puedan indicar lavado de dinero o delitos financieros. Estas reglas definen escenarios que activan alertas cuando se detectan ciertos patrones de transacción. Estos sistemas funcionan para identificar anomalías en el comportamiento del cliente y detectar actividades potencialmente ilegales.

La monitorización eficaz de las transacciones de prevención del blanqueo de capitales (AML) se rige por estándares globales clave, como los emitidos por el GAFI y las Directivas AML de la Unión Europea.

Un enfoque basado en el riesgo se considera ampliamente la mejor práctica. Esto implica priorizar a los clientes y transacciones de mayor riesgo para una monitorización más estrecha. Este enfoque garantiza que las instituciones puedan concentrar sus recursos en las áreas que presentan el mayor riesgo.

La integración de los procesos de Debida Diligencia del Cliente (CDD) y Conozca a su Cliente (KYC) también es crucial para sentar una base sólida para la monitorización de las transacciones. Esto incluye la verificación de la identidad de los clientes y la evaluación continua del riesgo. [Sumsuher \(2025a\)](#)

EJEMPLOS DE ESCENARIOS AML

Las empresas sujetas a las reglas AML deben comprender primero qué factores de riesgo específicos deben considerar al realizar un seguimiento continuo de la actividad de sus clientes. Algunos de estos incluyen:

- El comportamiento del cliente, como la negativa a proporcionar la información solicitada, transacciones inusuales o la superación de los umbrales.
- La reputación del cliente.
- El riesgo inherente al activo o servicio adquirido.
- Transacciones inusuales o superación de los umbrales.
- La consistencia de la información del perfil del cliente.
- Si las fuentes de los fondos parecen legítimas.
- Si las transacciones involucran a entidades sancionadas o Personas Expuestas Políticamente (PEP).

Las reglas de monitoreo de transacciones contra el blanqueo de capitales son criterios predefinidos que las instituciones financieras utilizan para detectar transacciones sospechosas y cumplir con las regulaciones contra el blanqueo de capitales. Estas reglas implican la revisión continua de las transacciones de los clientes para detectar patrones inusuales o señales de alerta que puedan indicar actividad ilegal. Incluyen la configuración de indicadores para importes y frecuencias de transacciones específicas, así como el establecimiento de perfiles de referencia de clientes para identificar desviaciones del comportamiento normal. Las normas de monitoreo de transacciones contra el blanqueo de capitales (AML) tienen dos componentes fundamentales [Focal \(2025\)](#):

- *Umbrales y Disparadores*: Implican establecer montos o frecuencias de transacciones específicas que, al superarse, activan alertas. Esto ayuda a identificar patrones inusuales o actividad sospechosa.
- *Perfiles de clientes*: Establecer perfiles de referencia para los clientes según su comportamiento habitual de transacciones, ubicación e industria. Cualquier desviación de estos perfiles puede indicar riesgos potenciales..

5

METODOLOGÍA

El tipo de investigación que se realizará será una investigación de tipo experimental, utilizando el método empírico, de análisis-síntesis y modelación, siendo los más apropiados para lograr los objetivos propuestos. Los cuales se desarrollarán en varias fases.

5.1. FASE 1: ANÁLISIS DE REQUERIMIENTOS

Para esta fase se usará la metodología de método empírico y modelación.

Actividades:

1. Realizar la revisión conceptual de la fundamentación teórica sobre la generación de detecciones en el sistema de monitoreo de actividad sospechosa.
2. Realizar la revisión documental y bibliográfica en el contexto internacional sobre experiencias en el campo de antilavado de dinero, con el fin de analizar los modelos de análisis de resultados en monitoreo de actividad sospechosa que se implementan, para considerar la viabilidad de hacer apropiación tecnológica y proponer un modelo que se ajuste a los requerimientos del proyecto.

Al finalizar esta fase se tendrá el modelo de casos de uso basado en el análisis de requerimientos.

5.2. FASE 2: DISEÑO DEL MODELO CONCEPTUAL

Para esta fase se usará la metodología de método análisis-síntesis y modelación.

Con base en los requerimientos establecidos en la sección anterior se procederá con la elaboración del modelo que se resume en las siguientes actividades [Grant et al. \(2001\)](#):

1. Definir los objetivos del modelo.
2. Definir los límites del sistema de interés.

3. Clasificar los componentes del sistema.
4. Establecer las relaciones entre los componentes del sistema.
5. Representación formal del modelo conceptual.
6. Proponer una arquitectura para la implementación del sistema.
7. Describir los patrones esperados del comportamiento del modelo.

Al finalizar esta fase se debe tener el modelo conceptual establecido del sistema donde se muestre la descripción funcional mediante un lenguaje de modelado.

5.3. FASE 3: DESARROLLO DEL MODELO FINAL CON LA DESCRIPCIÓN ESTRUCTURAL DEL SISTEMA.

5

Para esta fase se usará la metodología de método empírico y modelación.

Actividades:

1. Realizar la descripción estructural del sistema, mediante un lenguaje de modelado.
2. Realizar el proceso de implementación del modelo propuesto utilizando herramientas de procesamiento de datos con el fin de articular los diferentes componentes del sistema. Tal como se mencionó anteriormente el modelo podrá requerir de desarrollos en diferentes tecnologías, para poder construir las interfaces gráficas de usuario, lógica de procesos o aplicación y sistemas de bases de datos.
3. Realizar desarrollos con lenguajes de programación orientados a objetos, y para el caso donde se requiere análisis de datos utilizar herramientas de licencia libre y sistema gestor de base de datos.
4. Seguir lo establecido en metodologías ágiles para la elaboración, construcción, pruebas y evaluación de cada uno de los subsistemas implementados, manejando una arquitectura flexible con módulos especializados.

El resultado de esta fase será un prototipo de software de utilidad para el análisis de detecciones en reglas de monitoreo de actividad sospechosa en transacciones de grupos lógicos de entidades.

5.4. FASE 4: VALIDAR Y EVALUAR EL DESEMPEÑO DEL MODELO PROPUESTO.

Para esta fase se usará la metodología de método empírico y análisis-síntesis.

Actividades:

1. Establecer un protocolo de pruebas, en donde se establezcan los indicadores cualitativos y cuantitativos que permitan evaluar el desempeño del sistema implementado.
2. Realizar las pruebas de cada uno de los subsistemas con el fin de verificar su funcionamiento y que estén en concordancia con los requerimientos que dieron origen. Cumplida la prueba individual de cada uno de los subsistemas se procederá con las pruebas relacionadas con el sistema en conjunto con el fin de verificar el funcionamiento.
3. Realizar la evaluación del modelo con base en los indicadores.

Los anteriores procesos se realizarán mediante análisis y pruebas de los componentes tratando de proponer en lo posible los escenarios más cercanos a la operación del sistema con los datos disponibles en el alcance de este proyecto, con el fin de documentar cada uno de los procesos realizados con los indicadores más relevantes.

Al finalizar esta fase se obtendrán los resultados de validación y evaluación de desempeño del modelo propuesto.

6

ANÁLISIS DE DATOS

El análisis de datos es un proceso que consiste en inspeccionar, limpiar y transformar datos con el objetivo de resaltar información útil, para sugerir conclusiones y apoyo en la toma de decisiones. El análisis de datos tiene múltiples facetas y enfoques, que abarca diversas técnicas en una variedad de nombres, en diferentes negocios, la ciencia, y los dominios de las ciencias sociales. Los datos se coleccionan y analizan para indagar en cuestiones, probar conjeturas o refutar teorías.

Se centra en la inferencia estadística, la cual permite tomar una decisión de forma sencilla con un grado de confianza determinado, identificando, analizando tanto datos como patrones de comportamiento. Las técnicas de este análisis varían según las necesidades de la organización así como también las soluciones tecnológicas, tales como KNIME, R y tableros de visualización (como Power BI o Qlik View, Tableau o Sas Visual Analytics). Estos proyectan en tiempo real los datos en formato visual.

El análisis de datos es un proceso sistemático y metódico que implica la recopilación, organización, interpretación y visualización de conjuntos de datos con el objetivo de extraer información significativa y relevante. Este proceso es fundamental para la toma de decisiones informadas en diversos campos, desde la ciencia y la tecnología hasta la economía y las ciencias sociales.

El análisis de datos se sustenta en una amplia gama de técnicas y metodologías, entre las que se destacan la estadística descriptiva, la inferencia estadística, el aprendizaje automático y la minería de datos. Estas herramientas permiten a los investigadores y analistas identificar patrones, tendencias y relaciones subyacentes en los datos, lo que a su vez facilita la generación de hipótesis y la formulación de conclusiones fundamentadas.

La importancia del análisis de datos radica en su capacidad para transformar grandes volúmenes de información en conocimiento útil y accionable. Al procesar y analizar datos de manera sistemática, los profesionales pueden tomar decisiones más informadas, optimizar procesos, identificar oportunidades y mitigar riesgos. Esto ha llevado a un creciente interés y demanda por habilidades en análisis de datos en una amplia gama de sectores, desde la ciencia de datos hasta la toma de decisiones estratégicas.

6.1. ANTECEDENTES

El análisis de datos, en su estudio de la estructura de grandes conjuntos, es relativamente reciente; sin embargo, muchos de sus métodos tienen una larga trayectoria. El desarrollo inicial del análisis factorial se atribuye a Charles Spearman en 1904 (concepto de factor). La primera definición se remonta al año de 1961, cuando el matemático John Wilder Tukey, predijo el efecto de la computación en el análisis definiéndolo como: "(los) Procedimientos para analizar datos, (las) técnicas para interpretar los resultados de dichos procedimientos, (las) formas de planear la recolección de datos para hacer el análisis más fácil, más preciso o más exacto, y toda la maquinaria y los resultados de las estadísticas (matemáticas) que se aplican al análisis".

6.2. TIPOS DE ANÁLISIS

Puede dividirse, de acuerdo con el tipo de información que estudia, en análisis cuantitativo y cualitativo. El primero examina la relación entre información cuantificable; el segundo analiza información no numérica en contextos situacionales y estructurales.

El análisis de la información en este estudio adopta un enfoque correlacional y de carácter transversal, pues se pretende identificar la relación entre el valor FOB de las exportaciones de cobre y diversos indicadores macroeconómicos del Perú, sin intervenir en dichas variables y considerando un periodo temporal previamente delimitado. También puede dividirse de acuerdo al objetivo en: análisis exploratorio (ADE) y análisis confirmatorio (ADC). El primero, busca vínculos y relaciones entre los datos; El segundo, se enfoca en comprobar las hipótesis formuladas respecto a un conjunto de información.

6.3. MÉTODOS DE ANÁLISIS

Son varios los enfoques presentados, sin pretender ser una metodología estricta sino más bien inicial o para exploración de campo, podemos mencionar las siguientes.

6.3.1. ANÁLISIS FACTORIAL LINEAL

1. Análisis de componentes principales.
2. Análisis de correspondencia binaria.
3. Análisis de correspondencia múltiple.
4. Análisis discriminante.

6.3.2. ANÁLISIS NO LINEAL DE LOS DATOS

1. Basados en núcleos: Análisis de componentes principales del núcleo, Análisis discriminante del núcleo.
2. Basados en redes neuronales.

Se pueden aplicar fórmulas o modelos matemáticos (conocidos como algoritmos) a los datos para identificar relaciones entre las variables; por ejemplo, utilizando correlación o causalidad. En términos generales, se pueden desarrollar modelos para evaluar

una variable específica basada en otras variables contenidas en el conjunto de datos, con algún error residual dependiendo de la precisión del modelo implementado (por ejemplo, Datos = Modelo + Error).

La estadística inferencial incluye la utilización de técnicas que miden las relaciones entre variables particulares.

6.4. DATOS SINTÉTICOS

Los datos sintéticos (en inglés: ‘ ‘Synthetic data’) son datos generados artificialmente en lugar de producidos por eventos del mundo real. Los datos sintéticos, que suelen crearse mediante algoritmos, se pueden utilizar para validar modelos matemáticos y entrenar modelos de aprendizaje automático.

Los datos generados por una simulación por ordenador pueden considerarse datos sintéticos. Esto abarca la mayoría de las aplicaciones de modelado físico, como los sintetizadores musicales o los simuladores de vuelo. El resultado de estos sistemas se aproxima al real, pero se genera completamente mediante algoritmos.

Los datos sintéticos se utilizan en diversos campos como filtro de información que, de otro modo, comprometería la confidencialidad de determinados aspectos de los datos. En muchas aplicaciones sensibles, los conjuntos de datos existen teóricamente, pero no pueden divulgarse al público en general; los datos sintéticos evitan los problemas de privacidad que surgen del uso de información real de los consumidores sin permiso ni compensación.

6.4.1. UTILIDAD

Los datos sintéticos se generan para satisfacer necesidades específicas o ciertas condiciones que pueden no encontrarse en los datos reales originales. Uno de los obstáculos en la aplicación de enfoques de aprendizaje automático actualizados para tareas científicas complejas es la escasez de datos etiquetados, una brecha que se supera de manera eficaz mediante el uso de datos sintéticos, que replican de manera cercana los datos experimentales reales. Esto puede ser útil al diseñar muchos sistemas, desde simulaciones basadas en valores teóricos hasta procesadores de bases de datos, etc. Esto ayuda a detectar y resolver problemas inesperados, como limitaciones en el procesamiento de la información. Los datos sintéticos a menudo se generan para representar los datos auténticos y permiten establecer una línea de base. Otro beneficio de los datos sintéticos es proteger la privacidad y confidencialidad de los datos auténticos, al tiempo que permiten su uso en sistemas de prueba.

El resumen de un artículo científico, citado a continuación, describe un software que genera datos sintéticos para probar sistemas de detección de fraudes. “Esto nos permite crear perfiles de comportamiento realistas para usuarios y atacantes. Los datos se utilizan para entrenar al propio sistema de detección de fraudes, creando así la adaptación necesaria del sistema a un entorno específico”. En contextos militares y de defensa, los datos sintéticos se consideran una herramienta potencialmente valiosa para desarrollar y mejorar sistemas de IA complejos, particularmente en contextos donde los datos del mundo real de alta calidad son escasos. Al mismo tiempo, los datos sintéticos junto con el enfoque de prueba pueden brindar la capacidad de modelar.

6.4.2. CÁLCULOS

Los investigadores prueban el marco en datos sintéticos, que son "la única fuente de verdad fundamental con la que pueden evaluar objetivamente el rendimiento de sus algoritmos".

Los datos sintéticos se pueden generar mediante el uso de líneas aleatorias, con diferentes orientaciones y posiciones iniciales. Los conjuntos de datos pueden volverse bastante complicados. Se puede generar un conjunto de datos más complicado mediante el uso de una construcción de sintetizador. Para crear una construcción de sintetizador, primero use los datos originales para crear un modelo o ecuación que se ajuste mejor a los datos. Este modelo o ecuación se llamará construcción de sintetizador. Esta construcción se puede utilizar para generar más datos.

La construcción de un sintetizador implica la construcción de un modelo estadístico. En un ejemplo de línea de regresión lineal, se pueden representar gráficamente los datos originales y se puede crear una línea lineal de mejor ajuste a partir de los datos. Esta línea es un sintetizador creado a partir de los datos originales. El siguiente paso será generar más datos sintéticos a partir de la construcción del sintetizador o de esta ecuación de línea lineal. De esta manera, los nuevos datos se pueden utilizar para estudios e investigaciones, y se protege la confidencialidad de los datos originales.

David Jensen, del Knowledge Discovery Laboratory, explica cómo generar datos sintéticos: "Los investigadores necesitan con frecuencia explorar los efectos de ciertas características de los datos en su modelo de datos". Para ayudar a construir conjuntos de datos que exhiban propiedades específicas, como autocorrelación o disparidad de grados, la proximidad puede generar datos sintéticos que tengan uno de varios tipos de estructura gráfica: gráficos aleatorios que se generan mediante algún proceso aleatorio; gráficos reticulares que tienen una estructura de anillo; gráficos reticulares que tienen una estructura de cuadrícula, etc.

En todos los casos, el proceso de generación de datos sigue el mismo proceso:

1. Generar la estructura gráfica vacía.
2. Generar valores de atributos basados en probabilidades previas proporcionadas por el usuario.

Dado que los valores de los atributos de un objeto pueden depender de los valores de los atributos de objetos relacionados, el proceso de generación de atributos asigna valores colectivamente.[

6.4.3. APLICACIÓN EN SISTEMAS DE DETECCIÓN DE FRAUDE Y CONFIDENCIALIDAD

Los sistemas de detección de fraudes y de confidencialidad se prueban y entrenan utilizando datos sintéticos. Se diseñan algoritmos y generadores específicos para crear datos realistas, que luego ayudan a enseñarle al sistema cómo reaccionar ante determinadas situaciones o criterios. Por ejemplo, el software de detección de intrusiones se prueba utilizando datos sintéticos. Estos datos son una representación de los datos auténticos y pueden incluir instancias de intrusión que no se encuentran en los datos

auténticos. Los datos sintéticos permiten que el software reconozca estas situaciones y reaccione en consecuencia. Si no se utilizaran datos sintéticos, el software solo se entrenaría para reaccionar ante las situaciones proporcionadas por los datos auténticos y podría no reconocer otro tipo de intrusión.

7

DISEÑO DEL MODELO CONCEPTUAL

Un modelo conceptual es una representación de un sistema, hecho de la composición de conceptos que se utilizan para ayudar a las personas a conocer, comprender o simular un tema que representa el modelo, incluye las entidades importantes y las relaciones entre ellos. También es un conjunto de conceptos. Algunos modelos son objetos físicos; por ejemplo, un modelo de juguete que se puede ensamblar y se puede hacer que funcione como el objeto que representa.

El término modelo conceptual puede usarse para referirse a modelos que se forman después de un proceso de conceptualización o generalización. Los modelos conceptuales son a menudo abstracciones de cosas en el mundo real, ya sean físicas o sociales. Los estudios semánticos son relevantes para varias etapas de la formación de conceptos. La semántica se trata básicamente de conceptos, el significado que los seres pensantes dan a varios elementos de su experiencia.

7.1. DEFINICIÓN DE LOS OBJETIVOS DEL MODELO

En un sistema AML (Anti-Money Laundering), la definición de objetivos consiste en establecer qué comportamientos financieros sospechosos desea identificar y analizar la organización mediante el modelo.

El propósito principal es construir una representación del ecosistema transaccional que permita detectar:

- patrones de lavado de dinero
- financiación del terrorismo
- redes financieras ilícitas
- relaciones ocultas entre clientes
- comportamientos transaccionales anómalos

7.1.1. OBJETIVOS

Los objetivos del modelo pueden incluir:

- identificar transacciones sospechosas
- detectar estructuras de smurfing
- analizar relaciones indirectas entre cuentas
- evaluar riesgos asociados a clientes y jurisdicciones
- generar alertas AML
- descubrir redes financieras complejas mediante Link Analysis

7.2. DEFINICIÓN DE LOS LÍMITES DEL SISTEMA

Consiste en determinar qué elementos financieros y operacionales serán incluidos dentro del análisis AML y cuáles quedarán fuera del alcance del modelo.

Esta etapa permite controlar: el volumen de información, la complejidad analítica, y el dominio específico del monitoreo.

Los límites del sistema pueden definirse según los siguientes criterios.

- Tipo de transacción: transferencias internacionales
- Segmento de clientes: clientes corporativos
- Canal financiero: banca digital
- Periodo temporal: últimos 12 meses
- Región geográfica: Latinoamérica
- Productos financieros: cuentas corrientes

7.3. CLASIFICACIÓN DE LOS COMPONENTES DEL SISTEMA DE INTERÉS

Consiste en identificar y categorizar los elementos que participan en el ecosistema de monitoreo AML. Estos componentes representan: actores financieros, eventos transaccionales, mecanismos de control, y estructuras de análisis.

Componentes principales por categoría:

- Entidades financieras: Cliente, Cuenta
- Eventos: Transacción
- Componentes analíticos: Regla AML, Score de Riesgo
- Componentes de investigación: Alerta, Caso

- Componentes relacionales: Beneficiario, Empresa
- Componentes geográficos: País, Jurisdicción
- Componentes tecnológicos: Dispositivo, IP

7.4. IDENTIFICACIÓN DE LAS RELACIONES ENTRE LOS COMPONENTES DEL SISTEMA

Consiste en establecer cómo interactúan entre sí las entidades financieras y los eventos transaccionales dentro del ecosistema AML.

Las relaciones son especialmente importantes en AML porque el lavado de dinero generalmente se oculta mediante: múltiples intermediarios, conexiones indirectas, estructuras corporativas, y redes financieras distribuidas.

Relaciones típicas:

- Propiedad: Cliente posee Cuenta
- Transferencia: Cuenta envía fondos a otra Cuenta
- Beneficio: Cliente es beneficiario final
- Control: Cliente controla Empresa
- Asociación: Clientes comparten dirección/IP
- Riesgo: Cuenta asociada a país riesgoso

En AML moderno las relaciones son más importantes que las entidades individuales. Porque permiten detectar: redes criminales, estructuras de layering, circularidad financiera, y conexiones ocultas.

7.5. REPRESENTACIÓN FORMAL DEL MODELO

Consiste en representar formalmente el sistema AML mediante estructuras visuales, lógicas o computacionales que permitan: comprender el comportamiento financiero, implementar reglas AML, ejecutar análisis de riesgo, y soportar investigaciones.

La representación formal puede realizarse mediante los siguientes tipos de modelo:

- Modelo Entidad-Relación: almacenamiento transaccional
- UML: arquitectura de software AML
- Grafos: Link Analysis
- Knowledge Graph: relaciones financieras complejas
- Modelo relacional: motores SQL AML
- Modelo streaming: monitoreo en tiempo real

8

MODELO FINAL DE ANÁLISIS DE DETECCIONES

Para lograrlo de forma escalable y en tiempo real (o casi real), la arquitectura ideal se apoya en una Base de Datos de Grafos para las relaciones y un Motor de Reglas/ML para el análisis.

8.1. ARQUITECTURA DE ALTO NIVEL (CAPAS)

El sistema se divide en cuatro capas principales para separar la ingesta de datos, el almacenamiento relacional/grafos, el motor de análisis y la visualización.

1. Capa de Ingesta y Streaming ->(Kafka / Flink)
2. Capa de Almacenamiento ->(DB Relacional + DB de Grafos)
3. Capa de Análisis y Detección ->(Motor de Reglas + ML / Graph Data Science)
4. Capa de Salida y Consumo ->(API Gateway ->Dashboard de Operaciones)

8.2. COMPONENTES CLAVE DEL SOFTWARE

8.2.1. CAPA DE INGESTA Y PROCESAMIENTO EN TIEMPO REAL

- Pipeline de Eventos (Message Broker): Apache Kafka recibe los eventos de transacciones del core bancario en tiempo real.
- Procesamiento de Flujo (Stream Processing): Apache Flink o Spark Streaming. Aquí se realiza la resolución de entidades básica (por ejemplo, emparejar una transacción con un ID de cliente único) antes de guardarla.

8.2.2. CAPA DE ALMACENAMIENTO HÍBRIDO (POLYGLOT PERSISTENCE)

- Base de Datos Transaccional (RDBMS/NoSQL): Guarda el histórico de transacciones clásico para auditoría rápida (ej. PostgreSQL o Cassandra).
- Base de Datos de Grafos (Crucial para este modelo): Neo4j o Amazon Neptune.

Nodos: Entidades (Cliente, Cuenta, Dispositivo/IP, Empresa).

Bordes/Relaciones: Acciones (TRANSFERIDO_A, TITULAR_DE, INICIÓ_SESIÓN_DESDE).

Las transacciones se convierten en bordes con propiedades (monto, fecha).

8.2.3. MOTOR DE ANÁLISIS DE GRUPOS LÓGICOS (EL CEREBRO)

Este componente corre en paralelo en dos modalidades: Tiempo Real (para alertas inmediatas) y Batch (para descubrir redes complejas).

1. Módulo de Agrupamiento (Entity Resolution & Clustering): Algoritmos que identifican que 5 cuentas bancarias distintas pertenecen al mismo “grupo lógico” porque comparten la misma dirección IP de inicio de sesión, el mismo número de teléfono o un patrón de transferencias circulares.
2. Motor de Reglas de Negocio (Drools o similar): Evalúa reglas duras sobre los grupos (ej. “Si el grupo lógico X mueve más de \$50,000 en menos de 2 horas entre cuentas internas, genera alerta”).

3. Algoritmos de Grafos (GDS - Graph Data Science):

Connected Components: Para encontrar comunidades aisladas que transaccionan solo entre sí.

PageRank / Centrality: Para identificar la cuenta “mula” o el nodo central que dispersa el dinero.

8.3. MODELO DE DATOS DEL GRAFO (ESQUEMA LÓGICO)

Para detectar grupos, el diseño de la base de datos de grafos debe verse textualmente así:

- Entidades (Nodos):

Cliente {id, tipo_documento, nivel_riesgo}

Cuenta {numero_cuenta, fecha_apertura, saldo}

Dispositivo {ip_address, device_id}

- Relaciones (Bordes):

(:Cliente)-[:PROPIETARIO_DE]->(:Cuenta)

(:Cuenta)-[:TRANSACCION {monto: Float, fecha: Timestamp}]->(:Cuenta)

(:Cliente)-[:ACCEDIÓ_DESDE]->(:Dispositivo)

Cómo se detecta el grupo lógico: Si tres clientes diferentes (Cliente A, Cliente B, Cliente C) acceden desde el mismo Dispositivo X y envían dinero a la misma Cuenta Y, el sistema los agrupa automáticamente en un Grupo Lógico de Riesgo.

8.4. FLUJO DE TRABAJO DEL SISTEMA (WORKFLOW DE DETECCIÓN)

8.4.1. INGESTA Y ENRIQUECIMIENTO

Milisegundos - La transacción entra al sistema. Se enriquece con datos de contexto (geolocalización de la IP, datos del dispositivo móvil).

8.4.2. ACTUALIZACIÓN DEL GRAFO

Tiempo Real - Se crean o actualizan los nodos y relaciones en la base de datos de grafos. Si la cuenta es nueva, se crea; si ya existía, se dibuja una nueva flecha de transacción.

8.4.3. EVALUACIÓN DE REGLAS DE GRUPO

Micro-batch / Event-driven - El motor de grafos ejecuta consultas rápidas buscando patrones de red conocidos (ej. ciclos cerrados de dinero en menos de 24 horas).

8.4.4. GENERACIÓN DE ALERTAS Y PUNTUACIÓN

Segundos - Si el comportamiento del grupo supera el umbral de riesgo, se calcula un Score de Riesgo Grupal y se envía una alerta al bus de eventos.

8.4.5. PERSISTENCIA Y CONSUMO

Caso de uso final - La alerta se guarda en la base de datos de analítica y se despliega en la interfaz de usuario de los analistas de fraude/cumplimiento (PLD/AML).

9

VALIDACIÓN DE RESULTADOS

La Validación de Resultados en un sistema de análisis de detecciones grupales es el componente crítico que garantiza que el sistema realmente funcione en producción. Su objetivo es doble: asegurar que los algoritmos identifiquen fraudes o lavado de dinero reales (evitando falsos negativos) y que no inunden a los analistas humanos con alertas irrelevantes (minimizando falsos positivos).

En este tipo de sistemas basados en grafos y comportamiento grupal, la validación se divide en tres fases secuenciales: Validación Técnica, Validación Analítica y Validación Operativa (Bucle Cerrado).

9.1. EL PROCESO DE VALIDACIÓN

9.1.1. PRUEBAS DE INTEGRIDAD Y CONSISTENCIA DEL GRAFO

Fase 1: Técnica - Se verifica que la conversión de transacciones lineales a estructuras de grafos sea exacta. Se audita que el 100% de los nodos (clientes/cuentas) y bordes (transacciones) creados en la base de datos de grafos coincidan numéricamente con el Core Bancario.

9.1.2. BACKTESTING (SIMULACIÓN HISTÓRICA)

Fase 2: Analítica - Se corren las reglas y algoritmos de grafos sobre datos históricos (por ejemplo, los últimos 6 meses) que ya contienen casos de fraude confirmados en el pasado. Esto sirve para medir cuántos de esos casos habrían sido detectados por el nuevo modelo.

9.1.3. TUNING DE UMBRALES Y BENCHMARKING

Fase 2: Analítica - Se ajustan las variables del motor de reglas (como los montos mínimos de estructuración o el número de nodos compartidos) y los hiperparámetros de Machine Learning. Se comparan los resultados contra el sistema de monitoreo tradicional del banco para medir el “incremento de valor”.

9.1.4. VALIDACIÓN CON EXPERTOS (SHADOW TESTING)

Fase 3: Operativa - El sistema se despliega en un entorno de “espejo” o Shadowing en producción. Genera alertas reales que son enviadas a un grupo selecto de analistas de cumplimiento para que evalúen la calidad del grupo lógico detectado sin bloquear las transacciones aún.

9.2. MÉTRICAS CLAVE PARA LA VALIDACIÓN

Para determinar si los resultados son válidos, se deben medir rigurosamente estos indicadores:

- Tasa de Falsos Positivos (FPR): El porcentaje de grupos lógicos alertados que resultaron ser clientes legítimos (ej. una familia compartiendo cuentas legítimamente). El objetivo en banca suele ser mantenerlo por debajo del 10% - 15% del total de alertas.
- Precisión (*Precision*): De todas las alertas grupales que generó el sistema, ¿cuántas eran realmente sospechosas o delictivas?
- Exhaustividad o Recuerdo (*Recall*): De todos los fraudes grupales reales que ocurrieron en el banco, ¿cuántos logró capturar el sistema?
- Reducción del Tiempo de Investigación: Cuánto tiempo le toma a un analista entender el caso. Al usar grafos, ver el grupo lógico visualmente debería reducir este tiempo en más de un 40% en comparación con revisar tablas de Excel separadas.

9.3. TOOLKIT DE HERRAMIENTAS

Para llevar a cabo este proceso, el equipo de QA de Datos y los Científicos de Datos necesitan un stack de herramientas específico enfocado en grafos y análisis estadístico.

9.3.1. HERRAMIENTAS DE VALIDACIÓN Y PERFILADO DE DATOS

- Great Expectations: Excelente herramienta de código abierto para automatizar las pruebas de calidad de datos en la capa de ingesta. Permite definir reglas como “el ID del dispositivo nunca debe venir nulo” o “los montos de transacción no pueden ser negativos”.
- Apache Spark DataFrame Validation: Para asegurar que los datos procesados en micro-batches coinciden exactamente en conteos y sumatorias con los registros relacionales.

9.3.2. HERRAMIENTAS DE MACHINE LEARNING Y MONITOREO DE MODELOS

- MLflow / Weights & Biases: Esenciales para el Backtesting. Registran cada versión del algoritmo de grafos, las métricas obtenidas (Precision/Recall) y los umbrales configurados, permitiendo hacer comparaciones científicas entre el “Modelo A” y el “Modelo B”.

- Evidently AI: Herramienta especializada para monitorear el Data Drift (desviación de datos) y el Concept Drift. Te avisa si el comportamiento de los defraudadores cambió drásticamente en producción y los resultados del modelo están perdiendo efectividad.

9.3.3. HERRAMIENTAS DE VALIDACIÓN VISUAL Y FEEDBACK HUMANO

- Neo4j Bloom / Linkurious Enterprise: Herramientas de visualización de grafos para los analistas humanos. Permiten que el experto de Cumplimiento/PLD valide visualmente si el “grupo lógico” tiene sentido criminal (ej. un nodo central conectando 20 cuentas satélite que abrieron el mismo día) antes de aprobar la alerta del sistema.

El enfoque del Bucle Cerrado (Feedback Loop): La herramienta más importante es la base de datos donde se guarda la resolución de la alerta. Cada vez que un analista marca un caso como “Fraude Confirmado” o “Falso Positivo”, ese dato debe reinyectarse automáticamente al sistema de validación para recalcular las métricas y reentrenar los modelos de detección.

10

CONCLUSIONES

Implementar un sistema de análisis de detecciones basado en grupos lógicos y grafos marca un antes y un después en la estrategia de prevención de fraude y lavado de activos de un banco.

Tras la puesta en marcha, estabilización y validación del sistema, se llega a las siguientes conclusiones clave, divididas por impacto estratégico:

10.1. CONCLUSIONES DE NEGOCIO Y MITIGACIÓN DE RIESGO

- Descubrimiento de la “Cara Oculta” del Delito: La conclusión más contundente es que el análisis transaccional tradicional (lineal) era ciego ante estructuras complejas. El sistema demuestra que muchos clientes que operaban individualmente dentro de los límites legales formaban parte de una red coordinada (pitufeo/estructuración) que consolidaba sumas millonarias de origen ilícito.
- Reducción Drástica del Riesgo Reputacional y Regulatorio: Al automatizar la detección de redes complejas, el banco disminuye drásticamente la probabilidad de ser utilizado para el lavado de dinero a gran escala. Esto se traduce en auditorías regulatorias exitosas y en la evitación de multas multimillonarias.
- Blindaje Antifraude más Proactivo: El banco concluye que pasó de una postura reactiva (esperar la denuncia del cliente afectado) a una proactiva, logrando congelar fondos de redes de fraude (como granjas de cuentas mula) antes de que el dinero sea retirado del ecosistema financiero.

10.2. CONCLUSIONES OPERATIVAS Y DE EFICIENCIA

- Menos “Ruido”, Mayor Enfoque (Reducción de Falsos Positivos): Al consolidar transacciones en grupos lógicos, el volumen total de alertas disminuye, pero la calidad y severidad de las alertas restantes aumenta exponencialmente. Los analistas ya

no pierden tiempo revisando 50 alertas aisladas que pertenecían al mismo patrón; ahora revisan un solo caso consolidado.

- **El Poder de la Visualización:** La adopción de interfaces basadas en grafos demuestra que una imagen vale más que mil tablas de Excel. Los analistas concluyen que entender un caso de fraude les toma minutos en lugar de días, ya que la relación entre cuentas, IPs y dispositivos es inmediatamente evidente de forma visual.
- **Colaboración Interdepartamental Mejorada:** El sistema obliga a romper los silos de información. La conclusión operativa es que los datos de ciberseguridad (IPs, huellas digitales de dispositivos) son tan cruciales para prevenir el lavado de dinero como los datos financieros puros.

10.3. CONCLUSIONES TECNOLÓGICAS Y DE DATOS

- **La Flexibilidad del Grafo es Indispensable:** El equipo de arquitectura concluye que modelar estas relaciones en bases de datos relacionales tradicionales (SQL) habría sido inviable debido al costo computacional de hacer múltiples joins. La tecnología de grafos se valida como el estándar nativo para problemas de interconectividad.
- **La Calidad de los Datos es el Verdadero Cuello de Botella:** Al final del proceso, se concluye que el éxito del sistema no depende tanto de la complejidad del algoritmo de Machine Learning, sino de la limpieza y consistencia de los datos de entrada (resolución de entidades, datos de dispositivos no nulos, etc.).
- **Necesidad de un Modelo Evolutivo:** Los defraudadores y lavadores de dinero cambian sus tácticas tan pronto como detectan que el banco bloquea sus patrones actuales. La conclusión tecnológica definitiva es que el sistema no es un proyecto con fecha de fin, sino un producto vivo que requiere monitoreo y ajuste de reglas constante (MLOps).

BIBLIOGRAFÍA

- Akshay Kulkarni, Adarsha Shivananda, A. K. (2021). *Natural Language Processing Projects: Build Next-Generation NLP Applications Using AI Techniques*. Apress, 1 edition.
- Alkhalili, M., Qutqut, M. H., and Almasalha, F. (2021). Investigation of applying machine learning for watch-list filtering in anti-money laundering. *IEEE Access*, 9:18481–18496.
- Butgereit, L. (2021). Anti money laundering: Rule-based methods to identify funnel accounts. In *2021 Conference on Information Communications Technology and Society (ICTAS)*, pages 21–26.
- Chau, D. and van Dijck Nemcsik, M. (2020). *Anti-Money Laundering Transaction Monitoring Systems Implementation: Finding Anomalies*. Wiley and SAS Business Series. Wiley.
- Dill, A. (2021). *Anti-Money Laundering Regulation and Compliance: Key Problems and Practice Areas*. Elgar Compliance Guides. Edward Elgar Publishing Limited.
- Focal (2025). Aml transaction monitoring rules. <https://www.getfocal.ai/blog/aml-transaction-monitoring-rules>.
- Grant, W., Pedersen, E., and Marín, S. (2001). *Ecología y manejo de recursos naturales: análisis de sistemas y simulación*. Libros y materiales educativos. Editorial Agroamérica, Instituto Interamericano de Cooperación para la Agricultura.
- IBM (2020). Natural language processing (nlp). <http://https://www.ibm.com/cloud/learn/natural-language-processing>.
- Ketenci, U. G., Kurt, T., Onal, S., Erbil, C., Akturkoglu, S., and Ilhan, H. S. (2021). A time-frequency based suspicious activity detection for anti-money laundering. *IEEE Access*, 9:59957–59967.
- Kochmar, E. (2022). *Getting Started with Natural Language Processing*. Manning.
- Luger, G. (2024). *Artificial Intelligence: Principles and Practice*. Springer Nature Switzerland.
- Oztas, B., Cetinkaya, D., Adedoyin, F., Budka, M., Aksu, G., and Dogan, H. (2024). Transaction monitoring in anti-money laundering: A qualitative analysis and points of view from industry. *Future Generation Computer Systems*, 159:161–171.
- Raaijmakers, S. (2022). *Deep Learning for Natural Language Processing*. Manning Publications.

- Raj, M., Khan, H., Kathuria, S., Chanti, Y., and Sahu, M. (2024). The use of artificial intelligence in anti-money laundering (aml). In *2024 3rd International Conference on Sentiment Analysis and Deep Learning (ICSADL)*, pages 272–277.
- Saxena, A. (2021). *Deep Natural Language Processing and Ai Applications for Industry 5.0*. Engineering Science Reference.
- Singh, K. and Best, P. (2019). Anti-money laundering: Using data visualization to identify suspicious activity. *International Journal of Accounting Information Systems*, 34:100418.
- Sumsuber, T. (2025a). Aml transaction monitoring rules scenarios. <https://sumsub.com/blog/aml-transaction-monitoring-rules-scenarios/>.
- Sumsuber, T. (2025b). What is anti-money laundering? <https://sumsub.com/blog/what-is-anti-money-laundering>.
- Tai, C.-H. and Kan, T.-J. (2019). Identifying money laundering accounts. In *2019 International Conference on System Science and Engineering (ICSSE)*, pages 379–382.
- Tertychnyi, P., Godgildieva, M., Dumas, M., and Ollikainen, M. (2022). Time-aware and interpretable predictive monitoring system for anti-money laundering. *Machine Learning with Applications*, 8:100306.
- Visions, S. (2025). Entity resolution: How entity resolution changes working with data - from theory to practice. <https://www.semantic-visions.com/insights/entity-resolution>.