



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS

Modelo de estimación cuantitativa de precipitación a partir de datos de diferentes radares banda C para el territorio colombiano

Trabajo de grado para optar el título de
Magister en Ciencias de la Información y las Comunicaciones

Magda Lorena Garzón Correa

Asesor

ERNESTO GOMEZ VARGAS PhD

Codirector

CESAR ANDREY PERDOMO CHARRY PhD

Bogotá D. C. – Colombia

Mayo de 2025

INDICE GENERAL

Contenido

INDICE GENERAL.....	2
INDICE DE FIGURAS.....	5
INDICE DE TABLAS	6
1. INTRODUCCIÓN	7
1.1 PROBLEMA DE INVESTIGACIÓN.....	7
1.1.1 Planteamiento del problema	7
1.1.2 Formulación del problema	10
1.1.3 Sistematización del problema.....	10
1.2 OBJETIVOS.....	11
1.2.1 Objetivo General	11
1.2.2 Objetivos Específicos	11
1.3 JUSTIFICACIÓN.....	11
1.3.1 Justificación Metodológica	11
1.3.2 Justificación Práctica	12
1.4 MARCO DE REFERENCIA	12
1.4.1 Marco Teórico	12
1.4.2. Marco conceptual	16
1.4.3 Marco espacial.....	19
2. FUENTE DE DATOS.....	21
2.1 RADAR METEOROLÓGICO BARRANCABERMEJA (SANTANDER).....	21
2.2 RADAR METEOROLÓGICO SAN JOSÉ DEL GUAVIARE.....	22
2.3 RADAR METEOROLÓGICO CARIMAGUA (META).....	22
2.4 REPOSITORIO DE DATOS DE RADAR DEL IDEAM (AWS)	24

2.4.1 Acceso a los datos	24
2.4.2 Lectura y procesamiento de datos.....	24
2.4.3.3 Nombre de los archivos.....	25
2.4.4 Descarga de los datos.....	26
2.4.5 Fuentes de datos de estaciones meteorológicas.....	26
2.4.6 Emparejamiento espacio-temporal.....	27
3. ANÁLISIS DE DATOS.....	29
3.1 INTRODUCCION	29
3.2. DESCRIPCIÓN DEL CONJUNTO DE DATOS.....	29
3.2.1. Origen y estructura.....	29
3.2.2. Cobertura espacial y temporal.....	34
3.3. RELACIONES DE ESTIMACIÓN DE PRECIPITACIÓN.....	35
3.4. MÉTRICAS DE EVALUACIÓN.....	36
3.5. RESULTADOS DEL ANÁLISIS.....	37
3.5.1. Resultados globales por relación.....	37
3.5.3. Desempeño estratificado por intensidad de lluvia.....	39
3.6. COHERENCIA Y LIMITACIONES DE LOS DATOS	39
3.6.1. Dominancia de lluvia ligera	39
3.6.2. Sobreestimación sistemática en lluvia ligera	40
3.6.3. Falta de simultaneidad temporal	40
3.6.4. Limitaciones de las relaciones $R(KDP)$ y $R(Z,ZDR)$	40
3.6.5. Síntesis para el modelo QPE	40
4. DESCRIPCIÓN DEL MODELO DE ESTIMACIÓN.....	41
4.1. PROPÓSITO Y ALCANCE DEL MODELO.....	41
4.2. DEFINICIÓN DEL PROBLEMA	41

4.3. MODELO CONCEPTUAL	42
4.3.1. Bloque 1 — Entradas	42
4.3.2. Bloque 2 — Procesamiento	43
4.3.3. Bloque 3 — Salida	44
4.4. VARIABLES DEL MODELO.....	44
4.5. SUPUESTOS Y RESTRICCIONES.....	45
5. ESTRUCTURA DEL MODELO.....	46
5.1. JUSTIFICACIÓN DEL ENFOQUE BASADO EN REDES NEURONALES.....	46
5.2. ARQUITECTURA DEL MODELO.....	46
5.3. CONJUNTO DE DATOS Y PREPARACIÓN	48
5.4. ALGORITMO Y PARÁMETROS DE ENTRENAMIENTO	48
5.5. IMPLEMENTACIÓN.....	49
6. PROTOCOLO DE PRUEBAS Y VALIDACIÓN.....	56
6.1. DISEÑO DEL PROTOCOLO DE PRUEBAS	56
6.2. DEFINICIÓN DE LAS MÉTRICAS DE VALIDACIÓN	56
6.3. RESULTADOS DE LA VALIDACIÓN.....	57
6.4. INTERPRETACIÓN DE LA VALIDACIÓN.....	58
6.5. CONCLUSIONES DE LA VALIDACIÓN.....	60
6.6. RECOMENDACIONES.....	61
7. CONCLUSIONES	62
8. BIBLIOGRAFÍA.....	64
ANEXOS.....	69
CODIGO MATLAB.....	69

INDICE DE FIGURAS

<i>Figura 1. Imagen compuesta de radares meteorológicos (IDEAM)</i>	9
<i>Figura 2. Imagen de radar Barrancabermeja (IDEAM)</i>	22
<i>Figura 3. Imagen de radar Guaviare (IDEAM)</i>	23
<i>Figura 4. Radar Carimagua</i>	23
<i>Figura 5. Radares con solapamiento de cobertura</i>	24
<i>Figura 6. Emparejamiento espacio – temporal</i>	29
<i>Figura 7. Estaciones 0 a 5 Radares Carimagua – Guaviare</i>	31
<i>Figura 8. Estaciones 0 a 7 Radares Carimagua – Barrancabermeja</i>	31
<i>Figura 9. Estaciones 7 a 14 Radares Carimagua – Barrancabermeja</i>	32
<i>Figura 10. Estaciones 15 a 21 Radares Carimagua – Barrancabermeja</i>	32
<i>Figura 11. Estaciones 22 a 28 Radares Carimagua – Barrancabermeja</i>	32
<i>Figura 12. Estaciones 29 a 35 Radares Carimagua – Barrancabermeja</i>	33
<i>Figura 13. Estaciones 36 a 44 Radares Carimagua – Barrancabermeja</i>	33
<i>Figura 14. Estaciones metereologicas entre Radares Carimagua – Barrancabermeja</i>	33
<i>Figura 15 Diagrama de bloques</i>	43
<i>Figura 16 Diagrama de la arquitectura del modelo</i>	48
<i>Figura 17 Panel General de Entrenamiento</i>	50
<i>Figura 18 Dispersión observado vs estimado</i>	51
<i>Figura 19 Comparación de Métricas por Modelo</i>	52
<i>Figura 20 Histograma Comparativo de Errores</i>	52
<i>Figura 21 Curva de convergencia</i>	53
<i>Figura 22 Curva de rendimiento</i>	53
<i>Figura 23 Gráficos de Regresión Lineal (a)</i>	54
<i>Figura 24 Gráficos de Regresión Lineal (b)</i>	55
<i>Figura 25 Estado del Entrenamiento</i>	55
<i>Figura 26 Histograma de Error del Entrenamiento</i>	56

INDICE DE TABLAS

<i>Tabla 1. Estaciones meteorológicas zona de cobertura entre radares Carimagua – Guaviare</i>	29
<i>Tabla 2. Estaciones meteorológicas zona de cobertura entre radares Carimagua – Barrancabermeja</i>	29
<i>Tabla 3. Desempeño global de las tres relaciones (radar Carimagua)</i>	37
<i>Tabla 4. Error porcentual por rango de intensidad</i>	39
<i>Tabla 5 Clasificación funcional de las variables del modelo</i>	44
<i>Tabla 6 Configuración de las tres redes neuronales</i>	47
<i>Tabla 7 Métricas de validación del modelo</i>	57
<i>Tabla 8 Resultados de la validación sobre el conjunto de prueba</i>	58
<i>Tabla 9 Datos reflectividad ambos radares</i>	59

1. INTRODUCCIÓN

El presente documento expone la obtención del modelo QPE en su secuencia de partes en términos de descripción funcional, estructuración e implementación, y define los protocolos de prueba, así como las métricas de validación del mismo. Al tratarse de una implementación para radares de banda C en Colombia, se aclara que la aplicación del modelo incluye datos de dos radares de Carimagua y Barrancabermeja.

1.1 PROBLEMA DE INVESTIGACIÓN

1.1.1 Planteamiento del problema

La estimación cuantitativa de la precipitación (QPE) es fundamental para una amplia gama de aplicaciones, como la gestión de recursos hídricos, la predicción de inundaciones, la agricultura entre otros. En forma general representa una entrada esencial para modelos de pronóstico de inundaciones y aplicaciones hidrológicas brindando una cobertura y resolución espacial temporal superior a otras fuentes (ej. pluviómetros) como se menciona en Husnoo et al. (2021).

La Estimación Cuantitativa de la Precipitación presenta varios retos:

- Los pluviómetros tienen una cobertura espacial limitada
- Los radares ofrecen cobertura espacial mucho mayor, proporcionan datos en tiempo real. Pero la estimación de la precipitación a partir de datos de radar está sujeta a varias fuentes de error como reflectividad de objetos que no corresponden a hidrometeoros.
- Se han desarrollado nuevas metodologías y algoritmos para mejorar la Estimación Cuantitativa de la Precipitación (QPE), como técnicas de aprendizaje automático aplicadas a los datos de radar polarimétrico (Huangfu et al., 2024). Sin embargo, la implementación de estos métodos enfrenta obstáculos, destacados por los mismos autores, relacionados con la necesidad de grandes volúmenes de datos para el entrenamiento de modelos y su interpretación -especialmente para eventos meteorológicos extremos- lo cual reduce la generalización de estos en otros escenarios geográficos (Huangfu et al., 2024).
- En el territorio nacional se han usado los radares polarimétricos desde finales de 2011, siendo el primero el ubicado en el corregimiento de Santa Elena en Medellín para

la gestión del riesgo de desastres por medio de la determinación de intensidad de los sistemas de nubes que generan precipitaciones. Posteriormente en 2014 comenzó a operar el sistema de radares que cubre la mayor parte de la región Caribe y Andina, en consideración a las regiones más afectadas por fenómenos climatológicos.

- Actualmente hay zonas de cobertura que se traslapan por el alcance de un par de radares, una muestra de ello se observa en la figura 1. Imagen compuesta de radares meteorológicos (IDEAM).
- Esta situación puede ser útil en la Estimación Cuantitativa de la Precipitación (QPE), pero actualmente no se tiene un comparativo entre datos de diferentes radares que presenten traslape de cobertura para una misma región; por lo cual se están subutilizando los datos de radar.




Figura 1. Imagen compuesta de radares meteorológicos (IDEAM)

A partir de la Figura 1 y observando la imagen de cobertura de cada uno de los Radares que la conforman, se encuentra inicialmente que se tienen las siguientes zonas con traslape de cobertura:

- Bogota Idiger – Tablazo (Bogota)
- Guaviare – Tablazo - [Aerocivil 2](#) (Bogota)

- Barrancabermeja – Santa Helena (Antioquia)
- Tablazo - Santa Helena (Antioquia, Caldas y Risaralda)
- Barrancabermeja – Carimagua (Boyaca)
- Barrancabermeja – Tablazo (Bogota, municipios de Cundinamarca y Boyaca)

Los impactos concretos que tendría no mejorar la estimación de precipitación usando datos de radar incluyen las siguientes consideraciones: siendo Colombia un país caracterizado por presentar patrones climáticos extremos relacionados con la influencia de Fenómeno de La Niña, seguirá vulnerable al efecto de inundaciones y deslizamientos con los costos humanos y económicos asociados. La falta de precisión en la estimación cuantitativa de la precipitación (QPE) retardará las alertas tempranas, aumentando el riesgo para las comunidades y generando gastos públicos evitables.

Por otro lado teniendo en cuenta la infraestructura de radares existente, Colombia cuenta con una red de radares meteorológicos que requiere integración para el procesamiento de los datos que estos generan, la ausencia de esta integración conlleva la subsecuente subutilización de la misma limitando su potencial para la investigación climática y la gestión de riesgos.

Para mitigar los escenarios negativos derivados de una estimación imprecisa de la precipitación se propone con el presente proyecto desarrollar un modelo de Estimación Cuantitativa de Precipitación (QEP) que integre datos de dos radares banda C con cobertura traslapada en Colombia. Con los resultados al aplicar el método se espera contribuir a:

- Aumentar la precisión de las estimaciones (QPE) al corregir posibles sesgos en los datos obtenidos por un solo radar.
- Mejorar el uso de la infraestructura de radares ya existente.
- Mejorar la capacidad de respuesta ante eventos climáticos extremos
- Avanzar en el uso de metodologías adaptadas a las condiciones locales, que adicionalmente sean posiblemente aplicables a otros pares de radares en Colombia.

- Reducir el error de estimación al validar con métricas por definir (ejemplo: RMSE Root Mean Square Error o Raíz del Error Cuadrático Medio y MAE (Mean Absolute Error o Error absoluto promedio).

1.1.2 Formulación del problema

La Estimación Cuatitativa de la Precipitacion (QPE) es un componente importante dentro de la gestión de riesgos hidrometeorologicos. A pesar de que los radares metereologicos superan la limitación de cobertura espacial que presentan los pluviómetros, el uso de los mismos presenta desafíos propios asociados al mejor aprovechamiento de los datos que estos generar para mejorar la precisión mediante el uso de técnicas avanzadas. En Colombia, donde se presentan fenómenos climáticos extremos que tienen como consecuencia inundaciones y deslizamientos con el consecuente impacto socioeconómico, se convierte en una prioridad mejorar la QPE, ya que a pesar de la contar con una red de radares polarimetricos no se ha explorado el potencial de mejora que se podría obtener al integrar datos de diferentes radares con traslape de cobertura. Mediante el desarrollo el presente proyecto, se busca aprovechar dicha infraestructura por medio del desarrollo de un modelo que combine mediciones de dos radares banda C, con el fin de aumentar la precisión de las estimaciones mediante el uso de recursos ya disponibles. De acuerdo con ello la pregunta central que propone desarrollar este proyecto es:

¿Cómo se puede mejorar la precisión de la Estimación Cuantitativa de la Precipitación (QPE) utilizando datos de diferentes radares banda C?

1.1.3 Sistematización del problema

Con el fin de abordar el desafío de mejorar la Estimación Cuantitativa de la Precipitación (QPE) mediante la integración de datos de diferentes radares banda C, se requiere definir aquellos aspectos que guiaran el desarrollo del modelo. Lo anterior implica definir sus características funcionales, diseñar una estructura que permita procesar de forma eficiente la información y definir métodos de validación que aseguren el funcionamiento. A partir de esto, las preguntas que orientan la investigación son las siguientes:

¿Cuáles son las características funcionales que debe tener el modelo de Estimación Cuantitativa de la Precipitación(QPE)?

¿Cuál sería la estructura del modelo para integrar datos de múltiples radares y mejorar la precisión de la Estimación Cuantitativa de la Precipitación (QPE)?

¿Cómo validar la precisión del modelo y cuáles serían las métricas adecuadas para comprobar el correcto funcionamiento del modelo propuesto?

1.2 OBJETIVOS

1.2.1 Objetivo General

Diseñar un modelo para la Estimación Cuantitativa de la Precipitación (QPE), integrando datos de dos radares meteorológicos banda C para el territorio Colombiano.

1.2.2 Objetivos Específicos

- Definir la descripción funcional del modelo de Estimación Cuantitativa de la Precipitación (QPE) mediante un modelo conceptual.
- Estructurar el modelo de Estimación Cuantitativa de la Precipitación (QPE) a partir de la descripción funcional especificada.
- Diseñar el protocolo de pruebas y definir las métricas apropiadas conducentes a la validación del modelo propuesto.

1.3 JUSTIFICACIÓN

1.3.1 Justificación Metodológica

- Teniendo como antecedente que la integración de datos de dos radares en la Estimación Cuantitativa de la Precipitación (QPE), es un área poco explorada en Colombia. Por tanto el desarrollo del proyecto tiene relevancia para el contexto colombiano, ya que es sabido que Colombia es un país altamente vulnerable a fenómenos meteorológicos extremos, por lo cual mejorar la QPE puede permitir una mejor preparación y respuesta ante estos eventos.
- Al diseñar el modelo, se establecerá un precedente ya que servirá como base para estudios posteriores que busquen mejorar la precisión de la QPE en otras regiones del país o que busquen analizar y contrastar los datos provenientes de radar.

1.3.2 Justificación Práctica

- Una primera razón fundamental que soporta la justificación práctica del proyecto es la falta de integración de datos de dos radares; ya que actualmente, en Colombia no existen modelos que aprovechen el traslape de cobertura de los radares para mejorar la Estimación Cuantitativa de la Precipitación (QPE), lo que limita la precisión de las estimaciones.
- En segundo lugar se puede mencionar la necesidad de mejorar la precisión de la QPE, ya que una mayor precisión en la estimación de la precipitación es crucial. La Estimación Cuantitativa de la Precipitación (QPE) es una herramienta esencial para la gestión de riesgos asociados a fenómenos meteorológicos, como inundaciones y deslizamientos, así como otras aplicaciones. Sin embargo, actualmente la precisión de estas estimaciones está limitada por la falta de integración de datos provenientes de dos radares, especialmente en regiones como Bogotá y otras zonas del país donde existe alta incidencia de lluvias y el traslape en la cobertura de radares meteorológicos. En este proyecto se propone una solución práctica al diseñar un modelo que integre los datos de dos radares, mejorando la precisión de la QPE, lo cual permitirá una mejor toma de decisiones ante fenómenos meteorológicos intensos.

1.4 MARCO DE REFERENCIA

1.4.1 Marco Teórico

Estando en curso la revisión bibliográfica pertinente, junto con el desarrollo del proceso de lectura esta revisión teórica se va a presentar mostrando en primer lugar un repaso breve de la teoría básica del radar y posteriormente se presenta información relevante respecto a los factores importantes en la Estimación Cuantitativa de la Precipitación (QPE) a partir de datos de diferentes radares.

1.4.1.1. Un enfoque de aprendizaje automático para la estimación de precipitaciones integrando fuentes de datos heterogéneas"

Considerando que se han empleado métodos tradicionales para estimar la precipitación a partir de datos de pluviómetros y la existencia de limitaciones y dificultades en evaluación y análisis.

Proponen una metodología que se basa en aprendizaje automático que integran datos de múltiples fuentes que incluyen pluviómetros, radares meteorológicos y satélites. En el estudio implementan un clasificador jerárquico que combinado con otras herramientas estadísticas, permite establecer relaciones entre reflectividad del radar (ZZ), temperatura de nubes (satélite) y mediciones in situ. Con la aplicación de la metodología obtienen una mejora significativa en la precisión de la QPE, ya que los pluviómetros brindan mediciones puntuales precisas, en tanto que los radares y satélites aportan cobertura para zonas carentes de instrumentación. Así mismo evidencian que la integración con datos de pluviómetros corrige errores sistemáticos en los datos de radar asociados con el efecto de atenuación en bandas C. Por tanto se plantea en el estudio que la integración datos de múltiples fuentes mediante aprendizaje automático podría reemplazar los métodos tradicionales. (Guarascio et al., 2020)

1.4.1.2. Simulación de eco de un radar meteorológico Doppler de polarización dual basado en el modelo físico

El estudio se enfocó en simular el eco de un radar meteorológico Doppler de doble polarización utilizando las características de dispersión de las partículas de precipitación. Realizan la simulación con el fin de proporcionar señales de prueba cercanas al eco de precipitación real para el radar meteorológico, lo que permitiría ahorrar tiempo y costos en la investigación, el desarrollo y el mantenimiento de radares meteorológicos. Emplean las características de dispersión de las partículas de precipitación considerando que la forma esferoidal achatada para las gotas de lluvia que caen está determinada por el diámetro equivalente y la relación de los ejes. En la descripción de la distribución del espectro de gotas de lluvia de las partículas de precipitación, emplean la distribución de Marshall-Palmer. La distribución de la densidad espectral de potencia calculada por los dos algoritmos (FFT y transformada de Fourier del algoritmo de autocorrelación) es básicamente la misma tanto para la polarización vertical como para la horizontal. Encontrando que el método propuesto es eficaz para simular ecos de radar de doble polarización y puede ser útil en el desarrollo y prueba de radares meteorológicos, a pesar de esto se aclara que no se generaron ni analizaron conjuntos de datos durante el estudio. (JieLa et al., 2020)

1.4.1.3. Evaluación del algoritmo para la corrección de los efectos de banda brillante en QPE con radares de doble polarización de banda S, C y X

El estudio se enfoca en evaluar algoritmos de corrección de la banda brillante ("bright band") en la estimación cuantitativa de precipitación (QPE) utilizando radares de doble polarización en bandas S, C y X. La banda brillante, es causada por el derretimiento de partículas de hielo y se considera importante para la estimación cuantitativa de precipitaciones ya que introduce sobreestimaciones significativas de esta (QPE) cuando esta basada en la relación Z–R (reflectividad-tasa de lluvia). Dentro de los hallazgos encuentran que La corrección de la banda brillante, especialmente con el método AVPR+CC, redujo la sobreestimación de la precipitación, particularmente en eventos con tasas de lluvia horaria menores a 5 mm. Al usar el método AVPR+CC obtuvieron una mejora mayor en las métricas de error utilizadas error cuadrático medio, error absoluto medio relativo y sesgo medio relativo (RMSE, RMAE, RMB) en comparación con el método AVPR solo. Encuentran un efecto representativo en la corrección de atenuación para las bandas C y X, de tal modo que los algoritmos de corrección de la banda brillante, son efectivos para reducir la sobreestimación en la QPE basada en la relación Z–R, con resultados similares en radares de diferentes bandas. Lo que permite destacar la importancia de corregir los efectos de la banda brillante para mejorar la precisión de la QPE, especialmente en eventos de lluvia ligera a moderada. (Cao et al., 2018)

1.4.1.4. Estudio sobre la estimación cuantitativa de la precipitación mediante radar polarimétrico utilizando aprendizaje profundo

Dada la importancia del estudio de las precipitaciones en numerosos campos entre los cuales se encuentran agricultura, administración del recurso, prevención de desastres dada la variabilidad de estas asociada al efecto del calentamiento global. En el artículo presentado se proponen diseñar dos sistemas o redes de estimación cuantitativa de precipitaciones (QPE) basadas en la implementación de aprendizaje profundo (Deep Learning) dado los avances en el desarrollo y uso de la inteligencia artificial en este tipo de aplicaciones. Para ello proponen una red multiparametro y otra de un solo parámetro.

Usan un conjunto de datos proveniente de un radar de banda S y datos de pluviómetros correspondientes a la temporada de lluvias con inundaciones presentada en el año 2021 en China. A partir de estos datos y basándose en la relación lineal de la intensidad de las precipitaciones

con el factor KDP, usan una relación de $0.5 \text{ }^\circ/\text{km}$ para clasificar los datos de lluvia en ligera e intensa y dar posterior tratamiento a los mismos. Trabajan con una función de pérdida autodefinida (SLF) y con la función de pérdida de error cuadrático medio (MSE) convencional, dado que esta última no ofrece un buen ajuste en los casos en los que las precipitaciones son intensas. Entrenan 12 modelos de QPE basados en aprendizaje profundo de acuerdo con los parámetros de entrada del radar, los conjuntos de datos de precipitación y si se adopta una función de pérdida autodefinida (SLF), respectivamente. Los resultados de estos modelos son comparados con los de los métodos tradicionales de QPE: la ecuación de relación ZH-R y Método integrado ZH-ZDR-KDP. Dentro de los hallazgos presentados se encuentra que la segmentación de los datos entre lluvia ligera y lluvia intensa, ofrece mejores resultados en la estimación de las precipitaciones comparado con el análisis de los datos sin clasificar. Adicionalmente, encuentran que se obtienen mejores resultados al aplicar la función de pérdida autodefinida (SLF) respecto a cuándo aplican la función de pérdida de error cuadrático medio (MSE). Por último en el comparativo con la aplicación de los métodos tradicionales se encuentra que el método diseñado, ofrece mejoras con respecto a ambos. Obteniendo los mayores porcentajes de mejora en el error relativo medio cuando se aplica SLF con respecto a la aplicación de la relación ZH-R. (Huangfu et al., 2024)

1.4.1.5. Un esquema de control de calidad de redes neuronales para mejorar la precisión de la estimación cuantitativa de la precipitación en la red de radares meteorológicos del Reino Unido.

El estudio plantea la mejora la Estimación Cuantitativa de Precipitación (QPE) para una estructura de 15 radares meteorológicos en Reino Unido. Desarrollan de un esquema de control de calidad que se basa en redes neuronales para optimizar la selección de datos de radar con el fin de reducir errores y mejorar finalmente la Estimación Cuantitativa de la Precipitación QPE. Emplean una serie de algoritmos basados en características espectrales y parámetros polarimétricos así como en la corrección de perfiles verticales de reflectividad empleando datos climatológicos. Llevan a cabo la generación, entrenamiento y validación del red neuronal con datos independientes y llevando a cabo un comparativo con el esquema de operacional vigente. Como resultado se evidencia un aumento en la correlación y la respectiva disminución en el sesgo y el error cuadrático medio (RMSE). Logran evidenciar finalmente que se obtiene un mejor

resultado al filtrar datos contaminados en bajas elevaciones comparado con usar datos no contaminados en altas elevaciones. (Husnoo et al., 2021)

1.4.1.6. Un sistema de aprendizaje automático para la estimación de precipitaciones mediante observaciones satelitales y de redes de radar terrestres

El estudio en mención se propone mejorar la estimación cuantitativa de la precipitación (QPE) por medio del uso de un sistema de fusión de datos basado en aprendizaje automático, combinando datos de satélite (datos infrarrojos y microondas pasivas) con datos de radar de doble polarización; superando las limitaciones de aquellos basados únicamente en satélites, particularmente para eventos de lluvia ligera o extrema. Emplean observaciones infrarrojas (IR) de satélites geoestacionarios, mediciones de microondas pasivas de satélites de órbita baja y datos de radar meteorológico de banda X y S. Generan un modelo de aprendizaje automático multicapa para procesar los datos de satélite y radar. Utilizan los datos de radar como etiquetas de entrenamiento para el modelo y para el entrenamiento emplean datos de 12 eventos de precipitación, para finalmente comparar los resultados de la validación con las estimaciones de radar meteorológico terrestre. De este modo se evidencia que el sistema basado en aprendizaje automático genera estimaciones de precipitación más precisas que los métodos estándar aplicados en el centro de estudios y una distribución de tasas de lluvia estimadas de alta coincidencia con las mediciones de radar terrestre. Por último se proyecta la posibilidad de adaptación del esquema de aprendizaje automático para su aplicabilidad a diversas regiones climáticas, empleando diferentes fuentes de datos satelitales y de radar. (Chen et al., 2019)

1.4.2. Marco conceptual

Aprendizaje automático: Proceso mediante el cual se puede dirigir a los sistemas informáticos para que mejoren su rendimiento con el tiempo. Algunos ejemplos son las redes neuronales y los algoritmos genéticos. (American Meteorological Society, 2024)

Atenuación: Término general utilizado para denotar una disminución en la intensidad de la señal en la transmisión de un punto a otro. Para la propagación de ondas electromagnéticas a través de un medio, la atenuación es producida por absorción y dispersión. En el radar,

la atenuación específica es la reducción fraccional de la densidad de potencia por unidad de longitud de trayectoria a medida que la radiación de onda plana se propaga a través del medio, generalmente se expresa en decibelios por kilómetro. (American Meteorological Society, 2024)

Banda de frecuencia de radar: Banda de frecuencia de radiación de microondas en la que operan los radares. Las bandas de frecuencia de radar fueron inicialmente designadas con letras de código para mantener el secreto durante la Segunda Guerra Mundial. Todas se encuentran dentro de las bandas de radiofrecuencia UHF , SHF y EHF. Los radares que operan en las bandas S, C y X son utilizados principalmente para la medición de precipitaciones. (American Meteorological Society, 2024)

Dispersión: La variación del índice de refracción complejo con la frecuencia. Se clasifica como normal cuando el índice aumenta al aumentar la frecuencia, o como anómala cuando el índice disminuye al aumentar la frecuencia. Toda sustancia material exhibe dispersión anómala en determinadas frecuencias. Mediante la dispersión, un haz de luz compuesto por muchas frecuencias puede separarse espacialmente (dispersión angular) en sus componentes, como sucede con un prisma. Los arcoíris y los halos deben sus colores a la dispersión angular. (American Meteorological Society, 2024)

Error absoluto medio (MAE): El error absoluto medio (MAE) es una métrica que calcula la magnitud promedio de los errores absolutos entre los valores previstos y los reales. Caracteriza la alteración entre los valores originales y predecibles y se extrae como la media de alteración total del conjunto de datos. (Anand Singh Rajawat, 2022)

Error cuadrático medio (RMSE): El error cuadrático medio (EMM) es la diferencia entre el valor original y el valor predecible. Se obtiene mediante la formación del error cuadrático medio del conjunto de datos. (Anand Singh Rajawat, 2022)

Estimación Cuantitativa de la Precipitación (QPE): La estimación de la cantidad de lluvia o de las tasas de lluvia basándose en mediciones de radar o datos satelitales. (American Meteorological Society, 2024)

Meteorología: Estudio de la física, la química y la dinámica de la atmósfera terrestre, incluyendo los efectos relacionados en la frontera aire-tierra, tanto sobre la tierra como sobre los océanos. Incluye temas fundamentales como la composición, la estructura y el movimiento de

la atmósfera. Tiene como objetivos la comprensión y la predicción completa y precisa de los fenómenos atmosféricos. (American Meteorological Society, 2024)

Polarimetría de radar: Mediciones de radar basadas en la comparación de las propiedades de polarización de las señales transmitidas y recibidas. (American Meteorological Society, 2024)

Polarización: Es la correlación entre dos componentes ortogonales de su campo eléctrico (o, equivalentemente, magnético). Si la relación de las amplitudes de estos dos componentes y la diferencia en sus fases es constante en el tiempo (completamente correlacionada), se dice que la onda está polarizada (o completamente polarizada o 100% polarizada). Si estas dos amplitudes y fases no están correlacionadas, se dice que la onda no está polarizada (o polarizada 0%). Cualquier haz puede descomponerse únicamente como una superposición incoherente de dos haces, uno no polarizado y otro polarizado. A partir de esto, la relación entre la potencia transmitida del componente polarizado y la potencia transmitida total se puede tomar como una medida del grado de polarización del haz. (American Meteorological Society, 2024)

Radar Doppler: Un radar que detecta e interpreta el efecto Doppler en términos de la velocidad radial de un objetivo. La señal recibida por un radar desde un objetivo móvil difiere en la frecuencia respecto a la frecuencia transmitida en una cantidad proporcional al componente radial de la velocidad respecto al radar. (American Meteorological Society, 2024)

Radar meteorológico: Cualquier radar que sea adecuado o pueda utilizarse para la detección de precipitaciones o nubes. tienen como requisitos generales: 1) longitud de onda entre 1 y 30 cm; 2) transmisión pulsada con alta potencia pico (de kilovatios a megavatios); 3) anchos de haz relativamente estrechos; 4) longitudes de pulso de unos pocos microsegundos; 5) frecuencias de repetición de pulso de varios cientos de hercios; y 6) escaneo automático del ángulo de azimuth o elevación. Los circuitos electrónicos y el procesamiento de señales permiten la medición cuantitativa del factor de reflectividad del radar. (American Meteorological Society, 2024)

Radar polarimétrico: Radar capaz de medir cualquiera o todos los atributos dependientes de la polarización de un objetivo o medio de retrodispersión. Radar capaz de medir la matriz de polarización completa mediante polarización variable transmitida y recepción de doble canal. También puede referirse a un radar más simple que transmite una sola polarización y recibe por

separado los componentes copolarizados y cruzados de una señal de retorno. (American Meteorological Society, 2024)

Red Neuronal: Consiste en una red de nodos conectados mediante enlaces ponderados que establecen las relaciones entre ellos. Cada nodo suma las entradas ponderadas que recibe y compara el resultado con una función que generalmente no es lineal para generar su propia salida. La mayoría de las redes neuronales tienen una regla de entrenamiento que establece cómo se ajustan las ponderaciones para que la salida promedio sea lo más cercana posible a la deseada. (American Meteorological Society, 2024)

Reflectividad: Es una medida de la eficiencia de un objetivo de radar para interceptar y devolver energía de radio. Depende de tamaño, forma, aspecto y propiedades dieléctricas del objetivo. Incluye los efectos de la reflexión y también la dispersión y la difracción. La reflectividad de radar de un objetivo meteorológico depende de factores como 1) el número de hidrometeoros por unidad de volumen; 2) el tamaño de los hidrometeoros; 3) el estado físico de los hidrometeoros (hielo o agua); 4) la forma o formas de los elementos individuales del grupo; y 5) si son asimétricos, su aspecto con respecto al radar. (American Meteorological Society, 2024)

1.4.3 Marco espacial

La metodología del presente proyecto se va a desarrollar para Colombia, tomando en cuenta que los datos de trabajo son del país y que fueron seleccionados específicamente en zonas de traslape de cobertura de radares meteorológicos banda C. De tal modo que se cuenta con la disponibilidad de datos que permitan alimentar el modelo para mejorar la Estimación Cuantitativa de la Precipitación (QPE) y así mismo que se disponga de datos de pluviómetros en la zona de traslape. Las áreas de traslape fueron definidas con base en el análisis de la imagen compuesta de la red de radares meteorológicos del IDEAM y otras entidades y entre estas se selecciona inicialmente la zona de Bogotá teniendo en cuenta la alta densidad poblacional, así como la exposición a lluvias e inundaciones repentinas. De acuerdo a lo anterior es posible que los hallazgos solo correspondan a características y fenómenos específicos de la región, aunque no se debería descartar la posibilidad de escalar el modelo a otras zonas de traslape de cobertura.

2. FUENTE DE DATOS

Colombia cuenta actualmente con una red de radares meteorológicos operados por diferentes instituciones, entre ellas el IDEAM (Instituto de Hidrología, Meteorología y Estudios

Ambientales de Colombia) que a través de un bucket público en Amazon Web Services (AWS) publica datos de 4 radares banda C.

Tales radares meteorológicos tienen como función principal la detección y monitoreo en tiempo real de fenómenos atmosféricos, para actividades como el pronóstico y análisis climatológico. La red incluye cuatro radares meteorológicos en banda C con capacidad de doble polarización, que han sido ubicados en diferentes puntos estratégicos garantizando la cobertura en el territorio nacional, atendiendo especialmente aquellas regiones que son mas propensas a eventos meteorológicos extremos como lluvia intensa, tormentas eléctricas, granizo o vendavales. En términos de su funcionamiento, cada uno de ellos lleva a cabo escaneo con una frecuencia de 5 minutos, con lo cual se genera información de alta resolución espacio temporal; a través de barridos en múltiples ángulos de elevación del tipo PPI (Plan Position Indicator).

La red de radares banda C, esta conformada por cerro Munchique, Carimagua, Guaviare y Barrancabermeja, de tal modo que permite además de realizar monitoreo de las condiciones atmosféricas en tiempo real, generar alertas tempranas y apoyar la toma de decisiones en diferentes sectores como transporte aéreo, agricultura y prevención de desastres naturales.

Para efectos del estudio en la etapa inicial se consideran los radares con solapamiento de cobertura y sobre esta base, se define el par de radares a trabajar en función de la disponibilidad de los datos.

2.1 RADAR METEOROLÓGICO BARRANCABERMEJA (SANTANDER)

Se encuentra ubicado en las instalaciones de Ecopetrol y cuenta con un radio de acción estimado de 240 km, generando información útil para la población de los departamentos de Antioquia, Bolivar, Cordoba, Norte de Santander principalmente.




Figura 2. Imagen de radar Barrancabermeja (IDEAM)

2.2 RADAR METEOROLÓGICO SAN JOSÉ DEL GUAVIARE

Se encuentra ubicado en las instalaciones del Batallón de Infantería Joaquín París en San José del Guaviare y cuenta con cobertura en 8 departamentos y 61 municipios. (Vichada, Meta, Vaupés, Guainía, Caquetá, Guaviare, Casanare y Arauca).




Figura 3. Imagen de radar Guaviare (IDEAM)

2.3 RADAR METEOROLÓGICO CARIMAGUA (META)

Ubicado en la Orinoquía colombiana, en el batallón Ignacio de Herrera y Vergara, corregimiento de Carimagua – Meta. Cuenta con un radio de cobertura de 250 km, que permite monitorear la zona hidrográfica del Meta y abarcar otras cinco zonas del país, alcanzando una cobertura de aproximadamente el 52% del total del área hidrográfica del Orinoco, que incluye ocho

departamentos, principalmente con cobertura en Meta, Casanare, Arauca, Vichada y la región de la Orinoquía.



Figura 4. Radar Carimagua

De acuerdo con la necesidad de incluir datos de radares con solapamiento de cobertura y adicionalmente datos de estación meteorológica para el comparativo con el dato de precipitación en tierra. Se plantea la posibilidad de trabajar con las siguientes parejas de radares: Guaviare – Carimagua, Barrancabermeja – Carimagua. Para ello se considera la ubicación por coordenadas geográficas de cada uno de los radares y de las estaciones meteorológicas existentes en la zona de intersección o traslape de cobertura.




Figura 5. Radares con solapamiento de cobertura

El análisis inicial muestra que los radares Guaviare – Carimagua presentan una zona de solapamiento más extensa. Se procede a analizar la información relacionada a distancia entre radares y estaciones pluviométricas en la zona y posteriormente se verifica la disponibilidad de datos para cotejar la información.

2.4 REPOSITORIO DE DATOS DE RADAR DEL IDEAM (AWS)

Los datos son provenientes de la red de radares del IDEAM y corresponden al monitoreo de la atmósfera en tiempo real, a través de un repositorio (Bucket S3) en la nube de Amazon Web Services (AWS). Proporciona de esta forma el acceso a datos no procesados de radar, abriendo la posibilidad de analizarlos incluso sin necesidad de realizar la descarga de estos, se tienen datos registrados desde aproximadamente 2018.

Para el acceso al repositorio, dado el amplio volumen de datos almacenados en la nube, se emplea Python como herramienta tecnológica para el procesamiento inicial, dando lugar a la conformación del contenedor Docker o conjunto de herramientas que permiten el manejo de los datos.

2.4.1 Acceso a los datos

fsspec — corresponde al sistema de archivos para acceder a S3 (AWS) sin autenticación
s3fs — es el Backend específico para S3, es dependencia de fsspec

2.4.2 Lectura y procesamiento de datos

xradar — permite la lectura de archivos SIGMET/IRIS como formato propietario de radares
xarray — para la manipulación de datos multidimensionales en estructura DataTree
pandas — para el manejo de metadatos y tablas, de acuerdo a ubicaciones de radares
wradlib — Weather Radar Library para el procesamiento avanzado

2.4.3 Estructura del bucket

Se tiene la siguiente estructura del bucket:

2.4.3.1 Ruta del Servidor

En la ruta (*s3://s3-radaresideam/l2_data/*), se tiene:

s3://: Indica el protocolo de comunicación (Amazon Simple Storage Service).

s3-radaresideam: Es el nombre único del contenedor global , el Bucket donde el IDEAM aloja la información.

/l2_data/: Muestra que los archivos allí guardados son datos de Nivel 2 (Level 2), es decir, datos que ya pasaron por un procesamiento básico de ingeniería pero que siguen conservando las variables meteorológicas crudas como la reflectividad.

2.4.3.2 Carpetas por Calendario y Estación

(*/YYYY/MM/DD/Radar_name/*): El sistema organiza los archivos en carpetas nombradas cronológicamente para evitar la mezcla en un solo lugar de millones de archivos, dado que el bucket a diferencia de las carpetas tradicionales, no se pueden anidar:

YYYY: Año de 4 dígitos (ej. 2024).

MM: Mes de 2 dígitos (ej. 05 para mayo).

DD: Día de 2 dígitos (ej. 16).

Radar_name: El nombre propio de la estación de radar de origen (Carimagua, Guaviare, Munchique o Barrancabermeja).

2.4.3.3 Nombre de los archivos

(*RRRAAMMDDTTTTT.RAWXXXX*): Cuando el radar realiza un barrido de la atmósfera, genera un archivo con un nombre que es la combinación de datos clave bajo el formato del software meteorológico SIGMET / IRIS:

RRR: Código de tres letras asignado a la estación de radar (ej. CAR para Carimagua, GUA para Guaviare).

AA: Los últimos 2 dígitos del año (ej. 24).

MM: Mes de la captura (ej. 05).

DD: Día de la captura (ej. 16).

TTTTTT: La hora exacta (Hora, Minuto y Segundo) de adquisición de los datos, expresada siempre en Hora Universal Coordinada (UTC), no en hora local colombiana.

.RAWXXXX: Es la extensión del archivo crudo meteorológico (RAW). Las últimas letras (XXXX) son caracteres variables autogenerados por el software del radar para identificar el tipo específico de escaneo o producto interno que se guardó.

2.4.4 Descarga de los datos

Luego de conocer la estructura general, la descarga de datos comprende en forma breve los siguientes pasos:

1. Instalar bibliotecas necesarias Python (fsspec s3fs xradar --break-system-packages)
(conda install -c conda-forge fsspec s3fs xradar)
2. Crear script de descarga Python
3. Ejecutar y visualizar datos

Se obtienen archivos de texto plano separados por comas (csv) que por conveniencia para la visualización de los mismos son convertidos a formato xlsx (excel)

2.4.5 Fuentes de datos de estaciones meteorológicas

Las fuentes para la obtención de datos de estaciones meteorológicas o en tierra son las siguientes:

Por medio del Catálogo Nacional de Estaciones del IDEAM, podemos acceder al listado de estaciones ordenado por código, categoría, ubicación geográfica - municipio, departamento, latitud, longitud – y demás información acerca del área hidrográfica.

Datos históricos de estaciones del IDEAM: el portal institucional cuenta con un servicio de consulta y descarga, que permite acceder a herramientas de gestión de series temporales a través del Sistema de Información para la gestión de datos Hidrológicos y Meteorológicos (DHIME). El sistema permite consultar datos en distintas frecuencias. Para solicitar datos de precipitación, se deben especificar las estaciones de interés, rango de fechas y variables (precipitación), para posteriormente descargar los archivos en formato CSV/Excel.

Por último se pueden adquirir datos de estaciones automáticas de instituciones regionales que publican datos en tiempo real, que a diferencia de estaciones tradicionales, transmiten datos de

forma telemática (vía celular o satelital) en intervalos de 5, 10 o 15 minutos. Esto es posible para algunas Corporaciones Autónomas Regionales (CAR) que para cada departamento o cuenca hidrográfica representa la autoridad ambiental y cuentan con un geoportal de alertas en tiempo real. Tal es el caso de Cormacarena en el departamento del Meta y de las Corporaciones CDMB y CAS en Santanderes.

Cormacarena implementó seis estaciones hidrometeorológicas en el departamento del Meta entre los años 2016 y 2021, que miden en tiempo real variables como precipitación, nivel y velocidad del agua, temperatura, humedad, presión atmosférica, velocidad y dirección del viento, entre otras, dichas estaciones operan los 365 días del año 24/7. Los datos se transmiten automáticamente a través de radioenlace al Centro de Mando y Control Ambiental ubicado en Villavicencio, donde un datacenter de última generación procesa la información y emite alertas automáticas vía correo electrónico y SMS. Esto da lugar a la integración de datos radar-estación-procesamiento automatizado relevante para sistemas de estimación cuantitativa de precipitación (QPE) y alertas tempranas, articulándose con entidades municipales, departamentales y organismos de socorro para minimizar impactos de eventos hidrometeorológicos extremos y mejorar la gestión del riesgo.

2.4.6 Emparejamiento espacio-temporal

Para el emparejamiento espacio-temporal se aborda el problema espacial (dónde) y el temporal (cuándo).

Emparejamiento espacial: Encontrar píxel de radar más cercano a la estación (donde): de acuerdo a ubicación geográfica con base en datos de latitud y longitud- coordenadas de la de la estación meteorológica.

Es decir el radar hace su barrido con un radio de acción de aproximadamente 240-250 km y el comparativo para efectos de evaluación, debe hacerse con respecto al píxel (Representación digital en 2D de esa celda – en la computadora) o celda (volumen físico en 3D que el radar mide) que se encuentre más cercana a la estación meteorológica, considerando que el radar puede dar una estimación para toda una región, pero el pluviómetro da la verdad o dato observado en un punto en específico.

Emparejamiento temporal: En cuanto al problema temporal, por ejemplo se tienen datos de radar cada cinco minutos y datos de intensidad de lluvia para la estación en intervalos de 10 minutos; entonces hay que encontrar - emparejar los timestamps (o marca temporal) - el registro digital de la fecha y la hora exactas en que ocurrió el evento- que coinciden o están más cerca entre si buscando la diferencia de tiempo mas pequeña. Lo anterior considerando que el radar usa un sistema de coordenadas proyectado en metros y la estación usa coordenadas geográficas (lat/lon en grados que hay que convertir al mismo sistema.

Por ultimo una vez se ha llevado a cabo el emparejamiento por espacio y tiempo, la información se consolida en una tabla, en la cual cada fila de datos presenta - para un mismo punto geográfico y tiempo - las estimaciones del radar (variables como Z, ZDR, KDP...) con las mediciones reales de precipitación (datos crudos – raw_data) registradas por la estación pluviométrica.

Dataset Radar:				Dataset Estación:			
10:00 → Z=40.5				10:00 → 5.2 mm			
10:05 → Z=38.2				10:10 → 8.7 mm			
10:10 → Z=42.1				10:20 → 3.1 mm			
10:15 → Z=35.8							
10:20 → Z=30.5							
↓ EMPAREJAMIENTO ↓							
DESPUÉS (Excel final):							
Hora	raw_data	Z_cari	ZDR_cari				
10:00	5.2	40.5	2.1		← Emparejado		
10:10	8.7	42.1	2.3		← Emparejado		
10:20	3.1	30.5	1.8		← Emparejado		

Figura 6. Emparejamiento espacio – temporal

3. ANÁLISIS DE DATOS

3.1 INTRODUCCION

En el presente capitulo se describe el conjunto de datos construido a partir del emparejamiento radar-pluviómetro, se presentan las relaciones de estimación de precipitación aplicadas así como el análisis del desempeño de cada una mediante diferentes métricas de error.

3.2. DESCRIPCIÓN DEL CONJUNTO DE DATOS

3.2.1. Origen y estructura

Se consideran inicialmente las parejas de radares con solapamiento de cobertura Carimagua – Guaviare y Carimagua – Barrancabermeja; para estos se tienen información de la existencia de algunas estaciones meteorológicas a partir de las cuales se podrían tomar los datos de precipitación en tierra, según se muestra en las Tabla 1 y Tabla 2.

Tabla 1. Estaciones meteorológicas zona de cobertura entre radares Carimagua – Guaviare

#	Código IDEAM	Nombre de la Estación	Departamento	Municipio	Latitud (°N)	Longitud (°W)
0	35095110	Hacienda Carimagua	Meta	Puerto Gaitán	4.5683	71.3486
1	35185010	San José del Guaviare	Guaviare	San José del Guaviare	2.5744	-72.6419
2	35057010	Barrancabermeja (Aeropuerto)	Santander	Barrancabermeja	7.0242	-73.8061
3	3502700090	Puerto López	Meta	Puerto López	4.1458	-72.9542
4	35017020	Mapiripán	Meta	Mapiripán	2.8962	-72.1386
5	3505500061	Sabana de Torres	Santander	Sabana de Torres	7.3917	-73.4944

Tabla 2. Estaciones meteorológicas zona de cobertura entre radares Carimagua – Barrancabermeja

ESTACIONES METEREOLÓGICAS											
0	35085060	8	35167000	16	35087020	24	35160000	31	35095120	38	35197030
1	35217030	9	3518500127	17	24035250	25	35217090	32	24035410	39	35235050
2	35197190	10	35167010	18	2403500083	26	35235010	33	35160020	40	24035440
3	2403500041	11	35217060	19	35195060	27	24037190	34	24037080	41	35217010
4	24035340	12	35195050	20	2403500085	28	3508700103	35	35095130	42	35080050
5	35195020	13	24037290	21	35215030	29	35165000	36	35197020	43	35097080
6	35085070	14	35215020	22	2403500082	30	35160010	37	24035430	44	35075070
7	35197070	15	35167020	23	2403500084						

Previo a la descarga de datos para los radares de Carimagua – Barrancabermeja, se lleva a cabo el análisis detallado para la selección de las estaciones meteorológicas presentes en la zona de cobertura con solapamiento, para realizar el emparejamiento espacial.

En las siguientes graficas se muestran las estaciones meteorológicas ubicadas en la zona correspondiente al solapamiento entre los radares:




Figura 7. Estaciones 0 a 5 Radares Carimagua – Guaviare

De acuerdo con la información consignada en la página oficial del IDEAM sobre estaciones pluviométricas ubicadas en la zona de interés para los radares Carimagua – Guaviare, inicialmente se identificó la estación Isla del Muerto [32040020] como la opción más apropiada para realizar el comparativo de datos debido a su ubicación en la zona de traslape de los radares; igualmente, al comparar las distancias entre cada uno de los radares y las estaciones pluviométricas existentes en la zona, la estación La Esperanza apareció como la alternativa con la cercanía más conveniente para ambos radares. Sin embargo, luego de analizar el grupo completo de estaciones en la zona de interés —el cual incluye también a La Catalina y Mapiripán—, se estableció que el análisis carecía de viabilidad técnica debido a la falta de disponibilidad de datos cronológicos, por lo cual se optó por seleccionar un par de radares diferente.




Figura 8. Estaciones 0 a 7 Radares Carimagua – Barrancabermeja




Figura 9. Estaciones 7 a 14 Radares Carimagua – Barrancabermeja




Figura 10. Estaciones 15 a 21 Radares Carimagua – Barrancabermeja




Figura 11. Estaciones 22 a 28 Radares Carimagua – Barrancabermeja




Figura 12. Estaciones 29 a 35 Radares Carimagua – Barrancabermeja




Figura 13. Estaciones 36 a 44 Radares Carimagua – Barrancabermeja




Figura 14. Estaciones metereologicas entre Radares Carimagua – Barrancabermeja

Considerando que posiblemente no todos los puntos van a ser útiles se plantea la necesidad de utilizar varias de estas estaciones, razón por la cual a partir de la información reflejada en las **anteriores** gráficas, se incluyen en el análisis las siguientes estaciones por estar en la zona de solapamiento entre los dos radares:

1	35217030	2	35197190	5	35195020	7	35197070
8	35167000	10	35167010	12	35195050	19	35195060
36	35197020	38	35197030				

Adicionalmente al considerar la importancia de realizar validación en función de variaciones en la geografía de la zona de cobertura de los dos radares por la ubicación de montañas en la zona, se incluirían las siguientes estaciones ubicadas a una menor distancia del radar de Barrancabermeja:

13	24037290	23	2403500084	27	24037190	34	24037080
40	24035440						

Por medio del análisis inicial se define el conjunto de datos, luego de realizar emparejamiento espacial con las estaciones meteorológicas seleccionadas. Se genera a partir de esto un archivo de descarga inicialmente en formato csv, que convertido a formato Excel (xlsx) permite en la etapa inicial realizar una inspección de los datos.

El análisis de los datos parte de un dataset de 35.733 registros emparejados de los dos radares banda C (Carimagua y Barrancabermeja) con las estaciones pluviométricas previamente definidas; sobre el conjunto de datos se calcularon tres relaciones R clásicas para determinar la precipitación y se aplican siete métricas de error. El cálculo de R (tasa de precipitación) toma como referencia las variables polarimétricas que incluyen reflectividad (Z) en dBZ, reflectividad diferencial (ZDR), fase diferencial ΦDP (PhiDP) en grados, fase diferencial específica (Kdp) en $^{\circ}/\text{km}$, factor de correlación cruzada phv (RhoHV) que es adimensional y para el comparativo el dato de precipitación proveniente de pluviómetro en mm/h.

El archivo generado rawData_merge_BarraCari.xlsx integra, en cada fila:

- La precipitación observada por la estación pluviométrica mostrado como raw_data, columna E,
- Los cinco parámetros polarimétricos del radar Carimagua (columnas F–J),
- Los cinco parámetros polarimétricos del radar Barrancabermeja (columnas AF–AJ),
- Las relaciones R calculadas y
- Las métricas de error aplicadas en las columnas siguientes a cada radar.

3.2.2. Cobertura espacial y temporal

El dataset cuenta con un total de 35.733 registros emparejados para los dos radares, e involucra datos de quince estaciones meteorológicas ubicadas en la zona de solapamiento de señal. Así mismo incluye datos de radar que abarcan diferentes fechas de 2018 a 2022 tomados a distancias de entre 150 y 210 km, estas últimas definidas tomando en cuenta la existencia de estaciones en la zona de solapamiento se da a estas distancias y en función de que fueran visibles para los dos radares.

Las estaciones meteorológicas de las cuales se están tomando una parte representativa de los datos corresponden principalmente a 35197020 que aporta el 23.59% de los datos en Carimagua, 24037080 con el 24.13% de los datos en Barrancabermeja y en tercer lugar la estación 24037290 que aporta el 17.52% de los datos, de tal modo que estos 3 códigos representan aproximadamente el 65% de las 35,758 filas de datos.

3.3. RELACIONES DE ESTIMACIÓN DE PRECIPITACIÓN

Para la Estimación Cuantitativa de la Precipitación (QPE), se utilizan los modelos empíricos multiparametro basados en los estimadores polarimétricos a partir de los datos de radares banda C (Ryzhkov & Zrníc, 2019), que incluyen la reflectividad (Z), la fase diferencial específica (KDP) que disminuye el efecto de la variabilidad en el tamaño de las gotas y la combinación de reflectividad y reflectividad diferencial ($Z - ZDR$); esta última expresión incluyendo un exponente negativo en ZDR que funciona como factor de corrección asociado a la geometría, en el caso de haber sobreestimación de la lluvia por la presencia de otro tipo de partículas con diámetro grande en la muestra.

La elección de una relación en particular depende del tipo de lluvia (convectiva frente a estratiforme, tropical frente a continental, etc.), la estación del año y la región climática. La siguiente relación es de uso generalizado para condiciones de lluvia estratiforme basada en Marshall & Palmer (1948):

$$Z = 200 * R^{1.6} \quad (1)$$

$$R = \left(\frac{Z}{200}\right)^{\left(\frac{1}{1.6}\right)} \quad (2)$$

La tasa de precipitación basada en la relación de reflectividad (Ryzhkov & Zrníc, 2019) se expresa a partir de esta ecuación en mm h-1, con Z en términos lineales en mm⁶ m-3, la selección

de los respectivos coeficientes, dependen de varios factores entre los que se puede mencionar la categoría de lluvia por ejemplo estratiforme o convectiva y la región climática. Y sobre esto se aclara que para la elección de la relación $R(Z)$, no hay un único criterios que permita escoger la mejor para un lugar y momento específicos.

A partir de la fase diferencial específica

$$R = 19.63 * KDP^{0.823} \quad (3)$$

Expresión basada en la combinación de dos variables polarimétricas de reflectividad y reflectividad diferencial:

$$R = 0.0067 * Z^{0.927} * ZDR^{-3.43} \quad (4)$$

3.4. MÉTRICAS DE EVALUACIÓN

Una vez se lleva a cabo la Estimación Cuantitativa de la Precipitación (QPE) a partir de los datos de radar, se emplean los datos de pluviómetros para validar el rendimiento de los estimadores de precipitación empleando varias métricas estadísticas para analizar la calidad de la estimación. Se aplican varias métricas considerando que cada una revela un aspecto distinto del error por ejemplo magnitud absoluta, sensibilidad a extremos, sesgo, peso relativo. Algunas de ellas son: el sesgo B , el error absoluto medio (MAE), el error cuadrático medio (RMSE), la desviación estándar (SD) y el coeficiente de correlación (CC). Se definen como:

$$B = \langle TR - TG \rangle \quad (5)$$

$$MAE = \langle |TR - TG| \rangle \quad (6)$$

$$RMSE = \langle (TR - TG)^2 \rangle^{1/2} \quad (7)$$

$$SD = (RMSE^2 - B^2)^{1/2} \quad (8)$$

donde TR y TG son los totales de precipitación registrados por radar y pluviómetro para cada par de datos radar-pluviómetro, y los corchetes indican el promedio de todos los pares. Los errores fraccionarios, definidos por la división de B, MAE, RMSE y SD entre $\langle TG \rangle$, son métricas comunes de la calidad de la estimación cuantitativa de precipitación (QPE) (Ryzhkov & Zrnica, 2019).

3.5. RESULTADOS DEL ANÁLISIS

3.5.1. Resultados globales por relación

Tabla 3. Desempeño global de las tres relaciones (radar Carimagua)

Métrica	R(Z)	R(KDP)	R(Z,ZDR)
MAE (mm/h)	0.077	—	—
RMSE (mm/h)	0.16	—	—
MAPE (%)	34.96	492.5*	18230.8*
PBIAS (%)	10.73	-301.9*	-18194.4*
NRMSE	0.739	—	—

* Los valores extremadamente altos en R(KDP) y R(Z,ZDR) reflejan que estas relaciones no son utilizables con los datos disponibles.

De acuerdo con los resultados mostrados en la Tabla 3, la relación R(Z) es la que muestra un mejor desempeño, lo cual es coherente con datos de lluvias moderadas observados a partir de los datos de pluviómetro, con un RMSE bajo el cual implica que la desviación en lámina de agua es mínima, en tanto que las otras dos relaciones presentan errores superiores en varios órdenes de magnitud.

Esta aparente contradicción ocurre porque la muestra corresponde predominantemente a eventos de lluvia ligera. En precipitaciones de 0.1–0.2 mm/h, un error absoluto pequeño genera un gran error porcentual, lo que incrementa el MAPE; pero considerando que el RMSE mide magnitud

absoluta, mantiene un valor bajo. Por lo tanto, radar y pluviómetro coinciden en que "hay poca precipitación, y no se encuentran errores catastróficos en los pocos eventos de lluvia moderada.

Un RMSE de 0.16 mm/h significa que, en promedio, la diferencia entre la estimación del radar y lo que midió el pluviómetro es de menos de un cuarto de milímetro por hora. Lo cual en términos físicos muestra un error bajísimo, ya que aunque porcentualmente parezca que el radar falla mucho, en volumen de agua la diferencia es despreciable.

Al contrastar con el MAPE se evidencia el efecto del error porcentual, debido a que en lluvias de 0.1 o 0.2 mm/h, fallar por 0.2 mm/h es un error del 100% (MAPE), pero sigue siendo un error pequeño de 0.2 en magnitud real (RMSE).

Al analizar el contraste del RMSE bajo con el MAPE es mas alto, se confirma porque la base de datos está dominada por eventos de lluvia muy ligera. Como el RMSE eleva los errores al cuadrado, si hubiera errores grandes en las lluvias fuertes el RMSE saltaría inmediatamente a valores por encima de 2 o 3. El RMSE global de 0.16 mm/h demuestra que la desviación absoluta del modelo QPE es mínima.

El radar intenta estimar lluvia en un rango donde la señal es muy débil y con lluvias menores a 2 o 5 mm/h se dificulta la tarea del radar ya que la reflectividad Z es baja y puede confundirse con ecos no meteorológicos, polvo o humedad que no llega al suelo. De acuerdo con lo anterior puede decirse que el modelo de radar actual sobreestima en forma sistemática la lluvia ligera.

Adicionalmente, se puede considerar que el valor elevado de la métrica MAPE, puede estar relacionada con la falta de simultaneidad temporal entre sensores. Una solución global implicaría aplicar un filtrado de los datos menores a 1 o 2 mm/h para limpiar dataset de datos que se constituyen posiblemente en el ruido del análisis. Según esta métrica, en promedio, el radar se desvía un 35% de lo que marca el pluviómetro.

En cuanto a la métrica NRMSE, un modelo con buena capacidad predictiva debería tener un valor de RMSE menor a 0.5 (50%), por lo que un valor superior estaría mostrando que la

estimación del radar posiblemente tiene más ruido que señal y esto es coherente con la distancia a la cual fueron tomados los datos, de nuevo afectados por el emparejamiento espacial.

3.5.3. Desempeño estratificado por intensidad de lluvia

Una vez segmentados los datos de intensidad de lluvia para analizar el comportamiento de los datos, se encuentra lo siguiente:

Tabla 4. Error porcentual por rango de intensidad

Rango de intensidad	N.º de datos	Error porcentual (%)
$R \leq 5 \text{ mm/h}$	35.728	~59.9
$5 < R \leq 15 \text{ mm/h}$	5	~98.2
$R > 15 \text{ mm/h}$	0	sin datos
Total	35.733	—

A partir de la Tabla 4, se observa que el 99.99% de los datos corresponde a lluvia ligera ($R \leq 5 \text{ mm/h}$), ya que solo hay cinco (5) registros que caen en el rango de lluvia moderada y ninguno en lluvia intensa; y en los pocos datos de lluvia moderada (5-15 mm/h) no hay errores grandes. Esto podría ser una limitación fundamental del conjunto de datos para entrenar un modelo QPE, que se desprende de algunas limitantes en la disponibilidad de datos que coincidan exactamente al momento de realizar el emparejamiento espacio – temporal.

3.6. COHERENCIA Y LIMITACIONES DE LOS DATOS

3.6.1. Dominancia de lluvia ligera

El conjunto está fuertemente sesgado hacia precipitaciones ligeras. El valor 0.2 mm/h domina la variable observada, que corresponde a los datos de medición de precipitación en tierra por medio de pluviómetros. Esto puede tener implicaciones justamente relacionadas con los resultados que se obtendrían al entrenar un nuevo modelo, ya que trabajando sobre estos datos el nuevo modelo

puede presentar como tendencia la predicción de valores bajos con posiblemente poca capacidad para estimar eventos intensos.

3.6.2. Sobreestimación sistemática en lluvia ligera

De acuerdo a los resultados iniciales el radar sobreestima de forma sistemática la lluvia ligera. El radar intenta estimar precipitación en un rango donde la señal es débil y puede confundirse con ecos no meteorológicos, polvo o humedad que no llega al suelo.

3.6.3. Falta de simultaneidad temporal

La falta de simultaneidad temporal entre el radar y el pluviómetro degrada la métrica MAPE hasta niveles del 95%. Por lo cual se puede plantear que la ausencia de emparejamiento temporal introduce error que no es atribuible al modelo de estimación en sí.

3.6.4. Limitaciones de las relaciones $R(KDP)$ y $R(Z,ZDR)$

La fase diferencia específica KDP presenta cobertura casi nula en los datos (mayoritariamente ceros), lo que invalida cualquier estimación de precipitación que considere esta variable $R(KDP)$; y la combinación $R(Z,ZDR)$ retoma la inestabilidad de ZDR cuando toma valores extremos. Esto es coherente con los resultados que muestran refuerza a $R(Z)$ como la mejor de las tres relaciones.

3.6.5. Síntesis para el modelo QPE

Dado que la mejor relación clásica ($R(Z)$) aún presenta un MAPE elevado y un sesgo de sobreestimación, y debido a que el problema es no lineal y multivariable, puede tomarse esto como justificación para proponer el uso de un modelo basado en redes neuronales que combine las variables polarimétricas para reducir el error de estimación.

4. DESCRIPCIÓN DEL MODELO DE ESTIMACIÓN

Dentro de las etapas de desarrollo del proyecto se continua con la definición de la descripción funcional del modelo de Estimación Cuantitativa de la Precipitación (QPE) mediante un modelo conceptual. Para ello se establecen las entradas, los procesos y las salidas del modelo, así como las interacciones entre sus componentes; de tal modo que el modelo conceptual aquí definido se constituye en la base sobre la cual se estructura la subsecuente implementación técnica.

4.1. PROPÓSITO Y ALCANCE DEL MODELO

El objetivo del modelo de Estimación Cuantitativa de la Precipitación es calcular la intensidad de lluvia empleándolas variables polarimetrías medidas por cada uno de los radares banda C ubicados en territorio colombiano, esto con el fin de mejorar la estimación obtenida a partir de las relaciones empíricas. Dentro de su alcance, incluye datos de los radares Carimagua y Barrancabermeja y su comparativo con los datos de precipitación registrada en las estaciones pluviométricas tomadas en cuenta para el área de cobertura, conformando un sistema de estimación que integre la información de dos fuentes de radar independientes con un único dato de precipitación observada en estación meteorológica pluviométrica. La metodología de desarrollo se considera replicable a otros pares de radares de la red nacional del IDEAM, por lo cual sirve de base para posteriores estudios que contribuyan al futuro desarrollo de un sistema de QPE para Colombia.

4.2. DEFINICIÓN DEL PROBLEMA

La estimación de la precipitación a partir de los datos de radar, se basa en la aplicación de relaciones empíricas que conectan variables polarimetrías con la tasa de lluvia. Dichas relaciones entre las que se encuentran las mostradas en las ecuaciones (2) a (4), emplean coeficientes constantes que no se ajustan a las condiciones específicas de una región en particular, ni a la variedad de tipos de precipitación. Es esta la base sobre la cual se plantea el objetivo de disminuir el error en la estimación cuantitativa de la precipitación, mediante la obtención de un modelo que tenga la capacidad de aprender a partir del análisis del conjunto de datos inicial, que establezca

una relación multivariable sin asumir linealidad entre los parámetros del radar y el valor de precipitación observado por los pluviómetros. Lo anterior se sustenta en el hallazgo inicial respecto al cual, a pesar de que la relación $R(Z)$ es la que mejor se ajusta para la QPE, presenta problemas de sobre estimación de la lluvia.

4.3. MODELO CONCEPTUAL

El modelo QPE se puede describir conceptualmente, las entradas, el proceso y las salidas del sistema, sin detallar todavía su implementación, pero mostrando la conexión entre las entradas y las salidas.




Figura 15 Diagrama de bloques

4.3.1. Bloque 1 — Entradas

El modelo de Estimación Cuantitativa de la Precipitación en su definición conceptual, se conforma a partir de dos fuentes de entrada independientes operacionalmente, que corresponden a los dos radares banda C tomados para el estudio. Cada uno de ellos aporta valores medidos

correspondientes a cinco variables polarimétricas como reflectividad (Z), reflectividad diferencial (ZDR), fase diferencial (ΦDP), fase diferencial específica (KDP) y coeficiente de correlación cruzada (ρ_{HV}). Ambos conjuntos de datos están alineados con las mediciones de la estación pluviométrica de referencia, que funcionaría como variable de validación para ambos radares.

La estructura propuesta con doble entrada, difiere del modelo convencional que típicamente está propuesto con un enfoque monoradar, integrando por tanto información de dos instrumentos en ubicaciones geográficas distintas y en condiciones de observación potencialmente distintas, pero enfocados en una misma área de interés que corresponde al área con solapamiento de cobertura de los dos radares.

4.3.2. Bloque 2 — Procesamiento

El segundo bloque que en términos conceptuales es el núcleo del modelo o bloque de procesamiento de los datos, que opera en tres etapas secuenciales. Una primera etapa, en función de las variables polarimétricas de cada radar, calculando precipitación por medio de la relación clásica para $R(Z)$ mostrada en la ecuación (2), se obtiene allí un valor estimado de precipitación para cada radar y son la línea base de cada comparación a realizar en el modelo.

Luego una segunda etapa, en la cual cada estimación $R(Z)$ se compara con el valor medido (observado) por la estación pluviométrica que tiene como característica básica, ser único y común para ambos radares en función del emparejamiento del conjunto de datos. Este comparativo permite evaluar el error de estimación de cada radar respecto al valor observado, a través de las métricas de error definidas en el protocolo de validación.

En una tercera etapa, se plantea que las variables polarimétricas medidas por cada radar de forma independiente, alimentan una red neuronal artificial. La red es entrenada para estimar precipitación con una reducción del error que para cada conjunto de observaciones se evaluó en la etapa anterior. Enseguida los resultados de las redes individuales, se integran en una tercera red neuronal unificada, que en simultaneidad de condiciones toma como entrada las 10 variables

polarimétricas correspondientes a los dos radares y produce un único valor de estimación de precipitación.

4.3.3. Bloque 3 — Salida

El tercer bloque o bloque de salida entrega el valor de precipitación estimada en unidades de milímetros por hora (mm h^{-1}), proveniente del modelo de red neuronal unificada, que está integrada por la información de ambos radares. El valor de salida se compara directamente con la medición del pluviómetro o medidor en tierra, lo que permite evaluar la mejora que aporta el modelo de red neuronal unificada con respecto a la estimación clásica $R(Z)$ de cada radar. El ajuste del modelo se realiza utilizando el conjunto de datos de referencia construido a partir del emparejamiento de tipo espacio-temporal entre los datos de los dos radares y la estación pluviométrica.

4.4. VARIABLES DEL MODELO

Los cinco parámetros polarimétricos que se detallan en el capítulo de análisis de datos son las variables de entrada del modelo. La intensidad de la precipitación pronosticada es el parámetro de salida. La precipitación registrada por las estaciones de medición de lluvia es la variable de referencia utilizada para el ajuste y la validación. Esta categorización funcional es resumida en la Tabla 4.1.

Tabla 5 Clasificación funcional de las variables del modelo

Rol funcional	Variable	Unidad	Fuente
Entrada	Reflectividad (Z)	dBZ	Radar 1 y 2
Entrada	Reflectividad diferencial (ZDR)	dB	Radar 1 y 2
Entrada	Fase diferencial específica (KDP)	°/km	Radar 1 y 2
Entrada	Coeficiente de correlación cruzada (RhoHV)	adimensional	Radar 1 y 2
Referencia	Precipitación observada (pluviómetro)	mm/h	Estación pluviométrica
Salida	Precipitación estimada (R)	mm/h	Modelo Red Neuronal

4.5. SUPUESTOS Y RESTRICCIONES

La descripción funcional del modelo se fundamenta en algunos supuestos básicos que se declaran enseguida: en primer lugar que las observaciones del radar y del pluviómetro pueden ser emparejadas de manera confiable en el espacio y el tiempo; en segundo lugar que los datos de precipitación observada en estación pluviométrica son completamente confiables y provienen de elementos de medición calibrados; , en tercer lugar que las variables polarimétricas son información adecuada y suficiente para la estimación de la precipitación al provenir de un conjunto de datos son consistentes; en cuarto lugar que el conjunto de datos de referencia es representativo de las condiciones pluviométricas de la región. La calidad del modelo depende directamente de la calidad y representatividad del conjunto de datos que se tiene disponible, lo cual constituye la restricción principal.

5. ESTRUCTURA DEL MODELO

El presente capítulo responde al segundo objetivo propuesto en el presente estudio: estructurar el modelo QPE a partir de la descripción funcional. Esto implica que se traduce el modelo conceptual del capítulo anterior en una arquitectura técnica concreta, implementada mediante el uso de las herramientas de redes neuronales artificiales del entorno MATLAB.

5.1. JUSTIFICACIÓN DEL ENFOQUE BASADO EN REDES NEURONALES

Se espera que en el bloque de procesamiento establecido previamente en el modelo conceptual, se ejecute una función de estimación no lineal y multivariable entre las variables polarimétricas de los radares y la precipitación observada en tierra. Las relaciones empíricas clásicas, al emplear coeficientes fijos no reflejan la variabilidad de las relaciones en todas las condiciones climáticas, hablando particularmente del territorio colombiano. De acuerdo a la habilidad para aproximar relaciones no lineales complejas basándose en ejemplos (datos), se eligen las redes neuronales artificiales como alternativa apropiada; esto sin definir previamente la forma funcional de la relación. Esta propiedad es apropiada para la Estimación Cuantitativa de la Precipitación, particularmente porque la relación entre las variables polarimétricas y la lluvia detectada por pluviómetro en superficie no se representa adecuadamente por medio de una expresión cerrada con coeficientes fijos.

5.2. ARQUITECTURA DEL MODELO

En el presente apartado se muestra la descripción de la arquitectura concreta, junto con la presentación de las tres redes.

La configuración del modelo con base en los resultados iniciales, se plantea en términos de tres redes neuronales de tipo feed-forward complementarias. Las dos primeras, están vinculadas de forma independiente a cada radar con la denominación NN-Cari y NN-Barra. Cada una de ellas cuenta con dos capas ocultas que tienen diez y veinte neuronas respectivamente y reciben las cinco variables polarimétricas de cada radar. La tercera capa, es la capa unificada (NN-Unif), que

incluye por tanto las diez variables de los dos radares y, debido a su dimensionalidad más alta, se tiene dos capas ocultas de quince y treinta neuronas. La capa de salida utiliza una función lineal, adecuada para un problema de regresión, mientras que las capas ocultas utilizan la función de activación tangente hiperbólica.

Tabla 6 Configuración de las tres redes neuronales

Red	Entradas	Capas ocultas	Salida	Propósito
NN-Cari	5 (radar Carimagua)	20 — 10	1	Estimación radar Carimagua
NN-Barra	5 (radar Barrancabermeja)	20 — 10	1	Estimación radar Barrancabermeja
NN-Unif	10 (ambos radares)	30 — 15	1	Estimación unificada QPE final




Figura 16 Diagrama de la arquitectura del modelo

El diagrama de la arquitectura de la red unificada se muestra en la Figura 16, donde se pueden identificar las capas, neuronas en cada una, y cómo se conectan. Es decir para el caso muestra 10 entradas (los 5 parámetros polarimétricos de Carimagua sumados a los 5 de Barrancabermeja) → Luego la información la procesa a través de dos capas ocultas profundas de 30 y 15 neuronas respectivamente capa oculta de 30 → capa oculta de 15 → 1 salida y luego queda como una

única neurona de salida que entrega la tasa de precipitación estimada en mm/h. Este constituye la implementación técnica de la descripción funcional que fue previamente definida en el modelo conceptual.

5.3. CONJUNTO DE DATOS Y PREPARACIÓN

El modelo se desarrolla a partir del conjunto de datos que se describió en el apartado de análisis. Está compuesto por registros de datos de los dos radares emparejados espacialmente con datos de precipitación registrada por los pluviómetros. Previo al entrenamiento, se eliminan las filas de aquellos registros de datos que tienen valores no validos o faltantes. Posteriormente se hace la segmentación de los datos en tres subconjuntos por medio de una partición aleatoria que se implementa en forma idéntica a las tres redes con el fin de garantizar resultados comparables:

- El primero para entrenamiento 70% con 25.014 registros empleados en ajuste de los pesos de la red.
- El segundo para validación 15% con 5.360 registros empleados en el entrenamiento para vigilar la generalización.
- El tercero para llevar a cabo la prueba 15% con 5.359 registros reservados para la evaluación de desempeño al final.

5.4. ALGORITMO Y PARÁMETROS DE ENTRENAMIENTO

Para el ajuste de los pesos de las redes, se emplea el algoritmo Levenberg-Marquardt por su velocidad de convergencia en problemas de regresión de tamaño mediano. Se emplea el Error Cuadrático Medio (RMSE), como función de costo y se establece el procedimiento con un nivel de máximo épocas de 500 sumado al criterio de detección temprana de 20 fallos consecutivos sin mejora en el conjunto de validación, lo anterior se fundamenta en el desempeño sobre el subconjunto de validación. Con el fin de asegurar que los resultados sean reproducibles, se estableció la semilla del generador de números aleatorios.

El entrenamiento del modelo unificado NN-Unif finaliza al alcanzar el gradiente mínimo establecido en la época 302, con un RMSE de validación en ese punto. La Figura 5.2 presenta la curva de convergencia del entrenamiento.

5.5. IMPLEMENTACIÓN

El modelo fue implementado mediante el uso de las herramientas de redes neuronales del entorno MATLAB. El procedimiento incluye la carga, extracción y depuración del conjunto de datos y las variables; así como la segmentación de los datos y el entrenamiento consecutivo de las tres redes generando las predicciones y los respectivos gráficos desempeño de las redes. Como resultado del proceso se obtienen varios modelos que han sido entrenados y son exportables, con la posibilidad de utilizarse con nuevos datos de radar. En el Anexo se muestra el código de Matlab empleado y en las siguientes imágenes, los resultados al ejecutar la consola.




Figura 17 Panel General de Entrenamiento

En la Figura 17 se muestra la interfaz que resume el proceso de la red neuronal usando el algoritmo de Levenberg-Marquardt. El entrenamiento se detiene exitosamente en la época 302, cuando el gradiente alcanza el valor mínimo establecido como criterio de parada (9.83×10^{-8}). El valor muy bajo del **Error Cuadrático Medio (MSE)** final muestra que la red logró una convergencia eficiente sin requerir agotar el límite de 500 épocas, pero esto no debe ser una interpretación aislada dado el análisis subsiguiente. .




Figura 18 Dispersión observado vs estimado

En la Figura 18 se observa cómo las relaciones clásicas R(Z) para Carimagua y Barrancabermeja presentan una alta dispersión y subestimación respecto a la línea ideal (1:1). Lo anterior en contraste, respecto a los modelos neuronales, y particularmente la red unificada (NN-Unif), donde se observan alineadas las predicciones en forma casi perfecta con respecto a las observaciones del pluviómetro, por lo cual se reduce el RMSE a niveles muy pequeños (0.0078 mm/h). Esto muestra que el modelo logra captar las no linealidades complejas de los parámetros polarimétricos que quedan omitidas por las relaciones empíricas.

El cuadro de resumen en la parte inferior derecha muestra los cinco valores de RMSE, con una diferencia variada en magnitud entre la relación empírica y las redes neuronales.




Figura 19 Comparación de Métricas por Modelo

Las gráficas de barras mostradas en la Figura 19 muestran el beneficio en términos cuantitativos al trabajar con redes neuronales cuando se compara con QPE proveniente de las relaciones empíricas tradicionales. En todas las métricas se observa un patrón similar: R(Z) de Barrancabermeja con errores más elevados, enseguida la barra de R(Z) de Carimagua, luego las redes independientes NN-Cari y NN-Barra con una mejora importante y por último la red unificada NN-Unif que presenta valores prácticamente nulos. Se desprende de lo anterior que el análisis mediante métricas específicas como MAE, RMSE, WMAPE y NRMSE, muestran una disminución sustancial en el error al pasar de la QPE por modelos empíricos a la arquitectura de redes neuronales, es decir cuando se aplica la red NN-Unif. Esto demostraría que la combinación simultánea de variables de los dos radares diferentes aporta información complementaria que la red neuronal aprovecha para mejorar la estimación.

Se debe resaltar que se constituye en una mejora real y de interpretación física la que muestra NN-Cari respecto de R(Z) Carimagua, considerando que opera en el mismo rango de magnitudes.




Figura 20 Histograma Comparativo de Errores

En la Figura 20 se muestra la distribución de los errores (estimado - observado) para las 5 alternativas. Mientras que los modelos clásicos $R(Z)$ presentan distribuciones anchas y desplazadas al sector de valores negativos lo cual estaría relacionado con una tendencia a subestimar la precipitación, las distribuciones de las redes neuronales se muestran más estrechas y cerca al error nulo por lo cual se visualizan barras verticales en el centro del histograma. El modelo unificado muestra desviaciones despreciables en la mayoría de las estimaciones respecto a los pluviómetros en el conjunto de prueba.




Figura 21 Curva de convergencia




Figura 22 Curva de rendimiento

En las Figuras 21 y 22 se muestra la evolución del MSE durante las 302 épocas de entrenamiento para los conjuntos de Entrenamiento, Validación y Prueba. Se observa descenso en simultánea y paralelamente de la curva roja (Test) y la verde (Validation) con la curva azul de entrenamiento, alcanzando estabilidad en el orden de 10^{-7} .




Figura 23 Gráficos de Regresión Lineal (a)

En las Figuras 23 y 24 Gráficos de Regresión Lineal (a) y (b) se muestra la correlación lineal de Pearson (R) entre el objetivo (Target) y la salida de la red (Output). Para el conjunto de prueba independiente (Test set), el modelo unificado alcanza un coeficiente $R = 0.99929$. con un R prácticamente unitario al consolidar todos los subconjuntos, mostraría esto que la red unificada logra replicar la variabilidad del pluviómetro con una alta fidelidad.




Figura 24 Gráficos de Regresión Lineal (b)




Figura 25 Estado del Entrenamiento

En la Figura 25 se muestran los parámetros internos del algoritmo Levenberg-Marquardt. El comportamiento descendente en escalón del gradiente y el parámetro de control μ que confirman que el descenso del gradiente fue estable y sin oscilaciones anómalas, lo cual garantizaría el ajuste de la red. Al observar el panel inferior las verificaciones de validación (Validation Checks) muestran que la línea permanece en cero durante las 302 épocas, esto implica que el desempeño en validación nunca dejó de mejorar lo suficiente como para activar el denominado contador de fallos. Esto puede traducirse en que el mecanismo de detención temprana, que previene el sobreajuste, no funcionó como freno en este caso porque la red seguía mejorando su ajuste al valor dominante del conjunto de validación, o que se mantuvieron en cero hasta el final, mostrando específicamente la mejora continua en el proceso.

Esto último tiene validez considerando que se tiene un conjunto de datos coherente, proveniente de mediciones realizadas por los dos radares polarimétricos, es decir no se trata de un conjunto de datos lleno de "ruido", sino que las variables polarimétricas son consistentes; esto a pesar de que los datos de reflectividad (Z) correspondientes al radar Barrancabermeja, presentan un intervalo de variación un tanto distinto al del radar Carimagua, lo cual puede ser visto como una

inconsistencia, pero ese es el comportamiento de los datos y finalmente implica esto que el modelo aprendió y muestra de ello es el mejor comportamiento de la red individual Carimagua.




Figura 26 Histograma de Error del Entrenamiento

En contraste con la Figura 19 que comparaba todos los modelos, en la Figura 26 se muestra el modelo durante su entrenamiento. La gran concentración de instancias en la barra central (Error aproximado a cero) confirma que la capacidad de aproximación de la red unificada es sólida sobre el volumen total de datos.

6. PROTOCOLO DE PRUEBAS Y VALIDACIÓN

Respecto al tercer objetivo propuesto, se presenta en este apartado en primer lugar el protocolo de pruebas propuesto, así como las métricas con las cuales se va a evaluar y en seguida se muestran los resultados de la aplicación de los mismos, para finalizar con la interpretación de la validación correspondiente.

6.1. DISEÑO DEL PROTOCOLO DE PRUEBAS

El protocolo de pruebas se diseñó con el fin de evaluar de forma objetiva la capacidad del modelo propuesto para Estimación Cuantitativa de la Precipitación, con la idea de evitar que los resultados reflejen una simple memorización de los datos. La fundamentación del protocolo se basa en tres principios que corresponden a en primer lugar la segmentación de los datos, se calculan las métricas asociadas al rendimiento únicamente sobre el subconjunto de datos de prueba, que se reserva únicamente para ese fin, descartándolo del proceso de entrenamiento. En segundo lugar se lleva a cabo la comparación con una referencia, es decir la comparación de la actuación de cada red neuronal con la de la relación clásica $R(Z)$ obtenida por medio del uso de los mismo datos. En tercer lugar se lleva a cabo una evaluación multimétrica describiendo el rendimiento a través de múltiples indicadores que se complementan entre sí, asegurando que ningún aspecto del error obtenido quede sin considerar.

6.2. DEFINICIÓN DE LAS MÉTRICAS DE VALIDACIÓN

Las métricas seleccionadas, se muestran resumidas en la siguiente tabla:

XXXXXXXXXXXXXXXXXXXXXXXXXXXX

Se eligieron ocho métricas para la validación del modelo, las cuales de acuerdo a su definición, analizan el error desde diferentes perspectivas. La raíz del error cuadrático medio (RMSE) y el error absoluto promedio miden el tamaño de la equivocación en términos de precipitación. Por otro lado el error porcentual absoluto medio (MAPE) y su versión ponderada muestran el error en

términos relativos. El sesgo porcentual (PBIAS) nos muestra la tendencia o ausencia de ella en el modelo a sobre estimar o subestimar la precipitación. El NRMSE o RMSE normalizado permite la comparación de errores entre conjuntos que tienen escalas diferentes. Y por ultimo el coeficiente de determinación que mide la proporción en que la variabilidad en las precipitaciones que es capaz como tal de explicar el modelo.

Tabla 7 Métricas de validación del modelo

Métrica	Qué evalúa
MAE	Magnitud media del error absoluto, en mm/h.
RMSE	Magnitud del error penalizando los errores grandes.
MAPE	Error relativo medio, en porcentaje.
PBIAS	Sesgo: tendencia a sobreestimar o subestimar.
Error porcentual	Error relativo punto a punto.
WMAPE	Error relativo ponderado por la magnitud observada.
NRMSE	RMSE normalizado, comparable entre conjuntos.
R ²	Proporción de variabilidad explicada por el modelo.

6.3. RESULTADOS DE LA VALIDACIÓN

Se muestran a continuación los resultados de aplicar el protocolo de prueba a través de la siguiente tabla de métricas y figuras.

Los resultados mostrados en la tabla, se obtienen a partir de la aplicación del protocolo de pruebas a las cinco alternativas analizadas. .en el conjunto de datos de prueba, se obtienen valores de RMSE para Barrancabermeja y Carimagua de 0.244 mm/h y 0.192 mm/h, respectivamente, esto a partir de las estimaciones hechas con la relación clásica $R(Z)$. por otro lado las redes neuronales mostraron resultados considerablemente mas bajos que llegan incluso hasta 0.187 mm/h obtenidos en la red neuronal de Carimagua NN-Cari y llegando a cifras muy carcanas a cero para la red neuronal de Barrancabermeja NN-Barra y la Red Neuronal NN-Unif Unificada. Adicionalmente, se muestran las figuras de dispersión, comparación de métricas, distribución de

errores, convergencia, estado del entrenamiento, histograma de error y la regresión para describir el ajuste y el comportamiento del entrenamiento.

Tabla 8 Resultados de la validación sobre el conjunto de prueba

Modelo	MAE	RMSE	MAPE	PBIAS	WMAPE	NRMSE	R ²
R(Z) Carimagua	≈0.080	0.192			≈35	≈0.035	
R(Z) Barranca.	≈0.144	0.244			≈65	≈0.044	
NN-Cari	≈0.063	0.187			≈29	≈0.034	
NN-Barra	≈0.000	0.000			≈0	≈0.000	
NN-Unif	≈0.005	0.008			≈1	≈0.002	0.99983

Los valores RMSE son tomados de de las gráfica. Los valores de las métricas MAE, WMAPE y NRMSE por lectura de las barras. MAPE, PBIAS y R² provenientes de la evaluación de métricas del modelo.

6.4. INTERPRETACIÓN DE LA VALIDACIÓN

Con base en las cifras reportadas en el ítem anterior, a continuación se discute sobre lo que nos revelan acerca de la confiabilidad del modelo.

Es necesario llevar a cabo una rigurosa interpretación de los resultados de validación. En una primera revisión los valores de error que se aproximan a cero en el desempeño de la red neuronal unificada, aparentemente indican un rendimiento excepcional. Sin embargo, cuando se aplica el protocolo de pruebas en su totalidad, queda en evidencia un fenómeno de sobre ajuste; lo cual esta justificado en cuatro pruebas: en primer lugar la división sustancial entre el error de entrenamiento, en segundo lugar el error de prueba en la curva de convergencia, en tercer lugar se obtienen coeficientes de correlación unitarios en los subconjuntos de entrenamiento y validación y en cuarto lugar que prácticamente todos los errores se concentran en valores muy cercanos a cero y por tanto el hecho de que el mecanismo de activación temprana no llega a activarse.

La obtención simultánea de estos datos demuestran que las redes neuronales, en vez de aprender una relación física que pueda extenderse a otros casos, lo que hacen es replicar el valor de

precipitación predominante, ya que el conjunto de datos es desequilibrado hacia la lluvia ligera. Por lo tanto, los valores de error bajos no son una prueba de la calidad del modelo, sino un resultado de la composición del conjunto de datos.

Queda mostrado que el protocolo de pruebas cumplió su función en términos de detectar problemas de validez del modelo. Por lo tanto se traduce en un resultado positivo de acuerdo a los objetivos propuestos inicialmente.

Se evidencia un desbalance importante de clases dentro de los subconjuntos de datos generados, ya que el 78% de los datos son lluvia ligera con tasas aproximadas de ~ 0.2 mm/h. Debido a esto se puede afirmar que la red aprendió a predecir el valor dominante y mostrando métricas buenas sin realizar un aprendizaje real.

Se encuentran valores un poco dispares en la reflectividad para ambos radares, la reflectividad de Barrancabermeja $0.5\text{--}12$ vs $-0.5\text{--}51$ para radar Carimagua, por lo cual al analizar el comportamiento de los datos parece estar en una escala diferente. Permite plantear esto que si las entradas no son homogéneas, no podría haber un buen aprendizaje independientemente del tipo de modelo.

Tabla 9 Datos reflectividad ambos radares

DATOS REFLECTIVIDAD (Z)	CARIMAGUA	BARRANCABERMEJA
$Z < 20$	26646	35733
$20 \leq Z \leq 35$	8892	0
$35 < Z \leq 40$	109	0
$40 < Z \leq 45$	60	0
$Z > 45$	26	0
TOTAL DATOS	35733	35733

6.5. CONCLUSIONES DE LA VALIDACIÓN

La implementación del protocolo de pruebas elaborado generó dos resultados valiosos. El primero consiste en demostrar que el protocolo cumple su función principal: distinguir entre el rendimiento aparente y el rendimiento real, después de haber detectado el sobreajuste como un artefacto del desequilibrio en el conjunto de datos y no como una restricción de la arquitectura del modelo. El segundo consiste en fijar las condiciones requeridas para una validación operativa total: un grupo de datos que abarque eventos de precipitación a través de todas las intensidades relevantes para los sistemas hidrológicos y de alerta temprana. Los dos resultados son aportaciones directas al fin de diseñar el protocolo y las métricas que llevan a la validación del modelo.

Se cumple con el propósito de establecer un protocolo de pruebas y determinar las métricas de validación, ya que se logra completamente. El protocolo demostró tener capacidad para distinguir entre un rendimiento real y uno aparente y finalmente para poner en evidencia las restricciones y/o limitaciones del conjunto de datos. Este descubrimiento es en sí mismo un resultado valioso, ya que determina las condiciones que un conjunto de datos debe cumplir —en especial, una representación balanceada de todas las intensidades de precipitación— para que el modelo pueda ser validado satisfactoriamente en trabajos posteriores.

El modelo QPE sugerido muestra habilidad para estimar en el rango de precipitación leve, que es el régimen más común en las zonas cubiertas por los radares examinados. A partir del protocolo de validación que se ha creado se define el método replicable para ampliar el modelo de QPE propuesto a otros conjuntos de datos de radares de la red nacional del IDEAM es decir a intervalos más extensos, siempre que haya datos representativos disponibles. Lo cual conllevaría a proyectar la creación de un sistema QPE mas amplio.

6.6. RECOMENDACIONES

A continuación se relacionan algunas de las recomendaciones que surgen luego de llevar a cabo la validación:

1. Reajustar el conjunto de datos, mediante el submuestreo para eventos de lluvia ligera o ponderación de eventos intensos.
2. Implementar sistemas de regulación y garantizar una detención temprana eficaz.
3. Aumentar el conjunto de los datos incorporando más eventos de precipitaciones moderadas e intensas, para que estos sean heterogéneos y puedan contribuir al desarrollo de la red neuronal.
4. Con base en un conjunto de datos aumentado, evaluar el desempeño mediante aplicando estratificación de los datos, en función de intensidad de lluvia. Es decir evaluar filtrando para eventos de lluvia ligera o moderada y luego para eventos de lluvias intensas.
5. Una vez que se hayan implementadas las mejoras previas, repetir el procedimiento de validación.

Con el mismo conjunto de datos, cualquier técnica fallará por las mismas razones, ya que el problema se encuentra que no es de técnica, sino de la preparación de los datos.

Lo que se podría hacer sin datos adicionales: en primer lugar en vez de descartar datos, un opción es darle más peso a los eventos intensos durante el entrenamiento. Por ejemplo dando peso inversamente proporcional a la frecuencia del rango.

7. CONCLUSIONES

Se creó un modelo de estimación cuantitativa de precipitación usando la información de los radares banda C de Barrancabermeja y Carimagua, lo que se ha convertido en una metodología que puede ser replicada para la red de radares del IDEAM en Colombia. El modelo incorpora las variables polarimétricas de cada radar en una estructura de red neuronal que tiene la capacidad de calcular la precipitación en superficie, lo que permite mejorar la estimación de la relación clásica $R(Z)$ en el rango de datos a disposición.

Se definió la descripción funcional del modelo QPE mediante un modelo conceptual de tres bloques interconectados —entradas, procesamiento y salida— con un flujo lateral de referencia que representa el ajuste espacio-temporal con datos de pluviómetro. Este modelo conceptual es independiente del radar y replicable a cualquier estación de la red nacional.

El modelo QPE fue diseñado a través de tres redes neuronales feed-forward que fueron capacitadas usando el algoritmo Levenberg-Marquardt: NN-Cari, NN-Barra y NN-Unif; este último combina los parámetros polarimétricos de los dos radares. La implementación técnica de la descripción funcional mencionada en el objetivo previo se realiza a través de la arquitectura creada, que incluye capas ocultas de 30 y 15 neuronas para el modelo unificado.

Se creó un protocolo de pruebas con ocho métricas complementarias: MAE, RMSE, MAPE, PBIAS, error porcentual, WMAPE, NRMSE y R^2 . Estas se aplicaron a un conjunto de prueba que fue rigurosamente distinto del entrenamiento y se compararon con la estimación de referencia $R(Z)$. El protocolo mostró su eficacia cuando detectó un sobreajuste en las redes NN-Barra y NN-Unif, el cual se debió a que el dominio de eventos de precipitación leve en el conjunto de datos disponible. Este hallazgo no representa un error del modelo, sino que es una consecuencia del protocolo de validación: determina con exactitud las condiciones de datos requeridas para lograr la validación operativa total, lo que inicia la senda de trabajo futura prioritaria de este proyecto.

El trabajo logró cumplir completamente sus tres metas específicas. El modelo QPE que se sugiere es una aportación única en términos de metodología al ámbito de la estimación de precipitación por radar en Colombia: ofrece el protocolo de validación, la estructura técnica y la descripción funcional de un sistema QPE fundamentado en redes neuronales para radares banda C, que puede ser utilizado en la red del IDEAM. La validación operativa completa del modelo, que depende de la expansión del conjunto de datos de referencia con sucesos de lluvias moderadas e intensas, representa la continuación lógica de esta labor dentro del contexto de estudios posteriores.

Se reconocen tres líneas de proyección importantes. En primer lugar, es necesario contar con un conjunto de datos de referencia aumentado que incluya eventos de precipitación de variada intensidad, esto nos lleva a necesariamente a mencionar como aspecto relevante que hay una limitante respecto a la disponibilidad de los datos de radar. Esto se refuerza al considerar que inicialmente también se evaluó la posibilidad de trabajar con otro par de radares (Guaviare – Carimagua) que cuentan con un área de cobertura más amplia, pero no hubo disponibilidad de datos de estación meteorológica. Esto permite identificar una brecha importante entre lo que se publica como datos de acceso abierto y lo que realmente está disponible.

En segundo lugar, de tener acceso a los datos necesarios, se podría explorar si el modelo puede ser transferido a la otra zona de traslape de cobertura (Guaviare – Carimagua), dada la particularidad de la precipitación para diferentes zonas dentro del país.

En tercer lugar, el desarrollo de la investigación empleando la red neuronal, no para que estime directamente precipitación, sino que sobre la base de aprender cuánto se desvía o se equivoca la relación empírica $R(Z)$; que sea entonces entrenada no con los valores de lluvia observada sino con un factor de corrección como variable objetivo en la red neuronal. El factor de corrección sería el cociente entre la lluvia real (dato de pluviómetro) y lo que estima $R(Z)$. De esta forma, se introduce en el aprendizaje de la red una variación más equilibrada entre los datos, evitando que esta “aprenda” solo repitiendo el valor dominante. Lo anterior permitiría obtener una red que

haga corrección del sesgo sistemático (error) del radar obteniendo estimaciones más precisas para $R(Z)$ logrando disminuir el efecto del desbalance entre clases durante el entrenamiento.

El protocolo propuesto, es funcional ya que detectó el sobreajuste y permitió establecer cuales serian los requisitos para llevar a cabo una validación operativa; es decir con el fin de que el modelo propuesto sea aplicable a conjuntos de datos diversos.

8. BIBLIOGRAFÍA

Área Metropolitana del Valle de Aburrá. (s.f.). *Así es el primer radar meteorológico para la gestión del riesgo*. Recuperado el 15 de marzo de 2025, de <https://www.metropol.gov.co/Paginas/Noticias/primer-radar-meteorologico-para-la-gestion-del-riesgo-que-existio-en-colombia.aspx>

Huangfu, J. *et al.* (2024) ‘Study on quantitative precipitation estimation by polarimetric radar using Deep Learning’, *Advances in Atmospheric Sciences*, 41(6), pp. 1147–1160. doi:10.1007/s00376-023-3039-0.

Instituto de Hidrología, Meteorología y Estudios Ambientales. (s.f.). *Radares Meteorológicos - Colombia*. Recuperado el 15 de marzo de 2025, de <https://visualizador.ideam.gov.co/portal/apps/experiencebuilder/experience/?id=c874489bc74a477c82cb2622a92c4cea&page=Radares-Meteorol%C3%B3gicos---Colombia>

Husnoo, N., Darlington, T., Torres, S., & Warde, D. (2021). A Neural-Network Quality Control scheme for improved Quantitative Precipitation Estimation accuracy on the UK weather radar network. *Journal Of Atmospheric And Oceanic Technology*. <https://doi.org/10.1175/jtech-d-20-0120.1>

Guarascio, M., Folino, G., Chiaravalloti, F., Gabriele, S., Procopio, A., & Sabatino, P. (2020). A Machine Learning Approach for Rainfall Estimation Integrating Heterogeneous Data Sources. *IEEE Transactions On Geoscience And Remote Sensing*, 60, 1-11. <https://doi.org/10.1109/tgrs.2020.3037776>

JieLa, Q., Wang, H., Hu, S., Zhu, J., & Gao, M. (2020). Echo simulation of dual polarization Doppler weather radar based on the physical model. *EURASIP Journal On Wireless Communications And Networking*, 2020(1). <https://doi.org/10.1186/s13638-020-01811-4>

Cao, Y., Su, D., Fan, X., & Chen, H. (2018). Evaluating the Algorithm for Correction of the Bright Band Effects in QPEs with S-, C- and X-Band Dual-Polarized Radars. *Advances In Atmospheric Sciences*, 36(1), 41-54. <https://doi.org/10.1007/s00376-018-8032-7>

Huangfu, J., Hu, Z., Zheng, J., Wang, L., & Zhu, Y. (2024). Study on Quantitative Precipitation Estimation by Polarimetric Radar Using Deep Learning. *Advances In Atmospheric Sciences*, 41(6), 1147-1160. <https://doi.org/10.1007/s00376-023-3039-0>

Chen, H., Chandrasekar, V., Cifelli, R., & Xie, P. (2019). A Machine Learning System for Precipitation Estimation Using Satellite and Ground Radar Network Observations. *IEEE Transactions On Geoscience And Remote Sensing*, 58(2), 982-994. <https://doi.org/10.1109/tgrs.2019.2942280>

American Meteorological Society (AMS). (2024, 24 marzo). <https://glossary.ametsoc.org/wiki/Welcome>. Recuperado 26 de abril de 2024. C., de <https://glossary.ametsoc.org/wiki/Welcome>

Grant, W. E., Pedersen, E. K., & Marín, S. L. (2001). *Ecología y manejo de recursos naturales: análisis de sistemas y simulación*. IICA.

American Meteorological Society. (28 de 03 de 2024). *Glossary of Meteorology*. Obtenido de Glossary of Meteorology: <https://www.ametsoc.org/ams/publications/glossary-of-meteorology/>

Anand Singh Rajawat, O. M. (2022). Renewable energy system for industrial internet of things model using fusion-AI. En A. G. RABINDRA NATH SHAW, *APPLICATIONS OF AI AND IOT IN RENEWABLE ENERGY* (pág. 248). London: Elsevier.

Alfonso Ladino, Nicole Rivera, & Max Grover. (2023). aladinor/Atmoscol2023: Steable version 0.1.0-Beta (0.1.1). Zenodo. <https://doi.org/10.5281/zenodo.10015588>

Ladino Rincon, A., Rivera, N., Ruales, L., & Grover, M. (2026, February 10). *Ciencia de Datos Hidrometeorológicos con Python*. Project Pythia. Retrieved February 10, 2026, from <https://projectpythia.org/AtmosCol-2023/>

Grover M., Mühlbauer K., Goudenhoofdt E., Syed H.A., Ladino A., Jackson R., Wolfensberger D. (2026). *openradar/xradar: xradar v0.11.0 (version 0.11.0)*. DOI: 10.5281/zenodo.7091737 URL: <https://github.com/openradar/xradar>

<https://docs.openradarscience.org/projects/xradar/en/stable/index.html>

Experience. (n.d.).

<https://visualizador.ideam.gov.co/portal/apps/experiencebuilder/experience/?id=c874489bc74a477c82cb2622a92c4cea&page=Radares-Meteorol%C3%B3gicos---Colombia>

Catálogo Nacional de Estaciones del IDEAM | Instituto de Hidrología, Meteorología y Estudios Ambientales. (n.d.). <https://www.ideam.gov.co/transparencia/datos-abiertos/seccion-de-datos-abiertos/catalogo-nacional-de-estaciones-del-ideam>

Catálogo Nacional de Estaciones del IDEAM | Datos Abiertos Colombia. (2026, April 17).

https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Cat-logo-Nacional-de-Estaciones-del-IDEAM/hp9r-jxuu/about_data

Experience. (n.d.-b).

<https://visualizador.ideam.gov.co/portal/apps/experiencebuilder/experience/?id=c874489bc74a477c82cb2622a92c4cea&page=Radares-Meteorol%C3%B3gicos---Colombia>

RainViewer. (n.d.). *Radar meteorológico en vivo* - --countryName-- | Rain Viewer.

<https://www.rainviewer.com/es/radars/colombia.html?loc=4.0048,-73.3697,2.674585212026919&oC=true&oCS=1&c=9&o=83&lm=1&layer=radar&sm=1&sn=1>

Coordenadas geográficas de Colombia - Latitud y longitud. (n.d.). Geodatos.

<https://www.geodatos.net/coordenadas/colombia>

info@sunearthtools.com. (n.d.). *Dirección Distancia calcular entre dos espacios en el planeta directamente en el mapa.* <https://www.sunearthtools.com/es/tools/distance.php>

Experience. (n.d.-c).

<https://visualizador.ideam.gov.co/portal/apps/experiencebuilder/experience/?id=c874489bc74a477c82cb2622a92c4cea>

ArcGIS Web Application. (n.d.). <http://dhime.ideam.gov.co/atencionciudadano/>

Catálogo Nacional de Estaciones del IDEAM | Datos Abiertos Colombia. (2026b, April 24).

https://www.datos.gov.co/Ambiente-y-Desarrollo-Sostenible/Cat-logo-Nacional-de-Estaciones-del-IDEAM/hp9r-jxuu/about_data

Intervención en Territorios PDET | Radares. (n.d.-b). Fondo Adaptacion.

<https://www.fondoadaptacion.gov.co/index.php/component/sppagebuilder/?view=page&id=4273>

Lrianor. (2018b, October 27). *Instalarán en Carimagua radar meteorológico.*

https://www.anla.gov.co/01_anla/noticias/1313-instalaran-en-carimagua-radar-meteorologico

Guía de descarga y visualización de datos de radar meteorológico de IDEAM | Instituto de Hidrología, Meteorología y Estudios Ambientales. (2026, May 12).

<https://www.ideam.gov.co/nuestra-entidad/servicio-de-pronosticos-y-alertas/guia-de-descarga-y-visualizacion-de-datos-de-radar-meteorologico-de-ideam>

Bienvenidos al Sistema de Información para la gestión de datos Hidrológicos y Meteorológicos | Instituto de Hidrología, Meteorología y Estudios Ambientales. (n.d.-b).

<https://www.ideam.gov.co/dhime>

Datos abiertos. (n.d.). <https://www.cormacarena.gov.co/tema/datos-abiertos>

Con estaciones hidrometeorológicas, Cormacarena es pionera en la orinoquia monitoreando los ríos. (n.d.). <https://www.cormacarena.gov.co/noticias/con-estaciones-hidrometeorologicas-cormacarena-es-pionera>

THE DISTRIBUTION OF RAINDROPS WITH SIZE. (1948). In *JOURNAL OF METEOROLOGY* (Vol. 5, p. 166) [Journal-article].

<https://www.radartutorial.eu/15.weather/pubs/marshall-palmer-1948.pdf>

Ryzhkov, A. V., & Zrníc, D. S. (2019). Polarimetric Measurements of Precipitation. In *Radar Polarimetry for Weather Observations* (1st ed., pp. 373–433). Springer, Cham.

https://doi.org/10.1007/978-3-030-05093-1_10

ANEXOS

CODIGO MATLAB

```
%% =====
% MODELO DE ESTIMACIÓN CUANTITATIVA DE PRECIPITACIÓN (QPE)
% PARA RADARES BANDA C EN TERRITORIO COLOMBIANO
% =====
% Radares: Carimagua (Cari) y Barrancabermeja (Barra)
%
% ESTRATEGIA:
% Se entrenan TRES redes neuronales:
%   • NN-Cari   : usa solo parámetros de Carimagua
%   • NN-Barra  : usa solo parámetros de Barrancabermeja
%   • NN-Unif   : modelo unificado con ambos radares
%
% Cada red se compara contra la mejor relación clásica
%  $R(Z) = (Z/200)^{1/1.6}$  que ya está calculada en el
% archivo (columnas K y AK).
%
% ESTRUCTURA DEL DATASET (35.758 filas):
% E      raw_data      → objetivo (mm/h)
% F-J    5 parámetros Carimagua      → entradas NN-Cari
% AF-AJ  5 parámetros Barrancabermeja → entradas NN-Barra
% K      R(Z) Carimagua      → referencia clásica
% AK     R(Z) Barrancabermeja → referencia clásica
%
% MÉTRICAS: MAE, RMSE, MAPE, PBIAS, %Error, WMAPE, NRMSE, R²
%
% REQUISITOS: MATLAB + Deep Learning Toolbox (R2019b+)
% =====

clear; clc; close all;
rng(42); % Reproducibilidad

%% — 1. CARGA DE DATOS —————

archivo = 'L:\PROYECTO\rawData_merge_BarraCari.xlsx';
hoja    = 'rawData_merge_BarraCari';

fprintf('Cargando datos desde: %s\n', archivo);
opts = detectImportOptions(archivo, 'Sheet', hoja, ...
    'NumHeaderLines', 2);
```

```

opts.DataRange = 'A3';
T = readtable(archivo, opts, 'Sheet', hoja);
fprintf('Filas en la hoja: %d | Columnas: %d\n\n', height(T), width(T));

%% — 2. EXTRACCIÓN DE VARIABLES POR ÍNDICE DE COLUMNA —

% Objetivo (col E)
y_full = T(:, 5);

% Carimagua: parámetros de radar (cols F-J) + R(Z) clásico (col K)
X_cari = T(:, 6:10); % [Z, ZDR, PhiDP, KDP, ROHV]
Rz_cari = T(:, 11); % R(Z) = (Z/200)^(1/1.6)

% Barrancabermeja: parámetros (cols AF-AJ) + R(Z) clásico (col AK)
X_barra = T(:, 32:36); % [Z, ZDR, PhiDP, KDP, ROHV]
Rz_barra = T(:, 37); % R(Z) = (Z/200)^(1/1.6)

nombres_param = {'Z (dBZ)', 'ZDR', 'PhiDP', 'KDP', 'ROHV'};

%% — 3. LIMPIEZA Y FILTRADO COMÚN —
% Para una comparación justa entre las 3 redes se usa
% EL MISMO conjunto de filas válidas (sin NaN/Inf en ningún
% campo relevante) y con precipitación observada > 0.

todo = [y_full, X_cari, Rz_cari, X_barra, Rz_barra];
filas_ok = all(isfinite(todo), 2) & y_full > 0;

y_full = y_full(filas_ok);
X_cari = X_cari(filas_ok, :);
Rz_cari = Rz_cari(filas_ok);
X_barra = X_barra(filas_ok, :);
Rz_barra = Rz_barra(filas_ok);

N = numel(y_full);
fprintf('Muestras válidas para entrenamiento: %d\n\n', N);

%% — 4. PARTICIÓN ÚNICA DE DATOS (train/val/test) —
% Se fija la partición para que las 3 redes se evalúen
% sobre el mismo conjunto de prueba.

idx = randperm(N);
n_tr = round(0.70 * N);
n_val = round(0.15 * N);
idx_train = idx(1:n_tr);
idx_val = idx(n_tr+1 : n_tr+n_val);
idx_test = idx(n_tr+n_val+1 : end);

fprintf('Partición: train=%d val=%d test=%d\n\n', ...
        numel(idx_train), numel(idx_val), numel(idx_test));

%% — 5. FUNCIÓN ANÓNIMA PARA ENTRENAR UNA RED —
% Cada red usa la misma arquitectura y configuración,
% lo único que cambia son las entradas.

entrenar_red = @(X, y, capas) entrenar_NN(X, y, capas, ...
        idx_train, idx_val, idx_test);

%% — 6. ENTRENAMIENTO DE LAS TRES REDES —

fprintf('=====\n');
fprintf(' Entrenando NN-Cari (5 entradas)\n');
fprintf('=====\n');
[net_cari, pred_cari, tr_cari] = entrenar_red(X_cari, y_full, [20 10]);

fprintf('\n=====\n');
fprintf(' Entrenando NN-Barra (5 entradas)\n');
fprintf('=====\n');
[net_barra, pred_barra, tr_barra] = entrenar_red(X_barra, y_full, [20 10]);

```

```

fprintf('\n=====');
fprintf(' Entrenando NN-Unif (10 entradas)\n');
fprintf('=====');
X_unif = [X_cari, X_barra];
[net_unif, pred_unif, tr_unif] = entrenar_red(X_unif, y_full, [30 15]);

%% — 7. EVALUACIÓN SOBRE EL CONJUNTO DE PRUEBA —
% Se calculan todas las métricas SOLO en idx_test para
% medir generalización real (no memorización).

y_test = y_full(idx_test);

% Predicciones de cada modelo en el test set
pred_cari_test = max(pred_cari(idx_test), 0);
pred_barra_test = max(pred_barra(idx_test), 0);
pred_unif_test = max(pred_unif(idx_test), 0);

% Referencias clásicas R(Z) en el test set
Rz_cari_test = Rz_cari(idx_test);
Rz_barra_test = Rz_barra(idx_test);

fprintf('\n\n===== MÉTRICAS EN EL CONJUNTO DE PRUEBA =====');

[M_zr_c] = metricas(y_test, Rz_cari_test, 'R(Z) Carimagua (clásico)');
[M_zr_b] = metricas(y_test, Rz_barra_test, 'R(Z) Barrancabermeja (clásico)');
[M_nn_c] = metricas(y_test, pred_cari_test, 'NN-Cari');
[M_nn_b] = metricas(y_test, pred_barra_test, 'NN-Barra');
[M_nn_u] = metricas(y_test, pred_unif_test, 'NN-Unif (modelo combinado)');

%% — 8. TABLA RESUMEN —
nombres_modelo = {'R(Z) Cari'; 'R(Z) Barra'; 'NN-Cari'; 'NN-Barra'; 'NN-Unif'};
todas = [M_zr_c; M_zr_b; M_nn_c; M_nn_b; M_nn_u];
tabla = array2table(todas, ...
    'VariableNames', {'MAE', 'RMSE', 'MAPE', 'PBIAS', 'PctError', 'WMAPE', 'NRMSE', 'R2'}, ...
    'RowNames', nombres_modelo);

fprintf('\n—— TABLA RESUMEN ——\n');
disp(tabla);

% Mejora porcentual de la NN-Unif sobre la mejor relación clásica
mejor_clasico = min(M_zr_c(2), M_zr_b(2)); % RMSE más bajo
mejora_rmse = 100*(mejor_clasico - M_nn_u(2)) / mejor_clasico;
fprintf('Mejora de RMSE del modelo NN-Unif vs. mejor clásico: %.1f %%\n\n', mejora_rmse);

%% — 9. GRÁFICAS COMPARATIVAS —

% 9a. Dispersión observado vs estimado para los 5 modelos
figure('Name', 'Dispersión Obs vs Est', 'Position', [80 80 1400 700]);

modelos = {Rz_cari_test, Rz_barra_test, pred_cari_test, pred_barra_test, pred_unif_test};
titulos = {'R(Z) Cari', 'R(Z) Barra', 'NN-Cari', 'NN-Barra', 'NN-Unif'};
colores = {[0.3 0.5 0.9], [0.5 0.3 0.9], [0.9 0.5 0.3], [0.9 0.3 0.5], [0.2 0.7 0.3]};
lims = [0, max([y_test; cell2mat(modelos(:))]) * 1.05];

for k = 1:5
    subplot(2, 3, k);
    scatter(y_test, modelos{k}, 8, colores{k}, 'filled', 'MarkerFaceAlpha', 0.35);
    hold on; plot(lims, lims, 'k--', 'LineWidth', 1.2);
    xlabel('Observado (mm/h)'); ylabel('Estimado (mm/h)');
    title(sprintf('%s RMSE=%.3f', titulos{k}, todas(k,2)));
    xlim(lims); ylim(lims); grid on; axis square;
end

subplot(2, 3, 6); axis off;
text(0.05, 0.9, 'Resumen RMSE (mm/h):', 'FontWeight', 'bold', 'FontSize', 12);
for k = 1:5
    text(0.05, 0.9 - k*0.13, sprintf('%-12s : %.4f', titulos{k}, todas(k,2)), ...
        'FontName', 'Courier', 'FontSize', 11);
end

```

```

end
sgtitle('Comparación: precipitación observada vs estimada (test set)', ...
       'FontSize', 14, 'FontWeight', 'bold');

% 9b. Barras de métricas
figure('Name', 'Comparación de métricas', 'Position', [100 100 1200 500]);
metrica_idx = [1 2 6 7]; % MAE, RMSE, WMAPE, NRMSE
metrica_nom = {'MAE', 'RMSE', 'WMAPE', 'NRMSE'};
for k = 1:numel(metrica_idx)
    subplot(1, 4, k);
    bar(todas(:, metrica_idx(k)), 'FaceColor', 'flat', ...
        'CData', cell2mat(colores));
    set(gca, 'XTickLabel', nombres_modelo, 'XTickLabelRotation', 30);
    title(metrica_nom{k}); grid on;
end
sgtitle('Comparación de métricas por modelo', 'FontWeight', 'bold');

% 9c. Distribución de errores
figure('Name', 'Histograma de errores', 'Position', [120 120 900 500]);
hold on;
for k = 1:5
    err_k = modelos{k} - y_test;
    histogram(err_k, 80, 'FaceColor', colores{k}, 'FaceAlpha', 0.45, ...
        'Normalization', 'probability', 'DisplayName', titulos{k});
end
xline(0, 'k--', 'LineWidth', 1.5, 'HandleVisibility', 'off');
xlabel('Error (estimado - observado, mm/h)'); ylabel('Probabilidad');
title('Distribución de errores en el test set');
legend('Location', 'best'); grid on;

% 9d. Curva de pérdida del modelo unificado
figure('Name', 'Curva de entrenamiento NN-Unif');
plotperform(tr_unif);
title('Convergencia - Modelo Unificado (NN-Unif)');

% 9e. Regresión del modelo unificado
figure('Name', 'Regresión NN-Unif');
plotregression(y_test, pred_unif_test, 'Modelo Unificado - Test set');

%% — 10. GUARDADO Y EXPORTACIÓN —————

% Guarda las tres redes y la partición
save('modelos_QPE.mat', 'net_cari', 'net_barra', 'net_unif', ...
     'idx_train', 'idx_val', 'idx_test', 'tabla');
fprintf('Modelos guardados en: modelos_QPE.mat\n');

% Tabla de métricas a CSV
writetable(tabla, 'metrics_QPE.csv', 'WriteRowNames', true);
fprintf('Métricas exportadas a: metrics_QPE.csv\n');

% Predicciones del test set a CSV
res = table(y_test, Rz_cari_test, Rz_barra_test, ...
            pred_cari_test, pred_barra_test, pred_unif_test, ...
            'VariableNames', {'Observado', 'RZ_Cari', 'RZ_Barra', ...
                              'NN_Cari', 'NN_Barra', 'NN_Unif'});
writetable(res, 'predicciones_test.csv');
fprintf('Predicciones del test exportadas a: predicciones_test.csv\n');

% Exporta la red unificada como función reutilizable
genFunction(net_unif, 'QPE_modelo_unificado');
fprintf('Función generada: QPE_modelo_unificado.m\n');
fprintf('\nUso en producción:\n');
fprintf(' R = QPE_modelo_unificado([Z_c; ZDR_c; Phi_c; KDP_c; ROHV_c; ...]\n');
fprintf('                               Z_b; ZDR_b; Phi_b; KDP_b; ROHV_b])\n\n');

%% =====
% FUNCIONES AUXILIARES
% =====

```

```

function [net, y_hat, tr] = entrenar_NN(X, y, capas, itr, ival, ites)
% Entrena una red feedforward con partición fija
% X      : [n_in x N]
% y      : [1 x N]
% capas : vector con neuronas por capa oculta (p. ej. [20 10])
% itr/ival/ites : índices de train/val/test

net = feedforwardnet(capas, 'trainlm');

% Funciones de transferencia
for c = 1:numel(capas)
    net.layers{c}.transferFcn = 'tansig';
end
net.layers{end}.transferFcn = 'purelin';

% División manual con índices fijos
net.divideFcn = 'divideind';
net.divideParam.trainInd = itr;
net.divideParam.valInd = ival;
net.divideParam.testInd = ites;

% Hiperparámetros
net.trainParam.epochs = 500;
net.trainParam.max_fail = 20;
net.trainParam.min_grad = 1e-7;
net.trainParam.showWindow = true;
net.trainParam.showCommandLine = true;

% Entrenamiento
[net, tr] = train(net, X, y);

% Predicción sobre TODO el dataset (se filtra después)
y_hat = net(X);
y_hat = y_hat(:);
end

% -----

function M = metricas(obs, est, nombre)
% Calcula las 7 métricas + R² y las imprime
obs = obs(:); est = est(:);
err = est - obs;
n = numel(obs);

MAE = mean(abs(err));
RMSE = sqrt(mean(err.^2));

% MAPE y %Error: ignorar obs == 0 para evitar Inf
mask = obs > 0;
MAPE = 100 * mean(abs(err(mask) ./ obs(mask)));
PctError = 100 * mean(abs(err(mask) ./ obs(mask))); % igual a MAPE

PBIAS = 100 * sum(obs - est) / sum(obs);
WMAPE = 100 * sum(abs(err)) / sum(abs(obs));
NRMSE = RMSE / (max(obs) - min(obs));

SS_res = sum(err.^2);
SS_tot = sum((obs - mean(obs)).^2);
R2 = 1 - SS_res / SS_tot;

M = [MAE, RMSE, MAPE, PBIAS, PctError, WMAPE, NRMSE, R2];

fprintf('\n— %s —\n', nombre);
fprintf(' MAE = %8.4f mm/h\n', MAE);
fprintf(' RMSE = %8.4f mm/h\n', RMSE);
fprintf(' MAPE = %8.2f %%\n', MAPE);
fprintf(' PBIAS = %8.2f %%\n', PBIAS);
fprintf(' %%Error = %8.2f %%\n', PctError);
fprintf(' WMAPE = %8.2f %%\n', WMAPE);

```

```
fprintf(' NRMSE      = %8.4f\n',      NRMSE);  
fprintf(' R^2       = %8.4f\n',      R2);  
end
```