



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**

Modelo predictivo de temperatura en invernaderos basado en sistemas de inferencia difusa y técnicas de optimización

Trabajo de investigación/grado para optar el título de
Magíster en Ciencias de la Información y las Comunicaciones

Jonathan Steven Capera Quintana

Director: Julio Barón Velandia
Codirector: Sebastian Camilo Vanegas Ayala

Bogotá D. C. – Colombia
Mayo de 2026

RESUMEN

La presente propuesta de investigación aborda la problemática de predicción de temperatura en invernaderos a través de sistemas de inferencia difusa y la aplicación de técnicas de optimización. Lo anterior tiene como objetivo proponer un modelo basado en características altas de interpretabilidad y precisión que pueda apoyar el diseño de sistemas de control, mejorando la experiencia de los usuarios que brindan mantenimiento a cultivos en ambientes tipo invernadero.

PALABRAS CLAVE

Invernaderos, Optimización, Predicción, Sistema de Inferencia difusa, Temperatura.

Índice general

1. INTRODUCCIÓN	6
2. PROBLEMA DE INVESTIGACIÓN	7
2.1. PLANTEAMIENTO DEL PROBLEMA	7
2.2. FORMULACIÓN DEL PROBLEMA	8
2.3. SISTEMATIZACIÓN DEL PROBLEMA	8
3. OBJETIVOS	9
3.1. OBJETIVO GENERAL	9
3.2. OBJETIVOS ESPECÍFICOS	9
4. JUSTIFICACIÓN	10
4.1. JUSTIFICACIÓN TEÓRICA	10
4.2. JUSTIFICACIÓN METODOLÓGICA	10
4.3. JUSTIFICACIÓN PRÁCTICA	11
5. MARCO DE REFERENCIA	12
5.1. MARCO TEÓRICO	12
5.1.1. Descripción del balance energético al interior de un invernadero	12
5.1.2. Modelado térmico del ambiente interno de un invernadero aplicando técnicas de inteligencia artificial	14
5.2. MARCO CONCEPTUAL	17
5.2.1. Sistemas de inferencia difusa	18
5.2.2. Algoritmos Genéticos	19
5.2.3. Algoritmos Cuasi-Newton	20
6. HIPÓTESIS	22
7. METODOLOGÍA	23
7.1. FASE DE OBSERVACIÓN Y ANÁLISIS	23
7.1.1. Actividades planeadas	23
7.2. FASE DE DISEÑO E IMPLEMENTACIÓN	23
7.2.1. Actividades planeadas	24
7.3. FASE DE ANÁLISIS Y EVALUACIÓN DE RESULTADOS	24

7.3.1. Actividades planeadas	24
8. ALCANCES Y LIMITACIONES	26
9. DESARROLLO DE LA INVESTIGACIÓN	27
9.1. FASE DE OBSERVACIÓN y ANÁLISIS	27
9.1.1. Descripción del dataset	27
9.2. FASE DE DISEÑO E IMPLEMENTACIÓN	28
9.2.1. Modelo basado en sistema de inferencia difusa tipo Mamdani	28
9.2.2. Modelo ANFIS con aprendizaje residual	29
9.3. FASE DE ANÁLISIS Y EVALUACIÓN DE RESULTADOS	30
9.3.1. Modelo ANFIS con aprendizaje residual	30
10. CONCLUSIONES	36
11. RECOMENDACIONES Y TRABAJO FUTURO	37
11.1. RECOMENDACIONES	37
11.2. TRABAJO FUTURO	37
BIBLIOGRAFÍA	38

LISTA DE FIGURAS

9.1.	Comparación temperatura real en comparación con resultado predicción (Fold 1)	. 31
9.2.	Comparación temperatura real en comparación con resultado predicción (Fold 2)	. 32
9.3.	Comparación temperatura real en comparación con resultado predicción (Fold 3)	. 33
9.4.	Comparación temperatura real en comparación con resultado predicción (Fold 4)	. 34
9.5.	Comparación temperatura real en comparación con resultado predicción (Fold 5)	. 35

LISTA DE TABLAS

5.1. Detalles frente a los componentes y supuestos de los modelos que reflejan el balance energético al interior de un invernadero	14
9.1. Variables y parámetros del invernadero	28
9.2. Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 1)	30
9.3. Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 2)	31
9.4. Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 3)	32
9.5. Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 4)	33
9.6. Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 5)	34
9.7. Comparación promedio de desempeño entre el modelo ANFIS y el modelo Baseline	35

1. INTRODUCCIÓN

El principal objetivo del control climático proporcionado por un invernadero es mantener la temperatura interior del ambiente en rangos pertinentes para el desarrollo adecuado de un cultivo (Zhou et al., 2018). El uso de estos sistemas está relacionado con un conjunto de objetivos agrícolas y económicos orientados a: extender la temporada de crecimiento y el cultivo potencial, gestionar las condiciones ambientales con el fin de alcanzar altos estándares de calidad y desarrollar sistemas de bajo costo (Revathi & Sivakumaran, 2016a)

La investigación orientada a la predicción ha sido un factor relevante para determinar el comportamiento y la dinámica del fenómeno de temperatura al interior de un invernadero (Ding et al., 2018). Sin embargo, establecer un modelo matemático para representar estos sistemas se ha convertido en una difícil tarea, dado el rango de complejidad e incertidumbre que posee. En este ámbito, los sistemas de inferencia difusa proveen una gran ventaja al simplificar las relaciones complejas y no lineales, otorgando una mayor comprensión del modelo (Ramdani et al., 2015). Además, el empleo de técnicas de optimización puede mejorar el nivel de precisión de los resultados obtenidos por el sistema de inferencia empleado (Lenka & Mohapatra, 2016) Esta propuesta de investigación busca obtener un modelo para la predicción de la temperatura en invernaderos, utilizando sistemas de inferencia difusa y la aplicación de técnicas de optimización, que apoye el diseño eficiente de estrategias de control para proporcionar a usuarios de invernaderos una solución caracterizada por alta interpretabilidad y precisión.

En las secciones de este documento se presenta el problema de investigación, los objetivos, justificación, marco de referencia, hipótesis, metodología, el impacto y resultados esperados, así como apartados dedicados al establecimiento de recursos y presupuesto, el cronograma de trabajo, posibles limitaciones asociadas a la investigación y las referencias utilizadas.

2. PROBLEMA DE INVESTIGACIÓN

2.1 PLANTEAMIENTO DEL PROBLEMA

El propósito de un invernadero es mejorar el ambiente donde convencionalmente se desarrolla un tipo de cultivo, basado principalmente en la representación artificial de la temperatura interna que se requiere para un crecimiento adecuado (Xu et al., 2020). Se ha evidenciado que la temperatura es un factor clave para obtener un mayor rendimiento en las diferentes etapas de un cultivo, cuya mínima variación puede repercutir en que no se obtengan los resultados requeridos (Zhou et al., 2018), por lo tanto, la configuración de los parámetros del microclima al interior del invernadero es un aspecto de gran importancia para el diseño de estrategias de control (Shamshiri et al., 2020), en donde la predicción se convierte en una gran herramienta para este fin (Castañeda-Miranda & Castaño, 2020).

El ejercicio de predicción se aborda, generalmente, desde dos enfoques: la precisión, que busca evaluar la exactitud del modelo predictivo, en este enfoque se encuentran métodos orientados a redes neuronales artificiales (Nugroho et al., 2017); y la interpretabilidad, definida como la facilidad con que los usuarios pueden entender, analizar y usar apropiadamente la información (OECD, 2018), en donde es posible hallar métodos asociados a sistemas de inferencia difusa (Chen et al., 2016). La carencia de estos factores en un modelo de predicción de temperatura puede tener repercusiones importantes en la identificación del sistema. Por un lado, la falta de precisión, puede ocasionar errores en la predicción realizada que implicarían consecuencias graves en sistemas de control que usan como parámetro de configuración el valor de temperatura otorgado por la predicción del modelo. Por otro lado, la falta de interpretabilidad, puede generar dificultades en la comprensión de la dinámica del sistema, lo que se traduciría en una mayor dificultad para utilizar correctamente los resultados obtenidos a partir de la predicción en la implementación de estrategias de control.

Diferentes metodologías frente a la predicción han sido diseñadas en diversos campos de aplicación, tales como el modelado de retrasos troposféricos (Suparta & Alhasa, 2016) y la identificación de acumulación de sedimentos en el transporte mediante tuberías (Gharabaghi et al., 2019), en las cuales se propone el uso de modelos híbridos como el sistema de inferencia adaptativa neuro-difusa – ANFIS y la aplicación de algoritmos de optimización para sistemas de inferencia difusa. La extrapolación de estas estrategias a la predicción de la temperatura en invernaderos, proporciona balance frente a las condiciones de precisión e interpretabilidad, cuyo fin es brindar un modelo claro y sencillo que represente la dinámica del sistema y pueda apoyar el diseño de medidas de control para el desarrollo de cultivos.

2.2 FORMULACIÓN DEL PROBLEMA

Teniendo en cuenta la descripción de la problemática frente a la forma en la que se realiza la predicción de temperatura en invernaderos, se plantea la siguiente pregunta de investigación: ¿Cómo predecir temperatura en invernaderos manteniendo una alta interpretabilidad y precisión, aplicando técnicas de optimización para sistemas de inferencia difusa?

2.3 SISTEMATIZACIÓN DEL PROBLEMA

Una vez planteada la pregunta de investigación, se procede a presentar las siguientes subpreguntas que hacen parte de la sistematización del problema:

- ¿Cuáles son las características que determinan el comportamiento del fenómeno de temperatura al interior de un invernadero?
- ¿Qué combinación de sistemas de inferencia difusa y técnicas de optimización permite un balance entre precisión e interpretabilidad en el ejercicio de predicción?
- ¿Cómo evaluar la pertinencia de la solución propuesta para la predicción de temperatura en invernaderos?

3. OBJETIVOS

3.1 OBJETIVO GENERAL

Diseñar un modelo para la predicción de temperatura en invernaderos con una alta precisión e interpretabilidad, seleccionando técnicas de optimización y sistemas de inferencia difusa, con el fin de proporcionar una representación clara y funcional del fenómeno de temperatura al interior de un invernadero.

3.2 OBJETIVOS ESPECÍFICOS

- Identificar y caracterizar las variables de entrada que reflejen el comportamiento del fenómeno de temperatura interna de un invernadero, haciendo uso de datos estructurados que garanticen una alta calidad en el resultado de la predicción.
- Proponer y seleccionar entre distintas arquitecturas, un modelo de predicción de temperatura basado en un sistema de inferencia difusa y técnicas de optimización, las cuales permitan complementar el carácter cualitativo de la inferencia realizada.
- Evaluar los resultados obtenidos de los modelos propuestos basándose en pruebas estadísticas considerando su complejidad, para identificar la propuesta que mejor se adapte a las condiciones de precisión e interpretabilidad requeridas.

4. JUSTIFICACIÓN

4.1 JUSTIFICACIÓN TEÓRICA

Para la descripción del fenómeno de temperatura al interior de un invernadero se han propuesto modelos matemáticos que describen el balance de energía térmica a través de factores como: capacidad del aire interno para calentarse, energía contribuida por la radiación solar, energía proveída por el sistema de calefacción, intercambio de calor por procesos de convección e inducción, así como la pérdida de energía por procesos de ventilación e infiltración (Boughamsa & Ramdani, 2018). Adicionalmente, estos procesos de balance térmico se encuentran condicionados a factores como la estacionalidad y los periodos de influencia de radiación solar diaria (Laktionov et al., 2020).

No existe un consenso en la inclusión de ciertos parámetros o variables que hacen parte de la descripción del microclima de un invernadero, esto puede provocar inconvenientes a la hora de establecer criterios mínimos de diseño para el control en un invernadero (Revathi & Sivakumar, 2016b). Se busca proponer un modelo para la predicción de temperatura al interior de un invernadero que pueda establecer una descripción adecuada del aspecto termodinámico, mediante la caracterización de las variables que influyen en la dinámica de temperatura y la definición de un sistema de inferencia que permita realizar el ejercicio de predicción con una alta precisión e interpretabilidad.

4.2 JUSTIFICACIÓN METODOLÓGICA

Con el objetivo de complementar el enfoque de modelado y simulación se han generado técnicas que aprovechan el potencial que brinda el uso de la lógica difusa al otorgar interpretabilidad a los modelos, siendo las más importantes el diseño de sistemas de inferencia difusa, los cuales permiten representar con un alto grado cualitativo, la dinámica y comportamiento de un fenómeno a analizar (Izquierdo & Izquierdo, 2018). Teniendo en cuenta las necesidades frente a una alta precisión e interpretabilidad en la predicción de temperatura en invernaderos, se busca proporcionar un modelo que pueda otorgar veracidad y facilidad de comprensión en la información obtenida. De acuerdo a lo anterior, se espera que el desarrollo en la investigación realizada pueda servir como base a futuras investigaciones enfocadas a refinamientos del modelo propuesto para la predicción de temperatura, su aplicación para el análisis de otros factores que definen el microclima de un invernadero y el apoyo que puede brindar a la implementación de estrategias de control para mejorar la producción en un invernadero.

4.3 JUSTIFICACIÓN PRÁCTICA

La agricultura cumple una función productiva y alimentaria, adicionalmente, se le suman un sin número de funciones sociales, ambientales y económicas, entre las que se encuentran: la producción orgánica, el cuidado del ambiente, la creación de vínculos comunitarios y el desarrollo de procesos educativos ambientales (Calderón Cisneros, 2016), que son una muestra del gran valor que pueden generar los aportes desarrollados en este campo.

El desarrollo tecnológico en la agricultura se ha convertido en un factor determinante para cumplir con la demanda de alimentación en la población, involucrando el uso de tecnologías de cultivo inteligente, aplicaciones y diversas soluciones basadas en la Industria 4.0, que buscan transformar las capacidades de producción del sector agrícola (Charania & Li, 2020). Los invernaderos surgen como una solución para establecer un control en el ambiente que requiere el cultivo durante su desarrollo, por lo cual se ha determinado que la investigación orientada a la predicción, particularmente de la temperatura, ha sido significativa para el diseño eficiente de sistemas de control, que se traducen en una mejora de la calidad y cantidad de producto (Ding et al., 2018).

5. MARCO DE REFERENCIA

5.1 MARCO TEÓRICO

5.1.1 Descripción del balance energético al interior de un invernadero

Para analizar el comportamiento de la temperatura al interior de un invernadero, muchos autores concuerdan en que es posible abordar esta problemática viendo a los invernaderos como sistemas termodinámicos. En este aspecto, los esfuerzos se enfocan en determinar los factores fundamentales en la conservación del balance energético del ambiente interno. Basados en los principios termodinámicos, se han presentado diferentes acercamientos acerca de los componentes que interactúan en el balance energético y se han propuesto diferentes modelos que buscan representar este comportamiento. En (Choab et al., 2019) se recopilan las teorías de diferentes autores en un artículo de revisión, en donde se describen los componentes y supuestos que se consideraron en la construcción de los modelos termodinámicos del ambiente interno de los invernaderos, tal como se presenta en la Tabla 1.

Autores	Componentes que interactúan en el balance energético	Supuestos
(Sethi, 2009)	Plantas, Suelo, Aire cerrado	■ La capacidad de absorción y calor de la radiación solar del aire de invernadero fue despreciada. ■ No había intercambio de calor radiativo entre las construcciones del invernadero. ■ La estratificación de temperatura no se tuvo en cuenta. ■ Las propiedades técnicas de los cultivos fueron las mismas que las del agua.
(Sharma et al., 1999)	Cuatro zonas de aire verticales	■ Las propiedades técnicas de la planta eran equivalentes a las del agua. ■ No se asume estratificación de temperatura y la humedad relativa se considera constante con la altura. ■ Pérdida de calor por conducción a tierra considerada en modo de estado estacionario.

(Jain & Tiwari, 2004)	Dos zonas de aire horizontales	■ No se asume nueva estratificación. ■ La capacidad de absorción de la radiación solar y la capacidad calorífica del aire son despreciables. ■ La capacidad de mantenimiento técnico de la cubierta fue despreciada.
(Cooper & Fuller, 1983)	Medio creciente Suelo Cubierta Aire interno del cultivo	■ Las pérdidas de calor en los bordes fueron insignificantes en comparación con la conducción por el suelo. ■ No se produce condensación en la planta. ■ La cubierta del invernadero era transparente a la radiación de una larga.
(Tiwari et al., 1998)	Plantas Suelo Aire cerrado	■ Las propiedades de la masa vegetal equivalen a las del agua. ■ No se asume estratificación de temperatura y la humedad relativa fue constante con la altura. ■ Se espera la capacidad técnica del aire.
(Su & Xu, 2017)	Cubierta Cultivos Suelo Aire interno	■ El aire interno está bien mezclado ■ El toldo del cultivo es visto como una hoja de gran tamaño
(Mobtaker et al., 2019)	Capa de suelo Cubierta Muro norte Aire	■ La energía de radiación no es absorbida ni emitida por el aire interno.
(Mohammadi et al., 2018)	Superficie del suelo Aire interno Cubierta del techo	■ Los elementos del invernadero se consideran sistemas agrupados. ■ Las temperaturas del aire, cultivo, cobertura y suelo superior son uniformes. ■ No se produce evaporación del suelo. ■ La energía de radiación no es absorbida ni emitida por el aire interno. ■ El agua que se condensa en el lado interior del techo y en la pantalla es eliminada directamente y por lo tanto no está presente el proceso de evaporación.

Tabla 5.1: *Detalles frente a los componentes y supuestos de los modelos que reflejan el balance energético al interior de un invernadero*

5.1.2 Modelado térmico del ambiente interno de un invernadero aplicando técnicas de inteligencia artificial

Una vez descrito el comportamiento de la temperatura al interior de un invernadero desde la perspectiva de un sistema termodinámico, se procede a determinar modelos y técnicas orientadas a realizar la descripción de este fenómeno. Teniendo en cuenta la problemática que surge frente a la complejidad asociada a los modelos matemáticos de sistemas termodinámicos, se analizan modelos relacionados con técnicas y estrategias empleadas en el campo de la inteligencia artificial como las redes neuronales artificiales, la lógica difusa, los sistemas multi input multi output (MIMO) y los algoritmos de optimización.

Sistemas basados en redes neuronales artificiales

Un primer enfoque en cuanto a las técnicas de inteligencia artificial empleadas en el modelado de sistemas termodinámicos es el uso de redes neuronales artificiales, que buscan a través de una representación de entradas, neuronas, pesos y capas, poder reflejar un comportamiento o modelo particular a partir de un aprendizaje generado a través del entrenamiento.

En la investigación realizada por (Castañeda-Miranda & Castaño, 2020), se presentan los resultados de una arquitectura basada en IoT (Internet de las Cosas) para el control inteligente del impacto generado por el congelamiento en invernaderos. En este documento se muestra el análisis de 5 variables independientes: temperatura externa del aire, velocidad del viento, flujo global de radiación solar y humedad relativa interna, cuyos valores son obtenidos a través de un conjunto de sensores, en intervalos de medición de 10 minutos realizados durante un periodo de 365 días. El modelo propuesto busca realizar la predicción de la temperatura interna del invernadero a través de una red neuronal, que usa las variables mencionadas con anterioridad como entradas, y propone el uso de este resultado de predicción para determinar un control del factor de congelamiento sobre el invernadero, por medio de un sistema basado en lógica difusa.

Se pueden encontrar aportes frente al uso de redes neuronales de propagación hacia atrás en la predicción de la temperatura al interior de los invernaderos. En (Ding et al., 2018), se presenta una red neuronal artificial que consta de 3 capas, las cuales siguen una estructura de capas y neuronas 40-14-4, las capas corresponden a una capa de entrada, una capa oculta y una capa de salida. En la capa de entrada se usan datos de medición de 4 variables que corresponden a temperatura del suelo, humedad del suelo, humedad del aire y luz, que corresponden de igual forma a la salida

proporcionada por la red neuronal en su última capa.

Se ha observado el uso conjunto de redes neuronales artificiales (ANN), algoritmos perceptrón multicapa (MLP) y función de base radial (RBF). En (Taki et al., 2018) se describe el procedimiento para seleccionar métodos de entrenamiento para las redes neuronales, tanto para la red perceptrón multicapa como la red de función de base radial. En primer lugar, se normalizan las entradas en valores entre 0 y 1 para asegurar una mejor convergencia de la red de acuerdo a las funciones de activación usadas, se define el número de neuronas por capa y a través del coeficiente de determinación R^2 se escogen los métodos de entrenamiento que ofrecen la mejor convergencia.

La aplicación de análisis de componentes principales (PCA) para identificar componentes principales que sirven como entradas a la red neuronal artificial es una de las estrategias usadas en (Zhao et al., 2015), donde se plantea una estructura de red neuronal artificial basada en la teoría de Kolmogorov para identificar las capas y el número de neuronas por capa, donde se evidencia la estructura 3-7-1 (3 entradas, 7 neuronas en la capa oculta y 1 salida). Posteriormente, se dispone a entrenar la red y hacer uso de la regularización bayesiana para mejorar los resultados entregados por la misma.

Sistemas basados en lógica difusa

Frente a este enfoque se proponen modelos para el control de temperatura en invernaderos a través de sistema de lógica difusa, que hacen uso de mediciones realizadas de la temperatura interna y externa del invernadero para establecer acciones de control sobre un mecanismo de calefacción que pueda regular la temperatura interna de un invernadero (Revathi & Sivakumaran, 2016b). Para ello se define de forma detallada la descripción de la variable de temperatura mediante la identificación de las propiedades presentes en la dinámica de esta característica en los invernaderos, relacionando los conceptos conducción, convección, radiación y los factores que afectan la pérdida de calor al interior del invernadero, así como la determinación de los criterios mínimos de diseño para la temperatura ideal del invernadero.

De acuerdo a análisis realizados frente a la convergencia en el uso de una red neuronal, se identifican problemas frente a la velocidad de entrenamiento, que podían retardar el proceso de predicción. Como resultado se ha propuesto el uso de un método difuso para mejorar el proceso de entrenamiento de la red neuronal, cuyo procedimiento consiste en modificar el tamaño del paso y ajustar los pesos de la red en cada iteración, de acuerdo al grado de planitud de las funciones de activación (Ding et al., 2018). Para esto se definen un conjunto de funciones de pertenencia y de reglas que buscan ajustar los pesos la red para aumentar y acelerar la convergencia durante el entrenamiento.

Con el fin de establecer la diferencia de temperatura que se requiere para el crecimiento adecuado de un cultivo se han planteado esquemas de control difuso que usan puntos de control para tempe-

ratura y humedad establecidos por el usuario y que utilizan el modelo físico involucrado (Maher et al., 2016). Las entradas del controlador difuso son las diferencias en temperatura y humedad que están determinadas por funciones de pertenencia que reflejan valores positivos y negativos, los cuales representan una acción, determinada por un conjunto de reglas, que se refleja en conjuntos difusos de salida con funciones de pertenencia con valores asociados a control nulo, medio o alto.

Los sistemas de lógica difusa basados en el modelo Takagi-Sugeno han sido utilizados en la implementación de metodología de diseño que se centra en la identificación del antecedente y del consecuente en la estructura de una base de conocimiento. Estos son aplicados al diseño de modelos de controlador para regular el microclima de un invernadero mediante la descripción de la humedad y temperatura en su interior (Boughamsa & Ramdani, 2018). En la determinación del antecedente para el sistema de lógica difusa se utilizan algoritmos de clasificación difusa basado en la técnica C-Means para identificar las reglas que influirán en el sistema de control teniendo en cuenta las variables que actúan en el sistema. Adicionalmente, para determinar el consecuente se utiliza el algoritmo recursivo de mínimos cuadrados para resolver un conjunto de ecuaciones lineales que determinan los parámetros del consecuente.

En (Montes Olguín & Rodriguez Jorge, 2017) se propone un esquema de control basado en lógica difusa para regular la temperatura al interior de un invernadero casero que resguarda un cultivo hidropónico de tomates. El control se realiza a través de un conjunto de sensores para medir la temperatura al interior y al exterior del invernadero, y actuadores que se encargan de abrir o cerrar una ventana una cantidad de grados de acuerdo a las mediciones obtenidas.

Para la construcción del controlador difuso se hizo énfasis en el método de inferencia que hace alusión a las etapas de fuzzificación, determinación de reglas de control y defuzzificación que hacen parte del proceso general de construcción de un controlador difuso.

Se resalta la capacidad de los sistemas de lógica difusa para el enfoque de estimación de dinámicas desconocidas. Su aplicación en el control del microclima de un invernadero se ha relacionado con la descripción de modelos que relacionan ecuaciones diferenciales asociadas a procesos de calefacción, humidificación y ventilación (Su et al., 2016).

Sistemas Multi Input Multi Output

Los modelos físicos pueden ser definidos una aproximación a un sistema multivariable de entrada y salida (MIMO) que se basa principalmente en 2 enfoques: el balance de calor y el balance de humedad (Maher et al., 2016). El balance de calor al interior del invernadero está descrito por la capacidad térmica el aire, la radiación solar, la temperatura del suelo y la acción de los mecanismos de calefacción, humidificación y ventilación, procesos físicos que pueden ser modelados a través del enfoque de los sistemas MIMO.

Los sistemas multi-input and multi-output (MIMO) son usados para simplificar los sistemas

térmicos y su uso junto con la aplicación del modelo de lógica difusa Takagi-Sugeno permite describir el balance de energía térmica a través de los siguientes factores: capacidad del aire interno para calentarse, energía contribuida por la radiación solar, energía proveída por el sistema de calefacción, intercambio de calor por procesos de convección e inducción, así como la pérdida de energía por procesos de ventilación e infiltración (Boughamsa & Ramdani, 2018).

En (Su et al., 2016) se presenta un esquema para el control adaptativo difuso de sistemas no lineales/no afines Multi Input Multi Output (MIMO) que presentan dinámicas desconocidas y cuya aplicación se encuentra vinculada a problemas relacionados con el control del microclima al interior de un invernadero. El desarrollo se expone mostrando en primera instancia la forma básica de los problemas no lineales MIMO con $2p$ entradas y p salidas, así como la definición del objetivo de control en este tipo de sistemas.

Sistemas que aplican algoritmos de optimización

Se encuentran propuestas acerca del uso de algoritmos de optimización como el algoritmo de enjambre de partículas (PSO), para determinar la mejor configuración de las funciones de pertenencia que hacen parte de las entradas de un sistema de lógica difusa (Revathi & Sivakumaran, 2016b). Por otro lado, también se evidencia su aplicación en la identificación de parámetros inciertos en el modelado de subsistemas asociados a los procesos de flujo de energía, para ello se aplican algoritmos de optimización como el algoritmo de enjambre de partículas (PSO), el algoritmo de evolución diferencial (DE) y la técnica de algoritmo genético (GA) (Shen et al., 2018).

Los algoritmos de optimización se implementan en modelos de máquina de soporte vectorial en donde algoritmos mejorado de optimización por enjambre de partículas (IPSO) permiten obtener una mejor precisión en la predicción de valores mínimos y máximos de temperatura (Taki et al., 2018).

Adicionalmente, se identifica el uso de estos algoritmos en máquinas de soporte vectorial de mínimos cuadrados que, mediante la ejecución de un proceso de mutación, se definen los parámetros que serán objetivo de optimización por un algoritmo mejorado de enjambre de partículas. (Yu et al., 2016).

5.2 MARCO CONCEPTUAL

Acorde a los objetivos planteados, se propone un esquema de investigación para definir el estado del arte y priorizar los elementos teóricos, que constituyen el insumo para el planteamiento, diseño y desarrollo del proyecto. Se identifican 4 enfoques principales en los que se destaca el análisis de sistemas de inferencia basados en lógica difusa, la aplicación de métodos estocásticos como los algoritmos genéticos y métodos determinísticos como los algoritmos Cuasi-Newton.

5.2.1 Sistemas de inferencia difusa

El lenguaje natural es posiblemente la más poderosa forma de comunicación que poseen los seres humanos para cualquier problema o situación que requiera solución o razonamiento. Este poder no se ha explotado en los paradigmas matemáticos modernos, no tanto como en la lógica difusa (Ross, 2010).

Un sistema difuso consiste en un sistema en el cual los rangos de las variables sobre los cuales representan sus estados (o, al menos, algunas de ellas) se tratan de conjuntos difusos. Para cada variable, los conjuntos difusos son definidos en un algún conjunto difuso que a menudo es un intervalo de números reales y las variables asociadas son variables lingüísticas (Klir & Yuan, 1995).

A continuación, se presentan algunos tipos de sistemas de inferencia difusa más usados:

Sistemas de inferencia difusa MAMDANI

Los sistemas Mamdani están compuestos de múltiples reglas condicionales (IF-THEN), cada una de estas reglas puede pertenecer a distintos conjuntos difusos, los antecedentes y los consecuentes se pueden conectar a través de conectores lógicos “Y” (AND) y “O” (OR) (Izquierdo & Izquierdo, 2018).

Dado que los sistemas de tipo Mamdani cuentan con una base de reglas fácil de comprender e intuitivo, son apropiados para aplicaciones de sistemas expertos donde las reglas son creadas a partir del conocimiento experto humano, como en diagnósticos médicos. Están diseñados para una apropiada entrada de datos para un ser humano y poseen una base de reglas con mayor interpretabilidad. (MathWorks Inc., 2019).

En la Figura 1 se describe el funcionamiento y estructura de un sistema difuso convencional.

Sistemas de inferencia difusa SUGENO

La característica principal de este modelo es su capacidad para expresar la dinámica local de cada regla difusa mediante una expresión de tipo lineal (Mehran, 2008). En el sistema de inferencia difusa Sugeno no existe una función de pertenencia en la salida, ésta se expresa a través de un valor numérico concreto que es calculado multiplicando cada entrada por una constante y, posteriormente, realizando la suma de los resultados correspondientes (Knapp, 2007). En la Figura 2 se puede observar un ejemplo de un sistema de inferencia difusa tipo Sugeno.

Entre las ventajas con las que cuenta un sistema de inferencia difusa tipo Sugeno se puede mencionar su eficiencia a nivel computacional, así como la posibilidad de implementación de técnicas de optimización y técnicas adaptativas (MathWorks Inc., 2019)

Sistemas de inferencia difusa TSUKAMOTO

El sistema de inferencia difusa es un modelo que resulta bastante útil cuando existe incertidumbre, permitiendo otorgar flexibilidad y tolerancia en el análisis de los datos (Adriyendi, 2018). En este tipo de sistema de inferencia difusa el consecuente de cada regla condicional está representado por un conjunto difuso con una función de pertenencia monótona, es decir, las entradas de cada regla son concretas presentando un predicado y obteniendo como resultado final un promedio ponderado (Ariani & Endra, 2013). En la Figura 3 se evidencian las etapas que caracterizan el funcionamiento del sistema de inferencia Tsukamoto.

Sistemas de Inferencia Neurodifusa Adaptativo (ANFIS)

El Sistema de Inferencia Neurodifuso Adaptativo (ANFIS) utiliza un procedimiento de aprendizaje híbrido, donde se construye un mapa de entrada-salida basado tanto en conocimiento humano, así como de pares de entrada y de salida determinados.

Los parámetros de un sistema de inferencia difuso se pueden optimizar automáticamente utilizando un algoritmo. ANFIS es uno de los algoritmos que toma los parámetros del sistema de inferencia difuso y los adapta utilizando redes neuronales (Knapp, 2007a).

Los sistemas ANFIS son usados en la predicción de series de tiempo caóticas, el procesamiento de señales y el modelado de funciones no lineales (Shing & Jang, 1993). La Figura 4 presenta una comparación entre un sistema de razonamiento difuso tipo 1 junto con su homólogo ANFIS tipo 1.

5.2.2 Algoritmos Genéticos

Los algoritmos genéticos son algoritmos basados en los principios de la genética y de la selección natural, en donde se pueden encontrar etapas relacionadas a reproducción, cruzamiento y mutación. En la Tabla 2 se muestran algunas de las características de los algoritmos genéticos (Rao, 2009):

Característica	Descripción
Población	Con número de variables de diseño es n , usualmente el tamaño de la población se toma como $2n$ hasta $4n$. Esto reduce la probabilidad de caer en un mínimo local.
Variables	Las variables de diseño son cadenas binarias y corresponden a cromosomas de la genética.
Función objetivo	La función objetivo corresponde a un vector que calcula el nivel de aptitud o “fitness” en la genética.

Generaciones	En cada generación, un nuevo conjunto de cadenas se produce utilizando selección aleatoria de los padres y cruzamiento de las generaciones anteriores con el objetivo de encontrar una nueva generación con mejor “fitness” o valor de la función objetivo.
--------------	---

Algoritmo Genético Híbrido (HGA)

Este algoritmo surge de la necesidad de encontrar los valores iniciales adecuados para el algoritmo genético, ya que por lo general estos son seleccionados por la intuición y diferentes valores iniciales derivan en diferentes resultados óptimos. La debilidad del algoritmo genético tradicional reside en su dificultad cuando se establecen restricciones al problema, en especial a los problemas con restricciones exactas. El funcionamiento del algoritmo genético híbrido consiste en proveer un conjunto inicial de variables de diseño con el fin de evitar el proceso de prueba, luego se utiliza un método de optimización para hallar un resultado óptimo (Guo et al., 2010)

Algoritmo Genético de Intervalo (Interval Genetic Algorithm - IGA)

En ingeniería no es fácil establecer variables de diseño exactas debido a los errores de medición y adicionalmente porque resulta algo bastante costoso. En el proceso tradicional de optimización de intervalos, el análisis es presentado como una parte del proceso y su objetivo es determinar las cotas superiores e inferiores en el efecto de todos los errores asociados a las variables. Este análisis sirve para comprender la relación entre los parámetros del sistema y su rendimiento, no obstante, la formulación del intervalo no es fácil de construir. En IGA, los parámetros optimizados se pueden obtener y, además, el análisis de intervalo se puede excluir del proceso de optimización (Guo et al., 2010).

Algoritmo Genético Híbrido de Intervalo (Hybrid Interval Genetic Algorithm - HIGA)

En el algoritmo anterior, el error objetivo es calculado de la ecuación formulada. En los sistemas complicados, formular un sistema de ecuaciones que le describa resulta complejo y aun si se puede formular el sistema, es difícil determinar soluciones precisas. Para resolver esto, se combina Algoritmo Genético Intervalo (IGA) con software para la aplicación del método de elementos finitos con el fin de optimizar los intervalos (Guo et al., 2010).

5.2.3 Algoritmos Cuasi-Newton

El método de Newton posee muy buenas propiedades: es extremadamente rápido, al menos una vez llega cerca al mínimo y, con algunas modificaciones se convierte en un método descendiente

que busca un mínimo en vez de puntos críticos generales (Bryan, 2017). No obstante, la contra de utilizar este método es el costo computacional en el que debe incurrirse para solucionar sistemas de ecuaciones no lineales mediante el cálculo de derivadas parciales en un punto y luego solucionar el sistema a través de la matriz jacobiana. Este algoritmo no reutiliza la información de iteraciones previas y la evaluación de las derivadas parciales puede ser costosa a nivel computacional (Lambers, 2011). Para ello, los algoritmos Cuasi-Newton aparecen, son algoritmos que se basan en el método de la secante. Estos algoritmos son iterativos, conllevan una serie de búsquedas lineales y generalmente conllevan cálculo del valor de una función f y su gradiente en cada iteración (Bryan, 2017).

6. HIPÓTESIS

La descripción del balance térmico al interior de un invernadero está sujeta a factores como la capacidad del aire interno para calentarse, la energía contribuida por la radiación solar, la energía proveída por el sistema de calefacción, el intercambio de calor por procesos de convección e inducción, así como la pérdida de energía por procesos de ventilación e infiltración, que determinan el comportamiento de la temperatura a través del tiempo y cuya representación en sistemas de inferencia difusa optimizados permite realizar el ejercicio de predicción con una alta precisión e interpretabilidad.

7. METODOLOGÍA

7.1 FASE DE OBSERVACIÓN Y ANÁLISIS

Esta fase de la investigación se centra en la identificación y caracterización de las variables del modelo de predicción de temperatura. Se basa en los métodos empíricos de observación, medición y experimentación para determinar los datos que servirán como fuente para el reconocimiento de la funcionalidad específica del modelo. Una vez definido el esquema de los datos con los cuales se trabajará, se hace uso de métodos estadísticos pertenecientes a la estadística descriptiva e inferencial para visualizar un acercamiento hacia el comportamiento de los datos y establecer posibles relaciones a través de este análisis.

7.1.1 Actividades planeadas

Teniendo en cuenta los métodos empíricos y estadísticos propuestos se establece la siguiente secuencia de actividades en busca de cumplir con los objetivos planteados:

- Identificar las variables que harán parte del modelo de predicción a través de la observación del comportamiento del fenómeno de temperatura al interior de un invernadero.
- Determinar herramientas y estrategias de recolección de datos que garanticen una fuente fiable de la información y que se caractericen por procesos de medición estructurados.
- Analizar la información recolectada a través del uso de estadística descriptiva para hallar características representativas en las variables seleccionadas para el modelo.
- Identificar a través del uso de estadística inferencial posibles relaciones entre las variables del modelo que puedan ser usadas como base para la elaboración de la estructura del mismo.

7.2 FASE DE DISEÑO E IMPLEMENTACIÓN

En esta etapa se busca definir la estructura del modelo de predicción y establecer la forma en la que se evidenciarán los resultados ofrecidos por el mismo. Se propone el uso de métodos de inducción-deducción que, a partir de la lógica establecida por las relaciones que se puedan evidenciar entre las variables de entrada, permitan establecer un razonamiento válido sobre el comportamiento del fenómeno termodinámico al interior de un invernadero y que, finalmente, pueda proporcionar un modelo que refleje este comportamiento.

En este caso, se analizará, a través de los diferentes fundamentos teóricos hallados en la revisión temática de los trabajos de investigación, un enfoque que pueda evidenciar las relaciones existentes entre las variables de entrada a través del uso de sistemas de inferencia difusa. Posteriormente, teniendo en cuenta las características deseadas frente a precisión e interpretabilidad, se buscarán estrategias de optimización que puedan mejorar los resultados obtenidos.

7.2.1 Actividades planeadas

De acuerdo a los objetivos planteados y el enfoque del método de inducción-deducción propuesto, se establece la siguiente secuencia de actividades:

- Establecer relaciones lógicas entre las variables de entrada y que puedan servir como base para su uso en sistemas de inferencia difusa.
- Identificar los diferentes sistemas de inferencia difusa que pueden ser aplicables dentro de la estructura del modelo y seleccionar el que mejor se adapte a las condiciones de predicción.
- Evaluar la precisión de los resultados y determinar estrategias de optimización que puedan mejorar el ejercicio de predicción.
- Comparar los resultados obtenidos posterior a la implementación de las estrategias de optimización para seleccionar aquellas que reflejen un mejor comportamiento.

7.3 FASE DE ANÁLISIS Y EVALUACIÓN DE RESULTADOS

En la fase final, se analizarán los resultados obtenidos, a través de métodos estadísticos basados en estadística inferencial y técnicas de medición del error, estableciendo un conjunto de pruebas de hipótesis orientadas a establecer la variabilidad entre las muestras recolectadas de mediciones reales y las muestras obtenidas mediante el modelo de predicción. Esto con el fin de evaluar la precisión de los resultados y determinar la efectividad del modelo.

7.3.1 Actividades planeadas

Considerando el objetivo de evaluar los resultados otorgados por el modelo de predicción a través del uso de métodos estadísticos, se propone la siguiente secuencia de actividades:

- Contrastar los resultados obtenidos por la predicción con muestras obtenidas a través de la medición de valores de temperatura reales, que puedan determinar un porcentaje de error en la estimación.

- Plantear un conjunto de pruebas de hipótesis sobre las muestras de la predicción en contraste con los datos reales de medición de temperatura, que puedan brindar una conclusión acerca de la variabilidad de los resultados del modelo.
- Analizar la información otorgada por los porcentajes de medición del error y los resultados de las pruebas de hipótesis para determinar la efectividad del modelo propuesto.

8. ALCANCES Y LIMITACIONES

En la definición del modelo de comportamiento de un invernadero se pueden identificar variables como el nivel de pH del suelo, la radiación UV y el nivel de CO₂, que hacen parte del microclima que presenta el invernadero. Sin embargo, a través de la investigación realizada, se restringe el análisis a la variable de temperatura interna del ambiente que, de acuerdo a la revisión de la literatura, se considera uno de los aspectos más relevantes dentro de la dinámica de un invernadero.

La calidad de la información estará determinada por la fiabilidad de los datos recolectados, que a su vez depende de la calidad de los sensores y dispositivos usados en el proceso de identificación del comportamiento del invernadero a analizar. Adicionalmente, factores como la estacionalidad y cambios en el ambiente debido a la influencia de periodos de radiación solar pueden afectar el rendimiento frente a la precisión de la predicción.

9. DESARROLLO DE LA INVESTIGACIÓN

9.1 FASE DE OBSERVACIÓN y ANÁLISIS

9.1.1 Descripción del dataset

Los datos para el entrenamiento provienen del dataset Autonomous Greenhouse Challenge 2019, con aproximadamente 47,738 registros espaciados en ventanas de 5 minutos.

A continuación se describen las variables relacionadas al comportamiento climático del invernadero:

Encabezado	Descripción del parámetro	Unidad	Intervalo
Tair	Temperatura del aire del invernadero	°C	5 min
Rhair	Humedad relativa del invernadero	%	5 min
CO2air	CO ₂ del invernadero	ppm	5 min
HumDef	Déficit de humedad del invernadero	g/m ³	5 min
VentLee	Apertura de ventilas de sotavento	% [0 a 100]	5 min
Ventwind	Apertura de ventilas de barlovento	% [0 a 100]	5 min
AssimLight	Estado de lámparas HPS (encendido/apagado)	% [0 o 100]	5 min
EnScr	Apertura de cortina térmica	% [0 a 100]	5 min
BlackScr	Apertura de cortina de oscurecimiento	% [0 a 100]	5 min
PipeLow	Temperatura de tubería de riel (circuito inferior)	°C	5 min
PipeGrow	Temperatura de tubería de cultivo (circuito de crecimiento)	°C	5 min
co2_dos	Dosificación de CO ₂	kg/ha hora	5 min
Tot_PAR	PAR total interno (Sol + HPS + LED)	μmol/m ² ·s	5 min
Tot_PAR_Lamps	Suma de PAR proveniente de lámparas HPS y LED	μmol/m ² ·s	5 min
EC_drain_PC	Conductividad eléctrica del drenaje	dS/m	5 min
pH_drain_PC	pH del drenaje	[-]	5 min
Water_sup	Número acumulado de minutos de irrigación en un día	minutos	5 min
Cum_irr	Número acumulado de litros de irrigación en un día	L/m ² día	5 min

Tabla 9.1: *Variables y parámetros del invernadero*

9.2 FASE DE DISEÑO E IMPLEMENTACIÓN

9.2.1 Modelo basado en sistema de inferencia difusa tipo Mamdani

El sistema de inferencia difusa de Mamdani en el código se configura de la siguiente manera:

Variables de entrada (antecedentes):

El modelo utiliza las siguientes características de entrada:

- temp_ext (temperatura externa)
- radiación
- humidity_int (humedad interna)
- leeward_vent
- windward_vent

Cada variable de entrada tiene dos conjuntos difusos: 'bajo' y 'alto'. Estos se definen mediante funciones de pertenencia triangulares.

Variable de salida (consecuente):

La variable objetivo es temp_int (temperatura interna), que también tiene conjuntos difusos 'bajo' y 'alto' definidos por funciones de pertenencia triangulares.

Funciones de pertenencia (FP):

- Para modelo base:

Para todas las entradas y la salida (temp_int), la función de pertenencia 'BAJA' comienza en el valor mínimo, alcanza su máximo en el mínimo y termina en el punto medio del rango de la variable. La función de pertenencia (FP) 'ALTA' comienza en el punto medio, alcanza su máximo en el punto máximo y finaliza en el punto máximo.

- Para Mamdani optimizado:

Los puntos medios de las funciones de pertenencia de la temperatura externa y la radiación solar(*mid_te*, *mid_rad*) fueron optimizados mediante Optuna. Esto permite definiciones más flexibles de 'bajo' y 'alto' para estas características específicas.

Otras características (*humidity_int*, *leeward_vent*, *windward_vent*) y la salida (*temp_int*) utilizan las mismas funciones de pertenencia triangulares fijas que en el modelo original.

Reglas difusas:

El sistema se define mediante un conjunto de reglas SI-ENTONCES. Estas reglas combinan los conjuntos difusos de las variables de entrada para inferir el conjunto difuso de la variable de salida.

Estas son las reglas implementadas:

- SI *temp_ext* ES baja Y la radiación ES baja ENTONCES *temp_int* ES baja
- SI *temp_ext* ES alta Y la radiación ES alta ENTONCES *temp_int* ES alta
- SI *humidity_int* ES baja ENTONCES *temp_int* ES alta
- SI *humidity_int* ES alta ENTONCES *temp_int* ES baja
- SI *leeward_vent* ES baja ENTONCES *temp_int* ES baja
- SI *leeward_vent* ES alta ENTONCES *temp_int* ES alta
- SI *windward_vent* ES baja ENTONCES *temp_int* ES baja
- SI *windward_vent* ES alta ENTONCES *temp_int* ES alta

Desfuzificación:

Se utiliza el método del centroide para convertir la salida difusa de nuevo en un valor nítido (numérico) para la predicción de temperatura interna.

9.2.2 Modelo ANFIS con aprendizaje residual

Arquitectura del modelo:

- Número de funciones de pertenencia: 5
- Número máximo de reglas: 8

Parámetros de entrenamiento:

- Número de épocas de entrenamiento: 80
- Tasa de aprendizaje: 0.001
- Disminución de peso (weight_decay para ADAM Optimizer): 1e-5

Carga de datos:

- Tamaño de muestra (batch_size): 64

9.3 FASE DE ANÁLISIS Y EVALUACIÓN DE RESULTADOS

A continuación se describen los resultados obtenidos en los diferentes modelos entrenados, los cuales fueron evaluados a través de validación temporal tipo expanding window, realizando una división en 5 segmentos (folds) para determinar una mayor capacidad de generalización del modelo.

9.3.1 Modelo ANFIS con aprendizaje residual

En esta sección se muestran los resultados del modelo ANFIS con aprendizaje residual en cada uno de los folds donde se realizó la validación.

Fold 1

La Tabla 9.2 muestra los resultados de las métricas de evaluación del Fold 1 para el modelo ANFIS en comparación con el modelo baseline.

Se evidencia una mejora consistente en todas las métricas donde se resalta la mejora del 34.1 % en RMSE evidenciando un aumento aproximado de 0.07 grados de precisión respecto al modelo de persistencia.

Métrica	ANFIS	Baseline	Mejora de ANFIS
RMSE	0.1449	0.2198	34.1 %
MAE	0.0854	0.1407	39.3 %
MSE	0.0210	0.0483	56.5 %
R^2	0.9970	0.9930	0.4 %

Tabla 9.2: Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 1)

En la Figura 9.1 se muestra una gráfica de líneas que presenta la diferencia en el fold 1 de las distribuciones de los resultados de la predicción en contraste con los datos de temperatura real

obtenidos por los sensores. En el eje de las abcisas se muestra el rango de registros temporales (0-5000) en el que se validó dentro del fold y, en el eje de las ordenadas, se muestra el rango de temperatura ($^{\circ}\text{C}$) en el que se encuentran las distribuciones.




Figura 9.1: Comparación temperatura real en comparación con resultado predicción (Fold 1)

Fold 2

La Tabla ?? muestra los resultados de las métricas de evaluación del Fold 2 para el modelo ANFIS en comparación con el modelo baseline.

Se evidencia una mejora consistente en todas las métricas donde se resalta la mejora del 25.2 % en RMSE evidenciando un aumento aproximado de 0.08 grados de precisión respecto al modelo de persistencia.

Métrica	ANFIS	Baseline	Mejora de ANFIS
RMSE	0.2284	0.3055	25.2 %
MAE	0.1215	0.1977	38.5 %
MSE	0.0522	0.0933	44.1 %
R^2	0.9957	0.9924	0.3 %

Tabla 9.3: Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 2)

En la Figura 9.2 se muestra una gráfica de líneas que presenta la diferencia en el fold 2 de las distribuciones de los resultados de la predicción en contraste con los datos de temperatura real

obtenidos por los sensores. En el eje de las abcisas se muestra el rango de registros temporales (0-5000) en el que se validó dentro del fold y, en el eje de las ordenadas, se muestra el rango de temperatura ($^{\circ}\text{C}$) en el que se encuentran las distribuciones.




Figura 9.2: Comparación temperatura real en comparación con resultado predicción (Fold 2)

Fold 3

La Tabla ?? muestra los resultados de las métricas de evaluación del Fold 3 para el modelo ANFIS en comparación con el modelo baseline.

Se evidencia una mejora consistente en todas las métricas donde se resalta la mejora del 30.6 % en RMSE evidenciando un aumento aproximado de 0.11 grados de precisión respecto al modelo de persistencia.

Métrica	ANFIS	Baseline	Mejora de ANFIS
RMSE	0.2555	0.3679	30.6 %
MAE	0.1553	0.2450	36.6 %
MSE	0.0653	0.1354	51.8 %
R^2	0.9951	0.9899	0.5 %

Tabla 9.4: Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 3)

En la Figura 9.3 se muestra una gráfica de líneas que presenta la diferencia en el fold 3 de las distribuciones de los resultados de la predicción en contraste con los datos de temperatura real

obtenidos por los sensores. En el eje de las abcisas se muestra el rango de registros temporales (0-5000) en el que se validó dentro del fold y, en el eje de las ordenadas, se muestra el rango de temperatura ($^{\circ}\text{C}$) en el que se encuentran las distribuciones.




Figura 9.3: Comparación temperatura real en comparación con resultado predicción (Fold 3)

Fold 4

La Tabla ?? muestra los resultados de las métricas de evaluación del Fold 4 para el modelo ANFIS en comparación con el modelo baseline.

Se evidencia una mejora consistente en todas las métricas donde se resalta la mejora del 20.8 % en RMSE evidenciando un aumento aproximado de 0.09 grados de precisión respecto al modelo de persistencia.

Métrica	ANFIS	Baseline	Mejora de ANFIS
RMSE	0.3338	0.4214	20.8 %
MAE	0.1785	0.2550	30.0 %
MSE	0.1114	0.1776	37.3 %
R^2	0.9916	0.9866	0.5 %

Tabla 9.5: Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 4)

En la Figura 9.4 se muestra una gráfica de líneas que presenta la diferencia en el fold 4 de las distribuciones de los resultados de la predicción en contraste con los datos de temperatura real

obtenidos por los sensores. En el eje de las abscisas se muestra el rango de registros temporales (0-5000) en el que se validó dentro del fold y, en el eje de las ordenadas, se muestra el rango de temperatura ($^{\circ}\text{C}$) en el que se encuentran las distribuciones.




Figura 9.4: Comparación temperatura real en comparación con resultado predicción (Fold 4)

Fold 5

La Tabla ?? muestra los resultados de las métricas de evaluación del Fold 5 para el modelo ANFIS en comparación con el modelo baseline.

Se evidencia una mejora consistente en todas las métricas donde se resalta la mejora del 18.7 % en RMSE evidenciando un aumento aproximado de 0.08 grados de precisión respecto al modelo de persistencia.

Métrica	ANFIS	Baseline	Mejora de ANFIS
RMSE	0.3436	0.4226	18.7 %
MAE	0.1971	0.2517	21.7 %
MSE	0.1181	0.1786	33.9 %
R^2	0.9910	0.9863	0.5 %

Tabla 9.6: Comparación de desempeño entre el modelo ANFIS y el modelo Baseline (Fold 5)

En la Figura 9.5 se muestra una gráfica de líneas que presenta la diferencia en el fold 5 de las distribuciones de los resultados de la predicción en contraste con los datos de temperatura real

obtenidos por los sensores. En el eje de las abscisas se muestra el rango de registros temporales (0-5000) en el que se validó dentro del fold y, en el eje de las ordenadas, se muestra el rango de temperatura ($^{\circ}\text{C}$) en el que se encuentran las distribuciones.




Figura 9.5: Comparación temperatura real en comparación con resultado predicción (Fold 5)

Comparativa final

La Tabla 9.7 muestra los resultados promedio de las métricas de evaluación en todos los folds para el modelo ANFIS en comparación con el modelo baseline.

Se evidencia una mejora consistente en todas las métricas, donde se resalta la mejora del 24,8 % en RMSE evidenciando un aumento aproximado de 0.08 grados de precisión respecto al modelo de persistencia.

Métrica	ANFIS Mean	Baseline Mean	Mejora de ANFIS
MSE	0.0736	0.1266	41.9 %
RMSE	0.2612	0.3475	24.8 %
MAE	0.1476	0.2180	32.3 %
R^2	0.9941	0.9896	0.5 %

Tabla 9.7: Comparación promedio de desempeño entre el modelo ANFIS y el modelo Baseline

10. CONCLUSIONES

Los resultados obtenidos por el modelo ANFIS con aprendizaje residual evidencian una mejora en todas las métricas de evaluación en comparación el baseline de forma consistente, lo que implica una reducción global del error y una mayor estabilidad en el modelo.

Se destaca la alta interpretabilidad proporcionada por las reglas y funciones de pertenencia del modelo ANFIS que permiten un entendimiento claro y sencillo del comportamiento termodinámico del sistema.

Dentro de la metodología, se resalta el uso de aprendizaje residual y la implementación de características derivadas (retardos temporales, diferencias y variables de interacción), las cuales permitieron una descripción más adecuada de las dinámicas no lineales del fenómeno de temperatura al interior del invernadero.

El método de validación tipo expanding window fue una estrategia robusta para reducir la fuga de información y permitió proveer una estimación realista de la generalización del modelo.

Finalmente, se evidencia el gran potencial que poseen los modelos neurodifusos, su combinación con aprendizaje residual y técnicas de optimización, por su interpretabilidad y efectividad en la predicción de variables climáticas en entornos agrícolas controlados.

11. RECOMENDACIONES Y TRABAJO FUTURO

11.1 RECOMENDACIONES

1. Las variables utilizadas para el entrenamiento del modelo son un subconjunto de los datos totales que se encontraban disponibles. Adicionalmente, muchas de las variables asociadas a actuadores podrían variar significativamente si alguno de los componentes se reemplaza, si se incorporan nuevos o si llegan a operar en un rango de valores diferentes, por lo que se requiere tener esto en cuenta para evaluar un reentrenamiento.
2. El principal aporte de este trabajo de investigación es proponer una metodología y un marco de trabajo para el entrenamiento de un modelo que, al final, pueda proporcionar una alta interpretabilidad y precisión. Sin embargo, los resultados obtenidos en otras aplicaciones requieren un análisis minucioso de la información disponible y de las condiciones específicas del ambiente controlado.
3. Al ser este un modelo entrenado bajo el análisis de un periodo de tiempo específico, es probable que, si ciertas condiciones climáticas o de los actuadores cambian significativamente, el rendimiento del modelo pueda degradarse con el tiempo. Por lo cual, se requiere la implementación de un mecanismo de monitoreo que evalúe el rendimiento del modelo y permita definir la necesidad de futuros reentrenamientos.

11.2 TRABAJO FUTURO

Se plantean los siguientes productos resultado del proceso investigativo tales como ponencias en eventos, así como registro y protección de la propiedad intelectual.

- Ponencias en eventos

1. 5o Congreso Internacional en Ingeniería, Tecnología e Innovación (CIITI 2026)

- Proceso de registro de software y propiedad intelectual

1. Prototipo software para monitoreo y ejecución de predicciones asociadas a modelo ANFIS para predicción de temperatura en invernaderos

BIBLIOGRAFÍA

- Adriyendi. (2018). Fuzzy Logic using Tsukamoto Model and Sugeno Model on Prediction Cost. *I.J. Intelligent Systems and Applications*, 6, 13-21.
- Ariani, F., & Endra, R. Y. (2013). Implementation of Fuzzy Inference System with Tsukamoto Method for Study Programme Selection.
- Boughamsa, M., & Ramdani, M. (2018). Adaptive fuzzy control strategy for greenhouse microclimate. *International Journal of Automation and Control*, 12(1), 108-125. <https://doi.org/10.1504/IJAAC.2018.088604>
- Bryan, K. (2017). Rose-Hulman Institute of Technology. <https://www.rose-hulman.edu/~bryan/lottamath/quasinewton.pdf>
- Calderón Cisneros, A. (2016). Agricultura urbana familiar en una ciudad media en Chiapas. Implicaciones para la sustentabilidad urbana. *Estudios Sociales (Hermosillo, Son.)*, 26, 101-129.
- Castañeda-Miranda, A., & Castaño, V. M. (2020). Smart frost measurement for anti-disaster intelligent control in greenhouses via embedding IoT and hybrid AI methods. *Measurement*, 164, 108043. <https://doi.org/10.1016/j.measurement.2020.108043>
- Charania, I., & Li, X. (2020). Smart farming: Agriculture's shift from a labor intensive to technology-native industry. *Internet of Things*, 9, 100142. <https://doi.org/10.1016/j.iot.2019.100142>
- Chen, L., Zhang, B., Yao, F., & Cui, L. (2016). Modeling and simulation of a solar greenhouse with natural ventilation based on error optimization using fuzzy controller. *Chinese Control Conference (CCC)*, 2097-2102. <https://doi.org/10.1109/ChiCC.2016.7553676>
- Choab, N., Allouhi, A., El Maakoul, A., Kousksou, T., Saadeddine, S., & Jamil, A. (2019). Review on greenhouse microclimate and application: Design parameters, thermal modeling and simulation, climate controlling technologies. *Solar Energy*, 191, 109-137. <https://doi.org/10.1016/j.solener.2019.08.042>
- Cooper, P. I., & Fuller, R. J. (1983). A transient model of the interaction between crop, environment and greenhouse structure for predicting crop yield and energy consumption. *Journal of Agricultural Engineering Research*, 28(5), 401-417. [https://doi.org/10.1016/0021-8634\(83\)90133-6](https://doi.org/10.1016/0021-8634(83)90133-6)
- Ding, J. T., Tu, H. Y., Zang, Z. L., Huang, M., & Zhou, S. J. (2018). Precise control and prediction of the greenhouse growth environment of *Dendrobium candidum*. *Computers and Electronics in Agriculture*, 151, 453-459. <https://doi.org/10.1016/j.compag.2018.06.037>
- Gharabaghi, B., Bonakdari, H., & Ebtehaj, I. (2019). Hybrid evolutionary algorithm based on PSOGA for ANFIS designing in prediction of no-deposition bed load sediment transport

- in sewer pipe. En *Advances in Intelligent Systems and Computing* (pp. 106-118, Vol. 857). https://doi.org/10.1007/978-3-030-01177-2_8
- Guo, P., Wang, X., & Han, Y. (2010). The Enhanced Genetic Algorithms for the Optimization Design, 2990-2994.
- Izquierdo, S. S., & Izquierdo, L. R. (2018). Mamdani Fuzzy Systems for Modelling and Simulation: A Critical Assessment. *Journal of Artificial Societies and Social Simulation*, 21(3). <https://doi.org/10.18564/jasss.3660>
- Jain, D., & Tiwari, G. N. (2004). Effect of greenhouse on crop drying under natural and forced convection I: Evaluation of convective mass transfer coefficient. *Energy Conversion and Management*, 45(5), 765-783. [https://doi.org/10.1016/S0196-8904\(03\)00178-X](https://doi.org/10.1016/S0196-8904(03)00178-X)
- Klir, G. J., & Yuan, B. (1995). *Fuzzy Sets and Fuzzy Logic Theory and Applications*. Prentice Hall PTR.
- Knapp, R. B. (2007). Fuzzy Sets and Pattern Recognition - Fuzzy inference systems.
- Laktionov, I., Vovna, O., Kabanets, M., Derzhevetska, M., & Zori, A. (2020). Mathematical Model of Measuring Monitoring and Temperature Control of Growing Vegetables in Greenhouses. *International Journal of Design & Nature and Ecodynamics*, 15(3), 325-336. <https://doi.org/10.18280/ij dne.150306>
- Lambers, J. (2011). MAT 461/561 Numerical Analysis II. <https://www.rose-hulman.edu/~bryan/lottamath/quasinewton.pdf>
- Lenka, S. K., & Mohapatra, A. G. (2015). Gradient Descent with Momentum based Neural Network Pattern Classification for the Prediction of Soil Moisture Content in Precision Agriculture. *Proceedings - IEEE International Symposium on Nanoelectronic and Information Systems (INIS)*, 63-66. <https://doi.org/10.1109/iNIS.2015.56>
- Maher, A., Kamel, E., Enrico, F., Atif, I., & Abdelkader, M. (2016). An intelligent system for the climate control and energy savings in agricultural greenhouses. *Energy Efficiency*, 9(6), 1241-1255. <https://doi.org/10.1007/s12053-015-9421-8>
- MathWorks Inc. (2019). Mamdani and Sugeno Fuzzy Inference Systems - MATLAB and Simulink. <https://www.mathworks.com/help/fuzzy/types-of-fuzzy-inference-systems.html>
- Mehran, K. (2008). Takagi-Sugeno Fuzzy Modeling for Process Control. <https://www.staff.ncl.ac.uk/damian.giaouris/pdf/IA%5C%20Automation/TS%5C%20FL%5C%20tutorial.pdf>
- Mobtaker, H. G., Ajabshirchi, Y., Ranjbar, S. F., & Matloobi, M. (2019). Simulation of thermal performance of solar greenhouse in north-west of Iran: An experimental validation. *Renewable Energy*, 135, 88-97. <https://doi.org/10.1016/j.renene.2018.10.003>
- Mohammadi, B., Ranjbar, S. F., & Ajabshirchi, Y. (2018). Application of dynamic model to predict some inside environment variables in a semi-solar greenhouse. *Information Processing in Agriculture*, 5(2), 279-288. <https://doi.org/10.1016/j.inpa.2018.01.001>

- Montes Olguín, A., & Rodriguez Jorge, R. (2017). Fuzzy control proposal for the climate of a homemade greenhouse. En *Frontiers in Artificial Intelligence and Applications* (pp. 257-266, Vol. 295). <https://doi.org/10.3233/978-1-61499-773-3-257>
- Nugroho, L. E., Pratama, A. G. H., Mustika, I. W., & Ferdiana, R. (2017). Development of monitoring system for smart farming using Progressive Web App. *International Conference on Information Technology and Electrical Engineering (ICITEE)*, 1-5. <https://doi.org/10.1109/ICITEED.2017.8250513>
- OECD. (2018). *OECD Handbook for Internationally Comparative Education Statistics 2018*. <https://doi.org/10.1787/9789264304444-en>
- Ramdani, M., Hamza, A., & Boughamsa, M. (2015). Multiscale fuzzy model-based short term predictive control of greenhouse microclimate. *IEEE International Conference on Industrial Informatics (INDIN)*, 1348-1353. <https://doi.org/10.1109/INDIN.2015.7281931>
- Rao, S. (2009). *Engineering Optimization Theory and Practice*. John Wiley; Sons Inc.
- Revathi, S., & Sivakumaran, N. (2016). Fuzzy based temperature control of greenhouse. *IFAC-PapersOnLine*, 49(1), 549-554. <https://doi.org/10.1016/j.ifacol.2016.03.112>
- Reyes-Rosas, A., Molina-Aiz, F. D., Valera, D. L., López, A., & Khamkure, S. (2017). Development of a single energy balance model for prediction of temperatures inside a naturally ventilated greenhouse with polypropylene soil mulch. *Computers and Electronics in Agriculture*, 142, 9-28. <https://doi.org/10.1016/j.compag.2017.08.020>
- Ross, T. J. (2010). *Fuzzy Logic with Engineering Applications*. John Wiley; Sons, Ltd.
- Sethi, V. P. (2009). On the selection of shape and orientation of a greenhouse: Thermal modeling and experimental validation. *Solar Energy*, 83(1), 21-38. <https://doi.org/10.1016/j.solener.2008.05.018>
- Shamshiri, R. R., Bojic, I., van Henten, E., Balasundram, S. K., Dworak, V., Sultan, M., & Weltzien, C. (2020). Model-based evaluation of greenhouse microclimate using IoT-Sensor data fusion for energy efficient crop production. *Journal of Cleaner Production*, 263, 121303. <https://doi.org/10.1016/j.jclepro.2020.121303>
- Sharma, P. K., Tiwari, G. N., & Sorayan, V. P. S. (1999). Temperature distribution in different zones of the micro-climate of a greenhouse: A dynamic model. *Energy Conversion and Management*, 40(3), 335-348. [https://doi.org/10.1016/S0196-8904\(98\)00100-9](https://doi.org/10.1016/S0196-8904(98)00100-9)
- Shen, Y., Wei, R., & Xu, L. (2018). Energy Consumption Prediction of a Greenhouse and Optimization of Daily Average Temperature. *Energies*, 11(1), 65. <https://doi.org/10.3390/en11010065>
- Singh, G., Singh, P. P., Lubana, P. P. S., & Singh, K. G. (2006). Formulation and validation of a mathematical model of the microclimate of a greenhouse. *Renewable Energy*, 31(10), 1541-1560. <https://doi.org/10.1016/j.renene.2005.07.011>

- Su, Y., & Xu, L. (2017). Towards discrete time model for greenhouse climate control. *Engineering in Agriculture, Environment and Food*, 10(2), 157-170. <https://doi.org/10.1016/j.eaef.2017.01.001>
- Su, Y., Xu, L., & Li, D. (2016). Adaptive Fuzzy Control of a Class of MIMO Nonlinear System with Actuator Saturation for Greenhouse Climate Control Problem. *IEEE Transactions on Automation Science and Engineering*, 13(2), 772-788. <https://doi.org/10.1109/TASE.2015.2392161>
- Suparta, W., & Alhasa, K. M. (2016). *Modeling of Tropospheric Delays Using ANFIS*. <https://doi.org/10.1007/978-3-319-28437-8>
- Taki, M., Abdanan Mehdizadeh, S., Rohani, A., Rahnama, M., & Rahmati-Joneidabad, M. (2018). Applied machine learning in greenhouse simulation; new application and analysis. *Information Processing in Agriculture*, 5(2), 253-268. <https://doi.org/10.1016/j.inpa.2018.01.003>
- Tiwari, G. N., Sharma, P. K., Goyal, R. K., & Sutar, R. F. (1998). Estimation of an efficiency factor for a greenhouse: A numerical and experimental study. *Energy and Buildings*, 28(3), 241-250. [https://doi.org/10.1016/S0378-7788\(97\)00062-5](https://doi.org/10.1016/S0378-7788(97)00062-5)
- Xu, X., Sun, Y., Krishnamoorthy, S., & Chandran, K. (2020). An Empirical Analysis of Green Technology Innovation and Ecological Efficiency Based on a Greenhouse Evolutionary Ventilation Algorithm Fuzzy-Model. *Sustainability*, 12(9), 3886. <https://doi.org/10.3390/su12093886>
- Yu, H., Chen, Y., Hassan, S. G., & Li, D. (2016). Prediction of the temperature in a Chinese solar greenhouse based on LSSVM optimized by improved PSO. *Computers and Electronics in Agriculture*, 122, 94-102. <https://doi.org/10.1016/j.compag.2016.01.019>
- Zhao, H., Shi, L. R., & Wang, H. J. (2015). Sunlight Greenhouse Temperature Prediction Model Based on Bayesian Regularization BP Neural Network. *Applied Mechanics and Materials*, 740, 871-874. <https://doi.org/10.4028/www.scientific.net/amm.740.871>
- Zhou, M., Bie, Y., Wang, Q., & Zou, Z. (2018). Design and Testing of a monitoring system for mushroom planting greenhouse. *IEEE Information Technology and Mechatronics Engineering Conference (ITOEC)*, 1658-1661. <https://doi.org/10.1109/ITOEC.2018.8740715>