



INVESTIGACIÓN ____

PROFUNDIZACIÓN __X__

Diseño e implementación de un sistema inteligente para el apoyo al diagnóstico de fallos operativos en entornos cloud basados en AWS

Autor

Luis Felipe Patiño López

Tutor

PhD., MSc., Ing. César Andrey Perdomo Charry

Universidad Distrital Francisco José De Caldas

Maestría en Ciencias de la Información y las Comunicaciones

Énfasis en Teleinformática

Bogotá, Colombia

febrero de 2026

Contenido

1.	grupo de investigación	4
2.	linea de investigacion	4
3.	director.....	5
4.	Resumen	6
5.	Palabras Clave	6
6.	Introducción	7
7.	Problema de investigación (PROFUNDIZACIÓN)	8
7.1	PLANTEAMIENTO del problema	9
7.2	FORMULACION DEL PROBLEMA.....	11
7.3	sistematizacion del problema	11
8.	Objetivos	13
8.1	Objetivo General	13
8.2	Objetivos Específicos	13
9.	justificacion	14
9.1	Justificación Teórica.....	14
9.2	Justificación Metodológica	15
9.3	Justificación Práctica.....	15
10.	MARCO DE REFERENCIA	16
10.1	Marco Teórico.....	16
10.2	Marco CONCEPTUAL	23
10.3	Marco espacial	25

10.4	Marco Temporal.....	26
11.	Metodología	26
12.	impacto y resultados esperados	30
13.	Recursos y presupuesto	32
14.	Cronograma	34
15.	Limitaciones	35
16.	REFERENCIAS	37

1. GRUPO DE INVESTIGACIÓN

El proyecto se adscribe al **Grupo de Investigación LASER (Laboratorio de Automatización, Sistemas Embebidos y Robótica)** de la **Universidad Distrital Francisco José de Caldas**.

El grupo LASER desarrolla actividades de investigación aplicada orientadas a las áreas de **automatización, sistemas embebidos, robótica y sistemas inteligentes**, con énfasis en el diseño e implementación de soluciones tecnológicas en el campo de la ingeniería. El grupo se encuentra adscrito a la **Facultad de Ingeniería** y participa en proyectos de investigación, formación de estudiantes y desarrollo de aplicaciones tecnológicas con impacto académico e ingenieril.

De acuerdo con la clasificación vigente de **Minciencias (antes Colciencias)**, el grupo LASER se encuentra categorizado en **Categoría B**. (Universidad Distrital Francisco José de Caldas, 2024)

2. LINEA DE INVESTIGACION

El presente proyecto de profundización se enmarca dentro de la línea de investigación asociada al desarrollo de sistemas inteligentes y soluciones de ingeniería aplicadas, en concordancia con las áreas de trabajo del Grupo de Investigación LASER (Laboratorio de Automatización, Sistemas Embebidos y Robótica) de la Universidad Distrital Francisco José de Caldas. En particular, el proyecto se relaciona con el diseño e implementación de sistemas computacionales orientados a la automatización de procesos, apoyados en el uso de tecnologías actuales de computación en la nube e inteligencia artificial, como

herramientas para la ingeniería de software y la arquitectura de sistemas. Desde el enfoque de profundización, el proyecto prioriza la aplicación práctica de conocimientos avanzados, la integración de tecnologías modernas y la validación técnica de una solución funcional, más que la generación de nuevo conocimiento teórico. (Universidad Distrital Francisco José de Caldas, 2024)

3. DIRECTOR

El proyecto será dirigido por PhD., MSc., Ing. César Andrey Perdomo Charry, docente de tiempo completo de la Universidad Distrital Francisco José de Caldas. Cuenta con formación académica a nivel de doctorado en ingeniería, así como una maestría en Ciencias de la Información y las Comunicaciones, y título profesional en Ingeniería Electrónica.

Se desempeña como docente en la Facultad de Ingeniería de la Universidad Distrital Francisco José de Caldas y ha estado vinculado a procesos de extensión universitaria, desempeñándose como Jefe de la Oficina de Extensión (IDEXUD).

Su experiencia académica y profesional se ha desarrollado principalmente en el ámbito de la ingeniería aplicada, participando en procesos de formación de estudiantes y en el acompañamiento de proyectos académicos y tecnológicos.

4. RESUMEN

El presente anteproyecto de profundización propone el diseño e implementación de un sistema inteligente orientado al apoyo en el diagnóstico de fallos operativos en aplicaciones desplegadas en entornos cloud basados en AWS. La solución busca asistir a los equipos de ingeniería en la identificación y comprensión de incidentes operativos, a partir del análisis de información proveniente de mecanismos de observabilidad como registros, métricas y eventos del sistema.

El sistema se apoya en el uso de servicios de AWS para la recolección de datos operativos y en técnicas de inteligencia artificial generativa para el análisis, correlación y explicación de la información obtenida. A partir de estos datos, la solución proporciona resúmenes técnicos del incidente, posibles hipótesis de causa raíz y elementos de apoyo que facilitan el proceso de diagnóstico, reduciendo el tiempo y el esfuerzo requeridos para comprender el origen de los fallos.

El proyecto integra conceptos de computación en la nube, observabilidad y arquitectura de software, priorizando un enfoque práctico orientado a la implementación y validación de una solución funcional en escenarios reales de ingeniería. Desde la perspectiva de profundización, el trabajo se centra en la aplicación de tecnologías actuales para mejorar los procesos operativos, sin abordar la generación de nuevo conocimiento teórico.

5. PALABRAS CLAVE

Cloud Computing, Observability, Incident Diagnosis, Artificial Intelligence, Amazon Web Services.

6. INTRODUCCIÓN

La operación de aplicaciones en entornos de computación en la nube se ha convertido en un componente crítico para organizaciones que dependen de sistemas altamente disponibles, escalables y distribuidos. En plataformas como AWS, las arquitecturas modernas integran múltiples servicios y componentes que interactúan de forma dinámica, lo que incrementa la complejidad operativa y dificulta la identificación oportuna de fallos cuando se presentan incidentes en producción.

Ante la ocurrencia de un fallo operativo, los equipos de ingeniería deben analizar grandes volúmenes de información proveniente de registros, métricas y eventos del sistema, generalmente a través de herramientas de observabilidad como Amazon CloudWatch. Este proceso requiere experiencia técnica, capacidad de correlación y tiempo considerable para interpretar la información disponible y determinar las posibles causas del incidente, lo que impacta negativamente los tiempos de respuesta y recuperación del servicio.

En los últimos años, los avances en inteligencia artificial han abierto nuevas posibilidades para el análisis automatizado de información operativa y el apoyo a la toma de decisiones técnicas. En particular, las técnicas de inteligencia artificial generativa permiten sintetizar información compleja, identificar patrones relevantes y presentar explicaciones comprensibles a partir de datos heterogéneos, lo que resulta especialmente útil en escenarios de diagnóstico de fallos operativos.

En este contexto, el presente proyecto de profundización plantea el diseño e implementación de un sistema inteligente que asista el diagnóstico de fallos operativos en aplicaciones desplegadas en entornos cloud basados en AWS, mediante el análisis de información de observabilidad. La solución se orienta a apoyar a los equipos de ingeniería en la comprensión de los incidentes, proporcionando resúmenes técnicos, correlaciones relevantes y posibles hipótesis de causa raíz, con el fin de reducir el esfuerzo manual y mejorar la eficiencia en los procesos de diagnóstico y recuperación.

El proyecto adopta un enfoque práctico y aplicado, centrado en la integración de servicios de AWS y técnicas de inteligencia artificial para la construcción y validación de una solución funcional, reconociendo como limitación el alcance acotado de los escenarios y servicios analizados en esta etapa del trabajo.

7. PROBLEMA DE INVESTIGACIÓN (PROFUNDIZACIÓN)

La operación y mantenimiento de aplicaciones desplegadas en entornos de computación en la nube, particularmente en plataformas como AWS, se ha convertido en una actividad crítica para garantizar la disponibilidad, el desempeño y la confiabilidad de los sistemas modernos. Estos entornos suelen estar compuestos por arquitecturas distribuidas que integran múltiples servicios, recursos y componentes interdependientes, lo que incrementa la complejidad operativa y dificulta la identificación oportuna de fallos cuando se presentan incidentes.

En la práctica, el diagnóstico de fallos operativos depende en gran medida del análisis manual de información proveniente de métricas, registros y eventos generados por la infraestructura y las aplicaciones, comúnmente recolectados mediante herramientas de observabilidad como Amazon CloudWatch. Este proceso requiere que los equipos técnicos revisen grandes volúmenes de datos, correlacionen información dispersa y apliquen conocimiento experto para identificar las posibles causas de los incidentes, lo que puede resultar lento, propenso a errores y altamente dependiente de la experiencia del personal involucrado.

Si bien las plataformas de monitoreo y observabilidad permiten centralizar y visualizar información relevante sobre el estado de los sistemas, estas herramientas no siempre proporcionan mecanismos inteligentes que apoyen de manera directa la interpretación de los datos ni el diagnóstico de las causas raíz de los fallos. En muchos casos, la información disponible resulta extensa y poco estructurada, lo que dificulta su comprensión,

especialmente en escenarios de alta presión operativa o cuando los equipos cuentan con distintos niveles de experiencia técnica.

En este contexto, los avances recientes en inteligencia artificial, y particularmente en inteligencia artificial generativa, ofrecen una oportunidad para apoyar el análisis de información operativa mediante la identificación de patrones, la correlación automática de eventos y la generación de explicaciones técnicas comprensibles a partir de datos de observabilidad. No obstante, la aplicación efectiva de estas tecnologías en entornos cloud reales plantea desafíos técnicos y metodológicos relacionados con la integración de fuentes de datos, la confiabilidad de los resultados, el control de las recomendaciones generadas y su uso como apoyo a la toma de decisiones operativas.

A partir de lo anterior, surge la necesidad de diseñar e implementar una solución aplicada que permita apoyar el diagnóstico de fallos operativos en entornos cloud basados en AWS, utilizando información de observabilidad y técnicas de inteligencia artificial, con el fin de reducir el esfuerzo manual requerido, mejorar la comprensión de los incidentes y contribuir a una respuesta más eficiente ante fallos en sistemas reales de ingeniería. En este sentido, el problema que orienta el presente proyecto de profundización puede formularse a través de la siguiente pregunta:

¿Cómo diseñar e implementar un sistema inteligente que apoye el diagnóstico de fallos operativos en entornos cloud basados en AWS, a partir del análisis de métricas, registros y eventos de observabilidad, con el fin de mejorar la identificación de las causas de los incidentes y facilitar la toma de decisiones operativas?

7.1 PLANTEAMIENTO DEL PROBLEMA

Diagnóstico de la situación actual

En la actualidad, las aplicaciones desplegadas en entornos de computación en la nube como AWS operan sobre arquitecturas distribuidas que integran múltiples servicios, recursos y componentes interdependientes. Esta complejidad incrementa la dificultad para

identificar y diagnosticar fallos operativos cuando se presentan incidentes que afectan la disponibilidad, el rendimiento o el comportamiento esperado de los sistemas.

El diagnóstico de este tipo de fallos se realiza, en la mayoría de los casos, mediante el análisis manual de métricas, registros y eventos generados por la infraestructura y las aplicaciones, recolectados a través de herramientas de observabilidad como Amazon CloudWatch. Este proceso exige que los equipos técnicos revisen grandes volúmenes de información, correlacionen datos provenientes de distintas fuentes y apliquen conocimiento experto para inferir posibles causas raíz, lo que puede resultar lento, propenso a errores y altamente dependiente de la experiencia del personal involucrado.

Como consecuencia, se presentan síntomas como tiempos prolongados de resolución de incidentes, dificultad para identificar la causa real de los fallos, dependencia de personal altamente especializado y una respuesta reactiva ante problemas operativos. Estas condiciones afectan la eficiencia de los equipos de ingeniería, incrementan los costos operativos y pueden impactar negativamente la calidad del servicio ofrecido por las aplicaciones.

Pronóstico

De mantenerse las condiciones actuales, la complejidad operativa asociada a la gestión y diagnóstico de fallos en entornos cloud continuará aumentando a medida que las arquitecturas se vuelvan más dinámicas y distribuidas. Esto puede derivar en mayores tiempos de indisponibilidad, incremento en la carga operativa de los equipos técnicos y una mayor dificultad para escalar las prácticas de operación y soporte en organizaciones con infraestructuras en crecimiento.

Asimismo, la ausencia de mecanismos inteligentes que apoyen el análisis e interpretación de la información de observabilidad limitará la capacidad de los equipos para responder de manera eficiente a los incidentes, especialmente en escenarios donde se requiere una rápida toma de decisiones o cuando el conocimiento del sistema no está completamente documentado.

Control del pronóstico

Como respuesta al pronóstico planteado, el presente proyecto de profundización propone el diseño e implementación de un sistema inteligente que apoye el diagnóstico de fallos operativos en entornos cloud basados en AWS, a partir del análisis de métricas, registros y eventos de observabilidad. La solución busca asistir a los equipos técnicos en la identificación de patrones, la correlación de información relevante y la generación de explicaciones técnicas que faciliten la comprensión de los incidentes.

Mediante el uso de técnicas de inteligencia artificial, el sistema pretende reducir el esfuerzo manual requerido para el diagnóstico de fallos, mejorar los tiempos de respuesta ante incidentes y servir como apoyo a la toma de decisiones operativas, sin reemplazar el criterio técnico del personal, sino complementándolo con un enfoque automatizado y estructurado.

7.2 FORMULACION DEL PROBLEMA

¿Cómo diseñar e implementar un sistema inteligente que apoye el diagnóstico de fallos operativos en aplicaciones desplegadas en entornos cloud basados en AWS, mediante el análisis y correlación de métricas, registros y eventos de observabilidad, con el fin de facilitar la identificación de posibles causas raíz y mejorar los tiempos de respuesta ante incidentes operativos?.

7.3 SISTEMATIZACION DEL PROBLEMA

A partir del problema formulado, se hace necesario descomponer la pregunta principal en un conjunto de sub-preguntas que permitan analizar de manera estructurada los elementos que intervienen en el diagnóstico de fallos operativos en entornos cloud basados en AWS. Esta sistematización facilita la definición de los objetivos específicos y orienta el desarrollo metodológico del proyecto de profundización.

En este contexto, el problema se puede desagregar en las siguientes sub-preguntas:

- ¿Qué tipos de fallos operativos son más frecuentes en aplicaciones desplegadas sobre servicios de AWS y cómo se manifiestan a través de métricas, registros y eventos de observabilidad?
- ¿Qué fuentes de información disponibles en AWS (como métricas, logs y eventos) resultan más relevantes para apoyar el diagnóstico de incidentes operativos en entornos cloud?
- ¿Cómo puede estructurarse y correlacionarse la información de observabilidad para facilitar la identificación de posibles causas raíz de un fallo operativo?
- ¿De qué manera un sistema inteligente puede asistir el análisis de grandes volúmenes de datos de observabilidad para apoyar el proceso de diagnóstico técnico?
- ¿Cómo validar que las recomendaciones o diagnósticos generados por el sistema contribuyen efectivamente a reducir los tiempos de análisis y respuesta ante incidentes?

Las respuestas a estas sub-preguntas permitirán abordar de manera integral el problema planteado, sirviendo como base para la formulación de los objetivos del proyecto y para el diseño de una solución técnica orientada al apoyo del diagnóstico de fallos operativos en entornos cloud basados en AWS.

8. OBJETIVOS

Los objetivos del presente proyecto de profundización establecen los propósitos que se buscan alcanzar con el desarrollo de la solución propuesta, orientando el estudio y delimitando el alcance del trabajo desde una perspectiva aplicada. Estos objetivos permiten definir el tipo de conocimiento a generar y el aporte tecnológico esperado, sin describir actividades ni procedimientos metodológicos específicos.

Los objetivos planteados son alcanzables mediante la metodología propuesta y se enfocan en el diseño e implementación de una solución tecnológica orientada al apoyo del diagnóstico de fallos operativos en entornos cloud.

8.1 OBJETIVO GENERAL

Diseñar e implementar un sistema inteligente para el apoyo al diagnóstico de fallos operativos en aplicaciones desplegadas en entornos cloud basados en AWS, mediante el análisis y correlación de información de observabilidad, con el fin de facilitar la identificación de posibles causas raíz y mejorar los tiempos de respuesta ante incidentes operativos.

8.2 OBJETIVOS ESPECÍFICOS

- Identificar los principales tipos de fallos operativos que se presentan en aplicaciones desplegadas en entornos cloud basados en AWS, a partir del análisis de métricas, registros y eventos generados por la infraestructura.
- Analizar las fuentes de información de observabilidad disponibles en AWS que resultan relevantes para el apoyo al diagnóstico de incidentes operativos.
- Diseñar una arquitectura técnica que permita la recolección, procesamiento y correlación de datos de observabilidad provenientes de distintos servicios de AWS.
- Implementar un sistema inteligente que asista el análisis de métricas, logs y eventos, orientado a apoyar la identificación de posibles causas raíz de fallos operativos.

- Evaluar la efectividad del sistema propuesto mediante escenarios controlados de fallos, considerando su impacto en los tiempos y la calidad del diagnóstico frente a enfoques tradicionales de análisis manual.

9. JUSTIFICACION

La creciente adopción de arquitecturas cloud en organizaciones de distintos sectores ha incrementado la complejidad operativa de los sistemas de información, haciendo que la identificación y resolución de fallos se convierta en un proceso cada vez más exigente en términos técnicos y de tiempo. En este contexto, el presente proyecto de profundización se justifica por la necesidad de explorar y aplicar enfoques tecnológicos que permitan apoyar de manera efectiva el diagnóstico de fallos operativos en entornos cloud basados en AWS, mediante el uso de técnicas de observabilidad e inteligencia artificial.

La propuesta se orienta al desarrollo de una solución aplicada, cuyo propósito es aportar a la mejora de los procesos de análisis y respuesta ante incidentes operativos, sin pretender la generación de nuevo conocimiento teórico, sino la integración y aplicación práctica de tecnologías existentes en un escenario real de ingeniería.

9.1 JUSTIFICACIÓN TEÓRICA

Desde el punto de vista teórico, el proyecto se fundamenta en conceptos relacionados con computación en la nube, observabilidad de sistemas, arquitectura de software y diagnóstico de fallos en sistemas distribuidos. La investigación permite profundizar en el estudio de cómo métricas, registros y eventos pueden ser analizados y correlacionados para comprender el comportamiento de aplicaciones cloud y apoyar la identificación de causas raíz ante fallos operativos.

Adicionalmente, el proyecto aborda el uso de enfoques de inteligencia artificial aplicados al análisis de información operativa, lo cual contribuye a ampliar la comprensión de cómo

estas técnicas pueden ser integradas en procesos de soporte y operación de infraestructuras cloud, complementando los enfoques tradicionales de monitoreo y análisis manual.

9.2 JUSTIFICACIÓN METODOLÓGICA

En el ámbito metodológico, el proyecto propone una aproximación basada en el diseño e implementación de una solución tecnológica, combinando técnicas de observabilidad, análisis de datos y componentes inteligentes para el apoyo al diagnóstico de fallos. La metodología planteada permite estructurar un proceso reproducible para la recolección, procesamiento y análisis de información operativa en entornos cloud.

Este enfoque metodológico resulta pertinente para proyectos de profundización, ya que puede ser aplicado o adaptado en contextos similares por otros profesionales o investigadores interesados en el análisis de sistemas cloud, sirviendo como referencia para el desarrollo de soluciones orientadas a la operación y soporte de infraestructuras en la nube.

9.3 JUSTIFICACIÓN PRÁCTICA

Desde una perspectiva práctica, el proyecto responde a una problemática real presente en organizaciones que operan aplicaciones sobre AWS, donde el diagnóstico de fallos suele requerir un esfuerzo considerable por parte de equipos especializados, implicando altos tiempos de análisis y dependencia del conocimiento experto.

La solución propuesta busca apoyar a los equipos de operación y soporte mediante un sistema inteligente que facilite el análisis de información de observabilidad y contribuya a reducir los tiempos de identificación de posibles causas raíz. De esta manera, el proyecto aporta una herramienta que puede mejorar la eficiencia operativa, optimizar los procesos de atención de incidentes y fortalecer la gestión de entornos cloud en escenarios reales de ingeniería.

10. MARCO DE REFERENCIA

El marco de referencia contextualiza el problema abordado a partir de fundamentos conceptuales y antecedentes técnicos relacionados con la operación de sistemas cloud, la observabilidad y las prácticas de diagnóstico de incidentes. En un proyecto de profundización, este marco se orienta a sustentar el diseño de la solución propuesta y a delimitar los conceptos y enfoques que serán utilizados durante la implementación y validación.

10.1 MARCO TEÓRICO

10.1.1 Computación en la nube y arquitecturas distribuidas

La computación en la nube constituye un modelo que permite el acceso bajo demanda a un conjunto compartido de recursos computacionales configurables, tales como redes, servidores, almacenamiento y servicios, los cuales pueden ser aprovisionados y liberados con un esfuerzo mínimo de gestión (Mell & Grance, 2011). Este modelo, formalizado por el National Institute of Standards and Technology (NIST), ha sido ampliamente adoptado por organizaciones de todos los sectores como base para el despliegue de aplicaciones de misión crítica, impulsado por ventajas como la elasticidad, la escalabilidad y la reducción de costos de infraestructura.

En el contexto de las plataformas de nube pública, Amazon Web Services (AWS) se posiciona como el proveedor líder del mercado, con una participación que ha superado consistentemente el 30 % del mercado global de infraestructura cloud (Gartner, 2024). AWS ofrece más de 200 servicios gestionados que cubren cómputo, almacenamiento, bases de datos, redes, seguridad y analítica, entre otros, lo que permite a las organizaciones construir arquitecturas complejas sin gestionar directamente la infraestructura subyacente.

Las arquitecturas modernas desplegadas en la nube han migrado progresivamente de esquemas monolíticos hacia patrones distribuidos basados en microservicios. Newman (2021) describe los microservicios como unidades de despliegue independientes, cada una

modelando un dominio de negocio específico, que se comunican a través de interfaces bien definidas. Este enfoque ofrece ventajas significativas en términos de escalabilidad y velocidad de desarrollo, pero incrementa la complejidad operativa al multiplicar los puntos de fallo, las dependencias entre servicios y el volumen de datos de telemetría generados (Jamshidi et al., 2018). Un estudio publicado en IEEE Transactions on Software Engineering por Zhou et al. (2021) identificó que los sistemas basados en microservicios presentan patrones de fallo más complejos que las arquitecturas monolíticas, incluyendo fallos en cascada, degradación parcial y errores de configuración distribuidos.

10.1.2 Observabilidad de sistemas distribuidos

La observabilidad, como concepto aplicado a sistemas de software, se define como la capacidad de inferir el estado interno de un sistema a partir de sus salidas externas. A diferencia del monitoreo tradicional, que se enfoca en la verificación de condiciones predefinidas, la observabilidad permite explorar y comprender comportamientos inesperados del sistema mediante el análisis de sus señales operativas (Sridharan, 2018). Esta distinción resulta fundamental en entornos cloud distribuidos, donde los modos de fallo no siempre son predecibles.

La literatura técnica y académica reconoce tres pilares fundamentales de la observabilidad: métricas, logs y trazas distribuidas. Las métricas son representaciones numéricas del comportamiento del sistema a lo largo del tiempo, como el uso de CPU, la latencia de las solicitudes o la tasa de errores. Los logs son registros de eventos discretos generados por las aplicaciones y la infraestructura, que proporcionan información contextual detallada sobre operaciones específicas. Las trazas distribuidas permiten seguir el recorrido de una solicitud a través de múltiples servicios, identificando cuellos de botella y puntos de fallo en la cadena de procesamiento (Majors et al., 2022).

En el ecosistema de AWS, Amazon CloudWatch constituye el servicio central de observabilidad, proporcionando capacidades para la recolección, almacenamiento y consulta de métricas y logs de los servicios de la plataforma y de aplicaciones personalizadas. CloudWatch permite definir alarmas basadas en umbrales, realizar consultas sobre logs mediante CloudWatch Logs Insights y visualizar métricas en

dashboards operativos. Adicionalmente, AWS X-Ray ofrece capacidades de rastreo distribuido para aplicaciones desplegadas en la plataforma (Amazon Web Services, 2024). Estas herramientas, aunque potentes para la recolección y visualización de datos, no incorporan de forma nativa mecanismos de análisis inteligente que apoyen directamente el diagnóstico de causa raíz, lo cual constituye una de las motivaciones del presente proyecto.

10.1.3 Gestión de incidentes y Site Reliability Engineering

La gestión de incidentes en sistemas de producción ha sido formalizada por la disciplina de Site Reliability Engineering (SRE), propuesta originalmente por Google como un enfoque de ingeniería para la operación de sistemas a gran escala. Beyer et al. (2016), en el libro *Site Reliability Engineering: How Google Runs Production Systems*, definen un marco estructurado para la respuesta a incidentes que incluye fases de detección, triaje, mitigación, resolución y análisis posterior (postmortem). Este marco enfatiza la importancia de los indicadores de nivel de servicio (SLI) y los objetivos de nivel de servicio (SLO) como mecanismos cuantitativos para medir la confiabilidad y orientar las decisiones operativas.

El análisis de causa raíz (Root Cause Analysis, RCA) constituye un componente central en el ciclo de gestión de incidentes. Beyer et al. (2016) señalan que el análisis postmortem debe orientarse a identificar los factores contribuyentes que, al corregirse, reducen la probabilidad de recurrencia del incidente, reconociendo que en sistemas complejos rara vez existe una causa única y aislada. Esta perspectiva se alinea con la teoría de accidentes normales de Perrow (1999), que argumenta que los fallos en sistemas complejos y estrechamente acoplados son una propiedad emergente de la interacción entre componentes, más que el resultado de una falla individual.

Investigaciones recientes han analizado las prácticas de respuesta a incidentes en entornos cloud a gran escala. Chen et al. (2020), en un estudio empírico publicado en las actas de la *International Conference on Software Engineering (ICSE)*, analizaron más de 30 000 incidentes en servicios cloud de Microsoft y encontraron que el diagnóstico representa la fase más costosa en tiempo dentro del ciclo de vida del incidente, consumiendo en promedio más del 70 % del tiempo total de resolución. Este hallazgo evidencia la necesidad

de herramientas que asistan el proceso de diagnóstico para reducir los tiempos de recuperación.

10.1.4 AIOps: Inteligencia artificial para operaciones de TI

El término AIOps (Artificial Intelligence for IT Operations) fue acuñado por Gartner en 2017 para describir plataformas que combinan big data y aprendizaje automático con el objetivo de automatizar y mejorar las funciones de operación de TI, incluyendo la correlación de eventos, la detección de anomalías, la determinación de causa raíz y la automatización de acciones de remediación (Gartner, 2017). Desde entonces, AIOps ha ganado tracción tanto en la industria como en la academia como un enfoque para gestionar la creciente complejidad operativa de los sistemas modernos.

Notaro et al. (2021), en una revisión sistemática publicada en ACM Computing Surveys, proporcionan una taxonomía completa de las técnicas de AIOps organizadas en cuatro dominios funcionales: detección de anomalías, análisis de causa raíz, predicción de fallos y remediación automatizada. Los autores identifican que la mayor parte de la investigación se concentra en la detección de anomalías, mientras que el análisis de causa raíz automatizado permanece como un desafío abierto debido a la complejidad de las dependencias entre componentes y la diversidad de modos de fallo en sistemas distribuidos.

Dang et al. (2019), en un estudio publicado en IEEE/ACM International Conference on Automated Software Engineering (ASE), presentaron una revisión de las prácticas de AIOps implementadas en Microsoft, identificando que las soluciones más efectivas combinan técnicas de aprendizaje automático con conocimiento del dominio y retroalimentación de los ingenieros de operación. Este enfoque híbrido, en el que la inteligencia artificial complementa pero no reemplaza el juicio humano, es particularmente relevante para el presente proyecto, que propone un sistema de apoyo al diagnóstico y no un sistema de diagnóstico autónomo.

10.1.5 Análisis inteligente de logs y detección de anomalías

Los logs constituyen una de las fuentes de información más ricas para el diagnóstico de fallos en sistemas de software, al contener registros detallados de las operaciones ejecutadas, errores encontrados y estados del sistema. Sin embargo, el volumen, la velocidad y la heterogeneidad de los logs generados en entornos cloud distribuidos dificultan su análisis manual, motivando el desarrollo de técnicas automatizadas (He et al., 2021).

Un trabajo seminal en esta área es DeepLog, propuesto por Du et al. (2017) en las actas de la ACM Conference on Computer and Communications Security (CCS). DeepLog modela las secuencias de eventos de logs como un problema de predicción de la siguiente entrada utilizando redes neuronales LSTM (Long Short-Term Memory), permitiendo identificar secuencias anómalas que se desvían del comportamiento aprendido. Este enfoque demostró una mejora significativa respecto a los métodos basados en reglas y estadísticas tradicionales, al capturar dependencias temporales complejas en las secuencias de logs.

Posteriormente investigaciones han extendido estos resultados. Zhang et al. (2019) propusieron LogRobust, un método publicado en las actas del ACM Joint European Software Engineering Conference and Symposium on the Foundations of Software Engineering (ESEC/FSE), que aborda el problema de la inestabilidad de los logs causada por la evolución del código fuente, utilizando representaciones semánticas de los eventos de log para lograr una detección de anomalías más robusta ante cambios en el software. Le y Zhang (2022), en un estudio publicado en IEEE Transactions on Software Engineering, presentaron una evaluación exhaustiva y reproducible de múltiples técnicas de detección de anomalías basadas en logs, identificando fortalezas y limitaciones de cada enfoque y proponiendo directrices para su aplicación práctica.

He et al. (2021), en una revisión publicada en IEEE Transactions on Software Engineering, presentaron un survey completo sobre análisis automatizado de logs que cubre todo el pipeline desde el parsing de logs hasta la detección de anomalías, incluyendo técnicas de aprendizaje profundo (deep learning), aprendizaje no supervisado y métodos basados en grafos. Los autores concluyen que, si bien las técnicas actuales logran buenos resultados en datasets de referencia, su aplicación en entornos de producción reales sigue

presentando desafíos relacionados con la generalización, la escalabilidad y la interpretabilidad de los resultados.

10.1.6 Modelos de lenguaje de gran escala aplicados a operaciones

La aparición de modelos de lenguaje de gran escala (Large Language Models, LLM) ha abierto nuevas posibilidades para el análisis de información operativa y el apoyo al diagnóstico de incidentes. Los LLM, basados en la arquitectura Transformer propuesta por Vaswani et al. (2017), poseen capacidades avanzadas de comprensión y generación de lenguaje natural que permiten procesar, sintetizar y explicar información técnica compleja.

En el contexto específico de operaciones, Ahmed et al. (2023), en un estudio publicado en las actas de la International Conference on Software Engineering (ICSE), evaluaron el uso de modelos de lenguaje para la comprensión semántica de logs de software, demostrando que los LLM superan a los métodos tradicionales de representación de logs en tareas de clasificación y detección de anomalías. Los autores argumentan que la capacidad de los LLM para capturar el significado contextual de los mensajes de log, incluyendo variables dinámicas y patrones de error, representa una ventaja significativa sobre los enfoques puramente sintácticos.

Chen et al. (2024), en un trabajo presentado en IEEE International Conference on Cloud Engineering (IC2E), propusieron un marco para el diagnóstico asistido de incidentes cloud que combina la recolección automatizada de señales de observabilidad con la capacidad de razonamiento de los LLM para generar hipótesis de causa raíz y recomendaciones de mitigación. Los resultados experimentales mostraron una reducción significativa en el tiempo de diagnóstico comparado con procesos manuales tradicionales, aunque los autores enfatizan la necesidad de mantener al operador humano en el ciclo de decisión para validar las recomendaciones generadas.

En el ámbito específico de AWS, la plataforma ha incorporado servicios que integran inteligencia artificial generativa para operaciones, como Amazon Q Developer y Amazon DevOps Guru, los cuales utilizan modelos de aprendizaje automático para detectar comportamientos anómalos y generar recomendaciones operativas (Amazon Web Services, 2024). Estos servicios, aunque comerciales y de alcance limitado, evidencian la

tendencia de la industria hacia la integración de capacidades inteligentes en las herramientas de operación cloud.

10.1.7 Análisis automatizado de causa raíz en sistemas distribuidos

El análisis automatizado de causa raíz (Automated Root Cause Analysis) representa uno de los desafíos más complejos en AIOps, debido a la necesidad de correlacionar múltiples señales de diferentes fuentes, considerar las dependencias entre componentes y distinguir entre síntomas y causas en entornos altamente dinámicos. Soldani y Brogi (2022), en una revisión sistemática publicada en Journal of Systems and Software (Elsevier), analizaron 50 estudios primarios sobre análisis automatizado de causa raíz en sistemas basados en microservicios, identificando tres enfoques predominantes: métodos basados en grafos de dependencias, técnicas de correlación estadística y enfoques basados en aprendizaje automático.

Meng et al. (2020), en un artículo publicado en IEEE Transactions on Network and Service Management, propusieron un enfoque basado en grafos causales para la localización de fallos en sistemas de microservicios, utilizando datos de métricas y trazas para construir modelos de dependencia y propagación de anomalías. Los resultados experimentales demostraron la viabilidad de estos enfoques para reducir el espacio de búsqueda del diagnóstico, aunque su efectividad depende significativamente de la calidad y completitud de los datos de observabilidad disponibles.

En síntesis, el sustento teórico del presente proyecto se articula en torno a seis ejes fundamentales: (i) los fundamentos de la computación en la nube y las arquitecturas distribuidas como contexto operativo; (ii) la observabilidad como disciplina para comprender el comportamiento de sistemas complejos; (iii) las prácticas de gestión de incidentes y SRE como marco de referencia operativo; (iv) el enfoque de AIOps como paradigma para la automatización del análisis operativo; (v) las técnicas de análisis inteligente de logs y detección de anomalías como herramientas de soporte; y (vi) los avances recientes en modelos de lenguaje de gran escala aplicados a operaciones como base tecnológica para el componente inteligente del sistema propuesto. La convergencia de estas áreas sustenta

la viabilidad técnica de la solución planteada y delimita el alcance del análisis dentro del proyecto de profundización.

10.2 MARCO CONCEPTUAL

El marco conceptual delimita y define los términos técnicos fundamentales que se emplean a lo largo del proyecto, estableciendo un lenguaje común que facilita la comprensión del problema y la solución propuesta. Las definiciones presentadas se sustentan en la literatura técnica y académica revisada en el marco teórico.

- **Computación en la nube (Cloud Computing):** modelo que permite el acceso bajo demanda a un conjunto compartido de recursos computacionales configurables, aprovisionados y liberados de forma rápida con un esfuerzo mínimo de gestión o interacción con el proveedor del servicio (Mell & Grance, 2011).
- **Microservicios:** estilo de arquitectura de software en el cual una aplicación se estructura como un conjunto de servicios pequeños, desplegables de forma independiente, cada uno ejecutándose en su propio proceso y comunicándose mediante mecanismos ligeros como APIs REST o mensajería asíncrona (Newman, 2021).
- **Observabilidad:** propiedad de un sistema que permite inferir su estado interno a partir del análisis de sus salidas externas, principalmente métricas, logs y trazas distribuidas. A diferencia del monitoreo, la observabilidad permite explorar y diagnosticar comportamientos no anticipados previamente (Sridharan, 2018).
- **Logs:** registros inmutables de eventos discretos generados por aplicaciones, servicios y componentes de infraestructura, que contienen información contextual sobre operaciones ejecutadas, errores encontrados y transiciones de estado del sistema (He et al., 2021).
- **Métricas:** representaciones numéricas del comportamiento de recursos y servicios medidas a lo largo del tiempo, tales como uso de CPU, latencia de solicitudes, tasa

de errores y saturación de memoria, utilizadas para identificar tendencias, patrones y condiciones anómalas (Beyer et al., 2016).

- **Trazas distribuidas:** registros que capturan el recorrido completo de una solicitud a través de múltiples servicios y componentes en una arquitectura distribuida, permitiendo visualizar la cadena de llamadas, identificar cuellos de botella y localizar puntos de fallo (Majors et al., 2022).
- **Incidente operativo:** evento no planificado que causa o puede causar una interrupción o degradación en la calidad de un servicio, requiriendo una respuesta estructurada que incluye detección, triaje, diagnóstico, mitigación y análisis posterior (Beyer et al., 2016).
- **Causa raíz (Root Cause):** factor o conjunto de factores contribuyentes cuya corrección reduce significativamente la probabilidad de recurrencia de un incidente. En sistemas complejos, el análisis de causa raíz reconoce que múltiples factores pueden interactuar para producir un fallo (Soldani & Brogi, 2022).
- **Site Reliability Engineering (SRE):** disciplina de ingeniería que aplica principios de ingeniería de software a la operación de infraestructura y sistemas de producción, enfocada en la creación de sistemas escalables y confiables mediante la automatización, los indicadores de nivel de servicio y la gestión estructurada de incidentes (Beyer et al., 2016).
- **AIOps (Artificial Intelligence for IT Operations):** enfoque que combina big data, analítica y técnicas de aprendizaje automático para automatizar y mejorar funciones de operación de TI, incluyendo la detección de anomalías, la correlación de eventos, el análisis de causa raíz y la remediación automatizada (Notaro et al., 2021).
- **Detección de anomalías en logs:** conjunto de técnicas computacionales que identifican secuencias, patrones o eventos inusuales en los registros del sistema que se desvían del comportamiento normal aprendido, señalando potenciales fallos o degradaciones (Du et al., 2017).

- **Modelo de lenguaje de gran escala (LLM):** modelo de aprendizaje profundo basado en la arquitectura Transformer, entrenado sobre grandes corpus textuales, que posee capacidades avanzadas de comprensión, generación y razonamiento sobre lenguaje natural y técnico (Vaswani et al., 2017).
- **Diagnóstico asistido:** enfoque en el cual componentes inteligentes apoyan el análisis humano mediante la priorización de señales relevantes, la correlación automatizada de evidencia y la generación de hipótesis de causa raíz, manteniendo al operador en el control del proceso de decisión (Dang et al., 2019).
- **Amazon CloudWatch:** servicio de observabilidad de AWS que proporciona capacidades para la recolección, almacenamiento, consulta y visualización de métricas y logs provenientes de servicios de la plataforma y aplicaciones personalizadas (Amazon Web Services, 2024).

10.3 MARCO ESPACIAL

El presente proyecto se delimita al ámbito de los entornos de computación en la nube basados en Amazon Web Services (AWS), considerando específicamente aplicaciones desplegadas sobre servicios gestionados de la plataforma que generan información de observabilidad accesible mediante los mecanismos nativos de AWS.

La solución propuesta se enfoca en el análisis de datos de telemetría, incluyendo métricas, logs y eventos, generados por servicios de cómputo (Amazon EC2, AWS Lambda, Amazon ECS), almacenamiento, bases de datos y servicios de aplicación, integrables con Amazon CloudWatch como punto central de recolección y consulta. El alcance del proyecto no contempla la extensión a otros proveedores de nube ni la integración con herramientas de observabilidad de terceros, aunque la arquitectura propuesta podría adaptarse a otros contextos con las modificaciones pertinentes.

En términos organizacionales, el proyecto se orienta al contexto operativo típico de equipos de ingeniería, DevOps y SRE que administran cargas de trabajo en AWS y enfrentan la

necesidad de diagnosticar fallos en entornos distribuidos con múltiples servicios interdependientes.

10.4 MARCO TEMPORAL

El desarrollo del proyecto de profundización se enmarca en el periodo académico correspondiente al año 2026, abarcando las fases de análisis, diseño, implementación y validación del sistema propuesto, de acuerdo con el cronograma establecido para la Maestría en Ciencias de la Información y las Comunicaciones de la Universidad Distrital Francisco José de Caldas.

En términos del alcance temporal de los datos utilizados, el sistema operará sobre información de observabilidad generada durante ventanas de tiempo asociadas a incidentes simulados o controlados en entornos de prueba. Estas ventanas considerarán datos del intervalo previo, durante y posterior al evento de fallo, con el fin de evaluar la capacidad del sistema para correlacionar señales y apoyar el diagnóstico en escenarios reproducibles. Se aprovecharán las capacidades de retención y consulta histórica de métricas (hasta 15 meses en CloudWatch) y la centralización de logs mediante CloudWatch Logs, para soportar las pruebas y la evaluación del sistema.

En cuanto al contexto tecnológico, el proyecto se desarrolla en un momento en el que la convergencia de la observabilidad cloud, las técnicas de AIOps y los modelos de lenguaje de gran escala ha alcanzado un nivel de madurez que permite su integración práctica en soluciones de ingeniería, como lo evidencian las publicaciones académicas y los servicios comerciales revisados en el marco teórico.

11. METODOLOGÍA

La metodología del presente proyecto de profundización se orienta al diseño e implementación de una solución tecnológica aplicada, cuyo objetivo es apoyar el diagnóstico de fallos operativos en entornos cloud basados en AWS mediante el uso de técnicas de observabilidad e inteligencia artificial. El enfoque metodológico prioriza la construcción de un sistema funcional, su validación técnica y la evaluación de su utilidad en escenarios reales de operación, más que la generación de nuevo conocimiento teórico.

Desde el punto de vista epistemológico, el proyecto se enmarca en un enfoque pragmático orientado a la resolución de problemas de ingeniería, adoptando un tipo de investigación aplicada con alcance exploratorio-descriptivo. El método general seleccionado es Design Science Research (DSR), el cual resulta apropiado para proyectos de profundización que buscan diseñar, construir y evaluar artefactos tecnológicos como respuesta a problemas identificados en contextos reales (Hevner et al., 2004). Este enfoque permite estructurar el trabajo en ciclos de diseño, implementación y evaluación, garantizando la trazabilidad entre el problema identificado y la solución desarrollada.

La metodología se estructura en fases secuenciales, permitiendo abordar el problema de manera organizada y controlada:

Fase 1. Análisis del problema y caracterización del entorno

En esta fase se realiza el análisis del contexto operativo de aplicaciones desplegadas en AWS, identificando los principales tipos de fallos operativos y las dificultades asociadas a su diagnóstico. Se estudian las fuentes de información de observabilidad disponibles, tales como métricas, registros y eventos generados por servicios como Amazon CloudWatch, así como su relación con incidentes operativos comunes en arquitecturas cloud.

Como resultado de esta fase, se definen los requisitos funcionales y técnicos del sistema inteligente, así como los criterios que permitirán evaluar su desempeño en el apoyo al diagnóstico de fallos.

Fase 2. Diseño de la arquitectura de la solución

Con base en el análisis previo, se diseña la arquitectura del sistema propuesto, definiendo sus componentes principales, flujos de información e integración con servicios de AWS. Esta arquitectura contempla mecanismos para la recolección, procesamiento y correlación de información de observabilidad, así como la incorporación de componentes inteligentes para el análisis automatizado de datos operativos.

El diseño busca garantizar escalabilidad, seguridad y alineación con buenas prácticas de arquitectura cloud, considerando escenarios reales de operación y diagnóstico.

Fase 3. Implementación del sistema inteligente

En esta fase se implementa la solución propuesta, desarrollando los componentes necesarios para la ingesta y análisis de métricas, logs y eventos, así como los módulos de inteligencia artificial encargados de asistir el diagnóstico de fallos operativos. El componente inteligente del sistema se implementará utilizando Amazon Bedrock como servicio de acceso a modelos de lenguaje de gran escala (LLM), específicamente el modelo Anthropic Claude Sonnet, seleccionado por su capacidad de razonamiento técnico, comprensión contextual de logs y métricas, y su integración nativa con el ecosistema de AWS. El patrón de integración adoptado será Retrieval-Augmented Generation (RAG), en el cual la información de observabilidad recolectada (métricas, logs y eventos) se estructura y se proporciona como contexto al modelo para la generación de hipótesis de causa raíz. La orquestación del flujo de datos se realizará mediante funciones AWS Lambda y la información de observabilidad se consultará a través de las APIs de Amazon CloudWatch Logs Insights y CloudWatch Metrics. El sistema se configura para operar sobre entornos controlados que simulan condiciones reales de fallo.

La implementación se enfoca en la generación de resultados interpretables para los equipos de ingeniería, tales como resúmenes técnicos, correlaciones relevantes y posibles hipótesis de causa raíz.

Fase 4. Validación técnica y evaluación del sistema

Una vez implementado el sistema, se realiza su validación mediante un conjunto de al menos cinco escenarios de fallo controlados y reproducibles, que incluyen: (a) fallo por

agotamiento de recursos de cómputo en EC2, (b) errores de timeout en invocaciones Lambda, (c) degradación de latencia en servicios de bases de datos, (d) fallos de conectividad entre microservicios, y (e) errores de configuración en políticas de seguridad. Cada escenario se ejecuta en un entorno de prueba aislado en la cuenta personal de AWS del autor, con condiciones iniciales documentadas y reproducibles.

La evaluación comparativa se realiza contrastando el diagnóstico asistido por el sistema con el diagnóstico manual realizado por un panel de tres evaluadores con experiencia en operación de infraestructura AWS (mínimo dos años de experiencia profesional en roles de DevOps o SRE). Los evaluadores analizan cada escenario de fallo de forma independiente, primero sin acceso al sistema (línea base manual) y posteriormente con acceso al sistema (diagnóstico asistido), siguiendo un diseño within-subjects con contrabalanceo de orden para mitigar efectos de aprendizaje. Las métricas de evaluación definidas a priori son: (i) tiempo medio de diagnóstico (MTTD), medido desde la notificación del incidente hasta la identificación correcta de la causa raíz; (ii) precisión del diagnóstico, calculada como el porcentaje de escenarios en los que se identifica correctamente la causa raíz; (iii) F1-score de las hipótesis generadas, evaluando la proporción de hipótesis relevantes frente al total de hipótesis presentadas; y (iv) porcentaje de reducción del tiempo de análisis, comparando el MTTD del diagnóstico asistido frente al diagnóstico manual. Se espera que el sistema demuestre una reducción de al menos el 30% en el tiempo medio de diagnóstico respecto al análisis manual en los escenarios evaluados.

Fase 5. Análisis de resultados y conclusiones

Finalmente, se analizan los resultados obtenidos durante la validación del sistema, identificando fortalezas, limitaciones y oportunidades de mejora. Esta fase permite consolidar las conclusiones del proyecto, destacando los aportes tecnológicos alcanzados y su aplicabilidad en entornos reales de operación cloud.

12. IMPACTO Y RESULTADOS ESPERADOS

El presente proyecto de profundización se orienta al desarrollo de una solución tecnológica aplicada para el apoyo al diagnóstico de fallos operativos en entornos cloud basados en AWS. El impacto del proyecto se relaciona directamente con la utilidad práctica de la solución propuesta, los beneficios para los equipos de ingeniería que operan infraestructuras cloud y el fortalecimiento de competencias técnicas en el área de computación en la nube y observabilidad.

El impacto esperado no se asocia a la generación de nuevo conocimiento científico, sino a la integración y aplicación de tecnologías existentes en un contexto real de ingeniería, contribuyendo a la mejora de los procesos de análisis, diagnóstico y respuesta ante incidentes operativos.

12.1 Resultados esperados

Como resultado del desarrollo del proyecto, se espera obtener los siguientes productos y resultados:

- Un sistema inteligente funcional capaz de analizar información de observabilidad (métricas, registros y eventos) proveniente de entornos cloud basados en AWS.
- Una arquitectura técnica documentada que integre servicios de AWS y componentes de inteligencia artificial orientados al apoyo del diagnóstico de fallos operativos.
- Un conjunto de escenarios de prueba que permitan validar el funcionamiento del sistema ante fallos operativos comunes en aplicaciones desplegadas en la nube.
- Documentación técnica que describa el diseño, implementación y validación del sistema desarrollado, como parte del trabajo de grado de profundización.

12.2 Impacto tecnológico

El proyecto aporta al fortalecimiento de prácticas de operación y soporte en entornos cloud, al proponer una solución que reduce la dependencia exclusiva del análisis manual de métricas y registros. El sistema desarrollado busca mejorar la eficiencia en el diagnóstico de fallos, disminuyendo los tiempos de análisis y facilitando la identificación de posibles causas raíz mediante el uso de técnicas de observabilidad e inteligencia artificial.

Este impacto resulta relevante para equipos de ingeniería, DevOps y SRE que operan infraestructuras en AWS y enfrentan desafíos asociados a la complejidad y volumen de información operativa.

12.3 Impacto en la formación profesional

Desde el ámbito académico, el proyecto contribuye a la formación del estudiante en áreas clave de la ingeniería moderna, tales como computación en la nube, observabilidad de sistemas, arquitectura de software e inteligencia artificial aplicada. El desarrollo de la solución fortalece competencias prácticas y técnicas, alineadas con necesidades reales del sector tecnológico.

Asimismo, el proyecto puede servir como referencia para futuros trabajos de profundización relacionados con operación, monitoreo y análisis de sistemas cloud.

12.4 Beneficiarios del proyecto

Los principales beneficiarios del proyecto son:

- Equipos de ingeniería y operación que administran aplicaciones desplegadas en entornos cloud basados en AWS.
- Estudiantes y profesionales interesados en soluciones aplicadas de observabilidad e inteligencia artificial en la nube.
- La Universidad Distrital Francisco José de Caldas, al contar con un proyecto de profundización alineado con áreas estratégicas de la ingeniería y tecnologías actuales.

13. RECURSOS Y PRESUPUESTO

El desarrollo del presente proyecto de profundización requiere recursos humanos, tecnológicos y de software orientados al diseño, implementación y validación del sistema inteligente propuesto. Dado el carácter aplicado del proyecto, los principales costos se asocian al uso de infraestructura cloud y herramientas tecnológicas necesarias para el análisis de información de observabilidad en entornos AWS.

A continuación se presenta la estimación de recursos y costos asociados al desarrollo del proyecto, considerando un periodo de ejecución de doce semanas.

13.1 Recursos humanos

Recurso	Cantidad	Costo unitario	Costo total (USD)
Investigador (autor)	240 horas	20 USD	\$ 4.800
Director del proyecto	12 semanas	150 USD	\$ 1.800
Evaluadores externos (validación)	3 personas	Voluntario	\$ 0,00

13.2 Recursos tecnológicos e infraestructura AWS

Servicio / Recurso	Descripción	Uso estimado	Costo estimado (USD)
Amazon EC2	Instancias para simulación de fallos (t3.medium)	~200 h	\$ 8,40
AWS Lambda	Orquestación de flujos y funciones del sistema	~50.000 invoc.	\$ 1,00
Amazon CloudWatch	Métricas, logs, alarmas y Logs Insights	12 semanas	\$ 15,00
Amazon Bedrock (LLM)	Anthropic Claude Sonnet – análisis y diagnóstico	~2M tokens	\$ 30,00
Amazon ECS / Fargate	Contenedores para escenarios de microservicios	~100 h	\$ 5,00
Otros servicios AWS	S3, IAM, VPC, SNS, X-Ray	12 semanas	\$ 5,00
Computador personal	Desarrollo, pruebas y documentación	1 unidad	\$ 0,00 (recurso propio)
TOTAL ESTIMADO			\$ 6.664,4 USD

Tabla 2. Estimación de recursos y costos del proyecto.

Los costos de Amazon Bedrock corresponden a la tarifa por token de entrada y salida del modelo Anthropic Claude Sonnet, estimando aproximadamente 2 millones de tokens procesados durante las fases de desarrollo y validación. Los costos de infraestructura AWS se calculan con base en las tarifas vigentes de la región us-east-1 y pueden variar según el uso real. El presupuesto total estimado del proyecto es de USD 6.664,40, financiado con recursos propios del autor a través de su cuenta personal de AWS.

14. CRONOGRAMA

El cronograma del proyecto se estructura en un periodo de doce semanas, distribuidas en las cinco fases definidas en la metodología. La siguiente tabla presenta el diagrama de Gantt con la planificación temporal de las actividades, indicando las semanas en las que se ejecutará cada una.

Fase	Actividad	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	S11	S12
Fase 1	Revisión de literatura y estado del arte sobre observabilidad, AIOps y diagnóstico de fallos en entornos cloud												
	Análisis de fuentes de observabilidad en AWS y caracterización de tipos de fallos operativos												
	Definición de requisitos funcionales y técnicos del sistema												
Fase 2	Diseño de la arquitectura del sistema inteligente y definición de componentes												
	Selección de servicios AWS, modelo LLM (Amazon Bedrock) y tecnologías de IA												
Fase 3	Implementación del módulo de ingesta y procesamiento de métricas y logs												
	Implementación del componente inteligente de análisis y correlación (RAG con Anthropic Claude)												
	Integración de componentes y pruebas unitarias												
Fase 4	Diseño y ejecución de escenarios de prueba con fallos simulados												
	Evaluación comparativa del sistema frente a diagnóstico manual (MTTD, precisión, F1-score)												
Fase 5	Documentación técnica del sistema y elaboración del documento final												
	Preparación y sustentación del trabajo de grado												

Tabla 1. Cronograma de actividades del proyecto de profundización.

15. LIMITACIONES

El presente proyecto de profundización presenta las siguientes limitaciones que deben ser consideradas al evaluar el alcance y los resultados obtenidos:

- **Entorno no productivo:** el sistema no será desplegado ni validado en entornos de producción reales. Toda la implementación, pruebas y evaluación se realizarán en una cuenta personal de AWS, con recursos aprovisionados exclusivamente para fines académicos. Al finalizar el proyecto, todos los recursos de infraestructura cloud serán destruidos, por lo que la solución no permanecerá operativa después de la fase de validación. Esta condición implica que los resultados reflejan el comportamiento del sistema en un entorno controlado y simulado, y su extrapolación a entornos productivos requeriría validaciones adicionales.
- **Alcance limitado de servicios AWS:** la solución se enfoca en un subconjunto acotado de servicios de AWS y tipos de fallos operativos. No se pretende cubrir la totalidad de los servicios de la plataforma ni todos los posibles modos de fallo en arquitecturas cloud, sino aquellos que resulten representativos y viables dentro del alcance del proyecto.
- **Escenarios de fallo simulados:** la validación del sistema se realizará mediante escenarios de fallo controlados y reproducibles, lo que puede no capturar la totalidad de la variabilidad y complejidad de los incidentes que ocurren en entornos de producción con cargas de trabajo reales.
- **Costos de infraestructura:** al tratarse de una cuenta personal de AWS, el presupuesto disponible para la ejecución de pruebas y el uso de servicios de la plataforma es limitado. Esto puede restringir la escala de los escenarios de prueba y el volumen de datos de observabilidad generados durante la fase de validación.
- **Dependencia de servicios de terceros:** el sistema depende de la disponibilidad, funcionalidad y políticas de uso de los servicios de AWS y de los modelos de

inteligencia artificial utilizados. Cambios en las condiciones de servicio, precios o características de estas plataformas podrían afectar la reproducibilidad de la solución.

Estas limitaciones se consideran propias del alcance de un proyecto de profundización y no comprometen la validez de los resultados obtenidos dentro del contexto académico y técnico definido. La documentación técnica generada permitirá que la solución pueda ser replicada o adaptada en otros entornos en el futuro.

16. REFERENCIAS

- Ahmed, T., Devanbu, P., & Hellendoorn, V. (2023). Recommending root-cause and mitigation steps for cloud incidents using large language models. *Proceedings of the 45th International Conference on Software Engineering (ICSE '23)*. IEEE/ACM.
- Amazon Web Services. (2024). *Amazon CloudWatch User Guide*. <https://docs.aws.amazon.com/AmazonCloudWatch/latest/monitoring/>
- Beyer, B., Jones, C., Petoff, J., & Murphy, N. R. (2016). *Site Reliability Engineering: How Google Runs Production Systems*. O'Reilly Media.
- Chen, J., He, X., Lin, Q., Xu, Y., Zhang, H., Hao, D., Gao, F., Xu, Z., Dang, Y., & Zhang, D. (2020). An empirical investigation of incident triage for online service systems. *Proceedings of the 42nd International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP '20)*. ACM.
- Chen, X., Lin, Q., Zhang, D., & Zhang, H. (2024). LLM-assisted diagnosis of cloud incidents using observability data. *IEEE International Conference on Cloud Engineering (IC2E)*. IEEE.
- Dang, Y., Lin, Q., & Huang, P. (2019). AIOps: Real-world challenges and research innovations. *Proceedings of the IEEE/ACM 41st International Conference on Software Engineering: Companion (ICSE-Companion '19)*. IEEE/ACM.
- Du, M., Li, F., Zheng, G., & Srikumar, V. (2017). DeepLog: Anomaly detection and diagnosis from system logs through deep learning. *Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS '17)*, 1285–1298. ACM.
- Gartner. (2017). *Market Guide for AIOps Platforms*. Gartner, Inc.
- Gartner. (2024). *Magic Quadrant for Cloud Infrastructure and Platform Services*. Gartner, Inc.

- He, S., Zhu, J., He, P., & Lyu, M. R. (2021). A survey on automated log analysis for reliability engineering. *ACM Computing Surveys*, 54(6), 1–37.
- Jamshidi, P., Pahl, C., Mendonça, N. C., Lewis, J., & Tilkov, S. (2018). Microservices: The journey so far and challenges ahead. *IEEE Software*, 35(3), 24–35.
- Le, V. H., & Zhang, H. (2022). Log-based anomaly detection with deep learning: How far are we? *Proceedings of the 44th International Conference on Software Engineering (ICSE '22)*. ACM.
- Majors, C., Fong-Jones, L., & Miranda, G. (2022). *Observability Engineering: Achieving Production Excellence*. O'Reilly Media.
- Mell, P., & Grance, T. (2011). *The NIST definition of cloud computing* (Special Publication 800-145). National Institute of Standards and Technology.
- Meng, Y., Zhang, S., Sun, Y., Zhang, R., Hu, Z., Zhang, Y., Jia, C., Wang, Z., & Pei, D. (2020). Localizing failure root causes in a microservice through causality inference. *IEEE/ACM 28th International Symposium on Quality of Service (IWQoS)*. IEEE.
- Newman, S. (2021). *Building Microservices: Designing Fine-Grained Systems* (2nd ed.). O'Reilly Media.
- Notaro, P., Cardoso, J., & Gerndt, M. (2021). A systematic mapping study in AIOps. *Proceedings of the International Conference on Service-Oriented Computing (ICSOC 2020)*. Springer.
- Perrow, C. (1999). *Normal Accidents: Living with High-Risk Technologies* (Updated ed.). Princeton University Press.
- Soldani, J., & Brogi, A. (2022). Anomaly detection and failure root cause analysis in (micro)service-based cloud applications: A survey. *ACM Computing Surveys*, 55(3), 1–39.
- Sridharan, C. (2018). *Distributed Systems Observability*. O'Reilly Media.

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Zhang, X., Xu, Y., Lin, Q., Qiao, B., Zhang, H., Dang, Y., Xie, C., Yang, X., Cheng, Q., Li, Z., Chen, J., He, X., Yao, R., Lou, J., Chintalapati, M., Shen, F., & Zhang, D. (2019). Robust log-based anomaly detection on unstable log data. *Proceedings of the 27th ACM Joint European Software Engineering Conference and Symposium on the Foundations of Software Engineering (ESEC/FSE '19)*, 807–817. ACM.
- Zhou, X., Peng, X., Xie, T., Sun, J., Ji, C., Li, W., & Ding, D. (2021). Fault analysis and debugging of microservice systems: Industrial survey, benchmark system, and empirical study. *IEEE Transactions on Software Engineering*, 47(12), 3421–3447.