



INVESTIGACIÓN __X__

PROFUNDIZACIÓN ____

Diseño de un modelo para la identificación de URLs maliciosas o potencialmente fraudulentas en servicios financieros colombianos

Autor

Francisco Javier González Aguirre

Director

Ing. Roberto Ferro Escobar PhD

Codirector

Ing. Carlos Andrés Martínez Alayón MsC

Universidad Distrital Francisco José De Caldas

Maestría en Ciencias de la Información y las Comunicaciones

Énfasis en Teleinformática

Bogotá, Colombia

mayo de 2025

Contenido

1. Grupo de investigación	5
1.1 Objetivos	5
1.2 Misión	5
1.3 Visión.....	6
1.4 Proyectos destacados	6
2. Línea de investigación	6
3. Director y Codirector	7
3.1 Director.....	7
3.2 Codirector.....	7
4. Resumen	8
5. Palabras clave	9
6. Introducción	9
7. Problema de investigación.....	11
7.1 Planteamiento del problema	11
7.2 Formulación del problema	12
7.3 Sistematización del problema	12
8. Objetivos.....	14
8.1 Objetivo general	14
8.2 Objetivos específicos.....	14
9. Justificación	15
9.1 Justificación teórica	15
9.2 Justificación metodológica.....	15

10.	Marco de referencia	17
10.1	Marco Teórico	17
10.1.1	Introducción	17
10.1.2	Uniform Resource Locators	18
10.1.3	Técnicas de detección	19
10.2	Marco conceptual	21
10.3	Marco espacial	31
10.4	Marco Temporal	31
11.	Hipótesis	31
12.	Metodología	32
13.	Impacto y resultados esperados.....	34
14.	Recursos y presupuesto.....	37
15.	Cronograma	38
16.	Limitaciones	40
17.	Referencias.....	41

1. Grupo de investigación

El grupo LIDER (Laboratorio de Investigación y Desarrollo en Electrónica y Redes) es un grupo de investigación de categoría A de la Universidad Distrital Francisco José de Caldas. Fue creado en el año 2007 e institucionalizado a través del Acta 005-09 del Centro de Investigaciones y Desarrollo Científico (CIDC) de la Universidad Distrital.

1.1 OBJETIVOS

- Realizar investigación y desarrollo tecnológico avanzado en TIC y creación de tecnología aplicada en el área de Telemática, Telecomunicaciones y Electrónica.
- Crear soluciones basadas en tecnología emergente de alta calidad con aplicación en la solución de problemas técnicos y de carácter práctico a nivel nacional e internacional.
- Formar estudiantes con altos estándares de calidad y conocimiento en los tópicos de interés del grupo.
- Realizar patentes y nuevos diseños que puedan ser aplicados a nivel institucional dentro y fuera del país.
- Crear nuevas aplicaciones en electrónica, redes, informática y software que integren servicios de alta tecnología y contribuyan al desarrollo tecnológico de la Universidad Distrital y su proyección social a nivel local y nacional.

1.2 MISIÓN

Formular y ejecutar, en todas sus etapas, proyectos de investigación, desarrollo e innovación en las áreas de estudio de las líneas de investigación definidas, que propendan por la creación de soluciones basadas en tecnología emergente de alta calidad con

aplicación en la solución de problemas técnicos y de carácter práctico a nivel nacional e internacional.

1.3 VISIÓN

El Grupo de Investigación LIDER será, en un lapso no superior a 5 años, un grupo de excelencia reconocido a nivel universitario en el ámbito local y nacional, y valorado por la comunidad científica internacional por sus aportes al estudio e innovación en las áreas de interés.

1.4 PROYECTOS DESTACADOS

En el marco de las líneas de investigación del grupo, actualmente se desarrolla el proyecto doctoral titulado “Estructuración de un modelo, para el análisis, simulación y aplicación de tecnologías LPWAN, a través de la integración comunitaria de redes IoT al agro inteligente en sectores rurales colombianos”, bajo la dirección del docente tutor Roberto Ferro. Este proyecto ha sido institucionalizado sin recursos por el Consejo de la Facultad de Ingeniería y está registrado en el Sistema de Información del Centro de Investigaciones (SICIUD), evidenciando el compromiso del grupo con la investigación aplicada y el desarrollo tecnológico en contextos rurales del país.

2. Línea de investigación

El proyecto se enmarcará en las líneas de investigación Administración de Redes de Nueva Generación (IPv6), Redes IPv4 y Redes de Telefonía Móvil Celular y Ciudades inteligentes y aplicaciones de la matemática en el mejoramiento en problemas de ingeniería.

3. Director y Codirector

3.1 DIRECTOR

Roberto Ferro Escobar. Ingeniero Electrónico y Magister en Teleinformática de la Universidad Distrital Francisco José de Caldas. Doctor en Ingeniería Informática, Sociedad de la Información y Gestión del Conocimiento de la Universidad Pontificia de Salamanca. Fue Coordinador del Proyecto Curricular de Ingeniería Electrónica de la Universidad Distrital, Decano de la Facultad de Ingeniería, director de la Red de Investigaciones de Tecnología Avanzada - RITA y, actualmente, es Docente Titular de carrera en la misma Universidad. Director del Grupo LIDER - Laboratorio de Investigaciones y Desarrollo en Electrónica y Redes de la Universidad Distrital Francisco José de Caldas.

3.2 CODIRECTOR

Carlos Andrés Martínez Alayón. Ingeniero Electrónico y Magister en Ciencias de la Información y las Comunicaciones con énfasis en Teleinformática de la Universidad Distrital Francisco José de Caldas. Especialista tecnológico en Seguridad de Redes. Estudiante del Doctorado en Ingeniería de la Universidad Distrital. Ha trabajado como Coordinador y Gestor de proyectos en Redes académicas y de investigación, y actualmente es coordinador en RITA-UD. Codirector del Grupo de investigación LIDER (Laboratorio de Investigación y Desarrollo en Electrónica y Redes) de la Universidad Distrital. Con experiencia profesional en diseño e implementación de Redes y servicios de Telecomunicaciones e informática. Docente en el área de Redes y Telecomunicaciones de la Universidad Distrital Francisco José de Caldas.

4. Resumen

En el presente documento se propone desarrollar una solución basada en inteligencia artificial para combatir amenazas cibernéticas crecientes en Colombia, particularmente aquellas que afectan al sector financiero. Ataques como el phishing, smishing y el uso de enlaces maliciosos en plataformas de mensajería representan un riesgo serio para los usuarios, quienes pueden ser engañados para entregar información sensible o instalar malware. Es destacable la necesidad de un modelo que identifique proactivamente URLs maliciosas, contribuyendo así a mejorar la seguridad digital de usuarios y entidades financieras.

La presente propuesta se fundamenta conceptualmente en el uso de técnicas avanzadas de detección como el aprendizaje automático y profundo (Machine Learning y Deep Learning), y considera múltiples enfoques como Random Forest, SVM, RNN, LSTM y Transformers, así como el uso de embeddings de caracteres y análisis de características léxicas, de contenido y de comportamiento. Además, se consideran distintas técnicas de detección actualmente utilizadas —como listas negras, análisis heurísticos, o herramientas en la nube y el navegador—, se plantea una hipótesis que defiende la eficacia de un modelo híbrido que combine estos elementos para lograr una detección precisa, incluso ante amenazas desconocidas (zero-day).

Se espera que el desarrollo del modelo tenga un alto impacto en la ciberseguridad nacional, permitiendo una reducción en los fraudes financieros mediante la identificación automática de URLs maliciosas. Entre los resultados esperados están la creación de un conjunto de datos específico del sector financiero colombiano, el fortalecimiento de la capacidad científica de la Universidad Distrital y su grupo de investigación LIDER, y la publicación de artículos científicos. El proyecto, además de su valor técnico, tiene proyecciones estratégicas en la mejora de la confianza en los servicios financieros digitales del país.

5. Palabras clave

Ciberseguridad, URLs maliciosas, Aprendizaje automático, Phishing, Servicios financieros

6. Introducción

El crecimiento acelerado de los servicios financieros digitales en Colombia ha traído consigo una mayor exposición a riesgos cibernéticos, especialmente aquellos relacionados con el uso de enlaces maliciosos o potencialmente fraudulentos. Estos ataques, que comúnmente se manifiestan a través de técnicas de ingeniería social como el phishing o el smishing, explotan la confianza del usuario para engañarlo y obtener acceso a información sensible, como credenciales bancarias o datos personales. Esta problemática se ha intensificado por el uso de plataformas de mensajería como WhatsApp, Telegram o SMS, donde los ciberdelincuentes simulan comunicaciones legítimas para inducir al usuario a visitar URLs peligrosas.

Ante este panorama, se hace necesario el desarrollo de herramientas que permitan identificar de forma automática y eficaz los enlaces que representan una amenaza, antes de que el usuario interactúe con ellos. Si bien existen mecanismos tradicionales como listas negras o filtros heurísticos, estos resultan insuficientes frente a ataques nuevos o sofisticados que logran evadir las técnicas de detección convencionales. En respuesta a esta necesidad, el presente anteproyecto propone el diseño de un modelo basado en técnicas de inteligencia artificial, específicamente aprendizaje automático y aprendizaje profundo, que permita detectar URLs maliciosas en el contexto de los servicios financieros colombianos.

El modelo propuesto busca ir más allá de la detección basada en firmas estáticas, incorporando enfoques predictivos capaces de identificar patrones complejos mediante el

análisis de características léxicas, semánticas y de comportamiento. Su desarrollo no solo contribuirá a mejorar la seguridad informática en el sector financiero, sino que también fortalecerá el ecosistema de ciberseguridad nacional, al aportar una solución adaptable, escalable y contextualizada a la realidad digital del país. Este proyecto, enmarcado en las líneas de investigación del grupo LIDER de la Universidad Distrital, representa un esfuerzo académico orientado a mitigar una de las amenazas más relevantes del entorno digital contemporáneo.

7. Problema de investigación

7.1 Planteamiento del problema

Existe una gran variedad de amenazas de ciberseguridad que buscan explotar las vulnerabilidades de los sistemas de telecomunicaciones, pero hay una categoría de ellas que representa una complejidad mucho mayor, los ataques basados en ingeniería social. (Patil D. R., 2018)

Los ataques de ingeniería social utilizan la manipulación y el engaño para lograr que la víctima entregue información confidencial o cometa errores de seguridad que permitan al atacante lograr su objetivo.

Existen muchos tipos de ataques de ingeniería social, pero uno particularmente difícil de detectar y controlar es el conocido como SMISHING, que viene del término SMS, pues inicialmente se utilizaba la plataforma de mensajes de texto (SMS) para el envío de URLs maliciosas a un objetivo. Actualmente se utilizan diferentes plataformas de mensajería como WhatsApp, Telegram, Instagram o Facebook para enviar URLs maliciosas o potencialmente fraudulentas. (Patil D. R., 2015)

En Colombia se han conocido casos de mensajes de texto notificando transacciones en plataformas como Nequi o Daviplata e invitando a la víctima a acceder a una URL en caso de no reconocer la transacción. Una vez el usuario ingresa a la URL el entorno visual de la página es exactamente igual a la plataforma legítima pero alojada en servidores diferentes a los originales. De esta manera, cuando el usuario ingresa sus credenciales inmediatamente serán robadas por los delincuentes (Juan, 2024).

A través de WhatsApp también se difunden mensajes sobre concursos o premios entregados por reconocidas marcas que tienen como objetivo que el usuario acceda y potencialmente entregue información sensible o descargue software malicioso (Parra, 2025).

El acceso a URLs maliciosas puede permitir que se descargue e instale software malicioso en los dispositivos de los usuarios. Este software malicioso podría robar información sensible que permita a los atacantes realizar estafas, fraudes o robos de dinero y bienes materiales. (MA, 2011)

El acceso a páginas maliciosas o fraudulentas puede permitir que los atacantes roben información sensible de los usuarios, como credenciales de acceso a banca virtual o aplicaciones financieras, además, una URL maliciosa puede facilitar la distribución de software malicioso (malware) como ransomware o spyware sin que el usuario lo note.

Con el fin de proteger los datos personales y corporativos de los usuarios, evitar la instalación de malware, promover la seguridad financiera en línea, salvaguardar la reputación de personas y empresas y garantizar el cumplimiento normativo y legal, es necesaria la creación de un modelo que permita identificar si una URL es maliciosa o potencialmente fraudulenta.

7.2 Formulación del problema

El acceso a una URL maliciosa o potencialmente fraudulenta expone a los usuarios a ataques cibernéticos que pueden tener graves consecuencias financieras, de reputación, de seguridad y hasta legales. A partir de lo expuesto, es necesario crear un modelo que permita identificar si una URL es maliciosa o potencialmente fraudulenta. ¿Cómo identificar una URL maliciosa o potencialmente fraudulenta?

7.3 Sistematización del problema

Para dar respuesta a la pregunta ¿Cómo identificar una URL maliciosa o potencialmente fraudulenta? Es necesario plantear preguntas que permitan desagregarla en problemas con un alcance menor y que al dar respuesta a esas nuevas preguntas se pueda responder la pregunta planteada.

¿Cuáles son las características de una URL maliciosa o potencialmente fraudulenta?

¿Qué herramientas se utilizan para la identificación de URLs maliciosas o potencialmente fraudulentas?

¿Cómo se pueden integrar las herramientas dentro de un modelo para identificar URLs maliciosas o potencialmente fraudulentas?

¿Cuál es la efectividad del modelo propuesto para la identificación de URLs maliciosas o potencialmente fraudulentas?

8. Objetivos

8.1 Objetivo general

Diseñar un modelo de identificación de URLs maliciosas o potencialmente fraudulentas en servicios financieros colombianos.

8.2 Objetivos específicos

- Descripción funcional del modelo para identificar URLs maliciosas o potencialmente fraudulentas.
- Definición de la estructura del modelo propuesto para identificar URLs maliciosas o potencialmente fraudulentas.
- Validación del modelo propuesto para identificar URLs maliciosas o potencialmente fraudulentas.

9. Justificación

9.1 Justificación teórica

La identificación de URLs maliciosas o potencialmente fraudulentas se fundamenta en conceptos y teorías de ciberseguridad, análisis de datos y utilización de herramientas que permitan comprender y anticipar los patrones de comportamiento de los ciberdelincuentes.

La creciente sofisticación de los ataques de phishing, malware e ingeniería social hace necesario el desarrollo de métodos de detección basados en herramientas avanzadas de ciberseguridad.

En este contexto, técnicas como el aprendizaje automático (P. V. Jyothsna, 2019), el análisis de patrones de tráfico web (Bin Liang, 2009), la minería de datos y el reconocimiento de anomalías se vuelven esenciales para construir sistemas capaces de identificar amenazas en tiempo real. Además, la integración de modelos de inteligencia artificial permite no solo la detección reactiva de URLs maliciosas, sino también la predicción proactiva de nuevas variantes de ataque, mejorando significativamente los tiempos de respuesta y reduciendo el riesgo de incidentes de seguridad.

La combinación de enfoques supervisados y no supervisados, junto con la actualización constante de los algoritmos mediante técnicas de aprendizaje continuo, resulta clave para enfrentar un panorama de amenazas en constante evolución.

9.2 Justificación metodológica

Un modelo de identificación de URLs maliciosas o potencialmente fraudulentas que aplique técnicas como el aprendizaje automático, el análisis de patrones de tráfico web, la minería de datos y el reconocimiento de anomalías y que además integre modelos de inteligencia

artificial resulta de gran valor en la detección de amenazas actuales y futuras. El modelo que se desarrollará en este trabajo podrá aplicarse en la construcción de herramientas de detección rápida de URLs maliciosas o potencialmente fraudulentas.

10. MARCO DE REFERENCIA

Se presenta en esta sección el marco de referencia que servirá como fundamento conceptual para el desarrollo del proyecto propuesto.

10.1 MARCO TEÓRICO

10.1.1 Introducción

Los servicios basados en web (WWW) son ampliamente utilizados para acceder a servicios financieros, compras en línea, redes sociales, entre muchos otros. Las aplicaciones basadas en servicios web actualmente permiten la interacción entre personas de todo el mundo. Todos estos servicios procesan y almacenan grandes cantidades de información sensible de los usuarios personales y corporativos. Esta popularidad y la gran cantidad de información que está disponible también ha motivado y atraído a atacantes quienes realizan actividades ilegales con el fin de obtener un beneficio, frecuentemente económico.

Las páginas web utilizadas para realizar ataques o que contienen algún tipo de código malicioso reciben el nombre de páginas web maliciosas y su detección oportuna es necesaria para garantizar la seguridad de la información de usuarios personales y corporativos.

De acuerdo con el informe “El estado de la ciber seguridad 2025” presentado por Check Point Research los principales vectores de ataque son el correo electrónico y las páginas web (Research, 2025). En el mismo informe se presentan las siguientes estadísticas para el 2024:

- a. El 39% del malware detectado se clasifica como multipropósito y el 19% como ladrón de información.
- b. El top 5 de tipo de organización atacada lo encabeza las Instituciones Educativas seguido por Gobierno, Salud, Telecomunicaciones y Construcción e Ingeniería.

- c. El 61% de ataques enviados por correo electrónico contienen archivos de tipo HTML.

De acuerdo con (Patil D. R., 2015) existen varios tipos de ataques basados en web contra páginas web y aplicaciones web.

- Ataques de descarga automática: en este tipo de ataque se descarga automáticamente un malware, virus o código malicioso inmediatamente el usuario visita la página web. Frecuentemente este tipo de descarga ocurre en segundo plano y el usuario no lo nota.
- Ataques de secuestro de clics: este tipo de ataque tiene como objetivo que el usuario desencadene una acción dando clic en un lugar específico en la página web. Se impulsa al usuario a dar clic en un mensaje como “Dé clic para obtener \$1.000 dólares”, se redirecciona la página y se incluye un cuadro transparente que contiene una página legítima y reconocida, por ejemplo Instagram.com y se ubica un enlace malicioso sobre el botón de “Me gusta”.
- Ataques de plugins: existen muchos plugins que no han recibido actualizaciones y son vulnerables, estos plugins son aprovechados por un atacante para insertar código malicioso.
- Ataques de phishing: este tipo de ataque principalmente se realiza a través de correo electrónico y busca hacer creer al destinatario que fue enviado por una persona o empresa legítima y de esa forma robar información personal.

10.1.2 Uniform Resource Locators

Las URLs (Uniform Resource Locators), también son conocidas como “enlaces” y son la forma más utilizada de encontrar recursos en internet. Las URLs son cadenas de texto legibles y comprensibles por las personas, pero están construidas de tal manera que pueden ser interpretadas por los dispositivos (MA, 2011).

<https://aulasvirtuales.udistrital.edu.co/mod/assign/view.php?id=316155>

<protocolo>://<nombre de host>/<ruta>

Una URL maliciosa es un enlace construido para llevar al usuario a ejecutar una acción no deseada o potencialmente perjudicial. Las URLs maliciosas pueden adoptar diversas formas, a continuación, se presenta una breve descripción de las más relevantes (Reyes-Dorta, 2024):

URLs de phishing: Enlaces que llevan a páginas que simulan sitios web legítimos con el propósito de engañar al usuario e inducirlo a ingresar información confidencial como nombres de usuario, contraseñas o datos bancarios y así robarlos.

URLs de malware: Direcciones que conducen a la descarga o ejecución de software malicioso.

URLs de comando y control (C2): Utilizadas por botnets para enviar y recibir instrucciones desde un servidor remoto.

URLs de fraude: Vinculadas a esquemas de estafa o sitios falsos que buscan obtener beneficios ilícitos.

Estas URLs pueden estar disfrazadas con técnicas como el uso de acortadores de enlaces, dominios similares a los legítimos (typosquatting) y caracteres especiales.

Cuando un atacante requiere una URL también puede utilizar algoritmos de generación de dominios (DGA, Domain Generation Algorithms) que tienen como objetivo engañar a las herramientas de detección (Bisio, 2017).

10.1.3 Técnicas de detección

Existen diversas técnicas de detección que pueden utilizarse de forma individual o en conjunto entre sí haciendo uso de herramientas tradicionales y otras más avanzadas. Algunas de las técnicas más destacadas se presentan a continuación (Tian, 2025):

Listas negras (blacklists): Bases de datos que contienen URLs previamente identificadas como maliciosas. Es una técnica fácil de implementar, pero su principal desventaja es la

incapacidad de detectar amenazas nuevas que se conocen como ataques de día cero (zero-day).

Listas blancas (whitelists): Son bases con URLs consideradas seguras. Su aplicación en una red es restrictiva, implica que los usuarios únicamente pueden acceder a las URLs permitidas y pueden limitar la navegación si no están bien administradas.

Reglas heurísticas: La detección heurística se basa en conjuntos de patrones definidos manualmente que identifican comportamientos sospechosos. Es muy efectiva para ciertas amenazas, pero puede ser fácilmente evadida por atacantes sofisticados.

Enfoques de aprendizaje automático y profundo (Machine Learning y Deep Learning): El aprendizaje automático ha demostrado ser una herramienta poderosa para la detección de URLs maliciosas. A diferencia de los métodos tradicionales, permite identificar amenazas emergentes mediante el aprendizaje de patrones ocultos en los datos. Una forma de detectar este tipo de URLs se presenta en (Bisio, 2017) quienes proponen realizar un análisis de las peticiones DNS resueltas para luego extraer características lingüísticas y semánticas. Con esa información se clasifican e identifican los falsos positivos y se presentan los resultados de interés.

Los análisis se pueden realizar utilizando aprendizaje profundo como el presentado por (Vinayakumar, 2018) quienes evaluaron el desempeño de redes neuronales recurrentes (RNN), memoria larga de corto plazo (LSTM) y otros clasificadores clásicos de aprendizaje de máquina.

Se puede realizar detección automática de dominios generados por algoritmos con un alto porcentaje de éxito, (Lison, 2017) comprobó que el modelo propuesto detectó 93% de los nombres de dominio maliciosos generados.

Otro método de detección es el clasificador multiclase presentado por (Patil D. R., 2018) incluyendo nuevas características de URLs spam, phishing y malware, este método alcanzó un 98.44% de promedio de detección y un 99.86% de precisión de detección.

El reconocimiento de visibilidad anormal presentado por (Bin Liang, 2009) detecta el código ofuscado dentro del código fuente de la página web, obteniendo una tasa del 2,63% de falso negativo y 1,99% de falso positivo.

Dentro de los modelos más utilizados están los siguientes (Li, 2024):

Random Forests: Alta precisión y resistencia al overfitting.

Support Vector Machines (SVM): Eficientes para datos de alta dimensionalidad.

k-Nearest Neighbors (k-NN): Sencillo, pero menos escalable para grandes volúmenes de datos.

Redes Neuronales Recurrentes (RNNs) y LSTMs: Aptas para procesar secuencias de texto como las URLs.

Redes Convolucionales (CNNs): Identifican patrones espaciales en secuencias de caracteres.

Además, existen **técnicas de detección en tiempo real**. La detección en tiempo real es fundamental para evitar que los usuarios interactúen con URLs maliciosas (Singh, 2024).

Acción en el cliente (navegador): Se basa en plugins o extensiones que analizan URLs antes de su carga, notifican al usuario o bloquean su acceso.

Análisis en la nube: Esta técnica utiliza APIs que reciben URLs y devuelven una clasificación rápida.

Sistemas en gateways: Consiste en la integración con firewalls o proxies para filtrar tráfico HTTP/HTTPS sospechoso.

10.2 MARCO CONCEPTUAL

En esta sección se presentan los conceptos que permitirán fundamentar el desarrollo del proyecto propuesto.

Vector de ataque

Es el camino o método que utiliza un atacante para acceder a un sistema o red con el fin de llevar a cabo acciones maliciosas, como robar datos, instalar malware o interrumpir operaciones. Los vectores de ataque pueden incluir correos electrónicos de phishing, vulnerabilidades de software, dispositivos infectados, entre otros (Perez, 2015).

Malware

Es cualquier tipo de software diseñado para dañar, explotar o comprometer dispositivos, redes o datos. Existen diferentes tipos de malware, como virus, gusanos, troyanos, ransomware y spyware, cada uno con diferentes formas de afectar a sus víctimas (Baca Urbina, 2016).

URL

Siglas de Uniform Resource Locator (Localizador Uniforme de Recursos). Es la dirección específica que se usa para acceder a recursos en internet, como sitios web, documentos o imágenes. Una URL maliciosa es aquella que dirige a contenido dañino o fraudulento (Santos, 2015).

Ofuscamiento

Técnica utilizada para ocultar el verdadero propósito, estructura o contenido de un código o enlace, con el objetivo de dificultar su análisis o detección. En ciberseguridad, los atacantes usan el ofuscamiento para esconder malware o engañar a los sistemas de protección (Baca Urbina, 2016).

Spam

Mensajes electrónicos no solicitados, generalmente enviados de forma masiva, que suelen tener fines publicitarios, de fraude o de propagación de malware. Aunque el spam puede ser solo molesto, también puede ser un vehículo para ataques más peligrosos (Perez, 2015).

Phishing

Técnica de ingeniería social que busca engañar a las personas para que revelen información confidencial, como contraseñas, números de tarjetas de crédito o datos personales, haciéndose pasar por una entidad confiable a través de correos electrónicos, mensajes o sitios web falsificados (Santos, 2015).

Comando y Control (C2)

Se refiere al método y la infraestructura que los atacantes utilizan para comunicarse y controlar de forma remota los sistemas informáticos que han comprometido (a menudo mediante malware) (Baca Urbina, 2016).

Typosquatting

Los atacantes registran nombres de dominio que son ligeramente diferentes de los sitios web legítimos y populares, anticipando que los usuarios cometerán errores comunes al teclear. Cuando un usuario introduce por error una URL con una pequeña equivocación (un "typo"), es redirigido a este sitio falso en lugar del sitio original (Santos, 2015).

Los errores comunes que explotan los typosquatters incluyen:

Errores de escritura/omisiones: Por ejemplo, "gogle.com" en lugar de "google.com".

Transposiciones: Cambiar el orden de las letras, como "https://www.google.com/search?q=faecbook.com" en lugar de "facebook.com".

Letras adyacentes en el teclado: Usar una letra cercana en el teclado, como "amazom.com" en lugar de "amazon.com".

Dominio de nivel superior (TLD) incorrecto: Usar ".cm" o ".org" en lugar de ".com" (por ejemplo, "amazon.co" en lugar de "amazon.com").

Omisión o adición de guiones: Si el dominio legítimo es "https://www.google.com/search?q=mi-banco.com", podrían registrar "mibanco.com" o "https://www.google.com/search?q=mi--banco.com".

Acortadores de enlaces: Servicios que convierten URLs largas en cortas, ocultando su destino real.

Listas negras (blacklists)

Es una lista de entidades, elementos o comportamientos que se consideran maliciosos, no deseados o sospechosos, y a los que se les niega el acceso o la ejecución dentro de un sistema, red o servicio.

Funciona bajo el principio de "todo lo que no está en esta lista es permitido", a diferencia de una "lista blanca" (whitelist), que opera bajo el principio de "solo lo que está en esta lista es permitido" (Perez, 2015).

Listas blancas (whitelists)

Una lista blanca (whitelist) es una lista de entidades, elementos o comportamientos que se consideran seguros, confiables o autorizados, y a los que se les concede explícitamente el acceso o la ejecución dentro de un sistema, red o servicio.

Funciona bajo el principio de "solo lo que está en esta lista es permitido", mientras que todo lo demás (lo que no está en la lista) es automáticamente denegado o bloqueado. Es el opuesto de una "lista negra" (blacklist), que opera bajo el principio de "todo lo que no está en esta lista es permitido" (Perez, 2015).

Reglas heurísticas

Las reglas heurísticas (o análisis heurístico) se refieren a un enfoque basado en la experiencia, el comportamiento y los patrones para detectar amenazas cibernéticas, especialmente aquellas que son nuevas o desconocidas (conocidas como "zero-day"), sin depender de firmas específicas ya catalogadas.

A diferencia de la detección basada en firmas (que busca coincidencias exactas con códigos maliciosos conocidos), la heurística utiliza un conjunto de reglas y algoritmos para identificar actividades o características sospechosas (Baca Urbina, 2016).

Aprendizaje automático (Machine Learning)

El Aprendizaje Automático (Machine Learning - ML) es una rama de la Inteligencia Artificial (IA) que permite a los sistemas informáticos aprender de los datos, identificar patrones, tomar decisiones y mejorar su rendimiento con el tiempo sin ser programados explícitamente para cada tarea.

Consiste en entrenar algoritmos con grandes volúmenes de datos históricos y en tiempo real. Estos datos pueden incluir tráfico de red, registros de eventos (logs), archivos de malware, comportamientos de usuario, información de ataques anteriores, etc.

En ciberseguridad, el ML es una herramienta poderosa que ayuda a los profesionales a combatir el creciente volumen y la sofisticación de las ciberamenazas (Bisio, 2017).

Aprendizaje profundo (Deep Learning)

El Aprendizaje Profundo (Deep Learning - DL) es una subcategoría del Aprendizaje Automático (Machine Learning - ML) que utiliza redes neuronales artificiales (ANN) con múltiples capas (profundas) para aprender de los datos. Estas redes están inspiradas en la estructura y función del cerebro humano y son excepcionalmente buenas para identificar patrones complejos en grandes volúmenes de datos.

Mientras que el ML tradicional a menudo requiere que los ingenieros "ingenien" (extraigan) manualmente las características relevantes de los datos para que el algoritmo aprenda, el DL tiene la capacidad de aprender y extraer automáticamente estas características directamente de los datos crudos. Esta es su principal ventaja y lo que lo hace tan potente para tareas complejas en ciberseguridad (Vinayakumar, 2018).

Ingeniería de características

La ingeniería de características (Feature Engineering) se refiere al proceso de transformar los datos brutos disponibles en características significativas y relevantes que puedan ser utilizadas eficazmente por modelos de aprendizaje automático (Machine Learning) para la detección, prevención y mitigación de amenazas cibernéticas.

En esencia, es el arte y la ciencia de crear nuevas variables o modificar las existentes a partir de los datos originales, de manera que el modelo pueda aprender patrones y relaciones más fácilmente, mejorando así su rendimiento en tareas de seguridad (Singh, 2024).

Características léxicas

Las características léxicas (o "lexical features" en inglés) se refieren a los atributos que se pueden extraer y analizar a partir del lenguaje, las palabras, los caracteres o los patrones

de texto presentes en diferentes tipos de datos. Estas características no se centran en el significado semántico profundo, sino en las propiedades superficiales de la cadena de texto, como su composición, longitud, o la presencia de ciertos caracteres o patrones.

Las características léxicas son una forma de ingeniería de características que es particularmente útil en ciberseguridad porque muchos ataques y amenazas dejan "huellas" distintivas en el texto. Al analizar estas huellas, los modelos de machine learning pueden identificar y clasificar actividades maliciosas (Singh, 2024).

Características de WHOIS

Las características de WHOIS se refieren a la información y los metadatos que se pueden extraer de los registros WHOIS de nombres de dominio y direcciones IP. WHOIS es un protocolo de consulta y una base de datos que almacena información sobre quién es el propietario de un nombre de dominio o un bloque de direcciones IP, cuándo fue registrado, cuándo expira, y detalles de contacto (Li, 2024).

Características de comportamiento

Las características de comportamiento (o "behavioral features" en inglés) se refieren a los patrones y anomalías observadas en la actividad de usuarios, sistemas, aplicaciones o redes a lo largo del tiempo. A diferencia de las características estáticas (como las léxicas o WHOIS), que examinan atributos fijos, las características de comportamiento se centran en el dinamismo y la evolución de las interacciones y los procesos.

El objetivo principal de analizar las características de comportamiento es establecer una línea base de "comportamiento normal" y luego identificar desviaciones significativas que podrían indicar una actividad maliciosa. Este enfoque es fundamental para detectar amenazas avanzadas que pueden evadir la detección basada en firmas, ya que no se basan en conocer una amenaza específica de antemano, sino en reconocer un comportamiento inusual (Li, 2024).

Características de contenido

Las características de contenido (o "content features" en inglés) se refieren a los atributos intrínsecos y los patrones presentes dentro del cuerpo o los datos de un archivo, un paquete

de red, un correo electrónico, una página web, o cualquier otra fuente de información digital. A diferencia de las características léxicas que se centran en la superficie del texto o las características de comportamiento que observan la actividad a lo largo del tiempo, las características de contenido profundizan en la naturaleza y composición interna de los datos mismos (Tian, 2025).

El análisis de las características de contenido es crucial para detectar amenazas que residen directamente en los datos, como malware, archivos maliciosos, información confidencial, o la presencia de exploit kits.

Clasificación binaria

La clasificación binaria es un tipo de problema de aprendizaje automático supervisado donde un sistema o algoritmo es entrenado para categorizar datos en una de dos clases posibles. Es decir, el objetivo es predecir una de dos posibles respuestas (Tian, 2025).

Algunos ejemplos clave de cómo se aplica la clasificación binaria en ciberseguridad incluyen:

Detección de malware: Clasificar un archivo o un comportamiento como "malicioso" (malware) o "benigno" (legítimo).

Detección de intrusiones: Determinar si una actividad en la red es "normal" o "anómala/maliciosa" (una intrusión).

Detección de spam: Etiquetar un correo electrónico como "spam" o "no spam".

Detección de fraude: Identificar una transacción como "fraudulenta" o "no fraudulenta".

Clasificación de URLs: Distinguir entre URLs "seguras" y "maliciosas" (phishing, malware, etc.).

Análisis de vulnerabilidades: Determinar si un fragmento de código o una configuración es "vulnerable" o "seguro".

Random Forest

Random Forest (Bosque Aleatorio) es un algoritmo de aprendizaje automático de tipo ensemble (conjunto) muy popular y efectivo, utilizado para tareas de clasificación y

regresión. Su fuerza reside en combinar la salida de múltiples árboles de decisión para llegar a una predicción final más robusta y precisa que la de un solo árbol (Lison, 2017).

Support Vector Machine (SVM)

Una Support Vector Machine (SVM) o Máquina de Vectores de Soporte es un potente algoritmo de aprendizaje automático supervisado que se utiliza principalmente para problemas de clasificación binaria, aunque también puede aplicarse a la regresión. Su objetivo principal es encontrar el "mejor" hiperplano que separe las clases en un conjunto de datos, maximizando el margen entre ellas (Chowdhury, 2024).

k-Nearest Neighbors (k-NN)

k-Nearest Neighbors (k-NN) es un algoritmo de aprendizaje automático no paramétrico y basado en instancias (o "lazy learning") que se utiliza principalmente para clasificación y, en menor medida, para regresión (Fangli Ren, 2020).

Red Neuronal Recurrente (RNN)

Una Red Neuronal Recurrente (RNN) es un tipo de red neuronal artificial especializada en el procesamiento de datos secuenciales o series temporales. A diferencia de las redes neuronales "feedforward" (de avance), que procesan cada entrada de forma independiente, las RNN tienen conexiones que forman bucles, lo que les permite mantener un "estado interno" o "memoria" de la información de pasos temporales anteriores. Esta capacidad de "recordar" el contexto pasado las hace excepcionalmente adecuadas para analizar patrones que evolucionan con el tiempo (P. V. Jyothsna, 2019).

LSTM

LSTM (Long Short-Term Memory) es un tipo avanzado y muy efectivo de Red Neuronal Recurrente (RNN), diseñado específicamente para superar las limitaciones de las RNN tradicionales, particularmente el problema del gradiente desvanecedor. Esto permite a las LSTM aprender y recordar dependencias a largo plazo en datos secuenciales o series temporales (Patil D. R., 2015).

Red Neuronal Convolutiva (CNN)

Una Red Neuronal Convolucional (CNN), también conocida como ConvNet, es un tipo de red neuronal profunda que ha demostrado ser excepcionalmente eficaz en el procesamiento de datos con una estructura similar a una cuadrícula, como imágenes, pero también señales y otros datos representados espacialmente. Aunque inicialmente ganó fama en la visión por computadora, sus principios se han adaptado con éxito para diversas aplicaciones en ciberseguridad (P. V. Jyothsna, 2019).

Embedding de caracteres

Un embedding de caracteres (o character embedding) es una técnica de procesamiento de lenguaje natural (PLN) y aprendizaje automático que representa cada carácter individual (letras, números, símbolos, espacios) como un vector numérico denso y de baja dimensión en un espacio vectorial.

A diferencia de los embeddings de palabras (word embeddings) que representan palabras completas, los embeddings de caracteres se centran en las unidades más pequeñas del texto (Singh, 2024).

Modelo Transformer

Un Modelo Transformer es una arquitectura de red neuronal profunda que ha revolucionado el procesamiento de lenguaje natural (PLN) y el análisis de secuencias, y que cada vez más se aplica a la detección y respuesta a amenazas en ciberseguridad. A diferencia de las Redes Neuronales Recurrentes (RNNs) y las LSTM, que procesan las secuencias paso a paso, los Transformers utilizan un mecanismo de auto-atención (self-attention) que les permite procesar todos los elementos de una secuencia simultáneamente y capturar dependencias a largo plazo de manera muy eficiente (Tian, 2025).

BERT

BERT (Bidirectional Encoder Representations from Transformers) es un modelo de lenguaje pre-entrenado de última generación basado en la arquitectura Transformer, desarrollado por Google. Su impacto en el procesamiento de lenguaje natural (PLN) ha sido enorme, y su aplicación en ciberseguridad está abriendo nuevas vías para la detección, análisis y respuesta a amenazas (Fangli Ren, 2020).

Inferencia en tiempo real

La inferencia en tiempo real se refiere a la capacidad de un sistema de seguridad (típicamente impulsado por aprendizaje automático o IA) para analizar instantáneamente datos entrantes o eventos en vivo y tomar una decisión o acción de seguridad casi de inmediato después de que el evento ocurre.

El objetivo principal de la inferencia en tiempo real en ciberseguridad es detectar y responder a las amenazas de forma proactiva y lo más rápido posible, minimizando el tiempo de permanencia de los atacantes en la red y reduciendo el impacto potencial de un ciberataque (Tian, 2025).

Detección en el cliente

La detección en el cliente (o client-side detection) se refiere a los métodos y tecnologías que operan y realizan análisis directamente en el dispositivo del usuario final (el "cliente"), como un ordenador de escritorio, portátil, servidor, dispositivo móvil o incluso un navegador web.

A diferencia de la detección en el lado del servidor o en la red, donde el análisis ocurre en la infraestructura central o en los puntos de interconexión de la red, la detección en el cliente se enfoca en lo que sucede en el dispositivo individual o en el entorno local del usuario (Santos, 2015).

Análisis en la nube

El análisis en la nube (o cloud analytics para seguridad) se refiere a la utilización de los recursos y capacidades de las plataformas de computación en la nube (como AWS, Azure, Google Cloud Platform) para recopilar, procesar, almacenar y analizar grandes volúmenes de datos de seguridad con el fin de detectar, investigar y responder a amenazas cibernéticas.

Es una evolución de los sistemas de análisis de seguridad tradicionales (como los SIEMs locales), que aprovecha la escalabilidad, flexibilidad y las capacidades avanzadas de IA/ML que ofrece la nube (Li, 2024).

Ataques adversariales

Los ataques adversariales (también conocidos como adversarial attacks o adversarial machine learning) son un tipo de técnica sofisticada diseñada para engañar o manipular modelos de aprendizaje automático (ML) que se utilizan en sistemas de seguridad. El objetivo de estos ataques no es explotar una vulnerabilidad de software tradicional, sino explotar las debilidades inherentes al funcionamiento de los propios algoritmos de ML (Singh, 2024).

10.3 MARCO ESPACIAL

El modelo propuesto permitirá detectar URLs maliciosas o potencialmente fraudulentas y se enfocará en servicios financieros colombianos.

10.4 MARCO TEMPORAL

Para desarrollar el modelo se recopilará información de los últimos 15 años sobre aprendizaje de máquina, detección de dominios generados automáticamente y detección de malware.

11. HIPÓTESIS

Un modelo híbrido de aprendizaje automático permite identificar URLs maliciosas o potencialmente fraudulentas en el sector financiero colombiano, al aprender patrones complejos y sutiles asociados a las técnicas de ataque empleadas en este entorno.

12. METODOLOGÍA

Se presenta a continuación la metodología propuesta para el logro de cada objetivo específico.

Objetivos específicos	Metodología	Cómo se logra el objetivo Secuencia de actividades	Resultado de la actividad
Descripción funcional del modelo para identificar URLs maliciosas o potencialmente fraudulentas.	Método de análisis – síntesis	Búsqueda de publicaciones científicas relacionadas Recopilación de URLs legítimas y maliciosas que servirán como insumo para la creación del modelo	Documento con la descripción funcional del modelo
Definición de la estructura del modelo propuesto para identificar URLs maliciosas o potencialmente fraudulentas.	Método Hipotético – Deductivo	Entrenamiento del modelo con la base de URLs	Documento con la estructura del modelo propuesto.

Validación del modelo propuesto para identificar URLs maliciosas o potencialmente fraudulentas.	Método inductivo	Validación del modelo con URLs diferentes a las utilizadas en el entrenamiento. Creación de un entorno de pruebas.	Interfaz donde el usuario ingresará la URL que será procesada por el modelo.
---	------------------	---	--

13. IMPACTO Y RESULTADOS ESPERADOS

El proyecto de investigación "Diseño de un modelo para la identificación de URLs maliciosas o potencialmente fraudulentas en servicios financieros colombianos" aspira a generar un impacto significativo en la seguridad de la información del sector financiero colombiano, ofreciendo una solución innovadora y efectiva frente a las crecientes amenazas de phishing y fraude. Los resultados esperados se traducen en mejoras tangibles tanto a nivel técnico como operativo y estratégico.

El impacto principal será una defensa más robusta contra los ataques dirigidos a usuarios de servicios financieros. Al identificar y bloquear URLs maliciosas de manera proactiva, se reducirá la exposición de los clientes a fraudes y la reputación de las entidades financieras se verá salvaguardada. Esto contribuye directamente a mejorar la confianza en el sistema financiero digital del país.

Al prevenir el acceso a sitios fraudulentos, el modelo contribuirá directamente a la disminución de pérdidas económicas derivadas de estafas de phishing, tanto para los usuarios finales como para las propias instituciones financieras que asumen costos asociados a la resolución de fraudes y la mitigación de brechas.

El modelo, al emplear técnicas avanzadas de aprendizaje profundo y embeddings de caracteres, tendrá la capacidad de identificar URLs que utilizan métodos de ofuscación complejos, typosquatting sutil, o que son parte de campañas de ataque completamente nuevas (día cero). Esto representa un avance significativo sobre las detecciones tradicionales basadas en firmas, que a menudo son ineficaces contra este tipo de amenazas evolutivas.

La investigación contribuirá a robustecer el conocimiento en ciberseguridad y aprendizaje automático aplicado al contexto colombiano. Los hallazgos, la metodología y el modelo propuesto podrán servir de base para futuras investigaciones y desarrollos en la región.

Se espera obtener un modelo de aprendizaje automático (ej., basado en Transformer, LSTM o CNN con embeddings de caracteres) que pueda clasificar URLs con alta precisión como "maliciosa/fraudulenta" o "benigna". Este modelo será entrenado y validado con un conjunto de datos representativo del panorama de amenazas en el sector financiero colombiano.

Se demostrará la robustez del modelo frente a URLs modificadas o ligeramente ofuscadas, evidenciando su capacidad para generalizar y detectar variantes de amenazas conocidas y, potencialmente, amenazas emergentes que no estaban presentes en el conjunto de datos de entrenamiento.

Como resultado de la investigación, es posible que se construya un conjunto de datos de URLs (legítimas y maliciosas/fraudulentas) específicas del sector financiero colombiano, lo que representa un recurso valioso para futuras investigaciones y para la comunidad de ciberseguridad.

- Generación de conocimiento y nuevos desarrollos tecnológicos

Resultado/Producto esperado	Indicador	Beneficiario
Modelo para la identificación de URLs maliciosas o potencialmente fraudulentas en servicios financieros colombianos	Artículo aceptado para publicación, Ponencia en evento científico, Documento de Tesis	Sector financiero

- Fortalecimiento de la capacidad científica y la capacidad institucional

Resultado/Producto esperado	Indicador	Beneficiario
Estudiante en formación de Maestría	Documento de Trabajo de grado, acta sustentación	Francisco Javier González Aguirre, Grupo de investigación LIDER

- Apropiación social del conocimiento

Resultado/Producto esperado	Indicador	Beneficiario
Artículo Publicado en revista indexada en B	Carta-Correo de aceptación	Grupo de investigación, UDFJC LIDER, El estudiante
Ponencia en Evento científico	Certificado de ponente	Grupo de investigación, UDFJC LIDER, El estudiante

14. RECURSOS Y PRESUPUESTO

En la siguiente tabla se presenta el detalle del presupuesto requerido para el desarrollo del proyecto.

Descripción	Cantidad	Valor unitario	Valor Total	Fuente
Estudiante de maestría	576	\$ 125.000	\$ 72.000.000	Personal
Director de proyecto	45	\$ 250.000	\$ 11.250.000	Universidad
Computador	1	\$ 4.500.000	\$ 4.500.000	Personal
Servicios de computación en nube	1	\$ 10.000.000	\$ 10.000.000	Universidad
Inscripción ponencia evento internacional	1	\$ 900.000	\$ 900.000	Universidad
Tiquetes ponencia internacional	1	\$ 2.000.000	\$ 2.000.000	Universidad
Váticos ponencia internacional	1	\$ 900.000	\$ 900.000	Universidad
Publicación artículo en revista	1	\$ 1.500.000	\$ 1.500.000	Universidad
TOTAL			\$ 103.050.000	

15. CRONOGRAMA

A continuación, se presenta el cronograma propuesto para el desarrollo del proyecto.

Objetivo	Actividad	Mes							Resultado
		1	2	3	4	5	6	7	
Descripción funcional del modelo para identificar URLs maliciosas o potencialmente fraudulentas.	Búsqueda de publicaciones científicas relacionadas								Documento con la descripción funcional del modelo
	Recopilación de URLs legítimas y maliciosas que servirán como insumo para la creación del modelo								Documento con la descripción funcional del modelo
Definición de la estructura del modelo propuesto para identificar URLs maliciosas o potencialmente fraudulentas.	Entrenamiento del modelo con la base de URLs								Documento con la estructura del modelo propuesto.

Validación del modelo propuesto para identificar URLs maliciosas o potencialmente fraudulentas.	Validación del modelo con URLs diferentes a las utilizadas en el entrenamiento.								Interfaz donde el usuario ingresará la URL que será procesada por el modelo.
	Creación de un entorno de pruebas.								Interfaz donde el usuario ingresará la URL que será procesada por el modelo.

16. LIMITACIONES

Este proyecto se desarrollará para servicios financieros colombianos y en caso de ser necesario se identificarán los servicios más utilizados para enfocar la detección en ellos.

17. REFERENCIAS

- Baca Urbina, G. (2016). *Introducción a la seguridad informática*. Grupo Editorial Patria.
- Bin Liang, J. H. (2009). Malicious Web Pages Detection Based on Abnormal Visibility Recognition. *E-Business and Information System Security, 2009. EBISS '09*.
- Bisio, F. S. (2017). Realtime behavioural DGA detection through machine learning. *International Carnahan Conference on Security Technology (ICCST)*.
- Chowdhury, T. O. (2024). A systematic review on research utilising artificial intelligence for open source intelligence (OSINT) applications. *International Journal of Information Security*.
- Fangli Ren, Z. J. (2020). A DGA domain names detection modeling method based on integrating an attention mechanism and deep neural network. *Cybersecurity Springer Open*.
- GrupLAC - Plataforma SCienTI - Colombia. (s.f.). Obtenido de <https://scienti.minciencias.gov.co/gruplac/jsp/visualiza/visualizagr.jsp?nro=00000000005315>
- Juan, I. D. (05 de 04 de 2024). *Infobae*. Obtenido de Alerta de estafa: mensajeros falsos en Nequi ¡Cuidado con los enlaces sospechosos!: <https://www.infobae.com/tecno/2024/04/05/nequi-envian-mensajes-de-texto-con-transacciones-falsas-y-cualquiera-puede-caer/>
- Li, S. &. (2024). Enhancing Online Security: A Novel Machine Learning Framework for Robust Detection of Known and Unknown Malicious URLs. *Journal of Theoretical & Applied Electronic Commerce Research*, 2919–2960.
- Lison, P. M. (2017). Automatic detection of malware-generated domains with recurrent neural models. *The Norwegian Information Security Conference 2017 NISK 2017*.

- MA, J. S. (2011). Learning to Detect Malicious URLs. *ACM Transactions on Intelligent Systems and Technology*, 1-24.
- P. V. Jyothsna, G. P. (2019). Detecting DGA Using Deep Neural Networks (DNNs). *International Symposium on Security in Computing and Communications*, 695–706.
- Parra, P. A. (02 de 01 de 2025). *El Tiempo*. Obtenido de Reportan nueva modalidad de estafa usando los logos e imagen del D1: prometen millonario premio: <https://www.eltiempo.com/cultura/gente/reportan-nueva-modalidad-de-estafa-usando-los-logos-e-imagen-del-d1-3414161>
- Patil, D. R. (2015). Survey on Malicious Web Pages Detection Techniques. *International Journal of u- and e- Service, Science and Technology*, 195-206.
- Patil, D. R. (2018). Feature-based Malicious URL and Attack Type Detection Using Multi-class Classification. *The ISC Int'l Journal of Information Security*, 141-162.
- Perez, J. C. (2015). *Protección de Datos y Seguridad de la Información*. Madrid: Paracuellos de Jarama, Madrid: RA-MA Editorial.
- Research, C. P. (2025). The State of Cyber Security 2025.
- Reyes-Dorta, N. C.-G.-R. (2024). Detection of malicious URLs using machine learning. *Wireless Networks: The Journal of Mobile Communication, Computation and Information*, 7543–7560.
- Santos, J. C. (2015). *Seguridad informática*. RA-MA Editorial.
- Singh, A. C. (2024). Guardian Shield: A Machine Learning Approach for Proactive Malicious URL Detection. *Grenze International Journal of Engineering & Technology (GIJET)*, 4118–4121.
- Tian, Y. Y. (2025). *From Past to Present: A Survey of Malicious URL Detection Techniques, Datasets and Code Repositories*. arXiv.

Vinayakumar, R. S. (2018). Detecting malicious domain names using deep learning approaches at scale. *Journal of intelligent & fuzzy systems*.