



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS

Diseño de un modelo para la identificación de URLs maliciosas o potencialmente fraudulentas en servicios financieros colombianos

Trabajo de investigación/grado para optar el título de
Magister en Ciencias de la Información y las Comunicaciones

Francisco Javier González Aguirre

Asesor

Roberto Ferro Escobar
Carlos Andrés Martínez Alayón

Bogotá D. C. – Colombia

Mayo de 2026

Contenido

1. Introducción	3
a. Justificación teórica	5
b. Justificación metodológica	6
b. Marco de referencia	7
a. Marco Teórico	7
b. Marco conceptual	11
1.8 Referencias	19

1. Introducción

Existe una gran variedad de amenazas de ciberseguridad que buscan explotar las vulnerabilidades de los sistemas de telecomunicaciones, pero hay una categoría de ellas que representa una complejidad mucho mayor, los ataques basados en ingeniería social. (Patil D. R., 2018)

Los ataques de ingeniería social utilizan la manipulación y el engaño para lograr que la víctima entregue información confidencial o cometa errores de seguridad que permitan al atacante lograr su objetivo.

Existen muchos tipos de ataques de ingeniería social, pero uno particularmente difícil de detectar y controlar es el conocido como SMISHING, que viene del término SMS, pues inicialmente se utilizaba la plataforma de mensajes de texto (SMS) para el envío de URLs maliciosas a un objetivo. Actualmente se utilizan diferentes plataformas de mensajería como WhatsApp, Telegram, Instagram o Facebook para enviar URLs maliciosas o potencialmente fraudulentas. (Patil D. R., 2015)

En Colombia se han conocido casos de mensajes de texto notificando transacciones en plataformas como Nequi o Daviplata e invitando a la víctima a acceder a una URL en caso de no reconocer la transacción. Una vez el usuario ingresa a la URL el entorno visual de la página es exactamente igual a la plataforma legítima pero alojada en servidores diferentes a los originales. De esta manera, cuando el usuario ingresa sus credenciales inmediatamente serán robadas por los delincuentes (Juan, 2024).

A través de WhatsApp también se difunden mensajes sobre concursos o premios entregados por reconocidas marcas que tienen como objetivo que el usuario acceda y potencialmente entregue información sensible o descargue software malicioso (Parra, 2025).

El acceso a URLs maliciosas puede permitir que se descargue e instale software malicioso en los dispositivos de los usuarios. Este software malicioso podría robar información sensible que permita a los atacantes realizar estafas, fraudes o robos de dinero y bienes materiales. (MA, 2011)

El acceso a páginas maliciosas o fraudulentas puede permitir que los atacantes roben información sensible de los usuarios, como credenciales de acceso a banca virtual o aplicaciones financieras, además, una URL maliciosa puede facilitar la distribución de software malicioso (malware) como ransomware o spyware sin que el usuario lo note.

Con el fin de proteger los datos personales y corporativos de los usuarios, evitar la instalación de malware, promover la seguridad financiera en línea, salvaguardar la reputación de personas y empresas y garantizar el cumplimiento normativo y legal, es necesaria la creación de un modelo que permita identificar si una URL es maliciosa o potencialmente fraudulenta.

El acceso a una URL maliciosa o potencialmente fraudulenta expone a los usuarios a ataques cibernéticos que pueden tener graves consecuencias financieras, de reputación, de seguridad y hasta legales. A partir de lo expuesto, es necesario crear un modelo que permita identificar si una URL es maliciosa o potencialmente fraudulenta. ¿Cómo identificar una URL maliciosa o potencialmente fraudulenta?

Este proyecto de investigación plantea la siguiente hipótesis. Un modelo híbrido de aprendizaje automático permite identificar URLs maliciosas o potencialmente fraudulentas en el sector financiero colombiano, al aprender patrones complejos y sutiles asociados a las técnicas de ataque empleadas en este entorno.

El objetivo general de este trabajo de investigación es diseñar un modelo de identificación de URLs maliciosas o potencialmente fraudulentas en servicios financieros colombianos.

Los objetivos específicos son los siguientes:

- Descripción funcional del modelo para identificar URLs maliciosas o potencialmente fraudulentas.
- Definición de la estructura del modelo propuesto para identificar URLs maliciosas o potencialmente fraudulentas.
- Validación del modelo propuesto para identificar URLs maliciosas o potencialmente fraudulentas.

Este proyecto, enmarcado en las líneas de investigación del grupo LIDER de la Universidad Distrital, representa un esfuerzo académico orientado a mitigar una de las amenazas más relevantes del entorno digital contemporáneo.

En el presente documento se propone desarrollar una solución basada en inteligencia artificial para combatir amenazas cibernéticas crecientes en Colombia, particularmente aquellas que afectan al sector financiero. Ataques como el phishing, smishing y el uso de enlaces maliciosos en plataformas de mensajería representan un riesgo serio para los usuarios, quienes pueden ser engañados para entregar información sensible o instalar malware. Es destacable la necesidad de

un modelo que identifique proactivamente URLs maliciosas, contribuyendo así a mejorar la seguridad digital de usuarios y entidades financieras.

La presente propuesta se fundamenta conceptualmente en el uso de técnicas avanzadas de detección como el aprendizaje automático y profundo (Machine Learning y Deep Learning), y considera múltiples enfoques como Random Forest, SVM, RNN, LSTM y Transformers, así como el uso de embeddings de caracteres y análisis de características léxicas, de contenido y de comportamiento. Además, se consideran distintas técnicas de detección actualmente utilizadas —como listas negras, análisis heurísticos, o herramientas en la nube y el navegador—, se plantea una hipótesis que defiende la eficacia de un modelo híbrido que combine estos elementos para lograr una detección precisa, incluso ante amenazas desconocidas (zero-day).

Se espera que el desarrollo del modelo tenga un alto impacto en la ciberseguridad nacional, permitiendo una reducción en los fraudes financieros mediante la identificación automática de URLs maliciosas. Entre los resultados esperados están la creación de un conjunto de datos específico del sector financiero colombiano, el fortalecimiento de la capacidad científica de la Universidad Distrital y su grupo de investigación LIDER, y la publicación de artículos científicos. El proyecto, además de su valor técnico, tiene proyecciones estratégicas en la mejora de la confianza en los servicios financieros digitales del país.

a. Justificación teórica

La identificación de URLs maliciosas o potencialmente fraudulentas se fundamenta en conceptos y teorías de ciberseguridad, análisis de datos y utilización de herramientas que permitan comprender y anticipar los patrones de comportamiento de los ciberdelincuentes.

La creciente sofisticación de los ataques de phishing, malware e ingeniería social hace necesario el desarrollo de métodos de detección basados en herramientas avanzadas de ciberseguridad.

En este contexto, técnicas como el aprendizaje automático (P. V. Jyothsna, 2019), el análisis de patrones de tráfico web (Bin Liang, 2009), la minería de datos y el reconocimiento de anomalías se vuelven esenciales para construir sistemas capaces de identificar amenazas en tiempo real. Además, la integración de modelos de inteligencia artificial permite no solo la detección reactiva

de URLs maliciosas, sino también la predicción proactiva de nuevas variantes de ataque, mejorando significativamente los tiempos de respuesta y reduciendo el riesgo de incidentes de seguridad.

La combinación de enfoques supervisados y no supervisados, junto con la actualización constante de los algoritmos mediante técnicas de aprendizaje continuo, resulta clave para enfrentar un panorama de amenazas en constante evolución.

b. Justificación metodológica

Un modelo de identificación de URLs maliciosas o potencialmente fraudulentas que aplique técnicas como el aprendizaje automático, el análisis de patrones de tráfico web, la minería de datos y el reconocimiento de anomalías y que además integre modelos de inteligencia artificial resulta de gran valor en la detección de amenazas actuales y futuras. El modelo que se desarrollará en este trabajo podrá aplicarse en la construcción de herramientas de detección rápida de URLs maliciosas o potencialmente fraudulentas.

B. MARCO DE REFERENCIA

Se presenta en esta sección el marco de referencia que servirá como fundamento conceptual para el desarrollo del proyecto propuesto.

a. MARCO TEÓRICO

i. Introducción

Los servicios basados en web (WWW) son ampliamente utilizados para acceder a servicios financieros, compras en línea, redes sociales, entre muchos otros. Las aplicaciones basadas en servicios web actualmente permiten la interacción entre personas de todo el mundo. Todos estos servicios procesan y almacenan grandes cantidades de información sensible de los usuarios personales y corporativos. Esta popularidad y la gran cantidad de información que está disponible también ha motivado y atraído a atacantes quienes realizan actividades ilegales con el fin de obtener un beneficio, frecuentemente económico.

Las páginas web utilizadas para realizar ataques o que contienen algún tipo de código malicioso reciben el nombre de páginas web maliciosas y su detección oportuna es necesaria para garantizar la seguridad de la información de usuarios personales y corporativos.

De acuerdo con el informe “El estado de la ciber seguridad 2025” presentado por Check Point Research los principales vectores de ataque son el correo electrónico y las páginas web (Research, 2025). En el mismo informe se presentan las siguientes estadísticas para el 2024:

- a. El 39% del malware detectado se clasifica como multipropósito y el 19% como ladrón de información.
- b. El top 5 de tipo de organización atacada lo encabeza las Instituciones Educativas seguido por Gobierno, Salud, Telecomunicaciones y Construcción e Ingeniería.
- c. El 61% de ataques enviados por correo electrónico contienen archivos de tipo HTML.

De acuerdo con (Patil D. R., 2015) existen varios tipos de ataques basados en web contra páginas web y aplicaciones web.

- a. Ataques de descarga automática: en este tipo de ataque se descarga automáticamente un malware, virus o código malicioso inmediatamente el usuario visita la página web. Frecuentemente este tipo de descarga ocurre en segundo plano y el usuario no lo nota.
- b. Ataques de secuestro de clics: este tipo de ataque tiene como objetivo que el usuario desencadene una acción dando clic en un lugar específico en la página web. Se impulsa al usuario a dar clic en un mensaje como “Dé clic para obtener \$1.000 dólares”, se redirecciona la página y se incluye un cuadro transparente que contiene una página legítima y reconocida, por ejemplo Instagram.com y se ubica un enlace malicioso sobre el botón de “Me gusta”.
- c. Ataques de plugins: existen muchos plugins que no han recibido actualizaciones y son vulnerables, estos plugins son aprovechados por un atacante para insertar código malicioso.
- d. Ataques de phishing: este tipo de ataque principalmente se realiza a través de correo electrónico y busca hacer creer al destinatario que fue enviado por una persona o empresa legítima y de esa forma robar información personal.

ii. **Uniform Resource Locators**

Las URLs (Uniform Resource Locators), también son conocidas como “enlaces” y son la forma más utilizada de encontrar recursos en internet. Las URLs son cadenas de texto legibles y comprensibles por las personas, pero están construidas de tal manera que pueden ser interpretadas por los dispositivos (MA, 2011).

<https://aulasvirtuales.udistrital.edu.co/mod/assign/view.php?id=316155>

<protocolo>://<nombre de host>/<ruta>

Una URL maliciosa es un enlace construido para llevar al usuario a ejecutar una acción no deseada o potencialmente perjudicial. Las URLs maliciosas pueden adoptar diversas formas, a continuación, se presenta una breve descripción de las más relevantes (Reyes-Dorta, 2024):

URLs de phishing: Enlaces que llevan a páginas que simulan sitios web legítimos con el propósito de engañar al usuario e inducirlo a ingresar información confidencial como nombres de usuario, contraseñas o datos bancarios y así robarlos.

URLs de malware: Direcciones que conducen a la descarga o ejecución de software malicioso.

URLs de comando y control (C2): Utilizadas por botnets para enviar y recibir instrucciones desde un servidor remoto.

URLs de fraude: Vinculadas a esquemas de estafa o sitios falsos que buscan obtener beneficios ilícitos.

Estas URLs pueden estar disfrazadas con técnicas como el uso de acortadores de enlaces, dominios similares a los legítimos (typosquatting) y caracteres especiales.

Cuando un atacante requiere una URL también puede utilizar algoritmos de generación de dominios (DGA, Domain Generation Algorithms) que tienen como objetivo engañar a las herramientas de detección (Bisio, 2017).

iii. **Técnicas de detección**

Existen diversas técnicas de detección que pueden utilizarse de forma individual o en conjunto entre sí haciendo uso de herramientas tradicionales y otras más avanzadas. Algunas de las técnicas más destacadas se presentan a continuación (Tian, 2025):

Listas negras (blacklists): Bases de datos que contienen URLs previamente identificadas como maliciosas. Es una técnica fácil de implementar, pero su principal desventaja es la incapacidad de detectar amenazas nuevas que se conocen como ataques de día cero (zero-day).

Listas blancas (whitelists): Son bases con URLs consideradas seguras. Su aplicación en una red es restrictiva, implica que los usuarios únicamente pueden acceder a las URLs permitidas y pueden limitar la navegación si no están bien administradas.

Reglas heurísticas: La detección heurística se basa en conjuntos de patrones definidos manualmente que identifican comportamientos sospechosos. Es muy efectiva para ciertas amenazas, pero puede ser fácilmente evadida por atacantes sofisticados.

Enfoques de aprendizaje automático y profundo (Machine Learning y Deep Learning): El aprendizaje automático ha demostrado ser una herramienta poderosa para la detección de

URLs maliciosas. A diferencia de los métodos tradicionales, permite identificar amenazas emergentes mediante el aprendizaje de patrones ocultos en los datos. Una forma de detectar este tipo de URLs se presenta en (Bisio, 2017) quienes proponen realizar un análisis de las peticiones DNS resueltas para luego extraer características lingüísticas y semánticas. Con esa información se clasifican e identifican los falsos positivos y se presentan los resultados de interés.

Los análisis se pueden realizar utilizando aprendizaje profundo como el presentado por (Vinayakumar, 2018) quienes evaluaron el desempeño de redes neuronales recurrentes (RNN), memoria larga de corto plazo (LSTM) y otros clasificadores clásicos de aprendizaje de máquina.

Se puede realizar detección automática de dominios generados por algoritmos con un alto porcentaje de éxito, (Lison, 2017) comprobó que el modelo propuesto detectó 93% de los nombres de dominio maliciosos generados.

Otro método de detección es el clasificador multiclase presentado por (Patil D. R., 2018) incluyendo nuevas características de URLs spam, phishing y malware, este método alcanzó un 98.44% de promedio de detección y un 99.86% de precisión de detección.

El reconocimiento de visibilidad anormal presentado por (Bin Liang, 2009) detecta el código ofuscado dentro del código fuente de la página web, obteniendo una tasa del 2,63% de falso negativo y 1,99% de falso positivo.

Dentro de los modelos más utilizados están los siguientes (Li, 2024):

Random Forests: Alta precisión y resistencia al overfitting.

Support Vector Machines (SVM): Eficientes para datos de alta dimensionalidad.

k-Nearest Neighbors (k-NN): Sencillo, pero menos escalable para grandes volúmenes de datos.

Redes Neuronales Recurrentes (RNNs) y LSTMs: Aptas para procesar secuencias de texto como las URLs.

Redes Convolucionales (CNNs): Identifican patrones espaciales en secuencias de caracteres.

Además, existen **técnicas de detección en tiempo real**. La detección en tiempo real es fundamental para evitar que los usuarios interactúen con URLs maliciosas (Singh, 2024).

Acción en el cliente (navegador): Se basa en plugins o extensiones que analizan URLs antes de su carga, notifican al usuario o bloquean su acceso.

Análisis en la nube: Esta técnica utiliza APIs que reciben URLs y devuelven una clasificación rápida.

Sistemas en gateways: Consiste en la integración con firewalls o proxies para filtrar tráfico HTTP/HTTPS sospechoso.

b. MARCO CONCEPTUAL

En esta sección se presentan los conceptos que permitirán fundamentar el desarrollo del proyecto propuesto.

Vector de ataque

Es el camino o método que utiliza un atacante para acceder a un sistema o red con el fin de llevar a cabo acciones maliciosas, como robar datos, instalar malware o interrumpir operaciones. Los vectores de ataque pueden incluir correos electrónicos de phishing, vulnerabilidades de software, dispositivos infectados, entre otros (Perez, 2015).

Malware

Es cualquier tipo de software diseñado para dañar, explotar o comprometer dispositivos, redes o datos. Existen diferentes tipos de malware, como virus, gusanos, troyanos, ransomware y spyware, cada uno con diferentes formas de afectar a sus víctimas (Baca Urbina, 2016).

URL

Siglas de Uniform Resource Locator (Localizador Uniforme de Recursos). Es la dirección específica que se usa para acceder a recursos en internet, como sitios web, documentos o imágenes. Una URL maliciosa es aquella que dirige a contenido dañino o fraudulento (Santos, 2015).

Ofuscamiento

Técnica utilizada para ocultar el verdadero propósito, estructura o contenido de un código o enlace, con el objetivo de dificultar su análisis o detección. En ciberseguridad, los atacantes usan el ofuscamiento para esconder malware o engañar a los sistemas de protección (Baca Urbina, 2016).

Spam

Mensajes electrónicos no solicitados, generalmente enviados de forma masiva, que suelen tener fines publicitarios, de fraude o de propagación de malware. Aunque el spam puede ser solo molesto, también puede ser un vehículo para ataques más peligrosos (Perez, 2015).

Phishing

Técnica de ingeniería social que busca engañar a las personas para que revelen información confidencial, como contraseñas, números de tarjetas de crédito o datos personales, haciéndose pasar por una entidad confiable a través de correos electrónicos, mensajes o sitios web falsificados (Santos, 2015).

Comando y Control (C2)

Se refiere al método y la infraestructura que los atacantes utilizan para comunicarse y controlar de forma remota los sistemas informáticos que han comprometido (a menudo mediante malware) (Baca Urbina, 2016).

Typosquatting

Los atacantes registran nombres de dominio que son ligeramente diferentes de los sitios web legítimos y populares, anticipando que los usuarios cometerán errores comunes al teclear. Cuando un usuario introduce por error una URL con una pequeña equivocación (un "typo"), es redirigido a este sitio falso en lugar del sitio original (Santos, 2015).

Los errores comunes que explotan los typosquatters incluyen:

Errores de escritura/omisiones: Por ejemplo, "gogle.com" en lugar de "google.com".

Transposiciones: Cambiar el orden de las letras, como "https://www.google.com/search?q=faecbook.com" en lugar de "facebook.com".

Letras adyacentes en el teclado: Usar una letra cercana en el teclado, como "amazom.com" en lugar de "amazon.com".

Dominio de nivel superior (TLD) incorrecto: Usar ".cm" o ".org" en lugar de ".com" (por ejemplo, "amazon.co" en lugar de "amazon.com").

Omisión o adición de guiones: Si el dominio legítimo es "https://www.google.com/search?q=mi-banco.com", podrían registrar "mibanco.com" o "https://www.google.com/search?q=mi--banco.com".

Acortadores de enlaces: Servicios que convierten URLs largas en cortas, ocultando su destino real.

Listas negras (blacklists)

Es una lista de entidades, elementos o comportamientos que se consideran maliciosos, no deseados o sospechosos, y a los que se les niega el acceso o la ejecución dentro de un sistema, red o servicio.

Funciona bajo el principio de "todo lo que no está en esta lista es permitido", a diferencia de una "lista blanca" (whitelist), que opera bajo el principio de "solo lo que está en esta lista es permitido" (Perez, 2015).

Listas blancas (whitelists)

Una lista blanca (whitelist) es una lista de entidades, elementos o comportamientos que se consideran seguros, confiables o autorizados, y a los que se les concede explícitamente el acceso o la ejecución dentro de un sistema, red o servicio.

Funciona bajo el principio de "solo lo que está en esta lista es permitido", mientras que todo lo demás (lo que no está en la lista) es automáticamente denegado o bloqueado. Es el opuesto de una "lista negra" (blacklist), que opera bajo el principio de "todo lo que no está en esta lista es permitido" (Perez, 2015).

Reglas heurísticas

Las reglas heurísticas (o análisis heurístico) se refieren a un enfoque basado en la experiencia, el comportamiento y los patrones para detectar amenazas cibernéticas, especialmente aquellas que son nuevas o desconocidas (conocidas como "zero-day"), sin depender de firmas específicas ya catalogadas.

A diferencia de la detección basada en firmas (que busca coincidencias exactas con códigos maliciosos conocidos), la heurística utiliza un conjunto de reglas y algoritmos para identificar actividades o características sospechosas (Baca Urbina, 2016).

Aprendizaje automático (Machine Learning)

El Aprendizaje Automático (Machine Learning - ML) es una rama de la Inteligencia Artificial (IA) que permite a los sistemas informáticos aprender de los datos, identificar patrones, tomar decisiones y mejorar su rendimiento con el tiempo sin ser programados explícitamente para cada tarea.

Consiste en entrenar algoritmos con grandes volúmenes de datos históricos y en tiempo real. Estos datos pueden incluir tráfico de red, registros de eventos (logs), archivos de malware, comportamientos de usuario, información de ataques anteriores, etc.

En ciberseguridad, el ML es una herramienta poderosa que ayuda a los profesionales a combatir el creciente volumen y la sofisticación de las ciberamenazas (Bisio, 2017).

Aprendizaje profundo (Deep Learning)

El Aprendizaje Profundo (Deep Learning - DL) es una subcategoría del Aprendizaje Automático (Machine Learning - ML) que utiliza redes neuronales artificiales (ANN) con múltiples capas (profundas) para aprender de los datos. Estas redes están inspiradas en la estructura y función del cerebro humano y son excepcionalmente buenas para identificar patrones complejos en grandes volúmenes de datos.

Mientras que el ML tradicional a menudo requiere que los ingenieros "ingenien" (extraigan) manualmente las características relevantes de los datos para que el algoritmo aprenda, el DL tiene la capacidad de aprender y extraer automáticamente estas características directamente de los datos crudos. Esta es su principal ventaja y lo que lo hace tan potente para tareas complejas en ciberseguridad (Vinayakumar, 2018).

Ingeniería de características

La ingeniería de características (Feature Engineering) se refiere al proceso de transformar los datos brutos disponibles en características significativas y relevantes que puedan ser utilizadas eficazmente por modelos de aprendizaje automático (Machine Learning) para la detección, prevención y mitigación de amenazas cibernéticas.

En esencia, es el arte y la ciencia de crear nuevas variables o modificar las existentes a partir de los datos originales, de manera que el modelo pueda aprender patrones y relaciones más fácilmente, mejorando así su rendimiento en tareas de seguridad (Singh, 2024).

Características léxicas

Las características léxicas (o "lexical features" en inglés) se refieren a los atributos que se pueden extraer y analizar a partir del lenguaje, las palabras, los caracteres o los patrones de texto presentes en diferentes tipos de datos. Estas características no se centran en el significado semántico profundo, sino en las propiedades superficiales de la cadena de texto, como su composición, longitud, o la presencia de ciertos caracteres o patrones.

Las características léxicas son una forma de ingeniería de características que es particularmente útil en ciberseguridad porque muchos ataques y amenazas dejan "huellas" distintivas en el texto. Al analizar estas huellas, los modelos de machine learning pueden identificar y clasificar actividades maliciosas (Singh, 2024).

Características de WHOIS

Las características de WHOIS se refieren a la información y los metadatos que se pueden extraer de los registros WHOIS de nombres de dominio y direcciones IP. WHOIS es un protocolo de consulta y una base de datos que almacena información sobre quién es el propietario de un nombre de dominio o un bloque de direcciones IP, cuándo fue registrado, cuándo expira, y detalles de contacto (Li, 2024).

Características de comportamiento

Las características de comportamiento (o "behavioral features" en inglés) se refieren a los patrones y anomalías observadas en la actividad de usuarios, sistemas, aplicaciones o redes a lo largo del tiempo. A diferencia de las características estáticas (como las léxicas o WHOIS), que examinan atributos fijos, las características de comportamiento se centran en el dinamismo y la evolución de las interacciones y los procesos.

El objetivo principal de analizar las características de comportamiento es establecer una línea base de "comportamiento normal" y luego identificar desviaciones significativas que podrían indicar una actividad maliciosa. Este enfoque es fundamental para detectar amenazas avanzadas que pueden evadir la detección basada en firmas, ya que no se basan en conocer una amenaza específica de antemano, sino en reconocer un comportamiento inusual (Li, 2024).

Características de contenido

Las características de contenido (o "content features" en inglés) se refieren a los atributos intrínsecos y los patrones presentes dentro del cuerpo o los datos de un archivo, un paquete de red, un correo electrónico, una página web, o cualquier otra fuente de información digital. A diferencia de las características léxicas que se centran en la superficie del texto o las características de comportamiento que observan la actividad a lo largo del tiempo, las características de contenido profundizan en la naturaleza y composición interna de los datos mismos (Tian, 2025).

El análisis de las características de contenido es crucial para detectar amenazas que residen directamente en los datos, como malware, archivos maliciosos, información confidencial, o la presencia de exploit kits.

Clasificación binaria

La clasificación binaria es un tipo de problema de aprendizaje automático supervisado donde un sistema o algoritmo es entrenado para categorizar datos en una de dos clases posibles. Es decir, el objetivo es predecir una de dos posibles respuestas (Tian, 2025).

Algunos ejemplos clave de cómo se aplica la clasificación binaria en ciberseguridad incluyen:

Detección de malware: Clasificar un archivo o un comportamiento como "malicioso" (malware) o "benigno" (legítimo).

Detección de intrusiones: Determinar si una actividad en la red es "normal" o "anómala/maliciosa" (una intrusión).

Detección de spam: Etiquetar un correo electrónico como "spam" o "no spam".

Detección de fraude: Identificar una transacción como "fraudulenta" o "no fraudulenta".

Clasificación de URLs: Distinguir entre URLs "seguras" y "maliciosas" (phishing, malware, etc.).

Análisis de vulnerabilidades: Determinar si un fragmento de código o una configuración es "vulnerable" o "seguro".

Random Forest

Random Forest (Bosque Aleatorio) es un algoritmo de aprendizaje automático de tipo ensemble (conjunto) muy popular y efectivo, utilizado para tareas de clasificación y regresión. Su fuerza

reside en combinar la salida de múltiples árboles de decisión para llegar a una predicción final más robusta y precisa que la de un solo árbol (Lison, 2017).

Support Vector Machine (SVM)

Una Support Vector Machine (SVM) o Máquina de Vectores de Soporte es un potente algoritmo de aprendizaje automático supervisado que se utiliza principalmente para problemas de clasificación binaria, aunque también puede aplicarse a la regresión. Su objetivo principal es encontrar el "mejor" hiperplano que separe las clases en un conjunto de datos, maximizando el margen entre ellas (Chowdhury, 2024).

k-Nearest Neighbors (k-NN)

k-Nearest Neighbors (k-NN) es un algoritmo de aprendizaje automático no paramétrico y basado en instancias (o "lazy learning") que se utiliza principalmente para clasificación y, en menor medida, para regresión (Fangli Ren, 2020).

Red Neuronal Recurrente (RNN)

Una Red Neuronal Recurrente (RNN) es un tipo de red neuronal artificial especializada en el procesamiento de datos secuenciales o series temporales. A diferencia de las redes neuronales "feedforward" (de avance), que procesan cada entrada de forma independiente, las RNN tienen conexiones que forman bucles, lo que les permite mantener un "estado interno" o "memoria" de la información de pasos temporales anteriores. Esta capacidad de "recordar" el contexto pasado las hace excepcionalmente adecuadas para analizar patrones que evolucionan con el tiempo (P. V. Jyothsna, 2019).

LSTM

LSTM (Long Short-Term Memory) es un tipo avanzado y muy efectivo de Red Neuronal Recurrente (RNN), diseñado específicamente para superar las limitaciones de las RNN tradicionales, particularmente el problema del gradiente desvanecedor. Esto permite a las LSTM aprender y recordar dependencias a largo plazo en datos secuenciales o series temporales (Patil D. R., 2015).

Red Neuronal Convolucional (CNN)

Una Red Neuronal Convolucional (CNN), también conocida como ConvNet, es un tipo de red neuronal profunda que ha demostrado ser excepcionalmente eficaz en el procesamiento de datos con una estructura similar a una cuadrícula, como imágenes, pero también señales y

otros datos representados espacialmente. Aunque inicialmente ganó fama en la visión por computadora, sus principios se han adaptado con éxito para diversas aplicaciones en ciberseguridad (P. V. Jyothsna, 2019).

Embedding de caracteres

Un embedding de caracteres (o character embedding) es una técnica de procesamiento de lenguaje natural (PLN) y aprendizaje automático que representa cada carácter individual (letras, números, símbolos, espacios) como un vector numérico denso y de baja dimensión en un espacio vectorial.

A diferencia de los embeddings de palabras (word embeddings) que representan palabras completas, los embeddings de caracteres se centran en las unidades más pequeñas del texto (Singh, 2024).

Modelo Transformer

Un Modelo Transformer es una arquitectura de red neuronal profunda que ha revolucionado el procesamiento de lenguaje natural (PLN) y el análisis de secuencias, y que cada vez más se aplica a la detección y respuesta a amenazas en ciberseguridad. A diferencia de las Redes Neuronales Recurrentes (RNNs) y las LSTM, que procesan las secuencias paso a paso, los Transformers utilizan un mecanismo de auto-atención (self-attention) que les permite procesar todos los elementos de una secuencia simultáneamente y capturar dependencias a largo plazo de manera muy eficiente (Tian, 2025).

BERT

BERT (Bidirectional Encoder Representations from Transformers) es un modelo de lenguaje pre-entrenado de última generación basado en la arquitectura Transformer, desarrollado por Google. Su impacto en el procesamiento de lenguaje natural (PLN) ha sido enorme, y su aplicación en ciberseguridad está abriendo nuevas vías para la detección, análisis y respuesta a amenazas (Fangli Ren, 2020).

Inferencia en tiempo real

La inferencia en tiempo real se refiere a la capacidad de un sistema de seguridad (típicamente impulsado por aprendizaje automático o IA) para analizar instantáneamente datos entrantes o eventos en vivo y tomar una decisión o acción de seguridad casi de inmediato después de que el evento ocurre.

El objetivo principal de la inferencia en tiempo real en ciberseguridad es detectar y responder a las amenazas de forma proactiva y lo más rápido posible, minimizando el tiempo de permanencia de los atacantes en la red y reduciendo el impacto potencial de un ciberataque (Tian, 2025).

Detección en el cliente

La detección en el cliente (o client-side detection) se refiere a los métodos y tecnologías que operan y realizan análisis directamente en el dispositivo del usuario final (el "cliente"), como un ordenador de escritorio, portátil, servidor, dispositivo móvil o incluso un navegador web.

A diferencia de la detección en el lado del servidor o en la red, donde el análisis ocurre en la infraestructura central o en los puntos de interconexión de la red, la detección en el cliente se enfoca en lo que sucede en el dispositivo individual o en el entorno local del usuario (Santos, 2015).

Análisis en la nube

El análisis en la nube (o cloud analytics para seguridad) se refiere a la utilización de los recursos y capacidades de las plataformas de computación en la nube (como AWS, Azure, Google Cloud Platform) para recopilar, procesar, almacenar y analizar grandes volúmenes de datos de seguridad con el fin de detectar, investigar y responder a amenazas cibernéticas.

Es una evolución de los sistemas de análisis de seguridad tradicionales (como los SIEMs locales), que aprovecha la escalabilidad, flexibilidad y las capacidades avanzadas de IA/ML que ofrece la nube (Li, 2024).

Ataques adversariales

Los ataques adversariales (también conocidos como adversarial attacks o adversarial machine learning) son un tipo de técnica sofisticada diseñada para engañar o manipular modelos de aprendizaje automático (ML) que se utilizan en sistemas de seguridad. El objetivo de estos ataques no es explotar una vulnerabilidad de software tradicional, sino explotar las debilidades inherentes al funcionamiento de los propios algoritmos de ML (Singh, 2024).

1.8 Referencias

Baca Urbina, G. (2016). *Introducción a la seguridad informática*. Grupo Editorial Patria.

Bin Liang, J. H. (2009). Malicious Web Pages Detection Based on Abnormal Visibility Recognition. *E-Business and Information System Security*, 2009. EBISS '09.

Bisio, F. S. (2017). Realtime behavioural DGA detection through machine learning. *International Carnahan Conference on Security Technology (ICCST)*.

Chowdhury, T. O. (2024). A systematic review on research utilising artificial intelligence for open source intelligence (OSINT) applications. *International Journal of Information Security*.

Fangli Ren, Z. J. (2020). A DGA domain names detection modeling method based on integrating an attention mechanism and deep neural network. *Cybersecurity Springer Open*.

GrupLAC - Plataforma SCienTI - Colombia. (s.f.). Obtenido de <https://scienti.minciencias.gov.co/gruplac/jsp/visualiza/visualizagr.jsp?nro=00000000005315>

Juan, I. D. (05 de 04 de 2024). *Infobae*. Obtenido de Alerta de estafa: mensajeros falsos en Nequi ¡Cuidado con los enlaces sospechosos!: <https://www.infobae.com/tecno/2024/04/05/nequi-envian-mensajes-de-texto-con-transacciones-falsas-y-cualquiera-puede-caer/>

Li, S. &. (2024). Enhancing Online Security: A Novel Machine Learning Framework for Robust Detection of Known and Unknown Malicious URLs. *Journal of Theoretical & Applied Electronic Commerce Research*, 2919–2960.

Lison, P. M. (2017). Automatic detection of malware-generated domains with recurrent neural models. *The Norwegian Information Security Conference 2017 NISK 2017*.

MA, J. S. (2011). Learning to Detect Malicious URLs. *ACM Transactions on Intelligent Systems and Technology*, 1-24.

P. V. Jyothsna, G. P. (2019). Detecting DGA Using Deep Neural Networks (DNNs). *International Symposium on Security in Computing and Communications*, 695–706.

Parra, P. A. (02 de 01 de 2025). *El Tiempo*. Obtenido de Reportan nueva modalidad de estafa usando los logos e imagen del D1: prometen millonario premio: <https://www.eltiempo.com/cultura/gente/reportan-nueva-modalidad-de-estafa-usando-los-logos-e-imagen-del-d1-3414161>

- Patil, D. R. (2015). Survey on Malicious Web Pages Detection Techniques. *International Journal of u- and e- Service, Science and Technology*, 195-206.
- Patil, D. R. (2018). Feature-based Malicious URL and Attack Type Detection Using Multi-class Classification. *The ISC Int'l Journal of Information Security*, 141-162.
- Perez, J. C. (2015). *Protección de Datos y Seguridad de la Información*. Madrid: Paracuellos de Jarama, Madrid: RA-MA Editorial.
- Research, C. P. (2025). The State of Cyber Security 2025.
- Reyes-Dorta, N. C.-G.-R. (2024). Detection of malicious URLs using machine learning. *Wireless Networks: The Journal of Mobile Communication, Computation and Information*, 7543–7560.
- Santos, J. C. (2015). *Seguridad informática*. RA-MA Editorial.
- Singh, A. C. (2024). Guardian Shield: A Machine Learning Approach for Proactive Malicious URL Detection. *Grenze International Journal of Engineering & Technology (GIJET)*, 4118–4121.
- Tian, Y. Y. (2025). *From Past to Present: A Survey of Malicious URL Detection Techniques, Datasets and Code Repositories*. arXiv.
- Vinayakumar, R. S. (2018). Detecting malicious domain names using deep learning approaches at scale. *Journal of intelligent & fuzzy systems*.