



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**

Dinámica Energética del Malware: Autoorganización Morfológica de su Identidad Comportamental

Trabajo de investigación para optar por el título de
Magíster en Ciencias de la Información y las Comunicaciones

Andrés David Montenegro Alvarado

Director: Nelson Enrique Vera Parra

Bogotá D. C. – Colombia

Mayo de 2026

Índice general

1. RESUMEN DEL PROYECTO	4
2. FORMULACIÓN DEL PROBLEMA	5
3. MARCO TEÓRICO	8
3.1. MARCO CONCEPTUAL	9
3.1.1. Malware	9
3.1.2. Grafos Heterogéneos	10
3.1.2.1. Formalización tipada y meta-relaciones	12
3.1.3. Aprendizaje de Grafos	13
3.1.3.1. Heterogeneous Graph Transformer (HGT)	15
3.1.4. Arquitecturas Predictivas de Embeddings Conjuntos	17
3.1.4.1. Joint-Embedding Predictive Architectures (JEPA)	17
3.1.4.2. Graph-JEPA	18
3.1.5. Modelos Basados en Energía	20
3.1.5.1. Modelos basados en energía y muestreo	22
3.1.5.2. Entrenamiento por máxima verosimilitud	23
3.2. ESTADO DEL ARTE	25
4. OBJETIVOS	28
4.1. Objetivo General	29
4.2. Objetivos Específicos	30
5. HIPÓTESIS	31
5.1. HIPÓTESIS GENERAL	33
5.2. HIPÓTESIS ESPECÍFICAS	34
6. MARCO METODOLÓGICO	35
6.1. LA NATURALEZA COMPORTAMENTAL DEL MALWARE	36
6.1.1. La gramática comportamental del Malware: sintaxis y semántica maliciosa	36
6.1.2. Invarianza semántica y morfología energética: hacia un modelo autoorganizado del comportamiento	36
6.2. DISEÑO GENERAL DE LA METODOLOGÍA DE INVESTIGACIÓN	38

6.2.1.	De la Información al Conocimiento: Un Enfoque Multinivel para el Estudio Comportamental del Malware	38
6.3.	FLUJO METODOLÓGICO: DE LOS EVENTOS OBSERVABLES A LA EMERGENCIA DEL CONOCIMIENTO	40
6.3.1.	Estructuración del dominio informacional	40
6.3.1.1.	Construcción del grafo heterogéneo del comportamiento del malware	40
6.3.2.	Codificación Representacional: Del Espacio Sintáctico a la Coherencia Semántica	42
6.3.2.1.	Codificador representacional y aprendizaje auto-supervisado	42
6.3.2.2.	Partición de subgrafos heterogéneos mediante Att-LPA	43
6.3.2.3.	Codificación de subgrafos con HGT compartido	45
6.3.2.4.	Encoders de contexto y objetivo, predictor y pretexto predictivo	46
6.3.2.5.	Protocolos de evaluación de la representación	48
6.3.3.	Emergencia del Paisaje Energético: Dinámica Morfológica del Comportamiento del Malware	50
6.3.3.1.	Modelo basado en energía condicional sobre el espacio latente JEPA	51
6.3.3.2.	Muestreo de negativos: Langevin condicional con <i>replay buffer</i>	52
6.3.3.3.	Objetivo: entrenamiento por máxima verosimilitud con regularización	52
6.3.3.4.	Bucle de entrenamiento del modelo basado en energía	53
6.3.4.	Del Paisaje Energético a la Narrativa Comportamental: Hacia una Interpretación Morfológica del Malware	54
6.3.5.	Evaluación Representacional del Conocimiento Energético Autoorganizado	54
6.4.	MARCO EXPERIMENTAL	56
6.4.1.	Conjunto de datos	56
6.4.2.	Particiones de preentrenamiento y evaluación	57
6.4.3.	Métricas de desempeño	59
6.4.4.	Hiperparámetros	60
6.4.5.	Modelos basados en energía	62
6.4.6.	Análisis topológico del paisaje energético	62
6.4.6.1.	Caso de estudio	63
6.4.6.2.	Topología del conjunto de subnivel	63
6.4.6.3.	Topología de los mínimos locales	64
6.4.7.	Matriz de objetivos, fases metodológicas y resultados esperados	65

7. RESULTADOS	67
7.1. RESULTADOS PRINCIPALES	68
7.2. ABLACIÓN SOBRE EL NÚMERO DE OBJETIVOS K	70
7.3. COHERENCIA DEL PAISAJE ENERGÉTICO CON LAS FAMILIAS DEL CON- JUNTO DE DATOS	72
7.4. ANÁLISIS TOPOLÓGICO DEL PAISAJE ENERGÉTICO PARA EMOTET . . .	73
7.4.1. Topología del conjunto de subnivel	73
7.4.2. Topología de los mínimos locales	75
8. CONCLUSIONES	78
9. PRINCIPALES APORTES	80
10. RECOMENDACIONES Y TRABAJOS FUTUROS	81
11. BIBLIOGRAFÍA	83

1. RESUMEN DEL PROYECTO

La proliferación de código malicioso generado, modificado o asistido por grandes modelos de lenguaje ha impactado en la producción y evolución del malware, permitiendo la creación acelerada de variantes mediante transformaciones sintácticas deliberadas que cambian con una rapidez que supera ampliamente la capacidad de adaptación de los mecanismos de detección tradicionales. Estas mutaciones de forma incrementan de manera significativa la capacidad de evasión del malware y erosionan cualquier enfoque que dependa de la representación sintáctica del código fuente. Partiendo de la premisa de que los patrones comportamentales del malware —las invarianzas semánticas del ataque— preservan la identidad funcional del comportamiento malicioso a pesar de las alteraciones en su representación sintáctica, esta investigación propone un modelo basado en energía autoorganizado capaz de hacer emerger una morfología energética que describa de manera coherente la semántica maliciosa del ataque.

2. FORMULACIÓN DEL PROBLEMA

La irrupción de los Grandes Modelos de Lenguaje (LLMs) ha transformado de manera radical la relación entre la humanidad y el conocimiento, democratizando el acceso a capacidades cognitivas avanzadas y acelerando procesos creativos, científicos, comerciales y de ingeniería. Este salto tecnológico marca un punto de inflexión en nuestra civilización: esa misma potencia cognitiva generativa que expande la frontera del conocimiento y la creatividad humanas también redefine el panorama del riesgo cibernético, amplificando la escala y sofisticación de las amenazas digitales. Entre ellas, el uso malicioso de los LLMs para automatizar de manera creativa y sin precedentes la generación, adaptación o diseminación de software malicioso (malware), propiciando la producción de mutaciones adversariales que dificulten su detección tradicional, redefiniendo las fronteras de la defensa cibernética y dando paso a un nuevo paradigma de riesgo y resiliencia de las amenazas cibernéticas a escala global.

En la intersección entre el modelado dinámico del comportamiento del malware mediante redes de información heterogéneas y la ciberseguridad, los enfoques actuales basados en representaciones latentes y clasificación supervisada han permitido modelar las interacciones causales y correlacionales más relevantes entre eventos a nivel de entidad del sistema —tales como procesos creados, archivos modificados, conexiones de red establecidas o modificaciones a registros de memoria—, capturando patrones característicos del comportamiento subyacente del malware. Sin embargo, estos enfoques presentan limitaciones tanto en su capacidad de generalización frente a mutaciones de malware como en la posibilidad de acceder a una interpretación estructural y evolutiva del espacio de representación que permita discernir las fases de ataque característicos de una familia de malware.

En este contexto, se propone un modelo de aprendizaje de representaciones capaz de extraer características latentes a partir de la red heterogénea de información del sistema, sobre el cual pueda modelarse una distribución energética que describa las relaciones dinámicas entre eventos maliciosos. Este marco permite reformular la tarea de reconocimiento de familias de malware —tradicionalmente tratada como un problema de clasificación— en términos de un problema de optimización sobre un paisaje energético, donde dicho paisaje evoluciona en el tiempo representando las trayectorias dinámicas hacia los atractores asociados a las diferentes fases del ataque característicos de cada familia de malware.

Desde la perspectiva de este nuevo enfoque, un ataque puede entenderse como una secuencia de atractores topológicos que emergen conforme el malware ejecuta secuencialmente su carga maliciosa, revelando las deformaciones locales en la topología del paisaje energético inducidas por la evolución temporal de su comportamiento. Estas trayectorias temporales permiten identificar fases estables que expresan la estrategia subyacente de cada familia de malware, proporcionando una representación más rica e interpretable de su dinámica evolutiva frente a mutaciones de malware.

El impacto de esta reformulación en términos energéticos se manifiesta en la posibilidad de hacer emerger un paisaje energético capaz de representar la morfología estructural y evolutiva de los patrones coherentes que prevalecen en las interacciones comportamentales de las variantes del malware con su entorno. Tal representación energética debería ofrecer una comprensión lo suficientemente profunda de la dinámica del malware, concediendo al modelo la suficiente versatilidad para ser empleado en diversas tareas específicas, como identificar las fases de ataque —tales como propagación, evasión o explotación—, la clasificación de comportamientos maliciosos y anticipar sus trayectorias dinámicas.

Al modelar la dinámica del malware como un sistema complejo que evoluciona hacia configuraciones de mínima energía, el modelo revelará cómo la morfología del paisaje energético impone relieves que canalizan la dinámica hacia patrones coherentes y representativos de cada familia, haciendo visibles su identidad comportamental subyacente y, posiblemente, ofreciendo la robustez suficiente frente a comportamientos evasivos del malware.

La potencia conceptual de este enfoque permitiría que los mecanismos de defensa cibernética evolucionen hacia sistemas predictivos y adaptativos, capaces de anticipar trayectorias maliciosas y neutralizar amenazas mediante su comprensión de la dinámica evolutiva del malware. Además, la naturaleza generativa de los Modelos Basados en Energía permitiría simular mutaciones adversariales consistentes con la identidad de cada familia de malware, fortaleciendo tanto las capacidades de detección como de resiliencia dentro del ecosistema de la ciberseguridad. En este contexto, la sinergia entre el aprendizaje auto-supervisado y el modelamiento basado en energía constituyen un pilar fundamental para la emergencia de estructuras latentes que codifiquen la idiosincrasia comportamental de cada familia de malware, sin necesidad de etiquetado explícito de familias o fases de ataque, aprovechando únicamente la semántica intrínseca presente en las secuencias de ejecución maliciosas.

A partir de estas consideraciones, el problema que aborda esta investigación es determinar ¿qué características debe poseer un modelo energético autoorganizado para hacer emerger un paisaje dinámico en el que cada familia de malware moldee su singular morfología estructural y evolutiva, revelando patrones coherentes capaces de caracterizar su identidad comportamental subyacente?

Con base en la pregunta de investigación, a continuación se presenta la sistematización del problema mediante las subpreguntas que orientan el desarrollo metodológico de la investigación.

¿Cómo estructurar la secuencia de eventos del malware en una red de información heterogénea en tiempo discreto para formalizar la sintaxis temporal que describe la dinámica de su comportamiento malicioso?

¿Cómo generar representaciones en espacio latente capaces de capturar la coherencia sintáctica y semántica de los eventos comportamentales del malware a partir de su red de información heterogénea en tiempo discreto?

¿Cómo inducir la autoorganización necesaria para hacer emerger una morfología energética evolutiva que genere trayectorias dinámicas discretas representativas de la evolución temporal del comportamiento del malware?

¿Cómo analizar las trayectorias dinámicas del paisaje energético para evaluar la coherencia y la estabilidad morfológica con las que este representa los patrones comportamentales evolutivos que distinguen la identidad de distintas familias de malware?

3. MARCO TEÓRICO

3.1 MARCO CONCEPTUAL

3.1.1 Malware

El malware es un software que ataca de forma perjudicial a otros sistemas provocando desviaciones entre el comportamiento previsto y el comportamiento real, falsificando las condiciones necesarias para la corrección funcional y generando estados de incorrectitud operativa (Kramer & Bradfield, 2010). Al ejecutarse en el sistema comprometido como cualquier otro programa, traduce las intenciones del actor malicioso en instrucciones que operan sobre recursos específicos del entorno, cada instrucción constituye una acción puntual sobre un recurso y la composición estructural de estas acciones conforma la narrativa comportamental que expresa la estrategia del programa malicioso (A. Grégio et al., 2016; A. R. A. Grégio et al., 2014).

El surgimiento contemporáneo del malware, originado desde el primer ejemplar de malware autorreplicable conocido como Morris Worm en 1988 y consolidado con la masificación de los sistemas operativos de escritorio y móviles, amplió de manera exponencial la superficie de ataque y la complejidad del ecosistema digital, generando un entorno propicio para la explotación de fallas estructurales (Shalaginov et al., 2020). En este contexto, la aceleración de los ciclos de desarrollo y entrega de software ha degradado los estándares de ciberseguridad, introduciendo vulnerabilidades conocidas, no corregidas o inadvertidas, como evidencia el OWASP Top 10, lo que constituye una causa raíz que habilita la ejecución de comandos restringidos, accesos indebidos y otras formas de explotación maliciosa (Shalaginov et al., 2020). Actores maliciosos con profundo conocimiento técnico explotan sistemáticamente estos eslabones débiles, identificando activos valiosos, escenarios de intrusión y mecanismos comunes de explotación, frecuentemente sin que los sistemas de vigilancia detecten sus intenciones mientras no se manifiestan de forma explícita (Shalaginov et al., 2020). En esta convergencia, las vulnerabilidades dejan de ser defectos aislados para convertirse en puntos de ruptura estructural que el malware instrumentaliza como vías de acceso, persistencia y control dentro del sistema comprometido.

El descubrimiento tradicional del malware se ha basado en un procedimiento secuencial que inicia con el registro de actividades sospechosas y continúa con la identificación de artefactos relevantes, la localización de los binarios potencialmente involucrados, la verificación de sus huellas criptográficas frente a repositorios de muestras benignas y maliciosas, la ingeniería inversa para comprender su lógica interna y, finalmente, la asignación de una categoría, familia y variante que permita generar firmas y mecanismos de alerta para los sistemas de protección (Shalaginov et al., 2020). Este proceso puede ser descrito desde dos enfoques complementarios: el análisis estático, orientado a examinar las propiedades sintácticas del archivo sin ejecutarlo, y el análisis dinámico, centrado en observar

la influencia del binario durante su ejecución en el sistema comprometido, produciendo evidencia sintáctica y comportamental para su reconocimiento (Jacob et al., 2008; Shalaginov et al., 2020). Sin embargo, la comunidad de ciberseguridad ha enfrentado el desafío persistente de realizar estas tareas con la rapidez y eficiencia necesarias para identificar componentes maliciosos, clasificarlos y derivar recomendaciones de mitigación antes de que el ataque se consolide, especialmente ante la velocidad y variabilidad contemporánea del malware (Jacob et al., 2008; Shalaginov et al., 2020). Un ejemplo de esta limitación temporal es el gusano Sapphire, capaz de infectar más del 90 % de las máquinas vulnerables en menos de diez minutos, superando por completo la capacidad de reacción de los mecanismos tradicionales de análisis (Jacob et al., 2008).

La caracterización del malware enfrenta un problema estructural derivado de la modularidad que define su desarrollo contemporáneo: filtraciones de código fuente, como las de SpyEye y Zeus, evidencian que las muestras se construyen mediante la integración de componentes funcionales independientes que pueden combinarse en múltiples ensamblajes (Yavvari et al., 2012). Pese a esta complejidad composicional, la industria antivirus ha mantenido esquemas de categorización centrados en la actividad maliciosa dominante —virus, gusano, spyware, fakeAV o adware—, asignando etiquetas basadas en un solo componente dominante y desatendiendo la multiplicidad de funciones que coexisten en una misma muestra (Yavvari et al., 2012). Incluso los intentos posteriores de clasificación más detallada mediante estructuras jerárquicas de decisión resultan insuficientes para etiquetar adecuadamente malware que incorpora componentes pertenecientes a tipos distintos definidos en la jerarquía (Yavvari et al., 2012). Iniciativas como MAEC han propuesto una clasificación centrada en el conjunto de comportamientos para mitigar estas inconsistencias, pero los métodos de agrupamiento tradicionales continúan capturando únicamente el comportamiento dominante, ignorando componentes con huellas pequeñas pero semánticamente relevantes (Yavvari et al., 2012). Así, la diversidad y granularidad del malware moderno desborda los modelos clásicos de categorización, que no logran representar la naturaleza multi-componente que define su identidad funcional.

3.1.2 Grafos Heterogéneos

El desarrollo de la inteligencia artificial ha permitido que las arquitecturas de aprendizaje profundo alcancen un desempeño sobresaliente en datos euclidianos, como texto, imágenes y secuencias, automatizando la extracción de características mediante modelos altamente estructurados. Sin embargo, estas técnicas muestran limitaciones cuando se enfrentan a datos cuya naturaleza no-euclidiana imposibilita su representación para datos estructurados como grafos (Ratna et al., 2025). Para abordar este desafío, los Graph Neural Networks fueron concebidos como un marco capaz de adaptar los principios del aprendizaje profundo al dominio de los grafos, permitiendo modelar relaciones

complejas entre entidades interconectadas (Ratna et al., 2025).

Los grafos constituyen una estructura expresiva para modelar sistemas donde las entidades y sus relaciones presentan configuraciones que no pueden organizarse en formas regulares. Un grafo está compuesto por un conjunto de nodos que representan elementos del sistema y un conjunto de relaciones que describe sus interacciones, junto con atributos que permiten caracterizar sus propiedades y el contexto en que operan (M. Li et al., 2026; Mu et al., 2025). Mientras que los grafos homogéneos suponen que todos los nodos y conexiones pertenecen a un mismo tipo, los grafos heterogéneos amplían esta capacidad al integrar múltiples clases de elementos y vínculos dentro de una misma representación (Ratna et al., 2025). Esta característica resulta esencial en escenarios donde diferentes componentes del sistema participan de modo conjunto y no pueden describirse mediante una sola categoría estructural. En consecuencia, los grafos heterogéneos constituyen una herramienta indispensable para capturar la complejidad relacional en diferentes dominios (M. Li et al., 2026; Liu et al., 2021)

Un grafo heterogéneo incorpora distintos tipos de nodos y relaciones, cada uno con atributos que permiten distinguir sus funciones e interacciones en el sistema (S. Li et al., 2025). Esta organización fortalece la capacidad de representación al admitir configuraciones que requieren diferenciar entidades y conexiones para describir adecuadamente su comportamiento, una necesidad común en áreas donde los objetos y sus vínculos tienen naturalezas diversas (S. Li et al., 2025; Mu et al., 2025). Su principal ventaja radica en que permiten integrar esta información en una estructura única sin perder coherencia interna. Por ello, se utilizan ampliamente en contextos donde participan elementos heterogéneos —como redes de usuarios y recursos, motores de recomendación o análisis basados en secuencias de eventos— y donde capturar adecuadamente estas interacciones es clave para la tarea a resolver (Liu et al., 2021; Mu et al., 2025). Esta flexibilidad los posiciona como modelos adecuados para aplicaciones que requieren comprender sistemas con relaciones complejas.

Un grafo heterogéneo puede expresarse como

$$G = (V, E, X, T_V, T_E) \quad (3.1)$$

donde $V = \{v_1, \dots, v_n\}$ es el conjunto de nodos y $E \subseteq V \times V$ es el conjunto de relaciones entre ellos, con una matriz de atributos $X \in \mathbb{R}^{|V| \times d}$ que asigna a cada nodo un vector de características (Mu et al., 2025). A diferencia de un grafo homogéneo, en el que todos los nodos y conexiones pertenecen a un único tipo, un grafo heterogéneo incorpora funciones de mapeo $\tau : V \rightarrow T_V$ y $\phi : E \rightarrow T_E$,

que asignan a cada nodo y a cada relación un tipo dentro de los conjuntos T_V y T_E , cumpliendo $|T_V| + |T_E| > 2$ (S. Li et al., 2025). Esta definición permite representar sistemas donde diferentes clases de entidades y relaciones coexisten en una misma estructura, lo cual es fundamental para modelar escenarios complejos que presentan múltiples formas de interacción entre componentes (Ratna et al., 2025). En contextos dinámicos, esta formulación puede extenderse a una secuencia de grafos $G = \{G_1, G_2, \dots, G_T\}$, donde cada $G_t = (V_t, E_t)$ mantiene sus funciones de asignación de tipos τ y ϕ , proporcionando una descripción estructurada de la evolución temporal de nodos y relaciones en dominios como el análisis del comportamiento basado en eventos (Liu et al., 2021).

La representación de datos mediante grafos enfrenta varios desafíos que derivan directamente de las propiedades de los sistemas reales, donde la información suele ser incompleta, irregular y cambiante. En muchos casos, los grafos presentan nodos o relaciones ausentes, lo cual impide disponer de una imagen completa de la estructura y limita la capacidad para caracterizar adecuadamente el sistema que se desea modelar (Ratna et al., 2025). A ello se suma la presencia de distribuciones desbalanceadas, en las que ciertos grupos de nodos o patrones de conexión aparecen con mayor frecuencia que otros, afectando la calidad de los modelos que dependen de estas estructuras (Ratna et al., 2025). Además, la evolución continua de entidades y relaciones introduce inestabilidad temporal, ya que los cambios en atributos, conexiones o incluso la aparición de nuevos elementos modifican la organización del grafo de manera impredecible (Ratna et al., 2025). En conjunto, estos aspectos convierten la representación y el aprendizaje sobre grafos en una tarea compleja que exige modelos capaces de operar bajo condiciones de variabilidad, ausencia de información y cambios estructurales permanentes.

3.1.2.1 Formalización tipada y meta-relaciones

En escenarios donde la traza de ejecución de un programa es modelada como grafo heterogéneo, una formulación más detallada del formalismo es adoptada, en línea con trabajos previos sobre detección de variantes de *malware* (Liu, Li, Liu et al., 2024; Liu et al., 2021, 2025). Bajo esta formulación, un grafo heterogéneo es definido como

$$G = (V, E, \mathcal{A}, \mathcal{R}, \tau_v, \tau_e), \quad (3.2)$$

donde V denota el conjunto de nodos, $E \subseteq V \times V$ el conjunto de aristas dirigidas, $\mathcal{A}$ el conjunto de tipos de entidad y $\mathcal{R}$ el conjunto de tipos de relación. Las funciones $\tau_v : V \rightarrow \mathcal{A}$ y $\tau_e : E \rightarrow \mathcal{R}$ son introducidas para asignar a cada nodo y a cada arista su tipo correspondiente. Para que la condición de heterogeneidad sea satisfecha, debe cumplirse $|\mathcal{A}| + |\mathcal{R}| > 2$ (Sun & Han, 2012).

Cada arista $e = (u, v) \in E$ es caracterizada por una *meta-relación* expresada mediante el triple

$$(\tau_v(u), \tau_e(e), \tau_v(v)) \in \mathcal{A} \times \mathcal{R} \times \mathcal{A}, \quad (3.3)$$

el cual identifica de manera única la combinación tipo de origen-tipo de relación-tipo de destino sobre la que opera la arista. Sobre esta base, el *esquema de red* (Sun & Han, 2012), denotado $T_G = (\mathcal{A}, \mathcal{R})$, es construido como el grafo cuyos nodos son los tipos de entidad y cuyas aristas son los tipos de relación; de este modo, T_G resume el espacio de meta-relaciones admisibles en G y es empleado como referencia estructural para los mecanismos de aprendizaje que operan sobre él.

3.1.3 Aprendizaje de Grafos

El aprendizaje en grafos se ha consolidado como un campo orientado a modelar datos cuya estructura está definida por relaciones entre entidades, permitiendo capturar patrones que no pueden representarse mediante espacios euclidianos convencionales. Su objetivo principal es construir representaciones vectoriales de baja dimensión que preserven la organización del grafo y la información contenida en los atributos de nodos y conexiones, proporcionando descripciones útiles para tareas posteriores (M. Li et al., 2026). Para ello, los modelos operan directamente sobre la estructura relacional de los datos, transformando objetos e interacciones en nodos y enlaces que pueden ser procesados mediante mecanismos de agregación y actualización que integran información local y global (Corso et al., 2024; Ratna et al., 2025). Este enfoque evita la dependencia de características diseñadas manualmente y permite extraer información relevante con mayor eficiencia, lo que ha impulsado su adopción en aplicaciones que requieren análisis estructurado, como clasificación, predicción de relaciones y agrupamiento (Mu et al., 2025). Así, El aprendizaje en Grafos se presenta como un marco fundamental para comprender y explotar la complejidad de sistemas basados en interacciones.

El funcionamiento del Aprendizaje en Grafos se basa en la idea de que el conocimiento relevante de un sistema no reside únicamente en los atributos de cada entidad, sino también en la forma en que estas entidades se relacionan entre sí (Corso et al., 2024; M. Li et al., 2026; Nandan et al., 2025). Por ello, los modelos de Aprendizaje en Grafos operan directamente sobre la estructura del grafo, integrando tanto la información de los nodos como el patrón de sus conexiones que los vinculan para producir representaciones de baja dimensión capaces de preservar tanto las dependencias locales como el rol estructural de cada entidad dentro de la configuración global (M. Li et al., 2026). A través de este principio, el Aprendizaje en Grafos captura con mayor precisión el contexto y los patrones complejos que gobiernan la dinámica interna del grafo mediante mecanismos de agregación

iterativa, como los implementados en las arquitecturas basadas en propagación de mensajes entre vecinos propias de los GNNs (Corso et al., 2024; M. Li et al., 2026; Nandan et al., 2025; Ratna et al., 2025). El resultado es una representación compacta y enriquecida capaz de modelar la complejidad encapsulada en las estructuras relacionales del mundo real.

Las representaciones generadas por Aprendizaje en Grafos permiten abordar tareas en diferentes niveles de granularidad, ya que encapsulan información suficiente para razonar sobre nodos, relaciones o grafos completos. En el nivel de nodos, estas representaciones facilitan actividades como clasificación, regresión o agrupamiento, donde el interés se centra en caracterizar el comportamiento o las propiedades particulares de cada entidad (Nandan et al., 2025). En el nivel de relaciones, los modelos pueden predecir la presencia, ausencia o tipo de vínculo entre dos nodos, lo que resulta esencial en aplicaciones como recomendación, detección de interacciones o recuperación de conexiones faltantes (Nandan et al., 2025). Finalmente, a nivel de grafo, las representaciones permiten comparar, clasificar o detectar patrones globales en estructuras completas, lo que habilita tareas como clasificación de moléculas, identificación de anomalías o análisis de configuraciones complejas (Mu et al., 2025; Nandan et al., 2025). Esta capacidad para operar a múltiples niveles demuestra la versatilidad del enfoque y explica su creciente adopción en dominios donde las relaciones son tan importantes como las entidades mismas (Mu et al., 2025).

El Aprendizaje en Grafos enfrenta desafíos estructurales y algorítmicos que limitan su capacidad para extraer representaciones verdaderamente expresivas. Estas limitaciones se agravan cuando los datos disponibles no reflejan adecuadamente la diversidad del dominio, lo que afecta la generalización de los modelos en escenarios reales y en tareas que requieren distinguir patrones complejos a nivel de nodos, aristas o grafos completos (Corso et al., 2024). Además, persisten retos en la integración simultánea de la estructura global del grafo y la información local asociada a sus entidades, dado que muchos métodos aún tienen dificultades para combinar coherentemente ambos tipos de contexto para producir representaciones más completas y robustas (Mu et al., 2025). En conjunto, estas restricciones subrayan la necesidad de capturar patrones relacionales más profundos y diversos en grafos complejos.

El Aprendizaje en Grafos enfrenta desafíos estructurales que condicionan su capacidad para construir representaciones fieles y eficaces. Entre ellos destacan la escasez, la incompletitud y la inestabilidad dinámica, características frecuentes en grafos del mundo real que dificultan modelar adecuadamente las relaciones y los patrones de dependencia de largo alcance (M. Li et al., 2026). Estas limitaciones se intensifican cuando los datos no cubren la diversidad estructural del dominio, afectando la capacidad de generalización en tareas definidas a nivel de nodos, aristas o grafos completos (Corso et al., 2024). A ello se suma la dificultad persistente de integrar simultáneamente

la estructura global del grafo con la información local de sus entidades, ya que muchos métodos aún tienen dificultades para combinar con coherencia ambos niveles de contexto para producir representaciones más completas y robustas (Mu et al., 2025). En conjunto, estos desafíos manifiestan la necesidad de desarrollar mecanismos capaces de capturar patrones relacionales más complejos y de representar estructuras complejas con mayor riqueza y estabilidad.

3.1.3.1 Heterogeneous Graph Transformer (HGT)

Cuando el aprendizaje sobre grafos es trasladado al caso heterogéneo, las arquitecturas estándar de paso de mensajes son insuficientes, ya que los espacios de representación y los patrones de interacción dependen del tipo de cada nodo y de cada relación. El *Heterogeneous Graph Transformer* (HGT) (Hu et al., 2020) es introducido como una arquitectura de paso de mensajes sobre grafos heterogéneos en la que la atención y el mensaje son parametrizados por meta-relación. Cada arista $e = (s, t)$ es descompuesta en su triple $(\tau_v(s), \tau_e(e), \tau_v(t))$, lo que permite que espacios de representación específicos sean mantenidos por tipo de nodo y por tipo de relación, en correspondencia con la formalización presentada en la subsección anterior.

Sea $H^{(l)} \in \mathbb{R}^{|V| \times d}$ la matriz de representaciones de nodo en la capa l , donde $H^{(l)}[t]$ denota la representación del nodo t . Una capa HGT computa $H^{(l)}$ a partir de $H^{(l-1)}$ mediante tres operadores: atención mutua heterogénea, paso de mensaje heterogéneo y agregación específica del objetivo (Hu et al., 2020).

Atención mutua heterogénea. Para cada arista $e = (s, t)$ y cada cabeza $i \in \{1, \dots, h\}$, el nodo objetivo t es proyectado a una consulta $Q_i(t)$ y el nodo fuente s es proyectado a una clave $K_i(s)$ mediante proyecciones lineales tipadas:

$$Q_i(t) = \text{Q-Linear}_{\tau_v(t)}^i(H^{(l-1)}[t]), \quad K_i(s) = \text{K-Linear}_{\tau_v(s)}^i(H^{(l-1)}[s]). \quad (3.4)$$

La similitud entre clave y consulta es computada por medio de una matriz por tipo de relación $W_{\tau_e(e)}^{\text{ATT}} \in \mathbb{R}^{d/h \times d/h}$ y es escalada por un tensor previo $\mu \in \mathbb{R}^{|\mathcal{A}| \times |\mathcal{R}| \times |\mathcal{A}|}$ que codifica la importancia general de cada meta-relación:

$$\text{ATT-head}_i(s, e, t) = K_i(s) W_{\tau_e(e)}^{\text{ATT}} Q_i(t)^\top \cdot \frac{\mu_{\langle \tau_v(s), \tau_e(e), \tau_v(t) \rangle}}{\sqrt{d/h}}. \quad (3.5)$$

Las cabezas son concatenadas y normalizadas mediante una operación *softmax* aplicada sobre la vecindad $\mathcal{N}(t)$ del nodo objetivo:

$$\text{Attention}_{\text{HGT}}(s, e, t) = \text{Softmax}_{\forall s \in \mathcal{N}(t)} \left(\left\|_{i \in [1, h]} \text{ATT-head}_i(s, e, t) \right\| \right). \quad (3.6)$$

Paso de mensaje heterogéneo. En paralelo, el nodo fuente es proyectado a un mensaje multi-cabeza en el que es incorporada una matriz por tipo de relación $W_{\tau_e(e)}^{\text{MSG}} \in \mathbb{R}^{d/h \times d/h}$:

$$\text{MSG-head}_i(s, e, t) = \text{M-Linear}_{\tau_v(s)}^i(H^{(l-1)}[s]) W_{\tau_e(e)}^{\text{MSG}}, \quad (3.7)$$

$$\text{Message}_{\text{HGT}}(s, e, t) = \left\|_{i \in [1, h]} \text{MSG-head}_i(s, e, t) \right\|. \quad (3.8)$$

Agregación específica del objetivo. Los mensajes provenientes de la vecindad son agregados sobre el nodo objetivo, ponderados por las atenciones previamente computadas:

$$\tilde{H}^{(l)}[t] = \bigoplus_{\forall s \in \mathcal{N}(t)} \text{Attention}_{\text{HGT}}(s, e, t) \cdot \text{Message}_{\text{HGT}}(s, e, t). \quad (3.9)$$

Una proyección lineal tipada $\text{A-Linear}_{\tau_v(t)}$ y una conexión residual son aplicadas para producir la representación final del nodo en la capa l :

$$H^{(l)}[t] = \text{A-Linear}_{\tau_v(t)}(\sigma(\tilde{H}^{(l)}[t])) + H^{(l-1)}[t]. \quad (3.10)$$

Mediante el apilamiento de L capas, las representaciones contextualizadas $H^{(L)}$ son obtenidas, las cuales pueden ser empleadas en tareas posteriores como clasificación de nodos o predicción de enlaces (Hu et al., 2020). De esta manera, HGT es presentado como un mecanismo capaz de articular la heterogeneidad estructural y semántica del grafo dentro de un esquema unificado de atención y propagación, lo cual lo posiciona como un encoder adecuado para tareas de aprendizaje sobre grafos heterogéneos del comportamiento de programas.

3.1.4 Arquitecturas Predictivas de Embeddings Conjuntos

El aprendizaje auto-supervisado constituye un paradigma orientado a aprender representaciones útiles a partir de datos no anotados, formulando tareas de pretexto en las que la señal de supervisión es derivada de la propia estructura de la entrada. Dentro de este paradigma, las *Arquitecturas Predictivas de Embeddings Conjuntos* (JEPA, por sus siglas en inglés) son introducidas como una alternativa a los enfoques generativos clásicos, en la que la predicción es desplazada del dominio de entrada al espacio de representaciones (Assran et al., 2023; LeCun, 2022). Cuando el dominio de aplicación es el grafo, esta formulación es extendida en *Graph-JEPA* (Skenderi et al., 2024), donde la unidad básica de contexto y objetivo es el subgrafo en lugar del píxel o del parche. La presente subsección expone primero la formulación general de JEPA y, posteriormente, su instanciación en el dominio grafo, así como las limitaciones operacionales que dicha instanciación presenta cuando es confrontada con grafos heterogéneos.

3.1.4.1 Joint-Embedding Predictive Architectures (JEPA)

JEPA (LeCun, 2022) formula el aprendizaje auto-supervisado de representaciones como una tarea de predicción definida en un espacio de representación abstracto, en contraste con los paradigmas generativos que operan directamente sobre el dominio de entrada. Dada una entrada que es particionada en una región de contexto x y una región objetivo y , la representación de y es predicha a partir de la representación de x , sin que y sea reconstruido en el dominio de entrada. De este modo, los detalles irrelevantes para la tarea son descartados y la señal de aprendizaje es concentrada en estructuras semánticas estables (Assran et al., 2023; LeCun, 2022).

Una arquitectura JEPA está constituida por tres componentes parametrizados (Assran et al., 2023): un *encoder* de contexto f_θ , un *encoder* objetivo $f_{\bar{\theta}}$ y un predictor g_ϕ . Las entradas son mapeadas a representaciones latentes mediante los *encoders*:

$$z_{\text{ctx}} = f_\theta(x), \quad z_{\text{tgt}} = f_{\bar{\theta}}(y). \quad (3.11)$$

A partir de la representación del contexto, la representación del objetivo es estimada por el predictor, condicionado en una variable de localización m que indica qué objetivo debe ser predicho:

$$\hat{z}_{\text{tgt}} = g_\phi(z_{\text{ctx}}, m). \quad (3.12)$$

La pérdida es definida como la distancia ℓ_2 entre la predicción y la representación del objetivo

en el espacio latente. Cuando M objetivos $\{y^{(i)}\}_{i=1}^M$ son asociados a un mismo contexto x , la pérdida es expresada como

$$\mathcal{L}_{\text{JEPA}} = \frac{1}{M} \sum_{i=1}^M \left\| g_{\phi}(z_{\text{ctx}}, m^{(i)}) - \text{sg}(z_{\text{tgt}}^{(i)}) \right\|_2^2, \quad (3.13)$$

donde $\text{sg}(\cdot)$ denota el operador *stop-gradient*, mediante el cual la propagación de gradientes a través del *encoder* objetivo es bloqueada.

Los parámetros de la arquitectura son actualizados de manera asimétrica. Los parámetros del *encoder* de contexto θ y los del predictor ϕ son optimizados mediante descenso por gradiente sobre $\mathcal{L}_{\text{JEPA}}$, mientras que los parámetros del *encoder* objetivo $\bar{\theta}$ son actualizados por medio de un promedio móvil exponencial de los parámetros del *encoder* de contexto:

$$\bar{\theta} \leftarrow \alpha \bar{\theta} + (1 - \alpha) \theta, \quad \alpha \in [0, 1). \quad (3.14)$$

Esta asimetría, junto con el operador *stop-gradient*, es introducida con el fin de evitar el colapso de las representaciones, fenómeno en el que la pérdida es trivialmente minimizada al asignar a todas las entradas un mismo vector (Assran et al., 2023).

3.1.4.2 Graph-JEPA

Graph-JEPA (Skenderi et al., 2024) corresponde a la instanciación del paradigma JEPA al dominio de los grafos. Bajo este planteamiento, la unidad básica de contexto y objetivo es el subgrafo, no el nodo individual, lo cual permite que el aprendizaje sea articulado a una escala intermedia entre lo local y lo global. El procedimiento es organizado en cuatro pasos: partición espacial, codificación de subgrafo, codificación de contexto y objetivo, y predicción del objetivo en el espacio latente.

Partición espacial. Dado un grafo $G = (V, E)$ con $|V| = N$, una partición de V en p subconjuntos disjuntos es producida:

$$\{V_1, \dots, V_p\}, \quad V_i \cap V_j = \emptyset \text{ para } i \neq j, \quad |V_i| = N/p, \quad \bigcup_{i=1}^p V_i = V. \quad (3.15)$$

Por medio de la partición, son inducidas en la representación aprendida nociones de localidad y consciencia espacial a través de la tarea auto-predictiva en el espacio latente (Skenderi et al., 2024). Sin embargo, una partición estrictamente disjunta puede dar lugar a subgrafos sin aristas, lo cual bloquea la propagación de la señal entre regiones contiguas. Para que esta limitación sea mitigada, cada partición es expandida con los vecinos a 1-salto de sus nodos en el grafo original, con lo cual son obtenidos subgrafos $G'_i = (V'_i, E'_i)$ que presentan un solapamiento controlado en sus conjuntos de nodos y aristas. Mediante esta expansión, información de regiones contiguas es agregada durante la codificación.

Codificación de subgrafo. Una red neuronal de grafos (GNN) es empleada para aprender representaciones a nivel de nodo dentro de cada subgrafo G'_i . Las representaciones de nodo son agregadas mediante *mean pooling* para producir una representación vectorial por subgrafo:

$$h_i = \text{MeanPool}(\text{GNN}(G'_i)) \in \mathbb{R}^d. \quad (3.16)$$

El conjunto $\{h_1, \dots, h_p\}$ realiza la transformación del dominio de entrada al espacio de representaciones y constituye las variables de contexto u objetivo en el marco JEPA (Skenderi et al., 2024). La GNN específica que es utilizada se considera arbitraria y depende de las propiedades estructurales que se desee inducir en la representación. Dado que las representaciones $\{h_i\}$ por sí solas no determinan unívocamente la tarea auto-predictiva, ellas son acompañadas de codificaciones posicionales $\{m^{(1)}, \dots, m^{(p)}\}$ que identifican la localización de cada subgrafo en G , en correspondencia con el token m introducido en la subsección 3.1.4.1.

Codificación de contexto y objetivo. En cada paso de entrenamiento, un subgrafo de contexto G_{ctx} y M subgrafos objetivo $\{G_{\text{tgt}}^{(i)}\}_{i=1}^M$ son seleccionados aleatoriamente de la partición (Skenderi et al., 2024). Las representaciones de subgrafo correspondientes son procesadas por los codificadores f_θ y $f_{\bar{\theta}}$ de la subsección 3.1.4.1 para producir las representaciones latentes:

$$z_{\text{ctx}} = f_\theta(h_{\text{ctx}}) \in \mathbb{R}^d, \quad z_{\text{tgt}}^{(i)} = f_{\bar{\theta}}(h_{\text{tgt}}^{(i)}) \in \mathbb{R}^d. \quad (3.17)$$

Esta formulación se mantiene consistente con la estructura típica de los JEPA (Assran et al., 2023).

Predicción del objetivo en el espacio latente. El predictor g_ϕ , la pérdida $\mathcal{L}_{\text{JEPA}}$ definida en la ecuación (3.13) y la regla de actualización por EMA del *encoder* objetivo descrita en la ecuación (3.14) son conservadas sin modificación respecto de la formulación general.

Limitación operacional. La formulación de Graph-JEPA es planteada bajo el supuesto de un único tipo de nodo y un único tipo de arista. En consecuencia, la GNN, la partición espacial y la codificación posicional del subgrafo no incorporan la estructura tipada $(\mathcal{A}, \mathcal{R})$ propia de los grafos heterogéneos. Esta limitación es relevante para el presente trabajo, dado que el comportamiento de *malware* es modelado mediante grafos heterogéneos, y motiva la necesidad de extender el paradigma JEPA hacia mecanismos capaces de explotar la heterogeneidad de tipos de entidad y de relación.

3.1.5 Modelos Basados en Energía

Los Modelos Basados en Energía (EBM) constituyen un enfoque general para capturar dependencias entre variables asignando a cada configuración un valor escalar de energía que expresa su grado de compatibilidad estructural y semántica, de modo que la inferencia se formula como la búsqueda de configuraciones de mínima energía (LeCun et al., 2006; Marc'Aurelio et al., 2007). En este marco, la energía funciona como medida de compatibilidad entre una configuración (X, Y) , donde valores pequeños indican alta coherencia entre observación y estado latente, mientras que valores altos expresan incompatibilidad (LeCun et al., 2006; Marc'Aurelio et al., 2007). El aprendizaje se orienta a modelar superficies energéticas que asignen baja energía a regiones próximas a los datos y alta energía a configuraciones no observadas, recurriendo a pérdidas contrastivas para evitar el colapso de la energía y garantizar que el modelo preserve diferenciación estructural en el espacio de posibilidades (LeCun et al., 2006; Marc'Aurelio et al., 2007). Así, los EBM proporcionan un marco unificado para la predicción y la toma de decisiones, en el cual la organización del conocimiento emerge de la morfología misma de la superficie energética, cuya estructura topológica codifica las dependencias que sustentan el fenómeno analizado (LeCun et al., 2006; Marc'Aurelio et al., 2007).

Un Modelo Basado en Energía (EBM) se define como una función escalar

$$E_\theta : X \times Y \rightarrow \mathbb{R} \quad (3.18)$$

que asigna a cada configuración (x, y) un valor energético que representa su grado de compatibilidad, de modo que las configuraciones más coherentes presentan menor energía (LeCun et al., 2006). Dado un conjunto de variables observadas $x \in X$ y un conjunto de configuraciones latentes

$y \in Y$, la inferencia consiste en resolver

$$y^* = \arg_{y \in Y} \min E_\theta(x, y) \quad (3.19)$$

obteniendo el estado que minimiza la energía y, por tanto, maximiza la compatibilidad entre variables (LeCun et al., 2006). A diferencia de los modelos probabilísticos, los EBM no requieren normalización y evitan la estimación del término de partición, lo que otorga mayor flexibilidad arquitectónica y permite concebir los modelos probabilísticos como casos particulares donde la energía cumple condiciones adicionales de normalizabilidad (LeCun et al., 2006).

El proceso de entrenamiento de un Modelo Basado en Energía consiste en identificar, dentro de una familia paramétrica de funciones $E_\theta = \{E_\theta(x, y) : \theta \in \Theta\}$, aquella instancia cuya morfología energética produzca las configuraciones y más coherentes para cada entrada x observada (LeCun et al., 2006). La arquitectura del modelo —esto es, la estructura interna de la función de energía— impone la forma y capacidad expresiva de E_θ , permitiendo que dicha función abarque desde combinaciones lineales de bases hasta redes neuronales profundas capaces de operar sobre imágenes, secuencias o estructuras complejas (LeCun et al., 2006). El aprendizaje se realiza a partir de un conjunto de entrenamiento $S = \{(x_i, y_i)\}_{i=1}^P$, sobre el cual se evalúa un función de pérdida $L(E_\theta, S)$ que estima la calidad de la superficie energética considerando tanto los datos observados como el conocimiento previo incorporado mediante un término de regularización $R(\theta)$ (LeCun et al., 2006). En su forma general, este función se define como

$$L(E_\theta, S) = \frac{1}{P} \sum_{i=1}^P L(y_i, E_\theta(x_i, \cdot)) + R(\theta) \quad (3.20)$$

lo cual implica evaluar, para cada muestra, un “corte” de la superficie energética al mantener fijo x_i y explorar cómo varía la energía al modificar y (LeCun et al., 2006). El objetivo del entrenamiento es resolver

$$\theta^* = \arg_{\theta \in \Theta} \min L(E_\theta, S) \quad (3.21)$$

de manera que la función de energía aprendida presente valles profundos alrededor de las configuraciones coherentes y elevaciones pronunciadas en regiones incompatibles. Bajo condiciones estándar de capacidad y estabilidad estadística, este procedimiento garantiza que la superficie

energética resultante no solo represente adecuadamente los datos de entrenamiento, sino que conserve su coherencia estructural frente a muestras nuevas, consolidando así un paisaje energético capaz de generalizar de manera robusta (LeCun et al., 2006).

Los Modelos Basados en Energía (EBM) ofrecen un marco unificado para múltiples tareas cognitivas debido a su capacidad para evaluar la compatibilidad entre configuraciones mediante la función de energía. Bajo este principio, pueden emplearse para predicción, clasificación y toma de decisiones, donde el objetivo es identificar el estado Y que resulte más compatible con una observación X (LeCun et al., 2006). Su estructura también permite abordar tareas de ranking, al comparar la energía relativa entre múltiples configuraciones y ordenar las respuestas según su coherencia funcional (LeCun et al., 2006). Asimismo, los EBM resultan adecuados para detección, ya que la energía actúa como criterio continuo que distingue configuraciones plausibles de aquellas incompatibles mediante umbrales adaptativos (LeCun et al., 2006). Finalmente, cuando se requiere estimar distribuciones condicionales complejas —por ejemplo, en restauración de imágenes, síntesis gráfica o generación de lenguaje— los EBM pueden modelar superficies energéticas que capturan la variabilidad estructural de Y condicionada en X , lo cual los habilita para escenarios de modelamiento generativo y estimación de densidad condicional incluso en espacios de alta dimensionalidad (LeCun et al., 2006). De este modo, la versatilidad expresiva de la función de energía convierte a los EBM en una herramienta transversal para tareas discriminativas, generativas y de decisión dentro de dominios complejos.

3.1.5.1 Modelos basados en energía y muestreo

Cuando un EBM es empleado para representar la densidad de una variable x , la función escalar $E_\theta(x) \in \mathbb{R}$ es instanciada como una red neuronal con parámetros θ (Du & Mordatch, 2019). La densidad asociada es expresada en la forma de Boltzmann:

$$p_\theta(x) = \frac{\exp(-E_\theta(x))}{Z(\theta)}, \quad Z(\theta) = \int \exp(-E_\theta(x)) dx, \quad (3.22)$$

donde la función de partición $Z(\theta)$ es definida como la integral del factor exponencial sobre el espacio de entrada. Bajo esta formulación, la energía $E_\theta(x)$ ya no representa únicamente una medida abstracta de compatibilidad, sino que es articulada con una densidad de probabilidad explícita (Du & Mordatch, 2019).

Para que muestras del modelo sean generadas, la dinámica de Langevin es empleada como mecanismo iterativo de descenso por gradiente ruidoso sobre la energía (Du & Mordatch, 2019):

$$\tilde{x}_k = \tilde{x}_{k-1} - \nabla_x E_\theta(\tilde{x}_{k-1}) + \omega_k, \quad \omega_k \sim \mathcal{N}(0, \lambda). \quad (3.23)$$

En cada paso, una corrección determinista en la dirección $-\nabla_x E_\theta$ es combinada con una perturbación gaussiana ω_k , de modo que regiones de baja energía sean exploradas sin que la cadena quede atrapada en un único mínimo. Esta dinámica establece el puente operacional entre la formulación variacional del EBM y la generación de muestras representativas de p_θ .

3.1.5.2 Entrenamiento por máxima verosimilitud

El procedimiento de entrenamiento por máxima verosimilitud propuesto por Du y Mordatch (Du & Mordatch, 2019) es adoptado a continuación. Sea p_D la distribución empírica del conjunto de entrenamiento. Los parámetros θ son ajustados de modo que la distribución del modelo p_θ , definida en la ecuación (3.22), reproduzca p_D . Para que este objetivo sea alcanzado, la log-verosimilitud negativa es minimizada:

$$\mathcal{L}_{\text{ML}}(\theta) = \mathbb{E}_{x \sim p_D}[-\log p_\theta(x)] = \mathbb{E}_{x \sim p_D}[E_\theta(x)] + \log Z(\theta). \quad (3.24)$$

El gradiente de esta pérdida es derivado y expresado en su forma contrastiva:

$$\nabla_\theta \mathcal{L}_{\text{ML}} = \mathbb{E}_{x^+ \sim p_D}[\nabla_\theta E_\theta(x^+)] - \mathbb{E}_{x^- \sim p_\theta}[\nabla_\theta E_\theta(x^-)], \quad (3.25)$$

cuyas dos esperanzas separan los roles de p_D y p_θ . Mediante el término positivo, calculado sobre p_D , la energía es disminuida en muestras del conjunto de datos; mediante el término negativo, calculado sobre p_θ , la energía es elevada en muestras generadas por el modelo. Ambas esperanzas son hechas coincidir y el gradiente es anulado precisamente cuando $p_\theta = p_D$ (Du & Mordatch, 2019).

El cómputo exacto de la ecuación (3.25) exige que muestras sean obtenidas de p_θ , lo cual no resulta tratable: la densidad $p_\theta(x) = \exp(-E_\theta(x))/Z(\theta)$ depende de la función de partición $Z(\theta)$, una integral sobre el espacio de entrada que no admite evaluación exacta. Esta dificultad es sorteada por la dinámica de Langevin de la ecuación (3.23), dado que su paso de actualización solo requiere $\nabla_x E_\theta$, gradiente en el cual $Z(\theta)$ es cancelado. Tras K pasos, las muestras $\tilde{x}_K$ generadas mediante la ecuación (3.23) siguen una distribución q_θ , a la cual se accede únicamente por simulación: aunque

su densidad no es conocida en forma cerrada, tantas muestras como sean necesarias pueden ser producidas ejecutando la cadena. Esto basta para que la segunda esperanza de la ecuación (3.25) sea estimada por Monte Carlo, con p_θ reemplazada por q_θ (Du & Mordatch, 2019):

$$\nabla_\theta \mathcal{L}_{\text{ML}} \approx \mathbb{E}_{x^+ \sim p_D} [\nabla_\theta E_\theta(x^+)] - \mathbb{E}_{x^- \sim q_\theta} [\nabla_\theta E_\theta(x^-)]. \quad (3.26)$$

El sustituto es legítimo en la medida en que $q_\theta \approx p_\theta$. Welling y Teh (Welling & Teh, 2011) garantizan $q_\theta \rightarrow p_\theta$ en el límite $K \rightarrow \infty, \lambda \rightarrow 0$; cuando K es finito, la brecha $q_\theta - p_\theta$ es trasladada a la ecuación (3.26) como sesgo del estimador.

3.2 ESTADO DEL ARTE

En el estudio de la detección dinámica de variantes de malware, (Liu et al., 2021) aborda el desafío de caracterizar comportamientos maliciosos en tiempo real. Los autores proponen un marco basado en Aprendizaje Dinámico Heterogéneo de Grafos para modelar flujos de ejecución y extraer patrones evolutivos discriminativos entre malware y sus variantes. MG-DVD incorpora meta-grafos que representan de forma interpretable las interacciones entre malware y sus variantes, haciendo visible la sintaxis operativa del comportamiento. Sin embargo, aunque modela con precisión qué acciones ocurren, cuándo y entre qué entidades, su enfoque orientado a la detección carece de un mecanismo explícito para describir cómo evoluciona la estrategia comportamental del malware y no interpreta la semántica funcional de las fases maliciosas.

Los métodos actuales de análisis de malware basados en deep learning permanecen fuertemente ligados a esquemas supervisados que extraen huellas digitales maliciosas conocidas y carecen de mecanismos para capturar la intención dinámica del atacante. Frente a estas limitaciones, (Liu, Li, Liu et al., 2024) proponen MalIRL para analizar forensemente la secuencia de eventos de ejecución del malware con el propósito de inferir su intencionalidad maliciosa. Su metodología emplea ventanas deslizantes para estructurar los eventos observables en grafos heterogéneos con nodos que representan entidades del sistema (procesos, memoria, red, archivos) y aristas que describen relaciones operativas (crear, leer, conectar, modificar), a partir de los cuales construyen representaciones incrementales de estados y acciones que alimentan un esquema de Aprendizaje por Refuerzo Inverso (IRL) para cuantificar la maliciosidad del comportamiento, permitiendo que el Proceso de Decisión de Markov (MDP) explore autónomamente las intenciones intrínsecas del ataque. Aunque MalIRL articula la sintaxis mediante grafos incrementales y aproxima la semántica al cuantificar la maliciosidad con IRL, su combinación IRL+MDP induce una intención dominante y permanece restringida a políticas derivadas de recompensas óptimas. En contraste, un modelo basado en energía permite una organización autoestructurada de la morfología subyacente, haciendo emerger paisajes energéticos directamente del patrón de eventos observables para revelar las coherencias evolutivas, las transiciones estratégicas y las formas estables que configuran la identidad del comportamiento malicioso.

Los métodos de detección de malware basados en Redes Neuronales de Grafos (GNN) dinámicas suelen depender de ventanas de tamaño fijo para procesar flujos de comportamiento, lo que limita su capacidad para capturar cambios repentinos o patrones de ataque evolutivos al ignorar variaciones sutiles en las fases de comportamiento del malware. Para superar estas limitaciones, (Liu et al., 2025) introduce una función energética que segmenta adaptativamente los eventos de com-

portamiento del malware para construir grafos heterogéneos , integrando propagación intra-grafo e inter-grafo para preservar dependencias espaciales críticas de las fases de ataque del malware sin incurrir en cálculos repetitivos. Su aporte central es la identificación de vecindarios dinámicos coherentes en el tiempo. No obstante, su enfoque se restringe a delimitar fronteras locales mediante un clasificador energético, sin modelar la morfología global que articula la continuidad semántica del ataque. Aunque este mecanismo respalda parcialmente la hipótesis de que la energía captura coherencias comportamentales, la presente investigación busca trascender esa segmentación local y formular un paisaje energético autoorganizado que revele la identidad evolutiva y las trayectorias comportamentales subyacentes del malware.

La amenaza del malware constituye uno de los frentes más desafiantes debido a su rápida evolución, la explotación sistemática de vulnerabilidades y las graves implicaciones de una brecha exitosa, lo que exige enfoques igualmente dinámicos en ciberseguridad. En este contexto, (Su & Wang, 2024) introducen un método poco común en sistemas de detección convencionales, orientado a comprender cómo los patrones estructurales y conductuales de los archivos binarios revelan intencionalidad maliciosa. Su metodología emplea GNNs para aprender a la estructura y comportamiento subyacente en archivos binarios y trazas de ejecución, junto con un esquema auto-supervisado contrastivo que genera representaciones robustas sin requerir grandes volúmenes de datos etiquetados cruciales para identificar amenazas cibernéticas sofisticadas. Este enfoque es especialmente relevante en el campo de la ciberseguridad donde la rápida aparición de nuevas variantes de malware supera la capacidad de recopilación y etiquetado de datos de entrenamiento, a la vez que mejora la generalización del modelo a amenazas inéditas.

Uno de los enfoques más prometedores en la detección dinámica de malware es la representación del comportamiento de un ejecutable mediante grafos capaces de capturar relaciones operativas complejas. Sin embargo, muchas aproximaciones previas omiten información crítica —como parámetros, argumentos y cambios de estado— que resulta esencial para modelar la semántica del comportamiento malicioso. En respuesta a estas limitaciones, (Tu et al., 2020) proponen representar la ejecución de archivos como Multi-edge Directional Heterogeneous Graphs (MDHG) con el propósito de integrar múltiples tipos de información derivados de las llamadas API de Windows recolectadas en Cuckoo Sandbox. Su método construye grafos heterogéneos que codifican categorías de API, tipos de conexión y argumentos clave, los cuales alimentan un modelo de atención sobre grafos dotado de una capa de ponderación de aristas diseñada para resaltar la importancia contextual de cada operación. Este enfoque mejora sustancialmente la detección al aprender representaciones ricas del comportamiento a nivel de nodo, arista y grafo, demostrando que la incorporación explícita de atributos semánticos en grafos heterogéneos es crucial para identificar patrones complejos de actividad maliciosa.

Los enfoques basados en aprendizaje automático han emergido como alternativas robustas para la detección de malware, aunque muchos de ellos aún requieren conocer previamente características del código malicioso, lo cual resulta impráctico en escenarios industriales donde los datos defectuosos son escasos o inexistentes y la naturaleza de las anomalías no se conoce a priori. En respuesta a esta limitación, (Ge, 2021) propuso el uso de modelos basados en energía como herramienta capaz de detectar anomalías sin necesidad de supervisión explícita. Su método emplea estimaciones de densidad como puntajes de normalidad para distinguir código benigno de malware y utiliza los gradientes del puntaje de energía para generar mapas de calor que localizan regiones anómalas dentro del código, constituyendo la primera aproximación que interpreta dichos gradientes como información espacial relevante. Este enfoque consolidó un sistema más interpretable para los analistas de seguridad, capaz tanto de detectar malware de naturaleza arbitraria como de ofrecer explicaciones visuales sobre la localización de comportamientos maliciosos. No obstante, pese a demostrar el potencial de los EBM en tareas de detección, su aplicación se limita a análisis estático y no explora cómo modelar la dinámica comportamental ni la semántica funcional del malware mediante representaciones energéticas autoorganizadas.

En el estudio de la detección de malware en escenarios de escasez de datos, un desafío central es capturar la semántica de ejecución y la robustez frente a mutaciones que alteran la superficie sintáctica del comportamiento. En respuesta, (Liu, Li, Zhao et al., 2024) proponen A2-CLM, un marco auto-supervisado que busca comprender cómo la semántica de los comportamientos de ejecución y las perturbaciones adversariales pueden fortalecer la detección de muestras de malware inéditas mediante aprendizaje contrastivo. Su metodología construye grafos heterogéneos para modelar entidades y relaciones comportamentales, y genera instancias contrastivas mediante el diseño de múltiples ataques adversariales —incluyendo Descenso de Gradiente Proyectado (PGD), enmascaramiento de atributos, muestreo guiado por meta-grafos, llamadas directas al sistema y ofuscación— con el fin de aprender representaciones invariantes y robustas. Los hallazgos evidencian mejoras significativas bajo variaciones estructurales y semánticas inducidas por mutaciones reales de malware. Este enfoque auto-supervisado y contrastivo de A2-CLM demuestra la capacidad de extraer patrones semánticos sin necesidad de anotaciones extensivas, propiedades que serán aprovechadas para la captura de representaciones comportamentales latentes que serán modeladas energéticamente en la presente investigación.

4. OBJETIVOS

4.1 OBJETIVO GENERAL

Modelar el paisaje energético como una estructura morfológica emergente y autoorganizada desde la cual sea posible representar y comprender las trayectorias dinámicas que expresan los patrones comportamentales del malware.

4.2 OBJETIVOS ESPECÍFICOS

- Estructurar la secuencia de eventos comportamentales del malware mediante una red de información heterogénea en tiempo discreto.
- Desarrollar un codificador capaz de generar representaciones en espacio latente asociadas a la coherencia sintáctica y semántica de los eventos comportamentales del malware estructurados en la red heterogénea de información dinámica.
- Emerger la morfología estructural evolutiva del paisaje energético mediante un modelo basado en energía condicional, capaz de generar trayectorias dinámicas discretas que representen la evolución temporal del comportamiento del malware.
- Evaluar la coherencia y la estabilidad de las trayectorias dinámicas del paisaje energético emergente como representación de los patrones comportamentales evolutivos que distinguen la identidad de distintas familias de malware.

5. HIPÓTESIS

El punto de partida de esta investigación es el reconocimiento de que el comportamiento del malware, independientemente de su familia o variante, se desarrolla dentro de un entorno al que explota sistemáticamente sus vulnerabilidades y recursos disponibles para desplegar un conjunto representativo de estrategias subyacentes orientadas al cumplimiento de su propósito malicioso. Dichas estrategias se expresan como secuencias de eventos que, aunque varían en su superficie sintáctica, conservan una coherencia estructural y semántica profunda. Esta coherencia constituye la firma comportamental intrínseca del malware y puede ser modelada mediante estructuras energéticas autoorganizadas capaces de capturar la dinámica que articula su intención maliciosa.

Desde esta premisa, el problema de investigación —cómo hacer emerger un paisaje energético autoorganizado capaz de modelar la morfología estructural de los patrones comportamentales del malware— se deriva directamente de la necesidad de representar la dinámica maliciosa no como un problema de simple reconocimiento de patrones, sino como una morfología energética donde cada configuración de mínima energía expresa un estado estable del comportamiento malicioso y sus transiciones manifiestan las fases adaptativas de su estrategia.

En este contexto, una red de información heterogénea permite describir las interacciones observables del malware con su entorno, estructurando el flujo de eventos que constituye su comportamiento. A partir de esta red, un codificador transforma las relaciones estructurales en representaciones en espacio latente, dentro del cual emergen patrones que preservan la coherencia sintáctica y temporal de los eventos comportamentales. Este espacio constituye la codificación semántica del sistema, que actúa como conocimiento previo sobre el cual un modelo basado en energía condicional puede operar, generando un paisaje energético autoorganizado. En dicho paisaje, las cuencas de mínima energía revelan los patrones comportamentales subyacentes de cada familia de malware, mientras que los atractores topológicos que emergen de la dinámica energética representan configuraciones estables de significado y forma.

Así, el proceso completo habilita el descubrimiento de estructuras emergentes que encapsulan la identidad comportamental del malware en términos de coherencia morfológica y semántica. Este enfoque trasciende la clasificación convencional para situar el reconocimiento del malware en el plano de la interpretabilidad energética, donde la forma y el significado convergen en la dinámica misma del modelo.

En consecuencia, las hipótesis de investigación se derivan de esta estructura argumental: de la correspondencia esperada entre la coherencia semántico-energética emergente y la capacidad del modelo energético autoorganizado para representar, diferenciar e interpretar los patrones comportamentales del malware dentro de su paisaje morfogenético. Dichas hipótesis constituirán la formalización empírica y verificable de las expectativas epistemológicas implícitas en los objetivos específicos de la investigación.

5.1 HIPÓTESIS GENERAL

Si el comportamiento del malware puede representarse en una red de información heterogénea y esta es codificada en un espacio latente que preserve la coherencia sintáctica y semántica de los eventos comportamentales, entonces un modelo basado en energía condicional podrá autoorganizar un paisaje energético cuya morfología emerja de manera coherente con las dinámicas que caracterizan la identidad comportamental de cada familia de malware.

5.2 HIPÓTESIS ESPECÍFICAS

- La estructuración de la secuencia de eventos comportamentales del malware en una red de información heterogénea permitirá describir la sintaxis y semántica evolutiva de la secuencia de eventos maliciosos como base para la emergencia estructural energética del sistema. (Derivada del Objetivo Específico 1)
- Un codificador entrenado sobre dicha red heterogénea de información podrá generar representaciones en espacio latente que preserven la coherencia sintáctica y semántica de los eventos de malware, configurando un conocimiento previo representacional útil para la modelación energética. (Derivada del Objetivo Específico 2)
- La aplicación de un modelo basado en energía condicional sobre el espacio latente inducirá la emergencia de una morfología estructural del paisaje energético, donde los mínimos de energía correspondan a estados coherentes de las dinámicas representativas del comportamiento del malware. (Derivada del Objetivo Específico 3)
- El análisis de la dinámica del paisaje energético permitirá interpretar la morfología emergente como manifestación semántica de los patrones comportamentales del malware. (Derivada del Objetivo Específico 4)
- La estabilidad estructural del paisaje energético autoorganizado reflejará la consistencia de la emergencia estructural energética de la representación comportamental del malware, validando el modelo energético como una forma de abstracción comportamental coherente capaz de diferenciar, interpretar y generalizar las dinámicas entre distintas familias de malware. (Derivada del Objetivo Específico 4)

6. MARCO METODOLÓGICO

6.1 LA NATURALEZA COMPORTAMENTAL DEL MALWARE

En la formulación del problema se establece que el comportamiento del malware surge como un conjunto de estrategias subyacentes orientadas a la consecución de fines maliciosos específicos —escalada de privilegios, persistencia, evasión, exfiltración de datos, comando y control (C2), propagación, entre otros—, buscando aprovechar las vulnerabilidades para poder explotar los recursos del entorno comprometido para lograr cumplir su propósito.

Cada evento observable —la creación de procesos, la modificación de archivos, las conexiones de red o las alteraciones del registro del sistema— constituye una manifestación local de una dinámica global compleja. Por tanto, el estudio del malware requiere una aproximación que no reduzca su comportamiento al reconocimiento de relaciones de causa-efecto aisladas, sino que reconozca la emergencia de estructuras complejas que capturen las coherencias sintácticas y semánticas que definen su identidad comportamental en el tiempo.

El malware ha sido diseñado conforme a las presiones del entorno que va comprometer en el cual las defensas, vulnerabilidades y recursos disponibles actúan como fuerzas selectivas que guían sus próximas variantes o mutaciones comportamentales de nuevas versiones de malware. Cada acción ejecutada —ya sea una llamada al sistema, una modificación de registro o una conexión de red— forma parte de una secuencia dirigida hacia la preservación de su viabilidad operacional como resultado este propósito intrínseco guía su comportamiento para adaptar sus estrategias según la presión defensiva del entorno comprometido.

6.1.1 La gramática comportamental del Malware: sintaxis y semántica maliciosa

Cada acción del malware posee un significado operacional dentro de lo que se podría describir como la gramática comportamental del malware. Esta gramática no se limita a la estructura secuencia de eventos observables (sintaxis), sino que incorpora el propósito intencional y la interpretación funcional de dichas acciones en el contexto de la estrategia global del malware (semántica). Así la dimensión semiótica del comportamiento malicioso permite conceptualizarlo como un lenguaje operativo, en el que cada evento observable actúa como una táctica dentro de una narrativa funcional más amplia. Los eventos no son aislados, sino componentes dentro de una estructura sintáctica estratégica que orchestra el propósito global del malware.

6.1.2 Invarianza semántica y morfología energética: hacia un modelo autoorganizado del comportamiento

A pesar de las transformaciones en su código fuente —que alteran la superficie sintáctica del comportamiento—, las familias de malware conservan invarianzas semánticas que articulan la continuidad de su identidad comportamental. Estas invarianzas permiten preservar la coherencia de la estrategia maliciosa a lo largo de distintas versiones y contextos. Analizar el comportamiento del malware únicamente desde su dimensión sintáctica —la secuencia observable de eventos— implica perder la comprensión de su propósito malicioso. Así, la identidad comportamental del malware no se define solo por la estructura sintáctica de sus acciones, independientemente de cómo se manifiesten (ya sea a través de procesos, archivos modificados, redes comprometidas, etc.), sino por la persistencia de las invarianzas semánticas que reflejan su identidad, más allá de sus mutaciones superficiales.

Capturar estas invariancias semánticas exige un modelo capaz de describir la morfología energética de la información, entendida como la topología emergente que articula la relación entre sintaxis y semántica. En este contexto, los Modelos Basados en Energía (EBM) proporcionan un marco idóneo para permitir la autoorganización del conocimiento representacional, haciendo emerger los patrones latentes que revelan la firma comportamental de cada familia de malware sin requerir supervisión explícita. La energía actúa como la medida mediante la cual el sistema organiza y estabiliza la relación entre forma y significado dentro de su propio paisaje representacional.

6.2 DISEÑO GENERAL DE LA METODOLOGÍA DE INVESTIGACIÓN

6.2.1 De la Información al Conocimiento: Un Enfoque Multinivel para el Estudio Comportamental del Malware

El modelo propuesto describe un sistema que se organiza de manera autónoma para comprender el comportamiento del malware a través de una representación dinámica y autoorganizada del conocimiento. Este enfoque concibe al sistema como una entidad que aprende a estructurar la información observada —proveniente de la ejecución maliciosa— dentro de un paisaje energético, permitiendo que los patrones comportamentales emerjan espontáneamente como formas estables en este contexto emergente.

El paisaje energético funciona aquí como una metáfora operativa y formalización matemática del espacio de posibles comportamientos del malware, donde las configuraciones de mínima energía representan estados coherentes de acción maliciosa. Así, el modelo no solo busca detectar patrones, sino revelar la morfología de las estrategias que definen la identidad de cada familia de malware.

Este diseño metodológico se estructura en correspondencia directa con los objetivos e hipótesis de la investigación y traduce las dimensiones conceptuales establecidas —sintaxis, semántica y energía— en tres niveles interdependientes que articulan la transformación de la información en conocimiento:

1. Nivel estructural–informacional (sintáctico): Captura la organización explícita de los eventos comportamentales del malware en una red heterogénea de información(OE1, H1).
2. Nivel representacional–semántico: Construye un espacio latente que genere representaciones acerca de las relaciones de significado y coherencia entre los eventos comportamentales (OE2, H2).
3. Nivel energético: Modela la dinámica autoorganizada del sistema mediante un modelo basado en energía, en el cual los estados estables corresponden a configuraciones coherentes de comportamiento malicioso (OE3, H3).

Estos tres niveles operan como componentes de un ciclo continuo de adquisición, representación, transformación y organización del conocimiento. La información observable se transforma en representaciones semánticas, las cuales, a su vez, se reconfiguran en un paisaje energético que impulsa la generación de conocimiento interpretativo. Este proceso permite al sistema revelar

estructuras morfológicas con patrones semánticos que definen la dinámica del comportamiento malicioso, constituyendo así un marco interpretativo capaz de transformar el evento observable en conocimiento interpretativo.

6.3 FLUJO METODOLÓGICO: DE LOS EVENTOS OBSERVABLES A LA EMERGENCIA DEL CONOCIMIENTO

El flujo metodológico puede describirse como un ciclo de transformación de la información en conocimiento, en el cual los eventos observables, las representaciones latentes y las dinámicas energéticas se integran de manera progresiva para generar conocimiento sobre el comportamiento del malware.

Cada fase del flujo transforma el tipo de información representada: de observación a estructura, de estructura a significado y de significado a conocimiento energético interpretativo.

6.3.1 Estructuración del dominio informacional

La primera fase del modelo corresponde a la organización sintáctica de la información observada.

Se procesan trazas de ejecución almacenadas en formato XML, generadas a partir de entornos de análisis dinámico (sandboxing) diseñados para registrar el comportamiento del malware en ejecución. Cada traza contiene un flujo temporal de eventos a nivel de entidad del sistema —por ejemplo, creación de procesos, modificación de archivos, conexiones de red o alteración de registros del sistema—, los cuales se estructuran como relaciones entre entidades, tales como “*proceso A escribe archivo B*”.

Estos eventos se formalizan en grafos heterogéneos $G = (V, E)$ para expresarlo de la forma 3.1, donde:

- V representa el conjunto de entidades del sistema (procesos, archivos, conexiones, registros, etc.),
- E representa las interacciones o relaciones entre entidades,

De este modo, cada evento se convierte en una unidad elemental dentro de una estructura sintáctica relacional, y los grafos heterogéneos resultantes constituyen el espacio sintáctico de observación desde el cual se iniciará la construcción de las representaciones semánticas.

6.3.1.1 Construcción del grafo heterogéneo del comportamiento del malware

A partir de las trazas de ejecución almacenadas en formato XML, capturadas mediante análisis

dinámico en *sandbox*, una estructuración heterogénea es adoptada en línea con trabajos previos sobre detección de variantes de *malware* (Liu, Li, Liu et al., 2024; Liu et al., 2021, 2025). Bajo esta estructuración, cada evento de ejecución es modelado como una tripleta de la forma (*entidad origen*, *entidad destino*, *relación*) que instancia una arista del grafo heterogéneo G formalizado en la ecuación (3.2). Por ejemplo, el evento descrito como “el proceso `server.exe` escribe el valor `XP_FW_Disable` en la clave `MICROSOFT, DXDIAG, WINSETTINGS`” es representado como la tripleta (*Process_server.exe*, *Registry_WINSETTINGS*, *writes*), donde el tipo del nodo origen, el tipo del nodo destino y el tipo de la relación son fijados por las funciones τ_v y τ_e del esquema tipado.

El conjunto de tipos de entidad observados durante la ejecución es definido como

$$\mathcal{A} = \{\text{Process, File, Network, Registry, Memory, Mutex, Attribute, System}\}, \quad (6.1)$$

en el que la entidad *Process* es asumida como nodo central, dado que es la entidad a través de la cual el resto de los recursos del sistema operativo son accedidos y modificados durante la ejecución. El conjunto de tipos de relación $\mathcal{R}$ es derivado del repertorio de eventos registrados por el *sandbox*, de modo que cada arista observada es etiquetada con un tipo de relación admisible bajo el esquema de red $T_G = (\mathcal{A}, \mathcal{R})$ introducido en la subsección 3.1.2.1.

La Tabla 6.1 especifica el esquema de red T_G mediante la enumeración de las relaciones observadas, junto con los tipos de entidad admisibles como sujeto y objeto de cada una. De este modo, el espacio de meta-relaciones $(\tau_v(u), \tau_e(e), \tau_v(v))$ que pueden ser instanciadas durante la construcción del grafo es delimitado de manera explícita.

Mediante este esquema, las trazas XML son transformadas en grafos heterogéneos G tipados, en los que el rol de cada entidad y de cada interacción es preservado de manera explícita, evitando que la heterogeneidad estructural del comportamiento sea diluida en una representación homogénea. La centralidad de *Process* dentro del esquema permite, además, que la trayectoria operacional del *malware* sea organizada en torno a las acciones desencadenadas por sus procesos sobre los demás recursos del sistema, lo cual es coherente con la noción de gramática comportamental introducida al inicio del capítulo.

Desde una perspectiva epistemológica, esta fase constituye el nivel sintáctico del conocimiento, donde la información es estructurada, pero aún no interpretada: es la gramática estructural de la conducta maliciosa en su forma más elemental.

Cuadro 6.1: *Esquema de red T_G : relaciones admisibles entre tipos de entidad en el grafo heterogéneo del comportamiento del malware.*

Relación	Tipos de entidad admisibles
connects	Process $\rightarrow$ Network
creates	Process $\rightarrow$ {Mutex, System}
deletes	Process $\rightarrow$ {File, Registry}
fork	Process $\rightarrow$ Process
listens	Process $\rightarrow$ Network
modifies	Process $\rightarrow$ {File, Process, Registry, System}
queries	Process $\rightarrow$ {Network, Process, System}
reads	Process $\rightarrow$ {File, Memory, Network}
sends	Process $\rightarrow$ Network
terminates	Process $\rightarrow$ Process
triggers	{Process, System} $\rightarrow$ Attribute
writes	Process $\rightarrow$ {File, Memory, Registry}

6.3.2 Codificación Representacional: Del Espacio Sintáctico a la Coherencia Semántica

Una vez estructurado el dominio informacional en forma de redes heterogéneas $G[k]$, la siguiente fase del flujo metodológico consiste en transformar dichas estructuras en representaciones latentes que preserven sus principales propiedades semánticas. Esta fase marca la transición desde la dimensión sintáctica del modelo hacia la dimensión representacional–semántica, en la cual el conocimiento comienza a adquirir una forma latente, capaz de expresar la coherencia entre las acciones del malware más allá de su estructura superficial.

6.3.2.1 Codificador representacional y aprendizaje auto-supervisado

La codificación se implementa mediante un Graph Transformer, una red neuronal diseñada para aprender representaciones vectoriales de grafos heterogéneos en los que coexisten diferentes tipos de nodos, relaciones y atributos. Su propósito es construir un espacio latente en el que las relaciones semánticas implícitas en la red heterogénea de información se conserven de forma estructuralmente coherente.

El proceso de entrenamiento se desarrolla bajo un esquema auto-supervisado que le permite al modelo aprender las reglas estructurales y la coherencia semántica entre eventos comportamentales que gobiernan la red heterogénea de información. Para ello, se definen tareas pretextuales (pretext tasks) que permiten al modelo predecir elementos ausentes de la red.

Estas tareas fuerzan al modelo a internalizar los patrones sintácticos y semánticos que definen

la coherencia estructural del comportamiento.

Como resultado se pretende que el sistema aprenda la gramática estructural del malware, es decir, las combinaciones y dependencias válidas entre las entidades que componen sus acciones.

6.3.2.2 Partición de subgrafos heterogéneos mediante Att-LPA

La instanciación de Graph-JEPA al dominio heterogéneo exige que el procedimiento de partición espacial introducido en la subsección 3.1.4.2 sea revisado, dado que la formulación original es planteada bajo el supuesto de un único tipo de nodo y un único tipo de arista. Para que esta limitación operacional sea superada, la partición del conjunto de nodos V es instanciada mediante *Att-LPA*, un mecanismo de propagación de etiquetas ponderado por la atención de un HGT. *Att-LPA* es construido a partir de la formulación introducida en SHGP (Yang et al., 2022), donde la atención de un *encoder* heterogéneo es utilizada para guiar la propagación de etiquetas comunitarias y producir una asignación dura de cada nodo a una comunidad.

A diferencia de SHGP, en el cual las etiquetas comunitarias son empleadas como objetivo de pseudo-supervisión y la atención es optimizada explícitamente para el agrupamiento, en el presente trabajo las comunidades son utilizadas con un rol puramente estructural: la partición que sustenta la tarea predictiva auto-supervisada es definida por ellas. En consecuencia, la atención es optimizada por su utilidad en la predicción en el espacio latente y no para el agrupamiento. En ambos casos el paso de partición es mantenido fuera del flujo de gradientes; la diferencia reside en la fuente del gradiente que actualiza la atención: pseudo-supervisión por entropía cruzada en SHGP, predicción en espacio latente en el método propuesto.

Extracción de pesos por tipo de arista. La atención mutua heterogénea del HGT, descrita en la subsección 3.1.3.1, opera por meta-relación. A cada arista $e = (s, t)$ y cada cabeza $i \in \{1, \dots, H\}$ de la capa l es asignado un coeficiente $\alpha_i^{(l)}(e)$ que pondera la contribución del nodo fuente s a la representación del nodo objetivo t . Los coeficientes son agregados a nivel de tipo de relación, dado que el corpus consiste en grafos independientes sin correspondencia entre nodos; bajo esta condición, los coeficientes definidos sobre pares de nodos no son transferibles entre grafos, mientras que los pesos definidos sobre $\mathcal{R}$ sí lo son al estar asociados a un conjunto común a todo el corpus.

Para que un peso escalar por tipo de relación $r \in \mathcal{R}$ y capa $l \in \{1, \dots, L\}$ sea obtenido, los coeficientes son agregados en dos pasos: primero, un promedio es calculado sobre las H cabezas de la capa; posteriormente, un segundo promedio es computado sobre el conjunto S_r de aristas de

tipo r :

$$w_r^{(l)} = \frac{1}{H} \sum_{i=1}^H \frac{1}{|S_r|} \sum_{e \in S_r} \alpha_i^{(l)}(e). \quad (6.2)$$

Mediante el primer promedio, la diversidad de cabezas es colapsada en un único coeficiente de atención por arista; mediante el segundo, el peso que la capa l del HGT asigna al tipo de relación r es extraído. La extracción produce L vectores de pesos $\{w^{(1)}, \dots, w^{(L)}\}$, uno por capa, donde $w^{(l)} \in \mathbb{R}^{|\mathcal{R}|}$ recoge la importancia que la capa l del HGT asigna a cada tipo de relación.

Regla de propagación ponderada y layer-synchronized L -pass. Att-LPA es inicializado mediante la asignación a cada nodo $v \in V$ de una etiqueta única $L^{(0)}(v) = v$, lo cual produce un estado inicial con tantas etiquetas como nodos. La regla de propagación actualiza la etiqueta de cada nodo como una función de las etiquetas de sus vecinos, ponderadas por la importancia del tipo de relación que los conecta (Yang et al., 2022):

$$L^{(l)}(v) = \arg \max_y \sum_{u \in \mathcal{N}(v)} w_{\tau_e(v,u)}^{(l)} \cdot \mathbb{1}[L^{(l-1)}(u) = y]. \quad (6.3)$$

Bajo esta regla, los votos de los vecinos $u \in \mathcal{N}(v)$ son acumulados por cada etiqueta candidata y , donde cada voto es ponderado por el peso $w_{\tau_e(v,u)}^{(l)}$ del tipo de la arista (v, u) en la capa l y es contabilizado únicamente cuando el vecino u posee la etiqueta y . La operación $\arg \max$ selecciona la etiqueta que maximiza el voto ponderado acumulado, con lo cual una asignación dura es producida. Por ejemplo, un nodo de tipo *Process* conectado a un nodo de tipo *File* mediante una arista *writes* y a otro nodo de tipo *File* mediante una arista *reads* adopta la etiqueta del primer *File* cuando $w_{\text{writes}}^{(l)} > w_{\text{reads}}^{(l)}$.

Siguiendo el mismo diseño introducido en SHGP (Yang et al., 2022), Att-LPA ejecuta L pasos de propagación, uno por cada capa del HGT, donde el paso l utiliza el vector de pesos $w^{(l)}$ extraído de la capa l . Mediante este encadenamiento, la profundidad de la propagación es alineada con la profundidad del *encoder*: tras L pasos, información del vecindario a L saltos es incorporada por cada nodo, lo cual coincide con el campo receptivo del HGT de L capas.

Dos propiedades del diseño son derivadas de esta construcción. En primer lugar, el número de pasos de propagación es determinado por la profundidad del HGT y no constituye un hiperparámetro

independiente. En segundo lugar, cada paso es operado con los pesos específicos de su capa correspondiente, con lo cual la diferenciación de importancia que el HGT aprende a través de la profundidad es preservada: dado que las capas iniciales y las capas profundas pueden asignar pesos distintos al mismo tipo de relación, dicha diferenciación es propagada en lugar de ser colapsada en un único vector global.

Salida. Los nodos que comparten la misma etiqueta final $L^{(L)}(v)$ conforman una comunidad. La partición resultante es denotada como $\{C_1, \dots, C_p\}$. El número de comunidades p no es asumido como hiperparámetro: es emergido de la dinámica de propagación y depende tanto de la topología del grafo como de los pesos $w^{(l)}$ extraídos del HGT.

6.3.2.3 Codificación de subgrafos con HGT compartido

Expansión de comunidades a 1-salto. Cada comunidad C_k de la partición resultante de la subsección 6.3.2.2 es expandida con sus vecinos a 1-salto en G , en línea con la subsección 3.1.4.2. La expansión produce subgrafos $C'_k = (V'_k, E'_k)$ que se solapan en sus conjuntos de nodos, lo cual evita que la propagación entre comunidades disjuntas sea bloqueada durante la codificación.

Codificación con HGT compartido. Un único HGT, descrito en la subsección 3.1.3.1 y compartido entre las ramas de contexto y objetivo, es empleado para codificar cada subgrafo expandido C'_k . La codificación produce una representación $H^{(L)}[v] \in \mathbb{R}^d$ para cada nodo $v \in V'_k$. El gradiente de la pérdida es propagado al HGT únicamente a través de la rama de contexto.

Pooling y producción de embeddings de subgrafo. Las representaciones de nodo del subgrafo expandido C'_k son agregadas mediante *mean pooling* para que un *embedding* por subgrafo sea producido:

$$h_k = \frac{1}{|V'_k|} \sum_{v \in V'_k} H^{(L)}[v] \in \mathbb{R}^d. \quad (6.4)$$

El *embedding* h_k resume la información estructural y tipada que el HGT capturó sobre los nodos

de la comunidad expandida, condensándola en una representación de tamaño fijo.

Codificación posicional. A cada subgrafo C'_k es asociada una codificación posicional $m^{(k)} \in \mathbb{R}^d$ que el predictor utiliza para distinguir qué objetivo debe ser predicho. La codificación es construida a partir de dos vectores normalizados que describen la composición interna del subgrafo. La distribución de tipos de nodo es definida como

$$\text{PE}_{\text{nodo}}(C'_k)_i = \frac{1}{|V'_k|} \sum_{v \in V'_k} \mathbb{1}[\tau_v(v) = \tau_i], \quad i = 1, \dots, |\mathcal{A}|, \quad (6.5)$$

y la distribución de tipos de relación como

$$\text{PE}_{\text{arista}}(C'_k)_j = \frac{1}{|E'_k|} \sum_{e \in E'_k} \mathbb{1}[\tau_e(e) = r_j], \quad j = 1, \dots, |\mathcal{R}|. \quad (6.6)$$

Ambos vectores son concatenados y proyectados a la dimensión del *encoder* mediante una matriz aprendible $W_{\text{proj}} \in \mathbb{R}^{d \times (|\mathcal{A}| + |\mathcal{R}|)}$:

$$m^{(k)} = W_{\text{proj}} [\text{PE}_{\text{nodo}}(C'_k) \oplus \text{PE}_{\text{arista}}(C'_k)] \in \mathbb{R}^d. \quad (6.7)$$

Mediante esta codificación, la composición del subgrafo objetivo es capturada sin que su estructura relacional sea expuesta, evitando así que el predictor reconstruya el objetivo únicamente a partir de $m^{(k)}$.

Salida. La codificación produce el conjunto $\{h_1, \dots, h_p\}$ de *embeddings* de subgrafo y el conjunto $\{m^{(1)}, \dots, m^{(p)}\}$ de codificaciones posicionales asociadas. Estos pares constituyen la representación a nivel de subgrafo sobre la cual son operados los *encoders* de contexto y objetivo descritos a continuación.

6.3.2.4 Encoders de contexto y objetivo, predictor y pretexto predictivo

Selección de contexto y objetivos. En cada paso de entrenamiento, uno de los *embeddings* de subgrafo $\{h_1, \dots, h_p\}$ entregados por la subsección 6.3.2.3 es seleccionado aleatoriamente como *embedding* de contexto h_{ctx} , y K *embeddings* adicionales son muestreados del resto como *embeddings* objetivo $\{h_{\text{tgt}}^{(1)}, \dots, h_{\text{tgt}}^{(K)}\}$ (Assran et al., 2023). K es definido como hiperparámetro del método; su sensibilidad empírica es reportada en el capítulo de resultados.

Encoders de contexto y objetivo. El *encoder* de contexto f_θ es instanciado como un Transformer (Vaswani et al., 2017) sin *self-attention* que procesa el *embedding* único h_{ctx} y produce la representación latente de contexto:

$$z_{\text{ctx}} = f_\theta(h_{\text{ctx}}) \in \mathbb{R}^d. \quad (6.8)$$

El *encoder* de objetivo $f_{\bar{\theta}}$ es instanciado como un Transformer con *self-attention* estándar (Vaswani et al., 2017) que procesa los K *embeddings* objetivo de manera conjunta, lo cual permite que cada representación sea contextualizada por las demás:

$$\{z_{\text{tgt}}^{(1)}, \dots, z_{\text{tgt}}^{(K)}\} = f_{\bar{\theta}}(\{h_{\text{tgt}}^{(1)}, \dots, h_{\text{tgt}}^{(K)}\}) \subset \mathbb{R}^d. \quad (6.9)$$

Predictor y pretexto predictivo. El predictor g_ϕ es definido como un MLP de dos capas con activación GELU. La representación de cada subgrafo objetivo es estimada a partir de la representación de contexto z_{ctx} y de la codificación posicional $m^{(k)}$ del objetivo correspondiente, incorporada mediante una modulación aditiva:

$$\hat{z}_{\text{tgt}}^{(k)} = g_\phi(z_{\text{ctx}} + m^{(k)}) \in \mathbb{R}^d, \quad k = 1, \dots, K. \quad (6.10)$$

La pérdida es definida como la distancia *Smooth LI* entre la predicción y la representación objetivo en el espacio latente, promediada sobre los K objetivos:

$$\mathcal{L}_{\text{JEPA}} = \frac{1}{K} \sum_{k=1}^K \ell_{\text{smooth-LI}}(\hat{z}_{\text{tgt}}^{(k)}, \text{sg}(z_{\text{tgt}}^{(k)})), \quad (6.11)$$

donde la pérdida $\ell_{\text{smooth-L1}}$ es aplicada elemento a elemento y es definida como

$$\ell_{\text{smooth-L1}}(y, \hat{y}) = \frac{1}{d} \sum_{i=1}^d \begin{cases} \frac{1}{2\beta}(y_i - \hat{y}_i)^2, & \text{si } |y_i - \hat{y}_i| < \beta, \\ |y_i - \hat{y}_i| - \frac{1}{2}\beta, & \text{en otro caso,} \end{cases} \quad (6.12)$$

en la que $\beta > 0$ es un hiperparámetro y $\text{sg}(\cdot)$ denota el operador *stop-gradient*, mediante el cual la retropropagación a través de $z_{\text{tgt}}^{(k)}$ es bloqueada.

Cronograma de entrenamiento. El entrenamiento es organizado en dos fases. En la *fase de inicialización*, el algoritmo LPA estándar es ejecutado hasta convergencia sobre cada grafo del corpus para que las particiones iniciales sean producidas, y el HGT es entrenado durante E_0 *epochs* con estas particiones fijas. Mediante esta fase, un sustrato estable es establecido para que patrones iniciales de atención sean aprendidos por el HGT antes de que la partición evolucione.

En la *fase de iteración adaptativa*, Att-LPA reemplaza a LPA estándar como mecanismo de partición. En cada paso de entrenamiento, Att-LPA es reiniciado desde etiquetas únicas (*fresh-start*) y los L pasos de propagación descritos en la subsección 6.3.2.2 son ejecutados, lo cual produce una partición distinta en cada paso a medida que los pesos $w^{(l)}$ extraídos del HGT evolucionan. Los parámetros $\bar{\theta}$ del *encoder* de objetivo son actualizados por EMA del *encoder* de contexto, conforme a la regla introducida en la subsección 3.1.4.1.

El Algoritmo 1 sintetiza un paso de la fase de iteración adaptativa.

6.3.2.5 Protocolos de evaluación de la representación

La utilidad de la representación inducida por el preentrenamiento auto-supervisado es evaluada mediante tres protocolos complementarios. Los tres protocolos operan sobre la representación a nivel de grafo $z_G \in \mathbb{R}^d$, la cual es obtenida aplicando el *encoder* de objetivo $f_{\bar{\theta}}$ a los *embeddings* de subgrafo $\{h_1, \dots, h_p\}$ producidos por el HGT y promediando las salidas:

$$z_G = \frac{1}{p} \sum_{j=1}^p z_j, \quad \text{donde } (z_1, \dots, z_p) = f_{\bar{\theta}}(h_1, \dots, h_p). \quad (6.13)$$

Algorithm 1 Un paso de entrenamiento de Malware-JEPA (fase de iteración adaptativa).

Require: Grafo heterogéneo G ; parámetros $(\theta_{\text{HGT}}, \theta, \bar{\theta}, \phi)$; número de objetivos K ; coeficiente EMA α .

Ensure: Parámetros actualizados.

- 1: $\{w^{(l)}\}_{l=1}^L \leftarrow$ coeficientes de atención del HGT por tipo de relación y capa (subsección 6.3.2.2)
 - 2: $\{C_k\} \leftarrow \text{Att-LPA}(G, \{w^{(l)}\})$
 - 3: $\{C'_k\} \leftarrow \text{expandir-1-salto}(\{C_k\})$
 - 4: $h_k \leftarrow \text{MeanPool}(\text{HGT}(C'_k)) \quad \forall k$
 - 5: $m_k \leftarrow \text{PE}(C'_k) \quad \forall k$
 - 6: Muestrear $(h_{\text{ctx}}, m_{\text{ctx}})$ y K pares objetivo $(h_{\text{tgt}}, m_{\text{tgt}})$
 - 7: $z_{\text{ctx}} \leftarrow f_{\theta}(h_{\text{ctx}})$
 - 8: $z_{\text{tgt}} \leftarrow f_{\bar{\theta}}(h_{\text{tgt}})$
 - 9: $\hat{z}_{\text{tgt}} \leftarrow g_{\phi}(z_{\text{ctx}} + m_{\text{tgt}})$
 - 10: $\mathcal{L}_{\text{JEPA}} \leftarrow \frac{1}{K} \sum \ell_{\text{smooth-L1}}(\hat{z}_{\text{tgt}}, \text{sg}(z_{\text{tgt}}))$
 - 11: $(\theta_{\text{HGT}}, \theta, \phi) \leftarrow \nabla \mathcal{L}_{\text{JEPA}}$
 - 12: $\bar{\theta} \leftarrow \alpha \bar{\theta} + (1 - \alpha) \theta$
-

Linear probe. El protocolo de evaluación lineal (Chen et al., 2020) es aplicado como indicador de la utilidad de la representación z_G inducida por el preentrenamiento. Tras el preentrenamiento, los parámetros del HGT y de los *encoders* $(\theta_{\text{HGT}}, \bar{\theta})$ son congelados, y un clasificador lineal es entrenado sobre z_G para que la discriminación de clases de familias de *malware* sea evaluada.

Fine-tuning. El protocolo de *fine-tuning* es aplicado para que el desempeño máximo alcanzable sea estimado cuando el preentrenamiento es utilizado como punto de partida del entrenamiento supervisado. Tras el preentrenamiento, todos los parámetros del HGT y del *encoder* de objetivo $(\theta_{\text{HGT}}, \bar{\theta})$ son descongelados y entrenados conjuntamente con un clasificador MLP sobre el objetivo de clasificación de familia.

Baseline plenamente supervisado. Un HGT plenamente supervisado es adoptado como punto de comparación. Un HGT idéntico al utilizado en el método propuesto es instanciado con sus parámetros inicializados aleatoriamente, y la representación a nivel de grafo es computada por *mean pooling* global sobre los nodos:

$$z_G = \frac{1}{|V|} \sum_{v \in V} H^{(L)}[v] \in \mathbb{R}^d. \quad (6.14)$$

El HGT y un clasificador MLP son entrenados conjuntamente *end-to-end* sobre el objetivo de

clasificación de familia.

Evaluación de eficiencia de etiquetas. El desempeño de cada protocolo es cuantificado en función de la cantidad de supervisión disponible. Cada uno de los tres protocolos anteriores es evaluado sobre cinco fracciones del conjunto de datos etiquetado: {10 %, 20 %, 40 %, 70 %, 100 %}. La curva resultante caracteriza el impacto del preentrenamiento auto-supervisado sobre el desempeño en regímenes de etiquetado limitado, en comparación con el entrenamiento supervisado plenamente etiquetado.

Desde una perspectiva epistemológica, esta fase corresponde a la emergencia de la representación semántica: el conocimiento deja de estar anclado a la estructura observable y comienza a organizarse en un espacio de significado. El Graph Transformer actúa aquí como un codificador, capaz de convertir la estructura relacional G en una topología semántica, donde las formas del comportamiento malicioso se agrupan en torno a su coherencia funcional. Así, la información estructurada se transforma en representación significativa, sentando las bases para la siguiente fase del modelo: la emergencia del paisaje energético y la morfología del comportamiento.

6.3.3 Emergencia del Paisaje Energético: Dinámica Morfológica del Comportamiento del Malware

Una vez consolidado el espacio latente de coherencia semántica, la siguiente fase metodológica consiste en modelar la dinámica energética subyacente que estructura y estabiliza las representaciones comportamentales del malware. Esta fase constituye la transición desde la representación del significado en el espacio de representación latente hacia su expresión en términos de energía, donde las configuraciones coherentes del comportamiento malicioso emergen como formas estables dentro de un paisaje energético.

Sobre el espacio latente se define un modelo basado en energía condicional (Conditional Energy-Based Model, CEBM), que aprende una función de energía $E(x, y)$ encargada de asignar un valor energético a cada par de variables (x, y) , donde:

- x representa las observaciones o datos de entrada (las representaciones sintácticas y semánticas latentes aprendidas en la fase anterior),
- y representa las configuraciones comportamentales o estados latentes que el modelo busca predecir o estructurar.

En este esquema, la energía actúa como una medida de coherencia estructural y semántica entre las variables x y y . El proceso de aprendizaje de $E(x, y)$ consiste en deformar la superficie energética del sistema para:

- minimizar la energía de aquellas configuraciones que coincidan con la sintaxis y semántica observadas en la dinámica comportamental del malware, y
- maximizar la energía de aquellas configuraciones incoherentes o inconsistentes con dicha dinámica.

Como resultado, el modelo organiza el espacio latente en torno a regiones de estabilidad energética, donde los mínimos locales de energía corresponden a estados comportamentales estables.

La superficie resultante —el paisaje energético— constituye una topología que describe la forma en que las estrategias de ataque malicioso emergen y se organizan dentro de un espacio de posibilidades, siguiendo un patrón coherente, dinámico y emergente, que refleja la estrategia del malware.

El paisaje energético puede interpretarse como una métrica de coherencia estructural, donde cada valle representa una región del espacio de conocimiento en la que las estructuras sintácticas y semánticas convergen hacia un patrón estable, mientras que las pendientes y crestas expresan zonas de inestabilidad. En este sentido, la energía codifica el grado de estabilidad del significado, es decir, la persistencia de su identidad comportamental frente a perturbaciones o variaciones en el estado.

6.3.3.1 Modelo basado en energía condicional sobre el espacio latente JEPA

El procedimiento descrito en las subsecciones 3.1.5.1 y 3.1.5.2 es extendido al entrenamiento de un modelo de energía condicional sobre las representaciones abstractas producidas por el *encoder* JEPA preentrenado de mejor desempeño, con todos sus parámetros congelados. Para que esta extensión sea operacionalizada, las tres piezas del procedimiento de Du y Mordatch (Du & Mordatch, 2019) son adaptadas: una cadena de Langevin condicional con *replay buffer*, el entrenamiento por máxima verosimilitud adaptado al régimen condicional y el bucle de entrenamiento del modelo basado en energía.

Sea z una representación producida por el *encoder* JEPA congelado y sea $y \in \{1, \dots, C\}$ una etiqueta de familia de *malware*, con C el número total de familias. La formulación introducida en la subsección 6.4.1 es reescrita en términos condicionales mediante el reemplazo de $E_\theta(x)$ por

$E_\theta(z, y)$. La distribución de Boltzmann definida en la ecuación (3.22), el muestreador de Langevin de la ecuación (3.23) y la log-verosimilitud de la ecuación (3.24) heredan la condicionalización sobre y , y las distribuciones p_D , p_θ y q_θ son entendidas como distribuciones sobre z a y fijo. El parámetro θ designa exclusivamente los pesos de la red de energía. El *encoder* JEPA permanece intacto durante todo el entrenamiento.

6.3.3.2 Muestreo de negativos: Langevin condicional con *replay buffer*

Los negativos $z^- \sim q_\theta(\cdot | y)$ son generados ejecutando la cadena de Langevin de la ecuación (3.23) en su forma condicional sobre el espacio latente JEPA. Los estados intermedios de la cadena no reciben gradiente durante la retropropagación: los parámetros θ son actualizados a través de las energías evaluadas en z^+ y z^- , pero no a través de la trayectoria de Langevin que produjo z^- . Tras cada paso, el estado es proyectado a una hiperesfera centrada en el origen, calibrada al percentil empírico superior de la norma de las representaciones JEPA del conjunto de entrenamiento, con lo cual la cadena es acotada al dominio observable. La fracción de cadenas que excedieron la cota antes de la proyección es registrada como métrica de divergencia del muestreador.

Las cadenas son inicializadas mediante un *replay buffer* condicional $\mathcal{B}$, en el cual son persistidos estados de Langevin entre actualizaciones de θ . El *buffer* es inicializado con muestras de ruido gaussiano. En cada paso de entrenamiento, cada cadena del *batch* es inicializada de forma independiente, con probabilidad 0.95 desde el *buffer* condicionado a y_i^+ y con probabilidad 0.05 desde ruido gaussiano, lo que propicia la diversidad de las cadenas. La etiqueta de la cadena coincide con y_i^+ por construcción, requisito para que z_i^- aproxime una muestra de $q_\theta(\cdot | y_i^+)$ y para que el estimador de la ecuación (3.26) sea válido en el régimen condicional. Tras los pasos de Langevin, z_i^- es reincorporado al *buffer* en política FIFO.

Mediante la mezcla *buffer*-ruido, el tiempo efectivo de mezcla MCMC es reducido sin que la cobertura sea sacrificada. Información contrastiva entre épocas es acumulada por las cadenas persistentes, y la cobertura colectiva de los modos de $p_\theta(\cdot | y)$ es garantizada por la fracción de reinicios desde ruido aunque las cadenas individuales no se mezclen (Du & Mordatch, 2019).

6.3.3.3 Objetivo: entrenamiento por máxima verosimilitud con regularización

El estimador de la ecuación (3.26) es adoptado como objetivo de entrenamiento, adaptado al régimen condicional. Sobre un *batch* de positivos $\{(z_i^+, y_i)\}_{i=1}^B$ con sus negativos correspondientes $\{z_i^-\}_{i=1}^B$ producidos por la cadena descrita en la subsección 6.3.3.2, la pérdida es definida como

$$\mathcal{L}(\theta) = \frac{1}{B} \sum_{i=1}^B w_{y_i} \left[\tau (E_{\theta}(z_i^+, y_i) - E_{\theta}(z_i^-, y_i)) + \alpha (E_{\theta}(z_i^+, y_i)^2 + E_{\theta}(z_i^-, y_i)^2) \right]. \quad (6.15)$$

El primer término entre paréntesis estima el gradiente de la ecuación (3.26). Mediante el segundo término, la magnitud del paisaje energético es regularizada, evitando que la divergencia descontrolada que aparece cuando el modelo separa positivos y negativos colocando energías cada vez más extremas sea producida (Du & Mordatch, 2019). La temperatura inversa τ y el coeficiente α son hiperparámetros del método.

A continuación, dos adaptaciones al régimen condicional desbalanceado son introducidas:

(i) Ponderación por frecuencia de clase. Cada muestra es incorporada al promedio con un peso w_y inversamente proporcional a la frecuencia de la familia y en el conjunto de entrenamiento, con lo cual la simetría estructural entre familias raras y frecuentes es preservada. Sin esta corrección, fue observado un colapso del clasificador a un subconjunto reducido de familias dominantes.

(ii) Hinge cross-class. Para que la discriminación explícita entre familias en el paisaje condicional sea impuesta, un término de margen (LeCun et al., 2006) es añadido:

$$\beta \cdot \frac{1}{B} \sum_{i=1}^B \max(0, E_{\theta}(z_i^+, y_i) - E_{\theta}(z_i^+, \tilde{y}_i) + m), \quad \tilde{y}_i \sim \text{Unif}(\{1, \dots, C\} \setminus \{y_i\}), \quad (6.16)$$

mediante el cual la diferencia $E_{\theta}(z_i^+, y_i) - E_{\theta}(z_i^+, \tilde{y}_i)$ es penalizada linealmente cuando excede $-m$. A través del gradiente de este término, la energía del positivo es reducida bajo su etiqueta correcta y es incrementada bajo etiquetas incorrectas, instaurando una jerarquía con margen m entre familias en el paisaje condicional.

6.3.3.4 Bucle de entrenamiento del modelo basado en energía

Cada paso de optimización es ejecutado siguiendo la secuencia detallada en el Algoritmo 2, mediante la cual el patrón propuesto por Du y Mordatch (Du & Mordatch, 2019) es replicado.

Algorithm 2 Un paso de entrenamiento del modelo basado en energía condicional.

Require: Encoder JEPA congelado; parámetros θ de la red de energía; *replay buffer* condicional $\mathcal{B}$; hiperparámetros τ, α, β, m .

Ensure: Parámetros θ actualizados; *buffer* $\mathcal{B}$ actualizado.

- 1: Tomar un *batch* de positivos (z^+, y^+) del conjunto de entrenamiento.
 - 2: Inicializar los estados de la cadena desde $\mathcal{B}$ condicionado a y^+ , reemplazando la fracción correspondiente por ruido gaussiano.
 - 3: Ejecutar los pasos de Langevin condicional descritos en la subsección 6.3.3.2 para obtener z^- .
 - 4: Evaluar $E_\theta(z^+, y^+)$ y $E_\theta(z^-, y^+)$.
 - 5: Computar el objetivo de la ecuación (6.15) y, cuando $\beta > 0$, añadir el término *hinge* de la ecuación (6.16).
 - 6: Retropropagar a θ y aplicar un paso del optimizador.
 - 7: Reincorporar z^- al *replay buffer* $\mathcal{B}$ en política FIFO.
-

Desde una perspectiva epistemológica, el paisaje energético constituye la materialización formal del conocimiento autoorganizado: la información deja de ser un conjunto de eventos observables o representaciones, para convertirse en un campo energético donde la coherencia se manifiesta como forma capaz de traducir la complejidad dinámica del fenómeno en una topología de conocimiento interpretable. De este modo, el modelo transforma el significado en morfología, haciendo visible la estructura energética que sostiene la identidad del comportamiento malicioso.

6.3.4 Del Paisaje Energético a la Narrativa Comportamental: Hacia una Interpretación Morfológica del Malware

Una vez modelada la dinámica energética que organiza el espacio semántico del comportamiento malicioso, la fase siguiente del flujo metodológico se orienta a interpretar la topología energética como un espacio narrativo comportamental del malware. En este nivel, las trayectorias de energía se conciben como secuencias coherentes de transformación comportamental, donde cada mínimo local y cada transición energética revelan una fase o estrategia específica dentro del ciclo de vida del ataque.

La interpretación morfológica constituye, por tanto, el puente entre la dinámica energética y la gramática comportamental, permitiendo traducir la estructura del paisaje en conocimiento operativo sobre el significado de las acciones del malware.

6.3.5 Evaluación Representacional del Conocimiento Energético Autoorganizado

La fase final del flujo metodológico corresponde al proceso de validación topológica, cuyo propósito es evaluar la coherencia estructural, la estabilidad dinámica y la capacidad interpretativa

del paisaje energético emergido del modelo. En esta fase, la validez del modelo deja de depender de su precisión predictiva en términos clásicos y se mide en función de su robustez representacional, es decir, de su habilidad para sostener de manera estable y diferenciada las formas energéticas que representan las distintas familias de malware.

Desde una perspectiva epistemológica, la interpretación morfológica del paisaje energético representa la culminación del ciclo metodológico: el momento en el que la función de energía se transforma en significado narrativo. En este punto, el modelo a través de su función de energía, deja de ser únicamente un sistema de representación sino que es capaz de capturar la coherencia de diversas dinámicas comportamentales comunes de las familias de malware.

6.4 MARCO EXPERIMENTAL

En esta sección es descrito el marco experimental sobre el cual el método propuesto será evaluado. La descripción es organizada en cuatro componentes: el conjunto de datos empleado, las particiones diseñadas para los regímenes de preentrenamiento y de evaluación *downstream*, las métricas de desempeño adoptadas y los hiperparámetros que rigen cada configuración experimental. El propósito es que las decisiones experimentales sean fijadas de manera explícita, de forma que la trazabilidad y la replicabilidad de los resultados reportados en capítulos posteriores sean garantizadas.

6.4.1 Conjunto de datos

El método propuesto es evaluado sobre el conjunto ACT-KINGKONG, introducido por Liu et al. (Liu, Li, Zhao et al., 2024) como *benchmark* de análisis de *malware* sobre binarios recopilados del repositorio VIRUSSHARE entre marzo y octubre de 2019. El conjunto se encuentra disponible públicamente en <https://github.com/yidun1027/ACT-KingKong>. Cada binario fue ejecutado por los autores en el sistema KINGKONG para que reportes completos de comportamiento en tiempo de ejecución fueran generados. La caracterización original (Liu, Li, Zhao et al., 2024) atribuye al conjunto cobertura representativa de familias de *malware*, distribución *long-tail* que refleja el desbalance natural de tamaños de familia y amplia cobertura de comportamientos dinámicos.

Tras una exploración empírica, fue constatado que la versión del conjunto disponible públicamente presenta ausencia de etiquetas para una fracción considerable de muestras. Por ello, el conjunto fue procesado consultando el *hash* MD5 de cada binario en la API de VIRUSTOTAL en marzo de 2026, con el fin de que la etiqueta de clasificación de MICROSOFT DEFENDER fuera obtenida. El voto mayoritario sobre más de 60 motores antivirus empleado por los autores originales (Liu, Li, Zhao et al., 2024) fue descartado, y en su lugar fue adoptado el esquema CARO (Skulason et al., 1991), mediante el cual la nomenclatura de muestras maliciosas es estandarizada en cinco campos: tipo, plataforma, familia, variante y modificadores.

MICROSOFT es uno de los proveedores presentes en VIRUSTOTAL que cumple con esta convención (Shalaginov et al., 2020), lo cual permite que la familia sea extraída desde un campo dedicado de su esquema de clasificación estándar. Sin un esquema estandarizado, los resultados requerirían reconciliación heurística entre nomenclaturas heterogéneas (Shalaginov et al., 2020).

De las 21 466 muestras consultadas a VIRUSTOTAL, 10 707 (49.9 %) contienen errores y 917 (4.3 %) carecen de etiqueta, con lo cual 9 842 muestras con etiqueta MICROSOFT válida son retenidas.

La distribución por categoría CARO de este subconjunto está dominada por *Trojan* (4 263 muestras, 43.3 %), *Virus* (1 519, 15.4 %), *Worm* (1 139, 11.6 %) y *Backdoor* (658, 6.7 %), categorías que en conjunto agrupan el 77.0 % de las muestras válidas. Seguidas por *TrojanDownloader*, *PWS*, *VirTool* y *SoftwareBundler*, con frecuencias entre 199 y 326 que aportan un 10.8 % adicional. Las 22 categorías restantes acumulan el 12.2 % restante, lo cual es consistente con el carácter *long-tail* descrito por los autores originales. Para los experimentos la unidad de clasificación definida es a nivel de familias de *malware*.

El conjunto efectivo es construido en tres pasos. En primer lugar, son descartadas aquellas muestras cuyo grafo contiene al menos un evento marcado como formato PE inválido o no ejecutable, condición mediante la cual es indicado que el binario no fue ejecutado correctamente y que sus trazas contienen eventos no relacionados directamente con el comportamiento del *malware*. Aplicado este filtro, son retenidas 8 218 muestras distribuidas en 510 familias. En segundo lugar, es aplicado un umbral mínimo de muestras por familia, fijado como el menor entero N que satisface

$$N \cdot (1 - \nu) \cdot \lambda_{\min} \geq \tau_{\min}, \quad (6.17)$$

donde $\nu = 0.10$ es la fracción reservada por familia para el conjunto de prueba universal, $\lambda_{\min} = 0.10$ es la fracción de etiquetado más pequeña empleada en la curva de eficiencia, y $\tau_{\min} = 5$ es el número mínimo de muestras de entrenamiento por familia. El menor entero que satisface esta desigualdad es $N = 56$, dado que $56 \cdot 0.9 \cdot 0.10 = 5.04 \geq 5$, mientras que $55 \cdot 0.9 \cdot 0.10 = 4.95 < 5$.

Mediante este filtro son descartadas 473 familias y son retenidas 5 118 muestras en 37 familias. En tercer lugar, un 10 % por familia (512 muestras; mediana de 9 ejemplos por clase) es reservado como conjunto de prueba universal, el cual es mantenido fijo a través de las cinco fracciones de etiquetado y es empleado para que todas las métricas reportadas en la subsección 6.4.3 sean calculadas sobre la misma frontera de evaluación. Las 4 606 muestras restantes constituyen el *pool* de entrenamiento y validación, del cual son extraídos los subconjuntos correspondientes a cada fracción de etiquetado $\lambda \in \{10\%, 20\%, 40\%, 70\%, 100\%\}$.

6.4.2 Particiones de preentrenamiento y evaluación

El preentrenamiento del método propuesto es operado a nivel de eventos de comportamiento intra-grafo y no consume etiquetas de familia. Las 8 218 muestras con grafo válido son empleadas como conjunto de preentrenamiento. Las 512 muestras destinadas al conjunto de prueba universal participan en esta fase sin que la frontera de evaluación sea comprometida, dado que la pérdida

JEPA depende exclusivamente de la estructura interna del grafo y las etiquetas de familia jamás son expuestas al *encoder* durante el preentrenamiento.

La evaluación *downstream* es operada sobre las 5 118 muestras del conjunto efectivo definido en la subsección 6.4.1, particionadas en 4 606 muestras del conjunto de entrenamiento y 512 muestras del conjunto de prueba universal. El conjunto de prueba universal contiene una media de 9 ejemplos por familia (mínimo 6, máximo 52) y es mantenido fijo a través de las cinco fracciones de etiquetado y de las tres corridas, lo cual asegura comparabilidad directa entre puntos de la curva de eficiencia.

Para cada *seed*, los cinco subconjuntos $\lambda \in \{0.1, 0.2, 0.4, 0.7, 1.0\}$ son construidos sobre el *pool* de entrenamiento mediante muestreo estratificado anidado. La estratificación asigna a cada familia una fracción λ de sus muestras, con un piso mínimo de $\tau_{\min} = 5$ muestras por familia para que el soporte estadístico al *linear probe* sea preservado. El anidamiento garantiza que el subconjunto de cualquier fracción menor está contenido en el de cualquier fracción mayor: una muestra incluida en $\lambda = 0.1$ reaparece en $\lambda = 0.2$, $\lambda = 0.4$, $\lambda = 0.7$ y $\lambda = 1.0$. Mediante este protocolo, el efecto del tamaño del subconjunto es aislado de la variación incidental por re-muestreo, condición necesaria para que la curva de eficiencia sea leída como respuesta monotónica al volumen de etiquetado.

El protocolo completo es replicado con tres *seeds* independientes. Cada *seed* reinicializa el muestreo estratificado anidado y la inicialización de pesos del modelo *downstream*; el conjunto de preentrenamiento y el conjunto de prueba universal permanecen invariantes a través de *seeds*. La media sobre los tres *seeds* es reportada con la desviación estándar correspondiente.

La Tabla 6.2 reporta los tamaños efectivos del conjunto de entrenamiento por fracción de etiquetado. El conteo total n escala linealmente con λ por construcción, mientras que el tamaño mínimo por clase crece desde 5 en $\lambda = 0.1$ hasta 52 en $\lambda = 1.0$. El piso mínimo es saturado precisamente en $\lambda = 0.1$ con $\tau_{\min} = 5$, lo cual confirma el diseño del umbral $N = 56$ derivado en la subsección 6.4.1. La razón entre clase mayoritaria y minoritaria es preservada a través de fracciones (aproximadamente 9:1 en todos los λ), lo cual constituye un reflejo directo del muestreo estratificado.

Cuadro 6.2: *Tamaños efectivos del pool de entrenamiento por fracción de etiquetado λ . Las columnas $tr_{\min}$, tr_{med} y $tr_{\max}$ reportan el tamaño mínimo, mediano y máximo por familia sobre las 37 clases retenidas.*

λ	n	$tr_{\min}$	tr_{med}	$tr_{\max}$
0.10	460	5	8	47
0.20	921	11	17	94
0.40	1 842	21	34	188
0.70	3 224	36	59	328
1.00	4 606	52	84	469

6.4.3 Métricas de desempeño

Se reporta *Macro F1* sobre el conjunto de prueba universal como métrica primaria. F1 es una métrica adecuada cuando existe un *trade-off* entre precisión y *recall*, ya que las combina mediante su media armónica y considera simultáneamente falsos positivos y falsos negativos (Lipton et al., 2014). Por esta razón, se utiliza ampliamente en escenarios con clases desbalanceadas. La invariancia del F1 frente a cambios en el número de verdaderos negativos lo distingue de métricas como *accuracy* (Sokolova & Lapalme, 2009). Esta propiedad lo hace especialmente adecuado en escenarios desbalanceados, donde la clase negativa puede ser dominante y heterogénea, ya que evita que variaciones en los ejemplos negativos afecten significativamente la evaluación. Para una clase $c \in \{1, \dots, C\}$ con $C = 37$, el puntaje F1 se define como la media armónica de precisión y *recall*:

$$F_1^{(c)} = \frac{2 \cdot TP_c}{2 \cdot TP_c + FP_c + FN_c}, \quad (6.18)$$

donde TP_c , FP_c y FN_c denotan verdaderos positivos, falsos positivos y falsos negativos para la familia c . Bajo *Macro F1*, el puntaje se promedia sobre las 37 familias con peso uniforme,

$$\text{Macro } F_1 = \frac{1}{C} \sum_{c=1}^C F_1^{(c)}, \quad (6.19)$$

Agregación que asigna el mismo peso a cada familia independientemente de su frecuencia en el *dataset* (Sokolova & Lapalme, 2009) y se alinea con la noción operacional de generalización a través del conjunto completo de familias de *malware*.

6.4.4 Hiperparámetros

Los cuatro regímenes experimentales —*Pretraining JEPA*, *Linear Probe*, *Fine-Tuning* y *Supervised E2E*— comparten la misma arquitectura del codificador HGT con valores idénticos de L (número de capas), H (número de cabezas de atención) y d (dimensión de las representaciones).

La diferencia entre regímenes reside en dos ejes:

1. *Objetivo de entrenamiento*: pérdida JEPA *Smooth L1* en preentrenamiento, regresión logística multinomial sobre *embeddings* congelados para el protocolo de evaluación lineal, y *cross-entropy* sobre la cabeza de clasificación en ajuste fino y entrenamiento supervisado.
2. *Cabeza terminal*: proyector y predictor sobre el espacio abstracto de representaciones en JEPA; clasificador perceptrón multicapa de dos capas ($256 \rightarrow 128 \rightarrow C$) con activación ReLU y *dropout* 0.2 en los dos regímenes de *cross-entropy*.

Los resultados principales reportados en la Sección 7.1 emplean $K = 4$ como valor por defecto del número de subgrafos objetivo por contexto; la sensibilidad respecto a K se examina en la Sección 7.2. La Tabla 6.3 consigna la configuración de arquitectura y método por régimen experimental.

Cuadro 6.3: *Hiperparámetros de arquitectura y método por régimen experimental. La arquitectura del encoder HGT se comparte entre los cuatro regímenes. El símbolo “—” indica que el hiperparámetro no aplica.*

Hiperparámetro	Pretraining JEPA	Linear Probe	Fine-Tuning	Supervised E2E
<i>Arquitectura HGT</i>				
L (capas HGT)	3	3	3	3
H (cabezas de atención)	8	8	8	8
d (dimensión de <i>embedding</i>)	256	256	256	256
<i>Dropout</i> HGT	0.2	0.2	0.2	0.2
<i>Método JEPA</i>				
K (objetivos por contexto)	4	—	—	—
α (EMA <i>target encoder</i>)	0.996	—	—	—
β (<i>Smooth L1</i>)	1.0	—	—	—
E_0 (<i>warm-up</i> inicialización)	10	—	—	—
Iteraciones máx. Att-LPA	50	—	—	—
Predictor: capas Transformer	4	—	—	—
Predictor: cabezas Transformer	4	—	—	—
<i>Cabeza terminal</i>				
Tipo	proyector + predictor	regresión logística	MLP $256 \rightarrow 128 \rightarrow C$	MLP $256 \rightarrow 128 \rightarrow C$
<i>Dropout</i> cabeza	—	—	0.2	0.2
L_2 -normalización pre-cabeza	—	sí	no	no

El clasificador del *Linear Probe* se entrena por L-BFGS sobre los *embeddings* congelados, normalizados a norma unitaria L_2 antes del entrenamiento de la cabeza. Para fijar la regularización,

el procedimiento evalúa veinte valores de C espaciados logarítmicamente en el intervalo $[10^{-6}, 10^5]$ y se reporta el mejor desempeño, siguiendo el protocolo de evaluación lineal de Chen et al. (Chen et al., 2020).

El ajuste fino emplea dos refinamientos: decaimiento de tasa de aprendizaje por capa (*layer-wise learning rate decay*, LLRD) con factor 0.9 sobre las tres capas del codificador HGT, y un calentamiento de 50 épocas de la cabeza perceptrón multicapa sobre los *embeddings* congelados antes del ajuste conjunto. El LLRD protege las capas inferiores del codificador preentrenado del olvido catastrófico (Kirkpatrick et al., 2017) durante el ajuste de la cabeza, mientras que el calentamiento amortigua el impacto de los gradientes ruidosos provenientes de una cabeza inicializada aleatoriamente sobre *embeddings* ya informativos.

Los cuatro regímenes comparten el *dataloader*, un *batch size* de 32 y la métrica *Macro F1* para la selección del mejor modelo durante el entrenamiento. La Tabla 6.4 consigna la configuración de optimización por régimen.

Cuadro 6.4: *Hiperparámetros de optimización por régimen experimental. El símbolo “—” indica que el hiperparámetro no aplica.*

Hiperparámetro	Pretraining JEPA	Linear Probe	Fine-Tuning	Supervised E2E
<i>Optimizer</i>	AdamW	L-BFGS (<i>sklearn</i>)	AdamW	AdamW
<i>Learning rate</i>	1×10^{-4}	—	5×10^{-4} (enc.) / 1×10^{-4} (cabeza)	5×10^{-4}
<i>Batch size</i>	32	—	32	32
<i>Epochs</i>	100	—	50 (calent. cabeza) + 50 (ajuste conjunto)	100
<i>Scheduler</i>	ReduceLROnPlateau	—	<i>Cosine annealing</i>	<i>Cosine annealing</i>
<i>Warmup (epochs)</i>	—	—	5	—
<i>Weight decay</i>	—	—	0.05 (enc.) / 0.01 (cabeza)	—
LLRD	—	—	0.9	—
<i>Early stopping (patience)</i>	20	—	15	15
Regularización inversa C	—	10^5	—	—
Iteraciones máx. <i>probe</i>	—	25 000	—	—
<i>Class weight</i>	—	<i>balanced</i>	—	—

6.4.5 Modelos basados en energía

El objetivo experimental sobre el modelo basado en energía es la caracterización de la topología del paisaje energético aprendido por el modelo condicional descrito en la subsección 6.3.3.1, análisis que es desarrollado en el capítulo de resultados. Antes de ese análisis, la calidad del paisaje para modelar las familias de *malware* es validada mediante la evaluación de la capacidad discriminativa del modelo basado en energía bajo la regla de mínima energía sobre el conjunto de prueba.

El entrenamiento y la evaluación son realizados sobre el conjunto de datos ACT-KINGKONG, dividido en particiones de entrenamiento, validación y prueba estratificadas por familia con el fin de que la proporción de cada clase sea preservada en los tres subconjuntos. La partición es fijada una sola vez y es mantenida constante a lo largo de todos los experimentos. El conjunto cubre $C = 37$ familias de *malware*. El codificador JEPA empleado como extractor de representaciones es el de mejor desempeño reportado en la Sección 7.1, con todos sus parámetros congelados durante el entrenamiento del modelo de energía. La semilla aleatoria de todos los componentes —inicialización de la red, muestreo de Langevin, ordenamiento de *batches*— es fijada en 42.

La función de energía $E_\theta(z, y)$ es implementada como una red neuronal condicional sobre la etiqueta y , compuesta por tres bloques densos de dimensión de salida 512 con activación *Swish*, seguidos de una cabeza escalar que produce un valor real. En cada bloque y en la cabeza es incorporada normalización espectral (Miyato et al., 2018), mediante la cual la constante de Lipschitz de cada capa es acotada y el entrenamiento es estabilizado, con lo cual la divergencia del paisaje energético en regímenes prolongados de Langevin es prevenida.

La Tabla 6.5 consigna los valores de los hiperparámetros del muestreador, del *replay buffer*, del objetivo y del optimizador.

6.4.6 Análisis topológico del paisaje energético

La evaluación reportada en la subsección 6.4.5 es realizada a través de la regla de mínima energía sobre el conjunto de prueba, mediante la cual se verifica que la geometría aprendida codifica la estructura familias de *malware* del conjunto de datos. Esta verificación condensa el paisaje en una decisión por muestra y deja sin examinar la estructura del paisaje en sí mismo. La presente subsección caracteriza dicha estructura mediante *homología persistente* (Edelsbrunner et al., 2002), herramienta central del análisis topológico de datos (Chazal & Michel, 2021; Wasserman, 2018) a través de la cual los rasgos topológicos de un objeto son cuantificados a través de las escalas de filtración. El análisis es desarrollado sobre dos objetos topológicos extraídos del modelo entrenado: el conjunto de subnivel de la energía condicional, descrito en la subsección 6.4.6.2, y la nube de

Cuadro 6.5: *Hiperparámetros del entrenamiento del modelo basado en energía.*

Componente	Símbolo	Valor
Pasos de Langevin	K	60
Tamaño de paso de Langevin	λ	1.0
Desviación estándar del ruido de Langevin	σ	0.05
Cota de la hiperesfera de proyección	$\tau_{\text{máx}}$	60.0
Capacidad del <i>replay buffer</i>	$ \mathcal{B} $	2000
Probabilidad de reinicio desde ruido	—	0.05
Desviación estándar del ruido de inicialización	σ_{init}	1.1
Temperatura inversa	τ	1.0
Coefficiente de regularización L2	α	0.04
Coefficiente del término <i>hinge</i>	β	0.1
Margen del término <i>hinge</i>	m	0.5
Tamaño de <i>batch</i>	B	128
Optimizador	—	Adam ($\beta_1 = 0$, $\beta_2 = 0.999$)
Tasa de aprendizaje	—	4.2×10^{-4}
Épocas	—	50

mínimos locales muestreados por Langevin desde ruido, descrita en la subsección 6.4.6.3. Ambos productos son complementarios: el primero captura la forma de la cuenca de atracción completa, mientras que el segundo captura la concentración de masa en los valles.

6.4.6.1 Caso de estudio

El análisis topológico es restringido a la familia *emotet*, un troyano bancario detectado por primera vez en 2014 cuyo propósito original era la sustracción de credenciales financieras mediante la interceptación del tráfico de banca en línea, y que evolucionó hacia un *malware dropper* modular distribuido vía correo electrónico con adjuntos maliciosos, mediante el cual los sistemas son comprometidos para que troyanos bancarios secundarios como TRICKBOT, ICEDID y ZEUS PANDA sean descargados e instalados (Salvio & Wu, 2019). La *US Cybersecurity and Infrastructure Security Agency* reporta costos de remediación de hasta un millón de dólares por incidente, lo cual ubica a *emotet* entre las amenazas más costosas observadas en infraestructura crítica (Salvio & Wu, 2019). Mediante esta elección, la estructura del paisaje aprendido es examinada en detalle para una sola familia, evitando que resultados heterogéneos de comportamientos operacionalmente disjuntos sean agregados. El procedimiento es generalizable a cualquier familia $y \in \{1, \dots, C\}$ mediante el reemplazo de la etiqueta condicionante.

6.4.6.2 Topología del conjunto de subnivel

El conjunto de subnivel de la energía condicional para una familia y y umbral τ es definido como

$$S_\tau(y) = \{ z \in \mathbb{R}^{256} : E_\theta(z, y) \leq \tau \}, \quad (6.20)$$

es decir, la región del espacio latente que el modelo considera compatible con la familia y por debajo del umbral τ . El umbral τ es fijado como el percentil 90 de las energías $\{E_\theta(z_i^+, y) : y_i = y\}$ evaluadas sobre las representaciones reales del conjunto de entrenamiento de la familia y , con lo cual el umbral es anclado al rango empírico observado.

El conjunto $S_\tau(y)$ es aproximado discretamente mediante un mecanismo de exploración del paisaje. Una nube de puntos de exploración distribuidos uniformemente sobre el espacio latente, denominados *puntos de referencia*, es generada con el propósito de que regiones del paisaje energético no necesariamente alcanzadas por las muestras reales del entrenamiento sean cubiertas. La construcción es ejecutada en tres pasos. En primer lugar, puntos gaussianos $z_0 \sim \mathcal{N}(0, \sigma^2 I)$ son muestreados y su energía es minimizada mediante 20 pasos de Langevin sin condicionar a ninguna familia, mediante los cuales son aproximados al soporte global del paisaje aprendido. En segundo lugar, 5 000 de estos puntos son seleccionados mediante muestreo *MaxMin* (*farthest-point sampling*), procedimiento mediante el cual son retenidos los más distantes entre sí y la cobertura uniforme del espacio es garantizada. En tercer lugar, los puntos de referencia que satisfacen $E_\theta(z, y) \leq \tau$ son retenidos y son unidos con las representaciones reales del conjunto de entrenamiento que pasan el mismo filtro. La unión de ambos subconjuntos constituye la nube discreta sobre la que la topología es computada y, para *emotet*, contiene 1 597 puntos en $\mathbb{R}^{256}$.

6.4.6.3 Topología de los mínimos locales

La concentración de masa del paisaje en los valles de la cuenca es caracterizada mediante el muestreo de Langevin desde ruido gaussiano. Para *emotet*, 2 000 cadenas independientes son inicializadas desde $z_0 \sim \mathcal{N}(0, \sigma^2 I)$ con $\sigma = 1.1$, son ejecutados 200 pasos de Langevin de la ecuación (3.23) sobre $E_\theta(\cdot, \text{emotet})$ y el punto final de cada cadena es retenido como un mínimo local del paisaje. La cantidad de pasos excede la utilizada durante el entrenamiento, con lo cual el sesgo finito del muestreador en la región de prueba es reducido.

6.4.7 Matriz de objetivos, fases metodológicas y resultados esperados

La siguiente tabla resume la alineación entre los objetivos específicos de la investigación, las fases metodológicas desarrolladas y los entregables generados en cada etapa. Esta correspondencia proporciona una trazabilidad rigurosa del proceso investigativo, asegurando que cada decisión metodológica contribuya directamente al logro de los objetivos planteados.

Cuadro 6.6: *Relación entre objetivos específicos, fases del flujo metodológico y entregables*

	Objetivos específicos	Fases del flujo metodológico	Entregable
OE1	Estructurar la secuencia de eventos comportamentales del malware mediante una red de información heterogénea en tiempo discreto.	Estructuración del dominio informacional	Conjunto de grafos heterogéneos generados sobre múltiples muestras de malware que representan la secuencia de sus eventos bservables.
OE2	Desarrollar un codificador capaz de generar representaciones en espacio latente asociadas a la coherencia sintáctica y semántica de los eventos comportamentales del malware estructurados en la red heterogénea de información dinámica.	Codificación representacional: del espacio sintáctico a la coherencia semántica	Codificador representacional Graph Transformer entrenado con aprendizaje auto supervisado mediante JEPA que captura representaciones latentes asociadas a la coherencia sintáctica y semántica de los eventos del malware.
OE3	Emerger la morfología estructural evolutiva del paisaje energético mediante un modelo basado en energía condicional, capaz de generar trayectorias dinámicas discretas que representen la evolución temporal del comportamiento del malware.	Emergencia del paisaje energético: dinámica morfológica del comportamiento del malware	Modelo basado en energía condicional entrenado mediante máxima verosimilitud capaz de emerger el paisaje energético a partir del cual se estructura la dinámica del comportamiento del malware.

Continúa en la siguiente página

	Objetivos específicos	Fases del flujo metodológico	Entregable
OE4	Evaluar la capacidad del modelo energético para representar coherentemente los patrones comportamentales evolutivos que describen la identidad de familias de malware.	Del paisaje energético a la narrativa comportamental: hacia una interpretación morfológica del malware	Análisis Topológico de datos del paisaje energético como interpretación de las manifestaciones morfológicas de los patrones comportamentales que distinguen a las familias de malware.

7. RESULTADOS

En este capítulo son reportados los resultados experimentales obtenidos sobre el conjunto de prueba universal definido en el Marco Experimental. La presentación es organizada en cuatro secciones: en primer lugar, los resultados del preentrenamiento autosupervisado mediante JEPA son discutidos en términos de la curva de eficiencia de etiquetas que validan empíricamente la calidad representacional de codificador. En segundo lugar, la ablación sobre el número de subgrafos objetivo K es presentada con el propósito de justificar la elección $K = 4$ como número de objetivos de predicción en espacio latente. En tercer lugar, se evalúa la calidad del modelo basado en energía para capturar en su morfología la identidad comportamental de las familias de malware. Finalmente, se reporta el análisis topológico del paisaje energético para un caso de estudio.

7.1 PRE-ENTRENAMIENTO JEPA

La curva de eficiencia de etiquetas es reportada en la Figura 7.1 sobre las cinco fracciones $\lambda \in \{10\%, 20\%, 40\%, 70\%, 100\%\}$ para las tres configuraciones con mejor desempeño del método propuesto: *Linear Probe* con codificador pre-entrenado con $K = 4$, *Fine-Tuning* con $K = 4$ y *Supervised E2E*. La Tabla 7.1 reporta los valores numéricos correspondientes con desviación estándar sobre tres *seeds*.




Figura 7.1: Curva de eficiencia de etiquetas. Macro F1 sobre el conjunto de prueba universal frente a la fracción de etiquetado λ . Las curvas atenuadas correspondientes a Linear Probe con $K \in \{2, 3, 5\}$ son incluidas como contexto visual; su cuantificación es presentada en la Sección 7.2.

Cuadro 7.1: *Eficiencia de etiquetas: Linear Probe vs. Supervised E2E vs. Fine-Tuning. Macro F1 (media $\pm 1\sigma$ sobre tres seeds) de tres configuraciones a través de cinco fracciones de etiquetado: Linear Probe sobre el encoder Malware-JEPA congelado ($K = 4$), baseline HGT supervisado end-to-end y Fine-Tuning de Malware-JEPA ($K = 4 +$ cabeza MLP). Las brechas Δ_{Sup} y Δ_{LP} son reportadas en puntos porcentuales (pp) entre Fine-Tune y los baselines supervisado y Linear Probe congelado, respectivamente. La última columna reporta el Macro F1 de Fine-Tuning como porcentaje del baseline supervisado a $\lambda = 100\%$ ($Sup @ 100\% = 0.8586$).*

Fracción	LP ($K=4$)	Supervisado	Fine-Tune	Δ_{Sup} (pp)	Δ_{LP} (pp)	FT/Sup @100 % (%)
10 %	0.7133 ± 0.0130	0.7311 ± 0.0065	$0.7571 \pm 0.0083^{\ddagger}$	+2.60	+4.38	88.18
20 %	0.7613 ± 0.0049	0.7693 ± 0.0090	$0.8065 \pm 0.0095^{\ddagger}$	+3.72	+4.52	93.93
40 %	0.8093 ± 0.0092	0.8069 ± 0.0049	$0.8505 \pm 0.0082^{\ddagger}$	+4.36	+4.12	99.06
70 %	0.8214 ± 0.0065	0.8447 ± 0.0101	$0.8599 \pm 0.0049^{\ddagger}$	+1.52	+3.85	100.15
100 %	$0.8284 \pm 0.0000^{\dagger}$	0.8586 ± 0.0090	$0.8718 \pm 0.0027^{\ddagger}$	+1.32	+4.34	101.54
Media	—	—	—	+2.70	+4.24	—

El *Linear Probe* con $K = 4$ alcanza un Macro F1 igual a 0.8093 a $\lambda = 40\%$, valor que iguala al *baseline* supervisado evaluado en la misma fracción (0.8069 ± 0.0049). La diferencia absoluta de 0.24 pp queda dentro del rango de variabilidad por *seed* de ambas configuraciones, lo cual evidencia que la representación producida por el preentrenamiento JEPA admite clasificación lineal con desempeño equivalente al del *encoder* supervisado de extremo a extremo cuando la etiqueta cubre el 40 % de las muestras. A partir de $\lambda = 70\%$, el *baseline* supervisado recupera ventaja: alcanza 0.8447 frente a 0.8214 del *Linear Probe*, brecha de 2.33 pp que refleja la capacidad del clasificador supervisado entrenado conjuntamente con el codificador representacional para explotar las correlaciones no lineales entre las representaciones latentes y las señales supervisadas que el clasificador lineal no es capaz de explotar.

El *Fine-Tuning* con $K = 4$ alcanza un Macro F1 igual a 0.8505 a $\lambda = 40\%$, lo cual equivale al 99.06 % del *baseline* supervisado evaluado sobre el conjunto completo (0.8586 a $\lambda = 100\%$). A $\lambda = 70\%$, el *Fine-Tuning* alcanza un Macro F1 de 0.8599 y supera al *baseline* supervisado evaluado a $\lambda = 100\%$ por 1.32 pp, lo que implica que el máximo desempeño del régimen supervisado puede ser alcanzado por un modelo pre-entrenado en régimen de *Fine-Tuning* con una reducción del costo de etiquetado del 30 %.

La diferencia entre *Linear Probe* y *Fine-Tuning* a $\lambda = 70\%$ (0.8214 frente a 0.8599) cuantifica el aporte del ajuste fino de los pesos del codificador representacional durante el régimen *downstream* sobre una representación que ya alcanza desempeño competitivo bajo clasificación lineal.

El *Fine-Tuning* con $K = 4$ supera al *baseline* supervisado en las cinco fracciones evaluadas. La ventaja absoluta oscila entre 1.32 pp a $\lambda = 100\%$ y 4.36 pp a $\lambda = 40\%$, con valores intermedios de 2.60 pp, 3.72 pp y 1.52 pp en $\lambda \in \{10\%, 20\%, 70\%\}$.

La brecha persistente a $\lambda = 100\%$ indica que el preentrenamiento aporta señal más discriminativa incluso cuando el régimen supervisado dispone de la totalidad de las etiquetas lo que implica, que el pre-entrenamiento es capaz de capturar la estructura del comportamiento del *malware* que no es recuperable únicamente por *cross-entropy* sobre etiquetas de familias de *malware*.

7.2 ABLACIÓN SOBRE EL NÚMERO DE OBJETIVOS K

La elección de $K = 4$ que sustenta los resultados de la Sección 7.1 es derivada de una ablación sobre $K \in \{2, 3, 4, 5\}$ en el régimen *Linear Probe*, replicada sobre las cinco fracciones de etiquetado. La Figura 7.2 reporta la curva en V invertida y la Tabla 7.2 reporta los valores completos por fracción.




Figura 7.2: Ablación sobre K . *Macro F1* (Linear Probe) frente al número de subgrafos objetivo por contexto K , agregado sobre las cinco fracciones de etiquetado mediante promedio aritmético. Una forma en V invertida con máximo en $K = 4$ es exhibida por la curva.

Cuadro 7.2: Ablación: número de objetivos de predicción latente K . Macro F1 del Linear Probe (media $\pm 1\sigma$ sobre tres seeds) sobre el encoder HGT congelado, preentrenado con Malware-JEPA con $K \in \{2, 3, 4, 5\}$. El mejor K por fracción es resaltado en negrita. La ablación exhibe un perfil en V invertida que alcanza su máximo en $K = 4$ (mejora media $\Delta_{K=3 \rightarrow K=4} = +0.43$ pp; degradación media $\Delta_{K=4 \rightarrow K=5} = -0.79$ pp), lo cual justifica la elección $K = 4$ adoptada para los resultados principales reportados en la Tabla 7.1.

Frac.	LP ($K=2$)	LP ($K=3$)	LP ($K=4$)	LP ($K=5$)	Supervisado	Mejor K	Δ_{Sup} (pp)	Razón (%)
10 %	0.6824 $\pm$ 0.0114	0.7112 $\pm$ 0.0090	0.7133 $\pm$ 0.0130	0.7136 $\pm$ 0.0086	0.7311 $\pm$ 0.0065	$K=5$	+1.75	97.6
20 %	0.7271 $\pm$ 0.0081	0.7457 $\pm$ 0.0161	0.7613 $\pm$ 0.0049	0.7568 $\pm$ 0.0138	0.7693 $\pm$ 0.0090	$K=4$	+0.80	99.0
40 %	0.7913 $\pm$ 0.0112	0.8050 $\pm$ 0.0085	0.8093 $\pm$ 0.0092	0.7949 $\pm$ 0.0075	0.8069 $\pm$ 0.0049	$K=4$	-0.24	100.3
70 %	0.8047 $\pm$ 0.0123	0.8208 $\pm$ 0.0064	0.8214 $\pm$ 0.0065	0.8099 $\pm$ 0.0022	0.8447 $\pm$ 0.0101	$K=4$	+2.33	97.2
100 %	0.8203 $\pm$ 0.0116	0.8296 $\pm$ 0.0000 [†]	0.8284 $\pm$ 0.0000 [†]	0.8188 $\pm$ 0.0000 [†]	0.8586 $\pm$ 0.0090	$K=3$	+2.90	96.6

[†] A $\lambda = 100$ %, las configuraciones LP- $K=3$, $K=4$ y $K=5$ producen Macro F1 idéntico a través de seeds ($C = 10^5$ óptimo). Este comportamiento es esperado bajo optimización determinista del SVM convexo.

Progresión de la ablación. Mejora media $K=2 \rightarrow K=3$: +1.73 pp (ganancia fuerte). $K=3 \rightarrow K=4$: +0.43 pp (ganancia marginal). $K=4 \rightarrow K=5$: -0.79 pp (regresión sistemática en 4 de 5 fracciones). La ablación exhibe un perfil en V invertida con óptimo en $K = 4$, consistente con una sobre-especificación de la tarea de pretexto más allá de este punto.

$K = 4$ produce el máximo Macro F1 en tres de las cinco fracciones ($\lambda \in \{20\%, 40\%, 70\%\}$) y queda dentro de 0.12 pp del óptimo a $\lambda = 100$ %, donde $K = 3$ alcanza 0.8296 y $K = 4$ alcanza 0.8284. A $\lambda = 10$ %, las tres configuraciones $K \in \{3, 4, 5\}$ son convergidas a Macro F1 ≈ 0.71 con diferencias inferiores a 0.03 pp entre ellas, lo cual indica que el régimen de pocas etiquetas satura la capacidad discriminativa del *probe* lineal antes de que la sensibilidad a K sea exhibida. La forma en V invertida es nítida en $\lambda \in \{20\%, 40\%, 70\%\}$ donde $K = 2$ produce el peor desempeño en cada fracción, $K = 3$ y $K = 4$ producen la cota superior con $K = 4$ marginalmente por encima, y $K = 5$ cae sistemáticamente por debajo de $K = 4$.

La forma en V invertida admite una lectura operacional anclada en la pérdida JEPA. A K pequeño, pocos objetivos por contexto son recibidos por el predictor y la señal de gradiente que modela la representación del codificador durante el preentrenamiento queda disminuida dado que dos objetivos no obligan al modelo a discriminar entre componentes funcionales del grafo. $K = 4$ corresponde al punto donde la cobertura de la partición $\{C_1, \dots, C_p\}$ producida por Att-LPA es suficiente para que un componente funcional distinto sea capturado por cada subgrafo objetivo, de modo que una señal densa sin dispersión sea recibida por el predictor.

$K = 4$ es la configuración que sustenta los resultados de la Sección 7.1 por dos razones opera-

cionales: la calidad de la representación medida por *Linear Probe* es maximizada en las fracciones donde el *probe* es informativo ($\lambda \in \{20\%, 40\%, 70\%\}$), y queda dentro del régimen de equivalencia estadística con $K = 3$ a $\lambda = 100\%$. Los resultados de *Fine-Tuning* reportados en la Figura 7.1 emplean $K = 4$ heredado de esta ablación.

7.3 COHERENCIA DEL PAISAJE ENERGÉTICO CON LAS FAMILIAS DEL CONJUNTO DE DATOS

Para cada representación z del conjunto de prueba, $E_\theta(z, y)$ es evaluada bajo cada etiqueta candidata $y \in \{1, \dots, C\}$ y la familia de mínima energía es registrada:

$$\hat{y}(z) = \arg \min_{y \in \{1, \dots, C\}} E_\theta(z, y). \quad (7.1)$$

Una alta coherencia entre $\hat{y}(z)$ y la etiqueta real indica que energías mínimas son asignadas por el paisaje aprendido a la familia correcta y, en consecuencia, que la estructura familiar del conjunto de datos es codificada en su geometría.

La coherencia es cuantificada mediante *Macro F1* sobre el conjunto de prueba, métrica mediante la cual el desempeño es ponderado por igual sobre familias raras y frecuentes y el desbalance estructural del conjunto de datos es compensado. Un valor de *Macro F1* igual a 0.518 es alcanzado por el modelo sobre el conjunto de prueba, valor que indica una coherencia sustancial entre la regla de mínima energía y las etiquetas reales en las 37 familias del conjunto de datos. La estructura necesaria para que las familias de *malware* del conjunto de datos sean codificadas fue capturada por la geometría del paisaje energético. La estructura de ese paisaje energético es examinada en detalle por el análisis topológico descrito en la subsección 6.4.6.

7.4 ANÁLISIS TOPOLÓGICO DEL PAISAJE ENERGÉTICO PARA EMOTET

A continuación, los resultados experimentales del análisis topológico cuyo procedimiento metodológico fue establecido en la subsección 6.4.6 son reportados sobre la familia *emotet*. La presentación es organizada en dos lecturas complementarias del paisaje aprendido: la topología del conjunto de subnivel, mediante la cual la forma de la cuenca de atracción completa es caracterizada, y la topología de los mínimos locales, mediante la cual la concentración de masa en los valles es analizada.

7.4.1 Topología del conjunto de subnivel

La filtración de *Vietoris–Rips* (Henselman-Petrusek, 2024; Lim et al., 2024) es computada sobre 400 *landmarks MaxMin* extraídos de la nube descrita en la subsección 6.4.6.2, y los diagramas de persistencia $\mathcal{D}_0$, $\mathcal{D}_1$ y $\mathcal{D}_2$ son obtenidos. La Tabla 7.3 resume los descriptores topológicos del conjunto de subnivel para *emotet*.

Cuadro 7.3: *Descriptores topológicos del conjunto de subnivel S_τ para emotet.*

Descriptor	Valor
Componentes principales (PCA)	10
Varianza explicada acumulada	99.9 %
H_0 : número de rasgos	400
H_0 : persistencia máxima	1.585
H_0 : persistencia media	0.573
H_0 : cuencas persistentes en meseta de β_0	7
H_1 : número de rasgos	138
H_1 : persistencia máxima	0.228
H_2 : número de rasgos	24
H_2 : persistencia máxima	0.049
<i>Persistence entropy</i> (H_0)	8.40

La curva de Betti $\beta_0(t)$ desciende de 400 componentes a 7 en el intervalo $t \in [0.099, 0.619]$ y es estabilizada en $\beta_0 = 7$ desde $t \approx 0.62$ hasta el corte de la filtración en $t \approx 1.19$. Mediante la meseta resultante, son indicadas siete cuencas energéticas persistentemente separadas en $S_\tau(\text{emotet})$. La curva $\beta_1(t)$ alcanza un pico de 25 ciclos en $t \approx 0.32$ y decae rápidamente a un único *loop* sostenido. La Figura 7.3 presenta los diagramas de persistencia $\mathcal{D}_0$, $\mathcal{D}_1$ y $\mathcal{D}_2$, mientras que la Figura 7.4 presenta las curvas de Betti correspondientes.




Figura 7.3: Diagramas de persistencia $\mathcal{D}_0$, $\mathcal{D}_1$ y $\mathcal{D}_2$ obtenidos a partir de la filtración de Vietoris–Rips sobre 400 landmarks MaxMin del conjunto de subnivel $S_\tau(\text{emotet})$.




Figura 7.4: Curvas de Betti $\beta_0(t)$, $\beta_1(t)$ y $\beta_2(t)$ del conjunto de subnivel $S_\tau(\text{emotet})$. La meseta de $\beta_0 = 7$ entre $t \approx 0.62$ y $t \approx 1.19$ y el pico de β_1 en $t \approx 0.32$ son visibles, en correspondencia con los descriptores reportados en la Tabla 7.3.

Tres lecturas son derivadas del análisis. En primer lugar, el 99.9% de la varianza de la nube de subnivel es explicado por diez componentes principales, lo cual indica que la cuenca de atracción de *emotet* es proyectada esencialmente sobre un subespacio lineal de dimensión diez dentro del espacio latente de dimensión 256. En segundo lugar, las siete cuencas persistentes en β_0 indican que ese subespacio es fragmentado en siete segmentos topológicamente disjuntos, los cuales son detectados por el paisaje aprendido como sub-modos comportamentales internos a la familia. En tercer lugar, la presencia de bucles de persistencia no despreciable (H_1 con persistencia máxima 0.228, aproximadamente el 14% de la persistencia máxima de H_0) revela conectividad no trivial entre cuencas: regiones de mayor energía son rodeadas por la cuenca aprendida dejando estructura cíclica intermedia, fenómeno que puede reflejar sub-modos comportamentales similares pero separados por configuraciones intermedias improbables. Los vacíos de H_2 son escasos (24 rasgos

con persistencia máxima de 0.049, dos órdenes de magnitud por debajo de H_0) y no contribuyen significativamente a la organización de la cuenca.

7.4.2 Topología de los mínimos locales

La filtración de *Vietoris–Rips* es calculada sobre 500 *landmarks MaxMin* extraídos de la nube de 2 000 mínimos en $\mathbb{R}^{256}$ descrita en la subsección 6.4.6.3, y los diagramas de persistencia análogos a los de la subsección 7.4.1 son extraídos. La Tabla 7.4 resume los descriptores topológicos correspondientes.

Cuadro 7.4: *Descriptores topológicos de la nube de mínimos locales para emotet.*

Descriptor	Valor
Componentes principales (PCA)	10
Varianza explicada acumulada	98.2 %
H_0 : número de rasgos	500
H_0 : persistencia máxima	2.706
H_0 : persistencia media	2.490
H_0 : cuencas persistentes en meseta de β_0	65
H_1 : número de rasgos	1 183
H_1 : persistencia máxima	0.111
H_2 : número de rasgos	3 239
H_2 : persistencia máxima	0.082
<i>Persistence entropy</i> (H_0, H_1, H_2)	8.90, 9.52, 11.24

La curva de Betti $\beta_0(t)$ es mantenida en 500 componentes desde $t = 0$ hasta $t \approx 1.19$ (todos los mínimos topológicamente disjuntos a escalas pequeñas), es colapsada abruptamente entre $t \approx 1.19$ y $t \approx 1.35$, y es estabilizada en $\beta_0 = 65$ hasta el corte de la filtración. La curva $\beta_2(t)$ alcanza un pico de 1 217 vacíos en $t \approx 0.97$. La Figura 7.5 presenta los diagramas de persistencia $\mathcal{D}_0$, $\mathcal{D}_1$ y $\mathcal{D}_2$ de la nube de mínimos locales, y la Figura 7.6 presenta las curvas de Betti correspondientes.




Figura 7.5: Diagramas de persistencia $\mathcal{D}_0$, $\mathcal{D}_1$ y $\mathcal{D}_2$ obtenidos a partir de la filtración de Vietoris–Rips sobre 500 landmarks MaxMin de la nube de 2 000 mínimos locales muestreados por Langevin desde ruido para emotet.

A partir de la comparación con los resultados reportados en la subsección 7.4.1 se deriva un diagnóstico sobre el paisaje aprendido, cada uno de los 2 000 mínimos satisface $E_\theta(z, \text{emotet}) \leq \tau$ por construcción, con lo cual la nube de mínimos es ubicada íntegramente dentro del conjunto de subnivel. Los 65 grupos de mínimos constituyen una sub-resolución estricta de las siete cuencas: cada grupo es contenido en una de las siete cuencas que el subnivel describe.

De acuerdo a las curvas de Betti 7.6, las siete cuencas del subnivel son manifestadas como una meseta de $\beta_0 = 7$ que se extiende desde $t \approx 0.62$ hasta $t \approx 1.19$, cubriendo el 48 % del rango de filtración. La persistencia máxima de H_0 (1.585) supera en un factor de 2.8 la persistencia media (0.573), con lo cual las siete cuencas son estratificadas claramente como rasgos dominantes frente a los rasgos efímeros. Los 65 grupos de mínimos son sostenidos análogamente sobre una meseta de $\beta_0 = 65$ que cubre $t \in [1.35, 2.59]$. El cociente entre persistencia media y máxima de H_0 alcanza 0.92 sobre la nube de mínimos, lo cual indica que persistencias comparables entre sí son presentadas por los 65 grupos, sin jerarquía interna que permita que parte de ellos sea descartada como ruido. Las 65 sub-cuencas son, en consecuencia, rasgos topológicos genuinos y no artefactos de la discretización.

Los mínimos aportan información adicional sobre la estructura topológica fina del subnivel. Mediante la filtración son detectados 1 183 ciclos en H_1 y 3 239 cuencas en H_2 . Las persistencias máximas correspondientes (0.111 y 0.082) son menores que la persistencia máxima de H_0 por un factor de 24 y 33 respectivamente, con lo cual estos rasgos son ubicados a escalas finas dentro de las cuencas que H_0 delimita. Los mínimos revelan que una organización topológica interna estable es contenida por cada cuenca del subnivel: la familia no es organizada por el paisaje energético condicionado a *emotet* en regiones simplemente conectadas, sino en cuencas con estructura cíclica y cavitada a escalas finas.




Figura 7.6: Curvas de Betti $\beta_0(t)$, $\beta_1(t)$ y $\beta_2(t)$ de la nube de 2 000 mínimos locales para emotet. La meseta de $\beta_0 = 65$ y el pico de $\beta_2 \approx 1\,217$ en $t \approx 0.97$ son visibles, en correspondencia con los descriptores reportados en la Tabla 7.4.

Las siete cuencas del subnivel constituyen la morfología global del paisaje aprendido para emotet. Los mínimos refinan esa interpretación con mayor resolución, identificando 65 sub-cuencas locales y estructuras cíclicas y cavidades internas que el subnivel agrupa pero no identifica.

8. CONCLUSIONES

La validación experimental de la extensión de Graph-JEPA al dominio de grafos heterogéneos para la clasificación de familias de *malware*, realizada sobre ACT-KINGKONG a través de las cinco fracciones de etiquetado $\lambda \in \{10\%, 20\%, 40\%, 70\%, 100\%\}$, originó los siguientes hallazgos empíricos principales que son sintetizados a continuación:

El protocolo de evaluación lineal sobre la representación preentrenada con $K = 4$ iguala a la línea de referencia supervisada de extremo a extremo a $\lambda = 40\%$ en *Macro F1* (0.8093 frente a 0.8069).

El ajuste fino del modelo preentrenado con $K = 4$ recupera el 99.06 % del desempeño supervisado completo a $\lambda = 40\%$ e iguala dicho desempeño a $\lambda = 70\%$ dentro del rango de variabilidad de los experimentos.

El ajuste fino supera a la línea de referencia supervisada en las cinco fracciones evaluadas, con una ganancia máxima de 4.36 pp a $\lambda = 40\%$. La eficiencia muestral observada es sustentada en una asimetría estructural del protocolo experimental: el preentrenamiento explota la información comportamental contenida en cada muestra de *malware* sin requerir etiquetas mientras que el modelo entrenado supervisado debe encontrar patrones discriminativos correlacionados directamente con las etiquetas de las familias de malware.

El análisis topológico de la geometría del paisaje de energía reveló los siguientes hallazgos:

Las dos filtraciones consideradas —subnivel y mínimos— revelan rasgos persistentes en H_0 , H_1 y H_2 que son sostenidos sobre intervalos amplios de la filtración. El paisaje aprendido no es ni una región amorfa ni una colección de puntos sin estructura: cuencas, ciclos y cavidades son contenidos en él, los cuales son explotados por el modelo a partir de las representaciones abstractas producidas por JEPA.

El subnivel de *emotet* exhibe una meseta de $\beta_0 = 7$ que cubre el 48 % del rango de filtración. Esto significa que el paisaje aprendido para *emotet* no asume un comportamiento monolítico de la familia *emotet* sino que la organiza en siete sub-modos topológicamente disjuntos, cada uno asociado a su propia región de baja energía.

Diez componentes principales explican el 99.9 % de la varianza del subnivel, el espacio latente es de $\mathbb{R}^{256}$. El modelo de energía concentra la masa de probabilidad de emotet sobre un subespacio del 4 % de la dimensionalidad latente. Esto es coherente con la noción de que las representaciones JEPA capturan ejes comportamentales relevantes y el EBM los explota; el modelo no necesita la totalidad del espacio latente para codificar la familia de *malware*.

H_1 del subnivel reporta ciclos con persistencia máxima del 14 % de H_0 , entre ellos un ciclo sostenido a lo largo de todo el rango. Este hallazgo es confirmado a escalas finas por los mínimos (1 183 ciclos persistentes). El paisaje energético rodea regiones de mayor energía dejando estructura ciclica, lo que es topológicamente equivalente a decir que el modelo no asume conectividad suave y directa entre los diferentes sub-modo de la familia de *malware*.

Cada mínimo cae dentro del subnivel por construcción, dado que $E_\theta(z, y) \leq \tau$. En consecuencia, los 65 grupos de mínimos constituyen una sub-resolución estricta de las siete cuencas. Esto unifica los dos productos topológicos en una sola jerarquía: el subnivel con una baja resolución y los mínimos como una alta resolución. La metodología extrae dos vistas del mismo objeto a escalas distintas.

La métrica *Macro FI* = 0.518 es interpretada únicamente como un instrumento de validación de la calidad del paisaje de optimización. La mayor fuente de información del modelo basado en energía esta ubicada en su geometría topológica. A través del análisis se evidencia que el paisaje codifica más información que solo una decisión de clasificación: puede modelar cuántas sub-clases existen, cómo están organizadas internamente, cómo se conectan, y a qué escalas.

9. PRINCIPALES APORTES

De acuerdo a la investigación desarrollada, se presentó la primera extensión de una metodología de aprendizaje auto-supervisado del paradigma Graph-JEPA al dominio de grafos heterogéneos, con el propósito de modelar eventos comportamentales del *malware* y, además se explora la utilidad de sus representaciones abstractas para la clasificación de familias de *malware*.

Se emergió un modelo basado en energía condicional sobre las representaciones de un encoder de representaciones abstractas de comportamiento de familias de *malware* JEPA congelado. El modelo extiende el procedimiento de Du y Mordatch (Du & Mordatch, 2019) del régimen de imágenes a un espacio latente de representaciones auto-supervisadas y demuestra que un paisaje energético entrenado por máxima verosimilitud sobre el espacio JEPA captura la estructura de familias de *malware* del conjunto de datos a un nivel de fidelidad medible vía coherencia entre la regla de mínima energía y las etiquetas reales (*Macro F1* = 0.518 sobre 37 familias de *malware*).

Se analizó topológicamente el paisaje energético condicional que combina la homología persistente del conjunto de subnivel de la energía con la de los mínimos locales muestreados por Langevin, articulándolos como lecturas jerárquicas del mismo paisaje a escalas distintas. La metodología revela que el modelo aprende una organización topológica intra-familia que abre el modelo basado en energía como objeto de análisis interpretable y no únicamente como mecanismo de decisión.

10. RECOMENDACIONES Y TRABAJOS FUTUROS

Extender la metodología a grafos heterogéneos contruidos sobre la API de Windows (WinAPI), conjunto de interfaces que las aplicaciones invocan para interactuar con el sistema operativo. Esta extensión caracteriza el comportamiento del *malware* al nivel de invocaciones de API en lugar del nivel de entidades del sistema reportado en este trabajo, y permite evaluar el impacto del preentrenamiento JEPA para la discriminación de familias de *malware*.

Caracterizar la partición $\{C_1, \dots, C_p\}$ producida por Att-LPA durante el preentrenamiento. La hipótesis a verificar es que el mecanismo de atención del codificador HGT eleva el agrupamiento por encima del *clustering* estructural típico de LPA hacia agrupaciones que codifican semántica funcional del comportamiento del *malware*. Es decir, grupos de nodos que comparten función operacional dentro del grafo, no únicamente conectividad estructural.

Cuantificar el aporte de Att-LPA al desempeño global de la metodología mediante ablación frente a particiones alternativas: LPA sin atención, k -means sobre *embeddings* de capa intermedia y caminatas aleatorias sobre los grafos heterogéneos.

Caracterizar la robustez del modelo preentrenado frente a perturbaciones adversariales del grafo heterogéneo. El argumento de partida es que JEPA optimiza predicción en un espacio de representación abstracto en lugar de predicción generativa de grafos heterogéneos o incluso sobre entropía cruzada sobre etiquetas de familia de *malware*, lo que debería ofrecer mayor tolerancia a las varianzas de la representación bajo perturbaciones de tipos de nodo y aristas comparada con el régimen supervisado de extremo a extremo.

El análisis topológico de datos de dos escalas se aplicó a una sola familia (*emotet*) como caso de estudio. La extensión natural es replicar el estudio para las 37 familias del conjunto de datos y comparar los descriptores topológicos entre ellas. Se pueden desprender las siguientes preguntas concretas para responder con esa extensión: (i) ¿el número de cuencas del subnivel varía entre familias?; (ii) ¿familias con mayor diversidad de variantes (es decir, más sub-tipos comportamentales conocidos) producen más cuencas persistentes?; (iii) ¿las familias clasificadas mejor o peor en la Sección 7.3 tienen estructuras topológicas distinguibles? Esta línea convierte el análisis topológico de herramienta interpretativa en herramienta de diagnóstico comparativo entre familias.

Se establece que el paisaje aprendido organiza *emotet* en siete cuencas y 65 sub-grupos, pero **no demuestra que esas cuencas correspondan a sub-tipos comportamentales reales**. La validación natural es asociar cada mínimo a metadatos de su muestra original (campaña, *payload* entregado, infraestructura C2, año de detección) y verificar si los 65 grupos correlacionan con alguna de esas variables categóricas. Si la correlación existe, el paisaje aprendido se convierte en una **herramienta no supervisada de descubrimiento de variantes**; si no existe, las cuencas son artefactos de la geometría JEPA + EBM sin interpretación comportamental directa.

El modelo basado en energía es generativo en su arquitectura: $p_{\theta}(z | y)$ define una distribución sobre representaciones JEPA dada la condición de una familia de *malware*. La extensión natural es muestrear nuevas representaciones desde cada una de las siete cuencas identificadas para *emotet* y decodificarlas del espacio de representaciones abstractas (vía un decodificador entrenado) al espacio de comportamiento original (eventos, *syscalls*, llamadas API). Esto convertiría el modelo en un **generador de variantes sintéticas de *malware* por sub-modo comportamental**, con potencial aplicación en aumento de datos para entrenamiento de detectores y para evaluación de robustez de antivirus.

11. BIBLIOGRAFÍA

- Assran, M., Duval, Q., Misra, I., Bojanowski, P., Vincent, P., Rabbat, M., LeCun, Y., & Ballas, N. (2023). Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- Chazal, F., & Michel, B. (2021). An Introduction to Topological Data Analysis: Fundamental and Practical Aspects for Data Scientists. *Frontiers in Artificial Intelligence*, 4, 667963. <https://doi.org/10.3389/frai.2021.667963>
- Chen, T., Kornblith, S., Norouzi, M., & Hinton, G. (2020). A Simple Framework for Contrastive Learning of Visual Representations. *Proceedings of the 37th International Conference on Machine Learning (ICML)*.
- Corso, G., Stark, H., Jegelka, S., Jaakkola, T., & Barzilay, R. (2024). Graph neural networks. *Nature Reviews Methods Primers*, 4. <https://doi.org/10.1038/s43586-024-00294-7>
- Du, Y., & Mordatch, I. (2019). Implicit Generation and Generalization in Energy-Based Models. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Edelsbrunner, H., Letscher, D., & Zomorodian, A. (2002). Topological Persistence and Simplification. *Discrete & Computational Geometry*, 28(4), 511-533.
- Ge, L. (2021). A New Method for Malware Detection Based on Energy. *Proceedings - 2021 IEEE 6th International Conference on Data Science in Cyberspace, DSC 2021*, 625-628. <https://doi.org/10.1109/DSC53577.2021.00099>
- Grégio, A., Bonacin, R., Marchi, A. C. D., Nabuco, O. F., & Geus, P. L. D. (2016). An ontology of suspicious software behavior. *Applied Ontology*, 11, 29-49. <https://doi.org/10.3233/AO-160163>
- Grégio, A. R. A., Afonso, V. M., Filho, D. S. F., Geus, P. L. D., & Jino, M. (2014). Toward a Taxonomy of Malware Behaviors. *Computer Journal*, 58, 2758-2777. <https://doi.org/10.1093/comjnl/bxv047>
- Henselman-Petrusek, G. (2024). Vietoris–Rips Persistent Homology.
- Hu, Z., Dong, Y., Wang, K., & Sun, Y. (2020). Heterogeneous Graph Transformer. *Proceedings of The Web Conference 2020 (WWW '20)*, 2704-2710. <https://doi.org/10.1145/3366423.3380027>

- Jacob, G., Debar, H., & Filiol, E. (2008). Behavioral detection of malware: from a survey towards an established taxonomy. *Journal in Computer Virology* 2008 4:3, 4, 251-266. <https://doi.org/10.1007/S11416-008-0086-0>
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., Hassabis, D., Clopath, C., Kumaran, D., & Hadsell, R. (2017). Overcoming Catastrophic Forgetting in Neural Networks. *Proceedings of the National Academy of Sciences*, 114(13), 3521-3526.
- Kramer, S., & Bradfield, J. C. (2010). A general definition of malware. *Journal in Computer Virology*, 6, 105-114. <https://doi.org/10.1007/S11416-009-0137-1/METRICS>
- LeCun, Y. (2022, junio). *A Path Towards Autonomous Machine Intelligence* (inf. téc. N.º Version 0.9.2). Courant Institute of Mathematical Sciences, NYU; Meta – Fundamental AI Research.
- LeCun, Y., Chopra, S., Hadsell, R., Ranzato, A., & Huang, F. J. (2006). Predicting Structured Data. <http://yann.lecun.com>
- Li, M., Zhang, P., Xing, W., Zheng, Y., Zaporozhets, K., Chen, J., Zhang, R., Zhang, Y., Gong, S., Hu, J., Ma, X., Liu, Z., Groth, P., & Worring, M. (2026). A survey of large language models for data challenges in graphs. *Expert Systems with Applications*, 298. <https://doi.org/10.1016/j.eswa.2025.129643>
- Li, S., Gong, J., Ke, S., & Tang, S. (2025). Graph Transformer-based Heterogeneous Graph Neural Networks enhanced by multiple meta-path adjacency matrices decomposition. *Neurocomputing*, 629. <https://doi.org/10.1016/j.neucom.2025.129604>
- Lim, S., Mémoli, F., & Okutan, O. B. (2024). Vietoris–Rips Persistent Homology, Injective Metric Spaces, and the Filling Radius. *Algebraic & Geometric Topology*.
- Lipton, Z. C., Elkan, C., & Naryanaswamy, B. (2014). Optimal Thresholding of Classifiers to Maximize F1 Measure. *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*.
- Liu, C., Li, B., Liu, X., Li, C., & Bao, J. (2024). Evolving malware detection through instant dynamic graph inverse reinforcement learning. *Knowledge-Based Systems*, 299. <https://doi.org/10.1016/j.knosys.2024.111991>
- Liu, C., Li, B., Wu, Y., Liu, X., Li, J., & Li, C. (2025). DynMD : Energy-Based Dynamic Graph Representation Learning for Malware Detection. *IEEE Transactions on Dependable and Secure Computing*. <https://doi.org/10.1109/TDSC.2025.3619926>
- Liu, C., Li, B., Zhao, J., Feng, W., Liu, X., & Li, C. (2024). A2-CLM: Few-Shot Malware Detection Based on Adversarial Heterogeneous Graph Augmentation. *IEEE Transactions on Information Forensics and Security*, 19, 2023-2038. <https://doi.org/10.1109/TIFS.2023.3345640>
- Liu, C., Li, B., Zhao, J., Su, M., & Liu, X. (2021). MG-DVD: A Real-time Framework for Malware Variant Detection Based on Dynamic Heterogeneous Graph Learning. *IJCAI International*

- Joint Conference on Artificial Intelligence*, 1512-1519. <https://doi.org/10.24963/ijcai.2021/209>
- Marc'Aurelio, Boureau, Y.-L., Chopra, S., & LeCun, Y. R. (2007). A Unified Energy-Based Framework for Unsupervised Learning. En Marina & X. M. Shen (Eds.), *proceedings of the Eleventh International Conference on Artificial Intelligence and Statistics* (pp. 371-379). PMLR. <https://proceedings.mlr.press/v2/ranzato07a.html>
- Miyato, T., Kataoka, T., Koyama, M., & Yoshida, Y. (2018). Spectral Normalization for Generative Adversarial Networks. *International Conference on Learning Representations (ICLR)*.
- Mu, H., Zhou, C., Yu, Q., & Mu, Q. (2025). Graph representation learning via enhanced GNNs and transformers. *Scientific Reports*, 15. <https://doi.org/10.1038/s41598-025-08688-7>
- Nandan, M., Mitra, S., & De, D. (2025). GraphXAI: a survey of graph neural networks (GNNs) for explainable AI (XAI). *Neural Computing and Applications* 2025 37:17, 37, 10949-11000. <https://doi.org/10.1007/S00521-025-11054-3>
- Ratna, S., Singh, S., & Sharma, A. (2025). An inclusive analysis for performance and efficiency of graph neural network models for node classification. *Computer Science Review*, 56. <https://doi.org/10.1016/j.cosrev.2024.100722>
- Salvio, J., & Wu, R. (2019). *Exploring Emotet's Activities* (inf. téc.). Trend Micro Research. https://documents.trendmicro.com/assets/white_papers/ExploringEmotetsActivities_Final.pdf
- Shalaginov, A., Dyrkolbotn, G. O., & Alazab, M. (2020). Review of the malware categorization in the era of changing cyb threats landscape: Common approaches, challenges and future needs. *Malware Analysis Using Artificial Intelligence and Deep Learning*, 71-96. https://doi.org/10.1007/978-3-030-62582-5_3/FIGURES/6
- Skenderi, G., Li, H., Tang, J., & Cristani, M. (2024). Graph-level Representation Learning with Joint-Embedding Predictive Architectures. *arXiv preprint arXiv:2309.16014*.
- Skulason, F., Solomon, A., & Bontchev, V. (1991). *CARO Naming Scheme* (inf. téc.). Computer Antivirus Research Organization.
- Sokolova, M., & Lapalme, G. (2009). A Systematic Analysis of Performance Measures for Classification Tasks. *Information Processing & Management*, 45(4), 427-437.
- Su, Y., & Wang, X. (2024). An Graph Neural Network Approach with Self- Supervised Learning for Malware Detection. *IEEE Information Technology, Networking, Electronic and Automation Control Conference, ITNEC*, 775-778. <https://doi.org/10.1109/ITNEC60942.2024.10732985>
- Sun, Y., & Han, J. (2012). *Mining Heterogeneous Information Networks: Principles and Methodologies*. Morgan & Claypool.
- Tu, N. M., Hung, N. V., Anh, P. V., Loi, C. V., & Shone, N. (2020). Detecting Malware Based on Dynamic Analysis Techniques Using Deep Graph Learning. *Lecture Notes in Computer*

- Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 12466 LNCS, 357-378. https://doi.org/10.1007/978-3-030-63924-2_21/FIGURES/5
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Wasserman, L. (2018). Topological Data Analysis. *Annual Review of Statistics and Its Application*, 5, 501-532. <https://doi.org/10.1146/annurev-statistics-031017-100045>
- Welling, M., & Teh, Y. W. (2011). Bayesian Learning via Stochastic Gradient Langevin Dynamics. *Proceedings of the 28th International Conference on Machine Learning (ICML)*, 681-688.
- Yang, Y., Guan, Z., Wang, Z., Zhao, W., Xu, C., Lu, W., & Huang, J. (2022). Self-supervised Heterogeneous Graph Pre-training Based on Structural Clustering. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Yavvari, C., Tokhtabayev, A., Rangwala, H., & Stavrou, A. (2012). Malware Characterization Using Behavioral Components. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 7531 LNCS, 226-239. https://doi.org/10.1007/978-3-642-33704-8_20