

# **Arquitectura Cloud-Native para la transformación, fusión y análisis de datos de radar meteorológico en entornos AWS**

Trabajo de investigación/grado para optar el título de  
**Magister en Ciencias de la Información y las Comunicaciones**

**Jenifer Andrea Torres Rodriguez**

Director: Cesar Andrey Perdomo Charry, PhD

Universidad Distrital Francisco José De Caldas

Maestría en Ciencias de la Información y las Comunicaciones

Énfasis en Teleinformática

Bogotá D.C. – Colombia

2026

## Contenido

|                                                                   |    |
|-------------------------------------------------------------------|----|
| Lista de tablas.....                                              | 4  |
| Lista de figuras.....                                             | 4  |
| 1. Resumen.....                                                   | 5  |
| 2. Introducción .....                                             | 6  |
| 2.1. Planteamiento del problema.....                              | 7  |
| 2.2. Hipótesis .....                                              | 8  |
| 2.3. Objetivos .....                                              | 8  |
| 2.3.1. Objetivo General.....                                      | 8  |
| 2.3.2. Objetivos Específicos.....                                 | 8  |
| 2.4. Motivación y contexto institucional.....                     | 9  |
| 2.5. Organización del documento .....                             | 10 |
| 3. Marco de Referencia .....                                      | 11 |
| 3.1. Marco Conceptual.....                                        | 11 |
| 3.1.1. Radar meteorológico .....                                  | 11 |
| 3.1.2. Datos meteorológicos multidimensionales .....              | 11 |
| 3.1.5. Formatos científicos multidimensionales .....              | 13 |
| 3.2. Marco Teórico.....                                           | 13 |
| 3.2.1. Teoría de los radares meteorológicos.....                  | 13 |
| 3.2.2. Fusión espacio–temporal radar–estaciones .....             | 14 |
| 3.2.3. Procesamiento distribuido y chunking.....                  | 15 |
| 3.2.4. Arquitecturas serverless para analítica meteorológica..... | 15 |
| 3.2.4.1. AWS Athena.....                                          | 15 |

|          |                                                        |    |
|----------|--------------------------------------------------------|----|
| 3.2.4.2. | AWS Glue .....                                         | 15 |
| 3.2.5.   | Inteligencia Artificial aplicada a meteorología .....  | 16 |
| 3.3.     | Marco Espacial.....                                    | 16 |
| 3.4.     | Marco Temporal.....                                    | 17 |
| 4.       | Diseño de la Arquitectura Cloud-Native.....            | 18 |
| 4.1.     | Arquitectura general de la solución .....              | 18 |
| 4.2.     | Adquisición de datos.....                              | 20 |
| 4.3.     | Procesamiento ETL.....                                 | 20 |
| 4.4.     | Almacenamiento científico multidimensional .....       | 21 |
| 4.5.     | Capa analítica.....                                    | 22 |
| 4.6.     | Integración radar – estaciones y validación .....      | 23 |
| 4.7.     | Infraestructura como código y automatización.....      | 24 |
| 5.       | Implementación.....                                    | 25 |
| 5.1.     | Implementación general de la solución.....             | 25 |
| 5.2.     | Entorno de implementación .....                        | 25 |
| 5.3.     | Implementación del procesamiento ETL .....             | 26 |
| 5.4.     | Implementación del almacenamiento científico .....     | 27 |
| 5.5.     | Implementación de la capa analítica .....              | 28 |
| 5.6.     | Implementación de integración radar – estaciones ..... | 29 |
| 6.       | Resultados y evaluación.....                           | 31 |
| 7.       | Discusión.....                                         | 36 |
| 8.       | Conclusiones .....                                     | 38 |
| 9.       | Trabajo Futuro .....                                   | 39 |
| 10.      | Referencias.....                                       | 40 |

### Lista de tablas

|                                                                  |    |
|------------------------------------------------------------------|----|
| Tabla 1 Intensidad de precipitación.....                         | 14 |
| Tabla 2 Cobertura de Radares IDEAM .....                         | 16 |
| Tabla 3Etapas temporales de investigación.....                   | 17 |
| Tabla 4 Comparación de desempeño entre formatos científicos..... | 32 |
| Tabla 5 Resultados de la capa analítica.....                     | 34 |

### Lista de figuras

|                                                                         |    |
|-------------------------------------------------------------------------|----|
| Figura 1 Estructura Zarr .....                                          | 15 |
| Figura 2 Ejemplo consulta en AWS Athena .....                           | 15 |
| Figura 3 Diagrama de arquitectura a gran escala .....                   | 19 |
| Figura 4 Pipeline ETL implementado .....                                | 27 |
| Figura 5 Estructura de almacenamiento en S3 .....                       | 28 |
| Figura 6 Consulta SQL sobre datos de radar en S3.....                   | 29 |
| Figura 7 Integración radar - estaciones .....                           | 30 |
| Figura 8 Escalabilidad de formatos científicos en lectura paralela..... | 32 |

## 1. Resumen

La presente investigación desarrolla una arquitectura cloud-native en AWS para la transformación, almacenamiento, fusión y análisis escalable de datos de radar meteorológico y estaciones meteorológicas. La propuesta evoluciona una línea base local previamente implementada hacia un ecosistema desacoplado y reproducible, incorporando procesos ETL para transformar datos RAW heterogéneos en datasets científicos multidimensionales optimizados para computación ambiental. Como eje central del estudio, se realiza una evaluación comparativa entre los formatos científicos Zarr, NetCDF y HDF5, analizando su desempeño en escenarios de procesamiento distribuido, almacenamiento orientado a objetos y cargas analíticas concurrentes. La arquitectura adopta un enfoque Zarr-first para el dataset científico principal y una capa analítica derivada en Parquet catalogada mediante AWS Glue y consultable mediante Amazon Athena.

Adicionalmente, la propuesta integra datos abiertos de estaciones meteorológicas mediante procesos de alineación y fusión espacio-temporal orientados a mejorar la coherencia física de las estimaciones de precipitación y fortalecer la capacidad analítica del sistema. La investigación incorpora lineamientos de procesamiento distribuido, gobierno de datos y trazabilidad para garantizar reproducibilidad y escalabilidad en entornos cloud-native. Finalmente, el trabajo busca aportar un framework reutilizable para sistemas modernos de observación atmosférica, proporcionando una base metodológica y tecnológica para la gestión eficiente de grandes volúmenes de datos meteorológicos y la evaluación de formatos científicos en aplicaciones ambientales.

## 2. Introducción

La estimación y análisis de la precipitación continúan siendo un desafío central en la meteorología aplicada, especialmente en regiones tropicales donde los eventos convectivos presentan alta variabilidad espacial y temporal. En este contexto, los radares meteorológicos representan una herramienta fundamental debido a su capacidad para generar observaciones continuas y de alta resolución sobre fenómenos atmosféricos (Copete, 2023). Sin embargo, la estimación cuantitativa de precipitación basada únicamente en radar puede verse afectada por sesgos asociados a la relación reflectividad–lluvia y limitaciones físicas propias del sistema (Verdelho et al., 2024). Frente a ello, investigaciones recientes han demostrado que la integración de datos de estaciones meteorológicas y la incorporación de técnicas de Inteligencia Artificial permiten mejorar la precisión y consistencia de las estimaciones de precipitación mediante procesos de fusión espacio–temporal y control de calidad de datos (Ruan et al., 2025).

Paralelamente, el crecimiento acelerado del volumen y complejidad de los datos ambientales ha impulsado la adopción de arquitecturas cloud-native orientadas al procesamiento distribuido, almacenamiento desacoplado y escalabilidad bajo demanda. En este escenario, los data cubes ambientales y los formatos científicos multidimensionales han adquirido relevancia para el manejo eficiente de información meteorológica. Aunque formatos tradicionales como NetCDF y HDF5 han sido ampliamente utilizados en aplicaciones de teledetección y ciencias atmosféricas, nuevas alternativas como Zarr han sido diseñadas específicamente para entornos basados en almacenamiento de objetos y acceso concurrente, facilitando procesamiento paralelo, chunking y carga diferida en infraestructuras cloud-native (Faizal, 2024; Gowan et al., 2022). Asimismo, formatos columnares como Parquet permiten optimizar consultas analíticas sobre grandes volúmenes de información geoespacial mediante arquitecturas serverless y motores distribuidos (Bhosale, 2024).

En el contexto nacional, existen antecedentes académicos orientados al procesamiento y visualización de datos de radar meteorológico del IDEAM mediante procesos ETL y plataformas web de monitoreo. Sin embargo, estas soluciones aún operan bajo esquemas parcialmente locales y presentan limitaciones relacionadas con escalabilidad, integración de múltiples fuentes de datos y evaluación comparativa de formatos científicos para almacenamiento y análisis meteorológico. En respuesta a este escenario, la presente investigación propone una arquitectura cloud-native en

AWS para la transformación, almacenamiento, fusión y análisis de datos de radar meteorológico y estaciones meteorológicas públicas. La propuesta incorpora una evaluación comparativa entre los formatos científicos Zarr, NetCDF y HDF5, complementada con una estrategia Zarr-first y una capa analítica en Parquet para consultas eficientes mediante servicios serverless. Asimismo, integra mecanismos de fusión espacio-temporal y control de calidad asistido por Inteligencia Artificial con el fin de establecer una plataforma reproducible, escalable y científicamente robusta para la explotación de datos meteorológicos en Colombia.

## **2.1.Planteamiento del problema**

Actualmente, los datos de radar meteorológico del IDEAM representan una fuente estratégica de información para monitoreo atmosférico, pronóstico del tiempo y análisis hidrometeorológico. Sin embargo, el procesamiento y aprovechamiento de estos datos continúa enfrentando múltiples limitaciones técnicas asociadas al crecimiento del volumen, variedad y velocidad de los datos ambientales (Tran, 2024). Aunque existen procesos ETL y plataformas de visualización desarrolladas en investigaciones previas, estas soluciones operan principalmente bajo esquemas parcialmente locales, con capacidades limitadas de escalabilidad, integración y análisis avanzado de información meteorológica. Adicionalmente, la integración entre datos de radar y estaciones meteorológicas aún presenta desafíos relacionados con trazabilidad, sincronización espacio-temporal y validación cuantitativa de resultados (Jure et al., 2023).

Por otra parte, aunque formatos científicos como NetCDF y HDF5 han sido ampliamente utilizados para almacenamiento de datos multidimensionales, las arquitecturas tradicionales presentan limitaciones frente a escenarios de procesamiento distribuido y almacenamiento orientado a objetos. En este contexto, formatos como Zarr han surgido como alternativas optimizadas para entornos cloud-native debido a su capacidad de acceso paralelo, chunking y procesamiento concurrente sobre grandes volúmenes de datos ambientales (Gowan et al., 2022). No obstante, aún existe limitada evidencia experimental sobre el comportamiento comparativo de estos formatos en aplicaciones de radar meteorológico, especialmente en escenarios que involucren integración con estaciones meteorológicas, procesamiento distribuido y consultas analíticas de gran escala (Faizal, 2024).

Como consecuencia, actualmente no se dispone de una arquitectura integrada que permita transformar datos RAW de radar meteorológico en datasets científicos multidimensionales

escalables, incorporar mecanismos robustos de fusión radar–estaciones y habilitar análisis eficientes mediante capas analíticas optimizadas y servicios serverless. Asimismo, persisten limitaciones relacionadas con evaluación formal de desempeño, latencia, costos operativos y calidad de las estimaciones de precipitación. Frente a esta problemática, surge la necesidad de diseñar una arquitectura cloud-native en AWS que permita evaluar formatos científicos como Zarr, NetCDF y HDF5, integrar procesos de fusión espacio–temporal y aplicar mecanismos de control de calidad asistidos por Inteligencia Artificial, con el propósito de construir una plataforma reproducible, escalable y científicamente robusta para el procesamiento y análisis de datos meteorológicos en Colombia.

## **2.2.Hipótesis**

La implementación de una arquitectura Cloud-Native en AWS que transforme datos RAW de radar en un dataset científico en Zarr, incorpore una capa analítica gobernada en Parquet y realice fusión espacio–temporal con datos de estaciones meteorológicas, mejora la precisión de las estimaciones de precipitación y el desempeño operativo del sistema, evidenciado en la reducción de RMSE, MAE y sesgo, así como en menores tiempos de consulta y consumo de recursos frente a la línea base local.

## **2.3.Objetivos**

### **2.3.1. Objetivo General**

Diseñar una arquitectura Cloud Native asistida por Inteligencia Artificial en AWS que transforme datos RAW de radares meteorológicos en un dataset científico en Zarr y en una capa analítica gobernada (Parquet/Glue/Athena), integrando datos públicos de estaciones meteorológicas (Socrata) para generar estimaciones de lluvia más precisas, con consultas eficientes, trazables y de bajo costo.

### **2.3.2. Objetivos Específicos**

1. Definir el modelo de datos y los principios de diseño Zarr-first (dimensiones, metadatos y versionado) junto con el esquema analítico en Parquet y su catálogo en Glue para consultas en Athena.



2. Proponer y evaluar métodos de fusión de datos entre radar y estaciones meteorológicas (Socrata), cuantificando su impacto en la precisión de las estimaciones de lluvia mediante métricas como RMSE, MAE, sesgo y correlación.
3. Evaluar el desempeño y el costo de la arquitectura propuesta mediante métricas de latencia extremo a extremo, bytes escaneados por consulta y escalabilidad con concurrencia, comparando los resultados con la línea base local.
4. Validar los lineamientos para la orquestación, seguridad y gobierno de datos en AWS mediante la implementación y verificación de mecanismos de mínimo privilegio, linaje y trazabilidad, evaluando su impacto en la reproducibilidad y adopción del sistema.

#### **2.4.Motivación y contexto institucional**

La presente investigación se desarrolla en el marco del grupo de investigación LASER de la Universidad Distrital Francisco José de Caldas, dentro de la línea de Ingeniería de Datos y Computación en la Nube aplicada a Teledetección Meteorológica. Este trabajo da continuidad a una línea de investigación enfocada en el procesamiento y explotación de datos de radar meteorológico del IDEAM, tomando como base dos desarrollos académicos previos orientados a la adquisición, transformación y visualización de información meteorológica. La motivación principal surge de la necesidad de evolucionar estas soluciones hacia una arquitectura cloud-native escalable que permita integrar almacenamiento científico multidimensional, procesamiento distribuido y mecanismos avanzados de análisis y fusión de datos meteorológicos.

Desde una perspectiva práctica y científica, la investigación busca contribuir al fortalecimiento de sistemas de monitoreo atmosférico y gestión del riesgo hidrometeorológico en Colombia. La creciente disponibilidad de datos meteorológicos de alta resolución exige infraestructuras capaces de procesar, almacenar y consultar grandes volúmenes de información de manera eficiente, reproducible y sostenible. En este contexto, la evaluación de formatos científicos como Zarr, NetCDF y HDF5, junto con la integración de datos radar–estaciones y mecanismos de control de calidad asistidos por Inteligencia Artificial, pretende aportar un marco metodológico reutilizable para futuras aplicaciones de observación ambiental y análisis geoespacial en entornos cloud-native.

## **2.5.Organización del documento**

El presente documento se estructura en varios capítulos. Inicialmente, se presenta la introducción, el planteamiento del problema, los objetivos y la justificación de la investigación. Posteriormente, se desarrolla el marco de referencia, abordando conceptos relacionados con radares meteorológicos, arquitecturas cloud-native, formatos científicos multidimensionales, procesos ETL y técnicas de fusión espacio-temporal.

A continuación, se describe la metodología propuesta, incluyendo el diseño de la arquitectura en AWS, la estrategia de almacenamiento científico y la evaluación comparativa entre los formatos Zarr, NetCDF y HDF5. Seguidamente, se presentan los resultados obtenidos, el análisis de desempeño y costos, así como la validación de los mecanismos de integración y procesamiento implementados.

Finalmente, el documento expone las conclusiones de la investigación, las contribuciones realizadas y las posibles líneas de trabajo futuro relacionadas con procesamiento meteorológico distribuido, análisis ambiental escalable y aplicaciones de Inteligencia Artificial sobre datos geoespaciales multidimensionales.

### 3. Marco de Referencia

El presente marco de referencia sitúa el problema de investigación dentro del conocimiento previamente construido en teledetección meteorológica, ingeniería de datos y arquitecturas cloud-native, entregando el contexto conceptual y científico necesario para comprender por qué la integración de datos de radar y estaciones, la adopción de formatos n-dimensionales como Zarr y el uso de una capa analítica gobernada constituyen respuestas pertinentes a los desafíos actuales de volumen, variedad y velocidad en los datos ambientales.

#### 3.1.Marco Conceptual

##### 3.1.1. Radar meteorológico

Un radar meteorológico es un sistema de teledetección activa que emite pulsos electromagnéticos hacia la atmósfera y mide la energía retrodispersada por hidrometeoros como lluvia, granizo o nieve. Su principal ventaja frente a las estaciones meteorológicas tradicionales es la capacidad de generar observaciones espacio-temporales continuas y de alta resolución sobre amplias áreas geográficas, permitiendo el monitoreo de eventos atmosféricos en tiempo casi real (Bringi & Chandrasekar, 2001).

La variable principal utilizada en aplicaciones hidrológicas y meteorológicas es la reflectividad radar, representada en decibelios de reflectividad (dBZ), la cual está relacionada con el tamaño y concentración de partículas precipitantes presentes en la atmósfera (Fabry, 2015). Los radares del IDEAM operan mediante barridos volumétricos denominados *Plan Position Indicator* (PPI), donde cada elevación o *sweep* captura información de precipitación en diferentes alturas atmosféricas.

La relación entre reflectividad y precipitación se expresa comúnmente mediante ecuaciones  $Z-R$ ,  $Z = aR^b$ , donde  $Z$  es la reflectividad del radar,  $R$  la intensidad de precipitación y  $a$  y  $b$  son coeficientes empíricos dependientes del tipo de precipitación.

##### 3.1.2. Datos meteorológicos multidimensionales

Los datos meteorológicos corresponden a estructuras multidimensionales que integran variables espaciales, temporales y físicas. En el caso de radar meteorológico, los datos incluyen dimensiones

como tiempo, rango, azimut, elevación y reflectividad, lo que genera grandes volúmenes de información científica compleja (Hoyer & Hamman, 2017).

El concepto de *data cube ambiental* hace referencia a estructuras organizadas de datos multidimensionales que permiten representar fenómenos atmosféricos de manera consistente y reutilizable para análisis científicos reproducibles (Montero et al., 2025). Este enfoque facilita consultas sobre subconjuntos espaciales, temporales y variables específicas sin necesidad de cargar datasets completos en memoria.

### 3.1.3. Procesos ETL

Los procesos ETL (*Extract, Transform, Load*) son arquitecturas utilizadas para integrar información desde múltiples fuentes heterogéneas, transformarla y cargarla en sistemas de almacenamiento o análisis (Inmon, 2005). En sistemas meteorológicos, los procesos ETL permiten automatizar la descarga, conversión, limpieza, enriquecimiento y persistencia de datos provenientes de radares y estaciones meteorológicas.

En la presente investigación, los procesos ETL constituyen el mecanismo principal para:

- Extraer datos RAW desde AWS S3.
- Transformar archivos IRIS hacia formatos científicos multidimensionales.
- Georreferenciar información radar.
- Integrar datos de estaciones meteorológicas.
- Construir datasets analíticos y científicos reutilizables.

### 3.1.4. Cloud-Native

Las arquitecturas *cloud-native* son modelos de diseño orientados a construir aplicaciones escalables, desacopladas y resilientes sobre infraestructura en la nube (Faizal, 2024). Estas arquitecturas desacoplan almacenamiento y cómputo, permitiendo escalar recursos bajo demanda y procesar grandes volúmenes de datos distribuidos.

En aplicaciones científicas y ambientales, las arquitecturas cloud-native facilitan procesamiento paralelo, acceso concurrente a datasets, automatización basada en eventos, integración con motores analíticos serverless y reducción de costos operativos, entre otros.

### 3.1.5. Formatos científicos multidimensionales

Los formatos científicos multidimensionales permiten almacenar datos complejos junto con metadatos, coordenadas y convenciones de interoperabilidad.

- **NetCDF4:** Es un estándar internacional ampliamente utilizado en ciencias atmosféricas y oceanográficas para representar arreglos multidimensionales etiquetados. (Rew & Davis, 1990) Su principal ventaja es la interoperabilidad con herramientas científicas como MATLAB, Python, R y QGIS.
- **HDF5:** Es un formato jerárquico diseñado para almacenar grandes volúmenes de datos científicos de forma eficiente. Permite organizar datasets, grupos y metadatos dentro de una misma estructura binaria (The HDF Group, 2024).
- **Zarr:** Es un formato orientado a almacenamiento distribuido y acceso concurrente sobre almacenamiento de objetos. Utiliza fragmentación (*chunking*) y compresión independiente por bloques, permitiendo lectura diferida y procesamiento paralelo eficiente sobre infraestructuras cloud-native (Gowan et al., 2022).
- **Apache Parquet:** Es un formato columnar optimizado para consultas analíticas distribuidas. A diferencia de NetCDF o Zarr, Parquet está diseñado principalmente para cargas analíticas SQL y motores distribuidos como Athena y Spark (Bhosale, 2024).

## 3.2.Marco Teórico

### 3.2.1. Teoría de los radares meteorológicos

Los radares meteorológicos funcionan mediante transmisión y recepción de ondas electromagnéticas. La reflectividad se calcula a partir de la energía retrodispersada por partículas precipitantes:

$$Z = \sum_i D_i^6$$

Donde  $D_i$  representa el diámetro de las gotas de lluvia.

La reflectividad en decibelios se expresa como:

$$Z_{dBZ} = 10 \log_{10}(Z)$$

Esta relación permite clasificar intensidad de precipitación (Fabry, 2015):

| dBZ   | Interpretación            |
|-------|---------------------------|
| <20   | Lluvia débil              |
| 20–35 | Lluvia moderada           |
| 35–50 | Lluvia intensa            |
| >50   | Tormenta severa / granizo |

*Tabla 1 Intensidad de precipitación*

### 3.2.2. Fusión espacio–temporal radar–estaciones

La integración de radares y estaciones meteorológicas busca reducir sesgos presentes en estimaciones radar y mejorar consistencia física de precipitación (Ruan et al., 2025).

Las estaciones meteorológicas proporcionan observaciones puntuales de alta precisión, mientras que el radar ofrece cobertura espacial continua. La combinación de ambas fuentes permite construir campos ajustados de precipitación mediante interpolación y validación cruzada.

Las métricas principales utilizadas para validación son:

- Error cuadrático medio (RMSE)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- Error absoluto medio (MAE)

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Sesgo

$$Bias = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$$

Estas métricas permiten evaluar precisión de los productos meteorológicos generados.

### 3.2.3. Procesamiento distribuido y chunking

El procesamiento distribuido divide datasets en bloques independientes llamados *chunks*, permitiendo paralelismo y acceso parcial a información multidimensional (Gowan et al., 2022).

En Zarr, cada chunk puede almacenarse como objeto independiente dentro de S3:

```
dataset/
├── time/0.0
├── reflectivity/0.0.0
├── reflectivity/0.0.1
└── metadata/
```

*Figura 1 Estructura Zarr*

Este enfoque evita descargar datasets completos y reduce significativamente latencia y consumo de memoria.

### 3.2.4. Arquitecturas serverless para analítica meteorológica

Las arquitecturas serverless permiten ejecutar consultas analíticas sin administrar servidores físicos o clústeres dedicados.

#### 3.2.4.1.AWS Athena

Athena es un servicio serverless basado en Presto/Trino que permite consultar datos directamente sobre S3 utilizando SQL estándar (Amazon Web Services, 2024a). Athena trabaja eficientemente sobre formatos columnares como Parquet, reduciendo bytes escaneados y costos.

```
SQL
SELECT radar_name,
       AVG(mean_reflectivity)
FROM radar_statistics
WHERE observation_time BETWEEN
'2025-01-01' AND '2025-01-31'
GROUP BY radar_name;
```

*Figura 2 Ejemplo consulta en AWS Athena*

#### 3.2.4.2.AWS Glue

AWS Glue funciona como catálogo de metadatos y motor ETL administrado. Permite: catalogar datasets, descubrir particiones automáticamente, gestionar esquemas, integrarse con Athena. Glue constituye un componente clave para gobernanza y trazabilidad de datasets científicos (Amazon Web Services, 2024b).

### 3.2.5. Inteligencia Artificial aplicada a meteorología

Las técnicas de Inteligencia Artificial permiten detectar relaciones no lineales entre reflectividad radar y precipitación observada (Verdelho et al., 2024). Modelos como Random Forest, XGBoost, ConvLSTM y U-Net han demostrado capacidad para corrección de sesgos, estimación cuantitativa de precipitación, detección de anomalías y predicción de evolución convectiva.

### 3.3.Marco Espacial

La investigación se desarrolla sobre datos de radar meteorológico del Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) en Colombia. El área de cobertura corresponde a los seis radares operacionales publicados mediante el bucket público `s3-radaresideam` en AWS S3 (Instituto de Hidrología, 2024):

| <b>Radar</b>    | <b>Departamento</b> |
|-----------------|---------------------|
| Guaviare        | Guaviare            |
| Barrancabermeja | Santander           |
| Corozal         | Sucre               |
| Carimagua       | Meta                |
| Tablazo         | Antioquia           |
| Munchique       | Cauca               |

*Tabla 2 Cobertura de Radares IDEAM*

Estos radares cubren regiones estratégicas del territorio colombiano con alta vulnerabilidad hidrometeorológica.

Adicionalmente, la investigación incorpora datos de estaciones meteorológicas públicas obtenidas mediante plataformas de datos abiertos, permitiendo validación cruzada y procesos de fusión espacio–temporal.

La infraestructura tecnológica se despliega sobre Amazon Web Services (AWS), utilizando principalmente Amazon S3, AWS Glue, Athena, ECS/Lambda, EventBridge.



### 3.4.Marco Temporal

La investigación se desarrolla durante el período académico 2025–2026 en el marco de la Maestría en Ciencias de la Información y las Comunicaciones de la Universidad Distrital Francisco José de Caldas.

El estudio utiliza datos históricos y recientes de radar meteorológico del IDEAM almacenados en el bucket público `s3-radaresideam`, específicamente información correspondiente a productos de nivel 2 (L2). La investigación contempla las siguientes etapas temporales:

| <b>Etapas</b> | <b>Actividad</b>                                  |
|---------------|---------------------------------------------------|
| Fase 1        | Revisión bibliográfica y análisis de antecedentes |
| Fase 2        | Diseño arquitectura cloud-native                  |
| Fase 3        | Implementación ETL y transformación de formatos   |
| Fase 4        | Comparación Zarr, NetCDF y HDF5                   |
| Fase 5        | Integración radar–estaciones                      |
| Fase 6        | Evaluación de desempeño y costos                  |
| Fase 7        | Validación y documentación                        |

*Tabla 3Etapas temporales de investigación*

## 4. Diseño de la Arquitectura Cloud-Native

### 4.1. Arquitectura general de la solución

La arquitectura propuesta en esta investigación fue diseñada bajo principios *cloud-native* con el propósito de construir una plataforma escalable, desacoplada y orientada al procesamiento distribuido de datos meteorológicos multidimensionales. La solución busca resolver las limitaciones identificadas en arquitecturas tradicionales basadas en procesamiento local y almacenamiento monolítico, las cuales presentan restricciones importantes frente al crecimiento continuo del volumen y complejidad de los datos ambientales. En este contexto, la arquitectura plantea un enfoque centrado en el desacoplamiento entre almacenamiento y cómputo, permitiendo que los procesos de transformación, análisis y consulta puedan escalar independientemente de la persistencia de los datos.

La propuesta se fundamenta en la construcción de un *Data Lake científico* sobre Amazon Web Services (AWS), donde Amazon S3 actúa como repositorio principal para almacenamiento de datos RAW, datasets científicos multidimensionales y capas analíticas derivadas. Este enfoque permite aprovechar las capacidades de almacenamiento orientado a objetos, acceso concurrente y procesamiento distribuido, características fundamentales para aplicaciones de observación ambiental y análisis geoespacial de gran escala. La arquitectura integra además componentes especializados para automatización ETL, catalogación de metadatos, análisis serverless y observabilidad operacional, con el fin de garantizar reproducibilidad experimental, trazabilidad y eficiencia operacional.

Uno de los principios centrales del diseño corresponde a la estrategia “Zarr-first”, en la cual el formato Zarr se adopta como representación científica principal debido a sus capacidades de fragmentación (*chunking*), carga diferida y acceso paralelo sobre infraestructura basada en objetos. Esta decisión arquitectónica responde a la necesidad de optimizar el procesamiento multidimensional de datos radar sobre entornos cloud-native, permitiendo reducir latencia, minimizar consumo de memoria y habilitar procesamiento concurrente sobre múltiples subconjuntos de información meteorológica. Paralelamente, la arquitectura incorpora una capa analítica derivada en formato Parquet, diseñada específicamente para soportar consultas SQL distribuidas mediante servicios serverless como AWS Athena.

Desde una perspectiva funcional, la arquitectura puede dividirse en seis grandes capas: adquisición de datos, procesamiento ETL, almacenamiento científico, almacenamiento analítico, catalogación y consulta, y finalmente consumo de información mediante APIs y plataformas de visualización. Cada una de estas capas fue diseñada de manera desacoplada con el objetivo de garantizar modularidad, interoperabilidad y facilidad de escalamiento frente a futuras ampliaciones del sistema.




Figura 3 Diagrama de arquitectura a gran escala

## 4.2. Adquisición de datos

La adquisición de datos constituye el punto inicial del flujo de procesamiento propuesto. La investigación utiliza como fuente principal el repositorio público de radares meteorológicos del IDEAM disponible sobre AWS S3, específicamente los productos de nivel 2 (L2), los cuales contienen información volumétrica generada por los radares operacionales distribuidos en diferentes regiones de Colombia. Estos datos son almacenados originalmente en formato propietario IRIS y organizados jerárquicamente por fecha y radar, permitiendo acceder históricamente a grandes volúmenes de observaciones meteorológicas.

El diseño de la capa de adquisición considera la necesidad de automatizar el descubrimiento, descarga y validación de nuevos archivos meteorológicos sin depender de procesos manuales. Para ello, se plantea un componente ETL desacoplado desplegado sobre Amazon ECS Fargate y complementado mediante servicios serverless como AWS Lambda y Amazon EventBridge. Esta combinación permite ejecutar tareas de procesamiento tanto en esquemas batch programados como en flujos automatizados basados en eventos, reduciendo intervención humana y mejorando la capacidad de escalamiento del sistema.

El pipeline de adquisición implementa mecanismos de descarga incremental, validación de duplicados y control de integridad de archivos, permitiendo evitar reprocesamiento innecesario y garantizando consistencia sobre los datasets generados. Asimismo, se incorpora almacenamiento temporal mediante estrategias de caché local utilizando *fsspec* y *simplecache*, optimizando el acceso a archivos remotos y reduciendo latencia durante las fases iniciales del procesamiento ETL.

Además de los datos radar, la arquitectura contempla la integración de estaciones meteorológicas públicas obtenidas mediante plataformas Open Data y APIs basadas en Socrata. Estas estaciones aportan observaciones puntuales de variables atmosféricas como precipitación, temperatura y humedad, las cuales serán utilizadas posteriormente en procesos de validación y fusión espacio-temporal.

## 4.3. Procesamiento ETL

La capa ETL representa el núcleo operacional de la arquitectura propuesta y tiene como objetivo transformar los datos RAW provenientes de radar meteorológico en datasets científicos

estructurados y reutilizables. El diseño de esta capa se basa en principios de procesamiento modular y desacoplado, donde cada etapa del flujo cumple funciones específicas relacionadas con extracción, transformación, enriquecimiento y persistencia de información.

La extracción de datos se realiza directamente desde Amazon S3 mediante bibliotecas como *boto3*, *botocore* y *fsspec*, las cuales permiten acceso eficiente a almacenamiento remoto y manejo de grandes volúmenes de datos distribuidos. Posteriormente, los archivos IRIS son procesados utilizando *xradar*, una biblioteca especializada para lectura de datos radar meteorológicos, complementada con *xarray* para manipulación de arreglos multidimensionales etiquetados. Este enfoque facilita el tratamiento de variables complejas asociadas a dimensiones espaciales, temporales y atmosféricas.

Durante la transformación, la arquitectura ejecuta procesos de georreferenciación radar mediante conversión polar-cartesiana, utilizando información de rango, azimuth y elevación para generar representaciones espaciales compatibles con análisis geográficos posteriores. Asimismo, se extraen metadatos relevantes como tiempo de observación, ubicación del radar, estadísticas de reflectividad y parámetros operacionales del sistema radar.

La arquitectura también incorpora un proceso de enriquecimiento de datos mediante integración con estaciones meteorológicas públicas. Este procedimiento permite realizar alineación espacio-temporal entre observaciones radar y mediciones puntuales, facilitando posteriores etapas de validación y corrección de sesgos en estimaciones de precipitación.

Finalmente, los datasets transformados son persistidos simultáneamente en distintos formatos científicos y analíticos con el fin de soportar la evaluación comparativa propuesta por la investigación. En este sentido, cada producto meteorológico es convertido a NetCDF4, HDF5 y Zarr, permitiendo analizar experimentalmente las ventajas y limitaciones de cada formato frente a escenarios de procesamiento distribuido y almacenamiento cloud-native.

#### **4.4.Almacenamiento científico multidimensional**

Uno de los componentes más importantes de la arquitectura corresponde al diseño del almacenamiento científico multidimensional. La investigación propone abandonar esquemas tradicionales basados exclusivamente en archivos monolíticos y adoptar un enfoque distribuido

orientado a almacenamiento de objetos sobre Amazon S3. Este modelo permite desacoplar completamente almacenamiento y procesamiento, habilitando acceso concurrente y escalamiento horizontal sobre datasets meteorológicos de gran tamaño.

La estrategia “Zarr-first” constituye el eje principal del diseño de almacenamiento científico. A diferencia de formatos tradicionales como NetCDF4 y HDF5, Zarr fragmenta los datasets en pequeños bloques independientes denominados *chunks*, los cuales son almacenados como objetos separados dentro del bucket S3. Este enfoque permite que diferentes procesos puedan acceder simultáneamente a subconjuntos específicos del dataset sin necesidad de descargar el archivo completo, reduciendo significativamente latencia y consumo de memoria.

El diseño de chunking implementado en esta investigación considera dimensiones temporales, espaciales y angulares asociadas a los datos radar. De esta manera, las consultas sobre períodos específicos, regiones geográficas particulares o subconjuntos atmosféricos pueden resolverse accediendo únicamente a los bloques relevantes. Este comportamiento resulta especialmente importante en aplicaciones científicas distribuidas donde los datasets pueden alcanzar tamaños de varios terabytes.

Paralelamente, NetCDF4 y HDF5 son mantenidos dentro de la arquitectura como formatos de comparación experimental. Ambos representan estándares ampliamente utilizados en ciencias atmosféricas y permiten evaluar diferencias relacionadas con tiempos de lectura, escritura, concurrencia, compresión y eficiencia operacional frente al enfoque cloud-native basado en Zarr.

#### **4.5.Capa analítica**

Aunque los formatos científicos multidimensionales resultan adecuados para procesamiento atmosférico y análisis científicos complejos, no son óptimos para cargas analíticas SQL distribuidas. Por esta razón, la arquitectura incorpora una capa analítica independiente basada en Apache Parquet, diseñada específicamente para soportar consultas eficientes sobre grandes volúmenes históricos de información meteorológica.

La transformación hacia Parquet permite convertir datasets científicos en estructuras columnares optimizadas para motores distribuidos como Athena. Este enfoque reduce

considerablemente los bytes escaneados durante las consultas, mejorando tiempos de respuesta y disminuyendo costos operativos asociados al análisis serverless.

Sobre esta capa se integra AWS Glue como catálogo central de metadatos. Glue permite registrar esquemas, descubrir particiones automáticamente y mantener gobernanza sobre datasets analíticos. La arquitectura utiliza particionamiento temporal y espacial con el fin de optimizar consultas históricas relacionadas con radares, fechas y variables meteorológicas específicas.

Athena actúa como motor de consulta serverless sobre la capa Parquet, permitiendo ejecutar consultas SQL directamente sobre Amazon S3 sin necesidad de administrar infraestructura dedicada. Esta capacidad resulta fundamental para aplicaciones científicas donde se requiere explorar rápidamente grandes volúmenes de información meteorológica y generar análisis agregados sobre múltiples años de observación.

#### **4.6.Integración radar – estaciones y validación**

Uno de los principales aportes de la arquitectura corresponde a la integración de datos radar con observaciones provenientes de estaciones meteorológicas públicas. La estimación cuantitativa de precipitación basada exclusivamente en radar puede presentar errores asociados a calibración, atenuación de señal y relaciones reflectividad–lluvia. Por ello, la incorporación de estaciones meteorológicas permite validar y ajustar cuantitativamente los productos generados.

La arquitectura implementa procesos de alineación espacio–temporal entre observaciones radar y estaciones meteorológicas. Este procedimiento considera proximidad geográfica, sincronización temporal y transformación de unidades, permitiendo construir pares comparables entre reflectividad radar y precipitación observada.

La validación cuantitativa se realiza mediante métricas estadísticas ampliamente utilizadas en meteorología y aprendizaje automático, tales como RMSE, MAE, sesgo y correlación. Estas métricas permiten evaluar precisión de las estimaciones y cuantificar el impacto de los procesos de integración y corrección implementados.

Adicionalmente, la arquitectura contempla mecanismos preliminares de control de calidad asistidos por Inteligencia Artificial orientados a identificar anomalías, inconsistencias y patrones atípicos dentro de los datasets meteorológicos. Aunque esta línea no constituye el núcleo principal

de la investigación, representa una extensión relevante hacia futuras aplicaciones de analítica avanzada y modelamiento atmosférico.

#### **4.7.Infraestructura como código y automatización**

Con el fin de garantizar reproducibilidad y despliegue consistente, toda la infraestructura propuesta es administrada mediante Terraform bajo principios de Infraestructura como Código (IaC). La arquitectura se encuentra modularizada en componentes independientes para networking, almacenamiento, procesamiento, seguridad y analítica, permitiendo desacoplamiento y reutilización de configuraciones.

La automatización del procesamiento meteorológico se implementa mediante EventBridge y ECS Fargate, permitiendo ejecutar tareas programadas de adquisición y transformación sin intervención manual. Este enfoque facilita escalabilidad operacional y habilita futuras extensiones orientadas a procesamiento continuo o casi en tiempo real.

La arquitectura incorpora además mecanismos de observabilidad mediante Amazon CloudWatch, permitiendo monitorear logs, métricas y eventos asociados al pipeline ETL y las consultas analíticas. Esto resulta fundamental para evaluar desempeño operacional y garantizar trazabilidad experimental durante las pruebas comparativas de formatos y arquitecturas.



## **5. Implementación**

### **5.1.Implementación general de la solución**

La etapa de implementación tuvo como objetivo materializar la arquitectura cloud-native propuesta en el capítulo anterior, validando su funcionamiento sobre un entorno operativo real en AWS. Mientras el diseño arquitectónico definió la estructura conceptual, las capas funcionales y las decisiones tecnológicas de la solución, la implementación se enfocó específicamente en la construcción, configuración, integración y despliegue de los componentes necesarios para ejecutar el pipeline meteorológico distribuido.

En esta fase se desarrollaron los procesos automatizados de adquisición, transformación y almacenamiento de datos de radar meteorológico, así como la integración con servicios analíticos serverless y mecanismos de catalogación de metadatos. La implementación permitió validar experimentalmente el comportamiento de los formatos NetCDF4, HDF5 y Zarr sobre infraestructura cloud-native, además de construir una capa analítica en Parquet para consultas distribuidas mediante Athena.

A diferencia del capítulo de diseño, que se centra en la arquitectura conceptual y la justificación técnica de los componentes, este capítulo describe el entorno implementado, las tecnologías utilizadas, las configuraciones realizadas y los resultados operacionales obtenidos durante la construcción del sistema.

### **5.2.Entorno de implementación**

La solución fue desplegada sobre Amazon Web Services (AWS) utilizando una arquitectura desacoplada basada en almacenamiento orientado a objetos y procesamiento distribuido. La infraestructura fue administrada mediante Terraform bajo principios de Infraestructura como Código (IaC), permitiendo automatizar el aprovisionamiento de recursos y garantizar reproducibilidad del entorno experimental.

El entorno implementado incluyó componentes para almacenamiento científico, procesamiento ETL, catalogación de metadatos, consultas analíticas y monitoreo operacional. Amazon S3 fue

utilizado como repositorio principal del Data Lake meteorológico, mientras que ECS Fargate permitió ejecutar tareas ETL containerizadas sin necesidad de administrar servidores dedicados.

Para automatizar la ejecución del pipeline se configuraron reglas de Amazon EventBridge orientadas a disparar procesos de ingesta y transformación de datos. Asimismo, CloudWatch fue utilizado para centralizar logs y métricas operacionales relacionadas con tiempos de procesamiento, errores ETL y monitoreo general de la solución.

### **5.3.Implementación del procesamiento ETL**

La implementación del pipeline ETL se realizó completamente en Python utilizando bibliotecas especializadas para procesamiento meteorológico y análisis multidimensional. El proceso inició con la extracción automatizada de archivos RAW desde el bucket público del IDEAM utilizando `boto3` y `fsspec`, lo que permitió acceder directamente a los datos almacenados en AWS S3 sin necesidad de replicarlos completamente en infraestructura local.

Para la lectura de archivos IRIS se utilizó la biblioteca `xrader`, mientras que `xarray` permitió manipular la información meteorológica como arreglos multidimensionales etiquetados. Durante esta etapa se implementaron procesos de decodificación, georreferenciación radar y extracción de variables meteorológicas relevantes como reflectividad, tiempo de observación y coordenadas espaciales.

La transformación de datos incluyó además cálculo de estadísticas descriptivas y generación de estructuras multidimensionales reutilizables. Posteriormente, cada dataset procesado fue exportado simultáneamente a NetCDF4, HDF5 y Zarr, permitiendo mantener equivalencia experimental entre los formatos comparados.



Figura 4 Pipeline ETL implementado

#### 5.4.Implementación del almacenamiento científico

La implementación del almacenamiento científico se desarrolló sobre Amazon S3 utilizando un enfoque basado en Data Lake. Los datasets fueron organizados jerárquicamente separando datos RAW, datasets científicos y capas analíticas derivadas.

Zarr fue implementado como formato científico principal debido a su compatibilidad con arquitecturas cloud-native y su capacidad de acceso concurrente mediante *chunking*. Durante las pruebas realizadas se configuraron distintos tamaños de fragmentación para evaluar el impacto sobre tiempos de lectura y consumo de memoria.

NetCDF4 y HDF5 fueron implementados como formatos equivalentes de comparación experimental. Esto permitió ejecutar pruebas homogéneas relacionadas con escritura, lectura parcial, concurrencia y procesamiento distribuido sobre almacenamiento orientado a objetos.

La estructura final implementada dentro del Data Lake fue la siguiente:



Figura 5 Estructura de almacenamiento en S3

### 5.5.Implementación de la capa analítica

La capa analítica fue implementada mediante Apache Parquet, AWS Glue y Athena con el objetivo de habilitar consultas SQL distribuidas sobre datasets meteorológicos históricos. Para ello, los datasets multidimensionales fueron transformados a estructuras tabulares columnares optimizadas para análisis analítico.

Glue fue configurado como catálogo central de metadatos y particiones, permitiendo registrar automáticamente los datasets generados por el pipeline ETL. Esto facilitó la integración con Athena y simplificó la administración de esquemas analíticos sobre Amazon S3.

Athena permitió ejecutar consultas SQL serverless directamente sobre los datasets Parquet sin necesidad de administrar clústeres dedicados. Durante la implementación se realizaron pruebas relacionadas con agregaciones temporales, análisis de reflectividad promedio y consultas históricas sobre múltiples radares meteorológicos.



*Figura 6 Consulta SQL sobre datos de radar en S3*

### **5.6.Implementación de integración radar – estaciones**

La integración entre radar meteorológico y estaciones meteorológicas fue implementada mediante procesos de alineación espacio–temporal orientados a construir datasets de validación cuantitativa. Para ello, se desarrollaron mecanismos de sincronización temporal y asociación geográfica utilizando coordenadas espaciales y rangos de proximidad.

Esta implementación permitió generar pares comparables entre estimaciones radar y observaciones puntuales de precipitación provenientes de estaciones meteorológicas públicas. Los resultados obtenidos fueron utilizados posteriormente para calcular métricas de validación como RMSE, MAE, sesgo y correlación.

Adicionalmente, se realizaron pruebas preliminares relacionadas con detección de anomalías y validación básica de consistencia sobre los datos integrados.




Figura 7 Integración radar - estaciones

## 6. Resultados y evaluación

La implementación de la arquitectura cloud-native permitió validar experimentalmente la viabilidad de construir una plataforma distribuida para procesamiento y análisis de datos meteorológicos sobre infraestructura AWS. Los resultados preliminares obtenidos evidencian mejoras relacionadas con automatización operativa, desacoplamiento entre almacenamiento y cómputo, capacidad de escalamiento y eficiencia en consultas analíticas históricas frente a esquemas tradicionales basados en procesamiento local.

Durante las pruebas realizadas, el pipeline ETL logró automatizar correctamente la adquisición de archivos RAW provenientes del bucket público del IDEAM, ejecutando procesos de extracción, transformación y persistencia de información meteorológica sobre diferentes formatos científicos multidimensionales. La solución permitió transformar exitosamente archivos IRIS hacia NetCDF4, HDF5 y Zarr utilizando estructuras equivalentes de variables y dimensiones, garantizando condiciones homogéneas para la evaluación experimental.

La arquitectura implementada permitió además construir un Data Lake científico desacoplado sobre Amazon S3, donde los datasets meteorológicos fueron organizados de manera jerárquica y particionada. Esta organización facilitó la ejecución de pruebas relacionadas con acceso concurrente, lectura parcial y procesamiento distribuido sobre almacenamiento orientado a objetos.

Uno de los principales resultados obtenidos corresponde al comportamiento diferencial observado entre los formatos científicos evaluados. NetCDF4 demostró un desempeño sólido en interoperabilidad científica y compatibilidad con herramientas meteorológicas tradicionales. Sin embargo, durante escenarios de acceso concurrente sobre Amazon S3 se identificaron limitaciones relacionadas con su estructura monolítica, especialmente en operaciones de lectura parcial y procesamiento distribuido.

HDF5 presentó mejoras moderadas relacionadas con organización jerárquica y manejo estructurado de datasets complejos. No obstante, su comportamiento sobre arquitecturas orientadas a objetos continuó dependiendo de mecanismos de acceso secuencial y lectura relativamente centralizada, lo que limitó parcialmente su escalabilidad frente a cargas concurrentes distribuidas.

Por otra parte, Zarr evidenció ventajas significativas en escenarios cloud-native debido a su modelo basado en fragmentación independiente (*chunking*) y almacenamiento distribuido. Las pruebas preliminares permitieron observar reducciones en tiempos de lectura parcial, menor consumo de memoria y mejor desempeño frente a consultas concurrentes sobre subconjuntos específicos de información meteorológica.

| Característica evaluada     | NetCDF4  | HDF5       | Zarr   |
|-----------------------------|----------|------------|--------|
| Lectura parcial             | Media    | Media-Alta | Alta   |
| Acceso concurrente          | Bajo     | Medio      | Alto   |
| Compatibilidad cloud-native | Limitada | Parcial    | Alta   |
| Escalabilidad distribuida   | Baja     | Media      | Alta   |
| Integración con S3          | Parcial  | Parcial    | Nativa |
| Uso eficiente de memoria    | Medio    | Medio      | Alto   |
| Procesamiento paralelo      | Bajo     | Medio      | Alto   |

Tabla 4 Comparación de desempeño entre formatos científicos

La siguiente figura presenta conceptualmente la tendencia observada en escenarios de acceso concurrente sobre infraestructura distribuida.




Figura 8 Escalabilidad de formatos científicos en lectura paralela



Otro resultado importante corresponde a la validación de la estrategia “Zarr-first” propuesta en la arquitectura. Las pruebas realizadas mostraron que el modelo de fragmentación multidimensional implementado sobre Zarr permitió acceder únicamente a subconjuntos específicos de datos meteorológicos sin necesidad de descargar datasets completos desde Amazon S3. Esto redujo significativamente la transferencia de información innecesaria y permitió optimizar el comportamiento operacional del sistema frente a consultas espaciales y temporales parciales.

La implementación del chunking multidimensional mostró además que la organización de bloques por tiempo, rango y azimuth mejora considerablemente la eficiencia de acceso para análisis meteorológicos específicos. Esta capacidad representa una ventaja importante frente a arquitecturas tradicionales orientadas a archivos monolíticos.

En relación con la capa analítica, la implementación de Parquet, Glue y Athena permitió validar la viabilidad de ejecutar consultas SQL distribuidas directamente sobre datasets meteorológicos almacenados en Amazon S3. Los resultados preliminares evidenciaron mejoras importantes relacionadas con reducción de bytes escaneados y optimización de tiempos de respuesta en comparación con esquemas tradicionales basados en procesamiento local.

La utilización de Parquet como formato columnar permitió aprovechar mecanismos de compresión y *predicate pushdown*, reduciendo significativamente el volumen de información procesada durante las consultas. Adicionalmente, el particionamiento temporal implementado facilitó ejecutar análisis históricos sobre grandes volúmenes de datos meteorológicos sin necesidad de cargar datasets completos en memoria.

Athena demostró ser una alternativa eficiente para exploración analítica y generación de estadísticas meteorológicas distribuidas. Durante las pruebas realizadas fue posible ejecutar consultas relacionadas con reflectividad promedio, agregaciones temporales y análisis históricos sobre múltiples radares meteorológicos utilizando únicamente SQL serverless.

| <b>Métrica evaluada</b>           | <b>Resultado preliminar</b>   |
|-----------------------------------|-------------------------------|
| Tiempo de respuesta SQL           | Reducción significativa       |
| Bytes escaneados                  | Optimización mediante Parquet |
| Escalabilidad                     | Alta                          |
| Administración de infraestructura | Mínima                        |
| Integración con S3                | Nativa                        |
| Consultas históricas              | Eficientes                    |
| Procesamiento distribuido         | Validado                      |

*Tabla 5 Resultados de la capa analítica*

La integración entre radar meteorológico y estaciones meteorológicas públicas permitió construir un conjunto inicial de validación cuantitativa orientado a evaluar la consistencia de las estimaciones derivadas de reflectividad radar. Durante las pruebas realizadas se implementaron procesos de alineación espacio-temporal y asociación geográfica entre observaciones radar y registros puntuales de precipitación.

Los resultados preliminares muestran que la incorporación de estaciones meteorológicas facilita identificar sesgos presentes en las estimaciones radar y permite construir mecanismos básicos de validación cuantitativa. Las métricas RMSE, MAE y sesgo demostraron utilidad para cuantificar diferencias entre observaciones puntuales y estimaciones espaciales generadas por radar.

Adicionalmente, las pruebas operacionales permitieron validar la capacidad de automatización del pipeline ETL y la estabilidad general de la arquitectura desplegada sobre AWS. La utilización de EventBridge, ECS Fargate y CloudWatch facilitó automatizar tareas de adquisición y monitoreo operacional sin necesidad de intervención manual constante.

Finalmente, los resultados preliminares obtenidos evidencian que la arquitectura implementada constituye una base viable y escalable para procesamiento meteorológico multidimensional sobre infraestructura cloud-native. Asimismo, la combinación entre Zarr, Parquet, Glue y Athena

demostró potencial significativo para futuras aplicaciones científicas relacionadas con observación atmosférica distribuida, análisis geoespacial y procesamiento ambiental de gran escala.

## 7. Discusión

Los resultados obtenidos durante la implementación y evaluación experimental evidencian que las arquitecturas cloud-native representan una alternativa viable para el procesamiento y explotación de grandes volúmenes de datos meteorológicos multidimensionales. La investigación permitió identificar limitaciones importantes asociadas a esquemas tradicionales basados en procesamiento local y almacenamiento monolítico, particularmente frente a escenarios de acceso concurrente, crecimiento histórico de datos y procesamiento distribuido.

Uno de los hallazgos más relevantes corresponde al comportamiento observado en Zarr frente a NetCDF4 y HDF5. Aunque NetCDF4 continúa siendo un estándar ampliamente adoptado en ciencias atmosféricas debido a su interoperabilidad y compatibilidad con herramientas científicas tradicionales, sus limitaciones frente a arquitecturas orientadas a objetos se hacen evidentes cuando se requiere acceso concurrente y procesamiento parcial sobre datasets de gran tamaño.

En este contexto, Zarr demostró ventajas importantes relacionadas con fragmentación independiente, reducción de transferencia innecesaria de datos y compatibilidad nativa con almacenamiento distribuido sobre Amazon S3. Estos resultados coinciden con tendencias recientes observadas en ecosistemas científicos cloud-native, donde la fragmentación multidimensional y el desacoplamiento entre almacenamiento y cómputo se convierten en elementos fundamentales para aplicaciones geoespaciales de gran escala.

La investigación también permitió validar la importancia de separar el almacenamiento científico multidimensional de las cargas analíticas distribuidas. La incorporación de Parquet como capa analítica independiente facilitó optimizar consultas SQL históricas mediante Athena, reduciendo costos operativos y simplificando la exploración analítica de información meteorológica.

Otro aspecto importante corresponde a la integración radar–estaciones. Aunque esta etapa fue desarrollada de manera preliminar dentro del alcance actual de la investigación, los resultados muestran que la incorporación de estaciones meteorológicas permite construir mecanismos cuantitativos de validación y representa una base importante para futuros procesos de corrección de sesgos y modelamiento atmosférico asistido por Inteligencia Artificial.

Desde una perspectiva arquitectónica, la investigación demuestra que la adopción de servicios serverless y almacenamiento orientado a objetos reduce significativamente la complejidad operacional asociada al mantenimiento de infraestructura meteorológica distribuida. La utilización de AWS Glue, Athena y Amazon S3 permitió construir una plataforma reproducible y escalable sin necesidad de administrar clústeres dedicados de procesamiento analítico.

No obstante, la investigación presenta algunas limitaciones. Las pruebas experimentales fueron ejecutadas principalmente sobre datasets correspondientes al primer ángulo de elevación (*sweep\_0*), por lo que futuras extensiones podrían incorporar procesamiento multi-sweep y análisis volumétricos más complejos. Asimismo, aunque se realizaron pruebas preliminares de integración radar–estaciones, aún existen oportunidades para incorporar modelos avanzados de fusión espacio–temporal y aprendizaje automático.

En términos generales, los resultados obtenidos permiten concluir que la arquitectura propuesta constituye una base sólida para futuras plataformas meteorológicas distribuidas orientadas a observación ambiental, análisis geoespacial y procesamiento científico escalable sobre infraestructura cloud-native.

## 8. Conclusiones

La presente investigación permitió diseñar, implementar y evaluar preliminarmente una arquitectura cloud-native orientada al procesamiento y análisis distribuido de datos meteorológicos provenientes de radares del IDEAM y estaciones meteorológicas públicas.

Los resultados obtenidos evidencian que el uso de arquitecturas desacopladas basadas en Amazon S3, procesamiento ETL distribuido y servicios serverless facilita la construcción de plataformas escalables para almacenamiento y explotación de grandes volúmenes de información meteorológica multidimensional.

La comparación experimental entre NetCDF4, HDF5 y Zarr permitió identificar diferencias significativas relacionadas con acceso concurrente, procesamiento distribuido y compatibilidad cloud-native. En particular, Zarr mostró ventajas importantes frente a escenarios de almacenamiento orientado a objetos y acceso parcial sobre datasets multidimensionales, validando su potencial como formato científico principal dentro de arquitecturas meteorológicas modernas.

Asimismo, la incorporación de una capa analítica basada en Parquet, Glue y Athena permitió construir mecanismos eficientes para consultas SQL distribuidas sobre datasets históricos, demostrando la viabilidad de integrar procesamiento científico y analítica serverless dentro de una misma arquitectura.

La integración preliminar entre radar meteorológico y estaciones públicas permitió además establecer una base cuantitativa para validación de estimaciones de precipitación mediante métricas como RMSE, MAE y sesgo, abriendo posibilidades para futuros procesos de corrección y análisis avanzado.

Finalmente, la investigación contribuye al desarrollo de arquitecturas reproducibles y escalables para procesamiento ambiental distribuido, proporcionando un framework técnico y metodológico que puede ser extendido hacia futuras aplicaciones de observación atmosférica, analítica geoespacial e Inteligencia Artificial sobre datos meteorológicos multidimensionales.

## 9. Trabajo Futuro

Como líneas de trabajo futuro, se propone ampliar la arquitectura implementada hacia procesamiento multi-sweep y análisis volumétrico completo de datos radar, permitiendo incorporar información atmosférica de múltiples elevaciones y mejorar la representación tridimensional de fenómenos meteorológicos.

Asimismo, futuras investigaciones podrían integrar motores distribuidos como Dask o Apache Spark con el objetivo de optimizar procesamiento paralelo sobre datasets meteorológicos de gran escala y habilitar análisis en tiempo casi real.

Otra línea importante corresponde a la incorporación de modelos avanzados de Inteligencia Artificial y aprendizaje profundo orientados a estimación cuantitativa de precipitación, corrección de sesgos y predicción de evolución convectiva utilizando secuencias temporales de reflectividad radar.

También se plantea la posibilidad de evolucionar la arquitectura hacia un enfoque tipo *Lakehouse meteorológico*, integrando almacenamiento científico, analítica distribuida y capacidades transaccionales sobre plataformas modernas de procesamiento ambiental.

Finalmente, futuras extensiones podrían incorporar integración con datos satelitales, modelos numéricos de predicción atmosférica y sistemas de monitoreo hidrológico, fortaleciendo la capacidad analítica de la plataforma y ampliando su aplicabilidad dentro de escenarios de gestión del riesgo y observación ambiental distribuida.

## 10. Referencias

- Amazon Web Services. (2024a). *Amazon Athena User Guide*. <https://docs.aws.amazon.com/athena/>.
- Amazon Web Services. (2024b). *AWS Glue User Guide*. <https://docs.aws.amazon.com/glue/>.
- Bhosale, P. (2024). Parquet's Columnar Storage Advantage: A Case Study in Big Data Analytics. In *International Journal on Science and Technology*.
- Bringi, V. N., & Chandrasekar, V. (2001). *Polarimetric Doppler Weather Radar: Principles and Applications*. Cambridge University Press.
- Copete, J. (2023). *Uso de radares meteorológicos como herramienta para la Gestión del Riesgo y monitoreo dentro de los Sistemas de Alerta Temprana (SAT)*.
- Fabry, F. (2015). *Radar Meteorology: Principles and Practice*. Cambridge University Press.
- Faizal, A. (2024). *Building Scalable Data Lakes in the Cloud for Big Data Integration: Utilizing Amazon S3 and Apache Hadoop* (Vol. 9).
- Gowan, T. A., Horel, J. D., Jacques, A. A., & Kovac, A. (2022). Using Cloud Computing to Analyze Model Output Archived in Zarr Format. *Journal of Atmospheric and Oceanic Technology*, 39(4), 449–462. <https://doi.org/10.1175/JTECH-D-21-0106.1>
- Hoyer, S., & Hamman, J. (2017). xarray: N-D labeled Arrays and Datasets in Python. *Journal of Open Research Software*, 5, 1–6.
- Inmon, W. H. (2005). *Building the Data Warehouse* (4th ed.). Wiley.
- Instituto de Hidrología, M. y E. A. (2024). *Repositorio Público de Radares Meteorológicos en AWS S3*. <https://www.ideam.gov.co/>.
- Jure, P. V. R., Cabral, J. B., & Masuelli, S. (2023). *ETL for the integration of remote sensing data*. <http://arxiv.org/abs/2306.11164>
- Montero, D., Kraemer, G., Angheloa, A., Aybar, C., Brandt, G., Camps-Valls, G., Cremer, F., Flik, I., Gans, F., Habershon, S., Ji, C., Kattenborn, T., Martínez-Ferrer, L., Martinuzzi, F., Reinhardt, M., Söchting, M., Teber, K., & Mahecha, M. D. (2025). Earth System Data Cubes:



- Avenues for advancing Earth system research. In *Environmental Data Science* (Vol. 3). Cambridge University Press. <https://doi.org/10.1017/eds.2024.22>
- Rew, R., & Davis, G. (1990). NetCDF: An Interface for Scientific Data Access. *IEEE Computer Graphics and Applications*, 10, 76–82.
- Ruan, F., Chen, F., Liu, Q., & Song, Z. (2025). Fusion of satellite and gauge precipitation observations through coupling spatio-temporal properties with tree-based machine learning. *Journal of Hydrology*, 663. <https://doi.org/10.1016/j.jhydrol.2025.134240>
- The HDF Group. (2024). *Hierarchical Data Format Version 5 (HDF5)*. <https://www.hdfgroup.org/solutions/hdf5/>.
- Tran, T. (2024). *In-depth Analysis and Evaluation of ETL Solutions for Big Data Processing*.
- Verdelho, F. F., Beneti, C., Pavam, L. G., Calvetti, L., Oliveira, L. E. S., & Zanata Alves, M. A. (2024). Quantitative Precipitation Estimation Using Weather Radar Data and Machine Learning Algorithms for the Southern Region of Brazil. *Remote Sensing*, 16(11). <https://doi.org/10.3390/rs16111971>