



Universidad Distrital Francisco José de Caldas

**Maestría en Ciencias de la Información y las
Comunicaciones**

**Desarrollo de un modelo de predicción de
consumo de energía en comunidades ZNI a través
de Inteligencia Artificial**

Johan Nicolás Cuellar Salinas

Trabajo de investigación/grado para optar el título de
Magíster en Ciencias de la Información y las Comunicaciones

Directores:

Elvis Eduardo Gaona García, PhD
Diego Julián Rodríguez Patarroyo, PhD

Bogotá D.C. - Colombia

2026

Dedicatoria

Dedicado a Inés, Rosalba y Lucy, por enseñarme a vivir, esforzarme y amar.

Agradecimientos

A todos los que han estado en este camino enseñándome, escuchándome y apoyándome, a su paciencia y cariño les debo este logro.

Resumen

La garantía de un suministro eléctrico estable en regiones remotas es un motor indispensable para el progreso social y económico; sin embargo, en el contexto colombiano, las Zonas No Interconectadas (ZNI) sufren de una precariedad energética persistente (Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024). Estas comunidades dependen mayoritariamente de una generación térmica basada en diésel que, además de su alto costo operativo, presenta serias limitaciones en la calidad de la información telemétrica disponible (Bernal Suárez et al., 2024; Ministerio de Minas y Energía, 2024). La presente investigación se propuso superar la brecha de incertidumbre en la planificación energética de estas zonas mediante el diseño y validación de un marco predictivo basado en técnicas avanzadas de Inteligencia Artificial (IA), adaptado específicamente a las restricciones de datos y la volatilidad operativa de las micro-redes rurales.

Metodológicamente, el estudio implementó una arquitectura de datos escalable bajo el paradigma Medallion (*Medallion Architecture*), la cual permitió transformar registros fragmentados y heterogéneos del Instituto de Planificación y Promoción de Soluciones Energéticas (IPSE) y el Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) en una matriz de características (*feature matrix*) de alta fidelidad. Se desarrollaron y contrastaron tres aproximaciones de modelado: modelos estadísticos lineales (ARIMA/ARIMAX), modelos de ensamble tabular (XG-Boost) y arquitecturas de Aprendizaje Profundo (*Deep Learning*), específicamente redes de Memoria a Corto y Largo Plazo (*Long Short-Term Memory – LSTM*). Para abordar los desafíos estructurales de las ZNI, se introdujeron innovaciones como la normalización por anclas móviles y el uso de Incrustaciones de Proximidad Geográfica (*Geographic Proxy Embeddings*), diseñados para permitir que el sistema realice pronósticos efectivos incluso en asentamientos con mínima instrumentación histórica mediante el aprendizaje por transferencia o arranque en frío (*Zero-Shot*).

Los hallazgos principales confirmaron la superioridad de la red neuronal LSTM, la cual logró un Error Absoluto Medio Normalizado (nMAE) global del 5.01 % para el año de prueba 2025, demostrando una capacidad excepcional para asimilar interacciones no lineales entre variables climáticas y demanda eléctrica.

Un aporte significativo del trabajo fue la identificación y resolución de la Paradoja de Simpson (*Simpson's Paradox*) observada en los datos nacionales; este fenómeno estadístico causaba que las tendencias de consumo se invirtieran según la escala de la red (donde los grandes centros urbanos consumen más en días laborales mientras que los pequeños asentamientos lo hacen en festivos), lo cual confundiría a modelos tradicionales. El modelo desarrollado logró integrar estas tendencias opuestas en una sola arquitectura global de manera autónoma. Se concluye que el sistema se posiciona como una herramienta de soporte estratégica para entidades gubernamentales y educativas en la estructuración de proyectos de energía renovable y la implementación de la Transición Energética Justa (TEJ) en Colombia.

Palabras clave: Zonas No Interconectadas (ZNI), Aprendizaje Profundo (*Deep Learning*), Redes LSTM, Predicción de Demanda, Arquitectura Medallion, Transición Energética Justa.

Abstract

Ensuring a stable electricity supply in remote regions is an indispensable driver for social and economic progress; however, in the Colombian context, Non-Inter-connected Zones (ZNI – *Zonas No Interconectadas*) suffer from persistent energy precariousness (Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024). These communities mostly rely on diesel-based thermal generation which, beyond its high operating costs, faces serious limitations regarding the quality of available telemetry information (Bernal Suárez et al., 2024; Ministerio de Minas y Energía, 2024). This research aimed to overcome the uncertainty gap in energy planning for these areas by designing and validating a predictive framework based on advanced Artificial Intelligence (AI) techniques, specifically adapted to the data constraints and operational volatility of rural microgrids.

Methodologically, the study implemented a scalable data architecture under the Medallion paradigm (*Medallion Architecture*), which allowed for the transformation of fragmented and heterogeneous records from the Institute for Planning and Promotion of Energy Solutions (IPSE) and the Institute of Hydrology, Meteorology, and Environmental Studies (IDEAM) into a high-fidelity feature matrix. Three modeling approaches were developed and compared: linear statistical models (ARIMA/ARIMAX), tabular ensemble models (XGBoost), and Deep Learning architectures, specifically Long Short-Term Memory (LSTM) networks. To address the structural challenges of the ZNI, innovations such as moving anchor normalization and the use of Geographic Proxy Embeddings were introduced, designed to enable the system to perform effective forecasting even in settlements with minimal historical instrumentation through transfer learning or cold-start (*Zero-Shot*) approaches.

The main findings confirmed the superiority of the LSTM neural network, which achieved a global Normalized Mean Absolute Error (nMAE) of 5.01 % for the 2025 test year, demonstrating an exceptional ability to assimilate non-linear interactions between climate variables and electricity demand.

A significant contribution of this work was the identification and resolution of Simpson’s Paradox observed in the national data; this statistical phenomenon caused consumption trends to invert based on the grid scale (where large urban hubs consume more on workdays while small settlements do so on holidays), which would

confuse traditional models. The developed model successfully integrated these opposing trends into a single global architecture autonomously. It is concluded that the system serves as a strategic support tool for governmental and educational entities in structuring renewable energy projects and implementing the Just Energy Transition (TEJ – *Transición Energética Justa*) in Colombia.

Keywords: Non-Interconnected Zones (ZNI), Deep Learning, LSTM Networks, Demand Forecasting, Medallion Architecture, Just Energy Transition.

Introducción

El progreso social y económico de una nación está intrínsecamente relacionado con la disponibilidad de fuentes confiables de energía. Aun así, lograr esta disponibilidad de forma global es un reto que no se ha logrado conseguir, y en este panorama, países en vías de desarrollo como Colombia enfrentan dificultades severas. Fuentes de energía poco predecibles, afectan de forma directa el crecimiento económico y el desarrollo de iniciativas sociales, educativas e industriales (Fasipe et al., 2024). Dentro de Colombia, las Zonas No Interconectadas (ZNI) representan un 51 % del área geográfica total, allí los retos referentes a la disponibilidad de energía eléctrica son particularmente severos (Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024). Los residentes de estas zonas generalmente viven en pobreza energética, lo que traduce en poco acceso a fuentes consistentes de energía, la dependencia de fuentes de generación a base de diésel resulta en costos operacionales altos, problemas ambientales y comúnmente, horarios limitados de disponibilidad de servicio eléctrico, lo que directamente impide mejoras en las condiciones de vida de la población a su vez que restringe las economías locales (Bernal Suárez et al., 2024; Ministerio de Minas y Energía, 2024).

Afrontar estos déficits de energía, especialmente dentro del marco de las metas para la Transición Energética Justa en Colombia (TEJ), demanda una planeación meticulosa y la optimización en el despliegue de los recursos, ambas cosas dependen directamente de la habilidad para predecir de manera acertada el consumo futuro de energía (Gebre et al., 2024). Estas proyecciones son indispensables para cualquier proyecto energético, particularmente para sistemas no conectados a la red eléctrica general, donde resulta crítico evitar tanto la sobreestimación como la subestimación de las necesidades, esto con miras a lograr la viabilidad económica del proyecto y su éxito operacional (Rushman et al., 2019).

Las metodologías para proyectar el consumo energético de comunidades han avanzado más allá de los modelos estadísticos simples (Wang et al., 2021). Mientras técnicas de regresiones lineales han sido estudiadas y en algunos casos son aplicadas (Madhusudanan, 2019) comúnmente se quedan cortas al capturar dinámicas complejas y no-linealidades presentes en los datos de uso reales de energía eléctrica (Qiao et al., 2023). Consecuentemente, las aproximaciones basadas en datos que usan Apre-

dizaje Automático (ML) y Aprendizaje Profundo (DL) han ganado terreno. Algoritmos como Support Vector Machine (SVM), Random Forest (RF), Gradient Boosting Machine (GBM) y Long Short Term Memory (LSTMs) ofrecen capacidades mejoradas para el modelamiento de patrones temporales complejos influenciados por factores diversos como el clima y la actividad de los usuarios (Cabiddu et al., 2024; Jawad et al., 2020; Wang et al., 2021). Estos métodos han mostrado ser exitosos en varios contextos, desde edificaciones individuales hasta ciudades enteras (Gellert et al., 2024). Al tiempo, incluir información meteorológica (temperatura y humedad, por ejemplo) a estos sistemas ha mostrado ser beneficioso para el mejoramiento de la predicción (Jawad et al., 2020).

Sin embargo, la predicción de consumo de energía eléctrica en asentamientos urbanos aislados dentro de las ZNI de Colombia permanecía sin desarrollos significativos (Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024). Como se puede notar en estudios hechos en ambientes similares al colombiano, obtener datos históricos confiables de consumo en estas comunidades resulta difícil (Herraiz-Cañete et al., 2022; Rushman et al., 2019). Además, el comportamiento de consumo en estas áreas está comúnmente moldeado por prácticas culturales únicas y realidades socioeconómicas diversas (Molina et al., 2018), lo que demandaba un algoritmo hecho a la medida de estas características en vez de uno general que no tuviera en cuenta ninguno de los matices ya mencionados.

Por lo tanto, esta tesis de maestría, la cual contribuyó a un trabajo doctoral más grande enfocado a la aplicación de IA para la estimación de potenciales energéticos, se enfocó en desarrollar un modelo de ML/DL que predijera el consumo eléctrico de forma acertada en comunidades aisladas dentro del territorio colombiano. El trabajo aquí planteado apuntó a la creación de una herramienta predictiva que incorporara las dinámicas de consumo y factores ambientales locales. El desarrollo exitoso de dicho modelo ofrece más información para la planeación energética local, apoya el despliegue de tecnologías de energía renovable y contribuye a la reducción de la pobreza energética con lo cual se espera mejorar la calidad de vida en las Zonas No Interconectadas del país.

Índice general

Dedicatoria	I
Agradecimientos	II
Resumen	III
Abstract	V
Introducción	VII
Lista de Símbolos y Abreviaturas	XIV
1. Contexto	1
1.1. Planteamiento del Problema	1
1.2. Justificación	3
1.3. Objetivos	6
1.3.1. Objetivo General	6
1.3.2. Objetivos Específicos	7
1.4. Hipótesis	7
2. Marco de Referencia	8
2.1. Estado del Arte	8
2.2. Marco Teórico	11
3. Metodología	19
3.1. Caracterización y Selección de Datos	19
3.1.1. Origen de los Datos de Demanda Energética (IPSE)	19
3.1.2. Origen de los Datos Climatológicos (IDEAM)	22
3.2. Arquitectura de Datos y Preprocesamiento	23
3.2.1. Adquisición y Origen de la Información	23
3.2.2. Capa Bronce: Extracción y Preservación de Datos Crudos	25
3.2.3. Capa Plata: Limpieza, Tipificación y Validación Física	26
3.2.4. Capa Oro: Sincronización Espaciotemporal e Imputación Multinivel	27

3.3. Modelo Estadístico Base (ARIMA y ARIMAX)	31
3.4. Ensamble de Árboles de Decisión (XGBoost)	35
3.5. Redes Neuronales Recurrentes (LSTM)	39
3.6. Evaluación y Reconstrucción	51
3.6.1. Post-procesamiento y Derivación de Potencias Dependientes . .	51
3.6.2. Métricas de Desempeño Unificadas	51
4. Resultados y Discusión	53
4.1. Análisis Exploratorio de Datos (EDA) y Perfilamiento de Arquetipos . .	53
4.1.1. Diagnóstico de Infraestructura y Calidad de Datos	53
4.1.2. Dinámica Sociológica y la Paradoja de Simpson	55
4.1.3. Perfil de Sensibilidad Climática y Multicolinealidad	55
4.1.4. Selección de Arquetipos y Estrategia de Evaluación Dual	59
4.1.5. Conclusiones de la Fase Exploratoria	62
4.2. Desempeño de los Modelos	62
4.2.1. Precisión Global y Capacidad de Generalización a Escala	62
4.2.2. Análisis de Arquetipos y Perfilamiento Sociológico	63
4.2.3. La Trampa de las Métricas y la Captura de Picos	68
4.2.4. Robustez ante Datos Ausentes y Zero-Shot	69
4.3. Discusión: Viabilidad en el Contexto ZNI	70
4.3.1. Impacto Operativo y Eficiencia en la Gestión de Recursos	71
4.3.2. Escalabilidad Arquitectónica y Alternativas Costo-Efectivas . .	71
4.3.3. La Ventaja Estratégica del Arranque en Frío (Zero-Shot)	72
4.3.4. Reconocimiento de los Límites Estructurales y Socioeconómicos	72
5. Conclusiones y Trabajo Futuro	74
5.1. Conclusiones	74
5.2. Trabajo Futuro	75
Referencias Bibliográficas	78
A. Anexos	84
A.1. Guía de Arquitectura Computacional	84

Índice de figuras

3.1. Ejemplo del formato de reporte moderno y compacto emitido por el IP-SE, caracterizado por una disposición horizontal de las variables eléctricas.	20
3.2. Estructura tabular de datos energéticos carente de la columna o fila de horas de servicio.	21
3.3. Estructura tabular estandarizada que incluye de manera explícita el conteo de horas operativas.	21
3.4. Resumen ejecutivo en texto continuo, del cual el algoritmo debió inferir las horas promedio mensuales de servicio mediante procesamiento de lenguaje natural cuando la tabla carecía de este dato.	22
3.5. Flujo de procesamiento de datos (ETL) basado en la arquitectura Medallion.	24
3.6. Imagen ilustrativa de la diferencia climática entre municipios cercanos en latitud y longitud pero con diferencia de altitud significativa.	30
3.7. Esquema de partición temporal 80/20 y selección de la isla de continuidad para modelos estadísticos base.	35
3.8. Esquema de ingeniería de características, creación de rezagos temporales y promedios móviles para modelos tabulares.	36
3.9. Arquitectura de evaluación de retención espacial (<i>Spatial Holdout</i>) para predicción cero-shot en XGBoost.	40
3.10. Topología del modelo LSTM, ilustrando las capas de entrada, incrustaciones espaciales (<i>embeddings</i>), recurrencia y cabeza de regresión final.	45
3.11. Algoritmo de segmentación por Islas Temporales para la mitigación de vacíos de datos y generación estructurada de tensores.	47
4.1. Radiografía de intermitencia y fallos en la telemetría de las ZNI.	54
4.2. Perfil de calidad y proporción de datos reales frente a imputados.	54
4.3. Variación sociológica y demostración de la Paradoja de Simpson en el consumo por estratos.	56
4.4. Matriz de correlación global entre variables climáticas y de consumo.	57
4.5. Sensibilidad climática segmentada por tamaño de demanda.	58

4.6. Espacio de selección de arquetipos para evaluación predictiva macro y zero-shot.	60
4.7. Gráficas de dispersión (scatter plots) comparativas de la capacidad de generalización espacial. Panel izquierdo: LSTM. Panel derecho: XG-Boost.	64
4.8. Pronóstico con modelos de línea base estadística (ARIMA y ARIMAX) para el Arquetipo A (Providencia).	65
4.9. Pronóstico con modelos de línea base estadística (ARIMA y ARIMAX) para el Arquetipo C (Gálvez).	65
4.10. Pronóstico con modelos de línea base estadística (ARIMA y ARIMAX) para el Arquetipo B (Uribe Uribe).	66
4.11. Comparativa de predicción en redes de alta escala y estabilidad (Arquetipo A Primario - Providencia).	66
4.12. Comparativa de predicción bajo alta sensibilidad climática (Arquetipo C Primario - Gálvez).	67
4.13. Comparativa de predicción en entornos de micro-demanda y extrema volatilidad (Arquetipo B Primario - Uribe Uribe).	67
4.14. Ajuste de ciclos sociológicos frente a la distorsión de métricas de error generada por apagones estructurales en Piñuña Negra.	68
4.15. Evaluación de extrapolación por Arranque en Frío (Zero-Shot) en el Arquetipo A (Leticia).	69
4.16. Evaluación de extrapolación climática por Arranque en Frío (Zero-Shot) en el Arquetipo C (Cachicamo).	70
4.17. Límite predictivo ante fallos físicos de red en escenario Zero-Shot (Arquetipo B - San Roque).	70

Índice de tablas

3.1. Jerarquía de Estrategias de Imputación Multinivel para Variables Meteorológicas y de Consumo.	28
3.2. Diccionario de variables que conforman la matriz final de entrenamiento (Capa Oro).	31
3.3. Resumen de parámetros y justificación técnica para la configuración del modelo ARIMAX.	33
4.1. Correlación de Spearman entre variables climáticas y potencia activa segmentada por tamaño de demanda.	58
4.2. Arquetipos primarios y espejos seleccionados para la validación predictiva macro y prueba de Arranque en Frío (Zero-Shot).	61
4.3. Comparativa de desempeño predictivo global a nivel nacional para el año de prueba 2025.	63
4.4. Desempeño predictivo segmentado por Arquetipo Operativo en escenarios Primarios y de Arranque en Frío (Zero-Shot).	64

Lista de Símbolos y Abreviaturas

Abreviaturas Técnicas y Acrónimos

- ADF** Prueba de Dickey-Fuller Aumentada (*Augmented Dickey-Fuller Test*).
- AMI** Infraestructura de Medición Inteligente (*Advanced Metering Infrastructure*).
- ARIMA** Modelo Autorregresivo Integrado de Media Móvil (*Autoregressive Integrated Moving Average*).
- ARIMAX** Modelo ARIMA con Variables Exógenas (*ARIMA with Exogenous variables*).
- BESS** Sistemas de Almacenamiento de Energía con Baterías (*Battery Energy Storage Systems*).
- DL** Aprendizaje Profundo (*Deep Learning*).
- EDA** Análisis Exploratorio de Datos (*Exploratory Data Analysis*).
- ETL** Extracción, Transformación y Carga (*Extract, Transform, and Load*).
- GELU** Unidad Lineal de Error Gaussiano (*Gaussian Error Linear Unit*).
- IDEAM** Instituto de Hidrología, Meteorología y Estudios Ambientales.
- IPSE** Instituto de Planificación y Promoción de Soluciones Energéticas.
- k-NN** k-Vecinos más Próximos (*k-Nearest Neighbors*).
- KPSS** Prueba de Kwiatkowski-Phillips-Schmidt-Shin.
- LSTM** Memoria a Corto y Largo Plazo (*Long Short-Term Memory*).
- MAE** Error Absoluto Medio (*Mean Absolute Error*).
- ML** Aprendizaje Automático (*Machine Learning*).
- MLOps** Operaciones de Aprendizaje Automático (*Machine Learning Operations*).
- nMAE** Error Absoluto Medio Normalizado (*Normalized Mean Absolute Error*).

nRMSE Raíz del Error Cuadrático Medio Normalizada (*Normalized Root Mean Square Error*).

OCR Reconocimiento Óptico de Caracteres (*Optical Character Recognition*).

RMSE Raíz del Error Cuadrático Medio (*Root Mean Square Error*).

SIN Sistema Interconectado Nacional.

TEJ Transición Energética Justa.

XGBoost Aumento de Gradiente Extremo (*Extreme Gradient Boosting*).

ZNI Zonas No Interconectadas.

Símbolos y Variables Matemáticas

P	Potencia Activa (medida en kW).
Q	Potencia Reactiva (medida en kVAR).
S	Potencia Aparente (medida en kVA).
y_t	Valor de la variable objetivo en el tiempo t .
$\hat{y}$	Valor predicho por el modelo.
Y_{ancla}	Valor referencial (promedio móvil) para la normalización del objetivo.
ϵ_t	Término de error o residuo en el tiempo t .
ϕ, θ	Coeficientes de los componentes autorregresivos y de media móvil.
β	Coeficientes asociados a las variables exógenas.
σ	Desviación estándar.
μ	Media aritmética.
λ	Parámetro de regularización L2 (<i>Ridge</i>).

γ	Reducción mínima de pérdida para efectuar una partición en árboles de decisión.
η	Tasa de aprendizaje (<i>Learning Rate</i>).
Δ	Operador de diferencia o pendiente direccional.
d_{max}	Profundidad máxima de los árboles de decisión en el modelo XGBoost.
τ	Umbral dinámico utilizado para el cálculo de la Intensidad de Ráfaga Z (<i>Z-Surge</i>) en la arquitectura LSTM.

1. Contexto

1.1 Planteamiento del Problema

El acceso universal a energía eléctrica confiable y sostenible es un pilar fundamental para el desarrollo socioeconómico y el bienestar de las comunidades a nivel global (Gebre et al., 2024). No obstante, esta meta enfrenta obstáculos significativos, especialmente en regiones geográficamente aisladas y dispersas, como es el caso de las Zonas No Interconectadas (ZNI) en Colombia. Estas zonas, que abarcan una porción considerable del territorio nacional (Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024), se caracterizan por una alta incidencia de pobreza energética y una dependencia generalizada de sistemas de generación basados en diésel. Estos sistemas, además de ser costosos y tener un impacto ambiental negativo, frecuentemente ofrecen un suministro intermitente y de calidad deficiente, lo cual limita las oportunidades de desarrollo y perpetúa condiciones de vulnerabilidad (Bernal Suárez et al., 2024; Ministerio de Minas y Energía, 2024).

Para superar este déficit energético y avanzar hacia los objetivos de la Transición Energética Justa (TEJ) en Colombia (Bernal Suárez et al., 2024; Ministerio de Minas y Energía, 2024), se requiere imperativamente una planeación robusta y una administración eficiente de los recursos energéticos. Un componente crítico de esta planeación es la capacidad de proyectar con precisión el consumo futuro de energía eléctrica. Una predicción acertada de la demanda no solo optimiza la operación de los sistemas existentes y la gestión de recursos (Jawad et al., 2020), sino que también es fundamental para el diseño y dimensionamiento adecuado de nuevas soluciones energéticas, especialmente aquellas basadas en fuentes renovables (Rushman et al., 2019), y para la formulación de políticas energéticas efectivas (Gellert et al., 2024). La falta de predicciones confiables, por el contrario, conduce a ineficiencias, sobrecostos y dificulta la integración de alternativas energéticas limpias (Barja-Martinez et al., 2024).

Históricamente, los métodos estadísticos tradicionales, como los modelos ARI-MA, han sido utilizados para el pronóstico de demanda. Sin embargo, estos enfoques a menudo presentan dificultades para capturar la complejidad, no linealidad y

las dependencias dinámicas inherentes a los datos de consumo energético moderno (Madhusudanan, 2019; Qiao et al., 2023).

En respuesta a estas limitaciones, las técnicas de Aprendizaje Automático (ML) y Aprendizaje Profundo (DL) han emergido como alternativas prometedoras, demostrando un rendimiento superior en el modelado de relaciones intrincadas y dependencias temporales en diversos contextos energéticos (Cabiddu et al., 2024; Fasipe et al., 2024). Algoritmos como LSTM, Random Forest y Gradient Boosting Machines son cada vez más empleados por su capacidad para manejar la granularidad y complejidad de los datos de consumo (Patricio et al., 2024; Wang et al., 2021).

A pesar del avance y la creciente aplicación de ML/DL en el sector energético, existía una brecha significativa en el desarrollo y adaptación de estos modelos a las condiciones específicas y desafiantes de las comunidades aisladas en las ZNI colombianas. La literatura existente tiende a enfocarse en sistemas interconectados, áreas urbanas con mayor disponibilidad de datos, o contextos geográficos y socioeconómicos diferentes. Las comunidades ZNI, por su parte, presentan un conjunto de particularidades que dificultan la aplicación directa de modelos genéricos:

- **Escasez y baja calidad de datos históricos de consumo:** La falta de mediciones sistemáticas y detalladas es una barrera fundamental (Herraiz-Cañete et al., 2022; Rushman et al., 2019).
- **Patrones de consumo únicos y variables:** El comportamiento de consumo en estas áreas está moldeado por factores culturales, socioeconómicos (como la limitada penetración de electrodomésticos), y operativos (como la intermitencia del suministro) que difieren sustancialmente de los de zonas urbanas o interconectadas (Molina et al., 2018).
- **Influencia marcada de variables locales:** Factores como las condiciones climáticas específicas de micro-regiones, la estructura de las viviendas, o las actividades productivas incipientes pueden tener un impacto desproporcionado en la demanda.

La ausencia de modelos de predicción de consumo energético que estuvieran específicamente diseñados y validados para las ZNI colombianas constituyó el problema central de esta investigación. Esta carencia tiene consecuencias directas:

- Dificulta la planificación eficiente de la expansión y mejora del suministro energético.

- Obstaculiza el dimensionamiento óptimo y la integración efectiva de sistemas de energía renovable, que son cruciales para la TEJ y la sostenibilidad en estas regiones (un aspecto directamente relevante para el proyecto macro del cual esta tesis forma parte).
- Limita la capacidad de diseñar políticas y programas de gestión de la demanda y eficiencia energética que sean verdaderamente efectivos y adaptados a las necesidades locales.
- Contribuye a la perpetuación de la pobreza energética al no proveer las herramientas necesarias para optimizar el uso de recursos escasos.

Este panorama evidenció una necesidad clara y urgente de investigar y desarrollar metodologías predictivas que pudieran operar con eficacia bajo las condiciones de las ZNI.

Abordar esta problemática requirió, por tanto, una investigación sistemática que explorara la viabilidad y efectividad de los modelos ML/DL en este contexto particular. Se necesitó un enfoque que no solo seleccionara algoritmos adecuados, sino que también desarrollara estrategias para el manejo de datos limitados e incorporara las variables predictoras más relevantes para las ZNI.

1.2 Justificación

El acceso a fuentes confiables y sostenibles de energía es fundamental para el desarrollo social y económico, sin embargo, hay una disparidad significativa que afecta a múltiples comunidades a nivel global y de forma más específica a naciones en vías de desarrollo como Colombia (Molina et al., 2018). Colombia se enfrenta a desafíos considerables en este aspecto, mayormente en las Zonas No Interconectadas (ZNI), las cuales constituyen el 51 % del territorio nacional (Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024) pero este tipo de comunidades suelen estar altamente afectadas por pobreza energética y acceso limitado a una fuente confiable de electricidad (Bernal Suárez et al., 2024; Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ministerio de Minas y Energía, 2024; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024). Estas regiones que abarcan (aunque no se limitan

a) partes de la Orinoquía, Amazonía, la Costa Pacífica y la Guajira, frecuentemente dependen de generadores diésel que son costosos y contaminantes (constituyendo el 85 % de la capacidad de las ZNI) y a menudo estos generadores solo proveen energía de forma intermitente; incluso existen áreas donde solo cuentan con electricidad por 6 horas al día. Esta situación dificulta la prestación de servicios básicos como salud y educación, al tiempo que limita las oportunidades de desarrollo económico y perpetúa los ciclos de pobreza (Bernal Suárez et al., 2024; Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ministerio de Minas y Energía, 2024; Molina et al., 2018; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024).

Atender este déficit energético requiere una planeación robusta y una administración de recursos eficiente (Gebre et al., 2024). Colombia persigue estos objetivos como parte de la Hoja de Ruta para Una Transición Energética Justa, la cual apunta a integrar con mayor frecuencia y efectividad fuentes de energía renovables (Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024). Un componente crucial para esta planeación es la predicción acertada del consumo de energía. La predicción de la demanda energética es ampliamente considerada fundamental para el manejo moderno de sistemas eléctricos (Barja-Martinez et al., 2024). Además, juega un papel importante en la operación eficiente de redes eléctricas, la optimización de la planeación por parte de empresas proveedoras de energía (servicios públicos), y el fortalecimiento de la estabilidad de la malla energética a la vez que habilita la integración efectiva de fuentes renovables de energía como la energía solar y la eólica (T. Hong, 2015; Jawad et al., 2020). La habilidad de predecir necesidades energéticas futuras facilita la optimización del agendamiento de la producción, minimizando el desperdicio energético al tiempo que ayuda a prevenir sobrecargas del sistema (que generan altos costos) y ayuda a la toma informada de decisiones para el desarrollo de infraestructura y políticas energéticas (Gellert et al., 2024). Por el contrario, la inadecuada predicción de consumo puede producir sobrecostos significativos debido al desbalance entre la producción y el consumo, afectando particularmente a los productores en mercados competitivos (Barja-Martinez et al., 2024; Jawad et al., 2020). Por esto, desarrollar modelos de predicción robustos y acertados es una tarea crucial para cualquier parte interesada en el sector energético, incluyendo consumidores, empresas de servicios públicos y agentes gubernamentales a cargo de la creación de políticas energéticas ambiental y económicamente sostenibles.

Métodos estadísticos tradicionales para la predicción de consumo energético, tales como las regresiones lineales (ARIMA por ejemplo), a menudo tienen problemas para capturar los patrones complejos y no lineales inherentes a los datos de consumo energético (Wang et al., 2021). Técnicas de Aprendizaje Automático (ML) y Aprendizaje Profundo (DL) han emergido como alternativas efectivas, pues han demostrado un rendimiento superior al modelar relaciones intrincadas entre las variables y dependencias temporales de las mismas. Algoritmos como LSTM, Random Forests y Gradient Boosting Machines son cada vez más usados, debido principalmente a su habilidad de manejar la granularidad y complejidad de los datos de consumo energético desde distintas fuentes (Barja-Martinez et al., 2024; Fasipe et al., 2024).

Mientras las soluciones basadas en ML y DL van avanzando, existe una brecha en su aplicación en contextos como el colombiano; según se pudo encontrar, existen pocas investigaciones enfocadas en comunidades rurales aisladas, como las comunidades indígenas autóctonas de Colombia (Molina et al., 2018). Además, las comunidades en las ZNI frecuentemente carecen de datos de consumo histórico, y presentan distintos patrones de consumo, influenciados por factores culturales, poca disponibilidad de artículos eléctricos, así como condiciones ambientales únicas (Bernal Suárez et al., 2024; Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE), 2024; Ministerio de Minas y Energía, 2024; Molina et al., 2018; Ramírez Murillo, 2023; Unidad de Planeación Minero Energética (UPME), 2024).

Esta tesis de maestría se desarrolló como parte de una investigación doctoral más amplia enfocada en predecir los potenciales de energía usando IA. La justificación de este trabajo se basó en estos pilares:

- **Abordar la pobreza y desigualdad energética:** Proveer herramientas para un mejor manejo en las ZNI es crucial para la mejoría en los estándares de vida locales, permitiendo la diversificación de actividades económicas y la reducción de inequidades energéticas pronunciadas remarcadas en los índices nacionales.
- **Apoyar la transición energética sostenible:** Como ya se mencionó, la predicción acertada del consumo de energía eléctrica es indispensable para la planeación efectiva y la integración de soluciones de energía renovable (solares, eólicas, biomasas, etc.), lo que resulta vital para la reducción de la dependencia del diésel y de esta forma cumplir con los objetivos TEJ.

- **Mejorar la planeación y la eficiencia operacional:** El modelo predictivo generó una valiosa perspectiva que proporciona las bases técnicas para la optimización del despacho de generadores existentes, la estimación de tamaños de sistemas energéticos apropiada, designación de mejores tarifas (si es aplicable en el caso específico) y la creación de campañas de eficiencia energética enfocadas y bien informadas, incluso en ambientes con pocos datos disponibles.
- **Contribución científica:** El desarrollo y evaluación de un modelo de ML/DL para este caso específico, el cual no cuenta con investigaciones extensivas, contribuyó con conocimiento novedoso al campo de predicción de consumo de energía eléctrica (energía activa en kWh), mediante el diseño de una arquitectura agnóstica a la ubicación y la implementación de pruebas de arranque en frío (*Zero-Shot*), validando la capacidad de generalización del modelo sobre la calidad de los datos presentes y las características de las comunidades.

Esta investigación se justificó por la necesidad de abordar la pobreza energética desde todo campo posible y facilitar la transición energética sostenible. Al aprovechar las capacidades de los algoritmos de ML y DL, esta tesis apuntó a desarrollar una herramienta útil, un modelo acertado de predicción de consumo de energía eléctrica en el contexto de comunidades pequeñas. Esta herramienta aporta a la toma informada de decisiones, la optimización de la ubicación de recursos, el soporte a la integración de energías renovables y de esta forma apoyó, como objetivo final, la mejora de la calidad de vida de las personas en las comunidades apartadas en las que se aplicó dicho modelo.

1.3 Objetivos

Para comprobar la hipótesis formulada y dar respuesta a las preguntas de investigación, este trabajo se propuso alcanzar los siguientes objetivos:

1.3.1 *Objetivo General*

Desarrollar un modelo predictivo basado en aprendizaje automático/profundo (ML/DL) que demostrara la viabilidad de estimar con precisión útil el consumo de energía eléctrica en comunidades aisladas de las ZNI colombianas, adaptándose a las

limitaciones de datos y características locales para aumentar la información disponible y relevante para la planificación y el dimensionamiento de soluciones energéticas.

1.3.2 *Objetivos Específicos*

- Establecer los requisitos funcionales y de datos específicos para el modelo predictivo ML/DL, considerando las características únicas del consumo en las ZNI y las limitaciones de información identificadas.
- Seleccionar y adaptar modelos de aprendizaje automático/profundo (ej. LSTM, GBM, RF) que fueran adecuados para modelar series temporales de consumo energético.
- Validar el modelo ML/DL en términos de su capacidad para generar pronósticos de consumo que fueran suficientemente precisos y detallados como para informar decisiones sobre la planificación operativa y el dimensionamiento de sistemas energéticos locales.

1.4 Hipótesis

La presente investigación, reconociendo los desafíos únicos de la predicción de consumo en las ZNI y el potencial de los modelos ML/DL adaptados, se guía por la siguiente hipótesis fundamental:

El desarrollo y la validación rigurosa de un modelo predictivo de consumo energético, fundamentado en algoritmos de aprendizaje automático/profundo (ML/DL) y específicamente adaptado a las condiciones de datos y patrones de uso característicos de las comunidades ZNI en Colombia, demostrará la viabilidad de obtener pronósticos con la exactitud y el detalle necesarios para informar eficazmente la planificación y el dimensionamiento de sistemas energéticos locales en dichas zonas.

2. Marco de Referencia

2.1 Estado del Arte

Los métodos de predicción de consumo energético han evolucionado considerablemente en los últimos años. Las aproximaciones iniciales dependían de técnicas simples, pero el incremento en la complejidad de los sistemas energéticos y la disponibilidad de datos más granulares ha conducido a la adopción de métodos más sofisticados (T. Hong, 2015). Métodos estadísticos fundamentales, incluyendo varias formas de regresión lineal y modelos de series de tiempo como ARIMA (*Autoregressive Integrated Moving Average*) y ARIMAX, aún son relevantes, pues son comúnmente usados como puntos de referencia debido a sus metodologías e interpretabilidad (Almuhanna, 2024; Madhusudanan, 2019; Wang et al., 2021). Sin embargo, estos métodos tradicionales presentan limitaciones cuando deben lidiar con no linealidades inherentes, tales como estacionalidades complejas y dependencias dinámicas presentes en los datos de consumo energético moderno (Madhusudanan, 2019; Qiao et al., 2023). Esto ha producido una amplia exploración y aplicación de técnicas de Aprendizaje Automático (ML, por sus siglas en inglés) y Aprendizaje Profundo (DL, por sus siglas en inglés). Algoritmos como *Support Vector Machines* (SVM) (Shapi et al., 2021), *Random Forests* (RF) (Dubey et al., 2024), *Gradient Boosting Machines* (GBM) (Wang et al., 2021), *K-Nearest Neighbors* (KNN) (G. Hong et al., 2022), *Artificial Neural Networks* (ANN) (Shapi et al., 2021), y redes neuronales más avanzadas como las *Recurrent Neural Networks* (RNNs), específicamente *Long Short-Term Memory* (LSTM) (Kolluru et al., 2024; Patricio et al., 2024), son cada vez más preferidos por su capacidad de modelar patrones intrincados y dependencias temporales de amplio rango en datos de consumo energético.

Las aplicaciones prácticas de estas técnicas de predicción son diversas; se enfocan en múltiples ubicaciones geográficas, escalas de sistemas energéticos y objetivos específicos. Por ejemplo, existen múltiples trabajos que se enfocan en el hogar y los electrodomésticos usados en él; entre estos podemos encontrar el trabajo realizado por Li et al. (2024), que usa un algoritmo de *Temporal Graph Convolutional Networks* (TGCN) diseñado para aprender las posibles correlaciones entre diferentes electrodomésticos y que fue probado en los conjuntos de datos AMPDS y UK-DALE. También se encuentran desarrollos como el realizado por Patricio et al. (2024), que

combina las ventajas de los algoritmos genéticos para la optimización y la predicción de series temporales de las redes neuronales tipo LSTM, con lo que propusieron un método para minimizar el costo de la energía en los hogares de Portugal. Sistemas básicos de regresiones lineales han sido utilizados para la predicción de uso energético residencial; aunque este trabajo fue contrastado con conjuntos de datos de la plataforma Kaggle, solo logró llegar a un 66 % de acierto (Vidhate & Nema, 2024). Escenarios que facilitan la generación, recolección y almacenamiento de datos de consumo, tales como IoT, facilitan la creación de técnicas eficientes, tal como se documenta en Kolluru et al. (2024), que presentó resultados satisfactorios al predecir el consumo en el hogar: un error cuadrático medio de 0.0018 fue logrado al aprovechar las capacidades de las redes LSTM en series temporales.

De forma complementaria a los trabajos que intentan predecir el consumo en casas, existen investigaciones que apuntan a resolver el mismo problema, pero enfocándose en poblaciones enteras, es decir, comunidades, ciudades y regiones. En Wang et al. (2021) se realizó una comparación de modelos (regresión lineal, Prophet, GBM, RF, SVM) para predecir el consumo diario de energía en áreas metropolitanas de Estados Unidos. La predicción de consumo en áreas semirremotas en el Ártico fue abarcada en Eikeland et al. (2021); allí se remarcó la dificultad de la predicción en dichas áreas al tiempo que se compararon diferentes métodos para conseguir resultados satisfactorios. Modelos estadísticos como ARIMA y Prophet se compararon con métodos más complejos de ML (LSTM, GRU, ESN, CNN) en diferentes sectores y periodos de predicción; allí se demostró que, según el periodo de predicción deseado, se debe utilizar un algoritmo distinto, pues todos ellos presentan rendimientos diferentes altamente dependientes de dicho periodo. La tarea crítica de predecir la demanda energética para el diseño de minirredes de energía renovable en comunidades rurales aisladas fue examinada mediante un caso de estudio en Honduras (Herraiz-Cañete et al., 2022), en donde se compararon métodos estocásticos y determinísticos. En Ma et al. (2024) se hizo una aproximación global; allí se dividió el mapa mundial en regiones y se utilizaron datos temporales de luminosidad nocturna para predecir el consumo en cualquiera de las zonas demarcadas.

En Sibiu, Rumania, se estimó el consumo energético de la ciudad al comparar métodos estadísticos, de lógica difusa, LSTM y modelos de Markov aplicados a datos de empresas de servicios públicos que cubrían varios tipos de consumidores (Gellert et al., 2024). La influencia de parámetros meteorológicos en la predicción de consumo fue evaluada en Jawad et al. (2020); allí se utilizaron varios modelos de ML y se

aplicaron a datos obtenidos en Muzaffarabad, Pakistán. Las conclusiones de este artículo resultaron muy relevantes para la predicción planteada en esta investigación, pues dentro del territorio colombiano las condiciones climatológicas pueden variar sustancialmente de una región a otra.

Además de todo lo mencionado anteriormente, existieron algunos otros puntos encontrados en la literatura que resultaron relevantes para esta investigación:

- El Aprendizaje Federado (FL) y el FL Personalizado (FLP) han emergido como soluciones para el entrenamiento de modelos de predicción de consumo energético en hogares; estos métodos permiten hacer ajustes finos y adaptaciones de datos de poblaciones más grandes (datos globales como ejemplo) para su uso en hogares (Barja-Martinez et al., 2024).
- Plataformas de *Big Data* como Apache Spark y Hadoop son recomendadas para el manejo de los grandes volúmenes de datos generados por sensores inteligentes y otros dispositivos IoT (Dubey et al., 2024).

Se pudieron encontrar varios trabajos híbridos, en los que se realizó una combinación de métodos la cual se apalancó en las ventajas de cada uno. Por ejemplo, en Qiao et al. (2023) se utilizó una capa de Descomposición Modal Variacional (VMD) para preprocesar series de tiempo complejas antes de alimentar una red LSTM con ellas, lo que aumentó la precisión final del sistema. Otro ejemplo es el trabajo hecho por Guilian et al. (2023), en donde se utilizó un Algoritmo Genético para optimizar los parámetros de una red neuronal, demostrando nuevamente la efectividad que puede tener la combinación de múltiples algoritmos.

La revisión del estado del arte sobre la predicción de consumo energético y aplicaciones relacionadas mostró una clara tendencia al aprovechamiento de metodologías enfocadas en datos, en su mayoría técnicas de ML, tanto básicas como avanzadas. Los modelos de Aprendizaje de Máquina y Aprendizaje Profundo, particularmente LSTMs, CNNs y técnicas de aumento de gradiente, en general, mostraron un rendimiento superior a los métodos estadísticos clásicos; esto debido a la facilidad de los nuevos modelos de ML para adaptarse a las no linealidades inherentes a los sistemas de producción y consumo energético. Aunque se pudo ver con claridad que no existe un método que sea mejor o más acertado en toda situación, resultó claro que las investigaciones relacionadas apuntaron a modelos cada vez más sofisticados basados en datos, a menudo bien ajustados a entornos específicos, buscando mejorar la eficiencia, confiabilidad y sostenibilidad de los sistemas energéticos.

2.2 Marco Teórico

Zonas No Interconectadas (ZNI):

Se refiere a aquellas áreas geográficas (como municipios, corregimientos o localidades) dentro de Colombia que no están enlazadas al Sistema Interconectado Nacional (SIN). Estas zonas se caracterizan por su dispersión territorial y lejanía de los principales puntos de consumo, lo que hace inviable su conexión a la red eléctrica principal del país (Ramírez Murillo, 2023).

Pobreza Energética:

Describe la circunstancia en la cual un hogar sufre de un acceso insuficiente a los servicios energéticos, lo que restringe su capacidad para satisfacer las necesidades básicas que dependen de la energía (Bernal Suárez et al., 2024).

Inteligencia Artificial (IA):

Se define más comúnmente a través de la lente de los agentes inteligentes: sistemas que perciben su entorno y toman acciones que maximizan su probabilidad de alcanzar con éxito sus objetivos. Este enfoque moderno sintetiza diversas capacidades tradicionalmente asociadas con la inteligencia, incluyendo el razonamiento, el aprendizaje, la representación del conocimiento, la planificación, la percepción y la acción, enmarcando la IA como el estudio y diseño de dichos agentes. El campo es amplio, abarcando la lógica, la probabilidad y las matemáticas continuas, con aplicaciones que van desde dispositivos microelectrónicos hasta exploradores planetarios robóticos y sofisticados servicios en línea. La definición misma ha evolucionado; mientras que las conceptualizaciones tempranas se centraban en “la ciencia e ingeniería de hacer máquinas inteligentes”, la dificultad para definir formalmente la “inteligencia” ha llevado a un mayor énfasis en el comportamiento observable y la acción racional de los agentes dentro de su entorno, avanzando hacia criterios más operativos y medibles para la inteligencia (Russell & Norvig, 2020).

Aprendizaje Automático (*Machine Learning*, ML):

Es un subcampo de la Inteligencia Artificial que se ocupa del estudio y desarrollo de algoritmos que permiten a los programas informáticos mejorar automáticamente su rendimiento en una tarea específica a través de la experiencia, típicamente en forma de datos, sin ser programados explícitamente para esa tarea. Se centra en

algoritmos que permiten a las computadoras aprender de los datos y tomar decisiones basadas en ellos, descubriendo patrones automáticamente y mejorando con la experiencia. El campo tiene estrechos vínculos con el reconocimiento de patrones, y a menudo se consideran facetas del mismo campo; el ML tradicionalmente surgió de la informática, mientras que el reconocimiento de patrones tiene orígenes en la ingeniería, pero ambos implican la identificación de regularidades en los datos. Las definiciones centrales a menudo enfatizan el aspecto de mejora del rendimiento obtenido a través de la experiencia o el aspecto de descubrimiento de patrones, reflejando perspectivas ligeramente diferentes, pero convergiendo en la idea central de aprender de los datos en lugar de depender únicamente de reglas predefinidas. Los principales paradigmas dentro del ML incluyen el aprendizaje supervisado (aprender de pares entrada-salida etiquetados), el aprendizaje no supervisado (encontrar patrones en datos no etiquetados) y el aprendizaje por refuerzo (aprender acciones a través de prueba y error basado en recompensas) (Mitchell, 1997).

Aprendizaje Profundo (*Deep Learning*, DL):

Es una forma de aprendizaje automático que permite a las computadoras aprender de la experiencia y comprender el mundo en términos de una jerarquía de conceptos, utilizando modelos computacionales compuestos por múltiples capas de procesamiento para aprender representaciones de datos con múltiples niveles de abstracción. Debido a que la computadora adquiere conocimiento de la experiencia, no hay necesidad de que un operador humano especifique formalmente todo el conocimiento requerido; la jerarquía de conceptos permite a la computadora aprender conceptos complicados construyéndolos a partir de otros más simples, lo que lleva a gráficos “profundos” de estas jerarquías. Es una rama especializada del ML que enfatiza el entrenamiento de redes neuronales artificiales con múltiples capas ocultas (arquitecturas profundas). Una característica clave es su capacidad para el aprendizaje de representaciones, descubriendo automáticamente estructuras intrincadas en grandes conjuntos de datos al aprender características relevantes directamente de los datos brutos, reduciendo así la dependencia de la ingeniería manual de características. El aspecto definitorio no es simplemente la profundidad de la red, sino la capacidad de aprender esta jerarquía de representaciones, donde las capas inferiores podrían capturar características básicas y las capas superiores las combinan en conceptos más complejos y abstractos (Goodfellow et al., 2016).

Big Data:

Se refiere a activos de información caracterizados por un volumen, velocidad y variedad tan altos que demandan formas innovadoras y rentables de procesamiento de información para mejorar la percepción, la toma de decisiones y la automatización de procesos. Inicialmente conceptualizado en torno a estas tres “V” (Volumen, Velocidad, Variedad) por analistas de Gartner, la definición a menudo se extiende para incluir otras características como Veracidad (incertidumbre o confiabilidad de los datos) y Valor (la utilidad potencial derivable de los datos). El Instituto Nacional de Estándares y Tecnología (NIST) ofrece una perspectiva tecnológicamente fundamentada, definiendo Big Data como conjuntos de datos cuyo tamaño, velocidad de adquisición o formato de representación limita la capacidad de los enfoques tradicionales de bases de datos relacionales para realizar análisis efectivos, necesitando tecnologías escalables horizontalmente. Crucialmente, el término es relativo; lo que constituye “Big Data” depende de las capacidades de las tecnologías de procesamiento disponibles en un momento dado, definido más por los desafíos que plantea a las herramientas tradicionales que por el tamaño absoluto (Volk et al., 2022).

Aprendizaje Federado (*Federated Learning*, FL):

Es un entorno de aprendizaje automático donde múltiples clientes (por ejemplo, dispositivos móviles, organizaciones) entrenan colaborativamente un modelo compartido, típicamente orquestado por un servidor central, mientras mantienen sus datos de entrenamiento brutos descentralizados y localizados en los dispositivos del cliente. En lugar de agrupar los datos centralmente, solo las actualizaciones del modelo, como los gradientes calculados o los pesos del modelo actualizados, se comunican entre los clientes y el servidor (o entre clientes en variantes descentralizadas) para su agregación. La motivación principal para el FL surge de la necesidad de abordar desafíos relacionados con la privacidad de los datos, la minimización de datos, los derechos de acceso a los datos, la eficiencia de la comunicación y las restricciones regulatorias como el GDPR, lo que lo hace particularmente adecuado para escenarios que involucran datos sensibles o distribuidos. El proceso típico implica rondas iterativas de distribución del modelo global actual a clientes seleccionados, realización de entrenamiento local en los datos del cliente, agregación segura de las actualizaciones del modelo resultantes (por ejemplo, usando *Federated Averaging*) y actualización del modelo global (Kairouz et al., 2019).

Red Neuronal Artificial (RNA):

A menudo llamada simplemente red neuronal, es un modelo computacional inspirado en la estructura y función de las redes neuronales biológicas, particularmente el cerebro humano. Consiste en una colección de unidades de procesamiento interconectadas, conocidas como nodos o neuronas artificiales, que típicamente se organizan en capas (una capa de entrada, una o más capas ocultas y una capa de salida). Cada conexión entre neuronas tiene un peso numérico asociado, y cada neurona típicamente aplica una función de activación a su entrada agregada (la suma ponderada de las entradas más un sesgo) para determinar su señal de salida. Las RNA aprenden patrones y relaciones de los datos ajustando estos pesos de conexión a través de un proceso de entrenamiento, lo que les permite modelar dependencias complejas, a menudo no lineales, y realizar tareas como clasificación, regresión, reconocimiento de patrones y aproximación de funciones. Existen diversas arquitecturas, incluyendo redes de alimentación hacia adelante (FNNs), redes convolucionales (CNNs) y redes recurrentes (RNNs) (IBM, 2024; Pan, 2024).

Redes Neuronales Recurrentes (RNNs):

Son una clase de redes neuronales artificiales diseñadas específicamente para procesar datos secuenciales, como series de tiempo, texto o voz, donde el orden de los elementos es crucial. A diferencia de las redes de alimentación hacia adelante que procesan las entradas de forma independiente, las RNNs cuentan con conexiones recurrentes o bucles de retroalimentación, lo que permite que la salida de una neurona (o capa) en un paso de tiempo se retroalimente como entrada para el paso de tiempo subsiguiente. Esta arquitectura cíclica permite a las RNNs mantener un estado interno o “memoria”, a menudo llamado estado oculto, que captura información sobre entradas anteriores en la secuencia e influye en el procesamiento actual. El estado oculto se actualiza en cada paso de tiempo basándose tanto en la entrada actual como en el estado oculto anterior, lo que permite a la red exhibir un comportamiento temporal dinámico y aprender dependencias a lo largo del tiempo. Sin embargo, entrenar RNNs estándar en secuencias largas puede ser desafiante debido al problema del gradiente evanescente o explosivo (Pan, 2024).

Redes de Memoria a Corto y Largo Plazo (*Long Short-Term Memory, LSTM*):

Son un tipo especializado de arquitectura de red neuronal recurrente diseñada explícitamente para abordar las dificultades de aprender dependencias a largo plazo en datos secuenciales. Introducidas por Hochreiter y Schmidhuber (1997), las LSTMs logran esta capacidad a través de una estructura interna más compleja dentro de cada unidad recurrente, centrada alrededor de un estado de celda de memoria y varios mecanismos de compuerta multiplicativos: típicamente una compuerta de entrada, una compuerta de salida y una compuerta de olvido. La celda de memoria actúa como un acumulador de información de estado, capaz de preservar señales durante largos períodos, mientras que las compuertas aprenden a regular el flujo de información, controlando cuándo entra la información a la celda (compuerta de entrada), cuándo se borra (compuerta de olvido) y cuándo influye en la salida de la red (compuerta de salida). Este control explícito sobre la retención y el flujo de la memoria permite a las LSTMs recordar u olvidar selectivamente información a través de intervalos de tiempo extendidos, haciéndolas altamente efectivas para la predicción de series de tiempo (Van Houdt et al., 2020).

Máquinas de Vectores de Soporte (*Support Vector Machines, SVMs*):

Son un conjunto de métodos relacionados de aprendizaje supervisado utilizados para clasificación y regresión, arraigados en la teoría del aprendizaje estadístico. Para la clasificación, la idea central es encontrar un hiperplano óptimo que separe los puntos de datos pertenecientes a diferentes clases en un espacio de características con el margen máximo posible: la distancia entre el hiperplano y los puntos de datos más cercanos de cualquier clase. Estos puntos más cercanos, que se encuentran en los límites del margen, se llaman vectores de soporte. Las SVMs pueden manejar eficazmente datos no separables linealmente utilizando el “truco del kernel”, que implica el empleo de funciones kernel para mapear implícitamente los datos a un espacio de mayor dimensión donde podría existir una separación lineal (Kecman, 2005).

Regresión Lineal:

Es una técnica estadística fundamental utilizada para modelar y analizar la relación lineal entre una variable dependiente (resultado) continua y una o más variables independientes (predictoras). El objetivo es encontrar la ecuación lineal que mejor se ajuste que describa cómo cambia la variable dependiente en promedio con

los cambios en las variables independientes. Este “mejor ajuste” se determina típicamente utilizando el método de mínimos cuadrados, que minimiza la suma de las diferencias al cuadrado (residuos) entre los valores observados y los valores predichos por el modelo lineal (Schneider et al., 2010).

Bosque Aleatorio (*Random Forest*, RF):

Es un método de aprendizaje conjunto (*ensemble learning*) que construye una multitud de predictores de árbol de decisión durante el entrenamiento y produce la moda de las clases o la predicción media (regresión) de los árboles individuales. Combina la técnica de *bagging* (*bootstrap aggregating*) de Breiman con la selección aleatoria de características para cultivar una colección de árboles de decisión con varianza controlada (Breiman, 2001).

Máquinas de Potenciación del Gradiente (*Gradient Boosting Machines*, GBMs):

Representan una potente familia de algoritmos de aprendizaje automático conjunto que construyen modelos predictivos de manera aditiva y por etapas. A diferencia de métodos como los Bosques Aleatorios que promedian modelos independientes, el *boosting* construye el conjunto secuencialmente, donde cada nuevo aprendiz base (típicamente un árbol de decisión) se entrena para corregir los errores cometidos por el conjunto de aprendices construidos hasta el momento. Las GBMs generalizan este procedimiento enmarcándolo como un problema de optimización numérica en el espacio de funciones (Friedman, 2001).

Modelo Autorregresivo Integrado de Media Móvil (ARIMA):

Es un modelo estadístico utilizado extensamente para analizar y pronosticar datos de series de tiempo univariadas que exhiben dependencias temporales. El modelo combina tres componentes, denotados por los parámetros (p, d, q) : un componente Autorregresivo (AR), un componente Integrado (I) y un componente de Media Móvil (MA). El proceso de construcción de un modelo ARIMA generalmente sigue la metodología Box-Jenkins (Box et al., 2015).

***Prophet*:**

Es un procedimiento de pronóstico de código abierto diseñado específicamente para producir pronósticos para datos de series de tiempo que exhiben múltiples patrones de estacionalidad. Se basa en un modelo de regresión aditivo descomponi-

ble, donde la serie de tiempo se representa como la suma de varios componentes: un componente de tendencia, un componente estacional y un componente de días festivos (Taylor & Letham, 2017).

Inanición de Gradiente (*Gradient Starvation*):

Es una anomalía de entrenamiento en redes neuronales sobreparametrizadas donde la función de optimización obliga al modelo a enfocarse de manera desproporcionada en capturar un subconjunto inicial de características dominantes. Este fenómeno provoca que otras características predictivas igualmente relevantes sean ignoradas, reduciendo severamente la capacidad de generalización del modelo ante datos no vistos (Pezeshki et al., 2021).

Saturación Neuronal:

Es un estado en el cual las funciones de activación de una red neuronal profunda, como la sigmoide o la tangente hiperbólica ($\tanh$), alcanzan los extremos de sus rangos operativos. En este punto, las derivadas de gradiente se aproximan a cero, lo que bloquea la convergencia y detiene el aprendizaje matemático. Esto es particularmente crítico cuando se procesan variables eléctricas de alta volatilidad sin la inicialización o estabilización adecuada (Lee et al., 2024).

Codificación Cíclica Temporal:

Es una técnica de preprocesamiento que consiste en proyectar variables temporales continuas y periódicas (como horas o meses) en un espacio bidimensional continuo utilizando componentes ortogonales trigonométricas (seno y coseno). Este enfoque preserva la topología cíclica del tiempo, evitando discontinuidades artificiales y mejorando la capacidad de redes recurrentes para capturar patrones oscilatorios y estacionales subyacentes (Khazem & Kanso, 2025).

Aprendizaje *Zero-Shot* en Series Temporales:

Es un paradigma avanzado de aprendizaje automático, apalancado por modelos fundacionales, que permite generar pronósticos precisos sobre micro-redes eléctricas o secuencias de datos sin necesidad de contar con registros históricos previos para el entrenamiento (entornos de arranque en frío). Permite transferir patrones latentes globales a contextos geográficos y operativos inéditos (Liao et al., 2024).

Toma de Carga en Frío (*Cold Load Pickup*, CLPU):

Es un fenómeno termodinámico e inercial que ocurre durante la restauración del servicio eléctrico tras un apagón prolongado. La interrupción provoca la pérdida de la diversidad estadística en el consumo (por ejemplo, múltiples sistemas de refrigeración demandando arranque simultáneo), lo que genera un pico transitorio de potencia activa anormalmente alto. La modelación de este fenómeno resulta indispensable para prevenir que algoritmos predictivos confundan el transitorio térmico con una tendencia sostenida de la demanda base (Sun, 2024).

3. Metodología

3.1 Caracterización y Selección de Datos

La formulación de un marco predictivo robusto para las Zonas No Interconectadas (ZNI) depende críticamente de la cantidad, calidad y granularidad de los registros históricos disponibles. Dado que las ZNI carecen de un sistema centralizado de medición inteligente unificado con el Sistema Interconectado Nacional, la fase de adquisición requirió la convergencia de dos fuentes de datos institucionales de naturaleza fundamentalmente distinta: registros de telemetría de demanda energética y series temporales de variables climatológicas.

3.1.1 Origen de los Datos de Demanda Energética (IPSE)

La información correspondiente al consumo eléctrico de las micro-redes fue obtenida a través del portal oficial del Centro Nacional de Monitoreo (CNM), administrado por el Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE) (disponible en: <https://ipse.gov.co/cnm/>). Este portal actúa como el repositorio estatal encargado de auditar y registrar la operación técnica, las horas de servicio y las variables eléctricas de las plantas de generación diésel e híbridas distribuidas en los territorios aislados de Colombia.

Debido a que el portal no ofrece una Interfaz de Programación de Aplicaciones (API) de consulta directa para bases de datos relacionales, la adquisición de la información se llevó a cabo mediante el desarrollo e implementación de un algoritmo de extracción de datos web (*web scraping*). Este proceso permitió la descarga automatizada de 138 reportes técnicos en formato PDF, correspondientes a un periodo de observación comprendido entre marzo de 2014 y diciembre de 2025. Cada uno de estos documentos consolidaba el reporte de un mes específico y presentaba una longitud variable de entre 130 y 500 páginas, dependiendo de la evolución del formato de reporte institucional a lo largo de los años.

El reto principal en esta fase de extracción radicó en la estructura del documento. Las tablas y fuentes de información contenidas en los PDFs no agrupaban los datos a nivel nacional, sino que presentaban la información de una única población a la vez. En consecuencia, el algoritmo fue diseñado para iterar secuencialmente

por la totalidad del documento, capturando en memoria las tablas de telemetría y extrayendo simultáneamente los metadatos geográficos (Departamento, Municipio y Población) que encabezaban cada sección, permitiendo así estructurar y organizar la procedencia de cada registro eléctrico.

A lo largo de la década analizada, se identificaron múltiples formatos de presentación de los datos. A continuación, se ilustran las estructuras documentales que el algoritmo debió interpretar:




Tabla 218: Resumen Datos de Generación.

Energía Activa (kWh)	Energía Reactiva (kVArh)	Energía Aparente (kVAh)	Factor de Potencia	Promedio día-mes [h:mm]	Potencia Máxima (kW)
2,797,794	863,150	2,924,981.82	0.96	23:39	5,042.40

Ilustración 216: Esquema de conexión de la localidad.




Ilustración 217: Energía entregada por día de la semana.





Ilustración 218: Curva de Carga Promedio Diaria Mensual.



Sede Principal: Calle 99 No. 9 A - 54 Torre 3. Piso 14
 PDX: (57 1) 539 7888
 IPSE Centro Nacional de Monitoreo: (57 1) 6101130
 ipse@ipse.gov.co
 Bogotá D.C. - Colombia

@IPSEnergiaZNI
 IPSE
 @ipseenergiam
 IPSE
 IPSE EnergíaZNI

Figura 3.1: Ejemplo del formato de reporte moderno y compacto emitido por el IPSE, caracterizado por una disposición horizontal de las variables eléctricas.

Para los reportes de mayor antigüedad, la variabilidad estructural exigió lógicas de extracción condicionales, especialmente para la captura de la métrica de horas de servicio, identificando tres casos base:

12.2 Energía

El consumo de energía eléctrica para esta localidad en *Enero* de 2015, se presenta en la siguiente tabla, donde se encuentran los valores acumulados diarios de la energía activa (kWh), reactiva (kVARh), aparente (kVAh) y del factor de potencia (p.u).

Tabla 27 Energía Activa, Reactiva, Aparente y Factor de Potencia.

CAPURGANÁ (ACANDI - CHOCO)				
Fecha	Energía Activa (kWh)	Energía Reactiva (kVARh)	Energía Aparente (kVAh)	Factor de Potencia (p.u)
Enero 1, Jueves	10.960	3.847	11.615,80	0,94
Enero 2, Viernes	10.039	3.741	10.713,68	0,94
Enero 3, Sábado	10.768	3.899	11.452,53	0,94
Enero 4, Domingo	11.009	3.899	11.679,01	0,94
Enero 5, Lunes	10.639	3.785	11.292,67	0,94
Enero 6, Martes	8.168	3.015	8.706,27	0,94
Enero 7, Miércoles	8.266	3.075	8.819,12	0,94
Enero 8, Jueves	5.365	2.062	5.747,33	0,93
Enero 9, Viernes	5.891	2.157	6.273,66	0,94
Enero 10, Sábado	7.852	2.901	8.370,95	0,94
Enero 11, Domingo	7.650	2.924	8.190,32	0,93
Enero 12, Lunes	5.289	2.177	5.720,03	0,92
Enero 13, Martes	5.520	2.259	5.964,42	0,93
Enero 14, Miércoles	6.515	2.609	7.018,42	0,93
Enero 15, Jueves	7.001	2.812	7.544,53	0,93
Enero 16, Viernes	6.735	2.775	7.284,61	0,92
Enero 17, Sábado	6.129	2.576	6.648,45	0,92
Enero 18, Domingo	6.335	2.674	6.875,91	0,92
Enero 19, Lunes	5.857	2.524	6.377,75	0,92
Enero 20, Martes	5.814	2.516	6.335,25	0,92
Enero 21, Miércoles	5.639	2.416	6.134,65	0,92
Enero 22, Jueves	5.671	2.512	6.202,71	0,91
Enero 23, Viernes	5.837	2.539	6.364,90	0,92
Enero 24, Sábado	5.510	2.382	6.002,86	0,92
Enero 25, Domingo	5.757	2.474	6.266,42	0,92
Enero 26, Lunes	5.779	2.445	6.274,95	0,92
Enero 27, Martes	5.612	2.462	6.128,25	0,92
Enero 28, Miércoles	5.259	2.367	5.766,78	0,91
Enero 29, Jueves	5.294	2.340	5.788,12	0,91
Enero 30, Viernes	4.831	2.123	5.277,07	0,92
Enero 31, Sábado	5.327	2.391	5.838,50	0,91
TOTAL	212.320	84.679	228.582,97	0,93

El factor de potencia promedio fue 0,93.

Con referencia a Enero de 2014 (113.414 kWh), se presentó un fuerte crecimiento en la demanda de energía eléctrica del 87,21%. Este fuerte crecimiento es debido al aumento en el horario de prestación del servicio.

Figura 3.2: Estructura tabular de datos energéticos carente de la columna o fila de horas de servicio.

Tabla 7 Horas promedio por día prestación del servicio de energía

PUERTO NARIÑO (PUERTO NARIÑO - AMAZONAS) Febrero 2019	
DIA	Horas de servicio promedio en el día (hh:mm)
01-Feb-2019	24 Horas
02-Feb-2019	24 Horas
03-Feb-2019	24 Horas
04-Feb-2019	24 Horas
05-Feb-2019	24 Horas
06-Feb-2019	24 Horas
07-Feb-2019	24 Horas
08-Feb-2019	24 Horas
09-Feb-2019	24 Horas
10-Feb-2019	24 Horas
11-Feb-2019	24 Horas
12-Feb-2019	24 Horas
13-Feb-2019	24 Horas
14-Feb-2019	24 Horas
15-Feb-2019	24 Horas
16-Feb-2019	24 Horas
17-Feb-2019	24 Horas
18-Feb-2019	24 Horas
19-Feb-2019	23 Horas 45 Minutos
20-Feb-2019	24 Horas
21-Feb-2019	24 Horas
22-Feb-2019	24 Horas
23-Feb-2019	24 Horas
24-Feb-2019	24 Horas
25-Feb-2019	24 Horas
26-Feb-2019	24 Horas
27-Feb-2019	23 Horas 45 Minutos
28-Feb-2019	24 Horas

Fuente CNM

Figura 3.3: Estructura tabular estandarizada que incluye de manera explícita el conteo de horas operativas.

3.5 Horas de Prestación del Servicio

En Febrero, se prestó el servicio de energía eléctrica en la localidad, un promedio diario de 10 Horas 17 Minutos, como se presenta en la siguiente gráfica.

Figura 3.4: Resumen ejecutivo en texto continuo, del cual el algoritmo debió inferir las horas promedio mensuales de servicio mediante procesamiento de lenguaje natural cuando la tabla carecía de este dato.

3.1.2 Origen de los Datos Climatológicos (IDEAM)

Las variables exógenas medioambientales se extrajeron del portal de Consulta y Descarga de Datos Hidrometeorológicos (DHIME), operado por el Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM) (disponible en: <http://dhime.ideam.gov.co/atencionciudadano/>). Este sistema representa el catálogo oficial del Estado para el acceso a las mediciones físicas de la red de estaciones meteorológicas desplegadas a nivel nacional.

A diferencia de los datos de energía, las series temporales climatológicas se adquirieron mediante descarga manual. Esto obedeció a las restricciones de acceso, los sistemas de verificación humana (captchas) y la arquitectura de navegación de la plataforma, que inhabilitaban la aplicación de rutinas de *scraping* masivo. A pesar de las restricciones de descarga, la ventaja de esta fuente residió en su homogeneidad estructural: la totalidad de los archivos descargados conservó un formato CSV (Valores Separados por Comas) estandarizado, compuesto invariablemente por las siguientes ocho columnas: `CodigoEstacion`, `NombreEstacion`, `Variable`, `Parametro`, `Fecha`, `Unidad`, `Valor` y `NivelAprobacion`.

Para construir un conjunto representativo capaz de alimentar los modelos predictivos, se descargó un volumen sustancial de archivos individuales segmentados por variable climática:

- Humedad Relativa Mínima: 126 archivos.
- Humedad Relativa Máxima: 130 archivos.
- Temperatura Mínima: 130 archivos.
- Temperatura Máxima: 131 archivos.
- Precipitación: 226 archivos.

Una restricción crítica identificada en la estructura de estos archivos CSV fue la ausencia de columnas que indicaran la jerarquía geográfica de la estación (Departamento, Municipio y Población). Para solventar esta carencia sin depender de la posterior integración de una base de datos externa de estaciones meteorológicas del IDEAM, el protocolo de descarga exigió que la nomenclatura de procedencia espacial fuera extraída y codificada directamente durante el proceso de búsqueda en el portal web. Esta decisión metodológica garantizó que, al momento de almacenar el archivo localmente, el contexto geográfico estuviera firmemente adherido a la serie temporal, facilitando su posterior sincronización espacial en la Capa Oro de la arquitectura de datos.

3.2 Arquitectura de Datos y Preprocesamiento

La fase de tratamiento de datos se fundamentó en la implementación de una arquitectura de procesamiento incremental, diseñada para transformar registros crudos, heterogéneos y frecuentemente incompletos en una matriz de características de alta fidelidad, optimizada para el aprendizaje automático. Este flujo se estructuró bajo el paradigma de niveles de madurez de la información, permitiendo que los datos transiten de forma secuencial por tres estadios de refinamiento: Bronce, Plata y Oro.

El proceso comenzó con la ingesta de registros documentales técnicos y registros meteorológicos dispersos, los cuales fueron sometidos a una limpieza rigurosa, validaciones de integridad física y una compleja integración espacio-temporal. La arquitectura no solo buscó consolidar una fuente única de verdad, sino también construir mecanismos de resiliencia ante la escasez de datos técnicos en las Zonas No Interconectadas (ZNI), garantizando la trazabilidad y la calidad estadística en cada transformación. A continuación, se presenta la representación esquemática de este flujo de datos en la Figura 3.5.

3.2.1 Adquisición y Origen de la Información

La construcción del repositorio se basó en la convergencia de tres fuentes de diversa naturaleza, lo que exigió protocolos de recolección diferenciados:

- **Datos de Demanda Energética:** Se obtuvo un registro histórico (2014-2025) mediante la recuperación de reportes mensuales de telemetría desde el portal del Instituto de Planificación y Promoción de Soluciones Energéticas (IPSE).




Figura 3.5: Flujo de procesamiento de datos (ETL) basado en la arquitectura Medallion.

Estos documentos se caracterizaron por ser extensas memorias técnicas de periodicidad mensual, cuya longitud osciló entre las 140 y 420 páginas según el formato de emisión. Cada archivo consolidó la información de la totalidad de las comunidades monitoreadas a nivel nacional, estructurada en secciones individuales por localidad. Dichos registros incluyeron esquemas técnicos de la infraestructura de generación diésel, tablas de consumo energético diario, curvas de carga y, en los formatos de mayor antigüedad, un cuerpo narrativo de carácter descriptivo sobre las condiciones de prestación del servicio.

- **Información Meteorológica:** Se recolectaron series temporales de variables ambientales del Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM). Debido a la complejidad de la arquitectura del portal institucional, la adquisición se realizó mediante un protocolo de extracción manual. Se seleccionaron datos de temperatura (mínima y máxima), humedad relativa (mínima y máxima) y precipitación, por ser los que mayor consistencia mostraron frente a otras variables como la radiación solar, la cual presentaba vacíos críticos para las zonas de estudio.
- **Referenciación Geoespacial:** Se ejecutó un proceso automatizado que extrajo las ubicaciones únicas (municipio-departamento) validadas en etapas posteriores para consultar servicios de referenciación espacial inversa, obteniendo así la latitud, longitud y altitud exacta de cada micro-red.

3.2.2 Capa Bronce: Extracción y Preservación de Datos Crudos

El objetivo principal de la capa Bronce fue establecer un registro histórico inmutable de todos los datos en bruto, priorizando una ingesta tolerante a fallos sobre la validación estricta. Al extraer información de fuentes heterogéneas, tales como documentos digitalizados mediante reconocimiento óptico (OCR), y diferir deliberadamente la imposición de tipos de datos, esta capa garantizó que las anomalías impredecibles en el origen, como errores de lectura o formatos de texto corruptos, no interrumpieran el flujo de procesamiento, capturando los datos exactamente como fueron generados en su origen.

Procesamiento de Energía y Adaptabilidad de Formatos

Se identificaron al menos tres formatos estructurales distintos en los documentos de energía, lo que dificultó principalmente la extracción del dato de “horas de suministro”. Mientras que las variables métricas se extrajeron de tablas ubicadas en secciones por ubicación (pueblo), la métrica de horas requirió un sistema adaptativo de tres niveles: extracción de la tabla principal, búsqueda en tablas secundarias de disponibilidad o, en última instancia, inferencia mediante análisis de texto en los párrafos de los resúmenes ejecutivos.

Procesamiento Climatológico

Los registros ambientales se consolidaron en un formato de lista larga, manteniendo cada medición como una fila individual para no alterar la estructura nativa del sensor.

Variables Obtenidas (Salida Capa Bronce):

- **Datos de Energía:** Identificadores temporales, referencia geográfica cruda — formato genérico PUEBLO (MUNICIPIO - DEPARTAMENTO)—, fecha del registro, energía activa, reactiva y aparente, factor de potencia y horas de servicio resueltas.
- **Datos Climatológicos:** Ubicación, identificación de la estación, variable meteorológica, fecha de medición, unidad de medición y valor registrado.

3.2.3 Capa Plata: Limpieza, Tipificación y Validación Física

El objetivo de esta capa consistió en transformar los registros crudos en una estructura relacional limpia, estandarizada y validada bajo parámetros físicos y tipos de datos rígidos. Esta capa actuó como el motor principal de control de calidad al imponer tipos numéricos estrictos, generar claves subrogadas mediante funciones criptográficas para asegurar la integridad relacional, y aplicar lógicas operativas vitales. Entre estas lógicas se destacó la distinción entre apagones mecánicos y anomalías de demanda nula, así como el cambio en el formato de la información meteorológica pivotando de una estructura vertical (un registro por fecha y variable) a una horizontal (un solo registro por fecha con todas las variables).

Refinamiento y Segmentación de Energía

Se desagregó la información geográfica para aislar en dimensiones independientes el municipio, el departamento y el pueblo (micro-red). Esta separación fue vital para diferenciar comunidades que operan sistemas independientes bajo una misma jurisdicción municipal. Se generó un identificador único mediante funciones de síntesis criptográfica para asegurar la trazabilidad y se aplicaron filtros físicos para limitar las horas de servicio a un máximo de 24 horas diarias.

Refinamiento Climatológico y Cambio de Estructura

Se realizó una operación de pivote matricial para pasar del formato “largo” a un formato “ancho”. En esta nueva topología, cada fila representó una fecha única por ubicación, organizando las variables (temperatura, humedad, precipitación) en columnas independientes.

Variables Obtenidas (Salida Capa Plata):

- **Energía:** Departamento, municipio y pueblo segmentados, identificador geográfico, fecha validada, energía activa, reactiva y aparente, factor de potencia y horas de servicio normalizadas.
- **Clima:** Departamento, municipio, identificador geográfico, fecha validada, columnas independientes para cada variable meteorológica validada (precipitación, temperaturas y humedades).

3.2.4 Capa Oro: Sincronización Espaciotemporal e Imputación Multi-nivel

La transición hacia la Capa Oro inicia con el enriquecimiento espacial del conjunto de datos. Utilizando la lista de municipios validados en la etapa anterior, se ejecutó un proceso de georreferenciación automatizado para integrar coordenadas geográficas y altitudes corregidas, elementos indispensables para la posterior sincronización con las estaciones meteorológicas del IDEAM.

El objetivo de la capa Oro fue fusionar los conjuntos de datos depurados y dispares (de plata) en una fuente única de verdad, robusta y diseñada de manera específica para las fases posteriores de aprendizaje automático. Esta capa gestionó una integración para asegurar la coherencia física entre ubicaciones, ejecutando algoritmos de proximidad espacial en un plano cartesiano tridimensional con penalizacio-

nes por altitud para vincular adecuadamente los pueblos (las micro-redes) con las estaciones meteorológicas. También impuso un ordenamiento cronológico riguroso, lo cual garantizó que la matriz de características resultante estuviera completamente blindada contra la filtración temporal de información antes de su introducción a la red neuronal.

Mecanismos de Integración y Autocuración

Ante la ausencia de mediciones climáticas locales, se diseñó una estrategia de imputación multinivel en cascada. Se registraron el nivel de imputación (0 a 4) y la distancia a la estación como métricas de confiabilidad para los modelos de aprendizaje automático. La jerarquía y justificación analítica de estos niveles se describe a continuación y se detallan en la Tabla 3.1.

Tabla 3.1: Jerarquía de Estrategias de Imputación Multinivel para Variables Meteorológicas y de Consumo.

Nivel	Estrategia Aplicada	Condición de Activación	Justificación Analítica
Nivel 0	Observación Directa	Dato original presente y validado físicamente en Capa Plata.	Máxima confiabilidad. Representa la fuente de verdad sin intervención algorítmica.
Nivel 1	Imputación Temporal (Interpolación)	Brechas temporales cortas donde la serie mantiene alta autocorrelación.	Preserva la continuidad de la señal inmediata sin introducir sesgos espaciales externos.
Nivel 2	Imputación Espacial (K-NN Tridimensional)	Brechas medias. Requiere coordenadas (Lat, Lon) y Altitud de la tabla de georreferenciación.	Reconstruye el dato basándose en las estaciones más cercanas topográficamente, capturando microclimas.
Nivel 3	Perfil Histórico de Estación	Vacíos prolongados donde las estaciones vecinas también presentan fallas.	Utiliza promedios estacionales y ventanas móviles de 30 días de la misma estación para respetar la ciclicidad.
Nivel 4	Contingencia Regional/Global	Pérdida total de telemetría local e histórica. Último recurso.	Emplea promedios departamentales agregados para evitar la pérdida de la fila de entrenamiento.

- 1. Interpolación Temporal:** Para brechas cortas dentro de una misma estación.

2. **Fusión Espacial Tridimensional:** Para aquellas localidades que carecían de registros meteorológicos propios en fechas específicas, se implementó un algoritmo de búsqueda de los k vecinos más próximos (k -NN) basado en coordenadas proyectadas en un espacio tridimensional. Este procedimiento resultó imperativo debido a la compleja topografía colombiana, donde la cercanía geográfica bidimensional no garantiza la similitud climática.

Este fenómeno se ejemplifica claramente en la relación entre municipios limítrofes que habitan realidades térmicas opuestas. Por ejemplo, en el departamento del Cauca, los municipios de López de Micay y El Tambo presentan una proximidad horizontal estrecha; sin embargo, mientras el primero se ubica en las tierras bajas del Pacífico (aprox. 130 m s. n. m.) bajo un régimen cálido y húmedo de 27°C, el segundo se eleva hasta los 1.750 m s. n. m., registrando temperaturas templadas de 18°C. Una transición similar se observa entre Murindó y Frontino en Antioquia, donde la cercanía fronteriza contrasta con un diferencial de altitud de más de 1.300 metros, variando desde la selva tropical del Atrato Medio hasta los climas templados de montaña. Como se puede observar en la Figura 3.6:

Para mitigar estos sesgos, se aplicó una penalización matemática a la altitud mediante un factor multiplicativo de 1000.0. Este ajuste permitió que el algoritmo seleccionara siempre el sensor más próximo con información disponible que compartiera condiciones climáticas y térmicas similares, priorizando la afinidad altitudinal sobre la cercanía en un plano bidimensional.

3. **Contingencia Histórica y Regional:** Promedios móviles de 30 días con desplazamiento temporal y promedios departamentales como último recurso.

Incorporación de Patrones de Estacionalidad

Se integraron dimensiones temporales para capturar la variabilidad sociológica del consumo. Estas variables (mes, día de la semana e indicador de festivos) se incluyeron bajo la premisa de que la demanda energética responde a ciclos de actividad humana. Los patrones de carga varían significativamente durante fines de semana o festivos debido a cambios en la actividad productiva y doméstica, mientras que el factor mensual captura ciclos económicos o periodos vacacionales específicos de las comunidades ZNI.




Figura 3.6: Imagen ilustrativa de la diferencia climática entre municipios cercanos en latitud y longitud pero con diferencia de altitud significativa.

Variables Obtenidas (Salida Capa Oro / Matriz Final):

La integración y consolidación de las fuentes resultó en la matriz final de entrenamiento, cuyo diccionario de variables se presenta a continuación en la Tabla 3.2.

Tabla 3.2: Diccionario de variables que conforman la matriz final de entrenamiento (Capa Oro).

Categoría	Variable(s)	Descripción Analítica
Geolocalización e Identificadores	Departamento, municipio, pueblo, latitud, longitud y altitud.	Variables espaciales y de elevación corregida para el modelo. Permiten el agrupamiento jerárquico.
Estacionalidad	Mes, día de la semana, indicador de festivos.	Captura la variabilidad sociológica y los ciclos de actividad productiva y doméstica de la demanda.
Objetivo (Target)	Potencia activa, reactiva, aparente, factor de potencia y horas.	Señales base del consumo energético. La potencia activa es la variable principal a predecir.
Climatológicas (Exógenas)	Precipitación, temperatura (mín/máx), humedad relativa.	Impacto ambiental en la demanda, procesado y sincronizado desde las estaciones del IDEAM.
Métricas de Confiabilidad	Nivel de imputación y distancia a la estación de origen.	Trazabilidad algorítmica y espacial calculada individualmente para cada variable climática.

3.3 Modelo Estadístico Base (ARIMA y ARIMAX)

Para la cimentación de un marco comparativo de rigor científico, se implementaron modelos estadísticos de la familia de promedios móviles integrados. Esta elección como línea base (*baseline*) respondió a la necesidad de establecer un referente de complejidad lineal contra el cual contrastar las capacidades de arquitecturas no lineales superiores de aprendizaje profundo.

Metodológicamente, se determinó restringir la fase de entrenamiento y predicción de manera exclusiva a la Potencia Activa (P), medida en kilovatios (kW). Esta decisión técnica obedeció a dos razones fundamentales. En primer lugar, permitió eliminar el ruido estadístico derivado de los desfases reactivos que no responden necesariamente a los mismos patrones de comportamiento humano que la deman-

da de potencia real, garantizando la comparabilidad estricta entre todos los modelos evaluados. En segundo lugar, esta restricción redujo significativamente el costo computacional del proyecto; la inclusión de modelos independientes para las potencias reactiva y aparente habría duplicado, como mínimo, el tiempo de procesamiento y los recursos de infraestructura requeridos, sin representar una ventaja significativa en la precisión de la firma de carga fundamental.

El Concepto de Silo Estadístico y Heterogeneidad de las ZNI

Dada la naturaleza física de las Zonas No Interconectadas (ZNI), donde cada micro-red opera como una isla energética independiente, se descartó la implementación de un modelo estadístico global único. Las ecuaciones de promedios móviles son intrínsecamente univariadas y carecen de mecanismos nativos para compartir pesos matemáticos entre series temporales de distinta procedencia. En este contexto, la implementación se estructuró bajo la lógica de silos de modelado, donde se entrenó un modelo independiente para cada una de las comunidades analizadas. Esta estrategia permitió capturar la firma estructural de cada localidad sin diluir las particularidades regionales en un promedio global que podría ocultar comportamientos críticos para la estabilidad de la red.

Validación de Estacionariedad Dual y Optimización de Parámetros

La adaptación de cada modelo requirió una validación de estacionariedad dual para asegurar la integridad de las series temporales. Este procedimiento consistió en la aplicación simultánea de dos pruebas con hipótesis contrapuestas: el Test de Dickey-Fuller Aumentado (ADF), diseñado para detectar la presencia de raíces unitarias (tendencias estocásticas), y la prueba KPSS, que evalúa la estacionariedad alrededor de una tendencia determinística. La necesidad de este enfoque dual radicó en que una serie puede carecer de raíces unitarias y, aun así, presentar desviaciones que invaliden los supuestos de media y varianza constantes. Solo mediante la convergencia de ambas pruebas se determinó el orden de integración (d) necesario para transformar los registros en una señal estadísticamente estable.

La selección de la topología óptima para cada serie se realizó mediante el uso de la biblioteca especializada *pmdarima*, la cual funcionó como un motor de optimización que evalúa iterativamente criterios de información estadística para determinar la mejor combinación de parámetros autorregresivos, de integración y de media móvil. Este procedimiento permitió maximizar el principio de parsimonia. La par-

simonia se definió como la selección del modelo más simple posible que explicara adecuadamente la variabilidad de los datos; un modelo con exceso de parámetros tiende a sobreajustarse al ruido intrínseco de las mediciones, perdiendo su capacidad de generalización y aumentando el error en el pronóstico de datos futuros. Las ecuaciones resultantes fueron resueltas mediante el marco de trabajo para modelado estadístico *statsmodels*, que proporcionó los algoritmos de álgebra lineal necesarios para la estimación precisa de los coeficientes.

Transición a ARIMAX y Restricción Lineal de Exogeneidad

La evolución hacia el modelo ARIMAX permitió la inyección de dimensionalidad adicional proveniente de la matriz de características consolidada en la capa oro. En su núcleo, el modelo ARIMAX se define matemáticamente mediante la siguiente estructura lineal:

$$y_t = \delta + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{j=1}^q \theta_j \epsilon_{t-j} + \sum_{k=1}^n \beta_k x_{k,t} + \epsilon_t. \quad (3.1)$$

Donde y_t representa la potencia activa en el tiempo t , los términos ϕ y θ corresponden a los componentes autorregresivos y de media móvil, y la expresión $\sum \beta_k x_{k,t}$ representa el impacto de las variables exógenas mediante coeficientes fijos β . Las especificaciones técnicas de estos parámetros se consolidan en la Tabla 3.3.

Tabla 3.3: Resumen de parámetros y justificación técnica para la configuración del modelo ARIMAX.

Componente / Variable	Especificación	Justificación Técnica
Orden Autoregresivo (p)	Análisis <i>PACF</i>	Representa la inercia histórica y la correlación directa con los pasos de tiempo inmediatamente anteriores.
Diferenciación (d)	Test <i>ADF</i>	Define el orden de integración necesario para eliminar la tendencia y estabilizar la media de la serie.
Media Móvil (q)	Análisis <i>ACF</i>	Modela la persistencia de los choques aleatorios o errores en el sistema.
Regresores Climáticos	Temperatura, Precipitación, Humedad	Injectan la varianza ambiental; se destaca el tratamiento logarítmico de la precipitación para manejar la asimetría.
Regresores Calendario	Día de la semana, Festivos	Capturan los ciclos de actividad antropogénica que dictan los picos de demanda.

Bajo este marco, se estableció una restricción metodológica rigurosa: se incorporaron de manera exclusiva los indicadores de estacionalidad social (día de la semana y festivos), excluyendo deliberadamente todas las variables climatológicas.

Esta decisión se fundamentó en la diferencia entre el impacto de los cronogramas humanos y la interacción ambiental dentro de un modelo lineal. Un modelo ARIMAX opera como una regresión lineal extendida, donde las variables meteorológicas no impactan el consumo de manera lineal, sino compuesta; por ejemplo, una temperatura elevada combinada con una alta humedad genera un incremento exponencial en la carga térmica que obliga a los equipos de refrigeración a realizar un esfuerzo desproporcionado. Puesto que la arquitectura ARIMAX carece de capacidad nativa para modelar interacciones no lineales sin matrices de rezago prohibitivas, incluir el clima degradaría el rendimiento al introducir ruido algorítmico.

Por el contrario, los eventos de calendario modulan el comportamiento humano de manera lineal y discreta. La presencia de un día festivo actúa como un interruptor binario que detiene maquinaria y altera la ocupación de los hogares, permitiendo al modelo desplazar el intercepto de la demanda base sin comprometer la integridad autorregresiva. Estratégicamente, esta exclusión cimentó una línea base estadísticamente pura que demostró la necesidad imperativa de implementar arquitecturas avanzadas no lineales, como XGBoost y redes neuronales LSTM, en etapas posteriores del proyecto.

Preparación de Datos y la Isla de Continuidad Temporal

El entrenamiento consumió el conjunto de datos depurado obtenido en la capa oro. Para asegurar la validez de los cálculos, se aplicó un protocolo de detección de la “isla mayor de continuidad”, seleccionando el segmento temporal contiguo más extenso que no presentara interrupciones superiores a catorce días. Este límite fue imperativo para evitar la aparición de autocorrelaciones sintéticas. Este fenómeno ocurre cuando el modelo trata observaciones temporalmente distantes como si fueran adyacentes debido a la omisión inadecuada de brechas; esto obliga a los componentes autorregresivos a calcular dependencias sobre una línea de tiempo distorsionada que no existe en la realidad física, provocando que el sistema “aprenda” patrones inexistentes que invalidan los coeficientes de rezago.

Como se ilustra en la Figura 3.7, la partición se realizó siguiendo un esquema cronológico del 80 % para entrenamiento y 20 % para evaluación, sin aleatorización, preservando la dependencia temporal. Se estableció un umbral de viabilidad de sesenta días mínimos de datos históricos para garantizar que el entrenamiento cubriera suficientes ciclos semanales para ser significativo.




Figura 3.7: Esquema de partición temporal 80/20 y selección de la isla de continuidad para modelos estadísticos base.

Orquestación Paralela y Gestión de Experimentos con MLflow

Debido a la magnitud de ajustar cientos de modelos individuales, se empleó un motor de procesamiento paralelo basado en procesos distribuidos para eludir las restricciones de ejecución serial del entorno de programación. El seguimiento de este ciclo de vida se integró mediante la plataforma *MLflow*, un marco de trabajo dedicado a la gestión integral del ciclo de vida del aprendizaje automático. Su uso fue fundamental para centralizar el registro de parámetros estadísticos, métricas de error y los artefactos de cada uno de los modelos independientes generados. *MLflow* permitió auditar de forma sistemática la evolución del rendimiento, garantizando la reproducibilidad de cada experimento y facilitando una comparación estructurada entre las diferentes micro-redes.

3.4 Ensamble de Árboles de Decisión (XGBoost)

Como respuesta a la incapacidad estructural de los modelos lineales para capturar las interacciones ambientales compuestas y no lineales, se implementó un modelo de aprendizaje automático basado en la arquitectura de Máquinas de Potenciación del Gradiente (*Gradient Boosting Machines*). Para este propósito, se utilizó el marco de trabajo computacional *XGBoost*, una biblioteca matemática optimizada que construye un ensamble secuencial de árboles de decisión, donde cada nuevo árbol se entrena específicamente para minimizar el error residual de los árboles predecesores mediante el descenso de gradiente. A diferencia del enfoque de “silos aislados” utilizado en el modelo estadístico base, esta arquitectura operó como un modelo global único, capaz de analizar el cruce de datos de todas las micro-redes simultáneamente.

para descubrir patrones espaciotemporales universales. Al igual que en la línea base, la predicción se restringió de manera exclusiva a la Potencia Activa.

Justificación y Adaptación Tabular (Ingeniería de Características)

Para transitar de una serie de tiempo secuencial a un modelo de ensamble global, fue imperativo transformar la matriz de características consolidada en la capa oro en una estructura tabular de aprendizaje supervisado. Puesto que los árboles de decisión carecen de compuertas recurrentes nativas para procesar la secuencia del tiempo, cada fila de datos debió ser enriquecida con su propio contexto histórico explícito a través de la creación de rezagos temporales y promedios móviles, tal y como se detalla visualmente en la Figura 3.8.




Figura 3.8: Esquema de ingeniería de características, creación de rezagos temporales y promedios móviles para modelos tabulares.

Específicamente, se generaron rezagos (*lags*) de uno, siete y catorce días sobre la variable objetivo y las variables climáticas. Esta decisión matemática permitió dotar al algoritmo de una “memoria” a corto y mediano plazo, obligándolo a evaluar qué sucedió exactamente en el ciclo diario anterior y en el mismo día de las semanas previas. Complementariamente, se calcularon promedios móviles sobre ventanas de siete y treinta días; estas dimensiones adicionales actuaron como filtros de suavizado que permitieron al modelo diferenciar entre una anomalía aislada (un pico de un solo día) y una tendencia macroeconómica o estacional sostenida en la comunidad.

Este procedimiento matemático se orquestó bajo estrictas fronteras de aislamiento para prevenir la filtración de información. En primer lugar, se aplicó una segmentación fundamentada en una llave geográfica compuesta (departamento, municipio y pueblo) antes de cualquier desplazamiento temporal, garantizando que el al-

goritmo no cruzara matemáticamente la historia de consumo de dos comunidades físicamente distintas. En segundo lugar, se descartó el uso de desplazamientos de filas secuenciales abstractos, optando por cálculos exactos de calendario para evitar que la inactividad de los sensores en las ZNI generara adyacencias temporales falsas. Finalmente, para los cálculos de ventanas móviles, se impuso una restricción matemática de intervalo abierto por la derecha, asegurando que la estadística histórica terminara estrictamente un instante antes del tiempo a predecir ($t - 1$), erradicando cualquier riesgo de filtración de la variable objetivo.

Transformación del Objetivo y Tratamiento de Variables

El entrenamiento de un modelo global con micro-redes de escalas diametralmente opuestas presentó el desafío matemático de la “dominancia de magnitud”, donde las comunidades con alto consumo generan gradientes de error masivos que sesgan el algoritmo. Para neutralizar este efecto, la Potencia Activa fue sometida a una doble transformación matemática. Inicialmente, se aplicó una compresión logarítmica para estabilizar la varianza, utilizando la función:

$$y_{scaled} = \ln(1 + y). \quad (3.2)$$

Posteriormente, se ejecutó una estandarización espacial independiente para cada localidad, ajustando la distribución histórica de cada pueblo a una media de cero y desviación estándar de uno. Para garantizar la resiliencia del sistema durante la fase de evaluación ante el descubrimiento de poblaciones completamente nuevas (*cero-shot*), se implementó un mecanismo de respaldo (*Cold-Start Fallback*). Si el algoritmo encontraba una ubicación sin datos históricos locales durante la inferencia, el sistema revertía automáticamente a utilizar la media y la desviación estándar globales calculadas sobre la totalidad del conjunto de entrenamiento nacional, permitiendo inferir una línea base lógica para comunidades inéditas.

Topología de Optimización y Regularización

Para controlar la complejidad de las interacciones no lineales y evitar el sobreajuste, se implementó una estricta estrategia de regularización L2 (Ridge), descartando la regularización L1 para evitar que el algoritmo anulara arbitrariamente variables climáticas correlacionadas. Matemáticamente, el marco de trabajo calculó el peso óptimo de una hoja del árbol (w_j^*) como:

$$w_j^* = -\frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda}, \quad (3.3)$$

Donde g_i y h_i representan los gradientes de primer y segundo orden de la función de pérdida, e I_j es el conjunto de índices de las muestras en la hoja j . Al optimizar el parámetro de regularización λ , se penalizaron los pesos excesivamente grandes, forzando al modelo a distribuir su aprendizaje de forma equitativa entre múltiples sensores climáticos en lugar de memorizar el ruido de una única variable.

Partición Cronológica y Filtrado de Ceros Estructurales

El conjunto de datos tabular se dividió siguiendo un esquema cronológico inquebrantable: se asignaron los registros entre los años 2014 y 2023 para el entrenamiento, la totalidad del año 2024 se aisló para la validación de hiperparámetros, y el año 2025 se reservó de manera exclusiva para la prueba final de desempeño. Un paso crítico fue la exclusión proactiva de los “ceros estructurales” del conjunto de entrenamiento; puesto que un consumo de cero en las ZNI representa usualmente un apagón mecánico y no una decisión de demanda, eliminarlos de la matriz de entrenamiento garantizó que los gradientes de actualización matemática reflejaran puramente la dinámica real de la demanda.

Optimización Bayesiana de Hiperparámetros

Para identificar la arquitectura de ensamble óptima, se utilizó *Optuna*, implementando un algoritmo bayesiano de búsqueda inteligente. El espacio de búsqueda se configuró para optimizar los parámetros fundamentales del algoritmo, definidos matemáticamente como:

- La profundidad máxima de los árboles (d_{max}), que controla la complejidad de las interacciones.
- La tasa de aprendizaje (η), encargada de definir el tamaño del paso en el descenso de gradiente.
- El parámetro de regularización (λ), para el control de la magnitud de los pesos en las hojas.
- La reducción mínima de pérdida requerida para efectuar una partición (γ).

- Las fracciones de submuestreo estocástico de observaciones y columnas para inducir robustez.

Asimismo, para cuantificar el impacto de las variables, se extrajo la métrica de Ganancia (*Gain*). Esta métrica cuantifica la reducción exacta en la función de pérdida que se logra cada vez que una variable es utilizada para bifurcar un nodo del árbol, siguiendo la lógica matemática:

$$Gain = \frac{1}{2} \left[\frac{(\sum g_L)^2}{\sum h_L + \lambda} + \frac{(\sum g_R)^2}{\sum h_R + \lambda} - \frac{(\sum g)^2}{\sum h + \lambda} \right] - \gamma, \quad (3.4)$$

Donde los subíndices L y R representan los nodos hijos izquierdo y derecho. En términos prácticos, esta métrica proporciona una medida auditable de la importancia de los factores climáticos frente a los eventos sociales, indicando cuánto “valor” aporta cada variable para reducir la incertidumbre del pronóstico.

Evaluación Espacial Cero-Shot, Heurística y Orquestación

Como se detalla en la Figura 3.9, se diseñó una tubería de evaluación de retención espacial (*Spatial Holdout*), donde comunidades enteras fueron ocultas durante el entrenamiento para forzar al modelo a ejecutar una predicción “cero-shot” basada únicamente en similitudes meteorológicas y demográficas.

Durante la validación, se superpuso una regla heurística física: si los datos operativos indicaban que las horas de servicio fueron nulas debido a un fallo en planta, la salida del modelo fue sobreescrita forzosamente a cero kilovatios.

Finalmente, el ciclo de vida del ensamble fue monitoreado mediante la plataforma *MLflow*. A diferencia del uso en los modelos estadísticos, aquí la plataforma gestionó la matriz multidimensional de estudios de optimización bayesiana y serializó el modelo campeón global junto con los artefactos de estandarización local (medias y desviaciones por pueblo), asegurando la trazabilidad absoluta de las transformaciones aplicadas.

3.5 Redes Neuronales Recurrentes (LSTM)

La transición desde los ensambles basados en árboles hacia una arquitectura de Aprendizaje Profundo (*Deep Learning*) representó un cambio de paradigma fundamental en el procesamiento de la información de las Zonas No Interconectadas. Mientras que los modelos anteriores evaluaron el historial temporal como columnas




Figura 3.9: Arquitectura de evaluación de retención espacial (*Spatial Holdout*) para predicción cero-shot en XGBoost.

tabulares estáticas, las Redes Neuronales Recurrentes —específicamente las de Memoria a Corto y Largo Plazo (LSTM)— procesan secuencias de datos de manera nativa mediante compuertas de memoria interna Hochreiter y Schmidhuber, 1997. Esta capacidad estructural resulta imperativa para capturar dependencias temporales de largo alcance. Al igual que en las etapas metodológicas precedentes, el entrenamiento de esta red neuronal se restringió exclusivamente a la predicción de la Potencia Activa.

Justificación y el Fallo de Escala (Dominancia de Magnitud)

El entrenamiento de una red neuronal global capaz de inferir el consumo energético a través de micro-redes físicamente dispares impuso restricciones matemáticas severas. Las comunidades en estudio exhibieron una heterogeneidad extrema: desde pequeños asentamientos que consumen 50 kW hasta centros regionales que demandan 5,000 kW. Intentar predecir kilovatios absolutos de forma directa provoca un fenómeno conocido como “dominancia de magnitud” o fallo de escala. En este escenario, los gradientes de error generados por la localidad de 5,000 kW eclipsarían matemáticamente a los de la localidad de 50 kW, induciendo una “inanición del gra-

diente” (*Gradient Starvation*) Pezeshki et al., 2021 donde la red neuronal ignora por completo los patrones de las poblaciones más vulnerables.

Asimismo, la aplicación de escaladores globales tradicionales (como la normalización Min-Max) comprimiría la varianza operativa de un pueblo pequeño en una banda decimal microscópica (ej. 0.0001 a 0.0003), volviendo sus señales de consumo invisibles para las funciones de activación de la red. Por otro lado, utilizar variaciones porcentuales estándar genera una asimetría matemática destructiva: una caída de 100 kW a 50 kW produce un error del -50 %, pero la recuperación exacta de 50 kW a 100 kW produce un +100 %, distorsionando permanentemente la superficie de pérdida de la red neuronal.

Transformación Invariante a la Escala y el Sesgo de Persistencia

Para erradicar el fallo de escala, resultó indispensable implementar un método de transformación que homogeneizara el comportamiento de todas las localidades. A diferencia del modelo XGBoost, el cual se basa en la construcción de árboles de decisión que segmentan los datos mediante umbrales ortogonales, las redes neuronales operan mediante la suma de pesos que atraviesan funciones de activation saturables (como la sigmoide). Si los datos de entrada no se encuentran estrictamente delimitados, las activaciones neuronales se saturan, deteniendo el aprendizaje matemático Lee et al., 2024.

Para resolver esto, la variable objetivo fue desacoplada de su magnitud absoluta y transformada en un espacio de retornos relativos, denominado “Retorno Logarítmico Normalizado por Ancla”. Durante las pruebas iniciales, se identificó que anclar la predicción simplemente al día anterior ($t - 1$) generaba un grave “sesgo de persistencia”, también conocido como la trampa del pronóstico ingenuo (*Naive Forecasting Trap*) Park et al., 2024. Bajo esta configuración, la red neuronal aprendía a minimizar el error cuadrático medio pronosticando constantemente un retorno logarítmico de 0,0, copiando efectivamente la demanda del día anterior e ignorando por completo las variables meteorológicas exógenas.

Para romper este sesgo de persistencia y desacoplar la memoria de la línea base (*Decoupled Memory*), se redefinió el concepto fundamental de estabilización:

- **El Dato Ancla (Y_{ancla}):** Se definió formalmente como un promedio móvil calculado sobre una ventana de anclaje específica (*anchor_window*). Esta arquitectura obligó a la red a predecir las desviaciones frente a la tendencia local, separando matemáticamente la longitud de la memoria de la secuencia (*sequen-*

ce_length) de su línea base. Por ejemplo, la red fue configurada para ingerir un tensor histórico de 30 días para comprender la estacionalidad profunda, pero fue forzada a pronosticar la desviación del día objetivo frente al promedio matemático de los últimos 7 días.

Al establecer esta línea base móvil desplazada estratégicamente un paso hacia atrás para evitar filtración temporal, se calculó la diferencia logarítmica:

$$Objetivo_t = \ln(Y_t) - \ln(Y_{ancla}). \quad (3.5)$$

Esta transformación garantizó una simetría perfecta ante aumentos y caídas. Por ejemplo, si la media móvil de los últimos 7 días en una comunidad es de 50 kW y el consumo actual es de 55 kW (+10 %), la diferencia logarítmica ($\ln(55) - \ln(50) \approx 0,095$) es matemáticamente idéntica a la generada por un hub regional que pasa de un promedio de 5,000 kW a 5,500 kW ($\ln(5500) - \ln(5000) \approx 0,095$). Esto asegura que ambas variaciones generen exactamente el mismo gradiente de aprendizaje en la red.

Para proteger el cálculo ante picos transitorios masivos, el espacio latente fue sometido a una limitación dinámica estricta (*clipping*). Los límites de este recorte ($[latent_clip_min, latent_clip_max]$) fueron tratados como hiperparámetros y matemáticamente optimizados por la plataforma de búsqueda bayesiana para hallar el umbral ideal. Finalmente, este valor acotado fue comprimido al espacio de activación estricto de $[0,0, 1,0]$ requerido por la red mediante la ecuación estándar de Mínimos y Máximos:

$$Y_{activación} = \frac{Objetivo_{limitado} - \text{mín}}{\text{máx} - \text{mín}}. \quad (3.6)$$

Esta proyección centró elegantemente un escenario de “cero desviación respecto a la tendencia local” en un punto referencial constante dentro del espacio de activación neuronal, dotando a la LSTM de una escala universal. Para preservar la capacidad de predecir el pico de arranque en frío (*Cold Load Pick-up*), fenómeno ampliamente documentado en la recuperación de sistemas eléctricos Sun, 2024, la variable que medía la distancia temporal hacia el último día operativo se mantuvo inalterada y acoplada a una incrustación independiente, protegiendo así el modelado de la carga reprimida.

Ingeniería Exógena, Volatilidad Dinámica y Límites Físicos

La preparación de las variables externas requirió un tratamiento pausado y riguroso. Las técnicas de escalado convencionales fallan drásticamente frente a anomalías ambientales extremas. Para prevenir esto, se aplicó un escalado fundamentado en umbrales físicos absolutos aplicados matemáticamente de forma directa: las temperaturas se limitaron al rango operativo de $[-5^{\circ}\text{C}, 60^{\circ}\text{C}]$, la humedad relativa al rango lógico de $[0\%, 100\%]$, y las horas de servicio a $[0, 24]$. Para variables con alta asimetría positiva, como la precipitación acumulada y distancias espaciales, se aplicó una estabilización logarítmica ($\ln(1 + x)$) antes de ser normalizadas. Las variables temporales categóricas se codificaron de forma cíclica utilizando transformaciones geométricas de seno y coseno, erradicando las falsas discontinuidades del calendario Khazem y Kanso, 2025.

Para capturar la inestabilidad inherente de las ZNI y escalar empíricamente las anomalías (*Empirical Anomaly Scaling*), se incorporaron características de volatilidad dinámica calculadas estrictamente durante la extracción de la secuencia para evitar filtración temporal. Se introdujeron dos métricas fundamentales:

1. **Coefficiente de Variación Móvil:** Calculado como σ/μ , proporcionando una métrica directa de inestabilidad local, protegida con una máscara lógica para evitar divisiones por cero en caso de apagones.
2. **Intensidad de Ráfaga Z (Z-Surge):** Calculada como $\sum \max(0, \frac{y_i - \mu}{\sigma} - \tau)$, la cual enseñó explícitamente a la red la frecuencia y magnitud de anomalías recientes basadas en un umbral dinámico optimizado algebraicamente (τ).

Normalizar estas características introdujo una restricción física severa: el valor de cero tiene un significado físico absoluto de “cero volatilidad”. Utilizar un escalador estándar de Mínimos y Máximos habría desplazado la línea base y destruido esta proporcionalidad. Por consiguiente, se implementó un escalado sobre el valor máximo absoluto (*MaxAbsScaler*, calculado como $X/|X_{\text{máx}}|$), lo cual ancló el cero de forma impecable. Como medida de seguridad (*Safety Clipping*), en caso de que una tormenta inédita en el conjunto de prueba produjera un escalar superior a 1,0, los valores transformados fueron recortados rígidamente al intervalo $[0, 1, 0]$ para garantizar que ninguna anomalía externa pudiera desbordar los límites de activación neuronal.

Memorización Espacial y Generalización Cero-Shot (*Geographic Proxy Embeddings*)

Para resolver las discrepancias predictivas entre grandes concentraciones urbanas y diminutas aldeas rurales, se implementó un sistema de incrustaciones geográficas (*Geographic Proxy Embeddings*) que permitió a la LSTM memorizar y aprender los comportamientos socioeconómicos y las varianzas basales únicas de cada micro-red basándose en su identificador local (*town_id*).

Los codificadores tradicionales representan un riesgo masivo de fallo catastrófico en producción cuando encuentran una categoría completamente nueva. Para habilitar la generalización *cero-shot* ante micro-redes inéditas Liao et al., 2024, se diseñó un Árbol Jerárquico de Respaldo Geográfico (*Hierarchical Geographic Fall-back Tree*) acoplado a un transformador personalizado. Durante el entrenamiento, este sistema calcula la mediana matemática de la demanda de energía para cada pueblo, municipio, departamento y para el registro global. Durante la inferencia, si el algoritmo detecta una micro-red nunca antes vista, el sistema realiza una búsqueda en cascada (*Cascading Inference*): rastrea el municipio de la nueva red y le asigna el vector de identidad del poblado conocido dentro de ese mismo municipio que posea la mediana de demanda más cercana. Si el municipio también es desconocido, retrocede al proxy departamental y, finalmente, al proxy global. Esto garantiza que las micro-redes nuevas siempre reciban un vector físico asimilable y lógico.

La dimensionalidad de esta memoria espacial (*town_embedding_dim*) no fue fijada arbitrariamente, sino tratada como un hiperparámetro extraído dinámicamente, permitiendo al optimizador bayesiano descubrir la capacidad matemática exacta requerida para diferenciar comunidades sin sobreajustarse al ruido local. Además, como mecanismo de seguridad en la ingeniería de operaciones (*MLOps Safeguard*), la extracción de este identificador geográfico dentro del grafo computacional se realizó exclusivamente mediante indexación negativa relativa (ej. extrayendo siempre la última columna del tensor), inmunizando la estructura ante la adición de nuevas variables meteorológicas en etapas previas del canal de datos.

Topología de la Red Neural

Como se detalla en la Figura 3.10, el diseño del grafo computacional fue implementado utilizando PyTorch Paszke et al., 2019, un marco de trabajo de cálculo tensorial que permite un control dinámico de la memoria y la orquestación algebrái-

ca profunda. La red se diseñó para fusionar inteligentemente dimensiones continuas y categóricas.




Figura 3.10: Topología del modelo LSTM, ilustrando las capas de entrada, incrustaciones espaciales (*embeddings*), recurrencia y cabeza de regresión final.

Se implementó una capa de incrustación compartida para procesar todas las banderas categóricas indicadoras de calidad de los sensores. En lugar de aislar las señales de imputación meteorológica, enrutar todos los indicadores por una misma capa forzó a la red a aprender una representación matemática universal de la “calidad

de imputación”, reduciendo masivamente la cantidad de parámetros. Posteriormente, los tensores categóricos incrustados fueron aplanados y concatenados horizontalmente con las características flotantes continuas a nivel de secuencia.

Tras la fusión, el tensor tridimensional atravesó las celdas recurrentes de la LSTM, las cuales emplearon funciones de activación Sigmoide y Tangente Hiperbólica (Tanh) para regular el flujo de memoria histórica. Finalmente, el estado oculto absoluto del final de la secuencia fue extraído y procesado por una capa densa de regresión final utilizando la activación GELU (*Gaussian Error Linear Unit*). Esta es una función no monotónica que mitiga el problema de la “muerte del gradiente” de las unidades ReLU tradicionales Hendrycks y Gimpel, 2016, proporcionando una transformación suavizada antes de la proyección lineal de la predicción continua.

Estrategia de Entrenamiento y Optimización para LSTM: Tensores, Partición Cronológica y Enmascaramiento

Como se ilustra en la Figura 3.11, el diseño de la evaluación se basó en una partición estricta y cronológica de los datos, coincidiendo idénticamente con el método usado en los modelos previos: los registros hasta 2023 conformaron el entrenamiento, el 2024 fungió como validación y el 2025 se preservó para la prueba final, prohibiendo cualquier aleatorización cruzada para asegurar cero filtración de información temporal.

La información tabular debió ser reestructurada espacialmente en tensores tridimensionales de la forma [*muestras, pasos de tiempo, características*]. Las redes recurrentes asumen matemáticamente que cada paso de tiempo en una secuencia es rígidamente equidistante. Desplazar ventanas de memoria a través de brechas temporales causadas por fallos de telemetría corrompe la física del tiempo. Para resolver esto, el algoritmo calculó dinámicamente las distancias entre observaciones; cualquier vacío mayor a un día generó un nuevo bloque contiguo (“Isla Temporal”). Para evitar un consumo inmanejable de memoria RAM durante la extracción de estas secuencias, se implementó una estrategia de memoria de “cero copias” (*Zero-Copy Math*) utilizando manipulaciones algebraicas a bajo nivel sobre los ejes de las matrices, permitiendo la reestructuración tridimensional sin duplicar los datos en el sistema.

La longitud de la secuencia o horizonte histórico (*sequence_length*) no fue codificada con un valor teórico fijo (ej. 7 días), sino que fue tratada como un hiperparámetro fluido. Esto delegó en la optimización bayesiana la tarea de balancear matemá-




Figura 3.11: Algoritmo de segmentación por Islas Temporales para la mitigación de vacíos de datos y generación estructurada de tensores.

ticamente la recolección de contexto histórico frente al problema del desvanecimiento del gradiente en secuencias excesivamente largas.

Dado que la red debe predecir el comportamiento de la demanda, los apagones mecánicos (ceros estructurales) representaron una anomalía estructural. Para purgar este efecto, se implementó una máscara de purga (*Purge Mask*). El sistema interceptó la carga de datos hacia la red neuronal, identificó secuencias matemáticas donde la proyección futura predecía directamente un apagón físico y las purgó del espacio de características, obligando al algoritmo a entrenarse estrictamente sobre líneas base de demanda operativa real.

Optimización y Momento Autorregresivo (Penalización Direccional)

La actualización de los pesos neuronales se ejecutó mediante el optimizador AdamW Loshchilov y Hutter, 2019, una variante algorítmica de optimización adaptativa que desacopla activamente la penalización de la magnitud de los pesos (decaimiento de pesos o regularización L2) de la tasa de aprendizaje. Esta separación, fundamental en arquitecturas profundas, permitió constreñir pesos grandes sin interferir con la convergencia en superficies de pérdida complejas.

El Error Cuadrático Medio (MSE) base actúa de forma puntual y carece de la capacidad de penalizar desplazamientos de fase (por ejemplo, predecir el pico de consumo de hoy, pero para el día de mañana). Para corregir la lentitud de ajuste (*sluggishness*) y optimizar la predicción de picos, se abandonó la función MSE tradicional en favor de un módulo de pérdida matemático personalizado que implementó una Penalización de la Derivada Direccional (*Autoregressive Momentum*). El cálculo de este objetivo compuesto se estructuró mediante los siguientes pasos matemáticos:

- **Alineación de la Derivada:** La función de pérdida calculó la pendiente o derivada real ($\Delta_{true} = y_{true} - y_{t-1}$) y la contrastó con la pendiente predicha ($\Delta_{pred} = y_{pred} - y_{t-1}$).
- **Castigo por Discordancia de Signos:** Si el modelo pronosticaba una dirección física incorrecta (por ejemplo, predecir un aumento de demanda cuando la realidad caía), una máscara booleana activaba una penalización matemática severa:

$$Penalty = (\Delta_{true} - \Delta_{pred})^2 \quad (3.7)$$

Matemáticamente, al desarrollar esta expresión, los términos históricos y_{t-1} se cancelan, simplificando la penalización exactamente a $(y_{true} - y_{pred})^2$. En la prác-

tica, este comportamiento duplicó efectivamente el error base de la red, castigando de forma exclusiva a aquellos pronósticos que fallaron en la dirección de la tendencia.

- **Objetivo Compuesto:** La salida final de la función se consolidó como una suma ponderada que combinó el error base y el castigo direccional promediado:

$$\text{Pérdida Total} = \text{BaseMSE} + (\lambda \times \overline{\text{Penalty}}) \quad (3.8)$$

donde el factor λ representó el peso de la penalización direccional (*derivative_penalty_weight*), un hiperparámetro matemático optimizado dinámicamente por la plataforma bayesiana.

- **Ejecución en el Espacio Latente:** Para evitar la explosión de gradientes en el optimizador originada por variaciones de miles de kilovatios físicos, esta penalización se calculó de manera estricta dentro del espacio latente acotado $[0,0,1,0]$.

Además, como mecanismo de robustez operacional (*MLOps Safety*), para extraer el punto referencial histórico (y_{t-1}) se desarrolló un orquestador que consultó dinámicamente los índices numéricos exactos de las variables desde la matriz de datos y los inyectó en la firma matemática de entrenamiento. Esto aseguró la sincronización inquebrantable de la función de pérdida independientemente del reordenamiento previo de las columnas. El control final de la complejidad se garantizó aplicando la técnica de abandono de conexiones (*Dropout*) Srivastava et al., 2014 de forma estocástica dentro de las capas y de la cabeza de regresión final.

Búsqueda de Hiperparámetros, Parada Temprana y Orquestación

La determinación de la topología óptima —incluyendo la longitud de la secuencia de entrada, el número de capas recurrentes, la dimensionalidad oculta, la tasa de aprendizaje, los límites inferior y superior usados para acotar la función objetivo, *sequence_length*, *anchor_window* y τ — fue delegada al marco de trabajo de optimización bayesiana *Optuna*. Para garantizar la validez metodológica, la búsqueda se ejecutó bajo una barrera de partición cronológica estricta: los años hasta el 2023 se asignaron al entrenamiento, el año 2024 se utilizó exclusivamente como conjunto de validación para la evaluación bayesiana de los hiperparámetros, y el 2025 se aisló completamente como conjunto de prueba final sin permitir aleatorizaciones.

El proceso integró mecanismos heurísticos de poda (*pruning*); si las matemáticas bayesianas determinaban que una topología particular presentaba una convergencia deficiente, la iteración se abortaba tempranamente. Asimismo, un mecanismo de parada temprana detuvo el entrenamiento cuando el error sobre el conjunto de validación dejó de disminuir, previniendo el sobreajuste. Toda la evolución de las funciones de pérdida, la matriz de hiperparámetros y el modelo ganador final fueron almacenados de manera inmutable utilizando la plataforma de gestión de ciclo de vida de aprendizaje automático *MLflow*. Dada la complejidad de esta arquitectura profunda, la integración con *MLflow* fue instrumental para registrar no solo la precisión final, sino las curvas de pérdida por época y los artefactos de la red (pesos y grafos), asegurando la reproducibilidad total de los experimentos.

Reversión Matemática, Heurística Física y Análisis Estratigráfico de Errores

Para que la inferencia de la red neuronal tuviese utilidad técnica en la operación de las micro-redes, la predicción arrojada por el modelo (acotada en el espacio de activación $[0,0, 1,0]$) tuvo que ser invertida algebraicamente hacia kilovatios físicos reales. Este proceso inverso se ejecutó en dos pasos matemáticos exactos:

1. El sistema reconstruyó los tensores temporales creando desplazamientos idénticos en el conjunto de prueba para extraer la línea base de la tendencia móvil (las anclas, Y_{ancla}) con precisión exacta.
2. El proceso algebraico inverso procedió mediante la descompresión al espacio latente original ($\hat{Y}_{latente} = (\hat{Y}_{activación} - \text{mín}) \times (\text{máx} - \text{mín}) + \text{mín}$) seguido de la transformación de la base diferencial:

$$\hat{Y}_{kw} = \exp(\hat{Y}_{latente} + \ln(Y_{ancla})). \quad (3.9)$$

Sobre este resultado final, se aplicó una regla heurística física obligatoria: si los registros operativos determinaron que las horas de servicio fueron nulas, la predicción arrojada por la inteligencia artificial fue forzada deductivamente a cero kilovatios. Este paso garantizó que la evaluación de la precisión del modelo algorítmico se desligara por completo del comportamiento aleatorio de las fallas de infraestructura.

Finalmente, como mecanismo de validación final para comprobar la eficacia de la transformación invariante a la escala, se estableció dentro del diseño experi-

mental un análisis de la distribución estadística de los errores residuales (la diferencia entre el consumo físico real y la predicción) sobre el conjunto de prueba global. El objetivo metodológico de esta prueba es confirmar empíricamente la ausencia de sesgos poblacionales; si el diseño arquitectónico es exitoso, la distribución de los residuales deberá exhibir una forma simétrica y centrada de manera precisa en el valor cero, garantizando que el modelo generalizó la física del consumo sin importar la magnitud absoluta de la micro-red analizada.

3.6 Evaluación y Reconstrucción

3.6.1 *Post-procesamiento y Derivación de Potencias Dependientes*

Para el modelo que presente el mejor rendimiento predictivo global, se realizará una fase de reconstrucción de las variables eléctricas complementarias necesarias para la planificación técnica. En lugar de incurrir en el entrenamiento de modelos redundantes, se aplicará una derivación basada en las leyes de la ingeniería eléctrica utilizando el factor de potencia histórico validado en la etapa de limpieza de datos.

Mediante este procedimiento, la Potencia Aparente (S) se calculará como el cociente entre la potencia activa predicha y el factor de potencia, mientras que la Potencia Reactiva (Q) se obtendrá a partir de la relación geométrica del triángulo de potencias. Este enfoque garantiza una salida de datos físicamente coherente y completa para los tomadores de decisiones sin incrementar innecesariamente la complejidad del sistema predictivo.

3.6.2 *Métricas de Desempeño Unificadas*

Para evaluar de manera justa y comparar matemáticamente el desempeño de los modelos predictivos a través de infraestructuras diametralmente opuestas — desde grandes centros urbanos (ej. Leticia) hasta micro-redes rurales altamente volátiles (ej. Cachicamo)—, la tubería de evaluación implementó métricas de error tanto absolutas como independientes de la escala al finalizar el proceso de entrenamiento.

- **Métricas Absolutas (MAE y RMSE):** El Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE) estándar se calcularon de forma nativa en kilovatios físicos (kW) para evaluar la magnitud bruta de las desviaciones físicas del modelo a lo largo de la infraestructura. En el contexto de las ZNI, el

RMSE mantiene una importancia crítica, ya que penaliza de forma desproporcionada las desviaciones de gran magnitud; un error de subestimación severo puede exceder la capacidad de generación de la planta diésel local y desencadenar un colapso sistémico. Por su parte, el MAE proporciona una interpretación técnica directa de la desviación promedio, permitiendo a los operadores de red dimensionar físicamente el margen de reserva operativa necesario.

- **Error Absoluto Medio Normalizado (nMAE / WAPE):** Se calculó como la suma de los errores absolutos dividida por la suma de la demanda real. A diferencia del Error Porcentual Absoluto Medio (MAPE) estándar, el cual provoca errores matemáticos fatales de división por cero durante los apagones mecánicos característicos de las ZNI, el nMAE genera de manera segura un porcentaje limpio y proporcional de la carga típica del poblado.

$$nMAE = \frac{\sum |y_{true} - y_{pred}|}{\sum y_{true}} \quad (3.10)$$

- **Raíz del Error Cuadrático Medio Normalizado (nRMSE):** Se calculó como el RMSE bruto dividido por la demanda real promedio. Esta métrica independiente de la escala penaliza exponencialmente al modelo por omitir picos severos de consumo en poblados pequeños y altamente volátiles, proporcionando una medida relativa y estandarizada de la precisión en la predicción de picos de carga.

$$nRMSE = \frac{RMSE}{\bar{y}_{true}} \quad (3.11)$$

4. Resultados y Discusión

4.1 Análisis Exploratorio de Datos (EDA) y Perfilamiento de Arquetipos

El presente apartado detalla el Análisis Exploratorio de Datos (EDA, por sus siglas en inglés) aplicado a los registros telemétricos y climáticos de las Zonas No Interconectadas (ZNI) de Colombia. El objetivo de esta fase no es únicamente descriptivo, sino argumentativo: se busca demostrar empíricamente las dinámicas no lineales de la red que justifican la implementación de arquitecturas de Inteligencia Artificial, como el aumento de gradiente extremo (XGBoost) y las redes de memoria a corto y largo plazo (LSTM), por encima de modelos estadísticos tradicionales, y establecer un marco de pruebas matemáticamente riguroso para la evaluación de dichos modelos.

4.1.1 Diagnóstico de Infraestructura y Calidad de Datos

La telemetría en las ZNI presenta desafíos inherentes a su geografía y condiciones operativas. Como se observa en la Figura 4.1, existe una desincronización notable entre la tasa de fallos de la red eléctrica (apagones) y la disponibilidad de los sensores meteorológicos. Esta asimetría en la captura de datos genera series de tiempo altamente fragmentadas.

Para mitigar este impacto, el procesamiento de datos se estructuró bajo el estándar de Capa Oro (*Gold Layer*) (**véase la subsección 3.2.4**), donde los vacíos de información exógena fueron reconstruidos mediante imputaciones espaciales y promedios históricos. La Figura 4.2 ilustra la proporción de datos reales frente a datos imputados. La dependencia de valores reconstruidos en ciertos estratos de la red justifica metodológicamente la inclusión de capas de incrustación (*Embedding*) (**véase la subsección 3.5**) en la propuesta LSTM, permitiendo que el modelo pondere de forma autónoma la confiabilidad del dato de entrada en cada paso de tiempo y evite la propagación de errores estocásticos.




Figura 4.1: Radiografía de intermitencia y fallos en la telemetría de las ZNI.




Figura 4.2: Perfil de calidad y proporción de datos reales frente a imputados.

4.1.2 Dinámica Sociológica y la Paradoja de Simpson

El análisis del comportamiento de la demanda eléctrica frente al calendario sociológico —es decir, la categorización de los días de la semana en laborales, fines de semana y festivos— reveló uno de los hallazgos más determinantes para el diseño del modelo predictivo. Al normalizar espacialmente el consumo activo (Puntaje Z o *Z-Score*) y segmentar las micro-redes por su tamaño de demanda, se evidenció la presencia de la Paradoja de Simpson en el ecosistema de las ZNI. La Paradoja de Simpson es un fenómeno estadístico en el cual una tendencia aparente que se observa en diferentes grupos de datos desaparece o se invierte cuando estos grupos se combinan en un conjunto general (Ding, 2024). Como lo demuestra la Figura 4.3, el “efecto calendario” —entendido en este contexto como la variación sistemática del consumo energético en función de la tipología del día (Ding, 2024)— actúa de manera bidireccional, invirtiéndose según el volumen de la demanda. En las redes de gran demanda (promedio >250 kW), la carga principal se concentra en los días laborales, experimentando una caída drástica durante los fines de semana y festivos, posiblemente debido al cese de actividades en instalaciones comerciales y gubernamentales. Por el contrario, en las redes de menor demanda (<75 kW) —las cuales, bajo el contexto del sistema interconectado colombiano, se asume que poseen un carácter predominantemente residencial y rural (Ding, 2024)— el patrón es el opuesto: los días laborales presentan el menor consumo, mientras que los festivos registran picos de demanda. Este comportamiento divergente invalida el uso de parámetros estáticos globales e impone la necesidad de algoritmos de Aprendizaje Automático (*Machine Learning*) capaces de identificar estas interacciones complejas.

4.1.3 Perfil de Sensibilidad Climática y Multicolinealidad

La validación del impacto de las variables exógenas (meteorológicas) sobre el consumo energético requirió un análisis en dos etapas. Inicialmente, se evaluó una matriz de correlación global para todo el conjunto de datos (Figura 4.4). Este análisis general arrojó correlaciones débiles entre el clima y la potencia activa (ninguna superior a 0.20). Sin embargo, esta misma matriz global reveló una alta multicolinealidad entre las propias variables exógenas (por ejemplo, una fuerte correlación inversa de -0.43 entre la temperatura máxima y la humedad mínima). En la modelación estadística lineal tradicional (como ARIMAX), la multicolinealidad obliga a descartar variables predictoras para evitar la distorsión de los coeficientes (Lipovetsky, 2023). No




Figura 4.3: Variación sociológica y demostración de la Paradoja de Simpson en el consumo por estratos.

obstante, descartar variables como la humedad basándose únicamente en un análisis global habría resultado ser un error metodológico grave que ocultaría información crítica.




Figura 4.4: Matriz de correlación global entre variables climáticas y de consumo.

Para evitar la dilución estadística de estos fenómenos climáticos y superar la limitación del enfoque global, fue prudente dividir el análisis aplicando los mismos grupos por tamaño de demanda definidos anteriormente. La Figura 4.5 y la Tabla 4.1 resumen las correlaciones de Spearman aislando el comportamiento específico de cada segmento.

Los resultados estratificados confirman físicamente la divergencia estructural de las ZNI y la necesidad de conservar todas las características climáticas. Mientras las redes de gran demanda muestran una sensibilidad significativa y exclusiva a la Temperatura Máxima (correlación de 0.29), posiblemente debido al efecto metrópoli, definido como el impacto socioeconómico y de concentración de servicios en las grandes urbes impulsado por la carga térmica de sistemas de refrigeración, las redes




Figura 4.5: Sensibilidad climática segmentada por tamaño de demanda.

Tabla 4.1: Correlación de Spearman entre variables climáticas y potencia activa segmentada por tamaño de demanda.

Variable Climática	Redes Grandes (>250 kW)	Redes Medianas	Redes Pequeñas (<75 kW)
Temperatura Máxima	0.29	-0.05	0.20
Temperatura Mínima	0.01	0.07	0.02
Humedad Máxima	0.13	-0.28	-0.07
Humedad Mínima	-0.16	-0.39	-0.07
Precipitación	-0.01	-0.04	-0.13

de demanda media ignoran la temperatura (-0.05) y muestran una fuerte vulnerabilidad a los cambios de humedad relativa (correlación de -0.39). Finalmente, las redes de menor demanda son más sensibles a la precipitación (correlación de -0.13). Esta divergencia demuestra que no se puede aplicar una regla climática general ni minimizar variables manualmente sin perder información crítica para ciertos estratos. Este hallazgo justifica directamente la selección de arquitecturas como XGBoost y LSTM para esta investigación: al ser modelos no lineales con mecanismos internos de ponderación, importancia de características (*Feature Importance*) y compuertas de atención (*Attention Gates*), respectivamente, poseen la capacidad matemática de ingerir variables multicolineales y aprender de forma autónoma qué factor climático es relevante para cada micro-red. Adicionalmente, el análisis de correlación de Spearman arrojó valores cercanos a cero para la Temperatura Mínima en todos los estratos. En una metodología clásica, esto justificaría su eliminación inmediata. Sin embargo, dado que la correlación de Spearman evalúa únicamente relaciones monótonas, es incapaz de capturar efectos no lineales o interacciones compuestas, como la amplitud térmica (diferencia entre temperatura máxima y mínima diaria), la cual afecta el comportamiento de los sistemas de refrigeración. Por lo tanto, se tomó la decisión metodológica de conservar la Temperatura Mínima en el conjunto de datos de entrenamiento. La discriminación final de esta variable se delegará a los mecanismos autónomos de selección de características (*Feature Selection*) integrados en el algoritmo XGBoost, cuyo análisis se detallará en la fase de validación predictiva.

4.1.4 Selección de Arquetipos y Estrategia de Evaluación Dual

Tras caracterizar el comportamiento global de las Zonas No Interconectadas (ZNI), se definió un marco de validación en dos niveles. En primer lugar, se realizará una evaluación general sobre la totalidad de las micro-redes presentes en el conjunto de prueba (año 2025) para medir la capacidad de generalización macro del sistema. En segundo lugar, y con el fin de realizar un análisis de estrés detallado, se seleccionaron tres “Arquetipos” que representan los extremos operativos documentados en las fases anteriores. El propósito de este análisis profundo es evaluar el comportamiento de los modelos ante casos de alta complejidad y datos desconocidos que suelen diluirse en las métricas globales. Para la selección de estos casos, se siguió un procedimiento sistemático de filtrado basado en la viabilidad de los datos: solo se consideraron ubicaciones con un mínimo de 120 días de registros históricos válidos y presencia

activa en la ventana de prueba de 2025. Complementariamente, se implementó una **Estrategia Espejo** (*Mirror Strategy*), seleccionando dos ubicaciones por categoría: una primaria para la validación estándar y una ubicación espejo para una prueba de **Arranque en Frío** (*Zero-Shot*). El concepto de Arranque en Frío se refiere a la capacidad de un modelo para generar predicciones precisas sobre una serie de tiempo de la cual no ha recibido ningún dato previo durante las fases de entrenamiento o validación (Liao et al., 2024). Esta prueba es especialmente crítica para validar la naturaleza de los modelos de Aprendizaje Automático implementados. Mientras que la arquitectura de la red neuronal LSTM se diseñó para ser agnóstica a la ubicación — confiando puramente en la dinámica de las características climáticas y sociológicas—, el modelo XGBoost incorpora variables categóricas de ubicación que el sistema debe aprender a generalizar para pueblos nunca antes vistos. Por el contrario, los modelos estadísticos tradicionales como ARIMAX carecen inherentemente de la capacidad de realizar un Arranque en Frío, al depender estrictamente de la historia previa de la serie específica para su convergencia (Liao et al., 2024). La Figura 4.6 y la Tabla 4.2 detallan las seis ubicaciones seleccionadas para este análisis:




Figura 4.6: Espacio de selección de arquetipos para evaluación predictiva macro y zero-shot.

- **Arquetipo A (Estabilidad y Escala):**

Tabla 4.2: Arquetipos primarios y espejos seleccionados para la validación predictiva macro y prueba de Arranque en Frío (Zero-Shot).

Arquetipo	Función en Evaluación	Ubicación	Demanda Media (kWh)	CV
Arquetipo A (Estable)	Primario (Estándar)	Archipiélago de San Andrés, Providencia y Santa Catalina - Providencia - Providencia	39015.20	0.0738
	Espejo (Zero-Shot)	Amazonas - Leticia - Leticia	124349.35	0.1080
Arquetipo B (Volátil)	Primario (Estándar)	Nariño - El Charco - Uribe Uribe	15.51	1.1880
	Espejo (Zero-Shot)	Chocó - Medio Atrato - San Roque	52.29	0.9590
Arquetipo C (Sensible al Clima)	Primario (Estándar)	Valle del Cauca - Buenaventura - Galvez	116.03	0.4788
	Espejo (Zero-Shot)	Guaviare - San José del Guaviare - Cachicamo	367.12	0.1782

- **Primario:** Archipiélago de San Andrés, Providencia y Santa Catalina - Providencia - Providencia. Representa una demanda masiva ($\sim 39,015$ kW) con alta estabilidad, evidenciando un Coeficiente de Variación (CV) mínimo de 0.07.
- **Espejo (Zero-Shot):** Amazonas - Leticia - Leticia. Posee una escala mayor ($\sim 124,349$ kW) y se utiliza para validar si el modelo escala correctamente la magnitud de la demanda basándose en la jerarquía de la red.
- **Arquetipo B (Volatilidad y Caos Sociológico):**
 - **Primario:** Nariño - El Charco - Uribe Uribe. Representa el extremo de variabilidad (CV de 1.18) con una demanda reducida (~ 15.5 kW).
 - **Espejo (Zero-Shot):** Chocó - Medio Atrato - San Roque. Presenta una dinámica errática similar (CV de 0.89) y busca evaluar la captura de picos de demanda en entornos de baja calidad de telemetría.
- **Arquetipo C (Sensibilidad Climática y Transferencia Regional):**
 - **Primario:** Valle del Cauca - Buenaventura - Gálvez. Presenta la mayor correlación positiva con la temperatura máxima (0.26) en el conjunto viable.
 - **Espejo (Zero-Shot):** Guaviare - San José del Guaviare - Cachicamo. Muestra una correlación climática de 0.14 en una región geográfica distinta. El objetivo es probar si la red neuronal transfiere el conocimiento climático aprendido hacia regímenes meteorológicos diferentes.

4.1.5 Conclusiones de la Fase Exploratoria

El Análisis Exploratorio de Datos ha demostrado que el consumo energético en las ZNI obedece a un ecosistema dinámico dominado por interacciones no lineales. Al establecer una validación global complementada con el análisis de tres arquetipos primarios y sus respectivos espejos de Arranque en Frío, se ha construido un entorno de evaluación riguroso. En la siguiente sección, se procederá al entrenamiento y validación predictiva sobre estos escenarios, utilizando los casos extremos para demostrar la robustez de las arquitecturas propuestas frente a la degradación de datos observada en el año 2025.

4.2 Desempeño de los Modelos

4.2.1 Precisión Global y Capacidad de Generalización a Escala

Antes de analizar los resultados predictivos, es fundamental justificar la exclusión de los modelos estadísticos base (ARIMA y ARIMAX) de la evaluación a escala nacional. El despliegue de esta metodología exige el entrenamiento de un algoritmo independiente por cada micro-red. Optimizar los parámetros de integración y promedios móviles para la totalidad del país impone una complejidad computacional lineal que resulta ineficiente para sistemas de producción masiva. Adicionalmente, las ecuaciones lineales asumen varianzas constantes y dependencias regulares, premisas que se rompen constantemente en las ZNI debido a los apagones estocásticos y las interacciones no lineales entre el clima y la demanda. Al ser evaluados en los Arquetipos Primarios, ARIMA y ARIMAX confirmaron su incapacidad para adaptarse a estas anomalías, arrojando predicciones deficientes. Por lo tanto, se delegó la evaluación global exclusivamente a las arquitecturas XGBoost y LSTM, capaces de procesar la matriz nacional de forma simultánea.

La evaluación del desempeño global para el año 2025 demostró la superioridad de la arquitectura profunda (LSTM). Como se documenta en la Tabla 4.3, la red neuronal logró un Error Absoluto Medio Normalizado (nMAE) del 5.01 %, demostrando su viabilidad para modelar la carga base del país. Por el contrario, el modelo XGBoost presentó una degradación severa a nivel macro, con un error general que superó el 1200 %.

Tabla 4.3: Comparativa de desempeño predictivo global a nivel nacional para el año de prueba 2025.

Modelo	MAE (kW)	RMSE (kW)	nMAE (%)	nRMSE (%)
LSTM	726,56	4060,65	5,01	28,00
XGBoost	1819,05	10 357,87	12,67	72,15

Esta discrepancia se evidencia visualmente al comparar las gráficas de dispersión (scatter plots) en la Figura 4.7, que contrastan el consumo real frente al predicho. En la gráfica del modelo LSTM, los datos se agrupan de manera continua y estrecha sobre la línea de predicción perfecta a 45 grados. Esto confirma que la transformación matemática aplicada a los datos (el “Retorno Logarítmico”) permitió al modelo mantener su precisión independientemente de si la micro-red demandaba 10 kW o 700,000 kW.

En contraste, la gráfica de XGBoost muestra un comportamiento defectuoso caracterizado por densas franjas horizontales. En lugar de seguir la diagonal, el modelo agrupa los valores predichos en bandas fijas. Estas líneas horizontales son artefactos clásicos de los árboles de decisión: cuando el ensamble no logra clasificar correctamente la dinámica específica de un poblado, simplemente asigna el valor promedio estático de su hoja de entrenamiento más cercana, perdiendo por completo la sensibilidad a las variaciones diarias de la serie de tiempo.

4.2.2 *Análisis de Arquetipos y Perfilamiento Sociológico*

Para comprender el comportamiento de los modelos frente a las distintas realidades de las ZNI, se evaluaron las métricas sobre los tres Arquetipos Primarios, los cuales cuentan con datos históricos completos para su entrenamiento. Es en esta fase donde se incluyó la evaluación de las líneas base estadísticas (ARIMA y ARIMAX) frente a los modelos algorítmicos, cuyos resultados segmentados se consolidan en la Tabla 4.4.

El análisis de las predicciones arrojadas por ARIMA y ARIMAX reveló un fallo estructural conocido como la trampa del pronóstico ingenuo (naive forecasting trap). Como se observa de forma evidente en las gráficas de los Arquetipos Primarios (Figura 4.8, Figura 4.9 y Figura 4.10), las predicciones de estos modelos estadísticos se reducen a un simple corrimiento temporal (desfase) de los valores reales aderezado




Figura 4.7: Gráficas de dispersión (scatter plots) comparativas de la capacidad de generalización espacial. Panel izquierdo: LSTM. Panel derecho: XGBoost.

Tabla 4.4: Desempeño predictivo segmentado por Arquetipo Operativo en escenarios Primarios y de Arranque en Frío (Zero-Shot).

Arquetipo	Ubicación (Escenario)	nRMSE (%)			
		ARIMA	ARIMAX	XGBoost	LSTM
A (Estable)	Providencia (Primario)	6.74	5.95	3.89	3.90
	Leticia (Zero-Shot)	—	—	60.94	6.87
B (Volátil)	Uribe Uribe (Primario)	50.40	50.87	222.86	40.46
	San Roque (Zero-Shot)	—	—	60.05	51.21
C (Clima)	Gálvez (Primario)	34.15	34.64	36.30	25.67
	Cachicamo (Zero-Shot)	—	—	62.76	18.13

con un nivel básico de ruido estocástico. Las ecuaciones autorregresivas lineales asumieron erróneamente que la mejor estimación para el paso de tiempo actual era una copia casi directa del valor anterior. Esta incapacidad para anticipar cambios de fase o capturar los ciclos de demanda reafirma la necesidad de implementar arquitecturas de aprendizaje automático.




Figura 4.8: Pronóstico con modelos de línea base estadística (ARIMA y ARIMAX) para el Arquetipo A (Providencia).






Figura 4.9: Pronóstico con modelos de línea base estadística (ARIMA y ARIMAX) para el Arquetipo C (Gálvez).

Al evaluar los métodos modernos en el Arquetipo A (Providencia), caracterizado por una demanda masiva y estable, tanto XGBoost como LSTM demostraron un desempeño sobresaliente, obteniendo un nRMSE cercano al 3.89 % (Figura 4.11). Al contar con un volumen amplio de datos regulares, ambos algoritmos lograron replicar la estacionalidad base dictada por las actividades comerciales de este centro urbano. Esto demuestra que en entornos con baja volatilidad, los modelos de ensamble tabular son altamente competitivos y superan holgadamente la rigidez de los modelos lineales.




(a) ARIMA




(b) ARIMAX

Figura 4.10: Pronóstico con modelos de línea base estadística (ARIMA y ARIMAX) para el Arquetipo B (Uribe Uribe).



(a) LSTM



(b) XGBoost

Figura 4.11: Comparativa de predicción en redes de alta escala y estabilidad (Arquetipo A Primario - Providencia).

Sin embargo, las debilidades de XGBoost se hicieron evidentes en poblados de menor tamaño. En el Arquetipo C (Gálvez), altamente sensible a variables climáticas, XGBoost logró seguir la tendencia de la curva de consumo, pero generó un error nRMSE del 36.30 % debido a un sesgo de sobrestimación sistemática (prediciendo valores consistentemente por encima del consumo real). La red LSTM corrigió este sesgo y ajustó la curva con mayor precisión, reduciendo el error a un 25.67 % (Figura 4.12).




Figura 4.12: Comparativa de predicción bajo alta sensibilidad climática (Arquetipo C Primario - Gálvez).

El colapso de los modelos tabulares se confirmó en el Arquetipo B (Uribe Uribe), donde la demanda es inferior a 100 kW y la volatilidad es extrema (Figura 4.13). XGBoost presentó un error nRMSE del 222.86 %, sobrestimando agresivamente el consumo. Este fallo se debe a la “Dominancia de Magnitud” del modelo global: los gradientes de error de los grandes centros urbanos dominaron los pesos del algoritmo durante el entrenamiento, forzando a los árboles a ignorar la escala diminuta de Uribe Uribe. La red LSTM, gracias a su normalización local independiente, logró resistir este fenómeno y contuvo el nRMSE en un 40.46 %.




Figura 4.13: Comparativa de predicción en entornos de micro-demanda y extrema volatilidad (Arquetipo B Primario - Uribe Uribe).

4.2.3 La Trampa de las Métricas y la Captura de Picos

Al evaluar las gráficas en poblados con fuertes ciclos de consumo, se identificó un problema fundamental en la interpretación de las métricas de error puro aplicadas a infraestructuras inestables. El caso de Piñuña Negro (Figura 4.14) ilustra esta condición de forma excepcional.




Figura 4.14: Ajuste de ciclos sociológicos frente a la distorsión de métricas de error generada por apagones estructurales en Piñuña Negro.

En la gráfica, la predicción de la red LSTM se sincroniza fielmente con el patrón real, capturando de manera precisa la amplitud de los picos diurnos y los descensos de los fines de semana. No obstante, las métricas de error numérico resultaron altas para este poblado. Al inspeccionar la serie de tiempo, es evidente que el error se concentra en los instantes donde la demanda real cae de forma vertical a cero kilovatios. Estas caídas abruptas no obedecen a un comportamiento sociológico, sino a apagones físicos de la planta de generación. El modelo proyecta la energía que la comunidad hubiese consumido si el suministro fuera estable. Las ecuaciones del RMSE penalizan de forma drástica esta diferencia absoluta contra el cero del apagón. Este escenario demuestra que el algoritmo modeló exitosamente la física de la demanda, comprobando que en las ZNI las métricas estadísticas deben ser siempre contextualizadas con un análisis visual para no confundir un acierto predictivo con un fallo de infraestructura.

4.2.4 Robustez ante Datos Ausentes y Zero-Shot

La prueba definitiva para la generalización del sistema fue el Arranque en Frío (Zero-Shot) sobre los Arquetipos Espejo, exigiendo a los modelos algorítmicos inferir el consumo de localidades sin haber visto nunca sus datos históricos.

En el Arquetipo A Espejo (Leticia), el modelo XGBoost falló severamente, elevando su error a un 60.94 %. Visualmente (Figura 4.15), la predicción se estancó en una línea constante cercana a los 50,000 kW frente a una demanda real de 140,000 kW. Esto ocurre porque los modelos basados en árboles no poseen capacidad de extrapolación matemática; ante valores de entrada que superan sus rangos conocidos, se bloquean en su límite superior. La red LSTM superó esta prueba de manera contundente, manteniendo un nMAE sobresaliente del 5.62 %. Esto fue posible gracias a su sistema de embeddings espaciales, el cual le permitió identificar un perfil geográfico compatible y asignar una escala base correcta a la nueva ciudad.






Figura 4.15: Evaluación de extrapolación por Arranque en Frío (Zero-Shot) en el Arquetipo A (Leticia).

En el Arquetipo C Espejo (Cachicamo), la LSTM ratificó su capacidad de generalización climática (Figura 4.16), reduciendo el error a un 18.13 % frente al 62.76 % de XGBoost. La red neuronal demostró que pudo trasladar correctamente las reglas de interacción meteorológica a una región completamente desconocida.

Finalmente, el Arquetipo B Espejo (San Roque) combinó el peor escenario posible: ausencia de datos históricos y extrema inestabilidad de la red física (Figura 4.17). En estas condiciones de alta entropía, ambos modelos sufrieron degradación (60.05 % para XGBoost y 51.21 % para LSTM). Aunque la red neuronal logró un mejor ajuste, el error se mantuvo elevado debido al desfase temporal continuo entre la demanda que el modelo intentaba predecir y el comportamiento errático de una micro-red altamente defectuosa. Este caso establece la frontera técnica de la herramienta: la LSTM, en su esfuerzo por predecir variaciones dinámicas, fue castigada




(a) LSTM




(b) XGBoost

Figura 4.16: Evaluación de extrapolación climática por Arranque en Frío (Zero-Shot) en el Arquetipo C (Cachicamo).

más duramente por el desfase temporal entre sus picos proyectados y el ruido errático del sensor real, confirmando que el límite predictivo del sistema se alcanza cuando los datos de los sensores son tan erráticos que ya no reflejan patrones reales de consumo.



(a) LSTM



(b) XGBoost

Figura 4.17: Límite predictivo ante fallos físicos de red en escenario Zero-Shot (Arquetipo B - San Roque).

4.3 Discusión: Viabilidad en el Contexto ZNI

La evaluación de las arquitecturas predictivas sobre el ecosistema de las Zonas No Interconectadas (ZNI) permite trascender el análisis de métricas de error puro y proponer conclusiones sobre la viabilidad operativa de implementar Inteligencia Artificial en el sector energético rural colombiano. Los resultados obtenidos respaldan la hipótesis de investigación: la implementación de arquitecturas de aprendizaje profundo adaptadas representa una alternativa viable para modelar el consumo de infraestructuras aisladas, ofreciendo herramientas para mitigar las barreras históricas de la escasez de datos.

4.3.1 Impacto Operativo y Eficiencia en la Gestión de Recursos

El logro de un Error Absoluto Medio Normalizado (nMAE) del 5.01 % a nivel global mediante la arquitectura LSTM sugiere un avance técnico con posibles aplicaciones en la operación de las micro-redes. Sin embargo, es imperativo reconocer que al ser un valor normalizado, esta métrica refleja predominantemente el buen comportamiento del sistema en localidades con mayor estabilidad y confiabilidad de datos (como los grandes centros urbanos). Como se evidenció en los arquetipos de Uribe Uribe y San Roque, el rendimiento predictivo presenta una degradación severa en entornos altamente volátiles. Esto reafirma el principio fundamental de que la precisión de cualquier sistema algorítmico estará fuertemente supeditada a la calidad de la telemetría de origen.

A pesar de estas disparidades, lograr una certidumbre predictiva generalizada podría otorgar a los operadores de red y entidades como el IPSE una herramienta matemática complementaria para optimizar la planificación de los recursos. Reducir la incertidumbre en la curva de carga diaria tiene el potencial de facilitar una mejor sincronización operativa frente a la demanda real, lo cual contribuiría a mitigar el desperdicio de diésel. Asimismo, contar con una curva de carga proyectada ofrece una línea base técnica útil para iniciativas en el marco de la Transición Energética Justa (TEJ); estimar la demanda con mayor precisión es un paso clave para dimensionar sistemas híbridos (diésel-solar) o bancos de baterías (BESS), reduciendo el riesgo de dimensionamientos financieros alejados de la realidad operativa.

4.3.2 Escalabilidad Arquitectónica y Alternativas Costo-Efectivas

Desde la perspectiva del despliegue en producción (MLOps), la investigación sugiere que los modelos estadísticos univariados (ARIMA/ARIMAX) presentan desafíos de eficiencia para un sistema a escala nacional. La necesidad de aislar “silos de datos” y entrenar un modelo individual por cada comunidad impone una carga computacional que podría resultar restrictiva.

La solución basada en LSTM evidenció que un modelo global es capaz de identificar patrones generales de la demanda mitigando la “dominancia de magnitud”, lo que abre la posibilidad de su despliegue como un motor de inferencia centralizado en la nube capaz de procesar la telemetría nacional de manera integrada.

No obstante, a pesar de la ventaja global de la red neuronal, el modelo tabular de ensamble de árboles de decisión (XGBoost) demostró ser una alternativa técnica

robusta para poblaciones caracterizadas por una alta estabilidad y volumen de datos (como el Arquetipo A). Dado que los algoritmos tabulares requieren, por lo general, una fracción del tiempo y poder de cómputo para su optimización en comparación con las redes profundas, XGBoost se presenta como una alternativa costo-efectiva a considerar en escenarios donde la implementación de un sistema LSTM resulte financieramente compleja, o en micro-redes maduras que operen bajo regímenes de consumo constantes.

4.3.3 La Ventaja Estratégica del Arranque en Frío (Zero-Shot)

Un hallazgo de interés para los planes de expansión de la cobertura eléctrica en Colombia es la exploración del Arranque en Frío (Zero-Shot) mediante incrustaciones geográficas. Tradicionalmente, proyectar la demanda para una comunidad rural recién interconectada carece de bases estadísticas sólidas.

Al observar que la red neuronal logró asimilar características operativas de comunidades que nunca fueron vistas durante su fase de entrenamiento, requiriendo únicamente una ventana mínima de observaciones recientes para conformar sus tensores de entrada, el modelo demuestra una alta capacidad de generalización. Apoyándose estrictamente en la jerarquía de su ubicación espacial (a través del sistema de embeddings geográficos de respaldo) y en la dinámica de sus variables meteorológicas (obteniendo errores nMAE menores al 18 % en localidades espejo como Cachicamo), el algoritmo sugiere un camino prometedor como herramienta de apoyo para la planificación. Esto podría permitir a las entidades competentes simular escenarios teóricos de consumo para asentamientos remotos que cuentan con apenas unas pocas mediciones de demanda, basándose en la experiencia matemática aprendida de micro-redes espacialmente análogas y aportando datos técnicos preliminares a la estructuración de nuevos proyectos energéticos.

4.3.4 Reconocimiento de los Límites Estructurales y Socioeconómicos

La discusión sobre la viabilidad debe considerar objetivamente las fronteras del sistema. En primer lugar, el Análisis Exploratorio de Datos reveló un fenómeno de degradación en la calidad de la información: los años 2024 y 2025 —asignados a las fases de validación y prueba— presentaron una mayor necesidad de imputación climatológica y una mayor frecuencia de periodos sin información de demanda en comparación con la ventana histórica de entrenamiento. Esta diferencia estructural

entre los conjuntos de datos incrementó notablemente la dificultad del pronóstico durante la prueba final. Esto sugiere que, si en el futuro se reentrena el sistema con un conjunto de datos donde las condiciones de prueba sean más similares a las de entrenamiento, se podría conseguir un rendimiento predictivo superior.

En segundo lugar, si bien las variables meteorológicas y el consumo histórico operaron como predictores funcionales, el modelo encontró dificultades para anticipar picos y descensos abruptos aislados, incluso en poblaciones grandes. Es probable que estas variaciones atípicas estén fuertemente ligadas a interacciones de índole sociológica y económica que escapan a los sensores climáticos y de calendario actuales, tales como festividades locales no estandarizadas o fluctuaciones en dinámicas productivas y turísticas. La exploración futura de la integración de datos económicos en la matriz de características se perfila como una estrategia importante para intentar refinar el resultado predictivo.

Finalmente, los modelos algorítmicos no pueden suplir por completo la ausencia de instrumentación física constante. Cuando la pérdida de telemetría degrada la serie temporal severamente, el rendimiento del algoritmo disminuye proporcionalmente. Por tanto, la viabilidad a largo plazo de este modelo predictivo debería considerarse como un elemento complementario a las políticas de modernización de la infraestructura, apoyándose idealmente en una futura transición hacia sistemas de medición inteligente (AMI) que garanticen un nivel óptimo de transmisión de datos en las zonas aisladas.

5. Conclusiones y Trabajo Futuro

5.1 Conclusiones

La presente investigación permitió desarrollar y validar una metodología basada en Inteligencia Artificial para la predicción de demanda energética en las Zonas No Interconectadas (ZNI) de Colombia, aportando evidencia sobre la viabilidad técnica de estas herramientas en entornos caracterizados por la escasez de información. Tras el análisis y discusión de los resultados, se establecen las siguientes conclusiones:

- **Validación de la Hipótesis:** Los resultados obtenidos permiten aceptar la hipótesis de investigación. Se demostró que es viable obtener pronósticos de consumo energético con una exactitud útil mediante algoritmos de aprendizaje profundo adaptados a las condiciones de las ZNI. La arquitectura LSTM, apoyada en transformaciones invariantes a la escala, logró capturar la dinámica de la demanda incluso ante la ausencia de historiales extensos en poblaciones específicas, proporcionando una base técnica para la planificación operativa.
- **Eficacia de la Arquitectura de Datos:** La implementación de una arquitectura Medallion (Capas Bronce, Plata y Oro) resultó fundamental para resolver los problemas de baja calidad y fragmentación de la telemetría. Las estrategias de imputación multinivel y la integración de proximidad espacial tridimensional con penalización altitudinal permitieron consolidar una matriz de entrenamiento robusta, mitigando el impacto de los vacíos de información meteorológica y garantizando la integridad física de los datos.
- **Superioridad de los Modelos No Lineales:** La evaluación comparativa confirmó que los modelos estadísticos tradicionales (ARIMA/ARIMAX) son insuficientes para capturar la volatilidad y las interacciones no lineales climáticas presentes en las comunidades aisladas. Asimismo, se concluye que las Redes Neuronales Recurrentes (LSTM) superan a los modelos de ensamble tabular (XGBoost) en la generalización nacional, principalmente debido a su capacidad para manejar la dominancia de magnitud de las cargas masivas mediante el uso de retornos logarítmicos y capas de memoria secuencial.

- **Capacidad de Generalización y Escenario Zero-Shot:** Se validó que el sistema posee una alta capacidad de generalización espacial. El uso de *embeddings* geográficos de respaldo permitió que el modelo realizara inferencias precisas sobre comunidades que nunca fueron incluidas en el conjunto de entrenamiento, requiriendo solo una ventana mínima de mediciones recientes para su estabilización. Este hallazgo es de especial relevancia para la expansión de redes y la estructuración de nuevos proyectos energéticos en zonas donde no existe un registro estadístico previo.
- **Identificación de Patrones Sociológicos:** El estudio permitió identificar y superar la Paradoja de Simpson en el consumo de las ZNI. Se concluye que el tamaño de la demanda dicta una inversión en los patrones sociológicos: mientras los grandes centros urbanos concentran su carga en días laborales, los pequeños asentamientos presentan picos durante festivos y fines de semana. La arquitectura de aprendizaje profundo demostró ser capaz de asimilar estas divergencias de manera autónoma sin necesidad de modelos segmentados manualmente.
- **Límites del Sistema Predictivo:** Finalmente, se concluye que la efectividad de los modelos algorítmicos tiene una dependencia directa con la integridad mínima de la instrumentación física. En escenarios de extrema inestabilidad de red y pérdida severa de telemetría, el rendimiento del sistema disminuye, lo que establece que la Inteligencia Artificial debe entenderse como un complemento a la modernización de la infraestructura y no como un sustituto de la medición confiable en sitio.

5.2 Trabajo Futuro

La presente investigación establece las bases para el uso de arquitecturas de aprendizaje profundo en la planeación energética de las Zonas No Interconectadas de Colombia. A partir de los hallazgos y limitaciones identificadas, se proponen las siguientes líneas de trabajo futuro para la maduración y evolución del sistema:

- **Implementación de Explicabilidad Profunda (XAI):** Dado que la arquitectura LSTM opera como una “caja negra” matemática, es fundamental integrar algoritmos de interpretabilidad como *SHAP* (*SHapley Additive exPlanations*) o *Integrated Gradients*. Esto permitiría cuantificar con precisión el im-

pacto individual de cada variable meteorológica y de calendario en el pronóstico, proporcionando a los tomadores de decisiones una mayor transparencia sobre las causas detrás de los picos de demanda proyectados.

- **Desarrollo de Modelos de Transferencia para Comunidades Sin Historial (Deep Cold-Start):** Se propone la creación de un sistema de arranque diseñado específicamente para asentamientos que carecen por completo de mediciones de demanda, ya sea por ser comunidades analizadas desde cero o por no haber tenido acceso histórico a la energía eléctrica. Este enfoque implicaría el uso de **Aprendizaje por Transferencia (*Transfer Learning*)** o **Redes Generativas Antagónicas (GANs)** para sintetizar curvas de carga teóricas basadas puramente en perfiles de comunidades análogas (clima, ubicación y potencial productivo), permitiendo una planificación inicial robusta en zonas de expansión energética.
- **Integración de Dimensiones Socioeconómicas y Eventos Locales:** Como se evidenció en la discusión, existen variaciones atípicas que los sensores climáticos no logran capturar. Se propone enriquecer la matriz de características con datos de índole económica —como precios de productos locales o indicadores de actividad productiva— y calendarios de festividades municipales específicas. Esto permitiría al modelo ajustar su lógica sociológica ante eventos que alteran drásticamente el consumo residencial y comercial en las micro-redes.
- **Optimización de Arquitecturas Híbridas y Reentrenamiento Adaptativo:** Se sugiere la exploración de modelos híbridos que integren la robustez de los ensambles de árboles de decisión (**XGBoost**) con la capacidad secuencial de las **LSTM**, o el uso de mecanismos de atención (**Transformers**) para capturar dependencias de muy largo plazo. Asimismo, ante la degradación de la calidad de datos observada en los años 2024 y 2025, es necesario implementar ciclos de reentrenamiento continuo que asimilen los nuevos regímenes de inestabilidad operativa de la red física.
- **Despliegue de un Framework de MLOps Institucional:** Finalmente, se propone el diseño de una infraestructura de operaciones de aprendizaje automático (MLOps) orientada a **entidades gubernamentales y educativas**. Este sistema permitiría automatizar la ingesta de telemetría, el monitoreo de deriva de datos (*drift*) y la entrega de pronósticos en tiempo real, facilitando

la transición de un modelo académico hacia una herramienta de apoyo para la investigación y la política pública energética.

Referencias Bibliográficas

- Almuhanna, K. A. (2024). Home Energy Consumption Prediction Using Smart Meters in Riyadh Saudi Arabia. *2024 Conference on Renewable Energy Technologies and Modern Communications Systems: Future and Challenges*, 1-4. <https://doi.org/10.1109/IEEECONF63577.2024.10881359>
- Barja-Martinez, S., Teng, F., Junyent-Ferre, A., & Aragues-Penalba, M. (2024). Personalized Federated Learning with Cost-Oriented Load Forecasting for Home Energy Management Systems. *IEEE Transactions on Industry Applications*. <https://doi.org/10.1109/TIA.2024.3462668>
- Bernal Suárez, M. L., Lancheros Ramírez, P. V., Reyes Mosquera, K. O., Sánchez Cardozo, J. A., & Villegas Rodríguez, S. (2024). *INFORME SOBRE POBREZA ENERGÉTICA MULTIDIMENSIONAL EN COLOMBIA: Análisis Estratégico 2022-2023* (inf. téc.).
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *TIME SERIES ANALYSIS: FORECASTING AND CONTROL, 5TH EDITION*. Wiley.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324/METRICS>
- Cabiddu, S., Sanguinetti, M., De Falco, A., Manca, G., & Atzori, M. (2024). Effective Net Load Forecasting in Solar-Integrated Homes with Battery Systems. *Proceedings - 2024 IEEE International Conference on Big Data, BigData 2024*, 4643-4649. <https://doi.org/10.1109/BIGDATA62323.2024.10826060>
- Ding, e. a. (2024). Finding Non-Redundant Simpson's Paradox from Multidimensional Data. *Proceedings of the VLDB Endowment*. <https://doi.org/10.14778/3685800.3685805>
- Dubey, A., Tiwari, A., Bhardwaj, A., Sivamohan, S., & Krishnaveni, S. (2024). Global Energy Consumption Patterns and Optimization using Big Data. *Proceedings of the 9th International Conference on Communication and Electronics Systems, ICCES 2024*, 1025-1028. <https://doi.org/10.1109/ICCES63552.2024.10859370>
- Eikeland, O. F., Bianchi, F. M., Apostoleris, H., Hansen, M., Chiou, Y. C., & Chiesa, M. (2021). Predicting Energy Demand in Semi-Remote Arctic Locations. *Energies*, 14(4), 798. <https://doi.org/10.3390/EN14040798>

- Fasipe, O. O., Olabisi, P. O., & Folorunso, A. O. (2024). Review of Energy Requirement and Load Forecasting for A Medium Agro-Based Industrial Settlement: A Case Study of Oke-Agbo and Imota Villages. *2024 IEEE 5th International Conference on Electro-Computing Technologies for Humanity (NIGERCON)*, 1-7. <https://doi.org/10.1109/NIGERCON62786.2024.10927395>
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189-1232. <https://doi.org/10.1214/AOS/1013203451>
- Gebre, M. T., Hwang, J., & Biru, G. (2024). Electricity demand analysis and forecasting: The case of GADA special economic zone. *Heliyon*, 10(3), e25364. <https://doi.org/10.1016/J.HELIYON.2024.E25364>
- Gellert, A., Olaru, L. M., Florea, A., Cofaru, I. I., Fiore, U., & Palmieri, F. (2024). Estimating electricity consumption at city-level through advanced machine learning methods. *Connection Science*, 36(1), 2313852. <https://doi.org/10.1080/09540091.2024.2313852>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- Guilian, W., Linyao, Z., Tingting, L., Hao, C., Wenlong, L., Shaofang, W., Jun, Y., & Conghao, L. (2023). Forecast of total rural energy demand based on energy consumption intensity. *Frontiers in Energy Research*, 10, 1021164. <https://doi.org/10.3389/FENRG.2022.1021164>
- Hendrycks, D., & Gimpel, K. (2016). Gaussian Error Linear Units (GELUs). *arXiv preprint arXiv:1606.08415*. <https://doi.org/10.48550/arXiv.1606.08415>
- Herraiz-Cañete, Á., Ribó-Pérez, D., Bastida-Molina, P., & Gómez-Navarro, T. (2022). Forecasting energy demand in isolated rural communities: A comparison between deterministic and stochastic approaches. *Energy for Sustainable Development*, 66, 101-116. <https://doi.org/10.1016/J.ESD.2021.11.007>
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Hong, G., Choi, G. S., Eum, J. Y., Lee, H. S., & Kim, D. D. (2022). The Hourly Energy Consumption Prediction by KNN for Buildings in Community Buildings. *Buildings*, 12(10), 1636. <https://doi.org/10.3390/BUILDINGS12101636>
- Hong, T. (2015). Load Forecasting Case Study.
- IBM. (2024). What is a Neural Network? <https://www.ibm.com/think/topics/neural-networks>

- Instituto de Planificación y Promoción de Soluciones Energéticas para las ZNI (IPSE). (2024). *Informe de Rendición de Cuentas y Estados Financieros a Diciembre 2024 y 2025* (inf. téc.). República de Colombia. https://ipse.gov.co/wp-content/uploads/2024/12/Informe-de-Rendicion-de-cuentas-IPSE-2024_1.pdf
- Jawad, M., Nadeem, M. S. A., Shim, S. O., Khan, I. R., Shaheen, A., Habib, N., Husain, L., & Aziz, W. (2020). Machine Learning Based Cost Effective Electricity Load Forecasting Model Using Correlated Meteorological Parameters. *IEEE Access*, 8, 146847-146864. <https://doi.org/10.1109/ACCESS.2020.3014086>
- Kairouz, P., McMahan, H. B., Avent, B., et al. (2019). Advances and Open Problems in Federated Learning. *Foundations and Trends in Machine Learning*, 14(1-2), 1-210. <https://doi.org/10.1561/22000000083>
- Kecman, V. (2005). *Support Vector Machines - An Introduction*. https://doi.org/10.1007/10984697_1
- Khazem, S., & Kanso, H. (2025). Cyclical Temporal Encoding and Hybrid Deep Ensembles for Multistep Energy Forecasting. *arXiv preprint arXiv:2512.03656*. <https://doi.org/10.48550/arXiv.2512.03656>
- Kolluru, V. K., Challagundla, Y., Chintakunta, A. N., Roy, B., Bermak, A., & Renuka Devi, S. M. (2024). AI-Driven Energy Optimization: Household Power Consumption Prediction With LSTM Networks and PyTorch-Ray Tune in Smart IoT Systems. *Proceedings of the International Conference on Microelectronics, ICM*. <https://doi.org/10.1109/ICM63406.2024.10815802>
- Lee, H., et al. (2024). A Novel Weight Initialization Method for Tanh Neural Networks. *arXiv preprint arXiv:2410.02242*. <https://doi.org/10.48550/arXiv.2410.02242>
- Li, D., Xia, J., Li, J., Xiao, C., Stankovic, V., Stankovic, L., & Shi, Q. (2024). A Temporal-Spatial Graph Network with a Learnable Adjacency Matrix for Appliance-level Electricity Consumption Prediction. *IEEE Transactions on Artificial Intelligence*. <https://doi.org/10.1109/TAI.2024.3507734>
- Liao, W., Yang, Z., Jia, M., Rehtanz, C., Fang, J., & Porté-Agel, F. (2024). Zero-Shot Load Forecasting with Large Language Models. *arXiv preprint arXiv:2411.11350*. <https://doi.org/10.48550/arXiv.2411.11350>
- Lipovetsky, S. (2023). Beta Coefficients Greater Than One: Diagnostics for Multicollinearity in Multiple Regression. *Mathematics*, 11(3), 227. <https://doi.org/10.3390/math11030227>

- Loshchilov, I., & Hutter, F. (2019). Decoupled Weight Decay Regularization. *International Conference on Learning Representations (ICLR)*. <https://doi.org/10.48550/arXiv.1711.05101>
- Ma, S., Li, S., Luo, Q., Yu, Z., & Wang, Y. (2024). Revisiting the relationships between energy consumption, economic development and urban size: A global perspective using remote sensing data. *Heliyon*, 10(5), e27318. <https://doi.org/10.1016/J.HELIYON.2024.E27318>
- Madhusudanan, C. R. (2019). *A Machine Learning Framework for Energy Consumption Prediction* [Tesis de maestría, Clemson University]. https://open.clemson.edu/all_theses/3184
- Ministerio de Minas y Energía. (2024). *Informe sobre Pobreza Energética Multidimensional en Colombia 2022-2023* (inf. téc.). República de Colombia. <https://minenergia.gov.co/documents/14110/INFORME-SOBRE-POBREZA-ENERGETICA-MULTIDIMENSIONAL-EN-COLOMBIA-2022-2023.pdf>
- Mitchell, T. (1997). Machine Learning. En *Machine Learning*. McGraw Hill. <https://doi.org/10.1093/bioinformatics/btq112>
- Molina, E., Candelo-Becerra, J. E., & Ojeda-Camargo, E. (2018). Understanding Electricity Saving Behavior of Rural Indigenous Communities in La Guajira Department, Colombia. *Journal of Engineering Science and Technology Review*, 11(6), 47-53. <https://doi.org/10.25103/JESTR.112.07>
- Pan, Y. (2024). Different Types of Neural Networks and Applications: Evidence from Feedforward, Convolutional and Recurrent Neural Networks. *Highlights in Science, Engineering and Technology*, 85, 247-255. <https://doi.org/10.54097/6RN1WD81>
- Park, Y.-J., Kim, D., Odermatt, F., Lee, J., et al. (2024). Deep learning for prediction of energy consumption: an applied use case in an office building. *Applied Intelligence*, 54(7), 5813-5825.
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., et al. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. *Advances in Neural Information Processing Systems (NeurIPS)*, 32, 8024-8035. <https://doi.org/10.48550/arXiv.1912.01703>
- Patricio, J. T., Silva, F., Lopes, R. A., Amaro, N., & Martins, J. (2024). Combining Time-Series Forecasting and Genetic Algorithm Based Optimization to Explore Energy Flexibility at Building-Level. *Proceedings of the 30th ICE IEEE/ITMC*

- Conference on Engineering, Technology, and Innovation*. <https://doi.org/10.1109/ICE/ITMC61926.2024.10794398>
- Pezeshki, M., Kaba, S.-O., Bengio, Y., Courville, A., Precup, D., & Lajoie, G. (2021). Gradient Starvation: A Learning Proclivity in Neural Networks. *Advances in Neural Information Processing Systems (NeurIPS)*, 34, 1256-1272. <https://proceedings.neurips.cc/paper/2021/file/0987b8b338d6c90bbedd8631bc499221-Paper.pdf>
- Qiao, J., Song, D., Jiang, R., Hao, W., & Liu, C. (2023). Research on Home Energy Consumption Prediction Method Based on SSA-VMD-LSTM. *2023 5th International Conference on Electronic Engineering and Informatics, EEI 2023*, 27-32. <https://doi.org/10.1109/EEI59236.2023.10212906>
- Ramírez Murillo, J. E. (2023). *Necesidad de una mejora regulatoria para las Zonas no Interconectadas en Colombia* (inf. téc.). Universidad Externado de Colombia.
- Rushman, J. F., Thanarak, P., Artkla, S., & Maneechot, P. (2019). Electrical Power Demand Assessment of a Rural Community and the Forecast of Demand Growth for Rural Electrification in Ghana. *International Energy Journal*, 19(1).
- Russell, S., & Norvig, P. (2020). *Artificial intelligence: a modern approach*. Pearson.
- Schneider, A., Hommel, G., & Blettner, M. (2010). Linear Regression Analysis: Part 14 of a Series on Evaluation of Scientific Publications. *Deutsches Ärzteblatt International*, 107(44), 776. <https://doi.org/10.3238/ARZTEBL.2010.0776>
- Shapi, M. K. M., Ramli, N. A., & Awalin, L. J. (2021). Energy consumption prediction by using machine learning for smart building: Case study in Malaysia. *Developments in the Built Environment*, 5, 100037. <https://doi.org/10.1016/J.DIBE.2020.100037>
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: a simple way to prevent neural networks from overfitting. *The journal of machine learning research*, 15(1), 1929-1958.
- Sun, e. a. (2024). Dynamic Frequency-Constrained Load Restoration Method Considering Cold Load Pickup Behavior. *IEEE Transactions on Power Systems*, 39(1), 107-118. <https://doi.org/10.1109/TPWRS.2023.3235313>
- Taylor, S. J., & Letham, B. (2017). Forecasting at scale. <https://doi.org/10.7287/PEERJ.PREPRINTS.3190V2>
- Unidad de Planeación Minero Energética (UPME). (2024). *Boletín Oficial: Índice de Cobertura de Energía Eléctrica (ICEE)* (inf. téc.). Ministerio de Minas y

- Energía, República de Colombia. https://docs.upme.gov.co/SIMEC/Energia_Electrica/Documents/Informes_cobertura/Boletin_ICEE_2024.pdf
- Van Houdt, G., Mosquera, C., & Nápoles, G. (2020). A review on the long short-term memory model. *Artificial Intelligence Review*, 53(8), 5929-5955. <https://doi.org/10.1007/S10462-020-09838-1>
- Vidhate, K. D., & Nema, P. (2024). Forecasting Energy Utilization in Residential Areas through Machine Learning Techniques. *Journal of Electrical Systems*, 20(1s), 743-748. <https://doi.org/10.52783/JES.817>
- Volk, M., Staegemann, D., & Turowski, K. (2022). Providing Clarity on Big Data: Discussing Its Definition and the Most Relevant Data Characteristics. *International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management, IC3K - Proceedings*, 3, 141-148. <https://doi.org/10.5220/0011537500003335>
- Wang, Z., Hong, T., Li, H., & Ann Piette, M. (2021). Predicting city-scale daily electricity consumption using data-driven models. *Advances in Applied Energy*, 2, 100025. <https://doi.org/10.1016/J.ADAPEN.2021.100025>

A. Anexos

A.1 Guía de Arquitectura Computacional

Resumen de la Infraestructura de Software

El desarrollo tecnológico de esta tesis se encuentra sustentado en una infraestructura orientada a la ingeniería de datos escalable y la reproducibilidad académica. La orquestación del pronóstico de demanda de energía para las Zonas No Interconectadas (ZNI) se basa en la integración de marcos modernos para la inteligencia artificial (PyTorch para LSTM, XGBoost para árboles de decisión iterativos), bajo una topología orientada al registro inmutable de experimentos. El núcleo central del ecosistema opera a través del patrón Medallion Data Architecture, el cual asegura la integridad transaccional. De forma concurrente, todo modelo matemático generado es interceptado y catalogado mediante MLflow.

Repositorio Oficial: https://gitlab.com/jncuellar-group/ZNI_prediction.git

Jerarquía de Archivos del Repositorio

La base de código está estrictamente dividida para garantizar modularidad funcional:

- **data/ (Data Lake Medallion):** Alberga todo el ciclo de vida de la información.
 - **01_raw/ (Capa Bronce):** Datos inmutables.
 - **02_interim/ (Capa Plata):** Datos purificados.
 - **03_processed/ (Capa Oro):** Datos procesados orientados a negocio.
 - **04_eda/:** Salidas tabulares y gráficas exploratorias.
- **notebooks/:** Análisis Exploratorio de Datos (EDA).
- **src/ (Módulos de Producción):**
 - **data/:** Extracción e ingesta secuencial desde la capa Bronce a la Plata (`ingest_.py`, `clean_.py`).

- **features/:** Transición fundamental de Plata a Oro.
- **models/:** Motores de entrenamiento y pérdidas personalizadas como DirectionalMSELoss.
- **evaluation/:** Scripts agnósticos para validar el fenómeno de transferencia (Zero-Shot).
- **utils/:** Métodos compartidos de cálculo.
- **visualization/:** Bibliotecas internas de renderizado.
- **config/:** Archivos .yaml responsables de parámetros de control.

Flujo de Datos y Arquitectura Medallion (Pipeline)

- **Capa Bronce (Extracción):** Los módulos `src/data/ingest_energy.py` y `src/data/ingest_weather.py` actúan como la zona de aterrizaje.
- **Capa Plata (Transformación y Limpieza):** Los scripts `src/data/clean_energy.py` y `src/data/clean_weather.py` aplican reglas lógicas estrictas para estructurarlos.
- **Capa Oro (Ingeniería de Características):** Mediante `src/features/build_features_common.py`, los datos limpios adquieren profundidad predictiva.

Descripción Técnica de los Módulos Estrella

- **models/ (Motores Analíticos y Pérdida Direccional):** Un componente crítico es el `lstm_core.py`, el cual implementa la función de pérdida personalizada direccional.
- **training/ (Optimización e Hiperparámetros):** La orquestación de la búsqueda del mejor modelo se maneja a través de Optuna (ej. `src/optimize_lstm.py`).
- **evaluation/ (Zero-Shot y Transferencia Espacial):** Construido alrededor de `src/evaluation/evaluate_subsets_xgboost.py` y `src/evaluation/evaluate_champion_lstm.py`.

Garantía de Reproducibilidad

- **Semillas Aleatorias Fijas (Determinismo):** En todas las etapas estocásticas se aplican configuraciones universales de semillas (seeds).
- **Registro de Proveniencia (MLflow):** MLflow intercepta silenciosamente cada barrido de optimización, registrando el diccionario de hiperparámetros, los tiempos de convergencia y las métricas resultantes en un esquema Padre/Hijo (Parent/Child).