



INVESTIGACIÓN X

PROFUNDIZACIÓN

**MODELO BASADO EN REDES NEURONALES
CONVOLUCIONALES PARA EL MEJORAMIENTO EN LA
IDENTIFICACIÓN DE CÁNCER DE MAMA MEDIANTE IMÁGENES
HISTOPATOLÓGICAS.**

Autor

Guillermo Pinzón Gómez

Tutor

Lilia Edith Aparicio Pico, PhD.

Doctorado en Ciencias Técnicas

Profesor Titular Universidad Distrital Francisco José de Caldas

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS

Maestría en Ciencias de la Información y las Comunicaciones

Énfasis en Sistemas de Información

Bogotá, Colombia

mayo de 2026

Contenido

Resumen	4
Palabras Clave	5
Introducción	6
1. Problema de investigación	8
1.1 PLANTEaMIENTO del problema	8
1.2 FORMULACION DEL PROBLEMA.....	8
1.3 sistematizacion del problema.....	9
2. Objetivos.....	10
2.1 Objetivo General.....	10
2.2 Objetivos Específicos	10
3. justificacion	11
3.1 Justificación Teórica	11
3.2 Justificación Metodológica	12
3.3 Justificación Práctica	12
4. MARCO DE REFERENCIA	13
4.1 Marco Teórico.....	13
4.2 Marco CONCEPTUAL	14
5. hipÓtesis.....	18
6. Metodología.....	19
6.1 Conjunto de datos.....	19
6.2 ACONDICIONAR EL CONJUNTO DE DATOS	19
6.3 ARQUITECTURA PROPUESTA.....	20
6.4 Construcción de la red	20

6.5	Entrenamiento de la red.....	21
6.6	Prueba de la red	22
7.	impacto y resultados esperados	23
8.	Recursos y presupuesto	25
9.	Cronograma.....	26
10.	Limitaciones	27
11.	Referencias.....	28

RESUMEN

La investigación de cáncer es una de las principales prioridades de la salud pública en el mundo, que impacta a una gran población debido a su letalidad cuando no es diagnosticada a tiempo; sin embargo, a pesar de los avances en la ciencia, en el momento el campo de la salud tiene falencias en la detección temprana de la enfermedad, especialmente en países de bajos recursos, esto debido a la falta de inversión y especialistas en el área que permitan dar un diagnóstico a tiempo, además de aumentar la supervivencia del paciente con un tratamiento oportuno.

Con el auge de nuevas tecnologías en la digitalización de láminas patológicas, así como iniciativas globales para la construcción de conjuntos de datos para la investigación de la enfermedad, a través de imágenes con factores de aumento que van en el orden de 40X, 100X, 200X, y 400X, se ha impulsado el surgimiento de la patología digital que permite apoyar la interpretación y clasificación de muestras malignas y benignas. Todo esto ha impulsado el desarrollo de métodos computacionales que permiten el análisis automatizado de imágenes histopatológicas, mediante el uso de técnicas para identificar cada una de las áreas de las imágenes, sumado a la variación visual de las láminas de histopatología; plantea obstáculos para evaluar la efectividad de los métodos por falta de datos precisos no etiquetados por los patólogos, así como la necesidad de métodos eficientes que permitan su uso de forma intuitiva.

De otra parte, el Deep Learning tiene la facilidad de analizar y optimizar el consumo de gran cantidad de datos para procesarlos de forma automática produciendo gran cantidad de información útil, esto lo realiza con base a reglas que permiten procesar la información, el Deep Learning puede extraer y organizar la información discriminativa de los datos, sin requerir el diseño de extractores de características por parte de un experto en el dominio.

En los últimos años las Redes Neuronales Convolucionales CNN como arquitectura del Deep Learning DL, han sido utilizadas para la resolución de varios problemas de ingeniería, no siendo la ingeniería biomédica una excepción. Estos modelos de algoritmos computacionales tienen aplicaciones en varias ramas de la ingeniería **biomédica** como la

ómica (investigación y estudio de estructuras de ADN) y la **imagenología - bioimaging** (detección de enfermedades infecciosas, cáncer y condiciones inflamatorias a partir del estudio de las células 'citología' y del tejido 'histopatología'), El potencial de las Redes Neuronales Artificiales ANNs en la ingeniería biomédica permite manejar grandes conjuntos de datos, reconocer patrones, extraer características, clasificar y predecir comportamientos.

Nuevas técnicas están surgiendo en reemplazo de modelos tradicionales para la representación de datos de forma manual, esto es conocido como aprendizaje de representación. Es importante la exploración y validación de métodos computacionales de Deep Learning enfocado a Redes Neuronales Convolucionales, partiendo de conjuntos de datos de imágenes histopatológicas, para el aprendizaje automático de la representación en labores asociadas al apoyo en el diagnóstico del cáncer de mama, enfocándose en la identificación de patrones de células cancerígenas mediante la validación de datos de imágenes en prospectiva.

PALABRAS CLAVE

Imagen Histopatológica, Cáncer de Mama, Deep Learning, Red Neural Convolucional, Biomédica

INTRODUCCIÓN

La histopatología es el estudio de los indicadores de enfermedad mediante inspección microscópica de muestras de tejido preparadas y fijadas en portaobjetos de vidrio. Estas muestras provienen de biopsias por punción o escisiones quirúrgicas. (Kose y Alzubi, 2021, p. 3). De otro lado, el cáncer de mama es una enfermedad particularmente común entre las mujeres y causa asociada de mortalidad femenina (Kose y Alzubi, 2021, p. 1).]. Para la detección de dicha enfermedad se utilizan diversos métodos de diagnóstico entre los que se encuentra la histopatología de imágenes, la histopatología es una pieza fundamental en la identificación de cualquier tipo de cáncer incluyendo el cáncer de mama. Por medio del estudio automatizado de imágenes benignas y malignas a través del diagnóstico asistido por computadora CAD, lo cual permite al experto centrar su esfuerzo en los casos más difíciles de diagnosticar de acuerdo con esta clasificación. (Spanhol et al., 2016, p. 1455), existe la necesidad del CAD para disminuir las cargas de trabajo de los patólogos mediante el filtrado de áreas obviamente benignas en las muestras, de modo que los expertos puedan concentrarse en los casos más difíciles de diagnosticar.

El uso de la arquitectura de Deep Learning para diagnóstico de cáncer de mama, se realiza mediante el análisis de imágenes histopatológicas, de otra parte, utilizando una red neuronal convolucional de aprendizaje profundo, se establece la detección del área de interés para el cáncer de mama (BC-DROID), así mismo las redes neuronales convolucionales CNN detectan y clasifican el ROI como benigno y maligno sobre las imágenes logrando una clasificación y precisión de detección del 93,5% y 90% respectivamente. Para mejorar la precisión del diagnóstico del software de análisis de imágenes multipropósito, se involucra y capacita a la red neuronal artificial de aprendizaje profundo, utilizando un conjunto de datos del repositorio digital de cáncer de mama (Kose y Alzubi, 2021, p. 39)

Se pretende a través de la exploración de técnicas supervisadas de Aprendizaje Profundo basado en redes neuronales convolucionales CNN (usadas para procesar imágenes), identificar la precisión de esta arquitectura, para validar la existencia de células cancerígenas de mama mediante el análisis de representación de imágenes histopatológicas.

1. PROBLEMA DE INVESTIGACIÓN

1.1 PLANTEAMIENTO DEL PROBLEMA

El cáncer de mama es uno de los factores más predominantes en la afectación de salud pública, debido a su alta tasa de mortalidad entre mujeres y en menor proporción en hombres, es por esta razón que se requiere el uso de técnicas modernas para diagnóstico temprano, con el fin de mitigar los riesgos en la población afectada por esta enfermedad, para la identificación de este cáncer es necesario identificar la región de interés ROI donde posiblemente se identifica la mitosis de células cancerígenas y diagnosticar la existencia de células de cáncer en el seno.

Con el fin de mitigar el impacto de esta enfermedad se recurre a técnicas medicas como lo es la toma de biopsia a través de la tinción con hematoxilina y eosina para ayudar a identificar diferentes tipos de células y tejidos y posteriormente a través de un portaobjetos se captura la imagen micro celular a través de instrumentos de alta precisión y capacidad de aumento, lo cual permite observar patrones para la identificación de anomalías en el tejido, el hecho de hacerlo de manera manual da lugar a posible error en el diagnóstico efectivo, por esta razón se hace necesario desarrollar un apoyo diagnóstico para mejorar esa precisión de diagnóstico, sumado al cansancio de los patólogos al interpretar áreas de interés de las muestras pueden conducir a interpretaciones erradas.

1.2 FORMULACION DEL PROBLEMA

Actualmente el uso de imágenes histopatológicas es una de las técnicas más usadas, para identificar la presencia de células cancerosas en el seno a través de la toma de biopsias, por tal motivo el procesamiento de imágenes hace uso de herramientas que permitan tener resultados más exactos, basándose en técnicas de Deep Learning, las cuales contribuye a resultados más rápidos y exactos para la toma de decisiones por parte de los expertos como soporte en el diagnóstico del cáncer de mama.

Con respecto a esta premisa del procesamiento de imágenes histopatológicas se plantean la siguiente pregunta:

¿Cuánto incrementaría la precisión en el diagnóstico de cáncer de mama con el uso de redes neuronales convolucionales?

1.3 SISTEMATIZACION DEL PROBLEMA

El diagnóstico del cáncer de mama requiere de una serie de pasos, lo que implica tiempo y esfuerzo prolongado, produciendo riesgo de que ocurran errores en el análisis de los datos de imágenes histopatológicas. Se pretende investigar si con el uso de Deep Learning enfocado en redes neuronales convolucionales, puede lograr mejor precisión en el diagnóstico del cáncer de mama.

- ¿Qué características de las muestras malignas permiten determinar la precisión del diagnóstico de cáncer de mama a partir de las imágenes histopatológicas usando Deep Learning?
- ¿Como se relacionan las variables identificadas en el diagnóstico del cáncer de mama?
- ¿Cómo identificar patrones de imágenes histopatológicas con herramientas de Deep learning mediante algoritmos de redes convolucionales?
- ¿Cómo validara la precisión en el diagnóstico de cáncer de mama?

2. OBJETIVOS

2.1 OBJETIVO GENERAL

Establecer un modelo enfocado a la aplicación de redes neuronales convolucionales para mejorar la precisión en el diagnóstico de cáncer de mama mediante imágenes histopatológicas.

2.2 OBJETIVOS ESPECÍFICOS

- Analizar y establecer las variables que determinan el diagnóstico de cáncer con respecto al conjunto de datos de imágenes histopatológicas disponible
- Evaluar y establecer la técnica de Deep learning enfoca a redes neuronales convolucionales para determinar el espectro de precisión del diagnóstico que se requiere e identificar los patrones de entrenamiento de la red.
- Desarrollar el prototipo de red para entrenamiento con el conjunto de datos.
- Validar el modelo de red neuronal convolucional propuesto.

3. JUSTIFICACION

La salud es un tema de relevancia global, ya que enfermedades como el cáncer de mama ha mantenido una constante de aumentado considerablemente, la motivación de esta investigación es indagar sobre las posibles soluciones que se pueden plantear para que la enfermedad pueda ser diagnosticada de forma temprana, con la mayor precisión, contribuyendo a mitigar las tasas de mortalidad.

3.1 JUSTIFICACIÓN TEÓRICA

El conjunto de datos que se almacena en Reikis el cual está compuesto por 7,909 imágenes microscópicas clínicamente representativas de Cáncer de Mama, basado en imágenes de tejido tumoral en una población de 82 pacientes en el mundo. (Spanhol et al., 2016, p. 1456), la cual permite la exploración relevante relacionada con esta enfermedad y permite mejora la calidad de vida del paciente con respecto a un diagnóstico temprano, mediante el uso de técnicas de Deep Learning para comparar biopsias de tejidos identificando la probabilidad de la existencia de células benignas y malignas.

Al realizar el entrenamiento en el documento se evidencio que en algunos casos tumores benignos se clasificaron como malignos (alta tasa de falsos positivos), esto se debe a que por el hecho de que uno de los tumores benignos presentes en el conjunto de datos (fibroadenoma) comparte propiedades similares con un tumor maligno (Spanhol et al., 2016, p. 1460)

El autor sugiere en la conclusión del documento profundizar en los factores de aumento (de imágenes) los cuales se deben investigar a futuro para diseñar una posible estrategia de grueso a fino para procesar las imágenes de diferentes factores de aumento. (Spanhol et al., 2016)

Por otra parte, partiendo del reusó del conjunto de datos se puede plantear un modelo de clasificación y predicción de Cáncer con la comparación de imágenes de pacientes (Litjens

et al., 2018, p. 1) que pueda permitir el incremento en la precisión del diagnóstico de la enfermedad.

3.2 JUSTIFICACIÓN METODOLÓGICA

Es necesario enfocarse en la definición de un conjunto de datos de imágenes histopatológicas, que permita realizar la configuración de los parámetros mínimos para realizar predicciones con mayor precisión, haciendo uso de técnicas de Deep Learning seleccionando la arquitectura de redes neuronales convolucionales que mejor se adapte al problema, para posteriormente realizar la clasificación a través de algoritmos definidos en esta arquitectura, evaluando el incremento en la precisión del diagnóstico.

3.3 JUSTIFICACIÓN PRÁCTICA

Con el estudio de técnicas de Deep Learning enfocadas en Redes Neuronales Convolucionales se pretende identificar, cuanto incrementaría la precisión para el diagnóstico de cáncer de mama, esto mediante la utilización de conjuntos de datos de imágenes histopatológicas de fuentes públicas de consulta.

4. MARCO DE REFERENCIA

4.1 MARCO TEÓRICO

El cáncer de mama es una enfermedad particularmente común entre las mujeres y causa asociada de mortalidad femenina (Kose y Alzubi, 2021, p. 1), se estima que 8,2 millones de muertes fueron causadas por cáncer en 2012 y se esperan 27 millones de nuevos casos de esta enfermedad antes de 2030. En particular, el cáncer de mama (BC) es uno de los tipos de cáncer más comunes entre las mujeres. (Spanhol et al., 2016, p. 1455)

La obtención de imágenes de diapositivas completos es una técnica en la que los escáner de alta velocidad digitalizan diapositivas a muy alta resolución con tamaño alrededor de 10 giga pixeles llamadas imágenes de diapositiva completa (WSI), ideales para análisis con algoritmos machine learning. (Litjens et al., 2018, p. 2), El primero se basa en la segmentación explícita para extraer propiedades de la estructura mientras que el segundo es un enfoque global basado en la representación de la textura. El documento se basa en el enfoque global de representación de textura. (Spanhol et al., 2016, p. 1457)

El concepto CAD ha existido durante una década, el principal objetivo de los desafíos, tanto en imágenes médicas como en visión por computadora, es permitir una comparación significativa de algoritmos, normalmente los autores presentan En la literatura científica, a menudo este no era el caso, ya que los autores presentan resultados en sus propios conjuntos de datos, a menudo propietarios, con su propia elección de métricas de evaluación. En imágenes médicas, esto fue un problema, ya que compartir datos médicos a menudo resultaba complejo, los desafíos cambian esto al hacer que los conjuntos de datos estén disponibles y hacer cumplir la evaluación estandarizada. (Litjens et al., 2018, p. 3)

4.2 MARCO CONCEPTUAL

- **Cáncer de Mama**

El cáncer de mama es un tipo de cáncer que se forma en las células de las mamas. Después del cáncer de piel, el cáncer de mama es el tipo más común diagnosticado en mujeres en Estados Unidos. El cáncer de mama se puede producir tanto en hombres como en mujeres; sin embargo, es mucho más común en las mujeres.

El considerable apoyo para la concientización y el financiamiento de investigaciones sobre cáncer de mama ha ayudado a crear avances en el diagnóstico y tratamiento del cáncer de mama. Las tasas de supervivencia del cáncer de mama han aumentado, y el número de muertes asociadas con esta enfermedad está disminuyendo constantemente, en gran medida debido a factores como la detección temprana, un nuevo enfoque de tratamiento personalizado y un mejor entendimiento de la enfermedad.

- **Sistema TNM de determinación del estadio del Cáncer**

La herramienta más frecuente que los médicos utilizan para describir el estadio es el sistema TNM. Los médicos utilizan los resultados de las pruebas de diagnóstico y las exploraciones para responder a las siguientes preguntas:

- **Tumor (T):** ¿qué tan grande es el tumor primario? ¿Dónde está ubicado?
- **Ganglio (Node, N):** ¿el tumor se ha diseminado a los ganglios linfáticos? De ser así, ¿a dónde y cuántos?
- **Metástasis (M):** ¿el cáncer se ha diseminado a otras partes del cuerpo? De ser así, ¿a dónde y en qué medida?

Los resultados se combinan para determinar el estadio del cáncer de cada persona.

Existen 5 estadios: estadio 0 (cero), que es carcinoma ductal in situ no invasivo (DCIS), y los estadios I a IV (1 a 4), que representan cáncer de mama invasivo. El estadio es una forma frecuente de describir el cáncer, de manera que los médicos puedan planificar de forma conjunta los mejores tratamientos.

La determinación del estadio puede ser clínica o patológica. La determinación del estadio clínico está basada en los resultados de las pruebas que se realizan antes de la cirugía, que pueden incluir un examen físico, una mamografía, una ecografía y exploraciones por

MRI. La determinación del estadio patológico está basada en qué se encuentra durante la cirugía para extirpar el tejido de la mama y los ganglios linfáticos. Por lo general, los resultados están disponibles varios días después de la cirugía. En general, la determinación del estadio patológico brinda la mayor parte de la información para determinar el pronóstico de un paciente. (Junta Editorial de Cancer.Net, 2018)

- **Machine Learning (ML)**

El *machine learning* (ML), conocido en español como aprendizaje de máquina, es una disciplina de la ciencia de la computación y una rama de la inteligencia artificial que tiene por objetivo desarrollar sistemas que aprenden

automáticamente, reconocen patrones y predicen comportamientos, a partir de conjuntos de datos (Sarmiento-Ramos, 2020, p. 1)

- **Aprendizaje profundo - Deep Learning (DL)**

El aprendizaje profundo (Deep Learning) es un tipo de aprendizaje automático e inteligencia artificial (IA) que imita la forma en que los humanos obtienen ciertos tipos de conocimiento. El aprendizaje profundo es un elemento importante de la ciencia de datos, que incluye estadísticas y modelos predictivos. Es extremadamente beneficioso para los científicos de datos que tienen la tarea de recopilar, analizar e interpretar grandes cantidades de datos; El aprendizaje profundo hace que este proceso sea más rápido y sencillo. (TECHTARGET, 2021)

Deep learning vs. machine learning

El aprendizaje profundo es un subconjunto del aprendizaje automático que se diferencia por la forma en que resuelve problemas. El aprendizaje automático requiere un experto en el dominio para identificar la mayoría de las funciones aplicadas. Por otro lado, el aprendizaje profundo comprende las características de manera incremental, eliminando así la necesidad de experiencia en el dominio. Esto hace que los algoritmos de aprendizaje profundo tarden mucho más en entrenarse que los algoritmos de aprendizaje automático, que solo necesitan de unos segundos a unas pocas horas. Sin embargo, ocurre lo contrario durante las pruebas. Los algoritmos de aprendizaje profundo toman mucho menos tiempo

para ejecutar pruebas que los algoritmos de aprendizaje automático, cuyo tiempo de prueba aumenta junto con el tamaño de los datos.

Además, el aprendizaje automático no requiere las mismas máquinas costosas y de alta gama y GPU de alto rendimiento que el aprendizaje profundo.

Al final, muchos científicos de datos eligen el aprendizaje automático tradicional en lugar del aprendizaje profundo debido a su capacidad de interpretación superior o la capacidad de dar sentido a las soluciones. Los algoritmos de aprendizaje automático también se prefieren cuando los datos son pequeños.

Los casos en los que el aprendizaje profundo se vuelve preferible incluyen situaciones en las que hay una gran cantidad de datos, una falta de comprensión del dominio para la introspección de características o problemas complejos, como el reconocimiento de voz y la PNL.

- **Redes neuronales artificiales (ANNs)**

Las ANNs son un modelo de un algoritmo computacional inspirado en las redes neuronales biológicas. Se constituyen como una herramienta que tiene la capacidad para aprender, generalizar y procesar automáticamente datos, con aplicación a tareas de clasificación y regresión. En la clasificación se busca organizar los datos de entrada en diferentes clases, y en la regresión, o aproximación defunción, predecir un parámetro de salida desconocido. Es a partir de estas aplicaciones, que se concluye que el potencial de las ANNs se encuentra en el reconocimiento de patrones y la predicción de comportamientos.




Ilustración 1 - Red Neuronal (Perceptrón)

- **Convolutional Neural Network (CNN)**

Las redes neuronales convolucionales son inspiradas en la corteza visual, la cual consiste en mapas de campos receptivos locales que responden a los estímulos únicamente en una región del campo visual, y disminuyen a medida que la corteza se mueve hacia adelante; los campos receptivos se superponen de modo que cubren todo el campo visual. Las CNNs toman la arquitectura de la DMLP, pero su principal diferencia es que cada neurona solo se encuentra conectada a un parche local de neuronas de la siguiente capa.

Arquitecturas de redes neuronales convolucionales

Year	CNN	Developed by	Place	Top-5 error rate	No. of parameters
1998	LeNet(8)	Yann LeCun et al			60 thousand
2012	AlexNet(7)	Alex Krizhevsky, Geoffrey Hinton, Ilya Sutskever	1st	15.3%	60 million
2013	ZFNet()	Matthew Zeiler and Rob Fergus	1st	14.8%	
2014	GoogLeNet(19)	Google	1st	6.67%	4 million
2014	VGG Net(16)	Simonyan, Zisserman	2nd	7.3%	138 million
2015	<u>ResNet(152)</u>	Kaiming He	1st	3.6%	

Ilustración 2 – Arquitecturas CNN

5. HIPÓTESIS

La utilización de redes neuronales convolucionales incrementa la precisión en el diagnóstico del cáncer de mama a través de la identificación de los patrones de imágenes histopatológicas, dado que se realiza la validación a través de un modelo entrenado basado en un conjunto de datos de imágenes de muestras malignas y benignas.

6. METODOLOGÍA

La metodología que se utiliza para el presente trabajo es: como primer paso, seleccionar el conjunto de datos de imágenes públicas de histopatología de cáncer de mama. Luego, se realiza la división de las imágenes en entrenamiento y prueba. Posteriormente, se realiza el diseño y la construcción para reconocer los patrones visuales directamente a partir de imágenes de píxeles, tomando como base el diseño de las arquitecturas de CNN actuales (AlexNet, GoogleNet y ResNet). Por último, entrenamos y validamos la red diseñada. En la figura (ilustración 3) se muestra la metodología seguida para el desarrollo de esta tesis.




Ilustración 3 - Metodología propuesta

6.1 CONJUNTO DE DATOS

En el presente trabajo se utilizan conjuntos de imágenes histopatológicas que tienen como características principales: categorías con un número de imágenes con tamaños diferentes

6.2 ACONDICIONAR EL CONJUNTO DE DATOS

Existen varias formas de ingresar los datos a la red, tales como: cargar los datos en cada paso de ejecución, precargar los datos en variables y generar archivos que contengan las imágenes histopatológicas para después cargarlas. Cargar las imágenes en cada paso de ejecución tiene un problema específico el proceso de lectura es lento para grandes cantidades de datos.

Precargar los datos en variables, se utiliza únicamente para pequeños conjuntos de datos, debido al límite de carga en memoria lo que genera sobrecarga; generando problemas en los procesos. El método más utilizado para el manejo de cantidades de imágenes grandes es la creación de archivos que contienen las imágenes para después cargarlas; por tal razón es el método seleccionado para la experimentación. Estos conjuntos contienen varias imágenes ya pre-procesadas de cáncer maligno y benigno con etiquetas de clase a la cual se asocian.

Una vez definidas las características de la imagen, se procede a crear el archivo que contendrá las imágenes. Estos archivos pueden contener todas las imágenes o un número específico, se debe tener presente la cantidad de memoria disponible en la GPU y la CPU para no tener problemas.

6.3 ARQUITECTURA PROPUESTA

Para el diseño de la arquitectura de red neuronal convolucional se requiere recopilar información en diferentes aspectos. Sabemos que las redes neuronales convolucionales están formadas por neuronas las cuales tienen pesos y sesgos, estos son guardados y utilizados para que la red aprenda. El tamaño de la imagen histopatológica influye en la red diseñada para la extracción de sus características; puede comenzar con una imagen de $224 \times 224 \times 3$, al ir pasando entre varias capas se extraen los parámetros más representativos. En las capas de extracción de características finales el vector multidimensional puede ser muy pequeño, por ejemplo, de $3 \times 3 \times (\text{número de filtros})$; este vector se transforma a un vector unidimensional para poder realizar cálculos con la capa totalmente conectada. Finalmente, se realiza la clasificación reduciendo las neuronas al número de clases del que se está haciendo el estudio.

6.4 CONSTRUCCIÓN DE LA RED

Se describe la forma en que se construye la red. Primero el bloque de extracción características y después el de clasificación.

Extracción de características

Para la construcción de la red se crean funciones como convolución, batch normalization, entre otras. Estas serán llamadas para reutilizar el código.

Se definen tres redes, la primera red que se codifica es la que utiliza un kernel de una matriz definida (ejemplo: 3x3) en todas sus capas de convolución, con métodos max-pooling y average-pooling.

- Concatenación de las tres redes

Finalmente, se unen las tres redes generadas, cada una extrae diferente información dependiendo de la definición del kernel.

Clasificación

La salida de cada capa de extracción de características se une para generar un vector unidimensional. Así se puede continuar con las capas totalmente conectadas para realizar la clasificación.

- **Capa de salida:** en la última capa mostrará el porcentaje de éxito identificando si la imagen histopatológica que se ingresó sea una muestra maligna o benigna.

6.5 ENTRENAMIENTO DE LA RED

Una vez generados los archivos de entrenamiento, éstos se cargan en la red, pero debe existir un módulo que decodifique los datos para procesarlos como imágenes de entrada.

Primero se leen los archivos, después se generan lotes de imágenes y etiquetas (describen a que clase pertenece cada imagen). Luego se ingresa el lote a la red neuronal convolucional, empieza a iterar hasta cumplir el número de épocas programado, en el proceso los pesos cambian en cada iteración y con diferentes lotes, al final guarda la red entrenada y el grafo, esto para poder realizar las pruebas más adelante.

6.6 PRUEBA DE LA RED

Para realizar la prueba, se carga la red entrenada y se evalúa con el conjunto de imágenes histopatológicas de prueba, posteriormente se genera un nuevo código especial para las pruebas donde se carga el grafo con sus respectivos pesos, pero se quita el método de aprendizaje, se modifica el dropout (técnica en la que las neuronas seleccionadas al azar se ignoran durante el entrenamiento) entre otros parámetros.

7. IMPACTO Y RESULTADOS ESPERADOS

El aporte de este trabajo es establecer el incremento en la precisión para el diagnóstico de cáncer de mama, analizando arquitecturas de redes convolucionales para la clasificación de las muestras histopatológicas con base a las técnicas de Deep learning, midiendo la salida para una predicción o clasificación adecuada con respecto a las técnicas tradicionales.

Generación de conocimiento y nuevos desarrollos tecnológicos

Resultado/Producto esperado	Indicador	Beneficiario
modelo de Redes Neuronales Convolucionales para diagnóstico de cáncer de mama	Modelo de CNN	Sector Salud, patólogos
Artículo científico	Carta de aceptación de la publicación	Comunidad científica
Prototipo de aplicación	Registro de software	Comunidad de salud y científica

- Fortalecimiento de la capacidad científica y la capacidad institucional


Resultado/Producto esperado	Indicador	Beneficiario
-----------------------------	-----------	--------------

Estudiante en formación de Maestría	Documento de Trabajo de grado, acta sustentación	Guillermo Pinzón Gómez, Grupo de investigación GITEM +
--	--	--


8. RECURSOS Y PRESUPUESTO

	Descripción	Cantidad	Fuente	Unitario	Proyectado Meses 1	Acumulado 11 Meses	Pendiente por ejecutar
Ingresos	Valor del proyecto	0		29.210.000			0
				29.210.000			
Gastos de Personal					2.080.000	22.880.000	24.960.000
Honorarios	Estudiante de Maestría - Medio tiempo	1	Estudiante	2.000.000	2.000.000	2.000.000	24.000.000
Honorarios	Profesor - Tutor / 1 hora x 15 días	1	Universidad	40.000	80.000	80.000	960.000
Honorarios	Experto en patología	1	Universidad	40.000			
Gastos Generales					650.000	1.650.000	1.650.000
Trasporte	Transporte		Estudiante		100.000	100.000	1.100.000
Materiales y suministros	Papelería, fotocopias, etc.		Estudiante		20.000	20.000	220.000
Servicios públicos	Luz, teléfono e internet		Estudiante		30.000	30.000	330.000
Otros	costos por impuestos y ambientes que se dispongan para llevar a cabo la ejecución del presente proyecto		Estudiante		500.000		0
Inversión					1.800.000	1.800.000	0
EQUIPO PROCESA DATOS	Equipo de Computo	1	Estudiante	1.800.000	1.800.000	1.800.000	
INGRESOS			0		35.800.000		
GASTOS DIRECTOS (Personal General Inversión)					4.530.000	24.530.000	29.060.000
GASTOS INDIRECTOS ADMINISTRACIÓN CENTRAL			25%		1.132.500	223.000	2.453.500
GASTOS INDIRECTOS			1%		453.000	223.000	2.453.000
EXCEDENTES NETOS					4.174.000		4.174.000
EXCEDENTES BRUTOS					4.174.000		
MARGEN DE RENTABILIDAD					11,66%		

9. CRONOGRAMA



- Recursos



10. LIMITACIONES

El proyecto esta enmarcado en los conjuntos de datos de imágenes histopatológicas de cáncer de dominio público.

11. REFERENCIAS

- Junta Editorial de Cancer.Net. (2018). *Cáncer de mama: Estadios* [El contenido de Cancer.Net está aprobado por la Junta editorial de Cancer.Net, que está formada por más de 150 oncólogos clínicos, cirujanos, pediátricos y radiooncólogos; personal de enfermería oncológica; auxiliares médicos; trabajadores sociales y defensores de los derechos de los pacientes.]. <https://www.cancer.net/es/tipos-de-c%C3%A1ncer/c%C3%A1ncer-de-mama/estadios>
- Kose, U. y Alzubi, J. (2021). *Deep learning for cancer diagnosis. Studies in Computational Intelligence: v.908*. Springer.
- Litjens, G., Bandi, P., Ehteshami Bejnordi, B., Geessink, O., Balkenhol, M., Bult, P., Halilovic, A., Hermesen, M., van de Loo, R., Vogels, R., Manson, Q. F., Stathonikos, N., Baidoshvili, A., van Diest, P., Wauters, C., van Dijk, M. y van der Laak, J. (2018). 1399 H&E-stained sentinel lymph node sections of breast cancer patients: The CAMELYON dataset. *GigaScience*, 7(6). <https://doi.org/10.1093/gigascience/giy065>
- Sarmiento-Ramos, J. L. (2020). Aplicaciones de las redes neuronales y el deep learning a la ingeniería biomédica. *Revista UIS Ingenierías*, 19(4), 1–18. <https://doi.org/10.18273/revuin.v19n4-2020001>
- Spanhol, F. A., Oliveira, L. S., Petitjean, C. y Heutte, L. (2016). A Dataset for Breast Cancer Histopathological Image Classification. *IEEE Transactions on Bio-Medical Engineering*, 63(7), 1455–1462. <https://doi.org/10.1109/TBME.2015.2496264>
- TECHTARGET. (2021). *Deep learning*. https://searchenterpriseai.techtarget.com/definition/deep-learning-deep-neural-network?_gl=1*1vmjmoz*_ga*MTgzNDA2MTYzOC4xNjIxNTY0NDUz*_ga_RRBYR9CGB9*MTYyMTU2NDQ1Mi4xLjEuMTYyMTU2NDQ2Ni4w&_ga=2.16964089.1371172069.1621564453-1834061638.1621564453