



MODELO DE PREDICCIÓN DE PROCESOS DE REMOCIÓN EN MASA, PARA EL MUNICIPIO DE
CÁQUEZA CUNDINAMARCA, USANDO IMÁGENES DE RADAR QUE PERMITAN METODO
DINSAR

Autor

Julieth Natalia Acosta Agudelo

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
Maestría en Ciencias de la Información y las Comunicaciones
Énfasis en Geomática
Bogotá, Colombia
mayo de 2026

MODELO DE PREDICCIÓN DE PROCESOS DE REMOCIÓN EN MASA, PARA EL MUNICIPIO DE
CÁQUEZA CUNDINAMARCA, USANDO IMÁGENES DE RADAR QUE PERMITAN METODO
DINSAR

Autor

Julieth Natalia Acosta Agudelo

**Presentado para optar por el título de: Magister en Ciencias de la Información y las
telecomunicaciones con énfasis en Geomática.**

Director:

Prof. PH.D ing. Erika Sofía Upegui Cardona

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
Maestría en Ciencias de la Información y las Comunicaciones
Énfasis en Geomática
Bogotá, Colombia
mayo de 2026

AGRADECIMIENTOS

A las mujeres que marcan mi camino: mi abuela, mi tía Tere y mi mamá, por enseñarme a superar cada adversidad. Mi agradecimiento profundo a mi directora de tesis, cuyo respaldo y motivación fueron el motor para salir adelante frente a todo pronóstico.

GLOSARIO

Complejo de un Solo Vistazo (SLC - Single Look Complex): Producto de nivel 1 que preserva la matriz compleja (amplitud y fase) de la señal SAR por píxel, constituyendo el insumo matemático elemental para la interferometría (Hanssen, 2001).

Fase de Superficie Plana (Flat Earth Phase): Fracción de la fase interferométrica inducida por la geometría orbital y la curvatura terrestre; su remoción es obligatoria para aislar las componentes de topografía y desplazamiento (Rosen et al., 2000).

Línea de Base Perpendicular / Línea de Base Crítica: La línea de base perpendicular es la distancia espacial entre órbitas proyectada ortogonalmente al vector de mira, controlando la sensibilidad topográfica. Si supera la línea de base crítica, la decorrelación geométrica es absoluta, impidiendo la generación del interferograma (Zebker y Villasenor, 1992).

Ángulo de Incidencia: Vector angular comprendido entre el haz del radar y la normal de la superficie local, determinando la proyección de la sensibilidad del sensor respecto al vector real de movimiento de la vertiente (Bürgmann et al., 2000).

Retrodispersión (Backscattering): Fracción de la energía electromagnética reflejada por los elementos de la superficie en la dirección del sensor, condicionada por la rugosidad y las propiedades del material (Ulaby et al., 1982).

Multilooking: Operación de promediado espacial de píxeles contiguos diseñada para mitigar el *speckle* (ruido de fase granular) y estabilizar la coherencia, asumiendo una pérdida controlada de resolución espacial (Lee et al., 1994).

Relación Señal-Ruido (SNR - Signal-to-Noise Ratio): Proporción matemática entre la potencia de la señal geodinámica útil y el ruido ambiental/térmico, métrica crítica para validar la convergencia de modelos analíticos (Bamler y Hartl, 1998).

Correlación Temporal y Espacial: Degradación de la coherencia de fase debido a modificaciones de la geometría o de la permitividad dieléctrica de la superficie (como variaciones de humedad o dinámica de la vegetación) entre adquisiciones sucesivas (Zebker y Villasenor, 1992).

Geometría de Adquisición Ascendente y Descendente: Trayectorias orbitales del satélite (Sur-Norte y Norte-Sur, respectivamente). Su combinación vectorial permite descomponer el desplazamiento medido en la línea de mira (LOS) en vectores tridimensionales reales (vertical y horizontal Este-Oeste) (Fialko et al., 2001).

Retraso de Fase Atmosférico (APS - Atmospheric Phase Screen): Distorsión de fase provocada por gradientes locales en el índice de refracción atmosférico (principalmente vapor de agua troposférico), cuyo comportamiento estocástico puede mimetizar señales de deformación tectónica o gravitacional (Emardson et al., 2003).

Dispersores Persistentes (PS - Persistent Scatterers): Píxeles estables y puntuales de alta reflectividad (estructuras antrópicas, afloramientos rocosos masivos) que exhiben una fase coherente a largo plazo, permitiendo resolver series temporales con precisión subcentimétrica (Ferretti et al., 2000, 2001).

Dispersores Distribuidos (DS - Distributed Scatterers): Píxeles que agrupan múltiples dispersores microscópicos estadísticamente homogéneos (pastizales, suelos desnudos). Su procesamiento requiere optimizaciones matemáticas locales para recuperar fases estables (Ferretti et al., 2011 [Algoritmo SqueeSAR]).

Redes Neuronales Recurrentes (RNN) y LSTM (Long Short-Term Memory): Arquitecturas probabilísticas con conexiones de retroalimentación interna, idóneas para procesar dependencias temporales de largo plazo y predecir aceleraciones críticas en series históricas de deformación InSAR (Hochreiter y Schmidhuber, 1997; Hochreiter, 1998).

Autoencoders Convolucionales (CAE): Redes neurales no supervisadas orientadas a la compresión del espacio latente y eliminación de ruido (*denoising*), aislando la señal cinemática pura frente a efectos atmosféricos o de decorrelación (Masci et al., 2011).

Transfer Learning (Aprendizaje por Transferencia): Estrategia de optimización que emplea pesos sinápticos pre-entrenados en grandes volúmenes de datos genéricos, ejecutando un ajuste fino (*fine-tuning*) enfocado en las firmas cinemáticas de remoción en masa de la zona de estudio (Yosinski et al., 2014).

Mecanismos de Atención (Transformers): Capas de ponderación dinámica que computan relaciones de dependencia espacial o temporal de largo alcance, permitiendo al modelo discriminar gradientes de fase anómalos e ignorar zonas con ruido (Vaswani et al., 2017).

Redes Neuronales de Grafos (GCN - Graph Convolutional Networks): Operadores convolucionales adaptados a topologías no euclidianas, estructurando redes de nodos puntuales de monitoreo (como puntos PS/DS) o interconexiones geomorfológicas dentro de cuencas hidrográficas (Kipf y Welling, 2016).

Datos Multimodales / Fusión de Sensores: Integración algorítmica de tensores heterogéneos (fase/amplitud InSAR, reflectancia óptica, variables morfométricas de MDE) para maximizar la robustez del espacio de características del modelo de IA (Lahiran y Singh, 2013).

Inferencia Bayesiana en Redes Neuronales: Formulación probabilística de redes neuronales que asigna distribuciones de probabilidad a los pesos sinápticos, permitiendo cuantificar formalmente la incertidumbre asociada a las alertas predictivas de fallas de laderas (Neal, 1995).

Métricas de Desempeño (IoU / F1-Score): *Intersection over Union (IoU)* calcula la relación de área de solapamiento entre la predicción y la máscara real del fenómeno (Jaccard, 1912). El *F1-Score* evalúa la media armónica entre precisión y exhaustividad, métrica indispensable ante el desbalance de clases del terreno (Dice, 1945; Sorensen, 1948).

Factor de Seguridad (FS): Relación matemática adimensional entre las fuerzas o momentos resistentes y las fuerzas o momentos motores actuantes. Los modelos de IA modernos buscan establecer funciones de transferencia no lineales para mapear variaciones del FS basándose en los vectores de deformación superficial medidos por InSAR (Bishop, 1955; Morgenstern y Price, 1965).

Gradiente de Fase y Deformación Diferencial: Variación espacial de la fase interferométrica por unidad de distancia, indicativo directo de tasas de deformación diferencial y concentración de cizallamiento en las zonas limítrofes del cuerpo del deslizamiento (Massonnet y Feigl, 1998).

Análisis Cinemático: Estudio geométrico y temporal del desplazamiento de las masas en movimiento sin considerar las fuerzas motrices originarias, derivado rigurosamente de series temporales de deformación para clasificar los mecanismos del fallo de la ladera (Goodman, 1989; Cruden y Varnes, 1996).

Estado de Actividad (Activity State): Clasificación normalizada del dinamismo de un movimiento en masa (activo, reactivado, suspendido, inactivo, abandonado). Las arquitecturas de IA se entrenan para automatizar esta clasificación a través de series de velocidad (Cruden y Varnes, 1996).

Umbrales Críticos de Precipitación: Límites empíricos o físicos de intensidad y duración de lluvia acumulada que actúan como funciones umbral para el disparo del movimiento; la integración de estos datos meteorológicos en modelos de aprendizaje profundo permite estructurar sistemas de alerta temprana (Caine, 1980).

Factor Condicionante e Intrínseco / Factor Detonante (Triggering Factor): Características estáticas y preexistentes del medio geológico (geometría del relieve, litología, discontinuidades) que

configuran la susceptibilidad basal a la inestabilidad. Son activados por eventos exógenos transitorios de alta energía (sismos, lluvias extraordinarias) que alteran súbitamente las condiciones hidromecánicas, gatillando el fallo de la ladera (Vallejo, 2002).

Mapeo de Susceptibilidad: Zonificación cartográfica que expresa la probabilidad espacial de ocurrencia de fenómenos de remoción en masa, calculada mediante la correlación de factores condicionantes y cinemáticos del terreno (Varnes, 1984; Soeters y van Westen, 1996).

DInSAR (Differential Interferometric Synthetic Aperture Radar): Técnica geodésica que explota la diferencia de fase entre dos adquisiciones de radar para aislar la componente de deformación del terreno. Al sustraer la fase topográfica (mediante un DEM) y corregir errores orbitales, permite medir desplazamientos en la línea de visión (LOS) con precisión milimétrica. Es la base de datos fundamental para el entrenamiento de modelos de regresión en IA (Gabriel et al., 1989; Massonnet et al., 1993).

Relieve: Configuración tridimensional de la superficie terrestre resultante de la interacción dinámica entre procesos endógenos (tectónica) y exógenos (clima, erosión). En IA, se representa mediante descriptores morfométricos como rugosidad, curvatura y aspecto (Pike, 1988; Wilson y Gallant, 2000).

Modelado: Proceso de configuración de las formas del terreno a través de la denudación, el transporte y la sedimentación. Se refiere tanto a la acción física como a la representación matemática de estos cambios (Strahler, 1952; Kirkby, 1971).

Geoforma: Unidad geomorfológica individualizada (ej. un cono de deyección o una cicatriz de deslizamiento) con características geométricas y genéticas homogéneas que la IA puede clasificar mediante segmentación de imágenes (Zinck, 1988; MacMillan et al., 2004).

Sustrato: Roca madre o material geológico consolidado que subyace a las formaciones superficiales. Su competencia mecánica y estructura (diaclasamiento, foliación) condicionan la estabilidad profunda (Selby, 1993; González de Vallejo, 2002).

Formación Superficial: Depósito no consolidado (coluvión, eluvión, suelo residual) derivado de la alteración del sustrato o transporte gravitacional. Es la capa donde ocurren la mayoría de los procesos de remoción en masa detectados por InSAR (Birkeland, 1999; Fookes et al., 2005).

Proceso Morfogénico: Acción física o química (erosión hídrica, gravedad, meteorización) que modela el relieve. La IA busca identificar la "firma" de estos procesos en los datos de deformación (Gilbert, 1909; Chorley et al., 1984).

Sistema Morfogénico: Conjunto interdependiente de procesos y formas que operan bajo un mismo régimen climático (ej. sistema paraglacial o tropical húmedo), donde cualquier alteración en un componente afecta el equilibrio de todo el sistema (Tricart y Cailleux, 1965; Büdel, 1982).

Principio de Inestabilidad: Concepto que establece que las laderas tienden a evolucionar hacia un estado de equilibrio crítico. Los modelos de IA utilizan este principio para identificar "precursores" o aceleraciones en la velocidad de deformación antes de una falla catastrófica (Scheidegger, 1991; Saito, 1969 [Previsión de fallos]).

Catena (Catenas de Suelos): Secuencia de suelos a lo largo de una vertiente cuyas variaciones dependen de la topografía y el drenaje. Es crucial para entender cómo la humedad (detectable por cambio de fase SAR) varía desde la cima hasta el pie del talud (Milne, 1935; Conacher y Dalrymple, 1977).

Meteorización: Desintegración física (disyunción) y descomposición química (hidrólisis, oxidación) de las rocas *in situ*. Este proceso debilita las propiedades geotécnicas del sustrato, aumentando la susceptibilidad a la remoción (Bland y Rolls, 1998; Central Geotechnical Office, 2004).

Movimientos en Masa: Procesos de transporte de volumen de material (suelo, roca, detritos) ladera abajo debido a la gravedad, cuando el esfuerzo cortante supera la resistencia al corte (Sharpe, 1938; Varnes, 1978).

Desplomes (Topples): Movimiento de rotación hacia adelante de una unidad de roca o suelo alrededor de un punto de pivote situado en su base, inducido por la gravedad o presión en discontinuidades verticales (Goodman y Bray, 1976).

Derrumbes (Falls): Desprendimiento súbito de una masa de roca o suelo de una ladera escarpada que desciende principalmente a través del aire mediante caída libre, rebotes y rodamiento (Varnes, 1978; Whalley, 1984).

Deslizaciones (Slides): Movimientos de ladera donde existe una superficie de ruptura clara (plana o curva) (Skempton, 1985). Se subdividen según su cinemática y geometría en:

Traslacionales: El movimiento sigue una discontinuidad o plano estructural subhorizontal (Hutchinson, 1988).

Rotacionales (Slumps): El movimiento es curvo y cóncavo, generando una rotación en la masa desplazada (Bishop, 1955).

Flujos Torrenciales (Debris Flows): Movimientos de masa rápidos y saturados de agua que se canalizan en la red de drenaje, compuestos por una mezcla heterogénea de sedimentos finos, rocas y detritos orgánicos. Poseen una alta energía cinética y son un reto crítico para la predicción mediante IA debido a su naturaleza episódica y súbita (Takahashi, 1981; Costa, 1984).

TABLA DE FIGURAS

Figura 1. Distribución espacial y temporal de las publicaciones.....	29
Figura 2. Estructura de la red Feed Forward	48
Figura 3. Localización del área final de estudio, cabeceras municipales incluidas.	60
Figura 4. Metodología desarrollada en la investigación.	65
Figura 5. Espacio de trabajo del postproceso de imágenes DInSAR para 2015.	67
Figura 6. Banda de intensidad sin postprocesar DInSAR para 2015.....	68
Figura 7. Aplicación de la órbita del satélite DInSAR para 2015.	69
Figura 8. Geocodificación inversa DInSAR para 2015.	69
Figura 9. Interferograma sin fase desenrollada, inicial calculado para 2015.....	70
Figura 10. Interferograma final que identifica los desplazamientos, inicial calculado para 2015.	70
Figura 11. Fallas en el municipio de Cáqueza, SGC.2020.	77
Figura 12. Amenaza de sísmica esperada a partir de estudios del SGC 2022.....	79
Figura 13. Amenaza de sísmica observada a partir de estudios del SGC 2022.....	79
Figura 14. Amenaza de sismo.	80
Figura 15. Inventario movimientos en masa municipio de Cáqueza. Fuente: SGC (2022).....	80
Figura 16. Amenaza de Remoción en masa, escala 100k. Fuente: SGC (2022)	81
Figura 17. Postproceso de cálculo de DEM, para las 3 épocas, imagen ejemplo 2015.	82
Figura 18. Cálculo de Isoyetas mediante Google engine Code.....	87
Figura 19. Cálculo de Isotermas mediante Google engine Code.	89
Figura 20. Imagen Mosaico mejor pixel 2016 Landsat 8 utilizada para clasificación de coberturas.	93
Figura 21. Imagen Mosaico mejor pixel 2015 Landsat 8 utilizada para clasificación de coberturas.	93
Figura 22. Imagen Mosaico mejor pixel 2020 Sentinel utilizada para clasificación de coberturas.	93
Figura 23. Imagen Mosaico mejor pixel 2023 Sentinel utilizada para clasificación de coberturas.	94
Figura 24. Índice NVDI 2015.....	94
Figura 25. Índice NVDI 2016.....	95
Figura 26. Índice NVDI 2020.....	95
Figura 27. Índice NVDI 2023.....	95
Figura 28. Calculo de coberturas en Google engine con método de regiones simples.	96

Figura 29. Cálculo de coberturas en Arcgis pro con máquina de soportes vectoriales, la leyenda aplica para la figura anterior.	97
Figura 30. Proceso de entrenamiento con esquemas de clasificación en Arcgis pro.	100
Figura 31. Clasificación de coberturas 2015.	101
Figura 32. Clasificación de coberturas 2016.	101
Figura 33. Clasificación de coberturas 2020.	102
Figura 34. Clasificación de coberturas 2023.	102
Figura 34. Tool resultante del desarrollo en Arcpy, revive las 38 variables mencionadas, junto con los datos de puntos de muestra.	104
Figura 34. Muestra inicial insertada en el entrenamiento, que corresponde a 1 millón de puntos que extraen la variable amenaza, esto se debe insertar en el tool.	110
Figura 35. Datos esperados con el entrenamiento.	112
Figura 36. Resultado Maching Learning Regresión sin temporalidad.	112
Figura 37. Máquina de soportes vectoriales.	113
Figura 38. Resultado Maching Learning Regresión con temporalidad.	114
Figura 39. Grafica de diferencias encontradas entre el modelo entrenado y el resultado esperado . Fuente: Elaboración propia, 2026.	115
Figura 40. Resultados obtenidos, de la revisión del entrenamiento del modelo	116
Figura 41. Localización espacial de los 983 puntos de control	116

TABLA DE TABLAS

Tabla 1. Influencias de los factores en las condiciones de los materiales y las laderas (Vallejo, 2002).	31
Tabla 2. Área total estudiada por municipio.	59
Tabla 3. Reporte histórico de procesos de remoción en masa, herramienta desarrollada en el marco Sendai.	61
Tabla 4. Sismos seleccionados para realizar la extracción de los datos.	66
Tabla 5. Imágenes de correlación de cada uno de los pares de trabajo para el interferograma.	71
Tabla 6. Interferogramas calculados para el proceso de entrenamiento.	72
Tabla 7. Tabla de variables utilizadas en la investigación.	75
Tabla 8. Imágenes de PGA.	78
Tabla 9. Modelos digitales de terreno de las 4 épocas seleccionadas.	82
Tabla 10. Pendientes calculadoras a partir del modelo digital de terreno.	84
Tabla 11. Isoyetas e Isotermas calculadas para el estudio	89
Tabla 12. Tipo de errores dentro de la validación de la matriz de confusión.	115

TABLA DE ECUACIONES

Ecuación 1. Resistencia al corte de suelos no saturados.....	39
Ecuación 2. Fórmula de cálculo del índice de vegetación de diferencia Normalizada (NDVI).....	42
Ecuación 3. Formula de procesamiento inicial para implementar Feed Forward.	49
Ecuación 4. Formula de neurona de capa Oculta	49
Ecuación 5. Formula neurona Activa.....	49
Ecuación 6. Formula capa de salida con neuronas de la capa oculta.....	49
Ecuación 7. Formula Función de activación.....	50
Ecuación 8. Formula cálculo de error de las unidades de salida.	50
Ecuación 9. términos de error de las capas ocultas.	50
Ecuación 10. Formula actualización de los pesos para el entrenamiento.....	50
Ecuación 11. Formula de verificación del modelo para finalizar.....	51
Ecuación 12. Formula de variables restrictivas de primer orden.....	54
Ecuación 13. Derivadas expresadas del cálculo.....	55
Ecuación 14. Fórmula para elementos lineales.....	55
<i>Ecuación 15. Función de factor.....</i>	<i>56</i>
<i>Ecuación 16. Formula cálculo de variables y desviación de la variable.....</i>	<i>56</i>
<i>Ecuación 17. Fórmula de cálculo de desplazamiento anual y corto plazo.....</i>	<i>56</i>
<i>Ecuación 18. Fórmula del largo plazo según años de evaluación.....</i>	<i>57</i>

TABLA DE CONTENIDO

1.	RESUMEN	15
2.	PALABRAS CLAVE.....	16
3.	CAPITULO 1. DESCRIPCIÓN DEL ESTUDIO	17
3.1	INTRODUCCIÓN	17
3.2	PLANTEAMIENTO DEL PROBLEMA	18
3.3	SISTEMATIZACION DEL PROBLEMA.....	19
4.	OBJETIVOS.....	20
4.1	OBJETIVO GENERAL	20
4.2	OBJETIVOS ESPECÍFICOS	20
5.	JUSTIFICACION.....	21
5.1	JUSTIFICACIÓN TEÓRICA	21
5.2	JUSTIFICACIÓN METODOLÓGICA	22
5.3	JUSTIFICACIÓN PRÁCTICA.....	23
6.	HIPÓTESIS.....	24
7.	CAPITULO 2. MARCO DE REFERENCIAL	25
7.1	ESTADO DEL ARTE	25
7.1.1	CONTEXTO A NIVEL MUNDIAL	25
7.1.2	CONTEXTO LATINOAMERICANO	30
7.1.3	CONTEXTO COLOMBIANO.....	33
7.2	MARCO NORMATIVO	37
7.2.1	MARCO NORMATIVO A NIVEL INTERNACIONAL	37
7.2.2	MARCO NORMATIVO A NIVEL NACIONAL	38
7.3	MARCO TEÓRICO	39
7.3.1	RELIEVE, GEOLOGÍA, GEOMORFOLOGÍA, GEOTECNIA Y COBERTURA Y USO DEL SUELO.	39
7.3.1.1	RESISTENCIA AL CORTE DE SUELOS NO SATURADOS.....	39
7.3.1.2	COBERTURA Y USO DEL SUELO E IMÁGENES UTILIZADAS PARA LA CLASIFICACIÓN	40
7.3.1.3	INDICES IMÁGENES	42
7.3.2	FACTORES DETONANTES	43

7.3.3	LA INTERFEROMETRÍA COMO ESTUDIO DE LA REMOCIÓN EN MASA.	45
7.3.4	REDES NEURONALES Y TIPOS DE MODELADO	47
7.3.5	REMOCIÓN EN MASA Y LAS AFECTACIONES EN EL TERRITORIO	53
7.3.6	PROBABILIDADES DE FALLA DE TALUDES	54
7.3.6.1	DESARROLLO DE SERIES DE TAYLOR	54
7.3.6.2	MÉTODO DE PEM	56
7.3.6.3	CAMBIOS A CORTO PLAZO (ANUAL) Y A LARGO PLAZO	56
7.4	MARCO TEMPORAL	57
7.5	MARCO GEOGRÁFICO	58
7.6	MARCO HISTORICO	60
8.	CAPITULO 3. METODOLOGÍA	63
8.1	METODOLOGIA	65
9.	CAPITULO 4. DESARROLLO, RESULTADOS DE LA INVESTIGACIÓN Y ANÁLISIS	66
9.1	FASE 1: RECOLECCIÓN Y PRE-PROCESAMIENTO DE DATOS (INPUT)	66
9.1.1	INSUMOS RECOLECTADOS	66
9.2	FASE 2: PROCESAMIENTO INTERFEROMÉTRICO (DINSAR)	67
9.3	FASE 3: ANÁLISIS DE FACTORES DE INESTABILIDAD	75
9.3.1	FALLAS GEOLÓGICAS	76
9.3.2	SISMOLOGÍA	77
9.3.3	MOVIMIENTOS EN MASA	80
9.3.4	RELIEVE	81
9.3.5	HISTÓRICO ISOYETAS E ISOTERMAS	86
9.3.6	COBERTURA Y USO	91
9.4	FASE 4: ESTRUCTURACIÓN DEL MODELO DE PREDICCIÓN	102
9.5	FASE 5: VALIDACIÓN	111
10.	CAPITULO 5. CONCLUSIONES Y RECOMENDACIONES	118
10.1	CONCLUSIONES	118
10.2	RECOMENDACIONES	119
11.	BIBLIOGRAFÍA	120
12.	ANEXOS	125

GRUPO DE INVESTIGACIÓN

Grupo GEFEM, Grupo de investigación con reconocimiento en Colciencias y clasificación tipo C, con trayectoria de 13 años de investigación de la universidad distrital, con 358 artículos publicados en revistas nacionales, internacionales y no indexadas, se tiene varias líneas de investigación como la geomática, estudios del territorio, fotogrametría, las geo tecnologías y el uso de inteligencia artificial para análisis de imágenes, adicionalmente se trabajan áreas como la matemática y computación, como analítica de datos, modelación de sistemas físicos y biológicos (*Página de Inicio | GEFEM, 2026*).

LÍNEA DE INVESTIGACION

El núcleo estratégico de esta línea de investigación se fundamenta en la convergencia de las matemáticas avanzadas, la modelación estadística, la analítica predictiva y la ciencia de datos. Este andamiaje metodológico está estrictamente orientado hacia el avance y la optimización de la inteligencia computacional. A través de este enfoque interdisciplinar, se busca diseñar, validar e implementar algoritmos matemáticos complejos capaces de resolver problemas de alta dimensionalidad, procesar volúmenes masivos de información y optimizar la toma de decisiones automatizada en entornos de alta incertidumbre.

DIRECTOR Y CODIRECTOR

Erika Sofia Upegui, Ingeniera Catastral y geodesta es profesora actualmente en la Universidad Distrital Francisco José de Caldas, Cuenta con Doctorado en geografía y ordenamiento territorial. Cuenta con dos libros publicados, y 38 artículos publicados en revistas especializadas a participado como jurado en comités de evaluación y en múltiples eventos científicos, ha sido directora de tesis de proyectos de investigación de pregrado y posgrado.

1. RESUMEN

La gestión del riesgo por movimientos en masa en orógenos activos como la Cordillera Oriental de Colombia requieren pasar de estudios de marco subjetivo a un marco objetivo, es así que, esta investigación propone una **transición metodológica** al sustituir los modelos de susceptibilidad **heurísticos** —basados en el juicio subjetivo de expertos— por un sistema de **predicción objetivo**, donde el peso de cada variable es determinado matemáticamente por el aprendizaje estadístico. En el municipio de Cáqueza (Cundinamarca), la compleja interacción entre la dinámica lito-estructural y los procesos de ocupación antrópica ha derivado en una recurrencia crítica de fenómenos de remoción en masa en la última década (Ministerio de Minas y Energía & Servicio Geológico Colombiano, 2013). Esta investigación desarrolla un marco metodológico basado en el aprendizaje estadístico supervisado, implementando algoritmos de **Machine Learning** mediante el modelo **Random Forest Regresión (RFR)** para la cuantificación y predicción de la inestabilidad de vertientes. La arquitectura del modelo se fundamenta en un análisis multivariado que integra un *dataset* geoespacial de **38 variables predictoras**, el cual incorpora un **marco temporal de cuatro épocas** de observación. Este enfoque multitemporal permite capturar la evolución dinámica del terreno y mejorar la robustez de las predicciones frente a los cambios en las condiciones y los detonantes, realizando una armonización y procesamiento mediante un flujo de trabajo programático para obtener una aplicación geográfica entrenada, optimizando el apilamiento multibanda y la extracción de firmas espaciales-espectrales necesarias para el entrenamiento del algoritmo (Breiman, 2001).

El componente diferenciador de la investigación radica en la incorporación de la velocidad de deformación superficial derivada de la **DInSAR** mediante el procesamiento de imágenes del sensor Sentinel-1. Esta variable cinemática, permite capturar la evolución temporal de los desplazamientos y superar la naturaleza estática de los modelos de susceptibilidad convencionales (Bilgilioğlu, 2023). El entrenamiento del modelo se orientó a la minimización de la varianza del error mediante el análisis de la **Importancia de Variables (Gini Importancia)**, permitiendo identificar al vector de deformación interferométrica como el precursor cinemático con mayor peso relativo en la función de regresión (Lombardo et al., 2020).

Para garantizar la integridad y capacidad de generalización del modelo, se implementó un protocolo de validación cruzada (k-fold cross-validation), eliminando el sesgo por sobreajuste (overfitting) y evaluando el desempeño en áreas con vacíos de información histórica. El éxito del modelo se cuantificó a través de métricas de bondad de ajuste, alcanzando un Coeficiente de Determinación y una reducción sustancial del Error Cuadrático Medio (RMSE) y el Error Medio Absoluto (MAE), demostrando una precisión superior a los métodos de regresión logística o pesos de evidencia. En conclusión, la sinergia

entre el monitoreo interferométrica y los modelos de bosques aleatorios constituye un avance significativo en la gestión prospectiva del riesgo. Este enfoque proporciona una herramienta de precisión para la planificación territorial sostenible en Cáqueza, facilitando la toma de decisiones técnicas basadas en evidencia científica medible y reproducible, entregando un modelo de aplicación que se podrá utilizar para diferentes regiones del país.

2. PALABRAS CLAVE

Movimiento en masa, DInSAR, Redes Neuronales, Modelos de predicción, Sistema de Posicionamiento Global.

3. CAPITULO 1. DESCRIPCIÓN DEL ESTUDIO

3.1 INTRODUCCIÓN

Existen diferentes fenómenos naturales causados por las características específicas del terreno, como suelos, geología y fallas, dentro de la gama de eventos se evidencia el fenómeno de remoción en masa, desde el punto de vista geomorfológico es un fenómeno que involucra movimiento de material formador de ladera por influencia de la gravedad, sin transporte de fluido (Alcántara Ayala, García, & Giselle, 2008). En los últimos años, las técnicas de DInSAR han sido utilizadas para estudiar las deformaciones sobre el terreno, por sus grandes avances (Cui, Zeng, Liang, & Jiao, 2010); esta técnica ha demostrado ser excelente para monitorear las deformaciones terrestres ya que concede un patrón de deformaciones; adicionalmente las propiedades del tipo de sensor con el cual se obtienen las imágenes facilitan disminuir los efectos atmosféricos. La banda más relevante en radar es la Banda L para estos estudios (Ferro-Famil & Pottier, 2016), es interesante para las zonas donde se encuentra la vegetación, toda vez que, accede por su longitud de onda a penetrar el follaje de las hojas, mientras la banda X es más sensible a deformaciones de menor magnitud. Con técnicas de interferometría se pretende estudiar las deformaciones generadas en el entorno espacial y geográfico para relacionarlo con variables como el clima y características del terreno para formular un modelo mediante inteligencia artificial para poder predecir movimientos o deformaciones futuras (Fuquan, Zuxi, & Hanying, 2012).

Estas técnicas de DInSAR generan resultados de deformaciones únicamente en los pixeles que tienen la calidad suficiente a la largo de la información sobre el sensor, esto promueve determinar deformación y permite enlazar mediante una regresión para poder calcular cual son las variables que hacen que este proceso de deformaciones sea mayor (Yuanyuan Wang & Zhu, 2015).

Las redes neuronales son estructuras de neuronas en diferentes niveles que se enlazan para transmitir información, se trabaja mediante estructuras matemáticas, estas redes aprenden con un porcentaje de la información histórica a través de entrenamiento, en este proceso se ajustan los parámetros de la red, esto permite tener una salida o respuesta más acertada, los teóricos aprueban que el 80 % de los datos pueden ser aptos para entrenar el sistema de red y se comportará de acuerdo a los pesos de los enlaces, y dependiendo del algoritmo el error de pronóstico puede irse corrigiendo (Freeman & Skapura, 1991).

El municipio de Cáqueza (Cundinamarca) presenta una alta susceptibilidad a fenómenos de remoción en masa que comprometen directamente su infraestructura crítica. Para abordar esta

problemática, esta investigación propone el desarrollo de un modelo predictivo basado en Redes Neuronales Artificiales. El sistema se alimentará de forma multimodal mediante la integración de deformaciones milimétricas obtenidas por DInSAR, datos históricos de geodesia espacial provistos por el Servicio Geológico Colombiano (SGC), parámetros geotécnicos de análisis de suelos y mapas de cobertura vegetal. El modelo resultante permitirá correlacionar la dinámica geomorfológica del terreno con sus factores condicionantes, estructurando un sistema de monitoreo continuo para optimizar los tiempos de respuesta institucional ante futuros eventos catastróficos.

3.2 PLANTEAMIENTO DEL PROBLEMA

El territorio colombiano se encuentra dentro de la zona sísmica más activa conocida como Anillo Circumpacífico (Tiempo, 2016), tiene una topografía compuesta, el 33% de terreno montañoso y 67% de terreno plano, estas formaciones rocosas que representan las montañas tienen algunos inconvenientes por problemas de remoción en masa, el municipio de Cáqueza Cundinamarca, localizado en la cordillera oriental, tiene problemas evidentes en sus construcciones por grietas, que se dan por remociones en masa, esto solo es un caso de los muchos que se presentan a lo largo del territorio colombiano.

Actualmente las remociones en masa se evalúan mediante la técnica de DInSAR, la cual utiliza imágenes de Sistema de radar de apertura sintética (SAR), a su vez, la interferometría se centra en el estudio y explotación de la información proporcionada por las imágenes de fase de las imágenes complejas SAR (Fuquan et al., 2012). Tanto la técnica de interferometría SAR (InSAR), como la DInSAR, se basan en la explotación contenida en uno o más interferograma (Riyahi, Kleinn, & Fuchs, 2009). La interferometría es utilizada para la cuantificación de deformaciones ocurridas en la superficie terrestre, mediante la obtención de la altura del suelo a partir de dos imágenes SAR, obtenidas desde puntos próximos con cierto intervalo temporal de separación, donde se utiliza un Modelo Digital de Elevación (DEM) para poder generar el modelo completo.

Este proyecto busca definir un modelo de predicción de movimientos de remoción en masa dentro del municipio de Cáqueza con el objeto de, determinar las zonas en el municipio más afectadas y establecer las recomendaciones para la operación y recuperación del territorio para prevención de desastres. Para esto se utilizaron variables tales como: Coberturas del suelo, geología, geomorfología e hidrología, variables que a lo largo del documento se explicarán junto con las fuentes de información utilizadas.

3.3 SISTEMATIZACION DEL PROBLEMA

¿Cuáles han sido las zonas afectadas por movimientos en masa en el municipio de Cáqueza entre 2014 y 2024?

¿Cuáles son las variables que están interviniendo en las zonas afectadas de remoción en mapa del municipio?

¿Qué modelo de análisis de predicción de movimientos de remoción en masa, con el uso de redes neuronales artificiales, se ajusta mejor a las variables del proyecto?

¿Qué eficiencia y porcentaje de error presenta el modelo desarrollado?

4. OBJETIVOS

Los objetivos de la investigación se centran en la solución del problema de investigación:

4.1 OBJETIVO GENERAL

Desarrollar un modelo de predicción de los movimientos en masa del municipio de Cáqueza Cundinamarca mediante el uso de redes neuronales entrenándolo con información disponible durante los años 2014 y 2024.

4.2 OBJETIVOS ESPECÍFICOS

Definir las zonas afectadas por la subsidencia en el municipio de Cáqueza medida a partir de pares complejos de radar.

Definir las variables que intervienen en las zonas afectadas por el fenómeno de remoción en masa del municipio.

Generar una metodología de análisis de predicción de movimientos de remoción en masa con el uso de redes neuronales artificiales

Validar el modelo generado para la predicción de movimientos en masa, mediante los datos existentes del Servicio Geológico Colombiano.

5. JUSTIFICACION

De acuerdo con el Servicio Geológico de los Estados Unidos (USGS por sus siglas en inglés), el fenómeno conocido como “*subsistencia*” corresponde al hundimiento del terreno debido a cambios que ocurren en profundidad, principalmente a la extracción de fluidos de fuentes subterráneas (agua, gas, petróleo), disolución de rocas como calizas y dolomitas debido al flujo de acuíferos (karstificación), colapso de minas subterráneas, drenaje de suelos orgánicos, como también, al humedecimiento de suelos secos (hidro compactación). Dada la formación geológica de los suelos preferencialmente arcillosos y en general del entorno geomorfológico, se establece que existe susceptibilidad a que se presente dicho fenómeno en el municipio de Cáqueza Cundinamarca.

La subsistencia es un problema que afecta grandes extensiones de terreno, sin embargo, las zonas urbanas, debido a la infraestructura existente, son más susceptibles a los movimientos del terreno en menores extensiones de terreno, en el municipio y en general en el país no existe un modelo que permita determinar con anticipación los movimientos en masa o subsistencia de una zona, según las propiedades geográficas, esto permitiría general alertas tempranas (O. D. R. González, 2020).

Por lo anterior, este proyecto de investigación permitió definir un modelo de predicción basado en Redes Neuronales, que pronosticó como y cuáles serán los movimientos en masa o deformaciones en el terreno que se presentan.

5.1 JUSTIFICACIÓN TEÓRICA

Existen diferentes fenómenos naturales causados por las características específicas del terreno, como suelos, geología y fallas, dentro de la gama de eventos se evidencia el fenómeno de remoción en masa, desde el punto de vista geomorfológico es un fenómeno que involucra movimiento de material formador de ladera por influencia de la gravedad, sin transporte de fluido (Alcántara Ayala & Murillo García, 2008). En los últimos años, las técnicas de DInSAR han sido utilizadas para estudiar las deformaciones sobre el terreno, por sus grandes avances (Cui et al., 2010); esta técnica ha demostrado ser excelente para monitorear las deformaciones terrestres ya que concede un patrón de deformaciones, adicionalmente las propiedades del tipo de sensor con el cual se obtienen las imágenes facilitan disminuir los efectos atmosféricos. La banda más relevante en radar es la Banda L para estos estudios (Ferro-Famil & Pottier, 2016), es interesante para las zonas donde se encuentra la vegetación, toda vez que, accede por su longitud de onda a penetrar el follaje de las

hojas, mientras la banda X es más sensible a deformaciones de menor magnitud. Con técnicas de interferometría se pretende estudiar las deformaciones generadas en el entorno espacial y geográfico para relacionarlo con variables como el clima y características del terreno, formular un modelo mediante inteligencia artificial para poder predecir movimientos o deformaciones futuras (Fuquan et al., 2012).

5.2 JUSTIFICACIÓN METODOLÓGICA

La fundamentación y justificación metodológica de esta investigación se sustenta en la necesidad crítica de superar las limitaciones analíticas y operativas que caracterizan a los métodos convencionales de monitoreo geotécnico y cartografía de susceptibilidad. Tradicionalmente, la evaluación de fenómenos de remoción en masa se ha apoyado en instrumentación en campo (como inclinómetros, piezómetros y estaciones totales) o en modelos estadísticos estáticos (como el Proceso de Análisis Jerárquico o regresiones logísticas). Si bien estos enfoques son valiosos, exhiben restricciones severas: los métodos instrumentales de terreno conllevan altos costos de instalación, poseen una cobertura espacial de carácter puramente puntual y no permiten realizar análisis retrospectivos del terreno. Por su parte, las aproximaciones estadísticas clásicas fallan al intentar capturar la naturaleza dinámica, no lineal y multivariable que rige la inestabilidad de las laderas. Para resolver estas limitaciones, este proyecto propuso un enfoque metodológico de vanguardia basado en el acoplamiento de dos tecnologías disruptivas: la teledetección espacial por radar y la inteligencia computacional.

En primer lugar, la adopción de la DInSAR se justifica plenamente por su capacidad para cartografiar y cuantificar deformaciones superficiales con una precisión de escala milimétrica. Al explotar las diferencias de fase entre adquisiciones satelitales repetitivas, DInSAR proporciona series temporales continuas que permiten reconstruir el historial cinemático de la ladera sin necesidad de intervenir físicamente el territorio. Esta técnica resuelve el vacío de información geoespacial frecuente en el municipio de Cáqueza, transformando observaciones satelitales densas en vectores de desplazamiento que sirven como la variable dependiente (target) fundamental del estudio.

En segundo lugar, la integración de Redes Neuronales Artificiales (RNA) se justifica metodológicamente debido a su idoneidad para procesar e interpretar la fusión de datos multimodales y heterogéneos de alta dimensionalidad. El comportamiento geodinámico de una ladera no depende de un único factor; es el resultado de una interacción compleja entre variables condicionantes intrínsecas (geotecnia, tipo de suelo, cobertura y uso de la tierra) y detonantes activos. Las Redes Neuronales poseen la capacidad matemática intrínseca de aproximar funciones complejas no lineales y descubrir patrones ocultos entre estas variables sin necesidad de asumir distribuciones estadísticas previas. Al alimentar el algoritmo con datos procedentes del Servicio Geológico Colombiano, el modelo de IA actúa como un sintetizador

inteligente capaz de correlacionar las características del sustrato con las tasas de movimiento medidas por el satélite. Finalmente, la estrategia de evaluar y validar de forma comparativa diferentes arquitecturas neuronales preestablecidas en la literatura científica dota a la investigación de un riguroso sustento formal. Esta metodología experimental asegura que la selección del modelo final no sea arbitraria, sino el producto de un análisis estadístico de rendimiento (mediante métricas de error y matrices de confusión) frente a los datos reales de remoción en masa en la zona. En consecuencia, este marco procedimental no solo optimiza la precisión en la estimación de los desplazamientos del terreno en Cáqueza, sino que valida un protocolo metodológico robusto, escalable y altamente replicable. El flujo de trabajo propuesto establece un precedente metodológico para la transición desde el monitoreo reactivo tradicional hacia sistemas automatizados de predicción y alerta temprana, aplicables a otros municipios andinos que enfrentan crisis geomorfológicas e infraestructurales similares.

5.3 JUSTIFICACIÓN PRÁCTICA

Esta problemática se intensifica debido a las intervenciones humanas en el territorio, específicamente por las obras civiles en la vía Bogotá – Villavicencio y la densificación urbana descontrolada, factores que alteran la estabilidad natural de las laderas. La carencia de una planificación del desarrollo territorial en el municipio de Cáqueza ha desencadenado graves problemáticas geomorfológicas y estructurales. En el ámbito rural, específicamente en sectores como la vereda Placitas, se evidencia un incremento de construcciones ejecutadas sin licencias urbanísticas ni estudios geotécnicos pertinentes. Esta falta de control ha derivado en pérdidas económicas totales, debido a que los movimientos en masa y las fallas geológicas activas generan agrietamientos severos que vuelven inhabitables estas estructuras. Asimismo, las intervenciones antrópicas inadecuadas han desestabilizado laderas completas, ocasionando daños estructurales severos en las principales vías de acceso municipal. Actualmente, Cáqueza no dispone de una herramienta tecnológica que permita cuantificar la relación de causa y efecto entre las variables condicionantes del terreno y la dinámica de los deslizamientos. Por consiguiente, esta investigación se justifica al proveer un modelo predictivo que sirva como instrumento de soporte en la toma de decisiones para la planificación territorial y la regulación estricta en la expedición de licencias de construcción.

6. HIPÓTESIS

¿Se puede modelar mediante modelos inteligencia artificial los movimientos de la ladera y procesos de subsidencia, utilizando como bases variables como el clima, la geología, hidrogeología, geomorfología, metodologías de DInSAR e intervenciones antrópicas, que permita determinar zonas de mayores deformaciones, o zonas potenciales de susceptibilidad?, esto con el fin de que se convierta en una herramienta de planificación territorial, para minimizar el efecto o condiciones que potencialicen este fenómeno natural.

7. CAPITULO 2. MARCO DE REFERENCIAL

7.1 ESTADO DEL ARTE

“Remoción en masa, Inteligencia computacional y modelos predictivos”

Este apartado sintetiza el estado del arte y las investigaciones previas que sirven de base científica para el desarrollo de este proyecto. La revisión bibliográfica se estructuró de manera categórica mediante ejes temáticos, permitiendo identificar los factores comunes y las metodologías que fundamentan el carácter innovador de esta propuesta. A partir de este análisis conceptual, se establecen los antecedentes metodológicos y el marco de referencia necesarios para delimitar el alcance y los aportes de la investigación antes de su ejecución.

7.1.1 Contexto a nivel mundial

Evaluación de riesgos de deslizamiento de tierra

La información cartográfica facilita la identificación de patrones de ocurrencia espacial y espacio-temporal para proyectar futuros deslizamientos. No obstante, este análisis predictivo requiere precisar las condiciones que detonan y controlan la inestabilidad en el área de estudio. Al respecto, el Manual sobre el Manejo de Peligros Naturales en la Planificación para el Desarrollo Regional Integrado (1993) establece tres factores físicos fundamentales para la evaluación del terreno: el registro histórico de movimientos, la geometría de las pendientes y la naturaleza del sustrato rocoso. Adicionalmente, el documento reconoce el impacto crítico del factor hidrogeológico —asociado a la dinámica de las aguas subterráneas—, sugiriendo la evaluación integrada de la cobertura vegetal, la inclinación del terreno y los regímenes de precipitación como variables de control del flujo hídrico.

El manual anterior define criterios que se tomaron en cuenta, el cual divide el proceso en 4 etapas para la planificación:

- **Cartografía de los deslizamientos existentes y preparación de un mapa de inventario** (o bien, el mapa de sobreposición de deslizamientos de tierra que mencionas).
- **Cartografía de los factores físicos permanentes** asociados con deslizamientos de tierra (tipo de roca firme y geometría/clase de pendientes).
- **Combinación de grupos usando el análisis de factores** (para asociar estadísticamente los deslizamientos históricos con los factores permanentes).

- **La interpretación del peligro de deslizamientos de tierra y producción del mapa de peligro final.**

Se logra una división inicial en tres grupos separando en partes iguales el rango presente de valores proporcionales. Los límites superior e inferior de cada grupo se retienen o se ajustan para asegurar que la división final represente la suma mínima de las desviaciones al cuadrado, alrededor de los tres promedios de grupo. Esto está basado en la función W (Anderberg, 1973)

Avances Inteligencia Artificial Geoespacial (GeoAI)

En el ámbito de las ciencias geoespaciales, se ha impulsado el desarrollo de aplicaciones basadas en inteligencia artificial, especialmente mediante enfoques de aprendizaje profundo (Deep Learning). Uno de los desafíos más críticos identificados en esta disciplina es la escasez de datos etiquetados para el entrenamiento algorítmico. Para mitigar esta limitación, Li et al., (2021) examinaron la identificación automatizada de objetos geográficos complejos, como cráteres en Marte, mediante modelos de Detección de Objetos Débilmente Supervisada (WSOD, por sus siglas en inglés). Esta metodología convencional consta de tres etapas consecutivas: extracción de características, generación de regiones delimitadoras (bounding boxes) y clasificación. Dentro de esta categoría, destacan las Redes de Detección Profunda Débilmente Supervisadas (WSDDN), las cuales emplean Redes Neuronales Convolucionales (CNN) estructuradas en dos flujos paralelos para analizar regiones específicas de una imagen. Asimismo, se ha incorporado el modelo de Refinamiento del Clasificador de Instancias en Línea (OICR), el cual aprovecha el aprendizaje multietapa para optimizar iterativamente los cuadros delimitadores, superando el rendimiento estático de WSDDN. No obstante, el denominador común y la principal limitación técnica de estas arquitecturas radica en su dependencia de algoritmos de búsqueda selectiva previa al refinamiento, un proceso que incrementa significativamente el costo computacional y ralentiza el procesamiento de datos masivos.

La red de detección de múltiples instancias acoplada con segmentación guía para la detección de objetos con supervisión débil (C-MIDN), este algoritmo utiliza dos redes de detección de múltiples instancias, que trabajan de forma complementaria mediante la eliminación de cuadros delimitadores, adicionalmente agrega un nuevo algoritmo que elimina cuadro delimitadores, mediante segmentación (Gao et al., 2019).

En su investigación sobre modelamiento espacial Ivić, (2019) evaluó la eficacia de distintos algoritmos de clasificación de cobertura vegetal utilizando sensores ópticos. Para el procesamiento de imágenes Landsat, el autor estructuró el análisis en cinco categorías: áreas urbanas o consolidadas, vegetación,

cuerpos de agua, suelo desnudo y nubes. Por otro lado, para las imágenes del sensor Sentinel, expandió la clasificación a seis clases al incorporar el mapeo de sombras. Al aplicar métodos de muestreo homogéneos, el estudio demostró que las arquitecturas de Redes Neuronales Artificiales y las Máquinas de Vectores de Soporte (SVM) exhibieron un rendimiento estadístico superior para describir información geoespacial en comparación con otros algoritmos convencionales.

Modelación de DINSAR

Tradicionalmente, la **DInSAR** se ha empleado en el estudio de movimientos en masa para la identificación de fenómenos tras su ocurrencia. No obstante, investigaciones recientes han avanzado en su integración dentro de sistemas de alerta temprana. Un ejemplo destacado es el trabajo de Leyva Pinto, 2025, quien diseñó una metodología orientada a la prevención mediante la evaluación de tres métodos:

- **Primer método (tradicional):** Consiste en la corrección de imágenes de radar en formato SLC (Single Look Complex u óptico complejo de un solo vistazo) para generar el interferograma base. Posteriormente, se ejecuta la combinación de líneas de base, la aplicación de filtros de fase, el desenrollado de fase (phase unwrapping) y la georreferenciación de los datos para el cálculo final del desplazamiento en la línea de mira del satélite (LOS).
- **Segundo Método:** Basado en el anterior, pero con la particularidad de obtener los desplazamientos verticales utilizando efemérides precisas de la **Agencia Espacial Europea (ESA)**.
- **Tercer Método:** Propone corregir los datos tras el filtrado mediante las efemérides de la ESA, antes de proceder al desenrollado de la fase.

Los resultados de Leyva Pinto indican que el segundo y tercer método identifican cambios significativamente más notorios en comparación con el enfoque tradicional. En conclusión, el estudio resalta que el uso de **interferogramas diferenciales**, en conjunto con variables críticas como los **umbrales de precipitación**, puede fortalecer sustancialmente los sistemas de alerta temprana. Asimismo, se subraya que, aunque las zonas urbanas presentan mayores desafíos técnicos, esta herramienta es fundamental para definir mapas de desplazamientos potenciales y gestionar el riesgo. En la investigación desarrollada por Caizaluisa & Muñoz, 2014, se aplicó la técnica de **DInSAR** en una zona piloto de Ecuador para evaluar su eficacia en el monitoreo de terrenos. Los autores proponen una metodología estructurada en dos fases críticas. La primera fase, dedicada al procesamiento del interferograma, establece cuatro etapas fundamentales: la gestión de datos crudos, la focalización de las imágenes, el cálculo interferométrico y el desenrollado de la fase.

Posteriormente, para la generación precisa del **mapa de desplazamientos**, el estudio identifica un segundo flujo de trabajo compuesto por el refinamiento y aplanamiento de la fase, la conversión de fase a unidades métricas y la determinación de los desplazamientos de alturas.

Al contrastar este estudio con investigaciones previas (como la de Leyva Pinto), se observa una coincidencia técnica fundamental: la incorporación de **post-procesamientos avanzados** y el análisis de desplazamientos verticales permiten obtener resultados significativamente más precisos y robustos. Sin embargo, Caizaluisa y Muñoz (2014) advierten sobre una limitación crítica en el uso de sensores remotos: la **decorrelación temporal**. Las variaciones en los tiempos de adquisición entre las imágenes pueden alterar la respuesta de las propiedades físicas del terreno, provocando distorsiones que dificultan la interpretación de los datos. Esto subraya la importancia de seleccionar adecuadamente los tiempos de toma para minimizar los errores en la modelación de los desplazamientos.

En el marco de la revisión bibliográfica sobre el estado del arte, se destaca el reciente auge de la **inteligencia geoespacial aplicada a la interferometría de radar (InSAR)**. De manera particular, la investigación prospectiva de (Oro & Pereira, 2025) ofrece un análisis exhaustivo sobre los dominios de estudio, las fuentes de datos y los enfoques metodológicos predominantes hasta la fecha. Los autores estructuran los avances científicos en cuatro pilares temáticos esenciales:

1. **Dinámicas Espacio-Temporales y Aplicaciones Críticas:** Las investigaciones se han centrado primordialmente en la prevención de catástrofes, la planificación territorial, el desenrollado de fase y la detección precisa de deformaciones y objetos estructurales.
2. **Gestión de Datos:** Se observa una integración creciente entre datos reales y sintéticos para fortalecer la robustez de los modelos de entrenamiento.
3. **Paradigma del Machine Learning:** El estudio resalta la relevancia de comparar enfoques supervisados, no supervisados y semisupervisados. Los resultados sugieren que el **aprendizaje semisupervisado** posee el mayor potencial de escalabilidad, dada su capacidad para optimizar el procesamiento de grandes volúmenes de datos con un etiquetado manual mínimo.
4. **Desafíos de Estandarización:** Un hallazgo crítico es la ausencia de protocolos estandarizados para la aplicación de IA en InSAR, lo que dificulta la comparabilidad intermetodológica y limita la replicabilidad universal de los algoritmos.

Desde una perspectiva geográfica y cronológica, el estudio revela una **asimetría en la producción científica**. Los polos de desarrollo más relevantes (fig. 1.) se concentran en China, Italia y Estados Unidos, posicionando a Asia, Europa y América del Norte como los continentes líderes en innovación geoespacial. Asimismo, se evidencia una aceleración exponencial en este campo: el **70% de la literatura científica** especializada se produjo en el trienio comprendido entre 2021 y 2023, lo que confirma que nos encontramos ante una disciplina en plena fase de expansión y consolidación técnica.




Figura 1. Distribución espacial y temporal de las publicaciones.

Fuente: (Oro & Pereira, 2025).

7.1.2 Contexto Latinoamericano

Movimientos en masa, principales características del territorio

Según Vallejo, 2002; la estabilidad y evolución de las laderas responden a una estricta interacción entre variables endógenas y exógenas que modifican de forma continua las condiciones del terreno. Los factores intrínsecos establecen las bases de la susceptibilidad de la ladera: el relieve regula directamente la distribución del peso del terreno a lo largo de la pendiente; la litología condiciona variables críticas como la densidad, la resistencia y el comportamiento hidrogeológico general; la estructura geológica y el estado tensional introducen un comportamiento discontinuo, anisotrópico y zonas de debilidad estructural; las propiedades geomecánicas de los materiales determinan la generación interna de presiones de poros; la deforestación altera negativamente el balance hídrico y acelera la erosión; y la meteorización degrada el macizo mediante cambios físicos y químicos que generan superficies críticas de falla. Esta vulnerabilidad estática es activada por los factores detonantes, donde la precipitación incrementa el peso del terreno y altera las presiones de poros; los cambios en las condiciones hidrológicas provocan la saturación total del suelo (o modifican la succión en matrices parcialmente saturadas) además de generar erosión interna; la aplicación de cargas dinámicas desestabiliza bruscamente el estado de esfuerzos de la ladera con un consecuente incremento en la presión de poros; los cambios morfológicos y la erosión modifican la geometría, restan soporte basal y redistribuyen las fuerzas del peso; y finalmente, las acciones climáticas cíclicas varían el contenido de agua superficial, propiciando grietas de tracción y planos de debilidad que merman severamente las propiedades resistentes del material, dichas variables se resumen en la Tabla 1, los tipos factores e influencias, estos factores están descritos en la literatura y se toman de la investigación de (Vallejo, 2002).

La identificación sistemática y el análisis riguroso de dichos factores dentro del estado del arte resultan de carácter crítico para la viabilidad de la investigación. Su relevancia radica en que constituyen el sustento epistemológico y el fundamento teórico indispensables para justificar la selección de las variables de entrada (features) y los descriptores geoespaciales que alimentarán el algoritmo. En el ámbito del aprendizaje computacional, la elección de los predictores no puede realizarse de manera arbitraria o puramente empírica; por el contrario, requiere una validación bibliográfica previa que demuestre la correlación física y mecánica de cada variable con la inestabilidad de las laderas. De este modo, la literatura científica consultada actúa como un filtro metodológico que permite depurar el espacio de características del modelo, asegurando que los tensores de datos seleccionados posean una alta significancia estadística. Este proceso de curaduría teórica es un requisito fundamental para optimizar la fase de entrenamiento de la red neuronal, mitigar los riesgos de sobreajuste (overfitting) por

redundancia de información y garantizar la capacidad de generalización del modelo predictivo al ser evaluado con datos reales del territorio.

Tabla 1. Influencias de los factores en las condiciones de los materiales y las laderas (Vallejo, 2002).

TIPOS	FACTORES	INFLUENCIAS
INTRÍNSECOS	Relieve	Distribución del peso del terreno
	Litología	Densidad, resistencia. Comportamiento hidrogeológico.
	Estructura geológica y estado tensional	Resistencia, deformabilidad. Comportamiento discontinuo y anisotrópico. Zonas de debilidad.
	Propiedades geomecánicas de los materiales	Comportamiento hidrogeológico. Generación de presiones de poros
	Deforestación	Modificación del balance hídrico. Erosión
	Meteorización	Cambios físicos y químicos, erosión externa e interna, generación de zonas de debilidad.
	Precipitación	Variación de las presiones de poros y del peso del terreno.
	Cambio condiciones hidrológicas	Saturación de suelos (o cambios en la succión en suelos parcialmente saturados). Erosión.
DETONANTES	Aplicación de cargas dinámicas	Cambio en la distribución del peso de los materiales y en el estado de esfuerzos de la ladera. Incremento de presiones de poros.
	Cambios morfológicos	Variación de las fuerzas debidas al peso. Cambio en el estado de esfuerzos
	Erosión	Cambios geométricos en la ladera. Cambios en la distribución del peso de los materiales y en el estado de esfuerzos de la ladera.
	Acciones climáticas	Cambio en el contenido de agua del terreno. Generación de grietas y planos de debilidad. Disminución de las propiedades resistentes.

Fuente: Elaboración propia, 2026.

En la literatura científica se encuentran muchas clasificaciones de movimientos en masa; la mayoría de ellas se basan en el tipo de materiales, los mecanismos de movimiento, el grado de deformación del material y el grado de saturación. (Argentino et al., (2007) plantea que los movimientos en masa ocurren como deformaciones del terreno, movimientos de tipo viscoso y otros desplazamientos de masas en

cualquier parte de la tierra. Por su parte (Olarte, (2017) manifiesta que la mayoría de los autores adoptan como criterios de clasificación los mecanismos de falla de los movimientos, los tipos de materiales involucrados, la actividad de los movimientos y su velocidad. (Olarte, 2017).

Sísmica y su relación con remociones en masa

Diversas áreas de la región Andina, reconocidas por su actividad sísmica y tectónica, se caracterizan por una topografía abrupta con pronunciadas diferencias de elevación en distancias cortas que resultan en una alta energía del relieve (Mergili et al., 2015). Con el propósito de estructurar un marco histórico de análisis comparativo, en esta investigación se analizan eventos históricos de remoción en masa emblemáticos de la cordillera andina, como los deslizamientos de gran magnitud en el flanco oriental colombiano y los flujos torrenciales asociados a cuencas de alta pendiente. El estudio evalúa de forma integrada las variables geográficas, los factores geomorfológicos y el contexto de vulnerabilidad social de estos eventos. De este modo, el análisis de estos antecedentes fundamenta la necesidad de establecer sistemas de alerta temprana y herramientas de planificación territorial, prioritariamente en aquellas zonas que presentan altos índices de sobrepoblación e informalidad urbana.

Definición de riesgo para Planes de Ordenamiento

La evolución geológica del Norte Grande de Chile exhibe dos escenarios geomorfológicos, estructurales y sísmicos altamente propicios para el desarrollo de movimientos en masa a distintas escalas. De acuerdo con Farías Sarmiento (2017), el primer entorno comprende una extensa franja dominada por la morfología del acantilado costero, donde la inestabilidad de las vertientes está asociada, principalmente, a terremotos de subducción en uno de los márgenes tectónicos más activos del mundo. El segundo escenario está caracterizado por profundos cañones de orientación Este-Oeste, cuya incisión fluvial en la Precordillera y la Depresión Central favoreció la ocurrencia de mega-remociones en masa desde el Pleistoceno tardío hasta el Holoceno. Aunque estos fenómenos ocurren típicamente en laderas continentales de fuerte pendiente, la franja costera de esta región es especialmente susceptible debido a la inestabilidad intrínseca de sus taludes litorales. La confluencia entre la verticalidad de los acantilados escarpados y la proximidad de infraestructura vial estratégica acentúa la vulnerabilidad de la zona. Por consiguiente, la caracterización de este sector bajo criterios de peligrosidad sísmica es fundamental para delimitar los tramos con mayor susceptibilidad a generar fallos catastróficos que puedan comprometer las líneas de conectividad regional.

Para casos particulares en donde el relieve es de diferencias notables en sus elevaciones, con una topografía muy irregular y montañoso en su mayor parte, favorece la ocurrencia de procesos de remoción en masa, condición que se manifestó en octubre de 1999 con cientos de movimientos del terreno en la Sierra Norte de Puebla, detonados por las intensas lluvias ocasionadas por la tormenta tropical número 11 de Zacapoaxtla (Borja Baeza & Alcántara Ayala, 2004) Por lo anterior, la Precipitación es el factor detonante que más está involucrado en los procesos de remoción en masa, por los efectos que ésta tiene en el suelo, es decir la saturación del terreno y la pérdida de resistencia y cohesión (Ortiz et al., 2021).

En cuanto a las dinámicas para la preservación y mitigación de las afectaciones que ocurren a causa de la falta de gestión por parte de las entidades gubernamentales, así como, la Procuraduría Ambiental y del Ordenamiento Territorial, la Secretaría de Desarrollo Urbano y Vivienda, los Centros y unidades de Gestión del Riesgo y de Prevención de Desastres y los Servicios Geológicos, entre otras (O. D. R. González, 2020), cabe mencionar las actuaciones y herramientas tecnológicas apoyadas de imágenes ráster y análisis de información vectorial que a nivel federal disponen en países como México para implementar procesos de gestión del riesgo y la prevención y atención en caso de corrección o reparación del daño relacionado a problemáticas y vulnerabilidad de asentamientos humanos sobre zonas inundables, así como alertas de peligro de procesos de remoción en masa que dan como resultado serias afectaciones a la infraestructura urbana y de vivienda en colonias altamente marginadas e inclusive posibles muertes de los habitantes (O. D. R. González, 2020).

7.1.3 Contexto colombiano

En la investigación desarrollada por (Ospina Urán, 2024), se evalúa la implementación tecnológica de **InSAR** aplicada específicamente al contexto geodinámico del **Valle de Aburrá**. El estudio se centra en la generación de **mapas de visibilidad y sensibilidad InSAR**, herramientas diseñadas con el objetivo crítico de delimitar las áreas donde las tasas de deformación por movimientos en masa resultan técnicamente detectables por el sensor. Los resultados permitieron establecer una relación directa entre el uso del suelo y la calidad de la señal; se observaron tendencias de desplazamiento consistentes en zonas con suelos desnudos o vegetación escasa, mientras que las áreas urbanizadas exhibieron una estabilidad de fase superior, facilitando un monitoreo más preciso en entornos antrópicos.

No obstante, el estudio identifica limitaciones importantes en la **coherencia interferométrica** de zonas cubiertas por pastizales, cuerpos de agua, matorrales y vegetación arbórea densa, donde la alta tasa de decorrelación dificulta el seguimiento de los movimientos. A pesar de estos desafíos, la

investigación logró cartografiar al menos **seis zonas críticas de remoción en masa**, con la particularidad de que los desplazamientos de mayor magnitud se localizaron en sectores urbanos, incrementando el nivel de riesgo para la infraestructura.

Ante estos hallazgos, Ospina Urán (2024) subraya que la teledetección no debe actuar como una herramienta aislada; por el contrario, propone una metodología de validación integral que exige la **comprobación en campo** y el despliegue de **instrumentación geotécnica** in situ para calibrar las mediciones satelitales. Como recomendación prospectiva, el autor enfatiza la necesidad urgente de migrar hacia **herramientas de clasificación espacio-temporal automatizadas** basadas en inteligencia artificial. El objetivo de esta automatización es doble: por un lado, mitigar los sesgos humanos inherentes al procesamiento manual y, por otro, optimizar los tiempos de respuesta en la generación de alertas tempranas para la gestión del riesgo regional.

En contraste con las técnicas de teledetección pura, la investigación de Ramos & Pacheco (2013), se centra en el potencial de la **inteligencia artificial** aplicada al modelado predictivo de inestabilidades en el distrito capital de Bogotá. El núcleo de su estudio consistió en el desarrollo de un modelo basado en **Árboles de Decisión** una técnica de aprendizaje supervisado elegida por su capacidad para manejar variables categóricas y numéricas de origen multifuente. Para alimentar este algoritmo, los autores integraron un robusto conjunto de datos geoespaciales que incluyó cartografía geológica detallada, parámetros geotécnicos de los suelos locales, modelos digitales de pendientes y, fundamentalmente, un inventario histórico de eventos de remoción en masa ocurridos en la ciudad durante los últimos años. La arquitectura del modelo se fundamentó en el concepto de **entropía de la información** y la ganancia de información. Mediante este enfoque probabilístico, el algoritmo logró realizar particiones recursivas del espacio de datos para identificar **zonas homogéneas** con comportamientos mecánicos y topográficos similares. Este proceso de ramificación lógica permitió no solo predecir la probabilidad de ocurrencia, sino también clasificar taxonómicamente los diversos tipos de movimientos en masa que afectan la geografía bogotana, tales como deslizamientos traslacionales, rotacionales o flujos de lodos.

Uno de los aportes más significativos de este trabajo es la capacidad de transformar datos descriptivos en una herramienta de **zonificación predictiva**. Al segmentar el territorio en unidades con características de susceptibilidad análogas, el modelo de Ramos y Pacheco (2023) ofrece una base científica para la toma de decisiones en el ordenamiento territorial. Además, su enfoque basado en árboles de decisión proporciona una estructura de "caja blanca" (interpretación clara de las reglas de decisión), lo cual resulta invaluable para los organismos de gestión del riesgo al permitirles comprender exactamente qué variables —ya sea la inclinación de la ladera o la litología específica— están disparando la inestabilidad en cada sector de la capital.

La implementación de soluciones basadas en inteligencia artificial en Colombia ha trascendido la escala regional para enfocarse en la protección de infraestructura estratégica y el monitoreo de amenazas complejas. Un avance institucional significativo es el desarrollo de la plataforma **LAKIY** por parte del **Servicio Geológico Colombiano (SGC)**. Aunque este sistema fue concebido inicialmente para el análisis de señales sismo-volcánicas, su arquitectura basada en algoritmos de aprendizaje profundo (*Deep Learning*) representa un hito técnico en el país. **LAKIY** establece un precedente metodológico en la automatización de la clasificación de eventos geológicos, demostrando que la transición hacia procesos de interpretación no supervisados permite reducir drásticamente los tiempos de respuesta en redes de monitoreo nacional (SGC, 2023).

En la investigación de (Rubio Simanca, 2015), tuvo como objetivo la **evaluación del riesgo por movimientos en masa** en el sector suroccidental de la Comuna 18 del municipio de Santiago de Cali. Esta zona se localiza en la periferia urbana de ladera, específicamente en las estribaciones de la Cordillera Occidental, cuya configuración geomorfológica presenta una alta susceptibilidad intrínseca a la inestabilidad de vertientes, fenómeno que se intensifica drásticamente durante los periodos de alta precipitación.

La problemática de estudio se fundamenta en la interacción entre la dinámica natural del terreno y los procesos de **asentamiento informal**. Debido a factores de vulnerabilidad económica y procesos de desplazamiento forzado, poblaciones desplazadas han ocupado de manera irregular terrenos baldíos en la zona alta de la comuna, en el límite con el corregimiento de La Buitrera. Esta ocupación, caracterizada por la ausencia de infraestructura técnica y la falta de intervención gubernamental, ha generado un escenario de marginalidad y exclusión social que incrementa la exposición ante eventos geodinámicos.

Desde una perspectiva metodológica, el estudio se aborda bajo el paradigma de la **interacción sociedad-naturaleza**, analizando las dinámicas espaciales de los asentamientos humanos en zonas de riesgo. El objetivo central es la estimación del **Riesgo Multicriterio**, integrando tres fases analíticas:

1. **Caracterización de la Susceptibilidad:** Análisis de los factores condicionantes (geología, pendientes, uso del suelo).
2. **Evaluación de la Amenaza:** Determinación del potencial de ocurrencia del movimiento en masa ante factores detonantes.
3. **Determinación de la Vulnerabilidad Global:** Un análisis multidimensional que evalúa de forma holística cinco dimensiones: social, física, económica, educativa y cultural.

Para la integración y el procesamiento de estas variables, se emplearon **Sistemas de Información Geográfica (SIG)**. El uso de herramientas geoespaciales permitió el álgebra de mapas y la superposición de capas temáticas de diversa índole, facilitando la generación de cartografía de síntesis para la gestión del riesgo. Los resultados pretenden servir como una herramienta técnica esencial para la planificación territorial y la mitigación de desastres en áreas urbanas de alta vulnerabilidad.

Generación del potencial hidro gravitatorio

El potencial de amenaza en la región andina define la alta ocurrencia de movimientos en masa, los cuales se desarrollan principalmente sobre sustratos de materiales fracturados y formaciones superficiales no consolidadas. Estas zonas resultan críticamente afectadas al estar insertas en regiones tectónicamente activas, donde las grandes cadenas montañosas exhiben una marcada inestabilidad debido a sus fuertes gradientes altitudinales; un escenario que se agudiza por la intensa intervención antrópica. Bajo este contexto, Flórez (2003) explica que la arquitectura del relieve está condicionada litológicamente: las rocas que conforman la cresta superior de los frentes poseen una mayor resistencia mecánica (como areniscas, cuarcitas y calizas), mientras que las secciones basales están constituidas por rocas blandas y plásticas (como limolitas y arcillolitas) intercaladas con estratos duros. Esta disposición lito estructural genera una morfología característica de graderías inclinadas hacia atrás; una firma geomorfológica ampliamente documentada en el municipio de Cáqueza (Cundinamarca) que explica la alta recurrencia de movimientos en masa en el territorio.

En el sector de la ingeniería de hidrocarburos, destaca el modelo dinámico e interdisciplinar desarrollado por Correa et al. (2020) para la sectorización geotécnica y evaluación de amenazas pluviales en líneas de conducción. Esta metodología ha evolucionado recientemente mediante la integración de sistemas avanzados de inteligencia artificial y aprendizaje automático (Machine Learning) orientados a predecir fallas por movimientos en masa en corredores estratégicos de oleoductos. El flujo de trabajo computacional procesa volúmenes masivos de datos geoespaciales heterogéneos, superando los 45 millones de píxeles mediante el análisis de modelos de elevación digital y variables hidroclimáticas de la NASA, tales como las misiones SRTM (Shuttle Radar Topography Mission) y GPM (Global Precipitation Measurement). La capacidad de este sistema para operar de forma continua facilita una gestión predictiva de la integridad de activos en tiempo real. Este tipo de innovaciones valida la transición metodológica desde esquemas reactivos tradicionales hacia modelos autónomos basados en la fusión de Big Data espacial, sirviendo de referente para la tecnificación de los sistemas de alerta temprana en la región andina.

7.2 MARCO NORMATIVO

7.2.1 Marco normativo a Nivel internacional

A nivel mundial, la gestión del riesgo de desastres se rige bajo el Marco de Sendai para la Reducción del Riesgo de Desastres (2015-2030), un acuerdo internacional adoptado por la ONU que provee los lineamientos estructurales para que las naciones formulen sus normativas de prevención, mitigación y preparación. Este instrumento metodológico organiza sus esfuerzos institucionales a través de cuatro prioridades de acción fundamentales: 1) comprender el riesgo de desastres en todas sus dimensiones; 2) fortalecer la gobernanza del riesgo para una gestión eficiente; 3) invertir en la reducción del riesgo para fomentar la resiliencia; y 4) aumentar la preparación para una respuesta eficaz y 'reconstruir mejor' (Build Back Better) en las etapas de recuperación, rehabilitación y reconstrucción. Asimismo, para evaluar de forma cuantitativa el impacto de estas acciones en el horizonte temporal establecido, el acuerdo define siete metas globales de obligatorio cumplimiento para los Estados firmantes:

- Meta A: Reducir sustancialmente la mortalidad mundial por desastres para 2030.
- Meta B: Disminuir considerablemente el número de personas afectadas a nivel global.
- Meta C: Reducir las pérdidas económicas directas en relación con el Producto Interno Bruto (PIB) mundial.
- Meta D: Reducir significativamente los daños causados por desastres en la infraestructura crítica y la interrupción de los servicios básicos, principalmente las instalaciones de salud y educativas.
- Meta E: Incrementar sustancialmente el número de países que cuentan con estrategias nacionales y locales de reducción del riesgo de desastres.
- Meta F: Mejorar de manera integral la cooperación internacional para apoyar las acciones de los países en desarrollo.
- Meta G: Incrementar considerablemente la disponibilidad de los sistemas de alerta temprana multiamenaza y el acceso de la población a la información y las evaluaciones sobre el riesgo de desastres.

De este modo, la integración de metodologías geoespaciales y algoritmos inteligentes en el municipio de Cáqueza se alinea directamente con la consecución de la Prioridad 1 y la Meta G, al generar conocimiento técnico preciso para robustecer los sistemas de prevención locales.

Las metas e indicadores se enfocan en 3 dimensiones principalmente, la exposición a amenazas; vulnerabilidad y capacidad; y características de las amenazas, el alcance del monitoreo incluye 7 metas globales y 38 indicadores globales para medir el avance que se logre en cada país en la reducción de

riesgo, para ello definieron una herramienta de recopilación <https://www.desinventar.net/>, que permite crear las bases de datos necesarias para la gestión, en esta herramienta se cargaron los datos iniciales de 82 países el cual, para Colombia se cargó información disponible.

7.2.2 Marco Normativo a nivel Nacional

Se realiza la revisión y en Colombia están determinados por Leyes, decretos y la adopción de los instrumentos de ordenamiento territorial es por acuerdos, mediante la ley 388 de 1997, en su artículo 9 se menciona la regulación de los riesgos naturales y la importancia de determinarlos en los instrumentos de ordenamiento, para clasificar sobre todo las zonas no urbanizables. Este acápite de la Ley se reglamenta en el Decreto 879 de 1998, con posterioridad se define el decreto 1807 de 2014, que estableció las escalas y las condiciones para incorporar de manera gradual los riesgos en los instrumentos de ordenamiento municipal, posteriormente se compilan todas las normas y decretos anteriores en el decreto 1077 de 2015, Decreto único reglamentario del sector vivienda, ciudad y territorio, adicionalmente se tiene la Ley 1523 de 2012, que adopta la política de Gestión de riesgo de desastres en Colombia (*Normatividad*, 2025).

A continuación se listan normas y decreto relacionados con la gestión del riesgo??que aplican a qué??:

- Leyes:
 - Ley 1575 del 21 de agosto de 2012: Por medio de la cual se establece la Ley General de Bomberos de Colombia.
 - Ley 1523 del 24 de abril del 2012: Por el cual se adopta la política nacional de Gestión del Riesgo de Desastres y se establece el Sistema Nacional de Gestión del Riesgo de Desastres.
- Decretos:
 - Decreto 1478 de 2022 (03 de agosto): Por medio del cual se adopta la actualización del Plan Nacional de Gestión del Riesgo de Desastres y se modifica el Artículo 2.3.1.2.2.4.3 de la Subsección 4, Sección 2, Capítulo 2, Título 1, Libro 2, del Decreto Único Presidencial 1081 de 2015.
 - Decreto 2113 de 2022 (01 de noviembre): Por el cual se declara una Situación de Desastre de Carácter Nacional.
 - Decreto 544 de 2023 (06 de abril): Por el cual se modifican los términos de la declaratoria de la Situación de Desastre de Carácter Nacional y las normas especiales habilitadas de que trata el Decreto 2113 de 2022.
 - Decreto 1810 de 2023 (31 de octubre): Por el cual se prorroga la situación de Desastre de carácter Nacional declarada mediante el decreto No. 2113 de 01 de noviembre de 2022 y sus modificaciones.

- Decreto 0020 de 2024 (17 de enero): Por el cual se declara una situación de Desastre de Carácter Departamental.
- Decreto 0037 de 2024 (27 de enero): Por el cual se declara una situación de Desastre Nacional en todo el territorio nacional.
- Decreto 0978 de 2024 (02 de agosto): Por medio del cual se adopta la segunda actualización del Plan Nacional de Gestión del Riesgo de Desastres, y se dictan otras disposiciones.
- Decreto 1372 de 2024 (13 de noviembre): Por el cual se declara una Situación de Desastre Nacional. Decretó 0978 de 2024: Por medio del cual se adopta la segunda actualización del Plan Nacional de Gestión del Riesgo de Desastres, y se dictan otras disposiciones.

7.3 MARCO TEÓRICO

7.3.1 Relieve, geología, geomorfología, Geotecnia y Cobertura y uso del suelo.

Para poder iniciar con las variables de un estudio de remoción en masa es necesario conocer el relieve de la zona seleccionada, es necesario tener el modelo de elevación, Buzamiento y dirección de pendiente, de esta forma poder definir zonas homogéneas del relieve que permita definir las características (Sierra, 2003).

La estructura litológica, estratigrafía y geológica, son claves para determinar la potencialidad de movimientos según los tipos de material de la roca o del suelo, los procesos morfodinámicos modifican el relieve, si es posible definir perfil del subsuelo, el nivel freático, y las geomecánicas.

7.3.1.1 Resistencia al corte de suelos no saturados

Esta característica se puede escribir según MOHR-Coulomb (Sierra, 2003):

$$\tau = c' + (\omega_a - \omega_w) * \tan \theta^b + (\sigma - \omega) * \tan \theta'$$

Ecuación 1. Resistencia al corte de suelos no saturados.

Donde,

c' = Intersección de la cohesión cuando las dos variables de esfuerzo con cero.

θ^b = Angulo de fricción interna con respecto a la succión.

θ' = Angulo de fricción interna con respecto al esfuerzo efectivo.

Se puede determinar que los poros están llenos cuando la succión es cero, el exceso de agua de infiltración en un suelo no saturado, puede generar reducción de la resistencia del suelo lo cual puede producir una falla (Sierra, 2003).

7.3.1.2 Cobertura y uso del suelo e imágenes utilizadas para la clasificación

En el último siglo, la agricultura ha sido la causa de modificación del suelo, junto con la ganadería, estudiar la modificación permite conocer las dinámicas del territorio y las afecciones asociadas a ella, dentro de los usos más comunes de esta técnica se encuentran los ambientales, sin embargo, para el caso de la investigación permite definir la asociación de estos cambios (Mendoza Poggi et al., 2021).

La teledetección constituye la práctica metodológica estándar para monitorear las dinámicas de la cobertura vegetal y definir las transformaciones en el uso del suelo. Dentro de los enfoques de procesamiento digital, destaca la clasificación semiautomatizada, la cual explota las firmas espectrales de múltiples bandas satelitales para caracterizar las propiedades físicas de la superficie. A escala global, organismos como la Agencia Espacial Europea (ESA), a través de su Iniciativa de Cambio Climático (CCI), proveen mapas continuos con una resolución espacial de 300 metros. Sin embargo, para análisis a escala regional y local en el territorio colombiano, estos inventarios se estandarizan metodológicamente mediante el sistema de clasificación Corine Land Cover (CLC) adaptado para Colombia [3.3]. Este marco conceptual se complementa con el Sistema de Clasificación de la Cobertura Terrestre (LCCS), desarrollado por la Organización de las Naciones Unidas para la Alimentación y la Agricultura (FAO), garantizando la consistencia taxonómica y geométrica en la delimitación de las unidades espaciales.

Para el estudio de la remoción en masa se debe tener en cuenta esto porque las raíces de la vegetación proporcionan la resistencia al corte de los suelos, Sierra (2003) describió diferentes estudio que se han encontrado donde las raíces de los suelos proporcionan un amarre del suelo superficial, se define en la literatura, que especies arbóreas proporcionan una profundidad de raíces de hasta 1,5 metros?, mientras los árboles proporcionan mayor profundidad hasta de 3 metros, dependiente de la especie.

Adicionalmente los efectos hidrológicos sobre la vegetación son altamente importantes en el estudio ya que el agua se almacena en hojas y tallos y el proceso que lleva el agua es conocido como interceptación, proceso que desencadena consecuencias, tales como (Sierra, 2003):

- Esta captación de agua reduce la probabilidad de remoción en masa, ya que la cantidad de agua que llega a la superficie de agua es menor.
- Se evita el impacto directo de las gotas de agua en la superficie del terreno

La evapotranspiración, la escorrentía, infiltración son otras de las características que la vegetación aporta para generar la menor acumulación de agua en los suelos (Sierra, 2003).

El instrumento MSI (Sentinel-2) opera bajo un principio de barrido multilíneas que captura el espectro visible con un *pitch* de 10 metros, lo que induce una mayor sensibilidad a la anisotropía de la reflectancia superficial (efecto BRDF) en comparación con el sensor OLI (Landsat 8). Mientras que el registro de Landsat 8 se fundamenta en un diseño óptico *push-broom* de alta estabilidad térmica que minimiza el ruido radiométrico (*Signal-to-Noise Ratio* superior), Sentinel-2 introduce una fragmentación del espectro en el "red-edge", permitiendo una caracterización de la curva de absorción de la clorofila que Landsat solo puede inferir mediante interpolación.

La literatura contemporánea en **GeolA** y fotogrametría satelital sugiere que la verdadera potencia de estos flujos de datos reside en la **descomposición espectral de sub-píxel**. Al aplicar algoritmos de super-resolución guiada, los 30 metros de las bandas visibles de Landsat pueden ser condicionados por la textura espacial de 10 metros de Sentinel-2, logrando una síntesis de datos que preserva la fidelidad radiométrica de la serie histórica Landsat con la granularidad geométrica de la constelación Copérnico. Este proceso de fusión no lineal es crítico para mitigar el sesgo introducido por las diferentes Funciones de Respuesta Espectral (SRF); como señalan (Guzmán Torres et al., 2023), la disparidad en los anchos de banda, particularmente en el canal del Rojo, puede generar variaciones nominales de hasta 0.05 unidades en el Índice de Vegetación de Diferencia Normalizada (NDVI), exigiendo una **normalización de paso de banda** previa a cualquier análisis de series temporales densas. En consecuencia, la convergencia MSI-OLI no es solo un avance en frecuencia de revisita, sino un desafío de reescalado multivariante donde la precisión cartográfica se supedita a la correcta calibración de la reflectancia en el tope de la atmósfera (TOA) hacia la reflectancia de superficie (BOA).

La sinergia entre las misiones **Sentinel-2 (A/B)** de la Agencia Espacial Europea (ESA) y **Landsat 8 (OLI)** de la NASA/USGS permiten una capacidad de observación terrestre. Desde una perspectiva técnica, el sensor **MSI (Multispectral Instrument)** de Sentinel-2 proporciona una resolución espacial nominal de 10 metros en sus bandas visibles (Azul: B2, Verde: B3, Rojo: B4), lo que supone una ventaja crítica para la segmentación de paisajes altamente fragmentados y la identificación de infraestructuras lineales en comparación con los 30 metros del sensor **OLI** de Landsat 8. No obstante, la robustez de Landsat 8 radica en su estabilidad radiométrica y su calibración absoluta, que sirve como el "estándar de oro" para la consistencia climática global (Zhu et al., 2019).

La clasificación supervisada mediante **Máquinas de Vectores de Soporte (SVM)** en ArcGIS Pro representa uno de los enfoques más robustos de la geomática moderna para la extracción de

información biofísica y antrópica. A diferencia de los clasificadores paramétricos tradicionales, como la Máxima Verosimilitud, la SVM destaca por su naturaleza no paramétrica, lo que le permite manejar distribuciones de datos complejas sin asumir una normalidad estadística, siendo altamente eficiente incluso con sets de muestras de entrenamiento reducidos (Foody, 2020).

7.3.1.3 INDICES IMÁGENES

El Índice de Vegetación de Diferencia Normalizada (NDVI) es uno de los índices espectrales más ampliamente utilizados en la teledetección para cuantificar la biomasa vegetal, la salud y la actividad fotosintética de la vegetación. Su formulación matemática se basa en la reflectancia de la superficie en las bandas del infrarrojo cercano (NIR) y el rojo (Red) del espectro electromagnético (Wardlow et al., 2012), calculado como:

$$NDVI = (NIR - Red) / (NIR + Red)$$

Ecuación 2. Fórmula de cálculo del índice de vegetación de diferencia Normalizada (NDVI)

Donde:

- **NIR** = Reflectancia de la banda del infrarrojo cercano (Near-Infrared).
- **Red** = Reflectancia de la banda del rojo visible.

Este índice aprovecha las propiedades espectrales distintivas de la vegetación saludable: una fuerte absorción de la radiación en la región del rojo (debido a los pigmentos fotosintéticos como la clorofila) y una alta reflectancia en la región del infrarrojo cercano (debido a la estructura celular de las hojas) (Wardlow et al., 2012). Los valores de NDVI oscilan entre -1 y +1. Valores negativos o cercanos a cero suelen corresponder a superficies no vegetadas como agua, nieve, nubes o suelo desnudo. Por el contrario, valores positivos indican la presencia de vegetación, con valores más altos (típicamente superiores a 0.5) asociados a vegetación densa y fotosintéticamente activa, mientras que valores intermedios o bajos (e.g., 0.1-0.2) reflejan vegetación escasa, senescente o estresada (Maxwell et al., 2025)

Científicamente, el NDVI ha demostrado ser una métrica robusta para una vasta gama de aplicaciones que incluyen el monitoreo de la fenología vegetal, la estimación de la productividad primaria neta, la detección de estrés hídrico y sequías, **el mapeo de la cobertura terrestre y sus cambios**, y la predicción del rendimiento de cultivos (Garrott et al., 2008). A pesar de su amplia utilidad, es fundamental reconocer sus limitaciones, como el fenómeno de saturación en biomásas muy densas, donde la reflectancia en el infrarrojo cercano deja de aumentar a medida que la cubierta vegetal se vuelve más densa, subestimando la verdadera biomasa (Mukhopadhyay et al., 2021). Además, el NDVI

puede ser sensible a los efectos atmosféricos, la geometría de iluminación y observación, y la reflectancia del suelo subyacente, especialmente en áreas de vegetación escasa (Wu et al., 2023). Estas consideraciones subrayan la importancia de una interpretación cuidadosa y, en algunos contextos, la preferencia por índices espectrales mejorados que mitigan estas deficiencias, como el Enhanced Vegetation Index (EVI).

7.3.2 Factores detonantes

Precipitación, aporta un fundamento crucial para estudiar los fenómenos de remoción en masa según sus variables como volumen, intensidad y distribución, el agua de escorrentía puede causar procesos de erosión laminares, surcos, cangas o cárcavas; cuando el agua se infiltra en el suelo puede modificar la condición del suelo, subir el nivel freático.

El agua superficial o infiltrada puede reducir la resistencia de los materiales geológicos, pueden producir, erosión en taludes, originar pendientes más fuertes por movimientos en las laderas (Sierra, 2003), así mismo los manejos inadecuados de las aguas, en la recopilación de investigaciones definida en (Sierra, 2003), muestra que el mecanismo interno de almacenamiento puede explicar muchas causas de los deslizamientos, por la descarga de aguas que se ven interrumpidas por acumulación de materiales de desecho, haciendo que la presión de descarga aumente.

El comportamiento cinemático de los movimientos en masa profundos está intrínsecamente ligado a la interacción de variables hidrogeológicas y perturbaciones mecánicas en la ladera. Al respecto, Hoyos Patiño, F., (1990), establece que la reactivación de estos fallos estructurales depende principalmente de dos factores determinantes: el incremento de la supresión en la base del regolito —inducido por la fluctuación del nivel piezométrico del agua subterránea— y la pérdida de confinamiento basal debido a explanaciones u obras civiles. Por consiguiente, resulta indispensable integrar análisis hidrológicos detallados que cuantifiquen el balance hídrico mediante variables de precipitación, evapotranspiración, infiltración y escorrentía superficial. Dado que la escorrentía representa el flujo neto del agua sobre la superficie y canales de drenaje, su modelado numérico se apoya habitualmente en las ecuaciones de Saint-Venant, proveyendo un descriptor dinámico fundamental para alimentar el componente detonante de nuestro modelo de inteligencia computacional.

Los sismos actúan como factores detonantes críticos debido a que las ondas mecánicas internas y superficiales, producidas por la liberación de energía elástica interplaca (Arias, 2017), transfieren aceleraciones dinámicas y cíclicas al terreno. Desde la perspectiva de la mecánica de laderas, este

fenómeno induce fuerzas inerciales transitorias —principalmente en la componente horizontal— que incrementan de manera abrupta el esfuerzo cortante actuante sobre la masa del talud. Simultáneamente, la vibración sísmica somete a los materiales a deformaciones cíclicas contractivas que provocan un aumento súbito en la presión de poros, reduciendo el esfuerzo efectivo y la resistencia al corte del suelo o regolito. Esta alteración violenta en el balance de fuerzas desestabiliza instantáneamente el equilibrio límite de la vertiente, gatillando el fallo de la ladera.

Las isoyetas e isotermas son líneas isovaléricas que representan, respectivamente, precipitación acumulada y temperatura media (u otras estadísticas) en el espacio; su construcción exige datos depurados de estaciones, correcciones físicas y una interpolación consistente con la climatología y la topografía. Para isoyetas, se recomienda: (1) control de calidad y homogeneización de series (Menne & Williams, 2009). (2) corrección por subcaptura de pluviómetros según tipo de precipitación, viento y resguardo (Sevruk, 1996), (3) densidad y representatividad espacial suficientes (regla WMO: ≥ 1 estación/250–900 km² según relieve; (4) interpolación con métodos que incorporen orografía y barreras: kriging (con variograma climatológico), kriging universal con covariables DEM (altitud, pendiente, exposición), PRISM o splines delgados (ANUSPLIN) que modelan gradientes orográficos y efectos de barlovento/sotavento (Daly et al., 2002) y (5) fusión con productos satelitales/reanálisis (GPM IMERG, CHIRPS, ERA5) mediante bias-correction y cokriging cuando la red es escasa. Para isotermas, la clave es capturar el gradiente térmico vertical y efectos locales: (1) estandarizar a una hora o estadístico (Tmean, Tmax, Tmin) y homogenizar series (Menne & Williams, 2009). (2) ajustar por altitud usando lapse rates regionales/estacionales en vez de -6.5 K km⁻¹ fijo, preferentemente lapse dinámico derivado de observaciones o reanálisis, y considerar inversiones en valle, (3) interpolar con kriging universal o ANUSPLIN/PRISM con covariables DEM, distancia al mar y continentalidad/latitud; en zonas urbanas, incorporar isla de calor y (4) validar con cross-validation (RMSE, MAE, sesgo) y análisis del variograma para asegurar isotropía/anisotropía coherente con circulación y relieve. En ambos casos, se debe: definir el periodo climatológico, reportar incertidumbre espacial (mapas de error kriging o ensembles), documentar fuentes y proyecciones, y evitar contornos engañosos en regiones con baja densidad de estaciones; métodos simples (Thiessen, IDW) pueden servir como línea base pero subrepresentan orografía compleja. Para productos de referencia y verificación, WorldClim/CHELSA ofrecen superficies climatológicas de alta resolución basadas en estaciones y DEM, útiles como covariables o para contraste independiente (Fick & Hijmans, 2017).

7.3.3 La interferometría como estudio de la remoción en masa.

Los sistemas de teledetección satelital activos han optimizado la adquisición de datos de alta precisión sobre la superficie terrestre. Dentro de estos sensores remotos, esta investigación se fundamenta en los sistemas de Radar de Apertura Sintética, de los cuales se deriva la técnica de DInSAR. Esta metodología permite cuantificar la deformación milimétrica del terreno (subsistencia o levantamiento) mediante el análisis de interferogramas de fase. El comportamiento de la fase interferométrica responde a dos componentes geométricos principales: en primer lugar, la diferencia de posición orbital entre las dos trayectorias del satélite, variable que permite modelar la topografía del terreno; y en segundo lugar, el desplazamiento real de la zona observada entre ambas adquisiciones. De acuerdo con Wang y Zhu (2016), este segundo componente cinemático es el que permite aislar y medir las deformaciones de la corteza terrestre detonadas por fenómenos geodinámicos —como sismos y movimientos en masa— o por actividades antrópicas

El análisis DINSAR puede ser multitemporal, es decir, que se adquieren los pares de imágenes a lo largo del tiempo, para seguir movimientos de varios meses o años. La técnica para el procesado DINSAR parte de la obtención de los desplazamientos, se realiza a partir de las zonas alejadas del fenómeno (volcán, falla, deslizamiento), zonas que se suponen libres de cambios y con geometría constante, lo que permite filtrar ciertas diferencias “no reales”, producidas por cambios atmosféricos. A partir de las zonas alejadas se va “integrando” hacia el centro de la zona de estudio, obteniendo los desplazamientos totales (Londoño et al., 2021).

Fundamento físico y atributos de las imágenes SAR

Las imágenes de radar (SAR) capturan la respuesta electromagnética de la superficie terrestre en microondas, cuya amplitud y fase contienen información sobre la reflectividad de la escena y la distancia óptica sensor-objetivo, respectivamente (John C. Curlander, Robert N. McDonough, 1991). La señal recibida depende de la frecuencia de operación (banda), la geometría de observación (ángulo de incidencia y dirección de mirada), la polarización (VV, VH, HV, HH) y el comportamiento dieléctrico y estructural de los objetos en la escena. En aplicaciones interferométricas, la fase de la señal es la magnitud clave, ya que la diferencia de fase entre dos adquisiciones permite estimar cambios de trayectoria del frente de onda atribuibles a movimientos del terreno, cambios de condiciones superficiales o variaciones atmosféricas.

Un interferograma se deriva de la diferencia de fase de dos adquisiciones de Radar de Apertura Sintética (SAR) —una imagen "maestra" y una imagen "esclava"— capturadas desde órbitas ligeramente

diferentes en momentos distintos sobre la misma área geográfica (Massonnet & Rabaute, 1993). Una alta coherencia (valores cercanos a 1) indica que las propiedades dieléctricas y geométricas de los elementos dispersores en el terreno permanecieron estables y similares entre los dos tiempos de adquisición, lo que a su vez sugiere una medición de fase de alta calidad adecuada para un procesamiento interferométrico preciso, como la elaboración de mapas de deformación de la superficie. Por el contrario, una baja coherencia (valores cercanos a 0) sugiere cambios significativos en los mecanismos de dispersión, lo que resulta en una fase ruidosa e unreliable que dificulta la capacidad de extraer señales de deformación significativas. Esta pérdida de coherencia, denominada decorrelación, puede atribuirse a varios factores, incluyendo la decorrelación temporal (cambios en la cobertura superficial, crecimiento de la vegetación o humedad del suelo durante el intervalo de adquisición), la decorrelación espacial o geométrica (diferencias en el ángulo de visión y la geometría de la línea de base), y la decorrelación volumétrica (cuando la señal de radar penetra en un dispersor de volumen como un dosel forestal, lo que lleva a diferentes centros de dispersión en diferentes momentos) (L. Zhang et al., 2011). En consecuencia, el mapa de coherencia sirve como una herramienta de diagnóstico indispensable, que determina la confiabilidad de la fase desenrollada y la confianza en cualquier producto geodésico derivado.

1. Decorrelación Temporal:

- **Cambios Rápidos en la Superficie:** Si entre las dos adquisiciones de radar, la superficie del terreno experimentó cambios drásticos en sus propiedades dieléctricas o geométricas. Ejemplos incluyen:
 - **Crecimiento/Pérdida de Vegetación:** Las hojas y ramas de los árboles se mueven por el viento o cambian su estructura (crecimiento, caída de hojas), modificando radicalmente los puntos de dispersión del radar (Rosen et al., 1996a).
 - **Cambios en la Humedad del Suelo:** Una lluvia intensa o un periodo de sequía pueden alterar drásticamente la constante dieléctrica del suelo, cambiando cómo el radar lo "ve".
 - **Actividad Antrópica Intensa:** Labranza de campos, construcción, tala de bosques o movimientos de maquinaria pesada.

2. Decorrelación Geométrica/Espacial:

- **Baseline Perpendicular Excesiva:** Si la distancia perpendicular entre las dos órbitas (la "baseline perpendicular") es demasiado grande, los ángulos de visión del radar difieren significativamente. En terrenos con características tridimensionales complejas,

esto hace que el radar ilumine diferentes partes del mismo objeto en cada pasada, llevando a una señal incoherente.

- **Terreno Abrupto:** La decorrelación geométrica es exacerbada en terrenos con pendientes muy pronunciadas, donde pequeños cambios en el ángulo de visión tienen un gran impacto.

7.3.4 Redes Neuronales y tipos de modelado.

Las Redes Neuronales Artificiales (RNA) constituyen un modelo matemático y computacional fundamentado en el aprendizaje automático supervisado, diseñado para aproximar funciones complejas no lineales que describen las relaciones dentro de un conjunto de datos heterogéneo. Desde una perspectiva teórica, la arquitectura base de estos sistemas se originó con el desarrollo del perceptrón simple, un modelo fundacional que consta de una estructura elemental de capas donde los datos de entrada se someten a un procesamiento lineal directo a través de una función de activación. Con la evolución de la disciplina, el andamiaje matemático se extendió hacia arquitecturas multicapa capaces de optimizar el espacio de características mediante el reconocimiento de valores atípicos y ruidos intrínsecos en las variables de control (Beucher et al., 2017). Teóricamente, el procesamiento de señales complejas bajo entornos de alta incertidumbre se ha robustecido mediante el diseño de redes neuronales recurrentes profundas y autoencoders. Como lo analizan conceptualmente Maas et al. (2012) estas arquitecturas avanzadas operan bajo el principio de predicción y filtrado adaptativo, entrenándose con funciones de entrada duales (matrices limpias versus señales distorsionadas) para aislar los descriptores puros. Al no depender de suposiciones preestablecidas sobre la distribución estadística del ruido o las características del entorno, el modelo posee la propiedad matemática de asimilar cualquier distorsión aditiva mediante la optimización iterativa de sus pesos sinápticos, garantizando la estabilidad y generalización del sistema predictivo.

En el trabajo de investigación de Krizhevsky et al. (2012) se realiza la clasificación de imágenes con redes neuronales de convoluciones profundas, y se encontró que la red neuronal, que tiene 60 millones de parámetros y 500,000 neuronas, consta de cinco capas convolucionales, algunas de las cuales son seguidas por capas de acumulación máxima, y dos capas conectadas globalmente con un de 1000 vías. Para que el entrenamiento sea más rápido, se usa neuronas no saturantes y una implementación de GPU muy eficiente de redes convolucionales. Para reducir el sobreajuste en las capas conectadas globalmente, se emplea un nuevo método de regularización que demostró ser muy efectivo.

Las Redes Neuronales Convolucionales (CNN) son arquitecturas de aprendizaje profundo diseñadas para la extracción jerárquica de características espaciales mediante múltiples niveles de abstracción computacional. No obstante, en la clasificación del uso del suelo urbano, el procesamiento convencional indexado a nivel de píxel suele exhibir limitaciones teóricas ante fronteras difusas y distorsiones geométricas, incrementando la redundancia computacional (Garro & Malagón, 2025). Para resolver esta restricción conceptual, la teoría geoespacial contempla las Redes Neuronales Convolucionales Basadas en Objetos (OCNN). A diferencia de las CNN tradicionales, las OCNN adoptan segmentos o polígonos homogéneos —derivados de un proceso de segmentación previa— como sus unidades funcionales primarias. Bajo este esquema matemático, las operaciones convolucionales se aplican sobre el objeto geométrico integrado, permitiendo discriminar variables internas (intra-objeto) y relaciones espaciales de vecindad (inter-objeto). Estructuralmente, este enfoque conceptual permite diferenciar la topología del terreno mediante arquitecturas de doble flujo y ventanas dinámicas adaptativas, optimizando de forma lineal la predicción de elementos continuos frente a geometrías no lineales (C. Zhang et al., 2018).

A. Feed Forward Backpropagation

Esta red se caracteriza por conocer la salida y ajusta los pesos y los coeficientes de tal manera que son ajustados al mínimo error posible, el error se va midiendo según los valores de la salida esperados, esto entendiendo que el sistema de la red está compuesto por una capa de entrada, la capa de salida y las capas ocultas, esta Red también es llamada como red multicapa (MLP), son conocidas esta redes por que la información fluye a través de la función que se evalúa, a través de los cálculos intermedios (Contreras Urgilés et al., 2019).




Figura 2. Estructura de la red Feed Forward

Fuente: (Dr. Frank Dieterle, 2019.).

El algoritmo de propagación hacia atrás donde los valores de corrección se propagan a la red anterior, las redes de alimentación suelen tener una o más capas ocultas sigmoides, neuronas seguidas por una capa de salidas de neuronas lineales, la estructura de esta red permite aprender relaciones no lineales y lineales entre vectores de entrada y salida.

El procesamiento para implementar Feed Forward como primer paso se dan los vectores de entrada:

$$X_p = [X_{p1}, X_{p2}, \dots, X_{pn}]^T$$

Ecuación 3. Formula de procesamiento inicial para implementar Feed Forward.

Donde:

- X_p representa el vector columna de entrada para un patrón p
- n es la dimensión total del espacio de características o número de variables de entrada.

Se calcula la entrada neta de la j-esima neurona de la capa oculta.

$$Neta_{jp}^h = \sum_i^N w_{ji}^h x_{pi} + \theta_j^h$$

Ecuación 4. Formula de neurona de capa Oculta

Donde:

- $Neta_{jp}^h$ es la inducción local neta de la neurona j en la capa oculta ante el patrón p
- w_{ji}^h corresponde al peso sináptico que conecta la unidad de entrada i con la neurona oculta j.
- x_{pi} es el valor del predictor i para el patrón p.
- θ_j^h representa el umbral de polarización (*bias*) asignado a la neurona j en la capa oculta.

Se calcula la salida de la neurona con la función de activación

$$i_{jp}^h = f_j^h(Neta_{jp}^h)$$

Ecuación 5. Formula neurona Activa.

Donde:

- i_{jp}^h es la señal de activación o salida emitida por la neurona oculta j.
- f_j^h representa la función de transferencia (típicamente sigmoidea o ReLU) de la capa oculta.

Una vez calculadas las salidas de las neuronas de la capa oculta, éstas se convierten en las señales de excitación de las neuronas de la capa de salida y así podemos calcular la entrada neta de la k-ésima neurona de la capa de salida:

$$Neta_{pk}^h = \sum_{j=1}^L w_{kj}^o i_{pj}^o + \theta_k^o$$

Ecuación 6. Formula capa de salida con neuronas de la capa oculta.

Donde:

- $Neta_{pk}^h$ es la entrada neta de la k-ésima neurona de la capa de salida.

- w_{kj}^o es el peso sináptico que vincula la neurona oculta j con la neurona de salida k.
- L denota el número total de neuronas presentes en la capa oculta.
- θ_k^o corresponde al umbral de polarización (*bias*) de la unidad de salida k

Con base en la función de activación de la k-ésima neurona de la capa de salida se puede calcular la salida estimada por la red neuronal ante el estímulo de entrada:

$$y_{pk} = f_k^o(Neta_{pk}^o)$$

Ecuación 7. Formula Función de activación.

Donde:

- y_{pk} representa el valor escalar estimado (predicción) por la red para la salida k ante el patrón p.
- f_k^o es la función de activación de la capa de salida (comúnmente de naturaleza lineal).

Se calcula los términos de error para las unidades de salida.

$$d_{pk}^o = (d_{pk} + y_{pk}^o) f_k^{o'}(Neta_{pk}^o)$$

Ecuación 8. Formula cálculo de error de las unidades de salida.

Donde:

- d_{pk}^o es el gradiente de error local de la unidad de salida k para el patrón p.
- d_{pk} representa el valor real u observación objetivo (*target*) de la muestra.
- $f_k^{o'}$ denota la primera derivada matemática de la función de activación de la capa de salida respecto a su entrada neta.

Se estiman los términos de error para las unidades ocultas.

$$d_{pj}^h = f_j^{h'}(Neta_{pj}^h) \sum_{k=1}^M d_{pk}^o W_{jk}^o$$

Ecuación 9. términos de error de las capas ocultas.

Donde:

- d_{pj}^h representa el gradiente de error de la neurona oculta j ante el patrón p.
- M es el número total de neuronas configuradas en la capa de salida.
- $f_j^{h'}$ corresponde a la derivada de la función de activación de la capa oculta.

Se realiza la actualización pesos en la capa oculta. $w_{kj}^o(t+1) = W_{kj}^o(t) + \alpha d_{pk}^o i_{pj}^h$

Actualiza pesos en la capa oculta.

$$w_{kj}^o(t+1) = W_{kj}^o(t) + \alpha d_{pk}^o x_{pj}$$

Ecuación 10. Formula actualización de los pesos para el entrenamiento

Donde:

- t y $t+1$ representan el estado temporal o iteración actual y posterior del entrenamiento, respectivamente.
- α denota la tasa de aprendizaje (*learning rate*), un hiperparámetro adimensional que controla la magnitud del ajuste del peso.

Se verifica si el error global cumple con la condición de finalizar, y si es así el proceso termina

$$E_p = 1/2 \sum_{p=1}^P \sum_{k=1}^M (d_{pk} - y_{pk})^2$$

Ecuación 11. Formula de verificación del modelo para finalizar.

Donde:

- E_p representa la energía del error global acumulada por el modelo.
- P es el número total de patrones o muestras contenidas en el conjunto de datos de entrenamiento.

B. Elman Backpropagation

En esta arquitectura (Khandetsky & Antonyuk, 2002), las unidades ocultas son estimuladas simultáneamente por las unidades de entrada y las de contexto; posteriormente, esta capa oculta se propaga de manera unidireccional para activar las unidades de salida. Asimismo, las unidades ocultas se retroalimentan hacia las de contexto, completando así el proceso de activación hacia adelante (*feedforward*). Dependiendo de la naturaleza de la tarea, este ciclo temporal puede incorporar una fase de aprendizaje. De ser así, la salida generada se contrasta con una señal supervisada (*teacher input*) y se aplica el algoritmo de retropropagación del error para ajustar incrementalmente los pesos sinápticos. Cabe destacar que las conexiones recurrentes permanecen fijas en un valor de 1.0, por lo que no están sujetas a modificaciones. En el siguiente intervalo temporal $t + 1$, la secuencia descrita se repite de manera idéntica. En esta etapa, las unidades de contexto almacenan con exactitud los estados de la capa oculta del tiempo t , dotando a la red de un mecanismo de memoria temporal.

C. WSOD (Weakly Supervised object Detection).

En la actualidad, la proliferación de sensores remotos de última generación ha generado una disponibilidad sin precedentes de datos geoespaciales con una resolución tanto temporal como radiométrica de alto detalle. Esta abundancia de información ha permitido que el procesamiento digital de imágenes trascienda las metodologías clásicas de clasificación —basadas tradicionalmente en algoritmos supervisados y no supervisados— para dar paso a arquitecturas de aprendizaje profundo (Deep Learning) capaces de ejecutar tareas complejas de segmentación y detección de elementos en entornos geográficos heterogéneos.

Dentro de este panorama, las herramientas de Inteligencia Artificial (IA) han evolucionado significativamente en su capacidad para interpretar el espacio. Si bien el estándar de oro en la visión por computadora ha sido el uso de cuadros delimitadores (bounding boxes) para el entrenamiento de

modelos, este enfoque demanda un proceso de etiquetado manual exhaustivo, costoso y a menudo impracticable a gran escala. Como respuesta a esta limitación, ha emergido con fuerza la Detección de Objetos Débilmente Supervisada (WSOD, por sus siglas en inglés: Weakly Supervised Object Detection) (Fasana et al., 2022).

La WSOD representa un cambio de paradigma, ya que busca mitigar la dependencia de anotaciones detalladas a nivel de píxel o de coordenadas específicas, permitiendo que los modelos se entrenen utilizando únicamente etiquetas a nivel de imagen (indicando la presencia o ausencia de un objeto sin especificar su ubicación). Según señalan Fasana et al. (2022), esta transición hacia el uso de imágenes naturales ha permitido optimizar los recursos computacionales y humanos, aunque no exenta de desafíos críticos. En su investigación, Fasana y sus colaboradores analizan sistemáticamente las técnicas disponibles y comparan el rendimiento de diversos conjuntos de datos, concluyendo que la mayoría de los enfoques actuales de WSOD heredan la estructura de las clasificaciones supervisadas tradicionales. Sin embargo, se identifica una brecha técnica fundamental: aunque el método es eficaz para confirmar la existencia de un objeto dentro de una escena, la naturaleza de la supervisión débil conlleva una pérdida inherente de precisión espacial. Al basarse exclusivamente en descriptores globales de la imagen, el sistema a menudo presenta dificultades para delimitar con exactitud la geometría y la localización precisa del objeto detectado. Por tanto, el reto actual de la investigación científica reside en desarrollar algoritmos que logren cerrar la brecha entre el reconocimiento semántico y la precisión posicional, sin sacrificar la eficiencia que caracteriza a los métodos débilmente supervisados.

D. Máquinas de soportes vectoriales

Las máquinas de vectores de soporte (SVM, por sus siglas en inglés) pertenecen a una clase de algoritmos de Machine Learning denominados métodos kernel y también se conocen como máquinas kernel. Son un conjunto de algoritmos de aprendizaje, se han utilizado SVM para solucionar problemas de clasificación y regresión relacionados a la predicción de series de tiempo, mostrando ser mejores en comparación a otras metodologías tradicionales como modelos econométricos y en algunos casos a modelos de aprendizaje de máquina. Existen los casos que son linealmente separables y los casos que no son linealmente separables. En cuanto a los casos que son linealmente separables, para variables no negativas se obtiene. el entrenamiento de una máquina de vectores de soporte consta de dos fases. La primera fase se ocupa de transformar los predictores (datos de entrada) en un espacio de características altamente dimensional. En esta fase es suficiente con especificar el kernel; los datos nunca se transforman explícitamente al espacio de características. Este proceso se conoce comúnmente como el truco kernel y resolver un problema de optimización cuadrática que se ajuste a un hiperplano óptimo para clasificar las características transformadas en dos clases. El número de características transformadas está determinado por el número de vectores de soporte. (Matlab, 2014).

Para los casos que **no son linealmente separables**, las SVM adaptan sus dos fases de entrenamiento mediante modificaciones matemáticas específicas:

1. Fase de Transformación (Truco Kernel No Lineal): En lugar de utilizar un kernel lineal, se especifican funciones de mapeo no lineales, tales como el Kernel de Función de Base Radial (RBF / Gaussiano) o el Kernel Polinomial. El algoritmo proyecta implícitamente los predictores originales a un espacio de características de dimensión infinita o superior. En este nuevo espacio altamente dimensional, las clases complejas (por ejemplo, con geometrías concéntricas o entrelazadas) se reordenan de tal forma que vuelven a ser linealmente separables por un hiperplano. Al proyectar este hiperplano plano de vuelta al espacio original de los datos, este se manifiesta como una frontera de decisión curva u ondulada.
2. Fase de Optimización (Margen Blando y Variables de Holgura): Dado que en la práctica los datos reales suelen presentar solapamiento por ruido atmosférico o variaciones del terreno, el problema de optimización cuadrática estricta se flexibiliza introduciendo variables de holgura y un parámetro de regularización conocido como parámetro de caja o penalización. Esto permite al algoritmo tolerar un margen controlado de errores de clasificación durante el entrenamiento (puntos que cruzan la frontera), garantizando que el hiperplano óptimo mantenga una máxima capacidad de generalización frente a nuevos datos de series temporales y evitando el sobreajuste (*overfitting*) (Matlab, 2014).

7.3.5 Remoción en masa y las afectaciones en el territorio.

A. Evaluación Dinámica de la Susceptibilidad y Zonificación de Amenazas

La evaluación y zonificación de los procesos de remoción en masa constituyen el pilar fundamental para la planificación urbana y la mitigación del riesgo en zonas vulnerables. Este análisis requiere un enfoque multidimensional que logre integrar las variaciones espacio-temporales de variables hidrometeorológicas dinámicas —tales como las precipitaciones extremas— con las características físicas estáticas del territorio (González, 2011) Mediante el uso de Sistemas de Información Geográfica (SIG), es posible ejecutar la agregación y el procesamiento de tensores de datos geomorfológicos y climáticos. Esta integración permite mapear con precisión el peligro, aportando los insumos técnicos necesarios para el ordenamiento territorial y el diseño de planes de prevención de desastres (Alcántara Ayala et al., 2008).

B. Factores Condicionantes y Criterios de Ponderación Multicriterio

La modelación matemática para delimitar la susceptibilidad a la inestabilidad de laderas se fundamenta en la interacción de variables intrínsecas del medio físico. En los modelos de evaluación heurística o analítica, la asignación de pesos teóricos (ponderaciones) debe responder estrictamente al rol genético que cada variable ejerce sobre el desencadenamiento del fallo (Cartaya et al., 2006). Bajo este enfoque, las variables se estructuran jerárquicamente según su influencia en la estabilidad:

- **Geología de Superficie:** Se establece generalmente como el factor de mayor relevancia (atribuyéndosele hasta un 40% del peso relativo) debido a que las propiedades mecánicas y litológicas de los materiales controlan la resistencia basal del terreno (Cartaya et al., 2006).
- **Geomorfología:** Actúa como el segundo descriptor crítico (representando cerca del 30%). Las unidades morfológicas se encuentran intrínsecamente ligadas a la litología y reflejan la evolución del relieve bajo la influencia de las condiciones climáticas históricas (Cartaya et al., 2006).
- **Pendiente Media del Terreno:** Si bien la literatura científica cataloga universalmente a la pendiente como un detonante geométrico principal, su ponderación analítica (ej. 20%) debe ajustarse a la realidad empírica del área de estudio. Los registros históricos demuestran que los desplazamientos masivos pueden concentrarse en rangos de inclinación moderada (como el intervalo del 3% al 18%), condicionados por la saturación de los materiales y no únicamente por la verticalidad del relieve (Cartaya et al., 2006).
- **Conflictos de Uso del Suelo:** Representa la variable antropogénica o de cobertura superficial con menor peso relativo (típicamente 10%). Su relevancia decrece en entornos donde la densidad de los movimientos en masa responde a la degradación natural de las laderas y no a las alteraciones directas por actividad humana (Cartaya et al., 2006).

7.3.6 Probabilidades de falla de taludes

Dentro de la literatura existen diferentes métodos de cálculos de probabilidad en falla de taludes, sin embargo, esta investigación se centra en los más utilizados:

7.3.6.1 Desarrollo de series de Taylor

Función de los variables restringidas a las derivadas de primer orden:

$$F(x, y) \approx F(\tilde{x}, \tilde{y}) + \frac{dF}{dx}(x - \tilde{x}) + \frac{dF}{dy}(y - \tilde{y})$$

Ecuación 12. Formula de variables restrictivas de primer orden.

Donde:

- $F(x, y)$ representa la función de respuesta del sistema (por ejemplo, el Factor de Seguridad de la ladera).

- (x, y) corresponden a las variables aleatorias condicionantes del terreno evaluadas en el modelo.
- $\tilde{y}, \tilde{x}$ representan los valores medios (o promedios aritméticos) de las variables aleatorias x e y , respectivamente.
- $\frac{dF}{dx}, \frac{dF}{dy}$ son las derivadas parciales de primer orden de la función respecto a cada variable, evaluadas en el punto medio.

Las derivadas acá expresadas, se calculan con los valores promedio, siendo el valor esperado y la varianza de la función se puede aproximar a:

$$E[F(x, y)] \approx F(\tilde{x}, \tilde{y})$$

$$V[F(x, y)] \approx \left(\frac{dF}{dx}\right)^2 V(x) + \left(\frac{dF}{dy}\right)^2 V(y) + 2 \left(\frac{dF}{dx}\right) \left(\frac{dF}{dy}\right) cov(x, y)$$

Ecuación 13. Derivadas expresadas del cálculo.

Donde:

- $(E[F(x, y)])$ denota el operador de valor esperado (o media estimada) de la función analizada.
- $(V[F(x, y)])$ representa la varianza total de la función, la cual mide la dispersión o incertidumbre del resultado.
- $(V(x), V(y))$ corresponden a las varianzas intrínsecas de las variables aleatorias de entrada x e y .
- $cov(x, y)$ representa la covarianza entre las variables $\backslash(x\backslash)$ e $\backslash(y\backslash)$, la cual cuantifica el grado de dependencia lineal mutua (por ejemplo, la correlación estadística entre la cohesión y el ángulo de fricción interna del suelo).

Para n variables independientes (no correlacionadas) y teniendo en cuenta únicamente los elementos lineales, se tiene:

$$E[F] \approx F(\tilde{x}_1, \tilde{x}_2, \dots, x_n)$$

$$V[F] \approx \sum_{i=1}^n \left(\frac{dF}{dx_i}\right)^2 V(x_i)$$

Ecuación 14. Fórmula para elementos lineales.

Donde:

- n es el número total de variables independientes o predictores introducidos en el análisis del terreno.
- x_i representa la i -ésima variable aleatoria del modelo.
- $\tilde{x}_1$ corresponde al valor medio o esperado de la variable x_i .
- $V(x_i)$ es la varianza asociada a la i -ésima variable aleatoria.
- $\frac{dF}{dx_i}$ denota la derivada parcial de la función respecto a la variable x_i , actuando como el coeficiente de sensibilidad del sistema.

7.3.6.2 Método de PEM

Rosen et al., (1996), propuso este método para determinar probabilidades de fallas de obras civiles, pero se ha utilizado para diferentes estudios, este método establece que dada la función de factor de seguridad:

$$y = f(x_1 + x_2, \dots + x_n)$$

Ecuación 15. Función de factor.

Se definen los valores máximos y mínimos de cada una de las variables:

$$x_n^+ = \bar{x}_n + \delta(x_n), \text{ para el caso maximo}$$

$$x_n^- = \bar{x}_n - \delta(x_n), \text{ para el caso minimo}$$

Entonces, se define la probabilidad de cada combinación de los casos:

$$p^{+,+, \dots, +} = \frac{1}{2^n} \sum_{i=1}^{n-1} \sum_{j=i+1}^n a_{ij} * \rho_{ij}$$

Donde, en general, para n variables se tienen 2^n probabilidades y $n(n-1)/2$ coeficiente de correlación.

$a_{ij} = 1$ si las dos variables (i, j) son maximas o minimas, 0 – 1 en caso contrario.

ρ_{ij} = coeficiente de correlación entre las variables x_i y x_j

Se define el valor esperado de la variable y la desviación de la variable, como:

$$E(y) = \sum_{k=1}^{2^n} p^{+,+, \dots, +} * f_k(x_1^{\pm}, x_2^{\pm}, \dots, x_n^{\pm})$$

$$\sigma(y) = \sqrt{E(y^2) - (E(y))^2}$$

$$E(y)^2 = \sum_{k=1}^{2^n} p^{+,+, \dots, +} * f_k[(x_1^{\pm}, x_2^{\pm}, \dots, x_n^{\pm})]^2$$

Ecuación 16. Formula cálculo de variables y desviación de la variable.

Una vez definido el Valor esperado y la desviación de la variable aleatoria (Factor de seguridad), se puede definir la probabilidad de un valor determinado ajustando la función de probabilidad determinada.

7.3.6.3 Cambios a corto plazo (anual) y a largo plazo

Las variable que intervienen a corto plazo, corresponde a: Sin lluvia sin sismo, Con lluvia sin sismo, Sin lluvia con sismo, Con lluvia con sismo;, de forma que la fórmula de cálculo según (D. S. González, 2011):

$$P(FS \leq 1) = \sum_{i=0}^1 \sum_{j=0}^1 P[FS \leq 1/(S_i \cap L_j)] * P(S_i \cap L_j)$$

Ecuación 17. Fórmula de cálculo de desplazamiento anual y corto plazo.

Donde:

S_i = Probabilidad de ocurrencia de un sismo

$S_0 = 1 - S_i$ = Complemento de ocurrencia del sismo

L_1 = Probabilidad de ocurrencia de la lluvia

$L_0 = 1 - L_i$ = Complemento de ocurrencia de lluvia

La definición del largo plazo varía según los años de evaluación, donde n es el número de años:

$$P(Dz)_n = P(Dz) + P(Dz)_{n-1} - P(Dz) * P(Dz)_{n-1}$$

Ecuación 18. Fórmula del largo plazo según años de evaluación.

Variables de medición y validación.

Este procedimiento garantiza la mitigación del sesgo de optimismo predictivo y asegura la transferibilidad espacial y la generalización asintótica del modelo formulado. Con el propósito de cuantificar con precisión matemática la bondad de ajuste, el sesgo sistemático y la varianza de las estimaciones analíticas, se calcularon métricas de error y coeficientes de correspondencia de referencia en la literatura científica internacional (Gunson et al., 2011).

Específicamente, la evaluación del ajuste se computó mediante el Coeficiente de Determinación del Error Cuadrático y el Error Absoluto Medio (MAE). El estadístico permitió determinar de manera cuantitativa la proporción de la varianza total de la variable dependiente que es explicada unívocamente por el espacio de características de los predictores ambientales y geométricos incorporados. Paralelamente, el RMSE y el MAE proporcionaron una medida de la magnitud media de los residuos empíricos en las mismas unidades de medición del fenómeno estudiado. El RMSE se empleó estratégicamente debido a su sensibilidad matemática frente a valores atípicos (*outliers*), ya que penaliza cuadráticamente las desviaciones de gran magnitud, mientras que el MAE ofreció una métrica robusta de la tendencia central del error absoluto. Es fundamental precisar que, dado que el índice analítico *F1-score* constituye una métrica formulada estrictamente para escenarios de clasificación binaria o multinomial basada en matrices de confusión, su integración en este marco de regresión continua se restringió de manera exclusiva a la evaluación de la sensibilidad y especificidad del modelo tras la aplicación de umbrales de discretización probabilística o límites críticos de susceptibilidad.

7.4 MARCO TEMPORAL

Por la disponibilidad de datos y recolección de datos actuales, el estudio contempla como periodo de estudio los años entre 2014 y 2024 para tener un espectro temporal considerable y mayor cantidad de datos que permitirán tener mayor disponibilidad de datos para el aprendizaje y

comprobación de los datos en la red neuronal que se desarrollará en la investigación, comprobándolo con datos de 2025, que están disponibles.

7.5 MARCO GEOGRÁFICO

La configuración fisiográfica de Cáqueza presenta desafíos significativos en términos de estabilidad de laderas. De acuerdo con la **Zonificación de Amenaza por Movimientos en Masa** elaborada por el Servicio Geológico Colombiano (SGC), el municipio se localiza en una zona de vulnerabilidad geológica debido a la actividad tectónica de la región del Oriente de Cundinamarca (SGC, 2021). Para el análisis espacial, la **Infraestructura de Datos Espaciales de Cundinamarca (IDEC)** provee el Modelo Digital de Terreno (MDT) con una resolución espacial (GSD) de 1 metro, lo que permite modelar escenarios de riesgo hidrometeorológico con alta precisión técnica (Borja Baeza & Alcántara Ayala, 2004).

El municipio de Cáqueza presenta cuatro fracturas tectónicas internas cuya nomenclatura oficial aún no ha sido establecida; no obstante, su proximidad estructural a sistemas de falla regionales bien documentados, entre los que se incluyen la falla del río Sáname y la falla de Quetame, sugiere una interconexión geodinámica relevante para la génesis y evolución de procesos gravimétricos y de remoción en masa en la zona.

Según el acuerdo vigente de ordenamiento territorial del municipio de Cáqueza, dentro de las amenazas y riesgos que existen en el municipio se encuentran por sísmica y por movimientos en masa. Las unidades de actitud del suelo presentes son: IV la cual se caracteriza por presentar un relieve ligeramente ondulado, con limitaciones moderadas por pendientes, donde se deben realizar drenajes para la evacuación en épocas de lluvia; VI que son terrenos con susceptibilidad a la erosión por ser suelos superficiales; VII los cuales presentan limitaciones por fuertes pendientes y clima seco; y VIII suelos para protección y conservación por presentar estrictas limitantes, con pendientes superiores a 50%.

La gestión ambiental en la jurisdicción está supeditada a las determinantes de la **Corporación Autónoma Regional de Cundinamarca (CAR)**. En cumplimiento de las políticas de conservación de ecosistemas estratégicos, el municipio restringe el uso del suelo en áreas de subpáramo y bosques de niebla, situadas por encima de la cota de los 2,800 m.s.n.m., conforme a lo establecido en el diagnóstico regional de la cuenca del Río Negro (CAR, 2022). Estos lineamientos son imperativos y prevalecen sobre las decisiones locales de uso del suelo, garantizando la oferta hídrica regional.

El municipio de Cáqueza se encuentra situado en el oriente del departamento de Cundinamarca, su temperatura media es de 20 °C, la altura al nivel del mar es de 1.746 m, precipitación media de 1.150 mm y una extensión total de 120 Km².

Las coberturas de suelo que se encuentran en mayor porcentaje en el municipio son Bosques Plantados, Rastrojos, Pastos Naturales, Cultivos, Superficies de agua, afloramientos rocosos y arenas erosionadas.

La caracterización demográfica, basada en las proyecciones del **Censo Nacional de Población y Vivienda (DANE, 2018)** actualizadas a 2024, estima una población de 18,061 habitantes, con un índice de ruralidad (El cual mide la población fuera de la cabecera) que impacta directamente en la estructura de servicios públicos. Económicamente, Cáqueza se consolida como un nodo de servicios regionales; no obstante, su base productiva continúa anclada a la agricultura de minifundio, con una producción de cebolla de bulbo y maíz que suma más de 4,700 toneladas anuales, lo que resalta la dependencia del municipio a las fluctuaciones de los mercados de Bogotá (DANE, 2024; Secretaría de Agricultura de Cundinamarca, 2023).

Aunque Cáqueza tiene un total de 11.140,52 hectáreas, el área de trabajo utilizó un área mayor (definida en el recuadro negro, Figura 3) de 45.316,50 hectáreas en total. Se definió un cuadrado con fines de entrenamiento para facilidad de modelado el área de estudio comprende las siguientes áreas por municipio:

Tabla 2. Área total estudiada por municipio.

<i>MUNICIPIO</i>	<i>ÁREA TOTAL</i>	<i>ÁREA INCLUIDA EN EL ESTUDIO</i>	<i>PORCENTAJE ÁREA MUNICIPIO ESTUDIADA</i>
FOSCA	11.105,58	6.267,32	56%
QUETAME	13.759,64	6.385,26	46%
UNE	20.886,65	5.703,36	27%
CÁQUEZA	11.140,52	11.140,52	100%
CHIPAQUE	15.036,01	3.756,54	25%
UBAQUE	10.695,02	3.876,92	36%
FOMEQUE	45.951,73	8.186,58	18%
TOTAL	128.575,15	45.316,50	35%

Fuente. Elaboración Propia,2026.




Figura 3. Localización del área final de estudio, cabeceras municipales incluidas.

Fuente. Elaboración Propia, 2026.

Adicionalmente, es importante mencionar que los centros poblados y cabecera municipales que están incluidas dentro del área de estudio de los municipios mencionados y sus áreas en la Tabla 2, las cuales son Llano de Chipaque, Abasticos, Sáname, Guacapate, Timasita, Cáqueza, Fomeque y Fosca.

7.6 MARCO HISTORICO

En el marco Sendai herramienta de recopilación <https://www.desinventar.net/>, que permite crear las bases de datos necesarias para la gestión, en esta herramienta se cargaron los datos iniciales de 82 países el cual, para Colombia se cargó, información que fue consultada en este estudio, para el municipio de Cáqueza en el fenómeno de remoción en masa, y se cargaron datos desde 1985 a 2010 y se reportaron 12 eventos, que se mencionan como datos disponibles, definidos como eventos

importantes para este estudio, esto se tomó en cuenta para precisar eventos importantes de remoción en masa y elegir los 4 periodos de estudio de la investigación.

Parafrasear, en la tabla 3 se muestra el reporte, el consolidado, etc.

Tabla 3. Reporte histórico de procesos de remoción en masa, herramienta desarrollada en el marco Sendai.

Fecha evento	Fuente del dato	Tipo de evento	Observaciones
18/11/2010	Unidad de Gestión del Riesgo	Remoción en masa	Evento reportado por el Comité Regional para la Prevención y Atención de Desastres (CREPAD). Se identificaron 65 personas afectadas y 13 viviendas con daños estructurales en las veredas Girón de Blanco, Girón de Moyas y El Páramo.
11/10/1999	DNPAD – Oficina Nacional para la Prevención y el Apoyo en casos de Desastre	Remoción en masa	Se reportó un deslizamiento en la vía Bogotá-Villavicencio. El saldo del evento fue de 2 personas fallecidas, 1 herida, 15 afectadas y 3 viviendas destruidas.
14/7/1997	EL TIEMPO 1997-07-15/16/17	Remoción en masa	Bloqueo total de las dos carreteras que comunican a Bogotá con Villavicencio y los Llanos Orientales debido a múltiples derrumbes. Se reportó parálisis en la actividad comercial de paradores de la vía, incremento en las tarifas de pasajes, reducción del flujo de pasajeros terrestres y una afectación del 50% en el tráfico de carga y transporte aéreo debido a las condiciones invernales.
01/04/1993	EL TIEMPO 1993-10-15	Remoción en masa	Cierre total de la infraestructura vial durante un periodo de doce horas.
18/08/1991	EL TIEMPO	Remoción en masa	Caída de rocas sobre la calzada que provocó la pérdida total de un vehículo de carga pesada (tractomula) cargado con madera.

Fecha evento	Fuente del dato	Tipo de evento	Observaciones
07/07/1991	EL TIEMPO	Remoción en masa	Restablecimiento de la movilidad en la vía hacia Bogotá tras una restricción vial de más de 42 horas. El Distrito 13 de Carreteras ejecutó labores de refacción y estabilización de la banca en el kilómetro 33, en el tramo comprendido entre Chipaque y Cáqueza.
08/10/1986	EL TIEMPO 1986-10-09 7D	Remoción en masa	Desprendimiento y caída de un bloque rocoso de grandes dimensiones sobre un vehículo en la vía hacia Bogotá, ocasionando 1 persona fallecida y 1 herida.
17/05/1985	EL TIEMPO 1985-05-18	Remoción en masa	Desprendimiento y caída de un bloque rocoso de grandes dimensiones sobre un vehículo en la vía hacia Bogotá, ocasionando 1 persona fallecida y 1 herida.
15/06/1980	BDOD-30096	Remoción en masa	Interrupción temporal del tránsito vehicular en la vía al Llano.
29/10/1970	BDOD-20231	Remoción en masa	Interrupción temporal del tránsito vehicular en la vía al Llano.

Fuente: Elaboración Propia, 2026.

A partir de la información anterior se recopilaron datos históricos de eventos en Cáqueza, los hechos más relevantes se enuncian dentro del documentos mencionados en la Tabla 3, que se utilizó para poder georreferenciar datos por vereda, y poder establecer cantidad de sucesos por vereda.

8. CAPITULO 3. METODOLOGÍA

El proyecto se desarrolla en 5 fases, las cuales se describen a continuación

Fase 1 — Recolección y preprocesamiento de datos (Input)

- SAR Sentinel-1 (SLC): descargas Ascendente/Descendente (C-Band) — selección de pares maestros/esclavos; objetivo: minimizar efectos geométricos (layover/shadow).
- DEM/DTM: ALOS PALSAR RTC 12.5 m + DTM post-procesado — uso principal para remoción de fase topográfica.
- Variables condicionantes: geología (formaciones), uso de suelo, series de precipitación (IDEAM), suelos, cobertura vegetal y otros factores referenciales (normalizados y georreferenciados).

Primer entregable operativo: Salida F1 → Paquete espacial integrado: SLC alineados + DEM/DTM + capas condicionantes (formatos GeoTIFF/GPKG).

Fase 2 — Procesamiento interferométrico DInSAR (núcleo técnico) Herramientas: SNAP (preprocesos/interferogramas), SNAPHU (unwrapping), procesos complementarios de filtrado y análisis de calidad. Pasos:

1. Corregistro submétrico: alineación maestra/esclava para minimizar error geométrico.
2. Generación de interferograma diferencial: cálculo de diferencias de fase entre adquisiciones.
3. Remoción de fase topográfica: resta del DEM/DTM para aislar fase por desplazamiento.
4. Filtrado de fase (Goldstein): reducción de ruido y mejora de señal (evaluar coherencia).
5. Desrrolado de fase (SNAPHU): conversión de fase a desplazamiento LOS (mm/año). Productos DInSAR → Mapas de desplazamiento LOS (serie temporal o tasa), mapas de coherencia y mapas de incertidumbre; metadatos de calidad temporal/espacial.

Fase 3 — Análisis de factores de inestabilidad

- Geomorfología: derivación de pendientes, aspecto, curvatura y estabilidad superficial.
- Inventario histórico, digitalización y geocodificación de deslizamientos históricos y eventos registrados.
- Integración espacial: superposición de puntos/zonas DInSAR con capas condicionantes para extraer variables explicativas
- Salida F3 → Base de datos de muestras (atributos DInSAR + factores físicos + etiqueta histórica).

Fase 4 — Estructuración del modelo predictivo (Machine Learning)

- Predecir probabilidad espacial de remociones en masa y generar mapa dinámico de susceptibilidad.

- Entradas: velocidades DInSAR (como variable de alto peso), factores geomorfológicos, geológicos, pluviométricos e inventario histórico (etiquetas).
- Algoritmos propuestos: Random Forest (preferido por interpretabilidad/robustez) y SVM (comparativo).
- Procesos: preparación de muestras (balanceo, particionado entrenamiento/validación), selección de variables, ajuste de hiperparámetros, validación cruzada, evaluación de importancia de variables.
- Salida F4 → Mapa de susceptibilidad probabilístico (raster), capas clasificadas (baja/media/alta) y reporte de importancia de variables; mecanismo de actualización cuasi-temporal y umbrales de alerta según Unidad Nacional para la Gestión del Riesgo de Desastres (UNGRD).

Fase 5 — Evaluación y validación

- Validación estadística: Matriz de confusión, precisión, exactitud y F1.
- Análisis de incertidumbre y sensibilidad (especial énfasis en la calidad y resolución de datos DInSAR y DEM).
- Salida F5 → Informe de validación, métricas de desempeño, recomendaciones de umbral y plan de monitoreo.

Productos finales y entregables

- Mapa prospectivo de alerta por niveles (GeoTIFF/GPKG) y capas de soporte (velocidades LOS, coherencia, factores condicionantes).
- Validación espacial, mediante puntos aleatorios de muestreo.
- Reporte técnico con metodologías, parámetros DInSAR, importancia de variables y validación.
- Protocolos de actualización (frecuencia de monitoreo, criterio de retrabajo con nuevos pares SAR).


Puntos clave (énfasis DInSAR)

- DInSAR es la principal fuente de información dinámica: proporciona tasas de deformación espaciales y temporales que actúan como variable de peso en la predicción.
- La calidad del DEM/DTM y la coherencia SAR son críticas: errores en remoción topográfica o baja coherencia degradan el modelo.
- Integración robusta: combinar señales DInSAR con inventario histórico y variables físicas mejora poder predictivo y reduce falsos positivos.
- Recomendación operativa: implementar flujo automatizado de ingestión SAR → DInSAR → actualización del modelo para monitoreo cuasi-temporal.

8.1 METODOLOGIA

Figura 4. Metodología desarrollada en la investigación.

Fuente: elaboración propia, mediante mermaid 2026.



9. CAPITULO 4. DESARROLLO, RESULTADOS DE LA INVESTIGACIÓN Y ANÁLISIS

9.1 FASE 1: RECOLECCIÓN Y PRE-PROCESAMIENTO DE DATOS (INPUT)

9.1.1 Insumos recolectados

Para la identificación de los años a trabajar para entrenar el modelo, se realizó la búsqueda de información disponible para ello se consultaron imágenes disponibles e información que pudiera suministrar datos, lo que identifico que para hacer el estudio DInSAR tenemos imágenes disponibles Sentinel 1 desde julio 2014 hasta la actualidad, por ello mediante el inventario de sismología (Ver anexo 1) e información recopilatoria de lluvias, junto con diferentes noticias de presencia de Remociones en masa, reportados en la Tabla 3, se decide tomar las fechas:

- Sismos ocurridos entre 2014 y 2024, según disponibilidad de imágenes:

Tabla 4. Sismos seleccionados para realizar la extracción de los datos.

No.	Fecha del sismo	Magnitud	Profundidad (km)	Área epicentral
1	10/03/2015	6.4	157.7	Los Santos, Santander
2	30/10/2016	5.3	13.2	Colombia, Huila
3	15/04/2020	5.8	50	Santa Cruz De Mompox
4	17/08/2023	6.1	13	San Juanito, Meta

Fuente: Elaboración Propia, 2026.

- Mayores Épocas de lluvia entre 2020 y 2024, que son las fechas donde IDEAM permite descargar información, en Cáqueza se tiene una estación disponible (**Estación Las Casas** y está identificada con el **Código Técnico 35030080**) se utilizó dicha para descargar la información de las fechas con mayores lluvias.

Dentro del proceso fue necesario convertir toda la información en RASTER, esto para que cada pixel tuviera información continua en el espacio, el tamaño de píxel, sugerido por el programa de interferogramas fue de 40 m * 40 m, es así como todas las imágenes formaron matrices, de 574 columnas y 200 Filas, esto dado a que siempre se debe ir de la menor resolución espacial de los insumos disponibles esta correspondería.

9.2 FASE 2: PROCESAMIENTO INTERFEROMÉTRICO (DINSAR)

Para el desarrollo del presente proyecto y del proceso de delimitación mediante DInSAR (Differential Interferometric Synthetic Aperture Radar) se empleó la colección de imágenes Sentinel-1. El detalle del posprocesamiento —incluyendo descarga, calibración radiométrica, filtrado multilook, corrección fase plana, eliminación de la componente topográfica mediante un modelo digital de elevación y filtrado de fase— y la definición completa del flujo de trabajo se consignan en los anexos. Se seleccionaron cuatro fechas de adquisición por presentar, de forma conjunta, disponibilidad de imágenes con geometrías apropiadas y la ocurrencia de eventos sísmicos de interés; las fechas y metadatos asociados se resumen en la Tabla 4. El análisis siguió procedimientos estándar de DInSAR y SBAS (Small Baseline Subset - Subconjunto de Líneas de Base Pequeñas) cuando fue pertinente, con énfasis en la preservación de la coherencia espacial y temporal para la detección de señales de deformación retenidas por la fase SAR, una vez realizado el postprocesamiento de las imágenes de las 4 épocas mencionadas, posteriormente se procedió a revisar las correlaciones identificadas en el postproceso Tabla 5, la correlación encontrada es alta, esto se debe a la pendiente de la zona de estudio que toma el municipio de Cáqueza y los municipios vecinos, el paso a paso del desarrollo del postprocesamiento se puede ver en el Anexo 1, donde se detallan las fases del posprocesamiento realizado para cada par de imágenes de las 4 épocas.




Figura 5. Espacio de trabajo del postproceso de imágenes DInSAR para 2015.
Fuente: Elaboración Propia, 2026.

En la Figura 5, se puede ver el resultado del postproceso paso a paso, en esta figura se ve el espacio de trabajo para el año 2015, que es el primer par de imágenes como ejemplo de visualización, se puede ver en la figura los resultados del proceso paso a paso: Carga de imágenes en formato comprimido, Recorte o split de la zona de trabajo que en la figura se ve de color rojo, ya que vienen 3 escenas en cada paquete de imágenes, aplicación de la órbita del satélite, geocodificación inversa, se aplica la diversidad espectral mejorada, generación del interferograma, eliminación de ruido o líneas negras para dar continuidad al ráster, remoción de la fase topográfica, filtrados de la fase, desenrollado de la fase, conversión de la Fase a Imagen de desplazamiento.

A continuación se desplegarán las imágenes y resultados trabajados para la primera época como ejemplo de visualización de las imágenes trabajadas Sentinel 1.






Figura 6. Banda de intensidad sin postproceso DInSAR para 2015.
Fuente: Elaboración Propia, 2026.

*MODELO DE PREDICCIÓN DE PROCESOS DE REMOCIÓN EN MASA, PARA EL MUNICIPIO DE
CÁQUEZA CUNDINAMARCA, USANDO IMÁGENES DE RADAR QUE PERMITAN METODO DInSAR*



*Figura 7. Aplicación de la órbita del satélite DInSAR para 2015.
Fuente: Elaboración Propia, 2026.*

Entre la Figura 6 y Figura 7, se puede evidenciar el cambio de visualización al realizar el aplicado de la órbita.



*Figura 8. Geocodificación inversa DInSAR para 2015.
Fuente: Elaboración Propia, 2026.*




Figura 9. Interferograma sin fase desenrollada, inicial calculado para 2015.
Fuente: Elaboración Propia, 2026










Figura 10. Interferograma final que identifica los desplazamientos, inicial calculado para 2015.
Fuente: Elaboración Propia, 2026

En las figuras Figura 8, Figura 9 y Figura 10, se pueden observar los resultados obtenidos en la última fase de posprocesamiento, esto se muestra para 1 de las temporalidades para no hacer más largo el documento sin embargo, esta tarea se revisó para los 4 pares de fechas trabajados en el interferograma,

como resultado, se validaron las correlaciones en Tabla 5 y en la Tabla 6, se pueden observar los resultados finales de los interferogramas que muestran el desplazamiento encontrado en las 4 fechas.

Tabla 5. Imágenes de correlación de cada uno de los pares de trabajo para el interferograma.


Periodo	Correlación(Escala 1:150.000)	Correlación entre imagen Master y Slave (Leyenda)
<u>Sismo</u> <u>10/03/2015</u> Imagen Master: 07/02/2015 Imagen Slave: 15/03/2015		
<u>Sismo</u> <u>30/10/2016</u> Imagen Master: 07/02/2015 Imagen Slave: 15/03/2015		
<u>Sismo</u> <u>15/04/2020</u> Imagen Master: 11/04/2020 Imagen Slave: 23/04/2020		



<u>Sismo</u> <u>17/08/2023</u> Imagen Master: 12/08/2023 Imagen Slave: 24/08/2023		Value High : 0,983259 Low : 0,00095436
---	---	---


Fuente: Elaboración propia, 2026.

La correlación entre las imágenes maestra y esclava en un interferograma, comúnmente cuantificada como coherencia, representa una métrica fundamental para evaluar la calidad y fiabilidad de la señal de fase interferométrica, en el caso de la zona estudiada se encuentran en algunas zonas correlaciones altas que pueden ser inferidas por las pendientes tan pronunciadas en la zona de estudio, según lo encontrado en el apartado de las pendientes calculadas en Fase III, del desarrollo del proyecto. .

Tabla 6. Interferogramas calculados para el proceso de entrenamiento.

Periodo	Interferograma (Escala 1:150.000)	Movimiento en desplazamiento medido en milímetros (Fallas de la zona de pueden visualizar en gris)
<u>Sismo</u> <u>10/03/2015</u> Imagen Master: 07/02/2015 Imagen Slove: 15/03/2015		<VALUE> -0,01802385 - 0,015 0,015 - 0,03 0,03 - 0,045 0,045 - 0,06 0,06 - 0,075 0,075 - 0,09 0,09 - 0,115

Periodo	Interferograma (Escala 1:150.000)	Movimiento en desplazamiento medido en milímetros (Fallas de la zona de pueden visualizar en gris)
<u>Sismo</u> <u>30/10/2016</u> Imagen Master: 07/02/2015 Imagen Slave: 15/03/2015		<VALUE> -0,084908269 - -0,042 -0,042 - -0,03 -0,03 - -0,024 -0,024 - -0,019 -0,019 - -0,0145 -0,0145 - -0,004 -0,004 - 0,036
<u>Sismo</u> <u>15/04/2020</u> Imagen Master: 11/04/2020 Imagen Slave: 23/04/2020		<VALUE> -3,144 - -1,98 -1,98 - -0,82 -0,82 - -0,037 -0,037 - 0,63 0,63 - 1,34 1,34 - 2,16 2,16 - 3,14

Periodo	Interferograma (Escala 1:150.000)	Movimiento en desplazamiento medido en milímetros (Fallas de la zona de pueden visualizar en gris)
<u>Sismo</u> <u>17/08/2023</u> Imagen Master: 12/08/2023 Imagen Slave: 24/08/2023		<VALUE> -3,14 - -2,3 -2,30 - -1,45 -1,49 - -0,65 -0,65 - 0,28 0,28 - 1,31 1,31 - 2,27 2,2 - 3,141

Fuente: Elaboración propia, 2026.



9.3 FASE 3: ANÁLISIS DE FACTORES DE INESTABILIDAD

En esta fase se definieron las variables relevantes del proceso, esto fundamentado en el marco teórico y estado del arte, junto con la revisión de disponibilidad de insumos las variables adicionales a utilizar en el entrenamiento, las variables se pueden ver en la Tabla 7.

Tabla 7. Tabla de variables utilizadas en la investigación.

VARIABLES	PERIODO 2015	PERIODO 2016	PERIODO 2020	PERIODO 2023	OTROS PERIODOS
INTERFEROGRAMA	Variable 1	Variable 2	Variable 3	Variable 4	
INDICE NDVI	Variable 5	Variable 6	Variable 7	Variable 8	
COBERTURA DE LA TIERRA	Variable 9	Variable 10	Variable 11	Variable 12	
ISOTERMAS	Variable 13	Variable 14	Variable 15	Variable 16	
ISOYETAS	Variable 17	Variable 18	Variable 19	Variable 20	
DEM	Variable 21	Variable 22	Variable 23	Variable 24	
PENDIENTE	Variable 25	Variable 26	Variable 27	Variable 28	
ACELERACIÓN PICO DEL TERRENO (PGA)					2020 PGA 2,745 años Variable 29
ACELERACIÓN PICO DEL TERRENO (PGA)					2020 PGA 975 años Variable 30
ACELERACIÓN PICO DEL TERRENO (PGA)					2020 PGA 475 años Variable 31
ACELERACIÓN PICO DEL TERRENO (PGA)					2020 PGA 225 años Variable 32
FALLAS					2022 Variable 33
MOVIMIENTOS EN MASA REPORTADOS					2022 Variable 34
INTENSIDAD MÁXIMA OBSERVADA					2022 Variable 35

VARIABLES	PERIODO 2015	PERIODO 2016	PERIODO 2020	PERIODO 2023	OTROS PERIODOS
INTENSIDA MAXIMA ESPERADA					2022 Variable 36
AMENAZA DE SISTIMO					2022 Variable 37
SUELOS DEL IGAC DEPARTAMENTAL					2024 Variable 38.

Fuente: Elaboración Propia, 2026.

9.3.1 Fallas geológicas

Estudios geomorfológicos y sismo tectónicos previos muestran que la actividad relativa de estas estructuras mayores ha contribuido a la redistribución de esfuerzos cortantes y a la modificación del régimen de pendientes locales, favoreciendo la inestabilización de colinas y taludes. En consecuencia, las fallas sin nombre que afectan directamente al área municipal pueden considerarse elementos estructurales secundarios que actúan como coronas de debilidad: facilitan la concentración de tensiones, controlan la aparición de planos de deslizamiento y condicionan la permeabilidad y el drenaje subterráneo, factor determinante en los procesos de saturación y pérdida de cohesión del material superficial. Desde una perspectiva mecanicista, la interacción entre la tectónica local y la climatología (precipitaciones intensas y estacionales) amplifica la probabilidad de fallas superficiales y movimientos en masa por reducción de la resistencia efectiva del suelo y por la generación de sobrepresiones intersticiales. Por tanto, la evaluación del riesgo geodinámico en Cáqueza requiere (Moradi et al., 2019): (i) cartografía detallada de las fracturas y su continuidad hacia las estructuras regionales, (ii) caracterización geotécnica de perfiles de suelo y coluviones, (iii) monitoreo de la respuesta hidrológica y tensional ante eventos pluviométricos extremos, y (iv) modelado numérico acoplado que incorpore la evolución de esfuerzos y la variación de la presión de poros para estimar umbrales de inestabilidad. Integrar estos datos con información histórica de deslizamientos y con registros sísmicos permitirá cuantificar la contribución relativa de las fallas locales y regionales al fenómeno de remoción en masa y orientar medidas de mitigación y planificación territorial basadas en evidencia.







Figura 11. Fallas en el municipio de Cáqueza, SGC.2020.
Fuente: Elaboración Propia, 2026.


9.3.2 Sismología

Para completar las variables de sismología se tomaron los siguientes datos del SGC calculados en el 2020.

- La **Aceleración Pico del Terreno (PGA)** se define como el valor máximo de la amplitud de la aceleración horizontal registrado en un acelerograma durante un evento sísmico en un sitio específico. Este parámetro cinemático es fundamental en la ingeniería sismorresistente, ya que cuantifica la intensidad del movimiento fuerte del suelo y se correlaciona directamente con las fuerzas inerciales a las que se somete una estructura. En el contexto de la normativa colombiana y el **Modelo Nacional de Amenaza Sísmica (2020)**, el PGA se estima mediante **Leyes de Atenuación o GMMs** (Ground Motion Models), permitiendo caracterizar la peligrosidad sísmica regional para diferentes periodos de retorno, desde niveles de servicio (31 años) hasta eventos extremos de diseño (2.475 años).

Tabla 8. Imágenes de PGA.

Nivel de servicio en años	Resultado (imágenes a escala:1:150.000)	Utilidad
2.475		probabilidad de excedencia del 2% en 50 años. Es un sismo de muy baja probabilidad pero de consecuencias potencialmente catastróficas: • Aislamiento Sísmico. • Infraestructura Crítica Especial. • Diseño Basado en Desempeño. Nivel de amenaza: máximo
975		probabilidad de excedencia del 5% en 50 años. Es un nivel de exigencia mayor al estándar de 475 años (10% en 50 años) y se usa para infraestructuras críticas. • Infraestructura de Transporte • Edificaciones Indispensables • Aislamiento Sísmico Nivel de amenaza: Sismo de seguridad
475		probabilidad del 10% de ser excedido en un lapso de 50 años. Es el nivel de amenaza base utilizado en la normativa para el diseño de viviendas, oficinas y comercio: • Seguridad de Vida • Diseño de edificaciones comunes

Nivel de servicio en años	Resultado (imágenes a escala:1:150.000)	Utilidad
		Nivel de amenaza: Sismo de diseño probabilidad de excedencia del 20%.
225		Esto lo clasifica como un Sismo Ocasional: - Evaluación de Daño Controlado - Continuidad de operaciones - Análisis de vulnerabilidad Nivel de amenaza: Sismo Ocasional

Fuente: SGC,2020




Figura 12. Amenaza de sísmica esperada a partir de estudios del SGC 2022.
Fuente: (Sarabia Gómez et al., 2022)




Figura 13. Amenaza de sísmica observada a partir de estudios del SGC 2022.
Fuente: (Sarabia Gómez et al., 2022).




Figura 14. Amenaza de sismo.

Fuente: (Sarabia Gómez et al., 2022)

9.3.3 Movimientos en masa

La información disponible encontrada y postprocesada de los movimientos en masa, que serían en este caso la variable que se pretende explicar en el modelo de predicción, corresponde a información extraída de los estudios más recientes de la zona del SGC,2022.




Figura 15. Inventario movimientos en masa municipio de Cáqueza. Fuente: SGC (2022)





Figura 16. Amenaza de Remoción en masa, escala 100k. Fuente: SGC (2022)



9.3.4 Relieve

El relieve se define como la distribución espacial de elevaciones y sus derivadas geométricas en la superficie terrestre y se caracteriza cuantitativamente a partir de Modelos Digitales de Elevación (DEM), cuya elección y preprocesado determinan la calidad del análisis, para este apartado se muestran los datos utilizados los DEM fueron calculados en el marco de la investigación como resultado del postprocesamiento DInSAR, y las pendientes respectivas se calcularon a partir de los mismos dichas pendientes se calcularon el valor de porcentaje:

Rango de Pendiente (%) Denominación, según Planes de Ordenamiento Territorial (POT) bajo el Decreto 1077 de 2015.

- **0% - 1%** Nivel o plano
- **1% - 3%** Ligeramente plano
- **3% - 7%** Ligeramente ondulado
- **7% - 12%** Ondulado
- **12% - 25%** Fuertemente ondulado
- **25% - 50%** Fuertemente inclinado / Escarpado
- **> 50%** Muy escarpado / Montañoso

Una vez se cumple con el desenrollado de la fase y se aplica el ajuste topográfico en el postproceso en la metodología DInSAR, se calcula el Modelo de Elevación, en la Figura 17 se puede identificar el resultado del postproceso del cálculo de elevación. .

MODELO DE PREDICCIÓN DE PROCESOS DE REMOCIÓN EN MASA, PARA EL MUNICIPIO DE CAQUEZA CUNDINAMARCA, USANDO IMÁGENES DE RADAR QUE PERMITAN METODO DInSAR







Figura 17. Postproceso de cálculo de DEM, para las 3 épocas, imagen ejemplo 2015.
Fuente: Elaboración propia.

Tabla 9. Modelos digitales de terreno de las 4 épocas seleccionadas.

Periodo	DEM (Escala 1:150.000)	Altura en m
Sismo 10/03/2015		High : 3548,33 Low : 0


Periodo	DEM (Escala 1:150.000)	Altura en m
Periodo 2 Sismo 30/10/2016		Value High : 3548,46 Low : 1311,6
Periodo 3 Sismo 15/04/2020		Value High : 3549,69 Low : 1315,74






Fuente: Elaboración Propia,2026.

A partir de los DEM calculado para cada una de las fechas de estudio Tabla 9, se calculó la pendiente Tabla 10, se pueden observar dichas pendientes calculadas.

Tabla 10. Pendientes calculadoras a partir del modelo digital de terreno.



Periodo	Pendiente	Pendiente representada en %
Periodo 2 Sismo 30/10/201 6		Value 0% - 1% Nivel o plano 1% - 3% Ligeramente plano 3% - 7% Ligeramente ondulado 7% - 12% Ondulado 12% - 25% Fuertemente ondulado 25% - 50% Fuertemente inclinado / Escarpado > 50% Muy escarpado / Montañoso
Periodo 3 Sismo 15/04/202 0		Value 0% - 1% Nivel o plano 1% - 3% Ligeramente plano 3% - 7% Ligeramente ondulado 7% - 12% Ondulado 12% - 25% Fuertemente ondulado 25% - 50% Fuertemente inclinado / Escarpado > 50% Muy escarpado / Montañoso
Periodo 4 Sismo 17/08/202 3		Value 0% - 1% Nivel o plano 1% - 3% Ligeramente plano 3% - 7% Ligeramente ondulado 7% - 12% Ondulado 12% - 25% Fuertemente ondulado 25% - 50% Fuertemente inclinado / Escarpado > 50% Muy escarpado / Montañoso

Fuente: Elaboración Propia, 2026

9.3.5 histórico Isoyetas e Isotermas

Para calcular isoyetas e isotermas se procesaron los archivos ráster. En el caso de las **isoyetas**, se utilizan los datos de precipitación acumulada del producto **CHIRPS (UCSB-CHG)**:

El sistema CHIRPS (Climate Hazards Center InfraRed Precipitation with Station data) es un conjunto de datos de precipitación cuasi-global de más de 30 años. CHIRPS incorpora imágenes satelitales con una resolución de 0,05° y datos de estaciones meteorológicas para crear series temporales de precipitación en cuadrícula, útiles para el análisis de tendencias y el monitoreo de sequías estacionales (Funk et al., 2015).

Se extrajo el corte y se calcularon las isoyetas con ayuda de Google engine code mediante el siguiente código, para cada uno de los 4 años se utilizó realizando el filtro de fecha correspondiente:

```
// 1. Cargar colección de precipitación (CHIRPS)
var precip = ee.ImageCollection("UCSB-CHG/CHIRPS/DAILY")
    .filterDate('2016-01-01', '2016-12-31')
    .select('precipitation')
    .filterBounds(geometry);

// 2. Calcular la precipitación TOTAL anual (suma de lluvia)
var lluviaTotal = precip.sum().clip(geometry);

// 3. Crear niveles cada 100mm
var intervalo = 100;
var zonasLluvia = lluviaTotal.divide(intervalo).floor().multiply(intervalo)
    .toInt()
    .rename('precip_val');

// 4. Convertir a vectores
var isoyetas = zonasLluvia.reduceToVectors({
    geometry: geometry,
    scale: 5000, // CHIRPS tiene ~5km de resolución
    geometryType: 'polygon',
    labelProperty: 'lluvia_mm',
    eightConnected: true
});

// 5. Visualizar Ráster de Lluvia
var visLluvia = {min: 500, max: 3000, palette: ['white', 'lightblue', 'blue', 'darkblue']};
Map.addLayer(lluviaTotal, visLluvia, 'Precipitación Total');

// 6. Visualizar Isoyetas (solo bordes)
var lineasIsoyetas = ee.Image().paint(isoyetas, 0, 1);
Map.addLayer(lineasIsoyetas, {palette: ['000000']}, 'Líneas Isoyetas');

// 7. Exportar la IMAGEN (Ráster GeoTIFF)
Export.image.toDrive({
    image: lluviaTotal,
    description: 'Isoyetas_Raster_2016',
    scale: 5000,
    region: geometry,
```




Figura 18. Cálculo de Isoyetas mediante Google engine Code.
Fuente: Elaboración propia, en GEE.

Para las **isotermas**, se emplearon las bandas de temperatura de la superficie terrestre (**LST**) del sensor **MODIS**.

La selección del sensor **MODIS** sobre **Landsat 8** para la extracción de isotermas se justifica desde una perspectiva metodológica debido a su **alta resolución temporal diaria**. Dado que los factores detonantes de movimientos en masa (como las precipitaciones dinámicas) operan en escalas de tiempo cortas, los intervalos de 16 días de Landsat resultan insuficientes para capturar las variaciones del balance hidrológico superficial. Asimismo, el uso de productos compuestos de MODIS mitiga la pérdida de información por alta cobertura de nubes, suministrando un flujo constante de tensores térmicos aptos para el entrenamiento continuo de la red neuronal.

Para el caso de Isotermas también se trabajó con código disponible para descarga por Google engine.

/ Paso 1: Definir la fecha y zona

```
var fecha_inicio = '2025-01-01';
var fecha_fin = '2025-12-31';

// Paso 2: Cargar la colección MODIS LST (Temperatura superficial)
var modis = ee.ImageCollection("MODIS/061/MOD11A1")
    .filterDate(fecha_inicio, fecha_fin)
    .select('LST_Day_1km') // Seleccionar banda de temperatura diurna
    .filterBounds(geometry);

// Paso 3: Calcular el promedio anual y convertir a Celsius
var tempPromedio = modis.mean().clip(geometry);
var tempCelsius = tempPromedio.multiply(0.02).subtract(273.15); // Factor de escala MODIS

// Paso 4: Visualizar la imagen de temperatura
var visParams = {
    min: 10, max: 35,
    palette: ['blue', 'yellow', 'red']
};
Map.addLayer(tempCelsius, visParams, 'Temperatura Celsius');
Map.centerObject(geometry, 6);

// Paso 5: Generar isotermas cada 2 grados (CORRECCIÓN DEFINITIVA)
var isotermas = tempCelsius.divide(2).floor().multiply(2)
    .toInt()
    .rename('temp') // Nombrar la banda ayuda a evitar errores
    .reduceToVectors({
        geometry: geometry,
        scale: 1000,
        geometryType: 'polygon',
        labelProperty: 'temp',
        eightConnected: true,
        // NO incluir la propiedad 'reducer' aquí para que no pida más bandas
    });

// Paso 6: Visualizar las isotermas
Map.addLayer(isotermas, {palette: ['black']}, 'Isotermas');

// Paso 7: Exportar a Google Drive
Export.table.toDrive({
    collection: isotermas,
    description: 'Isotermas_2025',
    fileFormat: 'SHP'
});
// Exportar la imagen de temperatura a Google Drive
Export.image.toDrive({
    image: tempCelsius,
    description: 'Temperatura_Celsius_2025',
    scale: 1000, // Resolución de MODIS (1km)
    region: geometry,
    fileFormat: 'GeoTIFF',
    crs: 'EPSG:4326', // Coordenadas geográficas estándar
    maxPixels: 1e13
});
```





Figura 19. Cálculo de Isotermas mediante Google engine Code.
Fuente: Elaboración propia, en GEE.

Aunque la resolución espacial de las Isotherma e Isoyetas no es la indicada de 40 m *40 m, si no inferior, dichas imágenes se Re muestrearon a este tamaño de pixel, no es lo adecuado pero por disponibilidad de información en los 4 periodos se definió dentro de la investigación Re muestrear el tamaño del pixel para coincidir, con la escala de trabajo, en la Tabla 11, se pueden revisar los resultados para los 4 periodos de estudio.

Tabla 11. Isoyetas e Isotermas calculadas para el estudio .

Periodo	Isoyetas (Escala 1:150.000)	Isotermas(Escala 1:150.000)
2015		



Fuente Elaboración Propia, 2026

9.3.6 Cobertura y uso

Las imágenes que se utilizaron para el proceso de clasificación de coberturas corresponden a Landsat 8/Imágenes 2015 y 2016), y Sentinel 2A (2020 y 2023), las imágenes Landsat 8 tienen un tamaño de pixel de 30 m, en su resolución espacial, mientras que las imágenes Sentinel 2A tienen una resolución espacial de 10 m, para el proceso de clasificación de coberturas, se trabajaron con estas resoluciones espaciales pero al entrenar el modelo se remuestrearon, como se menciona a lo largo de la investigación a 40 .

La literatura reciente destaca que la integración de ambos sistemas no es directa debido a las diferencias en las **Funciones de Respuesta Espectral (SRF)**. Estudios de armonización, como los desarrollados para el producto *Harmonized Landsat Sentinel-2 (HLS)* de la NASA, subrayan que, aunque las bandas visibles guardan una alta correlación, existe un sesgo sistemático donde las reflectancias de Sentinel-2 tienden a ser ligeramente superiores en la banda del infrarrojo cercano (NIR) y el rojo, lo que requiere la aplicación de **funciones de transformación de paso de banda (bandas adjustment)** para evitar artefactos en el cálculo de índices biofísicos como el NDVI (Claverie et al., 2018).

Un aspecto diferenciador fundamental es la configuración del borde rojo (*red-edge*) presente en Sentinel-2 (bandas B5, B6, B7), la cual, al combinarse con las capacidades de infrarrojo térmico (TIRS) de Landsat 8, permite un desglose multivariado de la salud del dosel vegetal y el estrés hídrico. Según investigaciones actuales en *Remote Sensing of Environment*, la fusión de estos datos mediante algoritmos de aprendizaje profundo, como las **Redes Neuronales Convolucionales (CNN)**, ha permitido alcanzar precisiones superiores al 92% en el mapeo de tipos de cultivos específicos, superando las limitaciones individuales de cada sensor en términos de resolución temporal y espectral (Runge et al., 2022). Esta convergencia técnica no solo mejora la resolución de la "brecha de nubes" gracias a una frecuencia de revisita combinada de ~2.9 días, sino que establece una base sólida para el análisis de series temporales densas orientadas al estudio del cambio de uso de suelo a escala submétrica.

Las imágenes dispuestas para esta investigación se descargaron mediante la plataforma Google engine code, ya que permite un proceso más rápido, deja cortar y hacer la unión de capas en un solo proceso a continuación se describe el código de descarga para uno de los dos sensores pero aplica de la misma forma.

```
var landsatCollection = ee.ImageCollection('LANDSAT/LC08/C02/T1')  
  .filterDate('2016-01-01', '2016-12-30')  
  .filter(ee.Filter.Lte('CLOUD_COVER',50))  
  .filterBounds(roi);  
// Make a cloud-free composite.
```

```
var first_s2=landsatCollection.mean().clip(roi);

var composite = ee.Algorithms.Landsat.simpleComposite({
  collection: landsatCollection,
  asFloat: true
});

// Clip composite to aoi
var clipped_composite = composite.clip(roi);

// Visualize the Composite using different spectral band combinations to help you identify object
Map.addLayer(clipped_composite, {bands: ['B5', 'B4', 'B3'], max: 0.5, gamma: 2}, 'Natural color',
true);

// Center map on the clipped composite

Map.centerObject(roi,10);

// EXPORT IMAGE TO GOOGLE DRIVE

Export.image.toDrive({
  image:clipped_composite.toFloat(),
  description: 'Landsan_image_20161',
  folder:"Landsat collections",
  scale:10,
  region: roi,
  maxPixels:1E13,
  fileFormat:"TIFF",
  formatOptions: {
    cloudOptimized: true}
});
```




Figura 20. Imagen Mosaico mejor pixel 2016 Landsat 8 utilizada para clasificación de coberturas.

Fuente: Google engine, 2026.
RGB543




Figura 21. Imagen Mosaico mejor pixel 2015 Landsat 8 utilizada para clasificación de coberturas.

Fuente: Google engine, 2026.
RGB543




Figura 22. Imagen Mosaico mejor pixel 2020 Sentinel utilizada para clasificación de coberturas.

Fuente: Google engine, 2026.
RGB843




Figura 23. Imagen Mosaico
mejor pixel 2023 Sentinel
utilizada para clasificación de
coberturas.

Fuente: Google engine, 2026.
RGB843

Posteriormente para las imágenes descargadas se realizó el cálculo del índice NVDI, para poder tomarlo de base en la clasificación de coberturas, y como variable directa del modelo de predicción, ya que este permite como se ve en las Figura 24, Figura 25, Figura 26y Figura 27, los valores obtenidos, en todo el postproceso de la imagen del 2020, vamos a ver en la esquina superior izquierda un error esto se debe a que al buscar el mejor pixel de la zona para ese no se identificó áreas sin nubosidad.





Figura 24. Índice NVDI 2015
Fuente: Elaboración propia, 2026.





Figura 25. Índice NVDI 2016.
Fuente: Elaboración propia, 2026.





Figura 26. Índice NVDI 2020.
Fuente: Elaboración propia, 2026.





Figura 27. Índice NVDI 2023
Fuente: Elaboración propia, 2026.

Por ello al realizar diferentes pruebas con las imágenes que se trabajaron se optó en esta investigación por trabajar con Máquina de vectores de Soporte para realizar la clasificación supervisada de imágenes lo que permitió ir entrenando el modelo y las clases a medida que se tomaban las muestras de las coberturas trabajadas, lo anterior se tomó a partir de los resultados del entrenamiento con clases en las clasificaciones coberturas realizadas, donde también se pudo identificar que hay mejores resultados con el mismo algoritmo y muestras en ARCGIS pro que en Google engine code.




Figura 28. Cálculo de coberturas en Google engine con método de regiones simples.

Fuente: Elaboración propia,2026




Figura 29. Cálculo de coberturas en ArcGIS pro con máquina de soportes vectoriales, la leyenda aplica para la figura anterior.

Fuente: Elaboración propia,2026

En la Figura 28 y Figura 29 se pueden observar los resultados, la coincidencia y veracidad se revisa con coberturas disponibles de 2014, por el IDEM, encontrando que los procesos con máquina de vectores alcanzaron una eficiencia en comparación con la línea base de 89%, mientras que otros algoritmos y otro software, disminuyó al 75%, por ende se tomó la decisión de calcular y entrenar el modelo de clasificación de coberturas mediante la herramienta Image Classification Wizard.

```
// Búsqueda de imágenes y clasificación coberturas en Google engine  
  
var collections = ee.ImageCollection('LANDSAT/LC08/C02/T2_TOA')  
    .filterDate("2020-01-01", "2020-12-01")  
    .filter(ee.Filter.Lte('CLOUDY_PIXEL_PERCENTAGE',9))  
    .filterBounds(AOI2)  
    .mosaic();  
  
print (collections);  
  
var LandCor = collections.clip(AOI2);  
  
//Imagen resultante  
var LandDis = {  
    min:0,  
    max:1500,
```

```
bands:['B4','B3','B2'],};
Map.addLayer(LandCor,LandDis,"Imagen_Landsat_2015");

var Paleta = {color: 'black', fillColor: '#ffffff00'};
Map.addLayer(AOI2.style(Paleta),null,'Limite');
Map.centerObject(AOI2,11)

// reporte tabular

var superficie = AOI2.geometry();
var areazona = superficie.area().divide(10000);
print('La superficie total es: ', areazona.format('%.2f'), ' ha');

//Coleccion de puntos de muestreo

throw("stop");

var clases =
tejido_urbano.merge(Cuerpos_Agua).merge(Bosque).merge(Nubes).merge(Sombras).merge(Tierra_
degradada).merge(Material_Rocoso).merge(Cultivos).merge(Vegtacion_Secundaria).merge(Pasto
s).merge(Suelos_Desnudos);
print(clases);
var Bandas =['B2','B3','B4']
var muestreos = LandCor.select(Bandas).sampleRegions({
  collection:clases,
  properties: ['Sentinel_cober'],
  scale:50,});

print(muestreos);

var clasup = ee.Classifier.smileCart().train({
  features: muestreos,
  classProperty:'Sentinel_cober',
  inputProperties: Bandas,});

var Cobertura = LandCor.select(Bandas).classify(clasup);

Map.addLayer(Cobertura,{min:0,max:10,palette:['#006400', // 1. Bosque denso
'#228B22', // 2. Bosque disperso
'#00FF00', // 3. Matorral
'#FFD700', // 4. Pastizal
'#FF7F50', // 5. Agricultura
'#DC143C', // 6. Suelo desnudo
'#0000FF', // 7. Agua
'#87CEFA', // 8. Humedal
'#808080', // 9. Área urbana
'#D3D3D3', // 10. Nubes/Nieve
'#FFFFFF' // 11. Otros/Sombra
]},'Clasificacion');

Export.image.toDrive({
  image:Cobertura.toFloat(),
  description: 'Cobertura_2020',
  folder:"Clasificacion",
```

```
scale:10,  
region: AOI2,  
maxPixels:1E13,  
fileFormat:"TIFF",  
formatOptions: {  
  cloudOptimized: true}  
});
```

Las coberturas que se definieron trabajar corresponden a coberturas tomadas de Corin Land Cover adaptadas para la zona de estudio como se ven en la **¡Error! No se encuentra el origen de la referencia..** El software utilizado para esta tarea fue ArcGIS Pro, y este implementa esta tecnología permitiendo el uso de funciones **Kernel** (principalmente el Kernel de Función de Base Radial - RBF), lo que facilita la transposición de datos no lineales a dimensiones superiores donde la separación de coberturas (como tipos específicos de cultivos o densidades forestales) resulta matemáticamente posible (Maxwell et al., 2018).

Se pudo corroborar que la implementación en ArcGIS Pro no se limita a la respuesta espectral pura, sino que integra un análisis multidimensional:

- **Enriquecimiento del Espacio de Características:** Además de las bandas originales, el clasificador SVM en ArcGIS Pro se beneficia de la integración de índices de vegetación (NDVI, EVI).
- **Entrenamiento y Parametrización:** A través de la herramienta *Train Support Vector Machine Classifier*, el software permite ajustar parámetros críticos como el **C (parámetro de penalización)**, que equilibra la clasificación errónea de muestras de entrenamiento frente a la maximización del margen, evitando el *overfitting*.
- **Segmentación :** Para resultados de alta resolución, la SVM se suele aplicar sobre **objetos segmentados** en lugar de píxeles individuales. Esto reduce el efecto "sal y pimienta" y mejora la precisión en entornos urbanos y agrícolas complejos (Ma et al., 2017).




Figura 30. Proceso de entrenamiento con esquemas de clasificación en ArcGIS pro.

Fuente: Elaboración propia, 2026

En la Figura 30, se puede observar el mecanismo de entrenamiento los resultados para este caso resultaron favorables, toda vez que al realizar la primera clasificación y firmas, se garantizó la disminución de tiempo ya que con esas firmas entrenadas se tomaron como base para las clasificaciones de 2016, 2020 y 2023, lo que nos ahorró tiempos en nuevas capturas de firmas para cada periodo, el resultado del proceso de clasificación de coberturas se pueden ver en la Figura 31, Figura 32, Figura 33 y Figura 34.




Figura 31. Clasificación de coberturas 2015.

Fuente: Elaboración propia, 2026

Color	Upper value	Label
	≤ 1,0	Tejido Urbano
	≤ 2,0	Cuerpos de Agua
	≤ 3,0	Bosque
	≤ 4,0	Nube
	≤ 5,0	Sombras
	≤ 6,0	Tierra degradada
	≤ 7,0	Material Rocoso
	≤ 8,0	Cultivos
	≤ 9,0	Vegetacion Secundaria
	≤ 10,0	Pastos
	≤ 11,0	Suelos desnudos




Figura 32. Clasificación de coberturas 2016.

Fuente: Elaboración propia.

Color	Upper value	Label
	≤ 1,0	Tejido Urbano
	≤ 2,0	Cuerpos de Agua
	≤ 3,0	Bosque
	≤ 4,0	Nube
	≤ 5,0	Sombras
	≤ 6,0	Tierra degradada
	≤ 7,0	Material Rocoso
	≤ 8,0	Cultivos
	≤ 9,0	Vegetacion Secundaria
	≤ 10,0	Pastos
	≤ 11,0	Suelos desnudos




Figura 33. Clasificación de coberturas 2020.

Fuente: Elaboración propia, 2026.

Color	Upper value	Label
	≤ 1,0	Tejido Urbano
	≤ 2,0	Cuerpos de Agua
	≤ 3,0	Bosque
	≤ 4,0	Nube
	≤ 5,0	Sombras
	≤ 6,0	Tierra degradada
	≤ 7,0	Material Rocoso
	≤ 8,0	Cultivos
	≤ 9,0	Vegetación Secundaria
	≤ 10,0	Pastos
	≤ 11,0	Suelos desnudos




Figura 34. Clasificación de coberturas 2023.

Fuente: Elaboración propia .

Color	Upper value	Label
	≤ 1,0	Tejido Urbano
	≤ 2,0	Cuerpos de Agua
	≤ 3,0	Bosque
	≤ 4,0	Nube
	≤ 5,0	Sombras
	≤ 6,0	Tierra degradada
	≤ 7,0	Material Rocoso
	≤ 8,0	Cultivos
	≤ 9,0	Vegetación Secundaria
	≤ 10,0	Pastos
	≤ 11,0	Suelos desnudos

9.4 FASE 4: ESTRUCTURACIÓN DEL MODELO DE PREDICCIÓN

La creación de un modelo predictivo que integre interferogramas, aceleración pico de terreno (PGA), mapas de amenazas sísmicas y de remoción en masa, Modelos Digitales de Terreno (MDT), pendientes, isoyetas, isotermas, NDVI y clasificaciones de cobertura, requiere la aplicación de técnicas de aprendizaje automático (Machine Learning) disponibles en ArcGIS Pro, las variables utilizadas se pueden encontrar en la Tabla 7.

El objetivo es identificar patrones complejos entre estas variables predictoras y una **variable dependiente o de interés**, en nuestro caso es amenaza por remoción en masa.

Al final de los procesos se trabajaron con 38 capas de información para ayudar a predecir tomando como base 4 años diferentes según los datos base utilizados:

- 2015
- 2016
- 2020
- 2023

Estos 4 periodos se trabajaron para las capas de información, según lo disponible y explicado de la Fase II de la investigación. :

- Interferograma (Insumo primario, calculado para la investigación)
- **Aceleración Pico de Terreno (PGA)** (Insumo secundario, tomado del Servicio Geológico colombiano calculado para 2020)
- **Modelo digital de terreno** (Insumo primario, calculado para la investigación)
- **Pendiente** (Insumo primario, calculado para la investigación)
- **Isoyetas** (Insumo primario, calculado para la investigación)
- **Isotermas** (Insumo primario, calculado para la investigación)
- **NDVI** (Insumo primario, calculado para la investigación)
- **Coberturas** (Insumo primario, calculado para la investigación)

Se utilizaron dos variables contantes que solo se tenían para un año específico insumos secundarios:

- Intensidad máxima observada de posible remoción en masa (Insumo secundario, tomado del Servicio Geológico colombiano calculado para 2020)
- Intensidad Sísmica esperada (Insumo secundario, tomado del Servicio Geológico colombiano calculado para 2020)
- Variable de amanezca de remoción en masa, insumo secundario escala 1:100.000 del servicio geológico calculado para el 2022

1. **Selección y Entrenamiento del Modelo en ArcGIS Pro:** ArcGIS Pro ofrece diversas herramientas de aprendizaje automático en su *Spatial Analyst toolbox* o a través de la integración con librerías de Python (ArcPy, scikit-learn), para el desarrollo del proyecto se realizó un tool, a partir de lenguaje Arcpy, para desarrollar el entrenamiento, en el anexo 6 del modelo se verá discriminado el modelo de regresión desarrollado.

Desde la investigación se vio eficiente crear un tool completo en arcgis que entregara el modelo entrenado




Figura 35. Tool resultante del desarrollo en Arcpy, revive las 38 variables mencionadas, junto con los datos de puntos de muestra.

Fuente: Elaboración propia, 2026.

En tool que se muestra en la Figura 35, se entregará como resultado de la investigación, esto permitirá entrenar modelos a nivel pis, incluso se puede modificar para recibir variables adicionales, como monitoreos en terreno, a continuación se muestra la explicación del código desarrollado que se aplica:

- **Herramientas para Regresión:** Train Random Trees Regression Model, Train Geographically Weighted Regression, Train Support Vector Machine Regression.

La elección del algoritmo dependerá de la naturaleza de la variable dependiente y las características de los datos. Por ejemplo, los **Random Forests** (bosques aleatorios) o **Support Vector Machines (SVM)** son robustos para datos complejos y no lineales, con menor riesgo de sobreajuste (Mountrakis et al., 2011) Durante el entrenamiento, el algoritmo aprenderá las relaciones entre las variables predictoras y la variable dependiente a partir del conjunto de entrenamiento, en el caso del proyecto se utilizó Random Forests, aunque para el proceso de coberturas es más eficiente la máquina de soportes vectoriales como se mencionó en el apartado de Fase III, se logró identificar en los resultados del entrenamiento y literatura que los entrenamientos, entre máquinas de soporte vectorial y Bosques aleatorios en proceso de regresión, tiene mejores resultados los bosques aleatorio, esto se puede observar en la gráfica Figura 39y Figura 40, en métricas la precisión del cálculo en SVM corresponden a 65 %, mientras que para Bosques aleatorios están por encima del 85 %.

Tras la evaluación comparativa de las herramientas de regresión lineal y no lineal (*Train Random Trees Regression Model*, *Train Geographically Weighted Regression* y *Train Support Vector Machine Regression*), se determinó que el algoritmo de Bosques Aleatorios (*Random Forests*) exhibió el desempeño predictivo óptimo para el conjunto de variables estructuradas en este estudio. La selección de este modelo se fundamentó en su capacidad intrínseca para procesar interacciones multidimensionales y relaciones no lineales complejas sin incurrir en el sesgo de sobreajuste (*overfitting*), factores críticos dada la heterogeneidad de los datos analizados. Durante la fase de entrenamiento, el algoritmo parametrizó de manera iterativa las correlaciones subyacentes entre las variables predictoras y la variable dependiente. Los resultados empíricos confirmaron que esta arquitectura algorítmica superó las limitaciones de los enfoques basados en regresiones espaciales locales de **Random Forests** (bosques aleatorios) ver en la figura Figura 40 y Figura 42, consolidándose como la herramienta metodológica más robusta para garantizar la estabilidad y precisión de las proyecciones ejecutada.

A continuación se describe el código diseñado el cual se puede ver en el anexo 6.

```
import arcpy
import datetime
import os
from arcpy.sa import CompositeBand, ExtractMultiValuesToPoints, Slope # Spatial Analyst tools
from arcpy.sa import *
from arcpy.ia import * # Importante para herramientas de análisis de imagen
import arcgis.learn # Carga explícita del módulo de Machine Learning
import arcpy.ia
arcpy.env.overwriteOutput = True
start = datetime.datetime.today()
arcpy.AddMessage(f"Inicio del script: {start}")
arcpy.AddMessage("Obteniendo parámetros de entrada y preparando variables...")

# --- 1. Obtener parámetros de entrada ---
# Los parámetros se obtienen como texto. Asegúrate de que los índices son correctos.
# Carpeta de salida para la GDB y otros archivos. Este debe ser un directorio.
# (Parámetro 39)

carpeta_salida = arcpy.GetParameterAsText(38)
if not carpeta_salida:
    arcpy.AddError("La carpeta de salida no ha sido especificada (Parámetro 39). El script terminará.")
    exit()
if not os.path.isdir(carpeta_salida):
    arcpy.AddError(f"La ruta '{carpeta_salida}' no es un directorio válido o no existe. El script terminará.")
    exit()

# Rásteres predictores (Parámetros 0 a 37)
```

Se recopilan todas las rutas de los parámetros de entrada que corresponden a rásteres.

```
predictor_input_params = []
```

Ajusta este rango si tienes más o menos parámetros de ráster

```
for i in range(38): # Parámetros 0 a 37 (total 38 rásteres)
```

```
    param_value = arcpy.GetParameterAsText(i)
```

```
    if param_value: # Solo añadir si el parámetro no está vacío
```

```
        predictor_input_params.append(param_value)
```

Archivo de puntos de entrenamiento (Feature Class) (Parámetro 40)

```
training_points_fc = arcpy.GetParameterAsText(39)
```

```
if not arcpy.Exists(training_points_fc):
```

```
    arcpy.AddError(f"El Feature Class de puntos de entrenamiento '{training_points_fc}' no existe  
(Parámetro 40). El script terminará.")
```

```
    exit()
```

**# Nombre del campo objetivo en los puntos de entrenamiento (ej. "RISK_CLASS",
"DEFORMACION") (Parámetro 41)**

```
target_field = arcpy.GetParameterAsText(40)
```

```
if not target_field:
```

```
    arcpy.AddError("El nombre del campo objetivo no ha sido especificado (Parámetro 41). El script  
terminará.")
```

```
    exit()
```

```
if not arcpy.ListFields(training_points_fc, target_field):
```

```
    arcpy.AddError(f"El campo objetivo '{target_field}' no existe en el Feature Class de  
entrenamiento. El script terminará.")
```

```
    exit()
```

--- 2. Crear Geodatabase de Resultados y establecer como espacio de trabajo ---

```
gdb_name = "Modelo_predictivo.gdb"
```

```
gdb_path = os.path.join(carpetas_salida, gdb_name)
```

```
try:
```

```
    if arcpy.Exists(gdb_path):
```

```
        arcpy.AddWarning(f"La geodatabase '{gdb_name}' ya existe. Se usará la existente.")
```

```
    else:
```

```
        arcpy.management.CreateFileGDB(carpetas_salida, gdb_name)
```

```
        arcpy.AddMessage(f"Geodatabase '{gdb_name}' creada en '{carpetas_salida}'.")
```

```
        arcpy.env.workspace = gdb_path
```

```
        arcpy.AddMessage(f"Espacio de trabajo establecido en: {arcpy.env.workspace}")
```

```
except arcpy.ExecuteError:
```

```
    arcpy.AddError(f"Error al crear o establecer la geodatabase: {arcpy.GetMessages(2)}")
```

```
    exit()
```

```
except Exception as e:
```

```
    arcpy.AddError(f"Error inesperado al gestionar la geodatabase: {e}")
```

```
    exit()
```

--- 3. Validación y preparación de rásteres predictores ---

```
predictor_rasters_objects = []
```

```
arcpy.AddMessage("Validando y preparando rásteres predictores...")
```

```
for path in predictor_input_params:
```

```
    if not arcpy.Exists(path):
```

```
    arcpy.AddWarning(f"Ráster predictor '{path}' no existe o es inválido y será ignorado.")
else:
    try:
        # Convertir la ruta a un objeto Raster
        raster_obj = arcpy.Raster(path)
        predictor_rasters_objects.append(raster_obj)
    except Exception as e:
        arcpy.AddWarning(f"No se pudo cargar el ráster '{path}'. Ignorando. Error: {e}")
if not predictor_rasters_objects:
    arcpy.AddError("No se encontraron rústeres predictores válidos para continuar. El script
terminará.")
    exit()
arcpy.AddMessage(f"Se han validado {len(predictor_rasters_objects)} rústeres predictores.")
# ... (código previo) ...

# --- 4. Apilamiento de Bandas Predictoras (CompositeBand) ---
stacked_predictors = os.path.join(arcpy.env.workspace, "StackedPredictors")
arcpy.AddMessage(f"Apilando rústeres predictores en: {stacked_predictors}...")
try:
    # CORRECCIÓN: CompositeBand de Spatial Analyst solo toma 1 argumento y devuelve un
objeto.
    # Luego usamos .save() para guardarlo en el disco.
    stacked_raster_obj = CompositeBand(predictor_rasters_objects)
    stacked_raster_obj.save(stacked_predictors)

    arcpy.AddMessage("Rústeres apilados completados.")
except arcpy.ExecuteError:
    arcpy.AddError(f"Error al apilar rústeres: {arcpy.GetMessages(2)}")
    exit()
except Exception as e:
    arcpy.AddError(f"Error inesperado al apilar rústeres: {e}")
    exit()

# --- 5. Preparación de Datos y Limpieza de Negativos (CORREGIDO) ---
arcpy.AddMessage("Extrayendo valores y limpiando datos...")
try:
    # 1. Proyectar puntos al sistema del ráster
    desc_raster = arcpy.Describe(stacked_predictors)
    puntos_proyectados = os.path.join("memory", "puntos_proj")
    arcpy.management.Project(training_points_fc, puntos_proyectados,
desc_raster.spatialReference)

    # 2. Extraer valores del ráster apilado
    arcpy.sa.ExtractMultiValuesToPoints(puntos_proyectados, [[stacked_predictors, "Banda"]],
"NONE")

    # 3. DETECTOR AUTOMÁTICO DE CAMPOS (Para evitar el error de field_names)
    # Buscamos todos los campos numéricos excepto los del sistema y el objetivo
    campos_sistema = ["OBJECTID", "FID", "SHAPE", target_field.upper(), "CLASSNAME",
"CLASSVALUE"]
    campos_bandas = [f.name for f in arcpy.ListFields(puntos_proyectados)
if f.type in ("Double", "Single", "Integer", "SmallInteger")
and f.name.upper() not in campos_sistema]
```

```
if not campos_bandas:
    arcpy.AddWarning("No se detectaron campos de bandas. Se omitirá la limpieza de negativos.")
else:
    arcpy.AddMessage(f"Limpiando negativos en campos: {', '.join(campos_bandas)}")
    with arcpy.da.UpdateCursor(puntos_proyectados, campos_bandas) as cursor:
        eliminados = 0
        for row in cursor:
            # Si algún valor es None o menor a 0 (NoData), se elimina el punto
            if any(val is None or (isinstance(val, (int, float)) and val < 0) for val in row):
                cursor.deleteRow()
                eliminados += 1
    arcpy.AddMessage(f"Limpieza: Se eliminaron {eliminados} puntos con valores inválidos.")

# 4. Verificar cantidad mínima
conteo = int(arcpy.management.GetCount(puntos_proyectados)[0])
arcpy.AddMessage(f"Puntos finales para entrenar: {conteo}")
if conteo < 5:
    arcpy.AddError("Puntos insuficientes tras la limpieza.")
    exit()

except Exception as e:
    arcpy.AddError(f"Error en preparación de datos: {e}")
    exit()

# --- 6. Configuración de Atributos Alfanuméricos y Numéricos ---
arcpy.AddMessage("Configurando categorías: Media, Alta, Muy Alta...")
campo_nombre = "ClassName"
campo_valor = "ClassValue"

# Añadir campos si no existen
if not arcpy.ListFields(puntos_proyectados, campo_nombre):
    arcpy.management.AddField(puntos_proyectados, campo_nombre, "TEXT", field_length=50)
if not arcpy.ListFields(puntos_proyectados, campo_valor):
    arcpy.management.AddField(puntos_proyectados, campo_valor, "LONG")

# Mapeo: 1=Media, 2=Muy Alta, 3= Alta
mapeo_clases = {1: "Media", 2: "Muy Alta", 3: "Alta"}

with arcpy.da.UpdateCursor(puntos_proyectados, [target_field, campo_nombre, campo_valor]) as cursor:
    for row in cursor:
        try:
            val_num = int(row[0])
            row[1] = mapeo_clases.get(val_num, "Desconocido")
            row[2] = val_num
            cursor.updateRow(row)
        except: continue

# --- 7. Entrenamiento y Predicción Final (Versión Universal) ---
output_ecd = os.path.join(carpeta_salida, "PredictionModel.ecd")

try:
    arcpy.AddMessage("Sincronizando extensiones...")
```

```
arcpy.CheckOutExtension("ImageAnalyst")
arcpy.CheckOutExtension("Spatial")

# Entrenamiento del Modelo
# Usamos argumentos por posición para evitar errores de nombres de parámetros (keyword
arguments)
# Orden: (in_raster, in_training_features, out_classifier_definition, in_additional_raster,
#       max_num_trees, max_tree_depth, max_samples_per_class, used_attributes,
class_value_field)

arcpy.AddMessage("Entrenando el modelo Random Forest (esto puede tardar)...")

arcpy.ia.TrainRandomTreesClassifier(
    stacked_predictors,
    puntos_proyectados,
    output_ecd,
    None, "1000", "1000", "1000", None,
    campo_valor # El campo entero (1, 2, 3)
)

arcpy.AddMessage(f"Modelo .ecd creado exitosamente.")

# Predicción del Mapa Final
# NOTA: No uses arcpy.learn, usa arcpy.ia.ClassifyRaster que es el estándar de escritorio
mapa_final_tif = os.path.join(carpeta_salida, "Mapa_Susceptibilidad_Final.tif")
arcpy.AddMessage(f"Generando mapa final: {mapa_final_tif}")

# --- 8. Generación del Ráster Clasificado (Inferencia) ---
arcpy.AddMessage("Generando mapa clasificado final...")
mapa_final = os.path.join(arcpy.env.workspace, "Mapa_Riesgo_Final")

# Esta es la herramienta que realmente crea la imagen (.tif o raster en GDB)
raster_clasificado = arcpy.ia.ClassifyRaster(stacked_predictors, output_ecd)
raster_clasificado.save(mapa_final)
arcpy.AddMessage(f"Imagen generada exitosamente en: {mapa_final}")

# --- CIERRE OBLIGATORIO ---
except arcpy.ExecuteError:
    arcpy.AddError(f"Error de ArcGIS: {arcpy.GetMessages(2)}")
except Exception as e:
    arcpy.AddError(f"Error crítico: {e}")
finally:
    arcpy.CheckInExtension("ImageAnalyst")
    arcpy.CheckInExtension("Spatial")
    arcpy.AddMessage(f"Proceso terminado: {datetime.datetime.today()}")
```

Importante tener en cuenta que en el entrenamiento en la función train se puede seleccionar o modificar el máximo de árboles de cesión, al aumentar el número de árboles se observó mayor precisión en la precisión del modelo, aunque dependiendo el entrenamiento a medida que se entrene

el modelo este número podrá disminuir, la profundidad Maxima del árbol al ejecutar el tool refiere al número de reglas que cada árbol puede crear para tomar una decisión, y tercer parámetro a tener en cuenta del código anterior el valor predeterminado de 1000 para información no continua o segmentada, en el caso de este estudio se identificó que al utilizar los valores en 1000, para cada una de las 3 variables se obtuvieron mejores resultados que con otras combinaciones, como se ve en el siguiente apartado de validación.

El aplicativo pide el ingreso de puntos o clases con los valores, predeterminados para lo cual se calculó un millón de puntos aleatorios, se extrajo el valor de la capa esperada que corresponde a amenaza por remoción en masa.




Figura 36. Muestra inicial insertada en el entrenamiento, que corresponde a 1 millón de puntos que extraen la variable amenaza, esto se debe insertar en el tool.

Fuente: Elaboración propia, 2026.

En la Figura 36, se puede observar la cantidad de puntos insertados, sin embargo, el número de puntos utilizado en el entrenamiento como se ve en el código desarrollado, puede ser inferior ya que el algoritmo revisa puntos, con valores nulos, o datos que no se diferencian entre sí para lo cual hace una limpieza total, este valor depende de la muestra inicial y la ubicación de ellos puntos, el caso de esta investigación se evidenció que el número total de puntos que utilizo contemplo en las diferentes

muestras valores cercanos a los 200.000 puntos para entrenar, al realizar la revisión y limpieza, pero esto depende del millón de puntos seleccionados aleatoriamente.


9.5 FASE 5: VALIDACIÓN

La fase de validación estadística del modelo de regresión fundamentado en el algoritmo de Bosques Aleatorios (*Random Forests*) se estructuró bajo un protocolo analítico riguroso, utilizando un conjunto de datos de validación completamente independiente y ortogonal a la muestra de entrenamiento, esta se puede observar en la Figura 43.


Una vez alcanzada la convergencia algorítmica global, minimizado el error de generalización y validados los criterios de precisión mediante la estabilización de la función de pérdida, el operador matemático estocástico optimizado se aplicó vectorialmente sobre la totalidad de la extensión geográfica del área de estudio. Este proceso de extrapolación e inferencia espacial se ejecutó mediante la integración multidimensional de las capas de variables predictoras continuas y discretas, implementando algoritmos avanzados de álgebra de mapas y computación paralela de celdas. El producto cartográfico resultante se consolidó en una estructura de datos matricial de formato ráster de alta resolución. Este modelo digital georreferenciado proporciona una representación continua, homogénea y espacialmente explícita de los valores numéricos pronosticados para la variable objeto de estudio, suprimiendo los sesgos de vecindad e interpolación geométrica que limitan a los enfoques geoestadísticos tradicionales.

La robustez científica, la validez interna y la reproducibilidad técnica de los resultados derivados de esta arquitectura metodológica dependieron de un control estricto de los factores que inducen a la inestabilidad numérica durante la fase de preprocesamiento de datos.

En la Figura 37, Figura 38, Figura 39 y Figura 40, se pueden observar los diferentes resultados que se obtuvieron al ejecutar el algoritmo o bueno algunos ejemplos de los modelos y modificaciones ejecutadas, en la primera figura, los datos esperados contra los cuales se validó el modelo entrenado,, se hicieron pruebas eliminando las variables temporales es decir dejando solo la variable en un año, y se obtuvieron resultados de precisión por debajo del 50 %, lo que indica y da como resultado que las series temporales en el caso de ellos datos y zona estudiada son relevantes para el entrenamiento del modelo, en la figura dos mencionada al inicio del párrafo, se evidencia el resultado con máquinas de soportes vectorial, lo que arrojó una precisión del 65 %, resultados bastante deficientes si lo calculamos lo comparamos con la tercera gráfica que es el resultado del entrenamiento con las 38 variables, lo que nos da una precisión del 88 %.



*Figura 37. Datos esperados con el entrenamiento.
Fuente: Elaboración propia, Amenaza remoción de masa.*



*Figura 38. Resultado Maching Learning Regresión sin temporalidad.
Fuente: Elaboración propia, Amenaza remoción de masa.*




Figura 39. Máquina de soportes vectoriales.

Fuente: Elaboración propia, Amenaza remoción de masa.




Figura 40. Resultado Maching Learning Regresión con temporalidad.

Fuente: Elaboración propia, Amenaza remoción de masa.

Con el propósito de evaluar la capacidad de generalización del modelo predictivo y mitigar de manera rigurosa el riesgo de sesgo por optimismo o sobreajuste (*overfitting*), se implementó un estricto protocolo de validación cruzada externa. Este procedimiento metodológico consistió en la segregación a priori de un subconjunto de datos testigo de carácter estocástico, los cuales fueron excluidos sistemáticamente, estos se excluyeron aplicando la parte 5 del algoritmo diseñado de todas las fases de calibración y sintonización del algoritmo de Bosques Aleatorios (*Random Forests*). La evaluación del desempeño del operador matemático se fundamentó exclusivamente en el contraste numérico entre las observaciones reales de este vector de validación independiente y las estimaciones sintéticas generadas por la arquitectura algorítmica optimizada, los puntos se extraen de los 983, entre el ráster esperado Figura 37 y ráster obtenido final del entrenamiento Figura 40. Asimismo, la paridad matemática registrada entre las magnitudes de la exactitud precisión y F1-Score calculados se pueden ver en la Figura 41 del conjunto de entrenamiento frente al conjunto de prueba validó de forma empírica la resiliencia del modelo ante la variabilidad inherente y el ruido estocástico del área de estudio. Este comportamiento estadístico robusto certifica la validez interna del marco metodológico implementado y garantiza la transferibilidad y fiabilidad científica de las proyecciones geoespaciales resultantes.

Las clases para las amenazas están comprendidas en el siguiente listado:

- **Amenaza Muy Alta:** 85 % a 100%. Sectores críticos donde la red neuronal detecta una convergencia absoluta de factores (ej. pendientes extremas, suelo saturado y altas tasas de deformación por InSAR). El fallo o movimiento es inminente o ya está ocurriendo.
- **Amenaza Alta:** 70 % a 84 %. Zonas inestables con alta susceptibilidad intrínseca. El modelo identifica firmas cinemáticas claras de deformación diferencial que superan los umbrales de seguridad, requiriendo intervención y monitoreo prioritario.
- **Amenaza Media:** 30 % a 69%. Zonas de transición o estabilidad condicionada. El terreno cuenta con cierta resistencia geológica, pero es susceptible de activarse si se presentan factores detonantes externos (como lluvias intensas que superen los umbrales críticos).
- **Amenaza Baja:** 0% a 29%. Áreas estables o seguras (ej. valles planos, afloramientos rocosos macizos). La probabilidad matemática calculada por arquitecturas como LSTM o Transformers es marginal, y los datos de InSAR muestran velocidades cercanas a cero. (Cáqueza cómo se ve en la Figura 28.)




Figura 41. Grafica de diferencias encontradas entre el modelo entrenado y el resultado esperado.

Fuente: Elaboración propia, 2026.

Tabla 12. Tipo de errores dentro de la validación de la matriz de confusión.

Tipo de Error	Nombre Común	Lo que hace el modelo	La Realidad
Error Tipo I	Falso Positivo	Dice que SÍ hay deformación/fallo	El terreno está totalmente estable
Error Tipo II	Falsos Negativo	Dice que NO hay deformación/fallo	El terreno se está cayendo

Fuente: Elaboración Propia, 2026.

amenaza	Media	Muy Alta	Alta	Total general
Media	269	5	76	350
Muy Alta	1	217	24	242
Alta	84	49	258	391
Total general	354	271	358	983

Verdadero Positivo	744	76%
Falso Positivo	105	11%
FalsoNegativo	134	14%

Exactitud	76%	
Precisión	88%	
Sencibilidad	85%	
F1-Score	0,861609728	Modelo confiable y robusto

Figura 42. Resultados obtenidos, de la revisión del entrenamiento del modelo .

Fuente: Elaboración propia, 2026.

La robustez diagnóstica y el poder de discriminación del modelo predictivo optimizado se evaluaron formalmente mediante un protocolo de validación cruzada externa (*hold-out validación*), empleando un vector de prueba independiente compuesto por 983 puntos de control estocástico de carácter no correlacionado. El comportamiento inferencial del algoritmo de clasificación ante este espacio de características fue parametrizado de manera exhaustiva a través de los estimadores derivados de la matriz de confusión. El análisis de las tasas de error y acierto reveló una alta consistencia operativa, caracterizada por una tasa de verdaderos positivos (sensibilidad o *recall*) del 85%, lo que demuestra una elevada capacidad intrínseca de la arquitectura para discriminar correctamente las instancias positivas del fenómeno bajo estudio. Este rendimiento se complementó con un margen marginal de omisión equivalente a una tasa de falsos negativos del 14% (error tipo II) ver en la Tabla 12.




Figura 43. Localización espacial de los 983 puntos de control.

Fuente: Elaboración propia, 2026.

En lo que respecta a la validez predictiva interna, el modelo registró una precisión (*precisión*) del 88%, condicionada unívocamente por una tasa de falsos positivos limitada al 11% (error tipo I), lo que certifica matemáticamente una baja propensión a la emisión de falsas alarmas dentro del espacio geográfico analizado. La eficiencia general del sistema se consolidó con un índice de exactitud global (*accuracy*) del 76%, el cual cuantifica geométricamente la proporción agregada de clasificaciones concordantes (verdaderos positivos y verdaderos negativos) sobre el universo muestral evaluado $N = 983$ ver en la Figura 43 la localización de los puntos. Finalmente, para evaluar la estabilidad de la clasificación ante la variabilidad y posibles asimetrías en la densidad de los datos de prueba, se calculó la media armónica entre la precisión y la exhaustividad mediante el índice F_1 -score, el cual alcanzó un valor crítico del 86%. Esta convergencia métrica multivariante convalida formalmente el equilibrio asintótico del operador algorítmico, asegurando su fiabilidad científica y generalización estadística para su posterior integración en modelos de toma de decisiones predictivas.

10. CAPITULO 5. CONCLUSIONES Y RECOMENDACIONES

10.1 CONCLUSIONES

Se estructuró y entrenó con éxito un modelo de Redes Neuronales Artificiales (RNA) utilizando los registros históricos de inestabilidad de laderas en Cáqueza entre 2014 y 2024. El modelo demostró una alta capacidad de aprendizaje al procesar patrones climáticos y territoriales complejos de la última década. Esto permitió sectorizar de forma automatizada las áreas con mayor probabilidad de ocurrencia de futuros deslizamientos dentro del territorio municipal, la precisión del modelo alcanzo el 88 %, y se logró determinar que la mayor precisión de alcanzo con Bosques aleatorios con modelo de regresión, presentándose mayor precisión cuando se utilizaron series de tiempo en las variables.

El procesamiento e interferometría de pares complejos de radar permitieron cartografiar con precisión milimétrica las deformaciones verticales del terreno en el municipio. Se identificó que las zonas con mayores tasas de subsidencia acumulada corresponden a las zonas con mayor desplazamiento reportados. Este insumo evidenció procesos de hundimiento activo que comprometen directamente la infraestructura vial y habitacional, las zonas de mayores deslizamientos encontrados corresponden a las laderas que están continuas a la vía que conduce de Bogotá a Villavicencio, zonas que concuerdan con mayor intervención antrópica y perdida de vegetación en el tiempo, lo que incrementa el factor de desplazamiento.

Se consolidó una metodología estandarizada y replicable que integra Sistemas de Información Geográfica (SIG) con algoritmos de aprendizaje profundo. Este protocolo metodológico detalla de manera lógica las fases de recolección de datos, normalización de variables, arquitectura de la red neuronal y proyección espacial. El flujo de trabajo queda disponible como una herramienta técnica avanzada aplicable a otros municipios del país, con condiciones geomorfológicas similares. O si prefieren definir nuevas variables que permitan estudiar de forma adecuada el territorio.

La validación cruzada realizada frente al inventario histórico oficial del Servicio Geológico Colombiano (SGC) mediante la capa disponible de Amenaza por remoción en masa, otorgó al modelo un nivel de precisión del 88 %. La alta coincidencia espacial entre las zonas de amenaza predichas por la red neuronal y los eventos reales documentados por la institución estatal confirma la robustez, precisión y utilidad práctica del modelo para la toma de decisiones en el ordenamiento

10.2 RECOMENDACIONES

- Se recomienda la **integración del modelo predictivo en los sistemas de información geográfica (SIG) y plataformas de gestión de riesgos** del municipio de Cáqueza y Cundinamarca, para su uso continuo en la monitorización y emisión de alertas tempranas por parte de las autoridades competentes.
- Es crucial establecer un **protocolo claro para la interpretación y difusión de las alertas** generadas por el modelo, asegurando que la información llegue de manera efectiva a la comunidad y a los tomadores de decisiones para una respuesta oportuna.
- Realizar estudios comparativos con **otras arquitecturas de aprendizaje automático** (ej. *Support Vector Machines, Random Forests*) o modelos híbridos, para identificar la solución predictiva óptima para este tipo de fenómenos.
- Profundizar en la **interpretación de la "caja negra" de las Redes Neuronales** mediante técnicas de IA explicable (XAI), para comprender mejor la relación entre las variables de entrada y las predicciones del modelo, aportando mayor transparencia y confianza en sus resultados

11. BIBLIOGRAFÍA

- 2.7.1. *Principios de las redes neuronales* (Dr. Frank Dieterle). (s. f.). Recuperado 8 de septiembre de 2019, de http://www.frank-dieterle.de/phd/2_7_1.html
- Alcántara Ayala, I., García, M., & Giselle, F. (2008). Procesos de remoción en masa en México: Hacia una propuesta de elaboración de un inventario nacional. *Investigaciones geográficas*, (66), 47-64.
- Alcántara Ayala, I., & Murillo García, F. G. (2008). Procesos de remoción en masa en México: Hacia una propuesta de elaboración de un inventario nacional. *Investigaciones geográficas*, (66), 47-64.
- Anderberg, M. R. (1973). *Cluster analysis for applications*. Academic Press.
- Argentino, A. S. G. M., Bolivia (SERGEOTECMIN), B. S. N. de G. y T. de M. de, Canada (GSC), C. G. S. of, Minería (SERNAGEOMIN), C. S. N. de G. y, Minería (INGEOMINAS), C. I. C. de G. y, Nacional (SGN), E. S. G., Metalúrgico (INGEMMET), P. I. G. M. y, Minería (INGEOMIN), V. I. N. de G. y, & Masa (GEMMA), P. M. A. G. para las C. A. G. de E. para M. en. (2007). *Movimientos en Masa de la Región Andina: Una Guía para la Evaluación de Amenazas*. <https://repositorio.segemar.gov.ar/handle/308849217/2792>
- Arias, A. (2017). *Obtención de propiedades mecánicas a partir de la relación Vp/Vs para depósitos superficiales de ceniza volcánica en Manizales Colombia*.
- Beucher, A., Møller, A. B., & Greve, M. H. (2017). Artificial neural networks and decision tree classification for predicting soil drainage classes in Denmark. *Geoderma*. <https://doi.org/10.1016/j.geoderma.2017.11.004>
- Bilgilioglu, H. (2023). A comparison of different machine learning models for landslide susceptibility mapping in Rize (Türkiye). *Baltica*, 115-132. <https://doi.org/10.5200/baltica.2023.2.3>
- Borja Baeza, R. C., & Alcántara Ayala, I. (2004). Procesos de remoción en masa y riesgos asociados en Zacapoaxtla, Puebla. *Investigaciones geográficas*, (53), 7-26.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Caizaluisa, A., & Muñoz, E. (2014). CARACTERIZACIÓN DE LA DEFORMACIÓN SUPERFICIAL TERRESTRE EN UNA ZONA PILOTO EL ECUADOR, USANDO INTERFEROMETRÍA DIFERENCIAL (DInSAR). *Revista Geospacial*, 2, 45-53.
- Cartaya, S., Méndez, W., & Pacheco, H. (2006). Modelo de zonificación de la susceptibilidad a los procesos de remoción en masa a través de un sistema de información geográfica. *Interciencia*, 31(9), 638-646.
- Claverie, M., Ju, J., Masek, J. G., Dungan, J. L., Vermote, E. F., Roger, J.-C., Skakun, S. V., & Justice, C. (2018). The Harmonized Landsat and Sentinel-2 surface reflectance data set. *Remote Sensing of Environment*, 219, 145-161. <https://doi.org/10.1016/j.rse.2018.09.002>
- Contreras Urgilés, W., Maldonado Ortega, J., León Japa, R., Contreras Urgilés, W., Maldonado Ortega, J., & León Japa, R. (2019). APPLICATION OF FEED-FORWARD BACKPROPAGATION NEURAL NETWORK FOR THE DIAGNOSIS OF MECHANICAL FAILURES IN ENGINES PROVOKED IGNITION. *Ingenius. Revista de Ciencia y Tecnología*, (21), 32-40. <https://doi.org/10.17163/ings.n21.2019.03>
- Correa, O., García, F., Bernal, G., Cardona, O. D., & Rodríguez, C. (2020). Early warning system for rainfall-triggered landslides based on real-time probabilistic hazard assessment. *Natural Hazards*, 100(1), 345-361. <https://doi.org/10.1007/s11069-019-03815-w>
- Cui, X., Zeng, Q., Liang, C., & Jiao, J. (2010). *Research of InSAR Atmospheric Correction-Case Study of Yutian Earthquake, China*. 686, 509. <https://ui.adsabs.harvard.edu/abs/2010ESASP.686E.509C>
- Daly, C., Gibson, W. P., Taylor, G. H., Johnson, G. L., & Pasteris, P. (2002). A knowledge-based approach to the statistical mapping of climate. *Climate Research*, 22, 99-113. <https://doi.org/10.3354/cr022099>

- Farías Sarmiento, V. F. (2017). *Remociones en masa asociadas a sismicidad en el Norte de Chile: Análisis multiescala en distintos ambientes morfotectónicos*.
<https://repositorio.uchile.cl/handle/2250/144478>
- Fasana, C., Pasini, S., Milani, F., & Fraternali, P. (2022). Weakly Supervised Object Detection for Remote Sensing Images: A Survey. *Remote Sensing*, 14(21), 5362.
<https://doi.org/10.3390/rs14215362>
- Ferro-Famil, L., & Pottier, E. (2016). 2 - SAR Imaging using Coherent Modes of Diversity: SAR Polarimetry, Interferometry and Tomography. En N. Baghdadi & M. Zribi (Eds.), *Microwave Remote Sensing of Land Surface* (pp. 67-147). Elsevier. <https://doi.org/10.1016/B978-1-78548-159-8.50002-5>
- Fick, S. E., & Hijmans, R. J. (2017). WorldClim 2: New 1-km spatial resolution climate surfaces for global land areas. *International Journal of Climatology*, 37(12), 4302-4315.
<https://doi.org/10.1002/joc.5086>
- Foody, G. M. (2020). Explaining the unsuitability of the kappa coefficient in the assessment and comparison of the accuracy of thematic maps obtained by image classification. *Remote Sensing of Environment*, 239, 111630. <https://doi.org/10.1016/j.rse.2019.111630>
- Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A., & Michaelsen, J. (2015). The climate hazards infrared precipitation with stations—A new environmental record for monitoring extremes. *Scientific Data*, 2(1), 150066.
<https://doi.org/10.1038/sdata.2015.66>
- Fuquan, T., Zuxi, C., & Hanying, W. (2012). *Application of GPS/InSAR fusion technology in dynamic monitoring of mining subsidence in western mining areas*. 615.
<https://doi.org/10.1109/CECNet.2012.6202159>
- Gao, Y., Liu, B., Guo, N., Ye, X., Wan, F., You, H., & Fan, D. (2019). C-MIDN: Coupled Multiple Instance Detection Network With Segmentation Guidance for Weakly Supervised Object Detection. 9834-9843.
https://openaccess.thecvf.com/content_ICCV_2019/html/Gao_C-MIDN_Coupled_Multiple_Instance_Detection_Network_With_Segmentation_Guidance_for_ICCV_2019_paper.html
- Garro, K. J. V., & Malagón, K. L. Q. (2025). *Evaluación de Redes Neuronales Convolucionales para la extracción de linderos prediales como herramienta para la actualización catastral*.
- Garrott, R. A., White, P. J., & Watson, F. G. R. (2008). *The Ecology of Large Mammals in Central Yellowstone: Sixteen Years of Integrated Field Studies*. Academic Press.
- González, D. S. (2011). Precipitaciones extremas y sus implicaciones en procesos de remoción en masa en la planificación urbana de Tampico, México. *Cuadernos Geográficos*, 48(0), 135-159.
<https://doi.org/10.30827/cuadgeo.v48i0.583>
- González, O. D. R. (2020). Tecnologías de la Información Geográfica para todos los niveles educativos y socioeconómicos, SIG gratuitos vs SIG no gratuitos, aplicándolos al riesgo de procesos de remoción en masa, alcaldía Álvaro Obregón, Ciudad de México, México. *Revista Geográfica*, (161), 137-161. <https://doi.org/10.35424/regeo.161.2020.606>
- Gunson, K. E., Mountrakis, G., & Quackenbush, L. J. (2011). Spatial wildlife-vehicle collision models: A review of current work and its application to transportation mitigation projects. *Journal of Environmental Management*, 92(4), 1074-1082. <https://doi.org/10.1016/j.jenvman.2010.11.027>
- Guzmán Torres, R., Bezada, M., & Rodríguez Santalla, I. (2023). Cartografía de cobertura del suelo mediante datos de teledetección en la planicie de desborde del río Apure (Venezuela). *Cuadernos de investigación geográfica: Geographical Research Letters*, 49(1), 113-137.
- Hanssen, R. F. (Ed.). (2001). Radar system theory and interferometric processing. En *Radar Interferometry: Data Interpretation and Error Analysis* (pp. 9-60). Springer Netherlands.
https://doi.org/10.1007/0-306-47633-9_2
- Hoyos Patiño, F. (1990). *MECANISMO DE FALLA ASOCIADA A PRESIÓN HIDROSTÁTICA EN DESLIZAMIENTOS PROFUNDOS*.
- Ivić, M. (2019). ARTIFICIAL INTELLIGENCE AND GEOSPATIAL ANALYSIS IN DISASTER MANAGEMENT. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, XLII-3-W8, 161-166. ISPRS ICWG III/IVa
Gi4DM 2019 – GeoInformation

- for Disaster Management (Volume XLII-3/W8) - 3–6 September 2019, Prague, Czech Republic. <https://doi.org/10.5194/isprs-archives-XLII-3-W8-161-2019>
- John C. Curlander, Robert N. McDonough. (1991). *Synthetic Aperture Radar—Systems and Signal Processing-Wiley-*. Scribd. <https://www.scribd.com/document/325015867/John-C-Curlander-Robert-N-McDonough-Synthetic-Aperture-Radar-Systems-and-Signal-Processing-Wiley-Interscience-1991>
- Khandetsky, V., & Antonyuk, I. (2002). Signal processing in defect detection using back-propagation neural networks. *NDT & E International*, 35(7), 483-488. [https://doi.org/10.1016/S0963-8695\(02\)00022-1](https://doi.org/10.1016/S0963-8695(02)00022-1)
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. *Advances in Neural Information Processing Systems*, 25. https://proceedings.neurips.cc/paper_files/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html
- Leyva Pinto, T. (2025). *Evaluación de la interferometría diferencial de radar en el estudio de fenómenos de remoción en masa y su uso en alertas tempranas*. <https://repositorio.unal.edu.co/handle/unal/87904>
- Li, W., Hsu, C.-Y., & Hu, M. (2021). Tobler's First Law in GeoAI: A Spatially Explicit Deep Learning Model for Terrain Feature Detection under Weak Supervision. *Annals of the American Association of Geographers*, 111(7), 1887-1905. (152573622). <https://doi.org/10.1080/24694452.2021.1877527>
- Lombardo, L., Opitz, T., Ardizzone, F., Guzzetti, F., & Huser, R. (2020). Space-time landslide predictive modelling. *Earth-Science Reviews*, 209, 103318. <https://doi.org/10.1016/j.earscirev.2020.103318>
- Londoño, S., Bermudez, M., Restrepo, S., Marin, M., & García, D. (2021, febrero 9). *Earthquake ground deformation using DInSAR analysis and instrumental seismicity: The 2019 M 6.0 Mesetas Earthquake, Meta, Colombian Andes*. <https://doi.org/https://doi.org/10.18268/BSGM2021v73n2a090221>
- Ma, L., Li, M., Ma, X., Cheng, L., Du, P., & Liu, Y. (2017). A review of supervised object-based land-cover image classification. *ISPRS Journal of Photogrammetry and Remote Sensing*, 130, 277-293. <https://doi.org/10.1016/j.isprsjprs.2017.06.001>
- Maas, A., Le, Q. V., O'Neil, T. M., Vinyals, O., Nguyen, P., & Ng, A. Y. (2012). *Recurrent Neural Networks for Noise Reduction in Robust ASR*. Google AI. <https://ai.google/research/pubs/pub45168>
- Máquina de vectores de soporte (SVM). (s.f.). Recuperado 16 de junio de 2019, de <https://la.mathworks.com/discovery/support-vector-machine.html>
- Maxwell, A. E., Ramezan, C., & He, Y. (2025). *Supervised Learning in Remote Sensing and Geospatial Science*. Elsevier.
- Maxwell, A. E., Warner, T. A., & Fang, F. (2018). Implementation of machine-learning classification in remote sensing: An applied review. *International Journal of Remote Sensing*, 39(9), 2784-2817. <https://doi.org/10.1080/01431161.2018.1433343>
- Mendoza Poggi, M. L., Giler Ormaza, A. M., Aguilar Porro, C., & Pimentel Leiva, R. (2021). Evaluación del uso y cobertura del suelo en la cuenca río Chico. *Dilemas Contemporáneos: Educación, Política y Valores*, 8, 1-23. (158167674).
- Menne, M. J., & Williams, C. N. (2009). *Homogenization of Temperature Series via Pairwise Comparisons*. <https://doi.org/10.1175/2008JCLI2263.1>
- Mergili, M., Marchant Santiago, C. I., & Moreiras, S. M. (2015). Causas, características e impacto de los procesos de remoción en masa, en áreas contrastantes de la región Andina. *Cuadernos de Geografía: Revista Colombiana de Geografía*, 24(2), 113-131. <https://doi.org/10.15446/rcdg.v24n2.50211>
- Moradi, H., Avand, M. T., & Janizadeh, S. (2019). 11—Landslide Susceptibility Survey Using Modeling Methods. En H. R. Pourghasemi & C. Gokceoglu (Eds.), *Spatial Modeling in GIS and R for Earth and Environmental Sciences* (pp. 259-275). Elsevier. <https://doi.org/10.1016/B978-0-12-815226-3.00011-9>
- Mountrakis, G., Im, J., & Ogole, C. (2011). Support vector machines in remote sensing: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 66(3), 247-259. <https://doi.org/10.1016/j.isprsjprs.2010.11.001>

- Mukhopadhyay, A., Mitra, D., & Hazra, S. (2021). *Sundarbans Mangrove Systems: A Geo-Informatics Approach*. CRC Press.
- Normatividad. (2025). <https://portal.gestiondelriesgo.gov.co/paginas/normatividad.aspx>
- Olarte, J. M. (2017). Clasificación de movimiento en masa y su distribución en terrenos geológicos de Colombia. En *Libros del Servicio Geológico Colombiano*. Libros del Servicio Geológico Colombiano. <https://doi.org/10.32685/9789585978218>
- Oro, A., & Pereira, A. (2025). La Inteligencia Geoespacial Aplicada a la Interferometría Radar: Una Revisión: Geospatial Intelligence Applied to Radar Interferometry: A Review. *INTELETICA*, 2(3), 61-78. <https://doi.org/10.4114/INTELETICA.vol2iss3pp61-78>
- Ortiz, M. A. C., Santana, J. R. H., & Martínez, A. G. A. (2021). Susceptibilidad a procesos de remoción en masa: Aproximación metodológica para la construcción de un índice de amenaza en Álvaro Obregón-Ciudad de México. *Entorno Geográfico*, (21). <https://doi.org/10.25100/eg.v0i21.11291>
- Ospina Urán, A. (2024). *Evaluación del uso de técnicas InSAR para el monitoreo y detección de movimientos en masa en un sistema de alertas tempranas en los Andes colombianos*. <https://repositorio.unal.edu.co/handle/unal/86910>
- Página de Inicio | GEFEM. (s. f.). Recuperado 18 de mayo de 2026, de <https://pi.udistrital.edu.co/GEFEM/>
- Ramos, A., & Pacheco, J. (2013). Determinación del tipo de proceso de remoción en masa en Bogotá mediante árboles de decisión. *Ingeniería y Región*, 10, 125. <https://doi.org/10.25054/22161325.764>
- Rosen, P., Geophys, J., Earth, R., & Zebker, H. (1996a). *Atmospheric Artifacts in Interferometric SAR Surface Deformation and Topographic Maps*.
- Rosen, P., Geophys, J., Earth, R., & Zebker, H. (1996b). *Atmospheric Artifacts in Interferometric SAR Surface Deformation and Topographic Maps*.
- Rubio Simanca, E. M. (2015). *Evaluación del riesgo por remoción en masa en el sector sur occidente de la comuna 18 de Santiago de Cali*. <https://bibliotecadigital.univalle.edu.co/entities/publication/26a7bcad-d6e7-4b9d-ae5f-14b467796be9>
- Runge, S., Schwens, C., & Schulz, M. (2022). The invention performance implications of coopetition: How technological, geographical, and product market overlaps shape learning and competitive tension in R&D alliances. *Strategic Management Journal*, 43(2), 266-294. <https://doi.org/10.1002/smj.3334>
- Sarabia Gómez, A. M., Barbosa Castro, D. R., & Arcila Rivera, M. M. (2022). Macroseismic intensity data and effects of significant earthquakes in Colombia based on historical seismicity studies. *Boletín Geológico*, 49(2). <https://doi.org/10.32685/0120-1425/bol.geol.48.2.2021.638>
- Sevruk, B. (1996). Adjustment of tipping-bucket precipitation gauge measurements. *Atmospheric Research, Closing the gap between theory and practice in urban rainfall applications*, 42(1), 237-246. [https://doi.org/10.1016/0169-8095\(95\)00066-6](https://doi.org/10.1016/0169-8095(95)00066-6)
- Sierra, F. S. (2003). *METODOLOGÍA PARA EL ANÁLISIS DE RIESGOS POR DESLIZAMIENTOS*.
- Vallejo, L. I. G. de. (2002). *Ingeniería geológica*. Pearson Educación.
- Wardlow, B. D., Anderson, M. C., & Verdin, J. P. (2012). *Remote Sensing of Drought: Innovative Monitoring Approaches*. CRC Press.
- Wu, J., Sun, J., Jäschke, Y., Batsaikhan, B., & Yibeltal, M. (2023). *Grassland conservation in asia: Sustainability under climate change*. Frontiers Media SA.
- Zhang, C., Sargent, I., Pan, X., Li, H., Gardiner, A., Hare, J., & Atkinson, P. M. (2018). An object-based convolutional neural network (OCNN) for urban land use classification. *Remote Sensing of Environment*, 216, 57-70. <https://doi.org/10.1016/j.rse.2018.06.034>
- Zhang, L., Ding, X., & Lu, Z. (2011). Ground settlement monitoring based on temporarily coherent points between two SAR acquisitions. *ISPRS Journal of Photogrammetry and Remote Sensing*, 66(1), 146-152. <https://doi.org/10.1016/j.isprsjprs.2010.10.004>
- Zhu, Z., Wulder, M. A., Roy, D. P., Woodcock, C. E., Hansen, M. C., Radeloff, V. C., Healey, S. P., Schaaf, C., Hostert, P., Strobl, P., Pekel, J.-F., Lymburner, L., Pahlevan, N., & Scambos, T. A. (2019). Benefits of the free and open Landsat data policy. *Remote Sensing of Environment*, 224, 382-385. <https://doi.org/10.1016/j.rse.2019.02.016>

- amler, R., & Hartl, P. (1998). Synthetic aperture radar interferometry. *Inverse Problems*, 14(4), R1–R54. doi.org
- Bishop, A. W. (1955). The use of the slip circle in the stability analysis of slopes. *Géotechnique*, 5(1), 7–17. doi.org
- Bürgmann, R., Rosen, P. A., & Fielding, E. J. (2000). Synthetic aperture radar interferometry to measure Earth's surface deformation. *Annual Review of Earth and Planetary Sciences*, 28(1), 169–209. doi.org
- Caine, N. (1980). The rainfall intensity: duration control of shallow landslides and debris flows. *Geografiska Annaler: Series A, Physical Geography*, 62(1/2), 23–27. doi.org
- Cruden, D. M., & Varnes, D. J. (1996). Landslide types and processes. In A. K. Turner & R. L. Schuster (Eds.), *Landslides: Investigation and mitigation* (Special Report 247, pp. 36–75). Transportation Research Board, National Research Council.
- Dice, L. R. (1945). Measures of the amount of ecologic association between species. *Ecology*, 26(3), 297–302. doi.org
- Emardson, T. R., Simons, M., & Webb, F. H. (2003). Neutral atmospheric delay in interferometric synthetic aperture radar applications: Statistical description and mitigation. *Journal of Geophysical Research: Solid Earth*, 108(B5), 2231. doi.org
- Ferretti, A., Fumagalli, A., Novali, F., Prati, C., Rocca, F., & Rucci, A. (2011). A new algorithm for processing interferometric data-stacks: SqueeSAR. *IEEE Transactions on Geoscience and Remote Sensing*, 49(9), 3460–3470. doi.org
- Ferretti, A., Prati, C., & Rocca, F. (2000). Nonlinear subsidence rate estimation using permanent scatterers in differential SAR interferometry. *IEEE Transactions on Geoscience and Remote Sensing*, 38(5), 2202–2212. doi.org
- Ferretti, A., Prati, C., & Rocca, F. (2001). Permanent scatterers in SAR interferometry. *IEEE Transactions on Geoscience and Remote Sensing*, 39(1), 8–20. doi.org
- Fialko, Y., Simons, M., & Agnew, D. (2001). The 1999 Hector Mine, California, earthquake: Vector components of ground deformation using satellite radar interferometry. *Science*, 294(5541), 342–347. doi.org
- Goodman, R. E. (1989). *Introduction to rock mechanics* (2nd ed.). John Wiley & Sons.
- Hanssen, R. F. (2001). *Radar interferometry: Data interpretation and error analysis*. Kluwer Academic Publishers.
- Hochreiter, S. (1998). The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 6(02), 107–116. doi.org
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. doi.org
- Jaccard, P. (1912). The distribution of the flora in the alpine zone. *New Phytologist*, 11(2), 37–50. doi.org
- Kipf, T. N., & Welling, M. (2016). Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*. doi.org
- Lahiran, M., & Singh, R. (2013). Multi-modal data fusion and sensor integration using remote sensing data for landslide vulnerability assessment. *International Journal of Remote Sensing*, 34(12), 4210–4225.
- Lee, J. S., Hoppel, K. W., Mango, S. A., & Miller, A. R. (1994). Intensity and phase statistics of multilook polarimetric SAR imagery. *IEEE Transactions on Geoscience and Remote Sensing*, 32(5), 1017–1028. doi.org
- Masci, J., Meier, U., Cireşan, D., & Schmidhuber, J. (2011). Stacked convolutional auto-encoders for hierarchical feature extraction. In *International Conference on Artificial Neural Networks* (pp. 52–59). Springer. doi.org
- Massonnet, D., & Feigl, K. L. (1998). Radar interferometry and its application to changes in the Earth's surface. *Reviews of Geophysics*, 36(4), 441–500. doi.org

- Morgenstern, N. R., & Price, V. E. (1965). The analysis of the stability of general slip surfaces. *Géotechnique*, 15(1), 79–93. doi.org
- Neal, R. M. (1995). *Bayesian learning for neural networks* (Doctoral dissertation, University of Toronto). ProQuest Dissertations Publishing.
- Rosen, P. A., Hensley, S., Joughin, I. R., Li, F. K., Poretz, F. H., Rodriguez, E., & Goldstein, R. M. (2000). Synthetic aperture radar interferometry. *Proceedings of the IEEE*, 88(3), 333–382. doi.org
- Soeters, R., & van Westen, C. J. (1996). Slope instability recognition, analysis, and zonation. In A. K. Turner & R. L. Schuster (Eds.), *Landslides: Investigation and mitigation* (Special Report 247, pp. 129–177). Transportation Research Board, National Research Council.
- Sorensen, T. (1948). A method of establishing groups of equal amplitude in plant sociology based on similarity of species content and its application to analyses of the vegetation on Danish commons. *Kongelige Danske Videnskabernes Selskab*, 5(4), 1–34.
- Ulaby, F. T., Moore, R. K., & Fung, A. K. (1982). *Microwave remote sensing: Active and passive. Volume II: Radar remote sensing and surface scattering and emission theory*. Addison-Wesley.
- Vallejo, L. I. G. (2002). *Ingeniería geológica*. Pearson Educación.
- Varnes, D. J. (1984). *Landslide hazard zonation: A review of principles and practice*. UNESCO.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks?. *Advances in Neural Information Processing Systems*, 27, 3320–3328.
- Zebker, H. A., & Villasenor, J. (1992). Decorrelation in interferometric radar echoes. *IEEE Transactions on Geoscience and Remote Sensing*, 30(5), 950–959. doi.org
-

12. ANEXOS

Anexo 1. Postproceso Interferometría

Anexo 2. Clasificación de coberturas.

Anexo 3. Isoyetas e Isotermas.

Anexo 4. Desarrollo y entrenamiento del modelo

Anexo 5. Sismicidad Histórica

Anexo 6. Script de entrenamiento

Anexo 7. Script de validación

Anexo 8. Tool de entrenamiento