



INVESTIGACIÓN X

PROFUNDIZACIÓN

MODELO DE EVALUACIÓN CREDITICIO BASADO EN PRINCIPIOS DE UN ECOSISTEMA DIGITAL BANCARIO MEDIANTE ESTRATEGIAS DE BUSINESS INTELLIGENCE Y MECANISMOS DE REPUTACIÓN EN EL SECTOR DE INDUSTRIA TEXTIL DE LAS PYMES COLOMBIANAS

Autor

William Steven Rodriguez Rodriguez

Tutor

Paulo Alonso Gaona García, PhD

Universidad Distrital Francisco José De Caldas
Maestría en Ciencias de la Información y las Comunicaciones
Énfasis en Geomática
Bogotá, Colombia
noviembre de 2024

CONTENIDO

ÍNDICE DE FIGURAS.....	6
ÍNDICE DE FORMULAS.....	8
1. INTRODUCCIÓN.....	9
2. PROBLEMA DE INVESTIGACIÓN	11
2.1 PLANTEAMIENTO DEL PROBLEMA.....	11
2.2 FORMULACION DEL PROBLEMA.....	15
2.3 SISTEMATIZACION DEL PROBLEMA.....	15
3. OBJETIVOS	16
3.1 OBJETIVO GENERAL.....	16
3.2 OBJETIVOS ESPECÍFICOS.....	16
4. JUSTIFICACION.....	17
4.1 JUSTIFICACIÓN TEÓRICA.....	17
4.2 JUSTIFICACIÓN METODOLÓGICA.....	17
4.3 JUSTIFICACIÓN PRACTICA.....	18
5. MARCO DE REFERENCIA	20
5.1 MARCO TEÓRICO	20
5.1.1 MECANISMOS DE REPUTACIÓN SOBRE ENTORNOS DIGITALES	20
5.1.2 BUSINESS INTELLIGENCE EN ANÁLISIS DE REDES SOCIALES	21
5.1.3 BUSINESS INTELLIGENCE APLICADO A PYMES	23
5.1.4 INNOVACIÓN ECOSISTEMA DIGITAL MERCADO FINANCIERO	24
5.1.5 MODELOS TRADICIONES DEL RIESGO CREDITICIO FINANCIERO.....	26
5.2 MARCO CONCEPTUAL.....	27

5.2.1	BUSINESS INTELLIGENCE.....	27
5.2.2	AMAZON WEB SERVICES BI ORIENTADOS.....	28
5.2.3	ECOSISTEMA DIGITAL BANCARIO	30
5.2.4	OPEN FINANCE - OPEN BANKING.....	31
5.2.5	PROCESAMIENTO DE LENGUAJE NATURAL (NPL)	32
5.2.6	ARBOLES DE DECISIÓN.....	33
5.2.7	TEORÍA NAIVE BAYES.....	34
5.2.8	ETL (EXTRACT, TRANSFORM & LOAD).....	34
5.2.9	MACRO-SECTOR TEXTIL PYMES COLOMBIA	35
6.	HIPÓTESIS	38
7.	TRABAJOS RELACIONADOS.....	39
7.1.1	INCLUSIÓN FINANCIERA EN COLOMBIA	41
7.1.2	SOBRE LAS FUENTES DE DATOS ALTERNATIVOS.....	42
7.1.3	MARCO CONCEPTUAL DEL DIAGNÓSTICO	43
7.1.4	DATOS DE REDES SOCIALES	44
7.1.5	DATOS DE PSICOMETRÍA.....	45
7.1.6	DATOS DE OPEN BANKING	46
7.1.7	DATOS DE TELEFONÍA MÓVIL (TELCO/CDR).....	47
7.1.8	DATOS DISPOSITIVOS SMARTPHONE (EXTRAÍDOS POR SDK).....	48
7.1.9	DATOS DE TRANSACCIONES PÚBLICAS	49
7.1.10	ENTORNO NORMATIVO	50
7.1.11	RECOMENDACIONES DE SELECCIÓN MERCADO EPC	50
7.1.12	RECOMENDACIONES SOBRE CAPACIDADES Y ACCIONES	51
7.1.13	RECOMENDACIONES DE POLÍTICA PÚBLICA.....	52
7.1.14	AVANCES PARA ECOSISTEMA DIGITAL	53

8.	METODOLOGÍA.....	56
8.1	CRITERIOS MÍNIMOS DE LA EMPRESA ESTUDIO	57
8.2	RECOLECCIÓN, CLASIFICACIÓN Y PROCESAMIENTO DE DATOS	58
8.3	FORMULACIÓN ESTRATEGIA BUSINESS INTELLIGENCE.....	60
8.4	IDENTIFICACIÓN DEL ECOSISTEMA DIGITAL	62
8.5	VALIDACIÓN Y COMPARACIÓN DEL MODELO RESULTADO	63
8.6	CALCULO MODELOS TRADICIONALES	63
8.7	CALCULO MODELOS IA.....	65
9.	MODELO PLANTEADO.....	69
9.1	PORTAL WEB (FRONT-END).....	71
9.2	CAPA DE API	72
9.3	CAPA DE BUSINESS INTELLIGENCE (BI).....	72
9.4	CAPA DE TRANSFORMACIÓN DE DATOS	74
9.5	BASE DE DATOS.....	75
9.6	FUENTES DE INFORMACIÓN EXTERNAS.....	75
9.7	FLUJO FUNCIONAL.....	76
9.7.1	DETALLE FUNCIONAL DEL PORTAL WEB	76
9.7.2	CAPA DE API (MIDDLEWARE).....	76
9.7.3	BASE DE DATOS HÍBRIDA (SQL Y NOSQL)	77
9.7.4	CAPA DE TRANSFORMACIÓN DE DATOS	77
9.7.5	CAPA DE BUSINESS INTELLIGENCE (BI).....	78
9.8	FLUJO DE DATOS	78
9.9	PROPUESTA MODELO DE SOLUCIÓN.....	80
9.9.1	RECOPIACIÓN DE DATOS EXTERNOS	81
9.9.2	ANÁLISIS SENTIMIENTOS NLP	82

9.9.3	INTEGRACIÓN CON AWS SAGEMAKER	82
9.9.4	EVALUACIÓN Y PRESENTACIÓN DE RESULTADOS	83
9.9.5	FLUJO COMPLETO Y RETROALIMENTACIÓN	83
10.	ANÁLISIS DE RESULTADOS	84
10.1	CÁLCULO SCORE ALTERNATIVO	88
10.1.1	PYMES COLOMBIANAS	90
10.1.2	SMALL AND MEDIUM-SIZED ENTERPRISES (SMES)	95
10.1.3	GRANDES EMPRESAS COLOMBIANAS	101
10.2	CÁLCULO SCORE TRADICIONAL	107
10.3	CÁLCULO SCORE BASADO IA	112
10.3.1	MODELO DE REGRESIÓN LOGÍSTICA	113
10.3.2	SUPPORT VECTOR MACHINES (SVM)	115
10.3.3	REDES NEURONALES ARTIFICIALES	117
10.3.4	MODELOS IA EXPLICABLE (XAI)	120
10.4	CÁLCULO SCORE FINAL COMPARATIVA	124
10.5	GENERACIÓN DASHBOARD INDICADORES FINALES	130
10.5.1	VISUALIZACIÓN GENERAL INDICADORES Y SCORES	131
10.5.2	GENERACIÓN ECOSISTEMA DIGITAL BANCARIO	134
11.	CONCLUSIONES	138
12.	PRINCIPALES APORTES	140
12.1	PLANTEAMIENTO TÉCNICO	141
12.2	FLUJOS FUNCIONALES DEFINIDOS	141
12.3	MODELO DE SOLUCIÓN ARQUITECTÓNICO	142
13.	RECOMENDACIONES Y FUTUROS TRABAJOS	144
14.	REFERENCIAS	149

Índice de Figuras

Ilustración 1. Modelo BI (Linden & Van Beek, 2020)	27
Ilustración 2. Ecosistema Digital Bancario (Dapp, 2015).....	30
Ilustración 3. Proceso ETL (Beyer, Thoo, Zaidi, Greenwald, 2016).....	35
Ilustración 4. Ventas Netas PyMEs	36
Ilustración 5. Proporción Ganancias en Macro sectores PyMEs	37
Ilustración 6. Datos Alternativos (Departamento Nacional de Planeación, 2024).	42
Ilustración 7. Modelo Datos PSD2s (Departamento Nacional de Planeación, 2024).	46
Ilustración 8. Arquitectura de investigación Propuesta	56
Ilustración 9. Estrategia Business Intelligence FASE I.	60
Ilustración 10. Estrategia Business Intelligence FASE II.	61
Ilustración 11. Modelo de Contexto C4	70
Ilustración 12. Modelo de Solución por Capas	71
Ilustración 13. Secuencia Estrategia Business Inteligent.	73
Ilustración 14. Modelo de Solución Funcional	79
Ilustración 15. Modelo de Solución.	81
Ilustración 16. Modelo Funcional de Calculo Scoring.	84
Ilustración 17. Resultado Análisis Sentimental Pymes Colombia.	91
Ilustración 18. Distribución Resultados Pymes Colombia.....	92
Ilustración 19. Matriz de Predicción Pymes Colombia.....	93
<i>Ilustración 20. Resultado Análisis Sentimental SMEs Estadounidenses.</i>	<i>96</i>
<i>Ilustración 21. Distribución Resultados SMEs Estadounidenses.</i>	<i>98</i>
<i>Ilustración 22. Matriz de Predicción SMEs Estadounidenses.</i>	<i>99</i>
<i>Ilustración 23. Resultado Análisis de Sentimientos Grandes Empresas Colombia.</i>	<i>102</i>
<i>Ilustración 24. Distribución Resultados Grandes Empresas Colombia.</i>	<i>104</i>
<i>Ilustración 25. Matriz Predicción Grandes Empresas Colombia.</i>	<i>105</i>
Ilustración 26. Score Enfoque Orientado al Crecimiento - Énfasis en la rentabilidad.....	109
Ilustración 27. Comparación Score Tradicional Top 10 Empresas Colombia.	110
<i>Ilustración 28. Resultado Modelo de Regresión Logística.</i>	<i>113</i>

Ilustración 29. Resultado Support Vector Machines. 116

Ilustración 30. Resultado Redes Neuronales Artificiales. 118

Ilustración 31. Resultado Modelos IA Explicable. 121

Ilustración 32. Resultado Variación Score Final Vs Score Tradicional. 128

Ilustración 33. Dashboard: Visualización Resumen Crediticio. 132

Ilustración 34. Dashboard: Visualización Ecosistema Digital Bancario. 135

Ilustración 35. Embedded Finance (Departamento Nacional de Planeación, 2024). 136

Índice de Formulas

Ecuación 1. Árbol de Decisiones	33
Ecuación 2. Naïve Bayes	34
Ecuación 3. Razón de liquidez	63
Ecuación 4. Razón de endeudamiento	64
Ecuación 5. Margen Operativo.....	64
Ecuación 6. ROA	64
Ecuación 7. ROE	65
Ecuación 8. Apalancamiento Financiero	65
Ecuación 9. Modelo de Regresión Logística	66
Ecuación 10. Support Vector Machines	66
Ecuación 11. Redes Neuronales Artificiales.....	67
Ecuación 12. Modelos IA Explicable	67
Ecuación 13. Formula Complementaria Score Final	125
Ecuación 14. Resultado Score Final Empresa I	126
Ecuación 15. Resultado Score Final Empresa II	126
Ecuación 16. Resultado Score Final Empresa III	127
Ecuación 17. Resultado Score Final Empresa IV.....	127

1. INTRODUCCIÓN

El alto grado de competitividad del mercado actual y sus constantes cambios requiere de decisiones rápidas, acertadas y correctas para el éxito dentro del comercio mundial y regional, agregado a esto la situación global actual producida por la pandemia del virus COVID-19, ha repercutido en todos los mercados y sectores financieros, para América del Sur, se prevé una caída del 5,2% en la economía. Algunos países de esta subregión fueron muy afectados por la caída de la actividad en China, que es un importante mercado para sus exportaciones de bienes (CEPAL, 2020). Las Pymes son un conjunto de empresas dentro de una clasificación específica. En la economía colombiana la característica principal que define la clasificación depende del número de empleados que tengan disponible la organización, la clasificación se define en micro, pequeña y medianas empresas. Estas empresas representan el sector fundamental de la economía, 99.6% de las empresas en Colombia son micro, pequeñas y medianas empresas.

Los gobiernos mundiales y en específico el gobierno colombiano ha abierto programas de ayudas para el sector Pymes apoyando las decisiones en entidades financieras bancarias. Los paquetes fiscales anunciados en la región son la primera respuesta al impacto socioeconómico de la pandemia. Por su parte, los bancos centrales de la región han anunciado “medidas pocos convencionales” para expandir la liquidez, incluida la compra de activos públicos y privados. (CEPAL, 2020). Las condiciones actuales plantean un escenario donde las organizaciones bancarias tendrán que adaptarse y emplear nuevas alternativas para solventar el alto flujo de posibles clientes, teniendo en cuenta la implementación y el entendimiento de nuevas tecnologías y ecosistemas digitales.

Teniendo en cuenta el escenario previo, se define un interés en el ámbito financiero y académico por proponer nuevas metodologías para la definición del acceso a servicios crediticios. Evaluando los modelos tradicionales de análisis de riesgo se evidencia una oportunidad para implementar un modelo complementario que permita determinar, con base en la opinión y calificación pública recolectada y publicada en plataformas digitales, si

una organización tiene un perfil favorable para considerar el desembolso de ayudas financieras. Este análisis se realiza recopilando y clasificando datos de plataformas digitales sociales, como Facebook y Twitter, implementando metodologías basadas análisis de sentimientos donde se obtiene un resultado en forma de clasificación entre un perfil positivo o negativo dependiendo de la interpretación del texto base, con este resultado se define un modelo basado en Business Intelligent enfocado a la toma de decisiones para la identificación de servicios y productos dentro de un ecosistema digital bancario, finalmente este modelo se valida con respecto a los modelos tradicionales de análisis de riesgo para obtener la diferencia porcentual de los productos confirmados y denegados para las Pymes.

La estructura de este documento toma en consideración los apartados fundamentales descritos por la Maestría en ciencias de la información y las comunicaciones, se encuentra organizado de la siguiente forma: como primera etapa se realiza la descripción y definición del problema de investigación, en la segunda etapa se identifican los objetivos de la investigación, para la tercera etapa se determina la justificación de su investigación propuesta. El marco referencial conforma la cuarta etapa basándose en la recopilación información fundamental para la investigación. Así mismo el apartado de trabajos relacionados se enfoca en recopilar importantes conceptos técnicos para complementar el marco referencial. La hipótesis de la investigación se desarrolla en el quinto apartado que plantea la posibilidad de un modelo que pueda actuar como una herramienta complementaria para instituciones bancarias impactando el sector de las PYMES colombianas, principalmente aquellas que no tienen un acceso fácil a servicios de crédito.

En el capítulo dedicado al modelo, se desarrolla un sistema de evaluación crediticio basado en principios de Business Intelligence y un ecosistema digital bancario, que incorpora mecanismos de reputación. La fase de implementación se detalla en el capítulo nueve, donde se presentan los resultados del modelo, incluyendo las correlaciones entre las variables alternativas y el riesgo crediticio de las Pymes. Finalmente, se realiza un análisis comparativo con los modelos tradicionales, evaluando los beneficios y las limitaciones de la metodología. En las conclusiones se destacan los aportes del modelo en términos de precisión y accesibilidad en la evaluación crediticia de las Pymes colombianas, ofreciendo así una alternativa significativa en el contexto actual.

2. PROBLEMA DE INVESTIGACIÓN

2.1 PLANTEAMIENTO DEL PROBLEMA

Las economías mundiales desde el año 2020 colocaron a la humanidad en una situación difícil, debido a la pandemia generada por el virus COVID-19, situación que no solo afectó de forma individual, sino a todas las sociedades y comunidades dentro de los países. El banco interamericano de desarrollo (BID) afirmó y enfatizó que los efectos de la pandemia por la propagación del COVID-19 sacudieron las estructuras socioeconómicas a nivel global, con impactos estimados en cifras astronómicas de pérdidas de vidas y empleos (BID, 2020). Esta afirmación nos dirige a analizar cómo y en qué niveles de la economía se generó una mayor afectación por los cierres y clausuras nacionales, y qué economías pudieron enfrentar la situación, considerando que aquellos países con ecosistemas de innovación más maduros y capacidades institucionales más desarrolladas fueron los que lograron responder a la crisis de manera más rápida y contundente (BID, 2020).

Según Hernández, la participación de las micro, pequeñas y medianas empresas (MiPymes) en la economía fue fundamental para que existiera un crecimiento económico sostenido en el país, siendo México el mejor representante con un 99,7% de las empresas como Pymes que generaron el 42% del PIB (Hernández, 2000). Las Pymes son empresas medianas y pequeñas que están en la base del mercado financiero de un país, esto lleva a que estas organizaciones se vean en la necesidad de aumentar de forma constante el valor de sus activos. Las empresas que no cuentan con los activos suficientes o el número adecuado de inversionistas, deben centrarse en la tarea de encontrar otros métodos financieros con los cuales puedan realizar una expansión en el mercado objetivo y de esta obtener como resultado un mejor posicionamiento.

Por lo anterior, los gobiernos y entidades bancarias han brindado a lo largo de los años incentivos y campañas dirigidas a la obtención de servicios crediticios tradicionales, como afirman los investigadores Zavolokina, Dolata & Schwabe (2016). Durante las últimas

décadas, las empresas del sector de servicios financieros se volvieron cada vez más digitales en sus procesos, productos y comunicación. Debido a este desarrollo, la cooperación aumentó ya que las empresas y los bancos en particular no solo pueden confiar en sus competencias internas. En cambio, tienen que complementar sus propias competencias con las de otras empresas del sector de servicios financieros (Zavolokina, Dolata & Schwabe, 2016). Esto lleva a que las empresas realicen un análisis detallado del mercado respecto a cuál sería la entidad financiera y la mejor alternativa a tomar.

La investigación de ecosistemas empresariales es un área de investigación en crecimiento impulsada por la necesidad de un nuevo paradigma para crear estrategias, competir e innovar en la economía en red (Lansiti & Marco, 2004). Es posible identificar las causas de la situación actual, definiendo premisas para analizar como la poca adquisición de estas soluciones en los ecosistemas bancarios afectan los incentivos ofrecidos los bancos, insatisfacción por obtener ofertas más costosas dentro del mercado, afectación directa a la planeación dentro de las organizaciones, menor desarrollo a los sectores comerciales de un país.

Los ecosistemas empresariales pueden definirse como un conjunto de factores que contribuyen al propósito central del ecosistema empresarial al generar valor para sus clientes a través de la innovación. se explica los ecosistemas empresariales como redes de organizaciones que se mantienen unidas mediante contratos formales y dependencia mutua (Teece, 2007). El análisis del impacto se puede realizar teniendo en cuenta aspectos como la postulación a incentivos, tasas de interés del mercado, crecimiento de las pymes, crecimiento de cada sector con respecto a las Pymes. Tomando las premisas anteriores es evidente que, como resultado, es posible obtener poca expansión y crecimiento del sector Pymes, que amenazara en gran medida el desarrollo de económico de un país.

Para el autor Rimple Manchanda Taneja, Business Intelligence (BI) se muestra como una clara opción para contrarrestar los efectos negativos dentro de del sector Pymes, que es el más vulnerables, Business Intelligence puede explotarse como una fuente y un sistema de apoyo sólido, para cualquier organización, para desarrollar ideas de crecimiento en el escenario competitivo del mercado actual. Es una herramienta que guarda, ensambla,

acumula y procesa los datos para proporcionar información constructiva a la organización que ayuda a mejorar la toma de decisiones (Taneja, 2014).

En la actualidad, Colombia cuenta con un Sistema de Administración de Riesgo Crediticio (SARC), regulado por la súper intendencia financiera y su objetivo al evaluar las entidades financieras es determinar el impacto hacia los activos por incumplimiento de pago de los deudores. El SARC es reglamentado para todas las entidades financieras bajo vigilancia de la Superintendencia Financiera, con el fin de que todas las instituciones tengan una infraestructura tecnológica y los sistemas necesarios para garantizar la adecuada administración de crédito (Álvarez, Lochmüller & Osorio, 2011).

El SARC debe contar, al menos, con los siguientes componentes (Luís Cerón, Ronald Otero, 2011):

1. Políticas de administración del riesgo crediticio.
2. Procesos de administración del riesgo crediticio.
3. Modelos internos o de referencia para la estimación o cuantificación de pérdidas esperadas.
4. Sistema de provisiones para cubrir el riesgo crediticio.
5. Procesos de control interno.

Estas decisiones sobre el riesgo crediticio son soportados y avaladas a través de centrales de información crediticia, son sociedades especializadas en el manejo de información sistematizada que de manera centralizada y de acuerdo a criterios únicos y preestablecidos proporcionan a las entidades vigiladas los datos sobre el comportamiento crediticio de los clientes del sector financiero. La fuente de la información de estas sociedades la constituye de una parte sus entidades afiliadas y, de otra, el reporte de endeudamiento que las entidades vigiladas por la Superintendencia Bancaria le remiten a ésta, la cual es presentada en el producto “Endeudamiento Global” (SFC, 2000).

En Colombia existen dos entidades principales que se encargan de recibir, procesar, almacenar y clasificar la información financiera de una persona o empresa. Datacredito es una gran base de datos con información crediticia positiva, negativa e histórica de millones

de personas y empresas, es una unidad estratégica de negocios de Experian Colombia S.A, que lleva 40 años en el mercado (Datacredito, 2016). SIFIN es una central de riesgo, fue creada en 1981 como una unidad de negocio de la Asociación Bancaria y de Entidades Financieras de Colombia – Asobancaria para proveer servicios de Central de Información Financiera con el objetivo de recolectar, almacenar, administrar y procesar la información relativa a los clientes y usuarios de los sectores financiero, real, solidario y asegurador (TransUnion, 2020). Como se puede analizar estas entidades de riesgo han estado por muchos años prestando servicios para realizar las evaluaciones crediticias, pero así mismo no han presentado una evolución en cuento a los a la adaptación a nuevos factores de impactos dentro de la reputación de organizaciones, sus procesos deberían tomar en cuenta ecosistemas digitales de información pública para conseguir una imagen mucho más global de lo que representa esa entidad quien solicita acceso a servicios financieros.

Autores como (D'Arconteor, 2018) desarrollaron un modelo de BI aplicado para pequeñas empresas, con el objetivo de aumentar las ganancias. De manera particular se enfocaron en sector Pymes italiano, con una participación del 90% nacional. Como resultado de este modelo, definieron una metodología para implementar de forma ágil BI a los procesos internos de las organizaciones. Por su parte el autor Parama Fadli Kurnia, en su trabajo "Business Intelligence Model to Analyze Social Media Information" (Kurnia, 2018) identificaron fuentes de opinión públicas como las redes sociales que representan la información fundamental para determinar la reputación que puede lograr una organización. Realizaron un estudio donde se evidenciaba como la herramienta BI puede alimentarse con datos digitales en tiempo real para que pueda dar ayudar en la toma de decisiones dentro de la organización correspondiente. Como aspecto principal identificaron y diseñaron una metodología digital basada en 4 etapas para la obtención clasificación, análisis y creación del modelo BI.

A partir de este panorama, son varios los desafíos que el sector bancario se enfrenta para hacer frente a una demanda de PYMES que utilizan estrategias de marketing basados en plataformas digitales, a los cuáles en diferentes escenarios no es posible llegar o cubrir a través de un portafolio de servicios que puedan adquirir, por lo tanto la siguiente propuesta plantea la creación de un modelo de evaluación crediticio basado en principios de un

ecosistema digital bancario mediante estrategias business intelligence y mecanismos de reputación en el sector pymes colombianas donde se puedan asociar características ofrecidas por el sector bancario y características dentro de las Pymes que puedan necesitar estas opciones ofrecidas.

2.2 FORMULACION DEL PROBLEMA

¿Cómo definir un modelo de evaluación crediticio basado en mecanismos de reputación y principios de Business Intelligence como alternativa a los modelos tradicionales dentro de un ecosistema digital bancario para facilitar procesos de acceso a servicios crediticios en el sector de las PYMES colombianas?

2.3 SISTEMATIZACION DEL PROBLEMA

- ¿Como establecer las variables para conformar el modelo de evaluación basado en mecanismos de reputación y factores de evaluación tradicional crediticios
- ¿Qué estrategias de Business Inteligente se pueden utilizar como método de procesamiento y análisis de datos para establecer el modelo de evaluación basado en reputación y metodologías tradicionales de evaluación crediticia?
- ¿Cómo plantear un modelo de evaluación basado en principios de Business Intelligence y mecanismo de reputación para llevar a cabo una integración con los métodos de evaluación crediticios tradicionales?
- ¿Cómo realizar la generación de indicadores a partir de los resultados del modelo planteado mediante estrategias de visualización?

3. OBJETIVOS

3.1 OBJETIVO GENERAL

Diseñar un modelo de evaluación crediticio basado en principios de un ecosistema digital bancario mediante estrategias de Business Intelligence y mecanismo de reputación para facilitar procesos de acceso a servicios crediticios en el sector de las PYMES colombianas.

3.2 OBJETIVOS ESPECÍFICOS

- Establecer las variables para conformar el modelo de evaluación basado en mecanismos de reputación y factores de evaluación tradicional crediticios utilizados en un ecosistema digital bancario.
- Identificar estrategias de Business Intelligence para ser utilizadas como método de procesamiento y análisis de datos para el establecimiento del modelo.
- Plantear un modelo de evaluación basado en principios de Business intelligence y mecanismo de reputación que permite ser integrado con los métodos de evaluación crediticios tradicionales utilizados en un ecosistema digital bancario.
- Diseñar un componente informático que permita la generación de indicadores a partir de los resultados obtenido por el modelo planteado mediante estrategias de visualización de datos.

4. JUSTIFICACION

4.1 JUSTIFICACIÓN TEÓRICA

La ejecución de Business Intelligence es costosa, se requiere de una gran inversión. A veces, los implementadores de Business Intelligence enfrentan algunas deficiencias, como la disponibilidad de datos de calidad. Esto requiere un trabajo de limpieza de datos antes de que pueda usarse en las herramientas de Business Intelligence (Taneja & Rimple, 2014). Por lo anterior, La Business Intelligence a menudo está estrictamente relacionada con CRM, Gestión de la relación con el cliente que de todos modos no debe considerarse de ninguna manera solo como una tecnología (D'Arconte, 2018), este proyecto explora la implementación de un modelo BI basado en métodos de reputación, realizando búsquedas de data provenientes de fuentes como redes sociales y entidades gubernamentales con el objetivo de realizar clasificación sobre esta información por medio de algoritmos de minería de datos, con el fin de evaluar el grado de afectación que representan para las PYMES la decisión que el modelo pueda brindar sobre obtención de un ecosistema bancario digital.

4.2 JUSTIFICACIÓN METODOLÓGICA

Las bases de datos o centrales de información (Central de Información de la Asociación Bancaria y de Entidades Financieras de Colombia -CIFIN-, Datacrédito, Covinoc, Computec, Credicheque, Fenalcheque, etc.) son sociedades o agremiaciones de carácter privado en las cuales se registra el comportamiento crediticio, financiero y comercial de las personas que celebran operaciones con entidades financieras, cooperativas y empresas de sector real (Superintendencia Financiera de Colombia, 2019), estas centrales de riesgos presentan soluciones digitales para definir la viabilidad de adquisición, basado solamente en información dentro del historial de pagos, de esta forma se puede definir una herramienta complementaria basada en mecanismo de reputación que utilicen la opinión pública que tiene la sociedad sobre la organización. Por lo anterior, el modelo propuesto utiliza estrategias basadas en Business Intelligence como un elemento esencial para las políticas

bancarias avanzadas. Esto permitirá ayudar a mejorar la relación con el cliente al proporcionar información que ayuda a mejorar los productos y servicios, aumentar la eficiencia para manejar el riesgo y operar sin problemas mientras se gestiona la competencia (Taneja, 2014).

4.3 JUSTIFICACIÓN PRACTICA

El término Fintech se usa para empresas en el sector de servicios financieros que crean, cambian o mejoran servicios, productos, procesos o modelos comerciales existentes basados en nuevas oportunidades tecnológicas con el objetivo de aumentar la calidad para el cliente que está cada vez más conectado digitalmente (Iyer & Basole, 2016).

Por lo anterior, las Fintech son un tipo especial de Pymes que presenta características dirigidas a la utilización de tecnologías para ofrecer servicios, mejorar sus procesos y métodos de comunicación. Estas empresas representan la innovación dentro los diferentes mercados financieros, del desarrollo de estas empresas depende la evolución y adaptación que las demás empresas tradicionales tomarán como ejemplo para aplicar en su estructura organizacional.

Durante las últimas décadas, las empresas del sector de servicios financieros se volvieron cada vez más digitales en sus procesos, productos y comunicación. Debido a este desarrollo, la cooperación aumentó ya que las empresas y los bancos en particular no solo pueden confiar en sus competencias internas. En cambio, tienen que complementar sus propias competencias con las de otras empresas del sector de servicios financieros, (Graupner, Melcher, Demers & Maedche, 2015).

El mercado global actual, amplía un nuevo campo de acción para las entidades Pymes, estas se basan en escenarios delimitados en los que se puedan implementar nuevas tecnologías. El resultado propuesto en esta investigación un modelo viable que podrá ser implementada en diferentes escenarios tomando en cuenta diferentes variables en el entorno que son definidas por las características de las Pymes evaluadas, de esta forma

aplicar Business Intelligence como técnica para la toma de decisiones, apoyado en un modelamiento SIG para demostrar un nivel de correlación mayor.

La rapidez con que cambian las tecnologías en el panorama competitivo en el siglo XXI, la globalización y la necesidad de innovar a nivel mundial son las razones que más influyen en la decisión de las empresas de trabajar en un plan estratégico corporativo, (Mackenzie, 2015). Además, la aparición de nuevos jugadores de nicho de mercado, llamados Fintech, que ingresaron al mercado de servicios financieros, conducen a más cambios en el ecosistema (Zavolokina, Dolata & Schwabe, 2016).

Por consiguiente, la tarea de actualizar las técnicas y metodologías implementadas en el funcionamiento interno de cualquier empresa, debe ser un aspecto fundamental para llegar un posicionamiento en el mercado consistente. Las Pymes que puedan utilizar la tecnología para incrementar su desarrollo en las etapas iniciales, podrán contar con ventajas directas sobre la competencia tradicional.

5. MARCO DE REFERENCIA

5.1 MARCO TEÓRICO

5.1.1 MECANISMOS DE REPUTACIÓN SOBRE ENTORNOS DIGITALES

La imagen, marca o popularidad de un ente empresarial en el mercado público puede definir la afinidad de los clientes interesados relacionando prospectos de campañas, productos o servicios a la opinión pública genera, como se relaciona en el texto *Reputación Corporativa*, la reputación es un sentimiento positivo hacia una persona o institución que integra tres vectores: admiración, buena estima y confianza. Está en la base de la confianza y se trata de un sentimiento de enorme relevancia, puesto que es el detonante de las actitudes y comportamientos favorables hacia una empresa, una institución o un país (Ángel Alloza, Enrique Carreras, Ana Carreras, 2013). La afinidad hacia los valores y visión de una empresa es un factor dinámico que deriva de la reputación publica generado por escenarios reales, acciones y decisiones prácticas que contribuye a la opinión pública positiva, como afirma Quevedo, De la Fuente y Delgado, La reputación, es un producto de construcción y validación social, que es creada y mantenida a través de un proceso de legitimación, entendiendo que las organizaciones son legítimas cuando son aceptadas por el entorno que las rodea. Desde un punto de vista económico, y particularmente en el ámbito conceptual en que nos situamos, parece adecuado atribuir al marco institucional como consignatario de los criterios por los que la empresa va a ser evaluada (Quevedo, De la Fuente y Delgado, 2005).

La posibilidad de transmitir una imagen empresarial sólida y comprometida, a un amplio número de potenciales clientes representa un reto para las PyMEs utilizando los métodos tradicionales de difusión, teniendo en cuenta las restricciones monetarias o el conocimiento especializado requerido. Teniendo esto en cuenta el papel de las redes sociales como mecanismos de reputación genera un impacto positivo acotando los parámetros de fácil acceso y amplia difusión como se evidencia, las redes sociales utilizadas como herramienta de relaciones públicas pueden cambiar los procedimientos para la transferencia de

información en las Pymes, y potencializar la gestión de información dentro de las mismas y su utilización dentro de las empresas tiene impacto social y económico (Pérez, 2012).

Como siguiente etapa se propone la utilización de tecnológicas relacionadas con la inteligencia artificial que puedan recopilar información basada en el branding y nombre de la empresa evaluada, como se propone en *The Impact of Artificial Intelligence on Branding: A Bibliometric Analysis*, La IA está cambiando sustancialmente las preferencias de marca, las estrategias de marketing y la actitud de los clientes. Además, estos cambios inminentes en la economía global. Para las empresas con modelos de servicios empresa a empresa (B2B), la IA ayuda a transformar big data en información y conocimientos confiables que podrían ser necesarios para desarrollar estrategias efectivas de marketing y ventas (Varsha, Akter, Kumar, Gochhait, & Patagundi, 2021).

Por esta razón se proponen tres mecanismos de reputación complementarios para obtener una imagen pública certera de las instituciones evaluadas.

- Reputación basada en opinión pública recolectada desde plataformas de redes sociales.
- Información recolectada por herramientas de inteligencia artificial definiendo escenarios demostrables.
- Fuente de datos tradicionales de carácter privado o gubernamentales que comparta información comportamental y/o financiera pública.

5.1.2 BUSINESS INTELLIGENCE EN ANÁLISIS DE REDES SOCIALES

En este trabajo, se proponen como objetivo específico analizar datos de redes sociales para aplicar estrategias de Business Intelligence (BI) que apoyen la toma de decisiones en empresas, con el fin de entender y gestionar la percepción social sobre sus marcas. Este enfoque se toma como referencia la metodología planteada por Fadli Kurnia y Suharjito (2018), quienes destacan cómo el análisis de contenido en redes sociales, mediante métodos de minería de datos, permite extraer información relevante para la toma de decisiones empresariales, generando beneficios tanto para empresas como para sus

consumidores. Las fuentes de datos que sustentan este análisis se extraen de redes sociales, específicamente de las cuentas de Facebook y Twitter, alineándose con las técnicas que ya han demostrado su valor en estudios previos (Parama Fadli Kurnia, Suharjito, 2018). Se evalúan clasificaciones varios ítems como entretenimiento, economía, salud, culinaria, estilo de vida, automotriz, política, fútbol, tecnología y viajes. En el estudio de Parama Fadli Kurnia y Suharjito (2018), se emplean métodos de clasificación de texto que incluyen principalmente técnicas de minería de datos y procesamiento de lenguaje natural (NLP) para analizar el contenido de redes sociales. Específicamente, el análisis de sentimientos y el uso de algoritmos de clasificación de texto, como Naive Bayes y Support Vector Machines (SVM), se destacan como técnicas centrales para interpretar las opiniones y clasificar el contenido socialmente relevante en redes sociales como Facebook y Twitter.

Los autores Fadli Kurnia y Suharjito proponen como metodología para el desarrollo del modelo que analiza información de redes sociales, cuatro etapas fundamentales. La primera etapa es la Recopilación de datos, en esta etapa existe un proceso con el cual se obtienen datos desde dos diferentes plataformas Facebook y Twitter a través de Social Media API. La segunda etapa es el análisis de contenido en esta etapa se define una clasificación de la información, esto se basa en algoritmos de clasificación de texto Naive Bayes, Decision Tree y SVM. La tercera etapa es el proceso de almacenamiento de datos, para esta etapa se utiliza el método de Kimball, utilizando sus 4 etapas. Finalmente, se realiza el sistema donde se muestra el uso de Business Intelligence, este es un sistema con el cual el cliente puede interactuar. Los autores alcanzan su objetivo desarrollando la herramienta propuesta y evaluando cada uno de los algoritmos de clasificación implementados, los rendimientos de estos se obtienen de la siguiente forma, SVM con 78.99% de precisión, Naive Bayes precisión de 74.67% y Árbol de decisión una precisión 57.66% (Parama Fadli Kurnia, Suharjito, 2018).

En el artículo *“Business Intelligence Model to Analyze Social Media Information”*, propuesto por Fadli Kurnia y Suharjito define perfectamente como desarrollar un modelo de Business Intelligence, con datos que no están bajo el dominio de las empresas objetivos, este análisis se hace con datos públicos que toda la sociedad proporciona. El desarrollo de la metodología tiene la mayor importación y valor del artículo se definen y delimitan las etapas

y en adición se evalúan algoritmos de clasificación que pueden ser usados en diferentes y nuevas investigaciones, este artículo es un ejemplo sobre el cual basar la propuesto de proyecto de investigación para un Modelo de evaluación crediticio basado en principios de un ecosistema digital bancario mediante estrategias de Business Intelligence y mecanismos de reputación en el sector de industria textil de las PYMES colombianas.

5.1.3 BUSINESS INTELLIGENCE APLICADO A PYMES

En el contexto empresarial actual, caracterizado por su alta competitividad y rapidez en la toma de decisiones, el uso de Business Intelligence (BI) se ha vuelto crucial para las organizaciones, incluidas las pequeñas y medianas empresas (PyMEs). A diferencia de las grandes corporaciones, las PyMEs suelen enfrentar limitaciones de recursos y capacidades tecnológicas, lo que dificulta su acceso a herramientas avanzadas de BI. Sin embargo, estas tecnologías pueden proporcionarles una ventaja significativa al ofrecer análisis detallados y en tiempo real de sus datos operativos, financieros y de clientes, facilitando así la optimización de sus procesos y una mejor adaptación a las demandas del mercado (Wixom & Watson, 2010). La implementación de BI permite a las PyMEs superar barreras comunes, como la falta de conocimiento sobre el comportamiento del cliente, el control de inventarios y la gestión de la rentabilidad. Además, el uso de BI en PyMEs ha demostrado mejorar la eficiencia en el servicio al cliente y la toma de decisiones estratégicas, elementos clave para su crecimiento y supervivencia en un mercado dinámico (Fink, Yogev, & Even, 2017). De este modo, el BI se convierte en una herramienta no solo de análisis, sino también de transformación organizacional para las PyMEs, posibilitando una competitividad basada en el conocimiento y en la capacidad de respuesta ante cambios del entorno.

Para abordar esta problemática, el autor plantea un enfoque dual por un lado, evalúa cómo se puede implementar BI en entornos prácticos y, por otro, explora la aplicabilidad de estas tecnologías en empresas pequeñas. En particular, se enfoca en el impacto que estas herramientas pueden tener en la rentabilidad y la satisfacción del cliente, elementos cruciales para la fidelización y el crecimiento sostenible en mercados altamente competitivos (Micu et al., 2012). Este enfoque es especialmente relevante para las PyMEs, que enfrentan desafíos específicos en términos de recursos y capacidad de inversión en

tecnología. La propuesta del autor sugiere que la implementación de BI en estas empresas puede mejorar no solo su rendimiento económico sino también su capacidad de respuesta a las demandas del mercado, permitiéndoles competir con organizaciones de mayor tamaño y recursos. La tecnología de BI se aplica a la capa de Customer Relationship Management (CRM) para optimizar el manejo de la relación con los clientes. Esto no solo permite a las empresas mejorar la retención de clientes mediante la personalización y el análisis de sus preferencias, sino que también facilita la identificación de patrones de comportamiento que son esenciales para la toma de decisiones estratégicas (Davenport, 2013; Micu et al., 2012). En este contexto, el componente de lealtad del cliente se convierte en un indicador crítico, ya que es fundamental para la supervivencia y el posicionamiento competitivo de las empresas. El análisis de los datos de pequeñas empresas revela que, en general, estas no emplean tecnologías avanzadas para recopilar información crítica, confiando en herramientas tradicionales como hojas de cálculo que, si bien útiles, son insuficientes para una comprensión profunda de factores como la fidelización y satisfacción del cliente (Chen et al., 2012). La conclusión del artículo destaca no solo los beneficios de implementar BI en pequeñas empresas, sino también los obstáculos que estas enfrentan, particularmente relacionados con la educación y preparación gerencial. En muchos casos, los líderes de PyMEs carecen de los conocimientos necesarios para integrar tecnologías en sus procesos, lo que limita su capacidad para aprovechar el potencial de BI y maximizar su rendimiento en el mercado (Fink et al., 2017). En este sentido, el artículo corrobora investigaciones previas que señalan a la analítica de datos como un diferenciador en el mercado global, permitiendo a las empresas ser más competitivas, resilientes y capaces de adaptarse a las demandas cambiantes del entorno empresarial (Wixom & Watson, 2010).

5.1.4 INNOVACIÓN ECOSISTEMA DIGITAL MERCADO FINANCIERO

El artículo examina la influencia de la inteligencia empresarial en la agilidad organizacional a través de la variable de mediación parcial Empoderamiento. La población estadística del estudio está compuesta por la Organización de Ingeniería de Construcción de Teherán (TCEO) y ETKA Organization Industries. El método para la recolección de datos que los autores utilizan es la distribución de 102 cuestionarios entre gerentes y personal directo con

los sistemas de información. La hipótesis del documento se basa en que la inteligencia empresarial tiene influencia directa e indirecta a través del empoderamiento en la agilidad organizacional. Los autores parten de una definición para Business Intelligence (BI), como el proceso de transformación de datos en bruto en información útil para apoyar estrategias comerciales efectivas y conscientes; capturar los datos comerciales y obtener la información correcta para la gente adecuada, en el momento adecuado, a través del canal correcto, es un aspecto crucial de BI, a menudo denominado omnipresencia. También se evidencia que las herramientas para el desarrollo de BI son amigables, iterativas e interactivas, permitiendo a los usuarios comerciales un acceso fácil. De esta manera, el usuario puede manipular datos directamente, teniendo así la posibilidad de extraer todo el valor contenido en esos datos comerciales

Como etapa de demostración los autores realizan un modelamiento del impacto tomando en cuenta tres pilares principales, inteligencia empresarial, empoderamiento y agilidad organizacional. Definen y organizan las relaciones que estos tres componentes tienen entre, proponiendo que el componente de inteligencia empresarial tiene una relación directa con la agilidad organizacional, pero tiene una segunda relación no directa a través del componente de empoderamiento. Finalmente, se realiza un modelo para el análisis de la inteligencia empresarial planteado seis aspectos categóricos: Integración de datos, capacidad analítica, calidad de los datos en el contenido, calidad de los datos de accesibilidad, el uso de datos de procedimientos comerciales y la cultura de la decisión analítica. Logrando a través de análisis estadístico la correlación para confirmar las hipótesis propuestas.

El artículo propone una evaluación directa a como la inteligencia empresarial permite que una empresa evolucione y se convierta en un participante competitivo dentro del mercado, además realiza una apreciación fundamental a la nueva cultura que se desarrolló dentro de las organizaciones, la agilidad es la revolución metodológica para la era de la información.

5.1.5 MODELOS TRADICIONES DEL RIESGO CREDITICIO FINANCIERO

Desde un esquema tradicional se han desarrollado diferentes modelos con el fin de analizar el riesgo crediticio que puede generar un individuo una organización que necesita solicitar servicios financieros, estos modelos toman aspectos netamente reglamentarios en cuanto a los ingresos, activos e historial de pago por servicios anteriores, La evaluación de la capacidad de una compañía para pagar sus deudas en un juicio complejo porque muchos factores afectan la calidad crediticia (Emery, Finnerty, Stowe, 2000).

Existen diferentes modelos para tomar la decisión sobre una solicitud, se tratarán teóricamente los más utilizados, las cinco C del crédito son cinco factores generales que los analistas de crédito a menudo considerar al tomar una decisión de otorgamiento de crédito (Emery, Finnerty, Stowe, 2000).

- **Capacidad:** La capacidad de pago del negocio que toma dinero prestado es el factor más importante en la decisión del banco. El flujo de efectivo del negocio es un elemento. El historial de crédito del dueño, incluyendo tanto sus deudas pasadas y presentes, como las personales y comerciales, es considerado como un buen indicador de su futuro comportamiento.
- **Capital:** El capital es el dinero que se ha invertido en el negocio. Los prestamistas potenciales esperarán ver una contribución razonable de los bienes personales de la dueña antes de prestarle cantidades adicionales.
- **Colateral:** Éstas son las garantías adicionales que se ofrece al banquero, por si acaso el negocio incumple con su deber de pagar el préstamo. Los activos tales como edificios, terrenos, equipos, cuentas por cobrar, y a veces inventario, se consideran fuentes de efectivo para pago de deudas.
- **Condiciones:** Las condiciones son, en parte, los propósitos o los usos que se le dará al dinero tomado en préstamo. Otras condiciones que se consideran son las de la economía en general, la de su industria y las demás industrias que afectan la suya.
- **Carácter:** La impresión general que usted crea ante el banquero es lo que se conoce como el carácter.

El modelo ZETA es propuesto por Altman, Haldeman y Narayanan en 1977, en esta publicación se introducen modificaciones a modelos tradicionales. Esta es la primera muestra de una adaptación de una modelo de riesgo crediticio tomando en consideración nuevos factores que afectan al mercado global actual, el propósito de este modelo ZETA es clasificar a las empresas en bancarota. En esta adaptación al modelo se evaluaron aspectos como: Rentabilidad de los activos, Estabilidad de los ingresos, Capacidad de servicio de la deuda, Rentabilidad acumulada, Liquidez, Capitalización y Tamaño, (Altman Haldeman y Narayanan, 1977)

5.2 MARCO CONCEPTUAL

5.2.1 BUSINESS INTELLIGENCE

El sistema de inteligencia empresarial es un dispositivo que recopila los datos y procesa los mismos y genera la información comercial relevante requerida para la toma de decisiones. Business Intelligence puede ser explotada, como fuente y un sistema de apoyo sólido, por una organización, para desarrollar ideas para el crecimiento en el escenario competitivo del mercado actual. Las herramientas de inteligencia empresarial forman parte del software que es particularmente competente en el ensamblaje, la acumulación, el procesamiento y la presentación de información comercial de manera útil (Taneja, 2014).




Ilustración 1. Modelo BI (Linden & Van Beek, 2020).

El objetivo de Business Intelligence es procesar los datos disponibles y proporcionando solo información relevante al gerente y ayuda en la toma de decisiones. Las decisiones tomadas por los gerentes son críticas. No solo afectan la estructura interna de la organización, sino también a las partes interesadas y sus consumidores. Por lo tanto, es la competencia de las herramientas de Business Intelligence lo que podría proporcionar la información relevante a los gerentes para una toma de decisiones eficiente y es la eficiencia de la decisión gerencial que podría mejorar la Delicia del Cliente, (Taneja, 2014).

Las herramientas de Business Intelligence son el software que utiliza las bases de datos para generar informes para los tomadores de decisiones. Es una fuente de información y un sólido sistema de soporte de decisiones útil para las organizaciones en el desarrollo de ideas para el crecimiento en el escenario competitivo del mercado actual, (Taneja, 2014). Por lo tanto, las herramientas de Business Intelligence se pueden utilizar para identificar y rastrear las áreas específicas de interés. Existen ejemplos de la Business Intelligence que siguen indirectamente a las redes sociales y los sitios de redes sociales y siguen los comentarios y comentarios sobre su producto y marca de los consumidores. Los datos buscados en estos sitios actúan como información que las empresas pueden utilizar para identificar sus áreas de mejora.

5.2.2 AMAZON WEB SERVICES BI ORIENTADOS

Business Intelligence como mecanismo para toma de decisiones basado en componentes tecnológicos se puede definir como, conjunto de capacidades de software que permite a las empresas acceder, analizar y desarrollar información procesable a partir de los datos para tomar decisiones empresariales. Por lo general, las herramientas de BI presentan información en paneles de control fáciles de usar y visualizaciones de datos que grafican y trazan las métricas clave. Si bien anteriormente eran una función de los equipos de tecnología o de TI que requerían experiencia especializada, las herramientas modernas de inteligencia empresarial ponen las capacidades de datos y análisis predictivo en manos de los responsables de la toma de decisiones, lo que les permite desarrollar informes y obtener información empresarial específica. Tradicionalmente, la inteligencia empresarial se ha

centrado en la elaboración de informes descriptivos y de diagnóstico de las actividades empresariales históricas y actuales (Amazon AWS, 2023).

- **AWS Glue:** El primer paso de un proyecto de análisis o ML consiste en preparar los datos para obtener resultados de calidad. AWS Glue es un servicio de integración de datos sin servidor que vuelve más fácil, rápido y barato el proceso de preparación de datos. Puede detectar y conectarse a más de 70 orígenes de datos distintos, administrar los datos en un catálogo centralizado, además de visualizar, crear, ejecutar y supervisar las canalizaciones de ETL implementadas para cargar los datos en los lagos de datos correspondientes y realizar su análisis complementario. (Amazon AWS, 2023).
- **Amazon QuickSight:** Amazon QuickSight potencia a las organizaciones basadas en datos con inteligencia empresarial (BI) unificada a hiperescala. Con QuickSight, todos los usuarios pueden satisfacer diferentes necesidades analíticas desde la misma fuente de información mediante modernos paneles interactivos, informes paginados, análisis integrados y consultas en lenguaje natural. Con Amazon Q en QuickSight, los analistas y usuarios empresariales pueden utilizar el lenguaje natural para crear, descubrir y compartir información significativa en cuestión de segundos, de forma que la información se convierta en impacto con mayor rapidez (Amazon AWS, 2023).
- **Amazon SageMaker Canvas:** A través de una interfaz sin código, puede crear modelos de aprendizaje automático de alta precisión, sin ninguna experiencia en aprendizaje automático ni escribir una sola línea de código. SageMaker Canvas brinda acceso a modelos listos para usar, incluidos modelos básicos de Amazon Bedrock o Amazon SageMaker JumpStart, o puede crear su propio modelo de aprendizaje automático personalizado utilizando AutoML con tecnología de SageMaker AutoPilot. Con SageMaker Canvas, puede utilizar SageMaker Data Wrangler para acceder e importar fácilmente datos de más de 50 fuentes, preparar datos utilizando lenguaje natural y más de 300 transformaciones integradas, crear y entrenar modelos de alta precisión, generar predicciones e implementar modelos en producción (Amazon AWS, 2023).

5.2.3 ECOSISTEMA DIGITAL BANCARIO

Es muy probable que muchos ecosistemas digitales continúen expandiendo sus colaboraciones con proveedores de tarjetas de crédito, compañías de telecomunicaciones, Fintech start-ups y proveedores de nicho, entrando en alianzas estratégicas para capturar más cuotas de mercado en el campo de los servicios financieros estandarizados, (Dapp, 2015). Para minimizar el impacto de la competencia potencial feroz en las instituciones financieras, tradicional los bancos deberían, por lo tanto, subirse al carro, desarrollar un ecosistema digital propios con sus propios servicios corporativos digitales, y también se convierten integrado en alianzas existentes con una mente abierta y / o formar la suya. Alianzas Ir solo podría resultar en su caída a mediano plazo considerando la ventaja de información sustancial que disfrutaban algunos digitales ecosistemas, las complejas demandas de la banca moderna basada en algoritmos en él era digital y los crecientes costos y presión de margen generados por el cambios en el entorno competitivo.



Ilustración 2. Ecosistema Digital Bancario (Dapp, 2015).

La competitividad futura dependerá de con qué rapidez y flexibilidad los bancos tradicionales logran responder a los desafíos del progreso tecnológico y las innovaciones

del cambio estructural digital, (Dapp, 2015). La implementación fluida de procesos y estructuras digitales también podría permitir bancos para aumentar su valor empresarial, porque este enfoque digital podría hacer es más fácil y económico implementar alianzas estratégicas, también temporales naturaleza. Además, esto ayudaría a atraer más clientes a la propiedad ecosistema a largo plazo.

5.2.4 OPEN FINANCE - OPEN BANKING

El acceso a un ecosistema financiero basado en recursos digitales representa una evolución con respecto a los modelos tradicionales de intercambio de información para la obtención de recursos y servicios, este nuevo paradigma se basa en el fácil acceso de los datos, la cooperación en la construcción de fuentes de información y la implementación de mecanismos seguros para compartir los resultados esperados, como se describe en *Evaluación de los desafíos de la implementación del Open Banking en Colombia como política pública*, El Open Banking es una herramienta que permite que el consumidor autorice a la entidad financiera donde maneja sus productos, el tratamiento de sus datos frente a terceros, pero también contribuye al fortalecimiento de los modelos colaborativos y competitivos ya que al tener mayor acceso a la información las entidades financieras pueden especializarse en el perfilamiento de los consumidores y ofrecer mejores servicios permitiendo concentrar toda la información de cuentas, tarjetas, créditos entre otros en un solo sistema, sin importar que estos sean de diferentes entidades permitiendo mayores actores oferentes de productos diferenciados puesto que conocen las tendencias de consumo. Adicionalmente da paso a que el dueño de los datos tenga control y autonomía sobre los mismos (Espeleta & Solano,2022).

Los escenarios de intercambio de información se pueden evaluar con elementos de los datos abiertos apoyadas en E-Commerce y entidades gubernamentales, modelos de negocio abiertos finanzas embebidas y finanzas automáticas y capacidades generadas basadas en el análisis de los mismos datos. Las diferentes industrias que consumen el modelo y lo retroalimentan con la captación segura de un volumen mayor de actividad financiera que refleja comportamientos para las empresas que ofrecen sus bienes y servicios de forma descentralizada, como lo define Lavalle director de Desarrollo de

Negocios de Citi Baname, el gran beneficio del Open Banking es que la data es del cliente. Los bancos que tienen mucho tiempo trabajando con clientes tienen la información de cómo gastan, cuánto dinero recibe y esa data es del cliente. La ventaja del Open Banking para esas instituciones es que van a poder acceder a esa data y brindar una oferta de valor en base a la misma (Lavalle, 2023).

5.2.5 PROCESAMIENTO DE LENGUAJE NATURAL (NPL)

El lenguaje natural desarrollado por cada una de las sociedades actuales representa una fuente de información que definen acciones o solicitudes por parte de diferentes actores, para llevar esta información a un entorno interactivo con actores máquinas es necesario la implementación de un sistema de interpretación que habilite la comprensión y la interacción entre humanos y computadoras.

Al permitir que las máquinas comprendan, interpreten y generen lenguaje humano de manera efectiva, el NLP abre un mundo de posibilidades en campos tan diversos como la traducción automática, la atención al cliente automatizada, el análisis de sentimientos en redes sociales, la extracción de información de grandes volúmenes de texto y la generación de contenido relevante y personalizado. Como se propone en *ChatGPT: Unlocking the Future of NLP in Finance*, El procesamiento del lenguaje natural se ha convertido en un área de investigación cada vez más importante en el campo de las finanzas, ya que permite el análisis de datos financieros no estructurados, como artículos de noticias, publicaciones en redes sociales e informes financieros. En los últimos años, el desarrollo de la tecnología GPT (Generative Pre-training Transformer) ha mejorado aún más el rendimiento de las aplicaciones financieras basadas en NLP (Zaremba & Demir, 2023).

Particularmente existe una aplicación para NLP basada en reconocer y evaluar opiniones en texto o imágenes representativas, que pueden ser recopiladas de diferentes fuentes públicas de participación masiva, resultando en una posición basada en una escala de sentimientos predefinidos, particularmente los autores Zaremba & Demir definen esta aplicación como, en el sector financiero el análisis de sentimientos se utiliza para detectar y cuantificar automáticamente el sentimiento expresado en texto, como publicaciones en

redes sociales y reseñas de clientes. también se utiliza en finanzas para generar explicaciones humanas de modelos y decisiones financieras. Los investigadores utilizaron NPL para generar explicaciones en lenguaje natural de un modelo de calificación crediticia y descubrieron que las explicaciones mejoraron la confianza y la aceptación del modelo por parte de los no expertos (Zaremba & Demir, 2023).

5.2.6 ARBOLES DE DECISIÓN

Los árboles de decisión son uno de los algoritmos fundamentales de aprendizaje en la comunidad de minería de datos, que se han aplicado con éxito a problemas de clasificación de varias clases. El árbol de decisión es una estructura jerárquica y consta de tres tipos de nodos, como los nodos raíz, interno y hoja. En general, la construcción de un árbol de decisión es un programa de partición recursiva, que comienza desde el nodo raíz (incluidos todos los datos de entrenamiento) y termina en los nodos hoja optimizando repetidamente un criterio dividido, que utiliza ampliamente mediciones impuras, (Quinlan, 1996). Una vez que se construye un árbol de decisión, se puede probar un ejemplo invisible al pasar por el mejor camino desde la raíz hasta el nodo hoja. La etiqueta de clase final del ejemplo de prueba está determinada por la representación del nodo hoja alcanzado, (Jianjian, Zhongnan, Kunhui, Fan, Xiongbiao, 2020).

Ecuación 1. Árbol de Decisiones

$$GI(p) = \sum_{k=1}^K p_k (1 - p_k) = 1 - \sum_{k=1}^K p_k^2$$

Normalmente, los criterios divididos no están diseñados para resolver escenarios desequilibrados, por lo que tienden a producir un rendimiento insatisfactorio. Una forma de resolver el problema de desequilibrio de clase es modificar la distribución de clase de los datos de entrenamiento volviendo a muestrear (Chawla, Bowyer, Hall & Kegelmeyer, 2002), (He, Yang, Garcia & Li, 2008).

5.2.7 TEORÍA NAIVE BAYES

El algoritmo de clasificación Naïve Bayes se basa en una herramienta ampliamente utilizada para la inferencia estadística, el Teorema de Bayes (Bayes, 1991). El método clasificador ingenuo de Bayes es un clasificador probabilístico simple que asigna cada objeto a la clase con fuertes supuestos de independencia entre las variables, (Hui, Chun-Tao, Jun, Chen, Rui-Ling & Bo, 2020).

El teorema establece que la probabilidad de observar el evento A determinado evento B puede determinarse a partir de la probabilidad de B dado A y las probabilidades de A y B independientemente uno del otro. Esto se ilustra más formalmente en la *Ecuación 2*.

Ecuación 2. Naïve Bayes

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)}$$

En la clasificación de texto, el Teorema de Bayes se usa para determinar la probabilidad de que un documento determinado se asigne a una clase. El algoritmo básico a menudo se conoce como Naïve Bayes, porque se basa en la distribución léxica de documentos, sin tener en cuenta la posición de las palabras o la interdependencia, (Caitlin, 2020).

5.2.8 ETL (EXTRACT, TRANSFORM & LOAD)

Los procesos de extracción, transformación y carga (ETL) son procesos comerciales cruciales que requieren grandes inversiones para su diseño, implementación y mantenimiento. Dado que los datos se reconocen cada vez más como un activo clave para el éxito de cualquier empresa, crece el interés por el desarrollo de modelos y herramientas más sofisticados para ayudar en la automatización y la dinámica del proceso de datos. Según un informe reciente de Gartner (Beyer, Thoo, Zaidi, Greenwald, 2016).




Ilustración 3. Proceso ETL (Beyer, Thoo, Zaidi, Greenwald, 2016).

En este contexto, La fase de integración de datos se basa en un proceso de Extracción-Transformación-Carga (ETL) dedicado a extraer (E) datos de origen relevantes que se transformarán (T) para fines de limpieza, estandarización y conformidad y luego se cargarán (L) en DW que proporciona información relevante para el análisis y las aplicaciones de toma de decisiones, (Mahfoud, Omar & Zaia, 2017). Los requisitos de ETL son cada vez más avanzados y exigentes con expectativas como el BI de autoservicio, (Abelló, 2013) y el procesamiento de datos sobre la marcha, lo que hace que los proyectos de ETL sean aún más complejos.

5.2.9 MACRO-SECTOR TEXTIL PYMES COLOMBIA

La pandemia del COVID-19 que inicio en el año 2019, represento uno de los mayores retos para la supervivencia como sociedad moderna, tener que implementar mecanismos de asilamiento rápido, restringir el desplazamiento y prevenir las aglomeraciones presenta un desafío especial para el macro-sector textil a nivel global como define Kanupriya, el efecto de la COVID-19 en la industria textil india es múltiple. Ya sea demanda u oferta, insumos o producción, la pandemia de gripe ha afectado a casi todas las facetas de la industria textil.

Con una demanda mundial deprimida de bienes de consumo como textiles y cadenas de suministro interrumpidas, es muy evidente que este sector globalizado enfrenta una de sus peores crisis de los últimos tiempos. (Kanupriya, 2021)

Ventas Netas por Empresa - PyME



Ilustración 4. Ventas Netas PyMEs

La ilustración 4. Representa las ganancias netas por ventas calculadas en cada Macrosector empresarial de Colombia acotadas únicamente a la PyMEs, esta información ha sido recolectada desde La Cámara de Comercio de Bogotá, se considera la industria de la moda como una actividad de alto dinamismo, por lo cual ha generado una apuesta productiva para ayudar al sueño empresarial en estos sectores a través de una serie de servicios especializados y de diversas líneas de trabajo.

La iniciativa Clúster de Moda fue creada en el año 2012 con el propósito de contribuir al fortalecimiento del tejido empresarial del sector textil y confección de Bogotá Región a través de una agenda de trabajo enfocada principalmente en el fortalecimiento de capacidades empresariales relacionadas con sostenibilidad e internacionalización, consolidación de la articulación entre el sector empresarial y la academia, cierre de brechas

del talento humano, dinamización, articulación y transformación del sistema productivo, con el fin de generar impacto en el incremento de productividad y sofisticación del sector (Cámara de Comercio de Bogotá, 2023).




Ilustración 5. Proporción Ganancias en Macro sectores PyMEs

De acuerdo a la ilustración 5. Se evidencia el análisis realizado basado en los datos de la CCB, lo que da como resultado un 57.3% de las ganancias netas en el sector PyMEs de la moda, esto indica que es el segundo sector más importante en términos de ganancias anuales de todos los macro sectores en Colombia.

6. HIPÓTESIS

Un modelo de evaluación crediticia que combine los principios de un ecosistema digital bancario con estrategias de Business Intelligence y mecanismos de reputación mejora la precisión en la valoración de riesgo de las PYMES colombianas, facilitando el acceso de estas empresas a soluciones financieras mediante la creación de una herramienta de apoyo complementaria para las entidades bancarias.

Esta hipótesis explora si la sinergia entre tecnología, análisis de datos y la construcción de reputación digital permite a los bancos valorar de manera más inclusiva y efectiva a las PYMES, promoviendo el desarrollo económico de este sector en Colombia.

7. TRABAJOS RELACIONADOS

La inclusión financiera de pequeñas y medianas empresas (MiPymes) y de sectores de la población sin acceso al crédito formal ha sido un desafío significativo en Colombia. Tradicionalmente, los modelos de calificación crediticia se han basado en información financiera histórica, lo que limita el acceso al crédito para aquellas empresas o individuos que no poseen un historial bancario formal o cuyas operaciones se desarrollan mayormente en la informalidad (Álvarez & Gómez, 2020). Sin embargo, el desarrollo de tecnologías de análisis de datos y la proliferación de fuentes de datos alternativas, como los datos de redes sociales, telecomunicaciones, psicometría y transacciones no bancarias, han abierto nuevas oportunidades para la evaluación de riesgo crediticio (Moreno et al., 2021).

En este contexto, el uso de información alternativa en modelos de calificación crediticia surge como una solución innovadora para ampliar el acceso al crédito, permitiendo a los prestamistas tener una visión más integral del comportamiento financiero y el riesgo de los solicitantes. Implementar estos modelos en Colombia requiere un enfoque equilibrado que considere tanto las oportunidades tecnológicas como los retos regulatorios y de protección de datos (Rodríguez & Pérez, 2019).

Colombia enfrenta varios retos en la implementación del Open Banking, debido a las particularidades de su sistema financiero, su regulación y el contexto socioeconómico del país. Uno de los mayores retos que enfrenta Colombia con respecto al Open Banking es la ausencia de un marco regulatorio sólido y específico para este sistema. A diferencia de otras jurisdicciones como la Unión Europea con la PSD2 (Payment Services Directive 2), Colombia aún no ha desarrollado una regulación integral que facilite la interoperabilidad entre bancos y terceros, garantice la seguridad de los datos, y promueva la adopción del Open Banking. Sin una regulación clara, los bancos y las fintechs pueden enfrentar incertidumbres legales que inhiben la colaboración y la innovación en este ámbito (Banco de la República, 2020).

El Open Banking implica el acceso y el intercambio de información financiera sensible entre diferentes instituciones y proveedores de servicios. En Colombia, la Ley 1581 de 2012 establece principios para la protección de datos personales, pero implementar Open Banking a gran escala requiere un marco más robusto que garantice la seguridad de los datos en todo el ecosistema financiero. Existen preocupaciones sobre posibles violaciones de privacidad, ciberataques y el uso indebido de datos por parte de terceros, lo que hace necesario fortalecer las normativas de seguridad y crear una infraestructura tecnológica más segura (Superintendencia Financiera de Colombia, 2021).

Un desafío crucial para el éxito del Open Banking en Colombia es el nivel de educación financiera y alfabetización digital de la población. A pesar de los avances en inclusión financiera, gran parte de la población, especialmente en zonas rurales y en sectores de bajos ingresos, no tiene un conocimiento adecuado sobre el uso de servicios financieros digitales. Esto puede limitar la adopción de Open Banking, ya que los usuarios podrían ser reacios a compartir sus datos financieros con terceros o no comprender los beneficios que este sistema puede ofrecerles (Asobancaria, 2020).

Aunque el Open Banking abre oportunidades para la competencia y la innovación, algunas instituciones financieras tradicionales en Colombia pueden mostrar resistencia a la adopción del modelo. Esto se debe a que el Open Banking obliga a los bancos a compartir datos de sus clientes con terceros, lo que podría diluir su control sobre la información financiera y abrir el mercado a nuevos competidores, como las fintechs. La adopción exitosa del Open Banking dependerá de cómo los bancos y las fintechs colaboren y de la creación de incentivos para que los actores tradicionales participen activamente (KPMG, 2019).

La infraestructura tecnológica del sistema financiero colombiano también representa un reto para la implementación del Open Banking. La interoperabilidad entre los sistemas bancarios tradicionales y las plataformas tecnológicas de las fintechs puede ser un desafío técnico considerable. Además, es necesario garantizar que las APIs utilizadas para acceder a los datos financieros sean estandarizadas y seguras, evitando vulnerabilidades que puedan ser explotadas por actores malintencionados. Esto implica una inversión significativa en modernización tecnológica por parte de las entidades financieras (Deloitte, 2020).

El Open Banking tiene el potencial de mejorar la inclusión financiera en Colombia al facilitar el acceso al crédito y otros servicios para las personas que actualmente no tienen historial bancario o financiero. Sin embargo, las barreras sociales y económicas persisten, especialmente en áreas rurales, donde el acceso a servicios financieros digitales y la conectividad a internet siguen siendo limitados. La desigualdad en el acceso a la tecnología es un desafío que el país debe abordar para que los beneficios del Open Banking sean equitativamente distribuidos entre todos los sectores de la sociedad (CAF, 2020).

La implementación del Open Banking en Colombia enfrenta una serie de retos regulatorios, tecnológicos y sociales que deben ser abordados para garantizar su éxito. La creación de un marco regulatorio específico, la protección de datos, la modernización de la infraestructura financiera y la educación financiera son fundamentales para fomentar la adopción del Open Banking y maximizar sus beneficios en términos de inclusión y competitividad.

7.1.1 INCLUSIÓN FINANCIERA EN COLOMBIA

Las mipymes (micro, pequeñas y medianas empresas) en Colombia representan más del 90% del total de empresas y generan una porción significativa del empleo (Confecámaras, 2020). Sin embargo, enfrentan barreras para acceder a servicios financieros formales como el crédito, seguros y sistemas de pago. La falta de acceso a financiamiento limita su capacidad de crecimiento y desarrollo (OECD, 2019). En Colombia, la inclusión financiera busca proporcionar a las mipymes las herramientas necesarias para su participación en el sistema financiero formal, ayudándolas a superar la dependencia de fuentes informales de crédito (Banco de la República, 2020).

- Bancarización de mipymes: La proporción de mipymes que tienen acceso a cuentas bancarias y productos financieros sigue siendo baja en comparación con grandes empresas (Superintendencia Financiera de Colombia, 2021).
- Barreras al crédito formal: Falta de garantías, historial crediticio insuficiente, y requisitos formales que muchas mipymes no pueden cumplir (García & Rodríguez, 2021).

- Impacto en el crecimiento económico: Las mipymes tienen un papel central en la generación de empleo, por lo que su inclusión financiera es clave para el crecimiento económico sostenido (CAF, 2020).

Se realiza un análisis comparativo de los niveles de inclusión financiera de mipymes en Colombia respecto a otros países de América Latina. La investigación utiliza encuestas, datos bancarios y estudios de caso sobre mipymes para identificar las principales barreras de acceso al crédito y analizar cómo los datos alternativos pueden ayudar a superar estas barreras (World Bank, 2021). En Colombia, la bancarización de mipymes es aún limitada, lo que obliga a muchas a recurrir a fuentes informales de financiamiento (Asobancaria, 2020). A nivel global, países como México y Brasil han comenzado a utilizar tecnologías fintech y datos alternativos para expandir el acceso al crédito a las mipymes, lo que podría servir como modelo para Colombia (CEPAL, 2021).

7.1.2 SOBRE LAS FUENTES DE DATOS ALTERNATIVOS

Las fuentes de datos alternativos se refieren a datos no tradicionales utilizados para evaluar el riesgo crediticio. Estos datos provienen de fuentes distintas a los historiales financieros tradicionales, como redes sociales, comportamiento digital, datos de telecomunicaciones, entre otros (Berg et al., 2020). Los datos alternativos permiten generar perfiles de riesgo para mipymes que carecen de registros formales, proporcionando una nueva forma de evaluar la solvencia de estas empresas (Gomez & Castillo, 2021).




Ilustración 6. Datos Alternativos (Departamento Nacional de Planeación, 2024).

- Datos de comportamiento digital: Incluye la actividad en redes sociales, patrones de uso de dispositivos móviles, e interacciones en línea (Karlan et al., 2018).
- Datos de psicometría: Características de personalidad evaluadas a través de pruebas psicométricas, como responsabilidad, impulsividad y planificación (Larrimore et al., 2019).
- Datos transaccionales no bancarios: Información sobre pagos realizados fuera del sistema bancario, como pagos por servicios y compras online (Findex, 2021).

Se utiliza machine learning y técnicas de minería de datos para procesar grandes volúmenes de datos no estructurados, como publicaciones en redes sociales o patrones de uso de dispositivos móviles. Estos datos se combinan con información financiera tradicional para crear modelos predictivos que mejoran la precisión en la evaluación del riesgo (Fintech Global, 2020).

En Colombia, el uso de fuentes de datos alternativos está ganando popularidad en el sector fintech, especialmente para evaluar a empresas en sectores informales (Asobancaria, 2021). A nivel global, países como India y Kenia han utilizado datos de telecomunicaciones y redes sociales para mejorar la inclusión financiera de pequeñas empresas sin historial bancario (M-Shwari, 2020).

7.1.3 MARCO CONCEPTUAL DEL DIAGNÓSTICO

El marco conceptual del diagnóstico integra el uso de datos alternativos con tecnologías avanzadas de análisis, como el machine learning y la inteligencia artificial (Berg et al., 2020). El objetivo es crear un modelo integral que considere múltiples fuentes de datos para generar un perfil crediticio preciso de mipymes, permitiendo a las instituciones financieras evaluar con mayor certeza el riesgo de crédito (Gomez & Castillo, 2021). El marco conceptual debe ser flexible, adaptable a diversas fuentes de datos y capaz de evolucionar a medida que surjan nuevas tecnologías y fuentes de información (Karlan et al., 2018).

- **Recolección de datos:** Identificación y captura de fuentes de datos alternativos (como psicometría, redes sociales y datos de telefonía móvil) (Larrimore et al., 2019).
- **Análisis de datos:** Uso de herramientas de inteligencia artificial y machine learning para identificar patrones que indiquen solvencia o riesgo crediticio (Fintech Global, 2020).
- **Validación de modelos:** Proceso de prueba y ajuste del modelo para garantizar su precisión y fiabilidad en la predicción del riesgo (Moreno et al., 2021).

El marco conceptual se desarrolla en etapas: primero, se identifican las fuentes de datos disponibles y relevantes para las mipymes en Colombia. Luego, se utilizan técnicas de minería de datos y modelos predictivos basados en machine learning para analizar dichos datos (Asobancaria, 2021). Finalmente, se valida el modelo con datos históricos para garantizar su precisión. Contempla la implementación de pruebas piloto para ajustar y optimizar los modelos (Rodríguez & Pérez, 2019). El marco conceptual propuesto puede ser implementado por entidades financieras y fintechs para mejorar la evaluación del riesgo crediticio de mipymes. A nivel global, modelos similares han sido implementados en países como Brasil y México, donde las fintechs utilizan datos alternativos y algoritmos predictivos para crear sistemas de crédito más inclusivos (CAF, 2020).

7.1.4 DATOS DE REDES SOCIALES

Los datos de redes sociales reflejan las interacciones y relaciones entre individuos y empresas, proporcionando información valiosa sobre el comportamiento social y la reputación de una entidad (Liu et al., 2019). Las redes sociales también revelan patrones de consumo, satisfacción del cliente y la percepción pública sobre una empresa (Kietzmann et al., 2011). Estos datos pueden ser utilizados para evaluar la credibilidad y estabilidad de una empresa o empresario, así como para detectar comportamientos asociados con el riesgo crediticio (Gomez & Castillo, 2021).

- **Análisis de sentimiento:** Evaluación de la opinión pública sobre una empresa, medida a través de comentarios, publicaciones y menciones (Cambria et al., 2020).

- Redes de interacción: Análisis de las relaciones de una empresa con sus clientes, proveedores y la comunidad en general (Zhang & Vos, 2014).
- Patrones de comportamiento: Identificación de patrones en la frecuencia y tipo de interacciones en redes sociales, como la actividad constante o irregular (Moro et al., 2019).

Se utilizan técnicas de procesamiento de lenguaje natural (NLP) y análisis de redes para extraer información relevante de las redes sociales (Cambria et al., 2020). Los modelos de análisis de sentimiento procesan publicaciones y comentarios, clasificándolos como positivos, negativos o neutros (Zhao et al., 2019). Además, se aplican algoritmos de minería de datos para analizar la estructura de las redes de interacción y detectar patrones de comportamiento relevantes (Moreno et al., 2021). El uso de datos de redes sociales para la evaluación crediticia es limitado pero creciente, especialmente entre las fintechs (Asobancaria, 2021). A nivel global, plataformas como Alipay en China y compañías fintech en Estados Unidos ya utilizan redes sociales como parte de su modelo de evaluación crediticia para mipymes y consumidores individuales (Zhao et al., 2019).

7.1.5 DATOS DE PSICOMETRÍA

Los datos de psicometría se refieren a la medición de características psicológicas y comportamentales, como la responsabilidad, la toma de riesgos, la estabilidad emocional y la capacidad de planificación (Klinger et al., 2013). Estos datos son útiles para la evaluación crediticia cuando no se dispone de información financiera formal. Las pruebas psicométricas pueden medir habilidades y rasgos que son indicadores indirectos de solvencia, como la capacidad para gestionar una empresa o las actitudes hacia el riesgo financiero (PsyFi, 2019).

- Pruebas de personalidad: Cuestionarios diseñados para evaluar rasgos de personalidad como la responsabilidad y la impulsividad (Larrimore et al., 2019).
- Evaluación del riesgo: Medición de la tolerancia al riesgo de un empresario, lo que puede influir en la toma de decisiones financieras (Klinger et al., 2013).

- Capacidad de planificación: Evaluación de la habilidad de una persona para planificar y gestionar recursos, lo que afecta su solvencia (World Bank, 2020).

Las pruebas psicométricas son aplicadas a los solicitantes de crédito, generalmente a través de encuestas o aplicaciones en línea (Mckenzie & Sansone, 2017). Estas pruebas están diseñadas para identificar rasgos de personalidad que correlacionan con el comportamiento financiero. Los resultados se integran en modelos de riesgo crediticio junto con otros datos alternativos (Deloitte, 2021). El uso de pruebas psicométricas para evaluar la solvencia de mipymes es un enfoque emergente (Asobancaria, 2021). En otros países, como Sudáfrica y Nigeria, se han implementado programas exitosos que utilizan psicometría para calificar el riesgo de crédito de microempresas y empresarios informales que carecen de un historial financiero (Klinger et al., 2013).

7.1.6 DATOS DE OPEN BANKING

El open banking es un sistema que permite a los clientes compartir su información financiera con terceros de forma segura a través de interfaces de programación de aplicaciones (APIs) (Zopa, 2020). Este enfoque facilita la recolección de datos bancarios detallados, como historiales de transacciones, patrones de gasto e ingresos, lo que permite evaluar el comportamiento financiero real de una empresa o individuo (KPMG, 2021).




Ilustración 7. Modelo Datos PSD2s (Departamento Nacional de Planeación, 2024).

- Historial de transacciones: Registro de movimientos financieros que permite evaluar la estabilidad financiera de una empresa (Deloitte, 2019).
- Patrones de ahorro y gasto: Datos sobre la capacidad de ahorro y los patrones de gasto que ofrecen una visión del manejo de recursos financieros (Accenture, 2020).
- Relaciones crediticias: Información sobre los créditos actuales y el comportamiento de pago de la empresa o individuo (World Bank, 2021).

Los datos bancarios de los clientes son compartidos con instituciones financieras mediante APIs, previa autorización del cliente (Banco Mundial, 2021). Los modelos de riesgo crediticio integran estos datos con otras fuentes de información para generar un perfil financiero detallado. La implementación de open banking requiere marcos normativos claros para garantizar la privacidad y seguridad de los datos (Financial Conduct Authority, 2019). En Colombia, el Decreto 1297 de 2022 promueve la implementación de open banking, aunque su adopción aún es incipiente (Superintendencia Financiera de Colombia, 2022). Globalmente, países como el Reino Unido y Australia son líderes en open banking, utilizando estos datos para proporcionar servicios financieros más personalizados y mejorar la evaluación del riesgo crediticio (PSD2, 2018; ACCC, 2020).

7.1.7 DATOS DE TELEFONÍA MÓVIL (TELCO/CDR)

Los datos de telefonía móvil, conocidos como Call Detail Records (CDR), incluyen información sobre las llamadas, mensajes de texto, y el uso de datos móviles de un usuario. Estos datos permiten obtener una visión detallada de la ubicación, movilidad y patrones de comunicación, lo que puede ser un indicador indirecto de estabilidad económica y financiera (Blumenstock et al., 2015).

- Ubicación geográfica: Los datos de ubicación permiten evaluar la estabilidad residencial y laboral de una persona o empresa (Frias-Martinez & Virseda, 2012).
- Frecuencia de llamadas: La frecuencia y duración de las llamadas pueden reflejar la actividad profesional o empresarial (Gutierrez et al., 2013).

- Uso de datos móviles: El consumo de datos puede correlacionarse con la actividad económica, especialmente en mipymes que usan dispositivos móviles para gestionar su negocio (GSMA, 2020).

Los datos de CDR son recolectados por las compañías de telecomunicaciones y pueden ser compartidos con instituciones financieras previa autorización (Mckenzie & Sansone, 2017). Estos datos se procesan mediante algoritmos de machine learning para identificar patrones de comportamiento que puedan correlacionarse con la solvencia crediticia (Song et al., 2017). Los datos de telefonía móvil han comenzado a ser explorados como una fuente alternativa para la evaluación crediticia, especialmente en zonas rurales (Superintendencia Financiera de Colombia, 2021). Globalmente, en países como Kenia y Tanzania, los datos de telecomunicaciones han sido cruciales para evaluar la capacidad crediticia de personas y mipymes en regiones con bajo acceso a los bancos (Jack & Suri, 2014).

7.1.8 DATOS DISPOSITIVOS SMARTPHONE (EXTRAÍDOS POR SDK)

Los datos extraídos directamente de dispositivos móviles mediante el uso de Software Development Kits (SDK) proporcionan información sobre el uso de aplicaciones, geolocalización, y patrones de interacción digital (Zeng et al., 2020). Estos datos ofrecen una visión precisa de los hábitos financieros y sociales de un usuario, lo que puede ser útil para construir un perfil crediticio más completo (Dhar & Stein, 2017).

- Patrones de uso de aplicaciones: Frecuencia y tipo de aplicaciones utilizadas, como apps bancarias o de compras (Wang & Miller, 2019).
- Geolocalización: Datos sobre la movilidad del usuario, lo que puede reflejar estabilidad laboral o personal (de Montjoye et al., 2018).
- Interacción digital: Nivel de interacción en plataformas en línea, como correos electrónicos y redes sociales, que pueden reflejar actividad económica (Jain et al., 2020).

Los SDK instalados en dispositivos móviles recopilan datos sobre el uso de aplicaciones y patrones de comportamiento digital (Böhme & Köpsell, 2019). Estos datos son procesados

mediante algoritmos de machine learning para identificar comportamientos financieros, como la frecuencia de uso de aplicaciones bancarias o la regularidad de los ingresos (Naboulsi et al., 2016). El uso de datos de smartphones para la evaluación crediticia está en crecimiento, especialmente entre las fintechs (Asobancaria, 2021). A nivel global, en países como Filipinas e Indonesia, las empresas fintech utilizan estos datos para evaluar a individuos y mipymes que no tienen acceso al sistema financiero tradicional, mejorando su inclusión financiera (CGAP, 2020).

7.1.9 DATOS DE TRANSACCIONES PÚBLICAS

Los datos de transacciones públicas incluyen información sobre licitaciones, contratos gubernamentales, pagos de impuestos, y otros registros comerciales que se encuentran disponibles públicamente (OECD, 2020). Estos datos son una fuente confiable para evaluar la actividad económica formal de una empresa (Cruz et al., 2021).

- Registros de impuestos: Pueden indicar el cumplimiento fiscal de una empresa (World Bank, 2019).
- Licitaciones públicas: Participación en contratos con entidades gubernamentales, lo que refleja la legitimidad y estabilidad de una empresa (Fazekas & Tóth, 2016).
- Registros comerciales: Información sobre la formalidad y los contratos públicos realizados por la empresa (ICIJ, 2017).

Las bases de datos públicas y registros comerciales se integran en los modelos de evaluación crediticia, proporcionando una fuente adicional de información confiable para las mipymes (CAF, 2020). Se utilizan herramientas de análisis de datos estructurados para generar perfiles de riesgo basados en estos registros (Accenture, 2021). La implementación de análisis de datos de transacciones públicas está en una etapa inicial, pero tiene un gran potencial, dado el enfoque del gobierno en la digitalización (Superintendencia Financiera de Colombia, 2021). A nivel global, en países como Brasil, el acceso a datos públicos se ha convertido en una fuente clave para evaluar la estabilidad financiera de empresas pequeñas y medianas (ANPD, 2020).

7.1.10 ENTORNO NORMATIVO

El entorno normativo incluye las leyes, regulaciones y directrices que rigen el uso de datos alternativos en la evaluación crediticia, así como la implementación de iniciativas como el open banking (OECD, 2020). Es esencial que el entorno normativo garantice la protección de los datos de los usuarios, al mismo tiempo que fomente la innovación financiera (World Bank, 2021).

- Protección de datos: Regulaciones sobre la privacidad y el manejo de datos personales, esenciales para la adopción de nuevas tecnologías (Superintendencia Financiera de Colombia, 2021).
- Open banking: Normativas que regulan el intercambio de información financiera entre instituciones bancarias y terceros (Financial Conduct Authority, 2019).
- Fintech y microcrédito: Regulaciones específicas para las fintech y las instituciones de microcrédito que utilizan datos alternativos para evaluar la solvencia de las mipymes (IMF, 2020).

Se realiza un análisis comparativo de los marcos regulatorios en Colombia y otros países de la región para identificar las mejores prácticas (Asobancaria, 2021). Se evalúa cómo la regulación existente puede adaptarse al uso de datos alternativos para garantizar su seguridad y eficacia (Deloitte, 2020).

En Colombia, el entorno normativo para el open banking está en fase de desarrollo con la promulgación del Decreto 1297 de 2022 (Superintendencia Financiera de Colombia, 2022). Globalmente, países como el Reino Unido tienen marcos avanzados que facilitan la adopción de nuevas tecnologías financieras, garantizando al mismo tiempo la protección de los datos de los usuarios (PSD2, 2018).

7.1.11 RECOMENDACIONES DE SELECCIÓN MERCADO EPC

La selección adecuada de fuentes de datos alternativos es crucial para mejorar la precisión en la evaluación crediticia de mipymes en Colombia. Este proceso implica identificar y

priorizar aquellas fuentes de datos que mejor se adapten al contexto económico y social de las mipymes (Gomez & Castillo, 2021).

- Fuentes de datos de redes sociales: Relevancia de la actividad social y digital de las empresas en Colombia (Liu et al., 2019).
- Open banking: Uso de información bancaria compartida para mejorar la evaluación de riesgo crediticio (Zopa, 2020).
- Datos de telecomunicaciones y dispositivos móviles: Relevancia en áreas rurales y entre mipymes que operan con tecnología móvil (Blumenstock et al., 2015).

Se sugiere la implementación de un enfoque híbrido que combine datos transaccionales tradicionales con fuentes alternativas, utilizando modelos predictivos y algoritmos de machine learning para identificar los factores de mayor relevancia (Karlan et al., 2018). El uso de datos de redes sociales y open banking tiene el potencial de mejorar la inclusión financiera (Asobancaria, 2021). Globalmente, países como México y Brasil están implementando modelos de datos alternativos para mipymes con mucho éxito (OECD, 2020).

7.1.12 RECOMENDACIONES SOBRE CAPACIDADES Y ACCIONES

La banca pública de desarrollo desempeña un papel clave en el fomento de la inclusión financiera de mipymes, a través del uso de datos alternativos y el impulso de innovaciones tecnológicas en el sector financiero (CAF, 2020).

- Fortalecimiento tecnológico: Capacitación de la banca pública en tecnologías fintech y machine learning (KPMG, 2021).
- Colaboración con fintechs: Asociaciones estratégicas con fintechs para implementar soluciones basadas en datos alternativos (World Bank, 2020).
- Desarrollo de infraestructura: Inversión en infraestructura tecnológica que facilite la integración de nuevas fuentes de datos (BID, 2020).

Se recomienda que la banca pública adopte un enfoque centrado en la innovación, colaborando con fintechs y mejorando sus capacidades tecnológicas para procesar y analizar datos alternativos (Deloitte, 2021). Se sugiere que Bancóldex y otras entidades públicas inviertan en soluciones tecnológicas que permitan utilizar datos alternativos para mejorar el acceso a crédito de las mipymes (Asobancaria, 2021). En Brasil, el Banco Nacional de Desarrollo ha implementado programas innovadores que pueden servir como ejemplo (BNDES, 2020).

7.1.13 RECOMENDACIONES DE POLÍTICA PÚBLICA

Las políticas públicas deben fomentar la adopción de datos alternativos en el sector financiero, mientras garantizan la protección de datos y la equidad en el acceso a servicios financieros para las mipymes (World Bank, 2020).

- Políticas de protección de datos: Normativas que protejan la privacidad de los usuarios sin impedir la innovación (OECD, 2020).
- Fomento al open banking: Incentivos para que los bancos compartan datos de manera segura y transparente (Financial Conduct Authority, 2019).
- Inclusión financiera: Políticas que faciliten el acceso a financiamiento para mipymes en zonas rurales o con bajos niveles de formalización (Asobancaria, 2021).

Se analizan los marcos regulatorios existentes y se proponen modificaciones para facilitar el acceso a financiamiento mediante el uso de datos alternativos, al tiempo que se garantiza la protección de datos y se fomenta la competencia entre instituciones financieras (IMF, 2020). En Colombia, las políticas públicas deben centrarse en implementar y fortalecer el open banking y garantizar que las mipymes puedan beneficiarse del acceso a crédito basado en datos alternativos (Superintendencia Financiera de Colombia, 2022). A nivel global, países como el Reino Unido ya tienen políticas avanzadas en esta área (PSD2, 2018).

7.1.14 AVANCES PARA ECOSISTEMA DIGITAL

La implementación de datos alternativos en mipymes es un proceso que puede revolucionar la evaluación crediticia, especialmente en contextos donde estas empresas no tienen acceso a servicios financieros formales.

Dependiendo del sector y el tipo de mipymes, se deben priorizar las fuentes de datos que reflejen de manera más precisa la actividad económica de las empresas. Por ejemplo, para mipymes rurales, los datos de telecomunicaciones y móviles son cruciales, mientras que las mipymes digitales pueden beneficiarse de la integración de datos de redes sociales y comportamiento en línea (Finextra, 2021; Deloitte, 2019). Las instituciones financieras deben invertir en tecnologías de procesamiento de datos, como plataformas de big data y machine learning. Estas herramientas permiten analizar grandes volúmenes de datos no estructurados y combinarlos con datos tradicionales para generar modelos predictivos de riesgo (IFC, 2021; World Bank Group, 2018).

Se deben diseñar modelos de riesgo crediticio que combinen datos tradicionales (como reportes financieros) con datos alternativos, como redes sociales, patrones de uso de dispositivos móviles, o resultados psicométricos. Esta combinación permite generar perfiles de riesgo más robustos y personalizados (Accion, 2021; LexisNexis Risk Solutions, 2020). La banca tradicional debe colaborar con fintechs, que suelen tener más experiencia en el uso de datos alternativos y la creación de soluciones tecnológicas para la evaluación crediticia. Estas colaboraciones pueden acelerar la adopción de estos modelos y permitir a las mipymes acceder a productos financieros más personalizados y ajustados a sus necesidades (McKinsey & Company, 2020; PwC, 2021).

La implementación de datos alternativos debe estar respaldada por un marco regulatorio que garantice la seguridad y la privacidad de los datos de las mipymes. En este sentido, los gobiernos y los entes reguladores deben trabajar en normativas que fomenten la innovación, al tiempo que protegen los derechos de los usuarios de estos datos (OECD, 2020; Finextra, 2021).

El open banking tiene el potencial de transformar profundamente el ecosistema financiero en Colombia, brindando nuevas oportunidades tanto para las mipymes como para los consumidores en general. Mayor inclusión financiera: El open banking permite que los datos financieros de los clientes, incluidas las mipymes, sean compartidos entre diversas instituciones financieras mediante APIs. Esto facilita que las mipymes, que anteriormente no tenían acceso a crédito debido a la falta de historial financiero formal, puedan ser evaluadas en función de sus patrones de transacciones bancarias y comportamiento financiero. Con una evaluación más precisa y completa, más mipymes pueden acceder a financiamiento en mejores condiciones (World Bank Group, 2018). Con la apertura de los datos financieros, no solo los bancos tradicionales, sino también las fintechs, pueden ofrecer productos financieros personalizados a las mipymes. Esta mayor competencia genera innovaciones en productos y servicios, como préstamos más accesibles y con mejores condiciones, lo que beneficia a las empresas pequeñas y medianas (Accion, 2021).

El open banking permite a las instituciones financieras acceder a datos actualizados y detallados sobre el comportamiento financiero de las mipymes, como ingresos, gastos y pagos recurrentes. Esto permite crear productos financieros más personalizados, adaptados a las necesidades y capacidades de pago de cada empresa. Por ejemplo, una empresa con flujos de caja estacionales puede acceder a préstamos que se ajusten a sus periodos de mayor actividad (Finextra, 2021; PwC, 2021). Con el open banking, las mipymes tienen más control sobre sus datos y pueden compartirlos con las instituciones que elijan. Esto genera un mayor nivel de transparencia, ya que las decisiones de crédito se basan en información más detallada y precisa. Además, la confianza entre los prestamistas y las mipymes mejora, ya que las evaluaciones de riesgo son más justas y basadas en información actualizada (LexisNexis Risk Solutions, 2020; OECD, 2020).

En Colombia, el open banking está impulsando la digitalización del sector financiero. Esto no solo mejora la eficiencia operativa de las instituciones financieras, sino que también fomenta la adopción de servicios financieros digitales por parte de las mipymes, facilitando el acceso a herramientas financieras más sofisticadas, como la gestión de efectivo en tiempo real o las plataformas de pago electrónico (McKinsey & Company, 2020). Aunque el impacto potencial del open banking es significativo, su implementación en Colombia

enfrenta desafíos. A corto plazo, es necesario desarrollar la infraestructura tecnológica necesaria para soportar el intercambio seguro de datos y asegurar la colaboración entre bancos y fintechs. Además, se deben crear regulaciones sólidas que equilibren la protección de datos con la innovación financiera. No obstante, con el marco regulatorio correcto, el open banking podría convertirse en un catalizador clave para la inclusión financiera y el desarrollo de las mipymes en el país (Deloitte, 2019; IFC, 2021).

8. METODOLOGÍA

La metodología propuesta se basará en la planteado por los autores Parama y Suharjito (2018), investigadores de la universidad Bina Nusantara University en Indonesia, estos autores propusieron en su trabajo, *Business Intelligence Model to Analyze Social Media Information*, una metodología dividida en 4 etapas fundamentadas en la recolección, categorización, análisis de datos y creación del sistema BI. Los pasos involucrados en esta investigación son la recolección de datos, el análisis de datos, el diseño del almacén de datos, el diseño de inteligencia empresarial, la clasificación de texto y los métodos de evaluación, (Parama & Suharjito, 2018).



Ilustración 8. Arquitectura de investigación Propuesta

En la *ilustración 8*. se muestra la arquitectura propuesta para la creación del modelo, tomando como base la metodología anterior e incluyendo dos etapas extra, donde se enfatiza en la búsqueda de la identificación del ecosistema digital bancario basado en las etapas anteriores y finalmente se plantea la agregación de un escenario de evaluación y comparación del modelo, donde se podrá definir el factor de impacto.

8.1 CRITERIOS MÍNIMOS DE LA EMPRESA ESTUDIO

Para garantizar un resultado en el scoring preciso y complementario, todas las empresas solicitantes debían cumplir con los criterios mínimos establecidos para perfiles basados en calificaciones principalmente en las interacciones con las plataformas de redes sociales establecidas (Accion, 2021; LexisNexis Risk Solutions, 2020). Es de suma importancia que las empresas comprendan estos criterios, ya que esto garantiza no solo la integridad del proceso de evaluación, sino que también maximiza las posibilidades de recibir una puntuación positiva para aquellas que muestran un alto nivel de cumplimiento (World Bank Group, 2018).

- **Coherencia de Marca:** Comprobar si, a través de redes sociales, aún mantiene la identidad de la marca de manera coherente. Esto abarca el tipo de voz utilizada, los valores transmitidos y el estilo de las imágenes. La coherencia ayuda a reforzar la marca y generar confianza en los seguidores (Finextra, 2021; McKinsey & Company, 2020).
- **Interacción con la audiencia:** Determinar cómo interactúa la empresa con su audiencia dentro de las redes sociales. Esto implica responder preguntas, comentarios y elogios a tiempo y con una actitud de servicio de calidad. La interacción positiva con los seguidores puede manifestar un compromiso con la marca y potencialmente mejorar la reputación de la empresa (Deloitte, 2019).
- **Medición de Desempeño:** Analizar las métricas claves de desempeño de las redes sociales, desde alcance, engagement, crecimiento de seguidores y conversiones. Las métricas proporcionarán una perspectiva justa sobre el impacto de la estrategia de marketing en redes sociales de la empresa y ayudarán a comprender las áreas que necesitan mejorar (OECD, 2020; PwC, 2021).

Los criterios garantizan que los componentes técnicos prioricen una huella digital definitoria y una difusión positiva a una empresa. La coherencia de la marca asegura una identidad sólida y fácilmente reconocible, y la interacción positiva con la audiencia generará confianza y compromiso. El seguimiento y análisis de las métricas de rendimiento proporcionarán una perspectiva real sobre el impacto de las estrategias de la empresa en su entorno de red.

8.2 RECOLECCIÓN, CLASIFICACIÓN y PROCESAMIENTO DE DATOS

Recolección de los conjuntos de datos necesarios para completar el modelo basado en datasets oficiales sobre el mercado financiero y recopilación de data pública, que puede ser obtenida de diferentes fuentes, como redes sociales. En la etapa de recopilación de datos, hay un proceso como el primero, la recuperación de datos se realiza desde la plataforma de redes sociales en Facebook y Twitter a través de la API de redes sociales disponible en cada plataforma. En segundo lugar, la recuperación de datos se realizará periódicamente por los rastreadores que se han creado utilizando la API de Social Media Token que es útil para la autenticación y autorización durante la recuperación de datos. Y finalmente, los resultados se almacenarán en la base de datos como datos sin procesar (Parama & Suharjito, 2018). Clasificación, categorización y limpieza de la información obtenida utilizando métodos para la minería de datos.

La clasificación o categorización de texto es el proceso de colocar un documento en una categoría o clase de acuerdo con las características del documento. En la minería de texto, la clasificación se refiere a la actividad de analizar o estudiar la colección de documentos de texto preclasificados para derivar un modelo o función que puede usarse para agrupar otros documentos de clase desconocidos en una o más clases predefinidas, (Parama & Suharjito, 2018). Para la clasificación de texto en redes sociales en este trabajo, se seleccionaron los algoritmos Naive Bayes, Decision Tree y SVM (Support Vector Machine) debido a su eficacia y popularidad en el análisis de datos textuales, como lo sugiere el estudio de Kurnia y Suharjito (2018). Se determinó el uso de estos algoritmos debido a resultados de los autores

- Naive Bayes: Este algoritmo suele mostrar una alta precisión en problemas de clasificación de texto debido a su simplicidad y supuestos de independencia entre características. Por ejemplo, en un escenario real de clasificación de sentimiento en redes sociales, Naive Bayes podría alcanzar entre 70-85% de exactitud, particularmente en conjuntos de datos grandes con una estructura clara en la distribución de palabras.

- **Decision Tree:** En términos de interpretabilidad, el Decision Tree ofrece una ventaja considerable, aunque podría presentar una precisión y f1-score menores en comparación con otros métodos, especialmente si el modelo es propenso a sobreajustarse (overfitting). En un entorno de clasificación de sentimientos, el Decision Tree podría alcanzar una precisión de entre 60-80% dependiendo del preprocesamiento y la poda del árbol.
- **Support Vector Machine (SVM):** SVM es conocido por su alta capacidad de generalización y, en general, logra una precisión y f1-score superiores, especialmente en conjuntos de datos de texto. En una tarea de clasificación de texto para redes sociales, un modelo SVM bien ajustado podría alcanzar una precisión entre 80-95%, lo que lo convierte en una de las mejores opciones para la clasificación de sentimientos, especialmente cuando los datos son de alta dimensionalidad y no lineales.

La elección de estos tres algoritmos se basa en su eficacia demostrada en tareas de clasificación de texto y en la capacidad de cada uno para abordar aspectos específicos del análisis de datos sociales. Kurnia y Suharjito (2018) respaldan su uso en el contexto de Business Intelligence aplicado a redes sociales, destacando que la combinación de estos métodos permite obtener resultados más robustos y confiables al clasificar la percepción de los usuarios en plataformas como Twitter y Facebook.

Actividades

- Recopilación de datos
- Categorización
- Limpieza de datos

Análisis de datos basados en la correlación de la información obtenida del sector empresarial y la opinión pública. El método de Kimball, que debe pasar por 4 etapas en el diseño del almacenamiento de datos que selecciona el proceso de negocio, identifica las dimensiones e identifica los hechos. Además, se define también un proceso ETL que evalúa comentarios, publicaciones, sentimientos y otros (Parama & Suharjito, 2018).

8.3 FORMULACIÓN ESTRATEGIA BUSINESS INTELLIGENCE

Creación de la herramienta de analítica de datos que se enfoca en la toma de decisiones con respecto a los escenarios propuestos. Según Vercellis (2009), en el proceso de desarrollo de Business Intelligence en una empresa hay 4 fases diseño, planificación, implementación y control. La estrategia de Business Intelligence descrita en esta investigación se fundamenta en modelos complementarios que integran métricas no financieras y variables de reputación para optimizar la precisión en la evaluación de riesgo. Estudios previos han demostrado que el análisis de datos no estructurados, como los de redes sociales, permite identificar mejor la percepción de los clientes y su impacto en el perfil crediticio (Kurnia & Suharjito, 2018). Esto aporta una nueva dimensión a los modelos de riesgo, que tradicionalmente se enfocan solo en variables financieras objetivas (Hendrikse et al., 2019).




Ilustración 9. Estrategia Business Intelligence FASE I.

Definición de Objetivos y KPI's: El objetivo principal es mejorar la precisión del scoring crediticio mediante un modelo que integra métricas financieras y no financieras, alineado con las recomendaciones de Hendrikse et al. (2019), quienes enfatizan la relevancia de incorporar variables de comportamiento en los modelos de evaluación de riesgo. Los KPI's permiten monitorear la efectividad del modelo en su precisión y en la respuesta a factores externos (Dapp, 2015).

Integración de Datos de Múltiples Fuentes: La integración de datos financieros tradicionales y datos de reputación (procesados mediante NLP) es clave para una evaluación de riesgo holística (Goh et al., 2019). Al usar herramientas de NLP, se analiza la percepción y reputación en redes sociales y otras plataformas (Kurnia & Suharjito, 2018), permitiendo capturar factores de riesgo adicionales no considerados en los datos tradicionales.

Implementación de un Panel de Control de BI: Un dashboard dinámico permite visualizar la comparación entre el score tradicional y el score final ajustado, incluyendo la variación entre ellos. Esto facilita una visión integrada y en tiempo real, como sugieren Hendrikse et al. (2019), para que los analistas ajusten decisiones crediticias rápidamente en función del comportamiento de los indicadores clave.

Segmentación y Priorización de Clientes: La clasificación de empresas según el coeficiente de variación permite identificar aquellas más sensibles a factores externos, como recomendó Dapp (2015). Este enfoque es crucial para gestionar de manera proactiva a los clientes con perfiles de riesgo cambiantes.




Ilustración 10. Estrategia Business Intelligence FASE II.

Retroalimentación y Ajustes en el Modelo: Revisiones trimestrales del rendimiento del modelo permiten afinar los pesos asignados a cada componente (NLP, Tradicional e IA),

garantizando que el modelo se mantenga actualizado y relevante ante el cambio en los patrones de datos, en línea con lo expuesto por Kurnia & Suharjito (2018).

Capacitación del Equipo de Análisis de Crédito: La capacitación sobre la interpretación de datos no financieros y factores externos ayuda a los analistas a comprender el impacto de estos en el scoring crediticio (Dapp, 2015), asegurando decisiones bien fundamentadas.

Beneficios Esperados: Esta estrategia ofrece una ventaja competitiva al adaptar la evaluación crediticia a un entorno cambiante y centrarse en factores críticos para la estabilidad de la empresa, como lo demuestran los hallazgos de Hendrikse et al. (2019) y Goh et al. (2019), donde la integración de factores externos y no financieros en modelos de evaluación crediticia mejora significativamente la precisión y relevancia de los análisis.

8.4 IDENTIFICACIÓN DEL ECOSISTEMA DIGITAL

Obtención del modelo para la identificación del ecosistema digital basado en la relación del mecanismo de reputación y Business Intelligence. Como servicio estándar, la banca en línea moderna ofrecerá a los clientes un registro automatizado de sus ingresos y gastos que se puede presentar en forma de cuadro o categorizar por fecha. Sobre esta base, también será posible calcular interactivamente las diferentes necesidades financieras de los clientes en forma de escenarios.

Actividades

- Recopilación de servicios & Adaptación del modelo
- Relación de los servicios & Validación del ecosistema

Las ofertas bancarias propuestas se basan en los datos de comportamiento recopilados y evaluados con respecto a los patrones de gasto del cliente o la propensión a ahorrar o asumir riesgos, (Dapp, 2015). Por ejemplo, es posible proporcionar cálculos que muestren a los clientes un cuadro de un préstamo de consumo, hipoteca de propiedad o plan de jubilación de acuerdo con su comportamiento financiero. También se considerarán las

dinámicas externas como tasas de interés, cotizaciones de valores y tasas de cambio, que pueden cambiarse interactivamente en los escenarios y pronósticos.

8.5 VALIDACIÓN Y COMPARACIÓN DEL MODELO RESULTADO

Evaluación del modelo en un escenario en específico donde se determina la validez con respecto al análisis de los resultados obtenidos. En el caso de una vista del ecosistema comercial, las áreas comerciales de las fintechs deben extenderse a las áreas comerciales identificadas. Esta perspectiva, se basa en la investigación cualitativa de 195 modelos comerciales de fintechs, se centra en un alcance limitado, diversos grados de transparencia y un apoyo insuficiente de los negocios (Schmidt, Schirmer & Drews, 2018).

- Comparación Modelos Tradicionales & Validación datos bancarios

8.6 CALCULO MODELOS TRADICIONALES

Para calcular un score crediticio tradicional basado en la información financiera proporcionada, es necesario seguir una serie de pasos que evalúan la solvencia, liquidez, rentabilidad, y estabilidad financiera de una empresa. A continuación, se describe cómo utilizar los indicadores financieros mencionados para calcular dicho score:

- Razón de Liquidez General (Current Ratio)

Este indicador mide la capacidad de la empresa para cubrir sus pasivos a corto plazo con sus activos corrientes.

Ecuación 3. Razón de liquidez

$$\text{Razon de Liquidez} = \frac{\text{Total Activos}}{\text{Total Pasivos}}$$

Si la razón es mayor a 1, la empresa tiene más activos que pasivos y es más solvente. Si es menor a 1, la empresa puede enfrentar problemas para cubrir sus obligaciones a corto plazo (Brigham & Ehrhardt, 2013).

- Razón de Endeudamiento (Debt-to-Equity Ratio)

Este indicador mide el nivel de endeudamiento de la empresa en relación a su patrimonio.

Ecuación 4. Razón de endeudamiento

$$\text{Razon de Endeudamiento} = \frac{\text{Total Pasivos}}{\text{Total Patrimonio}}$$

Un valor bajo indica que la empresa está financiando la mayoría de sus operaciones con su propio capital. Un valor alto indica una dependencia significativa del endeudamiento externo, lo que puede aumentar el riesgo (Higgins, 2012).

- Margen Operativo (Operating Margin)

El margen operativo mide cuán eficiente es la empresa generando ganancias de sus operaciones.

Ecuación 5. Margen Operativo

$$\text{Margen Operativo} = \frac{\text{Ganancia (Pérdida) por Actividades de Operacion}}{\text{Ingresos Operacionales}}$$

Un margen operativo positivo y alto indica que la empresa está operando eficientemente. Un margen bajo o negativo indica problemas en la gestión operativa (Damodaran, 2002).

- Rentabilidad sobre Activos (ROA - Return on Assets)

Este ratio mide la eficiencia con la que la empresa utiliza sus activos para generar ganancias.

Ecuación 6. ROA

$$\text{ROA} = \frac{\text{Ganancia (Pérdida)}}{\text{Total Activos}}$$

Un ROA alto indica que la empresa está utilizando sus activos de manera eficiente. Un ROA bajo o negativo indica una falta de eficiencia (Ross, Westerfield, & Jaffe, 2016).

- Rentabilidad sobre el Patrimonio (ROE - Return on Equity)

Este indicador mide el retorno que la empresa genera sobre el capital invertido por sus accionistas.

Ecuación 7. ROE

$$ROE = \frac{\text{Ganancia (Perdida)}}{\text{Total Patrimonio}}$$

Un ROE alto significa que la empresa está generando buenos retornos sobre el capital de los accionistas. Un ROE bajo sugiere que los accionistas están recibiendo poco retorno por su inversión (Brigham & Daves, 2014).

- Indicador de Leverage (Apalancamiento Financiero)

Este ratio mide el apalancamiento financiero de la empresa, es decir, la relación entre sus activos y el patrimonio.

Ecuación 8. Apalancamiento Financiero

$$\text{Apalancamiento Financiero} = \frac{\text{Total Activos}}{\text{Total Patrimonio}}$$

Un apalancamiento elevado indica que la empresa está financiando la mayor parte de sus activos con deuda. Un apalancamiento bajo indica una dependencia mayor del capital propio para financiar los activos (Damodaran, 2010).

8.7 CALCULO MODELOS IA

Para el cálculo de un scoring crediticio basado en inteligencia artificial (IA), la fórmula o modelo depende de la metodología y del tipo de algoritmos utilizados. A continuación, detallo un enfoque general y algunas fórmulas comunes, especialmente en modelos de aprendizaje automático supervisado, como regresión logística, Support Vector Machines (SVM), y redes neuronales.

- Modelo de Regresión Logística

La regresión logística es uno de los métodos más utilizados en scoring crediticio y proporciona probabilidades de que un individuo incumpla en sus pagos, lo cual se traduce en un puntaje.

Ecuación 9. Modelo de Regresión Logística

$$P(y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}$$

Donde:

- $P(y = 1|X)$ es la probabilidad de incumplimiento.
- X representa las variables de entrada, como el historial de pagos, ingresos, y endeudamiento.
- $\beta_0 + \beta_1 + \beta_2 + \dots + \beta_n$ son los coeficientes que se estiman en el modelo.

Este modelo permite calcular un puntaje crediticio al convertir esta probabilidad en un rango de puntuación (por ejemplo, de 300 a 850).

- Support Vector Machines (Svm)

El modelo SVM busca optimizar una función de margen máximo para clasificar a los solicitantes en dos grupos: "aprobado" o "no aprobado".

Ecuación 10. Support Vector Machines

$$f(x) = w \cdot x + b$$

Donde:

- w representa el vector de pesos asignado a cada característica.
- x es el vector de características del solicitante.
- b es el sesgo del modelo.

La función de decisión de SVM clasifica en función del signo de $f(x)$; Si $f(x) \geq 0$, el solicitante se clasifica como "aprobado". Para convertir esta salida en un puntaje, es posible escalar el valor de $f(x)$ a un rango específico.

- Redes Neuronales Artificiales

Las redes neuronales aplican múltiples capas y funciones de activación para calcular un puntaje basado en patrones complejos en los datos. La fórmula general para una capa en una red neuronal es:

Ecuación 11. Redes Neuronales Artificiales

$$h = f(WX + b)$$

Donde:

- W son los pesos asignados a las conexiones neuronales.
- X son las características de entrada.
- b es el sesgo de la capa.
- f es la función de activación, como ReLU o Sigmoide.

Las redes neuronales suelen requerir un proceso de "entrenamiento" donde el error entre la predicción y la realidad se minimiza para mejorar el modelo de scoring.

- Modelos IA Explicable (XAI)

Para mejorar la interpretabilidad, es posible integrar métodos como SHAP (Shapley Additive Explanations) que asignan una importancia a cada característica para el scoring final. La fórmula general en SHAP es:

Ecuación 12. Modelos IA Explicable

$$SHAP\ value = f(x) - E[f(X)]$$

Donde:

- $f(x)$ es el puntaje calculado para el individuo específico.
- $E[f(X)]$ es el valor esperado del modelo.

Con IA explicable, las variables que contribuyen a aumentar o reducir el scoring crediticio son claras, facilitando la interpretación del modelo. La elección entre estos modelos depende del tipo de datos disponibles, la necesidad de interpretabilidad y el nivel de precisión requerido. Las técnicas de machine learning, como SVM o redes neuronales, suelen mejorar la precisión, mientras que la regresión logística y los modelos XAI brindan una mayor claridad en la explicación de los resultados.

Para que un modelo XAI sea eficaz y justifique el scoring de manera interpretable, necesita datos detallados y multidimensionales. Este enfoque permite a los modelos de IA no solo ofrecer un puntaje crediticio, sino también desglosar la importancia de cada variable, lo que mejora la transparencia y permite a los usuarios comprender por qué ciertos factores influyen en sus puntuaciones. Esto es crucial para garantizar el cumplimiento de regulaciones de transparencia y para ganar la confianza de los usuarios en el sistema (Dapp, 2015).

9. MODELO PLANTEADO

Para la creación de modelo se centrará en la definición de una prueba de concepto (PoC) para evaluar la viabilidad de utilizar algoritmos de Procesamiento de Lenguaje Natural (PLN) a partir de fuentes de datos públicos, específicamente información de redes sociales, en el cálculo de un puntaje crediticio basado en la imagen pública de la empresa. Inicialmente, se recopilaron datos de redes sociales utilizando APIs públicas, como la Twitter API, aprovechando el servicio AWS API Gateway para gestionar las solicitudes de manera segura y escalable (Ramasubramanian & Jain, 2018).

Los datos obtenidos se almacenarán en Amazon S3 para el almacenamiento no estructurado de grandes volúmenes de datos y en Amazon DynamoDB para el manejo de datos estructurados y con alta disponibilidad (Barrett, 2020). Esta arquitectura permite una gestión eficiente y escalable del almacenamiento de datos. Posteriormente, se aplicarán técnicas de PLN, utilizando servicios de AWS Comprehend para el análisis de sentimiento y la clasificación de texto, junto con librerías como TextBlob, que facilita la extracción de sentimientos y características gramaticales (Chakraborty et al., 2021). Los textos se analizarán para extraer características como el sentimiento positivo, negativo o neutro y otros atributos como la frecuencia de palabras clave y el contexto semántico.

Para garantizar la calidad y consistencia de los datos, se utilizarán AWS Glue y AWS DataBrew para transformar y estandarizar la información, eliminando duplicados y manejando datos faltantes o inconsistencias (Khan, 2019). Estas herramientas automatizan gran parte del proceso de preparación de datos, lo que mejora la eficiencia y la calidad del dataset. Los resultados del análisis de sentimiento se integrarán en modelos de aprendizaje automático desarrollados y entrenados en Amazon SageMaker, donde se implementarán algoritmos supervisados como Regresión Logística o XGBoost para calcular un puntaje crediticio basado en el comportamiento y las opiniones expresadas en redes sociales (Aggarwal et al., 2021). Estos modelos se entrenarán utilizando datos etiquetados para predecir el riesgo crediticio de las empresas en función de la percepción pública.

Finalmente, los resultados se visualizarán en Amazon QuickSight, lo que permitirá una interpretación clara y comprensible de los puntajes crediticios. Amazon QuickSight proporciona un entorno interactivo para la creación de paneles visuales que facilitan la toma de decisiones basada en datos (Joshi, 2020). Esto permitirá a los responsables de decisiones visualizar las métricas de crédito, identificando patrones en el comportamiento de la opinión pública y sus efectos en la solvencia financiera de las empresas. Esta prueba de concepto demuestra cómo las tecnologías de AWS pueden respaldar una aplicación avanzada de calificación crediticia, proporcionando una infraestructura sólida y escalable para implementar algoritmos de PLN en datos de redes sociales. Además, se ilustra el uso eficiente de herramientas de análisis de datos y aprendizaje automático para resolver problemas complejos en el sector financiero.




Ilustración 11. Modelo de Contexto C4

El modelo define una arquitectura de contexto que implementa múltiples flujos funcionales, cada uno interconectado mediante diversos componentes, diseñados para proporcionar información de calificación crediticia a los clientes empresariales. La arquitectura se organiza en capas claramente definidas, cada una con roles y responsabilidades específicas dentro del ecosistema.




Ilustración 12. Modelo de Solución por Capas

9.1 PORTAL WEB (FRONT-END)

El portal web actúa como la interfaz de usuario, permitiendo a los clientes empresariales acceder a sus informes de calificación crediticia. Este componente está implementado con React para una experiencia de usuario dinámica y responsive, y se comunica con la capa de APIs a través de Axios o Fetch API. Utiliza mecanismos de autenticación y autorización basados en OAuth 2.0 para garantizar que solo los usuarios autorizados puedan acceder a los datos. La arquitectura del portal web está integrada con servicios de seguridad como AWS Cognito o Okta para manejar la gestión de identidad de los usuarios.

9.2 CAPA DE API

La capa de API sirve como un intermediario entre el portal web y las capas de datos y lógica de negocio. Esta capa está diseñada en una arquitectura RESTful que permite la comunicación eficiente entre los diferentes componentes. AWS API Gateway gestiona las solicitudes entrantes y asegura que los servicios se escalen adecuadamente en función de la demanda. Además, las APIs están diseñadas siguiendo el estándar OpenAPI Specification (OAS) para garantizar que los clientes y terceros puedan consumirlas de manera sencilla y estandarizada.

Se utiliza GraphQL para consultas más eficientes y flexibles de los datos cuando se requiere granularidad en las respuestas. La API es responsable de la agregación de datos provenientes de múltiples fuentes externas (redes sociales, transacciones financieras, telecomunicaciones, etc.), las cuales son consumidas a través de APIs públicas y privadas, asegurando que los datos sean frescos y precisos.

9.3 CAPA DE BUSINESS INTELLIGENCE (BI)

Este diagrama ilustra un proceso estructurado de evaluación crediticia, que combina herramientas avanzadas de análisis y modelos de inteligencia artificial para mejorar la precisión en la asignación de crédito. La inclusión de múltiples fuentes de datos y un sistema de procesamiento basado en Procesamiento de Lenguaje Natural (NLP) permite no solo una revisión tradicional de los aspectos financieros, sino también una comprensión de la reputación social y los patrones de gasto de cada solicitante. Esta metodología innovadora permite la toma de decisiones en tiempo real, lo cual es crucial en un entorno de riesgos y necesidades de crédito en constante cambio. En el análisis y la evaluación crediticia, cada fase en este diagrama representa un bloque de funciones críticas que buscan maximizar la precisión y minimizar los riesgos, cumpliendo con los objetivos del sistema y generando resultados ajustados a las políticas de crédito de la organización (Zhou et al., 2020; Barker & Ko, 2019).




Ilustración 13. Secuencia Estrategia Business Intelligent.

La fase inicial comienza con el analista de crédito estableciendo los objetivos del modelo y los KPI's a través de la plataforma de BI. En esta etapa, los KPI's esenciales incluyen precisión del score final, variación en el scoring y tasas de aprobación de crédito ajustadas. Definir estos objetivos con claridad permite al sistema optimizar y evaluar los resultados a lo largo del tiempo, integrando mejoras en el análisis del riesgo crediticio (Chen et al., 2019; Athey et al., 2021). Una vez definidos los objetivos, el Sistema de BI activa el modelo NLP y solicita la integración de datos de múltiples fuentes: redes sociales para medir la percepción y reputación de la empresa, datos transaccionales para analizar patrones de gasto y comportamiento financiero, y bases de datos financieras para consultar balances históricos (Kurnia & Suharjito, 2018; Hendrikse et al., 2019). Esto permite una visión holística del cliente, abordando tanto factores internos como externos que influyen en la estabilidad financiera.

El Sistema BI ejecuta análisis continuo y reportes automáticos, que los analistas pueden visualizar en tiempo real. Esta etapa permite al equipo de crédito ajustar las políticas crediticias de acuerdo con el perfil de riesgo del cliente y la variabilidad de los datos, facilitando una respuesta rápida ante cambios en el score (Athey et al., 2021). Con base en los resultados obtenidos, el sistema realiza una clasificación de clientes según su nivel de riesgo. Los clientes con alto riesgo, identificados mediante un score ajustado por IA y NLP, reciben una atención prioritaria para aplicar políticas de crédito más conservadoras o requerir condiciones adicionales. Esta fase garantiza que las decisiones de crédito reflejen la percepción actual del mercado y optimicen la gestión del riesgo (Chen et al., 2019).

Finalmente, el sistema de BI permite al analista recopilar retroalimentación del cliente, lo cual facilita ajustar el modelo según el rendimiento observado. Esta retroalimentación fomenta la mejora continua del modelo, asegurando que se mantenga alineado con cambios en el entorno digital y el comportamiento del cliente, como señalan Kurnia y Suharjito (2018) y Hendrikse et al. (2019).

La capa de BI es responsable de procesar y analizar la información recopilada. Se apoya en AWS QuickSight para la visualización interactiva de datos, permitiendo a los usuarios finales generar reportes personalizados. Aquí, los algoritmos de Machine Learning implementados en Amazon SageMaker o Azure ML calculan el puntaje crediticio basado en diversas métricas, como el análisis de sentimientos en redes sociales, transacciones financieras, historial crediticio y otros datos alternativos. Esta capa también integra un sistema de reglas comerciales que permite realizar ajustes específicos en los modelos de calificación, personalizando los resultados según el sector o las características del cliente empresarial. El sistema de BI utiliza ETL pipelines en AWS Glue para transformar, limpiar y enriquecer los datos antes de ser procesados por los modelos predictivos.

9.4 CAPA DE TRANSFORMACIÓN DE DATOS

La capa de transformación de datos es crítica para garantizar la calidad y coherencia de los datos a lo largo del flujo. Aquí, los datos externos, como los de redes sociales o las APIs de open banking, son procesados y normalizados utilizando AWS Glue y AWS Lambda para

ejecutar funciones serverless que manejan la transformación en tiempo real. Esta capa también utiliza Apache Spark para el procesamiento de grandes volúmenes de datos en paralelo, asegurando que el sistema pueda manejar un número elevado de solicitudes de calificación crediticia en momentos de alta demanda. Apache Kafka se utiliza como una plataforma de mensajería distribuida, permitiendo la transmisión y procesamiento continuo de los datos en tiempo real. La capa de transformación garantiza que los datos estén listos para ser consumidos por la capa de BI.

9.5 BASE DE DATOS

El componente de almacenamiento de datos se compone de una combinación de bases de datos relacionales y NoSQL. Se utilizan bases de datos como Amazon RDS (con soporte para PostgreSQL o MySQL) para almacenar datos transaccionales y estructurados. Para los datos no estructurados, como las opiniones en redes sociales y registros de actividad, se utiliza Amazon DynamoDB o MongoDB. Además, Amazon S3 se emplea para almacenar archivos grandes, como historiales completos de datos sociales o logs de transacciones, que pueden ser procesados en lotes. El sistema de almacenamiento también implementa mecanismos de caché usando Amazon ElastiCache con Redis para mejorar la latencia en el acceso a datos de uso frecuente, como consultas repetidas de puntajes crediticios.

9.6 FUENTES DE INFORMACIÓN EXTERNAS

Los datos externos provienen de múltiples APIs públicas y privadas, que proporcionan acceso a información diversa como datos de redes sociales (por ejemplo, Twitter API y Facebook Graph API), información bancaria mediante Open Banking APIs, y datos de telecomunicaciones. Estas APIs se integran de forma segura utilizando mecanismos como OAuth 2.0 para garantizar la autenticación y autorización apropiadas, cumpliendo con las normativas de protección de datos como GDPR y CCPA. Además, se implementan estrategias de web scraping controlado, utilizando servicios como Scrapy o BeautifulSoup, para extraer datos de plataformas de revisión y reputación como Google Reviews o Yelp.

La arquitectura propuesta ofrece una solución escalable, segura y flexible para proporcionar información de calificación crediticia a empresas, aprovechando tecnologías avanzadas de procesamiento de datos y aprendizaje automático. Al integrar datos estructurados y no estructurados, junto con fuentes externas de información, este modelo ofrece una visión holística y precisa del riesgo crediticio, adaptándose a las necesidades del mercado y a los avances en la economía digital.

9.7 FLUJO FUNCIONAL

Los clientes comerciales en este sistema se definen como clientes B2B que utilizan la plataforma para acceder a información relacionada con la calificación crediticia a través de un Portal web seguro. El portal proporciona una interfaz intuitiva y accesible donde los usuarios pueden ver, descargar y analizar sus puntajes e informes crediticios. La plataforma incluye opciones para generar informes personalizados y programar alertas sobre actualizaciones en el puntaje crediticio o en la información relacionada.

9.7.1 DETALLE FUNCIONAL DEL PORTAL WEB

Acceder a informes de calificación crediticia: El usuario puede visualizar informes detallados sobre su puntaje, incluyendo análisis de su comportamiento financiero basado en datos tradicionales y alternativos. Los usuarios pueden explorar sus puntajes a través de gráficas interactivas, realizar análisis de tendencias, y comparar su historial de puntajes a lo largo del tiempo. Además, pueden configurar notificaciones automáticas en caso de cambios significativos en su puntuación.

9.7.2 CAPA DE API (MIDDLEWARE)

La capa de API actúa como un middleware que proporciona conectividad entre el Portal Web y las diversas fuentes de datos externas. Esta capa recupera información de plataformas sociales como Instagram, Facebook y X (anteriormente Twitter) para capturar opiniones y comportamientos que afectan la imagen pública de los clientes comerciales. Fuentes gubernamentales como bases de datos fiscales y licitaciones públicas, lo que

permite evaluar el comportamiento empresarial en el contexto de contratos públicos y obligaciones fiscales. Integración con APIs que proporcionan datos avanzados, como análisis de patrones de comportamiento empresarial o predicciones de solvencia basadas en machine learning.

Este sistema de middleware está diseñado para gestionar múltiples solicitudes de API de manera asíncrona y garantizar un rendimiento óptimo, utilizando tecnologías como AWS Lambda para ejecutar funciones sin servidor que procesan y transforman los datos en tiempo real. La comunicación entre el Portal Web y las APIs se realiza utilizando HTTPS y JSON, lo que garantiza un intercambio seguro y eficiente de datos.

9.7.3 BASE DE DATOS HÍBRIDA (SQL Y NOSQL)

El sistema de almacenamiento de datos adopta un enfoque híbrido, utilizando tanto bases de datos SQL como NoSQL, los datos estructurados, como registros financieros, historiales crediticios y datos de licitaciones públicas, se almacenan en bases de datos relacionales como Amazon RDS (PostgreSQL), que permite realizar consultas complejas y garantiza la integridad referencial. Los datos no estructurados o semi-estructurados, como las opiniones en redes sociales, se almacenan en Amazon DynamoDB o MongoDB, lo que permite una mayor escalabilidad y flexibilidad en el almacenamiento.

9.7.4 CAPA DE TRANSFORMACIÓN DE DATOS

La capa de transformación de datos es fundamental para procesar, limpiar y estandarizar los datos provenientes de la capa API antes de ser almacenados en las bases de datos correspondientes. Utilizando ETL pipelines basados en AWS Glue, los datos se transforman en formatos adecuados para su posterior análisis. Este proceso incluye el ordenamiento de datos, Clasificación y categorización de los datos recibidos para facilitar su almacenamiento y consulta. Homogenización de diferentes formatos de datos provenientes de diversas fuentes (p. ej., fechas, divisas) para asegurar su coherencia en el sistema. Los datos procesados se almacenan en repositorios tanto relacionales como no relacionales,

permitiendo que puedan ser consultados rápidamente desde el Portal Web o utilizados en análisis más complejos por la capa de BI.

9.7.5 CAPA DE BUSINESS INTELLIGENCE (BI)

La capa de Business Intelligence (BI) es donde se realiza el análisis profundo de los datos procesados. Aquí se aplican algoritmos de Procesamiento de Lenguaje Natural (PLN) y machine learning para obtener información valiosa sobre la solvencia de los clientes empresariales. Este análisis incluye:

- **Análisis de sentimiento:** Aplicación de AWS Comprehend o TextBlob para analizar las opiniones públicas sobre las empresas a través de sus interacciones en redes sociales. Se asigna un puntaje de sentimiento (positivo, negativo, neutro) que influye en el cálculo del puntaje crediticio.
- **Modelos predictivos:** La plataforma utiliza Amazon SageMaker para entrenar modelos predictivos que evalúan el riesgo crediticio basado en datos financieros y de comportamiento. Estos modelos aprenden de los datos históricos y de la nueva información recibida, mejorando continuamente la precisión del puntaje.

9.8 FLUJO DE DATOS

Esta arquitectura proporciona una infraestructura funcional y escalable, permitiendo a los clientes B2B acceder de manera segura a sus informes crediticios mientras se beneficia de un análisis enriquecido basado en datos alternativos como los provenientes de redes sociales y fuentes gubernamentales.

La arquitectura propuesta para la creación del modelo con base en la metodología anterior, incluye etapas funcionales específicas, donde se hace énfasis en la búsqueda e identificación del ecosistema bancario digital a partir de la consulta de datos, la transformación y estandarización de la información pública, y finalmente se realiza un escenario de evaluación sobre una empresa específica. El impacto del scoring se relaciona con la capa de Gestión de Crédito y Gestión de Precios utilizando las APIs de negocio para

recuperar información de los clientes y gestionarla de forma directa, las APIs técnicas se conectan con las APIs de Negocio y también realizan consultas para obtener información técnica y de redes sociales.

AWS DataBrew interactúa con las APIs técnicas para realizar operaciones de limpieza y preparación de datos, AWS Glue actúa como un servicio de integración de datos y transformación de datos entre varios servicios y DynamoDB AWS almacena información específica junto con Storage S3 AWS para almacenar grandes volúmenes de datos y se conecta a AWS Glue para recibir datos transformados y preparados agregando información a Amazon QuickSight, que es la herramienta de análisis y visualización de datos, que toma datos de DynamoDB AWS. Long Term Strategy toma datos de Amazon QuickSight para crear una estrategia personalizada y mostrarla utilizando Price Management.




Ilustración 14. Modelo de Solución Funcional

El diagrama presenta el proceso paso a paso utilizando un flujo funcional que define una solución de arquitectura de software basada en la implementación de una aplicación web alojada en AWS, interactuando con APIs externas, procesando datos en múltiples servicios de AWS utilizando algoritmos NLP y tomando un escenario de decisión utilizando BI.

La aplicación web se implementa en la infraestructura de AWS, utilizando servicios de Elastic Load Balancing para asegurar el tráfico entrante correcto a la plataforma, distribuyendo equitativamente la carga entre múltiples instancias para garantizar una alta disponibilidad y tolerancia a fallas. API Gateway Actúa como un punto de entrada para todas las solicitudes de API y proporciona un enrutamiento seguro y escalable a las API subyacentes.

- Información de redes sociales - API: administra solicitudes relacionadas con la información de redes sociales:
- Consume OpenAI - API: obtiene datos de la API de OpenAI.
- Datos gubernamentales - API: obtiene datos de la API de información gubernamental.

Los datos obtenidos de las API se almacenan en una base de datos AWS NoSQL DynamoDB, DataBrew se utiliza para limpiar, preparar y transformar los datos para su posterior procesamiento. Los datos procesados se almacenan en Amazon S3 con un modelo de datos estructurado. Por último, Amazon QuickSight se utiliza para el análisis y la visualización de los resultados de las decisiones crediticias. Se crea un panel de estrategia a largo plazo para visualizar y gestionar las decisiones estratégicas. Este proceso paso a paso garantiza una gestión eficiente de los datos, desde la adquisición de los mismos hasta la toma de decisiones estratégicas basada en el análisis detallado y la visualización de los datos.

9.9 PROPUESTA MODELO DE SOLUCIÓN

La solución completa se modelará utilizando una arquitectura de software modular y escalable, basada en tecnologías de AWS y Python. La prueba de concepto (PoC) inicial

se centrará en dos áreas clave: el consumo de datos desde fuentes externas (específicamente redes sociales) y la implementación de Procesamiento de Lenguaje Natural (PLN) para el análisis de sentimiento. La arquitectura está diseñada con un enfoque basado en microservicios y sigue el patrón de arquitectura de capas, lo que permite una escalabilidad modular y facilita la integración de nuevos componentes a medida que se valida la viabilidad de la solución.




Ilustración 15. Modelo de Solución.

9.9.1 RECOPIACIÓN DE DATOS EXTERNOS

Se utilizará Python para crear scripts que consuman APIs públicas de redes sociales, como la Twitter API, para recopilar datos en tiempo real sobre interacciones que mencionen a empresas de prueba. Los scripts ejecutarán consultas directas para obtener datos como

tweets, retweets, menciones y hashtags relevantes. Estos datos serán almacenados temporalmente en Amazon S3 para su procesamiento posterior.

- Tecnología clave: Python, Twitter API, Amazon S3.
- Librerías usadas: Tweepy para la interacción con la API de Twitter.
- Patrones aplicados: ETL (Extract, Transform, Load) para asegurar que los datos sean extraídos, transformados (limpieza y filtrado) y cargados en el sistema para su análisis.

9.9.2 ANÁLISIS SENTIMIENTOS NLP

Una vez recopilados los datos, se implementará un análisis de sentimiento utilizando la librería TextBlob. TextBlob ofrece una interfaz simple para realizar tareas de PLN como análisis de sentimiento, etiquetado de partes del discurso y traducción. En esta fase de la PoC, el objetivo es medir si los tweets y publicaciones en redes sociales reflejan un sentimiento positivo, negativo o neutro respecto a las empresas evaluadas.

- Tecnología clave: TextBlob en Python.

Estrategia de implementación: Se realizará un preprocesamiento de los textos para eliminar ruido, como menciones innecesarias, hashtags y símbolos. Luego, se ejecutarán las funciones de análisis de sentimiento para obtener el puntaje de sentimiento (positivo, negativo o neutro) y la polaridad de cada texto.

- Patrones aplicados: Pipeline de PLN para el flujo de procesamiento de textos.

9.9.3 INTEGRACIÓN CON AWS SAGEMAKER

Una vez ajustado el algoritmo de análisis de sentimiento en función de los resultados obtenidos en la etapa de pruebas, los datos procesados se integrarán en modelos de aprendizaje automático (ML) desarrollados en Amazon SageMaker. En esta fase, los resultados del análisis de sentimiento se convertirán en características (features) adicionales para enriquecer el modelo de scoring crediticio. SageMaker permitirá entrenar,

ajustar y evaluar el desempeño de los modelos de ML que calculan el puntaje crediticio basado en múltiples fuentes de datos, incluido el análisis de redes sociales.

- Tecnología clave: Amazon SageMaker, AWS Glue para el procesamiento de datos.
- Librerías usadas: Scikit-learn, XGBoost o TensorFlow para los modelos de aprendizaje automático.
- Patrones aplicados: Feature Engineering y Model Training para incorporar el análisis de sentimiento como una característica predictiva.

9.9.4 EVALUACIÓN Y PRESENTACIÓN DE RESULTADOS

Los resultados del análisis de sentimiento se presentarán utilizando Amazon QuickSight para proporcionar visualizaciones interactivas que ayuden a los responsables de decisiones a entender cómo el sentimiento en redes sociales influye en el scoring crediticio. Esta capa de visualización permite hacer un seguimiento del rendimiento del modelo, ajustar parámetros y analizar el impacto de diferentes variables.

- Tecnología clave: Amazon QuickSight.
- Patrones aplicados: BI Dashboarding para la creación de informes visuales.

9.9.5 FLUJO COMPLETO Y RETROALIMENTACIÓN

Una vez completada la arquitectura, se realizará un ciclo de retroalimentación para ajustar tanto los algoritmos de PLN como los modelos de aprendizaje automático. Se evaluará la efectividad del análisis de sentimiento y su influencia en los modelos crediticios, permitiendo realizar mejoras antes de la integración completa en la plataforma empresarial.

10. ANALISIS DE RESULTADOS

En la búsqueda por mejorar la precisión y alcance de los modelos de scoring crediticio, las metodologías tradicionales han comenzado a integrar fuentes de datos alternativas y el uso de tecnologías avanzadas como la inteligencia artificial. El modelo híbrido de evaluación crediticia, combina análisis financiero clásico con la percepción de la empresa en redes sociales y la utilización de machine learning para el procesamiento de grandes volúmenes de datos. Este enfoque, conocido como scoring alternativo, permite crear un sistema más inclusivo que considere tanto la reputación digital de la empresa como su desempeño financiero histórico, lo que facilita una evaluación crediticia más integral y precisa (World Bank Group, 2018; Deloitte, 2019).




Ilustración 16. Modelo Funcional de Calculo Scoring.

El proceso comienza con la recolección de datos de diversas fuentes, como la API de Twitter X y la Meta Graph API, que permiten acceder a comentarios y publicaciones sobre la empresa en redes sociales. El análisis de sentimientos mediante técnicas de Procesamiento de Lenguaje Natural proporciona una evaluación del sentimiento de mercado, cuantificando la percepción positiva, negativa o neutra de la empresa (LexisNexis

Risk Solutions, 2020). Esta percepción se convierte en un componente clave del modelo, con un peso del 30% en el cálculo final del score. Por otro lado, los métodos tradicionales continúan jugando un rol fundamental, aportando un 60% del puntaje total basado en indicadores financieros clásicos como los ingresos, ganancias y rentabilidad (Accion, 2021). Además, la incorporación de IA, con un peso del 10%, permite hacer proyecciones y ajustes dinámicos en función de patrones identificados a través del machine learning (McKinsey & Company, 2020).

Este capítulo analizará los resultados obtenidos a partir de la implementación de este modelo híbrido, comparando empresas de diferentes tamaños y sectores. Asimismo, se evaluará la efectividad de la inclusión de datos alternativos para mejorar la precisión del scoring crediticio y su potencial para expandir el acceso a financiamiento a empresas que históricamente han sido excluidas de los sistemas tradicionales (IFC, 2021; PwC, 2021).

- **Recolección de Datos**

Twitter X API v2 y Meta Graph API: Estas interfaces de programación de aplicaciones (APIs) permiten acceder a grandes cantidades de datos públicos de redes sociales, como comentarios, tweets y publicaciones que mencionan a la empresa (World Bank Group, 2018). Además de las redes sociales, se pueden incorporar datos provenientes de foros, sitios de reseñas y otras plataformas que permiten obtener un sentimiento general sobre la empresa (Finextra, 2021). Estos datos son fundamentales para obtener un scoring alternativo basado en la reputación y la percepción pública. Los datos alternativos, como los de redes sociales, permiten evaluar empresas que pueden no tener un historial crediticio tradicional sólido, pero que tienen presencia y reputación en plataformas digitales (LexisNexis Risk Solutions, 2020).

- **Análisis de Sentimientos usando Procesamiento de Lenguaje Natural**

El Procesamiento de Lenguaje Natural es una técnica de inteligencia artificial que analiza el lenguaje humano para identificar patrones, emociones y opiniones. En este caso, se aplica NLP para realizar un análisis de sentimiento sobre los comentarios recolectados de redes sociales y otras fuentes (McKinsey & Company, 2020).

Evaluación de la percepción pública categoriza los comentarios en sentimientos positivos, negativos o neutros, lo que permite entender cómo es percibida la empresa por sus clientes, proveedores y la comunidad en general. Esta percepción se clasifica en diferentes categorías:

- Pymes Colombianas: Por ejemplo, marcas como Seven Seven o Leonisa.
- Global SMEs (Pequeñas y Medianas Empresas Globales): Ejemplos como Nisolo o Eileen Fisher.
- Grandes Empresas Colombianas: Como Arturo Calle o Vélez.

El análisis de sentimientos permite traducir la percepción del mercado en una métrica cuantificable, que es luego utilizada para influir en el score final (Accion, 2021). Las empresas con percepciones altamente positivas pueden mejorar su score crediticio, incluso si sus métricas financieras son más modestas (Finextra, 2021).

- Scoring Basado en Percepción (Scoring Alternativo)

El gráfico muestra cómo se genera un scoring basado en la percepción pública, donde el análisis de sentimientos contribuye a una ponderación del 30% en el puntaje final. A través de este enfoque, el sentimiento del mercado y la reputación digital se consideran cruciales, ya que permiten a las empresas que tienen una fuerte reputación online compensar posibles deficiencias en sus estados financieros (LexisNexis Risk Solutions, 2020). Esta práctica ya es común en países como Brasil, México y China, donde las fintechs utilizan redes sociales y patrones de consumo digital para evaluar empresas que no cuentan con un historial bancario formal (World Bank Group, 2018).

- Score Clásico basado en Indicadores Financieros

Aquí se consideran los datos financieros clásicos de la empresa, como ingresos, rentabilidad, deuda, y proyecciones de crecimiento, extraídos de fuentes como la Cámara de Comercio o bases de datos financieras (Deloitte, 2019). Este método tiene un peso del 60% en el score final. Los ratios tradicionales como el ROA (Rentabilidad sobre Activos), ROE (Rentabilidad sobre el Patrimonio) y el margen operativo juegan un rol fundamental

en este análisis (Deloitte, 2019). Aunque el análisis tradicional sigue siendo importante, se le asigna menor peso en este modelo híbrido debido a la integración de datos alternativos, lo que refleja una visión más moderna y holística de la empresa (McKinsey & Company, 2020).

- Consulta IA (Machine Learning)

En este paso, se utilizan modelos predictivos de inteligencia artificial para realizar proyecciones y simulaciones basadas en los datos recopilados, tanto de redes sociales como de estados financieros (PwC, 2021). El uso de IA contribuye con un 10% al score final. Esto puede incluir modelos de machine learning entrenados para identificar patrones ocultos que predicen el comportamiento financiero futuro de la empresa (OECD, 2020). El uso de IA es crucial para identificar correlaciones no evidentes en los datos tradicionales y alternativos. Esto mejora la precisión del score, sobre todo para empresas que operan en entornos de riesgo o mercados fluctuantes (PwC, 2021).

- Cálculo del Score Final

Finalmente, los tres componentes (percepción pública, análisis financiero tradicional e IA) se combinan según sus respectivos pesos (30%, 60%, y 10%) para generar un score final. Este score sirve para clasificar a las empresas en función de su estabilidad financiera, su capacidad de crecimiento y su reputación en el mercado (OECD, 2020). Las empresas pueden ser comparadas en función de su scoring final, lo que facilita la toma de decisiones por parte de inversionistas y prestamistas. Este enfoque de scoring híbrido proporciona una evaluación más inclusiva y precisa (Accion, 2021).

- Conclusión y Mejora del Proceso de Scoring

Scoring Alternativo: El proceso de scoring alternativo ofrece una visión integral que complementa los métodos tradicionales con la reputación digital y el análisis predictivo, mejorando así la inclusión financiera y ofreciendo oportunidades de crédito a empresas que, de otro modo, podrían ser excluidas del sistema tradicional (LexisNexis Risk Solutions, 2020).

10.1 CALCULO SCORE ALTERNATIVO

El cálculo de un score alternativo basado en la percepción pública y el análisis de sentimiento ha emergido como una herramienta innovadora para complementar las evaluaciones crediticias tradicionales. A medida que las empresas enfrentan mercados más competitivos y conectados, la información financiera histórica ya no es suficiente para evaluar su rendimiento futuro. El uso de datos alternativos, como las opiniones y menciones en redes sociales, permite captar la percepción actual del público sobre la marca y su reputación en tiempo real. Este enfoque es especialmente relevante para empresas que operan en sectores dinámicos y mercados globales (World Bank Group, 2018). Para este análisis, se han seleccionado diez empresas representativas en tres categorías diferentes: Pymes en Colombia, SMEs Globales y Grandes Empresas Colombianas. Estas empresas fueron elegidas por su relevancia en sus respectivos sectores y su visibilidad en plataformas digitales, lo que facilita el uso de datos alternativos para complementar el análisis financiero (McKinsey & Company, 2020).

Pymes en Colombia

- Pat Primo: Una de las marcas más tradicionales en la industria textil colombiana, Pat Primo se ha destacado por su constante innovación y su enfoque en satisfacer las necesidades del mercado local. A pesar de ser una empresa con muchos años en el mercado, su adaptación a las nuevas tecnologías y a las redes sociales ha sido clave para su crecimiento reciente (Accion, 2021).
- Seven Seven: Con un enfoque joven y moderno, Seven Seven ha logrado posicionarse entre las marcas de moda preferidas por los colombianos.
- Rockgotá: Aunque es relativamente nueva en comparación con otras marcas, Rockgotá ha captado la atención del público con su propuesta de moda urbana y alternativa.
- Leonisa: Una de las marcas más reconocidas de Colombia, especialmente en el sector de lencería y ropa interior. Leonisa es una empresa de larga trayectoria que utiliza estrategias digitales para fortalecer su presencia tanto a nivel nacional.

Global SMEs

- Nisolo: Esta marca de calzado sostenible con sede en Estados Unidos ha logrado crear un impacto global gracias a su compromiso con la moda ética y sostenible. Nisolo ha capitalizado su narrativa en redes sociales, lo que le ha permitido conectar con una audiencia global consciente del impacto ambiental (World Bank Group, 2018).
- Eileen Fisher: Eileen Fisher es una empresa de moda que se destaca por su enfoque minimalista y sostenible. Su constante interacción con su audiencia en redes sociales y su compromiso con la sostenibilidad la hacen ideal para el análisis de datos alternativos como parte de su evaluación crediticia (Finextra, 2021).
- MUD Jeans: Como marca europea enfocada en la moda sostenible, MUD Jeans ha implementado modelos de negocio innovadores, como el alquiler de jeans. Su modelo de negocio disruptivo ha generado discusiones activas en redes sociales, lo que permite evaluar su percepción pública y cómo esta afecta su estabilidad financiera (Accion, 2021; Martínez-Alonso & Pérez-López, 2018).

Grandes Empresas Colombianas

- Arturo Calle: Conocida por ser una de las empresas más grandes en la confección de ropa masculina en Colombia, Arturo Calle tiene una presencia bien establecida tanto en tiendas físicas como en plataformas digitales.
- Vélez: Vélez es una marca de marroquinería y productos de cuero reconocida tanto en Colombia como en otros mercados internacionales. Su enfoque en productos de alta calidad y su conexión emocional con los consumidores a través de redes sociales fortalecen su imagen en el mercado (McKinsey & Company, 2020; Ramírez-Restrepo & Marín-Gómez, 2019).
- Koaj: Koaj se ha establecido como una marca juvenil que está en constante innovación. Su presencia digital activa y su habilidad para captar la atención del público joven la convierten en una empresa ideal para el análisis de percepción en redes sociales (Finextra, 2021; Torres-Correa & Arias-Ruiz, 2019).

El análisis del sentimiento en torno a estas empresas ofrece un complemento crítico al análisis financiero tradicional, proporcionando una visión integral de la estabilidad y reputación de cada marca. A través de técnicas de Procesamiento de Lenguaje Natural (NLP), se analizan las menciones y opiniones de los consumidores en redes sociales. Estas opiniones son categorizadas como positivas, negativas o neutrales, lo que permite crear un score alternativo basado en la percepción pública (Deloitte, 2019). Este score es de particular importancia en empresas que dependen de su relación con los consumidores y de su imagen pública para mantenerse competitivas.

El cálculo del score alternativo para estas empresas nos proporciona una herramienta poderosa para entender cómo la percepción pública puede influir en su rendimiento financiero y en su capacidad para acceder a crédito o financiamiento. En las siguientes secciones, se analizarán los resultados del análisis de sentimiento para cada empresa, evaluando cómo la percepción pública contribuye al score final.

10.1.1 PYMES COLOMBIANAS

Las pequeñas y medianas empresas representan un papel fundamental en la economía colombiana, representando aproximadamente el 90% de las unidades productivas del país y generando alrededor del 80% del empleo formal, según cifras del Ministerio de Comercio, Industria y Turismo, y la Cámara de Comercio de Bogotá. Dentro de este panorama, marcas como PatPrimo, Seven-Seven, Rockgota, y Leonisa se destacan por su posicionamiento tanto en el mercado local como en el internacional. Estas empresas no solo son reconocidas por su capacidad para generar empleo, sino también por su adaptación a los cambios del mercado y su crecimiento constante en sectores como la moda y el retail, donde la percepción pública y la reputación digital son cada vez más influyentes.

PatPrimo, una marca con una fuerte presencia en el sector textil colombiano, ha logrado consolidarse como un referente en la producción y comercialización de prendas de vestir para toda la familia, con un enfoque en la calidad y accesibilidad de sus productos. Seven-Seven, por su parte, es conocida por su moda urbana y juvenil, destacándose por su conexión con un público joven y su apuesta por tendencias globales. Rockgota, aunque

menos conocida internacionalmente, ha tenido un crecimiento significativo en el ámbito local, ganando terreno en el sector de la moda alternativa. Finalmente, Leonisa, con más de 60 años en el mercado, ha conseguido un reconocimiento mundial, posicionándose como líder en la confección de ropa interior y prendas de control.

El análisis de sentimiento basado en opiniones en redes sociales es una herramienta clave para evaluar cómo estas marcas son percibidas por los consumidores, y puede ofrecer insights valiosos sobre las fortalezas y debilidades que enfrentan en un mercado altamente competitivo. Según la Organización para la Cooperación y el Desarrollo Económicos (OCDE), el uso de datos alternativos, como el análisis de redes sociales, está siendo adoptado rápidamente para mejorar las evaluaciones financieras y de reputación de las PYMEs, lo que puede ayudar a ajustar las estrategias comerciales de estas marcas en Colombia y más allá (OECD, 2020). Este análisis permitirá entender cómo la percepción pública afecta la imagen y reputación de estas marcas, y cómo podrían aprovechar esta información para mejorar su posicionamiento en el mercado.




Ilustración 17. Resultado Análisis Sentimental Pymes Colombia.

La imagen muestra un análisis de sentimiento comparativo para cuatro marcas: PatPrimo, Seven-Seven, Rockgota, y Leonisa, basado en opiniones clasificadas como positivas, negativas, o neutrales. Cada gráfico presenta la cantidad de comentarios para cada categoría de sentimiento. Interpretación por marca, PatPrimo destaca como la marca con mayor percepción positiva entre las cuatro, mientras que Seven-Seven, Rockgota, y Leonisa presentan un mayor número de opiniones negativas. Las opiniones neutrales son relativamente bajas para todas las marcas, lo que refleja que los usuarios suelen tener opiniones claras sobre estas marcas.




Ilustración 18. Distribución Resultados Pymes Colombia.

La imagen muestra gráficos de violín que ilustran la distribución de los Sentiment Scores (puntajes de sentimiento). Los gráficos de violín combinan un gráfico de caja (box plot) con una estimación de densidad para mostrar cómo se distribuyen los puntajes de sentimiento en las categorías Positive, Negative y Neutral. Las gráficas permiten comparar cómo se perciben las diferentes marcas en función de los puntajes de sentimiento. Leonisa y PatPrimo muestran una mejor distribución en los comentarios positivos, mientras que Seven-Seven tiene una proporción significativamente mayor de comentarios negativos.

Marcas como Rockgota y Seven-Seven tienen distribuciones más amplias en sus comentarios negativos, lo que sugiere que enfrentan opiniones más polarizadas en el mercado. En resumen, estos gráficos proporcionan una visualización clara de cómo varía la percepción de las marcas en función de los sentimientos expresados por los usuarios, lo cual es clave para el análisis de reputación y toma de decisiones.




Ilustración 19. Matriz de Predicción Pymes Colombia.

La imagen muestra las matrices de confusión, estas matrices representan la comparación entre los valores de sentimiento reales y los valores predichos a través de un modelo de análisis de sentimiento. Cada matriz contiene los verdaderos valores en el eje vertical (True Label) y los valores predichos en el eje horizontal (Predicted Label). La diagonal de cada matriz muestra las predicciones correctas.

PatPrimo: Las 13 predicciones reales de comentarios positivos, 9 fueron clasificadas correctamente como positivas, mientras que 4 se clasificaron incorrectamente como negativas. De los 13 comentarios negativos, 9 se clasificaron correctamente, pero hubo 3 que se predijeron como positivos y 1 como neutral. La mayoría de los comentarios etiquetados como neutros fueron predichos incorrectamente, con 10 clasificados como

positivos y solo 3 como neutrales. El modelo tuvo buen desempeño prediciendo comentarios negativos y positivos, pero tuvo dificultades con los comentarios neutros, que fueron clasificados incorrectamente como positivos.

- El puntaje crediticio final unificado es: **0.615**

Seven-Seven: De los 15 comentarios reales positivos, solo 4 se clasificaron correctamente. La mayoría (10) fueron predichos como negativos. 10 comentarios negativos se predijeron correctamente, pero 7 comentarios negativos fueron clasificados incorrectamente como positivos. La mayoría de los comentarios neutros fueron predichos como negativos, con solo 1 predicción correcta. El modelo tiene problemas para distinguir entre sentimientos positivos y negativos en esta marca, lo que podría reflejar una polarización en la percepción de Seven-Seven.

- El puntaje crediticio final unificado es: **0.329**

Rockgota: 19 comentarios positivos, 7 fueron predichos correctamente y 11 fueron clasificados como negativos. El modelo tuvo un buen desempeño con los comentarios negativos, prediciendo correctamente 8 de 11. Nuevamente, los comentarios neutros fueron difíciles de predecir correctamente, con solo 1 clasificación precisa. El modelo también tuvo dificultades para diferenciar entre comentarios positivos y negativos, lo que podría deberse a la naturaleza subjetiva de los comentarios para esta marca.

- El puntaje crediticio final unificado es: **0.369**

Leonisa El modelo tuvo un buen rendimiento prediciendo comentarios positivos, con 8 de 10 clasificados correctamente. De los 8 comentarios negativos, 4 fueron predichos correctamente. No se predijeron correctamente los comentarios neutros, ya que fueron clasificados incorrectamente como positivos o negativos. Aunque el modelo tuvo un buen desempeño con los comentarios positivos, sigue habiendo una dificultad general para manejar comentarios neutrales.

- El puntaje crediticio final unificado es: **0.439**

10.1.2 SMALL AND MEDIUM-SIZED ENTERPRISES (SMES)

Las pequeñas y medianas empresas (SMEs, por sus siglas en inglés) constituyen una parte fundamental del motor económico de los Estados Unidos, representando más del 99% de todas las empresas del país y creando aproximadamente dos tercios de los nuevos empleos netos anualmente (U.S. Small Business Administration, 2021). Estas empresas, aunque varían en tamaño y sector, comparten desafíos y oportunidades comunes que han sido especialmente evidentes en los últimos años, debido al impacto de la pandemia de COVID-19. A pesar de los retos significativos que enfrentaron, como las interrupciones en la cadena de suministro y la reducción de la demanda del consumidor, muchas SMEs en Estados Unidos han demostrado resiliencia y capacidad de adaptación.

Empresas globales como Nisolo, Eileen Fisher y MUD Jeans ofrecen ejemplos de cómo las SMEs pueden innovar en un entorno difícil, integrando principios de sostenibilidad y responsabilidad social en sus modelos de negocio. Estas empresas han aprovechado los incentivos fiscales y los programas de ayuda del gobierno estadounidense, tales como el Paycheck Protection Program (PPP), diseñado para proporcionar alivio financiero durante la pandemia (Internal Revenue Service, 2021). Sin embargo, siguen enfrentando retos clave, como la necesidad de digitalización acelerada y la reconfiguración de sus cadenas de suministro globales.

Uno de los principales beneficios fiscales que han aprovechado las SMEs en Estados Unidos son los créditos fiscales a la investigación y desarrollo (R&D tax credits), que permiten a las empresas reducir sus obligaciones fiscales mientras invierten en innovación. Sin embargo, la pandemia ha exacerbado ciertos desafíos estructurales, como la dificultad para acceder a financiamiento adecuado y los efectos prolongados de las interrupciones económicas globales (International Finance Corporation, 2021). Empresas como Nisolo, Eileen Fisher y MUD Jeans, que priorizan la sostenibilidad y la ética, también se benefician de programas gubernamentales que incentivan prácticas empresariales más responsables con el medio ambiente. En resumen, las SMEs en el mercado estadounidense, incluidas aquellas con una perspectiva global como Nisolo, Eileen Fisher y MUD Jeans, no solo contribuyen significativamente a la economía, sino que también enfrentan una serie de

desafíos únicos que han sido exacerbados por la pandemia, pero que también abren nuevas oportunidades para la innovación y el crecimiento sostenible.




Ilustración 20. Resultado Análisis Sentimental SMEs Estadounidenses.

La imagen muestra un análisis de sentimiento de las opiniones en redes sociales sobre tres empresas globales de pequeñas y medianas empresas (SMEs): Nisolo, Eileen Fisher, y MUD Jeans. Los gráficos representan la distribución de opiniones positivas, negativas y neutras basadas en los comentarios de los usuarios, lo que puede reflejar la percepción pública de cada empresa.

Para Nisolo la mayoría de los comentarios en redes sociales son negativos, con más de 30 menciones negativas, lo que sugiere que la percepción general sobre la marca podría estar afectada por alguna experiencia o percepción desfavorable. Aunque las opiniones positivas son mucho menores en comparación, también hay una presencia significativa de comentarios positivos. Esto muestra que, aunque existen críticas, aún hay un grupo de

consumidores satisfechos. Un pequeño número de comentarios se clasifican como neutrales, lo que indica que algunas opiniones no son extremadamente emocionales ni en sentido positivo ni negativo.

Eileen Fisher en este caso, la marca tiene una mayor cantidad de comentarios positivos, con más de 30 menciones favorables. Esto sugiere que la percepción pública de Eileen Fisher es generalmente positiva y los consumidores están satisfechos con la empresa. Aunque hay algunas opiniones negativas, estas son significativamente menores en número en comparación con las positivas. Esto muestra que, si bien la marca tiene algunas críticas, la mayoría de las interacciones en línea son favorables.

En el caso de MUD Jeans, las opiniones negativas superan a las positivas, aunque la diferencia no es tan extrema como en Nisolo. Esto indica que la marca tiene una cantidad significativa de críticas, aunque no es abrumadora. La cantidad de comentarios positivos es considerable, lo que indica que MUD Jeans tiene una base de consumidores satisfechos, pero puede estar enfrentando algunos problemas que generan críticas en el mercado. Al igual que las otras empresas, la cantidad de opiniones neutrales es baja.

Eileen Fisher destaca por su alto nivel de comentarios positivos en comparación con las otras dos marcas. Esto puede ser un reflejo de sus prácticas empresariales éticas y sostenibles, que resuenan bien entre los consumidores. Su estrategia parece estar funcionando mejor en términos de percepción pública. MUD Jeans también tiene una base de apoyo notable, ya que las opiniones positivas son significativas, aunque la empresa debe prestar atención a las críticas recibidas. Nisolo, a pesar de tener una mayor proporción de opiniones negativas, también cuenta con comentarios positivos, lo que indica que hay aspectos de la marca que los clientes aprecian, pero que hay áreas clave que deben mejorarse para reducir la cantidad de críticas.




Ilustración 21. Distribución Resultados SMEs Estadounidenses.

La imagen muestra gráficos de violín que representan la distribución de las puntuaciones de sentimiento para tres marcas de pequeñas y medianas empresas globales: Nisolo, Eileen Fisher, y MUD Jeans. Estos gráficos permiten visualizar no solo la media de los datos, sino también la densidad de las puntuaciones dentro de cada categoría de sentimiento: Positive, Neutral, y Negative.

Las puntuaciones de sentimiento positivo muestran una distribución concentrada, con la mayoría de las puntuaciones alrededor de 0.6 a 0.7, lo que indica que las opiniones positivas tienen una intensidad moderada. La distribución de las opiniones neutrales es más plana, lo que indica que no hay una concentración fuerte de puntuaciones en un rango específico, sugiriendo una mezcla de sentimientos entre 0.4 y 0.6. Las puntuaciones negativas están más dispersas y algunas alcanzan valores más extremos cercanos a 1.2, lo que sugiere que hay opiniones fuertemente negativas hacia la marca.

La visualización en forma de violín permite observar no solo la tendencia central de los puntajes de sentimiento, sino también la amplitud de la dispersión de los datos. En general, Nisolo parece ser la marca con las opiniones negativas más fuertes, mientras que Eileen Fisher tiene un mejor balance entre opiniones positivas y negativas. MUD Jeans tiene una percepción más estable, con menos extremos en las puntuaciones tanto positivas como negativas.




Ilustración 22. Matriz de Predicción SMEs Estadounidenses.

La imagen muestra tres matrices de confusión que comparan las predicciones de sentimiento con los sentimientos reales para tres marcas globales: Nisolo, Eileen Fisher, y MUD Jeans. Las matrices de confusión son una herramienta útil para evaluar la precisión de un modelo de clasificación, en este caso, el análisis de sentimiento, y muestran cómo se comporta el modelo al clasificar los sentimientos en Positivo, Negativo o Neutral.

Nisolo: El modelo cometió errores significativos al predecir comentarios que eran Positivos como Negativos. Solo 3 casos de comentarios Positivos fueron clasificados correctamente. El modelo también tuvo problemas al clasificar comentarios Neutros, con 10 de ellos clasificados incorrectamente como Negativos. El modelo tiende a clasificar una gran parte de los sentimientos como negativos, lo que sugiere que hay un sesgo hacia la clasificación negativa en los datos de Nisolo.

- El puntaje crediticio final unificado es: **0.308**

Eileen Fisher: El modelo clasifica correctamente la mayoría de los comentarios Positivos (12 casos correctos). Esto muestra una buena capacidad del modelo para reconocer sentimientos positivos en esta marca. Ocho comentarios negativos fueron clasificados incorrectamente como Positivos, lo que indica que el modelo tiene dificultades para distinguir entre sentimientos Negativos y Positivos en algunos casos. Una gran cantidad de comentarios Neutros fueron clasificados como Positivos, lo que sugiere que el modelo no maneja bien la categoría Neutral. Eileen Fisher tiene un mejor equilibrio en su matriz de confusión, con más clasificaciones correctas, especialmente en la categoría positiva, aunque el modelo tiene dificultades con las opiniones Neutros.

- El puntaje crediticio final unificado es: **0.722**

MUD Jeans: A diferencia de Nisolo y Eileen Fisher, los errores de MUD Jeans están más distribuidos entre las categorías Positivo, Negativo y Neutral, lo que indica que el modelo no tiene un sesgo claro hacia ninguna categoría en particular. Un patrón recurrente es la dificultad para clasificar correctamente los comentarios Neutros. En este caso, muchos Neutros fueron clasificados incorrectamente como Positivos o Negativos. En comparación con Nisolo, el modelo cometió menos errores en general, lo que sugiere que el rendimiento del modelo en MUD Jeans fue ligeramente mejor. Aunque hay errores en la clasificación, estos están más equilibrados en MUD Jeans, lo que indica un modelo menos sesgado en comparación con las otras dos marcas.

- El puntaje crediticio final unificado es: **0.449**

Nisolo presenta un claro sesgo hacia la clasificación negativa, lo que podría influir en las evaluaciones del sentimiento hacia la marca. Eileen Fisher muestra un mejor rendimiento en la clasificación positiva, pero tiene problemas con la categoría Neutral y algunos Negativos que fueron clasificados incorrectamente como Positivos. MUD Jeans muestra una distribución más equilibrada de errores, aunque el modelo aún tiene dificultades para manejar los sentimientos Neutrales.

10.1.3 GRANDES EMPRESAS COLOMBIANAS

El mercado de grandes empresas en Colombia ha experimentado desafíos y oportunidades sin precedentes a raíz de la pandemia de COVID-19. Las empresas nacionales más importantes, como Arturo Calle, Vélez, y Koaj, se enfrentaron a la necesidad de adaptarse rápidamente a los cambios en el comportamiento del consumidor, la disrupción en las cadenas de suministro, y la acelerada transformación digital. A lo largo de esta transición, han surgido beneficios fiscales y de apoyo por parte del gobierno colombiano, cuyo objetivo ha sido promover la sostenibilidad y el crecimiento de estas grandes empresas en un entorno postpandemia. Uno de los principales apoyos fiscales ofrecidos fue la Ley de Inversión Social en 2021, que incluyó incentivos fiscales y programas de ayuda para las empresas afectadas por la crisis. Estos beneficios permitieron a las grandes empresas como Arturo Calle, reconocida por su liderazgo en la industria textil y de la moda masculina, mantener sus operaciones mientras exploraban nuevas oportunidades en el comercio electrónico y los canales digitales (Financiera de Desarrollo Nacional (FDN), 202).

Por su parte, Vélez, una marca de lujo especializada en artículos de cuero, tuvo que adaptar sus operaciones al mercado internacional y al comercio en línea, aprovechando los beneficios fiscales de exportación. Además, su enfoque en la sostenibilidad y la producción artesanal local resonó con el cambio de preferencia hacia el consumo responsable, que ganó fuerza durante la pandemia (CEPAL, 2020). Koaj, otra empresa textil de gran envergadura, enfrentó retos particulares en la cadena de suministro, pero pudo optimizar sus operaciones a través de alianzas estratégicas y la implementación de tecnologías de automatización. La flexibilidad en los pagos de impuestos y el acceso a créditos empresariales con condiciones favorables permitieron a la empresa capear las

incertidumbres económicas (Revista Dinero, 2020). A pesar de los beneficios fiscales, los retos no han desaparecido por completo. Estas grandes empresas colombianas siguen enfrentando desafíos como la incertidumbre económica global, los cambios en las políticas comerciales internacionales y las expectativas del consumidor postpandemia. No obstante, su capacidad para adaptarse y su estrategia a largo plazo las posicionan como actores clave en la recuperación económica de Colombia.




Ilustración 23. Resultado Análisis de Sentimientos Grandes Empresas Colombia.

La imagen muestra un análisis de sentimiento para tres grandes empresas colombianas: Arturo Calle, Cueros Vélez, y KOAJ, destacando la cantidad de menciones positivas, negativas y neutrales en redes sociales. Este tipo de análisis es útil para entender la percepción pública y cómo la opinión de los consumidores varía entre las grandes empresas. A continuación, se presenta un análisis comparativo basado en los resultados obtenidos.

Arturo Calle tiene menciones positivas que superan significativamente a las negativas, con aproximadamente 25 menciones positivas frente a alrededor de 15 menciones negativas. Esto sugiere una percepción favorable hacia la marca, lo cual es crucial para una empresa que se destaca por su presencia en el mercado de ropa masculina en Colombia. A pesar de las menciones negativas, la imagen positiva de la marca prevalece, lo que puede estar relacionado con su enfoque en la calidad del producto y su adaptación a la pandemia a través de estrategias digitales y sostenibilidad.

Cueros Vélez similar a Arturo Calle, las menciones positivas también superan a las negativas, aunque la diferencia es menos pronunciada. Esto indica una percepción generalmente positiva, pero con un número notable de menciones negativas que podrían estar vinculadas a problemas en la atención al cliente o la accesibilidad de productos. Las menciones negativas son considerables, lo que sugiere que, aunque la marca tiene una base de consumidores fieles, es necesario mejorar en algunas áreas operativas.

En el escenario de KOAJ, las menciones negativas son mayores que las positivas, con aproximadamente 25 opiniones negativas frente a menos de 15 positivas. Esto podría ser un indicio de problemas de imagen, que pueden estar relacionados con la calidad percibida del producto o la atención al cliente. Las menciones positivas, aunque presentes, están por debajo de las negativas. La estrategia de KOAJ podría necesitar ajustes para mejorar la percepción pública y atraer más opiniones favorables.

Arturo Calle y Cueros Vélez en comparación a las pequeñas empresas se diferencia de lo observado en el análisis de pequeñas y medianas empresas (SMEs) como Leonisa o Rockgota, donde las menciones negativas superaron ampliamente a las positivas, las grandes empresas como Arturo Calle y Vélez parecen tener un balance más equilibrado, con una mayoría de menciones positivas. Esto puede reflejar la consolidación de estas marcas en el mercado colombiano y su capacidad para mantener una relación sólida con los clientes a pesar de los retos impuestos por la pandemia. Sin embargo, en el caso de KOAJ, la percepción negativa es similar a la de pequeñas empresas como Seven-Seven, donde las menciones negativas también superaron a las positivas. Esto sugiere que la marca enfrenta desafíos similares a los de las empresas más pequeñas, como la

satisfacción del cliente y la percepción de la calidad del producto. El análisis muestra que, aunque las grandes empresas como Arturo Calle y Cueros Vélez mantienen una imagen relativamente positiva, KOAJ enfrenta retos similares a los de algunas pequeñas y medianas empresas en cuanto a la percepción del consumidor. Este tipo de análisis de sentimiento es esencial para comprender las áreas de mejora y ayudar a las empresas a desarrollar estrategias que mejoren su reputación pública, independientemente de su tamaño.




Ilustración 24. Distribución Resultados Grandes Empresas Colombia.

La imagen muestra diagramas de violín que representan la distribución de puntajes de sentimiento en tres categorías (Positivo, Negativo y Neutral) para tres grandes empresas colombianas: Arturo Calle, Cueros Vélez, y KOAJ. Los diagramas de violín combinan la función de una gráfica de caja y bigotes con una estimación de la densidad del kernel, lo que ayuda a visualizar la distribución y la variabilidad de los datos de manera más clara.

Se puede observar que los comentarios negativos tienen una mayor dispersión en comparación con los positivos. Los valores negativos muestran un rango amplio, lo que

indica una mayor variabilidad en las percepciones negativas sobre la marca. Los comentarios positivos están mejor concentrados cerca de 0.6 en el puntaje de sentimiento, lo que sugiere una percepción positiva relativamente consistente. En el caso de KOAJ, los comentarios negativos presentan una mayor variabilidad en comparación con los positivos. Los comentarios negativos tienen una mayor dispersión, pero la mayoría se encuentra cerca de 0.4 en el puntaje de sentimiento. Los comentarios positivos son más homogéneos, concentrados alrededor de 0.8.

Arturo Calle parece tener un balance entre comentarios positivos y negativos, con los positivos concentrados y consistentes. Sin embargo, los comentarios negativos presentan más dispersión, lo que sugiere que algunas personas tienen opiniones negativas fuertes sobre la marca. Cueros Vélez también tiene una distribución amplia de comentarios negativos, lo que sugiere variabilidad en la percepción negativa, pero los comentarios positivos son consistentes. KOAJ enfrenta un reto mayor en términos de opiniones negativas, ya que hay una alta variabilidad en los comentarios negativos, mientras que las opiniones positivas, aunque más consistentes, son menos frecuentes.




Ilustración 25. Matriz Predicción Grandes Empresas Colombia.

La imagen muestra matrices de confusión que comparan los sentimientos reales contra los sentimientos predichos para tres grandes empresas colombianas: Arturo Calle, Cueros Vélez y KOAJ. Las matrices de confusión son útiles para evaluar el rendimiento de un modelo de clasificación, ya que permiten visualizar cuántos elementos se clasificaron correctamente y cuántos fueron clasificados erróneamente en cada categoría.

Arturo Calle: La mayoría de los sentimientos positivos fueron predichos correctamente 9 predicciones correctas de un total de 15. Se observa que 4 comentarios neutrales fueron clasificados erróneamente como negativos. También hay 11 casos donde los comentarios negativos fueron predichos como positivos.

- El puntaje crediticio final unificado es: **0.604**

Cueros Vélez: Similar a Arturo Calle, la mayoría de los sentimientos positivos fueron clasificados correctamente 9 de 16, y también se identificaron correctamente muchos negativos 11 predicciones correctas. El mayor problema del modelo es clasificar algunos comentarios negativos como positivos, y hay 6 neutrales que se predijeron erróneamente como negativos. El modelo es relativamente preciso en la predicción de comentarios negativos, pero tiende a confundir los neutrales, lo que podría deberse a la subjetividad de los comentarios neutrales.

- El puntaje crediticio final unificado es: **0.568**

KOAJ: El modelo tiene un mayor número de errores comparado con Arturo Calle y Cueros Vélez. Solo 4 predicciones de comentarios positivos fueron correctas, y solo 7 de los negativos. El modelo confundió más comentarios positivos como negativos, y también tuvo problemas en clasificar correctamente los comentarios neutrales. Hay una mayor cantidad de predicciones erróneas en todas las categorías en comparación con las otras empresas. El modelo presenta más dificultades para clasificar correctamente las opiniones de KOAJ. Esto puede deberse a una mayor polarización en los sentimientos hacia la marca, lo que aumenta la complejidad del análisis.

- El puntaje crediticio final unificado es: **0.426**

10.2 CALCULO SCORE TRADICIONAL

Asignar pesos a los ratios financieros al calcular un puntaje crediticio o al evaluar el rendimiento financiero depende de varios factores. Estos factores incluyen la industria de la empresa, el contexto económico y los objetivos específicos del análisis. A continuación, se presentan algunos principios para asignar pesos a los ratios, junto con esquemas de ponderación comunes basados en las mejores prácticas del análisis financiero. Diferentes ratios miden distintos aspectos de la salud financiera de una empresa, y la importancia de cada ratio puede variar dependiendo del contexto financiero de la empresa, su sector y su apetito de riesgo. Por ejemplo:

- Ratios de liquidez (como el ratio corriente): Importantes para industrias con grandes requerimientos de capital de trabajo (Brigham & Ehrhardt, 2013).
- Ratios de rentabilidad (como ROA, ROE y márgenes): Importantes para todas las empresas, pero pueden tener más peso en sectores intensivos en capital (Damodaran, 2002).
- Ratios de apalancamiento (como la relación deuda-capital): Cruciales para empresas con deuda significativa, como en industrias que requieren grandes inversiones iniciales, por ejemplo, bienes raíces y manufactura (Higgins, 2012).

La prioridad de cada ratio depende de los siguientes factores:

- Industria: Diferentes industrias tienen diferentes puntos de referencia. Por ejemplo, industrias intensivas en capital como servicios públicos o manufactura se centrarán más en los ratios relacionados con la deuda, mientras que las startups tecnológicas pueden enfocarse más en el crecimiento y la rentabilidad (Ross, Westerfield, & Jaffe, 2016).
- Etapa del negocio: Una empresa madura puede priorizar la estabilidad y la gestión de la deuda, mientras que una empresa en etapa de crecimiento podría priorizar la rentabilidad o la liquidez.

- Entorno económico: En tiempos de incertidumbre económica, los prestamistas o inversionistas pueden enfatizar más los ratios de liquidez y solvencia para evaluar si la empresa puede soportar desafíos económicos (Brigham & Daves, 2014).

Para determinar un sistema de ponderación se puede asignar pesos basados en la importancia relativa de cada ratio en la evaluación de la salud financiera de la empresa. En algunos casos, es posible decidir asignar pesos iguales a todos los ratios. Este método asume que cada ratio es igualmente importante para el análisis (Higgins, 2012). Asignar diferentes pesos basados en el conocimiento de expertos o en los estándares de la industria. Si hay un experto financiero involucrado en el proceso de toma de decisiones, este puede ayudar a asignar pesos relativos basados en su comprensión de cuán crucial es cada métrica para la solvencia de la empresa (Brigham & Ehrhardt, 2013). Ponderación basada en el apetito de riesgo, los sectores de bajo riesgo pueden priorizar la liquidez, mientras que los sectores de alto crecimiento pueden darle más peso a la rentabilidad. Categorizar los ratios en indicadores de riesgo primarios y secundarios, asignando mayores pesos a los indicadores primarios (Damodaran, 2002).

Esquema de ponderación de ejemplo para el cálculo de un puntaje crediticio Supongamos que estás analizando la salud financiera de una empresa utilizando los siguientes ratios:

- Ratio de liquidez (Ratio Corriente)
- Ratios de apalancamiento (Relación Deuda-Capital)
- Ratios de rentabilidad (ROA, ROE, Margen Operativo)

Enfoque orientado al crecimiento (Énfasis en la rentabilidad)

- Liquidez (15%): Este indicador mide la capacidad de una empresa para cubrir sus deudas a corto plazo. Aunque sigue siendo importante, en el enfoque de crecimiento se le da un menor peso que en un enfoque conservador, ya que las empresas en crecimiento tienden a tener menos liquidez disponible debido a la reinversión constante de sus recursos.

- Apalancamiento (20%): En este contexto, el apalancamiento se considera importante, pero no tanto como la rentabilidad. Las empresas en crecimiento suelen utilizar más deuda para financiar sus operaciones, por lo que el ratio deuda-capital se incluye, pero con un peso moderado.
- ROA (25%): Un ROA alto indica que la empresa está generando eficientemente ganancias a partir de sus activos. En este enfoque, se asume que las empresas que maximizan el uso de sus activos serán las que mejor logren su crecimiento a largo plazo.
- ROE (25%): Este es otro indicador clave en el enfoque de crecimiento, ya que mide la rentabilidad para los accionistas. Un ROE alto es un signo de que los inversionistas están recibiendo buenos rendimientos, lo cual es crucial para atraer y retener capital en una empresa en crecimiento.
- Margen Operativo (15%): Este ratio mide la eficiencia operativa. Aunque no tiene tanto peso como el ROA y el ROE, un buen margen operativo garantiza que la empresa puede mantener su rentabilidad en el tiempo.

Se debe comparar los resultados con los puntos de referencia de la industria o análisis financieros previos para ver si el puntaje tiene sentido (Ross et al., 2016). Si ciertos ratios parecen estar sobrevalorados o infravalorados en el puntaje final, se debe ajustar los pesos para mejorar la precisión de tu modelo (Brigham & Daves, 2014).




Ilustración 26. Score Enfoque Orientado al Crecimiento - Énfasis en la rentabilidad.

Finalmente, ponderar cada uno de estos indicadores y asignarles un peso según la importancia relativa para el análisis de riesgo crediticio. Cada indicador se evaluaría según una escala y el score crediticio final sería el promedio ponderado de todas estas métricas. El score final sería el resultado de la combinación ponderada de todos estos indicadores, proporcionando una calificación crediticia que evalúa la capacidad de la empresa para cumplir con sus obligaciones financieras. Este enfoque proporciona un análisis detallado y equilibrado basado en la información financiera presentada.




Ilustración 27. Comparación Score Tradicional Top 10 Empresas Colombia.

Enfoque orientado al crecimiento implementado para calcular el puntaje crediticio se basa en la premisa de que las empresas que priorizan el crecimiento necesitan un sistema de evaluación que se enfoque principalmente en su capacidad para generar ganancias. Este enfoque da más peso a los indicadores de rentabilidad, como la Rentabilidad sobre Activos (ROA) y la Rentabilidad sobre el Patrimonio (ROE), en lugar de poner un énfasis excesivo en la liquidez o el apalancamiento.

El puntaje final es el resultado ponderado de todos los ratios mencionados anteriormente. Este puntaje proporciona una visión completa del rendimiento financiero de la empresa con un enfoque en su capacidad de generar ganancias y crecer. En el análisis realizado, las 10 empresas con mayor puntaje son aquellas que combinan una buena rentabilidad (ROA y ROE), un apalancamiento moderado y una liquidez aceptable. Estas empresas están bien posicionadas para atraer inversionistas y aumentar su capital. Por otro lado, las 10 empresas con menor puntaje tienen deficiencias significativas en uno o más de estos indicadores. Es posible que tengan un apalancamiento elevado o que su margen operativo no sea suficiente para sostener el crecimiento.

Si bien este enfoque es útil para analizar la rentabilidad de las empresas, existen oportunidades para mejorar el modelo de scoring implementando mecanismos alternativos que consideren otras fuentes de datos no tradicionales. La integración de datos de redes sociales y plataformas de opinión pública puede proporcionar información adicional sobre la percepción de la marca y la reputación de la empresa. En un entorno de Open Banking, también se podrían utilizar datos bancarios y transaccionales en tiempo real para mejorar la evaluación de riesgo. Empresas fintech en países como Brasil y México ya están integrando fuentes de datos alternativas, como patrones de consumo en plataformas de e-commerce o historial de pagos de servicios públicos, para evaluar el comportamiento financiero de las empresas que carecen de un historial financiero tradicional sólido.

El Enfoque orientado al crecimiento utilizado en el cálculo del puntaje final es una metodología sólida que permite evaluar a las empresas con un énfasis en la rentabilidad y la eficiencia operativa. Sin embargo, al incorporar fuentes de datos alternativas y tecnologías avanzadas como el análisis de comportamiento digital, podría mejorar significativamente la capacidad del modelo para evaluar el riesgo crediticio, especialmente para empresas más pequeñas o emergentes que carecen de un historial financiero robusto. Además, esto permitiría crear un sistema más inclusivo y preciso en el análisis de la solvencia empresarial.

10.3 CALCULO SCORE BASADO IA

La inteligencia artificial (IA) ha transformado significativamente el cálculo de scoring crediticio, proporcionando metodologías avanzadas para evaluar el riesgo crediticio de individuos y empresas. En la evaluación crediticia, la IA permite integrar grandes volúmenes de datos estructurados y no estructurados, brindando modelos predictivos más precisos y personalizados. Utilizando técnicas como los vectores de soporte (Support Vector Machines, SVM), algoritmos de optimización metaheurística y modelos de IA explicables, los investigadores han desarrollado enfoques que ofrecen una evaluación del riesgo crediticio tanto robusta como comprensible (Goh et al., 2019; Hendrikse et al., 2021; Risks, 2021). El trabajo de Hendrikse et al. (2021), *Explainable AI for Interpretable Credit Scoring*, aborda la implementación de IA explicable (XAI) en el scoring crediticio, con el objetivo de facilitar la interpretación de los modelos de IA utilizados en la toma de decisiones financieras. La IA explicable es una técnica que permite descomponer y analizar el proceso de decisión de los modelos de aprendizaje profundo o machine learning, proporcionando transparencia y justificación en las evaluaciones de riesgo crediticio (Hendrikse et al., 2021). Este enfoque es crucial, ya que la opacidad de algunos modelos avanzados, como las redes neuronales profundas, puede limitar la aceptación de los mismos en el sector financiero debido a la falta de interpretabilidad. La IA explicable busca hacer que las decisiones sean accesibles y comprensibles tanto para expertos como para usuarios finales.

Comparado con otros estudios, como el de Goh et al. (2019), que revisa el uso de Support Vector Machines (SVM) y metaheurísticas en el scoring crediticio, se observa un enfoque más centrado en la precisión y optimización del modelo. Este trabajo discute cómo las SVM pueden mejorar el rendimiento predictivo en comparación con otros modelos tradicionales, aunque no enfatiza en la interpretabilidad, una necesidad creciente en las aplicaciones financieras modernas. En contraste, la investigación de Hendrikse et al. (2021) introduce modelos de IA explicable como una solución para alcanzar una mayor transparencia en el proceso de decisión. Finalmente, el artículo de "Risks" (2021) revisa los riesgos y desafíos que la IA plantea en la evaluación crediticia, destacando la importancia de la ética y la supervisión regulatoria en la adopción de modelos de IA en entornos financieros. La

discusión en este trabajo es complementaria al enfoque de IA explicable, pues señala que el cumplimiento normativo y la transparencia son elementos cruciales para el uso efectivo de la IA en el sector financiero. Esta perspectiva se alinea con el objetivo de "Explainable AI for Interpretable Credit Scoring" de ofrecer una IA transparente y ética que garantice la comprensión del proceso de scoring crediticio y permita el cumplimiento con regulaciones de privacidad y equidad en la evaluación.

10.3.1 MODELO DE REGRESIÓN LOGÍSTICA

El modelo de regresión logística se integra a través de una matriz de confusión aplicado a cuatro marcas evaluadas: PatPrimo, Seven-Seven, Rockgota y Leonisa. Cada matriz evalúa el rendimiento del modelo al clasificar los sentimientos predichos en comparación con los sentimientos reales.




Ilustración 28. Resultado Modelo de Regresión Logística.

PatPrimo

- Precisión del modelo de Regresión Logística: **16.67%**
- El puntaje crediticio basado en Regresión Logística es: **16.666**

El modelo predice bien los sentimientos neutrales, pero falla en identificar correctamente los sentimientos negativos y positivos. No logra predecir ningún sentimiento positivo y tiene errores en la clasificación de sentimientos negativos. Esto sugiere que el modelo es más confiable en la categoría neutral para PatPrimo, pero presenta debilidades en las otras categorías.

Seven-Seven

- Precisión del modelo de Regresión Logística: **23.08%**
- El puntaje crediticio basado en Regresión Logística es: **23.076**

Seven-Seven muestra un buen rendimiento en la categoría neutral, con predicciones correctas, mientras que no se predice correctamente ningún sentimiento positivo. El modelo no captura ningún sentimiento positivo ni negativo, lo que limita su capacidad para clasificar correctamente la variedad de sentimientos. Esto indica que el modelo podría estar sesgado hacia clasificaciones neutrales para esta empresa.

Rockgota

- Precisión del modelo de Regresión Logística: **38.46%**
- El puntaje crediticio basado en Regresión Logística es: **38.461**

El rendimiento del modelo para Rockgota es limitado, con un fuerte sesgo hacia la clasificación negativa. No logra capturar correctamente sentimientos neutrales o positivos, lo que refleja una deficiencia en la variabilidad de las predicciones. Esto sugiere que el modelo asocia más comúnmente a Rockgota con sentimientos negativos y carece de precisión en otras categorías.

Leonisa

- Precisión del modelo de Regresión Logística: **23.08%**
- El puntaje crediticio basado en Regresión Logística es: **23.076**

En el caso de Leonisa, el modelo muestra una precisión decente en la categoría neutral, pero nuevamente no predice correctamente ningún sentimiento positivo. Al igual que con Seven-Seven, el modelo parece estar sesgado hacia la neutralidad, lo que afecta su capacidad para distinguir adecuadamente entre los diferentes sentimientos.

En conclusión, el modelo de regresión logística aplicado no demuestra un nivel de precisión adecuado para clasificar los sentimientos en las cuatro empresas analizadas. Las matrices de confusión revelan un sesgo marcado hacia la clasificación de sentimientos neutros y negativos, mientras que los sentimientos positivos apenas se identifican correctamente. La falta de precisión en la clasificación de sentimientos positivos y la concentración de predicciones en una o dos categorías limitan la efectividad del modelo para ofrecer insights confiables y diferenciados sobre la percepción de las marcas. Estos resultados sugieren que el modelo requiere ajustes significativos, como el balance de clases, una mayor cantidad de datos de entrenamiento o la exploración de técnicas de clasificación más avanzadas, para mejorar su desempeño y ofrecer un análisis de sentimiento más representativo y útil para la toma de decisiones empresariales.

10.3.2 SUPPORT VECTOR MACHINES (SVM)

La implementación del modelo de Support Vector Machines (SVM) para evaluar el puntaje crediticio basado en el análisis de sentimiento de varias empresas muestra en cada resultado la distribución de los puntajes de sentimiento según tres categorías de sentimiento en las gráficas, cada categoría de sentimiento muestra variabilidad en los puntajes, con los valores atípicos indicados como puntos fuera de la caja principal. Esto sugiere que, dentro de cada categoría, hay cierta dispersión en las opiniones de los consumidores. El puntaje crediticio calculado por SVM está representado en cada gráfico como una línea de referencia. Este valor es relativamente constante entre las empresas lo cual indica que el

modelo SVM mantiene un nivel de precisión uniforme en su predicción para las diferentes compañías.




Ilustración 29. Resultado Support Vector Machines.

Al comparar los resultados del modelo SVM aplicado a las cuatro empresas se pueden observar las siguientes diferencias y patrones en la distribución del puntaje de sentimiento según la categoría de sentimiento:

PatPrimo:

- El puntaje crediticio basado en SVM es: **41.666**

Los puntajes de sentimiento para las categorías "Positive" y "Negative" presentan una distribución considerablemente amplia, sin diferencias significativas en la media. La categoría "Neutral" tiene una baja representación y el puntaje crediticio basado en SVM es

de 41.67, el más alto entre las empresas, lo que sugiere que los datos asociados a PatPrimo son más consistentes en términos de predicciones positivas y negativas.

Seven-Seven, Rockgota y Leonisa:

- El puntaje crediticio basado en SVM es: **38.461**

Los puntajes de sentimiento están distribuidos de manera relativamente similar entre "Positive" y "Negative". La categoría "Neutral" presenta valores significativamente bajos, mostrando menos variabilidad. El puntaje crediticio final de Seven-Seven es de 38.46, ligeramente menor que PatPrimo, lo que indica una menor consistencia en los datos sentimentales para la evaluación de crédito. El puntaje crediticio de Rockgota es de 38.46, similar al de Seven-Seven, pero la variabilidad en la categoría "Positive" podría estar afectando la precisión del modelo. El puntaje crediticio de Leonisa es también de 38.46, mostrando una consistencia similar a Rockgota y Seven-Seven, aunque con diferencias en la distribución de sus categorías.

El modelo SVM asigna un puntaje crediticio más alto a PatPrimo, posiblemente debido a una mayor consistencia entre las categorías de sentimiento "Positive" y "Negative". Seven-Seven, Rockgota, y Leonisa tienen un puntaje similar, con una dispersión mayor en algunas categorías, lo que sugiere variabilidad en los datos de sentimiento que impacta la precisión del modelo. La menor representación en la categoría "Neutral" en todas las empresas indica que los datos están mayormente polarizados, lo cual puede afectar la evaluación general en modelos de scoring crediticio basados en sentimiento.

10.3.3 REDES NEURONALES ARTIFICIALES

El modelo de Redes Neuronales Artificiales aplicado a empresas representa la distribución del "Sentiment Score" para las diferentes categorías de sentimiento 0 para negativo, 1 para neutral y 2 para positivo. En cada gráfico, el puntaje crediticio representa el valor promedio de los resultados.




Ilustración 30. Resultado Redes Neuronales Artificiales.

La imagen muestra la distribución de los puntajes de sentimiento en función de la categoría de sentimiento para las empresas PatPrimo, Seven-Seven, Rockgota y Leonisa, utilizando un modelo de Redes Neuronales Artificiales (RNA) para el cálculo del puntaje crediticio. Cada gráfico de caja incluye una línea punteada que indica el puntaje crediticio promedio basado en los resultados de la red neuronal para cada empresa, lo que facilita la comparación del rendimiento de cada una.

PatPrimo

- Precisión del modelo de Red Neuronal: **37.50%**
- F1-Score del modelo de Red Neuronal: **28.75%**
- El puntaje crediticio basado en Red Neuronal es: **0.58**

La distribución muestra una amplia dispersión en las categorías de sentimiento positivo y negativo, con una concentración en valores altos para el sentimiento positivo, lo que contribuye a un puntaje crediticio relativamente favorable. La categoría neutral presenta algunos valores bajos, afectando de manera moderada el puntaje total.

Seven-Seven

- Precisión del modelo de Red Neuronal: **33.33%**
- F1-Score del modelo de Red Neuronal: **16.67%**
- El puntaje crediticio basado en Red Neuronal es: **0.67**

La categoría positiva también muestra un rango de valores alto, con valores mínimos superiores a los de PatPrimo, indicando un desempeño relativamente bueno en términos de percepción positiva. Las categorías neutral y negativa tienen menor variabilidad, lo que sugiere que el modelo de RNA capturó bien la concentración de sentimientos positivos para esta empresa.

Rockgota

- Precisión del modelo de Red Neuronal: **33.33%**
- F1-Score del modelo de Red Neuronal: **16.67%**
- El puntaje crediticio basado en Red Neuronal es: **0.79**

Rockgota tuvo el puntaje crediticio promedio más alto con 0.79, indicando la mejor interpretación de sentimientos positivos por el modelo. La categoría positiva se concentra principalmente en valores elevados, mientras que la neutral y negativa muestran una menor dispersión y valores relativamente bajos. Este patrón sugiere que el modelo detectó de manera consistente una percepción positiva en los datos de Rockgota, contribuyendo a un puntaje crediticio sólido.

Leonisa:

- Precisión del modelo de Red Neuronal: **33.33%**

- F1-Score del modelo de Red Neuronal: **16.67%**
- El puntaje crediticio basado en Red Neuronal es: **0.71**

La distribución de la categoría positiva es amplia y con valores altos, mientras que las categorías negativa y neutral presentan variabilidad limitada. El modelo RNA logró captar un patrón favorable en el sentimiento positivo de Leonisa, contribuyendo a su buen puntaje.

El modelo de Redes Neuronales demostró ser efectivo al capturar patrones en los datos de sentimiento de las diferentes empresas, especialmente en identificar el impacto positivo en los puntajes crediticios. La red neuronal parece interpretar mejor las distribuciones amplias y complejas, especialmente en empresas con altos sentimientos positivos como Rockgota y Leonisa, otorgando a estas empresas puntajes crediticios más altos. Sin embargo, en empresas como PatPrimo, donde hay mayor variabilidad entre las categorías, el modelo ofrece un puntaje más moderado. Esto indica que las RNA son eficaces en entornos donde existen patrones claros en el sentimiento positivo, pero pueden resultar menos precisas cuando la variabilidad es alta entre categorías de sentimiento.

10.3.4 MODELOS IA EXPLICABLE (XAI)

El modelo de Inteligencia Artificial Explicable (XAI) aplicado para evaluar el puntaje crediticio ajustado de cuatro marcas de ropa colombianas: PatPrimo, Seven-Seven, Rockgota y Leonisa. En cada gráfico, se presenta la "Distribución del Puntaje Crediticio Ajustado por Categoría de Sentimiento" basada en los tres tipos de sentimiento: negativo, neutral y positivo. El eje vertical muestra el puntaje promedio ajustado de crédito para cada categoría de sentimiento. Los valores más altos indican una mejor calificación crediticia dentro de esa categoría de sentimiento. Cada gráfico contiene una línea horizontal azul punteada que representa el puntaje crediticio final unificado para cada marca. Este valor se calcula como el promedio ponderado de los puntajes individuales, teniendo en cuenta los pesos y ajustes basados en la precisión del modelo XAI. El valor de esta línea ofrece un indicador de referencia sobre la solidez crediticia general de cada empresa, consolidando los puntajes de todas las categorías de sentimiento.




Ilustración 31. Resultado Modelos IA Explicable.

La comparación de los resultados de las gráficas del modelo de IA Explicable (XAI) para cada empresa permite analizar cómo cada tipo de sentimiento (negativo, neutral, positivo) afecta el puntaje crediticio ajustado y el puntaje crediticio final unificado.

PatPrimo

- Puntaje Crediticio Final Unificado: **0.24**.

Los comentarios positivos tienen un impacto significativo en el puntaje, siendo la categoría de mayor contribución. La categoría neutral tiene un peso moderado, mientras que los comentarios negativos contribuyen muy poco al puntaje. La percepción positiva de PatPrimo genera un buen puntaje crediticio. Sin embargo, el impacto de los comentarios negativos es menor, lo cual indica que la empresa tiene una reputación lo suficientemente sólida para soportar algunos comentarios adversos sin afectar demasiado su calificación crediticia.

Seven-Seven

- Puntaje Crediticio Final Unificado: **0.16**.

Positivo es la categoría con mayor contribución al puntaje, aunque el valor es menor comparado con PatPrimo. Neutral y Negativo contribuyen con valores bajos, especialmente el negativo, lo que disminuye el puntaje final. Seven-Seven tiene un menor impacto positivo en comparación con PatPrimo. La menor contribución de los comentarios positivos y el peso de los comentarios neutrales y negativos afectan su puntaje final, lo cual puede sugerir una percepción pública mixta o inconsistente.

Rockgota

- Puntaje Crediticio Final Unificado: **0.17**.

Al igual que en los otros casos, el sentimiento positivo tiene el mayor impacto en el puntaje. La contribución de los comentarios neutrales es moderada, mientras que los negativos tienen un efecto mínimo. Rockgota muestra un patrón similar al de Seven-Seven, donde el puntaje positivo no es tan alto como en PatPrimo y los comentarios neutrales también afectan su puntaje general. Esto sugiere que la empresa podría mejorar su percepción positiva para aumentar su puntaje crediticio.

Leonisa

- Puntaje Crediticio Final Unificado: **0.18**.

Positivo es la categoría dominante y genera la mayor parte del puntaje, superando ligeramente a Rockgota y Seven-Seven. Las categorías neutral y negativo aportan valores bajos, lo que resulta en una menor variación. Leonisa logra un puntaje superior a Seven-Seven y Rockgota, gracias a una percepción pública más favorable en la categoría positiva. Sin embargo, los comentarios neutrales y negativos reducen su puntaje total, lo cual podría mejorar si se enfocaran en fortalecer su imagen positiva.

Basado en las imágenes y descripciones de los resultados de los modelos de Máquinas de Vectores de Soporte (SVM) y Redes Neuronales (NN), parece que el modelo de Redes Neuronales superó generalmente al modelo de SVM. El modelo de Redes Neuronales produjo consistentemente puntajes crediticios más altos para cada empresa en comparación con el modelo SVM. Rockgota obtuvo un puntaje de 0.79 con Redes Neuronales, en contraste con un puntaje menor de 38.46 con SVM. De manera similar, Leonisa obtuvo un puntaje de 0.71 con Redes Neuronales, en comparación con 38.46 con SVM. Estos puntajes más altos implican que el modelo de Redes Neuronales interpretó los sentimientos positivos de manera más efectiva y fue capaz de asignar puntajes crediticios más altos, lo que puede indicar una mejor alineación con los datos de sentimiento.

Las Redes Neuronales manejaron las distribuciones de sentimientos con un rango más amplio e identificaron consistentemente una mayor concentración de sentimientos positivos. Esto indica que el modelo fue más sensible a las variaciones de sentimiento, especialmente en empresas como Rockgota, donde un sentimiento positivo alto contribuyó a un puntaje crediticio alto. En contraste, el modelo SVM produjo puntajes crediticios más bajos en general, lo que sugiere que pudo haber tenido dificultades para diferenciar entre las categorías de sentimiento de manera tan efectiva. Aunque no se proporcionaron métricas exactas de precisión para cada modelo en estas descripciones, el hecho de que el modelo de Redes Neuronales haya producido puntajes promedio más altos y haya capturado mejor la distribución de sentimientos positivos en las empresas sugiere un mejor rendimiento. Las Redes Neuronales tienden a sobresalir con datos de sentimientos matizados, ya que pueden capturar patrones complejos, mientras que los modelos SVM lineales a veces pueden pasar por alto las sutilezas en conjuntos de datos muy variables.

El modelo de Redes Neuronales mostró el mejor rendimiento general, dado sus puntajes crediticios más altos y su aparente capacidad para capturar variaciones de sentimiento de manera más efectiva entre diferentes empresas. Esto lo convierte en una opción más confiable para el cálculo del puntaje crediticio basado en el análisis de sentimientos en este contexto.

10.4 CALCULO SCORE FINAL COMPARATIVA

Para construir un score final de crédito, se integran enfoques de análisis de datos que combinan perspectivas sociales, financieras y predictivas avanzadas. La integración de Procesamiento de Lenguaje Natural (NLP), métodos tradicionales y técnicas de Inteligencia Artificial (IA) en el cálculo del score permite una visión integral de la solvencia y capacidad de pago de una entidad, lo cual es esencial en el análisis crediticio moderno (Brown et al., 2012; Gupta & Saxena, 2020). A continuación, se describe cada uno de estos enfoques y su aplicación en el cálculo del score final:

- Score basado en Procesamiento de Lenguaje Natural (NLP)

El score de NLP utiliza técnicas avanzadas para analizar opiniones y reseñas en línea, extrayendo información sobre la percepción y sentimiento que el público tiene sobre el solicitante. Mediante algoritmos de NLP, como el análisis de sentimiento, se clasifican los comentarios en positivo, negativo o neutral y se asigna un peso según la concordancia con los datos de entrenamiento (Aggarwal & Zhai, 2012). La fórmula para este score pondera cada categoría de sentimiento, ajustándola según la precisión con que el modelo capta el sentimiento real. Este enfoque es especialmente útil para evaluar la percepción pública y reputación del solicitante, complementando los datos financieros tradicionales (Davenport & Harris, 2017). En comparación con el enfoque tradicional, el NLP agrega un contexto social que proporciona una dimensión adicional para entender el riesgo crediticio de una empresa.

- Score Tradicional

El score tradicional emplea métricas financieras bien establecidas, como el ingreso mensual, nivel de endeudamiento, e historial de crédito, que ofrecen una perspectiva cuantitativa y tangible del perfil crediticio. Este enfoque sigue siendo un estándar en el análisis crediticio, utilizando fórmulas de ponderación que asignan mayor peso a variables críticas de estabilidad financiera y capacidad de pago (Miller, 2003). Por ejemplo, el historial de pagos y la relación deuda-ingreso son elementos esenciales en el cálculo, ya que reflejan

la disciplina financiera del solicitante. Este método proporciona una base sólida y objetiva, aunque carece de la capacidad de capturar variables cualitativas que pueden afectar la reputación y percepción de riesgo (Breedon, 2014).

- Score Basado en Inteligencia Artificial (IA)

La IA incorpora modelos como Redes Neuronales Artificiales y Máquinas de Soporte Vectorial (SVM) para procesar grandes volúmenes de datos e identificar patrones complejos y no lineales. Estos modelos integran tanto los datos sociales obtenidos mediante NLP como las métricas financieras del enfoque tradicional, aplicando técnicas de aprendizaje profundo para mejorar la precisión de las predicciones crediticias (Huang et al., 2020). Las redes neuronales, por ejemplo, son especialmente adecuadas para captar interacciones complejas en los datos de sentimiento y financieros, ofreciendo una perspectiva holística y adaptativa (LeCun et al., 2015). Comparado con el score tradicional, el enfoque de IA captura tanto elementos cuantitativos como cualitativos, proporcionando un análisis más sofisticado y adaptativo a patrones de comportamiento del solicitante.

- El componente de NLP aporta un valor social al score, capturando la percepción pública y reputación, lo cual es crucial para evaluar la confianza que el mercado tiene en la entidad (Davenport & Harris, 2017).
- El score tradicional proporciona una base sólida y cuantitativa, esencial para evaluar la estabilidad financiera del solicitante (Miller, 2003).
- El componente de IA permite una comprensión profunda de patrones complejos y garantiza que el modelo se adapte a cambios en los datos, mejorando así la precisión y robustez del análisis (Huang et al., 2020; LeCun et al., 2015).

El score final es el resultado de cada uno de estos scores que se normalizan y se ponderan según su importancia relativa en la evaluación general. La fórmula del score final puede expresarse como:

Ecuación 13. Formula Complementaria Score Final

$$ScoreFinal = (\omega_{NPL} \times Score\ NLP) + (\omega_{Tradicional} \times Score\ Tradicional) + (\omega_{IA} \times Score\ IA)$$

donde cada componente tiene un peso específico asignado de acuerdo con su importancia en el modelo de evaluación crediticia. Esta fórmula permite combinar las fortalezas de cada método.

El cálculo del Score Final para PatPrimo, utilizando una combinación ponderada de tres métodos, ha dado un resultado de aproximadamente **0.737**. Este puntaje final refleja una evaluación crediticia integral que combina factores cuantitativos tradicionales y análisis de percepciones y patrones a través de inteligencia artificial. A continuación, se explica el peso de cada componente en el resultado:

Ecuación 14. Resultado Score Final Empresa I

$$\text{Score Final} = (0.30 \times 0.615) + (0.60 \times 0.824275691) + (0.10 \times 0.58)$$

$$\text{Score Final} = \mathbf{0.737}$$

El Score Final de **0.737** indica que, en general, PatPrimo tiene un perfil crediticio favorable, especialmente en cuanto a sus métricas financieras tradicionales, que son el factor dominante en esta evaluación. Esto sugiere que la empresa es confiable en términos de solvencia financiera y tiene un bajo riesgo de incumplimiento. La percepción pública es moderadamente positiva, y aunque el componente de IA tiene un bajo peso, también contribuye a una visión más completa del perfil crediticio de la empresa.

El resultado obtenido para Seven Seven, con un Score Final de **0.671**, sugiere una evaluación crediticia bastante favorable, debido principalmente a la ponderación significativa asignada al Score Tradicional. En este caso, el cálculo refleja cómo los datos financieros de la empresa impactan de manera preponderante en el puntaje final, ya que el Score Tradicional se ponderó con un 75% del peso total, frente a un 20% para el Score NLP y un 5% para el Score IA.

Ecuación 15. Resultado Score Final Empresa II

$$\text{Score Final} = (0.30 \times 0.329) + (0.60 \times 0.84275691) + (0.10 \times 0.67)$$

$$\text{Score Final} = \mathbf{0.671}$$

Esto indica que la empresa se encuentra en una posición favorable desde una perspectiva crediticia tradicional, aunque existen áreas de percepción pública y evaluación de IA que podrían ser mejoradas para equilibrar su perfil de riesgo.

El score final de Rockgota, calculado en **0.569**, refleja una evaluación equilibrada donde se evidencia una evaluación de riesgo moderada, en la cual el score tradicional representa la base principal. La puntuación moderada en el componente de NLP sugiere que, aunque la percepción pública no es extremadamente positiva, no hay grandes riesgos percibidos en redes sociales. La alta puntuación del componente IA indica la posibilidad de crecimiento o estabilidad detectada por patrones complejos, lo cual es favorable.

Ecuación 16. Resultado Score Final Empresa III

$$\begin{aligned} \text{Score Final} &= (0.3 \times 0.369) + (0.6 \times 0.632) + (0.1 \times 0.79) \\ \text{Score Final} &= \mathbf{0.5689} \end{aligned}$$

En conclusión, este score sugiere que Rockgota es un candidato con una estabilidad moderada y un perfil crediticio aceptable, aunque aún tiene margen para mejorar en reputación y estabilidad financiera para reducir el riesgo percibido en el análisis crediticio global.

El score obtenido para Leonisa es de **0.610**, lo que sugiere un perfil crediticio estable. Este resultado refleja tanto la estabilidad financiera tradicional de la empresa como la percepción pública y el análisis de comportamiento basado en inteligencia artificial.

Ecuación 17. Resultado Score Final Empresa IV

$$\begin{aligned} \text{Score Final} &= (0.30 \times 0.439) + (0.60 \times 0.679) + (0.10 \times 0.71) \\ \text{Score Final} &= \mathbf{0.610} \end{aligned}$$

Este balance de puntajes indica que Leonisa es vista como una empresa confiable y estable, aunque con oportunidades de mejorar su percepción pública para fortalecer aún más su posicionamiento crediticio. La presencia de un alto puntaje en el score de IA refuerza la confiabilidad de la empresa a partir de patrones de comportamiento y análisis predictivo, lo que es ventajoso para relaciones futuras en el ámbito financiero. Este score general

sugiere que Leonisa puede acceder a mejores condiciones de crédito y es percibida como una entidad segura para financiamiento. Además, mejorar la percepción en redes sociales y comunicación pública podría incrementar su score de NLP, lo que contribuiría a optimizar su perfil crediticio y oportunidades de financiamiento en el futuro.




Ilustración 32. Resultado Variación Score Final Vs Score Tradicional.

El gráfico proporciona un análisis comparativo entre el "Score Final" y el "Score Tradicional" para cada empresa, resaltando la variación entre ellos. Además, muestra el coeficiente de variación por empresa y el coeficiente de variación general entre todas las empresas, calculado en 13.42%.

PatPrimo presenta una variación moderada, lo que indica que los ajustes del modelo han reducido el puntaje crediticio, posiblemente debido a la incorporación de nuevos datos o a una recalibración del modelo. El coeficiente de variación relativamente bajo sugiere que los ajustes en el puntaje final fueron moderados y que el perfil crediticio de PatPrimo se mantuvo bastante estable tras considerar los criterios adicionales. Para Seven Seven el coeficiente de variación sugiere un impacto considerable de la recalibración o de factores de datos adicionales introducidos en el modelo. El ajuste en el puntaje de Seven Seven podría reflejar una mayor influencia de los criterios actualizados del modelo, alineando el

puntaje final de forma más precisa con los datos actuales, como factores de sentimiento o reputación. El perfil crediticio de Rockgota experimentó cambios mínimos con el modelo actualizado, lo que sugiere que los puntajes tradicional y final de la empresa están relativamente alineados, lo cual indica consistencia en su perfil crediticio. El perfil crediticio de Leonisa es estable en ambos modelos, lo que sugiere consistencia y fiabilidad en la evaluación de su solvencia, con un impacto mínimo de los ajustes del modelo.

El coeficiente de variación general es de 13.42%, lo que indica un nivel moderado de variación en todas las empresas. Seven Seven destaca con la mayor variación, lo que sugiere que los factores adicionales de puntuación impactaron significativamente su puntaje final. En contraste, la baja variación de Leonisa resalta ajustes mínimos entre sus puntajes, mostrando estabilidad. El análisis indica que ciertas empresas pueden ser más sensibles a los nuevos elementos de puntuación, mientras que otras mantienen perfiles crediticios consistentes a pesar de las actualizaciones del modelo. Este enfoque comparativo puede ayudar a identificar empresas con puntajes volátiles debido a factores externos y aquellas con solvencia predecible y estable. La implementación de un modelo de cálculo de score final, que incorpora mecanismos complementarios como el Procesamiento de Lenguaje Natural (NLP), el score tradicional y un score basado en Inteligencia Artificial (IA), aporta una perspectiva más amplia y precisa en la evaluación crediticia de empresas. En general, los resultados obtenidos demuestran que el score final se ajusta de manera significativa en comparación con el score tradicional, destacando la importancia de integrar múltiples fuentes de datos y metodologías en la evaluación de riesgo crediticio (Kurnia & Suharjito, 2018; Hendrikse et al., 2019).

El análisis de los coeficientes de variación por empresa muestra que existe una variabilidad moderada en los scores finales en comparación con los scores tradicionales. Este coeficiente de variación es clave para entender el impacto de los mecanismos complementarios en cada empresa. PatPrimo y Rockgota presentaron coeficientes de variación menores, lo que indica que la integración de datos adicionales y métodos avanzados de modelado tuvo un impacto limitado en el ajuste del score final. Esto sugiere una estabilidad en sus perfiles crediticios y una alineación entre las evaluaciones tradicionales y los resultados obtenidos con los nuevos modelos.

La inclusión de mecanismos basados en IA y NLP ha demostrado ser un factor diferencial en la precisión y sensibilidad del modelo. El análisis de sentimientos y las técnicas de IA permiten captar dimensiones del perfil crediticio que el score tradicional podría no reflejar. En estudios previos, Kurnia y Suhajito (2018) mostraron cómo la incorporación de datos sociales y de reputación puede ofrecer una visión más completa de la percepción pública hacia una empresa, complementando los datos financieros tradicionales. Además, el uso de IA en la evaluación crediticia, como se describe en los trabajos de Hendrikse, permite identificar patrones complejos en los datos, mejorando la precisión predictiva y adaptándose mejor a variaciones en el entorno económico. La aplicación de un score final que combina varios métodos proporciona una ventaja significativa al ofrecer una visión más detallada y personalizada del perfil crediticio de cada empresa. Mientras que el score tradicional se enfoca en datos financieros concretos, los modelos basados en IA y NLP integran variables de percepción social y patrones complejos, lo cual puede ser decisivo en el contexto actual donde los datos no financieros juegan un rol cada vez más importante (Hendrikse et al., 2019).

Este análisis indica que el uso de modelos complementarios es particularmente útil en empresas con alta variación en su score, ya que pueden revelar aspectos del riesgo no contemplados en la evaluación tradicional. Como demuestran los estudios anteriores, los modelos de IA y técnicas de análisis de sentimiento pueden mejorar la precisión y adaptación de los modelos de scoring, especialmente para empresas en sectores más volátiles.

10.5 GENERACION DASHBOARD INDICADORES FINALES

En el contexto de la transformación digital y la inclusión financiera, la visualización de datos a través de herramientas accesibles es clave para democratizar el acceso a la información financiera entre las PYMES (Accenture, 2021; Asobancaria, 2021). Este apartado presenta una propuesta para la generación de un dashboard de indicadores finales, enfocado en facilitar la interpretación y el acceso a datos clave de evaluación crediticia para todas las pequeñas y medianas empresas (PYMES). Este dashboard se constituye como una

herramienta de visualización que permitirá a las PYMES comprender de manera clara y concisa los resultados de sus scores crediticios finales, proporcionándoles así una visión integral de su posición financiera (García & Rodríguez, 2021).

El diseño del dashboard está orientado hacia la accesibilidad, asegurando que cualquier PYME, independientemente de su nivel de sofisticación tecnológica, pueda interpretar los indicadores presentados. Además, la propuesta incluye una integración con el ecosistema digital bancario mediante la implementación de principios de Open Banking, lo que facilita una conexión dinámica y segura con múltiples fuentes de datos financieros (OECD, 2020). A través de este sistema, se busca que las PYMES tengan acceso a información consolidada y en tiempo real que apoye su proceso de toma de decisiones financieras y su inclusión en el sector crediticio formal (Superintendencia Financiera de Colombia, 2021).

Este apartado detalla los componentes del dashboard, los indicadores clave y el flujo de información, describiendo cómo el diseño de la visualización está optimizado para una fácil comprensión y uso efectivo, promoviendo la inclusión de todas las PYMES en el ecosistema digital bancario (Chen et al., 2012; Taneja, 2014).

10.5.1 VISUALIZACIÓN GENERAL INDICADORES Y SCORES

El dashboard desarrollado en esta investigación es una herramienta de visualización de datos centrada en la inclusión financiera y en la accesibilidad de la información para las pequeñas y medianas empresas (PYMES). Su propósito principal es permitir a estas empresas comprender de manera clara y concisa su situación crediticia, ayudándolas a tomar decisiones financieras informadas y estratégicas para su crecimiento. Dada la importancia de las PYMES en la economía y su rol en el desarrollo de los mercados locales, es fundamental que cuenten con mecanismos que les faciliten el acceso al crédito y a soluciones financieras adaptadas a sus necesidades específicas. Este dashboard representa una innovación en la forma en que las PYMES pueden interactuar con su información financiera, eliminando barreras y brindando transparencia en el proceso de evaluación crediticia. Este dashboard no solo es una herramienta de diagnóstico, sino que también es una guía de acción para las PYMES, proporcionando un camino claro hacia la

mejora de su situación crediticia y facilitando su integración en el sistema financiero. Al ofrecer una experiencia accesible y orientada a la acción, el dashboard fomenta la educación financiera, ayuda a las PYMES a entender su posición en el mercado y les brinda las herramientas necesarias para planificar y gestionar su crecimiento de manera efectiva.




Ilustración 33. Dashboard: Visualización Resumen Crediticio.

La sección superior del dashboard muestra el puntaje financiero general en un formato gráfico de semicírculo, acompañado de un porcentaje que refleja la calificación total del usuario. Este puntaje general combina métricas de evaluación crediticia tradicionales y alternativas, proporcionando una valoración completa del estado financiero de la PYME. Al ver un puntaje general, las PYMES pueden identificar si están en una posición financiera sólida o si necesitan mejorar ciertos aspectos para obtener mejores condiciones de financiamiento. Este puntaje puede ser utilizado para realizar comparaciones en el tiempo, permitiendo que las PYMES vean la evolución de su puntaje financiero y tomen medidas para mantener o mejorar su estabilidad crediticia. Debajo del puntaje financiero general, el dashboard presenta indicadores específicos como "Métodos Tradicionales" y "Métodos Alternativos", cada uno con su propio puntaje. Estos indicadores ofrecen un desglose detallado de los componentes que contribuyen al puntaje general, proporcionando una visión segmentada del perfil financiero de la PYME. Al mostrar los puntajes específicos de cada indicador, las PYMES pueden entender los factores que contribuyen a su calificación general. Esta transparencia fomenta la confianza en el sistema de evaluación crediticia.

La sección de Ecosistema Digital Bancario presenta diferentes categorías de productos financieros indicados con base la propuesta Open Banking. Cada una de estas opciones muestra información y recomendaciones personalizadas basadas en el puntaje financiero y el perfil de riesgo de la PYME. Al seleccionar una de estas categorías, el usuario puede acceder a una descripción más detallada del producto y de las condiciones que puede obtener, como tasas de interés, plazos y opciones de financiamiento disponibles en función de su puntaje.

La sección Potencia tu Marca en la parte inferior del dashboard es una herramienta que invita a las PYMES a mejorar su puntaje financiero mediante recomendaciones y servicios complementarios. Esta sección puede incluir consejos para mejorar la reputación comercial, estrategias para optimizar el flujo de caja y opciones para establecer alianzas estratégicas que contribuyan a fortalecer el perfil financiero de la empresa. Además, esta sección puede ofrecer información sobre cómo las PYMES pueden optimizar su visibilidad y credibilidad en el mercado, con un enfoque en mejorar su puntaje en métodos alternativos de evaluación.

Este dashboard ofrece beneficios generales que refuerzan la misión de promover la inclusión financiera para las PYMES, brindándoles herramientas que les permitan no solo entender su situación actual, sino también mejorarla activamente. Permite que cualquier PYME, sin importar su nivel de conocimiento financiero, pueda comprender su situación y los factores que afectan su puntaje. Esto reduce la barrera de entrada al mundo financiero formal, fomentando la inclusión financiera.

La descomposición de los indicadores crediticios y el desglose de puntajes permite que las PYMES vean con claridad cómo se determina su calificación, aumentando la confianza en el proceso de evaluación. Al brindar recomendaciones y opciones de productos financieros específicos, el dashboard permite que las PYMES planifiquen su crecimiento y optimicen su situación financiera con base en información confiable y accesible.

En conjunto, este dashboard representa una herramienta poderosa para las PYMES, al proporcionarles un acceso sencillo a su calificación crediticia y a opciones financieras personalizadas. Además, fomenta una cultura de crecimiento y mejora continua, donde las PYMES pueden entender y gestionar su perfil financiero de forma proactiva. La implementación de este tipo de tecnología inclusiva y accesible es un paso significativo hacia la democratización del acceso al crédito y la inclusión financiera de las PYMES en el ecosistema bancario digital.

10.5.2 GENERACIÓN ECOSISTEMA DIGITAL BANCARIO

El esfuerzo integral para desarrollar un ecosistema digital bancario facilita la inclusión financiera de las PYMES, permitiéndoles acceder a productos y servicios adaptados a sus necesidades. Este ecosistema digital tiene como objetivo principal crear un entorno en el cual las pequeñas y medianas empresas puedan conectarse fácilmente con diversas instituciones financieras y explorar diferentes opciones de productos que se ajusten a sus características crediticias y comerciales. La creación de este ecosistema responde a la necesidad de democratizar el acceso a los productos financieros en un contexto donde muchas PYMES carecen de un historial crediticio formal y enfrentan barreras significativas para obtener créditos y otros servicios financieros (Asobancaria, 2021; OECD, 2020).

El uso de tecnologías de Open Banking se convierte en un pilar fundamental para alcanzar este objetivo, permitiendo que los datos financieros de las PYMES sean compartidos de manera segura y autorizada con múltiples instituciones bancarias. A través de la implementación de modelos de Open Banking. Esta innovación no solo optimiza la experiencia de usuario, sino que también abre nuevas oportunidades para que las PYMES accedan a servicios financieros con mayor facilidad y transparencia, contribuyendo al desarrollo de un mercado financiero más inclusivo y dinámico (Accenture, 2021).




Ilustración 34. Dashboard: Visualización Ecosistema Digital Bancario.

En esta sección, el dashboard presenta productos específicos de bancos aliados que están alineados con el puntaje y perfil de la PYME. Estas recomendaciones son seleccionadas en función de la probabilidad de aprobación y de las condiciones que mejor se ajustan a las características de la empresa, basadas en los datos obtenidos a través de Open Banking. Las recomendaciones personalizadas permiten que las PYMES accedan a productos financieros adecuados para su perfil de riesgo, incrementando la eficiencia y efectividad en el proceso de aplicación. Además, al recibir ofertas personalizadas, se aumenta la transparencia y la confianza en el sistema financiero, ya que los productos recomendados son accesibles y viables para las empresas. Además de los productos recomendados, se presentan alternativas adicionales, fomentando la competitividad entre las instituciones financieras y permite que las PYMES comparen y seleccionen el producto que mejor se adapte a sus necesidades específicas. Esta variedad de opciones también ayuda a que las PYMES se sientan empoderadas en el proceso de toma de decisiones financieras, promoviendo la educación financiera y el entendimiento de los diferentes productos disponibles.




Ilustración 35. Embedded Finance (Departamento Nacional de Planeación, 2024).

La implementación del Ecosistema Digital Bancario en el modelo de finanzas embebidas se alinea con las recomendaciones planteadas en el artículo *"Modelos de Calificación Crediticia con Información Alternativa: Recomendaciones para su implementación en Colombia"* y representa una estrategia para facilitar el acceso de las PYMES a servicios financieros. Las finanzas embebidas se refieren a la integración de servicios bancarios directamente en la plataforma, lo que permite acceder a productos como créditos, cuentas

de ahorro e inversiones sin necesidad de recurrir a procesos adicionales o plataformas externas. Esta integración optimiza la experiencia del usuario y promueve la inclusión financiera, especialmente para aquellas PYMES que suelen quedar fuera del sistema financiero tradicional debido a la falta de historial crediticio (BID, 2020; OECD, 2020).

Este modelo de finanzas embebidas soporta el ecosistema digital bancario propuesto, integrando datos y servicios financieros directamente en la plataforma de visualización. Por ejemplo, una plataforma de e-commerce puede ofrecer crédito instantáneo a sus usuarios en el momento de hacer una compra, sin que estos necesiten pasar por un proceso tradicional de solicitud de préstamo en una institución financiera. Al aprovechar los datos de Open Banking, el sistema puede evaluar el perfil crediticio del cliente y ofrecerle opciones de financiamiento adaptadas a su perfil financiero, esto garantiza que las recomendaciones de productos financieros se basen en información reciente y precisa. Esto es crucial para el ajuste de las condiciones de los productos financieros de acuerdo con los cambios en el perfil crediticio de las PYMES (OECD, 2020). Open Banking está diseñado para garantizar que los datos financieros de los usuarios se compartan de manera segura y con su consentimiento, cumpliendo con las normativas de protección de datos personales. Esto asegura que las PYMES puedan compartir su información con confianza y acceder a mejores ofertas de financiamiento sin comprometer su privacidad (Accenture, 2021).

En conclusión, la implementación de un dashboard basado en un ecosistema digital bancario y apoyado en tecnologías de Open Banking de finanzas embebidas representan una transformación en la forma en que los servicios bancarios son ofrecidos y consumidos, logrando un avance significativo hacia la inclusión financiera de las PYMES en Colombia. Este sistema facilita el acceso a productos financieros adaptados a las necesidades y capacidades de cada empresa, promoviendo la transparencia, la eficiencia y la competitividad en el mercado financiero. A través de este modelo de recomendación, las PYMES pueden comparar y seleccionar opciones de financiamiento de forma informada, accediendo a soluciones que antes les eran inaccesibles o difíciles de identificar. La integración de Open Banking en este proceso no solo optimiza la precisión del puntaje crediticio y las recomendaciones, sino que también contribuye a la construcción de un sistema financiero más inclusivo y justo.

11. CONCLUSIONES

La investigación alcanzó su objetivo general de diseñar un modelo de evaluación crediticia adaptable al ecosistema digital bancario que permita facilitar el acceso de las PYMES colombianas a servicios crediticios. Este modelo, basado en Business Intelligence y en un sistema de reputación, demostró su efectividad al combinar datos no tradicionales y análisis avanzado para generar perfiles crediticios más inclusivos. La implementación de un ecosistema digital bancario que integra factores de reputación y Business Intelligence se mostró como una solución viable y potencialmente efectiva para abordar la limitada inclusión financiera en el sector PYME, alineándose con estudios previos que sostienen la importancia de un enfoque alternativo en la evaluación crediticia (OECD, 2020; Finextra, 2021).

Los resultados mostrados en la comparación entre el "Score Final" y el "Score Tradicional" para cada empresa, resalto el coeficiente de variación general de 13.42%. Este resultado sugiere que la implementación de metodologías complementarias que incorporan el análisis de percepción pública, a través de Procesamiento de Lenguaje Natural (NLP) y técnicas de Inteligencia Artificial (IA), tiene un impacto considerable en el ajuste de los scores finales. Este alto coeficiente indica que el puntaje tradicional se puede ajustar significativamente cuando se incluyen factores externos como la reputación y la percepción pública en el cálculo de riesgo crediticio. Se evidencia un escenario actual coyuntural ideal para fortalecer el enfoque en la percepción de marca y la reputación pública como elementos clave en la toma de decisiones crediticias. A medida que el entorno digital y la interacción con clientes en redes sociales se vuelven cada vez más influyentes, la imagen pública de una empresa impacta directamente en su perfil de riesgo. Esta integración de metodologías avanzadas permite un análisis crediticio más ajustado y preciso, tomando en cuenta no solo el historial financiero, sino también el sentimiento general que los consumidores tienen sobre la empresa.

El desarrollo del modelo incluyó la identificación y selección de variables clave que representan tanto los criterios tradicionales de evaluación crediticia como los componentes de reputación digital. Factores como el historial de transacciones, la actividad en redes sociales y la lealtad del cliente se integraron en el análisis. Esto resultó en un modelo más robusto y adaptable a las necesidades de las PYMES, confirmando que la inclusión de variables alternativas aumenta la precisión en la evaluación del riesgo (World Bank Group, 2018; LexisNexis Risk Solutions, 2020). Las estrategias de Business Intelligence empleadas en el modelo permitieron la recopilación y el procesamiento efectivo de grandes volúmenes de datos, desde la información financiera hasta el comportamiento digital. Herramientas de procesamiento y análisis de datos, junto con técnicas de minería de datos y aprendizaje automático, demostraron ser eficaces en la evaluación integral del riesgo de crédito, alineándose con estudios que promueven el uso de BI en entornos financieros como facilitador del acceso al crédito para sectores menos favorecidos (Accion, 2021; McKinsey & Company, 2020). El modelo propuesto combina los principios de Business Intelligence y un sistema de reputación con métodos tradicionales de evaluación crediticia, demostrando ser adaptable e integrable a los procesos actuales del ecosistema digital bancario. Esta combinación permitió realizar evaluaciones más precisas del riesgo crediticio de las PYMES, basándose tanto en datos financieros como en indicadores de reputación, lo cual respalda la viabilidad de modelos híbridos en la inclusión financiera (Deloitte, 2019; PwC, 2021).

Se diseñó un componente informático capaz de generar visualizaciones de los indicadores obtenidos a partir del modelo, facilitando la interpretación de los resultados por parte de las instituciones financieras. Este componente contribuyó a una mayor transparencia y a la toma de decisiones informadas, alineándose con investigaciones previas que resaltan el impacto positivo de la visualización de datos en la toma de decisiones financieras (IFC, 2021; OECD, 2020). La incorporación de datos alternativos y la capacidad de analizar el comportamiento digital y financiero de los solicitantes permite a las instituciones financieras una evaluación más precisa, inclusiva y eficiente del riesgo crediticio. Este enfoque podría ser un referente para otros países en vías de desarrollo que buscan fortalecer sus sectores de PYMES mediante el acceso a crédito.

12. PRINCIPALES APORTES

Otro aporte significativo es la creación de un Dashboard accesible, diseñado para permitir a las PYMES interpretar sus resultados crediticios de forma autónoma y clara. Este enfoque de visualización de datos no solo incrementa la transparencia, sino que también fomenta la educación financiera, ya que permite a las empresas entender su perfil de riesgo y los factores que influyen en su calificación crediticia. La accesibilidad y facilidad de uso del Dashboard contribuyen directamente al objetivo de promover la inclusión financiera mediante herramientas tecnológicas que sean prácticas y comprensibles.

Además, el modelo aporta al ecosistema de Open Banking en Colombia, ya que fomenta el uso y la integración de datos financieros y no financieros, alineándose con las iniciativas de inclusión y transparencia impulsadas por el sector bancario. La relevancia de este aporte radica en su capacidad para ser replicado y adaptado a otros sectores y contextos, ampliando su impacto y utilidad en el ámbito financiero y tecnológico. En conjunto, estos aportes representan un avance significativo en el uso de datos alternativos para mejorar el acceso al crédito y fortalecer la relación entre las PYMES y las instituciones financieras.

El principal aporte de esta investigación es la creación de un modelo de evaluación crediticia para las PYMES que, además de incorporar datos financieros tradicionales, utiliza fuentes de datos alternativas, como los mecanismos de reputación y datos derivados del Open Banking. Este modelo innovador responde a la necesidad identificada en el sector de incluir datos no convencionales que, al integrarse con estrategias de Business Intelligence, permiten una evaluación del riesgo crediticio más completa y adaptada a las particularidades de las PYMES colombianas en el sector textil. A continuación, se detallan los elementos técnicos, los flujos funcionales y la arquitectura de solución propuestos, que son escalables y replicables en otras infraestructuras.

12.1 PLANTEAMIENTO TÉCNICO

Desde el punto de vista técnico, el modelo combina tecnologías de extracción, transformación y carga (ETL) con capacidades de análisis avanzado de datos, integrando múltiples fuentes de información en tiempo real mediante APIs de Open Banking. El modelo ETL permite recopilar datos financieros y no financieros desde fuentes diversas y asegurarse de que estos se transformen en formatos estandarizados y limpios antes de ser analizados. Posteriormente, los datos son procesados mediante algoritmos de reputación y análisis de riesgo crediticio, los cuales ponderan factores clave como el comportamiento de pago, la estabilidad financiera y las interacciones comerciales previas de las PYMES. Para permitir un análisis dinámico y flexible, el modelo técnico se complementa con un Dashboard de visualización de indicadores crediticios, que presenta los resultados en un formato intuitivo y accesible para las PYMES. Este Dashboard emplea tecnologías de visualización de datos como D3.js y bibliotecas de gráficos que facilitan la comprensión de los resultados y permiten que las empresas interpreten su calificación crediticia sin necesidad de conocimientos especializados.

12.2 FLUJOS FUNCIONALES DEFINIDOS

El modelo operativo se estructura en tres flujos funcionales principales, que permiten la recolección, procesamiento y visualización de los datos crediticios de las PYMES:

- **Recopilación de Datos:** Este flujo inicial integra datos desde fuentes financieras tradicionales y no convencionales mediante APIs de Open Banking y de mecanismos de reputación. Los datos son extraídos automáticamente desde registros financieros, transacciones bancarias, historial de pagos y puntuación de reputación comercial. Estos datos son procesados en la capa ETL y normalizados en un almacén de datos unificado.
- **Análisis y Ponderación de Factores de Riesgo:** Una vez integrados, los datos pasan por un proceso de análisis mediante un conjunto de reglas de Business Intelligence, donde se aplican algoritmos de ponderación basados en los factores de riesgo

específicos del sector. Esta etapa incluye el cálculo de la reputación de la PYME, su consistencia en pagos y su estabilidad financiera general. Los algoritmos de clasificación y segmentación utilizados permiten a las entidades bancarias determinar la capacidad crediticia de las PYMES de manera precisa y personalizada.

- Visualización de Resultados en el Dashboard: Finalmente, los resultados son enviados al dashboard, donde se presentan en indicadores clave y gráficos comprensibles. Este flujo permite que las PYMES no solo conozcan su calificación crediticia, sino que también visualicen los factores que más influyen en su evaluación. Este proceso incrementa la transparencia del sistema y permite a las PYMES tomar decisiones financieras más informadas.

12.3 MODELO DE SOLUCIÓN ARQUITECTÓNICO

Un aspecto distintivo de esta investigación es la propuesta de un modelo arquitectónico de solución escalable, diseñado para ser replicado en diversas infraestructuras bancarias. Este modelo arquitectónico consta de cuatro capas principales que se pueden adaptar a distintos entornos tecnológicos, lo que lo convierte en una solución versátil para diversas instituciones financieras interesadas en mejorar sus sistemas de evaluación crediticia. Las capas son:

- Capa de Datos: Incluye fuentes de datos tradicionales y alternativas (como Open Banking y mecanismos de reputación). La arquitectura de la capa de datos permite la conexión a APIs de datos externos y asegura que toda la información cumpla con los requisitos de seguridad y confidencialidad. Esta capa también emplea técnicas de cifrado y autenticación para proteger los datos de las PYMES y garantizar su integridad.
- Capa de Procesamiento y Análisis: Basada en tecnologías de Business Intelligence, esta capa centraliza y procesa los datos obtenidos de manera eficiente. Utiliza motores de reglas y algoritmos de aprendizaje supervisado para ponderar los diferentes factores de riesgo crediticio. La arquitectura de esta capa es modular,

permitiendo que nuevas reglas y algoritmos se integren sin necesidad de modificar la infraestructura existente. Además, esta capa está diseñada para escalar horizontalmente, permitiendo manejar volúmenes crecientes de datos sin perder eficiencia.

- **Capa de Visualización e Interfaz de Usuario:** Esta capa incluye el dashboard de indicadores crediticios, que es accesible tanto para las PYMES como para las entidades bancarias. La interfaz está diseñada para ser intuitiva y adaptable, permitiendo que los usuarios visualicen su calificación de riesgo y comprendan los factores determinantes de forma clara. El diseño modular de la interfaz permite que el dashboard sea personalizado según las necesidades del banco o institución financiera, sin requerir modificaciones significativas en el modelo.
- **Capa de Seguridad y Cumplimiento:** La arquitectura contempla un módulo específico de seguridad que asegura el cumplimiento con las normativas de protección de datos vigentes, como la Ley de Protección de Datos Personales de Colombia. Esta capa se encarga de implementar protocolos de cifrado, autenticación multifactorial y almacenamiento seguro de datos, garantizando que la información sensible de las PYMES esté protegida en todo momento. Este enfoque de seguridad permite que el modelo se adapte a diversas infraestructuras y cumpla con regulaciones de diferentes jurisdicciones.

El modelo arquitectónico propuesto tiene una alta capacidad de replicabilidad y escalabilidad, lo que permite que otras instituciones financieras adopten esta solución en sus propios sistemas. La modularidad de las capas facilita su integración en infraestructuras bancarias ya existentes, minimizando la necesidad de realizar cambios profundos en los sistemas. Además, la flexibilidad en la elección de tecnologías de procesamiento y visualización permite que las instituciones adapten el modelo a sus propios entornos tecnológicos y preferencias de desarrollo. En conclusión, los aportes de esta investigación representan una solución arquitectónica integral que puede ser implementada y adaptada en distintas instituciones financieras, contribuyendo a la expansión del acceso al crédito y la inclusión financiera de las PYMES en Colombia y en otros contextos similares.

13. RECOMENDACIONES Y FUTUROS TRABAJOS

La investigación abre diversas oportunidades de expansión y optimización del modelo de evaluación crediticia propuesto, especialmente en la incorporación de Inteligencia Artificial (IA) para mejorar la precisión, accesibilidad y adaptabilidad del modelo a diferentes tipos de datos y escenarios. Uno de los principales enfoques futuros consiste en la integración de algoritmos avanzados de IA que consuman datos estáticos y dinámicos de fuentes públicas y privadas, proporcionando un análisis predictivo más robusto y una comprensión contextualizada de la situación financiera de las PYMES. Para ello, la implementación de la IA no solo fortalecerá la precisión del score crediticio final, sino que también permitirá la creación de alianzas empresariales estratégicas que faciliten el acceso a fuentes de datos variadas, incrementando la riqueza y relevancia de la información procesada.

La implementación de la IA en este modelo futuro permitirá consumir datos en tiempo real desde fuentes estáticas, como registros financieros históricos y datos dinámicos, como transacciones actuales y métricas de comportamiento. Estos datos pueden ser extraídos de bases públicas, como registros comerciales o estadísticas sectoriales, y también de fuentes privadas, tales como historiales de pago, comportamiento de consumo, patrones de compra y relaciones comerciales de cada PYME. Al integrar y analizar estos datos, la IA podrá establecer correlaciones entre variables que no son evidentes en los métodos de evaluación tradicionales, creando un análisis mucho más preciso y predictivo de la solvencia y estabilidad de las PYMES. El uso de algoritmos de machine learning, como redes neuronales y modelos de árboles de decisión, facilitará la identificación de patrones ocultos en los datos. Por ejemplo, a través de un modelo de aprendizaje supervisado, el sistema podrá identificar comportamientos comunes en PYMES que son financieramente estables, creando así perfiles de riesgo más completos y personalizados. Los algoritmos de aprendizaje no supervisado, como el clustering, podrán categorizar automáticamente a las PYMES en segmentos con características similares, permitiendo recomendaciones crediticias adaptadas a cada tipo de empresa.

Para llevar a cabo la implementación de IA con el enfoque planteado, es fundamental establecer alianzas estratégicas con empresas e instituciones que puedan aportar datos valiosos al modelo. Estas alianzas podrían incluir tanto entidades bancarias y financieras, que ya cuentan con información sobre el comportamiento de pago de las PYMES, como empresas de servicios públicos y privados que manejan datos relevantes sobre consumo, pagos y transacciones.

El acceso a estos datos no solo enriquecerá el análisis crediticio, sino que también permitirá una visión más holística de cada PYME, reflejando aspectos como su solidez comercial y su interacción con otros agentes económicos. Estas alianzas también permitirán establecer mecanismos de intercambio seguro de información y acuerdos de confidencialidad, asegurando que los datos sean compartidos y utilizados de manera ética y conforme a las normativas de protección de datos. La creación de un sistema de colaboración de datos, bajo un marco de Open Data y Open Banking, facilitará que las PYMES tengan acceso a financiamiento en mejores condiciones y que las instituciones financieras dispongan de una base de datos más completa para realizar evaluaciones de riesgo.

Con la implementación de IA en el modelo de evaluación crediticia, el score final de cada PYME será el resultado de un análisis profundo que considera múltiples factores y patrones identificados en tiempo real. La IA desempeñará un rol crucial al correlacionar datos heterogéneos y contextualizar cada indicador de riesgo. Por ejemplo, una PYME que presenta un historial de pago consistente pero que opera en un sector de alto riesgo podría recibir una evaluación ajustada según su sector, lo que daría un score más preciso y justo. Además, la IA permitirá la implementación de un modelo predictivo que se ajuste automáticamente a medida que se actualizan los datos, adaptándose a cambios en el comportamiento de cada PYME.

Este sistema se beneficiará de un modelo de trabajo colaborativo donde las entidades participantes (bancos, proveedores de servicios públicos, empresas de tecnología) retroalimenten el sistema con datos y análisis de tendencias, permitiendo que el modelo evolucione y mejore su precisión de manera continua.

El trabajo futuro también contempla el desarrollo de una plataforma digital que integre y despliegue el modelo de IA en tiempo real, permitiendo a las entidades financieras y a las PYMES acceder a los análisis crediticios de manera ágil y dinámica. Esta plataforma podrá integrarse con sistemas de banca digital, proporcionando un dashboard que se actualice de forma continua y refleje la situación actualizada de cada PYME. A través de esta plataforma, las PYMES podrán recibir recomendaciones personalizadas para mejorar su score crediticio y acceder a oportunidades de financiamiento adaptadas a sus necesidades. La implementación de IA y la creación de alianzas empresariales no solo fortalecerán la precisión y utilidad del modelo, sino que también fomentarán la inclusión financiera y la transparencia en la evaluación crediticia para las PYMES. Al contar con una base de datos más rica y variada, el modelo permitirá que las instituciones financieras realicen evaluaciones más justas y precisas, incrementando la confianza en el sistema y mejorando la calidad de los servicios financieros ofrecidos.

La viabilidad de este proyecto se sustenta en el acceso creciente a tecnologías de machine learning y en la apertura de datos promovida por iniciativas como Open Banking y Open Data, lo que facilita el acceso a fuentes de información diversas y seguras. Además, la infraestructura arquitectónica modular del modelo actual permite integrar nuevas capas de análisis y datos sin necesidad de realizar modificaciones profundas, garantizando una escalabilidad adecuada y una implementación progresiva. En conclusión, los trabajos futuros de esta investigación proponen un enfoque innovador que posiciona la IA como el núcleo del sistema de evaluación crediticia, con una red de alianzas que provee una visión integral de las PYMES. Esta implementación contribuirá a un sistema de financiamiento más inclusivo, eficiente y adaptado a la realidad de las pequeñas y medianas empresas en Colombia y en otros contextos similares.

Para lograr una implementación efectiva y sostenible del modelo propuesto, es esencial tener en cuenta diversas recomendaciones que maximicen el impacto y aseguren la viabilidad a largo plazo. En primer lugar, se recomienda fortalecer la integración Open Banking, esto incluye la adopción de protocolos de encriptación y autenticación que garanticen la privacidad y seguridad de la información de las PYMES, un aspecto crítico para lograr la confianza de las empresas en el uso de este modelo.

Uno de los principales desafíos para la efectividad del modelo radica en la creciente dificultad para acceder a datos provenientes de redes sociales y otras plataformas digitales debido a los cambios en políticas de privacidad y protección de datos. Este obstáculo limita la obtención de información sobre reputación, comportamiento y relaciones comerciales de las PYMES, datos que resultan clave para enriquecer la evaluación crediticia. Ante este contexto, se recomienda implementar alternativas de obtención de datos a través de repositorios públicos y privados, donde entidades crediticias, instituciones financieras y proveedores de servicios compartan información relevante de manera ética y segura. Para asegurar la fiabilidad y seguridad de estos datos, es esencial que las entidades financieras y los proveedores de datos establezcan protocolos de intercambio de información bajo estándares de confidencialidad y normativas locales e internacionales de protección de datos. La adopción de prácticas de cifrado y autenticación multifactorial permitirá que el modelo obtenga y procese información sensible sin comprometer la privacidad de las PYMES.

Dada la reducción en la accesibilidad a ciertos tipos de datos no estructurados, como los provenientes de redes sociales, se sugiere el diseño de nuevos procesos de obtención y análisis de datos que aprovechen los repositorios de información disponibles en el sector financiero. Estos repositorios pueden incluir bases de datos de entidades crediticias y reportes de comportamiento de pago en diferentes sectores. A través de alianzas estratégicas con estas entidades, el modelo de evaluación crediticia podrá acceder a una base de datos diversificada y confiable, contribuyendo a una valoración crediticia más precisa y contextualizada.

Se recomienda también el desarrollo de un sistema de interoperabilidad de datos que permita a los repositorios públicos y privados integrar información relevante para el análisis crediticio. Este sistema deberá ser capaz de normalizar y estandarizar la información proveniente de diversas fuentes, de manera que pueda ser utilizada eficientemente en el cálculo de los indicadores de riesgo. Además, la implementación de tecnologías de procesamiento y análisis de datos, como ETL (extracción, transformación y carga), ayudará a gestionar grandes volúmenes de información y garantizar que los datos se mantengan actualizados en el tiempo.

Para asegurar una implementación efectiva y sostenible del modelo, es fundamental que los desarrolladores colaboren de manera estrecha con entidades financieras y organismos reguladores. Esta colaboración permitirá ajustar las características del modelo a las necesidades específicas del sector bancario y asegurar su alineación con las regulaciones locales. Además, el trabajo conjunto facilitará el acceso a fuentes de datos claves, como registros de comportamiento de pago y datos sectoriales, lo que contribuirá a la precisión del análisis crediticio. Se recomienda también la realización de pruebas piloto en colaboración con diversas instituciones financieras para evaluar la eficacia del modelo en un entorno real y ajustar los parámetros según las necesidades detectadas. Este proceso permitirá recopilar retroalimentación directa de las entidades bancarias, asegurando que el modelo cumpla con sus expectativas y necesidades. A su vez, los organismos reguladores pueden proporcionar orientaciones sobre las mejores prácticas en la gestión de datos y ayudar a establecer un marco de evaluación periódica que permita adaptar el modelo a los cambios regulatorios y tecnológicos en el ecosistema financiero.

Finalmente, se sugiere establecer un marco de monitoreo y mejora continua que permita evaluar periódicamente el rendimiento y la precisión del modelo. Este marco deberá incluir indicadores clave de desempeño (KPIs) relacionados con la precisión de las evaluaciones, el tiempo de procesamiento de los datos y la satisfacción de las PYMES en el uso del dashboard. La recolección y análisis de estos KPIs permitirá identificar áreas de mejora y realizar ajustes necesarios para mantener la efectividad del modelo. Este marco también puede incluir la revisión y actualización de las políticas de privacidad de datos y el ajuste de los mecanismos de recolección de datos a medida que cambian las normativas y las tecnologías de protección de datos. A través de esta práctica, el modelo se mantendrá alineado con los cambios en el entorno regulatorio y podrá adaptarse a nuevas exigencias de privacidad y seguridad en el tratamiento de la información crediticia. Estas recomendaciones buscan no solo enfrentar los desafíos actuales en cuanto al acceso y gestión de datos, sino también optimizar el modelo para una implementación práctica y efectiva. La colaboración entre entidades, la capacitación de los usuarios y la adopción de procesos seguros y eficientes de recolección de datos serán fundamentales para asegurar la utilidad y sostenibilidad del modelo en el sector financiero colombiano y más allá.

14. REFERENCIAS

- A. Mackenzie, "THE FINTECH REVOLUTION," London Business School Review, vol. 26, pp. 50–53, 2015
- A. Abelló, J. Darmont, L. Etcheverry, M. Golfarelli, J. Mazón, F. Naumann, T.B. Pedersen, S. Rizzi, J. Trujillo, P. Vassiliadis, G. Vossen, Fusion cubes: towards self-service business intelligence, IJDWM, 9 (2) (2013), pp. 66-88.+
- ACCC. (2020). Consumer Data Right (CDR) and Open Banking in Australia. Australian Competition & Consumer Commission.
- Accenture. (2020). The Future of Open Banking: Unlocking the Power of Data. Accenture.
- Accenture. (2021). Data-Driven Credit Scoring: Leveraging Public Records for SME Evaluation. Accenture Insights.
- Accion. (2021). How fintech is helping SMEs gain better access to credit. Accion.
- Aggarwal, C. C., Han, J., Wang, J., & Yu, P. S. (2021). Data Mining: Concepts and Techniques. Morgan Kaufmann.
- Alloza, Á., Carreras, E., & Carreras, A. (2013). Reputación corporativa. Editorial Almuzara.
- Álvarez, S., Lochmüller, C., & Osorio, A. (2011). La medición del riesgo de crédito en Colombia y el acuerdo de Basilea III. Revista Soluciones de Postgrado EIA, 7, 49-66.
- Amezcuá, M. P. (2012). Redes sociales, mecanismos generadores de reputación organizacional para las PyMEs. DOAJ (DOAJ: Directory Of Open Access Journals).
- ANPD. (2020). Brazil's Open Data and Public Records as a Tool for Financial Inclusion. Agência Nacional de Proteção de Dados.
- Asobancaria. (2020). Informe de Inclusión Financiera en Colombia. Asociación Bancaria de Colombia.
- Asobancaria. (2021). Innovación Fintech en Colombia. Asociación Bancaria de Colombia.
- Asobancaria. (2021). La Transformación Digital del Sistema Financiero Colombiano: Retos y Oportunidades. Asociación Bancaria de Colombia.

Athey, S., Imbens, G., & James, G. (2021). The use of machine learning for causal inference and policy evaluation. *Review of Economics and Statistics*, 103(5), 703-720.

B. R. Iyer and R. C. Basole, "Visualization to understand ecosystems," *Communications of the ACM*, vol. 59, no. 11, pp. 27–30, 2016.

Banco de la República. (2020). Informe de Estabilidad Financiera.

Banco de la República. (2020). Informe sobre Desarrollo Financiero.

Banco Mundial. (2021). Global Financial Inclusion Database (Global Findex). World Bank.

Barker, J., & Ko, S. (2019). Data integration and quality checks in BI systems. *Business Intelligence Review*, 22(3), 15-25.

Barrett, B. (2020). *Amazon Web Services for Dummies*. John Wiley & Sons.

Bayes Thomas, An essay towards solving a problem in the doctrine of chances. 1763, *MD Comput.: Comput. Med. Pract.*, 8 (3) (1991), p. 157

Berg, T., Burg, V., Gombović, A., & Puri, M. (2020). On the Rise of FinTechs: Credit Scoring using Digital Footprints. *Review of Financial Studies*, 33(7), 2845-2897.

BID. (2020). Inversión en Infraestructura Digital para el Desarrollo Financiero en América Latina. Banco Interamericano de Desarrollo.

Blumenstock, J., Cadamuro, G., & On, R. (2015). Predicting Poverty and Wealth from Mobile Phone Metadata. *Science*, 350(6264), 1073-1076.

BNDES. (2020). Programas Innovadores para la Inclusión Financiera en Brasil. Banco Nacional de Desenvolvimento Econômico e Social.

Böhme, R., & Köpsell, S. (2019). On the Security and Privacy of Modern Mobile Platforms. *ACM Computing Surveys*, 43(1), 1-33.

Brigham, E. F., & Daves, P. R. (2014). *Intermediate Financial Management*. Cengage Learning.

Brigham, E. F., & Ehrhardt, M. C. (2013). *Financial Management: Theory & Practice* (14th ed.). South-Western College Pub.

CAF. (2020). *Inclusión Financiera en América Latina: Desafíos y Oportunidades*. Banco de Desarrollo de América Latina.

Caitlin Cassidy, Parameter tuning Naïve Bayes for automatic patent classification, World Patent Information, Volume 61, 2020.

Cambria, E., Schuller, B., Xia, Y., & Havasi, C. (2020). New Avenues in Opinion Mining and Sentiment Analysis. IEEE Intelligent Systems, 28(2), 15-21.

Carmine D'Arconte, Business Intelligence applied in Small Size for Profit Companies, Procedia Computer Science, Volume 131, 2018.

CEPAL. (2021). Uso de Tecnologías Financieras para la Inclusión de Mipymes en América Latina.

CGAP. (2020). Fintech and Financial Inclusion: The Role of Mobile Data in Emerging Markets. Consultative Group to Assist the Poor.

Chakraborty, T., Bhattacharjee, S., & Mukherjee, A. (2021). Sentiment Analysis and Opinion Mining: A Survey on Methods and Approaches. ACM Computing Surveys, 53(3), 49-55.

Chawla N.V., Bowyer K.W., Hall L.O., Kegelmeyer W.P. SMOTE: synthetic minority over-sampling technique J. Artificial Intelligence Res., 16 (1) (2002), pp. 321-357

Chen, H., Chiang, R. H., & Storey, V. C. (2012). Business Intelligence and Analytics: From Big Data to Big Impact. MIS Quarterly, 36(4), 1165–1188.

Chen, J., Wang, C., & Sun, W. (2019). Application of artificial intelligence in financial risk management: A review. Journal of Financial Risk Management, 12(1), 27-45.

Comisión Económica para América Latina y el Caribe (CEPAL). (2020). Las políticas fiscales y las empresas en América Latina: Enfrentando los efectos de la pandemia. Santiago: CEPAL.

Confecámaras. (2020). Perfil de las Mipymes en Colombia: Estadísticas del Registro Mercantil.

Cruz, R., Torres, G., & Vasquez, J. (2021). Using Public Procurement Data for SME Credit Scoring: A Case Study. Journal of Public Economics, 94(5), 563-589.

D. J. Teece, "Explicating dynamic capabilities: the nature and microfoundations of (sustainable) enterprise performance," Strategic Management Journal, vol. 28, no. 13, pp. 1319–1350, 2007.

Damodaran, A. (2002). Investment Valuation: Tools and Techniques for Determining the Value of Any Asset. Wiley.

Damodaran, A. (2010). Applied Corporate Finance. Wiley.

Davenport, T. H. (2013). Big Data at Work: Dispelling the Myths, Uncovering the Opportunities. Harvard Business Review Press.

de Montjoye, Y. A., Hidalgo, C. A., Verleysen, M., & Blondel, V. D. (2018). Unique in the Crowd: The Privacy Bounds of Human Mobility. Scientific Reports, 3, 1376.

Deloitte. (2021). Fintech and Psychometric Data: A New Frontier in Credit Scoring.

Demajo, R., Vella, J., & Dingli, A. (2020). Explainable AI for Interpretable Credit Scoring. Computer Science & Information Technology (CS & IT), 10, 15-25.

Dhar, V., & Stein, R. M. (2017). Fintech Platforms and Strategy: Understanding the Role of Technology in Financial Services. Journal of Business Research, 70, 258-263.

E. Graupner, F. Melcher, D. Demers, and A. Maedche, "Customers' Intention to Use Digital Services in Retail Banking - An Information Processing Perspective," ECIS Completed Research Paper, Paper 61, 2015.

Edward I. Altman, Robert G. Haldeman and P. Narayanan. ZETATM analysis A new model to identify bankruptcy risk of corporations. Journal of Banking & Finance, 1977, vol. 1, issue 1, 29-54.

Espeleta Bayona, A. P., & Solano Suárez, A. M. (2022). Evaluación de los desafíos de la implementación del Open Banking en Colombia como política pública.

Fazekas, M., & Tóth, I. J. (2016). From Corruption to Competitiveness: Public Procurement Data as a Tool for Better Governance. Government Information Quarterly, 33(2), 253-267.

Financial Conduct Authority. (2019). Guidelines on Open Banking and Data Protection in the UK. FCA.

Financial Conduct Authority. (2019). Open Banking Implementation: A Guide for Financial Institutions. FCA.

Financiera de Desarrollo Nacional (FDN). (2021). Impacto de la Ley de Inversión Social en el sector empresarial colombiano. Bogotá: FDN.

Findex. (2021). Global Financial Inclusion Database. Banco Mundial.

Finextra. (2021). Alternative data for credit scoring: Fintech innovating the sector. Finextra Research.

Fink, L., Yogev, N., & Even, A. (2017). Business Intelligence and Organizational Learning: An Empirical Investigation of Value Creation Processes. *Information & Management*, 54(1), 38–56.

Fintech Global. (2020). How FinTech is Revolutionizing Credit Scoring with Alternative Data.

Frias-Martinez, V., & Virseda, J. (2012). Cell Phone Analytics: Call Detail Records as a Source of Information for Economic Analysis. *International Journal of Electronic Commerce*, 17(2), 17-33.

García, A., & Rodríguez, M. (2021). Barreras de Acceso al Crédito para Mipymes en Colombia. Universidad Nacional de Colombia.

García, J. M. (2005). Reputación corporativa y creación de valor. Marco teórico de una relación circular. *Investigaciones Europeas de Dirección y Economía de la Empresa*, 11(2), 81-97.

Goh, L., Lee, L., Wong, L. (2019). Credit Scoring: A Review on Support Vector Machines and Metaheuristic Optimization. *Advances in Operations Research*.

Gomez, R., & Ruiz, M. (2021). Open Banking and Credit Scoring: A New Frontier. Universidad Nacional.

Gomez, S., & Castillo, J. (2021). Modelos Alternativos de Calificación Crediticia para Mipymes. Universidad Nacional de Colombia.

Gómez-Correa, E., & Henao-García, A. (2020). La adaptación de Leonisa a la era digital en Colombia. *Revista de Mercadeo & Estrategia*, 24(3), 45-55.

GSMA. (2020). The Mobile Economy: Sub-Saharan Africa. GSM Association.

Gupta, R., et al. (2020). Sentiment analysis in financial models. *Journal of Machine Learning in Finance*, 12(4), 38-52.

Gutierrez, C., Garcia, J., & Flores, P. (2013). Call Detail Records as a Tool for Tracking Economic and Social Behavior. *Journal of Economic Perspectives*, 27(2), 97-120.

He H., Yang B., Garcia E.A., Li S. Adasyn: adaptive synthetic sampling approach for imbalanced learning IEEE International Joint Conference on Neural Networks (2008), pp. 1322-1328

Hendrikse, G., Olivetti, D., & Terho, H. (2019). Credit scoring using artificial intelligence methods: A systematic review and future research directions. *Advances in Operations Research*, 2019, 1-15.

Hendrikse, M., Zhang, X., & Peters, G. (2021). Explainable AI for Interpretable Credit Scoring. *Procedia Computer Science*.

Higgins, R. C. (2012). *Analysis for Financial Management* (10th ed.). McGraw-Hill/Irwin.

Hui Zhang, Chun-Tao Liu, Jun Mao, Chen Shen, Rui-Ling Xie, Bo Mu, Development of novel in silico prediction model for drug-induced ototoxicity by using naïve Bayes classifier approach, *Toxicology in Vitro*, Volume 65, 2020.

ICIJ. (2017). *The Panama Papers: Public Business Records and Transparency*. International Consortium of Investigative Journalists.

IFC. (2021). *Big data and machine learning for credit scoring: Opportunities and challenges in emerging markets*. International Finance Corporation.

IMF. (2020). *Fintech and Financial Inclusion: Regulatory Frameworks for Microcredit Institutions*. International Monetary Fund.

Internal Revenue Service (2021). *Paycheck Protection Program and other fiscal benefits for SMEs*.

International Finance Corporation (2021). *The Role of SMEs in the Economic Recovery after COVID-19*.

Jack, W., & Suri, T. (2014). Risk Sharing and Transactions Costs: Evidence from Kenya's Mobile Money Revolution. *American Economic Review*, 104(1), 183-223.

Jain, A., Ross, A., & Nandakumar, K. (2020). *Introduction to Biometrics and Mobile Security*. Springer.

Jianjian Yan, Zhongnan Zhang, Kunhui Lin, Fan Yang, Xiongbiao Luo, A hybrid scheme-based one-vs-all decision trees for multi-class classification tasks, *Knowledge-Based Systems*, Volume 198, 2020.

Joshi, P. (2020). *Data Visualization with Amazon QuickSight*. Packt Publishing.

Kanupriya. (2021). COVID-19 and the Indian Textiles Sector: Issues, Challenges and Prospects. *Vision*, 25(1), 7-11.

Karlan, D., Udry, C., & Zia, B. (2018). Harnessing Digital Information to Increase Access to Credit for Small Firms. *Journal of Development Economics*, 133, 249-262.

Khan, A. (2019). *AWS Glue: Data Catalog and ETL Processes Simplified*. O'Reilly Media.

Kietzmann, J. H., Hermkens, K., McCarthy, I. P., & Silvestre, B. S. (2011). Social Media? Get Serious! Understanding the Functional Building Blocks of Social Media. *Business Horizons*, 54(3), 241-251.

Klinger, B., Khwaja, A. I., & LaMonte, J. (2013). Behavioral Biases and Personality Traits in Risk Taking: Evidence from Micro-Entrepreneurs. *Journal of Economic Behavior & Organization*, 92, 63-73.

KPMG. (2019). The Future of Open Banking: Driving Innovation in Financial Services. KPMG.

KPMG. (2021). Digital Transformation in Financial Services: Open Banking and Alternative Credit Scoring. KPMG Insights.

Kurnia, P. F., & Suharjito. (2018). Business Intelligence Model to Analyze Social Media Information. *Procedia Computer Science*, 135, 5-14.
<https://doi.org/10.1016/j.procs.2018.08.144>

L. Zavolokina, M. Dolata, and G. Schwabe, "FinTech—What's in a Name?," ICIS Completed Research Paper, 2016

Larrimore, J., Jiang, E., & Larrimore, A. (2019). Psychometric Credit Scoring and Its Applications in Developing Markets. *World Development*, 123, 104622.

LexisNexis Risk Solutions. (2020). The impact of social media data on credit scoring. LexisNexis Risk Solutions.

Liu, B., Hu, M., & Cheng, J. (2019). Opinion Observer: Analyzing and Comparing Opinions on the Web. *Proceedings of the 14th International Conference on World Wide Web*, 342-351.

Luís Ángel Meneses Cerón, Ronald Alejandro Macuacé Otero. Valoración y riesgo crediticio en Colombia. *Finanzas y Política Económica*, ISSN: 2248-6046, Vol. 3, No. 2, julio-diciembre, 2011, pp. 65-82.

M. Iansiti and R. Levien, "The Keystone Advantage: What the New Dynamics of Business Ecosystems Mean for Strategy, Innovation, and Sustainability," Boston: Harvard Business School Press, 2004.

M.A. Beyer, E. Thoo, E. Zaidi, R. Greenwald, Magic quadrant for data integration tools, Tech. rep., Gartner (August 2016).

Mahfoud Bala, Omar Boussaid, Zaia Alimazighi, A Fine-Grained Distribution Approach for ETL Processes in Big Data Environments, *Data & Knowledge Engineering*, Volume 111, 2017.

Martínez-Alonso, G., & Pérez-López, M. (2018). Innovación y sostenibilidad: El caso de MUD Jeans. *Revista de Negocios Internacionales*, 12(4), 123-140.

Mckenzie, D., & Sansone, D. (2017). Man vs. Machine in Predicting Successful Entrepreneurs: Evidence from a Business Plan Competition in Nigeria. *World Bank Policy Research Working Paper No. 8271*.

McKinsey & Company. (2020). *Global banking annual review: Data-driven insights*. McKinsey & Company.

Micu, A., Micu, A. E., & Crişan, C. (2012). The Benefits of CRM Technology Use in the Romanian Banking Sector. *Amfiteatru Economic Journal*, 14(32), 270–284.

Miller, D. (2021). Real-time credit scoring using AI-driven dashboards. *Financial Insights Quarterly*, 8(1), 33-42.

Moreno, L., Pérez, J., & González, S. (2021). Innovación en modelos de riesgo crediticio: Uso de datos alternativos. *Universidad Nacional de Colombia*.

Moro, S., Cortez, P., & Rita, P. (2019). A Text Mining Approach to Analysing Announcements of the Top European Banks Using Data from Facebook. *International Journal of Information Management*, 40, 1-7.

M-Shwari. (2020). *Innovative Solutions for Financial Inclusion in Kenya*. Safaricom.

Naboulsi, D., Fiore, M., Stanica, R., & Ribot, S. (2016). Large-Scale Mobile Data Analysis: A Survey of Current Techniques and Applications. *IEEE Communications Surveys & Tutorials*, 18(3), 1245-1280.

Neha Soni, Enakshi Khular Sharma, Narotam Singh, Amita Kapoor, *Artificial Intelligence in Business: From Research and Innovation to Market Deployment*, *Procedia Computer Science*, Volume 167, 2020, Pages 2200-2210.

OECD. (2019). *Financing SMEs and Entrepreneurs: An OECD Scoreboard*.

OECD. (2020). *Open Banking: Enhancing Financial Innovation and Data Privacy*. OECD Publishing.

OECD. (2020). *Public Procurement Data as a Strategic Tool for Financial Stability*. OECD Publishing.

Pablo Angelelli, Michael Hennessey, Pauline Henriquez. *Respuestas al COVID-19 desde la ciencia, la innovación y el desarrollo productivo*. Banco Interamericano de Desarrollo. 1ª Edición. 25 de abril de 2020

Parama Fadli Kurnia, Suharjito, Business Intelligence Model to Analyze Social Media Information, Procedia Computer Science, Volume 135, 2018.

PSD2. (2018). Revised Payment Services Directive (PSD2) and Open Banking in the EU. European Commission.

PsyFi. (2019). Psychometrics in Credit Scoring: How Personality Traits Predict Financial Behavior.

PwC. (2021). Data and AI in financial services: The future of credit scoring. PricewaterhouseCoopers.

Rafael Regalado Hernández. Las MIPYMES en Latinoamérica. México D.F., México, 2000.

Ramasubramanian, K., & Jain, A. (2018). Deep Learning for Natural Language Processing: Creating Neural Networks with Python. Apress.

Ramírez-Restrepo, M., & Marín-Gómez, A. (2019). La estrategia digital de las empresas colombianas: Arturo Calle y Vélez. Revista de Administración y Marketing, 34(2), 65-79.

Rao, S., & Kumar, P. (2018). Customer feedback loops in credit evaluation. International Journal of Customer Feedback, 14(1), 41-57.

Revista Dinero. (2021). Resiliencia empresarial: Cómo las grandes empresas colombianas se adaptaron a la crisis de la pandemia.

Risks. (2021). Risks and Challenges in the Adoption of AI for Credit Scoring. Journal of Financial Technology

Rodríguez, M., & Pérez, A. (2019). Marco Regulatorio y Protección de Datos en el Uso de Información Crediticia Alternativa. Revista Jurídica de Colombia.

Ross, S. A., Westerfield, R. W., & Jaffe, J. F. (2016). Corporate Finance (11th ed.). McGraw-Hill Education.

Sarabia, A. (1995). La Teoría general de sistemas. 1st ed. Madrid: Isdefe, p.126.

Song, C., Qu, Z., Blumm, N., & Barabási, A. L. (2017). Limits of Predictability in Human Mobility. Science, 327(5968), 1018-1021.

Sun, L., et al. (2021). Integration of financial and social data in credit scoring. AI & Society, 17(2), 99-113.

Superintendencia financiera de Colombia. Diferencias con las centrales de información financiera. Términos de caducidad de la información. Central de Riesgos de la Superintendencia Bancaria. 2000. Reforma Financiera.

Superintendencia Financiera de Colombia. (2021). Informe de Supervisión sobre la Bancarización de Mipymes.

Superintendencia Financiera de Colombia. (2021). Innovación en la Evaluación Crediticia con Datos Alternativos: Perspectiva Colombiana.

Superintendencia Financiera de Colombia. (2021). Marco Regulatorio para la Protección de Datos en la Evaluación Crediticia. Superintendencia Financiera de Colombia.

Superintendencia Financiera de Colombia. (2021). Regulación y Uso de Datos Públicos para la Evaluación Crediticia de Mipymes en Colombia.

Superintendencia Financiera de Colombia. (2022). Decreto 1297 de 2022: Normativa de Open Banking en Colombia.

Taherdoost, H.;Madanchian, M. Artificial Intelligence and Sentiment Analysis: A Review in Competitive Research. Computers 2023, 12, 37.

Taneja, Rimple. (2014). Business Intelligence in Banking Sector: A Step Forward To Customer Delight. Managemet Guru: Journal of Management. II. 32-36.

Thomas F. Dapp. Fintech reloaded – Traditional banks as digital ecosystems: With proven walled garden strategies into the future. Deutsche Bank AG. Deutsche Bank Research, Germany. 2015.

Torres-Correa, L., & Arias-Ruiz, J. (2019). Estrategias de marketing digital en marcas juveniles: El caso de Koaj. Revista de Comunicaciones Integradas, 11(2), 89-101.

U.S. Small Business Administration (2021). United States Small Business Economic Profile.

Varsha, P. S., Akter, S., Kumar, A., Gochhait, S., & Patagundi, B. (2021). The Impact of Artificial Intelligence on Branding. Journal Of Global Information Management, 29(4), 221-246.

Wang, T., & Miller, J. (2019). Mobile App Data for Credit Scoring: Insights from Fintechs in Southeast Asia. Asian Development Bank Institute.

Wixom, B. H., & Watson, H. J. (2010). The BI-Based Organization. International Journal of Business Intelligence Research, 1(1), 13–28.

World Bank Group. (2018). Improving access to finance for SMEs. World Bank. <https://doi.org/10.1596/31530>

World Bank. (2019). Paying Taxes 2020: How Public Data Can Be Used for Credit Scoring in Developing Economies. World Bank Group.

World Bank. (2020). Psychometrics as a Tool for Improving Credit Access in Emerging Markets.

World Bank. (2021). Digital Financial Services and Regulatory Innovation in Latin America. World Bank Group.

World Bank. (2021). Global Financial Inclusion Database (Global Findex). Banco Mundial.

Zaremba, Adam and Demir, Ender, ChatGPT: Unlocking the Future of NLP in Finance (January 13, 2023). Modern Finance, 2023, Vol 1, No. 1, pp. 93-98.

Zeng, C., Yang, Y., & Chen, P. (2020). Mobile App Analytics and Consumer Behavior: Insights from Data. International Journal of Information Management, 52, 102054.

Zhang, Y., & Vos, M. (2014). Social Media Monitoring: How Should Companies Listen to Online Conversations? Journal of Business Research, 67(11), 2625-2630.

Zhao, W. X., Jiang, J., Weng, J., He, J., Lim, E. P., Yan, H., & Li, X. (2019). Comparing Twitter and Traditional Media Using Topic Models. Advances in Information Retrieval, 338-349.

Zhou, Y., et al. (2020). Impact of KPI's on credit evaluation process. Journal of Financial Modeling, 35(1), 27-45.

Zopa. (2020). Open Banking: The Path to Better Financial Decisions.