

MODELO DE LEARNING ANALYTICS BASADO EN MÉTRICAS EMOCIONALES PARA APLICACIONES MÓVILES DE APRENDIZAJE EN SEGUNDA LENGUA



ANDRÉS OVIDIO RESTREPO RODRÍGUEZ

**UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
MAESTRÍA EN CIENCIAS DE LA INFORMACIÓN Y LAS COMUNICACIONES
FACULTAD DE INGENIERÍA
BOGOTÁ, COLOMBIA
2022**

MODELO DE LEARNING ANALYTICS BASADO EN MÉTRICAS EMOCIONALES PARA APLICACIONES MÓVILES DE APRENDIZAJE EN SEGUNDA LENGUA



TRABAJO DE INVESTIGACIÓN PARA OPTAR POR EL TÍTULO DE:
MAGISTER EN CIENCIAS DE LA INFORMACIÓN Y LAS COMUNICACIONES

ANDRÉS OVIDIO RESTREPO RODRÍGUEZ

DIRECTOR:

PAULO ALONSO GAONA GARCÍA, PhD.

GRUPO DE INVESTIGACIÓN:

MULTIMEDIA INTERACTIVA Y ANIMACIÓN DIGITAL

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
MAESTRÍA EN CIENCIAS DE LA INFORMACIÓN Y LAS COMUNICACIONES
BOGOTÁ, COLOMBIA
2022

Dedicatoria

*A mi familia, a mi pareja, amigos y todas las personas que me han apoyado y
aportado en este proceso.*

Agradecimientos:

- Agradecimiento especial a la Universidad Distrital Francisco José de Caldas, mi Alma Máter, promotora de mi formación personal y profesional.
- A mi familia y pareja por el apoyo incondicional, el acompañamiento y amor constante, convirtiéndose en un pilar fundamental para el trabajo realizado.
- A los docentes de la maestría que me han acompañado en la formación posgradual y a los miembros del grupo de investigación Multimedia Interactiva y Animación, por el acompañamiento durante este proceso de investigación.
- En especial a los docentes, Paulo Alonso Gaona García y Carlos Enrique Montenegro Marín, por el acompañamiento, disposición y mentoría, durante el desarrollo de mi proceso académico e investigativo.

Resumen

Este documento presenta los resultados obtenidos a partir de la implementación y aplicación de un modelo de learning analytics basado en métricas emocionales, el cual expone dos componentes principales. El primer componente está enfocado en la aplicación de técnicas de analítica de visualización y el segundo, está orientado en la aplicación de técnicas de clustering emocional de series de tiempo de longitud variable. Este modelo, consume un conjunto de datos llamado Emotional Data L2 Interaction (EDaLI), el cual también fue construido en este estudio. Este conjunto de datos cuenta con series de tiempo emocionales capturadas durante la interacción de un grupo de 19 personas con cuatro lecciones de portugués de la aplicación de aprendizaje de segunda lengua Babbel. Adicionalmente, este conjunto de datos se encuentra anotado, especificando las actividades que realizaban los participantes, segundo a segundo durante su interacción. Los resultados obtenidos presentan dos perspectivas, la primera orientada a analítica de visualización, la cual permite observar y comprender el comportamiento emocional y los resultados obtenidos por los participantes a nivel grupal e individual y de esta forma generar recomendaciones iniciales. La otra perspectiva está enfocada en el clustering emocional, donde se obtienen modelos que a partir de métricas como el índice de Silhouette, Davies-Bouldin y Calinski-Harabasz, presentan un nivel medio-alto de cohesión, compactabilidad y separación en los grupos generados, a partir de los datos emocionales analizados.

Palabras Claves

Learning analytics, métricas emocionales, interfaz cerebro-computadora, clustering de series de tiempo de longitud variable, analítica de visualización, aplicaciones de aprendizaje de segunda lengua.

Índice general

Capítulo 1	16
Introducción	16
1.1 Planteamiento de investigación.....	17
1.2 Objetivos	20
1.3 Justificación	21
1.4 Hipótesis	24
1.5 Limitaciones.....	24
Capítulo 2	25
Panorama y revisión de literatura	25
2.1 Aplicaciones móviles en educación	25
2.2 Aplicaciones móviles en aprendizaje de segunda lengua.....	26
2.3 Learning Analytics	27
2.4 Las emociones y la educación	28
2.5 Interfaces cerebro computadora en educación.....	30
Capítulo 3	32
Desarrollo Metodológico.....	32
3.1 Caracterización de aplicaciones móviles de aprendizaje de segunda lengua	33
3.2 Identificación y definición de métricas emocionales	39
3.3 Diseño del modelo de Learning Analytics basados en métricas emocionales	46
3.4 Definición del caso de estudio	55
Capítulo 4	61
Caso de estudio en profundidad.....	61
4.1 Estructura del curso de Babbel: portugués.....	61
4.2 Recopilación de métricas emocionales y evaluación	66

4.3	Implementación del modelo de Learning Analytics basado en métricas emocionales	74
4.4	Proyección de resultados.....	83
Capítulo 5		85
Resultados y análisis.....		85
5.1	Enfoque de técnicas de visualización	85
5.2	Clustering emocional.....	109
Capítulo 6		117
Conclusiones y trabajo futuros		117
6.1	Resultados derivados de la investigación	117
6.2	Conclusiones	118
6.3	Principales aportes.....	120
6.4	Recomendaciones y trabajos futuros	121
Referencias.....		123

Índice de Figuras

Figura 1 Infografía de la metodología del estudio	32
Figura 2 Emotiv Insight	41
Figura 3 MindWave (Engchuan et al., 2017)	44
Figura 4 Comparación distancia euclidiana y deformación dinámica de tiempo Tomada de (Costa et al., 2017)	51
Figura 5 Definición general del modelo de learning analytics	54
Figura 6 Caso de estudio - componente de aplicación móvil de segunda lengua	56
Figura 7 Caso de estudio - componente de recopilación de métricas	57
Figura 8 Caso de estudio - componente modelo de learning analytics	58
Figura 9 Definición del caso de estudio	59
Figura 10 Explicación de tema en lección 1	62
Figura 11 Aprendizaje de vocabulario (VL) en lección 1	63
Figura 12 actividad de selección de opción (OP) y subactividad escucha (LIS)	66
Figura 13 Flujo para la captura de métricas emocionales	67
Figura 14 Estructura de datos crudos	68
Figura 15 Métricas emocionales procesadas	69
Figura 16 Métricas emocionales anotadas	70
Figura 17 Estructura archivo JSON de resultados	72
Figura 18 Estructura conjunto de datos EDaLI	73
Figura 19 Mock Up análisis visual grupal para una lección (A). análisis visual grupal para un grupo de lecciones (B)	76
Figura 20 Mockup análisis visual grupal para una actividad (A). Mockup análisis visual grupal para una subactividad (B)	77
Figura 21 Mockup análisis visual individual para una lección (A). Mockup análisis visual individual para un grupo de lecciones (B)	79
Figura 22 Mockup análisis visual individual para una actividad (A). Mockup análisis visual individual para una subactividad (B)	81

Figura 23 Distribución Unificada de Métricas Emocionales grupo y lecciones.....	86
Figura 24 Distribución Superpuesta de Métricas Emocionales grupo y lecciones	87
Figura 25 Medición de tiempo grupo y lecciones	87
Figura 26 Resultados grupo y lección.....	88
Figura 27 Grupo de registro de emociones grupo y lección.....	88
Figura 28 Distribución Unificada de Métricas Emocionales grupo y lección	89
Figura 29 Medición de tiempo grupo y lección.....	90
Figura 30 Resultados grupo y lección.....	90
Figura 31 Distribución Unificada de Métricas Emocionales grupo, lecciones y actividad	92
Figura 32 Distribución Superpuesta de Métricas Emocionales grupo, lecciones y actividad	92
Figura 33 Medición de tiempo grupo, lecciones y actividad	93
Figura 34 Resultados grupo, lecciones y actividad	93
Figura 35 Distribución Unificada de Métricas Emocionales grupo, lecciones, actividad y subactividad	94
Figura 36 Distribución Superpuesta de Métricas Emocionales grupo, lecciones, actividad y subactividad	94
Figura 37 Medición de tiempo grupo, lecciones, actividad y subactividad	95
Figura 38 Resultados grupo, lecciones, actividad y subactividad	95
Figura 39 Grupo de registro de emociones participante y lecciones.....	97
Figura 40 Distribución Unificada de Métricas Emocionales participante y lecciones	97
Figura 41 Distribución Superpuesta de Métricas Emocionales participante y lecciones	98
Figura 42 Medición de tiempo participante y lecciones	98
Figura 43 Resultados participante y lecciones.....	99
Figura 44 Grupo de registro de emociones participante y lección.....	100

Figura 45 Distribución Unificada de Métricas Emocionales participante y lección	100
Figura 46 Mapa de calor de métricas emocionales participante y lección.....	101
Figura 47 Medición de tiempo participante y lección.....	101
Figura 48 Resultados participante y lección.....	102
Figura 49 Grupo de registro de emociones participante, lecciones y actividad.....	103
Figura 50 Distribución Unificada de Métricas Emocionales participante, lecciones y actividad	104
Figura 51 Distribución Superpuesta de Métricas Emocionales participante, lecciones y actividad.....	104
Figura 52 Medición de tiempo participante, lecciones y actividad	105
Figura 53 Resultados participante, lecciones y actividad.....	105
Figura 54 Grupo de registro de emociones participante, lecciones, actividad y subactividad.....	106
Figura 55 Distribución Unificada de Métricas Emocionales participante, lecciones, actividad y subactividad	106
Figura 56 Distribución Superpuesta de Métricas Emocionales participante, lecciones, actividad y subactividad	107
Figura 57 Medición de tiempo participante, lecciones, actividad y subactividad	108
Figura 58 Resultados participante, lecciones, actividad y subactividad	108

Índice de Tablas

Tabla 1 Lecciones seleccionadas del curso de portugués.....	61
Tabla 2 Agrupación y clasificación de actividades	62
Tabla 3 Subactividades de la actividad de selección de opción	63
Tabla 4 Definición de resultados de preguntas.....	71
Tabla 5 Explicación archivos EDaLI.....	73
Tabla 6 Configuración de algoritmos de clustering	82
Tabla 7 Mejores configuraciones de clustering emocional para lección 1	110
Tabla 8 Clústeres generados por las mejores configuraciones de clustering emocional para lección 1	111
Tabla 9 Mejores configuraciones de clustering emocional para lección 2	111
Tabla 10 Clústeres generados por las mejores configuraciones de clustering emocional para lección 2	112
Tabla 11 Mejores configuraciones de clustering emocional para lección 3.....	113
Tabla 12 Clústeres generados por las mejores configuraciones de clustering emocional para lección 3	114
Tabla 13 Mejores configuraciones de clustering emocional para lección 4.....	114
Tabla 14 Clústeres generados por las mejores configuraciones de clustering emocional para lección 4	115

Índice de Ecuaciones

Distancia Euclidiana (1).....	51
Alineación rápida global de núcleos (2).....	53

Capítulo 1

Introducción

Durante la última década, el aspecto emocional de los estudiantes ha tomado importancia en el proceso de aprendizaje en distintas áreas como la ciencia, tecnología, ingeniería y matemáticas (STEM) e Idiomas, entre otras. Esto, ha dejado en evidencia un gran número de estudios en el campo educativo, que comprueban su influencia e impacto positivo en dicho proceso (King & Chen, 2019a; Tyng et al., 2017). De igual manera, se presentan situaciones donde los alumnos evidencian falta de interés y motivación durante las actividades de aprendizaje que disponen los centros educativos, una de estas áreas es el campo de aprendizaje en segunda lengua, donde según (Chefneux, 2018), los estudiantes presentan una disminución gradual de su motivación de acuerdo con factores como las actividades realizadas y el tipo de materiales utilizados. Sin embargo, recientemente la tecnología cumple un rol relevante en este aspecto, dado que, al ser utilizadas como medio para llevar a cabo el desarrollo de actividades de aprendizaje, se ha evidenciado un aumento en el interés presentado por los estudiantes durante la ejecución de estas tareas (Tarng et al., 2015; Zhu et al., 2017). De igual manera, de acuerdo con (Zhou, 2020a), el uso de aplicaciones móviles en el área de adquisición de segunda lengua proporciona una gran cantidad de actividades de aprendizaje, de tal forma que, sus barreras de aprendizaje, tensiones y ansiedades se reducirán en gran medida, lo que se traducirá en un aumento significativo de la motivación, el interés y el compromiso de los estudiantes. No obstante, algunos de los métodos de medición emocional utilizados en estos estudios pueden carecer de confiabilidad, ya que hacen uso de instrumentos de recolección de datos tradicionales, que en algunas situaciones no logran capturar realmente las emociones del alumno.

Por otro lado, durante los últimos años, de acuerdo con (Gañán et al., 2017) al investigar el procesamiento y visualización del proceso de aprendizaje, surge el concepto de Learning Analytics, el cual se puede ver como la medición, recopilación, análisis y reporte de datos de alumnos en el contexto educativo (Long & Siemens, 2011). Es así que, han surgidos estudios donde se pretende incluir en este proceso, la recopilación de métricas emocionales en entornos de aprendizaje. Sin embargo, por lo general, la adquisición de estos datos, se realiza mediante instrumentos como los cuestionarios,

entrevistas y encuestas, que según (Debois, 2019; Noroozi et al., 2020; Vlahovic et al., 2022), estos métodos auto informados pueden revelar las intenciones declaradas de aprender de los alumnos y sus creencias sobre sí mismos como alumnos, tales percepciones a menudo no coinciden con lo que realmente sucede durante los procesos de aprendizaje, así como se puede generar distorsiones en las respuestas socavando su validez, incluso se podría no capturar en su totalidad las emociones de la persona encuestada. Lo cual, puede afectar la confiabilidad y veracidad de los modelos de Learning Analytics. No obstante, también se presentan algunos estudios como (Barrón Estrada et al., 2020; Liu et al., 2022), donde se capturan las emociones mediante reconocimiento de expresiones faciales, diálogo de personas, identificación de sentimientos a partir de texto, e incluso, a partir de signos vitales mediante sensores. Sin embargo, los estudios a partir de sensores no son comunes, así como el uso de datos obtenidos a partir de la actividad cerebral de los participantes, como por ejemplo en (Xu et al., 2018), donde los autores utilizan una interfaz cerebro computadora para capturar densidad espectral de potencia a partir de actividad cerebral, durante el desarrollo de productos matriciales y solución de problemas de lógica matemática, demostrando que, la banda Theta y Alpha disminuyen con el aumento del nivel de dificultad de la tarea cognitiva, sin embargo, en este estudio no se relaciona el aspecto emocional de los participantes.

De acuerdo con lo anterior, la presente investigación tiene como objetivo plantear un modelo de Learning Analytics que relacione y procese métricas emocionales, obtenidas a partir de la actividad cerebral capturada mediante interfaces cerebro-computadora. Todo esto a partir de la interacción de alumnos con aplicaciones móviles de aprendizaje en segunda lengua, con el propósito de evaluar la exposición a recursos, actividades y ejercicios expuestos en aplicaciones móviles utilizadas en este contexto. Lo anterior, se pretende llevar a cabo, mediante una metodología de investigación cuasiexperimental, la cual permita la caracterización de aplicativos móviles de aprendizaje en temáticas de segunda lengua, la adquisición de las métricas, la definición e implementación de técnicas de procesamiento, sus relaciones y, por último, la validación del modelo de acuerdo con un caso de estudio establecido.

1.1 Planteamiento de investigación

1.1.1 Planteamiento del problema

De acuerdo con (Dörnyei, 2019) uno de los principales problemas en el aprendizaje de segunda lengua es la desmotivación y falta de interés. Adicionalmente, en el campo del aprendizaje de lenguas extranjeras, según (Chefneux, 2018), los estudiantes generalmente

comienzan un curso de aprendizaje de segunda lengua con un alto nivel de motivación; sin embargo, disminuye gradualmente, donde uno de los factores que desencadena esta situación son el tipo de actividades realizadas y los materiales de enseñanzas utilizados.

Por otra parte, según un estudio realizado por (Hao et al., 2019), donde se implementó una aplicación móvil para llevar a cabo actividades de aprendizaje de vocabulario de inglés, evaluando su diseño, mediante entrevistas, observación y encuestas. Se obtuvo como resultado que, el uso de la aplicación mejoró el aprendizaje del idioma, además de, promover actitudes positivas hacia el aprendizaje de inglés como lengua extranjera. Además de esto, en el campo del aprendizaje de segunda lengua, de acuerdo con un estudio realizado por (Viberg et al., 2020), se implementó un aprendizaje autorregulado por medio de una aplicación móvil para fomentar habilidades de aprendizaje de segunda lengua, en este caso idioma japonés. Los resultados de este estudio exponen que, el uso de esta plataforma aumentaba su compromiso, interés y motivación durante el aprendizaje. De los estudios anteriores, se podría inferir que, en algunos casos, uno de los tantos factores que generan desinterés y desmotivación en los estudiantes puede ser el escaso uso de tecnologías, volviendo las sesiones de aprendizaje poco interactivas y participativas. Adicionalmente, de acuerdo con (Casas & Restrepo, 2019) al utilizar tecnología en estos campos, se ha presentado un aumento del interés a medida que transcurre la actividad. No obstante, como lo expresa (Lehtamo et al., 2018), en esta área hay una falta de medidas validadas para estudios longitudinales intensivos, por lo tanto, se requiere afinar los métodos de validación emocional presentados en estos estudios, dado que por lo general se tratan de encuestas, entrevistas u observación.

Por otra parte, el rol de las emociones en el proceso de aprendizaje se ha convertido en un tema relevante en la comunidad científica. Dado que, de acuerdo con (King & Chen, 2019b), las emociones estimulan la atención de los alumnos y desencadenan el proceso de aprendizaje, afectando lo que se aprende y lo que se retiene. De esta forma, es relevante poder analizar este aspecto emocional en el proceso de aprendizaje. Es así como en el campo de Learning Analytics se presentan estudios como (Gerbeth et al., 2022; Gibson, 2017; Hoemann et al., 2020; Roberts et al., 2017), donde se recopilan datos emocionales y de aprendizaje de forma implícita y explícita. La forma implícita se basa en el seguimiento y captura automática de datos, a partir de la interacción del usuario con su entorno, y la forma explícita se basa en cuestionarios y encuestas. Estos instrumentos según (Sarica et al., 2013), presentan en sus desventajas el bajo nivel de confiabilidad de los datos recolectados, proporcionando incertidumbre en la información que se obtiene en este tipo de procesos. Adicionalmente, de acuerdo con (Noroozi et al., 2020), si bien los datos auto informados pueden revelar las intenciones declaradas de aprender de los alumnos y sus

creencias sobre sí mismos como alumnos, tales percepciones a menudo no coinciden con lo que realmente sucede durante los procesos de aprendizaje.

Como se ha mencionado anteriormente y como lo expone (Hayat et al., 2020; Loayaza, 2015), las emociones se consideran un factor significativo asociado directa o indirectamente con los logros de los alumnos, satisfacción, motivación y consecuentemente, el rendimiento académico. En este orden de ideas, de acuerdo con autores como (Ji et al., 2022; Wang & Bailly, 2015) las emociones como el compromiso, que expone un estudiante es fundamental para el éxito de cualquier proceso educativo, incluido el aprendizaje de idiomas. Por lo tanto, de acuerdo a lo anterior se podría inferir que, si el alumno presenta falta de interés y motivación en sus actividades escolares, es probable que no logre desarrollar la competencia involucrada en una actividad de aprendizaje específica. Adicionalmente, al realizar la recolección de información emocional de forma explícita, haciendo uso de cuestionarios y encuestas, donde según (Debois, 2019), se pueden presentar respuestas deshonestas, que no expresen las emociones verdaderas que experimentan los estudiantes. Además, de acuerdo con (Vlahovic et al., 2022), el problema de las medidas subjetivas como las emociones o percepciones que son auto informadas por los participantes, pueden presentar distorsiones, socavando su validez. Por lo tanto, los modelos de Learning Analytics tienen como base, datos poco confiables, presentando un posible escenario donde estos modelos no sean totalmente asertivos o veraces.

Finalmente, gracias al impacto positivo en la educación generado por el avance y popularidad de las tecnologías de la información y las comunicaciones (Dwivedi et al., 2018), se puede llegar a establecer un modelo de Learning Analytics para realizar evaluación emocional de recursos o actividades expuestas en aplicaciones móviles afines al desarrollo de tareas de aprendizaje de segunda lengua. Este modelo podría relacionar y procesar métricas emocionales asociadas al proceso de desarrollo de una actividad de aprendizaje, deducidas a partir de la captura de la actividad cerebral de una persona mediante interfaces cerebro-computadora. Lo anterior, podría contemplarse como punto de partida y valor agregado para aumentar la confiabilidad en este tipo de procesos.

1.1.2 Formulación del problema

A continuación, se presenta, la pregunta que define el problema y guía esta investigación.

¿Cómo relacionar y procesar métricas emocionales para plantear un modelo de learning analytics, a partir de la interacción de estudiantes con aplicaciones móviles de aprendizaje en segunda lengua?

1.1.3 Sistematización del problema

Partiendo de la pregunta alusiva a la formulación del problema, se plantean sub-preguntas que, mediante su solución, contribuyen a la solución global de esta y permiten identificar y establecer la metodología de la investigación.

- ¿Cómo realizar la caracterización de aplicaciones móviles existentes, utilizadas para llevar a cabo aprendizaje de segunda lengua?
- ¿Cómo capturar métricas emocionales a partir de la interacción de estudiantes con aplicaciones móviles de aprendizaje en segunda lengua?
- ¿Cómo relacionar y procesar métricas emocionales derivadas del desarrollo de una actividad de aprendizaje de segunda lengua para evaluar la exposición a estos recursos en aplicaciones móviles?
- ¿Cómo validar el modelo de learning analytics aplicado en un caso de estudio a partir de la aplicación móvil seleccionada?

1.2 Objetivos

1.2.1 Objetivo General

Diseñar e implementar un modelo de learning analytics relacionando y procesando métricas emocionales para evaluar la exposición a recursos en aplicaciones móviles para aprendizaje en segunda lengua.

1.2.2 Objetivos Específicos

- Caracterizar aplicaciones móviles existentes utilizadas para el aprendizaje de segunda lengua.
- Definir e implementar mecanismos para la captura de métricas emocionales en aplicaciones móviles referentes a la enseñanza de una segunda lengua.
- Representar conceptualmente la relación y procesamiento entre variables emocionales derivadas del desarrollo de una actividad de aprendizaje, para

evaluar la exposición a recursos en aplicaciones móviles de aprendizaje de segunda lengua.

- Validar el modelo de learning analytics propuesto haciendo uso de una aplicación móvil para el aprendizaje de segunda lengua como caso de estudio.

1.3 Justificación

1.3.1 Justificación Teórica

Basado en una revisión de literatura realizada por (Wong & Li, 2019) en una ventana de tiempo de 2011 a 2020 se observó que, en el campo de Learning Analytics la recopilación de datos relacionados con emociones y percepciones es poco frecuente. Adicional a esto, Wong también expone que, uno de los retos que se presenta en este campo, es la cantidad de variables y la combinación, relación e integración entre ellas.

Por otra parte, como se ha expresado con anterioridad, en la mayoría de los estudios de Learning Analytics donde se toman en cuenta las emociones, técnicas como las entrevistas, autoinformes y observaciones, son las más frecuentes (Noroozi et al., 2020; F. Zhang et al., 2022). No obstante, de acuerdo con (Azevedo et al., 2017; Seng et al., 2019), en algunas investigaciones se intenta realizar la identificación y captura de emociones mediante reconocimiento de expresiones faciales, speech data y análisis de texto. Sin embargo, como lo menciona (Noroozi et al., 2020), son escasos los estudios enfocados en el uso de Learning Analytics que tengan como fuente de datos emocionales la actividad cerebral de una persona, la cual se puede capturar mediante interfaces cerebro-computadora.

Con base en lo expuesto anteriormente, esta investigación pretende definir un modelo de Learning Analytics, relacionando, procesando e integrando variables emocionales afines al desarrollo de una tarea de aprendizaje, deducidas a partir de la captura de la actividad cerebral de los estudiantes, mediante interfaces cerebro-computadora.

1.3.2 Justificación Metodológica

De acuerdo con un estudio realizado por el ministerio de tecnologías de la información y las comunicaciones (MinTIC) de Colombia, durante los últimos ocho años el gobierno nacional ha reducido la brecha digital en educación en un 83% (MinTIC, 2018), brindando mayor accesibilidad a computadores a los niños de las distintas entidades educativas del país. Con base en lo anterior y en declaraciones de la organización para la

cooperación y desarrollos económicos (OECD) (MinTIC, 2017), se logran identificar propuestas que pueden afirmar que, el gobierno colombiano se preocupa por la calidad de la educación, buscando, analizando y promoviendo entornos educativos más innovadores y efectivos. Adicionalmente, en Colombia desde 1994, en la Ley General de educación se reconoció la importancia de aprender una lengua extranjera y de igual manera, el Ministerio de Educación ha lanzado iniciativas como el Programa Nacional de Bilingüismo 2014-2019, la ley de bilingüismo 1651 de 2013 y el programa nacional de inglés (PNI) 2015-2025. Por lo tanto, a través de los últimos años, el gobierno nacional ha pretendido promover el aprendizaje en una segunda lengua.

Adicionalmente, de acuerdo con (Ifenthaler, 2017), Learning Analytics presenta para las entidades gubernamentales beneficios como: comparación entre instituciones, análisis de rendimiento, impacto en la toma de decisiones organizacionales y el desarrollo puntos de referencia. Además, por medio de Learning Analytics las instituciones pueden realizar monitoreo, análisis y pronóstico de procesos de aprendizaje, además de evaluar y optimizar los recursos presentados. A partir de lo anterior, se puede proyectar un plan de prueba piloto en alianza con el ministerio de educación y ministerio de las tecnologías de la información y las comunicaciones, con el propósito de realizar la implementación y validación del modelo.

Por otro lado, al diseñar un modelo de Learning Analytics que procese métricas emocionales determinadas a partir de la actividad cerebral, puede ser el punto de partida, para poder realizar estudios futuros, con el objetivo de involucrar, relacionar e integrar distintos tipos de variables como, las sociales, las psicológicas, las demográficas, entre otras.

1.3.3 Justificación práctica

Durante los últimos años, autores como (Huber & Bannert, 2022; Ji et al., 2022; Loderer et al., 2020; Seli et al., 2016; Tyng et al., 2017), han realizado estudios donde se afirma que, las emociones estimulan la atención e influyen en el proceso de aprendizaje, afectando lo que se aprende y se retiene. Además, se han presentado numerosos estudios en una variedad de disciplinas como neurociencia, educación y psicología, revelando que las emociones juegan un papel importante en el proceso de aprendizaje (King & Chen, 2019a). En este mismo orden de ideas, según (Shao et al., 2020; Smith Lesley and King, 2018) expresa que, recientemente ha crecido el interés en los aspectos emocionales en el aprendizaje de segunda lengua, a medida que los investigadores reconocen el papel crucial

de las emociones y su rol en la adquisición de una segunda lengua. Además de esto, de acuerdo con (Zhou, 2020a), el uso de aplicaciones móviles en el área de aprendizaje de segunda lengua proporciona una gran cantidad de actividades, de tal forma que, sus barreras de aprendizaje, tensiones y ansiedades se reducirán en gran medida, lo que se traducirá en un aumento significativo de la motivación, el interés y el compromiso de los estudiantes.

De acuerdo con (Tempelaar et al., 2020), la era digital trajo Learning Analytics con el objetivo de avanzar en la teoría de aprendizaje, alimentando los modelos a partir de la recopilación sistemática de datos de seguimiento mediante la interacción del estudiante con su entorno y datos emocionales basados en encuestas, para describir los comportamientos de aprendizaje. No obstante, de acuerdo con (Noroozi et al., 2020; Vlahovic et al., 2022), los datos recopilados mediante métodos de recopilación emocional y de percepción auto informados como los cuestionarios, encuestas y entrevistas, pueden presentar distorsiones, socavando su validez o incluso, no coincidir con lo que realmente sucede durante el proceso de aprendizaje.

Al intentar aumentar la confiabilidad en el proceso de adquisición de los datos emocionales y aptitudinales de los estudiantes, mediante la captura de la actividad cerebral, se puede tener una base sólida y objetiva para generar seguimiento en temáticas educativas con el propósito de apoyar la toma de decisiones en un contexto educativo.

Finalmente, es así como a partir de los componentes teórico, metodológico y práctico, expuestos anteriormente, esta propuesta de investigación tiene como finalidad llevar a cabo un modelo de Learning Analytics, que relacione, integre y procese métricas emocionales, derivadas a partir de la actividad cerebral, capturada mediante el uso de interfaces cerebro-computadora. Lo anterior, con la intención de obtener datos emocionales objetivos durante el desarrollo de una actividad de aprendizaje de segunda lengua, a partir de la interacción de estudiantes con aplicaciones móviles alusivas al aprendizaje de segunda lengua, enmarcadas dentro del proceso de aprendizaje, respaldando la premisa de la OECD de promover entornos educativos más innovadores. Este modelo de Learning Analytics tendría como propósito, evaluar la exposición del estudiante ante recursos durante el aprendizaje de una segunda lengua mediante aplicaciones móviles.

1.4 Hipótesis

Mediante técnicas de minería de datos educativos e inteligencia artificial se puede plantear un modelo de Learning Analytics que procese métricas emocionales para evaluar la exposición a recursos en aplicaciones móviles de aprendizaje en segunda lengua.

1.5 Limitaciones

1.5.1 Limitación de Licencias de Software

A lo largo de este estudio, se deben utilizar plataformas, aplicaciones e incluso consumir APIs de terceros. Por ejemplo, la aplicación móvil para el aprendizaje de segunda lengua, así como, el dispositivo y la captura de las métricas emocionales definidas a lo largo de la investigación. Sin embargo, en algunos casos se puede presentar el escenario donde, a partir de versiones o licencias libres no se obtengan las mismas prestaciones y características que con se podrían obtener con versiones pagas, lo cual podría limitar nuestro proyecto.

1.5.2 Limitación de población

Durante la fase experimental del estudio, puntualmente en la definición y aplicación del caso de estudio, se pueden presentar limitaciones frente a la población o número de personas que participen. Lo anterior, dado que, con el fin de capturar las métricas emocionales mediante interfaces cerebro-computadora y su interacción con la aplicación móvil de segunda lengua, es indispensable el contacto físico entre los participantes y los autores de este estudio. Y debido con la pandemia actual generada por el COVID-19, la reunión con un grupo grande de participantes se verá limitada, por seguridad de los participantes y de los autores.

Capítulo 2

Panorama y revisión de literatura

2.1 Aplicaciones móviles en educación

Actualmente, según (Hashim et al., 2018; Kamphuis et al., 2014) el avance tecnológico ha llevado a reformas en el sistema de enseñanza y de aprendizaje en el aula, centrándose en entornos educativos para la práctica de tareas interactivas. Es así como, el autor (Gaspar et al., 2019) expone que, las capacidades y posibilidades de poder crear experiencias educativas haciendo uso de dispositivos móviles han crecido y evolucionado durante la última década. Lo anterior, presentando numerosos estudios aplicando estas tecnologías en el campo educativo; como lo presenta (C. H. Chen et al., 2019), donde presenta un método de aprendizaje mediante mapas conceptuales multidimensionales basados en Realidad Aumentada, y haciendo uso de dispositivos móviles, aplicado a niños de una escuela primaria en Taiwán, teniendo un grupo de control; como resultado se obtuvo que, el grupo que utilizó el método propuesto se desempeñó significativamente mejor que el otro grupo, además se concluyó que el grupo experimental presentó mayor motivación durante el desarrollo de la actividad.

Adicionalmente, se encuentran estudios como (Berns et al., 2016) donde los autores presentan una aplicación móvil híbrida basada en juegos, que combine la oportunidad de aprendizaje individual y colaborativo. Este estudio presentaba como objetivos, medir la motivación del alumno, la utilidad percibida y el valor agregado de las aplicaciones híbridas basadas en juegos; y determinar su impacto en el aprendizaje de idiomas. Los datos cualitativos y cuantitativos obtenidos sugieren que, la aplicación híbridas basadas en juegos que combinan diferentes recursos de aprendizaje motivan a los estudiantes, estimulan la utilidad percibida y el valor agregado, además de, satisfacer de mejor manera las necesidades de aprendizaje de idiomas extranjeros. Asimismo, en un estudio realizado por (Campbell & Geertsema, 2017) donde se explora una aplicación móvil para mejorar la

pronunciación en el aprendizaje de inglés como segunda lengua en regiones de Asia Pacífico, los autores concluyen que, debido al avance tecnológico hay varias formas de avanzar en el uso de aplicaciones móviles para el aprendizaje, y las investigaciones sugieren que utilizar estas tecnologías aumenta las posibilidades pedagógicas en esta área.

2.2 Aplicaciones móviles en aprendizaje de segunda lengua

En este orden de ideas referentes como (Zhou, 2020b) han llevado a cabo un estudio donde, se realiza una revisión sistemática de estudios sobre el aprendizaje de idiomas asistido por dispositivos móviles en la enseñanza del chino como lengua extranjera durante el periodo de 2007 a 2019. A partir de esta revisión, han encontrado que varios resultados apuntan a que la aplicación de estas tecnologías expone un impacto afectivo y motivacional en los estudiantes. Adicionalmente, algunos de los estudios revisados, revelan actitudes positivas de los estudiantes hacia el uso de aplicaciones móviles para mejorar el dominio del chino. Finalmente, el autor Zhou, presenta que los estudiantes tienden a tener una actitud generalmente favorable hacia la usabilidad, efectividad y satisfacción de los teléfonos inteligentes y las aplicaciones en el aprendizaje de idiomas extranjeros. Además, cuando se les proporciona una gran cantidad de actividades de aprendizaje móvil, sus barreras de aprendizaje, tensiones y ansiedades se reducirán en gran medida, lo que se traducirá en un aumento significativo de la motivación, el interés y el compromiso.

En relación con estas aplicaciones móviles, de acuerdo con (Lotherington, 2018), actualmente algunas de las aplicaciones más populares son Babbel, Busuu, Duolingo, y Memrise. En este orden de ideas, Babbel tiene un enfoque único, con el propósito de que las personas conversen los antes posibles y desde la primera lección se pretende exponer actividades para que se comuniquen con el nuevo idioma a aprender (Lotherington, 2018). Una de las aplicaciones mencionadas es Babbel (www.babbel.com), la cual se enfoca directamente en construir habilidades conversacionales y de habla (Palmiter Bajorek, 2017). Adicionalmente, de acuerdo con (Palmiter Bajorek, 2017) las lecciones de Babbel son más desafiantes que las de muchos otros programas, además de, presenta un sistema de reconocimiento de speech único y poderoso. Además, presenta la posibilidad de aprender 14 idiomas entre ellos inglés, español, alemán, francés y portugués. Otra aplicación es Duolingo (www.duolingo.com), la cual es una plataforma de aprendizaje de idiomas en línea que se lanzó en 2012 y ofrece cursos en 27 idiomas diferentes del mundo (Teske, 2017). Por otra parte, se encuentra la aplicación Busuu (www.busuu.com), la cual tiene como premisa que los usuarios adquieran habilidades lingüísticas como hablar, leer, escribir y escuchar, a partir de componente de vocabulario y gramática (Nushi &

Jenabzadeh, 2016). De igual manera, otra aplicación para aprendizaje de idioma es Memrise (www.memrise.com), la cual está especializada en el aprendizaje de vocabulario con un sistema de revisión algorítmica (X. Zhang, 2019).

2.3 Learning Analytics

Por otro parte, históricamente Learning Analytics (LA) surge de la investigación sobre el procesamiento y visualización del conocimiento en el proceso de aprendizaje (Gañán et al., 2017) y debido al aumento y aparición de grandes volúmenes de datos, los estudios sobre LA han presentado un aumento significativo. Autores como (Kew et al., 2018) han hecho uso de plataformas de E-learning y LA, explorando el nivel de motivación de los estudiantes en el aprendizaje electrónico en instituciones de educación superior en Tailandia, utilizando una encuesta de motivación de cuatro dimensiones (ARCS): atención, relevancia, confidencialidad y satisfacción, obteniendo un valor promedio de motivación del 3.69 denominado un nivel medio alto.

Así mismo, en un estudio realizado por (Papamitsiou & Economides, 2014), se llevó a cabo revisión de literatura de LA y Educational Data Mining (EDM) contemplando un total de 40 estudios, donde se determinó que el segundo método de minería de datos más utilizado es Clustering; además la mayoría de estos estudios tienen como enfoque el modelamiento del comportamiento de los estudiantes. Finalmente, en este trabajo se plantea las oportunidades y debilidades de investigación en LA y EDM. Adicionalmente, se han realizado estudios por (Aguilar, 2018), donde se examina el nexo entre Learning Analytics y Big data, concluyendo que, estos dos conceptos tienen una alta relación, puesto que, en el proceso de análisis del gran volumen de datos de aprendizaje, se cuenta con distintos tipos de datos provenientes de diferentes fuentes, siendo información estructurada y no estructurada, por lo que, Big data juega un papel importante en el procesamiento de esta información.

Además de esto, autores como (Hussain et al., 2019) presentan un estudio con el objetivo de predecir las dificultades individuales de los estudiantes en una sesión e-learning, mediante técnicas de machine learning considerando variables como tiempo promedio, número total de actividades, tiempo promedio de inactividad, número promedio de pulsaciones y las calificaciones de los estudiantes en cada sesión. Este estudio obtuvo como resultado un mayor nivel de precisión en los algoritmos Artificial Neural Network (ANN) y Support Vector Machine (SVM), comparados con otros, concluyendo que se puede mejorar la enseñanza, el aprendizaje y éxito de los estudiantes. En (Saqr et al., 2018) se lleva a cabo un estudio donde se presenta la extracción de datos del módulo del foro del sistema de gestión de aprendizaje (LMS) del curso de cirugía en la Universidad de Qassim,

utilizando análisis de redes sociales, para calcular la correlación del rendimiento de los estudiantes, y predecir su rendimiento haciendo uso de regresión lineal. Los resultados de los coeficientes de correlación, la regresión lineal y la regresión logística indican que el rol de un estudiante en la transmisión de información y la fuerza de red de ese estudiante, pueden ser usados como indicadores de desempeño en distintos entornos.

2.4 Las emociones y la educación

Por otro lado, durante los últimos años, la tarea de comprender y apoyar los procesos emocionales involucrados en el aprendizaje basado en tecnologías se ha convertido en un objetivo primordial en diferentes comunidades de investigación (Loderer et al., 2018). Lo anterior dado que, según (Murphy et al., 2019), las diferentes emociones que experimentan los alumnos afectan sus experiencias y aptitudes hacia el aprendizaje, teniendo una influencia directa sobre este. Según (Shao et al., 2020), las emociones juegan un papel vital en el aprendizaje en general y en el aprendizaje de lenguas extranjeras (LE) en particular. Las emociones positivas como el disfrute, la esperanza y el orgullo pueden promover la motivación de los estudiantes para aprender, la atención, el uso de estrategias de aprendizaje profundo y el rendimiento académico. En cuanto a la detección y captura de emociones en distintos campos, se pueden identificar algunos grandes métodos, como el reconocimiento de expresiones faciales, respuesta de cuestionarios y encuestas, y a partir de la captura de la actividad cerebral.

Como primera parte, mediante el reconocimiento de expresiones se tienen estudios como (Niforatos & Karapanos, 2015), donde los autores presentan una aplicación móvil denominada EmoSnaps, la cual captura imágenes discretas de las expresiones faciales de una persona a lo largo del día, con el propósito de recordar sus emociones momentáneas, dentro de su caso de estudio, comprobaron la capacidad de la EmoSnaps para capturar las experiencias de los usuarios al interactuar con diferentes aplicaciones móviles, obteniendo en general resultado que proporcionan confianza sobre la validez de las imágenes utilizadas como memoria para recordar las emociones. Igualmente, (Sahla & Senthil, 2016) realizan un estudio donde, presentan un método de Deep Learning para el reconocimiento de emociones dentro del aula de clase, a partir de las expresiones faciales de los estudiantes. De este estudio, se obtuvo que el método propuesto presentó un porcentaje de eficiencia en tiempo real de aproximadamente 81.92%.

Por lo general, la herramienta más utilizada para la obtención de emociones en distintos escenarios son los cuestionarios y las encuestas, como lo expresa (Bielozorov et al., 2019). De acuerdo con lo anterior, se presentan estudios como (Lehtamo et al., 2018), donde pretenden determinar si es posible encontrar una conexión entre las emociones

académicas y la retención en el área de física. Durante la experimentación del estudio, se tuvieron un total de 36 estudiantes con un promedio de edad de 16 años y sus emociones se midieron con sus celulares respondiendo cuestionarios acerca de su estado emocional durante el desarrollo de las clases, concluyendo que, las emociones pueden ser un indicador que proporcione valor en el entendimiento del comportamiento de los estudiantes. Además de esto, en un estudio realizado por (Klonsky et al., 2019) se describe el desarrollo y las propiedades psicométricas del cuestionario de emoción multidimensional (MEQ), diseñado para cubrir necesidades como la reactividad emocional (positiva y negativa), su componente de frecuencia, intensidad y persistencia y por último, emociones discretas. Esta prueba fue aplicado a un total de 168 estudiantes universitarios durante 3 semanas, obteniendo resultados que respaldan la confiabilidad y validez de este cuestionario. La motivación e interés ha sido un punto enfático para evaluar el impacto de la tecnología educativa en el aprendizaje; sin embargo, la forma de evaluación presentada, como se ha expuesto en las investigaciones anteriores, ha sido mediante la implementación de encuestas o cuestionarios, que evalúan la disposición emocional al realizar las actividades, dejando una gran parte a la subjetividad como se aborda en algunos casos de pruebas de usabilidad; tal es el caso de (Gaona-García et al., 2016) donde se presenta un sistema de búsqueda para el acceso a objetos de aprendizaje académico y repositorios, como un marco visual, mostrando sus resultados a través de una prueba que evalúa el uso de la plataforma para la búsqueda de metadatos.

Otro de los métodos utilizados, pero no tan común para la identificación de emociones, es mediante la actividad cerebral capturada mediante interfaces cerebro-computadora. Es allí donde por medio de dispositivos no invasivos con electrodos miden la actividad cerebral de una persona. Por ejemplo, en un estudio realizado por (Rashid et al., 2019), llevaron a cabo la captura de electroencefalogramas (EEG) durante la resolución de problemas matemáticos y en estados de relajación. Lo anterior con el propósito de realizar la clasificación de estas señales mediante técnicas de machine learning como: Linear Discriminant Analysis (LDA), Support Vector Machine (SVM) y K-Nearest Neighbors (K-NN), obteniendo un rendimiento del 100% mediante SVM y K-NN. De igual manera, se cuentan con estudios realizados por (Strmiska & Koudelkova, 2018), donde se realiza el análisis de métricas de rendimiento (compromiso, relajación, interés, concentración y estrés), capturadas mediante un Emotiv Epoc+ el cual es una interfaz cerebro-computadora. La obtención de estos datos se realizó durante la ejecución de un examen de matemáticas, una sesión de rehabilitación y durante la visualización de un partido de fútbol, observando que, durante las tres situaciones presentadas, estas métricas presentan un comportamiento distinto. En el campo de Learning Analytics, emociones y aprendizaje de segunda lengua, se presenta el estudio (Ez-zaouia et al., 2020), donde los autores

presentan EMODASH, el cual es un dashboard interactivo que respalda el proceso de retrospectiva de los tutores sobre las emociones de los alumnos en un entorno de aprendizaje por videoconferencia. A partir de esto, los tutores incorporaron más elementos afectivos en sus informes, lo que sugiere una mayor conciencia de las emociones de los alumnos.

2.5 Interfaces cerebro computadora en educación

En el tema de la evaluación de emociones por medio de sensores, es importante mencionar las Interfaces cerebro-computadoras, las cuales según (Jin et al., 2019), son dispositivos que permiten capturar la actividad cerebral mientras se interactúa con un escenario o se controlan dispositivos externos basados en patrones mentales. Por ejemplo, en un estudio realizado por (Holewa & Nawrocka, 2014), se utilizó un dispositivo BCI llamado Emotiv Insight, con el propósito de capturar y evaluar emociones o métricas de rendimiento como: compromiso, interés, excitación, concentración, estrés y relajación, en tareas con retroalimentación háptica. Obteniendo como resultado, que el compromiso y la relajación son emociones que podrían ser de utilidad para identificar situaciones demandantes. Por otro lado, en (Rodríguez et al., 2020), se realiza una caracterización emocional de estudiantes a partir de métricas emocionales recopiladas mediante un Emotiv Epoc, en un ambiente de realidad aumentada. Esta caracterización emocional se realiza aplicando técnicas de clustering. Como resultado se obtuvo que los grupos obtenidos presentan buena diferenciación en las tendencias de las diferentes métricas.

Como se ha mencionado anteriormente, una forma de poder capturar y analizar las emociones en entornos de aprendizaje, es por medio de señales vitales o señales emitidas por el cuerpo humano. En este camino existen las interfaces cerebro-computadora, las cuales son un sistema de comunicación en el que las señales, mensajes o comando producidos por la actividad cerebral se pueden traducir a dispositivos externos (Li et al., 2022). Su uso en el tema de emociones y aprendizaje se puede ver expuesto en un estudio realizado por (Rodriguez et al., 2022), donde se aplican técnicas de series de tiempo para la evaluación de emociones a partir de la interacción con un entorno inmersivo, estas emociones son capturadas mediante una interfaz cerebro computadora llamada Emotiv Epoc. Los resultados de este estudio muestran en el grupo de participantes una tendencia creciente promedio del 60% en su interés, compromiso, enfoque, relajación y estrés al interactuar con el entorno inmersivo. Además de esto, en (Xu et al., 2018) los autores presentan un análisis densidad espectral de potencia (PSD) medida a partir de un dispositivo BCI en un contexto educativo por medio de una plataforma de cursos en línea. A partir de ello, los participantes resuelven dos tareas, la primera consiste en dar solución

a un conjunto de productos de matrices, mientras que el segundo propone resolver problemas de lógica matemática. A partir de esto, los autores demuestran que la banda theta y Alpha disminuyen con el aumento del nivel de dificultad de la tarea cognitiva.

Capítulo 3

Desarrollo Metodológico

La Figura 1, presenta las fases de la metodología implementada para el desarrollo de este estudio.



Figura 1 Infografía de la metodología del estudio

A partir de la Figura 1, se evidencian claramente cuatro fases de este proyecto. La primera, está enfocada en la caracterización de aplicaciones móviles de aprendizaje de segunda lengua, donde se busca recopilar datos e identificar características de las distintas

aplicaciones de segunda lengua existentes en el mercado. Lo anterior, mediante revisión de literatura e interacción con las aplicaciones. Esto proporcionará herramientas para la selección de una aplicación de aprendizaje de segunda lengua, para el desarrollo del estudio.

Posteriormente, se presenta la fase de identificación y definición de métricas. Esta etapa, se centrará en la identificación de las métricas emocionales que pueden ser capturadas, y mediante que dispositivos y técnicas se pueden capturar. Finalmente, a partir de la información recopilada, se definirán las métricas y los mecanismos de recopilación.

Después, se abordará el diseño del modelo de Learning Analytics, tomando como punto de partida, las métricas definidas en la fase anterior. Durante esta fase, se identificarán las técnicas que se han implementado en los tipos de métricas definidas. Asimismo, se procederá definir el diseño del modelo a partir de estas técnicas, para posteriormente, ser implementado.

Finalmente, a partir de la caracterización de aplicaciones móviles de segunda lengua, la identificación y definición de métricas y, el diseño del modelo de Learning Analytics, se procede a la especificación minuciosa del caso de estudio. Por lo tanto, en esta etapa, definirá la aplicación móvil de aprendizaje de segunda lengua a utilizar, la especificación de métricas a recopilar y como se realizará este proceso. Y, por último, que análisis se realizará a partir del modelo de learning analytics definido. De esta forma, en secciones posteriores, se profundizará en la implementación del caso de estudio definido y en los resultados obtenidos, con su respectivo análisis.

3.1 Caracterización de aplicaciones móviles de aprendizaje de segunda lengua

Actualmente, de acuerdo con (Lotherington, 2018; Pegrum, 2019), dentro de las aplicaciones móviles de aprendizaje de segunda lengua más populares y utilizadas, se encuentran Babbel, Duolingo y Memrise. A partir de esto, a lo largo de esta sección, se recopilará información acerca de estas aplicaciones mencionadas previamente, con el propósito de identificar las características propias de las aplicaciones, tipos de ejercicios o actividades de aprendizaje expuestos y lenguajes disponibles en cada plataforma.

3.1.1 Babbel

Babbel es la aplicación de aprendizaje de idiomas con mayor éxito financiero del mundo, con más de 10 millones de suscripciones vendidas desde su lanzamiento en 2008 y millones de suscriptores de pago activos en todo el mundo. Esta aplicación está disponible

en iOS, Android y web, con contenido sincronizado en múltiples dispositivos. El método de Babbel permite a los estudiantes hablar un nuevo idioma en el mundo real, en situaciones de la vida real (Sporn et al., 2020). Adicionalmente, Babbel ofrece un gran número de cursos y lecciones en su curriculum y estos están alineados con los estándares de dominio de idioma presentado en el Marco Común Europeo de Referencia (MCER). De acuerdo con esto, Babbel ofrece más de 10.000 horas de contenido de aprendizaje en más de 60.000 lecciones. De esta forma, Babbel se estructura en cursos para principiantes, intermedios e independientes, que de acuerdo con el MCER estos niveles van desde A1(principiantes) hasta C1 (competentes) (Aromiekim, 2021).

En este orden de ideas, Babbel expone al público un total de 14 idiomas, donde sus lecciones están diseñadas para ser relativamente cortas y ser completadas en alrededor de 10 o 15 min. También, estas lecciones son diseñadas por expertos en idiomas con experiencia en pedagogía y teoría de adquisición de un segundo idioma y lingüística aplicada. Estos diseños, se enfocan en lecciones progresivas y contenidos modulares. Además, estos contenidos progresivos están estructurados de forma que, cualquier persona pueda acceder sin tener conocimiento previo del idioma (Loewen et al., 2020). Además, estos mismos autores, expresan que, por medio de las lecciones progresivas, a medida que avanzan en las lecciones, se va utilizando vocabulario y conocimiento previamente adquirido. Por otro lado, el contenido modular que presenta Babbel, es independiente y brinda a los alumnos oportunidades de centrarse en temas de interés, como comida, viajes o negocios. Adicionalmente, Babbel trabaja sobre la premisa de permitir a los usuarios hablar el idioma desde las primeras lecciones, en situaciones del mundo real (Sporn et al., 2020). En este orden de ideas, Babbel permite a los usuarios seguir cursos de idiomas interactivos. La aplicación ayuda a los estudiantes a dominar no solo las características gramaticales de los idiomas, sino también la comprensión auditiva y la pronunciación (Ibáñez-Arenós & Bort-Mir, 2020).

En cuanto a estructura de las lecciones, de acuerdo con una revisión de la aplicación realizada por (de Carvalho & de Carvalho, 2020), Babbel hace un amplio uso de imágenes como recurso para exponer conceptos y situaciones. Sin embargo, estas imágenes suelen ser fotografías que, de acuerdo a lo autores, proyecta esta aplicación hacía un público adulto. Además, exponen que la estructura de aprendizaje de Babbel es secuencial dado que no se pueden saltar módulos o atender de manera desordenada. También, sustentan que durante las primeras lecciones se han topado con ejercicios de escucha, repetición de palabras y de expresiones, y traducciones por medio de escritura u ordenamiento de palabras. De acuerdo con esto, Babbel adopta el uso del método audio-lingüístico para la enseñanza de lenguas extranjeras, ya que se centra en el uso de la lengua extranjera para

desarrollar primero las habilidades auditivas y orales y, por tanto, desarrollar otras habilidades lingüísticas como la lectura y la escritura. Adicionalmente, estos autores exponen que Babel presenta una cantidad significativa de actividades, vocabulario amplio y diversificado, progresión de contenidos, explicación de contenidos gramaticales (reglas, formalidades e informalidades) y uso de diálogos en situaciones cercanas a reales.

Desde otro punto de vista, los autores de (Garnes-Tarazona, 2018) exponen que, esta aplicación ofrece un formato de juego al inicio de cada lección, dado que se presenta al estudiante una lista de tres o cuatro palabras nuevas para repetir o escribir, y en actividades posteriores el estudiante aprende a emparejar estas palabras con conceptos. Cuando la respuesta dada por el participante es incorrecta, la aplicación muestra una luz roja que se convierte en verde cuando la respuesta es correcta, de esta manera el estudiante también tiene intentos para llegar a esa respuesta correcta. De acuerdo con esto, el estudiante acumula puntos después de cada pregunta acertada. Los autores de este estudio concluyen que Babel presenta ejercicios de repetición, ordenación de letras, ordenación de palabras en oraciones, traducciones, completar espacios en blanco, ejercicios de asociación entre palabras e imágenes, ejercicios de pronunciación y de completar diálogos orientados a situaciones reales.

Además de esto, a partir de (Aromiekim, 2021; Nushi & Eqbali, 2018), los autores exponen que en Babel cada lección se centrará en un determinado concepto o vocabulario, que se aprenderá mediante ejercicios que incluyen texto, audios e imágenes y se entrenará con pocas palabras y frases seleccionadas. Las lecciones se basan predominantemente en escenarios y se centran en diferentes situaciones cotidianas, como cenar, comer, describir acciones futuras. Además, concluyen que, el vocabulario y frases se usan de manera realista, por lo que, al aprenderlo, se puede usar con bastante rapidez en escenarios de la vida real. Esto, se ve reflejado en los ejercicios donde se presentan fragmentos de conversaciones que se deben completar.

Según (Bajorek, 2017) dentro de las ventajas que presenta Babel, está que tiene lecciones más desafiantes que otras aplicaciones y que posee un umbral y un sistema de ASR (Automatic Speech Recognition) mejor para sus ejercicios de pronunciación, dado que modela con mayor precisión la pronunciación de los estudiantes. Otra ventaja expuesta por (Aromiekim, 2021) es la inclusión de consejos explicando conceptos específicos relacionados con lo que se está aprendiendo en determinada lección. No obstante, dentro de sus limitaciones se encuentra que no todos los cursos se encuentran disponibles en todos los idiomas (Aromiekim, 2021), es decir si el idioma nativo es español y se quiere aprender ruso, pero este curso y sus explicaciones no se encuentran en español. Además de esto, para poder acceder a ciertas características se debe contar con el software de pago

(de Carvalho & de Carvalho, 2020). Sin embargo, este mismo autor indica que, a pesar de esta limitación la aplicación cumple de buena manera con lo propuesto por la enseñanza y aprendizaje de lenguas extranjeras, capacidad de hablar, escuchar, escribir y leer, que son habilidades esenciales para aprender un idioma.

3.1.2 Duolingo

Duolingo es la aplicación gratuita de aprendizaje de idiomas más descargada en la categoría de educación tanto en iTunes como en Google Play (Lotherington, 2018). Esta aplicación fue fundada por Luis Von Ahn y Severin Hacker en el año 2011 pero lanzada al público en 2012. De acuerdo con (Woods, 2017), Duolingo cuenta con 170 millones de usuarios, aunque las estadísticas sobre los usuarios no son claras, dado que quienes descargan la aplicación pueden no ser usuarios activos. Duolingo, varía la cantidad de lenguajes ofrecidas, por ejemplo, actualmente si se quiere aprender una nueva lengua utilizando el inglés como lenguaje base, puede presentar hasta 30 cursos, pero si se utiliza el español como lenguaje base, puede exponer alrededor de 10 cursos. Los cursos de Duolingo están alineados con el Marco Común Europeo de Referencia (MCER), un estándar internacional para el dominio del idioma. El MCER guía el desarrollo curricular centrándose en las funciones comunicativas, es decir, lo que los estudiantes pueden hacer realmente con un idioma, como pedir direcciones o pedir una taza de café (Jiang et al., 2021).

De acuerdo con (Tuncay, 2020) el método de Duolingo se basa en dos pilares fundamentales: el conductista y el constructivista. El conductista, emplea ejercicios de gramática y tareas de aprendizaje en un entorno de gamificación, con árboles de habilidades, barras de experiencia, objetivos, recordatorios, gráficos coloridos y notificaciones de respuestas correctas e incorrectas. Y, por otro lado, el constructivista fomenta una formación social de aprendizaje, a través de la interacción en una red que facilita la discusión en fotos, la formación de clubes de usuarios, redes sociales y eventos que toman lugar fuera de la aplicación.

De esta forma, Duolingo enseña idiomas en un entorno gamificado utilizando cuatro habilidades: leer, escuchar, hablar y escribir, las cuales brinda oportunidades para actividades multimodales como traducción, transcripción y habla. De esta manera, las principales tareas de Duolingo son: traducir proporcionando equivalencias lingüísticas entre idiomas, transcribir palabras u oraciones que se escuchan, hablar para pronunciar palabras y oraciones en voz alta, construir oraciones a partir de un conjunto de palabras, llenar espacios en blanco para completar oraciones, unir tarjetas con su correspondiente palabra, para la asociación de conceptos (Ahmed, 2016; Garnes-Tarazona, 2018). Según

(Bajorek, 2017) las actividades de Duolingo se podrían agrupar en categorías como: ejercicios de emparejamiento, ejercicios de escucha y habla. Sin embargo, con relación a los ejercicios donde el usuario debe pronunciar palabras o frases, los autores en (Palmiter Bajorek, 2017) dicen que, la tecnología implementada por Duolingo para realizar el reconocimiento de lo pronunciado por el estudiante es subdesarrollada, presentando diversas fallas, donde en algunas ocasiones se le pide al estudiante repetir la frase o palabra entre 2 a 3 veces.

En cuanto a la calificación de actividades, de acuerdo con (Karjo & Andreani, 2018) para cada desafío desarrollado por los alumnos pueden ver instantáneamente que respuestas fueron correctas e incorrectas. Donde, las respuestas correctas generan una retroalimentación con una frase alentadora en color verde y en caso de ser incorrecta, con una oración en color rojo; además cuando la respuesta es incorrecta, se le da al estudiante inmediatamente la respuesta correcta. Adicionalmente, según (Ahmed, 2016), durante las lecciones se presentan las actividades de forma secuencial y pueden ser resueltas de una manera rápida. Sin embargo, la lección se puede extender si el estudiante obtiene respuestas incorrectas. No obstante, es importante resaltar que, como lo menciona (Alm, 2021) Duolingo acepta una variedad más amplia de respuestas y pequeños errores, como errores tipográficos o acentos faltantes, que se corrigen sin marcar como errónea la respuesta.

De acuerdo con (Tuncay, 2020) una de las ventajas que presenta Duolingo, es la inclusión de robots en la plataforma, en forma de una interfaz de mensajes de texto, los robots ofrecen a los alumnos oportunidades basadas en tareas para participar en una discusión con la inteligencia artificial. Sin embargo, los temas de conversación son limitados y esta funcionalidad solo se encuentra disponible para algunos idiomas. Otra ventaja, es el uso de gamificación mediante la implementación de premios y recompensas, dado que esto ayuda a motivar e involucrar a los estudiantes, durante su proceso de aprendizaje o adquisición de un nuevo idioma.

Por otra parte, dentro de las desventajas de Duolingo se encuentra, la falta de un sistema de reconocimiento de habla automático o Automatic Speech Recognition (ASR) robusto para fortalecer sus actividades de pronunciación (Palmiter Bajorek, 2017). También (Redjeki & Muhajir, 2020) indica que, algunas de las oraciones utilizadas en la plataforma son poco naturales, y muchas de las lecciones presentan oraciones extrañas y poco prácticas. Además, estos mismos autores, expresan que es un buen enfoque que Duolingo enfatice en la comprensión auditiva, pero que las voces sintéticas generadas para la aplicación no son las mejores y este aspecto puede ser crítico, por ejemplo, en aprendizaje

de lenguajes como francés, dado que este es un lenguaje lleno de nasales, enlaces, verbos irregulares y palabras que suenan de una manera, pero se escriben diferente.

3.1.3 Memrise

Memrise es una aplicación para el aprendizaje de vocabulario, la cual se basa en la técnica de memoria de repetición espaciada, mediante el uso de tarjetas como ayuda a la memoria. La repetición espaciada es una técnica de aprendizaje que incorpora intervalos de tiempo cada vez mayores entre la revisión posterior del material aprendido en sesiones previas, con el fin de explorar el efecto de espaciamiento psicológico (Karjo & Andreani, 2018). De acuerdo con el anterior autor, la repetición espaciada comenzó a implementarse con soluciones de software de aprendizaje de idiomas asistido por ordenadores. Esta técnica fue utilizada por primera vez por Paul Pimsleur en 1967, que tenía el nombre de sistema de aprendizaje de idiomas Pimsleur. El método de Pimsleur se basaba en la repetición de instrucciones de audio. Sin embargo, el software de repetición espaciada que se usa en Memrise sigue el modelo del estilo manual de aprendizaje con tarjetas físicas, por lo tanto, los elementos a memorizar se ingresan en el programa como pares de preguntas y respuestas.

En adición a lo anterior, como se ha mencionado Memrise es una aplicación moderna de tarjetas de palabras que facilita la memorización de vocabulario a través de su sistema automático de repetición espaciada y el uso de estrategias de gamificación, que se conciben como “desarrollos recientes” de las aplicaciones. Según (Fathi et al., 2018) atrae a los estudiantes al recompensar su aprendizaje en forma de puntos, lo que se asemeja al aprendizaje de vocabulario en un juego. Todo esto, se supone que debe cumplirse en un entorno descontextualizado que en sí mismo podría ser desconcertante para los alumnos, ya que hay un sin fin de elementos de vocabulario para aprender. No obstante, lo anterior es la premisa de Memrise, la cual tiene sus raíces en el conductismo que sostenía que el aprendizaje podría tener lugar a través de la formación de hábitos sin necesidad de ningún apoyo contextual (Spada et al., 1996).

Por otra parte, de acuerdo con (Izah, 2019) esta aplicación ofrece más de 150 cursos de idiomas de 25 idiomas y está disponible en algunos idiomas, como inglés, coreano, francés, español, japonés, alemán, ruso, chino, vietnamita, portugués, sueco, noruego, danés, árabe, holandés, indonesio, italiano, polaco y turco. También presenta alrededor de 20 millones de usuario registrados en la plataforma. Por otra parte (Izah, 2019) menciona que, Memrise tiene algunas características que consisten en medios visuales, de audio y video. En términos de funciones o elementos que se utilizan para desafiar a los usuarios de la aplicación. Además, estos autores clasifican las funciones o elementos del desafío en cinco

tipos: traducción de palabras, tarjetas didácticas, desafío para las opciones de audio, pregunta de escritura y traducción de frases.

El elemento principal de esta aplicación Memrise, es el uso de tarjetas rápidas. Sin embargo, de acuerdo con (Izah, 2019) dentro de una lección se pueden encontrar actividades como:

- Traducción de palabras y frases: Memrise proporciona un conjunto de cuadros u opciones de respuesta y el usuario debe elegir un significado similar con la palabra que se está preguntando.
- Flashcards: Tiene el objetivo de ayudar al usuario a recordar una palabra que se ha aprendido.
- Desafío de audio: El usuario debe seleccionar una de las opciones de audio que esté asociada al término que se le ha preguntado.

En cuanto al tipo de retroalimentación que maneja esta aplicación, los autores de (Karjo & Andreani, 2018), comentan que, la retroalimentación es inmediata, indicando cuando la respuesta es correcta o incorrecta. En caso de ser incorrecta, la aplicación proporciona al usuario la respuesta correcta. Adicionalmente a esto, según (Alm, 2021; Izah, 2019) los ejercicios expuestos por Memrise tienen a ser bastante rápidos, dinámicos y de corta interacción tal como sucede en Duolingo.

3.2 Identificación y definición de métricas emocionales

Esta sección, tendrá como punto de partida la definición de que es una emoción. De acuerdo con (De La Serna, 2018), las emociones son reacciones psicofisiológicas que representan modos de reacción del individuo frente a un escenario, objeto, lugar, persona o suceso. Además, (Shadiev et al., 2019) sugiere que las emociones son fenómenos multifacéticos y pueden ser evocados por ciertos estímulos, como eventos o experiencias. Por último, según (Bullis et al., 2019), una emoción se caracteriza por cambios en la fisiología, la experiencia subjetiva y comportamientos que se desarrollan con el tiempo y ocurren en respuesta a un evento activador.

De acuerdo con lo anterior y lo expuesto en secciones previas, los estudios sobre captura de métricas relacionadas a la motivación y las emociones en el aprendizaje suelen utilizar diseños y métodos de evaluación novedosos, donde actualmente predomina los reportes dados por los participantes. Adicionalmente, la aplicación de Learning Analytics para el análisis de los datos emocionales en entornos de aprendizaje se ha expuesto mediante una gama de métodos como: auto reporte del usuario, seguimiento de parámetros implícitos, reconocimiento de voz, reconocimiento facial de expresiones, reconocimiento de gestos y

signos vitales. Haciendo referencia a este último método, relacionado con la captura de emociones por medio de señales vitales o señales emitidas por el cuerpo humano, surge la necesidad de profundizar sobre las Interfaces cerebro-computadora, dado que, son dispositivos no invasivos que permiten una comunicación directa entre el cerebro y dispositivos externos, sin dependencia de nervios periféricos (Bulárka & Gontean, 2016). De esta manera, de acuerdo con (Rezeika et al., 2018) las interfaces cerebro-computadora o Brain Computer Interface (BCI) proporcionan un nuevo método de comunicación no muscular, a través de señales cerebrales. Por lo tanto, mediante estos dispositivos se pueden capturar señales a partir de la actividad cerebral, y con esto sería posible procesar estas señales y mediante diferentes técnicas obtener emociones asociadas a estos datos. Incluso, algunos dispositivos y plataformas relacionadas a esta tecnología ya traen integradas funciones que permiten obtener métricas relacionadas al interés, compromiso, relajación, estrés, excitación, meditación, entre otras. Por esta razón, a continuación, se explorarán alternativas referentes a tecnologías y dispositivos que permitan capturar estas métricas procesadas. Dentro de estas tecnologías se profundizará en Emotiv y Neurosky, dado que, según (Ienca et al., 2018), son dos de las empresas y tecnologías más importante en el campo y, empresas como Facebook y Samsung utilizan sus dispositivos.

3.2.1 Tecnología Emotiv

EMOTIV es una empresa de bioinformática que avanza en la comprensión del cerebro humano mediante electroencefalografía y tienen como misión capacitar a las personas para poder comprender mejor el cerebro y acelerar la investigación en temas relacionados al cerebro a nivel mundial. La tecnología que desarrollan se recoge en el concepto de interfaz cerebro computadora (BCI por sus siglas en inglés) o interfaz neuronal directa (DNI por sus siglas en inglés). Su tecnología tiene como propósito realizar un seguimiento al rendimiento cognitivo, monitorear emociones y controlar objetos físicos y virtuales (EMOTIV, 2022a).

Por otra parte, de acuerdo con (EMOTIV, 2022b), EMOTIV ofrece tres tipos diferentes de algoritmos de detección a partir de los datos capturados de la interacción cerebral. Cada uno de estos algoritmos son soportados por extensos estudios científicos para desarrollar algoritmos de aprendizaje automático precisos para clasificar y calificar la intensidad de diferentes condiciones. Estos algoritmos ayudan a exponer funcionalidades como la captura de métricas de rendimiento o emociones, el entrenamiento de comandos mentales y la detección de expresiones faciales.

Adicionalmente, esta compañía ha lanzado diferentes dispositivos y plataformas para el uso de estos algoritmos. Estos dispositivos los clasifican como de uso profesional y

personal. En este caso se mencionarán características relevantes del dispositivo personal Emotiv Insight. Además de esto, EMOTIV ha liberado al público Cortex API, la cual se visualiza como la pieza central para la comunicación entre los dispositivos construidos por esta compañía y el consumidor final, generando un canal de conexión entre las interfaces cerebro-computadora y una aplicación construida en diferentes lenguajes de programación. Como lo menciona esta compañía, Cortex API tiene la facilidad de ser consumida desde una amplia variedad de lenguajes de programación.

3.2.1.1 *Emotiv Insight*

El Emotiv Insight es un dispositivo Interfaz cerebro-computadora, de bajo costo, diseñado para la captura de actividad cerebral del día a día. Este contiene cinco sensores para adquisición de actividad cerebral, presentando una frecuencia de muestreo de 128Hz. Estos sensores son de material Polímero hidrofílico semiseco, lo cual es fácil y cómodo de usar para el participante (Toa et al., 2021). Además de esto, dos de los sensores son de referencia, para lograr obtener una mejor ubicación, con el fin de permitir la captura de seis métricas emocionales las cuales son, relajación, interés, estrés, concentración, compromiso y excitación (Cueva et al., 2017).

Este dispositivo se puede conectar a un computador mediante Bluetooth o con un controlador directamente conectado al computador. Además, este dispositivo se puede recargar para tener una actuación de 20 horas seguidas. La Figura 2, presenta un Emotiv Insight.




Figura 2 *Emotiv Insight*

Adicionalmente, de acuerdo con (Cueva et al., 2017), no es recomendable el uso del dispositivo por extensos periodos de tiempo dado que la presión que ejercen los sensores sobre la cabeza puede resultar molesta e incómoda para algunas personas. También, indican que, otra situación a tener en cuenta es que la distancia entre el Emotiv Insight y el dispositivo bluetooth no debe ser extensa, dado que se puede perder la conectividad.

3.2.1.2 Cortex API

Por otra parte, la compañía creadora de este dispositivo ha desarrollado y expuesto al público Emotiv Cortex, el cual es la pieza central de la tecnología Emotiv dado que, lleva la interfaz cerebro-computadora al consumidor. Básicamente, es un API que está basada en JSON y WebSockets, lo cual facilita el acceso desde una variedad de lenguajes de programación, entre ellos Python. En este orden de ideas, cualquier persona con conocimientos de programación puede desarrollar una aplicación que interactúe directamente con un dispositivo Emotiv. Además de esto, por medio de Emotiv Cortex y un dispositivo Emotiv Insight se pueden obtener métricas vía streaming como, datos de movimientos, comandos mentales, expresiones faciales, métricas de rendimiento (emociones) en baja resolución de 0,1Hz, lo cual indica obtener datos cada 10 segundos, bandas de frecuencia, calidad de contacto de los sensores y nivel de batería. También, mediante suscripciones pagas se pueden capturar Electroencefalogramas y métricas de rendimiento a una frecuencia de 2Hz, es decir, cada 0.5 segundos.

3.2.1.3 Métricas Emocionales con Emotiv

De acuerdo con esto, mediante un dispositivo como Emotiv Insight y una conexión con Cortex API, es posible capturar valores entre 0 y 1 de emociones como: Estrés, Compromiso, Interés, Excitación, Concentración y Relajación. Donde, valores cercanos a 1 significan una exposición alta a esa emoción y un valor cercano a 0 el caso contrario. De acuerdo con (EMOTIV, 2021), estas emociones se definen como:

- **Estrés:** También llamada frustración. Es una medida de comodidad frente al desafío actual. El alto nivel de estrés puede resultar de la incapacidad para completar una tarea difícil, sentirse abrumado y temer las consecuencias negativas por no cumplir con los requisitos de la tarea. En general, un nivel de estrés de bajo a moderado puede mejorar la productividad, mientras que un nivel más alto tiende a ser destructivo y puede tener consecuencias a largo plazo para la salud y el bienestar.
- **Compromiso:** Se experimenta como el estado de alerta y la dirección consciente de la atención hacia los estímulos más relevantes de una tarea. Mide el nivel de inmersión en un determinado momento, y es una mezcla entre atención y

concentración contrastando con el aburrimiento. El compromiso se caracteriza por una mayor excitación fisiológica y ondas beta junto con ondas alfa atenuadas. Cuanto mayor sea la atención, el enfoque y la carga de trabajo, mayor será la puntuación de salida informada por la detección.

- **Interés:** Es el grado de atracción a los estímulos, el entorno o a la actividad en desarrollo. Las puntuaciones de interés bajas indican una fuerte aversión a la tarea, el interés alto indica una gran afinidad con la tarea, mientras que las puntuaciones de rango medio indican que no le gusta ni le disgusta la actividad.
- **Excitación:** Es un sentimiento de excitación fisiológica con un valor positivo. Se caracteriza por la activación en el sistema nervioso simpático que da como resultado una variedad de respuestas fisiológicas que incluyen la dilatación de la pupila, el ensanchamiento de los ojos, la estimulación de las glándulas sudoríparas, el aumento de la frecuencia cardíaca y la tensión muscular, la desviación de la sangre y la inhibición digestiva. En general, cuanto mayor sea el aumento de la excitación fisiológica, mayor será la puntuación de salida para la detección. La detección de emoción se ajusta para proporcionar puntuaciones de salida que reflejan cambios a corto plazo en la emoción durante períodos de tiempo tan cortos como varios segundos.
- **Concentración:** Medida de atención fija a una tarea específica. Esta métrica mide la profundidad de la atención, así como la frecuencia con la que la atención cambia entre tareas. Un alto nivel de cambio de tareas es una indicación de falta de atención y distracción.
- **Relajación:** También llamada meditación. Es una medida de la capacidad de desconectarse y recuperarse de una concentración intensa. Los meditadores entrenados pueden obtener puntajes de relajación extremadamente altos.

De esta forma, mediante un dispositivo como Emotiv Insight y la elaboración de una conexión mediante Cortex API, se pueden obtener estas métricas cada 10 segundos, sin tener una suscripción o licencia de alta resolución. A partir de esto, se obtendría una serie de tiempo donde cada instante de tiempo, se tendrían los valores de estrés, relajación, compromiso, concentración, interés y excitación.

3.2.2 Tecnología Neurosky

NeuroSky, mediante su tecnología permite a los desarrolladores de productos y proveedores de servicios empresariales, crear soluciones que pueden capturar, cuantificar y revelar la gama más amplia de métricas personalizadas de salud y bienestar de la industria. La biometría avanzada habilitada por las tecnologías de NeuroSky brinda a los

consumidores información procesable para ayudarlos a evaluar su estado físico y, si es necesario, cambiar su comportamiento para encaminarse hacia una vida más saludable. La misión de NeuroSky es hacer que las tecnologías innovadoras de biosensores estén disponibles a escala de mercado masivo (NeuroSky, 2021a).

Además de esto, Neurosky basa su funcionamiento en la tecnología ThinkGear. Principalmente, esta tecnología es la que permite que los dispositivos de Neurosky interactúen con las ondas cerebrales de los usuarios. Adicionalmente, Neurosky permite capturar métricas como atención y meditación, y es precisamente este chip de ThinkGear el cual toma las señales en crudo de las ondas cerebrales de un usuario y calcula el nivel de atención y meditación (Raj et al., 2018).

3.2.2.1 *MindWave*

Este dispositivo consta de un par de electrodos, donde uno de ellos va ubicado en la frente y el otro se ubica en la parte inferior de la oreja izquierda, dándole soporte al dispositivo (Raja et al., 2020). Además de esto, el MindWave cuenta con una correa ajustable a la cabeza, para brindar comodidad a todos los usuarios. Este dispositivo utiliza baterías triple A para dar alrededor de 8 horas de duración. Adicionalmente, este dispositivo tiene Bluetooth y el módulo ThinkGearASIC. A partir de esto, los datos en crudo son recopilados mediante el sensor ubicado en la frente, y estos datos alimentan el ThinkGear, para obtener señales analizables como valores en crudo sin procesar, electroencefalogramas, bandas de poder y los niveles de atención y meditación (Raja et al., 2020). La Figura 3, presenta el dispositivo MindWave.



Figura 3 *MindWave* (Engchuan et al., 2017)

3.2.2.2 Neurosky Software Delevopment Kit

Neurosky expone al público un conjunto de herramientas de software que facilitan la creación de aplicaciones innovadoras que responden a las señales cerebrales y al estado mental de una persona. Mediante estas herramientas, se presentan varias formas de integrar la funcionalidad de detección de ondas cerebrales en programas existentes o crear nuevos proyectos desde cero. Además, incluye Kit de desarrollo de software (SDK) de ThinkGear, el controlador de comunicación, el conector y la capacidad de obtener datos en streamining (NeuroSky, 2021c). Uno de los elementos importante de esta herramienta que expone Neurosky, es el conector de ThinkGear, dado que, mediante es un programa de software, similar a un servidor de socket, que se ejecuta un proceso en segundo plano en su computadora y es responsable de dirigir los datos de un dispositivo como el MindWave con NeuroSky ThinkGear desde el puerto serie a un socket de red abierto. Cualquier lenguaje de programación que contenga una biblioteca de socket debería poder comunicarse con la API expuesto. De esta manera, se convierte en la herramienta ideal para lenguajes de scripting como Python y Ruby.

3.2.2.3 Métricas Emocionales con Neurosky

De acuerdo con (Katona et al., 2016), Neurosky utiliza la tecnología ThinkGear para procesar y clasificar las señales de los electroencefalogramas mediante un enfoque cuantitativo. De esta manera, mediante un MindWave se pueden calcular los valores de atención y meditación, entre un rango de 0 a 100. Según (NeuroSky, 2021b), estas métricas se pueden definir como:

- **Atención:** Indica la intensidad de atención mental. El nivel de atención aumenta cuando un usuario se enfoca en un solo pensamiento o en un objeto externo, y disminuye cuando se distrae. Los usuarios pueden observar su capacidad de concentración utilizando el algoritmo. En entornos educativos, se puede realizar un seguimiento de la atención a los planes de lecciones para medir su eficacia a la hora de involucrar a los estudiantes.
- **Meditación:** Indica el nivel de calma o relajación mental. Aumenta cuando los usuarios relajan la mente y disminuye cuando están inquietos o estresados. El medidor de meditación cuantifica la capacidad de encontrar un estado interno de atención y, por lo tanto, puede ayudar a los usuarios a aprender cómo autocorregirse y encontrar el equilibrio interno para superar el estrés de la vida cotidiana.

De igual manera que sucede con el Emotiv Insight y Cortex API, mediante un dispositivo como MindWave y el uso del controlador de ThinkGear, que provee Neurosky, se puede

obtener una serie de tiempo, que consolide los niveles de métricas como la atención y la meditación de un usuario.

3.3 Diseño del modelo de Learning Analytics basados en métricas emocionales

En concordancia con lo expuesto por (Wei, 2013), al estudiar un fenómeno, a menudo nos encontramos con un conjunto de datos donde las observaciones se toman de acuerdo con el orden del tiempo en que van ocurriendo. Esta secuencia de observaciones ordenada en el tiempo se conoce como serie de tiempo. En este orden de ideas y como se evidencia en la sección anterior, al utilizar algunos de los dispositivos de Interfaz cerebro-computadora y sus herramientas de conexión y consumo, se obtendrá como resultado series de tiempo que consolidan cada cierto instante de tiempo valores asociados a un conjunto de métricas emocionales, dependiendo del dispositivo y tecnología que se utilice. Además de esto, estas series de tiempo entre participantes serán de longitud variable, dado que se establecen a partir de la interacción del individuo con algún tipo de plataforma de aprendizaje de segunda lengua, y el tiempo de interacción de cada participante puede variar.

De acuerdo con una revisión de literatura referente a minería de datos educativa y learning analytics aplicado a educación superior en el siglo 21 realizada por (Aldowah et al., 2019), las técnicas más importantes y recurrentes en este tipo de estudios son la clasificación, el agrupamiento o clustering y la visualización de datos. De esta manera (Aldowah et al., 2019), indica que, las técnicas de clustering en este campo de educación tienden a utilizarse para agrupar a los estudiantes en función de sus características de aprendizaje, preferencias individuales de estilo de aprendizaje, rendimiento académico e interacción conductual. Adicionalmente, estos mismos autores, exponen que las técnicas de visualización se pueden usar para presentar diferentes datos educativos usando gráficos, que pueden permitir a los instructores y a los responsables de la toma de decisiones educativas explorar y obtener información sobre el desempeño de los estudiantes, de modo que se pueda brindar el apoyo adecuado.

En este mismo orden de ideas, de acuerdo con (Antzoulatos et al., 2022; Sheidin et al., 2019), la analítica visual para las series de tiempo ha recibido durante los últimos años una cantidad de atención considerable, obteniendo esta conclusión a partir de una revisión de literatura de las publicaciones más importantes en el campo de técnicas de clustering y clasificación de series de tiempo en analítica de visualización. Además, según (Kuromiya, 2021) para investigar cuantitativamente los patrones de aprendizaje de los

estudiantes, Learning Analytics (LA) mediante técnicas de clustering es una de las mejores opciones que ayudan a los instructores a comprender los comportamientos de los estudiantes. También, de acuerdo con (Ali et al., 2019), la investigación en la aplicación de clustering de series de tiempo de longitud variable se ha convertido durante los últimos años en un tema de relevancia. Tomando lo anterior como punto de partida, se profundizará en técnicas de visualización y de agrupamientos para series de tiempo, para posteriormente definir el modelo de learning analytics basando en métricas emocionales.

3.3.1 Visual Analytics

De acuerdo con (M. Chen et al., 2014) la visualización se ocupa de explorar los datos y la información de tal manera que se comprenda mejor los datos. El objetivo es promover un nivel más profundo de comprensión de los datos bajo investigación y fomentar nuevos conocimientos sobre los procesos subyacentes, confiando en la poderosa capacidad de visualización de los humanos.

De esta manera, tomando como referencia el estudio realizado por (Ali et al., 2019), aplicar técnicas de visualización a series de tiempo, ayuda a las personas a entender los datos y presentarlos en forma gráfica, ayudando a analistas a observar, analizar, tomar decisiones e identificar patrones con base en visualizaciones. Además, indican que, a un nivel bajo, los datos de una serie de tiempo son presentados en gráfico en 1-D. También, es frecuente implementar técnicas de interacción como acerca/alejar, desplazar y seleccionar, dando la oportunidad de profundizar en regiones de la serie de tiempo.

En la revisión de literatura realizada por (Ali et al., 2019), a nivel de visualización se define la siguiente taxonomía o agrupación:

- **Gráficos de barra:** Son los gráficos de barras, de ondulación e histogramas.
- **Gráficos de área:** Son los gráficos apilados, de río y de corriente.
- **Gráficos de círculo:** Son los gráficos de torta y radiales.
- **Gráficos de línea:** Son los gráficos de líneas y coordenadas paralelas.
- **Mapas geográficos, de grilla y matriz:** Son mapas de calor, mapas de calendario, cubos de espacio-tiempo.
- **Gráficos de punto:** Gráficos de píxel, de burbuja y de dispersión.
- **Gráficos de árbol y redes:** Son gráficos como dendrogramas y nodos vinculados.

A partir de esto, (Ali et al., 2019) indica que, algunas de las técnicas más utilizadas son los gráficos de línea, diagramas de torta, histogramas, gráficos de barras y mapas de calor. Según (Luo et al., 2019), los gráficos de línea buscan representar conexiones entre puntos de datos, presentando tendencias de una serie. De esta forma, las tendencias temporales y

otros patrones de interés se pueden percibir fácilmente según las pendientes ascendentes y descendentes de los cambios de datos. También (Luo et al., 2019), indica que, un gráfico de barras expone un recuento de elementos de datos categóricos mediante barras, cuya longitud representa el número de recuentos. Es así como, presenta datos bidimensionales donde el atributo clave es categórico y el otro es cuantitativo. A partir de esto, se pueden generar rápidamente comparaciones entre diferentes categorías. Otro de los tipos de visualización tratados por (Luo et al., 2019), son los histogramas. Este gráfico utiliza las longitudes de las barras para codificar la frecuencia o la densidad de frecuencia de los valores, se puede ver como una variación de los gráficos de barras, pero con la diferencia que, el atributo clave de un histograma es continuo en lugar de discreto, de esta manera se logra visualizar las distribuciones de datos numéricos.

Por otro lado, (Sander et al., 2014) profundiza en los gráficos circulares, los cuales se dividen en varios sectores, donde cada sector describe una proporción en una cantidad total de datos. De esta manera, se puede observar a nivel porcentual un valor dentro del universo de datos, o eventos. Adicionalmente, estos autores, indican que toda visualización debería contener tablas dado que, esta técnica de representación de datos es simple, fácil de entender e interpretar. También presenta un formato estructurado, organizado por filas y columnas que transmiten relaciones y es una de las definiciones más comunes.

En su investigación (Ali et al., 2019), los autores también expresan la importancia de la interactividad en la visualización de datos, exponiendo que, a diferentes niveles un analista debería poder consumir información en diferentes contextos de dominio, a lo cual lo llaman tarea de análisis a un alto nivel. Además, a un nivel medio, hacen referencia a búsqueda, con el propósito que, un usuario o analista pueda buscar y filtrar elementos de interés. Finalmente, a un bajo nivel, exponen la consulta, lo cual permite identificar, comparar y resumir elementos seleccionados.

3.3.2 Clustering de series de tiempo

Clustering es un método de aprendizaje automático o machine learning no supervisado, utilizado para ubicar puntos o individuos en un conjunto finito de grupos, también llamados clústeres. Estos grupos son formados de tal manera que, las observaciones que los componen exponen comportamientos o tendencias similares (Wu et al., 2008). Puntualmente, de acuerdo con (Aghabozorgi et al., 2015), el clustering de series de tiempo se define como:

Dado un conjunto de n datos de series de tiempo $D = \{F_1, F_2, \dots, F_n\}$, el proceso de partición no supervisada de D en $C = \{C_1, C_2, \dots, C_k\}$, de tal manera que las series de tiempo homogéneas se agrupan en función de una determinada medida de similitud,

a esto se le denomina agrupación o clustering de series de tiempo. Entonces, C_i es llamado Clúster, donde $D = \cup_i^k C_i$ y $C_i \cap C_j = \emptyset$ para cada $i \neq j$.

Lo anterior quiere decir que, a partir de este proceso, se generan k número de clústeres donde cada clúster está compuesto por un conjunto de series de tiempo, que presenten homogeneidad. De esta forma, al unir todos los individuos de todos los clústeres obtendremos el universo D de las series de tiempo y al intentar hacer intercepciones entre diferentes clústeres, el conjunto resultante debe ser vacío, dado que un individuo pertenece explícitamente a uno y solamente uno de los clústeres al mismo tiempo.

En este orden de ideas, de acuerdo con un estudio de referencia sobre clustering en series de tiempo (Javed et al., 2020), algunos de las estrategias más populares en esta área son, agrupaciones particionales, basados en densidad y agrupación jerárquica. Adicionalmente, menciona algunas medidas de distancia como la euclidiana, la deformación dinámica de tiempo (dynamic time warping - DTW), la basada en forma y la alineación global de núcleos rápida (GAK). En adición a lo anterior, autores como (Cuturi & Blondel, 2017), también menciona la distancia de deformación dinámica de tiempo suave (S-DTW), siendo una variación de DTW. A partir de lo expuesto, se profundizará en estos temas.

3.3.2.1 Algoritmos de clustering

3.3.2.1.1 Particionales

Algunos de los algoritmos más populares de esta estrategia son: K-means (MacQueen, 1967), K-medoids (Kaufman & Rousseeuw, 1990) y Fuzzy C-means (Bezdek, 2013). Además, estos algoritmos, presentan una alta precisión como lo indica (Paparrizos & Gravano, 2017). Estos algoritmos particionales, generan agrupaciones, intentando optimizar el agrupamiento, minimizando la distancia entre el centro de cada grupo o centroide, y los puntos de datos dentro de ese grupo. Otra característica relevante de estos algoritmos es que requieren que se indique el número de clústeres a generar. Una vez se conoce el número de clústeres denotado como k , el algoritmo itera en dos fases. La primera, consiste en calcular los centroides y la segunda, en asignar los puntos de datos a su centroide más cercano, hasta cumplir un criterio de finalización, puede ser un número máximo de iteraciones o convergencia del modelo. Para estos algoritmos los centroides iniciales se eligen al azar, lo que hace que el algoritmo no sea determinista; todos los centroides posteriores se calculan para minimizar la distancia a todos los demás puntos de datos dentro del grupo dado.

3.3.2.1.2 Jerárquico

Un algoritmo de agrupamiento jerárquico puede ser aglomerativo o divisivo. En el aglomerativo, cada punto de los datos comienza como su propio grupo y los pares de grupos se fusionan a medida que el algoritmo asciende en la jerarquía. En el divisivo, todos los puntos de datos se asignan inicialmente a un solo grupo y los grupos se dividen a medida que el algoritmo desciende en la jerarquía.

Para el algoritmo aglomerativo, se debe definir la cantidad de grupos que se desea formar denotado como k . Una vez esto se ha definido, el algoritmo emplea dos fases. La primera, inicializa cada punto de los datos como su propio grupo y luego fusiona repetidamente los dos grupos más cercanos en uno, hasta que se generen los k grupos definidos inicialmente. La medición de grupos cercanos se realiza mediante medidas de similitud.

3.3.2.1.3 Basados en densidad

De acuerdo con (Campello et al., 2020), los algoritmos de clustering por lo general son no paramétricos, dado que en las agrupaciones se consideran áreas de alta densidad de puntos o individuos. Lo anterior quiere decir que, no se requiere especificar el número de clústeres a generar. Como consecuencia, los conglomerados basados en la densidad no son necesariamente grupos de puntos con una baja disimilitud por pares dentro del conglomerado medida por una función de disimilitud, por lo tanto, no necesariamente tienen una forma convexa o regular. Puntualmente, un clúster basado en densidad es un conjunto de objetos de datos distribuidos en el espacio de datos sobre una región contigua de alta densidad de objetos, separados de otros clústeres basados en densidad por regiones contiguas de baja densidad de objetos. Algunos ejemplos de estos algoritmos son agrupamiento espacial basado en densidad de aplicaciones con ruido (DBSCAN) y Ordenamiento de puntos para identificar la estructura de agrupamiento (OPTIC).

No obstante, en el clustering de series de tiempo, según (Javed et al., 2020) el algoritmo Picos de Densidad (Density Peaks), recientemente ha presentado alta popularidad en esta área. Pero, a diferencia de otros algoritmos basados en la densidad, necesita el número de grupos k , como una de las entradas. El algoritmo de picos de densidad genera centroides de conglomerados (llamados "picos de densidad") que están rodeados por puntos de datos vecinos que tienen una densidad local más baja y están relativamente más lejos de los puntos de datos con una densidad local más alta. El algoritmo tiene dos fases. Primero encuentra centroides (picos de densidad), y luego asigna puntos de datos al centroide más cercano.

3.3.2.2 Medidas de distancia

De acuerdo con (Aghabozorgi et al., 2015), algunas de los métodos para la medición de similitud más utilizadas en clustering para series de tiempo son la distancia euclidiana y la deformación dinámica de tiempo (DTW).

3.3.2.2.1 Distancia euclidiana

La distancia euclidiana es la medida más común y utilizada en diferentes aplicaciones de clustering de datos (Javed et al., 2020). Esta medida se calcula punto a punto entre dos series de tiempo. Por tal motivo, las series de tiempo deben tener la misma longitud (Ali et al., 2019). Dadas dos series de tiempo $T1 = (T1_1, T1_2, \dots, T1_n)$ y $T2 = (T2_1, T2_2, \dots, T2_n)$ la ecuación para obtener la distancia euclideana entre estas series se tiempo se define como:

$$d(T1, T2) = \sqrt{\sum_i^n (T1_i - T2_i)^2} \quad (1)$$

3.3.2.2.2 Deformación dinámica de tiempo

La deformación dinámica de tiempo o en inglés Dynamic time warping (DTW), consiste en un mapeo de puntos entre dos series de tiempo $T1$ y $T2$. Este mapeo está diseñado para minimizar la distancia euclideana por pares (Javed et al., 2020). Además, de acuerdo con (Ali et al., 2019) se ha consolidado como una de las medidas de similitud más precisas en series de tiempo. Adicionalmente, de acuerdo con (Lee et al., 2020) esta medida es aplicable para series de tiempo de longitud variable. La Figura 4 presenta la diferencia entre el mapeo de puntos realizado entre la distancia euclidiana y DTW.




Figura 4 Comparación distancia euclidiana y deformación dinámica de tiempo Tomada de (Costa et al., 2017)

3.3.2.2.3 Deformación dinámica de tiempo suave

La distancia de deformación dinámica de tiempo suave o en inglés Soft dynamic time warping (S-DTW), surgió por la alta complejidad computacional de la distancia DTW tradicional, cuando es aplicada a largos conjunto de datos. Este método aplica técnicas de regularización, además de utilizar un mínimo parametrizado suave. Esto ayuda a calcular los centroides de forma optimizada durante el proceso de los algoritmos de clustering. Sin embargo, como medida de distancia independiente, la distancia DTW suave tiene algunas desventajas como que, la distancia puede ser negativa, la distancia entre X y sí mismo no es necesariamente cero, no cumple con la desigualdad triangular y también tiene complejidad cuadrática con respecto a la duración de la serie. Por otro lado, es una distancia simétrica, que admite series con diferentes longitudes (Sardá-Espinosa, 2018).

3.3.2.2.4 Distancia basada en la forma

La distancia basada en la forma o shape-based distance (SBD), es una medida invariable al cambio y a la escala (Paparrizos & Gravano, 2015) de las series de tiempo, es decir, no se ve afectada por el cambio o la escala de los datos de la serie temporal. Esta medida, calcula la correlación cruzada entre dos series de tiempo y produce un valor de distancia entre 0 y 2, donde 0 indica que las series de tiempo son idénticas y 2 indica formas máximamente diferentes. Además, para garantizar que la medida de la distancia sea invariable con respecto a la escala, a las series de tiempo se les aplica una normalización Z. Donde, el resultado de esta normalización genera valores entre el rango $[-1, 1]$ con una media igual a cero y una desviación estándar igual a 1.

3.3.2.2.5 Distancia global de alineamiento de núcleos

En (Cuturi, 2010) el autor planteó un algoritmo para evaluar la similitud entre dos series de tiempo mediante el uso de kernels o núcleos. Este algoritmo, tiene como punto de partida alinear dos series de tiempo y definir el posible conjunto de alineaciones de acuerdo con las longitudes. Un núcleo de alineación global (GAK – Global Alignment Kernel) es definido como se muestra en la Ecuación (2). Donde, κ es una función de similitud global, $A(n, m)$ es el conjunto de posibles alineaciones entre las series de tiempo y π es la formalización de una alineación. De esta manera, este kernel o núcleo considera el costo de todas las alineaciones posibles al calcular su mínimo suave exponenciado, por lo que se argumenta que cuantifica las similitudes de una manera más coherente (Cuturi, 2010).

$$k_{GA}(x, y) = \sum_{\pi \in A(n, m)} \prod_{i=1}^{|\pi|} \kappa(x_{\pi_1(i)}, y_{\pi_2(i)}) \quad (2)$$

3.3.2.3 Evaluación de algoritmos de clustering

La evaluación de algoritmos de clustering cumple un papel importante dado que, es necesario cuantificar automáticamente la calidad de las configuraciones de clúster generadas. Esto es especialmente útil para comparar el rendimiento de diferentes algoritmos de agrupamiento, así como para determinar el número óptimo de grupos a formar. Generalmente, para realizar la evaluación se utilizan índices internos y externos. Los índices internos miden la compactabilidad y la separación entre los clústeres, mientras que los índices externos se basan en la realidad sobre la partición óptima de los datos. Para estos últimos es necesario tener las etiquetas verdaderas de los grupos a generar (Tomašev & Radovanović, 2016).

Una de las métricas de evaluación internas es el coeficiente de Silhouette, el cual fue propuesto en (Rousseeuw, 1987), donde se define para cada objeto en el conjunto de datos, la medida de cómo este objeto es similar a otros objetos de la misma agrupación (cohesión, compactabilidad) en comparación con objetos de otras agrupaciones (separación). Para cada objeto, la medida puede obtener valores del rango $[-1, 1]$. El valor más alto significa una mejor coincidencia con el grupo en el que debe clasificarse y una menor aptitud para otros grupos. El promedio de los puntajes obtenidos por cada individuo será el coeficiente general. Se usa muy a menudo para encontrar la cantidad de clústeres en un conjunto de datos particionado (Dudek, 2020).

Otro índice de validación interna es el índice de Dunn el cual es de tipo relación donde la cohesión se estima por la distancia del vecino más cercano y la separación por el diámetro máximo del grupo. Este índice debe ser maximizado, es decir entre más alto mejor (Arbelaitz et al., 2013). También existe, el índice de Calinski–Harabasz, este índice indica la cohesión siendo estimada con base a las distancias desde los puntos de un grupo hasta su centroide. La separación se basa en la distancia de los centroides al centroide global. Este índice también cumple la condición de entre más elevado los grupos generados exponen mejor separación y cohesión (Arbelaitz et al., 2013). Por último, se tiene el índice Davies-Bouldin, el cual probablemente es uno de los índices más utilizados en los estudios de comparación interna. Este índice estima la cohesión en función de la distancia de los puntos de un grupo a su centroide y la separación en función de la distancia entre los centroides. En este caso, se busca minimizar este índice, es decir entre más bajo mejor (Arbelaitz et al., 2013).

3.3.3 Definición del modelo de learning analytics basado en métricas emocionales

La Figura 5, presenta la definición a nivel general del modelo de learning analytics basado en métricas emocionales que se utilizó para el presente proyecto.




Figura 5 Definición general del modelo de learning analytics

A partir de la Figura 5, se puede ver que el modelo tiene como entrada datos emocionales capturados durante la interacción con alguna plataforma de aprendizaje de segunda lengua. Adicionalmente, también se podrá recibir algunos datos asociados con el proceso de aprendizaje, como los resultados obtenidos. Es relevante aclarar, que estos datos deben venir procesados y en un formato que será especificado posteriormente. Una vez los datos ingresan al modelo, se presentan dos maneras de ser analizados. La primera es mediante analítica de visualización, donde se implementarán un conjunto de técnicas tanto de graficación como interacción. Estos gráficos, se generarán a nivel individual y general. Esto quiere decir que, se presentarán gráficos para un solo participante seleccionado o todo el grupo de participantes. También, este análisis se realizará sobre diferentes niveles de profundidad según la estructura del curso seleccionado para el aprendizaje de segunda lengua. Es decir, esto puede incluir un análisis general de una lección o de actividades específicas. Lo anterior, estará determinado por la aplicación de segunda lengua y la estructura del curso de aprendizaje. Finalmente, este análisis mediante analítica visual generará dashboards, con el propósito de visualizar los detalles mencionados anteriormente.

Por otra parte, la segunda línea de análisis de estos datos emocionales y de aprendizaje, será mediante métodos de agrupamiento o clustering emocional. De esta manera, como los datos emocionales vienen en forma de series de tiempo, se aplicarán algoritmos de

clustering para series de tiempo de longitud variable. Como se ha mencionado anteriormente, el proceso de aprendizaje e interacción con la plataforma de segunda lengua puede variar entre participantes, lo cual restringe este análisis a la implementación de algoritmos dedicados a este tipo de problema. Finalmente, esta línea de análisis generará agrupaciones en donde sus participantes presenten similitud en su comportamiento emocional. Lo anterior, exponiendo generaciones de grupos, para cada una de las métricas emocionales que se contemplen en el estudio.

3.4 Definición del caso de estudio

Como factor inicial de la definición del caso de estudio, se debe seleccionar la aplicación móvil que se utilizará para el aprendizaje de un segundo idioma. En este caso, se ha seleccionado Babbel, dado que, como se ha expuesto anteriormente y según (Sporn et al., 2020) Babbel es la aplicación de aprendizaje de idiomas con mayor éxito financiero del mundo. También, según Forbes la mejor aplicación de aprendizaje de idiomas en general es Babbel (Gajić T., 2022). Adicional a ello, se contó con una revisión realizada junto con un experto en el área de enseñanza de segunda lengua, donde se observaron características como: diversidad de tipo de ejercicios a realizar durante la interacción, estructura de aprendizaje y duración apropiada de las actividades frente a otras aplicaciones. En cuanto a diversidad de actividades o ejercicios, de acuerdo con (Nushi & Eqbali, 2018) se presentan actividades dispuestas para adquirir conocimiento de nuevos temas, practicar la escucha, la asociación de términos y la pronunciación de palabras.

De esta manera, de la amplia gama de idiomas por aprender que expone Babbel, se decidió seleccionar el idioma portugués para el caso de estudio. Lo anterior dado que, para aplicar este caso de estudio, se tendrá un grupo de 19 de personas, las cuales presentan como lengua materna el español y según (Molsing et al., 2020) una vez que un individuo tiene conocimientos en español, la adquisición de una nueva lengua como el portugués se lleva a cabo de manera más sencilla. También, se seleccionó este idioma dado que, sus explicaciones se presentaban en español, mientras que en otros idiomas solo estaban disponibles en inglés, lo cual podría generar incomodidad en los participantes que no tengan conocimiento avanzado en inglés, facilitando de esta manera la comprensión y guía en todo el proceso de aprendizaje. Otro de los factores para la selección de este idioma fue que las personas del grupo de participantes no presentaban conocimientos previos en este lenguaje y a partir de esto, se busca no sesgar los resultados de las emociones experimentadas, dado que, si el idioma elegido fuese inglés, probablemente algún participante podría tener un conocimiento previo, lo cual podría modificar su percepción, contrario a un lenguaje totalmente nuevo. De acuerdo con esto, se logra mantener en este

aspecto un nivel alto de homogeneidad en el grupo de participantes. En cuanto al grupo de 19 participantes, por aspectos éticos y de tratamiento de datos, se protege la información personal de ellos. No obstante, a manera general, en esta población se presentaba un total de 4 mujeres y 15 hombres, ubicados en un rango de edad entre 20 a 30 años. Además, todas las personas tenían nacionalidad colombiana.

Además de esto, con la ayuda del experto en aprendizaje de segunda lengua, se decidió utilizar las primeras 4 lecciones del curso número uno llamado “primeros pasos” del curso de portugués, dado que, durante las tres primeras lecciones se realiza un primer acercamiento a esta nueva lengua con explicaciones y actividades básicas e introductorias. Ya en la cuarta lección, se presenta una estructura compuesta solamente por actividades destinadas a la revisión de esos nuevos conceptos adquiridos previamente. En este orden de ideas, la Figura 6, condensa lo expuesto anteriormente, para el componente de la aplicación móvil de aprendizaje de segunda lengua.




Figura 6 Caso de estudio - componente de aplicación móvil de segunda lengua

Una vez definida la aplicación, el idioma, el curso y las actividades a realizar, se procede a definir cuales métricas emocionales se tendrá en cuenta y cómo serán capturadas. En este orden de ideas, se ha determinado utilizar el dispositivo Emotiv Insight, como interfaz cerebro-computadora y como medio para la captura de actividad cerebral. Adicionalmente, como se ha mencionado en secciones anteriores, mediante este dispositivo es posible capturar métricas emocionales como estrés, relajación, concentración, compromiso, interés y excitación. Lo cual, presenta un espectro más amplio frente a las métricas que se pueden capturar mediante otro dispositivo como Neurosky. A partir de esto, se implementarán scripts en el lenguaje de programación de Python, con el propósito de realizar una conexión entre el Emotiv Insight y Cortex API, para ser el puente de captura de estas métricas, con las restricciones que presenta una licencia no paga, la cual, radica en obtener estas métricas con una frecuencia de 0.1Hz, es decir cada 10 segundos. En este punto, se evidencia la importancia de haber seleccionado una aplicación de aprendizaje de segunda lengua, que demande un tiempo prudente en la solución e interacción de cada actividad presentada, dado que, proporciona la posibilidad de tener más de una muestra de las métricas emocionales durante su interacción con cada actividad desarrollada.

Adicionalmente, los datos capturados deberán ser preprocesados, de tal forma que, se presenten como estructura de series de tiempo para cada una de las métricas. Lo anterior, haciendo uso de Python nuevamente. También, se propone realizar una anotación de actividades. Es decir, los datos procesados, tendrán una etiqueta que identifique en que actividad se encontraba interactuando el participante en cada instante de tiempo. Para llevar esto a cabo, se realizará la grabación de la interacción del participante con la aplicación de aprendizaje de segunda lengua. Al tener esta grabación, se podrá realizar la anotación de los datos y adicionalmente, se tendría la posibilidad de capturar y consolidar los tiempos de interacción y resultados obtenidos para las distintas actividades y lecciones. En este orden de ideas, a partir de la captura de estos datos emocionales y de aprendizaje, se generará un conjunto de datos totalmente nuevo, el cual será el insumo de entrada para el modelo de Learning Analytics. La Figura 7, presenta el componente de recopilación y procesamiento de las métricas.




Figura 7 Caso de estudio - componente de recopilación de métricas

Considerando que, ya se ha definido cuál será la entrada para el modelo de Learning Analytics planteado anteriormente, para el componente de analítica de visualización, se tomarán las series de tiempo asociadas a las métricas emocionales, los tiempos y resultados obtenidos por el participante, para implementar tablas, gráficos de línea, gráficos de torta, mapas de calor, histogramas y gráficos de barras. Lo anterior, con el propósito de poder visualizar el comportamiento secuencial de las métricas emocionales recopiladas a lo largo de la interacción del usuario. También, se pretende identificar en que rango de valores se encuentra la acumulación de valores para cada métrica emocional. Además, se pretende tener la posibilidad de exponer los tiempos totales de interacción y

los resultados obtenidos en las actividades y lecciones realizadas por el participante. Este análisis visual se realizará tanto a nivel individual, es decir para un solo participante o a nivel general para todo un grupo de estudiantes. También se llevará a cabo para las diferentes lecciones seleccionadas y para las actividades que se encuentren dentro de cada lección. De este modo, se tendrán tableros de visualización (dashboard) que ayudarán a observar de forma clara y precisa el comportamiento emocional del grupo de participantes durante el aprendizaje de portugués. En concordancia con lo anterior, la generación de estos dashboard y sus gráficos se realizará mediante Python.

Por otro lado, a partir de las series de tiempo emocionales, las cuales presentaran duración variable de acuerdo con el tiempo de interacción del usuario con la plataforma, se procederá a aplicar agrupamiento o clustering para series de tiempo de longitud variable, para cada tipo de emoción en cada una de las cuatro lecciones seleccionadas. En este orden de ideas, se implementarán algoritmos de clustering que correspondan a estrategias particionales, utilizando medidas de distancia como deformación dinámica de tiempo (DTW), deformación dinámica de tiempo suavizada (S-DTW), alineación global de núcleos (GAK) y distancia basada en forma (SDB). Lo anterior dado que, como se ha expuesto previamente estas medidas de distancia son aplicables para series de tiempo de longitud variable. Esta implementación y pruebas de estos algoritmos se realizarán mediante el lenguaje de programación R, dado que presenta un paquete completo llamado dtwclust (Sardá-Espinosa, 2019), dedicado a este tipo de problemas. A partir de esto, se obtendrán, grupos de participantes que presenten comportamientos similares para cada emoción y para cada lección. Lo especificado para el modelo de learning analytics se condensa en la Figura 8.




Figura 8 Caso de estudio - componente modelo de learning analytics

De acuerdo con lo expuesto anteriormente, la interacción entre los componentes de la aplicación móvil de aprendizaje de segunda lengua, la recopilación y procesamiento de métricas emocionales y la definición del modelo de learning analytics, se expone en la Figura 9.




Figura 9 Definición del caso de estudio

Finalmente, en la siguiente sección se profundizará en el desarrollo e implementación del caso de estudio previamente expuesto. A partir de esto, se revisará en profundidad la estructura del curso “primeros pasos” de portugués. También, se abordará el proceso de

recopilación, procesamiento y anotación de los datos capturados a partir de la interacción de los participantes y la plataforma. Además de esto, se especificará la implementación computacional de cada componente del modelo de learning analytics. Por lo tanto, se abordará la generación de los dashboard y la implementación de los algoritmos de clustering. Y, por último, se definirá la proyección de resultados obtenidos a partir de la aplicación del caso de estudio.

Capítulo 4

Caso de estudio en profundidad

Esta sección tiene como finalidad, profundizar en la implementación del caso de estudio definido en capítulo 3. Por lo tanto, se presentará la estructura del curso de portugués seleccionado. También se expondrá el proceso de recopilación, procesamiento y anotación de métricas emocionales y de evaluación. Asimismo, se expondrá la implementación de las técnicas que componen el modelo de learning analytics planteado. Por último, se presentará la proyección de sección de resultados.

4.1 Estructura del curso de Babbel: portugués

Como se mencionó en Capítulo 3, el lenguaje seleccionado es el portugués, por medio del uso de la aplicación de Babbel. Además de especificar que se llevará a cabo el desarrollo de las cuatro primeras lecciones asociadas al curso de principiantes "mis primeros pasos" de este lenguaje. De esta forma, profundizando en la estructura y las lecciones que componen el curso "mis primeros pasos" de portugués en Babbel, expone la Tabla 1, donde se especifican las lecciones seleccionadas de este curso.

Tabla 1 Lecciones seleccionadas del curso de portugués

No.	Nombre	Descripción
1	Tudo bem? Primera parte.	Tiene como propósito adquirir conceptos como el saludo y dar las gracias.
2	Los pronombres personales en singular	Presenta explicaciones y actividades relacionadas con los pronombres personales singulares.
3	Tudo bem? Segunda parte.	Trata y desarrolla temas relacionados con despedidas y adición de conceptos referentes a la primera lección.
4	Tudo bem? Repaso	Presenta una revisión donde solo se exponen ejercicios a

		realizar utilizando los conceptos previamente adquiridos.
--	--	---

En este orden de ideas, la Figura 10, presenta la explicación de tema que toma lugar en la lección número 1.




Figura 10 Explicación de tema en lección 1

Adicionalmente, de acuerdo con lo expuesto en la sección 3.1, Babbel presenta ejercicios o actividades para aprendizaje de vocabulario, explicación o adquisición de nuevos de temas, ejercicios de repetición, ordenación de letras, ordenación de palabras en oraciones, traducciones, completar espacios en blanco, ejercicios de asociación entre palabras e imágenes, ejercicios de pronunciación, de escucha y de completar diálogos orientados a situaciones reales. Por esta razón y con el propósito de realizar un análisis diferencial pero compacto, se determina realizar agrupamiento y clasificaciones de estas actividades. La Tabla 2, presenta las agrupaciones y clasificaciones generadas.

Tabla 2 Agrupación y clasificación de actividades

Nombre Actividad	Síglas Actividad	Descripción
Explicación de tema	TE	Hace referencia a la introducción de un nuevo tema. Donde la plataforma presenta la explicación de dicho tema.
Aprendizaje de	VL	Sucede cuando la plataforma expone nuevo

vocabulario		vocabulario para ser adquirido.
Selección de opciones	OS	Hace referencia a una actividad donde se evalúa alguna competencia del participante, donde se le presentan algunas opciones a seleccionar o ejercicios a realizar.

La Figura 11, presenta un ejemplo de aprendizaje de vocabulario (VL) mediante la presentación del término de saludo “hola” tanto en español como portugués, como su respectiva pronunciación. Esto se presenta en la lección número 1, del curso primeros pasos.




Figura 11 Aprendizaje de vocabulario (VL) en lección 1

De esta forma, se generó la necesidad de realizar una subclasificación en subactividades para la actividad de selección de opciones (OS), dado que, este proceso se podría presentar de diferentes maneras, como por ejemplo ejercicio de traducción, de escucha, de pronunciación, entre otras. La Tabla 3, presenta las subactividades establecidas para la actividad de selección de opciones (OS).

Tabla 3 Subactividades de la actividad de selección de opción

Nombre Subactividad	Siglas subactividad	Descripción
Traducción correcta	TRA	Al usuario se le da una palabra en español y debe colocar su traducción en portugués.
Asociación correcta	ASSOC	Se expone una situación o premisa y se debe

		asociar el concepto correcto.
Dialogo	DLG	Se expone una conversación con palabras faltantes y se deben completar.
Ordenamiento de conceptos	ORD	Se presentan un conjunto de palabras y el participante debe ordenarlas de forma correcta para generar una frase.
Escucha y completa	LIS	Se exponen audios que contienen palabras en portugués y debe completar con lo escuchado.
Pronunciación	PRON	Se le expone un audio con la pronunciación de alguna palabra y el participante debe repetirla grabando su voz.
Unión de elementos	JOIN	El usuario debe unir los términos correctos en portugués con su respectiva representación en español.
No aplica	NA	Corresponde cuando una actividad no presenta subactividad, es decir como en el aprendizaje de vocabulario o en la explicación de tema. Solo la actividad selección de opción presenta subactividades.

Una vez se ha especificado la clasificación de actividades y subactividades definida, se procede a profundizar en el tipo de actividades que presentan cada una de las lecciones. En primer lugar, la lección 1, inicia con el aprendizaje de vocabulario (VL) donde se le permite al participante escuchar la pronunciación de términos iniciales y ver una imagen relacionada. Después, toma lugar la actividad de selección de opción mediante traducción (OS-TRA), donde al usuario se le presentan palabras en portugués y debe seleccionar la traducción en español correcta. Posteriormente, se explica la temática de esta lección (TE), la cual es dar las gracias en portugués. Después, el participante interactúa con un ejercicio de asociación (OS-ASSOC) de términos con imágenes. Finalmente, el participante debe completar un dialogo (OS-DLG), de una situación real que se puede vivir en el carnaval de Río de Janeiro.

Haciendo referencia a la lección 2, esta inicia con una actividad de aprendizaje de vocabulario (VL), sobre pronombres personales singulares. En esta oportunidad, se le expone una imagen al usuario asociada al pronombre, el pronombre en español y su respectiva traducción en portugués. Posteriormente, el participante desarrolla un ejercicio

de traducción. Acto seguido, se le da explicación de tema (TE) al participante, donde se expone el trato formal. Después, el usuario resuelve una actividad de pronunciación (OS-PRON), donde debe repetir algunos pronombres, hasta que el sistema de reconocimiento de voz lo acepte.

Por otra parte, se tiene la lección 3. Esta lección, inicia con el aprendizaje de nuevo vocabulario (VL). Posteriormente, al usuario se le presenta una imagen, su traducción en español y debe ordenar unas sílabas para generar la frase o palabra en portugués (OS-ORD). Después, se debe completar un diálogo (DLG), completando una conversación que toma lugar dentro de un vehículo de transporte. Acto seguido, se le explica el tema de artículos definidos singulares para género masculino y femenino (TE). Posteriormente, toma lugar una actividad de asociación, donde a partir de una imagen y la traducción en español, se debe seleccionar el artículo correcto (OS-ASSOC). Después, se vuelve a presentar una explicación de tema (TE), sobre artículos definidos en plural. Acto seguido, el participante resuelve una actividad de asociación para los artículos definidos en plural (OS-ASSOC). Finalmente, se le presenta al usuario una actividad de pronunciación (OS-PRON).

La última lección, solo contiene actividades de selección de opciones. La lección 4, inicia con una subactividad de traducción (OS-TRA), donde se expone la palabra en portugués y debe seleccionar su correspondiente equivalente en español. Después, toma lugar una actividad de ordenar palabras (OS-ORD), donde se presenta una frase en español y un conjunto de palabras en portugués, y se deben ordenar correctamente para generar la misma frase, pero en portugués. Posteriormente, se tiene el primer ejercicio de unión de términos, entre portugués y español (OS-JOIN). Después, el participante debe resolver un ejercicio de asociación de artículos definidos singulares y plurales (OS-ASSOC). Finalmente, se debe completar una conversación (OS-DLG), con una recepcionista en un lugar de relajación (spa). La Figura 12, presenta un ejemplo de la actividad de selección de opciones y subactividad de escucha (OS-LIS). Esto se presenta en la lección número 2.




Figura 12 actividad de selección de opción (OP) y subactividad escucha (LIS)

Este proceso de clasificación y agrupación de actividades y subactividades será utilizado durante el procesamiento de los datos emocionales definidos en el caso de estudio, los cuales son capturados durante la interacción de los participantes con las lecciones de portugués. A continuación, se expone la recopilación y procesamiento de estos datos.

4.2 Recopilación de métricas emocionales y evaluación

Esta sección presenta paso a paso la descripción del procedimiento que se llevó a cabo para realizar la captura de las métricas emocionales durante la interacción las lecciones de portugués de Babbel. Además, describe el procesamiento realizado a los datos, para generar una estructura de series de tiempo. Después, se expone el proceso de anotación de actividades para el conjunto de datos. Posteriormente, se presenta el proceso de consolidación de resultados obtenidos en las preguntas realizadas en la plataforma y el tiempo total de interacción. Finalmente, se expone la estructura general del conjunto de datos construido. El conjunto de datos expuesto en el desarrollo de esta sección está disponible en el siguiente repositorio de GitHub¹.

4.2.1 Recopilación de datos

La recopilación de datos se llevó a cabo a través de diferentes componentes. Estos componentes hacen referencia a, una plataforma móvil de aprendizaje de segunda lengua,

¹ https://github.com/AndresRestrepoRodriguez/Emotional_Dataset_Second_Language_Interaction_EDaLI

en este caso la aplicación Babbel, con el propósito de adquirir conocimiento de una lengua extranjera, como lo es portugués. Otro componente como una interfaz cerebro-computadora, para la captura de métricas emocionales durante la interacción de las personas con la aplicación de aprendizaje de segunda lengua. En este caso, puntualmente se ha usado un Emotiv Insight (Villegas Méndez & Rojas Fernández, 2018), capturando métricas emocionales como, interés, excitación, concentración, relajación, estrés y compromiso. La Figura 13, presenta de manera general el proceso de recopilación de datos.




Figura 13 Flujo para la captura de métricas emocionales

A partir de la Figura 13, se puede evidenciar que, inicialmente, se tiene instalada la aplicación Babbel en un dispositivo móvil, en este caso una Tablet con características básicas a nivel de software y hardware. Adicionalmente, el dispositivo cuenta con una aplicación para llevar a cabo la grabación de la pantalla durante la interacción del participante con la aplicación, lo cual permite grabar cada una de las interacciones e instrucciones del participante con la plataforma.

Adicionalmente, durante la interacción del participante con la plataforma, este usaba en su cabeza un dispositivo Emotiv Insight. De esta forma, el dispositivo Emotiv Insight provee

además de las señales cerebrales medidas directamente de los sensores, seis medidas de desempeño mental estimadas a partir de la actividad cerebral, las cuales son: Estrés, Concentración, Compromiso, Excitación, Interés y Relajación (Corredor Camargo et al., 2019). Además del uso del Emotiv Insight, fue necesario utilizar el lenguaje de programación Python, para realizar la conexión entre el dispositivo Emotiv Insight y un computador, con el fin de obtener y almacenar cada 10 segundos los valores de las métricas emocionales en un rango de 0 a 1, donde 1 indica mayor exposición a esa emoción y 0 una menor exposición. El proceso de conexión con entre Python y el Emotiv Insight, se realizó mediante Cortex API, la cual es expuesta por la compañía creadora de este dispositivo.

4.2.1.1 *Emotiv Insight para recopilación de datos*

Para llevar a cabo la captura de métricas emocionales ha sido necesario implementar un script en el lenguaje de programación Python, el cual se autentica automáticamente en API Cortex, comprueba el estado de conexión y calidad de contacto del Emotiv Insight. De esta manera, podrá consumir el streaming de las métricas emocionales con resolución de 0.1Hz. También, este script se encarga de tomar estos datos y almacenarlos en un tipo de estructura que pudiera ser cargada y procesada posteriormente a la captura de datos. Esta estructura de datos es un arreglo N-dimensional creado mediante Numpy (Walt et al., 2011) y almacenado mediante la librería Pickle. Los datos consolidados cada 10 segundos, presentaban dos campos clave, los valores de las métricas emocionales y la marca de tiempo asociada a esos valores. La Figura 14, presenta un ejemplo de la estructura de datos almacenada.

```
[
  {'time': timestamp, 'data':[metrics values]},
  {'time': timestamp, 'data':[metrics values]},
  ...
  {'time': timestamp, 'data':[metrics values]}
]
```

Figura 14 Estructura de datos crudos

4.2.2 Procesamiento de datos

Una vez se ha almacenado la estructura de datos de métricas asociadas a la interacción del participante con las cuatro lecciones seleccionadas para el aprendizaje de portugués en la aplicación de Babbel, se procede a realizar el procesamiento de estos datos. Este procesamiento consiste en, tomar cada una de las estructuras almacenadas, separar el campo 'timestamp' y 'data'. Inicialmente, se realiza ingeniería inversa para obtener la fecha a partir del timestamp. Posteriormente, se toma el nuevo campo de fecha

generado y los valores de las métricas asociadas a esa fecha. Una vez se ha creado este campo de fecha, se procede a eliminar la columna timestamp. Después, se adicionan los campos de identificador de usuario y el número de la lección. A partir de esto, se genera una estructura de datos tipo DataFrame, utilizando la librería Pandas. Sin embargo, en este punto se siguen presentando datos cada 10 segundos. Por lo tanto, con el fin de generar un dataset que presente una especificidad de 1 segundo, se procede a aplicar la técnica de interpolación lineal a los datos. De acuerdo con esto, se obtiene un DataFrame, el cual básicamente es una estructura de datos que se compone de filas y columnas. Este dataframe se obtiene para cada participante por cada lección, el cual contiene el identificador del usuario, la lección, la fecha asociada con su respectiva hora, minuto y segundo y los valores de las métricas de compromiso, excitación, estrés, relajación, interés y concentración. Lo anterior siendo presentado segundo a segundo gracias a la interpolación realizada. La Figura 15 presenta lo expuesto anteriormente.

	user_id	lesson	time_value	engagement	excitation	stress	relax	interest	focus
0	id_4	lesson_2	2022-02-27 18:00:00.596566	0.726623	0.167385	0.263859	0.269819	0.518935	0.287410
1	id_4	lesson_2	2022-02-27 18:00:01.596566	0.714163	0.168935	0.276033	0.291612	0.523398	0.293921
2	id_4	lesson_2	2022-02-27 18:00:02.596566	0.701704	0.170484	0.288208	0.313404	0.527861	0.300431
3	id_4	lesson_2	2022-02-27 18:00:03.596566	0.689244	0.172034	0.300382	0.335197	0.532323	0.306942
4	id_4	lesson_2	2022-02-27 18:00:04.596566	0.676784	0.173584	0.312557	0.356989	0.536786	0.313452
...	...	...	...	...	...	...	...	...	...
315	id_4	lesson_2	2022-02-27 18:05:15.596566	0.575122	0.658498	0.231879	0.378281	0.684784	0.171416
316	id_4	lesson_2	2022-02-27 18:05:16.596566	0.556606	0.669959	0.233469	0.377223	0.686979	0.170867
317	id_4	lesson_2	2022-02-27 18:05:17.596566	0.538089	0.681420	0.235059	0.376164	0.689173	0.170318
318	id_4	lesson_2	2022-02-27 18:05:18.596566	0.519573	0.692882	0.236648	0.375105	0.691368	0.169769
319	id_4	lesson_2	2022-02-27 18:05:19.596566	0.501056	0.704344	0.238237	0.374047	0.693562	0.169220

Figura 15 Métricas emocionales procesadas

No obstante, al conjunto de datos procesado se le escapa un factor importante de este estudio. Este aspecto es la anotación de datos. En este caso, en que actividad y subactividad se encontraba el participante en cada instante del tiempo. La siguiente sección tratará este proceso de anotación.

4.2.3 Anotación de datos

Esta etapa tiene como propósito realizar la anotación de la actividad y subactividad en la que se encontraba cada participante en cada instante t de tiempo de su interacción con la aplicación, una vez se inicia la lección correspondiente. Para poder realizar lo anterior, se presentan algunos aspectos como la revisión de las grabaciones, verificación de rango de marcas de tiempo de los datos asociados a las métricas emocionales,

generación de un archivo para la especificación de rangos de tiempo en cada actividad y por último la modificación de los datos sin anotación.

Inicialmente, se inicia la revisión, segundo a segundo de cada una de las grabaciones de interacción de los participantes con los 4 módulos de Babel. A partir de ello, se determina la cantidad de tiempo en segundos de interacción general de todo el módulo. Adicionalmente, para cada actividad y subactividad de cada módulo se especifica la marca de tiempo de inicio y de fin, obteniendo los segundos de diferencia. Lo anterior para poder identificar en que actividad se encontraba el participante en cada instante t de tiempo. Una vez se ha realizado esto, los datos son consolidados en un archivo con extensión JSON. Posteriormente, a partir de scripts generados en Python, se lee este archivo y se modifican los datos procesados con anterioridad. La Figura 16, presenta el resultado de la anotación.

	user_id	lesson	time_value	engagement	excitation	stress	relax	interest	focus	main_activity	sub_activity
0	id_4	lesson_2	2022-02-27 18:00:00.596566	0.726623	0.167385	0.263859	0.269819	0.518935	0.287410	VL	NA
1	id_4	lesson_2	2022-02-27 18:00:01.596566	0.714163	0.168935	0.276033	0.291612	0.523398	0.293921	VL	NA
2	id_4	lesson_2	2022-02-27 18:00:02.596566	0.701704	0.170484	0.288208	0.313404	0.527861	0.300431	VL	NA
3	id_4	lesson_2	2022-02-27 18:00:03.596566	0.689244	0.172034	0.300382	0.335197	0.532323	0.306942	VL	NA
4	id_4	lesson_2	2022-02-27 18:00:04.596566	0.676784	0.173584	0.312557	0.356989	0.536786	0.313452	VL	NA
...	...	...	...	...	...	...	...	...	...	...	...
315	id_4	lesson_2	2022-02-27 18:05:15.596566	0.575122	0.658498	0.231879	0.378281	0.684784	0.171416	OS	PRON
316	id_4	lesson_2	2022-02-27 18:05:16.596566	0.556606	0.669959	0.233469	0.377223	0.686979	0.170867	OS	PRON
317	id_4	lesson_2	2022-02-27 18:05:17.596566	0.538089	0.681420	0.235059	0.376164	0.689173	0.170318	OS	PRON
318	id_4	lesson_2	2022-02-27 18:05:18.596566	0.519573	0.692882	0.236648	0.375105	0.691368	0.169769	OS	PRON
319	id_4	lesson_2	2022-02-27 18:05:19.596566	0.501056	0.704344	0.238237	0.374047	0.693562	0.169220	OS	PRON

Figura 16 Métricas emocionales anotadas

En este punto, los datos se presentan como un conjunto de series de tiempo, donde para cada instante de tiempo, se mapea su respectivo valor de compromiso, excitación, estrés, relajación, interés y concentración. Además de indicar en que actividad principal y subactividad se encontraba. Sin embargo, la interacción con la aplicación de Babel y los niveles de portugués seleccionados, permiten determinar la cantidad de preguntas realizadas por módulo, la cantidad de preguntas correctas, las preguntas incorrectas y los intentos erróneos. Por tal motivo, la siguiente sección presentará el proceso de recopilación de estos datos.

4.2.4 Resultados de preguntas y tiempo

Como se ha mencionado previamente, la aplicación permite obtener al finalizar cada módulo el total de preguntas y la cantidad que se ha contestado correctamente. No obstante, no lo permite determinar para cada actividad y subactividad, si aplica el caso. Es

por esto, que se realiza una segunda revisión manual de los videos capturados, donde se evidencia la interacción de los participantes con Babbel. A partir de esta revisión se determina el total de preguntas, la cantidad de preguntas correctas, las preguntas incorrectas y los intentos erróneos. La Tabla 4, explica estos conceptos.

Tabla 4 Definición de resultados de preguntas

Concepto	Definición
Total preguntas	Corresponde a la totalidad de preguntas realizadas para un módulo determinado. Estas preguntas se encuentran repartidas entre las actividades de Explicación de tema (TE) y Selección de opción (OS).
Total correctas	Son las preguntas a las cuales el participante contestó de manera correcta.
Total incorrectas	Son aquellas preguntas que el sistema tomó como erróneas o que el participante utilizó una opción de ver la respuesta correcta o se saltó la pregunta.
Total intentos erróneos	Son la cantidad de veces que el usuario contestó erróneamente a una pregunta. Sin embargo, se traducen como intentos, dado que al segundo intento se podría haber proporcionado la respuesta correcta y el sistema no lo anota como pregunta incorrecta.

A partir de esta revisión, se define un archivo con extensión CSV donde se indica el orden de aparición de la actividad-subactividad, el total de preguntas, preguntas correctas, incorrectas e intentos erróneos. Una vez se ha realizado esto, con la ayuda de un script codificado en Python, se genera un archivo JSON donde se consolida, para cada actividad-subactividad los resultados de las preguntas mencionado anteriormente, y el total de segundos que ha tomado el participante durante cada ejercicio. De esta manera, para cada participante, se encuentra de forma resumida los resultados obtenidos durante su interacción y el tiempo. La Figura 17, presenta un ejemplo del archivo con extensión JSON generado.




Figura 17 Estructura archivo JSON de resultados

4.2.5 Dataset: Emotional Data L2 Interaction (EDaLI)

Durante la recopilación de los datos para la creación del conjunto de datos Emotional Data L2 Interaction (EDaLI), como se ha mencionado previamente participaron un total de 19 personas. Sin embargo, por aspectos éticos se protege la información personal de los participantes. No obstante, a manera general, en esta población se presentaba un total de 4 mujeres y 15 hombres, ubicados en un rango de edad entre 20 y 30 años. Además, todas las personas tenían nacionalidad colombiana y como lengua nativa el español. Además de esto, ninguno de los participantes presentaba conocimientos previos en la lengua portugués, siendo este su primer acercamiento con este lenguaje.

Por otro lado, una vez se ha llevado a cabo con éxito la recopilación de datos emocionales, el preprocesamiento, la anotación de actividades y, por último, la consolidación de resultados y tiempo, se publica el conjunto de datos EDaLI en el repositorio de GitHub². La Figura 18, presenta la estructura final del conjunto de datos creado.

²

https://github.com/AndresRestrepoRodriguez/Emotional_Dataset_Second_Language_Interaction_EDaLI




Figura 18 Estructura conjunto de datos EDaLI

A partir de esto, cada participante es propio de una carpeta, donde se encuentran las diferentes lecciones realizadas, en este caso, puntualmente 4 lecciones, las cuales también son carpetas. Dentro de cada lección, se encuentran dos archivos. La Tabla 5, presenta la explicación de estos archivos.

Tabla 5 Explicación archivos EDaLI

Nombre de Archivo	Descripción
data.csv	Contiene las series de tiempo para cada una de las métricas recopiladas. Adicionalmente, para cada instante de tiempo se presenta la actividad y subactividad en la cual se encontraba el participante.
results_time.json	Contiene el tiempo total en segundos, el total de preguntas, la cantidad de preguntas correctas, incorrectas y los intentos erróneos, para cada una de las actividades y subactividades que tomaban lugar en la lección de referencia.

4.3 Implementación del modelo de Learning Analytics basado en métricas emocionales

4.3.1 Visual Analytics

De acuerdo con lo mencionado en secciones anteriores, para llevar a cabo la analítica visual, se deben implementar un conjunto de dashboards que permitan observar el comportamiento emocional y los resultados obtenidos por los participantes, durante la interacción con el curso “primeros pasos” de portugués proporcionado por Babel. Además, este análisis se debe poder realizar tanto para un solo participante (Individual) como para un grupo de participantes (Grupal). De esta manera, se podrá realizar el análisis para una sola lección, para un conjunto de lecciones, para una actividad específica en un conjunto de lecciones y para una subactividad.

En este orden de ideas, y con el propósito de desarrollar el análisis visual de los datos recopilados previamente, se estableció un repositorio de GitHub³, donde se centraliza el código para la implementación de los dashboards mencionados previamente. Este proyecto de código se implementó mediante el uso de Python como lenguaje de programación y de paquetes como Pandas (McKinney, 2010), Numpy (Harris et al., 2020), Plotly (Sievert, 2020) y Dash (Dabbas, 2021). En este orden de ideas, se generaron diferentes módulos y scripts, con el fin de procesar los datos y prepararlos, para poder graficarlos. En el repositorio mencionado anteriormente, se encontrarán dos módulos y un script invocador, de la siguiente manera:

- **Módulo graph:** Contiene scripts que prestan las funcionalidades necesarias para realizar los diferentes gráficos que contienen los dashboards. Por tal motivo, utiliza las librerías de Plotly y Dash.
- **Módulo timeseries:** Este módulo se encarga de cargar los datos de las series de tiempo emocionales anotadas y, de los resultados y tiempos de interacción. Además, se presentan funcionalidades para realizar procesamiento y operaciones sobre las series de tiempo. En este módulo, se hace uso de librerías como Pandas, Numpy y Json.
- **Script analysis_generation.py:** Este script, se encarga de importar los módulos de graph y timeseries, y a partir de esto, generar los diferentes dashboards mencionados previamente.

³ https://github.com/AndresRestrepoRodriguez/Emotional_Time_Series/tree/develop

Adicionalmente, en este Notebook de Colab⁴, se puede evidenciar, como se puede consumir el código generado. A continuación, se exponen las gráficas utilizadas para cada tipo de análisis.

4.3.2 Análisis Grupal

La Figura 19, presenta los Mockups de los dashboards generados para el análisis visual del comportamiento emocional y resultados del grupo de participantes en una lección (Figura 19A) y en un conjunto de lecciones (Figura 19B). Inicialmente, la Figura 19A, se compone por 4 secciones, donde la primera corresponde a un conjunto de gráficos de línea para cada emoción. De esta manera, en cada gráfico, cada uno de los integrantes del grupo que se está analizando, tendrá una línea, para poder observar su comportamiento a través del tiempo. La sección 2, expone las distribuciones de los valores asociados a cada emoción de forma unificada. Por lo tanto, se tendrán tantos histogramas como emociones se analicen. Finalmente, la sección 3 y 4, se componen de tablas de resumen, gráficos de barras y diagramas de torta. Los anteriores gráficos, tiene como propósito presentar los tiempos y resultados obtenidos por el grupo a nivel general durante su interacción con la lección seleccionada para el análisis.

Por otra parte, la Figura 19B, presenta el análisis visual del comportamiento emocional y resultados del grupo de participantes para un conjunto de lecciones. En este caso, no se utilizan gráficos de línea, dado que, para cada estudiante corresponderían tantas líneas como lecciones se analizarán, lo cual podría obstaculizar la visualización de comportamientos. De esta forma, este dashboard contiene 4 apartados. El apartado 1, indica la distribución de valores emocionales de manera unificada. Es decir, se filtrarán los datos de tal manera que se unirán los valores de las métricas emocionales por tipo de emoción. De esta manera, se obtendrán 6 histogramas, uno para cada emoción. En este mismo sentido, se tiene la sección 2, la cual tiene un gráfico por cada emoción, en donde, se superpondrán los histogramas unificados para cada lección, por lo tanto, por emoción habrá tantos histogramas como lecciones. Por último, la sección 3 y 4, exponen tablas de resumen, gráficos de barras y diagramas de torta. Lo anterior, para mostrar los tiempos y resultados obtenidos por el grupo a nivel general durante su interacción con cada una de las lecciones analizadas.

4

https://github.com/AndresRestrepoRodriguez/Emotional_Time_Series/blob/develop/Test_Emotional_Series_Interaction.ipynb



Figura 19 Mock Up análisis visual grupal para una lección (A). análisis visual grupal para un grupo de lecciones (B)

En este mismo orden de ideas, la Figura 20, presenta los Mockups de los dashboards generados para el análisis visual del comportamiento emocional y resultados grupales en un conjunto de lecciones y una actividad específica (Figura 20A), y este mismo análisis, pero agregando una subactividad determinada (Figura 20B). Para el dashboard (Figura 20A), se tiene un total de 4 secciones. La primera sección, presenta la distribución de valores emocionales unificado por cada emoción. Esta palabra unificada hace referencia a que, se tomarán todas las lecciones de los participantes que ponen el grupo, se identificarán los valores emocionales experimentados y se unificarán en una única distribución por emoción. Esto, permite evidenciar acumulación de valores en la actividad definida. Posteriormente, la sección 2 expone histogramas superpuestos de las distribuciones de valores emocionales para cada lección en la que aparezca la actividad seleccionada. Después, la sección 3 tiene como objetivo presentar la acumulación de tiempos de interacción del grupo con la actividad especificada, es decir, sumará todos los tiempos que el usuario interactuó con dicha actividad para cada lección. Lo anterior, lo expone mediante una tabla de resumen, un diagrama de barras y un gráfico de torta para

la comparación de tiempos. Finalmente, la sección 4, presenta los resultados obtenidos de las preguntas realizadas durante la actividad que se desea analizar para todo el grupo, acumulando los resultados. Por otro lado, el dashboard presentado en (Figura 20B) tiene la misma estructura que el dashboard asociado a la Figura 20A. No obstante, para obtener estas gráficas no solo se filtra la actividad, sino que, se filtran los instantes de tiempo asociados a la interacción con la subactividad que se desea analizar.




Figura 20 Mockup análisis visual grupal para una actividad (A). Mockup análisis visual grupal para una subactividad (B).

4.3.3 Análisis Individual

La Figura 21, presenta los Mockups de los dashboards generados para el análisis visual del comportamiento emocional y resultados de un participante en una lección (Figura 21A) y un conjunto de lecciones (Figura 21B). En este orden de ideas, el dashboard de la Figura 21A, expone 5 secciones. La sección número 1, corresponde a un gráfico de línea, donde cada línea representará los valores emocionales experimentados por el participante en cada instante de tiempo. Además, se pigmentarán los intervalos de tiempo asociados a las distintas actividades que se le presentan secuencialmente al

participante. De esta manera, este gráfico ayudará a ver el comportamiento emocional a detalle en cada tipo de actividad realizada. Después, se encuentra la sección 2, la cual expone la distribución de los valores de las métricas emocionales mediante histogramas, generando un histograma para cada una de las emociones. De esta manera, se podrá visualizar donde se encuentra la mayor acumulación de valores en las métricas emocionales experimentadas, aislando el factor temporal. La sección 3, expone un mapa de calor asociado al componente temporal. Es decir, se podrá visualizar donde se presentan concentraciones altas de valores emocionales sin aislar el factor tiempo. En este orden de ideas, se expone un gráfico para cada emoción. Posteriormente se encuentra la sección 4, la cual está dedicada a presentar los datos de tiempos de interacción que tuvo el participante con la lección especificada. Es decir, se tomará la lección y desglosará el tiempo empleado en completar cada una de las actividades que componen dicha lección. En este orden de ideas, se empleará una tabla para resumir los tiempos, un gráfico de barras para poder compararlos fácilmente y un diagrama de torta, para visualizar cuál actividad le ha tomado mayor tiempo completar, a nivel porcentual. Finalmente, la sección 5, expone los resultados obtenidos por el usuario para cada actividad de la lección y también a manera general, es decir en la completitud de la lección. De esta forma, se expondrá el total de preguntas, total de respuestas correctas, incorrectas y de intentos erróneos. Para lo anterior, se utilizará una tabla de resumen, un diagrama de barras y un diagrama de torta, de tal forma que, es posible identificar en qué tipo de actividades el participante tuvo más preguntas correctas, incorrectas y más cantidad de intentos erróneos.

Por otra parte, el dashboard para un participante y un conjunto de lecciones (Figura 21 B), presenta 5 secciones. En este caso, la sección 1 presenta múltiples gráficos de línea, un gráfico para cada emoción. En este orden de ideas, en cada gráfico de líneas, se tendrán tantas líneas como lecciones se estén analizando. De esta manera, se podrá analizar el comportamiento emocional diferenciado y comparado para cada lección. La sección 2, presenta seis histogramas, uno para cada emoción, donde se visualizará aglomeraciones de los valores emocionales aislando el componente temporal. En este caso, no se realiza diferenciación por lección, se agrupan todos los valores asociados a cada emoción para todas las lecciones. Posteriormente, en la sección 3, se visualizan distribuciones emocionales como en la sección anterior. No obstante, en este caso se exponen para cada emoción las superposiciones de los histogramas asociados a cada lección. Después, la sección 4 hace uso de una tabla de resumen, un gráfico de barras y un diagrama de torta, para exponer los tiempos generales de interacción para cada lección. En este caso sin desglosar las actividades. Lo mismo sucede en la sección 5, haciendo uso de los mismos gráficos, pero con el objetivo de mostrar el resumen de los resultados de las preguntas de

cada lección. Evidenciando, en cual lección el estudiante presentó más errores y más intentos erróneos.




Figura 21 Mockup análisis visual individual para una lección (A). Mockup análisis visual individual para un grupo de lecciones (B)

En este mismo sentido, la Figura 22, presenta los Mockups de los dashboards generados para el análisis visual del comportamiento emocional y resultados de un participante, un conjunto de lecciones y una actividad puntual (Figura 22A), y este mismo análisis, pero agregando una subactividad específica (Figura 22B). Para el dashboard (Figura 22A), se tiene un total de 5 secciones. La primera, corresponde a un conjunto de gráficos de líneas, uno para cada emoción. Donde, se expone los valores emocionales experimentados por el participante, durante la interacción con la actividad definida, para cada lección en la que tome lugar dicha actividad. Es posible que una actividad aparezca múltiples veces en una lección, por lo tanto, una lección puede tener múltiples líneas en cada gráfico. En este caso,

se filtran los datos de tal forma que, solo se tengan en cuenta los valores de las métricas emocionales asociadas a dicha actividad. Después la sección 2, presenta la distribución de valores emocionales unificado por cada emoción. Por lo tanto, se tomarán todos los valores emocionales experimentados en la actividad seleccionada y se unificarán en una única distribución. Posteriormente, la sección 3, es similar a la sección 2, pero, con la diferencia que no se unifican los histogramas. Es así como, se superponen para evidenciar comportamientos similares entre las diferentes lecciones. Después, la sección 4 tiene como objetivo presentar los tiempos asociados a la interacción del participante con la actividad especificada, es decir, sumará todos los tiempos que el usuario interactuó con dicha actividad para cada lección. Lo anterior, lo expone mediante una tabla de resumen, un diagrama de barras y torta para la comparación de tiempos. Finalmente, la sección 5, presenta los resultados obtenidos de las preguntas realizadas durante la actividad que se desea analizar. En este caso, se exponen los resultados para cada lección, y se utiliza una tabla de resumen, un diagrama de barras y torta para la comparación estos resultados.

Por otro lado, el dashboard para visualizar el comportamiento emocional y resultados de un participante, un conjunto de lecciones, una actividad y subactividad específica (Figura 22B) tiene la misma estructura que el dashboard asociado a la Figura 22A. No obstante, para obtener estas gráficas no solo se filtra la actividad, sino que, se filtran los instantes de tiempo asociados a la interacción con la subactividad que se desea analizar. Esto permite, un análisis más profundo y focalizado en los tipos de ejercicios que realiza el participante.




Figura 22 Mockup análisis visual individual para una actividad (A). Mockup análisis visual individual para una subactividad (B)

4.3.4 Clustering emocional

Como se ha mencionado en secciones anteriores, el modelo de learning analytics aplicará técnicas de clustering para series de tiempo de longitud variable, para cada serie de datos emocionales recopiladas en cada lección del curso de portugués. Además, se ha definido implementar algoritmos bajo la estrategia particional, utilizando medidas de distancia como deformación dinámica de tiempo (DTW), deformación dinámica de tiempo suavizada (S-DTW), distancia global de alineación de núcleos (GAK) y distancia basada en forma (SDB). Dado que, estas medidas de distancia son aplicables para series de tiempo de longitud variable. Con el fin de resolver lo anterior, se hace uso del paquete *dtwclust* disponible en el lenguaje de programación R. Este paquete, expone funcionalidades para realizar agrupación de series temporales junto con técnicas optimizadas relacionadas con la distancia de deformación temporal dinámica y sus límites inferiores correspondientes. Están disponibles implementaciones de agrupamiento particional, jerárquico, difuso, k-Shape y TADPole. También se proporcionan implementaciones de DTW, distancia basada en núcleos de alineación global (GAK) y distancia DTW suave. También, incluye

funcionalidades para evaluar las agrupaciones generadas, exponiendo índices de validación internos y externos (Sardá-Espinosa, 2019). En este caso, como no se cuenta con etiquetas de los grupos a formar, se utilizará la validación interna mediante índices como Silhouette, Davies-Bouldin y Calinski-Harabasz.

En este orden de ideas, se implementó un script en R, haciendo uso de las funcionalidades expuestas por *dtwclust*. En este script, se realiza la lectura de las series de tiempo emocionales procesadas previamente para cada uno de los usuarios. Estos datos se separan por tipo de emoción y lección. Posteriormente, se definen configuraciones de comparación para los algoritmos de clustering. Lo anterior dado que, *dtwclust* proporcionar la función *compare_clusterings_configs*. Esta función permite definir que tipos de algoritmos se probarán, bajo qué tipo de distancias, la cantidad de iteraciones máximas para los algoritmos particionales y la cantidad de grupos a probar. En este caso es posible indicar un rango de valores para definir la cantidad de grupos que se desean probar junto con la combinación del resto de parámetros. De esta manera se probarán todas las posibles combinaciones. Adicionalmente, esta función permite obtener la mejor configuración de los parámetros, tomando como métrica de decisión el índice de Silhouette. La Tabla 6, presenta la configuración definida.

Tabla 6 Configuración de algoritmos de clustering

Parámetro	Valor
Número de clústeres	Rango de 2 a 18
Tipo de algoritmo	Particional
Tipo de centroide	Pam y Shape
Iteraciones máximas	50
Preprocesamiento	Ninguno y Normalización Z-Score.
Distancias	sbd, dtw, s-dtw y gak.

De acuerdo con la Tabla 6, los algoritmos a probar son de tipo particional, los tipos de centroides serán basados en extracción de forma (Shape) y Partición Alrededor de Medoids (PAM) o también conocido como k-medoids. También, se define un rango de clústeres entre 2 a 18, es decir el número de participantes. Este valor se tomó como límite, con el fin de probar si entre el comportamiento emocional analizado de los participantes no se encontraba ninguna similitud. Además, el algoritmo particional, presenta un máximo de 50 iteraciones, lo cual indica que, debe converger antes de llegar a ese número de iteraciones. También, a los datos es posible aplicarle una normalización mediante z-score

o dejarlos en sus valores iniciales. De igual manera, al dejarlo en sus valores originales, los datos emocionales se encontrarán en un rango de 0 a 1, dado que, de esa manera han sido almacenados y procesados previamente. Para el centroide de tipo Shape, se tendrá intrínsecamente la normalización mediante z-score. Por último, se definen como posibles medidas de distancia SBD, DTW, S-DTW y GAK.

En este orden de ideas, y según la configuración explicada anteriormente, es posible generar 204 combinaciones para cada emoción y lección, este número de combinaciones se traducirán en modelos entrenados. Por lo tanto, en total se entrenarán en total 4896 modelos de clustering para series de tiempo de longitud variable. Una vez se han entrenado y evaluado los 204 modelos para una lección y emoción específica, se procede a almacenar la configuración y las métricas, del mejor modelo de acuerdo con el coeficiente de Silhouette. El script descrito a lo largo de esta sección se encuentra en el siguiente repositorio⁵.

4.4 Proyección de resultados

Esta sección, tiene como finalidad exponer la forma en que se presentarán los resultados obtenidos al aplicar el modelo de learning analytics implementado a los datos emocionales y de aprendizaje recopilados y procesados. Por el lado de resultados de la analítica visual, de acuerdo con la implementación, se tendrían cuatro dashboards para el análisis grupal, donde se analiza el comportamiento emocional y los resultados obtenidos para una lección en particular, un conjunto de lecciones, una actividad y subactividad específica a lo largo de la interacción con todas las lecciones del curso de portugués. En este orden de ideas, se expondrán estos dashboards seccionando cada uno de los apartados explicados en secciones previas.

No obstante, para el análisis individual esta situación es diferente, dado que, se tienen los mismo 4 dashboards, con la diferencia que no se analiza el grupo sino a un participante específico. De esta forma, al analizar cada una de las 4 lecciones, 3 actividades y 7 subactividades, por participante se obtienen 15 dashboard y si multiplicamos este valor por la cantidad de participantes que es 19, en total serían 285 dashboards. Lo anterior, podría desencaminar el propósito verdadero de estos resultados. Por tal motivo, para exponer los resultados a nivel individual de la etapa de analítica visual, se seleccionará un solo participante, una sola lección, también se expondrá el análisis para el conjunto de

5

https://github.com/AndresRestrepoRodriguez/Emotional_Time_Series/blob/develop/timeseries_clustering.R

lecciones, pero solo para una actividad y una subactividad, esto acotará los resultados presentados. Adicionalmente, a partir de los dashboards que se presentarán en los resultados, se generarán inferencias, comentarios y recomendaciones.

Por último, para la etapa de clustering de series de tiempo emocionales, se presentará dos tablas resumen para cada lección. Donde, la primera de estas tablas expondrá la mejor configuración de clustering para cada una de las emociones, acompañada de los índices de validación interna obtenidos. La segunda tabla, contendrá los participantes que componen los diferentes grupos generados por las configuraciones previamente expuestas.

Capítulo 5

Resultados y análisis

A lo largo de este capítulo, se expondrán y analizarán los resultados obtenidos al aplicar el Modelo planteado de Learning Analytics a los datos de métricas emocionales y de aprendizaje recopilados. Se realizará, el análisis por separado para el enfoque de analítica visual y de clustering emocional.

5.1 Enfoque de técnicas de visualización

En esta sección, se presentarán las visualizaciones implementadas. Inicialmente se mostrará los resultados obtenidos para el grupo general, es decir los 19 participantes. En este caso, se ha tomado como lección 4, como objetivo de análisis profundo, dado que, es la lección donde los participantes practican de forma continua los conocimientos y conceptos adquiridos. No obstante, cuando sea posible, también se realiza un análisis más breve de la lección 2. Para el análisis de la actividad específica se ha definido la de selección de opción (OS), dado que, es la que más aparece más veces durante todas las lecciones, por lo tanto, genera mayores datos a analizar. De igual manera, la subactividad Dialogo (DLG), se ha seleccionado para visualización detallada. También se realizará un análisis breve para la subactividad de Pronunciación (PRON). Lo anterior, dado que, son actividades en las que se han presentado mayores dificultades por parte de los estudiantes.

Posteriormente, se presentarán los resultados para un solo participante, en este caso se ha seleccionado al número 4. A partir de esto, se seguirán los mismos lineamientos planteados para el análisis grupal. Por lo tanto, se tomará como lección objetivo la número 4 y de forma breve la número 2, como actividad principal de análisis la selección de opciones (OS) y en cuanto a subactividades se tendrán en cuenta DLG y un poco más breve el análisis para PRON.

5.1.1 Análisis grupal

En el análisis grupal se expondrá los resultados de la siguiente manera. Primero el análisis para el grupo y todas las lecciones. Después, el grupo contra una lección definida, principalmente la número 4 y secundaria la número 2. Posteriormente, se analizará el comportamiento y resultados del grupo frente a la actividad de selección de opciones (OS). Finalmente, se cierra con el análisis del grupo durante su interacción con las tareas de completar diálogos (DLG) y de pronunciación (PRON).

5.1.1.1 Grupo y lecciones

Realizando el análisis a nivel grupal para todas las lecciones, llevando a cabo las distribuciones unificadas mediante histogramas, en cuanto a compromiso, se evidencian una tendencia a presentar valores por encima de 0.4 hasta 0.8. Sobre los cambios fisiológicos en el grupo asociados con la excitación, no se ve que hayan experimentado cambios notorios, puesto que la aglomeración de datos se encuentra cercano a 0.2. Se evidencian algunos valores mayores a 0.4, realizando la separación por lecciones se podría identificar a cuál lección corresponden estos datos. Estrés, relajación y concentración, con agrupación de datos cercana a valores bajos. Mientras que, en cuanto a interés una distribución menos achatada, con concentración entre 0.5 y 0.6. Podría indicar una ligera inclinación hacia el gusto del curso en general (Figura 23).




Figura 23 Distribución Unificada de Métricas Emocionales grupo y lecciones

La Figura 24, tiene como objetivo mostrar las distribuciones de datos para cada emoción realizando una diferenciación entre las lecciones, de esta manera superpone los histogramas. Sin embargo, se sigue presentando el mismo comportamiento presentado en la Figura 23. Salvo por la excitación, dado que se podría decir que la lección 2, hizo que algunos participantes experimentarían valores más altos tal vez no tan constantes, sin embargo, pudo generar algún tipo de variación fisiológica en algunos de ellos.



Figura 24 Distribución Superpuesta de Métricas Emocionales grupo y lecciones

Por otra parte, la Figura 25, expone los tiempos acumulados por el grupo para cada lección. Donde, la lección 2, 3 y 4, presentan tiempos de interacción similares. La única que no sigue este patrón, es la lección 1, puede suponer que, al ser la lección inicial la carga sea baja y su resolución sea más rápida.



Figura 25 Medición de tiempo grupo y lecciones

En cuanto a resultados obtenidos (Figura 26), el grupo en general tuvo un buen rendimiento, con el 88.2% de éxito respondiendo las preguntas realizadas. En general tuvo un porcentaje de 3.89% de respuestas incorrectas y 7.94% de intentos erróneos. Donde se presenta la tasa más baja de respuestas incorrectas e intentos fallidos, es la lección número 1. En las lecciones 2, 3 y 4, se presentan respectivamente 41, 43 y 53 intentos erróneos, es decir que los estudiantes contestaban incorrectamente y el sistema les permitía seguir intentando o saltarse esa pregunta, siendo parejo. No obstante, la lección 4, expone la mayor cantidad de preguntas incorrectas, con un total de 38, frente al resto de lecciones. En este caso, esa lección como se ha mencionado en secciones anteriores corresponde a un repaso de los conceptos previamente aprendidos. Podría ser necesario focalizar un análisis en esta lección para identificar en qué tipo de actividades el grupo ha fallado con más frecuencia.



Figura 26 Resultados grupo y lección

5.1.1.2 Grupo y lección

Esta sección se realizará en análisis del dashboard generado para revisar los datos emocionales y resultados del grupo en tu totalidad, es decir los 19 participantes durante su interacción con la lección número 4. En la Figura 27, se exponen seis gráficos de línea, uno para cada emoción, donde, cada participante representa una línea. Tener tantas líneas puede llegar a provocar una sobrecarga en el gráfico, volviéndose difícil de comprender. No obstante, se puede resaltar que al estudiante número 6, le tomó un par de segundos más terminar esta lección, frente al resto de sus compañeros. También, en cuanto a la gráfica de interés, se puede ver que, el estudiante 4 y estudiante 7, presentan comportamientos un poco diferentes que el resto. Por un lado, el participante 4, presenta mayor interés que el resto de los participantes, además de una corta interacción. Mientras que, el participante 7, presenta un interés ligeramente más bajo que el resto. Sin embargo, es aquí donde las técnicas de clustering de series de tiempo de longitud variable, se puede convertir en una solución, para aislar la observación y poder abstraer comportamientos emocionales similares mediante algoritmos y matemática.




Figura 27 Grupo de registro de emociones grupo y lección

En cuanto a las distribuciones emocionales unificadas, para el compromiso, no se evidencia tendencia, puesto que, sus valores se ubican entre 0.3 y 0.8 para el grupo, casi evidenciando una distribución normal. En cuanto a excitación, se puede ver que el grupo

en general no presentó variaciones fisiológicas mientras realizaban la lección 4, dado que, la reunión de datos se encuentra en valores alrededor de 0.2. En cuanto a estrés, los valores se agrupan mayormente a la izquierda de 0.5, con valores agrupados entre 0.2 y 0.4. Por lo tanto, en general el grupo no presentó frustración en esta lección con sus actividades. Algo similar sucede con la relajación y la concentración. Su aglomeración de datos está alrededor del 0.4, distribuida uniformemente hasta 0.2 y 0.5. En cuanto al interés, el grupo no mostró una tendencia marcada de gusto o disgusto a la lección, dado que sus datos se agrupan alrededor de 0.55 (Figura 28).




Figura 28 Distribución Unificada de Métricas Emocionales grupo y lección

De acuerdo con la Figura 29, la cual expone los tiempos de interacción sumados de todos los participantes durante la lección 4, se puede ver que en general al grupo le tomo en total 4356 segundos. Esto podría indicar que en promedio esta lección puede tomar alrededor de 229 segundos lo cual equivale aproximadamente a 3 minutos con 50 segundos. Sin embargo, un estudiante se puede demorar más o menos que este tiempo. No obstante, si es importante resaltar que la actividad que más les tomó tiempo finalizar, fue la de completa del dialogo (DLG). Dado que, presenta aproximadamente 4x más de tiempo frente al resto de subactividades en esa lección. Los 1924 segundos que se presentan dialogo, corresponde al 44.2% del tiempo general de esta lección. De esta manera, se podría afirmar que a la mayoría del grupo o a una parte, este tipo de ejercicios donde se les expone un dialogo que representa una situación real, se les complica cuando deben escribir los términos por sí mismo sin ningún tipo de opciones. Esto puede inducir a permanecer más tiempo en dicho ejercicio, al pensar cómo se escribe correctamente la palabra que completa correctamente las frases del dialogo. El resto de las actividades, exponen tiempos similares.




Figura 29 Medición de tiempo grupo y lección

Por último, en cuanto a resultados, a partir de la Figura 30 el grupo tuvo en general 81.4% de respuestas correctas, en términos generales son buenos resultados. Solo el 7.76% son respuestas incorrectas. Incluso el porcentaje de intentos erróneos es de casi 11%. En este punto, no más allá de los porcentajes, es interesante observar, como la mayor cantidad de respuestas incorrectas y de intentos erróneos se ubican en la actividad de dialogo. Dado que, no es la actividad con más preguntas, la actividad con más preguntas es la actividad de traducción, y de 114 preguntas solo 1 estuvo incorrecta, y el grupo solo cometió 2 intentos erróneos, posiblemente asociados a esa respuesta incorrecta. Esto podría indicar que cuando se le presenta un término en el idioma que está aprendiendo, y se pueden observar las posibles traducciones, los participantes de este estudio, logran relacionar fácilmente con conceptos en español y portugués. Incluso, en este tipo de actividad no intervienen imágenes para realizar esa relación tan solo las posibles traducciones. En cuanto al dialogo, posiblemente los participantes en general no se sienten a gusto con esta actividad, donde deben escribir sin ningún tipo de pista, la palabra que completa cada cuadro de una conversación de un contexto real, en este caso la interacción con una recepcionista de un spa.




Figura 30 Resultados grupo y lección

Adicionalmente, se ha realizado el análisis para la lección número 2 enfocada al aprendizaje de pronombres personales singulares. En este caso, es relevante mencionar que, en distribuciones unificadas, se logra evidenciar un leve patrón en la acumulación de valores por encima de 0.5 en compromiso. No se presentan niveles de relajación, estrés y concentración altos. En cuanto a interés se mantiene cercano a 0.5, con algunas apariciones en valores de 0.7. Relacionado con el tiempo de interacción acumulado, el grupo en general gastó más tiempo en la explicación de tema, lo cual puede indicar que se tomaron en serio lo explicado en esta sección. En algunos casos cuando no se le presta atención a este tipo de actividad, su interacción puede ser fugaz. Después de la explicación de tema, se encuentra la subactividad de pronunciación con una diferencia de 400 segundos aproximadamente. Finalmente, en cuanto a resultados obtenidos en las actividades de la lección 2, relativamente el grupo tuvo un buen rendimiento con un 87.9% de éxito respondiendo las preguntas realizadas por la plataforma. No obstante, en la subactividad de pronunciación se presentaron 36 intentos erróneos, lo cual indica que puede ser un factor débil que tienen los integrantes del grupo.

5.1.1.3 Grupo, lecciones y actividad

Al analizar las distribuciones emocionales unificadas, a partir de la Figura 31, para la actividad de selección de opción (OS), la mayor agrupación de datos se ubica entre 0.4 y 0.8. Principalmente no expone una tendencia marcada a la experimentación de esta emoción. Por el contrario, para la excitación si se presenta tendencia a valores bajos, los participantes no presentaron altos niveles de excitación lo que se podía traducir en experimentación de variaciones fisiológicas. El grupo en general no presentó frustración durante el proceso de esta actividad. En cuanto a relajación y concentración, está más distribuida entre los valores de 0.2 y 0.6. A pesar de no tener un patrón diferenciado, se puede ver que la mayor agrupación de datos es en valores entre 0.3 y 0.4, lo cual denota baja relajación o meditación durante esta actividad y baja concentración. En cuanto a interés, encontramos un comportamiento intermedio, con una distribución cercana a 0.55. Ligera tendencia a gusto de la actividad, pero nada concluyente.




Figura 31 Distribución Unificada de Métricas Emocionales grupo, lecciones y actividad

Con la Figura 32, se busca tomar las agrupaciones emocionales unificadas y realizar una segregación por lección que contenga la actividad seleccionada. En este caso, se puede resaltar que para en la lección 2, 3 y 4, se presentan algunos valores de excitación experimentados por los participantes alrededor del 0.7. De igual forma sucede para el interés, donde las mismas lecciones presentan este comportamiento, con la diferencia que en alguna ocasión logran alcanzar valores cercanos a 0.8. Para resto de emociones, se evidencia comportamientos similares entre las lecciones.




Figura 32 Distribución Superpuesta de Métricas Emocionales grupo, lecciones y actividad

Continuando este análisis, se encuentra la Figura 33, la cual permite observar el tiempo empleado en la actividad de selección de opciones (OS), para cada lección. En este caso, donde mayor tiempo le ha tomado al grupo culminar estas actividades es en la lección 4, sin embargo, es un fenómeno normal, dado que, la última lección solo contiene este tipo de ejercicios.



Figura 33 Medición de tiempo grupo, lecciones y actividad

Finalizando este análisis, se tiene la Figura 34, la cual expone los resultados obtenidos a nivel grupal, para la actividad de selección de opción. De acuerdo con esta gráfica, durante la lección número 1, el grupo no cometió errores. Mientras que donde más intentos erróneos y respuestas incorrectas presentaron fue en la lección 4. También puede ser un comportamiento normal, por la naturaleza de la lección. No obstante, en términos generales, al grupo le fue bien, obteniendo un total de aproximadamente 87% de respuestas correctas, cuando se enfrentaban a este tipo de actividad.



Figura 34 Resultados grupo, lecciones y actividad

5.1.1.4 Grupo, lecciones, actividad y subactividad

Para finalizar, se tiene el análisis para el grupo, todas las lecciones, la actividad de selección de opción (OS) y la subactividad de completar el dialogo (DLG). Sin embargo, al observar las distribuciones unificadas para cada emoción en la Figura 35, se evidencia el mismo comportamiento descrito en la sección previamente anterior, específicamente en Figura 31.




Figura 35 Distribución Unificada de Métricas Emocionales grupo, lecciones, actividad y subactividad

Por otro lado, en la Figura 36, se realiza la separación de histogramas por cada lección en la cual se requiera llenar o completar una conversación escrita, relacionada con una situación del mundo real. Entre las distintas lecciones no se logra evidenciar una diferencia significativa entre las distribuciones de los valores emocionales.



Figura 36 Distribución Superpuesta de Métricas Emocionales grupo, lecciones, actividad y subactividad

Haciendo referencia a los tiempos de interacción con el proceso de completar diálogos escritos, se presenta la Figura 37. A partir de esto, se puede ver que la acumulación de tiempo es mayor para la lección 4. Como se ha mencionado previamente, puede ser por la naturaleza de la lección donde no se trabaja un tema específico como en las lecciones anterior, se trabajan todos los temas y términos aprendidos, y esto puede generar mayor dificultad para el grupo. Podría indicar que, en problemas que involucran distintos temas, a los estudiantes les toma mayor tiempo finalizar este tipo de ejercicios.




Figura 37 Medición de tiempo grupo, lecciones, actividad y subactividad

De igual manera, la Figura 38, nos muestra que, durante estos ejercicios de completar diálogos escritos, el grupo tuvo una tasa alta de intentos fallidos y de respuestas incorrectas frente al resto de lecciones. De esta manera, a nivel general, el rendimiento del grupo en esta actividad baja a un valor cercano a 73%. Esto quiere decir que, en general el grupo puede estar presentando inconvenientes con este tipo de ejercicios. Se podrían experimentar otras maneras de desarrollar conversaciones en contextos reales.




Figura 38 Resultados grupo, lecciones, actividad y subactividad

En este mismo orden de ideas, se realizó este análisis para la subactividad de pronunciación, la cual toma lugar en la lección 2 y 3. A nivel de distribuciones unificadas en cuanto a excitación e interés se presentan valores altos rodeando el 0.7. Sin embargo, entre la lección 2 y 3, no se presentan diferencias significativas. Referente a tiempo, la lección 2 duplica el tiempo de la lección 3. En promedio un estudiante puede estar tardando en completar la actividad de pronunciación alrededor de 69 segundos en la lección 2, mientras que en la lección 3, aproximadamente 36 segundos. Esto se puede presentar, porque en la lección 2 se involucran más palabras a pronunciar que en la lección 3. No obstante, según los resultados obtenidos del grupo en este tipo de ejercicio, se obtuvo un 64.4% de respuesta exitosas, dado que, se obtuvieron 11 respuestas incorrectas sumando ambas lecciones. Y para cada lección el grupo tuvo por encima de 30

intentos erróneos, 36 para la lección 2 y 31 para la lección 3. En este orden de ideas, se sigue evidenciando la dificultad que presentan estos ejercicios de pronunciación al grupo en general.

5.1.2 Análisis Individual

En el análisis individual se presentarán los resultados de la siguiente manera. Primero el análisis para el participante número 4 y todas las lecciones. Después, el mismo participante contra una lección definida, principalmente la número 4 y secundaría la 2. Posteriormente, se analizará el comportamiento y resultados de este participante frente a la actividad de selección de opciones. Finalmente, se cierra con el análisis del individuo durante su interacción con las tareas de completar diálogos y de pronunciación, a lo largo de todas las lecciones.

5.1.2.1 *Participante y lecciones*

En este caso se presenta el análisis para el participante 4 y todas las lecciones. A partir de la Figura 39, a nivel de compromiso se evidencia comportamientos similares a lo largo del tiempo para las lecciones 1, 2 y 4, presentando valores por encima de 0.6. No obstante, para la lección 3, el participante muestra poco compromiso. Existe la posibilidad que, durante esta lección el participante no se haya encontrado interesado en los términos expuestos. A nivel de estrés, las lecciones 2 y 4, presentan niveles bajos, pero la lección 1 y 3, exponen valores por encima del 0.5. Su nivel de frustración pudo haber aumentado durante estas lecciones. En cuanto excitación o variaciones fisiológicas, en todas las lecciones presenta comportamientos similares. De esta manera, durante los primeros segundos de interacción es baja, pero incrementa hacia el final de las lecciones 2, 3 y 4. Por ejemplo la lección 2 y 3, finalizan con un ejercicio de pronunciación y la lección 4 con un ejercicio de completar un dialogo. Podría indicar que este tipo de ejercicios causan algún tipo de reacción para ese participante. Por otro lado, en las lecciones donde el usuario presenta menor relajación, su compromiso presenta puntos altos. De igual manera que en el compromiso, el interés se mantiene bajo para la lección 3. En esa lección se trabajan los artículos definidos, el cual puede ser un tema aburrido para el estudiante.




Figura 39 Grupo de registro de emociones participante y lecciones

A partir de la Figura 40, la aglomeración de datos de compromiso se encuentra en valores mayores a 0.5. Indicaría que en su mayoría el participante estuvo alerta durante todo el curso. También, que no experimentó variaciones fisiológicas significativas. Que su interés no permite determinar si en general el curso le gustó o no, dado que muestra una concentración de datos cercana a 0.55, con pocos valores cercanos a 0.7. Además, expone una frustración que no evidencia notoriedad, con una distribución con tendencia uniforme en valores de 0.3 y 0.5.




Figura 40 Distribución Unificada de Métricas Emocionales participante y lecciones

Por otra parte, al separar las distribuciones de datos emocionales por emoción en la Figura 41, se observa la diferencia que se mostraba en la Figura 39, donde el compromiso de la lección 3 era bajo respecto al resto de lecciones. A nivel de excitación, todas presentan comportamientos similares, excepto durante la lección 2 que presenta una aglomeración leve pero notoria en valores cercanos a 0.7, relacionada con el incremento al final de la lección. En cuanto a estrés, se puede observar mayor frustración en lección 1 y 3. Tal vez, la lección 1 al ser el primer acercamiento con el idioma y la plataforma. En cuanto a interés, vemos un mayor gusto a la lección número 2, involucrando temas de pronombres personales, ejercicios de escuchar y pronunciación. En relación con lo anterior, donde

mayor relajación y menos compromiso presento el usuario fue en la lección 3. También, en la lección 2, es donde el usuario presenta buenos niveles de interés y de compromiso.



Figura 41 Distribución Superpuesta de Métricas Emocionales participante y lecciones

Haciendo referencia a los de tiempos de interacción, la lección 2 le ha tomado más tiempo que el resto de las lecciones. Sin embargo, a pesar de ser la más larga para este usuario, su compromiso se ha mostrado alto de acuerdo con análisis anteriores. Donde menor tiempo presentó fue en la lección número 1 (Figura 42).



Figura 42 Medición de tiempo participante y lecciones

En cuanto a los resultados obtenidos por el participante número 4 (Figura 43), la lección 1 tiene la menor cantidad de preguntas y es la lección de introducción al nuevo idioma. Por tal motivo, es posible que maneje una carga de dificultad baja. En las lecciones donde el participante número 4, presento mayor cantidad de intentos erróneos fue en la lección 2 y 4. Sin embargo, en la 4 tuvo más respuestas incorrectas. Pero en términos generales, el estudiante tuvo cerca del 85% de preguntas contestadas exitosamente. Sería importante, revisar puntualmente, la lección número 4, dado que, presenta mayor cantidad de preguntas con respuestas incorrectas, con el fin de identificar en qué tipo de ejercicio o ejercicios cometió estos errores.



Figura 43 Resultados participante y lecciones

5.1.2.2 Participante y lección

A partir de la Figura 44, se puede observar que durante la lección 4, el participante experimentó valores altos de compromiso. Lo cual indica que, durante esta lección se mantuvo alerta, estando inmerso en los ejercicios resueltos. Tan solo al inicio en la actividad de traducción (OS-TRA) esta emoción se mostró baja. Se debe recordar que esta lección está orientada a un repaso donde se utilizan los conceptos previamente aprendidos, y no se les proporciona ayuda a los participantes. Tal vez este es el motivo, de que el estudiante haya presentado esta atención. En cuanto a interés, el usuario lo expone constante con valores oscilantes entre 0.5 y 0.6. Puntualmente, al no expone valores ni altos ni bajos, al estudiante no le gusta ni le disgusta las actividades desarrolladas. Como se ha mencionado anteriormente, la excitación está relacionada con la variedad de respuestas fisiológicas, donde más alto sea el valor, entre más sea el aumento de la excitación fisiológica, mayor será la puntuación de salida para la detección. De acuerdo con esto, el participante durante las subactividades de traducción, ordenamiento y asociación no presentó mayores cambios. No obstante, en las tareas de unión y completar dialogo, si experimentó un salto de aumento, lo cual indica que durante estas actividades el tipo de material expuesto o tipo de tareas generó esos cambios. Podría ser por sentirse cómodo o incomodo con lo desarrollado. La relajación está asociada con meditación, al ser una tarea activa este valor es difícil que alcance valores altos. La concentración en este caso se evidencia constante, con valores relativamente medio-bajos. Lo anterior, indica que su atención no varía constantemente frente al cambio de tareas. Por último, el estrés no presenta valores altos, a lo largo del tiempo, se mantiene cercano al 0.4, por lo tanto, el participante no experimento un sentimiento de frustración notorio. Posiblemente, al entender que era una prueba controlada de un estudio, contrario a un curso donde exigen algún tipo de rendimiento. Adicionalmente, se puede observar que en la tarea en que más tiempo gastó el participante fue la de completar el dialogo.




Figura 44 Grupo de registro de emociones participante y lección

En este orden de ideas, a partir de la Figura 45, es posible confirmar que, para el compromiso, la aglomeración de los datos se encuentra entre valores 0.60 y 0.8, teniendo mayor concentración en 0.7. Además, es posible confirmar que, las métricas como relajación, concentración oscilan entre valores medios. El interés esta cercano a 0.5, sin embargo, la aglomeración se acerca levemente 0.6. De igual forma, nos confirma el comportamiento de estrés, oscilando entre 0.4 y 0.35. Por lo tanto, bajo estrés o frustración durante esta lección.



Figura 45 Distribución Unificada de Métricas Emocionales participante y lección

A partir de los mapas de calor presentados en la Figura 46, se pueden identificar tendencias temporales. En este orden de ideas, para el compromiso se puede observar la confirmación de un comportamiento constante en valores cercanos a 0.7, con un inicio por debajo de 0.6. Además, para la concentración se expone el comportamiento contante, con concentración y repetición en valores de 0.4. De igual forma, se logran evidenciar claramente los rangos de oscilación de las emociones, como por ejemplo para el interés, donde su rango se ubica aproximadamente entre 0.5 y 0.55. De esta misma manera, sucede con el estrés o frustración del usuario, que, a pesar de tener picos de incremento, estos valores no exceden el 0.45.




Figura 46 Mapa de calor de métricas emocionales participante y lección

En cuanto a tiempos de interacción, al usuario le tomó en total 274 segundos finalizar la lección, es decir 4 minutos con 34 segundos. A nivel específico, las actividades de traducción, ordenamiento y unión tienen un tiempo similar alrededor de los 40 segundos, siendo ejercicios que se componen de recursos fáciles de llevar a cabo. La tarea de asociación le ha tomado menos tiempo, fue más rápido para el usuario seleccionar respuestas que unir las, o traducir o incluso moverlas a su lado correcto. Por otro lado, la actividad que más tomó tiempo fue la de completar los diálogos, con un total de 124 segundos, alrededor de 3x más que el resto. Lo anterior, podría indicar que, el usuario no se siente a gusto en las actividades que involucran utilizar conceptos aprendidos en escenarios reales y más aún cuando no se le proporciona un conjunto de posibles opciones (Figura 47).



Figura 47 Medición de tiempo participante y lección

De acuerdo con la Figura 48, que tiene como propósito el análisis de los resultados obtenidos, se puede evidenciar que, en general, el usuario tuvo un 70.4% de respuestas contestadas exitosamente. Y tuvo un valor cercano a 15% de respuestas incorrectas y de intentos erróneos. Lo interesante respecto a esto, es que estos valores se dan a partir de la actividad de dialogo. Presentando 4 intentos erróneos, 4 respuestas incorrectas y 1 una respuesta correcta. De acuerdo con esto, al participante se le ha dificultado utilizar

términos que debe escribir sin ayuda, en algún contexto real. De esta manera, este comportamiento se ve reflejado en el tiempo que le tomó finalizar ese ejercicio, dado que, fue el más largo de todos.



Figura 48 Resultados participante y lección

Adicionalmente, a lo expuesto en este análisis, se analizó la lección 2, orientada a pronombres personales singulares, también para el participante número 4. Donde se observa que, durante las actividades de explicación de temática y pronunciación, los niveles de atención (compromiso) y excitación comienza a crecer. También es posible evidenciar que, por medio de las distribuciones emocionales, el estrés es bajo, concentrándose alrededor de 0.35, además, el interés presenta aglomeraciones de datos similares entre 0.5 y 0.55, y entre 0.65 y 0.7. Puede indicar que este participante sintió gusto por esta lección número 2. También, la concentración se mantuvo baja, mientras que, la excitación presenta valores cercanos a 0.2 y 0.7 en algunos casos, lo cual indica que no hay un patrón entre las actividades expuestas. Por otra parte, las actividades que más le tomaron tiempo a la persona desarrollar fue la explicación de tema y la pronunciación. En cuanto a la explicación de la temática es totalmente normal, dado que es donde la persona adquiere teoría sobre el tema. Mientras que, en cuanto a pronunciación, puede ser que se le dificulte al usuario, debido a que, la pronunciación y el entendimiento auditivo de una nueva lengua, pueden ser más demandantes, que la comprensión de la estructura gramatical. Por último, en cuanto a resultados, en esta lección número 2, el estudiante tuvo resultados perfectos para el aprendizaje de vocabulario, para actividades como traducción, escucha y preguntas realizadas durante la explicación de tema. Sin embargo, en el ejercicio de pronunciación, de 5 preguntas, tuvo 5 intentos fallidos, donde el sistema finalmente le tomó solo una respuesta incorrecta. No obstante, el volumen de intentos erróneos indica que realmente el usuario debe trabajar de mejor manera este tipo de actividad de pronunciación. También pueden existir factores de ruido que alteren el sistema de reconocimiento automático de voz que tiene Babbel. No obstante, dentro del

mercado de estas aplicaciones Babbel expone un sistema de reconocimiento automático de voz robusto.

5.1.2.3 Participante, lecciones y actividad

Como se ha mencionado anteriormente, la actividad seleccionada fue la selección de opciones (OS). En la Figura 49, se puede ver que para cada lección se puede encontrar una o más líneas, que representan las métricas emocionales experimentadas. Lo anterior dado que, en una misma lección este tipo de actividad se puede presentar en más de un periodo de tiempo. Por lo general, se observan comportamientos similares entre las líneas del mismo tipo de actividad. Tal vez, excepto en la lección 2, haciendo referencia en emociones como interés, excitación y compromiso. En algunas de las interacciones de la actividad de selección de opciones, estas tres métricas aumentan y particularmente, este fenómeno sucede en las interacciones más largas. Posiblemente, este usuario se pueda sentir más cómodo con ejercicios que requieran un poco más de análisis o tiempo de resolución. En compromiso, el participante en las interacciones con esta actividad siempre presenta valores bajos, durante la lección 3.




Figura 49 Grupo de registro de emociones participante, lecciones y actividad

Al revisar la Figura 50, en general se puede evidenciar una inclinación hacia los valores mayores a 0.5, en la distribución unificada de compromiso, durante la actividad de selección de opciones. Por otro lado, se ve una tendencia hacia valores por debajo de 0.4 a nivel de excitación. El participante, en esta lección a lo largo de esta actividad, no mostró altos niveles de estrés y su interés, a pesar de concentrarse en 0.55, presenta un par de apariciones en valores por encima de 0.6.




Figura 50 Distribución Unificada de Métricas Emocionales participante, lecciones y actividad

De acuerdo con la Figura 51, todas las lecciones presentan distribuciones de compromiso similares, excepto la lección 3. En esta lección, como se había visto en el gráfico de líneas, presentaba valores más bajos. En cuanto a excitación y variaciones fisiológicas, de acuerdo con esta gráfica, durante la lección 2, el participante experimentó mayores valores asociados a esta métrica. A nivel de estrés, se puede ver que durante la lección 1 y 3, el participante mostró mayor nivel de frustración, tal vez, la ansiedad generada por la primera lección pudo influir. Por lo tanto, podría ser necesaria una etapa de acondicionamiento y conocimiento con la plataforma.



Figura 51 Distribución Superpuesta de Métricas Emocionales participante, lecciones y actividad

A nivel de tiempos de interacción se tiene la Figura 52. A partir de esto, se observar que, la lección en donde le tomó más tiempo finalizar las actividades de selección de opciones fue la lección número 4. Recordemos que esta lección está orientada a un repaso o conjunto de actividades para aplicar los términos previamente adquiridos. Puede ser normal, dado que la lección 4, solo se compone de este tipo de actividad de selección de opción. No obstante, en las otras lecciones, este tipo de actividad también ha tomado un tiempo prudente, como en la lección 2. Esto quiere decir, que la plataforma se asegura de exponer plenamente al usuario a este tipo de ejercicios.




Figura 52 Medición de tiempo participante, lecciones y actividad

En este mismo orden de ideas, la Figura 53, presenta los resultados obtenidos específicamente para esta actividad a lo largo de las lecciones. Se puede observar que, la lección 4 tenía la mayor cantidad de preguntas asociadas a esta actividad. Incluso, en esa actividad el participante cometió la mayor cantidad respuestas incorrectas. No obstante, donde el estudiante tuvo que corregir más veces sus respuestas fue durante la lección 2.



Figura 53 Resultados participante, lecciones y actividad

5.1.2.4 Participante, lecciones, actividad y subactividad.

Profundizando un poco más en el análisis, ahora se presentarán los gráficos para la revisión de un estudiante, todas las lecciones, la actividad selección de opción (OS) y la subactividad de completar diálogos (DLG). En este caso, esta subactividad aparece en 3 lecciones, la lección 1, 3 y 4. En la Figura 54 se puede observar que, durante la lección 4, le ha tomado más tiempo completarla respecto al resto de lecciones. No obstante, no interfirió en la atención prestada, dado que a lo largo del tiempo se miente oscilando entre 0.6 y 0.8. En la lección 1, su atención estuvo cercana a 0.5 y 0.6, y en la lección 3, su nivel de compromiso estuvo por debajo de 0.4. En este orden de ideas, a pesar de que el tiempo fue mayor durante la lección 4, su estrés se mantuvo constantemente bajo. Su interés también creció en algunos instantes de tiempo, sin embargo, también se nota un comportamiento estable entre 0.5 y 0.55. Por otro lado, su nivel de concentración si fue un

poco más elevado en la lección 4 en el tramo final de la interacción, en comparación con las otras lecciones.




Figura 54 Grupo de registro de emociones participante, lecciones, actividad y subactividad

A partir de la Figura 55, se pueden analizar las distribuciones de métricas emocionales, al unificar los tramos de tiempo de las lecciones, donde toma lugar la subactividad de dialogo. A partir de esto, se observa dos secciones separadas a nivel de compromiso. Sin embargo, hay mayor concentración de datos cercanos a 0.7. Podría indicar que, en este tipo de actividades de completar diálogos, el participante presta mayor atención y está inmerso en el proceso, tal vez al ser expuesto en una situación real. En cuanto a excitación, se evidencia un comportamiento uniforme al aislar el factor temporal, donde sus datos se agrupan en valores menores a 0.4. Lo mismo sucede con el estrés, la frustración experimentada por el usuario no fue alta, salvo algunos valores ubicados en 0.55, no obstante, sigue siendo bajo. Su Interés, está ubicado en aproximadamente 0.55, lo cual no permite determinar si este tipo de actividades le gustan o le disgustan. Mientras que su concentración se torna baja cercana a 0.4 y su relajación cercana a 0.5 aproximadamente.




Figura 55 Distribución Unificada de Métricas Emocionales participante, lecciones, actividad y subactividad

De acuerdo con la Figura 56, al separar los histogramas por lección, en cuanto a compromiso, se evidencia que la parte aislada que se mostraba anteriormente en los gráficos unificados corresponde únicamente a la lección 3 como se podía ver en lo gráficos

de línea. También se puede ver que, la mayor concentración de compromiso sucedió en la lección 4. De igual forma, la relajación presenta valores por debajo de 0.5 en esta misma lección. Podría indicar que, entre más atención presta el participante al ejercicio, la relajación será menor. Y en el caso particular de este usuario, con esos niveles de compromiso, su estrés se mantuvo bajo con valores en un rango de 0.35 y 0.4. Mientras que para la lección 1, su estrés llegó a valores cercanos a 0.6. También, para la lección 4, en cuanto a la concentración del participante, sus de valores son más altos respecto al resto de lecciones, teniendo un par de muestras rozando el valor de 0.6. Quiere decir que se mantiene concentrado, a pesar de que en estos ejercicios de dialogo no se tiene una única pregunta, puesto que se presentan múltiples campos a llenar a medida que la conversación escrita avanza.




Figura 56 Distribución Superpuesta de Métricas Emocionales participante, lecciones, actividad y subactividad

Haciendo referencia a los tiempos interacción, como se ha expuesto en gráficas anteriores, al participante le tomó más tiempo completar la subactividad de dialogo de la lección 4. Hay que recordar que, esta lección es un tipo de repaso compuesto de ejercicios donde no se tiene ayuda y se debe resolver con lo aprendido anteriormente. De esta manera, tal vez al estudiante la costó mayor trabajo resolverlo. Podría indicar que al aumentar a la dificultad y al entender que esta sección era de evaluación de conocimiento, el usuario se indujo a prestar más atención, por eso el comportamiento de compromiso expuesto previamente. De acuerdo con esto, al participante, le tomo 124 segundos completar la actividad de dialogo, aproximadamente 3x más tiempos que en las lecciones 1 y 3 (Figura 57).




Figura 57 Medición de tiempo participante, lecciones, actividad y subactividad

Finalmente, de acuerdo con la Figura 58, al participante se le dificultó notablemente completar satisfactoriamente el ejercicio de dialogo en la lección4, dado que, tuvo cuatro intentos erróneos y cuatro respuestas tomadas como incorrectas. Esto hace que, a nivel general, en este tipo de actividad solo tenga un éxito de 50%. Se pueden concluir dos cosas a partir de esto. Como en esta lección número 4 se evaluaban los conceptos adquiridos durante las lecciones anteriores, el participante pudo haber quedado con dudas respecto a algunos de estos temas y esto provocó los errores. También se podría inferir que, cuando es necesario aplicar conceptos y términos en situaciones reales como conversaciones, el estudiante falla y sería conveniente buscar otra estrategia educativa que le permita desarrollar estas habilidades al estudiante, como, por ejemplo, darle un conjunto de opciones para ir completando las conversaciones. Dado que, en este tipo de ejercicio en la plataforma de Babel no se dan opciones, el participante debe escribirlas, por lo tanto, debe recordarlas perfectamente, puesto que de otra forma se tomará de forma incorrecta por el sistema. Tener un conjunto de opciones, podría ayudar al estudiante a tener mejores resultados. Incluso, se podrían utilizar este tipo de ejercicios con opciones a seleccionar durante los primeros niveles, donde el estudiante se familiariza con estas situaciones y posteriormente, que el ejercicio no presente opciones, sino que, el usuario tenga que escribirlas correctamente.




Figura 58 Resultados participante, lecciones, actividad y subactividad

En este mismo orden de ideas, se realizó este análisis para el participante 4, todas las lecciones, la actividad selección de opción y la subactividad de pronunciación. En este caso, la lección 2 y 3, presentan este tipo de ejercicio. A partir de esto, se observa que, la interacción más larga fue en la lección 2 y es donde el estudiante presentó incrementos periódicos en su nivel de compromiso. Además, en esta misma lección, el participante expone constantemente valores por encima de 0.6, para emociones como excitación e interés. De esta manera, en las distribuciones separadas por lección se nota una diferencia amplia entre la lección 2 y 3. Se podría inferir que el estudiante estuvo más inmerso durante la lección 2 que la 3, durante los ejercicios de pronunciación. En cuanto a tiempos, en la lección número 2 le tomo $3x$ más tiempo que en la lección 3. Además, a nivel de resultados, en la lección número 2, obtuvo 5 intentos fallidos, y una pregunta incorrecta. Su rendimiento en esta actividad no fue la mejor, dado que en la lección 3, solo tenía 3 preguntas y tuvo un intento erróneo, pero el sistema no lo tomó como respuesta incorrecta. Esto también está relacionado con el tiempo de interacción que tuvo el usuario en la lección 2. Lo relevante en este momento es que, los niveles de excitación e interés del participante fueron altos durante este tipo de subactividad, por ende, tal vez es un ejercicio que gusta al participante, pero presenta cierto tipo de nerviosismo al realizarlo. Esto se puede producir, al obtener una retroalimentación inmediata de la forma en cómo está pronunciando ciertas palabras, aspecto importante y difícil en el aprendizaje de una segunda lengua.

5.2 Clustering emocional

A continuación, se expondrán los resultados de la aplicación de clustering emocional implementada. Por tal motivo, se presentará para cada lección una tabla de resumen, donde se consolidarán las mejores configuraciones de los modelos obtenidos para el clustering de las series de tiempo emocionales de longitud variable, junto con las métricas obtenidas, coeficiente de silhouette (Sil), índice de Davies-Bouldin (DB) y Calinski-Harabasz (CH). Finalmente, se mostrará la composición de los grupos generados.

5.2.1 Lección 1: Tudo bem? Primera parte

La Tabla 7, presenta las mejores configuraciones de los algoritmos de clustering implementados y probados para la lección 1. De esta manera, expone el tipo de emoción utilizada para entrenar los modelos, el tipo de centroide, la distancia, el preprocesamiento aplicado a los datos y la cantidad de clústeres generados. Además, expone las métricas de evaluación interna para cada configuración por emoción.

Tabla 7 Mejores configuraciones de clustering emocional para lección 1

ID	Emoción	Centroide	Distancia	Procesamiento	Clústeres	Sil	DB	CH
1	Compromiso	Pam	GAK	Ninguno	4	0.64	4.05	17.73
2	Excitación	Shape	GAK	Z-Score	2	0.55	1.6	22.46
3	Estrés	Shape	GAK	Z-Score	2	0.55	1.57	21.92
4	Relajación	Pam	GAK	Ninguno	4	0.64	3.21	12.8
5	Interés	Pam	GAK	Ninguno	5	0.68	7.72	18.15
6	Concentración	Shape	GAK	Z-Score	2	0.55	1.57	22.88

A partir de la Tabla 7, se evidencia que dependiendo de la emoción se tiene diferente tipo de centroide. Por ejemplo, para el compromiso, relajación e interés se utiliza PAM. El resto de las emociones, obtienen sus mejores configuraciones mediante centroides de tipo extracción de forma (Shape). En este orden de ideas, para los centroides tipo PAM, no se utiliza preprocesamiento, mientras que, para Shape si se utiliza intrínsecamente la normalización Z. En adición, todas las configuraciones exponen mejor coeficiente de Silhouette haciendo uso de la distancia de alineación global rápida de núcleos (GAK). Adicionalmente, es importante resaltar que, para las emociones de excitación, estrés y concentración, donde se comparte configuración, se generan exactamente 2 grupos. En cuanto a métricas de evaluación, tomando los índices de Silhouette, Davies-Bouldin (DB) y Calinski-Harabasz, en promedio sin hacer distinción de emoción se obtienen valores de 0.61, 3.63 y 18.61, respectivamente para estos índices. Según esto, los clústeres generados exponen una cohesión, compactación y separación media dado que los valores de Silhouette, están por encima de 0.55. No obstante, expone sus valores más altos por encima o igual a 0.64 cuando se utilizan métodos PAM como centroide. Por otro lado, de acuerdo con el índice CH, este se aleja considerablemente de 0, lo cual es lo ideal. Finalmente, tomando en consideración el índice de Davies-Bouldin (DB), entre más cercano a cero mejor, y en este caso obtenemos en promedio 3.63, sería ideal intentar reducir este índice.

La Tabla 8, presenta los grupos generados para cada una de las mejores configuraciones expuestas previamente. En este orden de ideas se especifican los participantes que hacen parte de cada grupo.

Tabla 8 Clústeres generados por las mejores configuraciones de clustering emocional para lección 1

ID	Clústeres
1	C1: [2, 4, 7, 11, 15, 19] - C2: [14] - C3: [1, 3, 5, 6, 8, 9, 12, 13, 16, 17, 18] - C4: [10]
2	C1: [1, 3, 5, 6, 8, 9, 10, 12, 13, 16, 17, 18] - C2: [2, 4, 7, 11, 14, 15, 19]
3	C1: [1, 3, 5, 6, 8, 9, 10, 12, 13, 16, 17, 18] - C2: [2, 4, 7, 11, 14, 15, 19]
4	C1: [2, 4, 7, 11, 15, 19] - C2: [14] - C3: [1, 3, 5, 6, 8, 9, 12, 13, 16, 17, 18] - C4: [10]
5	C1: [1, 3, 5, 6, 8, 9, 12, 13, 16, 17, 18] - C2: [11] - C3: [14] - C4: [2, 4, 7, 15, 19] - C5: [10]
6	C1: [1, 3, 5, 6, 8, 9, 10, 12, 13, 16, 17, 18] - C2: [2, 4, 7, 11, 14, 15, 19]

De acuerdo con la Tabla 8, se observa que, para la configuración de la emoción de compromiso, relajación e interés, se encuentran grupos con tan solo un integrante. Lo recomendado sería profundizar en el comportamiento de estos participantes. Dado que, son participantes que exponen un comportamiento distinto al resto de integrantes y no logran ser parte de algunos de los otros grupos. Por otra parte, es importante indicar que, para las métricas de estrés, excitación y concentración, se generan la misma distribución de participantes. Además, lo mismo sucede entre las emociones de compromiso y relajación. Finalmente, la distribución de participantes para la emoción de interés tiene una alta similitud a las agrupaciones del compromiso y relajación.

5.2.2 Lección 2: Pronombres personales en singular

La Tabla 9, presenta las mejores configuraciones de los algoritmos de clustering implementados y probados para cada emoción durante la interacción con la lección 2.

Tabla 9 Mejores configuraciones de clustering emocional para lección 2

ID	Emoción	Centroide	Distancia	Preprocesamiento	Clústeres	Sil	DB	CH
1	Compromiso	Shape	GAK	Z-Score	4	0.75	1.73	18.38
2	Excitación	Pam	GAK	Z-Score	5	0.85	6.23	44.47
3	Estrés	Pam	GAK	Z-Score	5	0.84	6.13	43.81
4	Relajación	Pam	GAK	Z-Score	5	0.84	6.23	42.96
5	Interés	Pam	GAK	Z-Score	5	0.84	6.16	43.1
6	Concentración	Pam	GAK	Z-Score	5	0.84	5.86	44.48

A partir de la Tabla 9, se puede observar que el tipo de centroide predominante es PAM, excepto para el compromiso, donde su tipo de centroide es tipo Shape. De igual manera,

para todas las configuraciones toma lugar el uso de GAK como distancia entre las series de tiempo. En cuanto a la aplicación de procesamiento previo a los datos, para todas las configuraciones se aplica la normalización mediante el z-score. Adicionalmente, para las emociones de excitación, estrés, relajación, interés y concentración, se tiene la misma configuración, generando exactamente 5 grupos para cada uno, además de, presentar coeficientes de silhouette iguales o cercanos. Por el contrario, para el compromiso se generan exactamente 4 grupos y un coeficiente de silhouette un poco inferior. En cuanto a métricas de evaluación, tomando como los índices de silhouette, DB y CH, en promedio sin hacer distinción de emoción se obtienen valores de 0.83, 5.39 y 39.53, respectivamente para estos índices. Según esto, los clústeres generados exponen una alta cohesión, compactación y separación, dado que los valores de Silhouette, están por encima de 0.80, en la mayoría de los casos. No obstante, expone sus valores más altos por encima o igual a 0.84 cuando se utilizan métodos PAM como centroide. Por otro lado, de acuerdo con CH, este índice se aleja considerablemente de 0, dando soporte a la buena separación entre grupos y alta cohesión y compactación internamente en los participantes de los grupos. Finalmente, tomando en consideración el índice de Davies-Bouldin (DB), este índice debería poder acercarse más a cero.

La Tabla 10, presenta los grupos generados para cada configuración expuesta previamente. Es decir, para cada grupo se especifican la composición de participantes.

Tabla 10 Clústeres generados por las mejores configuraciones de clustering emocional para lección 2

ID	Clústeres
1	C1: [2, 5, 8, 9, 12] - C2: [7, 11, 13, 16] - C3: [1, 3, 6, 10, 17, 18] - C4: [4, 14, 15, 19]
2	C1: [1, 10, 17, 18] - C2: [3, 6] - C3: [7, 11, 13, 16] - C4: [2, 5, 8, 9, 12] - C5: [4, 14, 15, 19]
3	C1: [1, 10, 17, 18] - C2: [3, 6] - C3: [7, 11, 13, 16] - C4: [2, 5, 8, 9, 12] - C5: [4, 14, 15, 19]
4	C1: [1, 10, 17, 18] - C2: [3, 6] - C3: [7, 11, 13, 16] - C4: [2, 5, 8, 9, 12] - C5: [4, 14, 15, 19]
5	C1: [1, 10, 17, 18] - C2: [3, 6] - C3: [7, 11, 13, 16] - C4: [2, 5, 8, 9, 12] - C5: [4, 14, 15, 19]
6	C1: [1, 10, 17, 18] - C2: [3, 6] - C3: [7, 11, 13, 16] - C4: [2, 5, 8, 9, 12] - C5: [4, 14, 15, 19]

Tomando en consideración la Tabla 10, se puede observar que, para las configuraciones de agrupamiento, que obtuvieron un coeficiente de silhouette superior a 0.82 se generan exactamente la misma distribución de participantes. En relación con esto, tan solo 1 de los 5 grupos generados, contiene solo 2 participantes, lo cual implicaría poder realizar un análisis más profundo de estos dos usuarios, que tiene alta similitud entre sí, pero no con los otros grupos generados. Adicionalmente, la configuración para el compromiso difiere respecto a las demás, pero genera grupos distribución de grupos altamente similar,

tomando los dos usuarios aislados en las otras configuraciones y ubicándolos en uno de los grupos generados.

5.2.3 Lección 3: Tudo bem? Segunda parte

La Tabla 11, presenta las configuraciones de los algoritmos de clustering que obtuvieron los coeficientes de silhouette más altos para la lección número 3.

Tabla 11 Mejores configuraciones de clustering emocional para lección 3

ID	Emoción	Centroide	Distancia	Preprocesamiento	Clústeres	Sil	DB	CH
1	Compromiso	Shape	S-DTW	Z-Score	2	0.55	1.48	79.73
2	Excitación	Shape	GAK	Z-Score	6	0.63	2.36	45.28
3	Estrés	Shape	GAK	Z-Score	6	0.59	2.66	22.16
4	Relajación	Shape	DTW	Z-Score	2	0.62	3.62	27.31
5	Interés	Shape	GAK	Z-Score	3	0.49	1.76	15.07
6	Concentración	Shape	GAK	Z-Score	3	0.49	1.76	15.09

A partir de la Tabla 11, para todas las configuraciones los clústeres generados se realizan mediante la extracción de forma, por tal motivo utilizan Shape como centroide. A diferencia de anteriores resultados, en este caso las distancias para Compromiso y Relajación son S-DTW y DTW respectivamente, para el resto de las emociones se tiene GAK. También se puede observar que mediante la distancia GAK y DTW se obtiene los coeficientes de silhouette más altos, con un valor de 0.63 y 0.62. Además, como el tipo de centroide predominante es por extracción de forma, este centroide intrínsecamente aplica normalización z, como método de preprocesamiento a los datos. Adicionalmente, la configuración para compromiso y relajación generan 2 grupos, para excitación y estrés generan 6 grupos y para interés y concentración se generan 3 grupos. En cuanto a métricas de evaluación, para los índices de silhouette, DB y CH, en promedio sin hacer distinción de emoción se obtienen valores de 0.56, 2.27 y 34.11, respectivamente para estos índices. Según esto, los clústeres generados exponen un nivel medio de cohesión, compactación y separación, dado que los valores de Silhouette, están cercanos a 0.5. No obstante, expone el valor más alto es de 0.63 cuando se utilizando la distancia GAK, pero siendo el valor máximo no es relativamente alto. Por otro lado, de acuerdo con CH, este índice se aleja considerablemente de 0. Finalmente, tomando en consideración el índice de Davies-Bouldin (DB), este índice es cercano a cero, es decir, una cohesión y separación aceptable, al analizar la distancia de los puntos de un grupo a su centroide y de acuerdo con la distancia entre los centroides.

La Tabla 12, presenta los grupos generados para cada configuración expuesta anteriormente. Es decir, para cada grupo se especifican que participantes lo componen.

Tabla 12 Clústeres generados por las mejores configuraciones de clustering emocional para lección 3

ID	Clústeres
1	C1: [1, 2, 4, 6, 7, 9, 12, 13, 14, 16, 18] - C2: [3, 5, 8, 10, 11, 15, 17, 19]
2	C1: [1, 5, 18] - C2: [15, 19] - C3: [14] - C4: [3, 6, 10, 12] - C5: [8, 9, 17] - C6: [2, 4, 7, 11, 13, 16]
3	C1: [1, 5, 18] - C2: [15, 19] - C3: [14] - C4: [3, 6, 10, 12] - C5: [8, 9, 17] - C6: [2, 4, 7, 11, 13, 16]
4	C1: [3, 5, 7, 8, 9, 12, 16, 17, 18, 19] - C2: [1, 2, 4, 6, 10, 11, 13, 14, 15]
5	C1: [18] - C2: [1, 3, 5, 6, 8, 9, 10, 12, 17] - C3: [2, 4, 7, 11, 13, 14, 15, 16, 19]
6	C1: [18] - C2: [1, 3, 5, 6, 8, 9, 10, 12, 17] - C3: [2, 4, 7, 11, 13, 14, 15, 16, 19]

Según la Tabla 12, las configuraciones que generar la misma cantidad de clústeres, presenta la misma distribución de participantes. No obstante, para excitación y estrés, se presenta un grupo con tan solo un estudiante, específicamente el participante número 14. Este mismo comportamiento ya se había presentado para el análisis de clustering para las métricas emocionales de compromiso y relajación en la lección 1.

5.2.4 Lección 4: Tudo bem? Repaso

La Tabla 13, presenta las mejores configuraciones de los algoritmos de clustering implementados y probados para la lección número 4.

Tabla 13 Mejores configuraciones de clustering emocional para lección 4

ID	Emoción	Centroide	Distancia	Preprocesamiento	Clústeres	Sil	DB	CH
1	Compromiso	Pam	GAK	Z-Score	7	0.67	4.76	29.59
2	Excitación	Pam	GAK	Z-Score	6	0.67	5.49	25.36
3	Estrés	Pam	GAK	Z-Score	7	0.68	5.22	36.02
4	Relajación	Pam	GAK	Z-Score	7	0.68	5.44	36.3
5	Interés	Pam	GAK	Z-Score	6	0.66	5.57	25.56
6	Concentración	Pam	GAK	Z-Score	7	0.68	5.35	31.93

A partir de la Tabla 13, para todas las configuraciones el tipo de centroide predominante es PAM. También, en todas las configuraciones se presenta la distancia GAK como distancia de similitud entre las series de tiempo. Además, la normalización z-score es

aplicada para todos los casos. Los resultados obtenidos en esta última lección son altamente homogéneos, dado que para todas las emociones se tiene el mismo tipo de centroide, distancia y preprocesamiento. De igual manera, se obtiene valores para cada uno de los índices muy cercanos entre sí. En este mismo orden de ideas, se generan 7 grupos para concentración, relajación, estrés y compromiso, y 6 para interés y excitación. En relación con las métricas de evaluación interna realizada, para los índices de silhouette, DB y CH, en promedio sin hacer distinción de emoción se obtienen valores de 0.67, 5.3 y 30.78, respectivamente para estos índices. Según esto, los clústeres generados exponen un nivel medio-alto de cohesión, compactación y separación, dado que los valores de Silhouette, están alrededor de 0.67, acercándose a 0.7. Por otro lado, de acuerdo con CH, este índice se aleja considerablemente de 0, dándole soporte a la formación coherente de los grupos y una distinción aceptable entre los mismos. Finalmente, tomando en consideración el índice de David Bouldin (DB), este índice es cercano 5, y lo ideal sería obtener una configuración que mantengan los valores obtenidos para los otros índices, pero logre disminuir esta métrica.

La Tabla 14, presenta la composición de los grupos generados para las configuraciones de algoritmos de clustering expuestos previamente.

Tabla 14 Clústeres generados por las mejores configuraciones de clustering emocional para lección 4

ID	Clústeres
1	C1: [3, 8, 18] - C2: [14] - C3: [5, 11] - C4: [1, 10, 12] - C5: [2, 13, 15, 17] - C6: [4] - C7: [6, 7, 9, 16, 19]
2	C1: [3, 8, 18] - C2: [1, 10, 12] - C3: [14] - C4: [5, 11] - C5: [4] - C6: [2, 6, 7, 9, 13, 15, 16, 17, 19]
3	C1: [3, 8, 18] - C2: [14] - C3: [5, 11] - C4: [1, 10, 12] - C5: [2, 13, 15, 17] - C6: [4] - C7: [6, 7, 9, 16, 19]
4	C1: [3, 8, 18] - C2: [14] - C3: [5, 11] - C4: [1, 10, 12] - C5: [2, 13, 15, 17] - C6: [4] - C7: [6, 7, 9, 16, 19]
5	C1: [3, 8, 18] - C2: [1, 10, 12] - C3: [14] - C4: [5, 11] - C5: [4] - C6: [2, 6, 7, 9, 13, 15, 16, 17, 19]
6	C1: [3, 8, 18] - C2: [14] - C3: [5, 11] - C4: [1, 10, 12] - C5: [2, 13, 15, 17] - C6: [4] - C7: [6, 7, 9, 16, 19]

A partir de la Tabla 14, se puede ver que nuevamente para las configuraciones que generan la misma cantidad de clústeres, se presenta la misma distribución de participantes. Adicionalmente, para esta lección en cada una de las configuraciones, los participantes identificados con el número 4 y 14, se ubican solos en un grupo cada uno. Es decir, en esta última actividad, estos dos participantes, se postulan como dos individuos diferentes al respecto de sus compañeros a nivel de emocional. Por otra parte, para las configuraciones se evidencian similitudes, en cuanto compartir grupos o participantes reunidos en un mismo grupo.

En cuanto a resultados generales, las métricas obtenidas para los algoritmos, para algunas lecciones son bastante buenas, como en la lección número 2 y 4. Sus coeficientes de silhouette son bastante cercanos entre sí y exponen una cohesión, compactación y separación media-alta. También, se logra diferenciar que la distancia de similitud basada en la alineación global rápida de núcleos (GAK), aparece repetidamente en las configuraciones expuestas para los algoritmos de clustering de series de tiempo de longitud variable, tan solo en 2 de 24 configuraciones se utiliza otro tipo de distancia. También, se evidencia que la aplicación de normalización Z a los datos emocionales capturados aparece en 21 de las 24 configuraciones expuestas, mostrando afinidad con las métricas emocionales capturadas y los algoritmos de clustering probados. Por otra parte, en cuanto al tipo de centroide implementado, no se tiene inclinación hacía alguno de los tipos de centroides probados, dado que, para el centroide tipo PAM se presentaron 14 configuraciones y para extracción de forma (Shape) se tiene 10 configuraciones. Por último, a partir de la composición de participantes en los grupos generados por los algoritmos, al analizar las lecciones por separado, se logra evidenciar que cuando el número de grupos es cercano, se identifican similitudes fuertes en la conformación de los grupos.

Capítulo 6

Conclusiones y trabajo futuros

6.1 Resultados derivados de la investigación

Esta sección presenta los productos resultados del proceso de investigación de este estudio. Por tal motivo, se realizará una división de los artículos y las ponencias realizadas.

6.1.1 Artículos

- Emotional characterization of children through a learning environment using learning analytics and AR-Sandbox. Journal of Ambient Intelligence and Humanized Computing – Q2. Publicado.
- Advanced Clustering Techniques for Emotional Grouping in Learning Environments using an Ar-Sandbox. International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems – Q3. Publicado.
- Time Series for Evaluation of Performance Metrics as of Interaction with an AR-Sandbox Using Brain Computer Interfaces. Lecture Notes in Networks and Systems – Q4. Publicado.
- Application of Learning Analytics for Sequential Patterns Detection Associated with Moments of Distraction in Students in E-Learning Platforms. Scientific Programming – Q3. En revision.
- EDaLI: A Public Domain Dataset for emotional analysis using Brain Computer Interfaces during interaction with a Second Language Learning Platform. Electronics – Special Issue Collaborative Artificial Systems. En revision.
- Application of Learning Analytics from emotional time series clustering algorithms of variable length. En desarrollo.

- Learning analytics approach based on visual analytics for the analysis of emotional and learning metrics in second language learning applications. En desarrollo.
- Gamification: Preserving Cultural Heritage Through Immersive Scenarios and Second Language Strengthening. Smart Innovation, Systems and Technologies – Q3. Publicado.

6.1.2 Ponencias en eventos científicos

- Time Series for Evaluation of Performance Metrics as of Interaction with an AR-Sandbox Using Brain Computer Interfaces. The 2022 online International Conference on Information Technology & Systems - ICITS'22.
- Emotional response to the use of AR-Sandbox to perform motor exercises. Webinar on Fetal Medicine 2021.

6.2 Conclusiones

De acuerdo con el modelo de learning analytics planteado e implementado, a partir de técnicas de visualización y de algoritmos de clustering de series de tiempo de longitud variable, se puede afirmar que es posible procesar un conjunto de métricas emocionales para evaluar, entender y comprender el comportamiento emocional y los resultados obtenidos por un individuo durante su interacción con diferentes tipo de actividades y recursos expuestos por una aplicación de aprendizaje de segunda lengua. De esta manera y a partir de los resultados obtenidos, es posible identificar que al aplicar algoritmos de clustering a partir de métodos particionales a series de tiempo emocionales y medidas de distancia de similitud como alineación global de núcleos (GAK), es posible obtener indicadores de separación, cohesión y compactabilidad medio-altos entre los grupos generados, utilizando una evaluación interna mediante métricas como el coeficiente de Silhouette, el índice de Calinsky-Haraszck y índice de Davies-Bouldin.

En este mismo orden de ideas, aplicar un proceso de analítica visual a partir de gráficos de línea, circulares, histogramas y de barras, permite llevar a cabo una observación profunda de las métricas emocionales experimentadas por los participantes a nivel general e individual, durante cada proceso de aprendizaje. De esta manera, es posible profundizar de forma que se logre identificar los valores emocionales experimentados durante la interacción los distintos tipos de actividades y ejercicios. De tal modo que, permite comprender con qué tipo de actividades el usuario se siente más a gusto, o le genera una mayor frustración. Incluso, permite entender que actividades capturan mayor atención en las personas que interactúan con la plataforma. Además, es posible generar recomendaciones inicialmente a partir de su comportamiento emocional. Por ello, sería

posible variar los tipos de ejercicios que se le exponen a un participante determinado o a un grupo específico de participantes. Esta variación, puede estar orientada a cambiar completamente el ejercicio por otro, o realizar modificaciones sobre los ejercicios existentes, de tal forma que, de acuerdo con el análisis realizado, el participante pueda experimentar emociones positivas y resultados exitosos.

Sin embargo, para poder llevar a cabo el análisis emocional a partir del modelo de learning analytics planteado en este estudio, es indispensable disponer de un conjunto de datos apropiadamente procesado y anotado. No obstante, este tipo de datos no se encuentran abiertamente al público. Por lo anterior, uno de los principales problemas y procesos desarrollados en este estudio, fue la captura, procesamiento y anotación de las métricas emocionales capturadas mediante un emotiv insight como interfaz cerebro-computadora, durante el aprendizaje del idioma portugués en la plataforma de Babbel. A partir de esto, se puede abstraer una estructura clara y precisa de pasos e instrucciones, para futuras construcciones de conjunto de datos relacionados con los temas trabajados en este estudio. Sin embargo, se observa como aspecto de mejora el poder automatizar o semi automatizar el proceso de anotación de estos datos emocionales en entornos de aprendizaje. Adicionalmente, para la construcción de este tipo de conjuntos de datos se deben tener en cuenta ciertas consideraciones como, definir previamente el tipo de actividades que un usuario puede realizar durante su proceso de aprendizaje, definir cómo se recopilarán las métricas emocionales de tal forma que, se puedan representar de forma continua. Además, es relevante determinar el proceso de anotación de los datos de interacción con los recursos y actividades expuestas por la plataforma.

Por otra parte, para implementar un modelo de learning analytics a nivel computacional se presentan dos lenguajes de programación ampliamente utilizados como lo son Python y R. Esos lenguajes, permiten implementar los distintos algoritmos que se utilizarán para realizar los respectivos análisis a los datos recopilados. En este orden de ideas, no se debe caer en el error de sesgar el desarrollo del modelo a un solo lenguaje. Dado que, sería erróneo determinar cuál de los dos lenguajes de programación es mejor. Lo ideal es realizar una revisión de ventajas y desventajas para cada Python y R, de acuerdo con el caso de estudio que se esté implementando. De esta manera, permite utilizar cada lenguaje en lo que se desempeña de la mejor manera. De acuerdo con lo anterior, este estudio lo cumple a cabalidad, dado que, el análisis visual se ha implementado mediante Python y la aplicación de algoritmos de clustering de series de tiempo de longitud variable, se ha llevado a cabo con R, dado que expone mejores paquetes para llevar a cabo estos procesos.

Además de esto, a partir de la liberación del conjunto de datos construido en este estudio nombrado como EDaLI, se puede incentivar la exploración e investigación a profundidad

de otro tipo de métodos y análisis, que tengan como finalidad ayudar a comprender el comportamiento emocional y los resultados obtenidos a partir de la interacción de personas con actividades y recursos de aprendizaje de segunda lengua haciendo uso de aplicaciones móviles. Incluso, a partir de esto, se podría generar una etapa inicial de caracterización, con el propósito de determinar previamente al inicio de un curso de aprendizaje de segunda lengua, cuales recursos, actividades y ejercicios, son más afines al participante y a partir de esto, crear rutas de aprendizaje personalizadas.

6.3 Principales aportes

- Construcción y liberación de un conjunto de datos público para el análisis emocional, consolidando métricas como compromiso, excitación, estrés, relajación, interés y concentración. Estas fueron métricas capturadas a partir de un Emotiv Insight, durante la interacción de un grupo de 19 participantes con cuatro lecciones de aprendizaje del idioma portugués, proporcionadas por la aplicación móvil Babbel. Este conjunto de datos presenta una anotación del tipo de actividad que estaba realizando el participante en cada instante de tiempo durante su interacción, además de exponer los resultados obtenidos en las preguntas realizadas por la plataforma durante el desarrollo de sus actividades.
- Un modelo de learning analytics basado en métricas emocionales, el cual está integrado por dos componentes. Un componente de analítica visual el cual permite observar de forma clara el comportamiento emocional y los resultados obtenidos a nivel individual y grupal, realizando una discriminación por lección, lecciones, actividad y subactividad realizada. A partir de este componente, es posible comprender el comportamiento emocional a través del tiempo, lo que permite realizar recomendaciones iniciales sobre la interacción y reacción de los participantes frente a los recursos y actividades expuestas. El segundo componente está enfocado en realizar clustering emocional, a partir de series de tiempo de longitud variable. Los modelos obtenidos, presentan un coeficiente máximo de silhouette de 0.85, exponiendo un alto nivel de cohesión, compactación y separación.
- Generación de un repositorio público, donde se consolida la implementación del componente de analítica visual a partir de los datos recopilados y procesados, mediante librerías como Plotly y Dash, con el lenguaje de programación de Python. Además, se adiciona a este repositorio, el script en R, para la implementación de los algoritmos de clustering para series de tiempo de longitud variable, mediante el paquete dtwclust.

6.4 Recomendaciones y trabajos futuros

Teniendo en cuenta el proceso de investigación desarrollado y los resultados obtenidos, se proponen una serie de recomendaciones y trabajos futuros para la continuidad del proyecto presentado en este estudio.

6.4.1 Trabajos futuros

Se postulan los siguientes trabajos futuros mostrando diversas opciones de continuidad del proyecto desde otros enfoques:

- Investigar la viabilidad de la aplicación de algoritmos de pronóstico o forecasting para series de tiempo univariante y multivariantes. Con el fin de analizar aisladamente una emoción o múltiples emociones conjuntamente.
- Implementar algoritmos de visión por computadora y de procesamiento de lenguaje natural para realizar la anotación automática de la interacción de los usuarios con la aplicación de aprendizaje de segunda lengua.
- Para mejorar las métricas obtenidas en la evaluación interna de los algoritmos de clustering de series de tiempo de longitud variable, se pueden implementar algoritmos jerárquicos, basados en densidad y en lógica difusa.
- Abordar sobre la aplicación de algoritmos de clustering para series de tiempo multivariantes de longitud variable, con el fin de agrupar emocionalmente participantes, tomando en consideración un conjunto de emociones.
- Desarrollar un sistema de recomendación automático que tomé como entrada los gráficos y las agrupaciones generadas por el modelo de learning analytics.
- Integrar al modelo otro tipo de métricas como, variables fisiológicas, variables socioeconómicas y datos de interacción mediante captura intrínseca de acciones sobre la aplicación.

6.4.2 Recomendaciones

A partir de lo desarrollado y expuesto en este estudio se realizan las siguientes recomendaciones.

- El código realizado para el componente de analítica de visualización del modelo de learning analytics, se encuentra funcional, pero en una fase de desarrollo, no es un software que se encuentre completamente listo para producción. Por tal motivo si se requiere utilizar con otro tipo de datos, debe contener la misma estructura que

el dataset construido (EDaLI) y se requieren modificaciones en el script `analysis_generation.py` para su correcto funcionamiento.

- El script generado en R para la implementación y comparación de los modelos de clustering de series de tiempo de longitud variable, consume los datos del conjunto de datos EDaLI de forma local, por lo tanto, el conjunto de datos debe ser descargado.

Referencias

- Aghabozorgi, S., Seyed Shirkhorshidi, A., & Ying Wah, T. (2015). Time-series clustering – A decade review. *Information Systems*, 53, 16–38. <https://doi.org/https://doi.org/10.1016/j.is.2015.04.007>
- Aguilar, S. J. (2018). Learning Analytics: at the Nexus of Big Data, Digital Innovation, and Social Justice in Education. *TechTrends*, 62(1), 37–45. <https://doi.org/10.1007/s11528-017-0226-9>
- Ahmed, H. (2016). Duolingo as a Bilingual Learning App: a Case Study. *Arab World English Journal*, 7(2), 255–267. <https://doi.org/10.24093/awej/vol7no2.17>
- Aldowah, H., Al-Samarraie, H., & Fauzy, W. M. (2019). Educational data mining and learning analytics for 21st century higher education: A review and synthesis. *Telematics and Informatics*, 37, 13–49. <https://doi.org/https://doi.org/10.1016/j.tele.2019.01.007>
- Ali, M., Alqahtani, A., Jones, M. W., & Xie, X. (2019). Clustering and Classification for Time Series Data in Visual Analytics: A Survey. *IEEE Access*, 7, 181314–181338. <https://doi.org/10.1109/ACCESS.2019.2958551>
- Alm, A. (2021). *Apps for Informal Autonomous Language Learning: An Autoethnography BT - Language Education in Digital Spaces: Perspectives on Autonomy and Interaction* (C. Fuchs, M. Hauck, & M. Dooly, Eds.; pp. 201–223). Springer International Publishing. https://doi.org/10.1007/978-3-030-74958-3_10
- Antzoulatos, G., Mavropoulos, T., Tzionis, G., Karakostas, A., Gonzalez Costas, A., González Burgos, M., Vrochidis, S., & Kompatsiaris, I. (2022). Usage of Visual Analytics to Support Immigration-Related, Personalised Language Training Scenarios. In M. E. Auer & T. Tsiatsos (Eds.), *New Realities, Mobile Systems and Applications* (pp. 681–693). Springer International Publishing.
- Arbelaitz, O., Gurrutxaga, I., Muguerza, J., Pérez, J. M., & Perona, I. (2013). An extensive comparative study of cluster validity indices. *Pattern Recognition*, 46(1), 243–256. <https://doi.org/https://doi.org/10.1016/j.patcog.2012.07.021>
- Aromiekim. (2021). *Babbel Review: Prestigious Program with Limited Scope*. <https://www.fluentu.com/blog/babbel-review/>
- Azevedo, R., Millar, G. C., Taub, M., Mudrick, N. V., Bradbury, A. E., & Price, M. J. (2017). Using data visualizations to foster emotion regulation during self-regulated learning

- with advanced learning technologies: A conceptual framework. *ACM International Conference Proceeding Series*, 444–448. <https://doi.org/10.1145/3027385.3027440>
- Bajorek, J. (2017). L2 Pronunciation Tools: The Unrealized Potential of Prominent Computer-assisted Language Learning Software. *Issues and Trends in Educational Technology*, 5, 60–87. https://doi.org/10.2458/azu_itet_v5i1_bajorek
- Barrón Estrada, M. L., Zatarain Cabada, R., Oramas Bustillos, R., & Graff, M. (2020). Opinion mining and emotion recognition applied to learning environments. *Expert Systems with Applications*, 150, 113265. <https://doi.org/https://doi.org/10.1016/j.eswa.2020.113265>
- Berns, A., Isla-Montes, J. L., Palomo-Duarte, M., & Dodero, J. M. (2016). Motivation, students' needs and learning outcomes: a hybrid game-based app for enhanced language learning. *SpringerPlus*, 5(1). <https://doi.org/10.1186/s40064-016-2971-1>
- Bezdek, J. C. (2013). *Pattern recognition with fuzzy objective function algorithms*. Springer Science & Business Media.
- Bielozorov, A., Bezbradica, M., & Markus, H. (2019). The Role of User Emotions for Content Personalization in e-Commerce: Literature Review. *Lecture Notes in Computer Science*, 11588(64), 288–297. <https://doi.org/10.1007/978-3-030-22335-9>
- Bulárka, S., & Gontean, A. (2016). Brain-Computer Interface review. *2016 12th IEEE International Symposium on Electronics and Telecommunications (ISETC)*, 219–222. <https://doi.org/10.1109/ISETC.2016.7781096>
- Bullis, J., Boettcher, H., Sauer, S., & David, B. (2019). What is an emotional disorder? A transdiagnostic mechanistic definition with implications for assessment, treatment, and prevention. *Clinical Psychology: Science and Practice*, 26. <https://doi.org/10.1111/cpsp.12278>
- Campbell, C., & Geertsema, M. (2017). Improving Student Language Learning in Adult Education Through the Use of Mobile Learning: Barriers, Challenges and Ways to Move Forward. In A. Murphy, H. Farley, L. E. Dyson, & H. Jones (Eds.), *Mobile Learning in Higher Education in the Asia-Pacific Region: Harnessing Trends and Challenging Orthodoxies* (pp. 541–553). Springer Singapore. https://doi.org/10.1007/978-981-10-4944-6_26
- Campello, R. J. G. B., Kröger, P., Sander, J., & Zimek, A. (2020). Density-based clustering. *WIREs Data Mining and Knowledge Discovery*, 10(2), e1343. <https://doi.org/https://doi.org/10.1002/widm.1343>

- Casas, D., & Restrepo, A. (2019). *PROTOTIPO DE UN AMBIENTE INMERSIVO BASADO EN REALIDAD AUMENTADA HACIENDO USO DE DISPOSITIVOS DE CONTROL GESTUAL E INTERFACES CEREBRO-COMPUTADORA PARA LA TERAPIA FINOMOTORA EN NIÑOS*. Universidad Distrital Francisco José de Caldas.
- Chefneux, G. (2018). Students' Motivation to Learn Foreign Languages in Tertiary Education. In L.-M. Grosu-Rădulescu (Ed.), *Foreign Language Teaching in Romanian Higher Education: Teaching Methods, Learning Outcomes* (pp. 209–247). Springer International Publishing. https://doi.org/10.1007/978-3-319-93329-0_10
- Chen, C. H., Huang, C. Y., & Chou, Y. Y. (2019). Effects of augmented reality-based multidimensional concept maps on students' learning achievement, motivation and acceptance. *Universal Access in the Information Society*, 18(2), 257–268. <https://doi.org/10.1007/s10209-017-0595-z>
- Chen, M., Floridi, L., & Borgo, R. (2014). What Is Visualization Really For? In L. Floridi & P. Illari (Eds.), *The Philosophy of Information Quality* (pp. 75–93). Springer International Publishing. https://doi.org/10.1007/978-3-319-07121-3_5
- Corredor Camargo, J. A., Peña Cortés, C. A., & Pardo García, A. (2019). Evaluación de las emociones de usuarios en tareas con realimentación háptica utilizado el dispositivo Emotiv Insight. *Inge Cuc*, 15(1), 9–16. <https://doi.org/10.17981/ingecuc.15.1.2019.01>
- Costa, B., Freire, J., Cavalcante, H., Homci, M., Castro, A., Viégas Jr, R., Meiguins, B., & Morais, J. (2017). *Fault Classification on Transmission Lines Using KNN-DTW*. https://doi.org/10.1007/978-3-319-62392-4_13
- Cueva, L., Peña Cortés, C., Delgado, M., Villamizar, S., & Pardo, A. (2017). Registro de neuroseñales con una Interfaz Cerebro-Computador para estimar el nivel estrés en un estudiante durante una clase. *INGE CUC*, 13, 95–101. <https://doi.org/10.17981/ingecuc.13.2.2017.10>
- Cuturi, M. (2010). *Fast Global Alignment Kernels*.
- Cuturi, M., & Blondel, M. (2017). *Soft-DTW: a Differentiable Loss Function for Time-Series*. <http://arxiv.org/abs/1703.01541>
- Dabbas, E. (2021). *Interactive Dashboards and Data Apps with Plotly and Dash*. Packt.
- de Carvalho, L. B., & de Carvalho, T. L. (2020). ANÁLISES DE ATIVIDADES DOS APLICATIVOS MÓVEIS DUOLINGO E BABBEL PARA O ENSINO DE ELE. *ESPANHOL NA UNIVERSIDADE*, 3.

- De La Serna, J. M. (2018). *Alexitimia: Un Mundo Sin Emociones*.
- Debois, S. (2019). *Advantages and Disadvantages of Questionnaires*. <https://surveyanyplace.com/questionnaire-pros-and-cons/>
- Dörnyei, Z. (2019). *From Integrative Motivation to Directed Motivational Currents: The Evolution of the Understanding of L2 Motivation over Three Decades BT - The Palgrave Handbook of Motivation for Language Learning* (M. Lamb, K. Csizér, A. Henry, & S. Ryan, Eds.; pp. 39–69). Springer International Publishing. https://doi.org/10.1007/978-3-030-28380-3_3
- Dudek, A. (2020). *Silhouette Index as Clustering Evaluation Tool BT - Classification and Data Analysis* (K. Jajuga, J. Batóg, & M. Walesiak, Eds.; pp. 19–33). Springer International Publishing.
- Dwivedi, P., Kant, V., & Bharadwaj, K. K. (2018). Learning path recommendation based on modified variable length genetic algorithm. *Education and Information Technologies*, 23(2), 819–836. <https://doi.org/10.1007/s10639-017-9637-7>
- EMOTIV. (2021). *Performance Metrics*. <https://www.emotiv.com/knowledge-base/performance-metrics/>
- EMOTIV. (2022a). *About Emotiv*. <https://www.emotiv.com/about-emotiv/>
- EMOTIV. (2022b). *The Introductory Guide to BCI (Brain-Computer Interface)*. <https://www.emotiv.com/bci-guide/>
- Engchuan, P., Wongsuphasawat, K., & Sittiprapaporn, P. (2017). *Changes of EEG Power Spectra in Bench Press Weight Training Exercise*. <https://doi.org/10.1109/ECTIcon.2017.8096161>
- Ez-zaouia, M., Tabard, A., & Lavoué, E. (2020). Emodash: A dashboard supporting retrospective awareness of emotions in online learning. *International Journal of Human-Computer Studies*, 139, 102411. <https://doi.org/https://doi.org/10.1016/j.ijhcs.2020.102411>
- Fathi, J., Alipour, F., & Saeedian, A. (2018). Enhancing vocabulary learning and self-regulation via a mobile application: an investigation of the memrise app. *Journal of Modern Research in English Language Studies*, 5(1), 27–46.
- Gañán, D., Caballé, S., Clarisó, R., Conesa, J., & Bañeres, D. (2017). Evaluation of an eLearning Platform Featuring Learning Analytics and Gamification. *International Journal of Web Information Systems*, 13(1), 25–54. <https://doi.org/10.1108/IJWIS-12-2016-0074>

- Gaona-García, P. A., Stoitsis, G., Sánchez-Alonso, S., & Biniari, K. (2016). An exploratory study of user perception in visual search interfaces based on SKOS. *Knowledge Organization*. <https://doi.org/10.5771/0943-7444-2016-4-217>
- Garnes-Tarazona, I. (2018). Exploring Socio-Cultural Elements in Three Commercial English Language Learning Apps. *International Journal of Computer-Assisted Language Learning and Teaching*, 8, 65-82. <https://doi.org/10.4018/IJCALLT.2018010105>
- Gaspar, H., Morgado, L., Mamede, H., Oliveira, T., Manjón, B., & Gütl, C. (2019). Research priorities in immersive learning technology: the perspectives of the iLRN community. *Virtual Reality*, 0123456789. <https://doi.org/10.1007/s10055-019-00393-x>
- Gerbeth, S., Stamouli, E., & Mulder, R. H. (2022). The relationships between emotional competence and team learning behaviours. *Educational Research Review*, 36, 100439. <https://doi.org/https://doi.org/10.1016/j.edurev.2022.100439>
- Gibson, D. (2017). Big Data in Higher Education: Research Methods and Analytics Supporting the Learning Journey. *Technology, Knowledge and Learning*, 22(3), 237-241. <https://doi.org/10.1007/s10758-017-9331-2>
- Hao, Y., Lee, K. S., Chen, S. T., & Sim, S. C. (2019). An evaluative study of a mobile application for middle school students struggling with English vocabulary learning. *Computers in Human Behavior*, 95, 208-216. <https://doi.org/10.1016/j.chb.2018.10.013>
- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., ... Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585(7825), 357-362. <https://doi.org/10.1038/s41586-020-2649-2>
- Hashim, N. C., Majid, N. A. A., Arshad, H., & Obeidy, W. K. (2018). User Satisfaction for an Augmented Reality Application to Support Productive Vocabulary Using Speech Recognition. *Advances in Multimedia*, 2018. <https://doi.org/10.1155/2018/9753979>
- Hayat, A. A., Shateri, K., Amini, M., & Shokrpour, N. (2020). Relationships between academic self-efficacy, learning-related emotions, and metacognitive learning strategies with academic performance in medical students: a structural equation model. *BMC Medical Education*, 20(1), 76. <https://doi.org/10.1186/s12909-020-01995-9>

- Hoemann, K., Devlin, M., & Barrett, L. F. (2020). Comment: Emotions Are Abstract, Conceptual Categories That Are Learned by a Predicting Brain. *Emotion Review*, 12(4), 253–255. <https://doi.org/10.1177/1754073919897296>
- Holewa, K., & Nawrocka, A. (2014). Emotiv EPOC neuroheadset in brain - computer interface. *Proceedings of the 2014 15th International Carpathian Control Conference (ICCC)*, 149–152. <https://doi.org/10.1109/CarpathianCC.2014.6843587>
- Huber, K., & Bannert, M. (2022). What happens to your body during learning with computer-based environments? Exploring negative academic emotions using psychophysiological measurements. *Journal of Computers in Education*. <https://doi.org/10.1007/s40692-022-00228-w>
- Hussain, M., Zhu, W., Zhang, W., Abidi, S. M. R., & Ali, S. (2019). Using machine learning to predict student difficulties from learning session data. *Artificial Intelligence Review*, 52(1), 381–407. <https://doi.org/10.1007/s10462-018-9620-8>
- Ibáñez-Arenós, M., & Bort-Mir, L. (2020). Going Up Is Always Good: A Multimodal Analysis of Metaphors in a TV Ad with FILMIP, the Filmic Metaphor Identification Procedure. *Complutense Journal of English Studies*, 28, 189–201. <https://doi.org/10.5209/cjes.66959>
- Ienca, M., Haselager, P., & Emanuel, E. J. (2018). Brain leaks and consumer neurotechnology. *Nature Biotechnology*, 36(9), 805–810. <https://doi.org/10.1038/nbt.4240>
- Ifenthaler, D. (2017). Are Higher Education Institutions Prepared for Learning Analytics? *TechTrends*, 61(4), 366–371. <https://doi.org/10.1007/s11528-016-0154-0>
- Izah, N. (2019). Upgrading students' vocabulary through “memrise” app. *Proceeding of First Conference of English Language and Literature (CELL)*, 1–10.
- Javed, A., Lee, B. S., & Rizzo, D. M. (2020). A benchmark study on time series clustering. *Machine Learning with Applications*, 1, 100001. <https://doi.org/https://doi.org/10.1016/j.mlwa.2020.100001>
- Ji, H., Park, S., & Shin, H. W. (2022). Investigating the link between engagement, readiness, and satisfaction in a synchronous online second language learning environment. *System*, 105, 102720. <https://doi.org/https://doi.org/10.1016/j.system.2022.102720>
- Jiang, X., Rollinson, J., Plonsky, L., Gustafson, E., & Pajak, B. (2021). Evaluating the reading and listening outcomes of beginning-level Duolingo courses. *Foreign Language Annals*, 54(4), 974–1002. <https://doi.org/https://doi.org/10.1111/flan.12600>

- Jin, J., Miao, Y., Daly, I., Zuo, C., Hu, D., & Cichocki, A. (2019). Correlation-based channel selection and regularized feature optimization for MI-based BCI. *Neural Networks*, 118, 262–270. <https://doi.org/https://doi.org/10.1016/j.neunet.2019.07.008>
- Kamphuis, C., Barsom, E., Schijven, M., & Christoph, N. (2014). Augmented reality in medical education? *Perspectives on Medical Education*, 3(4), 300–311. <https://doi.org/10.1007/s40037-013-0107-7>
- Karjo, C. H., & Andreani, W. (2018). Learning Foreign Languages With Duolingo and Memrise. *Proceedings of the 2018 International Conference on Distance Education and Learning*, 109–112. <https://doi.org/10.1145/3231848.3231871>
- Katona, J., Ujbanyi, T., Sziladi, G., & Kovari, A. (2016). Speed control of Festo Robotino mobile robot using NeuroSky MindWave EEG headset based brain-computer interface. *2016 7th IEEE International Conference on Cognitive Infocommunications (CogInfoCom)*, 251–256. <https://doi.org/10.1109/CogInfoCom.2016.7804557>
- Kaufman, L., & Rousseeuw, P. (1990). Finding Groups in Data: An Introduction To Cluster Analysis. In *Wiley, New York*. ISBN 0-471-87876-6. <https://doi.org/10.2307/2532178>
- Kew, S. N., Petsangsri, S., Ratanaolarn, T., & Tasir, Z. (2018). Examining the motivation level of students in e-learning in higher education institution in Thailand: A case study. *Education and Information Technologies*, 23(6), 2947–2967. <https://doi.org/10.1007/s10639-018-9753-z>
- King, R. B., & Chen, J. (2019a). Emotions in Education: Asian Insights on the Role of Emotions in Learning and Teaching. *The Asia-Pacific Education Researcher*, 28(4), 279–281. <https://doi.org/10.1007/s40299-019-00469-x>
- King, R. B., & Chen, J. (2019b). Emotions in Education: Asian Insights on the Role of Emotions in Learning and Teaching. In *Asia-Pacific Education Researcher*. Springer. <https://doi.org/10.1007/s40299-019-00469-x>
- Klonsky, E. D., Victor, S. E., Hibbert, A. S., & Hajcak, G. (2019). The Multidimensional Emotion Questionnaire (MEQ): Rationale and Initial Psychometric Properties. *Journal of Psychopathology and Behavioral Assessment*, 409–424. <https://doi.org/10.1007/s10862-019-09741-2>
- Kuromiya, H. (2021). *Automatic Classification of the Learning Pattern - Time-Series Clustering of Students' Reading Behaviors*.
- Lee, S., Kim, J., Hwang, J., Lee, E., Lee, K.-J., Oh, J., Park, J., & Heo, T.-Y. (2020). Clustering of Time Series Water Quality Data Using Dynamic Time Warping: A Case Study from the

- Bukhan River Water Quality Monitoring Network. *Water*, 12(9).
<https://doi.org/10.3390/w12092411>
- Lehtamo, S., Juuti, K., Inkinen, J., & Lavonen, J. (2018). Connection between academic emotions in situ and retention in the physics track: applying experience sampling method. *International Journal of STEM Education*, 5(1).
<https://doi.org/10.1186/s40594-018-0126-3>
- Li, C., Li, N., Qiu, Y., Peng, Y., Wang, Y., Deng, L., Ma, T., Li, F., Yao, D., & Xu, P. (2022). Multimodal collaborative BCI system based on the improved CSP feature extraction algorithm. *Virtual Reality & Intelligent Hardware*, 4(1), 22–37.
<https://doi.org/https://doi.org/10.1016/j.vrih.2022.01.002>
- Liu, S., Liu, S., Liu, Z., Peng, X., & Yang, Z. (2022). Automated detection of emotional and cognitive engagement in MOOC discussions to predict learning achievement. *Computers & Education*, 181, 104461.
<https://doi.org/https://doi.org/10.1016/j.compedu.2022.104461>
- Loayaza, M. (2015). *Influencia de la motivación en el desarrollo cognitivo de los estudiantes en la asignatura de Matemática en el Instituto de Formación Bancaria-Certus*. Universidad de San Martín de Porres.
- Loderer, K., Pekrun, R., & Lester, J. C. (2018). Beyond cold technology: A systematic review and meta-analysis on emotions in technology-based learning environments. *Learning and Instruction*. <https://doi.org/10.1016/j.learninstruc.2018.08.002>
- Loderer, K., Pekrun, R., & Lester, J. C. (2020). Beyond cold technology: A systematic review and meta-analysis on emotions in technology-based learning environments. *Learning and Instruction*, 70, 101162.
<https://doi.org/https://doi.org/10.1016/j.learninstruc.2018.08.002>
- Loewen, S., Isbell, D. R., & Sporn, Z. (2020). The effectiveness of app-based language instruction for developing receptive linguistic knowledge and oral communicative ability. *Foreign Language Annals*, 53(2), 209–233.
<https://doi.org/https://doi.org/10.1111/flan.12454>
- Long, P., & Siemens, G. (2011). Penetrating the Fog: Analytics in learning and education. *Educause Review*, 46(4), 31–40. <https://doi.org/10.1177/0894318416647779>
- Lotherington, H. (2018). How mobile are top-rated mobile language learning apps? *Proceedings of the 14th International Conference on Mobile Learning 2018, ML 2018*, 121–128.

- Luo, X., Yuan, Y., Zhang, K., Xia, J., Zhou, Z., Chang, L., & Gu, T. (2019). Enhancing statistical charts: toward better data visualization and analysis. *Journal of Visualization*, 22(4), 819–832. <https://doi.org/10.1007/s12650-019-00569-2>
- MacQueen, J. (1967). Classification and analysis of multivariate observations. *5th Berkeley Symp. Math. Statist. Probability*, 281–297.
- McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. <https://doi.org/10.25080/Majora-92bf1922-00a>
- MinTIC. (2017). *TIC y educación*. <http://Vivedigitalparalagente.Gov.Co>. <http://vivedigitalparalagente.gov.co/612/w3-article-19513.html>
- MinTIC. (2018). *Colombia redujo su brecha digital en educación en 83%*. Mintic.Gov.Co. <https://mintic.gov.co/portal/inicio/Sala-de-Prensa/Noticias/75436:Colombia-redujo-su-brecha-digital-en-educacion-en-83>
- Molsing, K. V., Becker Lopes Perna, C., & Tramunt Ibaños, A. M. (Eds.). (2020). *Linguistic Approaches to Portuguese as an Additional Language*. John Benjamins.
- Murphy, S., MacDonald, A., Wang, C. A., & Danaia, L. (2019). Towards an Understanding of STEM Engagement: a Review of the Literature on Motivation and Academic Emotions. *Canadian Journal of Science, Mathematics and Technology Education*, 19(3), 304–320. <https://doi.org/10.1007/s42330-019-00054-w>
- NeuroSky. (2021a). *About Neurosky*. <http://neurosky.com/about-neurosky/>
- NeuroSky. (2021b). *Get to market faster with NeuroSky pre-built algorithms*. <http://neurosky.com/biosensors/eeg-sensor/algorithms/>
- NeuroSky. (2021c). *NeuroSky's Mind Developer Tools*. http://developer.neurosky.com/docs/doku.php?id=mdt_readme
- Niforatos, E., & Karapanos, E. (2015). EmoSnaps: a mobile application for emotion recall from facial expressions. *Personal and Ubiquitous Computing*, 19(2), 425–444. <https://doi.org/10.1007/s00779-014-0777-0>
- Noroozi, O., Pijeira-Díaz, H. J., Sobocinski, M., Dindar, M., Järvelä, S., & Kirschner, P. A. (2020). Multimodal data indicators for capturing cognitive, motivational, and emotional learning processes: A systematic literature review. *Education and Information Technologies*, 25(6), 5499–5547. <https://doi.org/10.1007/s10639-020-10229-w>
- Nushi, M., & Eqbali, M. (2018). Babel: A Mobile Language Learning App. *TESL Reporter*, 51, 109–121.

- Nushi, M., & Jenabzadeh, H. (2016). Busuu: A Mobile App. *The TESL Reporter Journal*, 49, 30–38.
- Palmiter Bajorek, J. (2017). L2 Pronunciation in CALL: The Unrealized Potential of Rosetta Stone, Duolingo, Babbel and Mango Languages. *Issues and Trends in Educational Technology*, 5(1), 28.
- Papamitsiou, Z., & Economides, A. A. (2014). Learning analytics and educational data mining in practice: A systemic literature review of empirical evidence. *Educational Technology and Society*, 17(4), 49–64.
- Paparrizos, J., & Gravano, L. (2015). K-shape: Efficient and accurate clustering of time series. *Proceedings of the ACM SIGMOD International Conference on Management of Data, 2015-May*, 1855–1870. <https://doi.org/10.1145/2723372.2737793>
- Paparrizos, J., & Gravano, L. (2017). Fast and Accurate Time-Series Clustering. *ACM Trans. Database Syst.*, 42(2). <https://doi.org/10.1145/3044711>
- Pegrum, M. (2019). *Mobile Learners BT - Mobile Lenses on Learning: Languages and Literacies on the Move* (M. Pegrum, Ed.; pp. 171–206). Springer Singapore. https://doi.org/10.1007/978-981-15-1240-7_5
- Raj, R., Deb, S., & Bhattacharya, P. (2018). Brain Computer Interfaced Single Key Omni Directional Pointing and Command System: a Screen Pointing Interface for Differently-abled Person. *Procedia Computer Science*, 133, 161–168. <https://doi.org/https://doi.org/10.1016/j.procs.2018.07.020>
- Raja, P. D. A., Akash, D., Kumar, S. J. P., Harsha, D. S., & Arunachalaperumal, C. (2020). Feature extraction and classification of EEG signal based anomaly detection and home automation for physically challenged/impaired people using neurosky mindwave headset. *AIP Conference Proceedings*, 2207(1), 40006. <https://doi.org/10.1063/5.0000064>
- Rashid, M., Sulaiman, N., Mustafa, M., Khatun, S., & Sama Bari, B. (2019). The Classification of EEG Signal using Different Machine Learning Techniques for BCI Application. In *Robot Intelligence Technology and Applications* (Vol. 5, Issue January). Springer Singapore. <https://doi.org/10.1007/978-981-13-7780-8>
- Redjeki, I. S., & Muhajir, R. (2020). DUOLINGO For Grammar Learning. *PROSIDING LPPM UIKA BOGOR*.
- Rezeika, A., Benda, M., Stawicki, P., Gembler, F., Saboor, A., & Volosyak, I. (2018). Brain-Computer Interface Spellers: A Review. *Brain Sciences*, 8(4). <https://doi.org/10.3390/brainsci8040057>

- Roberts, L. D., Howell, J. A., & Seaman, K. (2017). Give Me a Customizable Dashboard: Personalized Learning Analytics Dashboards in Higher Education. *Technology, Knowledge and Learning*, 22(3), 317–333. <https://doi.org/10.1007/s10758-017-9316-1>
- Rodriguez, A. O. R., Riaño, M. A., García, P. A. G., & Marín, C. E. M. (2022). *Time Series for Evaluation of Performance Metrics as of Interaction with an AR-Sandbox Using Brain Computer Interfaces BT - Information Technology and Systems* (Á. Rocha, C. Ferrás, A. Méndez Porras, & E. Jimenez Delgado, Eds.; pp. 426–434). Springer International Publishing.
- Rodríguez, A. O. R., Riaño, M. A., García, P. A. G., Marín, C. E. M., Crespo, R. G., & Wu, X. (2020). Emotional characterization of children through a learning environment using learning analytics and AR-Sandbox. *Journal of Ambient Intelligence and Humanized Computing*. <https://doi.org/10.1007/s12652-020-01887-2>
- Rousseeuw, P. (1987). Rousseeuw, P.J.: Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. *Comput. Appl. Math.* 20, 53-65. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- Sahla, K., & Senthil, T. (2016). Classroom Teaching Assessment Based on Student Emotions. *Intelligent Systems Technologies and Applications 2016*, 530, 789–802. <https://doi.org/10.1007/978-3-319-47952-1>
- Sander, N., Abel, G. J., Bauer, R., & Schmidt, J. (2014). *Visualising migration flow data with circular plots* (Issue 2/2014). Austrian Academy of Sciences (ÖAW), Vienna Institute of Demography (VID). <http://hdl.handle.net/10419/97018>
- Saqr, M., Fors, U., & Tedre, M. (2018). How the study of online collaborative learning can guide teachers and predict students' performance in a medical course. *BMC Medical Education*, 18(1), 1–14. <https://doi.org/10.1186/s12909-018-1126-1>
- Sardá-Espinosa, A. (2018). *Comparing Time-Series Clustering Algorithms in R Using the dtwclust Package*.
- Sardá-Espinosa, A. (2019). Time-series clustering in R Using the dtwclust package. *R Journal*, 11(1), 1–45. <https://doi.org/10.32614/rj-2019-023>
- Sarica, A., Guzzi, P. H., & Cannataro, M. (2013). Building and mining web-based questionnaires and surveys with SySQ. *Interdisciplinary Sciences: Computational Life Sciences*, 5(3), 233–239. <https://doi.org/10.1007/s12539-013-0167-8>

- Seli, P., Wammes, J. D., Risko, E. F., & Smilek, D. (2016). On the relation between motivation and retention in educational contexts: The role of intentional and unintentional mind wandering. *Psychonomic Bulletin and Review*, 23(4), 1280–1287. <https://doi.org/10.3758/s13423-015-0979-0>
- Seng, K. P., Ang, L., Liew, A. W., & Gao, J. (2019). Multimodal Analytics for Next-Generation Big Data Technologies and Applications. *Multimodal Analytics for Next-Generation Big Data Technologies and Applications*, 3–9. <https://doi.org/10.1007/978-3-319-97598-6>
- Shadiev, R., Shadiev, N., Fayziev, M., & Shadieva, B. (2019). *Impact of Speech-Enabled Language Translation Application on Perceived Learning Emotions in Lectures in English as a Medium of Instruction BT - Innovative Technologies and Learning* (L. Rønningsbakk, T.-T. Wu, F. E. Sandnes, & Y.-M. Huang, Eds.; pp. 809–814). Springer International Publishing.
- Shao, K., Pekrun, R., Marsh, H. W., & Loderer, K. (2020). Control-value appraisals, achievement emotions, and foreign language performance: A latent interaction analysis. *Learning and Instruction*, 69, 101356. <https://doi.org/https://doi.org/10.1016/j.learninstruc.2020.101356>
- Sheidin, J., Lanir, J., & Kuflik, T. (2019). A Comparative Evaluation of Techniques for Time Series Visualizations of Emotions. *Proceedings of the 13th Biannual Conference of the Italian SIGCHI Chapter: Designing the next Interaction*. <https://doi.org/10.1145/3351995.3352054>
- Sievert, C. (2020). *Interactive Web-Based Data Visualization with R, plotly, and shiny*. Chapman and Hall/CRC.
- Smith Lesley and King, J. (2018). Silence in the Foreign Language Classroom: The Emotional Challenges for L2 Teachers. In J. de D. Martínez Agudo (Ed.), *Emotions in Second Language Teaching: Theory, Research and Teacher Education* (pp. 323–339). Springer International Publishing. https://doi.org/10.1007/978-3-319-75438-3_18
- Spada, N., Ranta, L., & Lightbown, P. M. (1996). Working with teachers in second language acquisition research. *Second Language Classroom Research: Issues and Opportunities*, 31–44.
- Sporn, Z., Chanter, J., & Meehan, D. (2020). Babbel Language Learning Podcasts. *International Journal of Advanced Corporate Learning (IJAC)*, 13(3), 43–49. <https://doi.org/10.3991/ijac.v13i3.17025>

- Strmiska, M., & Koudelkova, Z. (2018). Analysis of Performance Metrics Using Emotiv EPOC +. *MATEC Web of Conferences*, 210, 4–7. <https://doi.org/10.1051/matecconf/201821004046>
- Tarng, W., Ou, K. L., Yu, C. S., Liou, F. L., & Liou, H. H. (2015). Development of a virtual butterfly ecological system based on augmented reality and mobile learning technologies. *Virtual Reality*, 19(3–4), 253–266. <https://doi.org/10.1007/s10055-015-0265-5>
- Tempelaar, D., Nguyen, Q., & Rienties, B. (2020). Learning feedback based on dispositional learning analytics. In *Intelligent Systems Reference Library* (Vol. 158). Springer International Publishing. https://doi.org/10.1007/978-3-030-13743-4_5
- Teske, K. (2017). Duolingo. *CALICO Journal*, 34(3), 393–401. <https://doi.org/10.1558/cj.32509>
- Toa, C. K., Sim, K. S., & Tan, S. C. (2021). *Emotiv Insight with Convolutional Neural Network: Visual Attention Test Classification BT - Advances in Computational Collective Intelligence* (K. Wojtkiewicz, J. Treur, E. Pimenidis, & M. Maleszka, Eds.; pp. 348–357). Springer International Publishing.
- Tomašev, N., & Radovanović, M. (2016). *Clustering Evaluation in High-Dimensional Data BT - Unsupervised Learning Algorithms* (M. E. Celebi & K. Aydin, Eds.; pp. 71–107). Springer International Publishing. https://doi.org/10.1007/978-3-319-24211-8_4
- Tuncay, H. O. (2020). *App Attrition in Computer-Assisted Language Learning: Focus on Duolingo*. McGill University (Canada).
- Tyng, C. M., Amin, H. U., Saad, M. N. M., & Malik, A. S. (2017). The Influences of Emotion on Learning and Memory. *Frontiers in Psychology*, 8, 1454. <https://doi.org/10.3389/fpsyg.2017.01454>
- Viberg, O., Mavroudi, A., & Ma, Y. (2020). Supporting second language learners' development of affective self-regulated learning skills through the use and design of mobile technology. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 12315 LNCS. https://doi.org/10.1007/978-3-030-57717-9_13
- Villegas Méndez, B. M., & Rojas Fernández, M. G. (2018). Interfaz cerebro ordenador BCI mediante el uso de Emotiv Insight BCI computer brain interface by using Emotiv Insight. *Insight, Emotiv*, 9(1), 3–31.

- Vlahovic, S., Suznjevic, M., & Skorin-Kapov, L. (2022). A survey of challenges and methods for Quality of Experience assessment of interactive VR applications. *Journal on Multimodal User Interfaces*. <https://doi.org/10.1007/s12193-022-00388-0>
- Walt, S. van der, Colbert, S. C., & Varoquaux, G. (2011). The NumPy Array: A Structure for Efficient Numerical Computation. *Computing in Science & Engineering*, 13(2), 22–30. <https://doi.org/10.1109/MCSE.2011.37>
- Wang, J., & Bailly, S. (2015). *Chinese Students Experiencing Learning French As A Second Language In France: A Case Study Of Individual Differences In The Context Of Study Abroad*. (pp. 59–83). https://doi.org/10.1057/9781137492913_4
- Wei, W. W. S. (2013). *Time Series Analysis*. Oxford University Press. <https://doi.org/10.1093/oxfordhb/9780199934898.013.0022>
- Wong, B. T., & Li, K. C. (2019). A review of learning analytics intervention in higher education (2011–2018). *Journal of Computers in Education*, 0123456789. <https://doi.org/10.1007/s40692-019-00143-7>
- Woods. (2017). *How duolingo got 170 million users worldwide to learn a second language*. <https://brainstation.io/magazine/how-duolingo-got-170-million-users-worldwide-to-learn-a-second-language>
- Wu, X., Kumar, V., Ross Quinlan, J., Ghosh, J., Yang, Q., Motoda, H., McLachlan, G. J., Ng, A., Liu, B., Yu, P. S., Zhou, Z.-H., Steinbach, M., Hand, D. J., & Steinberg, D. (2008). Top 10 algorithms in data mining. *Knowledge and Information Systems*, 14(1), 1–37. <https://doi.org/10.1007/s10115-007-0114-2>
- Xu, T., Zhou, Y., Wang, Z., & Peng, Y. (2018). Learning Emotions EEG-based Recognition and Brain Activity: A Survey Study on BCI for Intelligent Tutoring System. *Procedia Computer Science*, 130, 376–382. <https://doi.org/https://doi.org/10.1016/j.procs.2018.04.056>
- Zhang, F., Markopoulos, P., Bekker, T., Paule-Ruiz, M., & Schüll, M. (2022). Understanding design-based learning context and the associated emotional experience. *International Journal of Technology and Design Education*, 32(2), 845–882. <https://doi.org/10.1007/s10798-020-09630-w>
- Zhang, X. (2019). Learning Technology Review: Memrise. *CALICO Journal*, 36(2), 152–161. <https://doi.org/10.1558/cj.37857>
- Zhou, W. (2020a). Mobile Assisted Chinese Learning as a Foreign Language: An Overview of Publications between 2007 and 2019. *Frontiers of Education in China*, 15(1), 164–181. <https://doi.org/10.1007/s11516-020-0007-7>

- Zhou, W. (2020b). Mobile Assisted Chinese Learning as a Foreign Language: An Overview of Publications between 2007 and 2019. In *Frontiers of Education in China* (Vol. 15, Issue 1, pp. 164–181). Springer. <https://doi.org/10.1007/s11516-020-0007-7>
- Zhu, Y., Yang, X., & Jia Wang, S. (2017). Augmented Reality Meets Tangibility: A New Approach for Early Childhood Education. *EAI Endorsed Transactions on Creative Technologies*, 4(11), 153059. <https://doi.org/10.4108/eai.5-9-2017.153059>