



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS

INVESTIGACIÓN __X__

PROFUNDIZACIÓN ____

MEJORAMIENTO DE LA DESCRIPCIÓN DE RECURSOS
EDUCATIVOS ABIERTOS, A PARTIR DE TÉCNICAS BASADAS EN
INTELIGENCIA ARTIFICIAL, MACHINE LEARNING Y MINERÍA DE
DATOS

Autor

Juan Guillermo Cotta García

Director:

Jhon Francined Herrera Cubides

Co-director:

Paulo Alonso Gaona García

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
Maestría en Ciencias de la Información y las Comunicaciones
Énfasis en Ingeniería de Software
Bogotá, Colombia
agosto de 2025

TABLA DE CONTENIDO

RESUMEN.....	4
PALABRAS CLAVE	6
INTRODUCCIÓN.....	7
2. PROBLEMA DE INVESTIGACIÓN	8
2.1 PLANTEAMIENTO DEL PROBLEMA:.....	8
2.2 FORMULACIÓN DEL PROBLEMA.....	13
2.3 SISTEMATIZACIÓN DEL PROBLEMA.....	13
3. OBJETIVOS	14
3.1 OBJETIVO GENERAL:.....	14
3.2 OBJETIVOS ESPECÍFICOS:.....	14
4. JUSTIFICACIÓN.....	15
4.1 JUSTIFICACIÓN TEÓRICA.....	15
4.2 JUSTIFICACIÓN PRÁCTICA.....	16
3.3. JUSTIFICACIÓN METODOLÓGICA.....	16
5. MARCO DE REFERENCIA Y ESTADO DEL ARTE	18
4.1. MARCO TEÓRICO:.....	18
6. MARCO CONCEPTUAL	29
7. HIPÓTESIS	46
8. ANTECEDENTES DEL ESTADO DE DESCRIPCIÓN DE REAS	47
9. DESARROLLO METODOLÓGICO	68
10. DISEÑO DE LA ESTRATEGIA PLANTEADA	73
11. IMPLEMENTACIÓN Y DESPLIEGUE DE LA ESTRATEGIA PLANTEADA	90
12. VERIFICACIÓN DE RESULTADOS Y APORTES	108

13. CONCLUSIONES	131
14. TRABAJOS FUTUROS Y RECOMENDACIONES	134
15. BIBLIOGRAFÍA.....	136

ÍNDICE DE FIGURAS

Figura 1: Representación Gráfica del Modelo LDA. Tomado de: (Yu & Xiang, 2023).....	22
Figura 2 – KUJANE Nodo Colombia, Tomado de: (Minciencias, Repositorio Nacional KUJANE, 2019)	50
Figura 3 - Red Colombiana de Información Científica – Tomado de: (Minciencias, 2022)	51
Figura 4 - OER World Map - Tomado de: (OER World Map, 2025).....	62
Figura 5 - Portal re3data.org - Tomado de: (re3data.org, n.d.).....	63
Figura 6 - Desafíos para la descripción de la metada de REAs	67
Figura 7 - Puntaje EU-27 en la dimensión de calidad de metadatos. Fuente: (Capgemini Invent, 2024).....	68
Figura 8 – Fases para el diseño de la estrategia propuesta	74
Figura 9 - Estructura Metadatos BibJson – Repositorio DOAJ	76
Figura 10 - Proceso ETL - Tomado de: (SouthindusLabs, 2021)	77
Figura 11 – Vector embeddings: Proceso para la representación vectorial de los metadatos seleccionados.	80
Figura 12 - Características de selección de modelo de ML	81
Figura 13 - Indexado de Vectores (embeddings)	83
Figura 14 - Búsqueda vectorial - Workflow.....	84
Figura 15 - Proceso de búsqueda a través de la estructura multicapa del grafo HNSW. (Pinecone, 2025)	85
Figura 16 - Workflow de búsqueda híbrida. Fuente: (Belagatti, 2024).....	86
Figura 17 - Fases de RAG, Fuente: Datos Abiertos Gobierno España (Datos.gob.es, 2024)	87
Figura 18 - Estrategia para mejoramiento de los elementos de metadata que describen los REAs.	88
Figura 19 – Magic Quadrant for Cloud AI Developer Services. Fuente: (Azure, 2024).....	91
Figura 20 - Etapas para la generación de embeddings	92
Figura 21 - Distribución PCA 3D de los embeddings del vector de títulos de una muestra de datos.....	94
Figura 22 - Histograma de distancias coseno entre embeddings para el campo título.	95

Figura 23 - Mapa de calor de similitud coseno para el vector de título del dataset de recursos seleccionado.	96
Figura 24 - Estructura de índice creado	96
Figura 25 - Azure Index creado.....	102
Figura 26 - Sistema RAG en acción para estrategia de REAs	104
Figura 27 - Prompt de entrenamiento al modelo generativo LLM.	105
Figura 28 - Arquitectura Interfaz de Usuario y sistema RAG de REAs	107
Figura 29 - Proceso de Búsqueda vectorial. Fuente: (Microsoft, Vector Search, 2024)...	108
Figura 30 - Tamaño de índice de REAs en Azure	109
Figura 31 - Evidencia # 1 - Fuente Google Scholar.....	126

RESUMEN

Si bien los Recursos Educativos Abiertos (REA) son fundamentales para la enseñanza, el aprendizaje y la investigación gracias a las políticas de acceso abierto y las herramientas web, su potencial se ve frecuentemente limitado. A pesar de su crecimiento exponencial, muchos REA se publican con descripciones en los metadatos de baja calidad o incompletas, lo que dificulta su descubrimiento, recuperación y reutilización efectiva en repositorios digitales abiertos, generando problemas de ambigüedad e incoherencia.

Para abordar esta problemática, se propone una estrategia basada en técnicas de machine learning (Modelos Extensos de Lenguaje LLM), técnicas de embeddings (representaciones vectoriales) para captura semántica con el fin de mejorar los elementos de metadata que describen los REA. Esta estrategia busca descubrir nuevos detalles que proporcionen una mejor descripción de un recurso, y así, maximizar el potencial de los REA en los diferentes repositorios digitales abiertos.

PALABRAS CLAVE

REA (Recurso Educativo Abierto), Machine Learning, IA, LLM (Modelos Extensos de Lenguaje), RAG (Generación Aumentada por Recuperación).

INTRODUCCIÓN

La educación como eje transformador y de avance para la sociedad en general, ha evolucionado de tal manera, que puede atravesar cualquier frontera física y temporal para que cualquier individuo tenga la posibilidad de apoyar su proceso de aprendizaje y acceder a nuevo conocimiento. Esto en compañía del uso de las TIC (Tecnologías de la Información y las Comunicaciones), las políticas que promueven el acceso abierto de la información y las herramientas tecnológicas que se disponen en la Web, han evolucionado para que actualmente, se disponga de *Recursos Educativos Abiertos (REA)*, los cuales son aquel material de enseñanza, aprendizaje e investigación, que residen bajo dominio público y se permite su uso, redistribución y remezcla por parte de cualquier persona interesada.

Si bien el crecimiento exponencial que han tenido estos recursos ha logrado diversificar los diferentes tipos y temáticas de interés que se cubren, así como también, que cada vez más, diferentes centros académicos y gubernamentales, estén dispuestos a ser generadores de estos materiales, la evidencia ha demostrado que estos recursos se están publicando con una descripción precaria y de baja calidad, que no permite se aproveche todo el potencial que pretenden ofrecer, porque los procesos de búsqueda, recuperación y uso se ven afectados. Esto se deriva de diferentes situaciones que en su mayoría convergen al problema de llenado de información, al momento de publicar el recurso en el repositorio digital abierto, encontrando problemas de ambigüedad, incoherencia, incompletitud o nulidad de la información. De acuerdo con las circunstancias mencionadas, surge la necesidad de proponer un mecanismo, que permita mejorar la descripción de los REA, en cuanto sea necesario, para que estos recursos sean aprovechados dentro de los diferentes repositorios digitales abiertos dispuestos para su uso.

Considerando lo anterior, este trabajo de investigación pretende diseñar una estrategia basada en técnicas de inteligencia artificial, machine learning y minería de datos, que han demostrado, en otros contextos, ser factibles para el descubrimiento de nuevos detalles y recomendaciones para aportar una mejora a la descripción de REA.

1. PROBLEMA DE INVESTIGACIÓN

1.1 PLANTEAMIENTO DEL PROBLEMA:

El avance de la sociedad de la información y la expansión de la informática han abierto nuevas puertas para el aprendizaje. Las instituciones académicas y gubernamentales han aprovechado Internet y las prácticas derivadas como la Web Semántica, Apertura de Datos, Vinculación y publicación de datos, para mejorar y distribuir materiales educativos. En este contexto, surgen los *Recursos Educativos Abiertos (REA)*, que abarcan todo aquello material digitalizado, ofrecido con intención académica y/o de investigación que permite su uso y distribución de manera libre y abierta (Wesolek, Lashley, & Langley, 2018). El mercado laboral en constante evolución, las nuevas demandas de conocimiento y habilidades que cambian dinámicamente, los desafíos globales para el trabajo y la educación debido a la pandemia del COVID-19, son algunos de los ejemplos que resaltan la creciente necesidad de una educación flexible, concreta y personalizada (Molavi, Tavakoli, & Kismihók, 2020). En consecuencia, a esto, se enfrenta un crecimiento exponencial de materiales educativos distribuidos y heterogéneos como los REA, movimiento, que crece rápidamente con iniciativas tanto a gran escala como pequeñas, impulsadas por instituciones y comunidades y se presentan como una solución potencial para mejorar la accesibilidad y asequibilidad de los materiales educativos (Wesolek, Lashley, & Langley, 2018).

El interés en los REA ha llevado al aumento de colecciones de repositorios de objetos de aprendizaje digitales (ROER), donde se almacenan los recursos. De acuerdo con el estudio de (Simao De Deus & Francine Barbosa, 2020), se observó un crecimiento exponencial de REAs en la década de 2009 a 2019. Este crecimiento, en comparación con la década anterior (1999-2009), mostró una impresionante tasa de aumento del 319%.

Así pues, la proliferación de recursos educativos abiertos de diferentes áreas de estudio ha generado la necesidad de agregar descripciones (metadatos) a dichos recursos, los cuales definen el conjunto de propiedades que hacen posible la búsqueda y recuperación dentro de colecciones amplias de datos (Valiente, Sicilia, Garcia-Barriocanal, & Rajabi, 2015); (Simao De Deus & Francine Barbosa, 2020). En este sentido, los metadatos son

fundamentales para presentar buenos resultados y coincidencias a cualquier usuario que busque REAs. Ayudan a los usuarios a encontrar los recursos más relevantes para sus necesidades y ofrecen una visión general que ayuda al usuario a evaluar fácilmente si un recurso educativo abierto es adecuado para el propósito previsto. Los metadatos estandarizados simplifican el intercambio de recursos entre repositorios o con otras partes interesadas, como los motores de búsqueda especializados, facilitando la difusión e interoperabilidad de los REA (Menzel, 2023). La mayoría de los repositorios, que almacenan recursos, emplean estándares para la definición de metadatos como: IEEE Standard For Learning Object Metadata (LOM), Learning Resource Metadata Initiative (LRMI) ó Dublin Core Metadata Initiative (DCMI). A pesar de esto, la evidencia ha demostrado que existen problemas con los metadatos de los REA, causados principalmente a la baja calidad de estos, por factores como:

- *Ausencia de Metadatos:* Existe ausencia de metadatos sobre los temas cubiertos por los recursos. Los autores de REA, a menudo no proporcionan metadatos, porque lo consideran una actividad engorrosa que consume tiempo. Es común encontrar recursos que ni siquiera cubren la temática que aborda el recurso (Tavakoli, Mirette, Gábor, & Sören, 2021) (Molavi, Tavakoli, & Kismihók, 2020) o incluso recursos, donde datos indispensables como *año de creación* vienen vacíos (Simao De Deus & Francine Barbosa, 2020).
- *Inadecuada construcción de metadatos:* Los usuarios que completan los metadatos usan términos no relevantes, datos informales o textos significativamente diferentes, lo que causa problemas para encontrar y recuperar REA en los repositorios, afectando la utilización de metadatos por parte de los motores de búsqueda (Simao De Deus & Francine Barbosa, 2020).
- *Falla en el proceso de llenado de metadatos:* los autores de recursos educativos abiertos (OER) a menudo no están dispuestos a invertir el esfuerzo necesario para completar metadatos detallados (Hielscher, Cantieni, & Hartmann, 2015). La educación superior abarca una amplia gama de temas y los editores de material científico, como por ejemplo de revistas, pueden no tener conocimientos expertos en todos ellos. Los editores pueden verificar o proporcionar datos bibliográficos comunes y palabras clave. Sin embargo, la descripción del contenido se limita a un nivel general. Esto sugiere que, aunque los editores pueden ayudar en ciertos

aspectos de la creación de metadatos, su capacidad para proporcionar descripciones detalladas del contenido puede ser limitada (Menzel, 2023).

- *Ausencia de descripción significativa:* Por lo general, metadatos como título y autor son los más comunes y siempre proporcionados. No obstante, más allá de estos datos básicos, una descripción significativa es valiosa para los usuarios de Recursos Educativos Abiertos. Sin embargo, a menudo se debe solicitar a los autores o completarla por parte de los editores y es donde este proceso puede sufrir falencias (Menzel, 2023).

La observación de esta situación evidencia que se derivan principalmente consecuencias que afectan a varios aspectos:

- *Servicios personalizados en repositorios digitales abiertos:* La búsqueda, recuperación y recomendación de recursos dentro de repositorios, son cruciales para organizar los materiales y mejorar su aplicabilidad y dependen estrechamente de metadatos precisos. Estos metadatos también son esenciales para el control de calidad automático (Molavi, Tavakoli, & Kismihók, 2020) (Tavakoli, Mirette, Gábor, & Sören, 2021).
- *Desafíos relacionados con la calidad de los metadatos en los REA:* La calidad insuficiente de los metadatos en los Recursos Educativos Abiertos (REA) obstaculiza la búsqueda y el descubrimiento de recursos educativos, lo que repercute negativamente en la accesibilidad y reutilización de los materiales disponibles en los repositorios. La ausencia de metadatos precisos y de procedencia adecuada puede llegar a debilitar la confianza de los usuarios en la validez y relevancia de los recursos. Además, los metadatos incompletos o inconsistentes pueden llevar a la pérdida de información valiosa, afectando la habilidad de los usuarios para evaluar y utilizar los recursos de manera efectiva. La deficiente calidad de los metadatos puede representar un obstáculo para la innovación y el desarrollo de nuevas herramientas y métodos destinados a mejorar la educación abierta y los recursos educativos (Romero-Pelaez, Segarra-Faggioni, & Alarcon, 2018).

- **Desafíos de interoperabilidad:** La falta de precisión y estructura en los metadatos puede afectar la interoperabilidad entre diferentes sistemas y bases de datos (Alemu, 2016).
- Si los metadatos no se proporcionan o son escasos, su gestión puede volverse ineficiente. La disponibilidad de ciertos metadatos puede generar expectativas falsas si no se cumplen (Menzel, 2023).

La mejora y el enriquecimiento de los metadatos que describen los Recursos Educativos Abiertos (REA) ha sido objeto de numerosas investigaciones. Diversas iniciativas han desarrollado perfiles de metadatos para REA fundamentados en principios clave como la calidad, la apertura y la vinculación de datos (Herrera-Cubides, Gaona-García, Montenegro-Marín, & Sánchez-Alonso, 2022) (Menzel, 2023); (Kushwaha & Prabhakar, 2019). De forma complementaria, trabajos como los de (Molavi, Tavakoli, & Kismihók, 2020) ; (Tavakoli, Mirette, Gábor, & Sören, 2021); (Ludeña, Segarra-Faggioni, Romero-Pelaez, & Morocho-Yunga, 2024) que han buscado clasificar los REA, predecir su nivel de calidad y han puesto su esfuerzo en automatizar la exploración de temas o tópicos de estos recursos, para obtener información relevante sobre los mismos, y afrontar la situación de que los metadatos carecen en la cobertura para describir correctamente los recursos (Ludeña, Segarra-Faggioni, Romero-Pelaez, & Morocho-Yunga, 2024).

Ahora bien, lo propio se ha realizado en el contexto colombiano alrededor de la generación de REA, donde se han impulsado diferentes proyectos que principalmente han sido liderados por el Ministerio de Educación Nacional (MEN, 2012). Iniciativas como la creación del portal: *Colombia Aprende* en el año 2004, así como el proyecto del *Sistema Nacional de Innovación Educativa con Uso de TIC*, que desde el año 2012, mediante diferentes proyectos y estrategias, promueve el diseño e implementación de la Estrategia Nacional de Recursos Educativos Digitales Abiertos (REDA), para que instituciones educativas de educación superior, creen sus propios repositorios de recursos educativos a través de tecnologías como: DSpace (MEN, 2021). No obstante, tanto la literatura especializada como la observación del contexto nacional indican que la producción y gestión de REA en Colombia presenta un margen considerable de mejora. Esto abarca desde las políticas que regulan su creación y reutilización en las instituciones educativas, hasta la adopción de técnicas y buenas prácticas que aseguren la calidad y faciliten el uso extendido de estos

recursos (Toledo, Open access and OER in Latin America: A survey of the policy landscape in Chile, Colombia and Uruguay, 2017).

Por consiguiente, el presente trabajo busca aportar a la investigación sobre REA mediante la propuesta de una estrategia para completar y enriquecer el contenido descriptivo de sus metadatos. El objetivo, es abordar el problema de la descripción deficiente, generando recomendaciones automáticas, alimentadas por la información contenida en la propia colección de recursos analizada, que permitan complementar campos de metadatos faltantes o ambiguos.

Para enfrentar esta problemática, el objetivo principal de esta investigación es diseñar y evaluar una estrategia, basada en Inteligencia Artificial, para mejorar la calidad descriptiva de los metadatos de los REA. Si bien técnicas de machine learning, como el algoritmo Latent Dirichlet Allocation (LDA) y minería de texto han mostrado resultados relevantes en otros contextos geográficos (Molavi, Tavakoli, & Kismihók, 2020) ; (Tavakoli, Mirette, Gábor, & Sören, 2021); (Ludeña, Segarra-Faggioni, Romero-Pelaez, & Morocho-Yunga, 2024), esta investigación propone utilizar una combinación de Modelos Extensos de Lenguaje (LLM), técnicas de embeddings (representaciones vectoriales) para captura semántica, y Generación Aumentada por Recuperación (RAG). El diseño propuesto, buscará aprovechar la similitud semántica dentro de un conjunto de datasets de metadatos, previamente indexados, con el fin de recuperar información relevante y, a través del LLM, generar recomendaciones para completar campos de descripción deficientes o faltantes en los metadatos de los REA.

1.2 FORMULACIÓN DEL PROBLEMA

Con base en las circunstancias presentadas, se define formalmente el problema de investigación mediante la siguiente pregunta:

¿Cómo mejorar la información que describe los Recursos Educativos Abiertos a través de la implementación de una estrategia basada en inteligencia artificial, con el fin de proporcionar recomendaciones de contenido para los elementos de metadata vacíos o incompletos, aportando en la interoperabilidad y accesibilidad de estos recursos?

1.3 SISTEMATIZACIÓN DEL PROBLEMA

Se proponen las siguientes sub-preguntas relacionadas al problema de investigación:

- ¿Cuál es el estado de los recursos educativos abiertos en Colombia, cómo se encuentra su descripción y que repositorios existen actualmente?
- ¿Qué técnicas de inteligencia artificial y machine learning que, articuladas en conjunto, permitan identificar y proponer recomendaciones de contenido a campos de metadatos vacíos o incompletos, en la descripción de un REA?
- ¿Cómo verificar el aporte del mejoramiento en la descripción de los REA, mediante las aproximaciones de recomendación propuestas a los campos faltantes de determinado recurso?

2. OBJETIVOS

2.1 OBJETIVO GENERAL:

Mejorar la descripción y completitud de la información que describe los Recursos Educativos Abiertos, a través de la implementación de técnicas de inteligencia artificial y machine learning, que permitan realizar recomendaciones de contenido para los elementos de metadata vacíos o incompletos.

2.2 OBJETIVOS ESPECÍFICOS:

- Explorar y contextualizar la situación actual de la publicación y descripción de los Recursos Educativos Abiertos (REA) en Colombia, incluyendo un diagnóstico de los repositorios relevantes y la revisión de metadatos asociados.
- Evaluar técnicas de Inteligencia Artificial (IA), machine learning y minería de datos, cuyo alcance y articulación permitan identificar y proporcionar alternativas de contenido para los elementos de metadata incompletos o vacíos, en determinado recurso educativo abierto.
- Diseñar e implementar una estrategia basada en Inteligencia Artificial (IA) y técnicas de machine learning, para recomendar contenido faltante o incompleto, en la descripción de elementos de metadatos, del tipo de REA seleccionado.
- Verificar que la estrategia diseñada, genera recomendaciones de contenido, de acuerdo con los modelos de datos y los insumos de entrenamiento proporcionados.

3. JUSTIFICACIÓN

3.1 JUSTIFICACIÓN TEÓRICA

Como lo manifiesta (Romero-Ariza, Abril Gallego, Quesada Armenteros, & Rodríguez Ortega, 2023), la UNESCO (Organización de las Naciones Unidas para la Educación, la Ciencia y la Cultura), recomienda y promueve la investigación constante en el aseguramiento de la calidad de los REA, siendo uno de los aspectos cruciales, la mejora continua en la descripción de los elementos de metadatos. Esto tiene múltiples implicaciones; En primer lugar, una definición precisa de los REA favorece la interoperabilidad, facilitando el intercambio y uso de información, así como la adaptación y reutilización de los recursos por parte de otros; en segundo lugar, la calidad de los metadatos influye significativamente en la usabilidad de los REA. Por último, una descripción detallada de los recursos, mejora la accesibilidad, permitiendo a los usuarios encontrar y utilizar los recursos de manera más eficiente.

La presente investigación se centrará inicialmente en el contexto colombiano, con el propósito de analizar la situación actual de los repositorios existentes, así como la estructura de descripción de los Recursos Educativos Abiertos (REA) y los mecanismos de publicación. De ser necesario para complementar el análisis o si la información nacional resulta insuficiente para los objetivos propuestos, se procederá también a la revisión de repositorios externos, relevantes en otros países. Posteriormente, se busca contribuir al mejoramiento de la completitud de las descripciones de estos recursos, mediante el empleo de técnicas de inteligencia artificial, machine learning y minería de datos. Cabe destacar que investigaciones previas (Ludeña et al., 2024; Tavakoli et al., 2021) han demostrado resultados satisfactorios en diferentes contextos, lo cual subraya el potencial de estas técnicas. Sin embargo, se reconoce la necesidad de adaptar y optimizar estas herramientas para el contexto colombiano, considerando las particularidades y desafíos propios que se encuentren durante la fase de exploración del proyecto.

3.2 JUSTIFICACIÓN PRÁCTICA

La relevancia práctica de esta investigación se fundamenta, en primer lugar, en el reconocimiento de los Recursos Educativos Abiertos (REA) por parte de la UNESCO (2019) como herramientas prometedoras para avanzar hacia los **Objetivos de Desarrollo Sostenible** de la Agenda 2030, particularmente aquellos enfocados en la promoción de una educación de alta calidad, equitativa e inclusiva para toda la población. Sin embargo, el pleno aprovechamiento de los REA se ve frecuentemente obstaculizado por una problemática concreta: la incompletitud y variabilidad en la calidad de sus metadatos descriptivos.

En este contexto, la presente investigación busca generar un impacto práctico directo al abordar esta deficiencia. El propósito es desarrollar y proponer un mecanismo basado en técnicas de inteligencia artificial, que ofrezca recomendaciones específicas y contextualizadas para ayudar a los creadores y gestores de contenido a completar los campos ausentes o mejorar los existentes en los elementos de metadatos que describen los REA. Se ha observado que, frecuentemente, las personas responsables de la creación y curación de metadatos (autores, personal de editoriales o bibliotecas) pueden abstenerse de completar exhaustivamente las descripciones de los REA, debido a la falta de claridad sobre qué información diligenciar, la ambigüedad de ciertos campos, la incertidumbre sobre la aplicabilidad de descriptores específicos, o simplemente por limitaciones de tiempo y recursos. Por lo tanto, al ofrecer recomendaciones específicas, se busca eliminar estas barreras y promover una mayor eficacia en la búsqueda y utilización de los recursos educativos disponibles.

3.3. JUSTIFICACIÓN METODOLÓGICA

La presente investigación, se centra inicialmente en un diagnóstico del estado actual de la estructura y etiquetado de metadatos de los Recursos Educativos Abiertos (REA) en el contexto colombiano, así como de las herramientas existentes para su publicación. Esto es importante resaltarlo, porque el proyecto, no radica en la evaluación o modificación de la estructura y etiquetado existente de los elementos de metadatos de los Recursos Educativos Abiertos (REA), sino para comprender la realidad local y establecer el punto de

partida de la investigación. Posteriormente, se analizarán y adaptarán las técnicas basadas en inteligencia artificial (IA), machine learning y minería de datos, que articulados permiten cumplir con el objetivo de la investigación. La elección de estas tecnologías de IA se justifica por su demostrada capacidad para procesar información, identificar patrones y generar recomendaciones específicas y eficientes, permitiendo así desarrollar alternativas viables para enriquecer los elementos de metadatos de REA.

4. MARCO DE REFERENCIA Y ESTADO DEL ARTE

4.1. MARCO TEÓRICO:

En el contexto de la educación moderna, los REA han surgido como una solución innovadora y accesible para el aprendizaje y la enseñanza. El uso de metadatos en los REA es fundamental para su eficacia y accesibilidad. Los metadatos son datos que describen otros datos. En el caso de los REA, los metadatos pueden incluir información sobre el autor, el contenido, el nivel de grado, los estándares de aprendizaje, las revisiones y la licencia de uso, entre otros. Esta información permite a los usuarios buscar, identificar, evaluar y utilizar de manera efectiva los REA que satisfacen sus necesidades de aprendizaje o enseñanza. Este capítulo proporcionará las bases teóricas y las técnicas que se han explorado para el mejoramiento de la descripción.

4.1.1. *Análisis de metadatos de REA basado en métodos predictivos:*

La creciente cantidad de REA hace que el control de calidad manual sobre estos sea engorroso, por lo que como se resalta en (Tavakoli, Mirette, Gábor, & Sören, 2021), se debe impulsar la creación de métodos automáticos y predictivos que permitan evaluar la calidad de los metadatos. Este trabajo de investigación argumenta, que si bien, se ha explotado el uso de *Linked Open Data* para descubrir y analizar relación entre los metadatos de diferentes recursos, y lograr enriquecimiento entre estos, para mejorar la descripción, estos trabajos permanecen sobre un estado conceptual lo que limita su capacidad para evaluar y mejorar la calidad de los metadatos de los REA de manera escalable. En contraste, se sugiere que es oportuno y necesario analizar los metadatos de los REA basado un modelo de predicción inteligente que evalúe la calidad de los REA basándose en sus metadatos para facilitar el control de calidad. (Tavakoli, Mirette, Gábor, & Sören, 2021) propone modelo de predicción de calidad de metadatos, aplicándolo a un conjunto de datos de contenido de video educativo de YouTube

El modelo de puntuación de metadatos de REA inicia basado en la técnica de estadística “*proceso inverso de puntaje Z*” se centró en definir la importancia de cada campo de metadatos y una función de puntuación basada en dichos recursos que han pasado por

control de calidad. Se asigna una tasa de importancia a cada campo de metadatos según su tasa de disponibilidad entre los recursos controlados por calidad. Luego, se normalizan estas tasas de importancia y se crea una función de puntuación para cada campo, utilizando una distribución normal basada en la longitud de los valores de los campos, ya que tienen distribuciones similares a la normal. Los campos con valores más cercanos a la media de las distribuciones reciben una puntuación más alta. Además, se utilizan funciones booleanas para campos como nivel, duración, idioma y accesibilidad, asignando 1 cuando tienen un valor y 0 en caso contrario. Este modelo ayuda a evaluar la completitud y adherencia de los metadatos a los estándares definidos, lo que es crucial para la calidad general de los recursos. Por otra parte, se proponen dos modelos para completar el modelo de puntuación: *Modelo de Disponibilidad* y el *Modelo Normal* (Tavakoli, Mirette, Gábor, & Sören, 2021).

El *Modelo de Disponibilidad* calcula una puntuación basada en la presencia de campos de metadatos importantes y su tasa de importancia normalizada, lo que refleja la completitud de los metadatos. Por otro lado, el *Modelo Normal* evalúa qué tan cercanos están los metadatos a un estándar definido, utilizando una función de puntuación basada en la distribución normal de la longitud de los valores de los campos de metadatos. Ambos modelos contribuyen a la predicción automática de la calidad de los OER, facilitando así el control de calidad y mejorando la utilidad de los recursos educativos. Finalmente, los autores entrenaron un modelo de machine learning para predecir la calidad de los REA basándose en los metadatos recolectados y el modelo de puntuación desarrollado. Utilizando un conjunto de datos de SkillsCommons, clasificaron los REA en dos categorías: de alta calidad y de baja calidad, y entrenaron un modelo Random Forest que logró una precisión del 94.6%. Además, validaron su modelo en un conjunto de datos de videos educativos de YouTube, demostrando que el modelo puede generalizarse a diferentes tipos de recursos educativos y repositorios. Los resultados mostraron que los videos clasificados como de alta calidad tenían calificaciones de usuarios más altas, lo que sugiere que el modelo es efectivo para predecir la calidad de los REA basándose en sus metadatos.

4.1.2. Exploración de Tópicos en Recursos Educativos Abiertos

Otra importante contribución respecto al mejoramiento de la descripción de REA corresponde al modelo de extracción automática de temas (áreas de conocimiento que

cubre el recurso), propuesto por (Molavi, Tavakoli, & Kismihók, 2020). Esto se hace posible mediante la recopilación de recursos y la identificación de temas, utilizando técnicas de modelado como el LDA (Asignación Latente de Dirichlet). El proceso comienza con la selección del número de temas a través del cálculo de la *Coherencia CV*, eligiendo la cantidad que proporciona el valor más alto. Luego, se ejecuta LDA en el corpus de minería de texto, asignando manualmente nombres a los temas basados en la distribución de sus palabras. Se utilizó un conjunto de datos de Youtube, donde los tópicos fueron asignados manualmente a los videos por expertos en los temas de los REA que se usan como prueba. Los modelos de extracción de tópicos se aplicaron a las transcripciones de los videos y los resultados se compararon con las asignaciones manuales. La calidad de los modelos se midió utilizando score F-1, obteniendo un promedio del 79% en la extracción de tópicos cubiertos por los recursos educativos. Esto indica que los modelos son bastante precisos en identificar los tópicos relevantes en los materiales educativos.

Por otra parte, bajo la misma línea de investigación, se encuentra el trabajo realizado por (Ludeña, Segarra-Faggioni, Romero-Pelaez, & Morocho-Yunga, 2024), donde se señala el desafío de encontrar contenido relevante y útil debido a metadatos incompletos o inexactos de REA. Por ello, propone el uso del algoritmo LDA (Latent Dirichlet Allocation) como una técnica de aprendizaje automático y minería de texto para mejorar la descripción y clasificación de los OER, facilitando así la búsqueda y selección de recursos por parte de los usuarios. El algoritmo LDA, permite identificar la distribución del documento(recurso) sobre los temas y la distribución de un tema en función de las palabras observadas. De esta manera, se identificarán automáticamente temas de los REA, los mismos que pueden ser considerados como metadatos adicionales que enriquecerán la descripción y clasificación de los recursos educativos abiertos seleccionados. El análisis del estudio reveló que el valor más alto de coherencia de temas, 0.42, se logró con nueve temas en el modelo LDA, lo que sugiere una relación significativa entre las palabras dentro de los temas. Se utilizó la técnica *Tf-idf* para ponderar términos y la librería *gensim* para entrenar el modelo LDA. Además, se utilizó la librería *pyLDAvis* para una visualización interactiva de los temas y palabras clave, facilitando la interpretación de los temas modelados. Los resultados indican que los temas extraídos están bien relacionados y representan patrones claros, es decir que los temas extraídos están estrechamente relacionados con el área de conocimiento que perseguía la

investigación (área de TI), proporcionando una forma eficiente de identificar los temas principales sin revisar detalladamente cada recurso.

Estos antecedentes de investigación son relevantes para el presente trabajo porque:

- Es importante destacar el rendimiento sobresaliente de las técnicas machine learning y de aprendizaje automático y minería de texto. En particular, el algoritmo LDA ha demostrado ser especialmente eficaz, ya que puede identificar automáticamente los temas principales en un conjunto de documentos. Esta capacidad del algoritmo LDA es fundamental para descubrir patrones y tendencias en los datos.
- Los temas identificados por el algoritmo LDA pueden considerarse como metadatos adicionales que enriquecen la descripción y clasificación de los recursos. Esto puede mejorar la precisión y eficiencia de las búsquedas y selecciones de recursos relevantes.

4.1.3. Modelado de tópicos

El modelado de tópicos es una técnica avanzada que utiliza aprendizaje automático no supervisado, para la recuperación de información que automáticamente encuentra los temas generales en un conjunto de documentos de texto. Intenta encontrar temáticas implícitas en un conjunto de textos, permitiendo así organizar, comprender, buscar y resumir automáticamente gran cantidad de archivos electrónicos. Ayuda a descubrir patrones semánticos ocultos en un corpus de texto y a identificar automáticamente los temas que existen dentro de él. El modelado de tópicos intenta responder la pregunta: *¿Qué temáticas permiten describir una determinada colección de textos?* (Gogni & Bianco, 2020). A diferencia de la clasificación de texto, que es supervisada y requiere un conjunto de datos etiquetado, el modelado de tópicos es no supervisado y descubre temas subyacentes en una colección de documentos de texto.

Existen diversos algoritmos para implementar esta técnica, siendo los más referenciados:

4.1.3.1. LDA (Latent Dirichlet Allocation)

El modelado de tópicos es un algoritmo no supervisado que expone temas ocultos agrupando la estructura semántica latente del conjunto de documentos. (Yu & Xiang, 2023).

Como un tipo de modelo de tópicos, LDA fue propuesto por (Blei, Ng, & Jordan, 2003), que tiene como objetivo entregar los temas de cada documento en forma de distribución de probabilidad. Del mismo modo, cada tema/tópico se compone de una distribución de probabilidad sobre las palabras del corpus. En la *figura 1*, que es una ilustración de LDA, tiene como objetivo demostrar el proceso de generación de texto. El modelo LDA primero genera aleatoriamente la distribución de palabras de tema φ_k de K tópicos a partir de la distribución previa (distribución de Dirichlet) $Dir(\beta)$. Luego, genera aleatoriamente la distribución de documentos-tópico θ_m de M documentos a partir de otra distribución previa (distribución de Dirichlet) $Dir(\alpha)$, y obtiene la secuencia de temas de los documentos. Finalmente, combinando el número de palabras N_m de un documento generado a partir de la distribución de Poisson y la distribución de palabras de tema φ_k , se obtiene la secuencia de palabras de los documentos.




Figura 1: Representación Gráfica del Modelo LDA. Tomado de: (Yu & Xiang, 2023)

Como un problema de optimización complejo, el parámetro del modelo LDA solo puede ser estimado por una solución aproximada. Para la solución aproximada del LDA, a menudo se utilizan el muestreo de Gibbs y la inferencia variacional (Yu & Xiang, 2023).

4.1.4. Procesamiento de lenguaje natural y técnicas de Machine learning

El procesamiento de lenguaje natural (PLN) y las técnicas de Machine Learning son fundamentales para el desarrollo de sistemas inteligentes que pueden analizar grandes volúmenes de datos textuales. El PLN permite a las máquinas comprender, interpretar y generar lenguaje humano, lo cual es crucial para tareas como la traducción automática, el

análisis de sentimientos, la generación de resúmenes y la clasificación de textos. Por otro lado, el Machine Learning proporciona algoritmos que pueden aprender y mejorar a partir de la experiencia, identificando patrones y realizando predicciones basadas en datos.

El PNL se refiere a la rama de la inteligencia artificial (IA) encargada de comprender y comunicar el lenguaje humano. La IA colabora en este proceso, mediante el uso de algoritmos de aprendizaje automático (machine learning) que automatizan el análisis de textos no estructurados, permitiendo la extracción de información relevante y la categorización de elementos importantes como títulos, autores, fechas de publicación y palabras clave (Clay, et al., 2025). La integración con modelos de lenguaje extenso (LLM), como el modelo Generative Pre-trained Transformer (GPT), permite que estos sistemas procesen el lenguaje a un nivel más profundo, analizando factores como la longitud y complejidad de las frases, los constructos gramaticales y otros patrones sutiles y abstractos en el texto. De allí varias investigaciones, han aprovechado el potencial de machine learning y técnicas de inteligencia artificial para el procesamiento de volúmenes grandes de datos. En el proyecto desarrollado por (Clay, et al., 2025) manifiestan que los beneficios de aplicar NLP e IA en la extracción de metadatos, incluyen una mayor eficiencia en la recuperación de información, mejor organización de los datos académicos y una reducción significativa en el tiempo y esfuerzo necesarios para procesar grandes volúmenes de textos. En dicha investigación, las técnicas utilizadas incluyen el reconocimiento de entidades nombradas (NER), algoritmos de aprendizaje automático como máquinas de soporte vectorial y bosques aleatorios, sistemas basados en reglas, modelos de aprendizaje profundo como redes neuronales y transformadores, y enfoques híbridos que combinan la intervención humana con modelos de aprendizaje automático. La investigación aprovechó PNL e IA para procesar registros electrónicos de salud (EHR) en la investigación y práctica clínica con el objetivo de obtener y extraer datos clínicos relevantes en grandes volúmenes de datos, con fines de investigación y producción de respuestas prácticas a preguntas clínicas complejas.

Ahora bien, las técnicas de machine learning y procesamiento de lenguaje natural han sido ampliamente aceptadas en recientes investigaciones educativas. Por ejemplo, el trabajo hecho por (Raval & Bhaidasna, 2024), aborda el problema del crecimiento exponencial en la cantidad de artículos científicos publicados, lo que dificulta su indexación y recuperación eficiente. Debido a que la extracción manual de metadatos, como el título, autores, fecha

de publicación y resúmenes, es costosa y propensa a errores, se propone la automatización de este proceso mediante técnicas de procesamiento de lenguaje natural (NLP) y aprendizaje automático (ML). Entre las principales técnicas utilizadas se encuentra el Reconocimiento de Entidades Nombradas (NER), aplicado para identificar automáticamente componentes relevantes dentro del texto académico. Además, se emplean modelos de aprendizaje supervisado, como máquinas de vectores de soporte (SVM) y bosques aleatorios (Random Forests), para clasificar metadatos a partir de datos etiquetados. También se utilizan sistemas basados en reglas, especialmente en documentos con estructuras predecibles, y modelos de aprendizaje profundo, incluidos transformadores como BERT y GPT, que permiten capturar dependencias complejas en los textos. El estudio resalta el uso de transformadores enriquecidos con información sintáctica para mejorar la extracción de cantidades numéricas y atributos técnicos. Asimismo, se analizan enfoques híbridos que combinan la automatización con la intervención humana para mejorar la precisión, así como frameworks automatizados (como AutoIE y DAF) que integran diversas técnicas para ofrecer soluciones de extracción de metadatos de extremo a extremo. Finalmente, se exploran estrategias complementarias como la óptima parametrización para mejorar el rendimiento de los modelos, la extracción de aspectos específicos (objetivos, métodos, resultados) de los artículos y el uso de herramientas semi-automatizadas para apoyar revisiones sistemáticas. En conjunto, estas metodologías buscan mejorar la eficiencia, precisión y escalabilidad de los sistemas de extracción de metadatos en el ámbito académico.

4.1.5. *Embeddings y Representación Semántica (Representaciones Vectoriales)*

Los *embeddings* son representaciones vectoriales densas que capturan las relaciones semánticas entre elementos lingüísticos, como palabras o documentos, al proyectarlos en espacios de alta dimensión. Esta técnica se basa en la hipótesis distribucional, que sostiene que el significado de una palabra puede inferirse por los contextos en los que aparece (Mikolov, Chen, Corrado, & Dean, 2013). Modelos como Word2Vec, GloVe y BERT han demostrado eficacia en diversas tareas de Procesamiento de Lenguaje Natural (PLN), al permitir que palabras con significados similares estén representadas por vectores cercanos en el espacio semántico (Devlin, Chang, Lee, & Toutanova, 2019) (Pennington, Socher, & Manning, 2014). A diferencia de las representaciones tradicionales basadas en frecuencias

de palabras, los embeddings capturan el significado subyacente y las relaciones contextuales entre las palabras, lo que resulta fundamental para el Procesamiento de Lenguaje Natural (NLP) y otras aplicaciones de inteligencia artificial.

4.1.5.1. Modelos Relevantes de Embeddings:

4.1.5.1.1. Word2Vec

Word2Vec es un modelo de embeddings, desarrollado por Google en 2013, el cual utiliza redes neuronales para aprender representaciones vectoriales de palabras. Implementa dos arquitecturas: *Continuous Bag of Words (CBOW)*, que predice una palabra a partir de su contexto, y *Skip-gram*, que predice el contexto a partir de una palabra. que permite representar palabras en forma de vectores densos en un espacio multidimensional. Este modelo tiene un papel importante en el campo de la lingüística, especialmente para determinar la similitud semántica entre palabras. La similitud semántica se refiere a la búsqueda de semejanzas entre dos o más palabras, permitiendo identificar cuando dos palabras diferentes sintácticamente pueden tener el mismo significado o significados relacionados. El procesamiento del lenguaje natural (NLP), como campo de la Inteligencia Artificial, se ocupa de la interacción entre computadoras y el lenguaje natural humano. Para esto, las computadoras necesitan procesar el lenguaje humano para comprender las intenciones y proporcionar respuestas apropiadas (Jatnika, Bijaksana, & Suryani, 2019).

4.1.5.1.2. GloVe (Global Vector)

Desarrollado por Stanford en 2014, se basa en matrices de *co-ocurrencia* global para generar embeddings. A diferencia de Word2Vec, que es un modelo predictivo basado en el contexto local, GloVe captura estadísticas globales del corpus. Según (Giri, Banerjee, Bag, & Maiti, 2022), *GloVe word embedding*, considera el contexto global de la palabra en lugar de considerar solo el significado local. Para determinar el contexto, se prepara una matriz de co-ocurrencia que representa qué pares de palabras tienen mayor probabilidad de aparecer juntos que otros pares". Esta característica hace que GloVe sea particularmente efectivo para capturar relaciones semánticas a nivel de corpus completo.

4.1.5.1.3. BERT

BERT (*Bidirectional Encoder Representations from Transformers*) es un modelo de lenguaje preentrenado propuesto por Google en 2018, que ha revolucionado el campo del Procesamiento de Lenguaje Natural (PLN) debido a su capacidad para comprender el contexto de las palabras en ambas direcciones: izquierda y derecha dentro de una oración. A diferencia de técnicas tradicionales como **bag-of-words**, **TF-IDF** o **one-hot encoding**, que generan representaciones escasas y no consideran la semántica contextual, BERT emplea una arquitectura de tipo **Transformer** con codificación bidireccional, que permite entender relaciones semánticas complejas entre palabras y frases, mejorando así la calidad del modelado lingüístico (Devlin, Chang, Lee, & Toutanova, 2019).

4.1.5.1.4. **text-embedding-3-large: Representación Semántica Avanzada para Análisis de Texto**

El modelo **text-embedding-3-large**, desarrollado por OpenAI, constituye uno de los avances más recientes en la generación de representaciones semánticas mediante vectores de alta dimensión. Se trata de un modelo especializado para la tarea de *embedding*, es decir, la transformación de entradas textuales en vectores numéricos que preservan las relaciones semánticas implícitas del contenido (OpenAI, 2024). A nivel técnico, **text-embedding-3-large** produce vectores de hasta **3072 dimensiones**, lo que permite capturar una representación más rica y contextualizada del texto. Este modelo está diseñado para ser altamente versátil y se emplea comúnmente en aplicaciones como:

- Búsqueda semántica.
- Agrupamiento temático de documentos.
- Clasificación automática de texto.
- Generación de recomendaciones basadas en similitud textual.
- Análisis de sentimientos y detección de entidades.

En el contexto de esta investigación, el uso de **text-embedding-3-large** es altamente pertinente para abordar la problemática de metadatos incompletos o de baja calidad en Recursos Educativos Abiertos (REA). Al transformar campos textuales como títulos, resúmenes o nombres de autores, en vectores semánticos, es posible identificar patrones y similitudes entre recursos, lo cual permite:

1. **Completar metadatos faltantes** mediante comparación semántica con otros recursos similares.

2. **Mejorar la recuperación de información**, al permitir búsquedas más precisas basadas en el contenido, y no solamente en coincidencias literales de palabras clave.
3. **Facilitar la clasificación automática** de los REA según categorías temáticas o niveles educativos.
4. **Proveer recomendaciones de recursos relacionados**, incluso cuando no existan etiquetas explícitas compartidas.

4.1.5.2. Aplicación de Embeddings en Metadatos Educativos

La calidad de los metadatos en los REA es crucial para su descubrimiento, recuperación y reutilización. Sin embargo, muchos REA presentan descripciones incompletas o de baja calidad, lo que limita su potencial. La incorporación de embeddings en la descripción de estos recursos puede mejorar significativamente su accesibilidad y utilidad (Ostendorff, et al., 2019). En este contexto, se han propuesto estrategias que combinan representaciones generadas por modelos de lenguaje con grafos de conocimiento para enriquecer los metadatos de objetos educativos. En (Ostendorff, et al., 2019) se utilizó BERT en conjunto con datos estructurados, para clasificar automáticamente recursos educativos con resultados superiores a los enfoques tradicionales. Asimismo, en el trabajo de (Sajja, Kohli, Krishnaswamy, & Joshi, 2024), se entrenaron modelos de embeddings personalizados sobre corpus académicos y se probaron en sistemas de recuperación de información, evidenciando mejoras en precisión semántica en entornos de educación superior.

4.1.5.3. Beneficios de los embeddings

La aplicación de embeddings en metadatos de REA ofrece beneficios que la literatura ha demostrado como:

- *Mejora en la Recuperación de Información:* Permiten identificar recursos relevantes mediante similitud semántica, incluso si los términos exactos no coinciden (Sajja, Kohli, Krishnaswamy, & Joshi, 2024).
- *Agrupación y Clasificación Automática:* Los recursos con temáticas similares pueden agruparse automáticamente gracias a su proximidad en el espacio vectorial (Ostendorff, et al., 2019)

- **Detección de Temas Emergentes:** Las representaciones semánticas permiten realizar análisis de agrupamiento para identificar tendencias educativas latentes (Liu, et al., 2021).
- **Personalización del Aprendizaje:** Al vincular recursos semánticamente cercanos, los sistemas pueden generar recomendaciones adaptadas al perfil del estudiante (Chen, Liu, & Fang, 2020).

4.1.6. Modelos Extensos de Lenguaje (LLM)

Large Language Models (LLMs) se definen como modelos de inteligencia artificial entrenados con grandes volúmenes de datos textuales, capaces de comprender y generar texto en lenguaje natural con alta precisión. Los LLMs facilitan tareas como la clasificación, extracción y generación de información textual, reduciendo significativamente la necesidad de construir modelos especializados desde cero (Arslan, Munawar, & Cruz, 2024).

4.1.7. Generación aumentada por recuperación (RAG)

Aunque los LLMs muestran un excelente desempeño en tareas generales, presentan limitaciones al abordar consultas altamente específicas o de dominio particular, debido a su dependencia exclusiva del conocimiento contenido en sus datos de entrenamiento (Arslan, Munawar, & Cruz, 2024). Para superar estas limitaciones, se introduce el enfoque de Retrieval Augmented Generation (RAG), que complementa a los LLMs integrando mecanismos de recuperación de datos externos durante el proceso de generación de texto. En este esquema, el modelo no se limita a su conocimiento interno, sino que consulta bases de datos o documentos actualizados, ampliando su contexto y mejorando la exactitud de sus respuestas. La combinación de LLMs y RAG, resulta de gran relevancia: los LLMs proporcionan capacidades avanzadas de lenguaje y razonamiento, mientras que RAG permite incorporar información reciente o específica al proceso de respuesta. Esta integración, fortalece tanto la relevancia contextual como la credibilidad de las respuestas generadas, como se demostró en el desarrollo del sistema creado por (Arslan, Munawar, & Cruz, 2024), diseñado para extraer automáticamente eventos políticos a partir de noticias de forma más eficiente y precisa.

5. MARCO CONCEPTUAL

Teniendo en cuenta los fundamentos teóricos previamente descritos, es necesario rectificar y considerar los siguientes elementos conceptuales que suscitan el propósito y contexto del trabajo investigación:

5.1. **Recursos Educativos Abiertos (REA):**

Los Recursos Educativos Abiertos, como objeto fundamental de estudio para la investigación y teniendo en cuenta su importancia en apoyar la academia en entornos tecnológicos, se definen como:

“Materiales de enseñanza, aprendizaje e investigación que residen en el dominio público o han sido liberados bajo una licencia abierta que permite: (i) uso gratuito, (ii) conservación, reutilización, redistribución y remezcla por parte de otros (UNESCO, 2019). Estos recursos de enseñanza pueden incluir cursos, módulos, libros de texto, videos en tiempo real, pruebas, software y cualquier otra herramienta, material o técnica utilizada para respaldar el acceso al conocimiento (Wesolek, Lashley, & Langley, 2018). Entre mayor acceso e intercambio de conocimiento, mejores oportunidades de desarrollo económico y social equitativo, se propicia al diálogo intercultural, y se tiene el potencial de impulsar la innovación (Swan & Unesco., 2012).

En el contexto colombiano, se ha puesto esfuerzo en impulsar los recursos educativos abiertos, en el marco de lo que se denominó el Sistema Nacional de Innovación Educativa con Uso de TIC, que desde el año 2012 promovió la creación y uso de los recursos educativos abiertos con énfasis en lo digital (REDA). Así pues, un Recurso Educativo Digital Abierto, en Colombia, se define como: *todo tipo de material que tiene una intencionalidad y finalidad enmarcada en una acción Educativa, cuya información es Digital, y se dispone en una infraestructura de red pública, como internet, bajo un licenciamiento de Acceso Abierto que permite y promueve su uso, adaptación, modificación y/o personalización* (MEN, 2012).

5.1.1.1. Repositorio Institucional de Recursos Educativos Digitales Abiertos

De acuerdo con (MEN, 2012) , un *Repositorio Institucional de Recursos Educativos Digitales Abiertos*, se entiende como un sistema de información digital, gestionado por instituciones de educación superior, que tiene como objetivo principal recopilar, almacenar, organizar, preservar y difundir los recursos educativos digitales generados por la comunidad académica. Estos repositorios están diseñados para garantizar el acceso público y abierto a los contenidos, facilitando su uso, reuso y apropiación en procesos educativos y administrativos. La definición se fundamenta en principios de accesibilidad, acumulación, perpetuidad e interoperabilidad, según lo establecido por **SPARC**. Esta interoperabilidad se logra mediante la implementación de protocolos estandarizados como OAI-PMH, SOAP y HTTP, que permiten integrar los repositorios en redes federadas, facilitando el intercambio de datos y metadatos a nivel institucional, nacional e internacional.

El sistema incluye múltiples servicios como almacenamiento, recuperación, preservación, visualización y control de acceso, apoyados en plataformas de software libre **como DSpace, Fedora, Greenstone o Drupal**, y utilizando estándares de metadatos como **Dublin Core (DCMI), LOM y LRM** para asegurar la calidad y consistencia de la descripción de los recursos. Este enfoque técnico facilita la recolección automática de datos (harvest) desde diversas fuentes, promoviendo la homogeneidad y normalización de la información. Así, los repositorios no solo fortalecen la gestión del conocimiento institucional, sino que también posibilitan la construcción de ecosistemas de aprendizaje más inclusivos, colaborativos y abiertos (MEN, 2012).

5.1.1.1.1. Plataformas para la Gestión de Repositorios Institucionales de Acceso Abierto

- **DSpace** es una de las plataformas de código abierto más ampliamente adoptadas para la creación de repositorios institucionales de acceso abierto. Fue desarrollada originalmente por el MIT y HP Labs, y permite almacenar, preservar y compartir contenidos digitales, especialmente académicos y científicos, como artículos, tesis, datasets y objetos de aprendizaje. Su arquitectura basada en la web y su compatibilidad con el protocolo OAI-PMH lo hacen altamente interoperable, y es compatible con metadatos como Dublin Core, MODS y otros estándares reconocidos internacionalmente (Smith, et al., 2003).

- **Fedora (Flexible Extensible Digital Object Repository Architecture)** es una plataforma robusta, orientada a objetos, diseñada para gestionar contenidos digitales complejos con necesidades de preservación a largo plazo. Desarrollada inicialmente por la Universidad de Cornell y la Universidad de Virginia, Fedora permite un alto nivel de personalización mediante el uso de RDF, RESTful APIs y soporte para relaciones semánticas, lo que lo hace ideal para bibliotecas y archivos digitales con necesidades complejas de metadatos y relaciones entre objetos (Lagoze, Payette, Shin, & Wilper, 2005).
- **EPrints** fue una de las primeras plataformas en promover el movimiento de acceso abierto, desarrollada por la Universidad de Southampton. Está diseñada específicamente para la publicación y gestión de documentos científicos en línea, con una interfaz intuitiva y una estructura modular que facilita su implementación en instituciones educativas. También cumple con el protocolo OAI-PMH y soporta metadatos como Dublin Core, ofreciendo flexibilidad en su configuración y clasificación de contenido (Tansley, Bass, Stuve, & Choudhury, 2001)
- **Greenstone** es una herramienta desarrollada por la Universidad de Waikato (Nueva Zelanda), pensada para la creación de bibliotecas digitales, especialmente en contextos educativos y multilingües. Se enfoca en facilitar el acceso a información en comunidades con recursos limitados, y permite crear colecciones digitales ricas en metadatos, con soporte para múltiples formatos y configuraciones de búsqueda. Es muy utilizada por organizaciones no gubernamentales y agencias de cooperación internacional (Witten & Bainbridge, 2003).
- **Invenio** es una plataforma modular desarrollada por el CERN, ampliamente usada para gestionar repositorios científicos. Su diseño permite manejar grandes volúmenes de datos científicos y académicos, soporta estándares como MARC21, Dublin Core y BibTeX, y ofrece una potente capacidad de búsqueda y recuperación de información. Invenio se destaca por su escalabilidad y por integrar funcionalidades propias de bibliotecas digitales avanzadas (CERN, 2020).
- **Islandora** es una solución de código abierto que integra Fedora como motor de almacenamiento y Drupal como sistema de gestión de contenidos. Esta combinación permite crear repositorios visualmente personalizables y con gran capacidad de extensión. Está orientada a instituciones que requieren una interfaz

más amigable y flexible, especialmente aquellas que trabajan con recursos multimedia o desean integrar otras funcionalidades propias de portales web (Beard, McDonald, & Brisson, 2011).

- **Samvera (anteriormente Hydra)** es un framework colaborativo construido sobre Fedora y otras tecnologías, orientado a instituciones que desean construir soluciones personalizadas para la gestión de contenido digital. Utiliza Ruby on Rails, lo que le brinda una arquitectura moderna y modular, aunque requiere un equipo técnico especializado para su configuración. Es ideal para bibliotecas universitarias que buscan una solución altamente adaptable (Hull, Reddy, & Tripp, 2014).

5.1.1.2. Clasificación de los Recursos Educativos Digitales Abiertos

Como se presenta en (MEN, 2012), dada la heterogeneidad, multiplicidad y complejidad de los REA, se pueden distinguir dos clasificaciones:

- a) **Desde lo educativo:** El propósito de la clasificación de los recursos desde lo educativo se basa en características comunes entre ellos, las cuales pueden definirse desde los objetivos de aprendizaje, intencionalidades de uso, complejidad, estructura, entre otros.
 - i. *Cursos Virtuales:* Es una experiencia educativa que se lleva a cabo a través de un entorno tecnológico, donde los estudiantes interactúan con información, conocimientos y actividades que permitan desarrollar capacidades, competencias y nuevos conocimientos. Este entorno está equipado con las condiciones necesarias para desarrollar procesos de enseñanza y aprendizaje, con el fin de alcanzar los objetivos formativos establecidos.
 - ii. *Aplicaciones para Educación:* Programas y/o piezas de software diseñados y producidos para apoyar el desarrollo y cumplimiento de un objetivo, proceso, actividad o situación que implique un fin educativo. Se caracterizan por brindar a los usuarios una gran funcionalidad debido a su versatilidad, nivel de interacción, portabilidad y usabilidad.
 - iii. *Objeto de Aprendizaje:* en el contexto colombiano, el termino Objeto de Aprendizaje se define como una entidad digital con un propósito educativo,

constituida por al menos contenidos y actividades que se dispone para ser usada y/o reutilizada.

b) **Desde los formatos de información digital:** Para su representación, la información digital utiliza distintos formatos, los cuales pueden ser manipulados de manera individual o en conjunto durante los procesos de producción de REA. Los formatos más comunes:

- i. *Textual:* Información representada en un sistema de escritura a través de caracteres, que puede apoyarse en otro tipo de representaciones visuales: esquemas, diagramas, gráficos, tablas, entre otros, cuyo uso se desarrolla a través de la lectura
- ii. *Sonoro:* Elementos o secuencias de información acústica, cuya oscilación y vibración puede ser percibida mayormente por el sentido del oído.
- iii. *Visuales:* Elementos y/o secuencias de información representada en mayor porcentaje e importancia a través de imágenes, fotografías, gráficas, ilustraciones, capturas ópticas, entre otras; y cuyas oscilaciones y vibraciones pueden ser captados mayormente por el sentido de la vista.
- iv. *Audiovisuales:* Elementos de información secuenciados sincrónicamente donde convergen, articulan y se integra lo sonoro, lo textual y lo visual; y cuyas oscilaciones y vibraciones pueden ser captadas simultáneamente por los sentidos de la vista y el oído.
- v. *Multimediales:* Elementos de información secuenciados principalmente de forma asincrónica, que articula, secuencia e integra múltiples formatos (textuales, sonoros, visuales y audiovisuales); su potencialidad reside sobre las posibilidades de interacción que ofrece.

Con esta clasificación es importante identificar, que existen diferentes tipos de recursos y de acuerdo a lo que se logre identificar durante el barrido en los repositorios existentes en el país, se seleccionarán los tipos de recursos con estructura de descripción unificada y bien definida.

5.1.2. Metadatos:

Los metadatos, que se definen comúnmente como datos sobre datos, son la combinación de palabras clave que se utilizan para encontrar la información de un recurso específico

(Garshol, 2004). Cuanto más completo sea la información del recurso descrito, con metadatos relevantes, precisos, completos y centrados en el usuario, más eficiente y eficaz será su búsqueda y accesibilidad (Alemu, 2016). Al unificar diferentes metadatos se logra la descripción completa de un recurso (Simao De Deus & Francine Barbosa, 2020).

Es conveniente resaltar la importancia de los metadatos, tal como se menciona en (Bizer, Vidal, & Skaf-Molli, Linked Open Data, 2018): *Los metadatos son el puente entre los datos y el conocimiento. Sin metadatos, los datos carecen de significado y valor. Con metadatos, los datos se convierten en información útil y relevante para los usuarios.*

A propósito de la iniciativa de la *Digital Library Federation (DLF)* que sucede al proyecto Making of America II (MOA2), donde se creó la iniciativa METS (**Metadata Encoding and Transmission Standard**), se intenta proporcionar formatos de codificación para metadatos descriptivos, administrativos y estructurales de documentos basados en texto e imagen. METS es un formato basado en XML para codificar metadatos de objetos digitales de una biblioteca, ya sea para almacenarlos en un repositorio o para intercambiarlos entre repositorios. METS se compone de siete secciones principales: cabecera, descriptor, administrador, estructura de archivos, estructura lógica, estructura de comportamiento y sección de comportamiento. Cada sección contiene información específica sobre el objeto digital y sus componentes (Bizer, Vidal, & Skaf-Molli, Linked Open Data, 2018).

En este sentido, y también como se describe en (Caplan, 2003), existe una tipología de metadatos basado en sus funciones y la intención de los datos:

- Los **metadatos descriptivos** sirven para facilitar el descubrimiento, la identificación, la selección y otros fines relacionados con el contenido de los recursos. Incluyen información como el título, el autor, el tema, las palabras clave, el idioma, etc. Su propósito es facilitar la identificación, el descubrimiento y la recuperación de los recursos. Algunos ejemplos de formatos de metadatos descriptivos son Dublin Core, MODS, MARC y EAD.
- Los **metadatos administrativos** son información que facilita la gestión de los recursos, como la creación, el acceso, el control y la preservación. Incluyen información como el propietario, los derechos, el formato, la fecha de creación, la historia de acceso, la ubicación, etc. Su propósito es garantizar la autenticidad, la

integridad, la calidad y la disponibilidad de los recursos. Algunos ejemplos de formatos de metadatos administrativos son PREMIS, METS, MIX y EXIF.

- Los **metadatos estructurales** son los que mantienen unidos a los objetos digitales compuestos, como los libros, las imágenes o los conjuntos de datos, documentando las relaciones entre sus componentes. Incluyen información como el orden, la jerarquía, la navegación, la paginación, etc. Su propósito es facilitar la visualización, la manipulación y la reutilización de los recursos. Algunos ejemplos de formatos de metadatos estructurales son TEI, MPEG-7, SMIL y RDF.

5.1.2.1. Vocabularios en los metadatos:

Como se menciona en (Caplan, 2003), los vocabularios para los metadatos son conjuntos de términos controlados que se usan para organizar, categorizar o etiquetar sistemáticamente la información. Los vocabularios para los metadatos son importantes porque:

- Permiten una comprensión común y precisa de los conceptos y la terminología relacionados con los datos.
- Reducen el riesgo de que los datos sean mal utilizados debido a una comprensión inconsistente de los conceptos.
- Maximizan la capacidad de búsqueda, facilitando el acceso al conocimiento documentado.
- Impulsan la interoperabilidad y la reutilización de los datos, algo fundamental en el mundo del open data.

Se pueden distinguir tres tipos principales de vocabularios para los metadatos (Caplan, 2003):

- **Vocabularios controlados:** son conjuntos de términos predefinidos que se usan para asignar palabras o frases a los elementos de metadatos. Los vocabularios controlados pueden ser listas de términos, archivos de autoridad o tesauros, que muestran las relaciones entre los términos, como equivalencia, jerarquía o asociación. Los vocabularios controlados se usan para mejorar la recuperación de

información, al evitar la ambigüedad y la variación de los términos en el lenguaje natural.

De acuerdo con (Giordano, Kavasidis, Spampinato, & Bamidis, 2011), y en el contexto educativo, los vocabularios controlados son herramientas esenciales para mejorar la descripción, el acceso y la explotación de los recursos educativos en la web. Algunos casos de desarrollo de vocabularios controlados:

- El proyecto mEducator desarrolló un vocabulario controlado para el tipo de recurso educativo en el ámbito médico, teniendo en cuenta las necesidades específicas de la comunidad de educadores médicos y el proceso de reutilización de contenidos. El vocabulario controlado se ha implementado en formato SKOS para facilitar su interoperabilidad con otros estándares y fuentes de datos enlazados. El proyecto mEducator también desarrolló un esquema RDF para describir los recursos educativos médicos y los vinculó con otros conjuntos de datos abiertos, como DBpedia o **MeSH** (un tesoro médico que contiene términos normalizados para describir conceptos biomédicos, clínicos y de salud pública.).
- **Vocabularios de clasificación:** son formas de organizar el conocimiento en una estructura jerárquica o de árbol. Cada nodo del árbol tiene un código, llamado notación, que identifica una clase o subclase de recursos relacionados. Los vocabularios de clasificación pueden ser generales o específicos, y pueden ser enumerativos o facetados. Los vocabularios de clasificación se usan para agrupar recursos similares y facilitar la navegación y el descubrimiento.
- **Vocabularios de identificación:** son cadenas que se usan para identificar de forma única una entidad bibliográfica lógica. Los vocabularios de identificación pueden ser asignados por una autoridad o derivados de los datos bibliográficos. Algunos ejemplos de vocabularios de identificación son el ISBN, el ISSN, el DOI, el URN y el URI. Los vocabularios de identificación se usan para referenciar, enlazar y localizar recursos en el entorno digital.

En la presente investigación, no se tiene como alcance modificar o proponer sobre la estructura de descripción existente. Sin embargo, se pretende analizar y caracterizar los metadatos que describen los recursos, cuya estructura se encuentre bien definida y

se pueda identificar los patrones, prácticas y estándares que se emplearon, para su construcción, porque esto sentará las bases para poder realizar el preprocesamiento de los datos.

5.1.2.2. Estándares de los metadatos:

Hoy en día existen varios estándares de metadatos los cuales buscan facilitar el intercambio y accesibilidad de los REAs. Estos surgen por la necesidad de compartir objetos que provienen de distintas fuentes y organizar su almacenamiento (Andrea, 2013), (Caplan, 2003):

Estándar	Descripción
AACR2/MARC	Es un estándar de catalogación bibliográfica que usa un conjunto de reglas (AACR2) y un formato de codificación (MARC) para describir libros, videos, software y otros materiales que se encuentran en las bibliotecas. Permite integrar estos materiales en el catálogo de la biblioteca y facilitar su búsqueda y recuperación.
GEM	Es un estándar de metadatos para describir recursos educativos que se encuentran en Internet, como planes de lección, unidades curriculares y actividades. Usa un conjunto de elementos basados en el estándar Dublin Core, extendidos con elementos específicos para la educación, como el nivel, la audiencia y el método pedagógico. Permite crear un repositorio central de recursos educativos que se pueden acceder desde un portal llamado Gateway to Educational Materials.
IEEE LOM	Es un estándar de metadatos para describir objetos de aprendizaje, que son unidades pequeñas de contenido instruccional que se pueden reutilizar en diferentes contextos. Usa un conjunto de elementos agrupados en nueve categorías, que cubren aspectos generales, técnicos, educativos, de derechos, de relación, de anotación y de clasificación de los objetos de aprendizaje. Permite crear sistemas de gestión y distribución de objetos de aprendizaje que sean interoperables y adaptables a las necesidades de los usuarios.
Dublin Core	Es un modelo de metadatos que permite describir e identificar recursos de cualquier tipo, especialmente en la web. El estándar consta de 15 elementos semánticos que expresan las características básicas de un recurso, como el título, el creador, el tema, la fecha, el tipo, etc. Estos elementos son opcionales, repetibles y pueden aparecer en cualquier orden. El estándar también permite el uso de calificadores que refinan o especifican el significado de los elementos o el esquema de codificación utilizado. El estándar Dublin Core se define por la ISO en su norma ISO 15836 y por la NISO en su norma Z39.85. El estándar se puede representar en diferentes sintaxis, como HTML, XML o RDF,

	y se puede combinar con otros esquemas de metadatos mediante perfiles de aplicación.
CanCore Learning Resource Metadata Initiative	Es una iniciativa de metadatos de recursos educativos que facilita la indexación de objetos de aprendizaje (OA) en línea, basándose en el estándar IEEE Learning Object Metadata (LOM). CanCore ha contribuido al liderazgo de Canadá en la implementación de metadatos de e-learning, y ha facilitado el intercambio y la reutilización de recursos educativos en línea entre diferentes sistemas y comunidades. También ha impulsado la innovación y la colaboración en el campo de los objetos de aprendizaje. (Wiley, 2015).
LRMI(Learning Resource Metadata Initiative)	Es una especificación para marcar y describir recursos educativos usando clases, propiedades y esquemas de conceptos basados en Schema.org y otros estándares. El objetivo de LRMI es facilitar la búsqueda, el intercambio y el uso de recursos educativos de calidad en la Web (DublinCore, n.d.).

El mejoramiento de los metadatos en repositorios digitales permite garantizar el reúso y accesibilidad de REA. Sin embargo, como menciona (Romero-Pelaez, Segarra-Faggioni, & Alarcon, 2018), la calidad de los metadatos para recursos digitales continúa siendo un concepto difícil de medir como un todo. Dado esto, en la literatura se han establecido las siguientes métricas de calidad:

- 5.1.2.3. Completitud:** Consiste en comprobar si el metadato contiene la información necesaria para soportar la representación completa del recurso que se está describiendo. Según la norma ISO/IEC 25012, la completitud, se refiere al grado en que los datos asociados a una entidad tienen valores para todos los atributos esperados y las instancias de entidad relacionadas en un contexto de uso específico (ISO 25000, 2024).
- 5.1.2.4. Consistencia:** se refiere al grado de correspondencia de los metadatos con las normas para definirlos. Del mismo modo, la norma ISO/IEC 25012 define la consistencia, como una característica de los metadatos que están libres de contradicciones y son coherentes con otros datos en un contexto específico (ISO 25000, 2024).
- 5.1.2.5. Coherencia:** Verifica que la información contenida en los campos de metadatos se correlacione con otros. Esto significa, que todos los campos deben describir el mismo objeto de manera similar. Esta métrica calcula la distancia semántica entre diferentes campos de texto libre (título y descripción).

5.1.2.6. Precisión: Según la norma ISO/IEC 25012, la precisión se refiere al grado en que los atributos de los datos representan los valores correctos de un concepto en un uso específico (ISO 25000, 2024) .

5.1.2.7. Procedencia: Se refiere al proceso de rastrear la procedencia de los datos que [permiten conocer la indexación y transformación por la que han pasado los metadatos. Además, la procedencia se describe como la confianza que un determinado usuario tiene, en la fuente de la instancia de metadatos y es una cuestión importante para tener en cuenta a la hora de determinar cómo indexar los metadatos (Romero-Pelaez, Segarra-Faggioni, & Alarcon, 2018).

5.1.3. Datos Abiertos

Open Knowledge Foundation, define los datos abiertos, como aquellos datos que pueden ser utilizados, reutilizados y redistribuidos libremente por cualquier persona, y que se encuentran sujetos, cuando más, al requerimiento de atribución y de compartirse de la misma manera en que aparecen (OKFN, 2004). Esta definición, implica que se cumplen los siguientes principios de apertura de datos:

- Disponibilidad y acceso: la información debe estar disponible como un todo. Además, la información debe estar disponible en una forma conveniente y modificable.
- Reutilización y redistribución: los datos deben ser provistos bajo términos que permitan reutilizarlos y redistribuirlos, e incluso integrarlos con otros conjuntos de datos.
- Participación universal: los datos pueden ser utilizados, reutilizados y redistribuidos sin restricción alguna, siempre y cuando la licencia de libre acceso y uso esté disponible.

A propósito, del contexto del proyecto, respecto a recursos educativos, en 2003, fue firmada la Declaración de Berlín, sobre Acceso Abierto al Conocimiento en Ciencias y Humanidades (Society, 2024). Este documento, ofrece la declaración realizada sobre el acceso abierto a las publicaciones académicas, donde se afirma que la difusión del conocimiento es sólo a medias si la información no está amplia y fácilmente disponible para la sociedad. La declaración reconoce dos condiciones para las contribuciones de acceso abierto. (i) La

primera condición consiste, en que la información suministrada esté disponible para que todos los usuarios accedan a la obra original y se pueda distribuir los trabajos derivados con la debida atribución al autor y/o titular de los derechos. (ii) La segunda condición trata, que el trabajo completo, más los recursos complementarios y los permisos, deben ser depositados en un repositorio, que observe las normas adecuadas para la redistribución, la interoperabilidad y el archivo fuente (Rudasill & Dorta-Duque, 2013).

Es importante destacar la importancia de la interoperabilidad de los datos, porque esta denota la habilidad de diversas fuentes y repositorios colaborar en conjunto enlazar datos y llegar a la constitución de sistemas complejos y generación de nuevo conocimiento (OKFN, 2004).

5.1.3.1. Gestión de datos de investigación

Dataverse es una plataforma de código abierto desarrollada por el Institute for Quantitative Social Science (IQSS) de la Universidad de Harvard. Esta herramienta, está diseñada específicamente, para el almacenamiento, publicación, preservación y compartición de datos de investigación, en consonancia con los principios **FAIR (Findable, Accessible, Interoperable, Reusable)**. Cada conjunto de datos depositado en Dataverse puede ser citado mediante un identificador persistente como DOI o Handle, lo cual favorece la trazabilidad académica y el reconocimiento a los autores. Esta herramienta permite la creación de múltiples espacios de trabajo llamados **dataverses**, dentro de los cuales se pueden organizar colecciones de datasets. Además, proporciona control de versiones, distintos niveles de acceso, compatibilidad con estándares de metadatos como Dublin Core, DataCite y DDI, e interoperabilidad mediante APIs REST y el protocolo OAI-PMH. En el contexto institucional, Dataverse ha sido adoptado por universidades y centros de investigación en todo el mundo como solución para la gestión de datos abiertos, incluyendo algunas iniciativas en Colombia. Su facilidad de integración con sistemas como ORCID o RDA fortalece el ecosistema académico y científico al facilitar el intercambio de datos y su reutilización en nuevos proyectos de investigación (Crosas, 2011).

5.1.3.2. Datos Abiertos en Colombia

En Colombia, los Datos Abiertos son una iniciativa que comenzó en 2011 con la adhesión del país a la Alianza para el Gobierno Abierto. Los Datos Abiertos son información pública dispuesta en formatos que permiten su uso y reutilización bajo licencia abierta y sin restricciones legales para su aprovechamiento (Gov.co, 2024).

Los datos abiertos son información pública dispuesta en formatos que permiten su uso y reutilización bajo licencia abierta y sin restricciones legales para su aprovechamiento. En Colombia, la Ley 1712 de 2014 sobre Transparencia y Acceso a la Información Pública Nacional, define los datos abiertos en el numeral sexto como "todos aquellos datos primarios o sin procesar, que se encuentran en formatos estándar e interoperables que facilitan su acceso y reutilización, los cuales están bajo la custodia de las entidades públicas o privadas que cumplen con funciones públicas y que son puestos a disposición de cualquier ciudadano, de forma libre y sin restricciones, con el fin de que terceros puedan reutilizarlos y crear servicios derivados de los mismos. La iniciativa de datos abiertos administra la Plataforma Nacional de Datos Abiertos, datos.gov.co. Esta plataforma permite que más de **1500** entidades nacionales y territoriales publiquen más de **8000** conjuntos de datos. Estos conjuntos de datos están disponibles en formatos abiertos, estructurados y gratuitos.

Las plataformas e iniciativas de datos abiertos, que se encuentran en el territorio nacional, se pueden resumir a continuación:

Plataforma	URL
Portal de datos abiertos Bogotá	https://datosabiertos.bogota.gov.co/
Portal datos abiertos Medellín	https://medata.gov.co/
Portal de datos abiertos Cali	https://datos.cali.gov.co
Portal de datos abiertos Nariño	https://datos.narino.gov.co
Portal datos abiertos nacional	https://www.datos.gov.co/
Centro de análisis de datos de Bucaramanga	https://www.bucaramanga.gov.co/centro_analitica/
Agencia de analítica de datos de Bogotá, Ágata	https://agatadata.com/
Red de ciudades como vamos	https://redcomovamos.org
Terridata	https://terridata.dnp.gov.co/

Plataforma de Empoderamiento AprendelA: plataforma diseñada en línea diseñada para apoyar la enseñanza	https://aprendeia.org/
--	---

El portal de Datos Abiertos de Colombia adoptó el estándar **DCAT** para la definición de los metadatos de los conjuntos de datos, cuyo uso básico es hacer posible la interoperabilidad entre conjuntos de datos albergados en diferentes portales (MinTic, Guía de Estándares de Calidad e interoperabilidad de Datos Abiertos, 2022).

5.1.4. Repositorios de Objetos de Aprendizaje:

Los Repositorios de Objetos de Aprendizaje (ROAs) son bibliotecas digitales especializadas, que alojan múltiples tipos de recursos educativos y/o sus metadatos, los cuales son utilizados en diversos ambientes de e-learning. Son un catálogo electrónico/digital que facilita las búsquedas en entornos web de material educativo que apoyen el proceso de enseñanza y aprendizaje (Downes, 2001). Los ROAs surgen para establecer una solución que permitiera a los usuarios encontrar más fácilmente recursos digitales orientados a la educación, sin necesidad de gastar mucho tiempo tratando de encontrar material adecuado entre las largas listas de resultados de motores de búsquedas generales, ya que un ROA resuelve los problemas de gestión de contenidos y puede establecer normas para la calidad de sus recursos, además deben ofrecer facilidades para la creación y mantenimiento de los metadatos y recursos almacenados. Son varios los servicios y aplicaciones adicionales que se ofrecen desde los ROA, tales como herramientas para la gestión del etiquetado que soporten estándares de metadatos específicos orientados al campo educativo, mecanismos de integración e interoperabilidad con otros repositorios o federaciones, y servicios de administración de usuarios y control de acceso.

Existen repositorios locales que son aquellas bibliotecas digitales propias de una organización que contienen los OAs propios y los repositorios remotos que son aquellos a los que se accede a través de una red. Existen actualmente ROAs muy reconocidos y utilizados a nivel mundial tales como: Merlot, Gateway y The Maricopa Learning Exchange

de EEUU, Careo , Cloe , eduSourceCanada y Pool de Canadá, CeLeBraTe de Europa y Jorum9 2.1.5 Federación de ROAs de Reino Unido, Europeana entre otros.

5.1.5. Recursos educativos virtuales en Colombia:

La consolidación de la Estrategia Nacional de Recursos Educativos Digitales Abiertos es el resultado de un trabajo conjunto entre Instituciones de Educación Superior públicas y privadas, expertos internacionales y el Ministerio de Educación Nacional de Colombia. En esta estrategia convergen multiplicidad de necesidades y expectativas del sector educativo y del país, en asuntos como la posibilidad de contar con acceso a una amplia oferta de recursos educativos digitales abiertos, fortalecer las capacidades del uso educativo de las TIC de los miembros de las comunidades educativas, a través de la promoción sobre la producción, gestión y uso de este tipo de recursos; contribuir a la cualificación de los docentes, aportar en el desarrollo y renovación de las prácticas educativas, entre otras (Nacional, 2012).

De esta manera, para el año 2006, en los inicios de los objetos virtuales de aprendizaje, en el territorio nacional, se definen como: *Todo material estructurado de una forma significativa, asociado a un propósito educativo (en este caso para la Educación Superior) y que corresponda a un recurso de carácter digital que pueda ser distribuido y consultado a través de la Internet. El objeto de aprendizaje debe contar además con una ficha de registro o metadato consistente en un listado de atributos que además de describir el uso posible del objeto, permiten la catalogación y el intercambio de este.*

Para facilitar el cumplimiento de las condiciones anteriormente descritas por parte de los Recursos Educativos Digitales Abiertos, se cuenta con un conjunto de características de orden técnico y funcional, que parten de referentes conceptuales con reconocimiento internacional como: el Institute of Electrical and Electronics Engineers (IEEE), World Wide Web Consortium (W3C) y la International Electrotechnical (IEC). Entre estas cabe destacar las descritas en el documento (Nacional, 2012):

- Accesible: cualidad que busca garantizar que el Recurso Educativo Digital Abierto pueda ser consultado y/o utilizado por el mayor número de personas, incluyendo a

quienes se encuentran en condición de discapacidad²⁵, y de igual forma, a aquellos que no cuentan con condiciones técnicas y tecnológicas adecuadas

- **Adaptable:** propiedad de un Recurso Educativo Digital Abierto que le permite ser modificado, ajustado o personalizado²⁶ de acuerdo con los intereses, necesidades o expectativas del usuario.
- **Durable:** cualidad de un Recurso que garantiza su vigencia y validez en el tiempo, la cual se logra con el uso estándares y tecnologías comunes y reconocidas para ese fin.
- **Flexible:** característica que posee un Recurso para responder e integrarse con facilidad a diferentes escenarios digitales de usuario final, de modo que este último pueda configurar su uso según sus preferencias.
- **Lo Abierto:** es la condición que responde a los permisos legales que el autor o el titular del Derecho de Autor otorga sobre su obra (Recurso), a través de un sistema de licenciamiento reconocido, para su acceso, uso, modificación o adaptación de forma gratuita, la cual debe estar disponible en un lugar público que informe los permisos concedidos.

Al revisar el contexto nacional, se encuentran trabajos realizados como el mencionado en (Sociedad Geográfica de Colombia, 2007), donde el Ministerio de Educación Nacional apoyó a la Sociedad Geográfica de Colombia en la elaboración de un proyecto pedagógico tendiente a difundir conocimiento geográfico sobre el país. Emprendieron, en conjunto, la elaboración de dos Objetos Virtuales de Aprendizaje (OVAs) sobre las Fronteras de Colombia. El propósito de este material pedagógico, que facilita aprendizaje y consulta en línea, es aportar a las personas interesadas un conjunto integrado de conocimientos sobre la conformación territorial de Colombia en relación con los países vecinos, presentado con visión geográfica e histórica y enfoque geopolítico. La razón de ser de esta herramienta de aprendizaje es inducir en el usuario un proceso sistemático de autoaprendizaje. Opera como recurso didáctico en el aula y, por su contenido descriptivo, también opera como documento de consulta para quien lo requiera. Por su concepto, diseño y conformación resulta un curso abierto y en línea, realizable por cualquier persona. Sin embargo, su énfasis de uso está centrado en los profesores de cualquier nivel educativo ya que pueden emplearlo dentro y fuera del aula, en su totalidad o por fragmentos, dependiendo de sus requerimientos de enseñanza.

El material resulta altamente didáctico por la coherencia en las secuencias de aprendizaje, la clara estructura temática, la profundidad gradual del contenido, el lenguaje llano de la redacción, la riqueza cartográfica, la amabilidad del diseño y el fácil manejo interactivo y de navegación. Contiene actividades que miden el conocimiento teórico adquirido y permiten su aplicación práctica en ejercicios de análisis crítico.

Adicionalmente, en (Tabares, Duque, Rodríguez, Moreno, & Ovalle, 2015) se presenta FROAC (Federación de Repositorios de Objetos de Aprendizaje Colombia), una iniciativa colombiana para integrar repositorios de objetos de aprendizaje, que ha surgido como una plataforma que además de permitir acceso a recursos que se encuentran en repositorios distribuidos, ofrece servicios y aplicaciones que benefician a los usuarios aprovechando resultados de investigaciones de los grupos vinculados. Se proponen dos funcionalidades principales que son la gestión de los repositorios asociados y un mecanismo de búsqueda y recuperación de los OA. El objetivo principal de FROAC es el acceso por parte de los usuarios a múltiples recursos educativos que se encuentran almacenados en repositorios heterogéneos y distribuidos, además ha permitido el desarrollo de aplicaciones y servicios que permiten el mejoramiento en los procesos de gestión relacionados con los OA.

6. HIPÓTESIS

La implementación de una estrategia basada en Inteligencia Artificial, que combina Modelos Extensos de Lenguaje (LLM), embeddings semánticos y Generación Aumentada por Recuperación (RAG), mejorará significativamente la calidad descriptiva (completitud, precisión, relevancia) de los metadatos de Recursos Educativos Abiertos (REA) al generar automáticamente contenido relevante para campos deficientes o ausentes, utilizando la información semántica presente en la colección de metadatos existente.

7. ANTECEDENTES DEL ESTADO DE DESCRIPCIÓN DE REAS

7.1. Antecedentes y Análisis de la situación de REA en Colombia

7.1.1. Contexto actual de los repositorios digitales en Colombia

En el contexto colombiano, la implementación y gestión de repositorios de Recursos Educativos Abiertos (REA), respecto a lo que se ha recopilado en la investigación, presenta una serie de desafíos que limitan su eficacia o alcance. Uno de los principales problemas identificados es la falta de estandarización en la estructura de metadatos utilizada por los diferentes repositorios. Esta situación ha generado una heterogeneidad en la descripción y catalogación de los recursos, dificultando la interoperabilidad y el intercambio de información entre plataformas. A pesar de los esfuerzos institucionales por promover el uso de estándares internacionales como Dublin Core (DC) y Learning Object Metadata (LOM) (sólo por mencionar algunos), muchos repositorios en Colombia han adaptado estos esquemas de manera parcial o los han modificado según necesidades específicas, sin considerar la importancia de mantener una coherencia que facilite la integración y reutilización de los recursos a nivel nacional e internacional. Esta adaptación individualizada ha resultado en estructuras de metadatos dispares, lo que complica la búsqueda, recuperación y reutilización de los REA por parte de estudiantes, docentes e investigadores (MEN, 2012).

Además, la ausencia de políticas claras y unificadas sobre la gestión de metadatos en el país ha contribuido a la fragmentación de los repositorios. Aunque existen iniciativas como el Marco de Interoperabilidad para Gobierno Digital, promovido por el Ministerio de Tecnologías de la Información y las Comunicaciones (MinTIC), su aplicación en el ámbito educativo ha sido limitada (MinTic, 2019). Esta falta de alineación entre las políticas gubernamentales y las prácticas institucionales en la gestión de REA, evidencia la necesidad de establecer directrices más concretas y adaptadas al sector educativo.

Según el reporte de Ministerio de Educación Nacional (MEN, 2021), a diferencia de países como México, Argentina, Chile o Perú, Colombia representa un caso particular en materia de recursos educativos, porque no cuenta con una política pública nacional que organice,

consolide, oriente y proyecte este tipo de apuestas hacia el fortalecimiento del currículo escolar y la articulación con la formación docente.

7.1.2. Antecedentes de los Recursos Educativos Abiertos en Colombia

De acuerdo con (MEN, 2021), se identifican tres grandes momentos en la historia reciente de la disponibilidad de recursos educativos en Colombia:

7.1.2.1. Primer momento (1991-2001):

Enmarcado en el nuevo ordenamiento constitucional y la Ley 115 de 1994. Se destacan iniciativas como el Programa PACES (Programa de Ampliación de la Cobertura y mejoramiento de la Calidad de la Educación Secundaria y Media) y el Baúl Jaibaná.

7.1.2.2. Segundo periodo (2001-2011):

Bajo la Ley 715 de 2001, que define las competencias territoriales en el esquema de financiación de la educación estatal. Se creó una agenda educativa nacional en torno a los Recursos Educativos Digitales Abiertos (REDA) y se creó el portal Colombia Aprende en 2004. Sin embargo, según se menciona en (MEN, 2021), fue un periodo pausa, en materia de recursos educativos por la disminución drástica de la inversión en ese rubro.

7.1.2.3. Tercer periodo (2012-actualidad):

Se configura a partir del marco legislativo que permite la expansión de las competencias territoriales para la adquisición de recursos educativos, a través de la Ley de Regalías (Ley 1530 de 2012) y del decreto 1075 de 2015. Se realizaron importantes adquisiciones de libro/textos escolares mediante proyectos de bilingüismo y el programa **Todos a Aprender**. En 2012, fue aprobada la política de contenidos educativos para el entorno digital, conocida como **Estrategia REDA** (Recursos Educativos Digitales Abiertos). Esta estrategia prometedora en su momento, al centrarse en la educación superior mediante el establecimiento de una hoja de ruta para la creación de un sistema nacional de REA. Sin embargo, con cambios administrativos en el Ministerio de Educación, la estrategia REDA perdió fuerza y actualmente no existe ni una página web que comunique su estado actual (Botero & Soto, 2025).

En el año 2014 se implementaron los *Centros de Innovación Educativa Regional (CIER)*, una iniciativa que estableció cinco sedes en distintas regiones del país (Caribe, Centro, Sur, Oriente y Occidente) con el objetivo de fortalecer la formación docente en el uso pedagógico de las tecnologías de la información y la comunicación (TIC). Estos centros también promovieron el desarrollo de competencias para la creación de contenidos digitales de alta calidad, enfocados principalmente en áreas como Lenguaje, Ciencias Naturales y Matemáticas. No obstante, al revisar la información pública disponible relacionada con esta estrategia, la cual hace parte del Sistema Nacional de Innovación, no se identifica una orientación explícita hacia la creación ni la promoción de Recursos Educativos Abiertos (REA), lo que evidencia una oportunidad no explorada dentro de dicho programa (Botero & Soto, 2025).

Entre 2014 y 2016 se entregó la colección semilla en todos los establecimientos educativos del país, y el Plan Nacional de Lectura y Escritura (PNLE) ha mantenido procesos de dotación de colecciones bibliográficas. En 2021, se lanzó la **Política Pública de Recursos Educativos "Más y Mejores Aprendizajes"**, que tiene como fin aportar al mejoramiento de la calidad de la educación de carácter nacional, regional y local. Esta política busca organizar y orientar los procesos de selección, adquisición, creación, distribución, uso y evaluación de los recursos educativos en los ámbitos nacional, regional y local (MEN, 2021).

7.1.2.4. Otras iniciativas:

7.1.2.4.1. LA Referencia – Nodo KUJANE:

LA Referencia (*Red Federada de Repositorios de Acceso Abierto a la Ciencia*) es una red latinoamericana de repositorios de acceso abierto, que integra servicios de información científica provenientes de instituciones de educación superior y centros de investigación de diversos países de la región (LAR, 2019). Específicamente para Colombia, para finales del año 2019, se creó el Nodo KUJANE (Figura 2), proyecto liderado por (Minciencias, Repositorio Nacional KUJANE, 2019), el cual se diseñó para facilitar la búsqueda, acceso y análisis de recursos provenientes de diversos repositorios institucionales a nivel nacional. Utiliza el sistema VuFind como plataforma de descubrimiento, lo que permite a los usuarios explorar contenidos académicos mediante una experiencia unificada.



Figura 2 – KUJANE Nodo Colombia, Tomado de: (Minciencias, Repositorio Nacional KUJANE, 2019)

A la fecha de consulta, este repositorio, presenta fallas y no permite hacer ninguna búsqueda, a lo que se puede afirmar, que el proyecto no continuó bajo este nombre.

7.1.2.4.2. LA Referencia – Nuevo Nodo Colombia:

La **Red Colombiana de Información Científica (RedCol)** (Figura 3), liderada por el (Minciencias, 2022) ha sido designada como el nuevo nodo nacional de Colombia en LA Referencia. RedCol consolida y visibiliza la información científica del país, actuando como el nodo Colombia para participar en proyectos de intercambio de información, productos, datos científicos y proyectos de Ciencia Abierta de carácter internacional.




Figura 3 - Red Colombiana de Información Científica – Tomado de: (Minciencias, 2022)

Dentro de los tipos de recurso que alberga el repositorio REDCol se encuentran, en su mayoría, artículos científicos, trabajos de grado, tesis, informes técnicos y publicaciones institucionales. En algunos casos, también se incluyen conjuntos de datos de investigación. Para la gestión de metadatos, se utiliza el estándar Dublin Core, con extensiones adaptadas a los lineamientos de LA Referencia, lo que facilita la interoperabilidad con redes regionales. Las plataformas tecnológicas más empleadas por los repositorios que integran REDCol son DSpace y VuFind.

REDCol constituye una infraestructura sólida para la ciencia abierta en Colombia, especialmente en lo que respecta a la producción científica formal, dado que existen políticas más claras de publicación, preservación y visibilidad de este tipo de contenidos. No obstante, existe aún un vacío importante en cuanto a la integración de los Recursos Educativos Abiertos (REA) dentro de este ecosistema. A pesar de que la plataforma se articula técnicamente mediante herramientas interoperables como DSpace y protocolos como OAI-PMH, no se dispone de una API unificada, pública y documentada que permita la consulta directa de metadatos desde el sitio web oficial. En este sentido, aunque se ha avanzado en la apertura y estandarización de la información científica, los Recursos Educativos Abiertos aún no cuentan con un marco normativo, técnico ni operativo que garantice su adecuada inclusión y visibilidad dentro de este tipo de repositorios nacionales,

lo que representa un desafío importante para iniciativas como la que se plantea en esta investigación.



Muestra de ausencia de metadatos como el *autor* en el Nodo Nacional.

7.1.3. Políticas y Marco Normativo en cuando a lo educativo:

La Política Pública de Recursos Educativos en Colombia, propuesta por (MEN, 2021), reconoce el papel que juegan los recursos educativos en el fortalecimiento de los procesos pedagógicos. No obstante, la política presenta limitaciones relevantes cuando se analiza desde la perspectiva de los Recursos Educativos Abiertos (REA) y su publicación en entornos digitales. En este sentido, las dificultades que se identifican, de acuerdo con este tipo de políticas son:

- **Ausencia de lineamientos sobre publicación de REA:** No se establecen lineamientos específicos sobre cómo deben publicarse los REA. No se mencionan plataformas o repositorios recomendados, ni se sugieren procedimientos claros para garantizar su disponibilidad en formatos abiertos, estandarizados y reutilizables. Además, no hay directrices para el uso de licencias abiertas como Creative Commons, fundamentales para garantizar la legalidad del uso y adaptación de los REA.
- **Vacíos en estándares técnicos, de infraestructura e interoperabilidad:** La política no incluye referencias a estándares técnicos ampliamente utilizados para describir y estructurar recursos educativos, tales como *Dublin Core*, *LOM*, *SCORM* o *IMS*.

Tampoco se menciona la adopción de protocolos de interoperabilidad como OAI-PMH. Esta omisión limita la posibilidad de que los REA puedan ser fácilmente descubiertos, compartidos e integrados con otros sistemas nacionales e internacionales. Adicional, la política no propone una infraestructura tecnológica clara, para el almacenamiento, publicación y gestión de REA. No se plantea ni se incentiva a la creación de un portal nacional unificado, ni se sugieren mecanismos para versionar, ni para promover la preservación digital o acceso abierto a través de interfaces públicas como las (APIs).

7.1.4. Mapeo y Análisis de Repositorios de Recursos Educativos en Colombia

Como parte de esta investigación, se llevó a cabo un proceso de identificación, caracterización y análisis de repositorios y plataformas que contienen recursos educativos disponibles públicamente en Colombia. Ver (Tabla 1). Este ejercicio permitió evidenciar una alta diversidad en términos de arquitecturas tecnológicas, modelos de datos, tipos de contenido, mecanismos de interoperabilidad. La siguiente tabla presenta un resumen de los repositorios analizados, agrupando aspectos como la institución responsable, el tipo de recursos que albergan, los estándares de metadatos utilizados, la interoperabilidad y los hallazgos más relevantes:

Tabla 1: Listado de Repositorios enfocados en REA. Autoría propia

Repositorio /Plataforma	Institución	URL	Descripción	Tipo de Recursos	Estándar de metadatos/Plataforma	Interoperabilidad	Hallazgos Generales
Colombia aprende	Ministerio de Educación Nacional	https://www.colombiAAPrende.edu.co/	Colombia Aprende es una red de servicios, herramientas y contenidos para apoyar los procesos de enseñanza y aprendizaje.	Contenidos digitales educativos, guías, documentos, videos, recursos interactivos.	Plataforma propia, tipo LMS.	No Identificado	Similar a un LMS(Learning Management System).Funciona más como un ecosistema de portales que como un repositorio académico. Carece de estructuración orientada a REA interoperables.

Repositorio de Recursos Educativos - CECAR	CECAR Corporación Universitaria del Caribe	https://reda.cecar.edu.co/recursos	Plataforma que ofrece acceso a objetos virtuales de aprendizaje clasificados por programas académicos, áreas de conocimiento y tipos de recurso.	OVA's, OVI's, infografías, instructivos, podcast, teleclases, videos	No identificado	No Identificado	Aunque tiene vocación REA, la ausencia de licencias claras y estándares técnicos limita su interoperabilidad. Varios recursos tienen links no funcionales.
Funes	Universidad de los Andes	https://funes.uniandes.edu.co/	Repositorio digital de documentos y recursos en Educación Matemática.	Contiene principalmente documentos académicos y recursos educativos en el área de Educación Matemática.	No identificado	No Identificado	Buena organización y estructura. Carece de estándar de descripción.
Repositorio de Objetos Virtuales de Aprendizaje	Fundación Universitaria Agraria de Colombia	https://ova.uniagraria.edu.co/	Repositorio web que presenta OVA's clasificados en cuatro áreas: Medicina Veterinaria, Humanidades, Idiomas, Administración y Finanzas.	OVA's	No identificado	No Identificado	Las descripciones de metadatos no coinciden con el OVA. No hay estandarización de metadatos.

Aprender Digital	Ministerio de Educación Nacional	https://contenidos.colombi.aaprende.edu.co/	Plataforma de Colombia Aprende que pone a disposición recursos para apoyar procesos de aprendizaje	OVA's, Videos, juegos, infografías, simuladores, guías pedagógicas.	Plataforma cerrada tipo LMS	No Identificado	Aunque hay muchos recursos útiles, están incrustados sin estructura visible como REA. No hay claridad sobre licencias, metadatos ni mecanismos de búsqueda avanzados.
Recursos Educativos Digitales (Red Aprende)	Ministerio de Educación Nacional	https://redaprende.colombi.aaprende.edu.co/inicio	Recursos educativos digitales	OVA's (Recursos digitales interactivos, infografías, videos, guías docentes)	No Identificado	No Identificado	Tiene links a videos de YouTube. Existen categorías sin recursos
Aulas sin Fronteras	Ministerio de Educación Nacional	https://asf.git.ei.edu.co/inicio	Contenido pedagógico para las áreas de matemáticas, lenguaje, ciencias y sociales para los grados 7, 8 y 9. Son pdfs que se ofrecen para el maestro o el estudiante.	OVA's, Texto	No identificado	No Identificado	Cubre educación básica primaria grados 7,8,9

Eco Web	Ministerio de Educación Nacional	https://eco.colombiaaprende.edu.co/?playlist=d610631&video=d3092d9	Un espacio con más de 3000 recursos educativos en inglés: reúne libros de texto, audio, videos, readers, evaluaciones.	OVA's, Videos, libros de texto, lectores (readers), ejercicios interactivos, evaluaciones	No identificado	No Identificado	Amplia cantidad de recursos, pero sin claridad sobre licencias ni estructura de REA. No tiene funciones para exportar o describir recursos de forma estandarizada.
EduTEKA	Universidad Icesi	https://eduteka.icesi.edu.co	Plataforma educativa que promueve el uso pedagógico de las TIC, ofreciendo recursos para docentes, artículos, guías, proyectos, software educativo.	Artículos pedagógicos, herramientas didácticas, guías, rúbricas, software, blogs	No identificado	No Identificado	Valioso desde el punto de vista pedagógico, pero no cumple con requisitos técnicos para interoperabilidad como REA estructurados.
Repositorio Institucional	Secretaría de Educación de Bogotá	https://repositorio.sede.educacionbogota.edu.co/home	Contiene más de 3 mil publicaciones digitales producidas por la Secretaría de Educación del Distrito con acceso abierto.	OVA's, Documentos académicos, recursos pedagógicos, manuales, guías, proyectos institucionales	Plataforma: DSpace. Usa Dublin Core como estándar de metadatos.	No identificado	Enfocado en gestión documental y difusión pedagógica

Repositorio Institucional UNAL	Universidad Nacional de Colombia	https://repositorio.unal.edu.co	Plataforma que preserva y difunde la producción académica de la comunidad universitaria, incluyendo tesis, artículos, libros y revistas científicas.	Tesis, artículos científicos, libros, revistas, trabajos de grado	Plataforma: DSpace. Usa Dublin Core como estándar.	Compatible con OAI-PMH. Endpoint: https://repositorio.unal.edu.co/oai/request	Centrado en producción académica formal. No hay una categoría explícita de REA ni licencias educativas abiertas.
Repositorio Universidad de los Andes	Universidad de los Andes	https://repositorio.uniandes.edu.co/home	Plataforma para la preservación y consulta de la producción intelectual de la comunidad Uniandes, incluyendo trabajos de grado, artículos, libros y tesis.	Tesis, artículos académicos, libros, conferencias	Plataforma: DSpace. Usa Dublin Core.	Básica (OAI-PMH). No indica API	Repositorio robusto orientado a producción científica. No presenta categoría ni estructura específica para REA, aunque podría contener recursos reutilizables.
Repositorio Institucional Universidad Distrital Francisco José de Caldas RIUD	Universidad Distrital Francisco José de Caldas	https://repositorio.udistrital.edu.co/home	Plataforma de acceso abierto a la producción académica, científica y cultural de la comunidad universitaria. Preserva y divulga tesis y documentos.	Tesis, artículos, libros, informes técnicos	Plataforma: DSpace – Usa Dublin Core	Compatible con OAI-PMH. El endpoint es https://repositorio.udistrital.edu.co/oai/request	Repositorio bien organizado para producción científica formal. No contiene colecciones específicas de REA, ni licencias educativas claramente indicadas.

edX - Planestic	Universidad Distrital Francisco José de Caldas	https://edx.planestic.udistal.edu.co/	Plataforma educativa basada en Open edX, donde se ofrecen cursos en línea de libre acceso y recursos de formación digital para docentes y estudiantes.	Cursos en línea (MOOC), videos, guías, contenidos interactivos	Plataforma: Open edX. No se identifica uso explícito de estándares de metadatos	No se evidencian endpoints públicos de interoperabilidad (ej. OAI-PMH, API documentada). Posiblemente solo interfaz web para usuarios autenticados.	Funciona como una plataforma LMS abierta con enfoque en formación continua. Aunque contiene recursos educativos valiosos, no están estructurados ni publicados como REA interoperables.
Repositorio Institucional UNAD de REAs	Universidad Nacional Abierta y a Distancia (UNAD)	https://repositorio.unad.edu.co/handle/10596/1	Repositorio institucional que preserva, organiza y difunde la producción académica y científica de la comunidad UNAD. Contiene 120 recursos	Tesis, artículos académicos, informes de investigación, trabajos de grado	Plataforma: DSpace – Usa Dublin Core como estándar principal de metadatos	Compatible con OAI-PMH (el endpoint disponibles: https://repositorio.unad.edu.co/oai/request)	Plataforma sólida, centrada en producción científica formal. No incluye explícitamente Recursos Educativos Abiertos (REA).
Repositorio Institucional Universidad del Tolima	Universidad del Tolima	https://repositorio.ut.edu.co/home	Plataforma de acceso abierto que recopila, preserva y difunde la producción intelectual de la	Tesis de grado, artículos científicos, revistas institucionales, libros, ponencias, entre otros.	Plataforma: DSpace – Usa Dublin Core como estándar principal de metadatos.	Compatible con OAI-PMH: https://repositorio.ut.edu.co/oai/request	Enfocado en la producción académica formal. No hay evidencias de colecciones orientadas explícitamente a

			comunidad académica de la Universidad del Tolima.				REA. Se observan buenos metadatos en general.
Recursos Educativos – Pascual Bravo	Institución Universitaria Pascual Bravo	https://www.pascualbravovirtual.edu.co/recursos	Portal que ofrece acceso a libros interactivos, objetos de aprendizaje y materiales informativos diseñados para procesos formativos virtuales.	Libros digitales, objetos de aprendizaje, materiales multimedia	Plataforma institucional propia.	No Identificado	Ofrece contenido educativo digital , pero carece de licencias abiertas explícitas, estructuración de metadatos y mecanismos de interoperabilidad

El mapeo evidencia que, aunque en Colombia existen múltiples plataformas institucionales que ofrecen acceso a contenidos educativos digitales, la mayoría de los repositorios universitarios están orientados exclusivamente, a la publicación de tesis y producción académica formal, sin una distinción explícita o enfoque particular hacia los Recursos Educativos Abiertos. En efecto, muchos de estos repositorios, usan plataformas como **DSpace** y cumplen con estándares de descripción de metadatos como **Dublin Core**, y algunos pueden abrirse a la interoperabilidad por medio del protocolo **OAI-PMH**, sus contenidos están limitados a resultados de investigación y no a materiales diseñados explícitamente para la enseñanza y el aprendizaje abierto.

Por este motivo, la selección incluida en este listado no pretende ser exhaustiva de todos los repositorios institucionales de planteles educativos del país, sino que se enfoca en aquellos sistemas que especializan su oferta en contenidos educativos reutilizables, tales como Objetos Virtuales de Aprendizaje (OVA), guías pedagógicas, materiales interactivos o conjuntos de datos educativos. Esta decisión, corresponde al interés de este proyecto, por explorar el potencial de mejorar la descripción de recursos educativos que puedan ser reutilizados por otros docentes, estudiantes o investigadores, y que estén alineados con los principios de apertura, accesibilidad y adaptabilidad que caracterizan a los REA. Asimismo, el análisis revela grandes vacíos en la estandarización de metadatos, la interoperabilidad, y la presencia de APIs públicas, lo cual limita el descubrimiento, la agregación automática y la reutilización masiva de estos contenidos. Estos hallazgos reafirman la necesidad de desarrollar estrategias tecnológicas, como las que se proponen en esta investigación, que integren inteligencia artificial para mejorar la calidad descriptiva de los recursos y potenciar su visibilidad en los ecosistemas educativos digitales.

7.1.5. Colombia respecto a otras geografías

7.1.5.1. OER World Map

Para comprender el posicionamiento de Colombia frente a otros países en el ámbito de los Recursos Educativos Abiertos (REA), se consultó la plataforma **OER World Map** (Figura 4), una herramienta global que recopila, visualiza y organiza información sobre iniciativas, organizaciones, servicios y eventos relacionados con la educación abierta a nivel mundial. El portal OER World Map fue desarrollado como un proyecto colaborativo para mapear el

ecosistema de los REA, brindando un espacio donde individuos e instituciones pueden registrar y visibilizar sus contribuciones. (OER World Map, 2025).



Figura 4 - OER World Map - Tomado de: (OER World Map, 2025)

Específicamente, Colombia cuenta con **20** registros en la plataforma, muchos de los cuales corresponden meramente a perfiles de autores individuales más que a iniciativas institucionales. Una evaluación a cada uno de estos registros, revela problemas de infraestructura digital, como URLs de acceso no funcionales en varios repositorios. Se observa además un patrón recurrente: la mayoría de las iniciativas colombianas consisten en repositorios institucionales universitarios que implementan la plataforma DSpace como solución tecnológica, para crear y administrar sus repositorios digitales sin estar necesariamente especializados en REA. Esta situación contrasta notablemente con el panorama europeo, donde existe una proliferación de repositorios, diseñados específicamente para la gestión, preservación y difusión de recursos educativos abiertos con infraestructuras tecnológicas dedicadas y marcos de desarrollo especializados.

7.1.5.2. Repositorio Re3data (Registro mundial de repositorio de datos científicos)

En el marco de esta investigación, se consultó el portal **re3data.org** (Figura 5), el cual es un repositorio digital orientados a la preservación y difusión de datos científicos. Esta herramienta, permite identificar de forma precisa las infraestructuras digitales utilizadas por universidades, centros de investigación, y otras organizaciones para compartir información académica y científica en acceso abierto (re3data.org, n.d.). Pese a que no está enfocado

en temas relacionados con REA, se consultó para poder cuantificar la producción científica del país, frente a otras latitudes y analizar que estándares y plataformas se utilizan.




Figura 5 - Portal re3data.org - Tomado de: (re3data.org, n.d.)

7.1.5.2.1. Repositorios destacados

En esta sección, cabe destacar los siguientes repositorios enfocados en publicación de datos científicos, en el país (Tabla 2)

Tabla 2: Repositorios destacados de publicación de datos científicos

Repositorio / Plataforma	Institución	URL	Tipo de Recursos	Estándar de metadatos / Plataforma	Interoperabilidad / Hallazgos
SiB Colombia (Sistema de Información sobre Biodiversidad)	Instituto Humboldt + aliados nacionales	https://siacolombiana.net	Datos de biodiversidad	Darwin Core / GBIF IPT	API REST + OAI-PMH / Excelente interoperabilidad con GBIF

Repositorio de Datos Académicos - Universidad del Rosario	Universidad del Rosario	https://dataverse.urosario.edu.co	Conjuntos de datos de investigación	Dataverse / Dublin Core + DDI	OAI-PMH
Papyrus – Universidad de los Andes	Universidad de los Andes	https://papyrus.uniandes.edu.co	Datos abiertos, series estadísticas	Plataforma personalizada / JSON, CSV, XLS	No identificado
Repositorio de Datos de Investigación – UDistrital (Dataverse)	Universidad Distrital Francisco José de Caldas	https://datosinvestigacion.undistrital.edu.co/dataverse/root	Datos de investigación académica	Dataverse / Dublin Core, DDI	OAI-PMH
CENDAR – Artesanías de Colombia	Artesanías de Colombia	https://cendar.artesaniasdecolombia.com.co	Documentos técnicos, monografías, fotografías	Plataforma propia / No estandarizado	No identificado

La consulta realizada al catálogo de re3data.org permite identificar un total de **15** repositorios colombianos formalmente registrados en esta plataforma internacional. Se evidencia que la mayoría de los repositorios colombianos registrados en re3data.org están centrados en la preservación de la producción académica formal, principalmente tesis, artículos científicos y documentos institucionales. Si bien muchos de ellos utilizan plataformas como DSpace y cumplen con estándares básicos como Dublin Core y OAI-PMH, no presentan enfoques explícitos ni políticas claras orientadas a la gestión de Recursos Educativos Abiertos (REA).

7.1.6. Conclusiones del capítulo:

Este capítulo, ha permitido realizar un análisis del panorama actual de los Recursos Educativos Abiertos (REA) en Colombia, con énfasis en los repositorios digitales y las políticas institucionales y gubernamentales que los respaldan. Las principales conclusiones, especialmente orientadas al sector educativo, son las siguientes:

- Ausencia de políticas públicas claras para REA en educación: Aunque Colombia ha avanzado en la publicación de contenidos académicos en acceso abierto, no existe una política pública robusta y específica para los Recursos Educativos Abiertos. La mayoría de las normativas existentes están enfocadas en recursos científicos o bibliográficos generales, lo que deja un vacío normativo para el diseño, gestión y uso de REA dentro del sistema educativo (Botero & Soto, 2025).
- Desarticulación institucional en el tratamiento de REA: Las instituciones educativas, especialmente las universidades, gestionan repositorios con autonomía, lo que ha generado una gran diversidad en la forma de describir y clasificar los recursos. Este manejo aislado limita la interoperabilidad entre plataformas y afecta negativamente el descubrimiento, reutilización y enriquecimiento de los REA.
- Enfoque predominantemente académico y no pedagógico: La mayoría de los repositorios institucionales, se concentran en disertaciones académicas, como tesis, artículos científicos y trabajos de investigación, mientras que los recursos educativos con fines pedagógicos, como OVAs, guías o materiales interactivos, no son tratados como una categoría independiente ni prioritaria. Esto genera una invisibilidad estructural de los REA dentro del ecosistema educativo nacional.
- Falta de estandarización en los metadatos: Aunque el estándar Dublin Core es común, en muchos repositorios vistos, durante esta investigación, su implementación ha llegado a ser muy personalizada. En la práctica, se evidencia que cada institución ha modificado y configurado sus distintos sistemas de información, creando campos de metadatos adaptados a sus recursos de información propios y que no necesariamente están ajustados a algún estándar. También, se presentan campos fundamentales como el “autor”, vacíos. En lugar de seguir prácticas interoperables, cada institución crea variantes de campos, afectando la recolección automatizada. Esto tiene un impacto directo en la calidad y completitud de los metadatos.
- Escasa integración de los REA en la formación docente: En el estudio realizado por (Cubides, Chiappe, & Ramirez-Montoya, 2024) señalan que los programas de formación docente en Colombia no han incorporado de forma estructurada el uso ni la creación de REA. Existe una brecha entre el uso cotidiano de tecnologías por parte de futuros docentes y su aplicación pedagógica efectiva. Esto evidencia la necesidad de políticas institucionales que promuevan la competencia digital docente y la creación colaborativa de contenidos abiertos.

- Poca claridad en infraestructura: Aunque se observa muchas universidades cuentan con plataformas como DSpace o Dataverse y emplean el protocolo OAI-PMH, estas herramientas, no se utilizan ampliamente en lo que respecta a las funcionalidades para describir, clasificar y vincular REA de forma estandarizada y pedagógicamente significativa.
- Falta de estrategias para visibilizar los REA como recursos diferenciados: En la mayoría de los casos, los REA son descritos como si fueran documentos académicos comunes, sin reconocimiento de sus características específicas, lo que compromete su visibilidad y reutilización en contextos escolares o universitarios.

En la (Figura 6), se consolidan, las problemáticas identificadas respecto a la descripción de elementos de metadata asociada a los Recursos Educativos Abiertos. De esta manera y considerando las dificultades previamente identificadas, en relación con la calidad y la completitud de la metadata, en el contexto colombiano, el proyecto, se orienta a diseñar una estrategia tecnológica que permita recomendar campos de metadatos ausentes, teniendo en cuenta el contexto semántico y estructural del repositorio donde se encuentra el recurso. Es importante destacar, que el alcance de esta investigación no contempla la modificación, ni creación de un nuevo estándar de metadatos. La estrategia propuesta, busca mejorar la calidad descriptiva de los recursos, a través de la integración de componentes de inteligencia artificial (IA) para verificar, cómo la integración de estas técnicas, pueden impactar de manera significativa, a la solución del problema de metadatos incompletos o inconsistentes, un desafío persistente en repositorios educativos abiertos.




Figura 6 - Desafíos para la descripción de la metadatos de REAs

8. DESARROLLO METODOLÓGICO

La calidad de los elementos de metadatos, constituye un aspecto fundamental para el descubrimiento, la interoperabilidad y la reutilización efectiva de los recursos digitales, especialmente en contextos abiertos como los Recursos Educativos Abiertos (REA). Diversos informes internacionales han puesto en evidencia que, aun en regiones con alto grado de madurez digital, persisten desafíos significativos en este ámbito. En particular, el *Open Data Maturity Report 2024* (Capgemini Invent, 2024), señala, que la dimensión de calidad de los metadatos (Figura 7) en el contexto de los datos abiertos, es la menos desarrollada dentro de la Unión Europea, con una puntuación promedio del **79.7 %** y un retroceso con respecto al año 2023 (Capgemini Invent, 2024).




Figura 7 - Puntaje EU-27 en la dimensión de calidad de metadatos. Fuente: (Capgemini Invent, 2024)

Este informe atribuye dicha situación a la ausencia de mecanismos automáticos de monitoreo, la escasa actualización de metadatos y el bajo cumplimiento de estándares como DCAT-AP en varios portales nacionales. Además, se destaca que en varios países europeos los metadatos se gestionan de forma manual, sin validaciones semánticas o estructurales, lo que limita la vigencia, confiabilidad y reutilización de los recursos. No obstante, algunas naciones como Francia han implementado procesos completamente automatizados de extracción de metadatos desde la fuente, mientras que otros países como Serbia han incorporado espacios de retroalimentación con usuarios para mejorar la calidad descriptiva de los conjuntos de datos. Estas experiencias reflejan la importancia de implementar estrategias tanto automatizadas como participativas para abordar los problemas de calidad.

Esta situación respalda el enfoque de esta investigación, que busca aplicar técnicas basadas en inteligencia artificial (IA), para el mejoramiento de la descripción de los elementos de metadatos de los Recursos Educativos Abiertos (REA). La experiencia europea muestra que, incluso en contextos con políticas robustas y portales avanzados, la calidad de los metadatos sigue siendo una barrera para la reutilización efectiva de los recursos educativos abiertos. De acuerdo con los hallazgos presentados en los capítulos anteriores, la presente investigación propone una estrategia tecnológica basada especialmente en técnicas de inteligencia artificial y machine learning, para aportar recomendaciones de manera contextual, a la descripción de los elementos de metadatos de REA.

Para este propósito, se define una metodología compuesta por las siguientes etapas para diseñar, integrar, implementar, desplegar y verificar la estrategia planteada.

8.1. Fase 1: Exploración y contextualización

Esta etapa se enfocó en comprender el estado actual de los REA disponibles en Colombia, así como el entorno institucional y tecnológico que los soporta. Se realizó un análisis exploratorio de la estructura de metadatos, la oferta de los repositorios institucionales y la problemática asociada a la ambigüedad, inconsistencia y baja calidad descriptiva de los recursos. Adicionalmente, esto se complementa con la revisión literaria respectiva al tema

de investigación, la construcción teórica y conceptual que cubre los componentes y las técnicas empleadas.

Las actividades desarrolladas incluyen:

- **Identificación de REA y repositorios existentes:** Recolección y análisis de repositorios abiertos activos bajo el dominio público colombiano, como parte del diagnóstico de fuentes. Esto también se acompañó de la investigación realizada para explorar cual es el estado de madurez del país en lo que respecta a los REAs.
- **Caracterización de los metadatos actuales:** Evaluación de la estructura y completitud de los campos descriptivos utilizados en los recursos educativos.
- **Análisis de estándares y políticas:** Revisión de lineamientos existentes (o su ausencia) respecto a metadatos educativos abiertos en el contexto nacional.
- **Comprensión del problema semántico y técnico:** Delimitación de los vacíos de descripción, campos más frecuentemente ausentes y casos de uso afectados por la escasa calidad de los metadatos.
- **Mapeo de técnicas existentes** para descripción automática de contenido educativo (algoritmos LDA).

8.2. Fase 2: Diseño e integración de la estrategia.

En esta fase se establecieron los fundamentos arquitectónicos del sistema propuesto, definiendo y aclarando los componentes de entrada, los procesos de transformación y las salidas esperadas. Esta etapa abarcó desde la conceptualización del esquema de datos hasta la parametrización de los modelos de inteligencia artificial, para definir un pipeline completo de procesamiento. El diseño contempló la definición del esquema de datos que el sistema utilizaría como base, y se establecieron los protocolos de preprocesamiento necesarios para transformar los conjuntos de datos originales, a la estructura requerida por las técnicas seleccionadas.

Adicionalmente, se propone el diseño que especifica la articulación de todos los componentes que integran el modelo, desde las entradas de datos hasta la generación de recomendaciones, estableciendo los parámetros óptimos para los modelos de inteligencia artificial y machine learning previamente seleccionados para consolidar finalmente la

técnica de Generación Aumentada por Recuperación: RAG (Retrieval Augmented Generation).

Las principales actividades cubiertas fueron:

- **Selección y preprocesamiento de datos:** Limpieza, transformación y estructuración de los REA recolectados para su posterior vectorización y análisis.
- **Diseño de la arquitectura técnica:** Definición de los componentes tecnológicos involucrados, incluyendo la suite de servicios en nube de inteligencia artificial de Azure.
- **Conceptualización teórica para parametrizar los modelos seleccionados:**
 - Selección de los modelos de machine learning y LLM (Large Language Models) que se seleccionan de acuerdo con criterios de precisión y eficiencia para el propósito de la investigación.
 - Descripción de parámetros para algoritmos de machine learning que generan los embeddings o vectores.
- **Diseño del pipeline de recomendaciones de metadatos:** Parametrización de los algoritmos y flujos de procesamiento que integran técnicas como embeddings semánticos, recuperación basada en similitud, y generación asistida por LLM para proponer metadatos faltantes.

8.3. Fase 3: Implementación y Despliegue:

En esta fase se materializó el diseño previamente establecido, llevando a cabo la construcción efectiva del sistema de generación aumentada por recuperación RAG. Esta etapa comprendió desde la transformación de datos textuales en representaciones vectoriales hasta la integración completa del modelo RAG con el sistema de búsqueda semántica.

El proceso incluyó la vectorización exhaustiva de los conjuntos de datos para generar representaciones semánticas de alta dimensionalidad, permitiendo la captura de relaciones conceptuales complejas entre los recursos cargados. Se configuraron y parametrizaron los algoritmos de búsqueda semántica, para optimizar la recuperación de información relevante mediante técnicas de similitud vectorial. Se integró la arquitectura RAG completa, parametrizando el modelo de lenguaje grande (LLM) con instrucciones específicas y

contexto educativo para generar recomendaciones precisas y coherentes de metadatos para los recursos educativos abiertos. Finalmente, se consolidó una interfaz de usuario, para facilitar las interacciones con el backend del modelo.

Las principales actividades cubiertas son:

- Vectorización y Representación de Datos
- Configuración de Búsqueda Semántica
- Gestión del Repositorio de Índices
- Integración del Modelo RAG
- Parametrización del LLM
- Pruebas de Integración con la interfaz de usuario y Despliegue

8.4. Fase 4: Verificación de resultados:

En esta fase se realizó la verificación sistemática del comportamiento de los diferentes tipos de búsqueda, con el objetivo de determinar la configuración óptima para la arquitectura RAG propuesta. A través de un proceso escalonado, se identificó que las búsquedas híbridas constituyen la aproximación más efectiva, combinando las ventajas de la búsqueda léxica tradicional con las capacidades semánticas avanzadas de los embeddings vectoriales. La evaluación comprendió el análisis detallado de los resultados obtenidos por cada modalidad de búsqueda, examinando tanto la precisión en la recuperación de recursos relevantes como el comportamiento de los algoritmos de ranking en la ordenación de los resultados.

Finalmente, se verificaron las recomendaciones de metadatos generadas por el modelo RAG en respuesta a consultas de varios escenarios de pruebas, analizando la coherencia, relevancia y utilidad práctica de las descripciones automáticamente entregadas para los recursos educativos abiertos.

9. DISEÑO DE LA ESTRATEGIA PLANTEADA

El presente capítulo, describe la estrategia a implementar, para mejorar la descripción de los elementos de metadata que describe a los Recursos Educativos Abiertos (REAs) mediante técnicas basadas en Inteligencia Artificial, Machine Learning y Minería de Datos. La estrategia se fundamenta en la construcción de un sistema que aprovecha la similitud semántica y el procesamiento del lenguaje natural para enriquecer y completar metadatos de recursos educativos, potenciando así su descubrimiento y reutilización. Es necesario tener en cuenta que investigaciones previas como (Ahmed, Alexopoulos, Piangerelli, & Polini, 2024), (Huskova, Dikova, Petrenko, & Bönisch, 2025) (Patra, Giri, Nandi, Das, & Alenazi, 2025), brindan un respaldo teórico a la investigación, al demostrar la eficacia del uso de técnicas de inteligencia artificial, modelos extensos de lenguaje (LLMs) y mecanismos de similitud semántica para mejorar la calidad descriptiva de los datos. Estas investigaciones han abordado, desde distintos contextos, problemáticas relacionadas con la baja calidad de los metadatos, la necesidad de representaciones semánticas más ricas y la automatización en la extracción y enriquecimiento de información. Antes de entrar en detalle en los aspectos de implementación, es fundamental comprender los principios y conceptos que sustentan cada componente del sistema propuesto, así como su articulación en una arquitectura desplegada en Cloud. Dentro de las etapas fundamentales, para comprender el funcionamiento de la propuesta, se identifican tres momentos claves que permitieron consolidar el sistema RAG (Retrieval Augmented Generation), aplicado al mejoramiento de descripciones de Recursos Educativos Abiertos (Figura 8):

- **Fase 1: Preparación**

- **Entradas:** Datos del repositorio seleccionado.
- **Procesos principales:**
 - **Transformación de elementos textuales:** Conversión de contenido textual a representación vectorial para capturar significado semántico.
 - **Diseño de esquema de carga:** Estructuración de datos para el procesamiento posterior.

- **Salidas:** Representación vectorial de los datos
- **Fase 2: Integración**
 - **Procesos principales:**
 - **Indexación y configuración de índice de vectores:** Creación de estructuras de datos optimizadas para búsqueda semántica
 - **Creación de lógica vectoriales para habilitar búsquedas semánticas:** Selección de algoritmos de similitud y recuperación
 - **Salidas:** RAG (Retrieval Augmented Generation): Sistema integrado listo para generar respuestas aumentadas
- **Fase 3: Uso**
 - **Procesos principales:**
 - **Enriquecimiento mediante Large Language Model: LLM + Prompting:** Generación de recomendaciones a los elementos de metadata de los recursos, usando el contexto recuperado.
 - **Salidas:** Descripción enriquecida para el usuario final
- **Flujo General del Sistema:** El diseño sigue un pipeline lineal donde:
 - Los datos originales se vectorizan y estructuran
 - Se crea un sistema de búsqueda semántica indexado
 - El usuario interactúa con el sistema RAG que combina recuperación de información relevante con generación de texto mejorado



Figura 8 – Fases para el diseño de la estrategia propuesta

9.1. Preparación de los datos de entrada:

9.1.1. Selección del repositorio de datos: Con el objetivo de contar con datos relevantes para esta investigación, se realizó un barrido exploratorio de los principales repositorios de Recursos Educativos Abiertos (REA) disponibles en el contexto colombiano, como se documentó en el capítulo anterior. Durante este proceso, se identificaron diversas limitaciones, entre ellas, la ausencia de endpoints públicos accesibles o la necesidad de realizar solicitudes específicas para acceder a los datos, lo cual dificultaba su integración automatizada en flujos de trabajo reproducibles. En paralelo, se identificó el repositorio **Directory of Open Access Journals (DOAJ)** como una alternativa viable. A diferencia de otros repositorios, DOAJ ofreció acceso inmediato y transparente a sus conjuntos de datos a través de mecanismos de descarga directa, lo cual facilitó enormemente el proceso de obtención y procesamiento de la información.

Dada esta disponibilidad y considerando la necesidad de contar con datos estructurados, de alta calidad y con cobertura temática amplia, se seleccionó DOAJ como fuente principal de datos para esta investigación. Esta elección, también, se fundamenta en su reconocido prestigio internacional como una de las plataformas más representativas del movimiento de acceso abierto. Según (Sheikh, Zahra, & Richardson, 2022), DOAJ indexa más de 15.000 revistas científicas arbitradas de libre acceso, procedentes de 134 países, lo que lo convierte en un recurso de referencia tanto para investigadores como para bibliotecólogos y profesionales de la información comprometidos con la ciencia abierta.

La elección de DOAJ permitió garantizar la calidad, cantidad y diversidad temática necesarias para evaluar de manera robusta la estrategia propuesta en esta investigación, al tiempo que facilitó la aplicación de técnicas de inteligencia artificial sobre metadatos reales en un entorno controlado. Entre otras razones que justifican su elección:

- **Volumen y diversidad de recursos:** DOAJ contiene una amplia variedad de artículos académicos en múltiples disciplinas, proporcionando un corpus diverso para entrenar y evaluar modelos de similitud semántica.
- **Estructura de metadatos:** Los registros en DOAJ, siguen el esquema BibJSON (Bibliographic JSON), el cual proporciona una estructura clara y estandarizada de metadatos académicos (Figura 9) , facilitando su procesamiento y análisis. BibJSON se emplea como el modelo de datos subyacente, para representar los metadatos de las

revistas indexadas y para exponer su contenido mediante servicios web o APIs. Esto permite a desarrolladores e investigadores acceder, analizar y reutilizar los metadatos de forma eficiente, lo cual resulta fundamental para tareas de minería de datos, enriquecimiento automático de metadatos o integración con sistemas externos, como es el caso de la estrategia tecnológica propuesta en esta investigación.

- **Compatibilidad:** Además, uno de los factores que también motivó a la selección del repositorio DOAJ en esta investigación, para probar la técnica propuesta, fue por compatibilidad tecnológica. Al estar los metadatos disponibles en formato JSON, se facilita su integración con las fases posteriores del proceso de minería de datos, como la indexación semántica, la generación de embeddings vectoriales y el análisis automatizado con modelos de lenguaje.
- **Accesibilidad:** DOAJ proporciona acceso abierto a sus metadatos a través de APIs públicas, lo que facilita la extracción y procesamiento de datos a gran escala.
- **Relevancia académica:** Los recursos en DOAJ son de naturaleza académica y educativa, alineándose con el enfoque de la investigación en REAs.



Figura 9 - Estructura Metadatos BibJson – Repositorio DOAJ

9.1.2. Proceso de ETL: Extracción, Transformación y Carga de los datos.

Para la preparación de los datos de la investigación, el proyecto se inspira en el modelo *ETL (Extract-Transform-Load)* (Figura 10) como enfoque estructurado, para la preparación de datos, provenientes del repositorio seleccionado, con el fin de garantizar su calidad, coherencia y adecuación para los procesos de análisis que se quieren aplicar. Según IBM (2024), el proceso ETL no solo sirve para trasladar datos, sino también para estructurarlos, limpiarlos y enriquecerlos, de modo que puedan ser utilizados eficazmente en procesos analíticos, inteligencia de negocios y aplicaciones de inteligencia artificial. Este modelo ha evolucionado para adaptarse tanto a entornos tradicionales de análisis como a infraestructuras modernas basadas en la nube y Big Data. A continuación, el desglose de cada una de estas etapas:




Figura 10 - Proceso ETL - Tomado de: (SouthindusLabs, 2021)

9.1.2.1. Extracción:

En esta fase, se obtienen los datasets del repositorio DOAJ, que contiene 30 GB de registros de metadatos académicos. Estos datos, fueron compartidos a través de un punto API, con un API key único que fue suministrado para propósito de esta investigación.

9.1.2.2. Selección de campos de metadatos relevantes: Según el estudio de (Tavakoli, Mirette, Gábor, & Sören, 2021), los siguientes elementos de metadatos (Tabla 3), son considerados clave en la descripción de REA:

Tabla 3 - Importancia de campos de metadatos definidor por (Tavakoli, Mirette, Gábor, & Sören, 2021)

Campo de metadato	Importancia (%)	Descripción
Título	100	Identificación del recurso
Descripción	100	Resumen del contenido del recurso
Asignatura(Subject)	86	Facilita la categorización temática
Nivel educativo	98	Indica el grado o nivel educativo al que está dirigido el recurso
Idioma	92	Especifica el idioma en que está disponible el recurso
Duración estimada	58	Proporciona una estimación del tiempo necesario para completar el recurso
Accesibilidad	59	Indica las características de accesibilidad del recurso.

Estos campos, no solo son los más comúnmente presentes en los REA con buen puntaje de calidad en su descripción, sino que también son utilizados en modelos de puntuación y predicción de calidad de metadatos. Por ejemplo, (Tavakoli, Mirette, Gábor, & Sören, 2021). desarrollaron un modelo de puntuación que asigna valores de importancia normalizados a cada campo, basándose en su frecuencia y relevancia en REA de alta calidad. Este modelo demostró una alta precisión (94.6%) en la predicción de la calidad de los REA, subrayando la importancia de estos campos específicos.

De acuerdo con lo anterior y teniendo en cuenta los campos disponibles en el esquema de elementos de metadatos, presentados por el repositorio, los campos de metadatos candidatos y relevantes para el propósito de investigación son (Tabla 4):

Tabla 4 - Campos de metadatos seleccionados

Nombre campo	Metadato
Título del artículo	bibjson.title

Resumen o abstract	(bibjson.abstract)
Autores	(bibjson.author)

Estos campos se seleccionan debido a que serán transformados, en representaciones vectoriales para el proceso de búsqueda de información.

9.1.2.3. Transformación: hacia Embeddings vectoriales y representación semántica.

La fase de transformación de los datos, indica un componente clave de esta investigación, abordando uno de los objetivos del proyecto: encontrar técnicas de inteligencia artificial y machine learning que traten el problema de investigación. Durante la fase exploratoria del proyecto, se evaluaron varias técnicas de representación y modelado del lenguaje natural con el objetivo de mejorar la descripción de los Recursos Educativos Abiertos (REA) (Molavi, Tavakoli, & Kismihók, 2020) ; (Tavakoli, Mirette, Gábor, & Sören, 2021); (Ludeña, Segarra-Faggioni, Romero-Pelaez, & Morocho-Yunga, 2024), donde se destacan:

- LDA (Latent Dirichlet Allocation)
- Modelo de Bolsa de Palabras (BoW)
- Codificación One-hot

Si bien estas técnicas han sido ampliamente utilizadas en tareas de minería de texto y análisis temático, presentaron limitaciones significativas frente a los requerimientos del proyecto, especialmente en los escenarios, donde se requiere captura semántica y generalización contextual, para mejorar los elementos de metadata que describen los REA. Por estas razones, el proyecto migró hacia una estrategia basada en embeddings e integración con recuperación semántica, superando las limitaciones estructurales de los modelos anteriores.

Los embeddings son representaciones vectoriales densas de texto, que capturan relaciones semánticas entre palabras o frases. Estos vectores permiten transformar datos textuales en una forma numérica, que puede ser utilizada en tareas de búsqueda, clasificación y razonamiento automático. Tal y como afirma (Cavar & Zhang, 2024) los embeddings son esenciales para tareas de búsqueda, porque capturan propiedades semánticas distribucionales: las palabras que aparecen en contextos similares tienden a estar

representadas por vectores cercanos entre sí. Esto facilita búsquedas más precisas y relevantes, ya que no se limitan a coincidencias literales de texto, sino que pueden identificar conceptos relacionados, aunque estén expresados con diferentes términos.




Figura 11 – Vector embeddings: Proceso para la representación vectorial de los metadatos seleccionados.

En la (Figura 11) se ilustra el proceso mediante el cual conceptos textuales como los campos de metadatos (título, autor, abstract) son transformados en representaciones vectoriales mediante técnicas de Machine Learning, para posteriormente ser organizados y almacenados en un espacio de búsqueda semántico (Index Repository). A continuación, la explicación de cada una de estas etapas:

9.1.2.3.1. Entrada: Son todos aquellos términos, cadenas de texto que corresponden a los (Elementos de metadatos), que se seleccionaron previamente.

9.1.2.3.2. Proceso de Machine Learning:

Las cadenas de texto de cada categoría de elemento de metadata, son procesadas por el modelo: **text-embedding-3-large**, desarrollado por OpenAI, el cuál es un modelo de tercera generación y está optimizado para capturar tanto significados semánticos profundos como relaciones contextuales complejas entre palabras, frases o documentos. Este modelo fue seleccionado para el propósito de esta investigación, porque está alineado con el propósito de esta, en términos de (OpenAI, 2024): Ver (Figura 12):




Figura 12 - Características de selección de modelo de ML

- **Alta dimensionalidad:** Los vectores generados tienen una dimensión de 1536, lo que permite una representación detallada del contenido semántico.
- **Multilingüe:** El modelo soporta múltiples idiomas, lo que lo hace ideal para aplicaciones globales o contextos educativos con diversidad lingüística.
- **Entrenamiento a gran escala:** Está entrenado sobre una amplia cantidad de textos en diversos dominios, lo que mejora su capacidad de generalización.
- **Optimizado para eficiencia:** Aunque es un modelo grande, está diseñado para ser eficiente en tiempo de inferencia, facilitando su integración en aplicaciones en tiempo real o escalables.
- **Aplicable para RAG:** El modelo text-embedding-3-large se utiliza en la fase de recuperación de RAG, permitiendo encontrar documentos o fragmentos relevantes para una consulta, incluso si no coinciden literalmente con las palabras usadas.

En el contexto del mejoramiento de la descripción de los elementos de metadata de Recursos Educativos Abiertos (REA), el modelo seleccionado: text-embedding-3-large,

permite representar de forma vectorial los metadatos existentes (título, resumen, palabras clave, etc.) y compararlos semánticamente con otros recursos. Esto facilita:

- La identificación de recursos similares para sugerir autores, disciplinas o categorías faltantes.
- La detección de inconsistencias entre la descripción y el contenido real.
- La indexación semántica en motores de búsqueda inteligentes que entienden el significado, más allá de la coincidencia literal de palabras.

9.1.2.3.3. Resultado: Embeddings

Cada cadena de caracteres se convierte en un vector numérico. Estos vectores (llamados embeddings) representan la posición semántica de cada término en un espacio multidimensional. Ejemplo:

"matemáticas" → [4, 5]

"célula" → [-1.2, 1]

"fútbol" → [0.2, 1]

Los vectores generados capturan tanto información sintáctica como semántica del término. Esto permite que palabras con significados similares terminen cercanas en el espacio vectorial. Así, los embeddings no solo codifican el significado literal de una palabra, sino también su uso contextual.

9.1.2.3.4. Carga: Organización semántica en el repositorio indexado (Index Repository)

Una vez los vectores han sido generados, estos necesitan ser indexados para poder hacer los procesos de búsqueda. Indexar embeddings, es el proceso de almacenar y organizar vectores numéricos de representación semántica, en una estructura de datos especializada que permita consultas eficientes por similitud semántica (Guo, et al., 2020). Este proceso es esencial, cuando se trabaja con grandes volúmenes de datos textuales, como descripciones, títulos o palabras clave de REA, y se desea recuperar información relevante no solo por coincidencia textual, sino por significado (Figura 13).




Figura 13 - Indexado de Vectores (embeddings)

Para el propósito de la investigación, los embeddings indexados permiten:

- Sugerir descripciones faltantes con base en otros recursos similares.
- Un recurso con metadatos incompletos puede ser enriquecido, comparándolo con sus vecinos más cercanos en el índice vectorial.
- Un motor de búsqueda puede sugerir recursos similares sin depender de coincidencia exacta de palabras.
- Agrupar recursos automáticamente por temas, disciplinas o niveles educativos.
- El índice funciona como base para arquitecturas RAG (Retrieval-Augmented Generation), que combinan búsqueda semántica con modelos generativos para enriquecer o completar información.

9.2. Integración: Búsquedas Vectorial, Semánticas e Híbridas

Una vez completado el proceso de extracción, transformación y carga (ETL), previamente descrito, y tras haber indexado los datos enriquecidos mediante representaciones vectoriales (embeddings), se habilita la posibilidad de realizar búsquedas sobre el corpus indexado.

9.2.1. Búsqueda Vectorial:

La búsqueda vectorial ha emergido como una tecnología esencial en el contexto actual de procesamiento de información, particularmente ante el crecimiento exponencial de datos de alta dimensionalidad en diversos dominios como el procesamiento de lenguaje natural. Este paradigma representa los datos como vectores o embeddings en espacios de alta

dimensionalidad, donde la tarea de encontrar los vectores más similares a una consulta dada (búsqueda del vecino más cercano) se ha convertido en un desafío crítico y de mucho interés (Mathur & Chhabra, 2024).




Figura 14 - Búsqueda vectorial - Workflow

Además, la búsqueda vectorial se basa en algoritmos de vecinos más cercanos (k-Nearest Neighbors, KNN) y Approximate Nearest Neighbors (ANN) que identifican los puntos más próximos en un espacio vectorial multidimensional. Dentro de estos algoritmos, se encuentra: **HNSW (Hierarchical Navigable Small World)** que según la evaluación hecha por (Mathur & Chhabra, 2024), ver (Tabla 5), HNSW fue diseñado específicamente para búsquedas de vecinos más cercanos (*nearest neighbor*) en espacios vectoriales de alta dimensión, como ocurre con los embeddings generados por modelos de lenguaje como *text-embedding-3-large*, seleccionado para este proyecto. Además, este algoritmo, tiene bajo tiempo de consulta (latencia), lo que lo hace ideal para interactuar con el sistema en tiempo real o consultas interactivas. El algoritmo HNSW, organiza los vectores en una estructura de grafo jerárquico para optimizar la navegación entre vectores similares.




Figura 15 - Proceso de búsqueda a través de la estructura multicapa del grafo HNSW. (Pinecone, 2025)

Tabla 5 - Comparativo entre algoritmos ANN. Tomado de: (Mathur & Chhabra, 2024)

Algoritmo	Velocidad	Uso de Memoria	Casos de Uso
LSH	Rápido	Alto	Búsqueda de documentos e imágenes
HNSW	Muy rápido	Moderado	Recomendaciones en tiempo real
PQ	Moderado	Bajo	Búsqueda a gran escala
Annoy	Rápido	Bajo	Recomendaciones musicales
Faiss	Muy rápido	Alto	Pipelines de ML a gran escala

En el contexto específico de los REA, la búsqueda vectorial adquiere relevancia importante, al permitir la representación semántica de los elementos de metadata que describen al recurso, porque estos son representados como vectores o embeddings en espacios de alta dimensionalidad, capturando su contenido semántico de manera más enriquecida que las palabras clave. Esta capacidad de representación semántica profunda, es fundamental para el mejoramiento de las descripciones de REAs mediante técnicas de inteligencia artificial, ya que permite identificar relaciones conceptuales y similitudes que van más allá de las coincidencias léxicas superficiales.

9.2.2. Búsquedas híbridas:

Adicionalmente, para mejorar la precisión y cobertura de los resultados, se emplean estrategias de búsqueda híbrida. Esta técnica combina la búsqueda semántica con la búsqueda tradicional (basada en texto completo) dentro del mismo motor de búsqueda. Mientras que la búsqueda semántica detecta relaciones de significado implícitas, la

búsqueda tradicional ofrece exactitud y recuperación rápida de documentos relevantes que coincidan literalmente con la consulta (Belagatti, 2024).




Figura 16 - Workflow de búsqueda híbrida. Fuente: (Belagatti, 2024)

- En la (Figura 16), se muestra cómo una consulta sobre un corpus se analiza desde dos perspectivas: semánticamente, para identificar relaciones con los resultados, y mediante la búsqueda de palabras clave exactas. Luego, el sistema aplica un algoritmo de ranking para evaluar la relevancia de los resultados según la búsqueda. La búsqueda híbrida combina, precisión y flexibilidad al manejar coincidencias exactas e interpretar el contexto de las consultas. En el contexto de esta investigación, esta fase representa el punto en el cual la estrategia tecnológica propuesta permite realizar búsquedas, con mayor precisión, adaptativas y semánticamente relevantes sobre los metadatos enriquecidos de los REA, incrementando así las posibilidades de descubrimiento y reutilización efectiva.

9.3. Uso: LLM (Large Language Model) y Retrieval-Augmented Generation (RAG)

RAG fue propuesto formalmente por (Lewis, Oguz, Rinott, Riedel, & Schwenk, 2020) como una técnica para mejorar modelos generativos, complementándolos con un componente de recuperación de información. Esta es una técnica híbrida que combina capacidades de recuperación con generación natural de texto. En lugar de depender únicamente del conocimiento interno del modelo LLM, se consulta un índice semántico para recuperar documentos relevantes y utilizarlos como contexto de respuesta (Lewis, Oguz, Rinott, Riedel, & Schwenk, 2020). Un sistema RAG típico (Figura 17), incluye un LLM, como GPT,

un repositorio vectorial (donde se almacenan previamente los datos) y la ejecución de preguntas sobre el modelo.




Figura 17 - Fases de RAG, Fuente: Datos Abiertos Gobierno España (Datos.gob.es, 2024)

Para el contexto de la investigación, se ha seleccionado RAG como una técnica diferenciadora para el alcance de la presente investigación y, de acuerdo con lo que menciona (Dakshit, 2024), estas técnicas tienen gran relevancia en el ambiente educativo porque permiten integrar conocimientos externos confiables a los modelos de lenguaje, mejorando la precisión y pertinencia de las respuestas. La aplicabilidad de estas técnicas en la mejora de los elementos de metadata de los (REAs) tiene especial relevancia, ya que permiten enriquecer descripciones incompletas con información contextualizada y semánticamente alineada, optimizando su descubrimiento y reutilización en repositorios digitales abiertos.

9.4. Conclusiones del capítulo:

La estrategia diseñada del proyecto se puede resumir bajo los siguientes contextos (Figura 18):





Figura 18 - Estrategia para mejoramiento de los elementos de metadata que describen los REAs.

- Preparación de Datos:** La fase de preparación de datos resultó ser un componente crítico para garantizar la calidad y utilidad del modelo propuesto. A través del proceso de extracción, transformación y carga (ETL), se logró estructurar adecuadamente los metadatos de los Recursos Educativos Abiertos (REAs), generando representaciones vectoriales (embeddings) que habilitan capacidades de búsqueda semántica. No obstante, cabe mencionar, que esta fase fue necesaria debido a las limitaciones encontradas en los repositorios disponibles en el contexto colombiano. A pesar de que, conforme a los principios de apertura de datos (Open Data Principles), se esperaría que los conjuntos de datos estuvieran listos para su reutilización, en la práctica no fue así. De allí la selección del repositorio DOAJ y los pasos subsiguientes para implementar un proceso de preparación y transformación de los datos antes de poder integrarlos en la arquitectura propuesta.

- **Búsqueda semántica para recuperación de contenidos:** La implementación de búsqueda híbrida combinando técnicas tradicionales de similitud con embeddings generados mediante modelos de lenguaje, permite superar las limitaciones de las búsquedas basadas únicamente en coincidencia textual. Esta etapa es fundamental para identificar descriptores relevantes cuando hay metadatos incompletos o ausentes. La generación de vectores semánticos y su posterior consulta en una base de datos vectorial (Index repository) ofrece una recuperación más precisa y relevante de contenidos relacionados, mejorando significativamente la curación de REAs.
- **Técnica RAG (Retrieval Augmented Generation):** La técnica RAG se consolidó como una herramienta clave para complementar la información faltante en los metadatos, generando contenido a partir de la combinación entre resultados de búsqueda semántica y las capacidades generativas de un modelo extenso de lenguaje (LLM). Su integración en la arquitectura propuesta, permite no sólo recuperar información relevante sino también producir respuestas contextualizadas, coherentes y útiles para los curadores de metadatos. Este enfoque demuestra ser prometedor para enriquecer descripciones de REAs, apoyando su descubrimiento, reutilización y clasificación en repositorios digitales.

10. IMPLEMENTACIÓN Y DESPLIEGUE DE LA ESTRATEGIA PLANTEADA

Partiendo de los fundamentos teóricos expuestos y de la estrategia planteada previamente, esta sección presenta la implementación y despliegue del entorno tecnológico propuesto, que se presenta como técnica para mejorar los elementos de metadata que describen los REA. Se pretende cubrir las siguientes capas de implementación e infraestructura:



10.1. Consideraciones del entorno tecnológico en la nube

Para el despliegue del entorno tecnológico, que permitió implementar la técnica propuesta, se consideró usar el proveedor de nube de Azure. Este proveedor, según el último informe del cuadrante de Garnet (Azure, 2024), figura como líder en prestación de servicios de inteligencia artificial en la nube (Figura 19). Con Microsoft Azure se empleó la suite de servicios de Azure AI, que permite integrar múltiples capacidades de inteligencia artificial. Esta plataforma proporciona herramientas avanzadas como modelos de lenguaje extensos (LLMs), servicios de búsqueda cognitiva, generación de embeddings semánticos y capacidades de procesamiento de lenguaje natural, todos ellos fundamentales para el mejoramiento automatizado de los elementos de metadata en los Recursos Educativos Abiertos (REA). Se utilizaron principalmente los siguientes servicios principales:

- **Azure OpenAI:** para acceder a modelos de lenguaje extensos como text-embedding-3-large, utilizados en la generación de embeddings y en tareas de generación aumentada por recuperación (RAG).
- **Azure Cognitive Search:** configurado con búsqueda semántica y vectorial para habilitar consultas basadas en similitud conceptual entre recursos.
- **Azure AI Project y Azure AI Hub:** como contenedores centralizados de configuración y gestión de flujos de trabajo de inteligencia artificial, facilitando la integración entre servicios cognitivos y modelos de lenguaje.
- **Azure Storage Account:** utilizado para almacenar y gestionar los archivos de entrada (embeddings generados).
- **Azure Key Vault:** empleado para la gestión segura de secretos, claves API y credenciales necesarias para la autenticación entre servicios.

Figure 1: Magic Quadrant for Cloud AI Developer Services




Figura 19 – Magic Quadrant for Cloud AI Developer Services. Fuente: (Azure, 2024)

10.2. Etapa de transformación de datos: vectorización (generación de embeddings)

En esta etapa se satisfacen los siguientes pasos:

10.2.1. Generación de embeddings

El proceso de generación de embeddings constituye una etapa fundamental en la estrategia planteada. Este procedimiento transforma la información textual de los metadatos de REAs en representaciones vectoriales numéricas que capturan el significado semántico del contenido, permitiendo su procesamiento computacional eficiente. Se cubren las siguientes etapas (Figura 20):




Figura 20 - Etapas para la generación de embeddings

El sistema implementado utiliza la API de Azure OpenAI, a través del SDK oficial de Python para interactuar con Azure AI Search. Para la generación de embeddings, estableciendo una conexión segura mediante credenciales de Azure y un proveedor de tokens de autenticación. Se tomó una muestra de 150 recursos, para la generación de los embeddings.

Extracción de Campos Relevantes

El proceso inicia con la carga de datos estructurados en formato JSON, donde cada recurso educativo contiene metadatos bibliográficos esenciales. Se extraen cuatro campos fundamentales que caracterizan los REAs:

- **Título:** Identifica el recurso educativo de manera única
- **Resumen (Abstract):** Proporciona una descripción detallada del contenido
- **Autores:** Información sobre los creadores del recurso

Estrategia de Procesamiento por Lotes

Para optimizar el rendimiento y manejar grandes volúmenes de recursos educativos, se implementa una estrategia de procesamiento por lotes con las siguientes características:

- **Tamaño de lote configurable:** Permite procesar múltiples textos simultáneamente (por defecto 50 elementos)
- **Mecanismo de reintentos:** Garantiza la robustez ante fallos temporales de la API
- **Filtrado de contenido vacío:** Excluye automáticamente textos sin contenido

Parametrización:

El modelo que se configuró para la generación de embeddings es: **text-embedding-3-large** con **1024** dimensiones, considerando un equilibrio entre calidad semántica de los vectores y costo. Esta configuración permite generar representaciones suficientes para tareas de búsqueda y comparación semántica, reduciendo al mismo tiempo el tamaño del índice y los costos asociados al procesamiento y almacenamiento.

Integración y persistencia de los vectores resultantes:

Los embeddings generados se integran directamente en la estructura de datos original, enriqueciendo cada recurso con 3 nuevos campos vectoriales (abstractVector, TitleVector, authorVector). Esta estructura enriquecida se almacena en formato JSON, preservando toda la información original mientras se añaden las representaciones vectoriales. En la (Figura 21), a modo de ejemplificación, se quiso representar en tres dimensiones, el vector de títulos, usando reducción PCA (Análisis de Componentes Principales) (Jolliffe & Cadima, 2016), con nuevas dimensiones, donde se reduce la variabilidad de los datos originales (embeddings en 1024 dimensiones) para poder graficar y ayudar a visualizar agrupamientos, similitud semántica o patrones en los datos obtenidos.




Figura 21 - Distribución PCA 3D de los embeddings del vector de títulos de una muestra de datos.

La similitud coseno es una medida que cuantifica qué tan similares son dos vectores en un espacio vectorial, calculando el coseno del ángulo entre ellos (Huang, 2008). Esta métrica, permite comparar representaciones vectoriales en tareas de agrupamiento y recuperación semántica de documentos. Esta métrica evalúa el coseno del ángulo entre dos vectores, proporcionando un valor entre 0 (sin relación) y 1 (idénticos en dirección).


Ecuación 1 - Similitud Coseno

similitud coseno = $S_C(A,B) := \cos(\theta) = \frac{A \cdot B}{||A|| \ ||B||} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \cdot \sqrt{\sum_{i=1}^n B_i^2}}$

donde:

- $A \cdot B$ es el producto de los vectores A y B
- $||A|| \ ||B||$ son las magnitudes de los vectores.

Se utiliza la similitud coseno para obtener las gráficas (Figura 22) y (Figura 23) para analizar qué tan relacionados están los datos entre sí. De la muestra procesada, se obtiene gran variabilidad en los datos para el vector de título de los recursos analizados.

Descripción	Tipo de Visualización
El <i>histograma de distancias coseno</i> muestra qué tan similares o diferentes son entre sí los embeddings de la información. La forma del histograma ayuda a entender la dispersión y agrupamiento de los datos en el espacio de embeddings. Para este caso, se observa que hay gran variedad en distribución de los títulos de los recursos analizados.	Histograma de distancias coseno entre embeddings para (títulos)  Figura 22 - Histograma de distancias coseno entre embeddings para el campo título.

El mapa de calor de similitud coseno, para los primeros 100 títulos, sirve para visualizar qué textos son más similares entre sí según los embeddings generados. Cada celda muestra el grado de similitud entre dos títulos: valores cercanos a 1 indican alta similitud y valores cercanos a 0 indican baja similitud. Nuevamente, se observa gran variedad de los títulos vectorizados.




Figura 23 - Mapa de calor de similitud coseno para el vector de título del dataset de recursos seleccionado.

10.2.2. Creación de índice en Azure

El diseño del índice vectorial es fundamental para permitir búsquedas eficientes por similitud semántica. Los aspectos clave del diseño incluyen:

Estructura del índice

La estructura del índice combina campos tradicionales con campos vectoriales, manteniendo la riqueza de los metadatos originales mientras habilita la búsqueda vectorial (Figura 24)




Figura 24 - Estructura de índice creado

10.2.2.1. Parametrización del índice:

La configuración de cada uno de los campos tiene atributos configurables que se han parametrizado, de acuerdo con las diferentes pruebas realizadas, para encontrar un índice adaptado a las necesidades de la investigación. A continuación, se describen cada uno de los atributos que se pueden asociar a los campos (Microsoft Fields, 2024):

- retrievable: El campo se puede recuperar en los resultados de búsqueda (aparece en la respuesta).
- searchable: El campo se puede buscar por texto completo (se indexa para búsquedas de texto).
- filterable: El campo se puede usar en filtros (por ejemplo, en consultas tipo WHERE campo = valor).
- facetable: El campo se puede usar para crear facetas (agrupaciones o conteos por valores únicos).
- sortable: El campo se puede usar para ordenar los resultados.

De acuerdo con esto, la parametrización de cada campo, se puede resumir en la siguiente (Tabla 6):

Tabla 6 - Campos del índice creado

Campo	Tipo	Propiedades	Propósito
id	SearchableField(String)	key=True, sortable, filterable, searchable	Identificador único del recurso
last_updated	SimpleField(DateTimeOffset)	Deshabilitado	Deshabilitado
created_date	SimpleField(DateTimeOffset)	Deshabilitado	Deshabilitado
bibjson/journal/country	SearchableField(String)	searchable, filterable, facetable	Permite filtrar por país de origen del recurso educativo

bibjson/journal/publisher	SearchableField(String)	searchable, filterable, facetable	Editorial/institución que publica el REA
bibjson/journal/language	SimpleField(Collection)	filterable, facetable	Idiomas disponibles del recurso
bibjson/journal/title	SearchableField(String)	searchable, filterable, facetable	Título de la publicación/colección
bibjson/month	SimpleField(String)	filterable, facetable	Filtros temporales para recursos estacionales
bibjson/year	SimpleField(Int32)	filterable, sortable, facetable	Filtro por año de publicación, ordenamiento por actualidad
bibjson/keywords	SearchableField(Collection)	searchable, filterable, facetable	Palabras clave para clasificación temática
bibjson/subject/term	SearchableField(String)	searchable, filterable, facetable	Términos de clasificación académica estándar
bibjson/abstract	SearchableField(String)	searchable	Descripción del contenido educativo
bibjson/title	SearchableField(String)	searchable, filterable, facetable	Título principal
bibjson/author/name	SearchableField(String)	searchable, filterable, facetable	Búsqueda por autor específico
bibjson/author/affiliation	SearchableField(String)	searchable, filterable, facetable	Institución del autor para autoridad académica
bibjson/link/url	SimpleField(String)	filterable	URL de acceso al recurso

Campos Vectoriales para Búsqueda Semántica

El índice, implementa 4 vectores independientes para capturar diferentes aspectos semánticos (Tabla 7):

Tabla 7 - Campos para los vectores

Campo Vector	Dimensiones	Propósito
titleVector	1024	Embeddings del título del REA
abstractVector	1024	Embeddings del resumen/descripción
authorVector	1024	Embeddings de información de autoría

Configuración de Búsqueda Vectorial

Para implementar la búsqueda vectorial, como se ha mencionado previamente, se seleccionó el algoritmo HNSW (Hierarchical Navigable Small World) por su eficiencia y robustez en la búsqueda de vecinos más cercanos en espacios de alta dimensión (Malkov & Yashunin, 2020). A continuación, se presenta la configuración utilizada para el algoritmo (HNSW) en el índice vectorial del proyecto. Esta parametrización busca un equilibrio entre precisión, consumo de memoria y eficiencia de búsqueda, de acuerdo con la recomendación indicada por el fabricante (Microsoft, Vector Search, 2024) Tabla 8 :

Tabla 8 - Parametrización de algoritmo HNSW

Parámetro	Valor	Significado y Justificación
m	4	Especifica la cantidad de enlaces bidireccionales entre nodos en el grafo HNSW. El valor por defecto es 4. El rango permitido es de 4 a 10. Valores bajos de m tienden a producir índices más compactos y rápidos, y pueden reducir el ruido en los resultados.
efConstruction	400	El parámetro efConstruction define la cantidad de vecinos más cercanos que se consideran durante el proceso de indexación. Valor por defecto: 400. Rango permitido: 100 a 1,000. Un valor alto mejora la calidad del grafo construido, lo que incrementa la precisión de las búsquedas posteriores. Sin embargo, también incrementa el tiempo y consumo de recursos durante la creación del índice.

efSearch	500	El parámetro efSearch especifica la cantidad de vecinos más cercanos considerados durante la ejecución de una búsqueda. Valor por defecto: 500. Rango permitido: 100 a 1,000. Un valor más alto aumenta la precisión en los resultados de búsqueda, aunque también puede elevar la latencia en la respuesta. Es útil en contextos donde se prioriza la calidad de recuperación sobre la velocidad.
metric	cosine	Métrica utilizada para comparar vectores. La similitud coseno es adecuada para embeddings de texto porque mide la orientación entre vectores, permitiendo identificar similitud semántica.

Vectorización

Se incluye AzureOpenAIVectorizer para habilitar la vectorización automática de consultas de texto en Azure AI Search. Esto permite que, al realizar búsquedas, se puedan enviar directamente texto (no un vector) y Azure Search se encargue de generar el embedding usando el vectorizer configurado, de la misma forma y con el mismo modelo que se usó para indexar los documentos. Esto asegura consistencia entre los vectores de los recursos y los de las consultas. Y es acorde con el diseño de la investigación para usar consultas híbridas y mejorar el resultado de las búsquedas.

Parametrización de búsqueda semántica

En esta sección del índice, se definió la configuración semántica, lo que indica, cuales campos se deben interpretar semánticamente. Esto es útil para la investigación para poder hacer consultas basadas en el significado del contenido (más allá de palabras clave exactas), gracias al uso de embeddings y modelos de lenguaje (LLMs). Como se ha mencionado previamente, los campos seleccionados son el título, las palabras claves y el abstract.

Parametrización de Perfiles de Scoring Personalizados

El ScoringProfile es una función que se aplica para ajustar la puntuación de relevancia de los documentos durante la búsqueda. Permite asignar pesos diferenciados a los campos del documento, de manera que los más relevantes para el dominio (en este caso los REA) influyan más en los resultados (Microsoft(Scoring), 2024). Para este caso, se creó el siguiente perfil de scoring (Tabla 9):

Tabla 9 - Perfil de Scoring para REAs

Campo	Peso	Justificación
bibjson/title	3.5	Máxima relevancia - primera impresión del usuario
bibjson/abstract	3.0	Contenido descriptivo principal
bibjson/subject/term	2.5	Clasificación académica estándar
bibjson/author/name	2.0	Autoridad académica moderada
bibjson/journal/publisher	1.5	Credibilidad institucional
bibjson/keywords	1.5	Palabras clave temáticas

En Azure se observa el índice creado de la siguiente manera (Figura 24):

rea-index


Field name	Type	Retrievable	Filterable	Sortable	Facetable	Searchable	Analyzer	Dimension
id	String	☒	☒	☒	☐	☒	Standa...	
last_updated	DateTimeOffset	☒	☐	☐	☐			
created_date	DateTimeOffset	☒	☐	☐	☐			
bibjson	ComplexType							
> identifier	ComplexTypeColle...							
> journal	ComplexType							
month	String	☒	☒	☐	☒	☐		
keywords	String	☒	☒	☐	☒	☒	Standa...	
year	Int32	☒	☒	☒	☒			
> subject	ComplexTypeColle...							
> author	ComplexTypeColle...							
> link	ComplexTypeColle...							
abstract	String	☒	☐	☐	☐	☒	Standa...	
title	String	☒	☒	☐	☒	☒	Standa...	
titleVector	SingleCollection	☐				☒		1024
abstractVector	SingleCollection	☐				☒		1024
authorVector	SingleCollection	☐				☒		1024
subjectVector	SingleCollection	☐				☒		1024

Figura 25 - Azure Index creado

10.3. Configurador del indexador:

El indexador es un componente automatizado que va a permitir extraer datos de una fuente específica y los procesa para poblar el índice de búsqueda. En este escenario puntual, el indexador se ha configurado para:

- Tomar el archivo JSON con los datos, que fue previamente enriquecido con los embeddings.
- Se descompone el archivo JSON, en unidades documentales independientes (cada recurso).
- Cargar la información en el índice previamente creado (Figura 25)



Con el indexador cargando la información y la estructura del índice con la información poblada, se puede concluir en este capítulo que se ha culminado el proceso de ETL (extracción transformación y carga) empleado para propósito de la investigación.

10.4. Diseño de la arquitectura RAG propuesta:

La arquitectura RAG diseñada, permite aprovechar tanto la búsqueda vectorial como los modelos de lenguaje, con el objetivo específico de mejorar los elementos de metadata que describen los REAs.

RAG funciona como técnica híbrida que combina capacidades de recuperación, con generación natural de texto. En lugar de depender únicamente del conocimiento interno del modelo LLM, se consulta un índice semántico para recuperar documentos relevantes y utilizarlos como contexto de respuesta. En la Figura 26, se observa el flujo construido:




Figura 26 - Sistema RAG en acción para estrategia de REAs

El flujo operativo del sistema puede describirse en los siguientes pasos:

- **Entrada del usuario (Query):** El usuario formula una consulta en lenguaje natural, sobre algún metadato de interés que desee formular.
- **Vectorización de la consulta:** Permite buscar documentos/recursos en el índice, usando tanto la similitud semántica (texto) como la similitud vectorial (embeddings de los campos vectoriales previamente creados), entregando resultados enriquecidos, con resúmenes y respuestas automáticas. Se configuró para buscar los 50 vecinos más cercanos y se habilita capacidad exhaustiva (sobre los campos) para comparar contra todos los vectores del índice para máxima precisión.
- **Búsqueda semántica híbrida:** Se utiliza Azure Search AI para recuperar documentos relevantes combinando:
 - Búsqueda por texto
 - Búsqueda semántica configurada
 - Búsqueda por similitud de vectores

Esto permite recuperar documentos que contienen conceptos similares, incluso si las palabras no coinciden literalmente.

- **Filtrado de fuentes:** Los resultados recuperados se estructuran y serializan (en formato JSON) para que el modelo los pueda interpretar como contexto confiable.
- **Generación aumentada (RAG):** Se utilizó el modelo de lenguaje (LLM) desplegado en Azure OpenAI (en este caso, **gpt-4o**) basándose en los siguientes criterios (Nizon Deladoeuille, Stefánsson, Neukirchen, & Welsh, 2024):
 - **Rendimiento:** ha demostrado un alto rendimiento en tareas complejas que requieren precisión, aplicabilidad práctica y variedad de soluciones.
 - **Destacado en:** Tarea de relevancia, usabilidad y creatividad.
 - **Alta relevancia:** Entiende bien los objetivos de las tareas y utiliza eficientemente la información provista en los prompts.
 - **Orientación educativa:** Su rendimiento estable y su nivel de detalle lo hacen adecuado como herramienta de apoyo en entornos educativos y de investigación aplicada

10.4.1. Parametrización del modelo LLM

Para entrenar el modelo generativo, se define un prompt (Figura 27) que guía el comportamiento sobre cómo actuar, de dónde obtener la información y cómo ayudar a mejorar las descripciones de metadatos de un recurso. Este prompt, establece claramente el rol del asistente, las tareas específicas y las limitaciones de la generación (Lewis, Oguz, Rinott, Riedel, & Schwenk, 2020).

```
You are a helpful assistant helping librarians and researchers complete metadata for Open Educational Resources (OERs).  
You will be given details of an OER with missing metadata fields, and context about similar OERs .  
Your task is to analyze the input OER and the context, then suggest the most likely metadata that describes better for the input OER.  
Answer the query using only the sources provided below in a friendly and concise bulleted manner.  
Answer ONLY with the facts listed in the list of sources below.  
If there isn't enough information below, say you don't know.  
Do not generate answers that don't use the sources below.  
the sources are provided in the bibjson format, which is a standard for describing OERs.  
The bibjson format includes fields like title, abstract, authors, subjects, and more.  
Sources:\n{sources}
```

Figura 27 - Prompt de entrenamiento al modelo generativo LLM.

- ##### 10.4.1.1. Parámetros de control del LLM:
- Los parámetros de control del LLM (Tabla 10), son mecanismos de ajuste, que permiten optimizar el comportamiento del modelo de lenguaje para generar respuestas de alta calidad:

Tabla 10 - Parámetros de control LLM - Fuente: (GPtCache, n.d.)

Parámetro	Valor usado	Definición	Uso
temperature	0.2	Controla el nivel de aleatoriedad en las respuestas del modelo.	Ajusta la creatividad o determinismo del modelo.
max_tokens	2500	Límite máximo de tokens (palabras y símbolos) que puede generar el modelo.	Controla la longitud máxima de la respuesta.
top_p	0.3	Selecciona las palabras más probables cuya suma de probabilidades es p (nucleus sampling).	Ajusta la diversidad de las respuestas sin usar directamente temperature.

10.5. Interfaz de Usuario y Arquitectura

Con el fin de facilitar la interacción entre el usuario final y el sistema de recuperación aumentada por generación (RAG), se desarrolló una interfaz gráfica tipo **chat**, que permite consultar de manera conversacional los REAs indexados y de esta manera permitir al curador de metadatos, cumplir con las tareas esperadas. Esta herramienta cumple una doble función: por un lado, actúa como componente de validación de la efectividad del sistema RAG en la recuperación y generación de descripciones enriquecidas; por otro, proporciona una experiencia de usuario sencilla y accesible para explorar los resultados del modelo. En la (Figura 28) , se presenta la arquitectura de la capa visual y como interactúa con el sistema RAG. La solución implementada sigue un enfoque cliente-servidor. El frontend está construido utilizando el *Django*, lo cual permitió simular peticiones y renderizar una interfaz basada en formularios conversacionales. El backend se desarrolló en Python, donde reside la lógica principal del sistema RAG, incluyendo el manejo de peticiones, consulta al índice semántico y generación de respuestas mediante modelos de lenguaje (LLMs). Para la comunicación en tiempo real entre el cliente y el servidor, se empleó Redis con el patrón pub/sub (publicador/suscriptor). Esta arquitectura permite mantener un flujo asíncrono de mensajes entre las capas, optimizando el tiempo de respuesta y facilitando la gestión del estado de la conversación.

11. VERIFICACIÓN DE RESULTADOS Y APORTES

En este capítulo se presentan los resultados obtenidos durante la implementación y evaluación de técnicas de inteligencia artificial y machine learning para el mejoramiento de la descripción de Recursos Educativos Abiertos (REAs). Las pruebas, se diseñaron para evaluar diferentes estrategias de búsqueda semántica y su efectividad en la recuperación de información educativa, utilizando la suite de servicios de Azure AI como plataforma en la nube de implementación. A modo de contextualización, se presenta en la siguiente (Figura 29) cómo funciona el proceso esencial de búsqueda vectorial.




Figura 29 - Proceso de Búsqueda vectorial. Fuente: (Microsoft, Vector Search, 2024)

Azure AI Search permite indexar, almacenar y consultar representaciones vectoriales (embeddings) directamente desde un índice de búsqueda. Durante el proceso de indexación, los vectores generados son organizados mediante algoritmos de vecinos más cercanos (kNN), de forma que los elementos semánticamente similares se ubiquen próximos en el espacio vectorial (Microsoft, Vector Search, 2024).

Por otra parte, en la fase de consulta, se transforma la entrada del usuario en un vector, que es comparado contra el índice utilizando búsqueda por similitud. Azure AI Search también admite escenarios híbridos que combinan búsqueda vectorial y búsqueda tradicional por palabras clave, mejorando así la calidad de los resultados al unir ambas estrategias. De esta manera, se analizan y evalúan los diferentes tipos de búsqueda que permitieron descubrir el comportamiento y rendimiento de las mismas, así como evidenciar el tipo de búsqueda que se ajusta mejor para la propuesta del proyecto.

Cada resultado, tiene asociado un **score** que representa la similitud semántica entre la consulta y cada resultado encontrado:

Definición	Medida numérica de similitud entre vectores
Rango típico	0.0 a 1.0 (donde 1.0 = similitud perfecta)
Cálculo	Similitud coseno entre vector de consulta y vector del documento
Interpretación	Más alto = más relevante semánticamente

Por otra parte, se realizan las pruebas por medio de la interfaz web para facilitar la interacción de las pruebas. Cabe mencionar que el modelo RAG sólo funciona con la fuente de datos que se suministra. En el prompt del LLM está especificado.

11.1. Evaluación de las estrategias de búsqueda: En esta sección, se analizaron cada una de las estrategias de búsqueda, candidatas para entrenar el sistema, analizando cual puede lograr mejores resultados para el propósito de la investigación. Esta evaluación permitió obtener el tipo de búsqueda con la parametrización correcta, que permite obtener buenos resultados para el proyecto. Para iniciar pruebas, se tienen 409 documentos (recursos) cargados en el índice Figura 30.




Figura 30 - Tamaño de índice de REAs en Azure

11.1.1. Búsqueda Vectorial pura: Las pruebas iniciales se enfocaron en la implementación de búsqueda vectorial pura, donde las consultas en lenguaje natural se convierten

automáticamente en vectores semánticos mediante modelos de embeddings. Los resultados evidenciaron que esta aproximación logra capturar la similitud semántica entre consultas y recursos, independientemente de las coincidencias exactas de palabras clave.

Características:

Aspecto	Descripción
Tipo de Búsqueda	Búsqueda Vectorial Pura (Pure Vector Search)
Consulta de Entrada (Texto de consulta)	Artificial intelligence
Campo de Búsqueda	"abstractVector"
Algoritmo de Similitud	k-Nearest Neighbors (k-NN) con k=50
Texto de Búsqueda	None (deshabilitado - solo búsqueda vectorial)

Resultados:

Se obtienen los siguientes resultados iniciales al buscar por: artificial intelligence. Se pueden observar resultados con buena relevancia, asociados con esta temática:

	Título	Autores	Score
0	Preventing Foodborne Illness: Clostridium botulinum	Keith R. Schneider, Mickey E. Parish, Renée M. Goodrich, Taylor Cookingham	0.614771
1	Psychometric evaluation of the Chinese version of the Patient Self-Advocacy Scale using classical test theory and item response theory	Jialu Cui, Jing Wang, Ailin Yue, Jiayan Cao, Zhijie Zhang, Baoxin Shi	0.584117
2	O movimento negro no Brasil: ausências, emergências e a produção dos saberes.	Nilma Lino Gomes	0.580836
3	Sequence processing with quantum-inspired tensor networks	Carys Harvey, Richie Yeung, Konstantinos Meichanetzidis	0.578136
4	Ethoxychelerythrine as a potential therapeutic strategy targets PI3K/AKT/mTOR induced mitochondrial apoptosis in the treatment of colorectal cancer	Yaqin Meng, Yanpo Si, Tao Guo, Weiwei Zhao, Liping Zhang, Ya Wang, Lianping Wang, Ke Sun, Shuying Feng	0.574829

11.1.2. Análisis de Diversidad Lingüística: El modelo de machine learning seleccionado, afirma que soporta consultas multilingües. En esta prueba, se hace la consulta en español. Se pretende validar la capacidad *multidioma* del modelo.

Aspecto	Descripción
Tipo de Búsqueda	Búsqueda Vectorial Pura Multidioma
Consulta de Entrada	Inteligencia artificial (en español)
Campo de Búsqueda	"abstractVector"
Algoritmo de Similitud	k-Nearest Neighbors (k-NN) con k=50

Resultados:

	Título	Autores	Score
0	Information, Genetics and Entropy	Julio Ernesto Rubio Barrios	0.596455
1	Caracterización de una noción de simulación a partir de prácticas experimentales	Pio Garcia	0.590347
2	Preventing Foodborne Illness: Clostridium botulinum	Keith R. Schneider, Mickey E. Parish, Renée M. Goodrich, Taylor Cookingham	0.589330
3	Optimizing charge pathways by interface engineering in Fe ₂ O ₃ /Co ₃ O ₄ /Co(PO ₃) ₂ heterostructures for superior oxygen evolution reaction	Shucheng Liu, Yu Shuai, Tao Zhang, Xuefei Liu, Zhao Ding, Yi Liu	0.582753
4	Simuladores degenerados: una lectura foucaultiana de "La Simulación De La Locura" de José Ingenieros	Sandra Caponi	0.580990

Al realizar la consulta en español, los resultados no coincidieron consistentemente cuando se hizo la misma consulta en inglés. Este hallazgo, puede poner a evidencia un sesgo de idioma hacia inglés, en el modelo de embedding utilizado:

Aspecto	Descripción
Limitación identificada	Inconsistencia en búsqueda multiidioma
Impacto	Es español, solo se mantuvo 1 resultado en relación cuando se hizo la búsqueda en inglés.
Métrica	% de resultados en idioma de consulta vs. otros idiomas
Análisis	En inglés, los resultados de score son superiores. Puede suponer un sesgo lingüístico con el modelo seleccionado.

11.1.3. Búsqueda exhaustiva de vecinos exactos (Exhaustive KNN): Este tipo de prueba permite realizar una búsqueda exhaustiva en el índice vectorial, independientemente del tipo de índice configurado (ya sea HNSW o ExhaustiveKNN). Su principal utilidad, radica en la obtención de valores de referencia o "*ground-truth*", los cuales sirven como base para comparar y evaluar la precisión de otros métodos de búsqueda aproximada.

Aspecto	Descripción
Tipo de Búsqueda	Búsqueda Vectorial Pura Exhaustiva
Consulta de Entrada	"artificial intelligence"
Campo de Búsqueda	"abstractVector"
Algoritmo de Similitud	k-Nearest Neighbors (k-NN) con k=50 + Exhaustive Search

Característica Especial: Parámetro exhaustive=True

Aspecto	exhaustive=False (por defecto)	exhaustive=True (actual)
Método de búsqueda	Aproximada (ANN - Approximate Nearest Neighbor)	Exacta (examina todos los vectores)
Velocidad	Más rápida	Más lenta
Precisión	Buena aproximación	Máxima precisión posible
Recursos	Menor uso de CPU/memoria	Mayor uso de CPU/memoria
Casos de uso	Datasets grandes, tiempo real	Datasets pequeños, máxima precisión

Resultados:

La comparación entre búsqueda exhaustiva (exhaustive=True) y aproximada (exhaustive=False) no mostró diferencias observables en los scores de similitud ni en el orden de los resultados. Este resultado sugiere que el algoritmo KNN está optimizado para el volumen de datos que se utilizó para hacer la prueba.

	Título	Autores	Score
0	Preventing Foodborne Illness: Clostridium botulinum	Keith R. Schneider, Mickey E. Parish, Renée M. Goodrich, Taylor Cookingham	0.614771
1	Psychometric evaluation of the Chinese version of the Patient Self-Advocacy Scale using classical test theory and item response theory	Jialu Cui, Jing Wang, Ailin Yue, Jiayan Cao, Zhijie Zhang, Baoxin Shi	0.584117
2	O movimento negro no Brasil: ausências, emergências e a produção dos saberes.	Nilma Lino Gomes	0.580836
3	Sequence processing with quantum-inspired tensor networks	Carys Harvey, Richie Yeung, Konstantinos Meichanetzidis	0.578136
4	Ethoxychelerythrine as a potential therapeutic strategy targets PI3K/AKT/mTOR induced mitochondrial apoptosis in the treatment of colorectal cancer	Yaqin Meng, Yanpo Si, Tao Guo, Weiwei Zhao, Liping Zhang, Ya Wang, Lianping Wang, Ke Sun, Shuying Feng	0.574829

11.1.4. Búsqueda vectorial multi campo: Este tipo de consulta, demuestra una búsqueda vectorial multi campo que permite consultar simultáneamente múltiples campos vectoriales mediante vectores de consulta correspondientes.

Aspecto	Descripción
Tipo de Búsqueda	Búsqueda Multi-Vectorial
Consulta de Entrada	"artificial intelligence"
Campo de Búsqueda	"titleVector" + "abstractVector" (múltiples campos)

Algoritmo de Similitud	k-Nearest Neighbors (k-NN) con k=50 en cada campo
------------------------	---

Resultados:

	Título	Autores	Score
0	Sequence processing with quantum-inspired tensor networks	Carys Harvey, Richie Yeung, Konstantinos Meichanetzidis	0.030798
1	Software defect prediction based on residual/shuffle network optimized by upgraded fish migration optimization algorithm	Zhijing Liu, Tong Su, Michail A. Zakharov, Guoliang Wei, Sangkeum Lee	0.029907
2	Mixture of Emotion Dependent Experts: Facial Expressions Recognition in Videos Through Stacked Expert Models	Ali N. Salman, Karen Rosero, Lucas Goncalves, Carlos Busso	0.027783
3	Prediction of Myocardial Infarction Based on Non-ECG Sleep Data Combined With Domain Knowledge	Changyun Li, Yonghan Zhao, Qihui Mo, Zhibing Wang, Xi Xu	0.027480
4	Emotional Intelligence: What Is It and How Can It Transform Your Life?	Harpreet Singh Dhillon, Shibu Sasidharan, Gurpreet Kaur Dhillon, Babitha Manalikuzhiyil	0.027425

Hallazgos: Los resultados revelan que la búsqueda multi vectorial supera el rendimiento de las búsquedas de campo único, ofreciendo mayor precisión y cobertura. Esta mejora se atribuye a la capacidad del sistema para evaluar la similitud semántica en múltiples dimensiones del contenido, resultando en una correspondencia más precisa entre los recursos recuperados y la intención de búsqueda

Aspecto	Búsqueda Simple	Multi-Vector (actual)
Campos analizados	Un solo campo (ej: abstractVector)	Múltiples campos (titleVector + abstractVector)
Cobertura	Limitada a un aspecto del documento	Análisis holístico del contenido
Ranking	Score de un solo vector	Score combinado/fusionado
Precisión	Buena para contenido específico	Mayor precisión al considerar múltiples aspectos

11.1.5. Búsqueda multi vectorial ponderada: Esta consulta muestra una búsqueda vectorial entre campos que permite consultar múltiples campos vectoriales al mismo tiempo mediante el paso de múltiples vectores de consulta con diferentes ponderaciones.

Aspecto	Descripción
Tipo de Búsqueda	Búsqueda Multi-Vectorial con Pesos Diferenciados (Prioridad Abstract)
Consulta de Entrada	"artificial intelligence"

Campo de Búsqueda	de	"titleVector" (peso: 0.5) + "abstractVector" (peso: 2.0)
Algoritmo de Similitud	de	k-Nearest Neighbors (k-NN) con k=50 en cada campo

Resultados: Los abstracts contienen más información semántica detallada que los títulos, por lo que pueden ofrecer mejor precisión para consultas complejas sobre REAs. Si existe una variación en los resultados respecto a los que no son ponderados. Esto se puede usar para casos específicos de consultas.

	Titulo	Autores	Score
0	Sequence processing with quantum-inspired tensor networks	Carys Harvey, Richie Yeung, Konstantinos Meichanetzidis	0.039209
1	Emotional Intelligence: What Is It and How Can It Transform Your Life?	Harpreet Singh Dhillon, Shibu Sasidharan, Gurpreet Kaur Dhillon, Babitha Manalikuzhiyil	0.036101
2	Prediction of Myocardial Infarction Based on Non-ECG Sleep Data Combined With Domain Knowledge	Changyun Li, Yonghan Zhao, Qihui Mo, Zhibing Wang, Xi Xu	0.035479
3	Software defect prediction based on residual/shuffle network optimized by upgraded fish migration optimization algorithm	Zhijing Liu, Tong Su, Michail A. Zakharov, Guoliang Wei, Sangkeum Lee	0.035224
4	Mixture of Emotion Dependent Experts: Facial Expressions Recognition in Videos Through Stacked Expert Models	Ali N. Salman, Karen Rosero, Lucas Goncalves, Carlos Busso	0.034440

11.1.6. Búsqueda Híbrida: Este tipo de búsqueda combina similitud semántica vectorial con métodos de búsqueda textual tradicionales (BM25/TF-IDF)

Aspecto	Descripción
Tipo de Búsqueda	Búsqueda Híbrida (Textual + Vectorial)
Consulta de Entrada	"articles related to artificial intelligence"
Campo de Búsqueda	"abstractVector" (vectorial) + campos de texto tradicionales
Algoritmo de Similitud	k-Nearest Neighbors (k-NN) con k=50 + BM25/TF-IDF
Texto de Búsqueda	"articles related to artificial intelligence" (habilitado)

Resultados: Se evidenció un rendimiento superior al de los enfoques individuales. Esta aproximación logra balancear la precisión semántica con la especificidad terminológica, resultando particularmente efectiva para consultas que requieren tanto comprensión conceptual como coincidencias de términos específicos.

		Titulo	Autores	Score	Reranker Score
0		On the impact of Generative Artificial Intelligence on peer review	Giovanni de Gaetano, Chiara Cerletti, Augusto Di Castelnuovo	0.016393	2.578494
1		Optimizing black cattle tracking in complex open ranch environments using YOLOv8 embedded multi-camera system	Su Myat Noe, Thi Thi Zin, Ikko Kobayashi, Pyke Tin	0.023122	2.555808
2		Sequence processing with quantum-inspired tensor networks	Carys Harvey, Richie Yeung, Konstantinos Meichanetzidis	0.018028	2.520715
3		Secure and flexible image watermarking using IWT, SVD, and chaos models for robustness and imperceptibility	Wafa Hamdan Alshoura, Moatsum Alawida	0.017441	2.298552
4		Software defect prediction based on residual/shuffle network optimized by upgraded fish migration optimization algorithm	Zhijing Liu, Tong Su, Michail A. Zakharov, Guoliang Wei, Sangkeum Lee	0.030331	2.262928

 Generate  Code  Markdown

Comparación con la búsqueda vectorial pura:

Aspecto	Búsqueda Vectorial Pura	Búsqueda Híbrida
search_text	None (deshabilitado)	query (habilitado)
Métodos combinados	Solo similitud semántica	Similitud semántica + coincidencias textuales
Algoritmos	Solo vectorial (embeddings)	Vectorial + BM25/TF-IDF
Score final	Solo score vectorial	Score combinado/fusionado

Ventajas de la Búsqueda Híbrida:

Beneficio	Descripción
Precisión mejorada	Combina coincidencias exactas con similitud semántica
Cobertura amplia	Encuentra documentos por palabras clave Y por concepto
Redundancia positiva	Si falla un método, el otro puede compensar
Ranking optimizado	Documentos que coinciden en ambos métodos obtienen mayor score

11.1.7. Búsqueda Híbrida semántica avanzada + Re-Ranking: El re-ranker score es una puntuación mejorada que asigna Azure Search AI utilizando inteligencia artificial, para evaluar qué tan relevante es realmente un documento (REA) respecto a la consulta. Funciona en dos pasos (Microsoft-SemanticRanker, 2025):

- El sistema encuentra documentos candidatos usando métodos tradicionales y les asigna un score básico. (Lo que ya se cubrió en las evidencias anteriores).

- Después, el reranker semántico analiza estos resultados considerando el contexto y significado completo, no solo las palabras clave, y les asigna un nuevo puntaje (reranker score) que puede cambiar su orden de importancia. Esto significa que los documentos que aparecen primero son aquellos que mejor responden a la intención real de la búsqueda, no solo los que tienen más coincidencias de palabras, resultando en una experiencia de búsqueda más precisa y útil para encontrar REAs relevantes.

Tabla 11 Parametrización de la prueba

Aspecto	Descripción
Tipo de Búsqueda	Búsqueda Híbrida Semántica Avanzada
Consulta de Entrada	"articles related to artificial intelligence"
Campo de Búsqueda	"abstractVector" + "bibjson/title" + "bibjson/abstract"
Algoritmo de Similitud	k-NN (k=50, exhaustive) + BM25 + Semantic Ranking
Texto de Búsqueda	"articles related to artificial intelligence" (habilitado)

Tabla 12 Características habilitadas en búsqueda tipo híbrida

Componente	Función	Beneficio
QueryType.SEMANTIC	Reranking semántico de resultados	Mejora relevancia usando modelos de lenguaje
semantic_configuration_name	Configuración semántica personalizada	Optimización específica para el dominio
QueryCaptionType.EXTRACTIVE	Genera resúmenes contextuales	Destacar fragmentos relevantes
QueryAnswerType.EXTRACTIVE	Extrae respuestas directas	Proporciona respuestas concisas
search_fields	Campos específicos para búsqueda textual	Control granular de dónde buscar

Resultados: En esta tabla se observa, como el reranker calificó y reordenó nuevamente los resultados obtenidos. En **verde**, se observan los recursos donde mejoró el ranking. En **rojo** se muestra que el resultado bajó de posición en su ranking. Donde no hubo color, significa que el resultado mantuvo la misma posición en ambos rankings (original y ranqueado):

Reranked Results

Reranked Index	Original Index	@search.score	@search.reranker_score	Título	Autores
0	4	0.016393	2.578494	On the impact of Generative Artificial Intelligence on peer review	Giovanni de Gaetano, Chiara Cerletti, Augusto Di Castelnuovo
1	1	0.023122	2.555808	Optimizing black cattle tracking in complex open ranch environments using YOLOv8 embedded multi-camera system	Su Myat Noe, Thi Thi Zin, Ikko Kobayashi, Pyke Tin
2	2	0.018028	2.520715	Sequence processing with quantum-inspired tensor networks	Carys Harvey, Richie Yeung, Konstantinos Meichanetzidis
3	3	0.017399	2.298552	Secure and flexible image watermarking using IWT, SVD, and chaos models for robustness and imperceptibility	Wafa Hamdan Alshoura, Moatsum Alawida
4	0	0.030331	2.262928	Software defect prediction based on residual/shuffle network optimized by upgraded fish migration optimization algorithm	Zhijing Liu, Tong Su, Michail A. Zakharov, Guoliang Wei, Sangkeum Lee

Esto mejora el ranqueo de los resultados, optimizando la experiencia para el usuario.

Resultados con respuestas y resúmenes semánticos: Adicionalmente, como se especificó en la parametrización de la prueba, se habilitó las respuestas y resúmenes semánticos. El reranker semántico también soporta la generación automática de respuestas y resúmenes extraídos de los documentos recuperados para una consulta específica (Microsoft-SemanticRanker, 2025).

- **Respuestas Semánticas Extractivas:** El reranker semántico interpreta la consulta como una pregunta en lenguaje natural y busca la mejor respuesta dentro de los documentos mejor posicionados que se ajuste a dicha pregunta. A diferencia de la Generación Aumentada por Recuperación (RAG), esta funcionalidad es exclusivamente extractiva, es decir, extrae fragmentos textuales existentes sin generar contenido nuevo.

- **Resúmenes Contextuales (Captions):** El sistema extrae automáticamente un resumen representativo o fragmento de texto del documento que sea relevante para la consulta realizada. Estos resúmenes incluyen elementos resaltados que pueden mostrarse en la interfaz de búsqueda para guiar a los usuarios hacia los resultados más pertinentes, mejorando así la experiencia de descubrimiento de información.

Escenario de prueba: Se pregunta: *"who is the author that has talked about economic impacts of the Florida golf industry"*

Resultados: Esta información que realiza el motor, puede complementar al sistema RAG cuando se parametrize.

Reranked Results

Reranked Index	Original Index	@search.score	@search.reranker_score	Título	Autores	Caption Highlights
0	0	0.033333	3.205195	Economic Dimensions of the Florida Golf Course Industry	John Haydu, Alan Hodges	
1	1	0.032522	2.090921	Economic Impacts of Agricultural, Food, and Natural Resource Industries in Florida in 2004	Alan W. Hodges, Mohammad Rahmani, W. David Mulkey	FE680, a 15-page illustrated report by Alan W. Hodges, Mohammad Rahmani, and W. David Mulkey, aims to quantify the magnitude of contributions agricultural, food and natural resource industries make to the economy of Florida in 2004. This report updates a previous study for 2003. Includes references, glossary of economic impact terms, and tables.
2	3	0.025459	1.490982	A Brief History of the Sales Environment	Micah Strader, Allen Wysocki	This document is SN001, one of a series of the Food and Resource Economics Department, Florida Cooperative Extension Service, Institute of Food and Agricultural Sciences, University of Florida. Original publication date January 2002. Reviewed October 2008. SN001/SN001: A Brief History of the Sales Environment (ufl.edu).
3	2	0.032522	1.481766	Economic Impacts of the Florida Citrus Industry in 2003-04	Alan Hodges, Mohammad Rahmani, David Mulkey	The citrus industry remains a major part of Florida's agricultural and natural resource economy. This paper presents estimates of the total impacts of the Florida citrus industry on the state's economy based on production values for the 2003-2004 crop year. Estima... Impacts are expressed in terms of output, value added, employment, labor income,.
4	4	0.014376	1.393149	Taxation and Budget Reform Commission (TBRC) Constitutional Amendment 9: Requiring 65 Percent of School Funding for Classroom Instruction; State's Duty for Children's Education	Rodney L. Clouser	A series of 16 fact sheets by Rodney L. Clouser, inform the public on issues related to statutory and constitutional proposals adopted by the Taxation and Budget Reform Commission (TBRC). Fact sheets FE733 through FE741 address statutory changes and fact sheets FE742 through FE748 address constitutional amendments. Published by the UF Department.

Answers

	key	score	text
	057c9f45810a498697cf8c3ffc6e2321	0.999000	Economic impacts of the Florida golf industry were estimated for year 2000 based upon a survey of golf courses, together with other published data and regional economic models. Results for survey re... This 16-page fact sheet was written by John Haydu and Alan Hodges, and published by the UF Department of Food and Resource Economics, December 2012.
	974fbfca96714b89be5c58b287590974	0.854000	FE680, a 15-page illustrated report by Alan W. Hodges, Mohammad Rahmani, and W. David Mulkey, aims to quantify the magnitude of contributions agricultural, food and natural resource industries make to the economy of Florida in 2004. This report updates a previous study... Published by the UF Department of Food and Resource Economics, December 2006.

Conclusiones preliminares de los tipos de búsqueda: La búsqueda híbrida con re-ranking semántico se posiciona como la estrategia más efectiva, combinando múltiples aproximaciones para maximizar tanto la precisión como la cobertura de resultados. Este resultado permite parametrizar el sistema RAG para que se cumplan con las expectativas de recomendación esperadas por el curador de metadatos.


11.2. Resultados obtenidos según las pruebas con el sistema RAG integrado y la interfaz de usuario:

A continuación, se describen los actores involucrados en las pruebas interactivas con el sistema:

Actor	Rol	Responsabilidad	Interacción con el sistema
Curador de metadatos REAs	Usuario evaluador	Formula preguntas al sistema RAG sobre metadatos faltantes o incompletos en un REA. Valida las respuestas generadas.	Envía consultas mediante la interfaz gráfica tipo chat, revisa las sugerencias, y evalúa su relevancia.
Chat (Sistema)	Asistente automático	Procesa las preguntas del curador y genera recomendaciones de metadatos (autor, fecha, materia, etc.) basadas en su conocimiento indexado.	Responde consultas utilizando búsqueda semántica y generación aumentada por recuperación (RAG) desde el índice REA.

Escenario 1:

- **Información de Recurso de Entrada:** Se tiene un extracto de lo que trata el recurso, pero el metadato faltante es el autor.
- **Pregunta de entrada:** “Necesito completar los metadatos del siguiente REA: [...]. Indica el autor que hizo este recurso.”
- **Resultado esperado para metadato Autor:** **Curtis Rainbolt.**
- Interacción de chat:




Resultado: Se obtiene el autor correcto, de acuerdo con la pregunta.

Escenario 2:

- **Información de Recurso de Entrada:** Se tiene un extracto de lo que trata el recurso, pero el metadato **año de creación** está incompleto.
- **Pregunta de entrada:** “Necesito completar los metadatos del siguiente REA: [...]. Indica la fecha en que se hizo este recurso.”
- **Resultado esperado para metadato, Año Creación:** 2005.


- Interacción de chat:



Resultado: Se obtiene el año correcto, de acuerdo con la pregunta. Adicional, proporcionó información adicional respecto a la fecha de revisión. Que no se le preguntó explícitamente, pero pudo inferir esta recomendación.

Escenario 3:


- **Información de Entrada:** No se proporciona información de ningún recurso, pero se consulta sobre una universidad específica para obtener información de autores asociados con esta institución.
- **Pregunta de entrada:** “estoy buscando autor o autores, que han publicado recursos en la universidad: “Erasmus University Medical Center”
- Resultado esperado: metadato de **listado de autores**.
- Interacción de chat:



Resultado: Se obtuvo lista de autores correspondiente.

Escenario 4:

- **Información de Entrada:** Se tiene un recurso que tiene por título: "Vida saludable para personas de edad: El ejercicio y la Diabetes".
- **Pregunta de entrada:** "estoy buscando autor o autores, que han publicado recursos en la universidad: Erasmus University Medical Center"
- Resultado esperado: metadato Autor del recurso con nombre completo.
- Interacción de chat:



Resultado: Se obtuvo el nombre completo del autor y adicionalmente da detalle sobre la universidad donde se publicó.

Escenario 5:

- **Información de Entrada:** Se tiene un recurso que tiene por título: "Modelling of pome fruit pollen performance using machine learning". El curador de metadatos, pregunta sobre los metadatos básicos de este recurso.
- **Pregunta de entrada:** "sugiere los metadatos(year, autor y breve resumen) de este recurso que lleva por título: Modelling of pome fruit pollen performance using machine learning en una lista ordenada."
- Resultado esperado: metadatos descriptores de este recurso.
- Interacción de chat:

Mon 5/26/2025, 9:52:03 PM UTC

sugiere los metadatos(year, autor y breve resumen) de este recurso que lleva por titulo: Modelling of pome fruit pollen performance using machine learning en una lista ordenada.



Mon 5/26/2025, 9:52:11 PM UTC

sugiere los metadatos(year, autor y breve resumen) de este recurso que lleva por titulo:- **Título:** Modelling of pome fruit pollen performance using machine learning


- **Autores:**
 - Sultan Filiz Güçlü (Isparta University of Applied Sciences Atabey Vocational School)
- **Año:** 2025
- **Mes:** Febrero
- **Palabras clave:**
 - Pollen germination
 - Pollen tube growth
 - Machine learning
 - Apple
 - Pear
- **Resumen:**

Este estudio desarrolla un modelo de aprendizaje automático para predecir la tasa de germinación del polen en frutas de pepita (pome fruits). Se realizaron pruebas de germinación in vitro con polen de cuatro cultivares en diferentes medios, temperaturas y duraciones. Se utilizaron redes neuronales artificiales para crear modelos predictivos, logrando un valor R^2 de 0.89 con el optimizador Adam. Los resultados destacan el potencial del aprendizaje automático en la investigación agrícola.
- **Identificadores:**
 - DOI: 10.1038/s41598-025-91286-4
 - eISSN: 2045-2322
- **Revista:**
 - Título: Scientific Reports
 - Volumen: 15
 - Número: 1
 - País: Reino Unido (GB)
 - Editorial: Nature Portfolio
 - Idioma: Inglés (EN)
- **Temas:**
 - Medicina (LCC: R)
 - Ciencia (LCC: Q)
- **Enlace al texto completo:** <https://doi.org/10.1038/s41598-025-91286-4>

Resultado: Se obtienen los metadatos de este recurso, esperados. Se destaca también, que, si bien el recurso originalmente se encuentra indexado en idioma inglés, el sistema tiene capacidad multilinguaje para responder en español de acuerdo con lo requerido por el usuario que interactúa. Ahora bien, cabe resaltar, que cuando se hizo la búsqueda simple en español, sin utilizar el sistema RAG, la búsqueda no arrojó buenos resultados. Lo que evidencia el buen desempeño del sistema RAG junto con LLM.

Escenario 6:

- **Información de Entrada:** Se pretende conocer si el modelo es capaz de buscar relaciones semánticas, de acuerdo con la consulta inicial. En este caso se consulta si cierto autor está relacionado con cierta temática.
- **Pregunta de entrada:** “Busca si el autor: [...], está relacionado con publicaciones relacionadas con temas de salud”
- **Resultado esperado:** debe confirmar, que está relacionado con temas en salud.
- Interacción de chat:



Resultado: El sistema puede inferir que el autor si se relaciona con temas asociados al sector salud y proporciona el recurso que encontró. Se observa que, al buscar en internet, el autor si está relacionado en áreas del sector salud, como se observa en (Figura 31)





Figura 31 - Evidencia # 1 - Fuente Google Scholar

Escenario 7: En concordancia con el escenario 6 de la prueba anterior, se observa que el recurso, no tiene resumen.

- **Recurso analizado:**
 - Título: Online Learning: Indian Nurses' Perception and a Feasibility Study
 - Autores: G. Balamurugan, Radhakrishnan Govindan, M. Vijayarani
 - Resumen (abstract): No disponible
 - Palabras clave: No proporcionadas
 - Temas: Nursing (Enfermería)
 - Año: 2021
 - Revista: Indian Journal of Psychiatric Nursing

Se consulta al sistema para rectificar la información:



Se continúa la prueba con la siguiente pregunta:

Pregunta planteada:

¿Puedes sugerir un resumen al trabajo titulado "Online Learning: Indian Nurses' Perception and a Feasibility Study"?

Puede sugerir un resumen al trabajo titulado: Online Learning: Indian Nurses' Perception and a Feasibility Study

Thu 5/29/2025, 12:55:32 AM UTC

Puede sugerir un resumen al trabajo titulado: Online Learning: The publication titled **"Online Learning: Indian Nurses' Perception and a Feasibility Study"** lacks an abstract, making it difficult to provide a detailed analysis of its content. However, based on the title and metadata, here is what can be inferred:

Key Details:

- **Authors:** G. Balamurugan, Radhakrishnan Govindan, M. Vijayarani
- **Year:** 2021
- **Journal:** Indian Journal of Psychiatric Nursing
- **Subjects:** Nursing
- **Keywords:** None provided
- **Country:** India
- **Publisher:** Wolters Kluwer Medknow Publications

Suggestions:

1. **Abstract Creation:** Since the abstract is missing, a speculative abstract could be:
 - "This study explores the perceptions of Indian nurses regarding online learning and evaluates its feasibility in the context of nursing education. The research aims to identify challenges, benefits, and the potential for integrating online learning into nursing curricula in India."
 - This speculative abstract aligns with the title and the journal's focus on nursing.
2. **Shared Themes Across Publications:**
 - The publication may share themes with other studies in the dataset, such as:
 - **Nursing Education:** Similar to the study on "Factors influencing constructive conflict management style of nursing interns" and "Effect of educational program on nurses' performance regarding application of liberation bundle in pediatric intensive care unit."
 - **Psychological and Professional Development:** Related to studies like "Emotional Intelligence: What is It and How Can It Transform Your Life?" and "Qualitative Study on the Psychological Experience of Nursing Officers Caring COVID-19 Patients."
3. **Potential Keywords:**
 - Online learning
 - Nursing education
 - Feasibility study
 - Indian nurses
 - Digital education in healthcare
4. **Further Research:**
 - If the study involves online learning during the COVID-19 pandemic, it could be compared with other studies in the dataset that address pandemic-related challenges, such as "Qualitative Study on the Psychological Experience of Nursing Officers Caring COVID-19 Patients."

If more information is required, the full text of the study should be consulted.

Validación del resumen Generado vs. resumen original

Artículo Original:

- Título: Online Learning: Indian Nurses' Perception and a Feasibility Study
- Fuente: Indian Journal of Psychiatric Nursing, 2021
- Enlace: https://journals.lww.com/iopn/fulltext/2021/18020/online_learning__indian_nurses__perception_and_a.16.aspx

Resumen generado por el sistema (en inglés)	Resumen original(traducido)
<i>This study explores the perceptions of Indian nurses regarding online learning and evaluates its feasibility in the context of nursing education. The research aims to identify challenges, benefits, and the potential for integrating online learning into nursing curricula in India.</i>	Contexto: El aprendizaje en línea se ha convertido en una necesidad para proporcionar educación continua a las enfermeras, especialmente durante situaciones como la pandemia. Objetivo: Evaluar la percepción de las enfermeras registradas sobre el aprendizaje en línea y determinar su viabilidad como método educativo. Métodos: Se usó un enfoque cuantitativo con diseño descriptivo para recopilar datos de 60 enfermeras utilizando un cuestionario estructurado. Resultados: La mayoría de las enfermeras tuvieron una percepción favorable del aprendizaje en línea. Factores como el acceso a internet, familiaridad con la tecnología y flexibilidad fueron claves en la aceptación del modelo. Conclusión: El aprendizaje en línea es factible para la educación en enfermería, pero requiere infraestructura técnica y orientación adecuada para ser efectivo.

En la Tabla 13, se muestra una comparación entre el resumen generado por el sistema y el resumen original extraído del artículo publicado. Se evalúan los elementos clave para verificar la coherencia semántica del contenido recomendado por el modelo RAG.

Tabla 13 - Comparación de resúmenes

Aspecto evaluado	Resumen generado por el sistema	Resumen original del artículo
Enfoque general	Percepción de enfermeras sobre aprendizaje en línea y su viabilidad	Percepción de enfermeras y viabilidad del aprendizaje en línea
Objetivo de percepción	Sí está incluido	Sí está incluido
Evaluación de viabilidad	Sí está incluida	Sí está incluida
Mención de metodología	No incluida	Diseño descriptivo con cuestionario a 60 enfermeras
Factores clave de resultados	No mencionados	Acceso a internet, familiaridad tecnológica, flexibilidad
Conclusión general	Factibilidad de integración en educación de enfermería	Factible con necesidad de infraestructura y orientación

Resultados obtenidos:

- El resumen generado por el sistema, es semánticamente coherente con el contenido del artículo. Aunque omite detalles específicos como la metodología y factores clave de los resultados, logra capturar la esencia de la investigación: percepción de enfermeras sobre el aprendizaje en línea, evaluación de su viabilidad y contexto en la educación en enfermería. Esto valida la capacidad del modelo para generar contenido inferido útil a partir de metadatos básicos pre existentes y el contexto del repositorio de datos de entrada.
- El modelo justificó que el resumen generado era consistente con el tema del recurso y el enfoque de la revista.
- El sistema sugirió palabras clave relevantes (en inglés) ausentes en el documento original:
 - Online learning
 - Nursing education
 - Feasibility study
 - Indian nurses
 - Digital education in healthcare

Verificación de Resultados y Aportes obtenidos:

- La evaluación de diferentes estrategias de búsqueda semántica permitió identificar fortalezas y limitaciones de cada enfoque. En particular, la búsqueda híbrida con re-ranking semántico, demostró ser la más efectiva, al combinar precisión contextual con capacidades de recuperación textual, logrando así una mayor relevancia en los resultados obtenidos para RAG.
- La integración de múltiples vectores en las consultas (multi vector y multi campo) mejoró la cobertura semántica de los resultados.
- Las pruebas de re-ranking semántico agregaron una capa avanzada de evaluación contextual, logrando mejorar la posición de resultados relevantes. Esto fortaleció la experiencia de búsqueda y demostró ser una alternativa efectiva para guiar al usuario hacia REAs de alta calidad.
- Desde una perspectiva funcional, el sistema RAG implementado con interfaz conversacional permitió validar de forma interactiva la capacidad del modelo para completar metadatos ausentes (como autor, año, palabras clave, etc), basándose en contenidos ya indexados y su capacidad de inferencia semántica. Los escenarios de prueba demostraron casos exitosos donde el sistema generó respuestas correctas y, en ocasiones, enriquecidas con información adicional no solicitada.

12. CONCLUSIONES

La presente investigación ha demostrado la viabilidad de aplicar técnicas de inteligencia artificial y aprendizaje automático para mejorar los elementos descriptivos de los Recursos Educativos Abiertos (REAs). Este objetivo se alcanzó, mediante el diseño e implementación de una arquitectura basada en el enfoque RAG (Generación Aumentada por Recuperación), la cual fue parametrizada y adaptada para generar recomendaciones contextuales a partir de fuentes de datos específicas. Los resultados obtenidos, validan la hipótesis inicial: la combinación de técnicas de inteligencia artificial, incluyendo modelos de aprendizaje automático y minería de datos, permite entregar recomendaciones a los elementos de metadata que describen los REA. Aunque esta investigación se centró en el caso particular de los REAs, la estrategia propuesta puede extenderse a otros dominios vinculados a políticas de datos abiertos.

A partir del desarrollo e implementación de la estrategia propuesta, se identificaron los siguientes hallazgos y aportes específicos:

- La evaluación sistemática de diferentes estrategias de búsqueda, reveló que la búsqueda híbrida con re-ranking semántico, constituyó la aproximación más efectiva para el contexto de REAs. En la verificación de resultados, se evidenció que, comparada con estrategias individuales, el enfoque híbrido, supera las limitaciones inherentes de cada técnica por separado.
- La integración de modelos extensos de lenguaje (LLMs) y representaciones vectoriales (embeddings), demostró ser una estrategia prometedora en escenarios donde se busca automatizar el procesamiento de grandes volúmenes de datos. Estas técnicas permiten que las máquinas identifiquen patrones relevantes y generen recomendaciones útiles para la curación y mejora de metadatos, contribuyendo así a procesos más eficientes y escalables de gestión de la información.
- La integración de técnicas de búsqueda semántica con generación de lenguaje natural, mediante el enfoque RAG (Retrieval-Augmented Generation), permitió la entrega automática de respuestas contextualizadas y relevantes. Desde la perspectiva de un curador de datos, esta capacidad puede representar una

herramienta importante para facilitar la mejora y enriquecimiento de los metadatos asociados a los Recursos Educativos Abiertos (REA). El hecho de que tanto las consultas como las respuestas puedan formularse en lenguaje natural simplifica significativamente la interacción con el sistema, reduciendo barreras técnicas y mejorando la experiencia del usuario en tareas de curación y análisis de información.

- La integración de técnicas de minería de datos en las fases de preprocesamiento y carga al índice vectorial, resultó fundamental para la extracción de patrones semánticos y la optimización de la estructura de almacenamiento vectorial.
- Uno de los hallazgos más relevantes durante la validación de pruebas, es que el prompting (ingeniería de instrucciones) juega un papel fundamental en la calidad de las respuestas generadas por el modelo LLM. Un prompt cuidadosamente diseñado, permite orientar al modelo para aprovechar de forma efectiva los datos estructurados disponibles en los metadatos, logrando inferencias coherentes, relevantes y alineadas con el objetivo de enriquecer la descripción de los Recursos Educativos Abiertos (REAs). Por tanto, optimizar el prompt es una etapa crítica en el desarrollo de sistemas de recuperación semántica basados en inteligencia artificial.
- Es fundamental destacar la importancia del proceso de extracción, transformación y carga (ETL) en la preparación de los datos iniciales, especialmente cuando se pretende aplicar modelos como RAG (Retrieval-Augmented Generation). Este proceso debe estar cuidadosamente estructurado y parametrizado, teniendo en cuenta las condiciones particulares de los conjuntos de datos disponibles. La necesidad de implementar un ETL robusto surge, en gran medida, de la limitada apertura de datos en el contexto analizado, donde no existe un modelo estandarizado ni una construcción consistente de los metadatos. Aunque publicar datos es un primer paso, resulta imprescindible avanzar hacia una verdadera apertura que garantice la accesibilidad, usabilidad y completitud de los datos, alineada con principios de calidad y reutilización.
- Se concluye también que el preprocesamiento de los datos, apoyado en técnicas de minería de datos, sigue siendo un paso crucial para garantizar el correcto funcionamiento de los modelos aplicados. En particular, disponer de los metadatos en formato JSON, bajo el esquema BibJson, resultó altamente conveniente tanto

para su transformación como para su posterior carga en el indexador. Esto se debe a que el proceso de indexación utilizado, no admite archivos en formato XML de forma nativa. En contraste, trabajar con esquemas basados en XML, como los que se exponen mediante el protocolo de cosecha OAI-PMH, habría requerido una capa adicional de transformación para convertir dichos datos a un formato estructurado en JSON, compatible con la infraestructura implementada.

13. TRABAJOS FUTUROS Y RECOMENDACIONES

A partir de los resultados obtenidos y las limitaciones identificadas en el proyecto, se proponen las siguientes líneas de trabajo futuro, orientadas a fortalecer y extender la estrategia desarrollada:

- La arquitectura propuesta, puede adaptarse a otros conjuntos de datos abiertos, como los relacionados con datos gubernamentales o patrimonio cultural. Esto en consecuencia, de que, en la exploración de repositorios de datos abiertos en el país, existen iniciativas respecto a estas temáticas. Explorar estos contextos permitiría validar la versatilidad de la solución y su impacto en distintas áreas del conocimiento.
- Si bien la validación experimental de la estrategia se centró en Recursos Educativos Abiertos (REA) de tipo textual, es importante señalar que su aplicabilidad no se limita exclusivamente a este formato. Dado que la estrategia planteada, se basa en el análisis y enriquecimiento de metadatos mediante técnicas de inteligencia artificial, su diseño permite adaptarse a otros tipos de recursos, como videos, presentaciones interactivas y objetos virtuales de aprendizaje (OVAs). En efecto, lo que se evalúa no es el formato del recurso en sí, sino la estructura de sus metadatos, los cuales pueden ser tratados y enriquecidos semánticamente mediante la misma estrategia, siempre que estén disponibles o puedan ser generados a partir del contenido.
- Exploración de diversos tipos de REAs: las arquitecturas basadas en RAG no se limitan únicamente al procesamiento de fuentes textuales, sino que también pueden integrar datos provenientes de imágenes, videos y otros formatos multimedia. Una línea de investigación futura, consiste en aplicar estos modelos a REAs de tipo no textual, con el objetivo de analizar cómo sería posible generar recomendaciones automáticas para la descripción de metadatos en estos casos. Esto permitiría ampliar el alcance de la estrategia desarrollada y adaptarla a una mayor diversidad de recursos educativos.
- Articulación con políticas públicas educativas: este proyecto puede extenderse mediante su integración con iniciativas de política pública orientadas a fomentar la creación, curación y difusión de Recursos Educativos Abiertos (REAs) en el contexto nacional. Una línea de trabajo futura relevante consistiría en colaborar con entidades

gubernamentales y educativas para promover la adopción de estándares comunes de metadatos, estructuras bien definidas y modelos de interoperabilidad robustos. De esta forma, no solo se fortalecería el ecosistema de REAs, sino que se impulsaría una estrategia sostenible de educación abierta alineada con los principios de apertura de datos.

Como recomendaciones que presenta el proyecto, es posible recopilar las siguientes:

- Para responsables de políticas públicas en el contexto colombiano:
 - Impulsar la creación de lineamientos nacionales para la producción y publicación de REAs con metadatos normalizados e interoperables.
- Para los centros educativos del contexto colombiano:
 - Fomentar la adopción de formatos interoperables que faciliten el procesamiento y la reutilización de metadatos de Recursos Educativos Abiertos.
 - Facilitar espacios de formación y capacitación para docentes y bibliotecólogos en el uso de tecnologías de curación de datos y publicación de REAs.
 - Promover el uso de modelos de inteligencia artificial y herramientas de curación automatizada para mejorar la calidad de los metadatos en plataformas de REAs.
 - Se recomienda poner mayor énfasis en la calidad de los metadatos al momento de crear y publicar Recursos Educativos Abiertos (REA). La evidencia analizada sugiere que, a pesar de los avances en políticas de apertura y disponibilidad de datos, la falta de metadatos completos, coherentes y normalizados limita significativamente el descubrimiento, la reutilización y la interoperabilidad de los recursos. Esta situación afecta directamente los principios fundamentales de la apertura de datos, reduciendo su impacto potencial en contextos educativos. Por tanto, es fundamental que las instituciones y desarrolladores de REA adopten buenas prácticas en la generación de metadatos desde las etapas iniciales de diseño y publicación.

14. BIBLIOGRAFÍA

- Ahmed, U., Alexopoulos, C., Piangerelli, M., & Polini, A. (9 de 2024). BRYT: Automated keyword extraction for open datasets. *Intelligent Systems with Applications*, 23, 200421. doi:10.1016/j.iswa.2024.200421
- Alemu, G. (2016). A Theory of Metadata Enriching and Filtering: Challenges and Opportunities to Implementation. *Qualitative and Quantitative Methods in Libraries (QQML)*, 5, 311-334.
- Alsayed, M. H. (2012). Knowledge Sharing in Collaborative Research Activities. *Journal of Information Systems Research and Innovation*, 1-8.
- Arslan, M., Munawar, S., & Cruz, C. (1 de 2024). Political Events using RAG with LLMs. *Procedia Computer Science*, 246(C), 5027-5035.
- Azure. (2024). *Microsoft is a Leader in the 2024 Gartner® Magic Quadrant™ for Cloud AI Developer Services*. Recuperado el May de 2025, de Azure: <https://azure.microsoft.com/en-us/blog/microsoft-is-a-leader-in-the-2024-gartner-magic-quadrant-for-cloud-ai-developer-services/>
- Baker, T. (3 de 2012). Libraries, languages of description, and linked data: A Dublin Core perspective. *Library Hi Tech*, 30(1), 116-133. doi:doi.org/10.1108/07378831211213256
- Beard, J., McDonald, R., & Brisson, R. (2011). Islandora: A community-driven digital repository framework. *Code4Lib Journal*(14).
- Belagatti, P. (6 de February de 2024). *Linkedin*. Obtenido de Hybrid Search: The Next Frontier Beyond Vector Search!: <https://www.linkedin.com/pulse/hybrid-search-next-frontier-beyond-vector-pavan-belagatti-rmusc>

Berners-Lee, T. (July de 2006). *Linked Data*. Recuperado el February de 2024, de <https://www.w3.org/DesignIssues/LinkedData.html>

Berners-Lee, T., Hendler, J., & Ora, L. (2001). The semantic web: a brain for humankind. *16*(2), pp. 24-25. doi:10.1109/MIS.2001.920595

Bizer, C., Heath, T., & Berners-Lee, T. (2009). Linked Data - The Story So Far. *International Journal on Semantic Web and Information Systems*. doi:<https://doi.org/10.1145/3591366.3591378>

Bizer, C., Vidal, M.-E., & Skaf-Molli, H. (2018). Linked Open Data. (L. Liu, & M. Özsu, Edits.) *Encyclopedia of Database Systems*, 2096-2101. Obtenido de https://doi.org/10.1007/978-1-4614-8265-9_80603

Bizer, L., JKobilarov, A., & al., B. C. (2009). DBpedia - A crystallization point for the Web of Data. *Journal of Web Semantics*, 154-165.

Blei, D., Ng, A., & Jordan, M. (3 de 2003). Latent dirichlet allocation. *J. Mach. Learn. Res.*, *3*(null), 993-1022.

Botero, C., & Soto, J. (Mayo de 2025). *Fundación Karisma*. Obtenido de OE LATAM Nodo Regional Latinoamericano: <https://www.oelatam.org/que-sucede-en-latinoamerica/colombia/>

Capgemini Invent. (2024). *2024 Open Data Maturity Report*. Publications Office of the European Union. doi:10.2830/8656811

Caplan, P. (2003). *Metadata Fundamentals for All Librarians*. Chicago, UNITED STATES: ALA Editions. Obtenido de https://books.google.com.co/books?id=yt2863FismcC&printsec=frontcover&redir_esc=y#v=onepage&q&f=false

Cavar, D., & Zhang, C. (2024). *Semantic Similarities Using Classical Embeddings in Quantum NLP*.

CERN. (2020). Invenio Digital Library Framework. Obtenido de <https://invenio-software.org>

- Charalampidis, C., & Keramopoulos, E. (2018). Semantic Web user interfaces - A model and a review. *Data & Knowledge Engineering*, 115, 214-227. Obtenido de <https://doi.org/10.1016/j.datak.2018.04.003>
- Chen, Y., Liu, Y., & Fang, Y. (2020). Personalized Learning Path Recommendation Based on Knowledge Graph and BERT. *IEEE*, 8, 19019-19029. doi:10.1109/ACCESS.2020.2968686
- Clay, B., Bergman, H., Salim, S., Pergola, G., Shalhoub, J., & Davies, A. (4 de 2025). *Natural language processing techniques applied to the electronic health record in clinical research and practice - an introduction to methodologies* (Vol. 188). Pergamon.
- Crosas, M. (2011). The Dataverse Network®: An Open-Source Application for Sharing, Discovering and Preserving Data. *D-Lib Magazine*, 17. doi:10.1045/january2011-crosas
- Cubides, S., Chiappe, A., & Ramirez-Montoya, M.-S. (10 de 2024). The transformative potential of Open Educational Resources for teacher education and practice. *Open Learning: The Journal of Open, Distance and e-Learning*. doi:10.1080/02680513.2024.2409808
- Dakshit, S. (2024). Faculty Perspectives on the Potential of RAG in Computer Science Higher Education. In *Proceedings of the 25th Annual Conference on Information Technology Education (SIGITE '24)*, 1-6. doi:doi.org/10.1145/3686852.3686864
- Datos.gob.es. (January de 2024). *RAG - Retrieval Augmented Generation: La llave que abre la puerta de la precisión a los modelos del lenguaje* . Obtenido de datos.gob.es: <https://datos.gob.es/es/blog/rag-retrieval-augmented-generation-la-llave-que-abre-la-puerta-de-la-precision-los-modelos-del>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *NAACL-HLT*. Retrieved from <https://arxiv.org/abs/1810.04805>
- DublinCore. (s.f.). Recuperado el February de 2024, de <https://www.dublincore.org/specifications/lrmi/>

- Elias, M., Oelen, A., Tavakoli, M., Kismihok, G., & Auer, S. (2020). Quality Evaluation of Open Educational Resources. *Springer*, 410-415. doi:https://doi.org/10.1007/978-3-030-57717-9_36
- Esposito, C. R. (2016). A systematic review of supply chain knowledge management research: State of the art and research opportunities. *International Journal of Production Economics*, 276-292.
- Farzand Ali, A., & Fatima Warraich, D. (2020). Integration of Open Educational Resources Through Linked Data: Challenges and Benefits Review. *Library Philosophy and Practice (e-journal)*. Obtenido de <https://digitalcommons.unl.edu/libphilprac>
- Figueiredo, M. S. (2017). Managing Knowledge – The Importance of Databases in the Scientific Production. *Procedia Manufacturing*, 166-173.
- Foundation, H. (s.f.). Obtenido de <https://hewlett.org/strategy/open-education/>
- Garshol, L. (2004). Metadata? Thesauri? Taxonomies? Topic maps! Making sense of it all. *Journal of Information Science*, 30(4), 378-391.
- Giordano, D., Kavasidis, I., Spampinato, C., & Bamidis, P. (2011). Developing controlled Vocabularies for educational Resources Sharing: a Case Study. *Linked Learning@ESWC*.
- Giri, S., Banerjee, S., Bag, K., & Maiti, D. (2022). Comparative Study of Content-Based Phishing Email Detection Using Global Vector (GloVe) and Bidirectional Encoder Representation from Transformer (BERT) Word Embedding Models. *2022 First International Conference on Electrical, Electronics, Information and Communication Technologies (ICEEICT)*, 1-6.
- Gogni, V., & Bianco, M. (October de 2020). *Modelados de Tópicos. Clasificación no supervisada con LDA - Repositorio Digital UNC*. Obtenido de <https://rdu.unc.edu.ar/handle/11086/16847>

- Gov.co. (2024). *Iniciativa Datos Abiertos de Colombia 2024*. Recuperado el April de 2024, de <https://www.datos.gov.co/stories/s/Iniciativa-Datos-Abiertos-de-Colombia-2024/nvf3-jun6>
- GPTCache. (s.f.). *Bootcamp: temperature in chat*. Recuperado el May de 2025, de <https://gptcache.readthedocs.io/en/latest/bootcamp/temperature/chat.html>
- Gruber, T. (6 de 1993). A translation approach to portable ontology specifications. *Knowledge Acquisition*, 5(2), 199-220.
- Guo, J., Fan, Y., Pang, L., Yang, L., Ai, Q., Zamani, H., . . . Cheng, X. (11 de 2020). A Deep Look into neural ranking models for information retrieval. *Information Processing & Management*, 57(6), 102067. doi:10.1016/J.IPM.2019.102067
- Herrera-Cubides, J., Gaona-García, P., Montenegro-Marín, C., & Sánchez-Alonso, S. (3 de 2022). Improving OER descriptions to enhance their availability, reuse, and enrichment. *Education and Information Technologies*, 27(2), 1811-1839.
- Hielscher, M., Cantieni, A., & Hartmann, W. (2015). To share or not to share: Ist die Nutzung von OER-Austauschplattformen eine Frage der Kultur? *DeLFI 2015 - Die 13. e-Learning Fachtagung Informatik der Gesellschaft für Informatik e.V. (GI), München, 1.-4. September 2015*, 145-156. Obtenido de <https://dl.gi.de/handle/20.500.12116/2046>
- Holford, M. E. (2012). A semantic web framework to integrate cancer omics data with biological knowledge. *BMC Bioinformatics*.
- Huang, A. (2008). Similarity measures for text document clustering. *In Proceedings of the 6th New Zealand Computer Science Research Student Conference (NZCSRSC), New Zealand*.
- Hull, E., Reddy, S., & Tripp, L. (2014). Samvera: A collaborative platform for building repository solutions. *Digital Library Perspectives*, 30(4), 270–276.

- Huskova, N., Dikova, Y., Petrenko, T., & Bönisch, T. (2 de 2025). Improvement of data and metadata quality in catalysis research: A use case-driven methodology. *Catalysis Today*, 446, 115111.
- IBM. (2024). *What is ETL (Extract, Transform, Load)?* Obtenido de <https://www.ibm.com/think/topics/etl>
- ISO 25000. (2024). *Software Product Quality*. Obtenido de <https://iso25000.com/index.php/en/iso-25000-standards/iso-25012>
- Jatnika, D., Bijaksana, M., & Suryani, A. (1 de 2019). Word2Vec Model Analysis for Semantic Similarities in English Words. *Procedia Computer Science*, 157, 160-167.
- Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*. doi:10.1098/rsta.2015.0202
- Kherwa, P., & Bansal, P. (2017). Latent Semantic Analysis: An Approach to Understand Semantic of Text. *2017 International Conference on Current Trends in Computer, Electrical, Electronics and Communication (CTCEEC)*, 870-874.
- Koutsomitropoulos, D., & Solomou, G. (3 de 2018). A learning object ontology repository to support annotation and discovery of educational resources using semantic thesauri. *IFLA Journal*, 44(1), 4-22.
- Kushwaha, V., & Prabhakar, T. (2019). Harvesting metadata from Open Educational Resources for semantic annotation of online educational content. *Commonwealth of Learning (COL)*. Obtenido de www.iso.org/standard/60613.html
- Lagoze, C., Payette, S., Shin, E., & Wilper, C. (2005). Fedora: An architecture for complex objects and their relationships. *International Journal on Digital Libraries*, 6(2), 124–138.
- LAR. (2019). *Red de Repositorios de Acceso Abierto a la Ciencia*. Recuperado el 05 de 2025, de LA Referencia: <https://www.lareferencia.info/>

- Lewis, P., Oguz, B., Rinott, R., Riedel, S., & Schwenk, H. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *In NeurIPS*. Obtenido de <https://arxiv.org/abs/2005.11401>
- Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., & Stoyanov, V. (2021). RoBERTa: A Robustly Optimized BERT Pretraining Approach. *arXiv preprint arXiv:1907.11692*.
- Ludeña, X., Segarra-Faggioni, V., Romero-Pelaez, A., & Morocho-Yunga, J. (2024). Exploring Topics in Information Technology Open Educational Resources through the LDA Algorithm. *Latin-American Journal of Computing (LAJC)*, IX(1). doi:10.5281/zenodo.10402399
- Malkov, Y. A., & Yashunin, D. A. (2020). Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 824-836. doi:10.1109/TPAMI.2018.2889473
- Mathur, S., & Chhabra, A. (2024). Vector Search Algorithms: A Brief Survey. *2024 4th International Conference on Ubiquitous Computing and Intelligent Information Systems (ICUIS)*, 365-371. doi:10.1109/ICUIS64676.2024.10866377
- MEN. (2012). *Ministerio de Educación Nacional - Recursos Educativos Digitales Abiertos*. Bogotá D.C, Cundinamarca, Colombia: Graficando Servicios Integrados. Obtenido de <http://www.colombiaaprende.edu.co/reda/REDA2012.pdf>
- MEN. (2021). *Mas y Mejores Aprendizajes: Política Pública de Recursos Educativos*.
- Menzel, M. (2023). Developing a Metadata Profile for Higher Education OER Repositories. (D. Otto, G. Scharnberg, M. Kerres, & O. Zawacki-Richter, Edits.) *Distributed Learning Ecosystems : Concepts, Resources, and Repositories*, 263-278. Obtenido de https://doi.org/10.1007/978-3-658-38703-7_14
- Microsoft. (2024). *How to use Azure OpenAI embeddings with Azure AI Search*. Recuperado el May de 2025, de <https://learn.microsoft.com/en-us/azure/ai-services/openai/how-to/embeddings?tabs=console>

Microsoft Fields. (2024). *What is an index in Azure AI Search?* Recuperado el Mayo de 2025, de <https://learn.microsoft.com/en-us/azure/search/search-what-is-an-index#field-attributes>

Microsoft(Scoring). (2024). *Microsoft Learn*. Obtenido de Scoring Profiles: <https://learn.microsoft.com/en-us/azure/search/index-add-scoring-profiles>

Microsoft,Vector Search. (2024). *Vector search scoring and ranking in Azure AI Search*. Recuperado el May de 2025, de Microsoft Learn: <https://learn.microsoft.com/en-us/azure/search/vector-search-how-to-create-index?tabs=config-2024-07-01%2Crest-2024-07-01%2Cpush%2Cportal-check-index>

Microsoft-SemanticRanker. (2025). *Semantic ranking in Azure AI Search*. Obtenido de Microsoft Learn: <https://learn.microsoft.com/en-us/azure/search/semantic-search-overview>

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. *arXiv preprint arXiv:1301.3781*.

Minciencias. (2019). *Repositorio Nacional KUJANE*. Recuperado el Mayo de 2025, de <http://kujane.colciencias.gov.co/vufind>

Minciencias. (2022). *Red Colombiana de Información Científica*. Obtenido de <https://redcol.minciencias.gov.co/>

Minciencias. (2022). *Red Colombiana de Información Científica*. Obtenido de <https://redcol.minciencias.gov.co/>

MinTIC. (2018). *Guía de Transformación de Datos Abiertos a Datos Abiertos Enlazados*. Ministerio de Tecnologías de la Información y las Comunicaciones de Colombia. Obtenido de <https://herramientas.datos.gov.co/sites/default/files/2020-11/Guia%20Linked%20Open%20Data.pdf>

MinTic. (2019). *Marco de interoperabilidad para Gobierno Digital*. Obtenido de https://lenguaje.mintic.gov.co/sites/default/files/archivos/marco_de_interoperabilidad_para_gobierno_digital.pdf

MinTic. (2022). *Guía de Estándares de Calidad e interoperabilidad de Datos Abiertos*.

Molavi, M., Tavakoli, M., & Kismihók, G. (6 de 2020). Extracting Topics from Open Educational Resources. *The European Conference on Technology-Enhanced Learning (EC-TEL)*. doi:<https://doi.org/10.48550/arXiv.2006.11109>

Nacer, H., & Aissani, D. (2014). Semantic web services: Standards, applications, challenges and solutions. *Journal of Network and Computer Applications*, 44, 134-151.

Navarrete, R., & Luján-Mora, S. (2015). Use of Linked Data to enhance Open Educational Resources. *IEEE*, 1-6. doi:10.1109/ITHET.2015.7218017

Nizon Deladoeulle, M., Stefánsson, B., Neukirchen, H., & Welsh, T. (2024). Towards Supporting Penetration Testing Education with Large Language Models: an Evaluation and Comparison. *2024 11th International Conference on Social Networks Analysis, Management and Security (SNAMS)*, 227–229. doi:10.1109/SNAMS64316.2024.10883774

Ochoa, X., & Duval, E. (2009, 12). Automatic evaluation of metadata quality in digital repositories. *International Journal on Digital Libraries*, 10(2), 67-91.

OER World Map. (2025, Mayo 1). Retrieved 2025, from OER World Map: <https://oerworldmap.org>

OKFN. (2004). *What is Open Data?* Recuperado el February de 2024, de <http://opendatahandbook.org/guide/en/what-is-open-data/>

OpenAI. (2024). *New embedding models and API updates*. OpenAI. Obtenido de <https://openai.com/index/new-embedding-models-and-api-updates/>

Osorio, L. A., Galvis, A., & Mariño, O. (2016). *Innova-TE 330: investigando la innovación con TIC en educación*. Universidad de los Andes, Facultad de Educación.

Ostendorff, M., Bourgonje, P., Berger, M., Moreno-Schneider, J., Rehm, G., & Gipp, B. (2019). Enriching BERT with Knowledge Graph Embeddings for Document Classification. *arXiv preprint arXiv:1909.08402*. Obtenido de <https://arxiv.org/abs/1909.08402>

- Patra, C., Giri, D., Nandi, S., Das, A., & Alenazi, M. (5 de 2025). Phishing email detection using vector similarity search leveraging transformer-based word embedding. *Computers and Electrical Engineering*, 124, 110403.
- Pennington, J., Socher, R., & Manning, C. D. (2014). GloVe: Global Vectors for Word Representation. *EMNLP*. Obtenido de <https://aclanthology.org/D14-1162/>
- Phillips, M., Zavalina, O., & Tarver, H. (2019). Using Metadata Record Graphs to Understand Digital Library Metadata. *Dublin Core Metadata Initiative*, 49-58. Obtenido de <https://doi.org/10.23106/dcmi.952141695>
- Piedra, N., Chicaiza, J., & Quichimbo, P. (2015). Integración Semántica de Recursos Educativos Abiertos cosechados con OAI-PMH. Proceso aplicado al servicio de búsqueda de OERs en la Red ESVIAL.
- Piedra, N., Chicaiza, J., López, J., Martínez, O., & Caro, E. (2010). An approach for description of Open Educational Resources based on semantic technologies. *IEEE EDUCON 2010 Conference*, 1111-1119.
- Pinecone. (2025). *Hierarchical Navigable Small Worlds (HNSW)*. Obtenido de <https://www.pinecone.io/learn/series/faiss/hnsw/>
- Raval, P., & Bhaidasna, H. (2024). A Review of Extracting Metadata from Scholarly Articles using Natural Language Processing (NLP). *2024 3rd International Conference on Automation, Computing and Renewable Systems (ICACRS)*, 1355-1359.
- re3data.org. (s.f.). *Registry of Research Data Repositories*. doi:<https://doi.org/10.17616/R3D>
- Research, G. F. (s.f.). *OER World Map*. (German Federal Ministry of Education and Research) Obtenido de OER World Map: <https://oerworldmap.org/#description>
- Romero-Ariza, M., Abril Gallego, A., Quesada Armenteros, A., & Rodríguez Ortega, P. (2023). OER interoperability educational design: enabling research-informed improvement of public repositories. *Frontiers in Education*, 8. Obtenido de <https://www.frontiersin.org/articles/10.3389/feduc.2023.1082577>

- Romero-Pelaez, A., Segarra-Faggioni, V., & Alarcon, P. (10 de 2018). Exploring the provenance and accuracy as metadata quality metrics in assessment resources of OCW repositories. *ACM International Conference Proceeding Series*, 292-296.
- Rouzbeh Meymandpour, J. G. (2016). A semantic similarity measure for linked data: An information content-based approach. *Knowledge-Based Systems*.
- Rudasill, L., & Dorta-Duque, M. (2013). *Open Access and Digital Libraries: Social Science Libraries in Action*. Strauss GmbH, Mörlenbach, Germany: De Gruyter Saur.
- Sajja, S., Kohli, A., Krishnaswamy, K., & Joshi, A. (2024). Leveraging Domain-specific Language Models for Semantic Retrieval in Educational. *arXiv preprint arXiv:2505.04916*. Obtenido de <https://arxiv.org/abs/2505.04916>
- Sheikh, A., Zahra, A., & Richardson, J. (5 de 2022). Scholarly open access journals in medicine: A bibliometric study of DOAJ. *The Journal of Academic Librarianship*, 48(3), 102516.
- Simao De Deus, W., & Francine Barbosa, E. (7 de 2020). The Use of Metadata in Open Educational Resources Repositories: An Exploratory Study. (págs. 123-132). Institute of Electrical and Electronics Engineers Inc.
- Smith, M., Bass, M., McClellan, G., Tansley, R., Barton, M., Branschovsky, M., & Walker, J. H. (2003). DSpace: An open source dynamic digital repository. *D-Lib Magazine*, 9(1). Obtenido de <https://doi.org/10.1045/january2003-smith>
- Society, M. P. (2024). *Berlin Declaration on Open Access to Knowledge in the Sciences and Humanities*. Obtenido de <http://oa.mpg.de/berlin-prozess/berliner-erklarung/> .
- SouthindusLabs. (August de 2021). *ETL - Foundation of Data-Driven Business*. Recuperado el 2025, de <https://www.southindus.com/etl-foundation-of-data-driven-business>
- Swan, A., & Unesco. (2012). *Policy guidelines for the development and promotion of open access*. United Nations Educational, Scientific, and Cultural Organization. Obtenido de <https://unesdoc.unesco.org/ark:/48223/pf0000215863>

- Tansley, R., Bass, M., Stuve, D., & Choudhury, S. (2001). EPrints: A software platform for institutional repository development. *Ariadne*(29).
- Tarver, H., Phillips, M., & Zavalina, O. (2020). Exploring the Utility of Metadata Record Graphs and Network Analysis for Metadata Quality Evaluation and Augmentation. *International Journal of Metadata, Semantics and Ontologies*, 14(2), 112-123. doi:<https://doi.org/10.1504/IJMSO.2020.10030296>
- Tavakoli, M., Mirette, E., Gábor, K., & Sören, A. (2021). Metadata Analysis of Open Educational Resources. In LAK21: 11th International Learning Analytics and Knowledge Conference (LAK21). *Association for Computing Machinery*, 1, 626–631. doi:<https://doi.org/10.1145/3448139.3448208>
- Toledo, A. (3 de 2017). *Open access and OER in Latin America: A survey of the policy landscape in Chile, Colombia and Uruguay*. (C. Hodgkinson-Williams, & P. Arinto, Edits.) Cape Town & Ottawa: Adoption and impact of OER in the Global South. Obtenido de <https://doi.org/10.5281/zenodo.1094840>
- Toledo, A. (2018). Acceso abierto y REA en América Latina: un estudio sobre el panorama de las políticas en Chile, Colombia y Uruguay. *Cape Town: Research on Open Educational Resources for Development*. doi:<https://doi.org/10.5281/zenodo.1240157>
- UNESCO. (2002). *Forum on the Impact of Open Courseware for Higher Education in Developing Countries Final report*. Obtenido de <https://unesdoc.unesco.org/ark:/48223/pf0000128515>
- UNESCO. (2019). *Recomendación sobre los Recursos Educativos Abiertos (REA)*. Recuperado el February de 2024, de <https://www.unesco.org/es/legal-affairs/recommendation-open-educational-resources-oer>
- Valiente, M., Sicilia, M., Garcia-Barriocanal, E., & Rajabi, E. (10 de 2015). Adopting the metadata approach to improve the search and analysis of educational resources for online learning. *Computers in Human Behavior*, 51, 1134-1141.

W3C. (25 de February de 2014). *Resource Description Framework (RDF): Concepts and Abstract Syntax*. Recuperado el 2024, de <https://www.w3.org/TR/rdf11-concepts/>

Wesolek, A., Lashley, J., & Langley, A. (2018). *OER : a field guide for academic librarians*. Pacific University Press.

Witten, I. H., & Bainbridge, D. (2003). Greenstone: Open-source digital library software. *D-Lib Magazine*, 9(10).

Yu, D., & Xiang, B. (9 de 2023). Discovering topics and trends in the field of Artificial Intelligence: Using LDA topic modeling. *Expert Systems with Applications*, 225, 120114.

Zhang, X. (2017). MMKG: An approach to generate metallic materials knowledge graph based on DBpedia and Wikipedia. *Computer Physics Communications*, 98-112.