





INVESTIGACIÓN __X__

DESARROLLO DE UN ROBOT ORUGA EN IMPRESIÓN 3D PARA EL CONTROL DE CAMINOS ENTRE SURCOS DE CULTIVOS DE BARRERA VEGETAL CON CAMINOS IRREGULARES

Autor

Gerson David Cruz Capador

Director/Tutor

Andrés Leonardo Jutinico PhD.

Co-Director/Tutor

Henry Borrero Guerrero PhD.

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS
Maestría en Ciencias de la Información y las Comunicaciones
Énfasis en Teleinformática
Bogotá, Colombia
mayo de 2026

Contenido

Resumen	5
ABSTRACT	6
1. Introducción	7
1.1 Planteamiento del problema	8
1.2 Justificación	8
1.3 Objetivos	10
1.3.1 Objetivo general	10
1.3.2 Objetivos específicos	10
1.4 Estado del arte	11
1.4.1 Agricultura de precisión y robótica agrícola terrestre	11
1.4.2 Navegación entre surcos basada en visión artificial	12
1.4.3 LiDAR, fusión sensorial y navegación local sin dependencia estricta de GNSS	14
1.4.4 Representación del entorno y navegación en campos semiestructurados ..	15
1.4.5 Control de trayectoria, deslizamiento y vehículos tipo oruga	16
1.4.6 Arquitectura ROS 2 e integración de procesos	17
1.4.7 Síntesis crítica y brecha de investigación	17
1.5 Marco teórico	18
1.5.1 Agricultura de precisión	18
1.5.2 Requisitos de operación en entornos agrícolas semiestructurados	20
1.5.3 Robótica móvil agrícola terrestre	21
1.5.4 Plataforma tipo oruga, tracción diferencial y restricciones no holonómicas ..	21
1.5.5 Interacción suelo-oruga y modelado del deslizamiento	23
1.5.6 Sensórica para navegación local: LiDAR - IMU	24

1.5.6.1	LiDAR como sensor geométrico lateral	25
1.5.6.2	IMU para actitud, estabilidad y corrección de orientación.....	26
1.5.7	Fusión sensorial y estimación de estado	26
1.5.8	Navegación autónoma entre surcos y seguimiento de trayectoria local	27
1.5.9	Control reactivo, control discreto y decisión secuencial	29
1.5.10	Formulación Markoviana del control de camino	29
1.5.11	Arquitectura ROS 2 para integración percepción-decisión-actuación.....	31
1.5.12	Prototipado rápido, impresión 3D y sistemas embebidos.....	32
Referencias		38

RESUMEN

Desde su descubrimiento, la práctica de la agricultura permitió que el hombre lograra radicarse en zonas específicas y asegurar un elemento vital para la supervivencia como lo son los alimentos, hoy eso no ha cambiado y sigue siendo la agricultura el medio más usado para obtenerlo (Narváez et al., 2017).

Es evidente que se requieren opciones que reduzcan los impactos perjudiciales y aseguren la producción de la tierra mediante una agricultura sustentable. Por ello, la incorporación de tecnologías, especialmente la robótica, brindan soluciones atractivas como la automatización de labores reiterativas, posibilitar el funcionamiento constante y reasignar los recursos humanos en sectores más estratégicos de la administración agrícola. Este tipo de sistemas también potencian la sostenibilidad al maximizar la utilización de recursos tales como el agua, el uso de pesticidas y fertilizantes, disminuir los desechos y reducir el impacto en el medio ambiente (Papadopoulos et al., 2024).

Este trabajo presenta el diseño y construcción de un robot móvil tipo oruga de tracción diferencial que navegue de forma autónoma a través de surcos de barrera vegetal, implementando un sistema de percepción compuesto por un LiDar para la medición de las distancias laterales, una IMU para estimación de actitud y una cámara para validación visual. Se propone una estrategia de control para los procesos de decisión y una gestión de procesos a través de ROS 2.

ABSTRACT

Since its emergence, agricultural practice has enabled human beings to settle in specific areas and secure a vital element for survival: food. Today, this remains unchanged, as agriculture continues to be the most widely used means of obtaining it (Narvaez et al., 2017).

It is evident that alternatives are required to reduce harmful impacts and ensure land productivity through sustainable agriculture. Therefore, the incorporation of technologies, particularly robotics, offers attractive solutions, such as the automation of repetitive tasks, the possibility of continuous operation, and the reallocation of human resources to more strategic areas of agricultural management. These systems also enhance sustainability by optimizing the use of resources such as water, pesticides, and fertilizers, reducing waste, and minimizing environmental impact (Papadopoulos et al., 2025).

This work presents the design and construction of a differential-drive tracked mobile robot capable of autonomously navigating through vegetative barrier furrows. The proposed system implements a perception architecture composed of a LiDAR sensor for lateral distance measurement, an IMU for attitude estimation, and a camera for visual validation. A control strategy is proposed for decision-making processes, along with process management through ROS 2.

1. INTRODUCCIÓN

En la actualidad el desarrollo de la agricultura continúa siendo un proceso esencial para el sostenimiento de la sociedad, Según la Organización de las Naciones Unidas para la Alimentación y la Agricultura (FAO) se anticipa que para el año 2050 la demanda de alimentos aumente en un 50% debido al crecimiento de la población (FAO, 2018; OCDE-FAO, 2021). Adicionalmente se espera según los objetivos de desarrollo sostenible de la Organización de las Naciones Unidas (ONU), particularmente el segundo objetivo, que para el 2030 se pueda garantizar sistemas de producción alimentaria sostenibles, capaces de adaptarse al cambio climático y que puedan contribuir de manera positiva en la conservación y mantenimiento de los ecosistemas (Naciones Unidas, s.f.).

En este contexto, la agricultura de precisión emerge como una solución oportuna que fortalece las metodologías de producción agrícola convencionales mediante el uso de tecnologías actuales como las comunicaciones, el análisis de datos, los sistemas de control inteligente y la robótica móvil. Actualmente los robots tienen la capacidad de planificar operaciones de cobertura total, identificar surcos de cultivos, eludir obstáculos de manera autónoma en terrenos de cultivo y transmitir información de producción y toma de decisiones entre el ser humano y la máquina. Adicionalmente, los robots de campo emplean sensores avanzados y sistemas de visión artificial para llevar a cabo tareas tales como el reconocimiento de objetivos, la predicción de la producción, la toma de decisiones sobre tareas específicas del campo. Los robots pueden adaptarse a diversas tareas y entornos agrícolas a nivel de ejecución mediante la orientación precisa, la operación flexible y la interacción humano-robot (Bechar et al., 2016).

A continuación se presenta el desarrollo de un robot móvil tipo oruga impreso en 3D, que tiene la capacidad de hacer recorridos de manera autónoma a través de surcos vegetales implementando un sistema de percepción, un control inteligente y una integración ROS 2 para la comunicación entre procesos entre la etapa de percepción y la etapa de control, aportando un desarrollo innovador para aplicaciones de agricultura de precisión en terrenos difíciles como los que encontramos en el contexto colombiano.

1.1 PLANTEAMIENTO DEL PROBLEMA

En el contexto de la agricultura de precisión, y a partir de los hallazgos de investigaciones recientes, es evidente que la implementación de robots móviles equipados con sistemas de percepción y habilidades de navegación autónoma optimiza las condiciones y procesos en la producción agrícola, abarcando desde las tareas de monitoreo e identificación de plagas, la correcta administración de agua, fertilizantes y pesticidas, hasta la gestión de residuos. No obstante, la mayoría de los robots diseñados para dichas tareas se fundamentan en estructuras con ruedas o el uso de drones, cuyas prestaciones se ven restringidas cuando se encuentran en entornos abiertos que presentan desafíos significativos como caminos irregulares, suelos inestables, maleza y obstáculos naturales, pendientes pronunciadas, entre otros, lo que resulta en un desempeño deficiente y dificultades de movilización para el robot (Bakken, Moore, & From, 2019).

Conforme a lo anterior, una opción viable es la implementación de robots móviles tipo oruga, los cuales presentan un desempeño superior en este tipo de circunstancias, proporcionando una mayor estabilidad, una mejor tracción y una disminución en el deslizamiento lateral debido al incremento en el área de contacto con el suelo. Además, su configuración le permite enfrentarse a surcos que presenten pendientes pronunciadas y surcos irregulares sin perder la trayectoria a seguir (Corradini, 2023).

1.2 JUSTIFICACIÓN

La agricultura de precisión ha señalado su relevancia en el campo de la automatización de procesos en aplicaciones como la navegación de surcos, el control y la supervisión de cultivos (Mulla & Khosla, 2017; Avila & Barbosa, 2025). Sin embargo, los autómatas agrícolas se han diseñado mediante ruedas o estructuras comerciales, lo que aumenta el rubro de inversión y limita su operación en terrenos diversos muchas veces irregulares y abandonados por la naturaleza misma. (Cisternas et al., 2020; Padhiary, Kumar & Sethi, 2024).

Con lo anterior, se presenta el diseño y fabricación mediante impresión 3D un robot tipo oruga de tracción diferencial que navega de forma autónoma por los distintos tipos de terrenos que

podemos encontrar en cultivos; para facilitar la creación de estructuras modulares y livianas se usó la impresión 3D y el corte láser, tecnología adaptable a las distintas geometrías de los terrenos de los surcos y los requisitos de carga útil, esta es una diferencia significativa que no ofrecen las plataformas comerciales. (Sharma, Pandey & Mondal, 2023).

Además de esto, una vez diseñada e impresa la estructura mecánica, se instaló la instrumentación compuesta de un sistema embebido, una unidad de medición inercial -IMU- para la estimación de actitud y el componente Light Detection and Ranging -LiDAR- utilizado, para nuestro caso, en la medición de las distancias laterales en las barreras vegetales. Lo anterior, garantizará un sistema reactivo que interpretará su entorno (territorio) sin subordinarse a un Global Navigation Satellite System (GNSS) o a una infraestructura externa, permitiéndose su operatividad en invernaderos, parcelas con dosel denso y caminos irregulares.

El cerebro de la estrategia de control se basa en el enfoque Markov Decision Process (MDP) esta estrategia aporta dos aspectos clave:

1. Al tomar las decisiones óptimas que se basan en el “estado actual” del autómata y la recompensa por mantenerse centrado originan la robustez ante la irregularidad de terreno y el ruido sensorial.
2. Bajo las políticas markovianas se pueden realizar los precomputos o entrenamientos fuera de línea -off-line- y su ejecución en tiempo real con recursos limitados (Liu et al., 2023; Patle et al., 2019) lo que genera su simplicidad de implementación en plataformas de baja potencia.

De acuerdo a lo expuesto esta solución de robot tipo oruga impreso en 3D para la Agricultura de Precisión no solo cierra las brechas entre diseños mecánicos y políticas de control avanzadas validadas en pruebas de campo, sino que con ello se entrega de un prototipo funcional y de bajo costo.

1.3 OBJETIVOS

1.3.1 Objetivo general

Desarrollar un robot tipo oruga de tracción diferencial fabricado mediante impresión 3D, que permita realizar control de camino entre los surcos de un cultivo con barrera vegetal.

1.3.2 Objetivos específicos

- Construir un robot tipo oruga a partir de impresión 3D que recorra caminos irregulares.
- Implementar la instrumentación electrónica, el sistema de procesamiento de información, el sistema de percepción, el sistema de almacenamiento de energía y el sistema de actuación que le permita al robot realizar control reactivo.
- Implementar una estrategia de control Markoviano que le permita al robot hacer seguimiento de la barrera vegetal y realizar maniobras de control de camino entre filas de un cultivo.
- Validar el sistema robótico desarrollado mediante pruebas de concepto, que incluyan la comparación con al menos otra técnica de control.

1.4 ESTADO DEL ARTE

1.4.1 Agricultura de precisión y robótica agrícola terrestre

Entre 2020 y 2026 la agricultura de precisión ha evolucionado desde la adquisición de datos hacia ecosistemas integrados en los que sensores, comunicaciones, análisis de información, actuación robótica y toma de decisiones se articulan para intervenir el cultivo de manera localizada. Cisternas et al. (2020) muestran que las implementaciones de agricultura de precisión se apoyan en sensores remotos, sensores proximales, sistemas de posicionamiento y análisis de datos, pero también evidencian que la selección tecnológica sigue dependiendo del tipo de cultivo, la cantidad de producción y las condiciones económicas para su adopción. De forma complementaria, Rejeb et al. (2024) identifican un crecimiento sostenido de la investigación en agricultura de precisión y organizan sus beneficios alrededor del uso eficiente de insumos, la mejora de productividad, la reducción de impactos ambientales y la automatización de operaciones. Para este trabajo, estas revisiones permiten ubicar el robot propuesto no como un dispositivo aislado, sino como una solución física de intervención y monitoreo dentro de un sistema agrícola digital.

La robótica agrícola presenta una dificultad adicional frente a otras aplicaciones de robótica móvil: el entorno no es ideal y constante, cambia con el crecimiento de la planta, presenta oclusiones, suelos blandos, maleza, pendientes, irregularidades y obstáculos naturales. Fountas et al. (2020) revisan robots agrícolas para operaciones de campo y destacan que el diseño debe resolver simultáneamente desplazamiento, percepción, seguridad, actuación y control. Xie et al. (2022) complementan esta visión al revisar sensores y actuadores usados en robots agrícolas, señalando la importancia de combinar sensores exteroceptivos, sensores propioceptivos y mecanismos de actuación adecuados al terreno. En la misma línea, Montalvo-Romero et al. (2023) señalan que los sistemas agrotecnológicos pueden apoyar la agricultura tradicional siempre que sean adaptables, asequibles y pertinentes para el contexto rural. Esta condición resulta especialmente importante para la tesis, porque el prototipo busca una solución de bajo costo, fabricable mediante impresión 3D y orientada a caminos agrícolas irregulares.

El desarrollo de plataformas terrestres autónomas todo terreno ha ganado relevancia porque muchas tareas agrícolas no pueden depender exclusivamente de drones o vehículos de ruedas convencionales. Padhiary et al. (2024) revisan los vehículos autónomos todoterreno en agricultura de precisión y resaltan su potencial para monitoreo, transporte, aplicación de insumos y operación en terrenos de difícil acceso. Esta línea justifica el uso de una plataforma tipo oruga: el incremento del área de contacto con el suelo mejora la tracción, reduce la presión sobre el terreno y ofrece mayor estabilidad en superficies blandas o con obstáculos. La revisión de Sharma et al. (2023) sobre robots móviles también respalda la pertinencia de plataformas adaptables y modulares, mientras que la revisión de Béchar y Vigneault (2016) conserva vigencia al mostrar que los robots agrícolas deben entenderse como sistemas compuestos por locomoción, percepción, manipulación, energía y control, no como simples vehículos motorizados.

1.4.2 Navegación entre surcos basada en visión artificial

Bakken et al. (2019), quienes propusieron un enfoque de aprendizaje extremo a extremo para el seguimiento de filas de cultivo mediante imágenes RGB. Aunque el trabajo antecede al periodo principal de esta actualización, se conserva porque plantea un problema equivalente al de esta tesis: estimar una corrección de rumbo a partir de la percepción del surco. Su principal limitación es que las pruebas reportadas no cerraron completamente el lazo de control autónomo en campo, lo cual deja abierta la necesidad de validar algoritmos de percepción dentro de una arquitectura de navegación real. Esta limitación es relevante para el presente proyecto, porque la tesis no se restringe a clasificar imágenes o estimar ángulos, sino que busca integrar percepción, decisión y actuación sobre una plataforma física tipo oruga.

La navegación visual entre surcos ha continuado avanzando con métodos más robustos ante variaciones de iluminación, presencia de maleza y cambios fenológicos del cultivo. Shi et al. (2023) revisan métodos de detección de filas para navegación y guiado de maquinaria agrícola, y resaltan que la detección de surcos sigue siendo una tecnología base para el control de robots y vehículos autónomos en cultivos sembrados en surcos lineales. Zhang et al. (2024) actualizan este panorama desde la perspectiva de métodos de visión para operaciones de navegación terrestre, destacando segmentación, transformación de

perspectiva, extracción de líneas, aprendizaje profundo y combinaciones híbridas. Estos trabajos muestran que la visión artificial es útil por su bajo costo y riqueza semántica, pero también sensible a sombras, saturación, oclusiones, discontinuidades en las plantas y variación de color entre etapas de crecimiento.

En esta misma línea, de Silva et al. (2024) proponen un método de navegación visual en cultivos arables bajo condiciones variables, considerando hileras curvas, maleza, discontinuidades, sombras, diferentes estados de crecimiento y niveles de iluminación. El aporte de esta investigación es doble: por una parte, reconoce que las condiciones de campo reales son mucho más complejas que los escenarios controlados; por otra, demuestra la necesidad de diseñar algoritmos que puedan recuperarse cuando la estructura visual del surco se degrada. El trabajo de Abanay et al. (2025), incluido originalmente en el documento, plantea un Modelo de Transformación de Vista Superior para convertir imágenes de una cámara frontal en una representación superior en la que las hileras aparecen con menor distorsión de perspectiva. Esta solución es útil para ambientes estructurados como cultivos de fresa; sin embargo, su desempeño puede afectarse por pendientes, vibraciones, irregularidades del suelo y cambios de geometría del surco, lo que refuerza la conveniencia de no depender de un único sensor visual.

Gai et al. (2025) aportan una aproximación diferente al detectar hileras mediante Transformada Discreta de Fourier. Su hipótesis es que la regularidad espacial de los cultivos en hileras genera una firma espectral que puede ser explotada para estimar orientación y desviación lateral. El resultado reportado muestra que el procesamiento en el dominio de la frecuencia puede ser robusto frente a ciertas condiciones de iluminación y crecimiento, especialmente cuando el patrón de siembra mantiene periodicidad. No obstante, para el caso de barreras vegetales y caminos irregulares, la periodicidad puede romperse por maleza, discontinuidades, pérdida de plantas o curvatura del camino. Por esta razón, la tesis puede aprovechar el aprendizaje de estos métodos visuales como validación complementaria, pero su estrategia principal de control de camino se fundamenta en percepción geométrica lateral mediante LiDAR e información inercial.

1.4.3 LiDAR, fusión sensorial y navegación local sin dependencia estricta de GNSS

La dependencia de GNSS/RTK ha sido una solución frecuente en maquinaria agrícola de precisión, pero presenta limitaciones en invernaderos, zonas con dosel, parcelas pequeñas, corredores estrechos y áreas con multipath. Por ello, una tendencia fuerte del periodo 2020-2026 es el uso de percepción local basada en LiDAR, visión e IMU. Nehme et al. (2021) proponen seguimiento de estructuras con LiDAR para navegación autónoma en viñedos, aprovechando la geometría repetitiva de las hileras sin requerir un mapa GNSS detallado del campo. Abanay et al. (2022) desarrollan una navegación autónoma basada en LiDAR 2D para el robot AgriEco en invernaderos de fresa, demostrando que los escaneos laterales pueden guiar un vehículo agrícola entre filas y apoyar la transición al final del surco. Estos trabajos son especialmente cercanos a la tesis porque el LiDAR no se usa como sensor genérico, sino como herramienta para estimar distancia lateral y mantener el vehículo centrado respecto a estructuras vegetales.

La literatura reciente también evidencia que la robustez aumenta cuando se combinan sensores. Ban et al. (2024) proponen una fusión Cámara-LiDAR-IMU para extraer en tiempo real la línea de navegación entre hileras de maíz, integrando información visual, nube de puntos y actitud del vehículo. Posteriormente, Ban et al. (2025) profundizan en la fusión de cámara monocular y LiDAR 3D para extraer líneas de navegación bajo el dosel de maíz, un escenario particularmente desafiante por la oclusión y la variabilidad de la iluminación. Yao et al. (2025) presentan una navegación adaptativa para ambientes agrícolas no estructurados que combina localización basada en características estables con detección multisensorial de obstáculos. En conjunto, estas investigaciones respaldan la arquitectura sensorial de la tesis: LiDAR para geometría lateral, IMU para actitud y cámara como validación visual, evitando que el sistema dependa de una única fuente de información.

Fasiolo et al. (2023) revisan tecnologías de soporte para mapeo autónomo con robótica terrestre en agricultura y muestran que la navegación agrícola moderna requiere articular localización, mapeo, planeación, percepción y extracción de información agronómica. Fujinaga (2025) propone una navegación autónoma para robots agrícolas en ambientes de camas elevadas, combinando navegación por puntos de referencia y navegación entre

camas de cultivo. Aunque este último escenario difiere de los surcos de barrera vegetal, aporta una idea relevante: un robot agrícola puede alternar entre modos de navegación según la estructura del entorno. Para el prototipo de la tesis, esta idea se traduce en la posibilidad de distinguir entre seguimiento reactivo del corredor vegetal, corrección por desviación lateral y maniobras de recuperación cuando el robot se aproxima a límites físicos o pierde simetría de distancias.

1.4.4 Representación del entorno y navegación en campos semiestructurados

El trabajo de Emmi et al. (2021), propone una representación híbrida del entorno para mejorar la navegación autónoma en agricultura. Su enfoque divide el campo en lugares semánticos como cabecera, carril, callejón y puerta, y combina percepción con odometría para construir una representación topológica. Este aporte es importante porque muestra que el campo agrícola no necesita representarse siempre como un mapa métrico denso; en muchos casos, basta una representación semántica que capture transiciones relevantes para la tarea. En el contexto de esta tesis, donde el objetivo es mantener el robot dentro de un camino entre barreras vegetales, la representación del estado puede ser más compacta: centrado, desviación izquierda, desviación derecha, pérdida parcial de referencia u obstáculo. Esa simplificación es compatible con una formulación Markoviana y reduce la carga computacional del sistema embebido.

Las revisiones de planificación de movimiento en robots móviles también ayudan a delimitar el alcance del proyecto. Liu et al. (2023) clasifican la planeación en enfoques globales y locales, e identifican métodos clásicos, heurísticos, bioinspirados y basados en aprendizaje. Patle et al. (2019) ya habían mostrado que la selección de una estrategia depende del conocimiento del entorno, la dinámica del robot, los obstáculos y la necesidad de respuesta en tiempo real. En un robot de baja potencia, que opera en un corredor agrícola estrecho, no siempre se justifica un planificador global complejo; puede ser más apropiado un control local reactivo, interpretable y de bajo costo computacional. Esta lectura respalda el uso de estados discretos y políticas Markovianas para decidir acciones de corrección a partir de la percepción lateral e inercial.

1.4.5 Control de trayectoria, deslizamiento y vehículos tipo oruga

El control de robots agrícolas en terreno irregular no puede analizarse únicamente desde la geometría de la trayectoria; también debe considerar el deslizamiento, la pérdida de adherencia, la variación de carga y la deformabilidad del suelo. Corradini (2023), aborda el control basado en datos y la estimación de deslizamiento en vehículos agrícolas tipo oruga. La autora destaca que la odometría puede degradarse de forma importante en terrenos rugosos y espacios estrechos, por lo que la estimación y compensación del deslizamiento resultan fundamentales para mantener la trayectoria. Esta conclusión se conecta directamente con la tesis: al emplear tracción diferencial tipo oruga, el robot gana estabilidad y tracción, pero también debe enfrentar errores derivados del contacto suelo-oruga y de la diferencia entre velocidad comandada y desplazamiento real.

La literatura más reciente confirma que el control de vehículos oruga agrícolas sigue siendo un problema abierto. Liu et al. (2026) proponen un método de seguimiento de trayectoria para vehículos agrícolas tipo oruga basado en compensación de punto de mira sensible al deslizamiento. El trabajo combina estimación de deslizamiento mediante filtro de Kalman extendido, RTK-IMU y retroalimentación de velocidad de las orugas, con una estrategia de compensación del punto objetivo. Aunque dicho enfoque usa una instrumentación más compleja que la propuesta en esta tesis, su aporte es clave: muestra que el deslizamiento asimétrico de las orugas puede causar desviaciones significativas y que el controlador debe incorporar alguna forma de adaptación o corrección. Para un prototipo de bajo costo, una política Markoviana basada en estados de desviación y recompensas por centrado ofrece una alternativa más simple e interpretable frente a controladores de mayor complejidad computacional.

Los enfoques basados en aprendizaje por refuerzo y procesos de decisión de Markov han ganado espacio en navegación robótica, sobre todo para problemas con incertidumbre, obstáculos y decisiones secuenciales. Zhu y Zhang (2021) revisan el aprendizaje profundo por refuerzo aplicado a navegación de robots móviles y muestran su utilidad en evasión local de obstáculos, navegación sin mapa y toma de decisiones en entornos dinámicos. Sin embargo, para el presente trabajo no es necesario asumir una arquitectura profunda de aprendizaje por refuerzo: la formulación Markoviana puede emplearse de manera más transparente mediante estados discretos derivados de distancias laterales, actitud y

condiciones de seguridad, con acciones de corrección diferencial para mantener el robot centrado. Esta decisión metodológica aporta trazabilidad, facilita la implementación en hardware limitado y permite comparar el desempeño con otra técnica de control durante la validación experimental.

1.4.6 Arquitectura ROS 2 e integración de procesos

La integración de percepción, estimación de estado, decisión y actuación requiere una arquitectura de software modular. Macenski et al. (2022) describen ROS 2 como una evolución del ecosistema ROS orientada a sistemas robóticos modernos, con mejoras en comunicación distribuida, modularidad, calidad de servicio, escalabilidad y despliegue en aplicaciones reales. Portugal et al. (2025) analizan la adopción de ROS 2 en la comunidad robótica y muestran que su migración responde a necesidades de robustez, soporte para sistemas distribuidos y mejor adecuación a aplicaciones fuera del laboratorio. En la tesis, ROS 2 no debe entenderse únicamente como una herramienta de programación, sino como el mecanismo que ordena la comunicación entre nodos de adquisición sensorial, filtrado, estimación del estado, política de control y actuación de motores.

Esta arquitectura modular también facilita la validación experimental. Por ejemplo, el nodo de LiDAR puede publicar distancias laterales filtradas; el nodo de IMU puede entregar orientación o inclinación; el nodo de decisión Markoviana puede transformar el estado observado en una acción; y el nodo de actuación puede convertir esa acción en velocidades diferenciales para las orugas. La separación de responsabilidades permite sustituir sensores, comparar técnicas de control o registrar datos para análisis posterior sin rediseñar todo el sistema. Así, la tesis se alinea con una tendencia clara de la robótica contemporánea: desarrollar prototipos reproducibles, instrumentados y escalables, aunque sean de bajo costo.

1.4.7 Síntesis crítica y brecha de investigación

La revisión desarrollada para este trabajo permite identificar varias tendencias convergentes. Primero, la agricultura de precisión y la robótica agrícola avanzan hacia sistemas autónomos capaces de operar con percepción local y no solo con mapas o GNSS. Segundo, la navegación entre surcos ha sido abordada con visión artificial, LiDAR y fusión

multisensorial, pero los métodos puramente visuales pueden degradarse por iluminación, oclusión, maleza, discontinuidad del cultivo y cambios de perspectiva. Tercero, las plataformas tipo oruga son pertinentes para terrenos irregulares por su estabilidad y tracción, aunque introducen desafíos de deslizamiento y modelado. Cuarto, ROS 2 se consolida como una arquitectura adecuada para integrar procesos de percepción, decisión y control en sistemas robóticos reales. Quinto, los enfoques de control deben equilibrar precisión, interpretabilidad y costo computacional, especialmente cuando el hardware disponible es limitado.

En este marco, la contribución de la tesis se ubica en una zona intermedia entre soluciones agrícolas de alta complejidad y prototipos académicos de bajo costo: se propone un robot tipo oruga fabricado mediante impresión 3D, instrumentado con LiDAR, IMU y/o cámara, gestionado con ROS 2 y controlado mediante una política Markoviana para mantener el recorrido entre barreras vegetales. La originalidad no reside en presentar por separado un sensor, una oruga o un algoritmo, sino en integrarlos en una plataforma física capaz de enfrentar caminos irregulares entre surcos, con una estrategia de decisión interpretable, verificable y viable para contextos agrícolas donde la infraestructura externa, el presupuesto y las condiciones del terreno limitan el uso de soluciones comerciales.

1.5 MARCO TEÓRICO

El presente marco teórico sustenta el desarrollo de un robot móvil tipo oruga de tracción diferencial, fabricado mediante impresión 3D, orientado al control autónomo de camino entre surcos de cultivos con barrera vegetal. El marco teórico se organiza desde el contexto de la agricultura hacia el sistema robótico: primero se delimita la agricultura de precisión como contexto de aplicación; luego se formaliza el robot como plataforma móvil terrestre; posteriormente se definen las variables de percepción, estado, navegación y control; finalmente se integra la estrategia de decisión Markoviana con una arquitectura de ejecución basada en ROS 2.

1.5.1 Agricultura de precisión

La agricultura de precisión puede interpretarse como un sistema ciberfísico aplicado al manejo del cultivo: el estado físico del terreno y de las plantas se mide mediante sensores,

se transforma en información mediante procesamiento computacional y se convierte en acciones localizadas mediante actuadores o decisiones operativas. Cisternas et al. (2020) identifican que las implementaciones de agricultura de precisión se apoyan en sensores, tecnologías de información, métodos de selección tecnológica y marcos de decisión contextual. Desde una mirada técnica, esta definición implica un ciclo percepción-decisión-actuación semejante al de los robots autónomos: medir, estimar, decidir, actuar y validar la respuesta del sistema.

El valor técnico de la robótica agrícola no se limita a automatizar una tarea repetitiva. En campo, el robot debe operar en condiciones de variabilidad espacial y temporal: cambios de iluminación, heterogeneidad del suelo, deformación del terreno, humedad, maleza, pendiente, oclusiones vegetales y errores sensoriales. Fountas et al. (2020) muestran que los robots agrícolas de campo requieren sensores, actuadores y algoritmos capaces de adaptarse a tareas como deshierbe, cosecha, monitoreo y navegación. A su vez, los beneficios económicos y ambientales de las tecnologías agrícolas digitales dependen de la correspondencia entre tecnología, costo, escala de producción y restricciones reales del entorno (Papadopoulos et al., 2024).

Este enfoque también responde a un contexto global de presión sobre los sistemas agroalimentarios. La FAO (2018) plantea escenarios de demanda creciente hacia 2050, mientras que OECD/FAO (2021) presenta proyecciones agrícolas que refuerzan la necesidad de aumentar productividad con sostenibilidad. En la misma línea, el Objetivo de Desarrollo Sostenible 2 propone sistemas alimentarios resilientes y sostenibles (Naciones Unidas, s. f.). Desde la investigación bibliométrica, Rejeb et al. (2024) muestran que la agricultura de precisión ha consolidado una agenda de investigación alrededor de sensado, automatización, análisis de datos y toma de decisiones.

En esta tesis, la agricultura de precisión no se aborda como un marco general de digitalización del agro, sino como el dominio que justifica una plataforma móvil capaz de desplazarse autónomamente entre barreras vegetales. Esto introduce una condición crítica: la solución debe ser local, robusta y viable en escenarios donde no siempre se dispone de infraestructura externa, señal GNSS confiable o caminos perfectamente definidos. Por tanto, el marco teórico se orienta a un robot terrestre de percepción local, con capacidad de decisión en tiempo real y diseño mecánico compatible con suelos agrícolas irregulares.

1.5.2 Requisitos de operación en entornos agrícolas semiestructurados

Un cultivo en surcos puede considerarse un entorno semiestructurado. Existe una geometría dominante asociada con la disposición de las hileras o barreras vegetales, pero dicha geometría no es rígida: las plantas crecen de forma no uniforme, aparecen zonas de sombra, maleza, huecos, ramas, irregularidades del suelo y obstáculos. Emmi et al. (2021) proponen representar campos agrícolas mediante zonas semánticas, tales como carriles, cabeceras, callejones y puertas, mostrando que la navegación agrícola combina regularidad geométrica con interpretación contextual del entorno.

Para el caso de esta investigación, el espacio de navegación se puede modelar localmente como una región transitable delimitada por dos barreras vegetales. Si $d_L(k)$ y $d_R(k)$ representan las distancias laterales medidas hacia la barrera izquierda y derecha en el instante discreto k , entonces una medida primaria de centrado puede definirse como:

Error lateral relativo al centro del corredor

$$e_y(k) = \frac{d_R(k) - d_L(k)}{2}$$

donde $e_y(k)$ es el error lateral relativo al centro del corredor. Cuando $e_y(k)$ tiende a cero, el robot se encuentra aproximadamente centrado. Una versión normalizada, útil cuando el ancho del corredor varía, puede definirse como:

Error lateral normalizado

$$e_n(k) = \frac{d_R(k) - d_L(k)}{d_R(k) + d_L(k) + \varepsilon}$$

donde epsilon evita división por cero. Esta normalización es útil para comparar errores entre trayectos con diferentes anchos de surco. La variable no reemplaza una estimación completa de pose, pero sí proporciona una señal de control directa para navegación reactiva entre barreras vegetales.

En términos de requisitos de operación, el robot debe satisfacer al menos cuatro condiciones: mantener e_y dentro de un umbral admisible; evitar contacto con las barreras; conservar avance longitudinal; y responder ante pérdida temporal de lectura sensorial. Estos requisitos conectan la teoría de percepción local con la teoría de control y decisión,

porque la acción del robot no depende de un mapa global, sino del estado observable del corredor en cada instante.

1.5.3 Robótica móvil agrícola terrestre

La robótica móvil agrícola estudia robots capaces de desplazarse en ambientes de cultivo para realizar monitoreo, inspección, aplicación selectiva, transporte, asistencia o navegación autónoma. Bechar y Vigneault (2016) describen que un robot agrícola integra una plataforma móvil, sensores, unidad de control, actuadores y mecanismos de interacción con el entorno. En revisiones recientes, la robótica agrícola se asocia con reducción de costos, optimización de cosechas, disminución de impactos ambientales y adquisición de información de cultivo (Yépez-Ponce et al., 2023).

Desde el punto de vista de ingeniería, un robot agrícola terrestre debe analizarse como un sistema mecatrónico con restricciones acopladas. La selección de locomoción influye sobre la estabilidad; la estabilidad condiciona la calidad de percepción; la percepción afecta la estimación del estado; la estimación determina la acción de control; y la acción de control modifica nuevamente la interacción suelo-robot. Por tanto, el diseño de la plataforma no puede separarse de la estrategia de navegación. En terrenos irregulares, un sistema de control sofisticado puede perder desempeño si la locomoción produce deslizamientos no modelados, vibraciones excesivas o pérdida de contacto con el suelo.

Padhiary et al. (2024) revisan vehículos automáticos todo terreno para agricultura de precisión y destacan la relevancia de plataformas capaces de operar en condiciones de suelo variables. Esta observación es pertinente para la tesis porque el uso de orugas no es solo una decisión constructiva, es una hipótesis de diseño relacionada con tracción, estabilidad, distribución de carga y continuidad de movimiento en caminos irregulares.

1.5.4 Plataforma tipo oruga, tracción diferencial y restricciones no holonómicas

Una plataforma tipo oruga de tracción diferencial se comporta, en una primera aproximación, como un robot móvil no holonómico. El movimiento plano puede describirse mediante:

$q = [x, y, \theta]^T$, donde x e y representan la posición del centro de referencia del robot en el plano y θ su orientación respecto al marco global. Si v es la velocidad lineal longitudinal y ω la velocidad angular alrededor del eje vertical, la cinemática unicycle estándar se expresa como (Siegwart et al., 2011; Lynch & Park, 2017):

Cinemática plana del robot móvil

$$\dot{x} = v \cos(\theta), \quad \dot{y} = v \sin(\theta), \quad \dot{\theta} = \omega$$

Para una plataforma diferencial ideal, v y ω se relacionan con las velocidades tangenciales de las orugas izquierda y derecha, v_L y v_R , y con la separación efectiva entre orugas b :

Relación entre velocidades de orugas y movimiento del robot

$$v = \frac{v_R + v_L}{2}, \quad \omega = \frac{v_R - v_L}{b}$$

Si las velocidades se expresan a partir de motores o ruedas motrices equivalentes, con radio efectivo r y velocidades angulares ω_R y ω_L , entonces:

Conversión entre velocidad angular del motor/oruga y velocidad tangencial

$$v_R = r \omega_R, \quad v_L = r \omega_L$$

Estas ecuaciones son una idealización. En plataformas tipo oruga, el giro no ocurre mediante rodadura pura, sino mediante deslizamiento lateral controlado sobre el suelo. Por ello, el parámetro b debe entenderse como una separación cinemática efectiva, no necesariamente igual a la distancia geométrica entre centros de oruga. En la práctica, b puede calibrarse experimentalmente a partir de maniobras de giro y mediciones de yaw mediante IMU.

La restricción no holonómica principal establece que el robot no puede desplazarse lateralmente de forma directa respecto a su eje longitudinal. En forma ideal, dicha restricción se expresa como:

Restricción no holonómica ideal

$$-\sin(\theta)\dot{x} + \cos(\theta)\dot{y} = 0$$

En suelos agrícolas, esta restricción se relaja por deslizamiento. Sin embargo, mantenerla como supuesto de primer orden permite diseñar controladores y estimadores simples, y luego incorporar términos de error o factores de compensación por pérdida de adherencia.

1.5.5 Interacción suelo-oruga y modelado del deslizamiento

El deslizamiento es una de las diferencias fundamentales entre una plataforma tipo oruga real y un robot diferencial ideal. Corradini (2023) muestra que, en vehículos agrícolas tipo oruga, el seguimiento de trayectoria se ve afectado por la reducción de confiabilidad odométrica debida a terreno irregular, espacios de navegación estrechos e interacción suelo-vehículo. Por ello, la estimación o acomodación del deslizamiento se vuelve relevante para navegación segura.

Una forma técnica de introducir el deslizamiento en el modelo cinemático consiste en definir factores de efectividad $\eta_{L(K)}$ y $\eta_{R(K)}$ asociados con las velocidades efectivas de las orugas. Si v_L^C y v_R^C son las velocidades comandadas, las velocidades efectivas pueden representarse como:

Velocidades efectivas con deslizamiento

$$v_L^e(k) = \eta_L(k)v_L^C(k), \quad v_R^e(k) = \eta_R(k)v_R^C(k), \quad 0 \leq \eta_i(k) \leq 1$$

Sustituyendo en la cinemática diferencial se obtiene:

Velocidad lineal efectiva

$$v^e(k) = \frac{\eta_R v_R^C + \eta_L v_L^C}{2}$$

Velocidad angular efectiva

$$\omega^e(k) = \frac{\eta_R v_R^C - \eta_L v_L^C}{b}$$

Esta formulación no pretende reemplazar modelos de terramecánica de alta fidelidad, pero es útil para una tesis aplicada porque permite explicar por qué la trayectoria real difiere de la trayectoria comandada. La pérdida de efectividad puede provenir de suelo suelto, inclinación, saturación del motor, carga, vibración o contacto parcial de la oruga. Si $\eta_{L(k)}$ es diferente de $\eta_{R(k)}$, el robot puede girar aun cuando se haya comandado avance recto. Por esta razón, la IMU y la realimentación lateral mediante LiDAR resultan relevantes porque permiten detectar desviaciones que la odometría pura podría no representar.

En términos experimentales, el deslizamiento puede evaluarse indirectamente comparando el cambio de orientación estimado por encoders y el yaw de la IMU, o comparando el avance comandado con el avance observado. Una métrica simple para validar esta condición es el error angular acumulado:

Error de orientación entre IMU y odometría

$$E_{\theta}(k) = \theta_{IMU}(k) - \theta_{odom}(k)$$

Cuando E_{θ} crece de forma sostenida, la odometría basada en comando o encoder pierde confiabilidad. En ese caso, el control reactivo basado en distancias laterales puede funcionar como mecanismo de corrección local, aunque no sustituye completamente una estimación global de pose.

1.5.6 Sensórica para navegación local: LiDAR - IMU

Los sensores y actuadores son el puente físico entre el robot y el entorno agrícola. Xie et al. (2022) revisan tecnologías de sensado y actuación para robots agrícolas en ambientes no estructurados, destacando que la selección de sensores depende de la tarea, las condiciones de campo y la robustez requerida. Para esta tesis, la arquitectura sensorial se concentra en tres fuentes complementarias: LiDAR para geometría lateral, IMU para actitud y cámara para validación visual.

1.5.6.1 LiDAR como sensor geométrico lateral

El LiDAR permite medir distancias mediante haces láser y representa el entorno como un conjunto de mediciones polares. Para un LiDAR 2D, cada muestra puede expresarse como ρ_i y α_i , donde ρ_i es la distancia medida y α_i el ángulo del haz. La conversión al marco local del robot se obtiene mediante:

Conversión de medición LiDAR polar a coordenadas cartesianas

$$p_i = (x_i, y_i)^T = (\rho_i \cos(\alpha_i), \rho_i \sin(\alpha_i))^T$$

En navegación entre barreras vegetales, las nubes de puntos laterales pueden filtrarse por sector angular para separar mediciones hacia la izquierda y derecha del robot. Luego, d_L y d_R pueden estimarse mediante estadísticos robustos, por ejemplo, mediana o percentiles, evitando que puntos espurios de hojas, maleza o huecos dominen la decisión. El uso de LiDAR en navegación agrícola se observa en trabajos como Abanay et al. (2022), donde se emplea para navegación autónoma en invernadero, y Affonso et al. (2025), donde los escaneos se transforman para detectar líneas de cultivo y generar puntos de referencia para control.

Una opción más elaborada es ajustar líneas laterales usando mínimos cuadrados robustos o RANSAC, si la geometría del cultivo lo permite. Para una barrera aproximada por una recta $ax + by + c = 0$, la distancia perpendicular del origen del robot a esa línea es:

Distancia perpendicular desde el robot hasta una recta lateral

$$d = \frac{|c|}{\sqrt{a^2 + b^2}}$$

Este enfoque permite estimar tanto distancia lateral como orientación relativa de la barrera. Sin embargo, en barreras vegetales irregulares, un modelo de línea puede ser inestable; por ello, para una plataforma de bajo costo y control reactivo puede ser más robusto combinar distancia lateral local, ventana temporal y validación visual, en lugar de depender de una reconstrucción geométrica completa.

1.5.6.2 IMU para actitud, estabilidad y corrección de orientación

La unidad de medición inercial proporciona aceleraciones lineales y velocidades angulares, normalmente en los tres ejes. En esta tesis, la IMU es relevante por tres razones: estimar yaw o cambios de orientación, detectar inclinaciones del chasis y aportar información sobre vibraciones o perturbaciones. En un terreno agrícola, roll y pitch no son variables secundarias: una inclinación transversal puede modificar las distancias laterales medidas por el LiDAR, mientras que una inclinación longitudinal puede afectar tracción y lectura de avance.

Si $\omega_z(k)$ es la velocidad angular medida por el giróscopo alrededor del eje vertical, la orientación yaw puede integrarse de forma discreta como:

Integración discreta de orientación yaw

$$\theta(k) = \theta(k-1) + \omega_z(k)\Delta t$$

Esta integración acumula deriva; por ello, debe interpretarse como una estimación local de corto plazo o combinarse con otras fuentes sensoriales. Fan et al. (2025) señalan que los sistemas de fusión LiDAR-IMU-cámara se emplean precisamente porque cada sensor compensa limitaciones de los demás: el LiDAR aporta geometría, la cámara aporta textura o semántica, y la IMU aporta continuidad dinámica.

1.5.7 Fusión sensorial y estimación de estado

La fusión sensorial busca combinar mediciones parciales, ruidosas o asincrónicas para estimar variables de estado más útiles que las lecturas individuales. En este proyecto, la estimación no requiere necesariamente un SLAM global completo; basta con estimar un estado local suficiente para decidir acciones de corrección. Una representación mínima para el control de camino puede expresarse como:

Vector de estado local para navegación

$$\mathbf{x}_k = [e_y(k), e_n(k), e_\psi(k), d_L(k), d_R(k), \phi(k), \theta_p(k), c_s(k)]^T$$

donde e_y es error lateral, e_n es error lateral normalizado, e_ψ es error de orientación respecto al corredor, d_L y d_R son distancias laterales, ρ es roll, θ_p es pitch y c_s representa un indicador

de confianza sensorial. Esta variable de confianza puede derivarse de criterios como número de puntos LiDAR válidos, simetría lateral, saturación de distancia, consistencia temporal o coincidencia con validación visual.

En forma general, el problema de estimación de estado puede escribirse mediante un modelo discreto:

Modelo de evolución del estado

$$\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) + \mathbf{w}_k$$

Modelo de medición sensorial

$$\mathbf{z}_k = h(\mathbf{x}_k) + \mathbf{v}_k$$

Donde $\mathbf{u}_k$ representa comandos de velocidad, $\mathbf{z}_k$ el vector de mediciones, $\mathbf{w}_k$ el ruido de proceso y $\mathbf{v}_k$ el ruido de medición. Este formalismo es la base de filtros Bayesianos y filtros de Kalman extendidos cuando los modelos son no lineales. Thrun et al. (2005) presentan este marco probabilístico para robótica móvil, mientras que Fan et al. (2025) lo contextualizan en sistemas modernos de fusión LiDAR, IMU y cámara.

Para una implementación de bajo costo, la fusión puede iniciar con reglas determinísticas y filtrado temporal: promedio móvil, mediana, rechazo de valores atípicos y ponderación por confianza. La tesis puede formular una evolución gradual: una primera versión reactiva basada en LiDAR e IMU, y una extensión donde la cámara incremente o disminuya la confianza de navegación. Esta decisión es técnicamente defendible porque el objetivo no es construir un sistema SLAM universal, sino mantener control de camino en un corredor agrícola observable localmente.

1.5.8 Navegación autónoma entre surcos y seguimiento de trayectoria local

La navegación autónoma implica seleccionar acciones de movimiento que permitan alcanzar o mantener una condición deseada sin intervención humana directa. En navegación entre surcos, la referencia no necesariamente es una trayectoria global predefinida, sino el eje central del corredor vegetal. Por tanto, el problema puede formularse

como seguimiento de una trayectoria local implícita, definida por las barreras laterales detectadas.

El error de orientación e_ψ puede estimarse de varias formas. Si se ajustan líneas laterales al corredor, e_ψ corresponde al ángulo entre el eje longitudinal del robot y la dirección del corredor. Si no se ajustan líneas, una aproximación reactiva puede derivarse de la variación temporal del error lateral:

Aproximación del error angular a partir del cambio del error lateral

$$e_\psi(k) \approx \text{atan2}(e_y(k) - e_y(k-1), v(k)\Delta t)$$

Esta aproximación no reemplaza una estimación geométrica rigurosa, pero puede indicar si el robot se está acercando o alejando del centro del corredor. Para una plataforma con IMU, también puede compararse el yaw actual contra una orientación local suavizada del corredor, cuando dicha orientación se obtenga por LiDAR o visión.

Una ley de control reactiva continua, útil como línea base de comparación, puede definirse como:

Ley de control angular proporcional

$$\omega_c(k) = -K_y e_y(k) - K_\psi e_\psi(k)$$

Velocidad lineal modulada por seguridad y confianza

$$v_c(k) = v_0 g(c_s, |e_y|, |\phi|, |\theta_p|)$$

donde K_y y K_ψ son ganancias positivas, v_0 es una velocidad nominal y $g(\cdot)$ es una función que reduce la velocidad cuando disminuye la confianza sensorial, aumenta la inclinación o crece el error lateral. Esta formulación permite comparar una política Markoviana con una estrategia clásica de control proporcional o PID, cumpliendo el objetivo específico de validar el sistema frente a otra técnica de control.

La literatura reciente muestra diversas alternativas para navegación de robots agrícolas. Affonso et al. (2025) integran percepción, generación de puntos de referencia y control

predictivo para navegación entre cultivos; Gai et al. (2025) conectan detección visual robusta de hileras con control de seguimiento; y Liu et al. (2023) revisan técnicas de planificación de caminos para robots móviles. Estas referencias muestran que la navegación agrícola puede formularse desde diferentes niveles: detección local, seguimiento de referencia, planificación global o control óptimo. La tesis se ubica principalmente en el nivel de navegación local y control de camino.

1.5.9 Control reactivo, control discreto y decisión secuencial

En robótica móvil, el control reactivo se caracteriza por transformar información sensorial actual en acciones inmediatas, sin requerir planificación global extensa. Esta propiedad es adecuada para robots de bajo costo que operan en entornos donde el corredor se observa localmente y las decisiones principales son corregir hacia la izquierda, corregir hacia la derecha, avanzar, reducir velocidad o detenerse. Sin embargo, un control puramente reactivo puede oscilar si las mediciones son ruidosas o si no considera el efecto acumulado de sus acciones.

Para resolver esta limitación, el problema puede formularse como una decisión secuencial. En lugar de decidir únicamente por umbrales instantáneos, el robot selecciona acciones con base en un estado discreto que resume su condición de navegación. Esta idea conecta directamente con los Procesos de Decisión de Markov, cuya formulación clásica permite modelar decisiones en sistemas con incertidumbre, estados, acciones, transiciones y recompensas (Puterman, 1994; Sutton & Barto, 2018).

1.5.10 Formulación Markoviana del control de camino

Un Proceso de Decisión de Markov se define por la tupla $M = (S, A, P, R, \gamma)$, donde S es el conjunto de estados, A el conjunto de acciones, $P(s'|s,a)$ la probabilidad de transición hacia el estado s' al ejecutar la acción a en el estado s , $R(s,a,s')$ la recompensa inmediata y γ el factor de descuento. Para esta tesis, el MDP permite convertir el problema de mantenerse centrado entre barreras vegetales en un problema de selección de acciones de corrección.

El estado continuo x_k puede discretizarse en categorías operativas. Por ejemplo:

- Error lateral: izquierda crítica, izquierda moderada, centrado, derecha moderada, derecha crítica.
- Error angular: orientado a la izquierda, alineado, orientado a la derecha.
- Confianza sensorial: alta, media, baja.
- Condición de inclinación o estabilidad: segura, precaución, riesgo.

Así, un estado discreto puede expresarse como:

Discretización del estado para el MDP

$$s_k = \text{discretizar}(e_n(k), e_\psi(k), c_s(k), \phi(k), \theta_p(k))$$

El conjunto de acciones puede definirse de forma compatible con la tracción diferencial:

Conjunto discreto de acciones

$$A = \{a_{Ll}, a_{li}, a_0, a_{ld}, a_{LD}, a_{stop}\}$$

Cada acción se traduce en comandos de velocidad diferencial. Por ejemplo, avanzar corresponde a $v_R \approx v_L$; girar suavemente a una pequeña diferencia entre v_R y v_L ; y girar fuerte a una diferencia mayor o incluso a velocidades opuestas, si la mecánica lo permite. La recompensa debe reflejar el objetivo físico del sistema: mantenerse centrado, alineado, avanzar sin contacto y evitar acciones bruscas. Una función de recompensa posible es:

Función de recompensa

$$R_k = -\alpha|e_n(k)| - \beta|e_\psi(k)| - \lambda l_c - \mu l_b - \nu|\Delta\omega_c| + \rho l_a$$

donde α , β , λ , μ , ν y ρ son pesos de diseño. En la ecuación se usan l_c , l_b e l_a como abreviaturas de indicadores binarios de contacto, baja confianza sensorial y avance. Esta recompensa penaliza desviación lateral, desalineación, posible contacto con barreras, baja confianza sensorial y cambios bruscos de control, mientras premia el avance seguro. Con esta estructura, el problema de control no queda descrito solo en lenguaje cualitativo: se convierte en un criterio de optimización explícito.

La política π define qué acción seleccionar en cada estado:

Política óptima basada en valor de acción

$$\pi(s) = \arg \max_a Q(s, a)$$

La ecuación de optimalidad de Bellman para la función de valor acción se expresa como:

Ecuación de optimalidad de Bellman

$$Q^*(s, a) = \sum_{s'} P(s'|s, a) \left[R(s, a, s') + \gamma \max_{a'} Q^*(s', a') \right]$$

Si las probabilidades de transición se estiman mediante pruebas de campo o simulación, puede usarse iteración de valores o iteración de políticas. Si no se dispone inicialmente del modelo P , la política puede entrenarse o ajustarse mediante aprendizaje por refuerzo tabular, siempre que el espacio de estados sea pequeño y las acciones estén discretizadas. Zhu y Zhang (2021) revisan navegación robótica basada en aprendizaje por refuerzo profundo; sin embargo, para esta tesis resulta más defendible iniciar con MDP tabular o política discreta por su interpretabilidad, menor costo computacional y facilidad de validación en una plataforma embebida.

La ventaja técnica del enfoque Markoviano en este proyecto es que permite formalizar decisiones simples, pero robustas. En vez de afirmar que el robot “gira si está cerca de una barrera”, se define el estado, la acción, la recompensa, la transición y la política.

1.5.11 Arquitectura ROS 2 para integración percepción-decisión-actuación

ROS 2 es un middleware robótico diseñado para integrar componentes distribuidos mediante nodos, tópicos, servicios, acciones, parámetros, transformaciones y políticas de calidad de servicio. Macenski et al. (2022) explican que ROS 2 fue rediseñado para superar limitaciones de ROS 1 en despliegues modernos, incluyendo necesidades de modularidad, escalabilidad y uso en sistemas reales. Portugal et al. (2025) analizan la adopción de ROS 2 en la comunidad y muestran que el middleware responde a muchas expectativas de desarrollo, aunque su migración e implementación requieren decisiones cuidadosas.

Para esta tesis, ROS 2 puede conceptualizarse como la capa que sincroniza percepción, estimación, decisión y actuación.

La comunicación entre nodos debe considerar frecuencia de muestreo, latencia y pérdida de mensajes. Para sensores como LiDAR e IMU, los tópicos pueden requerir políticas QoS tipo `sensor_data`, donde se privilegia la información reciente frente a la entrega garantizada de datos antiguos.

Macenski et al. (2023) describen algoritmos modernos de navegación disponibles en ROS 2, especialmente en el ecosistema Nav2. Aunque esta tesis no necesariamente requiere usar todo Nav2, sí puede beneficiarse de su filosofía de arquitectura modular: separación entre percepción, estimación, planificación/control y ejecución. Esto facilita depuración, comparación de controladores y repetición experimental.

1.5.12 Prototipado rápido, impresión 3D y sistemas embebidos

El prototipado mediante impresión 3D permite diseñar piezas mecánicas iterables, adaptar geometrías al tamaño del sensor, modificar soportes, reducir costo inicial y fabricar componentes personalizados para pruebas. Rastegarpanah et al. (2024) revisan la relación entre robótica móvil e impresión 3D en contextos de manufactura aditiva, destacando retos de planeación, navegación y escalabilidad. Aunque su dominio no es específicamente agrícola, su aporte es pertinente para justificar la fabricación de plataformas móviles modulares mediante tecnologías aditivas.

En una tesis de robótica agrícola de bajo costo, la impresión 3D debe analizarse técnicamente, no solo como método de fabricación. Variables como rigidez, masa, resistencia al impacto, tolerancia dimensional, vibración, temperatura y facilidad de mantenimiento afectan directamente la calidad de locomoción y percepción. Por ejemplo, un soporte LiDAR flexible puede inducir variaciones angulares que se interpretan erróneamente como cambios del entorno; una base de IMU con vibración excesiva puede contaminar la estimación de yaw; y una estructura demasiado pesada puede aumentar consumo energético y deslizamiento.

Los sistemas embebidos agregan otra restricción: memoria, procesamiento, consumo y tiempo de respuesta. Por ello, el uso de MDP discreto y control reactivo es coherente con una plataforma de recursos limitados. En vez de ejecutar algoritmos computacionalmente

costosos de reconstrucción global, el robot puede operar con variables locales, discretización de estados y una política de control previamente calculada o ajustada offline.

2. DESARROLLO MECÁNICO

Para la construcción del robot, se ha escogido un esquema tipo oruga con el objetivo de que puede circular por terrenos irregulares y blandos, ya que las orugas reducen la presión de contacto y mantienen el vehículo estable en pendientes, lo que evita que el robot se entierre y se dañe o que dañe los cultivos. Para el proceso de diseño se tiene en cuenta 3 requerimientos principales:

1. El robot debe tener una estructura de fácil construcción y ensamblaje, con dimensiones que le permitan desplazarse con facilidad por terrenos irregulares como los que podemos encontrar en surcos de barrera vegetal.
2. Debe ser construido con materiales de fácil obtención.
3. Debe tener la posibilidad de implementar cambios y mejoras de rápida adaptación.

El diseño del robot se divide en tres secciones principales: la mecánica, electrónica y software.

2.1 SECCIÓN MECÁNICA

Materiales

Para la construcción del robot se eligió la impresión aditiva (fabricación por deposición fundida, FDM) como principal método de fabricación de las piezas estructurales del robot. La impresión 3D permite fabricar piezas de geometrías complejas y personalizadas sin incurrir a procesos costosos, maximizando los recursos en la fase de prototipado. Además, la impresión aditiva permite un proceso iterativo de diseño y prueba estructural, esencial en la robótica móvil como en este trabajo. Gracias a la facilidad con la que pueden alterarse y replicarse los modelos digitales, pueden analizarse rápidamente diferentes configuraciones



de chasis, sistemas de tracción y soportes mecánicos, mejorando continuamente el diseño. Esta capacidad de iteración ágil permite refinar aspectos importantes como el peso del robot, el encaje de piezas y módulos y la accesibilidad a la electrónica necesaria para su funcionamiento, mejorando la eficiencia del proceso de desarrollo y reduciendo los tiempos de ajuste del prototipo.

Finalmente, la impresión 3D permite elegir entre diversos materiales termoplásticos (ácido poliláctico (PLA), acrilonitrilo butadieno estireno (ABS), polietileno tereftalato glicol (PETG), etc.) en función de las propiedades mecánicas y térmicas deseadas; en el caso del robot, se optó por usar PLA con buena rigidez/peso y estabilidad dimensional para mejorar la eficiencia de desplazamiento y la resistencia estructural.

- Especificaciones técnicas del filamento
 - **Nombre del material:** Filamento PLA para impresión 3d
 - **Temperatura de impresión:** 190~220°C
 - **Velocidad de impresión:** 60~90mm/s
 - **Sugerencia resolución de capa:** 0.1~0.2mm
 - **Temperatura de cama:** No necesario
 - **Printing Raft:** No necesario
 - **Fuerza de Tensión** $\geq 60\text{MPa}$
 - **Fuerza flexible** $\geq 60\text{MPa}$
 - **Módulo de flexión** $\geq 2500\text{MPa}$
 - **Fuerza de impacto (IZOD, 23°C)** $\geq 3\text{KJ/m}$ (ASTM D256)"
 - **Elongation at Break** $\geq 3\%$
 - **Temperatura de distorsión** $\geq 55^\circ\text{C}$

2.2 DISEÑO DE LAS PARTES MECÁNICAS:

1. Eslabones de la oruga




El eslabón se concibió como una pieza enteriza y compacta, que favorece el ensamblaje entre eslabones que conforman la oruga. Para ensamble y guiado, el eslabón en su diseño se contempló alojamientos y ventanas que definen el paso del elemento de unión (pasador/eje), asegurando coaxialidad y un acoplamiento repetible entre eslabones



adyacentes. Se espera que esta solución permita un movimiento estable en la cadena y mejora la transferencia de tracción por parte del piñón que está sujeto al motor. Los aligeramientos internos (vacíos estratégicos en la zona media) disminuyen la cantidad de material aligerando el peso total de la oruga, sin comprometer la rigidez flexional del conjunto, de modo que el centro de masa del eslabón se mantenga próximo al plano de rodadura para estabilizar el contacto y reducir vibraciones en maniobras.

2. Engranaje con el motor

Piñón delantero - Vista frontal




Piñón delantero - Vista lateral



El piñón motriz de acoplamiento con el motor se diseñó como una pieza entera de 12 dientes, proporcionando un engrane estable con los eslabones de la oruga, la forma de diente del piñón fue definida con transiciones suavizadas mediante chaflanes para reducir el desgaste y favorecer un enganche adecuado en la progresión y un rodamiento más continuo sobre los eslabones. El acoplamiento al motor se solucionó mediante un cubo central apto para evitar el deslizamiento con el motor.

Posterior al proceso de fabricación, se debe verificar si existe alguna desalineación para implementar una corrección que evite al máximo vibraciones no deseadas y desgaste de la oruga o del piñón.

3. Ensamblaje principal



REFERENCIAS

- Abanay, A., Masmoudi, L., Benkhedra, D., El Amraoui, K., Lghoul, M., Jimenez, J.-G., & Moreno, F.-A. (2025). A transformation model for vision-based navigation of agricultural robots. *Cognitive Robotics*, 5, 140-151. <https://doi.org/10.1016/j.cogr.2025.03.002>
- Abanay, A., Masmoudi, L., El Ansari, M., Gonzalez-Jimenez, J., & Moreno, F.-A. (2022). LIDAR-based autonomous navigation method for an agricultural mobile robot in strawberry greenhouse: AgriEco Robot. *AIMS Electronics and Electrical Engineering*, 6(3), 317-328. <https://doi.org/10.3934/electreng.2022019>
- Affonso, F., Tommaselli, F. A. G., Capezzuto, G., Gasparino, M. V., Chowdhary, G., & Becker, M. (2025). CROW: A self-supervised crop row navigation algorithm for agricultural fields. *Journal of Intelligent & Robotic Systems*, 111, Article 28. <https://doi.org/10.1007/s10846-025-02219-2>
- Bakken, M., Moore, R. J. D., & From, P. (2019). End-to-end learning for autonomous crop row-following. *IFAC-PapersOnLine*, 52(30), 102-107. <https://doi.org/10.1016/j.ifacol.2019.12.505>
- Ban, C., Wang, L., Chi, R., Su, T., & Ma, Y. (2024). A Camera-LiDAR-IMU fusion method for real-time extraction of navigation line between maize field rows. *Computers and Electronics in Agriculture*, 223, Article 109114. <https://doi.org/10.1016/j.compag.2024.109114>
- Ban, C., Wang, L., Su, T., Chi, R., & Fu, G. (2025). Fusion of monocular camera and 3D LiDAR data for navigation line extraction under corn canopy. *Computers and Electronics in Agriculture*, 232, Article 110124. <https://doi.org/10.1016/j.compag.2025.110124>
- Birman, K., & Joseph, T. (1987). Exploiting virtual synchrony in distributed systems. In *Proceedings of the Eleventh ACM Symposium on Operating Systems Principles* (pp. 123-138). Association for Computing Machinery. <https://doi.org/10.1145/41457.37515>
- Béchar, A., & Vigneault, C. (2016). Agricultural robots for field operations: Concepts and components. *Biosystems Engineering*, 149, 94-111. <https://doi.org/10.1016/j.biosystemseng.2016.06.014>
- Cisternas, I., Velásquez, I., Caro, A., & Rodríguez, A. (2020). Systematic literature review of implementations of precision agriculture. *Computers and Electronics in Agriculture*, 176, Article 105626. <https://doi.org/10.1016/j.compag.2020.105626>
- Corradini, M. L. (2023). Data driven control and slip estimation for agricultural tracked vehicles. *Franklin Open*, 5, Article 100048. <https://doi.org/10.1016/j.fraope.2023.100048>
- de Avila, F. R., & Barbosa, J. L. V. (2025). Smart environments in digital agriculture: A systematic review and taxonomy. *Computers and Electronics in Agriculture*, 236, Article 110393. <https://doi.org/10.1016/j.compag.2025.110393>

- de Silva, R., Cielniak, G., & Gao, J. (2024). Vision based crop row navigation under varying field conditions in arable fields. *Computers and Electronics in Agriculture*, 217, Article 108581. <https://doi.org/10.1016/j.compag.2023.108581>
- Emmi, L., Le Flécher, E., Cadenat, V., & Devy, M. (2021). A hybrid representation of the environment to improve autonomous navigation of mobile robots in agriculture. *Precision Agriculture*, 22, 524-549. <https://doi.org/10.1007/s11119-020-09773-9>
- Fasiolo, D. T., Scalera, L., Maset, E., & Gasparetto, A. (2023). Towards autonomous mapping in agriculture: A review of supportive technologies for ground robotics. *Robotics and Autonomous Systems*, 169, Article 104514. <https://doi.org/10.1016/j.robot.2023.104514>
- Food and Agriculture Organization of the United Nations. (2018). The future of food and agriculture: Alternative pathways to 2050. FAO. <https://www.fao.org/3/l8429EN/i8429en.pdf>
- Fountas, S., Mylonas, N., Malounas, I., Rodias, E., Hellmann Santos, C., & Pekkeriet, E. (2020). Agricultural robotics for field operations. *Sensors*, 20(9), Article 2672. <https://doi.org/10.3390/s20092672>
- Frintrop, S., Rome, E., Nüchter, A., & Surmann, H. (2005). A bimodal laser-based attention system. *Computer Vision and Image Understanding*, 100(1-2), 124-151. <https://doi.org/10.1016/j.cviu.2004.08.005>
- Fujinaga, T. (2025). Autonomous navigation method for agricultural robots in high-bed cultivation environments. *Computers and Electronics in Agriculture*, 231, Article 110001. <https://doi.org/10.1016/j.compag.2025.110001>
- Gai, J., Guo, Z., Raj, A., & Tang, L. (2025). Robust crop row detection using discrete Fourier transform (DFT) for vision-based in-field navigation. *Computers and Electronics in Agriculture*, 229, Article 109666. <https://doi.org/10.1016/j.compag.2024.109666>
- Habib, M. K. (2007). Real time mapping and dynamic navigation for mobile robots. *International Journal of Advanced Robotic Systems*, 4(3), 323-338. <https://doi.org/10.5772/5681>
- Khan, N., Ray, R. L., Sargani, G. R., Ihtisham, M., Khayyam, M., & Ismail, S. (2021). Current progress and future prospects of agriculture technology: Gateway to sustainable agriculture. *Sustainability*, 13(9), Article 4883. <https://doi.org/10.3390/su13094883>
- Liu, H., Han, Z., Yin, J., Bao, J., Mu, J., Tan, H., & Liu, X. (2026). Path tracking control method for tracked agricultural vehicles based on slip-aware look-ahead point offset. *Frontiers in Plant Science*, 16, Article 1754679. <https://doi.org/10.3389/fpls.2025.1754679>
- Liu, L., Wang, X., Yang, X., Liu, H., Li, J., & Wang, P. (2023). Path planning techniques for mobile robots: Review and prospect. *Expert Systems with Applications*, 227, Article 120254. <https://doi.org/10.1016/j.eswa.2023.120254>
- Macenski, S., Foote, T., Gerkey, B., Lalancette, C., & Woodall, W. (2022). Robot Operating System 2: Design, architecture, and uses in the wild. *Science Robotics*, 7(66), Article eabm6074. <https://doi.org/10.1126/scirobotics.abm6074>

- Malanowski, M., Kulpa, K., Kulpa, J., Samczynski, P., & Misiurewicz, J. (2014). Analysis of detection range of FM-based passive radar. *IET Radar, Sonar & Navigation*, 8(2), 153-159. <https://doi.org/10.1049/iet-rsn.2013.0185>
- Montalvo-Romero, N., Montiel-Rosales, A., Purroy-Vásquez, R., & Quechulpa-Pérez, P. (2023). Agro-technological systems in traditional agriculture assistance: A systematic review. *IEEE Access*, 11, 123047-123069. <https://doi.org/10.1109/ACCESS.2023.3329087>
- Mulla, D., & Khosla, R. (2017). Historical evolution and recent advances in precision farming. In *Soil-specific farming* (pp. 1-25). CRC Press. <https://doi.org/10.1201/b18759-2>
- Naciones Unidas. (s. f.). Hambre y seguridad alimentaria. United Nations Sustainable Development. Recuperado el 29 de mayo de 2025, de <https://www.un.org/sustainabledevelopment/es/hunger/>
- OECD/FAO. (2021). OCDE-FAO Perspectivas agrícolas 2021-2030. OECD Publishing. <https://doi.org/10.1787/47a9fa44-es>
- Okonkwo, C., & Awolusi, I. (2025). Environmental sensing in autonomous construction robots: Applicable technologies and systems. *Automation in Construction*, 172, Article 106075. <https://doi.org/10.1016/j.autcon.2025.106075>
- Padhiary, M., Kumar, R., & Sethi, L. N. (2024). Navigating the future of agriculture: A comprehensive review of automatic all-terrain vehicles in precision farming. *Journal of The Institution of Engineers (India): Series A*, 105, 767-782. <https://doi.org/10.1007/s40030-024-00816-2>
- Papadopoulos, G., Arduini, S., Uyar, H., Psiroukis, V., Kasimati, A., & Fountas, S. (2024). Economic and environmental benefits of digital agricultural technologies in crop production: A review. *Smart Agricultural Technology*, 8, Article 100441. <https://doi.org/10.1016/j.atech.2024.100441>
- Patle, B. K., Babu, G. L., Pandey, A., Parhi, D. R. K., & Jagadeesh, A. (2019). A review: On path-planning strategies for navigation of mobile robot. *Defence Technology*, 15(4), 582-606. <https://doi.org/10.1016/j.dt.2019.04.011>
- Pechiar, J. (2021). Architecture and design considerations for an autonomous mobile robot. In *2021 IEEE URUCON* (pp. 343-346). IEEE. <https://doi.org/10.1109/URUCON53396.2021.9647380>
- Portugal, D., Rocha, R. P., & Castilho, J. P. (2025). Inquiring the robot operating system community on the state of adoption of the ROS 2 robotics middleware. *International Journal of Intelligent Robotics and Applications*, 9, 454-479. <https://doi.org/10.1007/s41315-024-00393-4>
- Rejeb, A., Rejeb, K., Abdollahi, A., & Hassoun, A. (2024). Precision agriculture: A bibliometric analysis and research agenda. *Smart Agricultural Technology*, 9, Article 100684. <https://doi.org/10.1016/j.atech.2024.100684>
- Sharma, N., Pandey, J. K., & Mondal, S. (2023). A review of mobile robots: Applications and future prospect. *International Journal of Precision Engineering and Manufacturing*, 24, 1695-1706. <https://doi.org/10.1007/s12541-023-00876-7>
- Shi, J., Bai, Y., Diao, Z., Zhou, J., Yao, X., & Zhang, B. (2023). Row detection based navigation and guidance for agricultural robots and autonomous vehicles in row-

- crop fields: Methods and applications. *Agronomy*, 13(7), Article 1780.
<https://doi.org/10.3390/agronomy13071780>
- Sujan, V. A., Meggiolaro, M. A., & Belo, F. A. W. (2006). Information-based indoor environment robotic exploration and modeling using 2-D images and graphs. *Autonomous Robots*, 21(1), 15-28. <https://doi.org/10.1007/s10514-005-6066-z>
- Wu, H., Wang, X., Chen, X., Zhang, Y., & Zhang, Y. (2025). Review on key technologies for autonomous navigation in field agricultural machinery. *Agriculture*, 15(12), Article 1297. <https://doi.org/10.3390/agriculture15121297>
- Xie, D., Chen, L., Liu, L., Chen, L., & Wang, H. (2022). Actuators and sensors for application in agricultural robots: A review. *Machines*, 10(10), Article 913. <https://doi.org/10.3390/machines10100913>
- Yao, X., Zhang, B., Wang, X., Su, Y., Cao, G., & Bian, Y. (2025). Adaptive navigation for robots in unstructured agricultural environments using stable feature localization and multi-sensor obstacle detection. *Computers and Electronics in Agriculture*, 234, Article 110302. <https://doi.org/10.1016/j.compag.2025.110302>
- Zhang, S., Liu, Y., Xiong, K., Tian, Y., Du, Y., Zhu, Z., Du, M., & Zhai, Z. (2024). A review of vision-based crop row detection method: Focusing on field ground autonomous navigation operations. *Computers and Electronics in Agriculture*, 222, Article 109086. <https://doi.org/10.1016/j.compag.2024.109086>
- Zhu, D., Ji, K., Wu, D., & Liu, S. (2022). A coupled visual and inertial measurement units method for locating and mapping in coal mine tunnel. *Sensors*, 22(19), Article 7437. <https://doi.org/10.3390/s22197437>
- Zhu, K., & Zhang, T. (2021). Deep reinforcement learning based mobile robot navigation: A review. *Tsinghua Science and Technology*, 26(5), 674-691. <https://doi.org/10.26599/TST.2021.9010012>