



UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS

MODELO DE MACHINE LEARNING PARA LA PREDICCIÓN DEL PRECIO DE VIVIENDAS URBANAS EN BOGOTÁ

Trabajo de investigación/grado para optar el título de
Magister en Ciencias de la Información y las Comunicaciones

Henry Arias Bernal

Asesor

PhD. Jorge Enrique Rodríguez Rodríguez

Bogotá D. C. – Colombia

Mayo de 2026

“Es mejor comprender el universo como realmente es, que persistir en una ilusión, por reconfortante y tentadora que sea.”

Carl Sagan, *El mundo y sus demonios*.

Contenido

1.	Introducción	1
1.1	Planteamiento del problema	2
1.2	Pregunta de investigación	8
1.3	Objetivos	8
1.3.1	Objetivo General	8
1.3.2	Objetivos Específicos	8
2.	Marco conceptual	9
2.1	Vivienda	9
2.2	Métodos de avalúos	9
2.3	Minería de datos	10
2.4	Preparación de datos	11
2.5	Machine learning	12
2.5.1	Aprendizaje supervisado	12
2.5.2	Regresión lineal	13
2.5.3	SVM (Support Vector Machine)	14
2.5.4	Redes neuronales artificiales	17
2.5.5	Aprendizaje no supervisado	19
2.5.6	Métodos jerárquicos	20
2.5.7	Métodos de particionamiento	22
2.5.8	Ensamble de modelos	23
2.5.9	Exactitud de modelos predictivos	25
2.5.10	Validación cruzada	26
3.	Marco teórico	27
3.1	Detección de outliers	28

3.2	Análisis de investigaciones en la predicción de valores de viviendas.....	34
3.3	Síntesis de las investigaciones.....	44
4.	Hipótesis	45
5.	Metodología	46
5.1	Preparación de los datos	46
5.1.1	Descripción de los datos	47
5.1.2	Duplicados y valores faltantes	48
5.1.3	Valores inválidos o inconsistentes	50
5.1.4	Transformación de variable tiempo de construido.....	52
5.1.5	Diagramas de caja y valores atípicos (outliers)	52
5.1.6	Valores NA en el conjunto de datos	57
5.1.7	Detección de outliers con algoritmo LOF.....	57
5.1.8	Detección outliers con algoritmo IForest.....	60
5.1.9	Detección outliers con algoritmo OCSVM.....	63
5.2	Análisis exploratorio de los datos (EDA).....	67
5.2.1	Diagramas de caja e histogramas de los conjuntos de datos.....	67
5.2.2	Medidas de tendencia central y dispersión	72
5.2.3	Asimetría, curtosis, prueba de normalidad y correlación	75
5.2.4	Análisis de componentes principales	79
5.3	Modelos predictivos	81
5.3.1	ElasticNET	81
5.3.2	Random Forest	84
5.3.3	XGBoost	87
5.3.4	Red perceptrón multicapa	93
6.	Resultados y discusión	98

6.1	Desempeño global de los modelos	98
6.2	Impacto en la detección de valores atípicos	99
6.3	Análisis de residuos	100
6.4	Complejidad computacional	104
6.5	Selección del modelo predictivo.....	105
7.	Conclusiones	106
8.	Principales aportes	107
9.	Recomendaciones y futuros trabajos	108
10.	Referencias	109

Índice de figuras

Figura 1. Cantidad de predios 2012-2024 en Bogotá.	2
Figura 2. Porcentajes de predios residenciales por estrato.	2
Figura 3. Participación de los predios residenciales nuevos vigencia 2024.	3
Figura 4. Número de ventas de viviendas.	4
Figura 5. Oferta de viviendas disponibles por rangos de precios.	4
Figura 6. Índice de Precios de Vivienda Usada.	5
Figura 7. IPVN – IPC, Variación anual Bogotá y Nacional.	6
Figura 8. Taxonomía de algoritmos supervisados.	13
Figura 9. Datos linealmente separables.	14
Figura 10. Diferentes márgenes de separación del mismo conjunto de datos.	15
Figura 11. Vectores de soporte (Enmarcados con borde más grueso).	17
Figura 12. Funcionamiento neurona artificial.	18
Figura 13. Topologías FNN y RNN.	19
Figura 14. Taxonomía de algoritmos no supervisados.	20
Figura 15. Métodos aglomerativo y divisivo.	21
Figura 16. Dendrograma que representa el agrupamiento jerárquico.	21
Figura 17. Esquema del Bagging.	23
Figura 18. Esquema del Boosting.	25
Figura 19. Esquema de una validación cruzada.	27
Figura 20. Cola de distribución de la variable precio.	51
Figura 21. Cola de distribución de la variable área.	51
Figura 22. Diagrama de caja variables área y número de habitaciones.	53
Figura 23. Diagrama de caja variables número de baños y estrato.	53
Figura 24. Diagrama de caja variables longitud y latitud.	54
Figura 25. Diagrama de caja variables garajes y precio.	54
Figura 26. Histograma variables área, habitaciones, baños y estrato.	56
Figura 27. Histograma variables garajes, latitud, longitud y precio.	56
Figura 28. LOF score y umbral de outlier.	59
Figura 29. Grafica del LOF score.	59
Figura 30. Histograma IForest score.	61

Figura 31. <i>IForest score y umbral de outlier.</i>	62
Figura 32. <i>Grafica del IForest score.</i>	62
Figura 33. <i>Outlier variables área y precio OCSVM.</i>	64
Figura 34. <i>Outlier variables latitud y longitud OCSVM.</i>	65
Figura 35. <i>Outlier variables habitaciones y baños OCSVM.</i>	65
Figura 36. <i>Diagramas de caja variable área, conjuntos de datos referencia, LOF, Iforest y OCSVM.</i>	68
Figura 37. <i>Histograma variable área, conjuntos de datos referencia, LOF, Iforest y OCSVM.</i> ...	69
Figura 38. <i>Diagramas de caja variable habitaciones, conjuntos de datos referencia, LOF, Iforest y OCSVM.</i>	69
Figura 39. <i>Histograma variable habitaciones, conjuntos de datos referencia, LOF, Iforest y OCSVM.</i>	70
Figura 40. <i>Diagramas de caja variable baños, conjuntos de datos referencia, LOF, Iforest y OCSVM.</i>	70
Figura 41. <i>Histograma variable baños, conjuntos de datos referencia, LOF, Iforest y OCSVM.</i> .	71
Figura 42. <i>Diagramas de caja variable precio, conjuntos de datos referencia, LOF, Iforest y OCSVM.</i>	71
Figura 43. <i>Histograma variable precio, conjuntos de datos referencia, LOF, Iforest y OCSVM.</i> .	72
Figura 44. <i>Matriz de correlación de Spearman para conjunto de datos de referencia.</i>	77
Figura 45. <i>Matriz de correlación de Spearman para conjunto de datos LOF.</i>	77
Figura 46. <i>Matriz de correlación de Spearman para conjunto de datos Iforest.</i>	78
Figura 47. <i>Matriz de correlación de Spearman para conjunto de datos OCSVM.</i>	78
Figura 48. <i>Varianza explicada por componente de los conjuntos de datos.</i>	80
Figura 49. <i>Círculo de correlación, conjunto de datos OCSVM.</i>	80
Figura 50. <i>Dispersión de valores reales y recta estimada con el conjunto de datos IForest.</i>	83
Figura 51. <i>Dispersión de valores reales y recta estimada con el conjunto de datos OCSVM.</i>	84
Figura 52. <i>Error OOB vs número de mtry para el conjunto de datos de referencia.</i>	85
Figura 53. <i>Error OOB vs número de mtry para el conjunto de datos OCSVM.</i>	85
Figura 54. <i>Error OOB vs número de árboles para el conjunto de datos IForest.</i>	86
Figura 55. <i>Importancia de las variables del modelo con hiperparámetros Grid search y datos IForest.</i>	91

Figura 56. <i>Importancia de las variables del modelo con hiperparámetros Random search y datos IForest.</i>	91
Figura 57. <i>Importancia de las variables del modelo con hiperparámetros Grid search y datos OCSVM.</i>	92
Figura 58. <i>Importancia de las variables del modelo con hiperparámetros Random search y datos OCSVM.</i>	92
Figura 59. <i>Curva de convergencia del entrenamiento con conjunto de datos de referencia.</i>	96
Figura 60. <i>Curva de convergencia del entrenamiento con conjunto de datos LOF.</i>	96
Figura 61. <i>Curva de convergencia del entrenamiento con conjunto de datos IForest.</i>	97
Figura 62. <i>Curva de convergencia del entrenamiento con conjunto de datos OCSVM.</i>	97
Figura 63. <i>Residuos vs valores predichos modelo ElasticNet y conjunto IForest.</i>	102
Figura 64. <i>Residuos vs valores predichos modelo Random Forest y conjunto IForest.</i>	103
Figura 65. <i>Residuos vs valores predichos modelo XGBoost y conjunto IForest.</i>	103
Figura 66. <i>Residuos vs valores predichos modelo MLP y conjunto IForest.</i>	104

Índice de tablas

Tabla 1. Conjuntos de datos reales para las pruebas de detección de valores atípicos.....	28
Tabla 2. AUC de los algoritmos de detección.	29
Tabla 3. Conjunto de datos reales para el caso de estudio.....	30
Tabla 4. Precisión promedio de ABOD, CBLOF, HBOS, Iforest , KNN, LODA en la detección de outliers.....	31
Tabla 5. Precisión promedio de LOF, LSCP, OCSVM, PCA, SOUD, ECOD en la detección de outliers.....	32
Tabla 6. Resultados modelos sencillos.	34
Tabla 7. Resultados modelos ensamblados.	35
Tabla 8. Resultados de los algoritmos.	36
Tabla 9. Resultados MAE de los algoritmos.	36
Tabla 10. Comparación resultados MAE del modelo ANN.	37
Tabla 11. Selección del modelo de regresión.....	38
Tabla 12. Comparación de desempeño entre GLM y ANN.	39
Tabla 13. Resultados estimados.	40
Tabla 14. Comparación de desempeño de los modelos predictivos.....	41
Tabla 15. Evaluación de las métricas de XGBoost con parámetros optimizados.....	41
Tabla 16. Resultados del ajuste de hiperparámetros por validación cruzada.....	43
Tabla 17. Resultados del desempeño de los algoritmos con hiperparámetros optimizados.....	43
Tabla 18. Tipos de variables del conjunto de datos.....	47
Tabla 19. Valores faltantes en el conjunto de datos	49
Tabla 20. Cuartiles, valores faltantes, mediana y promedio de datos sin procesamiento de detección de outliers.....	52
Tabla 21. Coeficiente de variación de las variables.	55
Tabla 22. Medidas de tendencia central y cuartiles de los LOF score	58
Tabla 23. Cuartiles, mediana y promedio variables de conjunto de datos LOF	60
Tabla 24. Cuartiles, mediana y promedio variables de conjunto de datos IForest.	63
Tabla 25. Cuartiles, mediana y promedio variables de conjunto de datos OCSVM.....	66
Tabla 26. Coeficiente de variación de las variables de los conjuntos de datos.....	68
Tabla 27. Medidas de tendencia central conjunto de datos de referencia y LOF.	73

Tabla 28. <i>Medidas de tendencia central conjunto de datos de IForest y OCSVM.</i>	73
Tabla 29. <i>Medidas de tendencia dispersión conjunto de datos de referencia y LOF.</i>	74
Tabla 30. <i>Medidas de tendencia dispersión conjunto de datos de IForest y OCSVM.</i>	74
Tabla 31. <i>Asimetría, curtosis y prueba de normalidad conjunto de datos de referencia y LOF.</i> .	75
Tabla 32. <i>Asimetría, curtosis y prueba de normalidad conjunto de datos de IForest y OCSVM.</i>	76
Tabla 33. <i>Proporción de la varianza acumulada de los conjuntos de datos.</i>	79
Tabla 34. <i>Valor de cos2 de la variable tiempo en los componentes principales de los conjuntos de datos.</i>	81
Tabla 35. <i>Medidas de desempeño algoritmo ElasticNET con Alpha=0 (Ridge)</i>	82
Tabla 36. <i>Medidas de desempeño algoritmo ElasticNET con Alpha=1 (Lasso)</i>	82
Tabla 37. <i>Lambda mínimo y lambda1se</i>	83
Tabla 38. <i>Medidas de desempeño algoritmo Random Forest</i>	87
Tabla 39. <i>Valores hiperparámetros obtenidos con Grid Search y Random Search para XGBoost.</i>	89
Tabla 40. <i>Medidas de desempeño algoritmo XGBoost con hiperparámetros Grid Search.</i>	89
Tabla 41. <i>Medidas de desempeño algoritmo XGBoost con hiperparámetros Random Search.</i> ...	90
Tabla 42. <i>Valores de referencia y obtenidos del Random Search.</i>	94
Tabla 43. <i>Medidas de desempeño algoritmo MLP</i>	95
Tabla 44. <i>Desempeño global modelos ElasticNet, Random Forest, XGBoost y MLP.</i>	98
Tabla 45. <i>Porcentaje de mejora en RMSE de los modelos.</i>	100
Tabla 46. <i>Porcentaje de mejora en MAE de los modelos.</i>	100
Tabla 47. <i>Sesgo de predicción (Bias) de los modelos ElasticNet, Random Forest, XGBoost y MLP.</i>	101

Resumen

El mercado inmobiliario de Bogotá es el más valorizado del país, donde diferentes sectores participan en el mercado y están expuestos a diversos riesgos por la incertidumbre asociada al precio de la vivienda. El objetivo de esta investigación fue desarrollar un modelo predictivo del precio de las viviendas en Bogotá utilizando un conjunto de datos inicial de 145.552 registros y 44 variables. Para el preprocesamiento de los datos se eliminaron registros duplicados y variables con alto porcentaje de valores faltantes. En la detección de valores atípicos se aplicaron los algoritmos LOF y OCSVM con normalización Z-score, así como el algoritmo IForest que no requiere normalización. El 70% de los datos preprocesados se utilizó para el entrenamiento de los modelos y el 30% restante para su evaluación. Se entrenaron modelos predictivos con ElasticNet, Random Forest, XGBoost y perceptrón multicapa (MLP). El mejor modelo fue Random Forest utilizando el conjunto de datos generado por IForest obteniendo un RMSE de 180.605.754 COP, un MAE de 102.731.883 COP y un R^2 de 0.936. La eliminación de valores atípicos mediante LOF, IForest y OCSVM disminuyó los errores de predicción (RMSE y MAE) en todos los modelos, con mejoras absolutas de hasta un 37 % en RMSE y un 28% en MAE en el modelo Random Forest respecto al conjunto de datos de referencia, lo que demuestra la relevancia de la detección de outliers para mejorar la precisión de modelos de predicción de precios de viviendas.

Palabras clave

Aprendizaje automático, detección de valores atípicos, predicción de precios de vivienda, Random Forest, OCSVM.

1. Introducción

El mercado inmobiliario de vivienda tiene una alta relevancia económica en diversos sectores involucrados en su desarrollo y comercialización, siendo Bogotá el principal mercado inmobiliario en Colombia. Para los actores del sector como bancos, constructoras, inversores y compradores es valioso contar con herramientas que les permitan fortalecer la toma de decisiones reduciendo la incertidumbre asociada a la estimación del precio de la vivienda para procesos de compra-venta, inversiones, pólizas, créditos entre otros.

El método más utilizado para valorar una vivienda es el de comparación de mercado. En este proceso el perito deberá seleccionar inmuebles con características semejantes a la vivienda que está valuando y no es claro cuáles son los criterios para determinar las “semejanzas” utilizadas para seleccionar las viviendas. Por lo tanto, es susceptible a sesgos y subjetividad por parte del perito y podría disminuir la confiabilidad del proceso de valuación del inmueble. Esto hace necesario diseñar un modelo predictivo del precio de viviendas urbanas en la ciudad de Bogotá que permita realizar el proceso de valuación de manera independiente del perito.

Generalmente las investigaciones relacionadas a la predicción del precio de viviendas no describen explícitamente los procesos utilizados para el preprocesamiento de datos como la detección de valores atípicos, valores faltantes entre otros (Rampini & Cecconi, 2021), (Ho et al., 2021), (Mora Garcia et al., 2022) y (Kalliola et al., 2021) y falta evaluación sistemática sobre cómo la detección de outliers afecta el desempeño predictivo en los modelos. Por lo tanto, es necesario evaluar comparativamente el impacto de técnicas de detección de valores atípicos en modelos de predicción de precios en inmuebles.


Para evaluar la influencia de valores atípicos en la predicción de precios de vivienda, se generaron tres conjuntos de datos a partir del conjunto de datos original aplicando diferentes técnicas de detección de outliers como LOF, Isolation Forest y OCSVM para obtener en total cuatro conjuntos de datos. Finalmente, se entrenaron modelos predictivos experimentales con los algoritmos ElasticNet, Random Forest, XGBoost y MLP. Estos modelos constituyen la base para el análisis comparativo del desempeño predictivo y el impacto de la detección de valores atípicos en los conjuntos de datos.

1.1 Planteamiento del problema

Bogotá cuenta con 2.817.536 predios de los cuales 2.302.344 son destinados para el uso de vivienda residencial, según el censo inmobiliario 2024 del observatorio técnico catastral de Bogotá. (Unidad Administrativa Especial de Catastro Distrital, 2024)

Figura 1.


Cantidad de predios 2012-2024 en Bogotá.



Fuente: (Unidad Administrativa Especial de Catastro Distrital, 2024)

Figura 2.

Porcentajes de predios residenciales por estrato.




Fuente: (Unidad Administrativa Especial de Catastro Distrital, 2024)

En la Figura 3 se observa que actualmente cerca del 80% de los predios residenciales corresponden al estrato 2, 3 y 4, “los predios residenciales nuevos que ingresaron al inventario un poco más de la mitad el 52%, son de estrato 3, el 23% son de estrato 4, el 10% de estrato 2, y el 15% restante corresponde a predios de estratos 1 ,5 y 6.” (Unidad Administrativa Especial de Catastro Distrital, 2024)

Figura 3.

Participación de los predios residenciales nuevos vigencia 2024.



Fuente: (Unidad Administrativa Especial de Catastro Distrital, 2024)

El mercado inmobiliario es un sector muy dinámico que tiene gran impacto en la economía nacional y en el bienestar de la población. Durante el año 2024 se vendieron 133.918 viviendas nuevas en Colombia según estadísticas de la cámara colombiana de la construcción. (Camacol, 2025b)


Bogotá es la ciudad más importante dentro del mercado inmobiliario de vivienda. El tamaño de su población es de 7.181.469 personas y según proyecciones para el 2025 será de 8.101.412 según cifras DANE (*DANE - Proyecciones de población - Bogotá*, s. f.). “Bogotá aporta al PIB nacional una participación mayoritaria del 25% y junto con Cundinamarca (6,3%) representan el 31,3%, superior al aporte de Antioquia (14,7%), Valle del Cauca (9,7%) y Santander (6.4 %).” (*DANE - Cuentas nacionales departamentales: PIB por departamento*, s. f.)

En la Figura 4 se observa que Bogotá junto al departamento de Cundinamarca cuentan con el mayor número de ventas de vivienda lo cual los hace un mercado muy atractivo.

Dado el PIB, población, valor y número de ventas de vivienda, Bogotá es el actor principal en el mercado inmobiliario del país.

Figura 4.

Número de ventas de viviendas.




Fuente: (Camacol, 2025a)

Con el mayor porcentaje de la oferta concentrada en los estratos 2, 3 y 4, se relaciona directamente también que el 80% de la oferta de viviendas se encuentren entre el rango de precios de 70 SMMLV (Equivale a 99 millones de pesos aproximadamente) a 435 SMMLV (Equivale a 620 millones de pesos aproximadamente),

Figura 5.

Oferta de viviendas disponibles por rangos de precios.



Segmento de precios	Var % ene-24	Var % ene-25
VIP	21,4%	21,2%
VIS (70-135 SML)	2,9%	-11,4%
(135 - 435 SML)	7,7%	-6,0%
(Más de 435 SML)	-17,1%	-12,7%
TOTAL	3,6%	-7,6%

Fuente: (Camacol, 2025a)


“El índice de precios de la vivienda usada IPVU- para Colombia, mide la evolución de los precios de la vivienda usada, mediante su variación promedio para el período de análisis ya sea anual o trimestral. El cálculo es basado en la metodología de ventas repetidas propuesta por Case and Shiller (1989).” (Banco de la República, 2025b)

“El método de ventas repetidas caracteriza el comportamiento del precio de una vivienda individual como un proceso estocástico en el cual la variación media es representada por un índice de precio de mercado, mientras que la dispersión y la volatilidad de los valores alrededor del promedio de mercado son modeladas como un proceso de difusión log-normal (Calhoun, 1996).”(Banco de la República, 2025b)

“La estimación del índice requiere identificar viviendas que hayan sido vendidas por lo menos dos veces dentro del periodo de estudio. Para identificar cada inmueble se utilizan las variables dirección y matrícula inmobiliaria y se cruza la información estableciendo la variación en los precios entre la primera y segunda transacción. Ante la ausencia del precio exacto de la vivienda, se utiliza el valor del avalúo comercial de las viviendas financiadas durante el periodo de cálculo, valor que es utilizado como garantía al momento del desembolso del crédito hipotecario.” (Banco de la República, 2025b)

Figura 6.

Índice de Precios de Vivienda Usada.




Fuente: (Camacol, 2024)

“El índice de precios de la vivienda nueva (IPVN) mide la evolución mensual de los precios de la vivienda nueva en las tres principales ciudades de Colombia: Bogotá, Medellín, Cali y los municipios aledaños de Bogotá (Chía, Cota, Cajicá, Tabio, Tenjo, La Calera, Sopó, Guaymaral, Funza, Madrid, Mosquera, Facatativá, Soacha y Ciudad verde). La metodología empleada consiste en un índice de precios superlativo de Fisher con base fija (diciembre de 2006), para el cual se utilizan los precios y áreas de todos los inmuebles nuevos disponibles para la venta en un determinado período. El cálculo e implementación del índice es realizado por el Banco de la República con información de La Galería Inmobiliaria.” (Banco de la República, 2025a).

Figura 7.

IPVN – IPC, Variación anual Bogotá y Nacional.



Fuente: (Observatorio de Hábitat, 2025)

Los métodos para valuar un inmueble están enmarcados por la resolución 620 de 2008 del instituto geográfico Agustín Codazzi, los bancos utilizan diferentes características de la vivienda para determinar el valor comercial, el método de comparación utiliza características: área del inmueble, ubicación, estrato socioeconómico, año de construcción (Antigüedad), número de habitaciones y baños entre otros.

El método más utilizado para valorar una vivienda es el de comparación de mercado, en este proceso el perito deberá seleccionar inmuebles con características semejantes a la vivienda que esta valuando, en esta etapa, no es claro cuáles son los criterios para determinar las “semejanzas” y así seleccionar las viviendas para la comparación, por lo tanto, es susceptible a un sesgo y subjetividad por parte del perito y podría disminuir la confiabilidad del proceso de valuación del inmueble.

El precio de un inmueble es variante en el tiempo, produciendo incertidumbre en los actores involucrados en el sector inmobiliario, por ejemplo, en la Figura 6 y Figura 7 se observa que los índices de precio tanto para vivienda usada como nueva tiene fluctuaciones significativas.

Carecer de un mecanismo confiable para predecir el precio de una vivienda, implica grandes pérdidas financieras para el sector bancario, constructor, inversor, asegurador y para todos los que hacen parte durante el proceso de compra y venta de bienes inmuebles.

Es muy importante que el mercado inmobiliario y sus participantes cuenten con un mecanismo que brinde una visión más ajustada a la realidad de los precios de la vivienda en Bogotá, la utilización de diferentes algoritmos de machine learning aplicadas a la predicción del precio de vivienda en Bogotá permitirá seleccionar las más adecuadas para construir un modelo que minimice la incertidumbre en la predicción del precio de las viviendas en Bogotá y entregue información con un grado de exactitud que permita disminuir los riesgos asociados al realizar transacciones con inmuebles como compra, venta, hipoteca, aseguramiento, entre otros.

1.2 Pregunta de investigación

¿Cómo se puede predecir el precio de una vivienda urbana en la ciudad de Bogotá?

1.3 Objetivos

1.3.1 Objetivo General

Diseñar un modelo predictivo del precio de inmuebles urbanos destinados a vivienda en la ciudad de Bogotá con técnicas de machine learning.

1.3.2 Objetivos Específicos

- Aplicar técnicas estadísticas y/o machine learning para la recolección, limpieza, integración y transformación de los datos.
- Definir la estructura de un modelo predictivo del precio de las viviendas urbanas en Bogotá.
- Validar la exactitud y eficacia del modelo predictivo del precio de viviendas urbanas en Bogotá.

2. Marco conceptual

2.1 Vivienda

Según el título III, artículo 11 del acuerdo 7 de 1979 vivienda es “toda edificación, cuya función arquitectónica y ambiental principal, es dar albergue en forma adecuada a una familia.” (*Acuerdo 7 de 1979 Concejo de Bogotá, D.C.*, s. f.)

Según el capítulo 1 “Usos del suelo” en el artículo 341 del decreto 190 de 2004 vivienda se designa como “un suelo como lugar de habitación, para proporcionar alojamiento permanente a las personas.” (*Decreto 190 de 2004 Alcaldía Mayor de Bogotá, D.C.*, s. f.)

“El concepto de vivienda digna implica contar con un lugar, propio o ajeno, que le permita a la persona desarrollarse en unas mínimas condiciones de dignidad y en el cual pueda desarrollar su proyecto de vida.” (Corte Constitucional de Colombia, 2025).

2.2 Métodos de avalúos

Valuar es “la actividad, por medio de la cual se determina el valor de un bien, de conformidad con los métodos, técnicas, actuaciones, criterios y herramientas que se consideren necesarios y pertinentes para el dictamen. El dictamen de la valuación se denomina avalúo” (Ley 1673 de 2013, 2013, p. 16).

Los 4 métodos para realizar avalúos están demarcados dentro de la resolución 620 de 2008 del instituto geográfico Agustín Codazzi la cual reza: “Que es de suma importancia tener procedimientos unificados, claros y actualizados para que las personas que se encarguen de realizar los avalúos especiales puedan contar con un marco único para su ejecución.” (IGAC, 2025).

“Artículo 1º - Método de comparación o de mercado: Es la técnica valuatoria que busca establecer el valor comercial del bien, a partir del estudio de las ofertas o transacciones recientes, de bienes semejantes y comparables al del objeto de avalúo. Tales ofertas o transacciones deberán ser clasificadas, analizadas e interpretadas para llegar a la estimación del valor comercial.” (IGAC, 2025)

“Artículo 2º.- Método de capitalización de rentas o ingresos. Es la técnica valuatoria que busca establecer el valor comercial de un bien, a partir de las rentas o ingresos que se puedan obtener del mismo bien, o inmuebles semejantes y comparables por sus características físicas, de uso y ubicación, trayendo a valor presente la suma de los probables ingresos o rentas generadas en la vida remanente del bien objeto de avalúo, con una tasa de capitalización o interés.” (IGAC, 2025)

“Artículo 3°.- Método de costo de reposición. Es el que busca establecer el valor comercial del bien objeto de avalúo a partir de estimar el costo total de la construcción a precios de hoy, un bien semejante al del objeto de avalúo, y restarle la depreciación acumulada. Al valor así obtenido se le debe adicionar el valor correspondiente al terreno.” (IGAC, 2025)

“Artículo 4°. Método (técnica) residual. Es el que busca establecer el valor comercial del bien, normalmente para el terreno, a partir de estimar el monto total de las ventas de un proyecto de construcción, acorde con la reglamentación urbanística vigente y de conformidad con el mercado del bien final vendible, en el terreno objeto de avalúo. Para encontrar el valor total del terreno se debe descontar al monto total de las ventas proyectadas, los costos totales y la utilidad esperada del proyecto constructivo. Es indispensable que además de la factibilidad técnica y jurídica se evalúe la factibilidad comercial del proyecto, es decir la real posibilidad de vender lo proyectado.” (IGAC, 2025)

Dentro del marco de esta investigación el método de comparación o mercado sería el más semejante dado que utiliza como información de entrada estudios de oferta o transacciones recientes, este método valuación esta descrito en la resolución 620 de 2008 así:

“Para tal fin es necesario calcular medidas de tendencia central y la más usual es la media aritmética. Siempre que se acuda a medidas de tendencia central es necesario calcular indicadores de dispersión tales como la varianza y el coeficiente de variación. Cuando el coeficiente de variación sea inferior al $\pm 7,5\%$, la media obtenida se podrá adoptar como el más probable valor asignable al bien. Cuando el coeficiente de variación sea superior al $\pm 7,5\%$; no es conveniente utilizar la media obtenida y por el contrario es necesario reforzar el número de puntos de investigación con el fin de mejorar la representatividad del valor medio encontrado. En caso que el perito desee separarse del valor medio encontrado, deberá calcular el coeficiente de asimetría para establecer hacia donde tiende a desplazarse la información, pero no podrá sobrepasar el porcentaje encontrado en las medidas de dispersión.” (IGAC, 2025)

2.3 Minería de datos

La minería de datos ha atraído la atención de la sociedad y la industria de la información en los últimos años debido a la gran disponibilidad de enormes cantidades de datos y a la inminente necesidad de convertir esos datos en información y conocimientos útiles. La información y los conocimientos adquiridos pueden utilizarse en aplicaciones que van desde análisis de mercado,

detección de fraude y retención de clientes hasta control de producción y exploración científica.(Han et al., 2011).

La minería de datos es un área transversal que involucra diferentes campos de investigación, una definición ampliamente utilizada es la aportada por (Fayyad, 1997) “La minería de datos es un área de investigación en rápida evolución que está en la intersección de varias disciplinas, incluyendo estadística, bases de datos, reconocimiento de patrones, inteligencia artificial y computación paralela.” Además esta definición es muy similar a la suministrada por (Gartner Glossary, s. f.) “La minería de datos es el proceso de descubrir correlaciones, patrones y tendencias significativas mediante el cribado de grandes cantidades de datos almacenados en repositorios. La minería de datos emplea tecnologías de reconocimiento de patrones, así como técnicas estadísticas y matemáticas.”

2.4 Preparación de datos

La primera etapa del proceso de minería es la preparación de los datos para obtener un conjunto de datos con la calidad requerida para la aplicación de las diversas técnicas de machine learning.

La preparación de los datos para una investigación de minería de datos generalmente consume la mayor parte del esfuerzo invertido en todo el proceso de minería. (Witten et al., 2017).

“Incluso cuando los datos están en la forma estándar, no se puede suponer que están libres de errores. En los conjuntos de datos del mundo real, los valores erróneos se pueden registrar por una variedad de razones, incluidos errores de medición, juicios subjetivos y mal funcionamiento o mal uso del equipo de grabación automática.” (Bramer, 2016).

Las técnicas de procesamiento de datos, cuando se aplican antes del proceso de extracción, pueden mejorar sustancialmente la calidad general de los patrones extraídos y / o el tiempo requerido para dicha extracción.(Han et al., 2011).

Las principales actividades dentro de la preparación de datos son:

- Limpieza: “Completar los valores faltantes, suavizar el ruido al identificar valores atípicos y corregir las inconsistencias en los datos.” (Han et al., 2011)
- Integración: Combinación de datos proveniente de múltiples fuentes en un solo conjunto de datos coherente. Estas fuentes pueden incluir múltiples bases de datos, cubos de datos y archivos planos.(Han et al., 2011)

- Transformación: Los datos se transforman o consolidan en formas apropiadas para la minería, esto puede involucrar suavizado, agregación, generalización, normalización y construcción de atributos. (Han et al., 2011)
- Reducción: Se aplica para obtener una representación reducida del conjunto de datos de mucho menor en tamaño, pero que mantiene estrechamente la integridad de los datos originales. Es decir, la minería en el conjunto de datos reducido debería ser más eficiente y producir los mismos (o casi los mismos) resultados analíticos. (Han et al., 2011)

El propósito fundamental de la limpieza de datos es manipular y transformar los datos sin procesar para que el contenido de información incluido en el conjunto de datos pueda exponerse o hacerse más fácilmente accesible. Por lo tanto, es necesario obtener datos de muestra adecuados para el proceso de minería. El pre procesamiento de datos puede generar un conjunto de datos más pequeño que el original, lo que nos permite mejorar la eficiencia en el proceso de minería de datos. Este desempeño incluye técnicas de reducción de datos como selección de características, muestreo o selección de instancias y discretización. (Hariharakrishnan et al., 2017).

2.5 Machine learning

El aprendizaje automático (Machine learning) es el área de la inteligencia artificial y ciencias de la computación dedicada a la investigación y desarrollo de técnicas las cuales permiten un aprendizaje autónomo de los sistemas a partir de un conjunto de datos de entrada, cabe anotar que este aprendizaje no es programado de forma explícita.


El término aprendizaje en este contexto es definido cuando un “algoritmo aprende de la experiencia E respecto a alguna clase de tareas T y con medida de eficiencia P, si el desempeño del algoritmo en las tareas T, tal y como las mide P, mejora con la experiencia E” (Mitchell, 1997), según esta definición el término aprendizaje aplica si el sistema mejora su rendimiento en la ejecución de alguna tarea con el incremento de la experiencia realizando dicha labor.

2.5.1 Aprendizaje supervisado

En este método se “proporciona un conjunto de datos de entrenamiento con las respuestas correctas y basado en este conjunto de datos, el algoritmo se generaliza para responder correctamente a todas las entradas posibles.” (Marsland, 2015).

Figura 8.

Taxonomía de algoritmos supervisados.



Fuente: (Nicolas, 2015)

2.5.2 Regresión lineal

“Este es un método básico en la estadística. La idea es expresar la clase como una combinación lineal de los atributos, con pesos predeterminados:” (Witten et al., 2017)

$$x = w_0 + w_1 a_1 + w_2 a_2 + \dots + w_k a_k \quad (1)$$

Donde x es la clase, $a_1, a_2, \dots, a_k$ son los valores de los atributos y $w_0, w_1, \dots, w_k$ son los pesos los cuales son calculados utilizando el conjunto de datos de entrenamiento. (Witten et al., 2017)

Para el caso de la primera instancia podemos decir que la clase a predecir sería $x^{(1)}$ y los valores de los atributos sería $a_1^{(1)}, a_2^{(1)}, \dots, a_k^{(1)}$, donde el superíndice denota el número de la instancia. Para la notación es conveniente aclarar que el atributo extra a_0 siempre tendrá el valor de 1. La predicción del valor de la clase de la primera instancia se puede expresar como (Witten et al., 2017):

$$w_0 a_0^{(1)} + w_1 a_1^{(1)} + w_2 a_2^{(1)} + \dots + w_k a_k^{(1)} = \sum_{j=0}^k w_j a_j^{(1)} \quad (2)$$

2.5.3 SVM (Support Vector Machine)

Este método permite realizar clasificación tanto en datos linealmente separables como para datos no linealmente separables, adicionalmente permite realizar predicción de valores continuos.


“Para la predicción numérica que comparten muchas de las propiedades encontradas en el caso de clasificación: producen un modelo que generalmente se puede expresar en términos de unos pocos vectores de soporte y se puede aplicar a problemas no lineales usando funciones kernel” (Witten et al., 2017)

“SVM utiliza un mapeo no lineal para transformar los datos de entrenamiento originales en una dimensión superior. Dentro de esta nueva dimensión, busca el hiperplano de separación óptimo lineal (es decir, un "límite de decisión" que separa las tuplas de una clase de otra). Con un mapeo no lineal apropiado a una dimensión suficientemente alta, los datos de dos clases siempre pueden estar separados por un hiperplano. El SVM encuentra este hiperplano utilizando vectores de soporte (tuplas de entrenamiento "esenciales") y márgenes (definidos por los vectores de soporte).”(Han et al., 2011).

Cuando el conjunto de datos es linealmente separable Figura 9. Hay un número infinito de (posibles) hiperplanos de separación o "límites de decisión, en este caso los conjuntos de datos tienen dos atributos, A_1 y A_2 .

Figura 9.

Datos linealmente separables.




Fuente: (Han et al., 2011)

El enfoque de SVM es buscar el hiperplano con margen máximo, en la Figura 10 se observa dos posibles hiperplanos con sus márgenes asociadas. Ambos hiperplanos pueden clasificar

correctamente todos los datos del conjunto, se espera que el hiperplano con el mayor margen sea más exacto en la clasificación de datos futuros respecto al hiperplano con margen más pequeño.

Figura 10.

Diferentes márgenes de separación del mismo conjunto de datos.



Fuente: (Han et al., 2011)

SVM durante la fase de aprendizaje “entrenamiento” busca el hiperplano con el mayor margen, el cual se conoce como MMH (*Maximum marginal hyperplane*), es decir que la distancia más corta desde un hiperplano a un lado de su margen es igual a la distancia más corta desde el hiperplano al otro lado de su margen, donde están los "lados" del margen paralelo al hiperplano. Cuando se trata con el MMH, esta distancia es, de hecho, la distancia más corta desde el MMH hasta el dato de entrenamiento más cercana de cualquier clase. Una separación del hiperplano puede ser expresada como: (Han et al., 2011)

$$W \bullet X + b = 0 \quad (3)$$

Donde W es un vector de peso dado por $W = \{w_1, w_2, \dots, w_n\}$; donde n es el número de atributos del conjunto de datos y donde b es un escalar referido como bias. Considerando los atributos A_1 y A_2 de la Figura 10, la tupla de entrenamiento sería $X = (x_1, x_2)$ donde x_1 y x_2 serían los valores de los atributos A_1 y A_2 respectivamente para X . Si b lo asignamos como un peso adicional w_0 , podemos describir el anterior hiperplano de separación como: (Han et al., 2011)

$$w_0 + w_1x_1 + w_2x_2 = 0 \quad (4)$$

Por lo tanto, cualquier punto que se encuentre por encima del hiperplano de separación satisface:(Han et al., 2011)

$$w_0 + w_1x_1 + w_2x_2 > 0 \quad (5)$$

Del mismo modo, cualquier punto que se encuentre debajo del hiperplano de separación satisface:(Han et al., 2011)

$$w_0 + w_1x_1 + w_2x_2 < 0 \quad (6)$$

Los pesos se pueden ajustar para que los hiperplanos que definen los "lados" del margen se puedan escribir como: (Han et al., 2011)

$$H_1 : w_0 + w_1x_1 + w_2x_2 \geq 1 \text{ para } y_i = +1 \quad (7)$$

$$H_2 : w_0 + w_1x_1 + w_2x_2 \leq -1 \text{ para } y_i = -1$$

(8)


Es decir, cualquier tupla que cae sobre H_1 o por encima pertenece a la clase +1, y cualquier tupla que cae sobre o por debajo de H_2 pertenece a la clase -1. Combinando las dos desigualdades de las ecuaciones (7) y (8), obtenemos: (Han et al., 2011)

$$y_i (w_0 + w_1x_1 + w_2x_2) \geq 1, \forall i \quad (9)$$

Cualquier tupla de entrenamiento que caiga en los hiperplanos H_1 o H_2 (es decir, los "lados" que definen el margen) satisfacen la ecuación (9) y se denominan vectores de soporte. Es decir, están igualmente cerca del MMH. En la Figura 11, los vectores de soporte se muestran rodeados con un borde más grueso. Esencialmente, los vectores de soporte son las tuplas más difíciles de clasificar y brindan la mayor información con respecto a la clasificación.

Figura 11.

Vectores de soporte (Enmarcados con borde más grueso).



Fuente: (Han et al., 2011)

2.5.4 Redes neuronales artificiales

“Una red neuronal artificial (RNA) es un modelo matemático que intenta simular la estructura y funcionalidades de una red neuronal biológica. El bloque básico de construcción de una RNA es la neurona artificial la cual es un simple modelo matemático con tres sencillos conjuntos de reglas: multiplicación, adición y activación.” (Suzuki, 2011)

Cada entrada de la neurona artificial es multiplicada por un peso individual, en la sección intermedia se suman todos los resultados de dicha multiplicación incluyendo un sesgo (bias), la salida de la neurona artificial es la suma de todos los pesos anteriores pasando a través de una función de activación que también es conocida como función de transferencia. (Suzuki, 2011)

Un beneficio de la neurona artificial es la simplicidad del modelo, donde la descripción matemática es: (Suzuki, 2011)


$$y(k) = F\left(\sum_{i=0}^m w_i(k) \bullet x_i(k) + b\right) \quad (10)$$

Donde:

- $x_i(k)$ es el valor de entrada en tiempo discreto k
- $w_i(k)$ es el valor del peso en tiempo discreto k
- b es el sesgo o bias.
- F es la función de transferencia
- $y_i(k)$ es el valor de salida en el tiempo discreto k (Suzuki, 2011)

Figura 12.


Funcionamiento neurona artificial



Fuente: (Suzuki, 2011)

La mayor incógnita del modelo es la función de transferencia F , esta define las propiedades de la neurona artificial y puede ser cualquier función matemática. Las funciones de transferencia más utilizadas son la función paso, función lineal y la función no lineal (Sigmoid). (Suzuki, 2011)

Cuando se combina dos o más neuronas artificiales se obtiene una red neuronal artificial (RNA), la forma en la cual estas neuronas están conectadas entre sí se denomina topología o arquitectura. De hecho, las formas de conectar las neuronas pueden tomar numerosas topologías que se dividen en dos tipos básicos: *Feed-forward* y recurrente. (Suzuki, 2011)

Figura 13.*Topologías FNN y RNN**Fuente: (Suzuki, 2011)*

Existen varias topologías en las redes neuronales artificiales como:

- LSTM (Long Short Term Memory).
- SOM (Self-Organizing Map).
- Estocástica.


“Las ventajas de las redes neuronales incluyen su alta tolerancia a los datos ruidosos, así como su capacidad para clasificar patrones en los que no han sido entrenados. Se pueden usar cuando tenga poco conocimiento de las relaciones entre atributos y clases. Son adecuados para entradas y salidas de valor continuo, a diferencia de la mayoría de los algoritmos de árbol de decisión. Han tenido éxito en una amplia gama de datos del mundo real, incluido el reconocimiento de caracteres escritos a mano, la patología y la medicina de laboratorio. Los algoritmos de redes neuronales son inherentemente paralelos; Las técnicas de paralelización se pueden utilizar para acelerar el proceso de cálculo. Además, recientemente se han desarrollado varias técnicas para extraer reglas de redes neuronales entrenadas. Estos factores contribuyen a la utilidad de las redes neuronales para la clasificación y predicción en la minería de datos.” (Han et al., 2011)

2.5.5 Aprendizaje no supervisado

En el conjunto de datos de entrenamiento “no se proporcionan respuestas correctas, sino que el algoritmo trata de identificar similitudes entre las entradas de modo que las que tienen algo en común se clasifican en un conjunto.” (Marsland, 2015).

Figura 14.

Taxonomía de algoritmos no supervisados.



Fuente: (Nicolas, 2015)

“El agrupamiento de datos se encuentra en un fuerte desarrollo contribuyendo a la investigación en áreas como la minería de datos, estadística, aprendizaje automático (machine learning), bases de datos espaciales, biología y marketing.” (Han et al., 2011).

“El clustering también es llamado segmentación de datos en algunas aplicaciones porque divide grandes cantidades de datos y los agrupa de acuerdo a su grado de similitud” (Han et al., 2011).

2.5.6 Métodos jerárquicos


Este método crea una descomposición jerárquica de un conjunto de datos, según se realice esta descomposición el método se clasifica en aglomerativo o divisivo. (Han et al., 2011)

El método aglomerativo inicia asumiendo un clúster individual por cada caso, en cada iteración realiza una combinación de los clúster hasta el punto de que todos los casos estén en un solo clúster. Este método también es conocido como AGNES (AGlomerative NESTing).(Han et al., 2011)

El método divisivo inicia con un único clúster donde se encuentran todos los objetos y con cada iteración lo divide en partes más pequeñas hasta llegar al número de clúster deseados o que el diámetro de cada clúster este en un umbral definido. Este método también es conocido como DIANA (DIVisive ANALysis).(Han et al., 2011)

Figura 15.

Métodos aglomerativo y divisivo




Fuente: (Han et al., 2011)

Para representar el resultado del método jerárquico comúnmente es usado el dendrograma

Figura 16.

Dendrograma que representa el agrupamiento jerárquico



Fuente: (Han et al., 2011)

Para determinar las distancias entre clúster se utilizan las siguientes medidas, donde $|p - p'|$ es la distancia entre dos puntos p y p' , m_i es la media del clúster C_i y n_i es el número de objetos en C_i .

$$d_{\min}(C_i, C_j) = \min_{p \in C_i, p' \in C_j} |p - p'| \quad (11)$$

$$d_{\max}(C_i, C_j) = \max_{p \in C_i, p' \in C_j} |p - p'| \quad (12)$$

$$d_{mean}(C_i, C_j) = |m_i - m_j| \quad (13)$$

$$d_{avg}(C_i, C_j) = \frac{1}{n_i n_j} \sum_{p \in C_i} \sum_{p' \in C_j} |p - p'| \quad (14)$$

2.5.7 Métodos de particionamiento

Estos métodos consisten en organizar los objetos n de un conjunto de datos A dentro de un número de particiones K , el número de particiones K debe ser menor o igual al número de objetos n del conjunto de datos A . El criterio de esta partición se basa en la distancia de los objetos que no son similares en términos de los atributos del conjunto de datos. Existen dos técnicas para la partición K-means y K-medoids.

La técnica k-means consiste primero en seleccionar de manera aleatoria un número de clúster k los cuales inicialmente representan una media o centro, luego cada objeto es asignado a un clúster según sea su grado de similitud basado en la distancia entre el objeto y el centro o media del clúster. Este proceso es iterativo hasta que la función de criterio converge, esta función es el criterio del error cuadrado corresponde a la ecuación 15. (Han et al., 2011)

$$E = \sum_{i=1}^k \sum_{p \in C_i} |p - m_i|^2 \quad (15)$$

La técnica k-means es sensible a los datos fuera de rango o aislados (outliers), esto causa una distorsión en la distribución de los datos, por este motivo existe la técnica k-medoids, esta variante no toma el valor medio del clúster como referencia, en cambio toma un objeto representativo del clúster. Así cada objeto es asignado a un clúster dependiendo de la similitud con el objeto representativo del clúster y no de la media del mismo. Para minimizar las diferencias entre los objetos y el punto de referencia del clúster (Objeto representativo) se define el criterio como el error absoluto corresponde a la ecuación 16. Teniendo a O_j como el punto de referencia del clúster (Objeto representativo). (Han et al., 2011)

$$E = \sum_{j=1}^k \sum_{p \in C_j} |p - o_j| \quad (16)$$

2.5.8 Ensemble de modelos


El ensemble de modelos es una estrategia para combinar diferentes algoritmos de machine learning con el objetivo de crear un mejor modelo, el cual tenga un desempeño superior a los modelos individuales que lo componen. Existen diversas estrategias como *Bagging*, *Boosting*, *Stacking*, *Additive regression*, *Randomization*, *Option trees* entre otras. A continuación, se describen las más utilizadas:

“Combinar las decisiones de diferentes modelos significa amalgamar los diversos resultados en una sola predicción. La forma más sencilla de hacer esto en el caso de la clasificación es hacer una votación (quizás una votación ponderada); en el caso de la predicción numérica, es calcular el promedio (quizás un promedio ponderado).” (Witten et al., 2017)

Para el entrenamiento de los modelos que serán ensamblados se crean unos subconjuntos partiendo del conjunto de datos original de entrenamiento, estos subconjuntos son conformados utilizando la técnica *Bootstrap*.

Figura 17.

Esquema del Bagging.



Fuente: (ML | Bagging Classifier, 2025)

“La idea del bootstrap es muestrear el conjunto de datos con reemplazo para formar un conjunto de entrenamiento. Para esto, un conjunto de datos de n instancias se muestrea n veces, con reemplazo, para dar otro conjunto de datos de n instancias. Debido a que algunos elementos en este segundo conjunto de datos se repetirán (casi con certeza), debe haber algunas instancias en el


conjunto de datos original que no se hayan seleccionado: las utilizaremos como instancias de prueba.” (Witten et al., 2017).

La clasificación utilizando la estrategia de ensamble bagging a menudo tiene una exactitud significativamente mayor que un único modelo clasificador derivado del conjunto de datos de entrenamiento original. El ensamble por bagging no es considerado peor respecto a utilizar un solo modelo y es más robusto a los efectos de los datos ruidosos. La mayor exactitud se produce porque el modelo ensamblado reduce la varianza de los clasificadores individuales. Para la predicción, se demostró teóricamente que un modelo ensamblado usando bagging siempre tendrá una mejor exactitud sobre un solo predictor derivado del conjunto de datos de entrenamiento original. (Han et al., 2011).

“En *boosting* se asignan pesos a cada tupla de entrenamiento. Se aprende iterativamente una serie de clasificadores k . Después de que se entrena un clasificador M_i , los pesos se actualizan para permitir que el clasificador posterior, M_{i+1} , "preste más atención" a las tuplas de entrenamiento que M_i clasificó erróneamente. El clasificador final, M_* , combina los votos de cada clasificador individual, donde el peso del voto de cada clasificador depende de su exactitud. El *boosting* se puede ampliar para la predicción de valores continuos.” (Han et al., 2011).

El primer algoritmo práctico de *boosting* fue el ADABOOST propuesto Freund y Schapire en 1995, con esta implementación se permite combinar múltiples clasificadores débiles en un solo clasificador más fuerte.

Si una tupla se clasificó incorrectamente, su peso aumenta. Si una tupla se clasificó correctamente, su peso disminuye. El peso de una tupla refleja lo difícil que es clasificarlo: cuanto mayor es el peso, más a menudo se ha clasificado erróneamente. Estos pesos se utilizarán para generar las muestras de entrenamiento para el clasificador de la próxima iteración. La idea básica es que cuando construimos un clasificador, queremos que se centre más en las tuplas mal clasificadas de la iteración anterior. Algunos clasificadores pueden ser mejores para clasificar algunas tuplas "difíciles" que otras. De esta manera, construimos una serie de clasificadores que se complementan entre sí. (Han et al., 2011).

Figura 18.*Esquema del Boosting.**Fuente: (Boosting, 2025)*

2.5.9 Exactitud de modelos predictivos

“Dado que los predictores devuelven un valor continuo en lugar de una etiqueta categórica, es difícil determinar con exactitud si el valor predicho es correcto. En lugar de centrarnos si y'_i coincide "exactamente" con y_i , analizamos la diferencia entre el valor predicho y el valor conocido real. Las funciones de pérdida miden el error entre el valor real y el valor predicho.” (Han et al., 2011). Las funciones de pérdida más comunes son:

$$\text{Error absoluto: } |y_i - y'_i| \quad (17)$$

$$\text{Error cuadrado: } (y_i - y'_i)^2 \quad (18)$$

El error de prueba (o tasa de error), o error de generalización, es la pérdida promedio en el conjunto de prueba. Por lo tanto, obtenemos las siguientes tasas de error:

$$\text{Error absoluto medio: } \frac{\sum_{i=1}^d |y_i - y'_i|}{d} \quad (19)$$

$$\text{Error cuadrático medio: } \frac{\sum_{i=1}^d (y_i - y'_i)^2}{d} \quad (20)$$

“El error cuadrático medio exagera la presencia de valores atípicos, mientras que el error absoluto medio no. Si calculamos la raíz cuadrada del error cuadrático medio, la medida de error resultante se denomina raíz del error cuadrático medio. Esto es útil porque permite que el error medido tenga la misma magnitud que la cantidad que se predice. A veces, podemos querer que el error sea relativo a lo que habría sido si simplemente hubiéramos predicho $\bar{y}$, el valor medio de y a partir de los datos de entrenamiento. Es decir, podemos normalizar la pérdida total dividiéndola por la pérdida total incurrida al predecir siempre la media.” (Han et al., 2011) Las medidas relativas de error incluyen:

$$\text{Error absoluto relativo: } \frac{\sum_{i=1}^d |y_i - y'_i|}{\sum_{i=1}^d |y_i - \bar{y}|} \quad (21)$$

$$\text{Error cuadrático relativo: } \frac{\sum_{i=1}^d (y_i - y'_i)^2}{\sum_{i=1}^d (y_i - \bar{y})^2} \quad (22)$$

Donde $\bar{y} = \frac{\sum_{i=1}^t y_i}{d}$ es el valor medio de y'_i del conjunto de datos de entrenamiento.


2.5.10 Validación cruzada

“En la validación cruzada *k-fold*, los datos iniciales se dividen aleatoriamente en k subconjuntos mutuamente excluyentes, $D_1, D_2, D_3, \dots, D_k$, cada uno de aproximadamente el mismo tamaño. El entrenamiento y las pruebas se realizan k veces. En la iteración i , la partición D_i se reserva como el conjunto de prueba y las particiones restantes se usan colectivamente para entrenar el modelo. Es decir, en la primera iteración, los subconjuntos $D_2, D_3, \dots, D_k$, sirven colectivamente como el conjunto de entrenamiento para obtener un primer modelo, el cual se prueba con el subconjunto D_1 ; la segunda iteración se entrena en los subconjuntos $D_1, D_3, \dots, D_k$, y se prueba con el subconjunto D_2 ; y así sucesivamente. Cada muestra se usa la misma cantidad de veces para el entrenamiento y una vez para la prueba. Para clasificación, la estimación de precisión es el número

total de clasificaciones correctas de las k iteraciones, dividido por el número total de tuplas en los datos iniciales. Para la predicción, la estimación del error se puede calcular como la pérdida total de las k iteraciones, dividida por el número total de tuplas iniciales.” (Han et al., 2011)

Figura 19.

Esquema de una validación cruzada



Fuente: (Casas, s. f.)

3. Marco teórico

La predicción del precio de las viviendas ha sido ampliamente estudiada en el campo del machine learning, generalmente las investigaciones utilizan diferentes algoritmos para abordar el problema de la predicción y comparan el resultado de los diferentes modelos del caso de estudio con métricas estándar en el área como RMSE, MSE entre otras.

En investigaciones como (Rampini & Cecconi, 2021), (Ho et al., 2021), (Mora Garcia et al., 2022) y (Kalliola et al., 2021) en la etapa de preprocesamiento de datos no se especifica las técnicas utilizadas para la detección de valores atípicos (outliers), siendo estos un reto para cualquier proceso de machine learning, se indaga en otras investigaciones no relacionadas a la predicción del precio de viviendas cuales son los algoritmos más utilizados o los enfoques mas eficientes para realizar dicha tarea.

3.1 Detección de outliers

Uno de los primeros pasos para la preparación del conjunto de datos consiste en la detección de valores atípicos “outliers”, estos valores constituyen un problema fundamental en el análisis de datos porque distorsiona los resultados de la predicción.

(Yang et al., 2021) propone un enfoque para la detección de valores atípicos de manera previa al análisis de datos utilizando los algoritmos mean shift (MOD) y medoid shift (DOD), para realizar el experimento primero procesa los conjuntos de datos con varios algoritmos de referencia para la detección de valores atípicos como KNN, LOF, ODIN entre otros.

Los conjuntos de datos para el estudio son datos reales de diferentes tipos, dimensiones (cantidad de atributos), número de valores atípicos y tamaño como se muestra en la Tabla 1. La variedad en los conjuntos de datos asegura que los algoritmos de detección sean probados en diferentes escenarios y así puede ayudar a realizar una mejor selección del tipo de algoritmos a utilizar según sea la naturaleza de los conjuntos de datos.

La selección de los algoritmos de detección fue realizada con el objetivo de probar diferentes principios de funcionamiento, en la segunda columna de la *Fuente: (Yang et al., 2021)*

Tabla 2 se encuentra el tipo de cada uno de los algoritmos utilizados, este planteamiento sugiere realizar la detección de valores atípicos con algoritmos de diferente naturaleza y evaluar los más adecuados para el conjunto de datos objeto de estudio.

Tabla 1.

Conjuntos de datos reales para las pruebas de detección de valores atípicos.

Dataset	Tamaño	Outliers	Dim	Tipo
KDD-Cup99	60.632	246	38	Intrusiones de red
Stamps	340	31	9	Sellos falsificados
PageBlocks	5473	560	10	Imágenes o gráficos
Pima	768	268	8	Pacientes
Arrhythmia	450	206	259	Pacientes afectados
Parkinson	195	147	22	Pacientes

Fuente: (Yang et al., 2021)

Tabla 2.*AUC de los algoritmos de detección.*

Dataset (outliers)	Tipo	KDD. (0.4%)	Stamps (9.1%)	Page. (10.2%)	Pima (34.9%)	Arrh. (45.8%)	Parkinson (75.4%)	AVG
DOD +	Corrimiento	0.98	0.94	0.91	0.78	0.73	0.71	0.84
MOD +	Corrimiento	0.99	0.94	0.91	0.76	0.74	0.68	0.84
DOD	Corrimiento	0.78	0.92	0.89	0.71	0.74	0.71	0.79
MOD	Corrimiento	0.99	0.90	0.91	0.68	0.74	0.67	0.82
LOF	Densidad	0.84	0.89	0.91	0.69	0.73	0.61	0.78
ODIN	Grafico	0.81	0.83	0.79	0.63	0.72	0.53	0.72
NC	Representación	0.69	0.68	0.70	0.57	0.67	0.61	0.65
KNN	Distancia	0.99	0.91	0.92	0.73	0.74	0.64	0.82
ABOD	Angulo	0.78	0.73	0.75	0.68	0.71	0.61	0.71
MCD	Estadístico	0.97	0.85	0.92	0.68	0.72	0.65	0.80
IFOREST	Árbol	0.99	0.86	0.90	0.67	0.76	0.49	0.78
OCSVM	SVM	0.99	0.87	0.91	0.62	0.74	0.36	0.75
PCAD	PCA	0.99	0.90	0.90	0.63	0.73	0.38	0.76
QES	Entropía	0.96	0.89	0.77	0.60	0.66	0.36	0.71
MO-GAAL	Red neuronal	0.85	0.38	0.25	0.69	0.47	0.75	0.57

Fuente: (Yang et al., 2021)

(Li et al., 2023) En esta investigación los autores proponen un novedoso algoritmo para la detección de outlier denominado ECOD “Empirical-Cumulative-distribution-based Outlier Detection”. En la primera parte realizan un estado del arte respecto a algoritmos ampliamente utilizados en la detección de outliers agrupándolos en 3 categorías que son: Algoritmos basados en densidad (LOF, KNN), modelos estadísticos (GMM), regresión, paramétricos, no paramétricos y basados en aprendizaje automático (one-class SVM, ANN).

Antes de iniciar el experimento, los investigadores dedican una buena parte del artículo detallar el algoritmo ECOD dividiendo la explicación en 3 partes: retos de la detección de outlier, motivación y detalles técnicos y por último propiedades de ECOD incluyendo interpretabilidad y escalabilidad. Un punto muy importante del artículo es que asumen la independencia de las variables entre sí y remarcan la importancia de como eliminar esta premisa en futuros trabajos.

El ECOD se motiva con la definición de outlier como un evento raro dentro del conjunto de datos y estos eventos raros suelen ser aquellos que aparecen en una de las colas de una distribución. Por ejemplo, si los datos se muestrean a partir de una gaussiana unidimensional, los puntos en las colas izquierda o derecha suelen considerarse eventos raros o outliers.

Para realizar el experimento utilizan 30 conjuntos de datos como punto de referencia, estos data set son de repositorios abiertos y tienen diferente cantidad de outliers, tamaño y variables:

Tabla 3.

Conjunto de datos reales para el caso de estudio

Dataset	# Samp. (n)	# Dims. (d)	% Outlier
Arrhythmia (mat)	452	274	14,601
Breasts (mat)	683	9	34,992
Cardio (mat)	1831	21	9,612
lonosphere (mat)	351	33	35,897
Lympho (mat)	148	18	4,054
Mammography (mat)	11183	6	2,325
Optdigits (mat)	5216	64	2,875
Pima (mat)	768	8	34,895
Satellite (mat)	6435	36	31,639
Satimage-2 (mat)	5803	36	1,223
Shuffle (mat) (*)	10000	9	7,120
Speech (mat)	3686	400	1,654
WBC (mat)	378	30	5,555
Wine (mat)	129	13	7,751
Arrhythmia (arff)	450	259	45,777
Cardiotocography (arff)	2114	21	22,043
HeartDisease (arff)	270	13	44,444
Hepatitis (arff)	80	19	16,250
InterneiAds (arff)	1966	1555	18,718
lonosphere (arff)	768	8	34,895
KDDCup99 (arff)	4207	57	39,909
Lymphography (arff)	340	9	9,116

Pima (arff)	351	32	35,897
Shuffle (arff)	10000	41	0,156
SpamBase (arff)	148	18	4,054
Stamps (arff)	1013	9	1,283
Waveform (arff)	3443	21	2,904
WBC (arff)	223	9	4,484
WDBC (arff)	367	30	2,724
WPBC (arff)	198	33	23,737

Fuente: (Li et al., 2023)

Los investigadores basados en el “estado del arte” seleccionan 11 algoritmos que son ampliamente utilizados en la detección de outliers para realizar la comparación con la propuesta ECOD y así evidenciar su desempeño con los 30 conjuntos de datos. Los algoritmos seleccionados son: ABOD (A Bias-free Outlier Detection), CBLOF (Clustering-Based Local Outlier Factor), HBOS (Histogram-Based Outlier Score), IForest (Isolation forest), KNN, LODA (Lightweight Online Detector of Anomalies), LOF (Local Outlier Factor), LSCP (Locally Selective Combination in Parallel Outlier Ensemble), OCSVM (One-Class SVM), PCA (Principal Component Analysis), SUOD (Scalable Unsupervised Outlier Detection).

En cada experimento se utilizó el 60% de los datos para el entrenamiento y el 40% restante para la prueba, los resultados en la detección de outlier son evaluados utilizando ROC y la precisión promedio (AP) en la Tabla 4 y Tabla 5, el número entre paréntesis corresponde a su orden según el desempeño.

Tabla 4.

Precisión promedio de ABOD, CBLOF, HBOS, Iforest , KNN, LODA en la detección de outliers

Dataset	ABOD	CBLOF	HBOS	Iforest	KNN	LODA
Arrhythmia (mat)	0.359 (12)	0.399 (9)	0.493 (3)	0.506 (1)	0.397 (10)	0.436 (5)
Breastw (mat)	0.295 (12)	0.914 (8)	0.953 (5)	0.972 (3)	0.927 (7)	0.978 (2)
Cardio (mat)	0.194 (11)	0.414 (8)	0.46 (6)	0.576 (3)	0.345 (10)	0.424 (7)
Ionosphere (mat)	0.914 (2)	0.871 (3)	0.366 (12)	0.789 (8)	0.924 (1)	0.716 (11)
Lympho (mat)	0.517 (11)	0.808 (9)	0.925 (2)	0.952 (1)	0.82 (7)	0.417 (12)
Mammography (mat)	0.023 (12)	0.137 (9)	0.122 (10)	0.233 (3)	0.17 (6)	0.281 (2)
Optdigits (mat)	0.028 (8)	0.062 (2)	0.196 (1)	0.055 (3)	0.022 (12)	0.024 (11)
Pima (mat)	0.511 (4)	0.477 (7)	0.569 (1)	0.503 (5)	0.515 (3)	0.408 (12)

Satellite (mat)	0.397 (11)	0.69 (1)	0.687 (2)	0.654 (3)	0.543 (9)	0.581 (8)
Satimage-2 (mat)	0.187 (11)	0.978 (1)	0.758 (7)	0.929 (3)	0.419 (9)	0.87 (5)
Shuttle (mat)	0.171 (11)	0.195 (10)	0.98 (3)	0.986 (1)	0.204 (9)	0.379 (8)
Speech (mat)	0.04 (1)	0.022 (6)	0.027 (3)	0.018 (11)	0.022 (6)	0.017 (12)
Wbc (mat)	0.355 (12)	0.5 (11)	0.663 (2)	0.59 (4)	0.529 (9)	0.564 (5)
Wine (mat)	0.084 (11)	0.06 (12)	0.405 (2)	0.279 (6)	0.095 (10)	0.278 (7)
Arrhythmia (arff)	0.699 (11)	0.712 (8)	0.75 (3)	0.746 (4)	0.712 (8)	0.697 (12)
Cardiotocography (arff)	0.247 (12)	0.363 (9)	0.366 (8)	0.434 (2)	0.311 (10)	0.432 (3)
HeartDisease (arff)	0.534 (4)	0.521 (9)	0.625 (2)	0.534 (4)	0.538 (3)	0.445 (12)
Hepatitis (arff)	0.33 (12)	0.374 (11)	0.473 (6)	0.442 (8)	0.475 (5)	0.396 (10)
InternetAds (arff)	0.276 (10)	0.315 (8)	0.535 (1)	0.49 (3)	0.281 (9)	0.242 (12)
Ionosphere (arff)	0.915 (1)	0.862 (3)	0.364 (12)	0.777 (8)	0.915 (1)	0.763 (9)
KDDCup99 (arff)	0.018 (12)	0.198 (5)	0.278 (1)	0.273 (2)	0.046 (10)	0.135 (7)
Lymphography (arff)	0.801 (11)	0.925 (7)	0.978 (3)	0.992 (1)	0.942 (6)	0.491 (12)
Pima (arff)	0.506 (5)	0.484 (7)	0.528 (2)	0.515 (4)	0.525 (3)	0.42 (12)
Shuttle (arff)	0.263 (5)	0.358 (3)	0.08 (12)	0.13 (10)	0.36 (2)	0.132 (9)
SpamBase (arff)	0.38 (10)	0.414 (8)	0.525 (2)	0.492 (3)	0.422 (6)	0.375 (11)
Stamps (arff)	0.247 (10)	0.241 (11)	0.398 (5)	0.394 (6)	0.341 (9)	0.404 (4)
Waveform (arff)	0.066 (8)	0.129 (2)	0.055 (10)	0.056 (9)	0.134 (1)	0.052 (12)
WBC (arff)	0.542 (11)	0.556 (9)	0.694 (6)	0.863 (1)	0.581 (8)	0.724 (4)
WDBC (arff)	0.43 (12)	0.667 (9)	0.795 (2)	0.718 (7)	0.654 (10)	0.794 (3)
WPBC (arff)	0.21 (12)	0.224 (8)	0.23 (6)	0.231 (5)	0.233 (4)	0.223 (9)
AVG	0.351 (12)	0.462 (8)	0.509 (3)	0.538 (2)	0.447 (9)	0.436 (10)

Fuente: (Li et al., 2023)

Tabla 5.

Precisión promedio de LOF, LSCP, OCSVM, PCA, SOUD, ECOD en la detección de outliers

Dataset	LOF	LSCP	OCSVM	PCA	SUOD	ECOD
Arrhythmia (mat)	0.374 (11)	0.411 (6)	0.405 (7)	0.402 (8)	0.495 (2)	0.473 (4)
Breastw (mat)	0.322 (11)	0.826 (9)	0.934 (6)	0.96 (4)	0.791 (10)	0.988 (1)
Cardio (mat)	0.163 (12)	0.396 (9)	0.532 (4)	0.611 (1)	0.462 (5)	0.579 (2)
Ionosphere (mat)	0.821 (6)	0.818 (7)	0.823 (5)	0.736 (9)	0.824 (4)	0.719 (10)
Lympho (mat)	0.825 (6)	0.861 (4)	0.814 (8)	0.852 (5)	0.799 (10)	0.894 (3)
Mammography (mat)	0.118 (11)	0.169 (7)	0.188 (5)	0.199 (4)	0.164 (8)	0.429 (1)
Optdigits (mat)	0.029 (7)	0.043 (6)	0.028 (8)	0.028 (8)	0.046 (5)	0.053 (4)
Pima (mat)	0.43 (11)	0.47 (9)	0.461 (10)	0.478 (6)	0.473 (8)	0.541 (2)

Satellite (mat)	0.39 (12)	0.51 (10)	0.653 (4)	0.603 (6)	0.608 (5)	0.585 (7)
Satimage-2 (mat)	0.027 (12)	0.333 (10)	0.975 (2)	0.874 (4)	0.623 (8)	0.86 (6)
Shuttle (mat)	0.142 (12)	0.715 (7)	0.902 (6)	0.926 (4)	0.913 (5)	0.981 (2)
Speech (mat)	0.024 (5)	0.027 (3)	0.021 (9)	0.022 (6)	0.029 (2)	0.02 (10)
Wbc (mat)	0.558 (6)	0.554 (7)	0.514 (10)	0.534 (8)	0.602 (3)	0.783 (1)
Wine (mat)	0.361 (4)	0.299 (5)	0.141 (9)	0.254 (8)	0.364 (3)	0.608 (1)
Arrhythmia (arff)	0.704 (10)	0.718 (5)	0.716 (6)	0.714 (7)	0.751 (2)	0.752 (1)
Cardiotocography (arff)	0.258 (11)	0.374 (7)	0.419 (4)	0.478 (1)	0.398 (5)	0.378 (6)
HeartDisease (arff)	0.478 (11)	0.525 (8)	0.513 (10)	0.53 (6)	0.528 (7)	0.64 (1)
Hepatitis (arff)	0.499 (4)	0.472 (7)	0.427 (9)	0.543 (3)	0.557 (2)	0.585 (1)
InternetAds (arff)	0.262 (11)	0.387 (5)	0.316 (7)	0.32 (6)	0.475 (4)	0.51 (2)
Ionosphere (arff)	0.811 (7)	0.819 (6)	0.822 (5)	0.723 (10)	0.835 (4)	0.703 (11)
KDDCup99 (arff)	0.028 (11)	0.127 (8)	0.125 (9)	0.199 (4)	0.157 (6)	0.239 (3)
Lymphography (arff)	0.925 (7)	0.922 (9)	0.837 (10)	0.953 (4)	0.944 (5)	0.982 (2)
Pima (arff)	0.458 (11)	0.48 (9)	0.478 (10)	0.484 (7)	0.487 (6)	0.53 (1)
Shuttle (arff)	0.395 (1)	0.184 (7)	0.304 (4)	0.232 (6)	0.171 (8)	0.085 (11)
SpamBase (arff)	0.349 (12)	0.45 (4)	0.412 (9)	0.42 (7)	0.431 (5)	0.567 (1)
Stamps (arff)	0.229 (12)	0.425 (2)	0.346 (8)	0.411 (3)	0.392 (7)	0.464 (1)
Waveform (arff)	0.108 (4)	0.114 (3)	0.07 (6)	0.054 (11)	0.07 (6)	0.079 (5)
WBC (arff)	0.33 (12)	0.543 (10)	0.702 (5)	0.638 (7)	0.728 (3)	0.838 (2)
WDBC (arff)	0.704 (8)	0.773 (4)	0.612 (11)	0.688 (8)	0.729 (5)	0.841 (1)
WPBC (arff)	0.225 (7)	0.248 (1)	0.223 (9)	0.223 (9)	0.245 (2)	0.244 (3)
AVG	0.378 (11)	0.466 (7)	0.49 (6)	0.503 (4)	0.503 (4)	0.565 (1)

Fuente: (Li et al., 2023)

El algoritmo ECOD tiene el mejor desempeño ROC en promedio y es el mejor para la detección de outliers en 13 de los 30 conjuntos de datos seguido de IForest en mejor promedio y con mejor desempeño en 3 de los 30 conjuntos, pero el HBOS tiene mejor desempeño en 6 de los 30 conjuntos de datos. También evalúan la velocidad de ECOD en comparación con los otros 11 algoritmos de referencia encontrando que ECOD es el tercero más rápido en promedio, siendo solo superado por HBOS y LODA.

Las investigaciones de (Yang et al., 2021) y (Li et al., 2023) sirven de guía para el proceso de detección de valores atípicos recopilando los resultados de su desempeño con diferentes conjuntos de datos. E adecuado utilizar algoritmos con diferentes principios de funcionamiento para evaluar cual responde mejor a la naturaleza de los datos.

3.2 Análisis de investigaciones en la predicción de valores de viviendas

En la investigación de (Chen & Huang, 2023) realizan una comparación entre el desempeño de modelos convencionales “sencillos” y modelos ensamblados, para ello cuentan con un conjunto de datos de 320.000 registros con 26 columnas perteneciente a transacciones realizadas entre 2007 y 2018 de viviendas en la ciudad de Beijing.

En esta investigación comparan la exactitud de modelos convencionales y modelos ensamblados, donde los modelos convencionales corresponden a los construidos con una sola técnica como XGB, regresión lineal entre otros. Y los modelos ensamblados corresponden a uso de técnicas como bagging y boosting donde se utilizan varios modelos para mejorar la exactitud, prevenir el sobre ajuste y reducir la varianza.

Utilizan dos versiones del conjunto de datos como puntos de referencia para realizar los experimentos así:

- Benchmark 1: Eliminación “Sumaria” de todos los valores faltantes para tener un total de 150.000 registros.
- Benckmark 2: Eliminación pequeña de valores atípicos, gestión de valores faltantes, eliminación de atributos no relevantes para tener cerca de 320.000 registros.

El objetivo de tener estos dos puntos de referencia es evidenciar las diferencias de desempeño entre los modelos cuando la información de entrada cambia respecto a su calidad y completitud.

Los autores indican que descartaron técnicas como AdaBoost, Random forest, Extra Tree y SVM porque los resultados obtenidos en la predicción no son ideales a pesar de que consumen gran potencia de cálculo y que esta aumenta exponencial a medida que aumenta la validación cruzada. El método de ensamble stacking también fue descartado porque el resultado en la predicción no era mejor en comparación con los modelos convencionales.

Tabla 6.

Resultados modelos sencillos.

Métrica	Algoritmo	Benchmark 1	Benchmark 2
MAE	LGBM	7,097	6,315
	XGB	6,972	6,194
	HistGB	7,094	6,315
RMSE	LGBM	9,228	8,197
	XGB	9,066	8,045

R^2	HistGB	9,231	8,197
	LGBM	59,66%	4.467%
	XGB	60,12%	46,02%
	HistGB	59,78%	44,55%

Fuente: (Chen & Huang, 2023)

Tabla 7.

Resultados modelos ensamblados.

Métrica	Algoritmo	Bagging	Boosting 1	Boosting 2	Boosting 3
MAE	LGBM	3,679	3,693	3,202	3,001
	XGB	3,271	3,384	3,001	2,903
	HistGB	3,710	3,701	3,204	3,013
RMSE	LGBM	5,290	5,316	4,698	4,465
	XGB	4,831	4,938	4,492	4,393
	HistGB	5,353	5,328	4,710	4,485
R^2	LGBM	7.500%	75,27%	81,00%	82,00%
	XGB	80.00%	78,65 %	82,00%	83,00%
	HistGB	75,21%	75,21%	81,00%	82,00%

Fuente: (Chen & Huang, 2023)

Como resultado principal se obtiene que el modelo con mejor desempeño es el XGB usando el método de ensamble boosting.

En el trabajo de (Obagbuwa & Danster, 2024) utilizan un conjunto de datos con 4 archivos con 163 columnas, dentro de estos cuentan con 80 atributos como precio, barrio, área, número de pisos, estilo de la vivienda, años de construido, estilo de la terraza, garajes entre otros. Para este estudio utilizaron Phyton y el IDE Jupiter, las técnicas de machine learning a ser implementadas son: Regresión lineal, Random forest, Gradient Boost Machine, redes neuronales (Perceptrón multicapa) y LSTM.

Realizaron la preparación de los datos eliminando errores y reduciendo outliers para mejorar la calidad del conjunto de datos, también eliminaron atributos donde los valores perdidos correspondían al 80%. Para el entrenamiento de los modelos dedicaron el 80% del conjunto de datos y para la evaluación el 20% restante. Dentro del artículo no detallan los parámetros utilizados para la construcción de los modelos con cada una de las técnicas aplicadas. Es interesante que el modelo de red neuronal tuvo un desempeño muy inferior respecto a los otros algoritmos.

Tabla 8.*Resultados de los algoritmos.*

Algoritmo	R²
Regresión lineal	0.914
Random forest	0.905
Gradient Boost Machine	0.911
Perceptrón multicapa	0.584
LSTM	0.863

Fuente: (Obagbuwa & Danster, 2024)

(Rampini & Cecconi, 2021) realizan tres modelos de predicción de viviendas en dos ciudades ubicadas en el norte de Italia que son Brescia y Varese. Los algoritmos utilizados para la construcción de los modelos son ElasticNet, XGBoost y redes neuronales. El conjunto de datos lo dividen en 3 partes, una para entrenamiento, otra para validación y la última parte para evaluación de los modelos con el objetivo de evitar el sobreajuste o sobre entrenamiento. Los conjuntos de datos tienen 6 variables o atributos que son: Área, Latitud, Longitud, Parqueadero, Año de construido, Precio, Precio por metro cuadrado, Índice de desempeño o eficiencia energética EPh. Como métrica de desempeño utilizan MAE con los siguientes resultados:

Tabla 9.*Resultados MAE de los algoritmos.*

Algoritmo	MAE	MAE
	Brescia	Varese
ElasticNet	92.988 €	62.921 €
XGB	81.025 €	58.990 €
ANN	77.015 €	56.128 €

Fuente: (Rampini & Cecconi, 2021)

Los autores identifican que los valores altos en los precios afectan significativamente el desempeño de los modelos, exponen que en el rango (max-min) en el tercer cuartil en Brescia es de 256.250€ y en el cuarto cuartil es de 1.618.750 €, para la ciudad de Varese es el rango del tercer cuartil es de

317.500 € y del cuarto cuartil es de 1.687.500 €. Con esto, realizan un nuevo entrenamiento para el modelo de red neuronal considerando solo los precios menores de 800.000 € obtenido así una mejora significativa del 11% para Brescia y del 12% para Varese.

Tabla 10.

Comparación resultados MAE del modelo ANN.

Algoritmo	MAE	MAE
	Brescia	Varese
ANN (Datos originales)	77.015 €	56.128 €
ANN (Datos con precios hasta 800.000€)	68.365 €	49.251 €

Fuente: (Rampini & Cecconi, 2021)

(Deaconu et al., 2022) desarrollan la investigación con un conjunto de datos de 33 atributos y 900 transacciones de venta de apartamentos del segundo semestre del 2019 ubicados en la ciudad de Cluj-Napoca en Rumania, este conjunto de datos tiene información respecto a las características físicas del inmueble como del entorno cercano.

Los investigadores realizan una revisión sobre artículos de trabajos sobre predicción de precio de viviendas donde se utilizan algoritmos de redes neuronales y de regresión para determinar una serie de ventajas y desventajas de las redes neuronales de acuerdo a los artículos revisados. En general, las ventajas de las ANN sobresalen respecto a las pocas desventajas, entre algunas de las ventajas son:

- Cuentan con mayor exactitud en la predicción.
- Predice mejor los precios en entornos volátiles.
- Las ANN se puede mejorar su desempeño utilizando algoritmos de optimización.

Algunas de las desventajas que presentan son:

- La estructura del modelo es como una caja negra, por lo tanto, no se conoce la contribución de las variables en la predicción y tampoco permite una interpretación.
- No hay una repetibilidad en el diseño del modelo, este cambia cuando se vuelve a construir.

También los autores realizan una revisión de artículos previos donde se realicen comparación entre modelos de ANN y modelos de regresión para la predicción de precios de viviendas, donde plasman información relevante como tamaño de los datos, ciudad de ubicación de los inmuebles, métricas de desempeño utilizadas y cual algoritmo mostro mejor rendimiento.

Los autores analizan las diferentes especificaciones entre el modelo GLM para determinar cuál utilizar en el experimento, donde M1 (Distribución normal en relación entre el precio y el área), M2 (Distribución normal en relación entre el precio con el número de habitaciones), M3 (Distribución gamma en relación entre precio y el área) y por último M4 (Distribución gamma en relación entre el precio y el número de habitaciones).

Tabla 11.

Selección del modelo de regresión.

Métrica	M1	M2	M3	M4
R^2	0.7485	0.6668	0.5880	0.6633
Chi-square	1242	989	1011	1149
MAE	13933	16753	14822	16642

Fuente: (Deaconu et al., 2022)

Los investigadores encontraron que el GLM con (M1) distribución normal entre el precio y el área es el mejor, por lo tanto, lo emplean para la comparación con el modelo ANN.

Con el software SPSS versión 22, utilizaron una ANN perceptrón multicapa con 8 capas ocultas y función de activación tangente hiperbólica. Los resultados del estudio fueron en la misma dirección que los mostrados en las investigaciones similares donde las ANN muestran un mejor desempeño en la predicción del precio de las viviendas, excepto en el trabajo de (Obagbuwa & Danster, 2024).

Tabla 12.

Comparación de desempeño entre GLM y ANN.

Métrica	GLM	ANN
MSE	650	572
RMSE	19489	17162
RMSPE	2.2271	1.8844
R^2	0.7485	0.8051
Mean raw residuals	-3.4954	-2.2697

Fuente: (Deaconu et al., 2022)

(Choy & Ho, 2023) comparan el desempeño (MSE, RMSE, MAPE) en la predicción de precios de propiedades ubicadas en Hong Kong utilizando algoritmos de machine learning como Extra trees, KNN, random forest y OLS (Ordinary Least Squares). Para este estudio los investigadores cuentan con un conjunto de datos de 24.317 registros correspondientes a las transacciones entre enero de 1997 y mayo de 2021 en el distrito de Quarry Bay en Hong Kong. Esta información proviene de las urbanizaciones privadas Grand Promenade, Kornhill Garden, Les Saisons y Taikoo Shing. La selección de estos algoritmos según los autores es porque son sencillos para calcular, manejan bien la alta dimensionalidad y tienen una buena exactitud.

Dentro del artículo no expone actividades de preprocesamiento y limpieza de los datos, solo mencionan que los algoritmos pueden ser usados con datos ruidosos porque manejan bien los outliers y valores perdidos.

Los autores exponen la selección de los hiper parámetros de esta manera:

- La parametrización del algoritmo extra trees se realizó con Optuna, configurando la máxima profundidad (2, 3, ..., 20), máximo de características (2, 3, ..., 14), muestras mínimas (2, 3, ..., 10) y número de estimadores (10, 20, ..., 200).
- La parametrización del algoritmo KNN se realizó con Optuna, se utiliza la distancia Minkowski, numero de leaf (1, 2, ..., 31), número de vecinos (1, 2, ..., 31), p(1, 2) y peso (Uniforme).
- La parametrización del algoritmo Random Forest se realizó con Optuna, emplearon bootstrapping, con el criterio selección MSE, máxima profundidad (1, 2, ..., 20),

máximas características (1, 2, ..., 14) mínimo muestras leaf y split (1, 2, ..., 10) y número de estimadores (10, 20, ..., 200)

A continuación, se encuentra el desempeño con diferentes métricas de los 4 algoritmos utilizados:

Tabla 13.

Resultados estimados.

Algoritmo	R^2	MSE	RMSE	MAPE
ET (Datos entrenamiento)	0,95800	0,14405	0,37953	6,49590%
ET (Datos de prueba)	0,91164	0,30561	0,55282	9,04650%
KNN (Datos entrenamiento)	0,93007	0,23986	0,48976	8,49790%
KNN (Datos de prueba)	0,89530	0,36211	0,60176	10,39520%
RF (Datos entrenamiento)	0,96165	0,13155	0,36270	6,22300%
RF (Datos de prueba)	0,91928	0,27918	0,52837	8,88930%
OLS	0,81400	0,63890	0,79931	14,54270%

Fuente: (Choy & Ho, 2023)

Con los resultados los autores concluyen que el algoritmo Random Forest es el que mejor desempeño demuestra, esto no solo basado en las métricas de desempeño si no apoyado en el análisis residual de la prueba con el conjunto de datos de prueba. OLS es el método que normalmente se utiliza para la predicción del precio, con los resultados se demuestra que las técnicas analizadas de machine learning tiene un desempeño mejor que el método tradicional. Es muy interesante el uso de una herramienta como optuna para realizar una mejor ingeniería en la selección de los parámetros para los algoritmos utilizados en esta investigación.

El estudio de (Trindade Neves et al., 2024) se realiza con transacciones de ventas de viviendas en la ciudad de Lisboa, el conjunto de datos consta de 23781 registros correspondientes desde el 2018 hasta el 2021, estos datos son compuestos de información propietaria de www.confidencialinmobiliario.com y también de información de acceso público. Los datos cuentan con 25 variables predictoras, muchas de las cuales no son características propias de las viviendas si no del entorno cercano, algunas de ellas son: latitud, longitud, número de habitaciones, PGA (Superficie privada bruta de la vivienda), número de paradas de bus en un radio de 250m, EPC

Eficiencia energética, número de escuelas en un radio de 500m, distancia más corta entre la vivienda al tren, metro, universidades, seguridad (Policía) entre otros.

En la preparación de datos, realizaron imputación en la variable EPC porque solo tenía el 12% de valores faltantes, otras variables donde los valores faltantes superaban el 30% como garaje, piscina, terraza fueron eliminadas del conjunto de datos. También se realiza eliminación de outliers en el precio usando el método de Z-score y así eliminan 1204 registros. Se excluyen 107 registros porque el precio por m2 es inferior a 1000 euros. Para la predicción utilizan XGBoost, random forest, AdaBoost y ANN obteniendo los siguientes resultados:

Tabla 14.

Comparación de desempeño de los modelos predictivos.

Datos	Métrica	XGBoost	RF	AdaBoost	ANN
Entrenamiento	MAE	40.821,22	36.166,76	73.917,53	63.803,96
	MAPE	16.66	14.34	31.27	58.37
	RMSE	55,568.64	51,184.51	95,210.09	91,295.80
	R^2	0.87	0,89	0,62	0,65
Prueba	MAE	51.733,88	52.678,57	74.764,45	65.366,37
	MAPE	19.58	19.74	30.43	58.31
	RMSE	72,488.87	74,482.71	97,492.31	94,369.38
	R^2	0,79	0,78	0,62	0,64

Fuente: (Trindade Neves et al., 2024)

El algoritmo de mejor desempeño es el modelo XGBoost, con él se procede a realizar la optimización de los parámetros utilizando Optuna y así luego validar si el desempeño del modelo mejoró con esta optimización. Efectivamente el desempeño del modelo XGBoost mejoró sustancialmente utilizando los parámetros entregados por Optuna en comparación con el modelo de referencia así:

Tabla 15.

Evaluación de las métricas de XGBoost con parámetros optimizados.

Datos	Métrica	Referencia	Optimizado	Reducción (%)	Gain R^2 (%)
Prueba	MAE	51.733,88	47.469,62	8,24	N/A
	MAPE	19.58	17.75	9,36	N/A
	RMSE	72.488,87	68.347,98	5,71	N/A
	R^2	0,79	0,81	N/A	2,96

Fuente: (Trindade Neves et al., 2024)

(Mora Garcia et al., 2022) en Este caso de estudio se centra en la ciudad de alicante en España, el conjunto de datos consta de 49.875 registros con 28 variables. Las variables las organizan en 5 categorías de acuerdo a las características así:

- Vivienda (Área, número de habitaciones, número de baños, tipología, HVAC, antigüedad entre otros)
- Edificio (Ascensor, parqueadero, piscina, jardín entre otros)
- Ubicación (Coordenadas en X y Y)
- Sector/Barrio (Antigüedad del barrio, porcentaje de población foránea, distancia a centros educativos, costa y parques entre otros)
- Temporal (Cuatrimestre en donde se conoce el precio de la vivienda 2019Q2, 2019Q3... 2021Q1, hasta 2021Q4)
- Variable dependiente (Precio)

Para iniciar la limpieza de datos hacen un análisis univariable para detectar y eliminar outliers donde su valor sea mayor o menor a seis veces la desviación estándar. Luego eliminan los registros que tienen valores perdidos en variables como precio, localización, área, numero de habitación y numero de baños, con esto se eliminan en total 2506 registros y el conjunto de datos queda con 47.369 registros. También se eliminan los registros que contienen valores idénticos dado que es habitual la comercialización de varias unidades del mismo edificio con las mismas características, después de esta eliminación de 7.426 registros el conjunto de datos final cuenta con 39.943 registros.

Para la variable dependiente precio realizaron transformación logarítmica natural para reducir problemas de heterocedasticidad, los algoritmos utilizados en este caso de estudio son regresión lineal, random forest, extra tres regressor, GBR gradient boosting regressor, XGBM Extreme gradient boosting y LGBM light gradient boosting machine.

Para la selección de los hiperparámetros de los algoritmos utilizan dos métodos, uno buscando los parámetros de manera aleatoria durante 200 iteraciones y el segundo con una búsqueda bayesiana de 100 iteraciones luego se realiza una validación cruzada para comparar los resultados. A continuación, está la tabla con los resultados encontrados y su desempeño medido con R^2 score.

Tabla 16.

Resultados del ajuste de hiperparámetros por validación cruzada.

Algoritmo	Hiperparámetros	Optimización hiperparámetros		
	iniciales	Aleatorio	Bayesiano	Mejor
Regresión lineal	0.8048 (0.0060)	-	-	-
Random Forest	0.9036 (0.0049)	0.8869 (0.0037) [time 37 min 56 s]	0.8855 (0.0038) [time 30 min 11 s]	Iniciales
Extra Trees	0.9101 (0.0040)	0.8628 (0.0044) [time 20 min 7 s]	0.8800 (0.0039) [time 38 min 42 s]	Iniciales
GBR	0.8581 (0.0054)	0.9101 (0.0035) [time 53 min 28 s]	0.9125 (0.0034) [time 39 min 32 s]	Bayesiano
XGBM	0.8921 (0.0034)	0.9094 (0.0041) [time 1 h 3 min 36 s]	0.9077 (0.0039) [time 45 min 10 s]	Bayesiano
LGBM	0.8864 (0.0042)	0.9065 (0.0043) [time 28 min 42 s]	0.9076 (0.0044) [time 16 min 17 s]	Bayesiano

Fuente: (Mora Garcia et al., 2022)

Los autores resaltan que para seleccionar el “mejor” algoritmo, son varias consideraciones a tener en cuenta y no solamente el desempeño de R^2 , también se debe considerar otros aspectos como el overfitting, variabilidad y tamaño de los datos a procesar por el costo computacional de cada algoritmo.

Tabla 17.

Resultados del desempeño de los algoritmos con hiperparámetros optimizados.

Algoritmo	MAE	MSE	RMSE	R^2
Regresión lineal	0.2166	0.0797	0.2823	0.8052
Random Forest	0.1252	0.0354	0.1882	0.9135
Extra Trees	0.1219	0.0336	0.1834	0.9178
GBR	0.1264	0.0331	0.1818	0.9192
XGBM	0.1298	0.0336	0.1834	0.9178
LGBM	0.1322	0.0352	0.1876	0.9140

Fuente: (Mora Garcia et al., 2022)

3.3 Síntesis de las investigaciones

Generalmente las investigaciones relacionadas a la predicción del precio de viviendas no exponen que procesos utilizan para el preprocesamiento de datos como la detección de valores atípicos, valores faltantes entre otros (Rampini & Cecconi, 2021), (Ho et al., 2021), (Mora Garcia et al., 2022) y (Kalliola et al., 2021). Por lo tanto, es necesario investigar con otro enfoque para estudiar algoritmos principalmente para la detección de outliers como LOF, KNN y para relleno de valores faltantes (Yang et al., 2021) y (Li et al., 2023).

Todas las investigaciones utilizan diferentes algoritmos en la predicción para evaluar su desempeño con los casos de estudio, lo algoritmos más recurrentes son:

- Regresión lineal, muy utilizado como punto de referencia.(Obagbuwa & Danster, 2024), (Rampini & Cecconi, 2021), (Deaconu et al., 2022) y (Mora Garcia et al., 2022)
- XGB, los resultados muestran buen desempeño. (Chen & Huang, 2023), (Obagbuwa & Danster, 2024), (Rampini & Cecconi, 2021), (Trindade Neves et al., 2024) y (Mora Garcia et al., 2022).
- ANN, los MLP son utilizados en amplia variedad de problemas incluyendo regresión/predicción.(Obagbuwa & Danster, 2024), (Rampini & Cecconi, 2021), (Deaconu et al., 2022) y (Trindade Neves et al., 2024).

Los valores de los hiperparámetros para los algoritmos pueden ser mejorados utilizando técnicas como búsqueda bayesiana, esta se realiza con herramientas como Optuna o librerías especializadas.

4. Hipótesis

La eliminación de valores atípicos mediante algoritmos de detección de anomalías mejora el desempeño de modelos de predicción de precios de viviendas en Bogotá.

5. Metodología

En este capítulo se desarrollan las actividades requeridas para el cumplimiento de los objetivos de esta investigación. A continuación, se presenta la metodología utilizada para el diseño de un modelo predictivo del precio de inmuebles urbanos destinados a vivienda en la ciudad de Bogotá con técnicas de machine learning.

Para esta investigación se utilizó lenguaje R en la suite RStudio versión 2026.04.0. Para el preprocesamiento de los datos se empleó librerías como dplyr, DescTools, dbscan, factoextra entre otras. Para los modelos predictivos se implementó las siguientes librerías:

- glmnet para ElasticNet.
- ranger para Random Forest.
- Xgboost para XGBoost.
- H2O para MLP.

Para evaluar la influencia de valores atípicos en la predicción de precios de vivienda, se generaron cuatro conjuntos de datos a partir del conjunto de datos original. En el conjunto de datos original se eliminó observaciones duplicadas, variables con alto porcentaje de valores faltantes y valores incoherentes y como resultado se obtiene el conjunto de datos de referencia. A este conjunto de referencia se le aplicó diferentes técnicas de detección de outliers como LOF, Isolation Forest y OCSVM para así obtener los tres conjuntos de datos restantes.

Finalmente, los cuatro conjuntos de datos se utilizaron para entrenar los modelos predictivos con los algoritmos ElasticNet, Random Forest, XGBoost y MLP obteniendo así un total de 16 modelos experimentales. Estos modelos constituyen la base para el análisis comparativo del desempeño predictivo y el impacto de la detección de valores atípicos en los conjuntos de datos.

5.1 Preparación de los datos

Para la recolección, limpieza, integración y transformación de los datos se utilizará una metodología estadística descriptiva y metodología empírica experimental para obtener conjunto de datos con la calidad requerida para el proceso de modelamiento.

5.1.1 Descripción de los datos

El conjunto de datos original para esta investigación cuenta con 145552 registros y 43 variables explicativas y la variable objetivo (valor o precio), a continuación, se presenta la Tabla 18 donde se indica el nombre, tipo de variable y en la última columna un ejemplo de la información de un registro del conjunto de datos:

Tabla 18.

Tipos de variables del conjunto de datos.

Ítem	Variable	Tipo	Subtipo	Ejemplo
1	antiguedad_original	Cualitativa	Ordinal	Entre 5 y 10 años
2	area	Cuantitativa	Continua	140.0
3	areabalcon	Cuantitativa	Continua	6.0
4	areaconstruida	Cuantitativa	Continua	140.0
5	areaterraza	Cuantitativa	Continua	6.0
6	balcon	Cualitativa	Nominal	Balcón
7	banos	Cuantitativa	Discreta	4.0
8	banoservicio	Cualitativa	Binaria	
9	conjuntocerrado	Cualitativa	Binaria	Si
10	cuarto_de_escolas	Cualitativa	Binaria	
11	cuartodeservicio	Cualitativa	Binaria	Si
12	depositoocuartoutil	Cualitativa	Binaria	1
13	depositos	Cuantitativa	Discreta	1
14	estrato	Cualitativa	Ordinal	4.0
15	estudioobiblioteca	Cualitativa	Binaria	
16	garajecubierto	Cualitativa	Binaria	Si
17	garajes	Cuantitativa	Discreta	2.0
18	gimnasio	Cualitativa	Binaria	Si
19	habitaciones	Cuantitativa	Discreta	3.0
20	halldealcobasoestar	Cualitativa	Binaria	Si
21	instalaciondegas	Cualitativa	Binaria	Natural
22	jacuzzi	Cualitativa	Binaria	Si
23	jardin	Cualitativa	Binaria	
24	latitud	Cuantitativa	Continua	4.7375211716
25	longitud	Cuantitativa	Continua	-74.0618057251
26	numeroascensores	Cuantitativa	Discreta	1.0
27	parqueaderovisitantes	Cualitativa	Binaria	
28	piscina	Cualitativa	Binaria	Si
29	planta electrica	Cualitativa	Binaria	
30	porteriaovigilancia	Cualitativa	Binaria	
31	remodelado	Cualitativa	Binaria	

32	saloncomunal	Cualitativa	Binaria	Si
33	sauna_yo_turco	Cualitativa	Binaria	Si
34	terrazza	Cualitativa	Nominal	BalcÃ³n
35	tiempodeconstruido	Cualitativa	Ordinal	Entre 5 y 10 aÃ±os
36	tipodegaraje	Cualitativa	Nominal	Servidumbre
37	valor	Cuantitativa	Continua	520000000.0
38	valorventa	Cuantitativa	Continua	520000000.0
39	vigilancia	Cualitativa	Binaria	
40	vista	Cualitativa	Binaria	Exterior
41	zona_de_bbq	Cualitativa	Binaria	Si
42	zonadelavanderia	Cualitativa	Binaria	Si
43	zonaninos	Cualitativa	Binaria	Si
44	zonasverdes	Cualitativa	Binaria	Si

En el conjunto de datos se identifica que los siguientes tipos de variables:

- Cuantitativa discreta: Variable numérica que toma valores finitos y generalmente son números enteros.
- Cuantitativa continua: Variable numérica dentro de un intervalo definido.
- Cualitativa ordinal: Variable categórica con un orden determinado.
- Cualitativa nominal: Variable categórica sin un orden determinado.
- Cualitativa binaria: Variable categórica con dos valores posibles, generalmente presencia o ausencia de una determinada característica.

5.1.2 Duplicados y valores faltantes

El siguiente paso en la preparación de los datos consiste en verificar si hay variables o registros duplicados dentro del conjunto de datos. Al verificar los registros, se evidencia que en el conjunto de datos se tienen 70748 duplicados.

En las variables al realizar la inspección se identificó 3 repetidos así:

- Variable “valor” igual a “valorventa”
- Variable “antigüedad_original” igual a “tiempodeconstruido”
- Variable “area” igual a “areaconstruida”

Con la eliminación de estos registros y variables repetidos el conjunto de datos queda con 41 variables y 74804 registros. Luego se verifica la cantidad de valores faltantes o perdidos para cada variable del conjunto de datos, el resultado se observa en la Tabla 19.

Tabla 19.*Valores faltantes en el conjunto de datos*

Ítem	Variable	Número valores faltantes	Porcentaje de valores faltantes
1	area	21	0,01
2	areabalcon	64170	85,8
3	areaterraza	64170	85,8
4	balcon	37090	49,6
5	banos	175	0,2
6	banoservicio	73701	98,5
7	conjuntocerrado	40561	54,2
8	cuarto_de_escoltas	72827	97,4
9	cuartodeservicio	60063	80,3
10	depositoocuartoutil	42267	56,5
11	depositos	57067	76,3
12	estrato	1034	1,4
13	estudioobiblioteca	44844	59,9
14	garajecubierto	43017	57,5
15	garajes	8599	11,5
16	gimnasio	55711	74,5
17	habitaciones	11	0,01
18	haldealcobasoestar	48562	64,9
19	instalaciondegas	23342	31,2
20	jacuzzi	71111	95,1
21	jardin	68895	92,1
22	latitud	0	0,0
23	longitud	0	0,0
24	numeroascensores	30310	40,5
25	parqueaderovisitantes	58447	78,1
26	piscina	68371	91,4
27	plantaelectrica	72687	97,2
28	porteriaovigilancia	35958	48,1
29	remodelado	45109	60,3
30	saloncomunal	33348	44,6
31	sauna_yo_turco	69349	92,7
32	terrazza	41515	55,5
33	tiempodeconstruido	0	0,0
34	tipodegaraje	47313	63,2
35	valor	0	0,0
36	vigilancia	27241	36,4
37	vista	42501	56,8
38	zona_de_bbq	62991	84,2

39	zonadelavanderia	24073	32,2
40	zonaninos	46439	62,1
41	zonasverdes	48707	65,1

Aunque no existe un porcentaje de valores faltantes universalmente definido para determinar si una variable se imputa o se elimina, para esta investigación se utiliza el umbral del 30% porque este garantiza que la cantidad de información restante es suficiente para realizar una correcta imputación de valores y así no eliminar una cantidad significativa de registros.

Con los resultados de la Tabla 19 y el umbral de máximo el 30% de valores faltantes, el conjunto de datos queda 74804 registros y nueve variables que son: Área, número de baños, número de habitaciones, estrato, número de garajes, latitud, longitud, tiempo de construido y precio.

5.1.3 Valores inválidos o inconsistentes

En el proceso de depuración, se realiza la búsqueda de valores inválidos o inconsistentes, el conjunto de datos al representar características de una vivienda, se toman como valores inválidos los siguientes casos particulares:


- Viviendas con menos de un baño. (Se eliminan 120 registros)
- Viviendas con menos de una habitación. (Se eliminan 57 registros)
- Viviendas con un área menor a $21 m^2$. (Se eliminan 326 registros)

Estos criterios de número de baños, habitaciones y área mínima son los que debe tener un inmueble para que sea considerado como una vivienda habitable. Para la variable precio, se clasifican como valores inválidos los registros que tengan un precio menor a 90 millones de pesos, este valor se determina teniendo en cuenta que para el año 2025 el precio de la vivienda de interés prioritario VIP en Bogotá estaba en alrededor de 117 millones de pesos, por lo tanto, un valor un poco inferior a ese tope mantiene una coherencia en los precios del mercado. En el conjunto de datos hay 135 registros con precios menores de 90 millones los cuales son eliminados.

En la Figura 20 se observa la cola de distribución de la variable precio, donde la línea roja corresponde a precios de 10 mil millones, quedando claro que la gran mayoría de registros se ubican por debajo de ese precio, por lo tanto, se eliminan 164 registros con un precio superior a 10 mil millones de pesos, quedando el conjunto de datos con 74002 registros y nueve variables.

Figura 20.


Cola de distribución de la variable precio.



En la Figura 21 se observa la cola de distribución de la variable área, donde la línea roja corresponde a áreas de 700 m², quedando claro que la gran mayoría de registros se ubican por debajo de esa área, por lo tanto, se eliminan 127 registros con un precio superior a 10 mil millones de pesos, quedando el conjunto de datos con 73875 registros y nueve variables.

Figura 21.

Cola de distribución de la variable área.



5.1.4 Transformación de variable tiempo de construido

La variable tiempo de construido se presenta de manera cualitativa ordinal, por lo tanto, transforma al tipo numérico con el objetivo de poder ser usada en diferentes algoritmos que no pueden procesar este tipo de variables cualitativas quedando de la siguiente manera:

- Entre 0 y 5 años = 1.
- Entre 5 y 10 años = 2.
- Entre 10 y 20 años = 3.
- Mas de 20 años = 4.

5.1.5 Diagramas de caja y valores atípicos (outliers)

Los valores atípicos (outliers) son un problema ampliamente conocido por su impacto negativo en análisis estadísticos y modelos de regresión, por lo tanto, es imperativo detectarlos para evitar afectar el desempeño del modelo predictivo. Los diagramas de caja es una herramienta que permite visualizar los outliers dentro de una variable utilizando el cálculo de los cuartiles. A continuación, se presenta la tabla con los valores de los cuartiles, mediana, media, valores máximos y mínimos del conjunto de datos.

Tabla 20.

Cuartiles, valores faltantes, mediana y promedio de datos sin procesamiento de detección de outliers.

Valor	Mínimo	Primer cuartil Q_1	Mediana	Promedio	Tercer cuartil Q_3	Máximo	NA
Área	21	66	90	112.8	136	700	21
Habitaciones	1	2	3	2.63	3	66	8
Baños	1	2	2	2.575	3	52	162
Estrato	1	4	5	4.687	6	7	1018
Garajes	1	1	2	1.731	2	10	8413
Latitud	4.445	4.667	4.696	4.691	4.720	4.814	0
Longitud	-74.21	-74.07	-75.05	-74.06	-74.04	-74.02	0
Precio	98*	558*	849*	1200*	1422*	9935*	0
Tiempo construido	1	1	3	2.287	3	4	0

*Valores dados en millones de pesos

A continuación, se presentan los diagramas de caja de todas las variables del conjunto de datos para visualizar de mejor manera los outliers detectados (puntos de color rojo).

Figura 22.

Diagrama de caja variables área y número de habitaciones.




Figura 23.

Diagrama de caja variables número de baños y estrato.





Figura 24.

Diagrama de caja variables longitud y latitud.

**Figura 25.**

Diagrama de caja variables garajes y precio.



Además, un alto coeficiente de variación indica una gran heterogeneidad o presencia de valores atípicos lo cual se muestra en la Tabla 21.


Tabla 21.*Coeficiente de variación de las variables.*

Variable	Cv%
Área	62.02
Número de habitaciones	32.81
Número de baños	40.74
Estrato	24.88
Garajes	45.12
Latitud	0.83
Longitud	-0.043
Tiempo construido	45.77
Precio	90.68


Es claro que el conjunto de datos presenta outliers, según el coeficiente de variación los más extremos se presentan en las variables precio y área. Con los histogramas de la Figura 26 y Figura 27 también se observa la distribución de los datos y se evidencia la presencia de outliers lo cual es un problema para los algoritmos de predicción, como menciona (Trindade Neves et al., 2024) “Los valores atípicos pueden distorsionar la capacidad de generalización de un modelo al provocar un sobreajuste a estos valores extremos.” y también (Kalliola et al., 2021) donde “Se eliminaron los valores atípicos y los casos falsos para garantizar las mejores condiciones posibles para entrenar un modelo preciso y robusto. Los valores atípicos (como apartamentos extremadamente caros o grandes que se venden con poca frecuencia) pueden afectar negativamente el rendimiento general; por lo tanto, se excluyeron.”. Por este motivo se procede a realizar detección de outliers con los algoritmos LOF (Densidad), IForest (Arboles de decisión) y OCSVM (SVM).

Figura 26.

Histograma variables área, habitaciones, baños y estrato.

**Figura 27.**

Histograma variables garajes, latitud, longitud y precio.



5.1.6 Valores NA en el conjunto de datos

Para la detección de outliers con algoritmos LOF, Iforest y OCSVM es necesario retirar los registros que tengan valores faltantes NA. Para ello se crea un subconjunto de datos con los valores faltantes con un tamaño de 9220 registros. El conjunto de datos sin valores NA para la detección de outliers queda con 64655 registros, este conjunto de datos será el de referencia para la detección de valores atípicos. Cuando el conjunto de datos quede depurado de outliers, será posible utilizarlo para realizar imputación al subconjunto de valores faltantes.

5.1.7 Detección de outliers con algoritmo LOF

Local Outlier Factor (LOF) es un algoritmo de aprendizaje automático no supervisado utilizado para detectar outliers midiendo la desviación de la densidad local de un punto de datos en relación con sus vecinos. “El LOF de un objeto se basa en el parámetro MinPts, que representa el número de vecinos más cercanos utilizados para definir su entorno local.” (Breunig et al., 2020).

Para definir la distancia entre dos puntos a y b el algoritmo LOF utiliza la distancia euclidiana:

$$d(a, b) = \sqrt{\sum_{i=1}^p (a_i - b_i)^2} \quad (23)$$

Al utilizar la distancia euclidiana, el algoritmo es sensible a la diferencia de magnitudes de las variables, por lo tanto, es necesario realizar un proceso de normalización. La normalización o estandarización será la Z-score:

$$z = \frac{x - \mu}{\sigma} \quad (24)$$

Donde:

- z = z-score
- x = Valor original
- μ = Media.
- σ = Desviación estándar.

Con el conjunto de datos normalizado con z-score, se aplica el algoritmo LOF, el hiperparámetro Minpts generalmente se ajusta para que el valor mínimo sea el número de dimensiones más 1, para seleccionar este valor se realizó varias pruebas para definir un valor adecuado para el conjunto de datos, en la Tabla 22 se ven los resultados del LOF score con varios Minpts.

Tabla 22.

Medidas de tendencia central y cuartiles de los LOF score

Minpts	Mínimo	1er Cuartil	Mediana	Promedio	3er Cuartil	Máximo
9	0.88	1.002	1.064	Inf	1.269	Inf
10	0.88	1.002	1.064	Inf	1.261	Inf
15	0.91	1.001	1.061	Inf	1.233	Inf
20	0.914	1.001	1.060	Inf	1.219	Inf
25	0.926	1.000	1.060	1.194	1.2122	58.08
30	0.927	1.000	1.059	1.183	1.2095	16.26
40	0.933	1.001	1.059	1.177	1.203	20.89


Los valores Inf (infinitos) indican que un punto del conjunto de datos no tiene la densidad local dentro del vecindario definido, es decir, está completamente aislado. Por lo tanto, para esta investigación se utiliza un Minpts de 30.

Un valor del conjunto de datos se asocia a un valor atípico cuando el valor de los resultados del LOF score supera un valor de umbral definido, el valor del umbral es ajustado de manera heurística con apoyo de la Figura 28 donde la línea azul son los LOF score del conjunto de datos, la línea roja corresponde al valor de umbral de 1.62, se selecciona este valor al evidenciar que agrupa gran parte del conjunto de datos, el punto de intersección con la línea azul indica la cantidad de registros considerados outliers, que para este caso es 4526. Por lo tanto, el conjunto de datos sin outlier entregado por el algoritmo LOF tiene 60129 registros.


En la Figura 29 se observa el LOF score asociado a cada registro, el color rojo son los outlier y los azules son los registros categorizados como normales o inlier.

Figura 28.

LOF score y umbral de outlier.

**Figura 29.**

Grafica del LOF score.



A continuación, en la Tabla 23 se observan los cuartiles y algunas medidas de tendencia central del conjunto de datos obtenidos después de depurar los outlier con el algoritmo LOF, estos datos se comparan con la Tabla 20 correspondientes a los datos antes del procesamiento y se concluye que mejora especialmente en lo valores máximos de habitaciones, baños y garajes. Los valores máximos de las variables área y precio no tuvieron un cambio relevante.

Tabla 23.

Cuartiles, mediana y promedio variables de conjunto de datos LOF

Valor	Mínimo	Primer cuartil Q_1	Mediana	Promedio	Tercer cuartil Q_3	Máximo
Área	21	71	97	118	143	650
Habitaciones	1	2	3	2.64	3	6
Baños	1	2	2	2.69	3	7
Estrato	1	4	5	4.89	6	6
Garajes	1	1	2	1.74	2	7
Latitud	4.445	4.672	4.697	4.693	4.719	4.798
Longitud	-74.21	-74.06	-74.05	-74.06	-74.04	-74.02
Precio	126*	630*	936*	1.294*	1.530*	9.935*
Tiempo construido	1	1	3	2.289	3	4

*Valores dados en millones de pesos

5.1.8 Detección outliers con algoritmo IForest

Isolation Forest es un algoritmo de aprendizaje automático no supervisado utilizado para detectar outliers construyendo arboles aleatorios para asilar las anomalías, porque éstas son más fáciles de separar que los valores normales. “iForest construye un conjunto de iTrees para un conjunto de datos dado; las anomalías son aquellas instancias que presentan longitudes de ruta promedio cortas en los iTrees. Este método solo tiene dos variables: el número de árboles a construir y el tamaño del submuestreo. Demostramos que el rendimiento de detección de iForest converge rápidamente

con un número muy pequeño de árboles, y que solo requiere un tamaño de submuestreo pequeño para lograr un alto rendimiento de detección con gran eficiencia.”(Fei Tony Liu et al., 2008).

“La detección de anomalías mediante iForest es un proceso de dos etapas. La primera etapa (entrenamiento) construye árboles de aislamiento utilizando submuestras del conjunto de entrenamiento. La segunda etapa (prueba) procesa las instancias de prueba a través de los árboles de aislamiento para obtener una puntuación de anomalía para cada instancia.”(Fei Tony Liu et al., 2008).

Los hiperparámetros utilizados en el IForest para la detección de outliers son:

- Número de árboles = 500
- Número de dimensiones/variables para el split = 3.
- Profundidad máxima = 5.
- Tamaño de la muestra = 256.

Un valor del conjunto de datos se asocia a un valor atípico cuando el valor de los resultados del *IForest score* supera un valor de umbral definido igual que con el algoritmo LOF, el valor del umbral es ajustado de manera heurística con apoyo de la Figura 30 y Figura 31 donde la línea azul son los *IForest score* del conjunto de datos, la línea roja corresponde al valor de umbral de 0.5, se selecciona este valor al evidenciar que agrupa gran parte del conjunto de datos. El punto de intersección con la línea azul indica la cantidad de registros considerados outliers, que para este caso es 4889. Por lo tanto, el conjunto de datos sin outlier entregado por el algoritmo IForest tiene 59766 registros.

Figura 30.

Histograma IForest score.





Figura 31.


IForest score y umbral de outlier.



En la Figura 32 se observa el *IForest score* asociado a cada registro, el color rojo son los outlier y los azules son los registros categorizados como normales o inlier.

Figura 32.

Grafica del IForest score.



A continuación, en la Tabla 24 se observan los cuartiles y algunas medidas de tendencia central del conjunto de datos obtenidos después de depurar los outlier con el algoritmo IForest, estos datos se comparan con la Tabla 20 correspondientes a los datos antes del procesamiento y se concluye que mejora especialmente en los valores máximos de área, habitaciones, baños, garajes y precio.

Tabla 24.

Cuartiles, mediana y promedio variables de conjunto de datos IForest.

Valor	Mínimo	Primer cuartil Q_1	Mediana	Promedio	Tercer cuartil Q_3	Máximo
Área	21.95	70	93	107.89	132	360
Habitaciones	1	2	3	2.583	3	6
Baños	1	2	2	2.585	3	6
Estrato	1	4	5	4.843	6	7
Garajes	1	1	2	1.644	2	5
Latitud	4.55	4.67	4.69	4.69	4.72	4.81
Longitud	-74.17	-74.06	-74.05	-74.06	-74.04	-74.02
Precio	115*	622*	891*	1116*	1384*	5400*
Tiempo construido	1	1	3	2.273	3	4

*Valores dados en millones de pesos

5.1.9 Detección outliers con algoritmo OCSVM

One-Class Support Vector Machine es un algoritmo de aprendizaje automático no supervisado utilizado para detectar outliers aprendiendo una frontera que encierra la mayoría de los datos normales en un espacio transformado mediante kernels, y marcando como anomalías los puntos que quedan fuera de esa región. “El algoritmo calcula una función binaria que se supone captura regiones en el espacio de entrada donde reside la densidad de probabilidad (su soporte), es decir, una función tal que la mayor parte de los datos residirán en la región donde la función es distinta de cero.” (Schölkopf et al., 1999).

OCSVM requiere que el conjunto de datos este normalizado, este proceso se hace de la misma manera que se realizó para el algoritmo LOF utilizado z-score.

Los hiperparámetros utilizados en el OC-SVM para la detección de outliers son:

- $\nu = 0.08$.
- $\gamma = 0.05$.
- Kernel = RBF (Radial Basis Function)

Se implementa el Kernel RBF representado en la ecuación (25) porque permite fronteras no lineales dado que los datos no están distribuidos linealmente, este kernel utiliza distancia euclidiana para medir la similitud entre dos puntos, por esto, es necesario normalizar el conjunto de datos.

$$K(x, x') = \exp\left(-\gamma \|x - x'\|^2\right) \quad (25)$$

A continuación, se presentan graficas con los datos normales (azul) y outlier (rojo) detectados con el algoritmo OCSVM.

Figura 33.

Outlier variables área y precio OCSVM.






Figura 34.

Outlier variables latitud y longitud OCSVM.

**Figura 35.**

Outlier variables habitaciones y baños OCSVM.



En los algoritmos LOF y IForest al procesar el conjunto de datos el resultado es un score y para definir si es un valor normal o atípico se debe seleccionar un valor de umbral de ese score para realizar la clasificación normal u outlier. En el caso de OCSVM, la clasificación de un dato como normal/outlier no depende de un umbral seleccionado, para esta clasificación se realiza una predicción utilizando el modelo entrenado con los datos originales de entrada, con ello el modelo determina que valor es normal y que valor es outlier. Como resultado el conjunto de datos depurado de outliers con OCSVM queda con 59481 registros.

A continuación, en la Tabla 25 se observan los cuartiles y algunas medidas de tendencia central del conjunto de datos obtenidos después de depurar los outlier con el algoritmo OCSVM, estos datos se comparan con la Tabla 20 correspondientes a los datos antes del procesamiento y se concluye que mejora especialmente en los valores máximos de área, habitaciones, baños, garajes y precio.

Tabla 25.

Cuartiles, mediana y promedio variables de conjunto de datos OCSVM.

Valor	Mínimo	Primer cuartil Q_1	Mediana	Promedio	Tercer cuartil Q_3	Máximo
Área	21.95	72	96	112.6	137	415
Habitaciones	1	2	3	2.613	3	5
Baños	1	2	2	2.641	3	6
Estrato	2	4	5	4.873	6	6
Garajes	1	1	2	1.691	2	4
Latitud	4.567	4.674	4.698	4.695	4.720	4.771
Longitud	-74.16	-74.06	-74.05	-74.06	-74.04	-74.02
Precio	115*	630*	918*	1190*	1440*	6120*
Tiempo construido	1	1	3	2.227	3	4

*Valores dados en millones de pesos

5.2 Análisis exploratorio de los datos (EDA)

En los procesos de machine learning la etapa EDA (Exploratory Data Analysis) incluye típicamente:

- Descripción del conjunto de datos.
- Detección de anomalías.
- Estadística descriptiva.
- Análisis de correlaciones.

La descripción de los datos fue abordado en el numeral 5.1.1, la detección de anomalías como outliers y valores faltantes fue tratado en los numerales 5.1.6, 5.1.7, 5.1.8 y 5.1.9. La estadística descriptiva fue parcialmente mencionada en los 5.1.5, 5.1.6, 5.1.7, 5.1.8 y 5.1.9 enfocándose en diagramas de caja y diagramas de frecuencia del conjunto de datos de referencia y en algunas medidas de tendencia central de los conjuntos de datos obtenidos después de la detección de outliers con los algoritmos LOF, IForest y OCSVM. A continuación, se completará la estadística descriptiva de los conjuntos de datos a tratar en esta investigación.

5.2.1 Diagramas de caja e histogramas de los conjuntos de datos

Los diagramas de caja (boxplot) e histogramas permiten conocer la distribución y dispersión de los datos, a continuación, se presentan estas graficas para comparar estas características entre los cuatro conjuntos de datos disponibles que son:

- Referencia: Datos sin valores faltantes y con outliers.
- LOF: Datos sin outliers entregados por el algoritmo LOF.
- IForest: Datos sin outliers entregados por el algoritmo IForest.
- OCSVM: Datos sin outliers entregados por el algoritmo OCSVM.

En la Tabla 26 se resumen los coeficientes de variación de cada variable de los cuatros conjuntos de datos, en él se observa como disminuye el Cv cuando se aplican los algoritmos de detección de outliers.

Tabla 26.

Coeficiente de variación de las variables de los conjuntos de datos.

Variable	Cv % Referencia	Cv % LOF	Cv % IForest	Cv % OCSVM
Área	62.02	59.11	47.54	51.18
Número de habitaciones	32.81	29.03	28.34	27.81
Número de baños	40.74	36.69	34.08	34.42
Estrato	24.88	21.34	21.22	20.84
Garajes	45.12	44.66	39.65	41.26
Latitud	0.83	0.75	0.70	0.69
Longitud	-0.043	-0.03	-0.03	-0.03
Tiempo construido	45.77	45.45	45.79	45.17
Precio	90.68	84.90	63.84	70.28

A continuación, se presentan los diagramas de caja e histogramas de las variables área, número de habitaciones, número de baños y precio correspondientes a los cuatro conjuntos de datos. Se selecciona estas variables porque el coeficiente de variación es más mayor.

Figura 36.

Diagramas de caja variable área, conjuntos de datos referencia, LOF, Iforest y OCSVM.





Figura 37.

Histograma variable área, conjuntos de datos referencia, LOF, Iforest y OCSVM.

**Figura 38.**

Diagramas de caja variable habitaciones, conjuntos de datos referencia, LOF, Iforest y OCSVM.





Figura 39.

Histograma variable habitaciones, conjuntos de datos referencia, LOF, Iforest y OCSVM.

**Figura 40.**

Diagramas de caja variable baños, conjuntos de datos referencia, LOF, Iforest y OCSVM.





Figura 41.

Histograma variable baños, conjuntos de datos referencia, LOF, Iforest y OCSVM.

**Figura 42.**

Diagramas de caja variable precio, conjuntos de datos referencia, LOF, Iforest y OCSVM.





Figura 43.

Histograma variable precio, conjuntos de datos referencia, LOF, Iforest y OCSVM.



Con los diagramas de caja e histogramas anteriores se evidencia que los conjuntos de datos LOF, IForest y OCSVM mejoran significativamente la calidad de los datos en especial con la depuración de valores atípicos superiores, por ejemplo, la variable número de baños en el conjunto de referencia tenía un outlier con un valor superior a 40, en los demás conjuntos ese valor quedo en máximo en 7 baños.

5.2.2 Medidas de tendencia central y dispersión

En la Tabla 27 y Tabla 28 se encuentran las principales medidas de tendencia central que son la mediana, media y moda aplicada según el tipo de variable, con esta información se determina algunos aspectos relevantes de los conjuntos de datos como:

En la variable precio, la media es mucho mayor que la mediana, esto indica que hay valores muy grandes que aumentan el promedio. Además, los valores de moda y mediana de la variable estrato están en 5 y 6, indicando que gran parte de los inmuebles están ubicados en sectores de alto valor.

Tabla 27.*Medidas de tendencia central conjunto de datos de referencia y LOF.*

Variable	Referencia			LOF		
	Mediana	Media	Moda	Mediana	Media	Moda
Área	96	117.76	N/A	97	118.61	N/A
Número de habitaciones	3	2.64	3	3	2.641	3
Número de baños	2	2.672	2	2	2.692	2
Estrato	5	N/A	6	5	N/A	6
Garajes	2	1.731	2	2	1.744	2
Latitud	4.696	4.693	N/A	4.696	4.693	N/A
Longitud	-74.051	-74.059	N/A	-74.051	-74.058	N/A
Tiempo construido	3	N/A	3	3	N/A	3
Precio	927*	1277*	N/A	936*	1293*	N/A

*Valores dados en millones de pesos

Tabla 28.*Medidas de tendencia central conjunto de datos de IForest y OCSVM.*

Variable	IForest			OCSVM		
	Mediana	Media	Moda	Mediana	Media	Moda
Área	93	107.89	N/A	93	112.66	N/A
Número de habitaciones	3	2.582	3	3	2.613	3
Número de baños	2	2.584	2	2	2.641	2
Estrato	5	N/A	6	5	N/A	6
Garajes	2	1.643	2	2	1.690	2
Latitud	4.698	4.695	N/A	4.697	4.694	N/A
Longitud	-74.051	-74.057	N/A	-74.051	-74.057	N/A
Tiempo construido	3	N/A	3	3	N/A	3
Precio	891*	1116*	N/A	918*	1189*	N/A

*Valores dados en millones de pesos

Tabla 29.

Medidas de tendencia dispersión conjunto de datos de referencia y LOF.

Variable	Referencia			LOF		
	Rango	Varianza	Desviación estándar	Rango	Varianza	Desviación estándar
Área	656	4877	69.83	629	4917	70.12
Número de habitaciones	65	0.771	0.878	5	0.588	0.766
Número de baños	45	1.023	1.011	6	0.976	0.987
Garajes	9	0.610	0.781	6	0.606	0.779
Latitud	0.368	0.001	0.036	0.353	0.001	0.035
Longitud	0.196	0.0007	0.027	0.195	0.0007	0.026
Precio	9827*	1.18e18	1089*	9809*	1.20e18	1098*

*Valores dados en millones de pesos

Tabla 30.

Medidas de tendencia dispersión conjunto de datos de IForest y OCSVM.

Variable	IForest			OCSVM		
	Rango	Varianza	Desviación estándar	Rango	Varianza	Desviación estándar
Área	338.05	2631	51.30	393.05	3325	57.66
Número de habitaciones	5	0.536	0.732	4	0.528	0.726
Número de baños	5	0.776	0.881	5	0.826	0.909
Garajes	4	0.425	0.651	3	0.487	0.697
Latitud	0.262	0.001	0.033	0.203	0.001	0.032
Longitud	0.151	0.0006	0.025	0.142	0.0006	0.025
Precio	5284*	5.07e17	712*	6007*	6.98e17	835*

*Valores dados en millones de pesos

En la Tabla 29 y Tabla 30 se encuentran las principales medidas de dispersión que son el rango, varianza y desviación estándar, con esta información se determinan algunos aspectos relevantes de los conjuntos de datos como:

- La variable precio tiene una alta dispersión, hay viviendas de lujo que distorsionan la distribución.
- En la variable área también hay alta dispersión, también asociado a viviendas muy grandes dado también el rango tan amplio. Es coherente con la dispersión presentada en la variable precio.
- La detección de valores atípicos con IForest muestra mejores resultados disminuyendo la varianza y reduciendo el rango, en especial en las variables precio y área.
- No se incluye la variable estrato y tiempo de construido porque son del tipo cualitativa ordinal.

5.2.3 Asimetría, curtosis, prueba de normalidad y correlación

En la Tabla 31 y Tabla 32 se encuentran los resultados del cálculo de asimetría, curtosis y p-value de normalidad utilizando la prueba Shapiro-Wilk para los conjuntos de datos y las variables cuantitativas continuas. Para las variables cuantitativas discretas los resultados de asimetría y curtosis no son significativos cuando tiene pocos valores posibles. Para realizar la prueba Shapiro-Wilk se utilizó una muestra de 1000 registros.

Tabla 31.

Asimetría, curtosis y prueba de normalidad conjunto de datos de referencia y LOF.

Variable	Referencia			LOF		
	Asimetría	Curtosis	p-value	Asimetría	Curtosis	p-value
Área	1.95056	8.1111	2.2e-16	1.90838	7.774213	2.2e-16
Latitud	-0.82179	4.7711	8.732e-11	-0.82789	4.935311	1.404e-12
Longitud	-1.70553	5.9524	2.2e-16	-1.76759	6.267318	2.2e-16
Precio	2.81567	14.034	2.2e-16	2.78157	13.73718	2.2e-16

Tabla 32.

Asimetría, curtosis y prueba de normalidad conjunto de datos de IForest y OCSVM.


Variable	IForest			OCSVM		
	Asimetría	Curtosis	p-value	Asimetría	Curtosis	p-value
Área	1.28375	4.51885	2.2e-16	1.48728	5.28457	2.2e-16
Latitud	-0.45317	3.03005	1.221e-07	-0.45150	2.96314	1.883e-09
Longitud	-1.62077	5.55593	2.2e-16	-1.63481	5.61628	2.2e-16
Precio	1.65756	6.03277	2.2e-16	1.97933	7.73340	2.2e-16

Los resultados de asimetría y curtosis indican que los datos no tienen una distribución normal porque la asimetría es diferente y lejana de 0, la curtosis tampoco tiene un valor cercano a 3, esto aplica a todas variables de los cuatro conjuntos de datos de estudio. Además, ninguna variable supero la prueba de normalidad. Por lo tanto, se aplica la correlación de Spearman que es la adecuada para datos que no presenten una distribución normal, en las siguientes figuras se encuentran las matrices de correlación de los cuatro conjuntos de datos.

Se identifica que las correlaciones más fuertes con la variable precio corresponden a las variables área, número de baños, estrato y número de garajes. Las variables tiempo de construido y latitud tienen una correlación muy débil con la variable precio.

Figura 44.

Matriz de correlación de Spearman para conjunto de datos de referencia.

**Figura 45.**

Matriz de correlación de Spearman para conjunto de datos LOF.






Figura 46.

Matriz de correlación de Spearman para conjunto de datos Iforest.

**Figura 47.**

Matriz de correlación de Spearman para conjunto de datos OCSVM.



5.2.4 Análisis de componentes principales

El PCA se emplea para determinar que componentes contienen mayor varianza (mayor información) dentro del conjunto de datos, esto es especialmente útil en conjuntos de datos con muchas variables y donde se hace necesario reducir la dimensionalidad. En este caso de estudio, el objetivo del análisis de componentes principales (PCA) es evaluar el aporte de cada variable a la varianza total de los datos, como se muestra en la Figura 48.

Para este análisis, se excluye la variable precio, dado que el objetivo es estudiar cómo se relacionan las variables independientes entre sí. En todos los conjuntos de datos, la PC1 representa aproximadamente el 40% de la varianza, la acumulación con la PC3 alcanza cerca del 72%, y con la PC5 se acumula cerca del 90%, como se detalla en la Tabla 33.

En la Figura 49 se presenta el círculo de correlación, donde se visualiza el aporte de cada variable a PC1 y PC2. También se muestran los valores de $\cos^2$, que indican qué tan bien está representada cada variable en el componente principal. Para simplificar la presentación, se muestra únicamente el conjunto de datos correspondiente a OCSVM, dado que la distribución es similar en los cuatro conjuntos. La variable “Tiempo de construido” tiene valores de $\cos^2$ bajos en casi todos los componentes, como se observa en la Tabla 34. Los valores son especialmente bajos excepto para PC4. Considerando además que su correlación máxima con la variable objetivo (precio) es 0.04, y que su correlación máxima con otras variables es 0.23 según la correlación Spearman, esta variable puede ser considerada como candidata a eliminar de los datos antes de la construcción de los modelos predictivos.


Tabla 33.

Proporción de la varianza acumulada de los conjuntos de datos.

Componente	Referencia	LOF	IForest	OCSVM
PC1	0.395	0.409	0.384	0.400
PC2	0.578	0.593	0.565	0.579
PC3	0.722	0.739	0.721	0.730
PC4	0.845	0.862	0.844	0.853
PC5	0.894	0.905	0.893	0.897
PC6	0.935	0.944	0.936	0.939
PC7	0.973	0.975	0.973	0.975
PC8	1	1	1	1

Figura 48.

Varianza explicada por componente de los conjuntos de datos.

**Figura 49.**

Círculo de correlación, conjunto de datos OCSVM.




Tabla 34.

Valor de $\cos^2$ de la variable tiempo en los componentes principales de los conjuntos de datos.

Componente	$\cos^2$ Tiempo Referencia	$\cos^2$ Tiempo LOF	$\cos^2$ Tiempo IForest	$\cos^2$ Tiempo OCSVM
PC1	0.0485	0.0488	0.0571	0.0565
PC2	0.0239	0.0315	0.0771	0.0618
PC3	0.1300	0.1240	0.0224	0.0674
PC4	0.7730	0.7730	0.8140	0.7900
PC5	0.0194	0.0159	0.0162	0.0151
PC6	0.000196	0.0000248	0.000499	0.000413
PC7	0.00134	0.00425	0.0104	0.00721
PC8	0.00341	0.00203	0.00192	0.00195

5.3 Modelos predictivos

Para definir la estructura del modelo predictivo se empleará metodología empírica experimental y modelación. Para esta investigación se utilizan modelos de distintas familias con el objetivo de comparar evaluando diferencias en capacidad predictiva, robustez y adaptación a relaciones no lineales.

Los algoritmos empleados son ElasticNet (Lineal regularizado), Random Forest (Bagging de árboles), XGBoost (Boosting) y MLP (Red neuronal). Estos algoritmos tienen fundamentos diferentes para la predicción lo cual enriquece esta investigación.

Cada conjunto de datos (referencia, LOF, IForest y OCSVM) fue dividido de manera aleatoria para obtener un 70% de los datos para el entrenamiento de los modelos y el 30% restante para la evaluación. Para validar el desempeño de los modelos predictivos se utilizó las métricas RMSE, MAE, MAPE y R^2 .

5.3.1 ElasticNET

Elastic Net es un método de regresión lineal regularizada que combina las penalizaciones L1 y L2, integrando las propiedades de selección de variables de *Lasso* y la estabilidad de *Ridge*. Esto

permite controlar el sobreajuste y manejar problemas de multicolinealidad en conjuntos de datos con múltiples variables predictoras correlacionadas.

La regresión Ridge introduce una penalización L2 que reduce la magnitud de los coeficientes mediante la minimización de una función de pérdida modificada, lo que permite mejorar la estabilidad del modelo al reducir la varianza, pero incrementando el sesgo (James et al., 2013). Esta característica es clave dentro de Elastic Net, porque forma parte de su estructura de regularización combinada. El algoritmo ElasticNet realiza la normalización Z-score de los datos antes del entrenamiento del modelo, el hiperparámetro Alpha puede tener valores entre 0 y 1, donde 0 es la penalización Ridge y 1 es la penalización Lasso, en este caso de estudio, los modelos tuvieron mejor desempeño predictivo con valores de Alpha superiores a 0.5, donde las métricas RMSE y MAE convergen.

Tabla 35.

Medidas de desempeño algoritmo ElasticNET con Alpha=0 (Ridge)

Conjunto de datos	RMSE	MAE	MAPE%	R^2
Referencia	487.319.853	277.963.492	24.54%	0.8034904
LOF	482.059.881	273.093.676	23.94%	0.8107662
IForest	295.297.959	195.392.842	18.95%	0.8296107
OCSVM	338.437.147	220.096.617	20.39%	0.8370937

*RMSE y MAE en pesos colombianos.

Tabla 36.

Medidas de desempeño algoritmo ElasticNET con Alpha=1 (Lasso)

Conjunto de datos	RMSE	MAE	MAPE%	R^2
Referencia	463.057.042	267.405.327	24.49%	0.8105664
LOF	460.323.352	268.196.462	24.00%	0.819306
IForest	288.311.793	190.731.256	18.98%	0.8371621
OCSVM	322.443.571	222.443.571	20.29%	0.8501889

*RMSE y MAE en Pesos colombianos.

A continuación, se presentan los gráficos de dispersión entre valores reales y la recta que mejor se ajusta a la distribución de los datos utilizando la regularización Lasso (Alpha=1).

A continuación, en la Tabla 37 se encuentran los valores lambda mínimo y lambda1se (Lambda dentro de 1 error estándar) para cada uno de los modelos, las cuales son métricas para seleccionar la regularización y controla la complejidad del modelo. Con λ_{1se} el modelo es más estable y tiene mayor capacidad de generalización respecto a λ_{min} por lo tanto, es el utilizado en los modelos generador por ElasticNet.

Figura 50.

Dispersión de valores reales y recta estimada con el conjunto de datos IForest.




Tabla 37.

Lambda mínimo y lambda1se

Conjunto de datos	λ_{min}	λ_{1se}
Referencia	2677374	27403757
LOF	1711123	25409629
IForest	1744913	17859727
OCSVM	1909431	13470658

Figura 51.

Dispersión de valores reales y recta estimada con el conjunto de datos OCSVM.



Con estos resultados se determina que el modelo ElasticNet con mejor desempeño fue el configurado así:

- Alpha=1, regularización Lasso.
- Modelo entrenado con conjunto de datos IForest, ver Tabla 36.

5.3.2 Random Forest

Random Forest es un método de ensamble basado en la construcción de múltiples árboles de decisión entrenados (Bagging) a partir de muestras aleatorias del conjunto de datos y subconjuntos de variables predictoras. La combinación de estos árboles permite mejorar la capacidad de generalización del modelo, reduciendo la varianza asociada a predicciones individuales. Según Breiman (2001), el error de generalización del bosque converge a un valor límite a medida que aumenta el número de árboles, el cual depende de la precisión de los clasificadores individuales y de la correlación entre ellos.

Los hiperparámetros principales de Random Forest son mtry y el número de árboles. Mtry corresponde al número de variables que se evalúan aleatoriamente para cada división de un nodo (Split). La función “tuneRF” de la librería “Ranfom Forest” entrena varios RandomForest con valores diferentes de mtry buscando el valor menor del error OOB con 500 árboles. Los hiperparámetros utilizados para la función “tuneRF” fueron:

- $\text{stepFactor} = 1.5$: Es el factor que aumenta el mtry en cada iteración.
- $\text{improve} = 0.01$: Criterio de parada del algoritmo, este itera hasta que la diferencia en el error entre el modelo actual y el modelo anterior sea igual o menor a este valor que corresponde al 1%.

Se aplicó la función “`tuneRF`” a los cuatro conjuntos de datos, el resultado de mtry donde converge el error OOB es de 4 para todos los conjuntos de datos, a continuación, se presenta las gráficas de convergencia del error OOB y el número de mtry para los conjuntos de datos de referencia y OCSVM para visualizar los resultados que son similares para los conjuntos de datos LOF y IForest.

Figura 52.

Error OOB vs número de mtry para el conjunto de datos de referencia.





Figura 53.

Error OOB vs número de mtry para el conjunto de datos OCSVM.




Con estos resultados, se define que un valor de mtry igual a 4 es un valor adecuado para implementar en los modelos predictivos a ser entrenados con los conjuntos de datos referencia, LOF, IForest y OCSVM. Este valor de mtry se aproxima a la heurística encontrada en diversa literatura donde sugieren que para modelos predictivos usar un mtry cercano a un tercio de las variables explicativas.

Para seleccionar el número de árboles adecuados, se sigue el mismo criterio usado para el mtry, seleccionar la cantidad de árboles donde el error OOB converge, para esto, se aplica la función “Random Forest” para calcular el error OOB iterando desde 1 hasta 500 árboles con el conjunto de datos IForest. Cuando se utiliza 500 árboles el error OOB es de $3.786e16$, este valor converge con cerca de 270 árboles con un error OOB de $3.799e16$, por lo tanto, se selecciona 270 árboles para el entrenamiento de los modelos predictivos. En la Figura 54 se encuentra el error OOB respecto al número de árboles del Random Forest, la línea roja es un error OOB de $3.8e16$ donde la intersección muestra el área donde el error empieza a converger y corresponde a los 270 árboles aproximadamente.

Figura 54.

Error OOB vs número de árboles para el conjunto de datos IForest.



Utilizando 270 árboles y un mtry de 4, se entrenan los modelos Random Forest con los 4 conjuntos de datos y los resultados se encuentran la Tabla 38.

Tabla 38.*Medidas de desempeño algoritmo Random Forest*

Conjunto de datos	RMSE	MAE	MAPE %	R^2
Referencia	281.622.482	135.296.699	9.90%	0.9344442
LOF	271.449.718	128.562.784	9.27%	0.9401299
IForest	180.605.754	102.731.883	9.17%	0.9364325
OCSVM	207.648.458	113.753.605	9.32%	0.9387616

*RMSE y MAE en pesos

Con estos resultados se determina que el modelo Random Forest con mejor desempeño fue el configurado así:

- Número de árboles 270.
- Mtry de 4.
- Modelo entrenado con conjunto de datos IForest, ver Tabla 38.

5.3.3 XGBoost

El algoritmo XGBoost (eXtreme Gradient Boosting) es “un sistema escalable para el boosting de árboles” (Tianqi Chen & Carlos Guestrin, 2016) que construye modelos mediante árboles de decisión entrenados secuencialmente para optimizar una función objetivo. El algoritmo XGboost tiene aproximadamente 11 hiperparámetros que controla la construcción de los árboles, para esta investigación el ajuste se va a centrar en los seis siguientes:

- Nrounds: Número máximo de iteraciones.
- Eta (Learning rate) Tasa de aprendizaje, es el tamaño del paso que se utiliza en las iteraciones.
- max_depth: Profundidad máxima del árbol, permite controlar el sobre ajuste, un valor alto hace el algoritmo más complejo porque aprende relaciones muy específicas. Un valor bajo ayuda a la generalización del modelo.
- Subsample: Es la fracción de observaciones que se muestrearán aleatoriamente por cada árbol, los valores pequeños evitan el sobreajuste.

- `Colsample_bytree`: Representa la fracción de las variables utilizadas en cada árbol. Un valor puede provocar sobreajuste porque considera más características en cada división.
- `min_child_weight`: Suma mínima del peso, si el paso de partición en árbol da como resultado un nodo hoja con la suma del peso de la instancia menor, entonces el proceso de construcción renunciará a una partición adicional.

Para la búsqueda de los valores de los hiperparámetros se empleó *Grid Search* y *random search*, donde *Grid Search* es “La búsqueda en cuadrícula que puede describirse como una exploración exhaustiva o un método de fuerza bruta que prueba todas las combinaciones de hiperparámetros dadas a la configuración de la cuadrícula. Está opera evaluando el producto cartesiano de un conjunto finito de valores definidos por el usuario” (Belete & Huchaiah, 2022).

La búsqueda aleatoria “se consideraba en la década de 1950 como un método de optimización global. Es quizás el procedimiento conceptualmente más sencillo para la optimización de alto rendimiento. *Random Search* consiste en extraer repetidamente configuraciones de hiperparámetros de una distribución predefinida ν sobre Λ , y se puede paralelizar fácilmente.” (Franceschi et al., 2025).

Para *Grid Search* se utilizaron los siguientes rangos en sus respectivos hiperparámetros:

- `nrounds` = 50 y 100
- `max_depth` = 2, 3, 5, 7, 10
- `eta` = 0.01, 0.1, 0.3
- `gamma` = 0
- `colsample_bytree` = 0.7, 0.8, 0.9, 1
- `min_child_weight` = 1
- `subsample` = 0.7, 0.8, 0.9, 1

Estos rangos fueron definidos basados en el trabajo de (Philipp Probst et al., 2019) donde: “En primer lugar, formalizan el problema de la optimización desde un punto de vista estadístico, definiendo valores predeterminados basados en datos y sugieren medidas generales que cuantifican la capacidad de optimización de los hiperparámetros de los algoritmos. Los resultados proporcionan valores predeterminados para los hiperparámetros y permiten a los usuarios decidir si merece la pena llevar a cabo una estrategia de ajuste que podría consumir mucho tiempo,

centrarse en los hiperparámetros más importantes y elegir espacios de hiperparámetros adecuados para el ajuste.” En la Tabla 39 se encuentran los valores para los hiperparámetros resultantes de los métodos de búsqueda *Grid Search* y *Random Search*. Estas búsquedas se realizaron con el conjunto de datos IForest solamente, esto debido a su costo computacional de ejecutarlos con los cuatro conjuntos de datos disponibles.

Tabla 39.

Valores hiperparámetros obtenidos con Grid Search y Random Search para XGBoost.

Hiperparámetros	Grid Search	Random Search
Nrounds	100	250
Eta	0.1	0.3
Max_depth	10	5
Subsample	0.7	0.875
Colsample_bytree	1	0.7
min_child_weight	1	1

Con los valores de los hiperparámetros seleccionados, se entrenan los modelos obteniendo el desempeño de la Tabla 40 para los modelos utilizando los valores resultantes de *Grid Search* y Tabla 41 para *Random Search*.

Tabla 40.

Medidas de desempeño algoritmo XGBoost con hiperparámetros Grid Search.

Conjunto de datos	RMSE	MAE	MAPE%	R^2
Referencia	291.644.885	148.569.228	11.16%	0.9296175
LOF	277.475.423	140.034.794	10.31%	0.9373031
IForest	189.099.246	113.246.462	10.11%	0.9301284
OCSVM	212.177.251	119.397.333	9.84%	0.9359706

*RMSE y MAE en pesos colombianos.

Tabla 41.

Medidas de desempeño algoritmo XGBoost con hiperparámetros Random Search.

Conjunto de datos	RMSE	MAE	MAPE %	R^2
Referencia	309.889.992	165.023.339	12.43%	0.9205359
LOF	296.248.539	157.576.486	11.77%	0.9285324
IForest	203.485.900	126.915.010	11.28%	0.9190923
OCSVM	230.165.931	137.884.646	11.55%	0.9246533

*RMSE y MAE en pesos colombianos.

Para los dos grupos de hiperparámetros, el modelo entrenado con el conjunto de datos IForest tiene los mejores resultados en las métricas RMSE, MAE y MAPE.


Una de las ventajas de XGBoost es la interpretabilidad que se obtiene con la característica “Importancia” que corresponde a la contribución de cada variable a la capacidad predictiva de los modelos. A continuación, se expone la importancia de las variables para los modelos entrenados con los conjuntos de datos IForest y OCSVM que son los de mejor desempeño con ambos grupos de hiperparámetros.

Comparando la importancia de las variables entre los modelos entrenados con los valores de los hiperparámetros obtenidos con *Grid Search* y *Random Search*, si existe una diferencia sustancial, a pesar que las métricas RMSE, MAE, MAPE y R^2 sean muy similares entre ambos grupos.

Para los modelos con los hiperparámetros *Grid Search*, la importancia de la variable área es de 0.78 para el conjunto de datos IForest y de 0.81 para los datos OCSVM, este valor indica que dicha variable es dominante dentro del modelo o bien que puede existir overfitting. Para los modelos con los hiperparámetros *Random Search*, la importancia de la variable área es de 0.49 para el conjunto de datos IForest y de 0.50 para los datos OCSVM, este valor indica que el modelo es más distribuido y robusto.

Figura 55.

Importancia de las variables del modelo con hiperparámetros Grid search y datos IForest.

**Figura 56.**

Importancia de las variables del modelo con hiperparámetros Random search y datos IForest.






Figura 57.

Importancia de las variables del modelo con hiperparámetros Grid search y datos OCSVM.

**Figura 58.**

Importancia de las variables del modelo con hiperparámetros Random search y datos OCSVM.



Con estos resultados se determina que el modelo XGBoost con mejor desempeño fue el configurado así:

- Valores de hiperparámetros obtenidos por *Random Search*, a pesar que las métricas sean mejores con *Grid Search*, la característica de importancia de las variables es más balanceado y robusto con *Random Search* ver Tabla 39.
- Modelo entrenado con conjunto de datos IForest, ver Tabla 41.

5.3.4 Red perceptrón multicapa

“El modelo MLP es el modelo de red neuronal más fundamental e importante. También es el modelo de red neuronal más investigado. Incluso en esta era de la IA o el aprendizaje profundo, el MLP sigue estando entre los pocos modelos de redes neuronales más investigados y utilizados. Se han obtenido numerosos resultados nuevos en las últimas tres décadas.” (Du et al., 2022).

Para esta investigación el ajuste se va a centrar en los seis siguientes hiperparámetros:

- Función de activación: Transformación no lineal aplicada a la salida de una neurona, que permite a la red neuronal modelar relaciones complejas y no lineales entre las variables de entrada y la salida.
- Hidden: Estructura de la MLP definiendo número de capas y número de neuronas por cada capa.
- Rate; Determina el tamaño de los pasos en el espacio de parámetros durante el descenso del gradiente hacia la minimización de la función de pérdida.
- L1 y L2: Penalizaciones a la función de pérdida.
- input_dropout_ratio: Proporción de variables de entrada que se desactivan aleatoriamente durante cada iteración para reducir el sobreajuste y mejorar la capacidad de generalización del modelo.

La función de activación fue “ReLU” que es la más ampliamente utilizada por su buen desempeño en problemas de regresión y su eficiencia computacional.

Para la búsqueda de los valores de los hiperparámetros se empleó *random search* utilizando como referencia de búsqueda los valores de la columna 2 y obteniendo los resultados de la columna 4 de la Tabla 42. La búsqueda no se realizó tipo *Grid Search* por el alto costo computacional.

Tabla 42.

Valores de referencia y obtenidos del Random Search.

Hiperparámetros	Referencia	Valores obtenidos
Hidden	32 16	128 64 32
	32 32	
	64 32	
	64 64	
	128 64	
	128 64 32	
Rate	0.001	0.01
	0.01	
	0.05	
	0.1	
L1	0	0
	1e-5	
	1e-4	
L2	0	1e-04
	1e-5	
	1e-4	
input_dropout_ratio	0	0
	0.1	
	0.2	
	0.3	

Para la búsqueda de hiperparámetros tipo *Random Search* el modelo MLP fue entrenado durante 20 épocas utilizando validación cruzada de 4 folds. Las variables fueron estandarizadas automáticamente para mejorar la estabilidad numérica del entrenamiento. Se implementó un mecanismo de early stopping basado en RMSE con tolerancia de 10^{-4} y 5 rondas consecutivas sin mejora detiene el entrenamiento. Además, se estableció una semilla aleatoria de 123 para garantizar reproducibilidad experimental.

Para entrenar los modelos MLP con los conjuntos de datos de referencia, LOF, IForest y OCSVM se utilizaron los siguientes parámetros:

- Función de activación ReLU.
- Épocas = 100.
- Hidden = 128 64 32.
- Rate = 0.01.

- $L1 = 0$.
- $L2 = 1e-04$.
- $input_dropout_ratio = 0$.
- Métrica de parada = RMSE.
- Rondas de parada = 50.
- Semilla aleatoria = 123.
- Datos estandarizados = Si.

En las figuras 59, 60, 61 y 62 se muestran las curvas de convergencia de los modelos con cada conjunto de datos, se evidencia que efectivamente el RMSE disminuye a lo largo de las épocas y no existe comportamientos que indiquen sobre ajuste.

Con los valores de los hiperparámetros seleccionados, se entrenan los modelos obteniendo el desempeño de la Tabla 43 para los modelos utilizando los valores resultantes del *Random Search*. Con estos resultados se determina que el modelo MLP con mejor desempeño fue el entrenado con el conjunto de datos IForest.

Tabla 43.


Medidas de desempeño algoritmo MLP

Conjunto de datos	RMSE	MAE	MAPE%	R^2
Referencia	333.979.865	173.588.733	12.98%	0.9057956
LOF	325.949.104	171.050.010	12.67%	0.9157696
IForest	214.575.732	130.817.751	11.74%	0.9087117
OCSVM	238.948.447	143.202.332	12.10%	0.9199419

*RMSE y MAE en pesos colombianos.

Figura 59.

Curva de convergencia del entrenamiento con conjunto de datos de referencia.

**Figura 60.**

Curva de convergencia del entrenamiento con conjunto de datos LOF.






Figura 61.

Curva de convergencia del entrenamiento con conjunto de datos IForest.

**Figura 62.**

Curva de convergencia del entrenamiento con conjunto de datos OCSVM.



6. Resultados y discusión

6.1 Desempeño global de los modelos

En esta sección se presenta el desempeño global de los modelos predictivos entrenados con los algoritmos ElasticNet, Random Forest, XGBoost y MLP. Empleando los cuatro conjuntos de datos: el conjunto de referencia y los conjuntos con detección de valores atípicos mediante LOF, Isolation Forest y OCSVM.

El análisis se realiza con las métricas RMSE, MAE, MAPE y R^2 (ver Tabla 44) y así identificar las configuraciones con mejor capacidad predictiva.

Tabla 44.

Desempeño global modelos ElasticNet, Random Forest, XGBoost y MLP.

Modelo	Conjunto de datos	RMSE	MAE	MAPE %	R^2
ElasticNet	Referencia	463.057.042	267.405.327	24.49%	0.8105664
	LOF	460.323.352	268.196.462	24.00%	0.819306
	IForest	288.311.793	190.731.256	18.98%	0.8371621
	OCSVM	322.443.571	222.443.571	20.29%	0.8501889
Random Forest	Referencia	281.622.482	135.296.699	9.90%	0.9344442
	LOF	271.449.718	128.562.784	9.27%	0.9401299
	IForest	180.605.754	102.731.883	9.17%	0.9364325
	OCSVM	207.648.458	113.753.605	9.32%	0.9387616
XGBoost	Referencia	309.889.992	165.023.339	12.43%	0.9205359
	LOF	296.248.539	157.576.486	11.77%	0.9285324
	IForest	203.485.900	126.915.010	11.28%	0.9190923
	OCSVM	230.165.931	137.884.646	11.55%	0.9246533
MLP	Referencia	333.979.865	173.588.733	12.98%	0.9057956
	LOF	325.949.104	171.050.010	12.67%	0.9157696
	IForest	214.575.732	130.817.751	11.74%	0.9087117
	OCSVM	238.948.447	143.202.332	12.10%	0.9199419

*RMSE y MAE en pesos colombianos.

El modelo ElasticNet presenta el desempeño más bajo en todos los escenarios, lo cual sugiere limitaciones para capturar relaciones no lineales presentes en los datos.

Random Forest es el modelo con mejor desempeño global, alcanzando los menores errores con todos los conjuntos de datos, con un RMSE mínimo 180.605.754 y un MAE de 102.731.883 con el conjunto de datos IForest.

XGBoost presenta un desempeño consistente y cercano al Random Forest, manteniéndose como uno de los modelos más robustos. El modelo MLP muestra un desempeño competitivo, aunque inferior a los modelos basados en ensamble, evidenciando sensibilidad a la calidad del conjunto de datos.

En términos generales, se observa que los modelos basados en ensamble, como Random Forest y XGBoost, presentan el mejor desempeño en los conjuntos de datos evaluados, al obtener los menores valores de RMSE y MAE. No obstante, los modelos entrenados con el conjunto de datos procesado mediante Isolation Forest no presentan necesariamente los valores más altos de R^2 en comparación con los demás escenarios. Este comportamiento indica que la reducción de errores absolutos no implica necesariamente una mayor varianza explicada, ya que ambas métricas capturan aspectos distintos del desempeño del modelo.

6.2 Impacto en la detección de valores atípicos

En relación con los conjuntos de datos utilizados, se observa que las técnicas de detección de valores atípicos mejoran el desempeño de todos los modelos en comparación con el conjunto de referencia. En particular, el conjunto de datos IForest genera los mejores resultados para los algoritmos evaluados como se evidencia en la Tabla 45 y Tabla 46. Logrando así reducciones consistentes en RMSE y MAE. OCSVM presenta mejoras moderadas, mientras que LOF muestra un desempeño limitado e inconsistente, especialmente en modelos lineales como ElasticNet.

Tabla 45.*Porcentaje de mejora en RMSE de los modelos.*

Modelo	LOF	IForest	OCSVM
ElasticNet	0.59%	37.78%	30.37%
Random Forest	3.61%	35.89%	26.26%
XGBoost	4.40%	34.35%	25.77%
MLP	2.40%	35.79%	28.42%

Tabla 46.*Porcentaje de mejora en MAE de los modelos.*

Modelo	LOF	IForest	OCSVM
ElasticNet	-0.30%	28.72%	16.83%
Random Forest	4.98%	24.08%	15.87%
XGBoost	4.52%	23.12%	16.44%
MLP	1.46%	24.69%	17.45%

La eliminación de valores atípicos tiene un impacto más significativo en errores cuadráticos (RMSE) que en errores absolutos (MAE), lo que indica que los valores atípicos afectan principalmente los errores extremos de los modelos.

6.3 Análisis de residuos

El análisis de residuos evidenció que la aplicación de técnicas de detección de valores atípicos mejoró consistentemente el desempeño de los modelos predictivos. En particular, los conjuntos de datos tratados mediante Isolation Forest presentaron menor dispersión residual y una reducción importante de errores extremos, indicando una mayor estabilidad en las predicciones.

Entre los modelos evaluados, Random Forest y XGBoost mostraron los residuos más estables y errores promedio más cercanos a cero, sugiriendo una mayor robustez predictiva. Por el contrario, ElasticNet y MLP evidenciaron mayor sensibilidad a los valores atípicos en el conjunto de datos

de referencia, aunque mejoraron considerablemente tras la aplicación de técnicas de detección de anomalías como LOF, Isolation Forest y OCSVM.

Los resultados presentados en la Tabla 47 muestran que los mayores porcentajes de mejora se obtuvieron utilizando conjuntos de entrenamiento depurados mediante Isolation Forest. Las mejoras alcanzaron hasta un 39 % en la desviación estándar residual para ElasticNet, un 79 % en el error promedio para MLP y un 63 % en el error máximo absoluto para Random Forest.

Tabla 47.

Sesgo de predicción (Bias) de los modelos ElasticNet, Random Forest, XGBoost y MLP.

Modelo	Conjunto de datos	Error promedio	Desviación estándar	Error máximo absoluto
ElasticNet	Referencia	3.059.930	476.413.534	5.432.809.240
	LOF	2.695.873	471.025.158	5.558.871.463
	IForest	2.469.773	289.956.708	2.650.486.261
	OCSVM	3.862.129	329.524.789	2.707.992.153
Random Forest	Referencia	-709.172	280.904.175	5.759.877.429
	LOF	-676.480	271.400.806	4.335.260.666
	IForest	802.893	180.626.949	2.095.047.298
	OCSVM	534.071	207.632.255	2.670.973.158
XGBoost	Referencia	1.608.421	320.628.990	6.304.174.912
	LOF	1.919.499	301.636.277	4.170.220.288
	IForest	942.802	206.056.224	2.529.192.832
	OCSVM	-1.495.241	230.659.965	2.353.276.160
MLP	Referencia	34.582.490	333.650.901	7.276.753.227
	LOF	-13.060.056	322.980.469	4.251.337.743
	IForest	7.166.135	215.973.057	3.354.176.329
	OCSVM	-8.301.640	239.170.044	2.790.318.024

*Valores en pesos colombianos.

Otro aspecto relevante es la distribución de los residuos, en las figuras 63, 64, 65 y 66 se observa que la distribución del error se amplió conforme crece el valor de la variable objetivo precio en todos los modelos. Esto sugiere que la varianza del error depende del nivel de la variable objetivo y constituye una característica inherente de los datos, la heterocedasticidad observada indica que el desempeño predictivo varía especialmente en valores altos de la variable precio.

La diferencia sistemática entre el RMSE siempre es mayor que el MAE, sugiere la presencia de errores extremos en las observaciones. Esto junto con la heterocedasticidad observada indica que el desempeño predictivo no es homogéneo y que en valores altos de la variable precio presenta mayor incertidumbre.

Figura 63.

Residuos vs valores predichos modelo ElasticNet y conjunto IForest.





Figura 64.

Residuos vs valores predichos modelo Random Forest y conjunto IForest.

**Figura 65.**

Residuos vs valores predichos modelo XGBoost y conjunto IForest.





Figura 66.

Residuos vs valores predichos modelo MLP y conjunto IForest.



6.4 Complejidad computacional

El modelo ElasticNet presenta una complejidad aproximadamente lineal $O(n)$, lo que lo convierte en el algoritmo más eficiente computacionalmente en esta investigación. Los modelos basados en ensamble de árboles, como Random Forest y XGBoost, presentan una complejidad del orden $O(n \log n)$ pero XGBoost tiende a presentar un mayor costo computacional debido a su entrenamiento secuencial y al proceso de optimización basado en gradientes.

El perceptrón multicapa (MLP) es típicamente $O(n \log n)$, sin embargo, presenta una complejidad dependiente del número de operaciones por capa y de las iteraciones de entrenamiento, lo que lo convierte en el modelo de mayor costo computacional en la práctica.

Otro aspecto relevante que impacta la complejidad computacional del proceso es la selección de hiperparámetros. Para el algoritmo XGBoost, se aplicaron estrategias de búsqueda como *Grid Search* y *Random Search*, lo que incrementa significativamente el tiempo de entrenamiento debido a la evaluación repetida de múltiples combinaciones de hiperparámetros.

Para el modelo MLP, se utilizó únicamente la búsqueda *Random Search*, porque que la aplicación de *Grid Search* fue descartada debido a su alto costo computacional asociado al gran número de combinaciones posibles y al tiempo de entrenamiento requerido por cada configuración.

En conjunto, estas estrategias de optimización contribuyen de manera importante al costo computacional total del experimento, especialmente en modelos de mayor complejidad como los basados en boosting y redes neuronales.

6.5 Selección del modelo predictivo

Con la evaluación de los 16 modelos entrenados en esta investigación, se selecciona el modelo Random Forest entrenado con el conjunto de datos depurado mediante Isolation Forest como el modelo con mejor desempeño y mayor robustez para la predicción de precios de viviendas en Bogotá. Esta selección se fundamenta en los siguientes criterios:

- Menores valores de RMSE, MAE y MAPE en comparación con los demás modelos evaluados.
- Menor error promedio, menor desviación estándar del error y menor error máximo absoluto.
- Menor costo computacional en comparación con modelos como XGBoost y MLP.
- Menor complejidad en el ajuste de hiperparámetros, lo que facilita su entrenamiento y replicabilidad.

En conjunto, estos resultados permiten concluir que este modelo cumple de manera satisfactoria el objetivo general de la investigación, al proporcionar una solución eficiente, robusta y de alto desempeño para la predicción del precio de viviendas.

7. Conclusiones

Se logró diseñar un modelo predictivo para la estimación del precio de viviendas en Bogotá mediante técnicas de machine learning. El modelo más efectivo correspondió a Random Forest entrenado con el conjunto de datos depurado mediante Isolation Forest, el cual presentó el mejor balance entre error de predicción, estabilidad y robustez frente a valores atípicos.

Las técnicas de preparación y depuración de datos, incluyendo LOF, Isolation Forest y OCSVM, permitieron mejorar la calidad del conjunto de datos y reducir inconsistencias, lo cual se reflejó en una mejora general del desempeño de los modelos predictivos.

Se definió una estructura de modelado basada en la comparación de modelos lineales, ensambles y redes neuronales, identificando que los modelos basados en ensamble, particularmente Random Forest y XGBoost, presentan la estructura más adecuada para la predicción del precio de viviendas debido a su capacidad para capturar relaciones no lineales y manejar datos con ruido.

La validación del desempeño mediante métricas como RMSE, MAE, MAPE y R^2 permitió evidenciar que el modelo seleccionado presenta la mayor precisión predictiva y estabilidad, cumpliendo de manera satisfactoria con los criterios de exactitud establecidos en la investigación.

La aplicación de técnicas de detección de valores atípicos mejoró consistentemente el desempeño de todos los modelos evaluados, evidenciando que la presencia de outliers afecta de manera significativa la capacidad predictiva de los algoritmos, siendo Isolation Forest la técnica con mayor impacto positivo en la reducción de errores.

Se identificó la presencia de heterocedasticidad en los residuos, indicando que la varianza del error no es constante y aumenta con el nivel del precio de la vivienda, lo que sugiere una estructura no homogénea en los datos.

8. Principales aportes

La principal contribución de esta investigación consiste en demostrar empíricamente el impacto de la detección de valores atípicos sobre el desempeño de modelos de predicción de precios de vivienda en Bogotá mediante técnicas de machine learning. A través de un esquema experimental basado en 16 configuraciones de modelado, se cuantificó el efecto de las técnicas LOF, Isolation Forest y OCSVM sobre modelos lineales, ensambles y redes neuronales, evidenciando mejoras consistentes en precisión predictiva tras la eliminación de valores atípicos.

Los resultados muestran que Isolation Forest produce las mayores reducciones de error, alcanzando mejoras de hasta 37% en RMSE y 28% en MAE respecto al conjunto de referencia, validando la relevancia de la detección de valores atípicos en los datos.

La investigación también evidencia que los modelos basados en ensamble, particularmente Random Forest y XGBoost, presentan mayor robustez frente a ruido y relaciones no lineales en comparación con modelos lineales y redes neuronales, siendo Random Forest el modelo con mejor desempeño global.

Adicionalmente, el análisis residual permitió identificar heterocedasticidad en los errores de predicción, mostrando que la incertidumbre aumenta en viviendas de mayor valor y aportando evidencia sobre el comportamiento no homogéneo de los datos.

Finalmente, se aporta una metodología reproducible para la evaluación integrada de técnicas de detección de valores atípicos y modelos predictivos aplicados al mercado inmobiliario, contribuyendo al desarrollo de soluciones de analítica de datos para valoración de viviendas.

9. Recomendaciones y futuros trabajos

Se recomienda explorar técnicas de optimización bayesiana para mejorar la selección de hiperparámetros, especialmente en los algoritmos XGBoost y MLP debido a su mayor costo computacional en el proceso de entrenamiento.

Se propone incluir otras técnicas de detección de valores atípicos debido a su impacto en la reducción del RMSE y MAE de los modelos predictivos.

Se sugiere la implementación de validación cruzada k-fold como estrategia de evaluación, con el objetivo de incrementar la estabilidad de las métricas de desempeño y disminuir la varianza asociada a la partición entrenamiento–prueba.

Finalmente se recomienda integrar datos espaciales asociados a la ubicación de las viviendas para nutrir el conjunto de datos con información de infraestructura como transporte público, universidades, comercio para analizar si estos influyen en el precio de la vivienda.

Adicionalmente, se propone incorporar técnicas de interpretabilidad de modelos como SHAP con el fin de comprender el impacto de cada variable en la predicción del precio.

10. Referencias

- Acuerdo 7 de 1979 Concejo de Bogotá, D.C.* (s. f.). Recuperado 18 de marzo de 2025, de <https://www.alcaldiabogota.gov.co/sisjur/normas/Norma1.jsp?i=902>
- Banco de la República. (2025a). *Índice de precios de la vivienda nueva (IPVNBR)*. <https://www.banrep.gov.co/es/glosario/ipvnbr>
- Banco de la República. (2025b). *Índice de precios de la vivienda usada (IPVU)*. <https://www.banrep.gov.co/es/glosario/ipvu>
- Belete, D. M., & Huchaiah, M. D. (2022). Grid search in hyperparameter optimization of machine learning models for prediction of HIV/AIDS test results. *International Journal of Computers and Applications*, 44(9), 875-886. <https://doi.org/10.1080/1206212X.2021.1974663>
- Boosting*. (2025). Corporate Finance Institute. <https://corporatefinanceinstitute.com/resources/data-science/boosting/>
- Bramer, M. (2016). *Principles of Data Mining* (3.^a ed.). Springer-Verlag. <https://doi.org/10.1007/978-1-4471-7307-6>
- Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2020). *LOF: Identifying Density-Based Local Outliers*. <https://doi.org/https://doi.org/10.1145/335191.33538>
- Camacol. (2024). Informe de actividad edificadora junio 2024. *Cámara Colombiana de la Construcción*, 62.
- Camacol. (2025a). Informe de actividad edificadora febrero 2025. *Cámara colombiana de la construcción*, 60.
- Camacol. (2025b). Tendencias de la Construcción 28. *Cámara colombiana de la construcción*, (28), 66.

- Casas, P. (s. f.). *Libro Vivo de Ciencia de Datos*. Recuperado 3 de julio de 2020, de <https://librovivodecienciadedatos.ai/>
- Chen, K., & Huang, J. (2023). Research on the Design and Application of House Price Prediction Algorithms and Model Based on Machine Learning. *2023 International Conference on Internet of Things, Robotics and Distributed Computing (ICIRDC)*, 815-821. <https://doi.org/10.1109/ICIRDC62824.2023.00154>
- Choy, L. H. T., & Ho, W. K. O. (2023). The Use of Machine Learning in Real Estate Research. *Land*, 12(4), 740. <https://doi.org/10.3390/land12040740>
- Corte Constitucional de Colombia, C. C. de C. (2025). *Sentencia T-409/13*. www.corteconstitucional.gov.co.
<https://www.corteconstitucional.gov.co/relatoria/2013/T-409-13.htm>
- DANE - *Cuentas nacionales departamentales: PIB por departamento*. (s. f.). Recuperado 4 de marzo de 2025, de <https://www.dane.gov.co/index.php/estadisticas-por-tema/cuentas-nacionales/cuentas-nacionales-departamentales>
- DANE - *Proyecciones de población—Bogotá*. (s. f.). Recuperado 4 de marzo de 2025, de <https://www.dane.gov.co/index.php/estadisticas-por-tema/demografia-y-poblacion/proyecciones-de-poblacion/proyecciones-de-poblacion-bogota>
- Deaconu, A., Buiga, A., & Tothăzan, H. (2022). Real estate valuation models performance in price prediction. *International Journal of Strategic Property Management*, 26(2), 86-105. <https://doi.org/10.3846/ijspm.2022.15962>
- Decreto 190 de 2004 Alcaldía Mayor de Bogotá, D.C.* (s. f.). Recuperado 18 de marzo de 2025, de <https://www.alcaldiabogota.gov.co/sisjur/normas/Norma1.jsp?i=13935>

- Du, K.-L., Leung, C.-S., Mow, W. H., & Swamy, M. N. S. (2022). Perceptron: Learning, Generalization, Model Selection, Fault Tolerance, and Role in the Deep Learning Era. *Mathematics*, 10(24), 4730. <https://doi.org/10.3390/math10244730>
- Fayyad, U. (1997). Data mining and knowledge discovery in databases: Implications for scientific databases. *Proceedings. Ninth International Conference on Scientific and Statistical Database Management (Cat. No.97TB100150)*, 2-11. <https://doi.org/10.1109/SSDM.1997.621141>
- Fei Tony Liu, Kai Ming Ting, & Zhi-Hua Zhou. (2008). Isolation Forest. *2008 Eighth IEEE International Conference on Data Mining*. <https://doi.org/10.1109/ICDM.2008.17>
- Franceschi, L., Donini, M., Perrone, V., Klein, A., Archambeau, C., Seeger, M., Pontil, M., & Frasconi, P. (2025). Hyperparameter Optimization in Machine Learning. *Foundations and Trends® in Machine Learning*, 18(6), 1054-1201. <https://doi.org/10.1561/22000000088>
- Gartner Glossary. (s. f.). *Definition of Data Mining—Gartner Information Technology Glossary*. Gartner. Recuperado 18 de marzo de 2025, de <https://www.gartner.com/en/information-technology/glossary/data-mining>
- Han, J., Pei, J., & Kamber, M. (2011). *Data Mining: Concepts and Techniques*. Elsevier.
- Hariharakrishnan, J., Mohanavalli, S., Srividya, & Kumar, K. B. S. (2017). Survey of pre-processing techniques for mining big data. *2017 International Conference on Computer, Communication and Signal Processing (ICCCSP)*, 1-5. <https://doi.org/10.1109/ICCCSP.2017.7944072>
- Ho, W. K. O., Tang, B.-S., & Wong, S. W. (2021). Predicting property prices with machine learning algorithms. *Journal of Property Research*, 38(1), 48-70. <https://doi.org/10.1080/09599916.2020.1832558>

- IGAC. (2025). *Resolución 620 de 2008*.
<https://www.alcaldiabogota.gov.co/sisjur/normas/Norma1.jsp?i=36158>
- Kalliola, J., Kapočiūtė-Dzikienė, J., & Damaševičius, R. (2021). Neural network hyperparameter optimization for prediction of real estate prices in Helsinki. *PeerJ Computer Science*, 7, e444. <https://doi.org/10.7717/peerj-cs.444>
- Ley 1673 de 2013, Legislation No. 1673 (2013).
http://www.secretariassenado.gov.co/senado/basedoc/ley_1673_2013.html
- Li, Z., Zhao, Y., Hu, X., Botta, N., Ionescu, C., & Chen, G. H. (2023). ECOD: Unsupervised Outlier Detection Using Empirical Cumulative Distribution Functions. *IEEE Transactions on Knowledge and Data Engineering*, 35(12), 12181-12193.
<https://doi.org/10.1109/TKDE.2022.3159580>
- Marsland, S. (2015). *Machine Learning: An Algorithmic Perspective, Second Edition*. CRC Press.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill Education.
- ML | Bagging classifier. (2025). GeeksforGeeks. <https://www.geeksforgeeks.org/ml-bagging-classifier/>
- Mora Garcia, R. T., Cespedes Lopez, M. F., & Perez Sanches, R. (2022). *Housing Price Prediction Using Machine Learning Algorithms in COVID-19 Times*.
<https://doi.org/https://doi.org/10.3390/land11112100>
- Nicolas, P. R. (2015). *Scala for Machine Learning*. Packt Publishing Ltd.
- Obagbuwa, I. C., & Danster, S. (2024). Housing Price Prediction Using Machine Learning Techniques. *2024 International Conference on Science, Engineering and Business for Driving Sustainable Development Goals (SEB4SDG)*, 1-12.
<https://doi.org/10.1109/SEB4SDG60871.2024.10629723>

- Observatorio de Hábitat. (2025). *Boletín índice de Precios de la Vivienda Nueva (IPVN) e Índice de Costos de Construcción de Edificaciones (ICOCED)*.
https://observatoriohabitat.org/wp-content/uploads/2024/11/IPVN_Septiembre_2024.pdf
- Philipp Probst, Anne-Laure Boulesteix, & Bernd Bischl. (2019). Tunability: Importance of hyperparameters of machine learning algorithms. *The Journal of Machine Learning Research*, 20(1), 1934-1965. <https://doi.org/10.5555/3322706.3361994>
- Rampini, L., & Cecconi, F. R. (2021). Artificial intelligence algorithms to predict Italian real estate market prices. *Journal of Property Investment & Finance*, 40(6), 588-611. (world).
<https://doi.org/10.1108/JPIF-08-2021-0073>
- Schölkopf, B., Williamson, R., Smola, A., Shawe-Taylor, J., & Platt, J. (1999). Support vector method for novelty detection. *Proceedings of the 13th International Conference on Neural Information Processing Systems, NIPS'99*, 582-588.
- Suzuki, K. (2011). *Artificial Neural Networks: Methodological Advances and Biomedical Applications*. BoD – Books on Demand.
- Tianqi Chen & Carlos Guestrin. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Trindade Neves, F., Aparicio, M., & de Castro Neto, M. (2024). The Impacts of Open Data and eXplainable AI on Real Estate Price Predictions in Smart Cities. *Applied Sciences*, 14(5), 2209. <https://doi.org/10.3390/app14052209>
- Unidad Administrativa Especial de Catastro Distrital. (2024). *Resultados Censo Inmobiliario 2023*. 59.

Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2017). *Data Mining—Practical Machine Learning Tools and Techniques*. Elsevier.

<https://linkinghub.elsevier.com/retrieve/pii/C20150020718>

Yang, J., Rahardja, S., & Fränti, P. (2021). Mean-shift outlier detection and filtering. *Pattern Recognition*, 115, 107874. <https://doi.org/10.1016/j.patcog.2021.107874>