



INVESTIGACIÓN [X](#)

Algoritmos basados en machine learning aplicados a la predicción de flujo de tráfico en ciudades inteligentes

Autor

Nombre William Yesid Aguirre Carpeta

Director/Tutor

Ing. Roberto Ferro Escobar, PhD

Universidad Distrital Francisco José De Caldas

Maestría en Ciencias de la Información y las Comunicaciones

Énfasis en Ingeniería de Software

Bogotá, Colombia

junio de 2025

Contenido

1.	Grupo de investigación	3
2.	Línea de investigación	3
3.	Director	4
4.	Resumen	4
5.	Palabras Clave	5
6.	Introducción	6
7.	Problema de investigación	7
7.1	Planteamiento del problema	8
7.2	Formulación del problema	10
7.3	Sistematización del problema	10
8.	Objetivos.....	11
8.1	Objetivo general	11
8.2	Objetivos específicos	11
9.	Justificación	11
10.	Marco de referencia	13
10.1	Cuerpo de conocimiento (teórico).....	14
10.1.1	Ciudades Inteligentes	14
10.1.2	Sistemas de Transporte Inteligente (ITS).....	15
10.1.3	Machine Learning en la Optimización del Tráfico.....	16
10.1.4	Análisis y Procesamiento de Datos en ITS: Técnicas de Recolección y Análisis de Datos	18
10.1.5	Evaluación de Modelos de Machine Learning	21
10.2	Investigaciones previas	23
11.	Hipótesis.....	25
12.	Metodología.....	25
13.	Impacto y resultados esperados	28
14.	Recursos y presupuesto	29
15.	Cronograma.....	30
16.	Limitaciones.....	31
17.	Referencias	31

1. GRUPO DE INVESTIGACIÓN

El Grupo de Investigación LIDER (Laboratorio de Investigación y Desarrollo en Electrónica y Redes) de la Universidad Distrital Francisco José de Caldas es un grupo que tiene como misión la generación y ejecución de proyectos de investigación, desarrollo e innovación en áreas como telemática, telecomunicaciones, electrónica, redes e informática, con especial énfasis en la creación de soluciones basadas en tecnologías emergentes para resolver problemas técnicos y prácticos a nivel nacional e internacional. Fue creado en 2007 y está institucionalizado mediante el Acta 005-09 del Centro de Investigaciones y Desarrollo Científico (CIDC) de la universidad. Su director es el Ing. Ph.D. Roberto Ferro Escobar, y el grupo está conformado por un equipo multidisciplinario que incluye profesores y estudiantes de pregrado, maestría y doctorado. Actualmente, su categoría es B según la Convocatoria 833 de 2018 de MinCiencias.

Entre sus objetivos destacan la formación de estudiantes con altos estándares de calidad, la producción de patentes y nuevos diseños aplicables en distintos contextos, así como la creación de aplicaciones tecnológicas que contribuyan al desarrollo institucional y nacional.

Proyectos como el 'Aula Ambiental Viva Digital' en el municipio de Nimaima, orientado a la recuperación de la memoria histórica ambiental y territorial, y ganador de la convocatoria del Ministerio de Ciencia, Tecnología e Innovación (Minciencias) en el programa 'Ideas para el cambio han sido casos de éxito del grupo en donde se ha destacado por su impacto social y académico.

2. LINEA DE INVESTIGACION

La línea de investigación en la cual se enmarca el proyecto es Ciudades inteligentes y aplicaciones de la matemática en el mejoramiento en problemas de ingeniería.

3. DIRECTOR

El ingeniero Roberto Ferro Escobar, actual director del presenta trabajo de grado, es un Ingeniero Electrónico, Magíster en Teleinformática y doctor en Ingeniería Informática. En su trayectoria académica y profesional se destacan funciones como exdirector del doctorado en ingeniería de la Universidad Distrital Francisco José de Caldas. También, ha dirigido a la red RITA y fue decano de la Facultad de Ingeniería de la misma Universidad.

Actualmente es el director del grupo LIDER (**Laboratorio de Investigación y Desarrollo en Electrónica y Redes**) y anteriormente fue nombrado director del **IDEXUD**. Adicionalmente, ha sido docente de distintas Universidades, entre las que destacan la Corporación Unificada De Educación Superior CUN, la Fundación Universitaria UNINPAHU y la Universidad Distrital Francisco José de Caldas.

El ingeniero Ferro ha recibido algunos reconocimientos como la Acreditación de alta Calidad en Ingeniería Electrónica, - Juniode 2011 y una Mención Honorífica Cumlaude, de la Universidad Distrital Francisco José de Caldas – Septiembre de 2022.

4. RESUMEN

Las ciudades del futuro están orientadas y fundamentadas sobre las Tecnologías de la Información y las Comunicaciones TIC que brindan herramientas y soluciones para el desarrollo de nuevas e innovadoras alternativas que permiten mejorar la calidad de vida y bienestar del creciente flujo de población y demanda de infraestructura de las grandes urbes. Lograr que dicho crecimiento sea ordenado y planificado, supone un gran reto para los gobernantes y quienes las habitan, ya que son las ciudades, el motor de la economía de los países.

En una Smart City (Ciudad Inteligente), un concepto que adquiere gran relevancia debido al impacto que genera en su entorno es la movilidad y transporte. En la medida en que las ciudades crecen, también lo hace el número de sus habitantes, ocasionando que la

congestión del tráfico aumente debido al incremento del parque automotor y, así mismo, los aumentan los índices de accidentalidad, contaminación, consumo energético, entre otros. Esto impacta sustancial y negativamente la calidad de vida y bienestar de los habitantes y del medio ambiente. Resolver este problema resulta en una tarea bastante compleja que puede apoyarse en herramientas computacionales que puedan proveer facilidad en la toma de decisiones. Esto, gracias a que los Sistemas de Transporte (ST) suministran grandes cantidades de datos que, en tiempos anteriores, no eran tenidos en cuenta y se descartaban como un insumo importante en la planificación ordenada de las ciudades. Hoy en día, gracias a los grandes avances de la Inteligencia Artificial, estadística y Ciencia de los Datos, disponer de grandes cantidades de información es un insumo fundamental para la alimentación de modelos de aprendizaje automático y predicción en sistemas computacionales.

El uso de algoritmos de auto aprendizaje basados en Machine Learning para el análisis de datos que permita una toma de decisiones acertada o con un mínimo porcentaje de error acerca de la predicción del flujo de tráfico en tiempos muy cortos con mínima intervención humana, apoya el interés en la investigación de este tipo de escenarios en donde la aplicación de herramientas TIC provee de elementos que optimizan el tráfico y, consecuentemente, mejoran el bienestar y calidad de vida de los habitantes de una ciudad.

5. PALABRAS CLAVE

Tráfico Inteligente, Machine Learning, Predicción de Flujo de Tráfico, Ciudades Inteligentes.

6. INTRODUCCIÓN

Los sistemas de transporte (ST) de esta era, enfrentan un desafío de infraestructura bastante complejo debido a la enorme cantidad de variables que la componen, como por ejemplo, la creciente cantidad de vehículos, la gran cantidad de rutas disponibles para los desplazamientos, la complejidad en la administración de las intersecciones disponibles en las rutas en donde también intervienen los peatones, los controladores semafóricos, la contaminación al medio ambiente producida por los vehículos, el clima, entre muchas otras.

El uso de las Tecnologías de la Información y las Comunicaciones TIC, se ha convertido en un gran aliado de las llamadas Ciudades Inteligentes, en donde a través de herramientas computacionales, se ha facilitado la toma de decisiones a gran escala teniendo como insumo principal los datos recopilados a través de observaciones de eventos particulares como el clima, la congestión vehicular y el tiempo en desplazamientos, que necesitan sean analizados y estudiados para comprender su comportamiento. Para esto, es posible emplear técnicas de análisis de datos con la ayuda de la Inteligencia Artificial y sus enfoques como Machine Learning o Deep Learning.

Unos de los objetivos principales de las Ciudades Inteligentes es brindar bienestar y calidad de vida a sus habitantes, algo que la congestión en el tráfico impacta negativamente a diario ya que aumenta considerablemente los tiempos de desplazamiento, siendo un evento que ocurre en muchas ciudades del mundo. Utilizar aprendizaje automático supone una herramienta que puede permitir la predicción del comportamiento del tráfico vehicular para mejorar los tiempos de transición de luces de las redes semafóricas de una ciudad con el fin de mejorar los tiempos de desplazamiento vehicular en las vías de una ciudad con el aumento u homogenización de la velocidad que puedan alcanzar.

Se deben analizar muchas variables disponibles, como el clima, la cantidad de transeúntes, la tipicidad de las intersecciones, entre muchas otras. Para este trabajo, se propone trabajar con la información recopilada de las cámaras instaladas en los semáforos de un tramo de vía de la ciudad de Bogotá, Colombia, en donde es posible realizar un conteo de la cantidad de vehículos que circulan y sus velocidades correspondientes con el fin de desarrollar algoritmos que permitan predecir el flujo de tráfico por medio del análisis de datos.

7. PROBLEMA DE INVESTIGACIÓN

El acceso a la información, en esta era del conocimiento, se ha convertido en una fuente sustancialmente importante para la alimentación de diversos sistemas inteligentes basados en algoritmos desarrollados en Machine Learning y Deep Learning. El auto aprendizaje computacional se fundamenta, en este momento de la historia, como el siguiente paso a seguir y a desarrollar para alcanzar sistemas cada vez más autónomos y conscientes de su entorno implementando soluciones en áreas en donde el ser humano necesitaría muchísimo tiempo para analizar, depurar y así poder decidir sobre las situaciones que se presenten.

Es gracias a la gran cantidad de información que hoy se encuentra disponible, que los sistemas de aprendizaje computacionales pueden lograr resolver tareas en tiempos muy cortos y así, proveer de información importante a las organizaciones para la toma de decisiones.

Un campo importante para la analítica de datos es el análisis predictivo de datos, que consiste en crear y usar modelos que hacen predicciones basados en patrones extraídos de datos históricos. El análisis predictivo de datos tiene aplicaciones que van desde la predicción de precios de boletos de avión de aerolíneas, según la época del año y la demanda de los clientes, la evaluación de riesgos en la emisión de un crédito bancario evaluando las características del comportamiento del mercado y el comportamiento de pago histórico del cliente, hasta la predicción del clima según las características meteorológicas recopiladas en años pasados para una misma época.

El tráfico de una ciudad provee de mucha información relevante a los científicos de datos que puede ser utilizada para realizar predicciones sobre el comportamiento que lo compone. Así mismo, provee de muchas variables que es necesario analizar constantemente en el tiempo para optimizar el flujo de tráfico y así proveer la mayor velocidad posible en los desplazamientos que hacen diariamente los habitantes de una ciudad.

Mohammed, Osama y Kianfar Jalil (Mohammed & Kianfar, 2018) utilizaron aproximaciones algorítmicas basadas en Machine Learning para la predicción de tráfico en términos cortos

de la Interestatal 64 de Missouri. En su trabajo, utilizaron variables como el volumen de tráfico, velocidad y ocupación de segmentos de vía sobre cuatro métodos de predicción basados en Deep Neural Networks, árboles de decisiones distribuidos, un modelo lineal generalizado y máquinas de aumento por gradiente con el objetivo de comparar cuál de ellos ofrecía mejores resultados.

En otros casos de estudio, se incorpora a la lluvia como una variable adicional para la predicción del flujo de tráfico utilizando algoritmos de aprendizaje no supervisado sobre una vía arteria en Beijing, China. El estudio concluyó que la introducción de la lluvia, en su modelo, mejoraba la predicción del flujo de tráfico sobre el tramo de vía seleccionado.

¿Entrenar un modelo basado en Machine Learning con información proveniente del sistema de semaforización de un tramo de vía de la ciudad de Bogotá permitiría la predicción de flujo de tráfico para así mejorar los desplazamientos de los habitantes de la ciudad de ese mismo tramo?

El uso de variables concretas para la predicción de flujo de tráfico sobre un tramo de vía seleccionado puede alimentar sustancialmente distintos tipos de algoritmos, que una vez entrenados, permitan concluir cuál de ellos es el que mejor se acopla al contexto de la ciudad para así decidir cuál es la mejor opción para implementar sobre los tiempos de transición de los semáforos implantados en la vía.

7.1 PLANTEAMIENTO DEL PROBLEMA

Los sistemas de transporte urbano son, en general, un gran marco de referencia para la evaluación de la calidad de vida de los habitantes de una ciudad ya que, teniendo en cuenta las dinámicas de modelos de construcción de soluciones habitacionales masivas cada vez más alejadas del centro urbano, lugares de estudio y/o trabajo, servicios médicos, entre otros, encaran un reto complejo para que los tiempos de desplazamiento diarios sean mínimos y así, favorecer no solo al usuario sino también, la economía y el medio ambiente, entre otros.

El impacto negativo derivado de una mala gestión, no solo en la planificación de la infraestructura requerida para el crecimiento urbano (sumado a la aparición de invasiones

o asentamientos informales de vivienda) sino también, en la escasa recolección de información de las dinámicas de una ciudad en torno al flujo de vehículos por las vías que circulan, impide implantar sistemas que permitan optimizar y tomar medidas sobre las características necesarias para un buen manejo del tráfico, entre ellas, periodos de detención, periodos de circulación, detección de niveles de tráfico según la hora del día, congestión, tipos de vehículos, etc. Según el índice Cities In Motion 2019 de la IESE (Instituto de Estudios Superiores de la Empresa), Bogotá ocupa el lugar 117 en el ranking de Movilidad y Transporte que comparado con el puesto número 1 en el ranking Shanghai-China y el puesto 2 en el ranking Beijing-China. En 2022, el mismo índice posiciona a Bogotá en el puesto 132, indicando que existe un reto de gran complejidad para mejorar la eficiencia en la gestión actual.

La movilidad, entre otros conceptos, es un indicador principal que se encuentra en el marco de las Smart Cities, concepto que cada vez acoge más fuerza y que implica necesariamente el uso de las TIC como herramienta fundamental para su desarrollo. Según el Banco Interamericano de Desarrollo (BID), “una Ciudad Inteligente y sostenible es una ciudad innovadora que utiliza las Tecnologías de la Información y Comunicación (TIC) y otros medios para mejorar la toma de decisiones, la eficiencia de las operaciones, la prestación de los servicios urbanos y su competitividad ... De esa manera, las Ciudades Inteligentes promueven un ciclo virtuoso que produce no solo bienestar económico y social, sino también el uso sostenible de sus recursos con miras a elevar la calidad de vida a largo plazo.”(Bouskela et al., n.d.). Así, existe un interés por parte de los gobiernos en formular alternativas que involucren a las TIC como eje transversal para adelantar escenarios de desarrollo de ideas que permitan dar solución a las diversas problemáticas que impiden mejorar la calidad de vida de los ciudadanos.

En términos de la movilidad, debido a la particularidad del contexto que ciñe a cada ciudad debido a su topografía, infraestructura y necesidades específicas, no es posible seguir un modelo específico de aplicación de optimización. En ese orden de ideas, se puede aprender de los modelos aplicados en otras ciudades y de ese modo construir un marco de referencia basado en las propias necesidades de cada ciudad que permita formular metas a cumplir utilizando a las TIC como herramienta principal.

Según Camila Pérez, directora de Análisis Macroeconómico y Sectorial de Fedesarrollo, “En Bogotá ha habido un avance importante con respecto a movilidad. Se está incorporando tecnología en todo el sistema integrado de transporte, detrás de Transmilenio, y en el diseño de ciclorutas o bicicletas compartidas.”¹

Un aspecto importante, en términos de la movilidad, es la determinación optimizada de los tiempos de transición de los controladores semafóricos en la ciudad. La incorporación de las TIC ofrece alternativas que permiten aplicar mecanismos de recolección y análisis de información (Big Data, Business Intelligence, Machine Learning, Deep Learning, entre otros) que han de ser usados y analizados para la toma de decisiones con la promesa de optimizar cada uno de los procesos que intervienen en la dinámica del flujo vehicular. De este modo, Bogotá ha iniciado la implementación de un modelo de semaforización inteligente (aún todavía sin éxito) que espera reduzca los tiempos de desplazamiento de los usuarios en alrededor de un 30% por trayecto.

7.2 FORMULACIÓN DEL PROBLEMA

¿Cómo implementar algoritmos de *Machine Learning* que, a partir de los datos recolectados del sistema de semaforización de Bogotá, permitan predecir y optimizar el flujo de tráfico vehicular en un tramo específico de la ciudad?

7.3 SISTEMATIZACIÓN DEL PROBLEMA

- ¿Qué características fundamentan la relación entre una Smart City y Movilidad teniendo en cuenta el contexto de una ciudad como Bogotá?
- ¿Cuáles son los conceptos de Smart City que se están implementando en este momento en Bogotá en cuanto a movilidad se refiere?

¹ Hamann, A. (2016, julio). Bogotá y Medellín, en proceso de ser ciudades inteligentes. *Pensamiento Urbano*, 3. Tomado de [https://repositorio.findeter.gov.co/handle/123456789/491]

- ¿Qué herramientas y modelos se encuentran implementándose en el marco del desarrollo de una movilidad sostenible y tecnológica en los sistemas de semaforización de Bogotá?
- ¿Cuál sería la pertinencia de aplicación de sistemas basados en análisis de datos predictivo para la recolección y depuración de información de los sistemas semaforización de la ciudad?

8. OBJETIVOS

8.1 OBJETIVO GENERAL

Implementar algoritmos Machine Learning para la recolección, análisis y depuración de información del sistema de semaforización de Bogotá que permita identificar y establecer estrategias para la predicción del tráfico en un tramo de la ciudad.

8.2 OBJETIVOS ESPECÍFICOS

- Identificar diferentes métodos de Machine Learning, con el fin de determinar aproximaciones algorítmicas en la optimización del tráfico en el tramo de vía seleccionado.
- Validar, mediante herramientas informáticas las aproximaciones algorítmicas mediante la evaluación del índice de error estadístico.
- Evaluar el rendimiento computacional de los métodos de Machine Learning empleados en la optimización del flujo de tráfico.

9. JUSTIFICACIÓN

Las ciudades inteligentes se apoyan en herramientas TIC para favorecer el bienestar y calidad de vida de sus habitantes. Una de las cualidades más representativas de este

panorama es el acceso y uso de la información de manera coherente, dinámica, predictiva y decisiva. Quiere decir esto, que el uso de la información debe proporcionar a las organizaciones de elementos necesarios y suficientes para permitir una toma de decisiones acertada, oportuna y validada sobre atributos relevantes al contexto de aplicación.

El contexto actual de los sistemas de información ha hecho que a diario cantidades astronómicas de datos de muchos tipos circulen en la red de Internet y, en consecuencia, es necesario distribuirlos, clasificarlos y adaptarlos apropiadamente para que puedan ser considerados como información para así darles un uso correcto. Este trabajo, que debe realizarse con grandes cantidades de datos, resulta demasiado complejo sin el uso de sistemas o herramientas computacionales debido a que se deben procesar en poco tiempo y en volúmenes muy altos.

Teniendo en cuenta el contexto de movilidad en una ciudad como Bogotá, en donde constantemente aumenta el número de vehículos que circulan por las vías disponibles, en donde las vías se encuentran en constantes modificaciones en su infraestructura de intersecciones, pasos peatonales, y en donde existe una mezcla entre vehículos de transporte público, vehicular, etc., que circulan por una misma vía, ¿extraer y analizar los datos provenientes de la red de semáforos de un tramo específico para ser introducidos en diferentes métodos de Machine Learning proporcionaría un horizonte de posibilidades para mejorar el flujo de tráfico?

Una de las propiedades más relevantes de Machine Learning, es la posibilidad que ofrece para extraer patrones de los datos que se encuentran disponibles para analizar. El aprendizaje de máquina supervisado permite construir modelos que pueden ser utilizados en aplicaciones de análisis de datos predictivos lo cual, constituye el mejor escenario para examinar el comportamiento del tráfico de una vía. Esto, teniendo en cuenta que se pueden obtener características descriptivas, como velocidades, número de vehículos por hora y por tramo, congestión vehicular, entre otros, todos ellos con datos almacenados de manera histórica.

A partir de este escenario, es posible utilizar estos modelos para entrenarlos con la información proveniente de la red de semaforización de la ciudad de Bogotá para generar predicciones sobre nuevas instancias como, por ejemplo, predecir el flujo vehicular que

ocurrirá en 10, 15 o 30 minutos a futuro. Así, con esta predicción, los modelos permitirían la toma apropiada de decisiones sobre cómo operar la transición de luces de semáforos de una vía para mejorar el flujo vehicular, o también, compararlo con el actual sistema de administración para corroborar si cumple o no su objetivo de manera optimizada.

En general, el uso de herramientas computacionales permite en este caso analizar datos en masa, provenientes de una red de sensores ya instalados que continuamente se alimentan para que a través de modelos predictivos se logre la toma de decisiones acertada sobre un problema que puede mejorar el bienestar y calidad de vida de los habitantes de una ciudad.

10. MARCO DE REFERENCIA

La movilidad urbana, calidad de vida y sostenibilidad ambiental, son retos importantes que enfrentan las ciudades modernas teniendo en cuenta su acelerado crecimiento. Frente a estos desafíos, las Ciudades Inteligentes (Smart Cities) cuentan con las Tecnologías de la Información y las Comunicaciones (TIC) para optimizar diversos aspectos de la vida urbana, entre ellos, el transporte y la movilidad.

Un gran problema que enfrentan las Ciudades Inteligentes es la congestión vehicular. Entre las mayores consecuencias podemos encontrar que tiene un gran impacto negativo sobre la calidad de vida de los ciudadanos ya que aumenta los tiempos de desplazamiento, contamina el ambiente e incluso, puede aumentar los índices de accidentalidad. Aquí, el uso de técnicas de análisis de datos y de algoritmos de Machine Learning se plantean como herramientas efectivas para predecir el flujo de tráfico vehicular, permitiendo una toma de decisiones en tiempo real para optimizar la operación de los sistemas de control de tráfico.

Ante este panorama, el presente proyecto de investigación plantea el uso de algoritmos de aprendizaje automático aplicados a la predicción del flujo de tráfico contemplando distintas variables extraídas desde los controladores semafóricos que se encuentran instalados en los distintos semáforos de un tramo de vía de la ciudad como insumo de datos principal.

10.1 CUERPO DE CONOCIMIENTO (TEÓRICO)

La información se ha convertido, a lo largo de los años, en uno de los activos más importantes y de mayor valor de una organización. Anteriormente, los datos propios de las actividades de una empresa eran simplemente guardados o almacenados en papel, en cajas y, por lo tanto, era poco viable identificar las funcionalidades propias de su contenido y su importancia en la toma de decisiones.

Este escenario ha ido cambiando de una manera drástica en los últimos años gracias “a la evolución acelerada de las prestaciones, y la disponibilidad y la variedad de las tecnologías adecuadas para producir, captar, tratar y difundir información”(Cobarsí Morales, 2011). Así, gracias al conjunto de características anteriormente mencionadas, la información puede ofrecer para una organización un escenario potencialmente positivo para la correcta toma de decisiones y, en consecuencia, la optimización de sus procesos. Este hecho ha favorecido el desarrollo de un conjunto de disciplinas, herramientas y métodos que permiten analizar y depurar la información de tal manera que incluso pueden ser utilizados para predecir eventos futuros. A continuación, exploraremos algunos de ellos que son clave para el desarrollo de este proyecto de investigación.

10.1.1 Ciudades Inteligentes

El concepto de "ciudad inteligente" refiere a un contexto urbano que, a través de la integración de Tecnologías de la Información y Comunicaciones (TIC), busca mejorar la calidad de los servicios urbanos y de sus ciudadanos, reduciendo al mismo tiempo el consumo de recursos que se usan para su funcionamiento y el impacto ambiental que generan. Las ciudades inteligentes utilizan tecnologías para conectar, proteger y mejorar la calidad de vida de sus ciudadanos en varias áreas clave tales como transporte, energía, salud, agua y gestión de desechos(Caragliu et al., 2009), entre otros.

Las TIC son el pilar sobre el que se construyen las ciudades inteligentes ya que facilitan la recolección, procesamiento e interpretación de datos a gran escala, permitiendo una gestión más eficiente de los recursos urbanos. En el contexto del tráfico y la movilidad, las TIC ayudan a recopilar datos en tiempo real de vehículos y sistemas de transporte, que

luego pueden ser utilizados para optimizar rutas, reducir congestiones y mejorar la seguridad vial.

Los **Sistemas de Información Geográfica (GIS)** e **Internet de las Cosas (IoT)** son ejemplos de tecnologías usadas en ciudades inteligentes que permiten una recolección y análisis detallados de datos geoespaciales y de sensores respectivamente, fundamentales para el manejo eficaz del tráfico (Thakuriah et al., 2017). Así, en la gestión de tráfico, las ciudades inteligentes implementan modelos predictivos y adaptativos que utilizan algoritmos de Machine Learning para ajustar los patrones de semaforización y las señalizaciones en respuesta a las condiciones cambiantes del tráfico. Estos modelos permiten predecir congestiones y ajustar automáticamente los flujos de tráfico, mejorando la eficiencia general del sistema de transporte (Papageorgiou et al., 2003).

10.1.2 Sistemas de Transporte Inteligente (ITS)

Los Sistemas de Transporte Inteligente (ITS, por sus siglas en inglés) son un enfoque holístico que integra tecnologías avanzadas de información y comunicación (TIC) en la infraestructura de transporte y los vehículos para garantizar una movilidad urbana más segura, eficiente y económica. Son elementos clave en un ecosistema de ciudad inteligente (Papageorgiou et al., 2003), ya que facilitan el control en tiempo real del flujo de tráfico, la optimización de rutas de viaje, la minimización de emisiones contaminantes y la mejora de la experiencia del usuario.

Los sistemas de transporte, según la Sociedad Internacional de ITS, incluyen una variedad de aplicaciones que procesan y comparten información para respaldar la toma de decisiones por parte de usuarios, operadores y responsables de políticas públicas. Sus componentes básicos son los siguientes:

- **Sistemas de Control de Tráfico:** Estos sistemas utilizan cámaras, sensores y algoritmos de aprendizaje automático para monitorear y gestionar el flujo vehicular.
- **Plataformas de Comunicación en Tiempo Real:** Redes V2X (vehicle-to-everything) y sistemas de control centralizados, como V2V, V2I, V2P (Lu et al., 2014), que proporcionan interacción entre vehículos, infraestructura y usuarios.
- **Gestión de Incidentes:** Habilitan respuestas rápidas a accidentes o problemas en la red de transporte, mejorando la seguridad y minimizando demoras.
- **Sistemas de Pago Electrónico:** Son útiles para agilizar un sistema de pago fluido en peajes y en el transporte público, reducen el tiempo de espera y mejoran la experiencia del usuario.

Los algoritmos de aprendizaje automático (ML) y de aprendizaje profundo se han integrado en los ITS durante las últimas décadas, permitiendo identificar patrones intrincados, prever con precisión el flujo de tráfico y tomar decisiones de control basadas en resultados. Esto da lugar a los emergentes sistemas de previsión de congestión, modelos de categorización de incidentes y algoritmos de asignación de rutas dinámicas (Lv et al., 2015).

A continuación, se presentan algunas de sus ventajas:

- **Reducción de la Congestión del Tráfico:** Mejorando el rendimiento vial mediante el ajuste dinámico del comportamiento de los semáforos y la redirección de los flujos vehiculares (Vlahogianni et al., 2014).
- **Mejora de la Seguridad Vial:** Asistiendo en la conducción y vigilando condiciones adversas.
- **Eficiencia Energética y Reducción de Emisiones:** Con menos paradas innecesarias, los ITS promueven un uso más eficiente del combustible y reducen la huella de carbono del conductor.
- **Mejor planificación urbana:** A través de los datos generados por ITS, será posible identificar patrones de movilidad para una intervención más precisa en la infraestructura.

10.1.3 Machine Learning en la Optimización del Tráfico

El crecimiento acelerado de las ciudades ha generado la necesidad de una gestión mucho más eficiente y precisa del tráfico urbano. Esta realidad, ha motivado el desarrollo de nuevos enfoques que superen los modelos tradicionales de análisis de tráfico, en donde se destaca el uso de algoritmos de **Machine Learning (ML)** como herramientas para la predicción, diagnóstico y optimización del flujo vehicular. A diferencia de los modelos deterministas o puramente estadísticos, ML permite construir modelos que aprenden de grandes volúmenes de datos históricos y en tiempo real, adaptándose dinámicamente a entornos urbanos que cambian constantemente.

Los algoritmos de ML han demostrado una alta eficacia en diversas tareas dentro de los Sistemas de Transporte Inteligente (ITS), entre ellas:

- **Predicción del flujo vehicular:** técnicas como las redes neuronales recurrentes (RNN) y sus variantes como LSTM han sido ampliamente utilizadas para predecir el tráfico en función del tiempo, permitiendo anticipar congestiones con minutos o incluso horas de antelación (Ma et al., 2015).

- **Clasificación de incidentes:** algoritmos como *Support Vector Machines* (SVM), *Random Forests* o k-NN permiten detectar automáticamente eventos atípicos (accidentes, obras, bloqueos) a partir de datos de sensores, cámaras o redes sociales (Sun et al., 2006).
- **Control de semáforos:** los sistemas de control adaptativo basados en ML ajustan en tiempo real la duración de los ciclos semafóricos para optimizar el flujo en intersecciones congestionadas (Arel et al., 2010).
- **Optimización de rutas:** se emplean técnicas como *Q-learning* o modelos basados en grafos para ofrecer rutas alternativas a los conductores en tiempo real, considerando factores como densidad vehicular, tiempo estimado en ruta y eventos inesperados (J. Zhang et al., 2017).

Estas aplicaciones son posibles gracias a la capacidad de ML para manejar múltiples fuentes de datos heterogéneos, como sensores vehiculares, GPS, redes sociales, imágenes satelitales y datos climáticos, que enriquecen en gran manera el contexto de las predicciones.

A continuación, se describen los principales algoritmos de ML utilizados en el análisis del tráfico vehicular:

- **Regresión lineal y polinómica:** son útiles para modelar relaciones simples entre variables como volumen vehicular y tiempo, aunque limitados frente a problemas no lineales (Witten et al., 2016).
- **Árboles de decisión y Random Forest:** permiten crear modelos interpretables, robustos ante ruido y efectivos en tareas de clasificación de tráfico.
- **Support Vector Machines (SVM):** especialmente útiles para clasificar condiciones de tráfico (fluido, denso, congestionado) con precisión elevada.
- **Redes Neuronales Artificiales (ANN) y Profundas (DNN):** permiten capturar relaciones no lineales complejas entre múltiples variables del tráfico, siendo las más utilizadas en tareas de predicción de alto nivel.

- **Modelos no supervisados:** como k-means o DBSCAN, que agrupan patrones similares de comportamiento vehicular para segmentar áreas con problemas recurrentes o identificar perfiles de movilidad.

A diferencia de los modelos estadísticos clásicos, que requieren supuestos rígidos sobre la distribución de los datos o la linealidad de las relaciones, los algoritmos de ML tienen las siguientes características:

- Aprenden directamente de los datos, sin necesidad de especificar una función de relación predefinida.
- Se adaptan a datos dinámicos y de alta dimensión.
- Son capaces de detectar patrones complejos, relaciones no lineales e interacciones multivariadas.
- Pueden operar en entornos con datos incompletos, ruidosos o no estructurados.

Estos atributos los convierten en herramientas especialmente útiles para entornos urbanos caóticos, donde el comportamiento del tráfico puede variar por múltiples causas no controladas.

10.1.4 Análisis y Procesamiento de Datos en ITS: Técnicas de Recolección y Análisis de Datos

Los **Sistemas de Transporte Inteligente (ITS)** dependen críticamente de la calidad, cantidad y relevancia de los datos para funcionar de manera efectiva. Estos datos, provenientes de diversas fuentes, deben ser recolectados, preprocesados, analizados y transformados en conocimiento útil para la toma de decisiones en tiempo real. Este proceso es fundamental tanto para la predicción como para la optimización del tráfico urbano.

En la actualidad, la recolección de datos para ITS se realiza mediante una combinación de tecnologías que permiten monitorear variables del tráfico en tiempo real y a gran escala:

- **Sensores de Inducción Magnética:** instalados en la superficie vial, capturan el número de vehículos y su velocidad al paso por puntos específicos.

- **Cámaras de vigilancia con visión por computador:** permiten detectar flujos vehiculares, tipos de vehículos, eventos anómalos y patrones de movilidad.
- **Sistemas GPS de flotas o usuarios:** los datos de localización permiten reconstruir rutas y estimar tiempos de viaje o congestión (Herrera et al., 2010).
- **Redes sociales y crowdsourcing:** plataformas como Waze o Twitter generan datos colaborativos útiles para identificar incidentes y congestiones.
- **Dispositivos IoT y redes vehiculares (VANETs):** proporcionan información en tiempo real sobre condiciones mecánicas del vehículo, comportamiento del conductor y estado del entorno vial.
- **Drones y sensores aéreos:** ofrecen perspectivas globales y permiten el monitoreo de corredores urbanos a gran escala.

Cada fuente tiene diferentes niveles de granularidad, frecuencia de muestreo, exactitud y cobertura, por lo que es esencial integrar y armonizar estos datos de forma eficaz.

La recolección de datos en ITS puede ser de tipo:

- **Pasivo:** el sistema capta datos sin intervención del usuario (sensores, cámaras).
- **Activo:** requiere participación humana directa o indirecta (por ejemplo, informes desde aplicaciones móviles).

Para almacenar y gestionar estos datos, se debe tener en cuenta que pueden ser masivos, por lo que se emplean infraestructuras de **Big Data**, tales como:

- **Bases de datos NoSQL** (e.g., MongoDB, Cassandra), apropiadas para datos no estructurados y de alta variabilidad.
- **Plataformas de transmisión en tiempo real**, como Apache Kafka o Apache Storm, que permiten procesar eventos conforme se generan.

- **Sistemas en la nube** que ofrecen elasticidad y escalabilidad para soportar el volumen creciente de información generada por los ITS modernos (Y. Zhang & Haghani, 2015).

Antes de alimentar los modelos de análisis o predicción, es necesario realizar tareas de **limpieza y normalización**, tales como:

- Eliminación de datos incompletos, redundantes o erróneos.
- Verificación de valores faltantes usando técnicas estadísticas o de aprendizaje automático.
- Homogeneización de formatos, frecuencias temporales y unidades.
- Identificación y corrección de valores atípicos (outliers).

Este paso es crítico para garantizar la calidad de los datos que alimentarán los modelos posteriores.

Una vez recolectados y preprocesados los datos, se aplican técnicas de **análisis exploratorio y minería de datos**, que incluyen:

- **Análisis estadístico descriptivo** (media, varianza, percentiles).
- **Análisis de series temporales** para detectar patrones diarios, semanales o estacionales del tráfico.
- **Algoritmos de clustering** (como K-means o DBSCAN) para segmentar zonas geográficas según su comportamiento vehicular.
- **Análisis de correlación** entre variables como clima, hora del día y densidad vehicular.
- **Redes bayesianas y árboles de decisión** para modelar la relación entre eventos e identificar causas probables de congestión.

Estas técnicas permiten extraer conocimiento valioso que sirve como base para las etapas de modelado predictivo y posterior toma de decisiones.

Los datos analizados pueden ser utilizados para entrenar modelos de **Machine Learning** supervisado y no supervisado, los cuales alimentan sistemas de predicción del flujo vehicular, detección de incidentes o control inteligente del tráfico. La información también puede retroalimentar sistemas **predictivos** y **prescriptivos**, capaces de:

- Sugerir rutas óptimas.
- Ajustar señales semafóricas.
- Redirigir vehículos ante eventos adversos.
- Estimar tiempos de viaje y generar alertas anticipadas.

En la actualidad, se desarrollan **sistemas integrados** en los que la recolección, procesamiento, análisis y acción ocurren en ciclos de retroalimentación continua, acercándose a un modelo de gestión autónoma del tráfico urbano.

10.1.5 Evaluación de Modelos de Machine Learning

En sistemas como los de semaforización inteligente, control de rutas y predicción de congestión, los errores del modelo pueden derivar en **malas decisiones operativas**, generando más congestión, mayores emisiones contaminantes o incluso riesgos de seguridad. Por ello, los modelos deben ser evaluados tanto **offline**, con datos históricos, como **online**, en tiempo real, idealmente con retroalimentación continua del entorno.

En problemas de predicción del tráfico (por ejemplo, volumen vehicular, velocidad promedio o tiempo de viaje), se utilizan métricas de regresión como:

- **MAE (Mean Absolute Error)**: promedio de errores absolutos.
- **RMSE (Root Mean Squared Error)**: penaliza errores grandes, útil cuando se desea minimizar desviaciones importantes.

- **R² (Coeficiente de determinación)**: mide qué tanto varía la variable dependiente como función del modelo; un valor cercano a 1 indica buen ajuste (Chai & Draxler, 2014).
- **MAPE (Mean Absolute Percentage Error)**: útil cuando se requiere expresar el error en porcentaje respecto a los valores reales.

La evaluación rigurosa también implica **comparar distintos algoritmos** bajo las mismas condiciones y métricas. Esto incluye desde modelos simples (como regresión lineal o árboles de decisión) hasta modelos complejos como:

- Redes neuronales profundas (Deep Learning).
- Modelos de series temporales (ARIMA, LSTM).
- Modelos híbridos (e.g., CNN-LSTM, autoencoders con clustering).
- Algoritmos basados en **aprendizaje por refuerzo** (Q-learning, DDPG, PPO).

Una buena práctica es acompañar la evaluación numérica con visualizaciones (gráficas de error, curvas ROC, histogramas) y análisis cualitativos del comportamiento del modelo en casos extremos.

Para validar modelos de control del tráfico (por ejemplo, semáforos inteligentes), se utilizan **entornos de simulación** como:

- **SUMO (Simulation of Urban MObility)**.
- **MATSim**.
- **VISSIM**.

Estas plataformas permiten replicar condiciones urbanas reales con tráfico sintético, evaluando el impacto de cada modelo en indicadores como tiempo promedio de viaje, número de detenciones, consumo energético, entre otros (Krajzewicz et al., 2012).

10.2 INVESTIGACIONES PREVIAS

El uso de Machine Learning para la predicción de flujo de tráfico, ha sido utilizado como caso de estudio en algunos trabajos realizados en diversas partes del mundo como una aproximación para la solución de problemas de movilidad bajo los conceptos de Smart Cities. En Missouri, Estados Unidos, se utilizaron cuatro modelos de predicción de corto tiempo, del comportamiento del tráfico (Mohammed & Kianfar, 2018) y se tomaron los resultados para comparar estadísticamente cuál de ellos ofrecía una mejor optimización sobre la Ruta Interestatal 64. Los modelos fueron, respectivamente, Deep Neural Networks, Distributed Random Forest, Gradient Boost Machine y un modelo lineal generalizado. La investigación concluyó que la inclusión de la mayor cantidad de variables posibles reduce el error en la predicción del comportamiento del tráfico.

En Manchester, United Kingdom, se utilizó Deep Learning en conjunto de datos con redes neuronales para la predicción de la velocidad del tráfico en una zona urbana (Essien et al., 2019). El estudio propone la optimización de los modelos ya existentes utilizando Big Data, en donde se plantea el desarrollo de una red neuronal de tiempo corto combinando variables adicionales como el clima para la alimentación del conjunto de datos en donde se concluye que, precisamente, esta variable influyó drásticamente en los resultados de la predicción obtenida y, por lo tanto, debe ser tomada en cuenta en los futuros análisis que se realicen.

La predicción de flujo de tráfico tiene también relevancia en carreteras arteriales urbanizadas, ya que conectan áreas geográficamente importantes para el desplazamiento de mercancías, bienes y alimentos. La comparación de métodos de Machine Learning en este escenario, permite examinar la exactitud y sensibilidad en la predicción (Bartlett et al., 2019) teniendo en cuenta, en este caso, los diferentes tipos de vehículos que pueden existir en la vía. Los resultados experimentales del estudio mostraron que el uso de modelos basados en redes neuronales artificiales arrojó mejores predicciones. La comparación se realizó utilizando el error cuadrático medio.

El uso de Sistemas Expertos, basados en Inteligencia Artificial, ha sido usado para el control inteligente del sistema de luces (Albatish & Abu-Naser, 2019). Aquí, se analiza el problema de congestión vehicular en las vías lo que ocasiona menores velocidades, tiempos de

desplazamiento más largos y largas colas de vehículos, produciendo disminución en la calidad de vida de los habitantes de una ciudad. El sistema, resultado de la investigación, produce una administración en tiempo real del control de cambio de luces de los semáforos, para lo cual utilizan sensores infra rojos de radiación y un Arduino para la interconexión de los sensores y el sistema inteligente.

Internet de las cosas e Inteligencia Artificial, son ampliamente compatibles para la disminución de la congestión del tráfico (Soomro et al., 2018). Gracias a la capacidad que tienen los sensores de enviar y recibir datos y a la capacidad que tiene la Inteligencia Artificial de procesarlos, es posible tomar decisiones calculadas con el objetivo de maximizar la reducción de la congestión vehicular. El estudio propone un algoritmo simple basado en Inteligencia Artificial que permite reducir la congestión vehicular con pocas variables incluidas en el marco de las ciudades inteligentes o Smart Cities.

Machine Learning ha provisto de herramientas para el control de luces de tráfico (Iram et al., 2019) en el marco de las ciudades inteligentes. Se propone el uso de dos métodos de autoaprendizaje para dos escenarios en particular: para un área pequeña en donde la congestión vehicular también es pequeña y para toda una ciudad en donde existe diversidad en la congestión según el área. Los casos de estudios fueron implementados utilizando un simulador de tráfico que dotó al sistema con datos suficientes para la alimentación de los modelos. El estudio concluyó, que el método utilizado para áreas pequeñas tenía buenos resultados aplicando lógica difusa para la disminución de la congestión vehicular. Sin embargo, el uso de este tipo de solución no obtuvo mejores resultados para áreas de congestión más grandes y que, además, debía tenerse en cuenta horarios pico de congestión en donde los datos mostraban cambios más relevantes.

La relevancia de este tipo de estudios tiene justificación en el contexto donde se aplica, debido a la particularidad de cada caso. Cada vía tiene sus propias características por lo que no es posible utilizar un único método para el análisis de los datos que pueda ofrecer dicho escenario. Adicionalmente, el conjunto de aplicación del flujo de tráfico aplicado a su optimización unido al control inteligente de luces semaforicos ofrece la apertura de brechas en las que es posible abrir campos de investigación en donde se puedan aplicar métodos que ofrezcan una solución óptima al problema de predicción.

11. HIPÓTESIS

La aplicación de algoritmos basados en Machine Learning para la extracción de patrones sobre un conjunto de datos históricos relacionados con el comportamiento del flujo de tráfico de un tramo de vía especificado podría mejorar la relación de estados de la red de semáforos para reducir la congestión vehicular y mejorar los tiempos de desplazamiento.

12. METODOLOGÍA

Este estudio se desarrollará con un enfoque mixto, predominantemente cuantitativo, dentro del paradigma empírico-analítico. Dado que este trabajo busca, básicamente, aplicar, entrenar y validar algoritmos de aprendizaje automático para predecir el flujo vehicular en un escenario de ciudad inteligente, requiere el procesamiento de grandes volúmenes de datos estructurados y su análisis estadístico y computacional.

Sin embargo, para evaluar el contexto urbano, institucional y operativo donde estos algoritmos podrían implementarse potencialmente, también se integra un elemento cualitativo complementario. Esto permite dar contexto a los resultados, articular los factores que serían invisibles al observar solo los números y defender que las soluciones propuestas serían relevantes en la movilidad del mundo real. A continuación, se describen las fases que componen el proceso metodológico:

1. Recolección de información

En esta etapa se obtendrán **datos cuantitativos** de diversas fuentes, como sensores vehiculares ubicados en los sistemas de semaforización, plataformas de datos abiertos (como la Secretaría Distrital de Movilidad de Bogotá) en donde se recopilan y almacenan los datos recolectados por los controladores semafóricos y APIs de tránsito (como Google Maps, Waze, o TomTom). Los datos recolectados incluirán variables como: conteo vehicular, velocidad promedio, tiempos de viaje, horarios, condiciones meteorológicas, entre otras.

2. Procesamiento y selección de variables

Los datos cuantitativos serán sometidos a un proceso de **preprocesamiento** que incluirá: limpieza, normalización, transformación temporal y detección de valores atípicos. Posteriormente, se aplicarán técnicas de selección de variables (feature selection) para determinar cuáles tienen mayor correlación con la variable objetivo: el flujo vehicular.

Simultáneamente, los insumos cualitativos permitirán comprender posibles variables contextuales que incidan en el tráfico, pero que no estén directamente registradas en las bases de datos (por ejemplo: decisiones administrativas, zonas de alto riesgo, cambios urbanísticos).

3. Selección de algoritmos de *Machine Learning*

Una vez identificadas las variables relevantes, se procederá a seleccionar los algoritmos más adecuados para abordar el problema de **predicción multivariable con componente temporal**. Se explorarán modelos como:

- Regresión lineal y polinomial.
- Árboles de decisión y *Random Forest*.
- *Gradient Boosting Machines* (GBM, XGBoost).
- Redes neuronales artificiales (ANN).
- Modelos secuenciales como LSTM (*Long Short-Term Memory*), especialmente eficaces para series de tiempo.

La elección final de algoritmos considerará tanto su rendimiento estadístico como su capacidad de adaptarse a contextos urbanos dinámicos.

4. Entrenamiento y validación de modelos

Los datos serán divididos en conjuntos de entrenamiento, validación y prueba (train-validation-test split). Se aplicarán técnicas como la **validación cruzada k-fold** para mitigar el riesgo de sobreajuste (*overfitting*). Las métricas de evaluación incluirán:

- **RMSE (Root Mean Square Error)**
- **MAE (Mean Absolute Error)**
- **MAPE (Mean Absolute Percentage Error)**
- **R² (coeficiente de determinación)**

5. Simulación y entorno de pruebas

Se construirá un entorno de simulación utilizando herramientas como **SUMO (Simulation of Urban MObility)** o plataformas similares, donde se podrá modelar el comportamiento del tráfico bajo diferentes escenarios, incluyendo la implementación de los algoritmos entrenados. Esta fase permitirá anticipar el impacto potencial de las predicciones en tiempo real sobre la eficiencia del tráfico en el tramo analizado.

6. Evaluación integral y selección del modelo óptimo

Finalmente, se evaluará cada modelo no solo desde su desempeño cuantitativo y eficiencia computacional, sino también desde su **viabilidad operativa**. Para ello, se tendrá en cuenta:

- Precisión de las predicciones.
- Tiempo de respuesta.
- Facilidad de implementación en sistemas existentes.

El modelo que logre el mejor equilibrio entre estos criterios será propuesto como solución óptima para su integración en estrategias de gestión del tráfico en entornos de ciudad inteligente.

13. IMPACTO Y RESULTADOS ESPERADOS

Ofrecer algoritmos que permitan la predicción de flujo de tráfico, utilizando Machine Learning, que ofrezcan elementos que puedan utilizarse para la comparación de los modelos actuales que se utilizan en ingeniería de tráfico en donde su principal uso está en el control de transición de luces de los semáforos de una vía. De este modo, se permitiría utilizar herramientas computacionales y recursos TIC, basados en grandes cantidades de datos, para resolver tareas complejas que requerirían bastantes recursos humanos y tiempo, con el objetivo de impactar directamente a los habitantes de una ciudad en su bienestar, movilidad y calidad de vida de una manera positiva.

- Generación de conocimiento y nuevos desarrollos tecnológicos

Resultado/Producto esperado	Indicador	Beneficiario
Modelos de predicción de flujo de tráfico basados en datos provenientes de controladores semafóricos para la mejora de la movilidad	Artículo publicado	Sector transporte y sector académico

- Apropiación social del conocimiento

Resultado/Producto esperado	Indicador	Beneficiario
Informe final de investigación	Documento radicado en el Oficina de Investigaciones	Grupo de investigación, UDFJC, El estudiante

14. RECURSOS Y PRESUPUESTO

Los recursos que serán utilizados y dispuestos para el desarrollo de este trabajo de investigación son principalmente de fuente personal. A continuación, se presenta en detalle cada elemento necesario para el despliegue de este trabajo y sus rubros correspondientes:

- Computador de escritorio:
 - Costo: \$9'800.000
 - Procesador: **Intel® Core™ i7-12700KF**, 8 Performance Cores, 4 Efficient-cores. 20 hilos, 25MB de Smart Cache y hasta 5 GHz de frecuencia máxima
 - Memoria RAM: 32 GB DDR5
 - Almacenamiento: 512 GB M2 Nvme Gigabyte + HDD 1 TB Western Digital
 - Tarjeta aceleradora gráfica: RTX 4060 TI
 - Monitor: Gigabyte GS32QC
 - Teclado y Mouse: SteelSeries Apex 5 y Rival 3
 - MainBoard: MSI FORCE Z690
 - Windows 11 PRO licenciado
- Presupuesto para la publicación en revistas indexadas: \$3'000.000
- Presupuesto para ponencias en congresos nacionales e internacionales: \$3'000.000
- Gastos relacionados con papelería: \$300.000
- Gastos comunes de mantenimiento: \$800.000
- Se propone utilizar para el desarrollo del proyecto software de código abierto

15. CRONOGRAMA

A continuación, se presenta el cronograma, el cual, está dispuesto para terminarse en 32 semanas de trabajo.

[illegible]

16. LIMITACIONES

Una posible limitación que puede tener este proyecto de investigación es el acceso y disponibilidad de la información con la que se desea trabajar. Los datos provienen de la red de semaforización de la ciudad de Bogotá y, por lo tanto, pertenecen al Distrito. En este caso, se procede a establecer el contacto con la Secretaría Distrital de Movilidad de Bogotá para que sea posible el préstamo de la información con fines de investigación a través de un derecho de petición ya enviado y en espera de respuesta.

Sin embargo, en este aspecto, desde el Ministerio de las Tecnologías de la Información se tiene disponible una plataforma de Datos Abiertos en donde es necesario generar un proceso de consulta de información como parte del proceso de recopilación de datos inicial para el proyecto.

17. REFERENCIAS

- Albatish, I. M., & Abu-Naser, S. S. (2019). Modeling and controlling smart traffic light system using a rule based system. *Proceedings - 2019 International Conference on Promising Electronic Technologies, ICPET 2019*. <https://doi.org/10.1109/ICPET.2019.00018>
- Arel, I., Liu, C., Urbanik, T., & Kohls, A. G. (2010). Reinforcement learning-based multi-agent system for network traffic signal control. *IET Intelligent Transport Systems*, 4(2). <https://doi.org/10.1049/iet-its.2009.0070>
- Bartlett, Z., Han, L., Nguyen, T. T., & Johnson, P. (2019). A Machine Learning Based Approach for the Prediction of Road Traffic Flow on Urbanised Arterial Roads. *Proceedings - 20th International Conference on High Performance Computing and Communications, 16th International Conference on Smart City and 4th International Conference on Data Science and Systems, HPCC/SmartCity/DSS 2018*. <https://doi.org/10.1109/HPCC/SmartCity/DSS.2018.00215>

- Bouskela, M., Casseb, M., & Bassi, S. (n.d.). *La ruta hacia las Smart Cities Migrando de una gestión tradicional a la ciudad inteligente*.
- Caragliu, A., Del Bo, C., & Nijkamp, P. (2009). Smart cities in Europe, series research memoranda 0048. *VU University Amsterdam, Faculty of Economics, Business Administration and Econometrics*, 48.
- Chai, T., & Draxler, R. R. (2014). Root mean square error (RMSE) or mean absolute error (MAE)? -Arguments against avoiding RMSE in literature. *Geoscientific Model Development*, 7(3). <https://doi.org/10.5194/gmd-7-1247-2014>
- Cobarsí Morales, Josep. (2011). *Sistemas de información en la empresa* [Book]. UOC.
- Essien, A., Petrounias, I., Sampaio, P., & Sampaio, S. (2019). Improving Urban Traffic Speed Prediction Using Data Source Fusion and Deep Learning. *2019 IEEE International Conference on Big Data and Smart Computing, BigComp 2019 - Proceedings*. <https://doi.org/10.1109/BIGCOMP.2019.8679231>
- Herrera, J. C., Work, D. B., Herring, R., Ban, X. (Jeff), Jacobson, Q., & Bayen, A. M. (2010). Evaluation of traffic data obtained via GPS-enabled mobile phones: The Mobile Century field experiment. *Transportation Research Part C: Emerging Technologies*, 18(4). <https://doi.org/10.1016/j.trc.2009.10.006>
- Iram, T., Shamsi, J., Alvi, U., Rahman, S. U., & Maaz, M. (2019). Controlling smart-city traffic using machine learning. *Proceedings - 2019 International Conference on Frontiers of Information Technology, FIT 2019*. <https://doi.org/10.1109/FIT47737.2019.00046>
- Krajzewicz, D., Erdmann, J., Behrisch, M., & Bieker, L. (2012). Recent Development and Applications of {SUMO - Simulation of Urban MObility}. *International Journal On Advances in Systems and Measurements*, 5(3).
- Lu, N., Cheng, N., Zhang, N., Shen, X., & Mark, J. W. (2014). Connected vehicles: Solutions and challenges. In *IEEE Internet of Things Journal* (Vol. 1, Issue 4, pp. 289–299). Institute of Electrical and Electronics Engineers Inc. <https://doi.org/10.1109/JIOT.2014.2327587>

- Lv, Y., Duan, Y., Kang, W., Li, Z., & Wang, F. Y. (2015). Traffic Flow Prediction with Big Data: A Deep Learning Approach. *IEEE Transactions on Intelligent Transportation Systems*, 16(2). <https://doi.org/10.1109/TITS.2014.2345663>
- Ma, X., Tao, Z., Wang, Y., Yu, H., & Wang, Y. (2015). Long short-term memory neural network for traffic speed prediction using remote microwave sensor data. *Transportation Research Part C: Emerging Technologies*, 54. <https://doi.org/10.1016/j.trc.2015.03.014>
- Mohammed, O., & Kianfar, J. (2018). A Machine Learning Approach to Short-Term Traffic Flow Prediction: A Case Study of Interstate 64 in Missouri. *2018 IEEE International Smart Cities Conference, ISC2 2018*. <https://doi.org/10.1109/ISC2.2018.8656924>
- Papageorgiou, M., Diakaki, C., Dinopoulou, V., Kotsialos, A., & Wang, Y. (2003). Review of road traffic control strategies. *Proceedings of the IEEE*, 91(12). <https://doi.org/10.1109/JPROC.2003.819610>
- Soomro, S., Miraz, M. H., Prasanth, A., & Abdullah, M. (2018). Artificial Intelligence enabled IoT: Traffic congestion reduction in smart cities. *IET Conference Publications, 2018(CP747)*. <https://doi.org/10.1049/cp.2018.1381>
- Sun, S., Zhang, C., & Yu, G. (2006). A Bayesian network approach to traffic flow forecasting. *IEEE Transactions on Intelligent Transportation Systems*, 7(1). <https://doi.org/10.1109/TITS.2006.869623>
- Thakuriah, P. (Vonu), Tilahun, N. Y., & Zellner, M. (2017). Introduction to seeing cities through big data: Research, methods and applications in urban informatics. In *Springer Geography*. https://doi.org/10.1007/978-3-319-40902-3_1
- Vlahogianni, E. I., Karlaftis, M. G., & Golias, J. C. (2014). Short-term traffic forecasting: Where we are and where we're going. *Transportation Research Part C: Emerging Technologies*, 43. <https://doi.org/10.1016/j.trc.2014.01.005>
- Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016). Data Mining: Practical Machine Learning Tools and Techniques. In *Data Mining: Practical Machine Learning Tools and Techniques*.

Zhang, J., Zheng, Y., & Qi, D. (2017). Deep spatio-temporal residual networks for citywide crowd flows prediction. *31st AAAI Conference on Artificial Intelligence, AAAI 2017*.
<https://doi.org/10.1609/aaai.v31i1.10735>

Zhang, Y., & Haghani, A. (2015). A gradient boosting method to improve travel time prediction. *Transportation Research Part C: Emerging Technologies*, 58.
<https://doi.org/10.1016/j.trc.2015.02.019>