



**UNIVERSIDAD DISTRITAL
FRANCISCO JOSÉ DE CALDAS**

Modelo Predictivo de recurso Eólico para territorios de las ZNI usando IA

Trabajo de investigación/grado para optar el título de
Magíster en Ciencias de la Información y las Comunicaciones

Juan Pablo Oviedo Perdomo

Director: Javier Antonio Guacaneme Moreno, PhD

CoDirector: Elvis Eduardo Gaona, PhD

Bogotá D. C. – Colombia

Mayo de 2026

Índice general

1. GRUPO DE INVESTIGACIÓN	3
2. LÍNEA DE INVESTIGACIÓN	4
3. DIRECTOR Y CODIRECTOR	5
3.1. Director	5
3.2. Codirector	5
4. RESUMEN	6
5. PRESENTACIÓN DE LA PROPUESTA	7
6. FORMULACIÓN DEL PROBLEMA	9
7. MARCO TEÓRICO	10
8. HIPÓTESIS	13
9. IDENTIFICACIÓN DE FUENTES DE DATOS	14
9.1. Datos viento - Colombia	14
10. MODELOS PARA PREDICCIÓN DE GENERACIÓN EÓLICA	17
10.1. Modelos Estadísticos	17
10.1.1. Regresión Lineal	17
10.1.2. Regresión Logística	18
10.2. Modelos de Inteligencia Artificial	18
10.2.1. Long short Term Memory NN	18
10.2.2. XGBoost	19
10.3. Generación de Recurso Eólico	19
11. VALIDACIÓN DE MODELOS DE IA	22
12. ANÁLISIS	24
12.1. Resultados XGBOOST	25
12.2. Resultados LSTM	25
12.2.1. Paiba	25

12.2.2. Leticia	25
13. DISCUSIÓN	29
14. CONCLUSIONES	31
15. TRABAJOS FUTUROS	33

1. GRUPO DE INVESTIGACIÓN

El grupo de investigación GITUD es constituido en la universidad distrital apoyando las líneas de investigación de optimización de redes microondas, antenas y redes inalámbricas y compuestas por sensores IoT, finalmente la gestión del espectro, con las cuales se busca apoyar proyectos que contemplen la transmisión de información, datos y el análisis de estos. El grupo de investigación LIFAE orienta sus proyectos en la línea de renovables y fuentes alternas de energía.

2. LÍNEA DE INVESTIGACIÓN

La línea de investigación de este proyecto es la investigación de Wireless sensor Network IoT el cual junto al análisis de datos propuestos permitirá relacionar la capacidad de velocidad del viento y la captura de datos en una fuente confiable para predecir la capacidad de generación eléctrica.

3. DIRECTOR Y CODIRECTOR

3.1 Director

El profesor Javier Antonio Guacaneme es profesor de la Universidad Distrital Francisco José de Caldas, en las cuales dedica su tiempo a diferentes actividades como la docencia en el programa de ingeniería Electrónica, además de ser miembro del grupo de investigación LIFAE. Destacando su investigación en temas de energías renovables.

3.2 Codirector

El profesor Elvis Eduardo Gaona es profesor de la Universidad Distrital Francisco José de Caldas, en las cuales dedica su tiempo a diferentes actividades como la docencia en el programa de ingeniería Electrónica, además de la dirección del grupo de investigación GITUD, y la dirección del programa de Doctorado de Ingeniería.

4. RESUMEN

resumen de todo el trabajo

5. PRESENTACIÓN DE LA PROPUESTA

El uso de energía en los últimos años ha impulsado el desarrollo de los territorios en diferentes ámbitos, desde lograr la construcción y funcionamiento de muchos lugares hasta lograr la conectividad con el mundo a través de las redes de distribución. Lo cual hace necesario contar con suficiente producción de energía para lograr que los servicios instalados en los territorios puedan tener una confiabilidad suficiente para evitar que se creen nuevas brechas tecnológicas en los territorios. Sin embargo, en Colombia aún existen territorios con múltiples municipios que hacen parte de las Zonas No Interconectadas, las cuales, debido a la dificultad de conexión, impulsada por factores geográficos generalmente, indican que están aisladas de las redes de distribución del país. En estos territorios existen otras soluciones para la generación de energía con el fin de satisfacer las necesidades de sus habitantes, pero generalmente estas siguen siendo impulsadas por energías no renovables, lo cual genera muchos impactos en términos generalmente económicos y ecológicos. Como lo indicó Muñoz es importante empezar a identificar la planeación de las redes en zonas aisladas (Muñoz y Bel, 2012) lo cual puede ser muy aprovechable cuando se tienen fuentes renovables especialmente en zonas sin interconexión. Por otro lado, es importante resaltar que este tipo de proyectos toman mucha relevancia cuando se presentan eventos en proyectos gigantescos que no se logran terminar en el momento adecuado y esto termina afectando el precio de la energía como ya lo establece Trespalacios en su evaluación del precio de energía cuando el proyecto en Ituango no terminó en el momento esperado (Trespalacios et al., 2025) . En un país como Colombia se cuenta con la posibilidad de aprovechar el recurso solar y eólico principalmente para tener fuentes de energía renovable con el fin de aprovechar mejor la capacidad energética en territorios donde los combustibles no renovables suplen las necesidades de generación eléctrica. La inclusión de energías renovables en otros países ya se ha estudiado y se han logrado identificar potenciales eléctricos que suplen necesidades de territorios específicos, o donde se puede involucrar la fuente renovable para empezar a reemplazar las fuentes convencionales y mejorar el impacto ambiental del país. Como ejemplos ya se han observado ejercicios de caracterización como el hecho por Ramírez y Murillo a través de la minería de datos para obtener según la producción anterior valores de la capacidad de generación de energía (Ramírez-Murillo et al., 2019). Así como se han hecho estimaciones en la zona de la guajira (C. et al., 2017) y el valle de Aburrá (Cano et al., 2022) e incluso en la zona de la sabana de Bogotá (Mesa, 2020) y dentro de la misma ciudad de Bogotá (Ruiz, 2024) y de esta manera como ya se tiene un antecedente interesante de estudios donde se han identificado potenciales eléctricos por lo cual es importante empezar a identificar la capacidad de generación de energía en zonas no interconectadas como ya lo hizo Collazos usando analítica visual (Barrera, 2017), además de identificar la capacidad del potencial eléctrico es importante enlazar con este un

modelo económico adecuado como ya lo hizo Maya Ochoa quien identificó la necesidad de implementar ayudas económicas en el principio de este tipo de proyectos para aumentar su viabilidad (Ochoa et al., 2012). Por ello en este proyecto se busca la predicción de la capacidad de generación a través de herramientas de IA con el fin de aprovechar los datos capturados en varias estaciones de medición provistas por la universidad distrital para tener en tiempo real y de forma continua el monitoreo de estos dos recursos en diferentes lugares de la zona de Cundinamarca. Como se ha hecho en anteriores trabajos se ha utilizado las técnicas de inteligencia artificial para determinar el consumo de energía (Palomeque, 2023; Pla, 2015) con diferentes técnicas como Machine Learning (M. J. L. Sánchez, 2025) y también para la identificación de la demanda de energía del país (Guevara, 2025) lo cual puede ser importante para empezar a buscar nuevas fuentes de energía, y entonces se observa la capacidad de Colombia para utilizar fuentes renovables cuando ya he investigado la capacidad del recurso solar (castillo y Sainea, 2024; Ortiz y Mora, 2021). Adicionalmente se han hecho trabajos para identificar la capacidad de predicción de la velocidad del viento, lo cual puede aportar información valiosa para identificar las mejoras que deben plantearse en los algoritmos ya que no siempre obtienen resultados totalmente claros (Quispe y Huamani, 2024), finalmente es importante además de reconocer la capacidad para la producción de energía, se identifican importantes opciones para transmitir esta información de manera apropiada y mostrar estos datos a través de algún servicio específico como ya lo hizo Roa para el consumo de energía eléctrica usando modelos de regresión (Ortiz y Mora, 2021). Con ello este trabajo se fundamenta en la predicción en una zona perteneciente a la ZNI donde las condiciones de temperatura, altitud, y humedad puedan ser cercanas a las zonas con una medición precisa entregadas por las estaciones de la universidad Distrital. Para ello se debe tener en cuenta la capacidad de generación de energía en los territorios de forma diaria, interpretando las horas de mayor y menor producción, interpretando los cambios según las condiciones climatológicas del territorio, para ajustar la predicción lo más posible a un resultado aceptado. La inclusión de la inteligencia artificial nos dará mucho valor al poder procesar miles de datos que ya están disponibles en las diferentes estaciones para predecir de manera correcta el comportamiento esperado.

6. FORMULACIÓN DEL PROBLEMA

Este proyecto busca identificar los potenciales energéticos de los territorios dentro de las ZNI para la producción eólica, aprovechando las mediciones efectuadas sobre zonas que se encuentran en condiciones similares de temperatura, altitud sobre el nivel del mar y humedad, aprovechando las mediciones de velocidad del viento para la generación de energía eólica. En este proyecto se deben tener en cuenta las variaciones de la producción energética a lo largo de los días y evaluar los límites mayores y menores de la producción según la variación que se presentan en las diferentes épocas del año. El análisis de estas variables se hará a través de modelos de inteligencia artificial que describan el comportamiento de estas y logren predecir de manera aceptable los valores de producción eólica para el futuro. Este proyecto busca la predicción de la cantidad de generación eléctrica posible utilizando fuentes de energía renovables y el resultado esperado se busca obtener a partir de modelos de inteligencia artificial, con ello se espera reducir la variación entre los datos y la dificultad para el manejo de grandes grupos de datos que puedan existir, así mismo identificar de mejor manera la variabilidad de los datos a partir de épocas específicas. Finalmente se busca seleccionar un grupo de datos de entrenamiento y de validación con los cuales se pueda probar el modelo de manera adecuada y generar una predicción esperada de la energía eólica que se acople a los valores reales entregados por las estaciones de monitoreo existentes en los municipios del departamento de Cundinamarca. Por lo tanto, surge la siguiente pregunta de investigación:

¿Cómo se puede predecir la generación eólica en los territorios pertenecientes a las Zonas No Interconectadas de Colombia usando datos confiables?

7. MARCO TEÓRICO

La inteligencia artificial es una herramienta que en los últimos años ha tomado tanta popularidad, haciendo posible evaluar grandes grupos de datos y evaluar diferentes condiciones que con técnicas más tradicionales pueden llevar un tiempo mayor y no siempre tener resultados reproducibles. Por lo cual estas técnicas tienen ahora gran acogida y representan un gran método para la evaluación de los recursos solares y eólicos principalmente para lograr la generación eléctrica en territorios que buscan una fuente de energía renovable. En diferentes trabajos previos se ha utilizado técnicas como machine Learning (Ortiz y Mora, 2021) para la predicción del recurso solar y estadística para la evaluación de la velocidad del viento, y como estos mismos valores pueden predecirse para lograr un potencial eléctrico (Quispe y Huamani, 2024). En este caso el trabajo buscará identificar la capacidad de generación de energía, y utilizar los datos reales capturados para la predicción de datos como ya ha sido evaluado en diferentes territorios dentro de Colombia, Cundinamarca y Bogotá (Cano et al., 2022; Ramírez-Murillo et al., 2019; Ruiz, 2024). En este caso también es importante evaluar la capacidad de aprovechamiento de los potenciales eléctricos y buscar soluciones para la implementación de este tipo de recursos en el país, como ya fue recomendado por Maya Ochoa (Ochoa et al., 2012) para identificar que los proyectos de energía renovable, aún podría requerir apoyo estatal para lograr una mejor respuesta y facilitar la instalación de estas fuentes en territorio dentro de las zonas conectadas y por supuesto incrementar la aceptación e implementación en las zonas donde es más necesaria como las zonas no interconectadas (Barrera, 2017).

Radiación solar: Esta fuente de energía es específicamente la cantidad de energía que se transmiten a través de los rayos solares y pueden emplearse para obtener energía, sin embargo, es importante poder identificar la cantidad de radiación que puede obtenerse según la ubicación del territorio. Esto puede afectar de mayor medida la capacidad de generación de energía en una estación, además es necesario identificar las variaciones que pueden presentarse según las épocas del año y las horas del día ya que las horas de mayor radiación generalmente se producen cerca de las 12:00PM pero la radiación solar con el cambio climático presente no siempre es igual. Así lo evaluó Ulloa en su artículo cuando reviso los efectos de la radiación solar en la ciudad de Guadalajara en México (Ulloa et al., 2011). **Velocidad del viento:** Esta fuente de energía es un recurso renovable que permite la generación de energía cuando se aprovecha la fuerza que impulsa el viento para mover algún generador eléctrico y producir una corriente eléctrica, de la misma manera que funciona un generador hidroeléctrico. En este caso la velocidad del viento ha sido estudiada y se ha relacionado de fuerte manera con la generación de energía como lo hizo Camargo para identificar la capacidad del viento ciudades como Veracruz y evaluar la capacidad de generación de energía que puede encontrarse en esta fuente (Ruiz, 2024). **Inteligencia Artificial:** La inteligencia artificial ha sido un concepto

muy famoso en el último siglo pero cuyo desarrollo inicial es más antiguo de lo que se piensa, estos algoritmos que tuvieron un inicio en los años 60's han sido desarrollados con múltiples fines, en un principio su aplicación se vio limitada por la capacidad computacional de la época, lo cual reducía su campo de acción y fue necesario esperar casi 50 años para poder lograr los primeros desarrollos con una eficiencia aceptable en este campo. Este tipo de algoritmos tiene características muy importantes entre las cuales se destaca la capacidad de entrenamiento para un ajuste apropiado de sus propios parámetros y el mejoramiento de la evaluación hecha. Adicionalmente esta capacidad de mejoramiento se une a la evaluación de grandes grupos de datos. La inteligencia artificial, ya se ha popularizado tanto que ha llegado a aplicaciones de uso diario como los procesadores de lenguaje natural, que ayudan a muchas personas a resolver múltiples consultas entre simples o complicadas. Históricamente la inteligencia artificial desarrollada en sistemas computacionales ha destacado desde el siglo anterior, sin embargo, los primeros procesos automáticos donde existieron sistemas que funcionaban sin intervención humana como el llamado El ajedrecista el cual puede considerarse como el primer juego por computador este fue desarrollado en 1912. Esto adicionalmente se dio junto al desarrollo de estos conceptos donde se desarrollan analogías para el estudio de la mente en el siglo XIX, y finalmente en la segunda parte de este siglo se empieza a manejar el termino de inteligencia artificial gracias a Alan Turing (Rojas, 2015). Dentro de las aplicaciones más recientes de la inteligencia artificial encontramos:

- Desarrollo de videojuegos
- Desarrollo computacional
- Robótica
- Visión Artificial
- Bot de respuesta

Durante la pandemia del COVID-19 la Inteligencia artificial adquirió mucha popularidad y fue utilizada para evaluar grandes grupos de datos relacionados a esta enfermedad, por ejemplo, se buscó identificar patrones de contagio que llevaran a descifrar la posible gravedad de una persona contagiada con esta enfermedad que ya contara con alguna otra enfermedad o condición que deteriorara su condición (Lorenzo et al., 2020). Adicionalmente para este proyecto la inteligencia artificial se piensa utilizar para clasificar algunos escenarios de riesgos en eventos como la conducción, esto indicaría un posible evento donde el conductor este incurriendo en un riesgo para sí mismo que podría terminar en un accidente.

Modelo de Regresión: Este modelo busca establecer la relación entre dos variables dentro de un modelo matemático. En el cuál se pueden encontrar la regresión lineal, logística y otros

modelos más complejos que incluyen, arboles de decisión, redes neuronales, entre otros, los cuales buscan identificar una relación entre variables para identificar un patrón y establecer un resultado generalmente indicando si el grupo de datos se puede identificar dentro de un grupo definido. En este modelo se puede encontrar ejemplos como los identificados de correos falsos, o spam. Ya en algunos casos de interés estos modelos se han usado para evaluar imágenes logrando en ciertos casos niveles altos llegando al 95 % en algunos resultados, siendo estos los más relevantes y logrando con él reducir problemas añadidos durante los mismos experimentos(Shah et al., 2017).

Modelo Clasificador: Este modelo lo que busca idealmente es clasificar un grupo de datos dentro de una etiqueta especial, indicando si el dato evaluado pertenece a una categoría a partir de un porcentaje de acierto en la clasificación. Al igual que el modelo anterior, este tipo de inteligencia artificial utiliza un entrenamiento inicial luego de evaluar unos datos y ajusta sus parámetros para lograr una evaluación más adecuada. En la evaluación de estos modelos se utilizan métricas que evalúan las tasas de acierto en relación a las fallas e identificaciones erróneas como los verdaderos positivos y negativos, y los falsos positivos y negativos. Es importante relacionar en cada investigación que tipo de error puede ser más importante reducir, en muchos casos es más importante identificar correctamente todos los valores positivos, y en otros puede ser más importante reducir los falsos positivos y negativos al mínimo. En muchas casos se han utilizado estos métodos para la clasificación de imágenes y se han obtenido resultados muy interesantes, los cuales nos permiten identificar que por ejemplo, el Random forest y Support Vector Machine (SVM) tiene un menor tiempo de entrenamiento y validación en comparación con las Convolutional Neural Network (CNN) y con los Probabilistic Maps (PM), siendo este último el de mayor tiempo y siendo este muy superior a los demás. Aunque es bastante relevante indicar que en muchos casos se pueden obtener buenos resultados con todos estos métodos (DelaO-Arévalo et al., 2019).

8. HIPÓTESIS

El modelo predictivo basado en IA para identificar la generación de energía a través de fuentes renovables utilizará datos obtenidos principalmente por las estaciones pertenecientes a la universidad Distrital las cuales emiten periódicamente un grupo de datos. Con ello se incrementa la disponibilidad del grupo de datos y se aumenta el volumen disponible para obtener una predicción más precisa. El objetivo principal de este proyecto es relacionar las mediciones de potencia producida en una turbina de aire y la velocidad del viento para la predicción de energía renovable en un entorno conocido y verificado con mediciones reales, y con ello utilizar las mismas para obtener una predicción en un entorno con condiciones ambientales similares como son temperatura, humedad y altitud sobre el nivel del mar.

9. IDENTIFICACIÓN DE FUENTES DE DATOS

Para la identificación de este trabajo se han identificado diversas fuentes de datos, con el objetivo de identificar cuales pueden ser las más fiables y útiles para el uso de datos, en esto se evalúa la cantidad de datos, las fechas disponibles, las variables adicionales que se pueden obtener, como temperatura, humedad, entre otras. Se busca identificar fuentes en Colombia y en otros países donde haya disponibilidad de información específicamente en zonas aisladas.

9.1 Datos viento - Colombia

En Colombia se cuenta con un servicio web de acceso abierto para visualización de datos los cuales son de origen gubernamental, los cuales contienen miles de grupos de datos que están disponibles para el acceso público, por lo cual cualquier persona podría solicitar y utilizar estos datos para su uso propio. El sitio principal para la visualización de datos se encuentra en <https://www.datos.gov.co> y según la necesidad del usuario puede seleccionar que datos requiere. Dentro de los grupos de datos más relevantes se encuentran temperatura, humedad, calidad de aire, entre miles de otros. Todos estos datos no son solo de tipo climatológico, en este sitio se pueden ver todo tipo de estadísticas de Colombia, como emergencias, áreas de producción, zonas de wifi, relacionados a turismo. Toda esta información se encuentra disponible ya que este sitio es el principal centro de datos público de Colombia.

En este caso el acceso a los datos se accedieron los datos de velocidad del viento, por lo cual es importante destacar que los datos están disponibles desde Enero de 2001, por lo cual se cuenta con un gran número de datos ya que además existen registros en los 32 departamentos de Colombia, y en miles de municipios asociados. Para este trabajo hemos revisado algunos municipios que son:

- Anapoima: Es una ciudad del departamento de Cundinamarca con altura media de 770 m.s.n.m., el cual permite tener una temperatura templada, con una velocidad del viento medida en la estación máxima al rededor de 11 m/s lo cual puede ser suficiente para algunas turbinas evaluadas para la producción energética.
- Bogotá: Es la capital de Colombia, una ciudad con altura media de 2600 m.s.n.m. los cuales permiten tener una temperatura fría y una velocidad del viento identificada de 9 m/s lo cual puede ser una velocidad del viento que no permitiría el funcionamiento ideal de una turbina de viento, sin embargo es importante evaluar que en una ciudad altamente poblada es un poco más complicado establecer una posición adecuada para una turbina de viento, ya que existen muchos más obstáculos. Por lo cual esta ciudad será usada como una referencia pero no como

el punto principal de la predicción.

- Usme: Es un municipio de Cundinamarca ubicado muy cerca a la ciudad de Bogotá pero con una altura mayor llegando a los 2800 m.s.n.m. los cuales permitirían tener una velocidad máxima un poco más elevada, la cual se registró como $13m/s$, esto permitiendo un poco más el funcionamiento ideal de la turbina caracterizada. Estos modelos identificados por las estaciones provistas por la UDFJC, serán el punto de datos de confianza ya que estos si se tienen plenamente identificados para este estudio y permite tener claramente identificadas las condiciones donde fueron medidas.
- Leticia: es una ciudad ubicada en la zona sur de Colombia, limitando con Perú y Brasil, junto al río Amazonas, lo cual permite tener unas condiciones de temperatura y humedad especiales. La altura de esta ciudad se encuentra aproximadamente a 96m.s.n.m., las temperaturas medias de la ciudad rondan entre $25^{\circ}C$ y $27^{\circ}C$. Dentro de los datos importantes como el viento que ha sido medido en esta ciudad la velocidad máxima de los datos disponibles es de $12m/s$
- Tumaco: es una ciudad de la costa pacífica de Colombia la cual se encuentra a nivel del mar, esto permite unas velocidades de viento registradas de hasta $10m/s$, lo cual se acompaña de una temperatura media de $27^{\circ}C$. Esta ciudad presenta muchas limitaciones y estos territorios son ejemplos de los mismos que presentan mayores diferencias entre las zonas industrializadas y conectadas a la red, respecto a aquellas que no cuentan con esta conexión de forma permanente.
- Ciénaga: Es un municipio ubicado en la zona atlántica de Colombia, que limita con el océano atlántico, lo cual causa en esta ciudad una temperatura media de $29^{\circ}C$, llegando hasta unas máximas de $32^{\circ}C$. En este caso las velocidades máximas registradas son alrededor de $6m/s$ lo cual puede ser un valor bajo, pero en este caso las estaciones de medición se pueden encontrar en lugares con muchos obstáculos, como se ha registrado con anterioridad esto puede afectar la medición del viento.

En estos casos las estaciones de Anapoima, Cajica y Bogotá serán usadas como punto de comparación para las estaciones provistas por la universidad Distrital Francisco José de Caldas. De la estructura de datos que se obtiene de esta base de datos, se tienen unos resultados como los nombres de la estación, el departamento y el municipio donde está ubicada la estación. Además de su ubicación como latitud y longitud. En estos casos es importante la limpieza y manejo de datos para formar una estructura que fue usada para las predicciones de recurso eólico.

Para los territorios inmersos en las ZNI, se usarán los datos provistos por la página oficial de datos de Colombia <https://www.datos.gov.co> la cual permite identificar diferentes mediciones, como la velocidad del viento, la orientación, temperatura, y muchas más variables capturadas de forma oficial y de las cuales se tiene mucha información. En este caso la velocidad del viento es

nuestra variable de interés pero para el modelamiento de datos también utilizaremos algunas como temperature, humedad, presión atmosférica y radiación solar.

10. MODELOS PARA PREDICCIÓN DE GENERACIÓN EÓLICA

10.1 Modelos Estadísticos

Los modelos estadísticos han sido ampliamente utilizados en los últimos años debido a su alta precisión en el manejo de grandes grupos de datos, y particulares resultados. Popularmente han usado para la predicción y la inferencia o explicación de comportamiento de datos, en las cuales se busca para la predicción la alta confiabilidad y robustez de los datos no observados cuando se obtiene una predicción, y en la inferencia obtener la relación de importancia de las variables usadas con el resultado, crucialmente relacionado con la incertidumbre estadística. En este caso los modelos estadísticos serán usados como primer punto de comparación logrando un resultado aceptable pero con alta posibilidad de mejora cuando se trata de predecir la velocidad del viento en algún territorio. Buscando el acercamiento a los comportamientos y validando a partir las inferencias que otras variables relacionadas al viento (Temperatura, humedad, etc) pueden tener un valor alto de importancia si son altamente variables.

Estos dos puntos de vista igualmente no deben ser mutuamente excluyentes, generalmente ambos resultados pueden estar correctamente relacionados, ya que un modelo con buenas predicciones generalmente tiene una alta comprensión de los datos y las relaciones que usa para sus predicciones tienen realmente asociaciones correctas, y por consiguiente pueden tener buenas predicciones ya que los patrones obtenidos son claros y reales, lejos de ser solamente una coincidencia.

10.1.1 Regresión Lineal Esta técnica estadística utilizada para estudiar la relación entre algunas variables de interés en situaciones particulares, con ello también se busca predecir diferentes fenómenos. En este caso la regresión lineal múltiple evalúa más de dos variables cuyas interacciones son cuantificadas para encontrar la relación entre la variable dependiente de las independientes. El modelo lineal viene dado por la forma:

$$Y = b_0 + b_1X_1 + b_2X_2 + \dots + b_kX_k + u \quad (10.1)$$

Del cual se pueden identificar los coeficientes $b_1, b_2, \dots, b_k$ que denotan la magnitud del evento de las variables independientes sobre la variable dependiente Y , además el coeficiente individual b_0 es un término constante del modelo y u es el error del modelo. Para aplicar este tipo de modelo deben cumplirse ciertas condiciones:

- La relación entre las variables es lineal.
- Los errores entre las variables independientes es también independientes entre sí.

- Los errores tienen una varianza constante.
- Las variables siguen la ley Normal.
- Las variables independientes no tienen una correlación entre ellas.

Generalmente estos modelos se evalúan utilizando dos métricas sencillas que son El error en la magnitud de la precisión, y el porcentaje de error absoluto medio dadas por sus expresiones:

$$e_t = A_t - F_t \quad (10.2)$$

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{a_t} \right| \quad (10.3)$$

Con ello se busca evaluar el error continuamente y reducirlo, logrando el mejor acercamiento, pero esto solo sucede en los problemas cuya naturaleza puede favorecerse de este tipo de algoritmo (Ferreira et al., 2019).

10.1.2 Regresión Logística La regresión logística es también un modelo lineal que ha sido ampliamente utilizado en anteriores proyectos, y que permite al evaluar diferentes variables que también son independientes entre si, el resultado de una variable categórica o de valor discreto, este modelo principalmente evalúa la probabilidad de que un resultado ocurra o no (J. L. Sánchez et al., 2001).

10.2 Modelos de Inteligencia Artificial

El uso de inteligencia artificial en los últimos años ha tenido una gran acogida en múltiples campos, los cuales permiten por su capacidad el manejo de grandes grupos de datos, analizar patrones, y percibir características que en muchos casos pueden ser complicadas de identificar para el análisis humano, y también para los algoritmos mencionados anteriormente, cuyas capacidades se limitan a problemas con características más básicas.

Dentro de los modelos más conocidos se encuentran las redes neuronales, arboles de decisión, y algunos otros los cuales han sido utilizados con éxito para resolver problemas de clasificación e inferencia. En la actualidad existen millones de ejemplos en las cuales se logran altos valores de clasificación en casos como escritura, identificación de patrones y clasificaciones en general. En los casos de predicción se han logrado muchos resultados positivos en casos como la inferencia de precios de materias, valores de divisas, entre otros.

10.2.1 Long short Term Memory NN Las Redes Neuronales recurrentes son un tipo de algoritmo de Inteligencia artificial donde la información se pasa por múltiples capas ocultas y se transforma en

algunas de ellas incluyendo ciclos de estados ocultos que permiten a la red mantener la información por un periodo corto de tiempo, donde se busca igualmente un aprendizaje largo para identificar de mejor manera los patrones existentes. Para solucionar el problema de la memoria corta existen las Long Short Term Memory (LSTM).

Este tipo de red neuronal, es un algoritmo cuyas características y composición permiten tener una memoria de corto o largo plazo, eliminando limitantes cuando la serie de tiempo analizada presenta patrones con una secuencia larga, y su característica de memoria corta permite ajustes importante cuando se relacionan patrones poco usuales.

Este ajuste en la memoria de la red neuronal se debe a que el dato inicial recibido generalmente es preservado por más tiempo entre las capas de la red, en comparación a una red neuronal recurrente tradicional. Esto se produce en una celda de estado que permite mantener estos datos e inyectarlos posteriormente cuando son necesarios, esto ayuda a mantener la memoria y eliminar el problema del corto plazo. Todo este proceso se ejecuta internamente dentro de las redes neuronales a base de configuraciones que actúan como compuertas lógicas y permiten tomar la decisión de cual dato mantener y cual olvidar de la red neuronal.

10.2.2 XGBoost El XGBoost es un algoritmo compuesto de diferentes arboles de decisión que son potenciados por un descenso de gradiente para las tareas de clasificación y regresión. En este caso se tiene como base un árbol que toma las primeras predicciones el cual puede ser llamado aprendiz débil. A partir de los errores cometidos se crean nuevos arboles, y entonces los errores producidos por cada árbol se van evaluando para determinar la lejanía con el valor real. Estos valores de residuo se van sumando a la función de pérdida. En el caso de las funciones de pérdida que son usadas para medir el rendimiento del modelo, el descenso de gradiente se utiliza para reducir estos residuos lo cual mejora este rendimiento cuando se van entrenando nuevos arboles.

10.3 Generación de Recurso Eólico

En este contexto la generación de Recurso eólico es descrito como la posibilidad de predicción de un valor obtenido al generar energía a través de una turbina eólica utilizando como fluido para impulsarla la velocidad del viento medida en la estación meteorológica. De esta manera podemos obtener un potencial energético a través del viento producido y la capacidad de la turbina de generar energía.

En la siguiente imagen podemos observar la señal de viento producida en la estación de Paiba y la estación de Leticia. Estas dos estaciones están ubicadas en territorios completamente diferentes, en Paiba los datos son capturados por un sistema de medición propio de la UDFJC, mientras que los datos para la ciudad de Leticia son obtenidos del sitio oficial de Colombia (www.datos.gov.co) en el cual se han obtenido los datos de junio a Diciembre de 2025 para hacer una estimación

con un grupo de datos similar. En este caso es importante resaltar que ambas ciudades presentan condiciones muy diferentes a pesar de que los datos cubren el mismo rango de tiempo, por lo cual los resultados pueden ser muy diferentes.




Figura 10.1: *Medición del viento en la estación de Paiba*




Figura 10.2: *Medición del viento en la estación de Leticia*

A partir de estas fuentes de información se modelan la potencia generada en un aerogenerador con el fin de identificar los posibles potenciales eléctricos de la zona. Esto conlleva a utilizar los datos de viento en un modelo de aerogenerador ya identificado e implementado en MATLAB para la producción teórica de energía que podría tener la turbina. En este caso las turbinas modeladas serán de tamaño pequeño, cercano a los 400W, ya que esta opción puede ser apropiada para pequeños consumidores de energía en un espacio residencial.

El modelo de turbina utilizado corresponde a una PIKASOLA de 400W, la cual puede instalarse fácilmente en lugares rurales con una baja velocidad de trabajo desde los 5 m/s , aunque su mayor producción la alcanzaría en las velocidades alrededor de 11 m/s . Pero igualmente podría satisfacer

las necesidades de una familia pequeña. Este modelo es implementado en el software MATLAB Simulink donde las características de la turbina han sido modeladas y es capaz de producir una señal similar a la potencia suministrada por la turbina real. La figura 10.3 muestra el modelo de bloques utilizado para la producción de la señal. Este modelo de turbina eólica trabaja a 12V , lo cual la




Figura 10.3: *Modelo de bloques de la turbina PIKASOLA*

hace muy apropiada para sistemas con baterías para almacenamiento de energía y su utilización en horas de poco viento, además de tener unas características de inicio temprano, lo cual permite una generación de energía con bajos valores de viento, claramente esta reducción puede ver afectada su capacidad de entregar suficiente corriente para alimentar una carga alta en el sistema.

11. VALIDACIÓN DE MODELOS DE IA

Los modelos estadísticos en este caso pueden resultar poco fiables para la evaluación y predicción de la señal ya que estos permiten un comportamiento más lineal pero en estos datos los cambios son tan bruscos que la evaluación de regresiones de tipo lineal o logarítmico, no permite un ajuste completo de los datos.

Como se observa en la ?? la replicación de los datos después de la predicción usando estos métodos pretende un comportamiento algo similar en la visualización de los datos de viento pero su ajuste es engañoso y cuando se usando los datos de la potencia obtenida es un resultado poco favorable para los datos utilizados. Además de ello el resultado en métricas reales como el valor cuadrático medio y ajuste R^2 es muy diferente del obtenido en métodos más complejos basados en IA.

Al utilizar nuestros diferentes grupos de datos provenientes de las estaciones propias (provistas por la UDFJC) y los datos obtenidos de las estaciones en los territorios de la ZNI como Leticia, Cienaga y San Andrés vemos que la única fuente que produce suficiente energía con estos datos son las ubicadas en la ciudad de LETICIA y la estación de PAIBA, Bogotá. Por lo cual en este caso se utilizó el modelo de turbina para evaluar la cantidad de energía esperada en estas dos estaciones al momento de la predicción debemos calcular la energía acumulada en estos eventos, ya que solo tenemos datos capturados por un instante de tiempo.




Figura 11.1: *Potencia generada por los datos de Paiba en la turbina de prueba*

La figura 11.1 muestra el resultado de la potencia generada por el modelo de la turbina, lo cual debe corresponder a una energía obtenida a partir del viento medido en esta estación. Esto permitirá

calcular la potencia obtenida por ejemplo en algunos periodos de tiempo como una hora, un día o similar.




Figura 11.2: *Potencia generada por los datos de Leticia en la turbina de prueba*

La figura 11.2 muestra también la potencia obtenida en la turbina por esta cantidad de viento, estos datos al ser obtenidos de una fuente diferente a la UDFJC no pueden ser directamente comprobados y deben ser tratados como datos validos. En este caso la potencia resultante es de menores valores a lo observado en la estación de Paiba, lo cual causaría un mayor impacto en la ciudad dificultando su producción energética.

12. ANÁLISIS

En este apartado comparamos los dos métodos de IA utilizados para la predicción de potencia obtenida a través de los datos de viento usando un modelo de simulink para la turbina. En este caso vemos en la figura ?? que los datos obtenidos para la estación de Paiba son bastante similares en los datos de entrenamiento del algoritmos, salvo algunos valores pico.

Los algoritmos utilizados en este caso fueron una LSTM y XGBOOST que ya han sido descritos en anteriores apartados. El proceso con estos algoritmos llevó un ajuste de los valores iniciales en ambos algoritmos los cuales fueron:

- **Épocas de entrenamiento:** En este caso el número de épocas es comúnmente un parámetro que se varía para lograr evaluar las capacidades de aprendizaje del algoritmo. Este parámetro puede indicar fácilmente si un ajuste en capacidad del entrenamiento es fiable o si los ajustes deben ser mucho mayores.
- **Castigo a los errores obtenidos:** en ambos algoritmos planteamos un componente de mayor castigo a los errores cuando el valor detectado era un pico para con ello ayudar a los mismos a identificar los cambios más fuertes y que estos puedan identificar mejor los patrones más importantes.
- **Función de activación:** En este caso las diferentes funciones utilizadas pueden cambiar la respuesta del algoritmo, en algunos casos las variaciones hechas lograron respuestas más adecuadas. En otros las predicciones fueron totalmente erradas causando señales de salidas al rededor de un solo valor fijo. Por lo cual fue importante realizar varias pruebas con ellas e identificar cuales fueron las que presentaron mejores resultados. Algunas de las funciones utilizadas fueron: ReLu, SeLu, Sigmoid, Tanh pero no todas fueron escogidas para el funcionamiento final de la red neuronal.
- **Métrica de evaluación:** Este parámetro en ambos algoritmos fue variado, ya que en algunos casos como la señal de prueba tenia picos demasiado bruscos, el uso de la MSE puede llevar a la red neuronal a reducir los cambios de la señal a valores medios, por lo tanto esto contribuye al fenómeno donde los picos son casi ignorados en la predicción.
- **Optimizador:** En este caso el optimizador es una parte del algoritmo que se encarga de ajustar los pesos y bias dentro de las capas de la red neuronal para reducir el error, por lo cual pueden existir diversos métodos y algunos de ellos fueron altamente explorados para verificar que funcionamiento puede tener un mejor resultado.

12.1 Resultados XGBOOST

12.2 Resultados LSTM

12.2.1 Paiba La red neuronal LSTM, en este caso obtuvo un resultado importante al poder predecir con un valor alto la señal de prueba, en la figura 12.1 se observa que solo en algunos valores picos demasiado altos la señal no fue correctamente producida pero esto sin embargo no causa un valor equivocado, por el contrario tiene un valor altamente similar al evento actual.

Esta figura está compuesta por 3 partes, donde se observan la división entre los datos de entrenamiento y prueba, en el cual también se tiene la predicción sobre los datos de prueba, en esta segunda sección es importante destacar donde el comportamiento de los datos, donde no solo se proyectan los datos con una alta correlación sino que se muestra claramente que incluso los valores con los valores más altos son identificados, estos no pretenden ser solamente un promedio de los datos reales, sino se muestra una alta correlación entre los datos altos, medios y bajos. Finalmente la última sección de esta imagen muestra una comparación con la predicción "perfecta" en el cual se tiene la línea verde como los datos de prueba y en los puntos amarillos se tienen los valores que fueron producidos, mostrando una clara similitud a los valores sin estar totalmente alejados y conservando la misma tendencia que los valores esperados.

En la tabla 12.1 se muestra el compilado de los datos usando diferentes funciones de activación, épocas. De esta manera podemos observar que los resultados en algunas funciones de optimización (3 de 4) alcanzaron al tener 30 épocas un valor bastante alto en el R^2 y un error bastante bajo. Lo cual permite indicar que estos datos pueden ser correlacionados correctamente con los datos esperados y así se pueden validar de forma correcta que los mecanismos de predicción usados puedan ser adecuados para este grupo de datos. Únicamente la función *sigmoid* no tuvo resultados adecuados manteniendo siempre un valor alto de error incluso en el mayor número de épocas y un R^2 muy bajo.

En la tabla 12.2 se observan los resultados utilizando las mismas funciones de activación y el número de épocas, esto con el fin de tener una comparación justa. En este caso este optimizador no tuvo los resultados esperados dentro de la corrección de los pesos y el bias en la función de la red neuronal, como se puede observar en este caso únicamente la función *ReLU* presentó valores apropiados y una mejora importante al aumentar el número de épocas. Las demás funciones siempre tuvieron un valor muy bajo de R^2 y unos valores de error demasiado alto. En todos los casos se observa para estas 3 funciones un MAE mayor a las decenas y que no pudo ser corregido de buena manera, incluso en un caso con la función *sigmoid* se empeora con el incremento de las épocas.

12.2.2 Leticia En este caso la predicción para la ciudad de Leticia que resultaba un poco más simple ya que los datos utilizados mostraron menores niveles de potencia producidos ya que los




Figura 12.1: Potencia producida por la LSTM con los datos de validación

Resultados para la LSTM en Paiba				
Función	Épocas	MAE	MSE	R ²
ReLu	1	46.94	4.42	0.13
	10	1.96	1.11	0.95
	30	0.36	0.43	0.99
SeLu	1	40.03	3.25	0.03
	10	13.74	2.79	0.66
	30	4.85	0.89	0.88
Sigmoid	1	45.30	3.42	0.09
	10	45.33	3.60	0.09
	30	25.48	2.26	0.38
Tanh	1	38.09	2.86	0.07
	10	15.41	2.41	0.62
	30	6.72	1.65	0.83

Tabla 12.1: Resultados para la LSTM usando diferente número épocas y diferentes funciones de activación con el optimizador Adam.

Resultados para la LSTM en Paiba				
Función	Épocas	MAE	MSE	R ²
ReLu	1	47.74	3.20	0.15
	10	6.88	0.75	0.833
	30	1.03	0.46	0.97
SeLu	1	39.09	3.21	0.05
	10	18.57	2.03	0.55
	30	16.31	2.61	0.60
Sigmoid	1	46.17	3.40	0.117
	10	59.60	4.79	0.44
	30	92.13	8.00	0.22
Tanh	1	48.45	3.75	0.17
	10	38.92	3.24	0.05
	30	28.9	2.675	0.3

Tabla 12.2: Resultados para la LSTM usando diferente número épocas y diferentes funciones de activación con el optimizador RMSprop.

vientos alcanzados en estos territorios eran mucho menores. Esto puede deberse a múltiples factores externos además de las características aquí seleccionadas. En general, estas ciudades pertenecientes a las ZNI, pueden tener muchas dificultades y entre ellas pueden existir también las condiciones que impiden aprovechar o producir grandes cantidades de energía a partir de las fuentes más abundantes.

Resultados para la LSTM en Leticia				
Función	Épocas	MSE	MAE	R ²
ReLu	1	27.64	4.23	0.72
	10	26.18	4.14	0.73
	30	14.93	2.90	0.85
SeLu	1	24.24	3.90	0.75
	10	29.97	4.41	0.70
	30	20.55	3.66	0.79
Sigmoid	1	65.39	7.41	0.34
	10	30.18	4.60	0.69
	30	14.87	3.10	0.85
Tanh	1	27.16	4.36	0.72
	10	31.12	4.67	0.69
	30	15.22	2.89	0.84

Tabla 12.3: Resultados para la LSTM usando diferente número épocas y diferentes funciones de activación con el optimizador Adam con los datos de Leticia.

En el caso de los datos de Leticia mostrados en la tabla 12.3 es interesante ver como a partir de las épocas la intención de la LSTM de aprender los pocos patrones que aparecen en la señal de potencia generada, se observa que las métricas empeoran en el primer cambio hasta las 10 épocas, pero al evaluar 30 épocas los valores de R² aumentan y los errores disminuyen, esto en el caso de las funciones SeLu y tanh, por lo cual es complicado establecer un modelo adecuado para la predicción de estos datos usando dichas funciones ya que sería apropiado ejecutar pruebas con mayor número de épocas para poder evaluar si ya se corrige el modelo de aprendizaje. En el caso de las funciones ReLu y sigmoid, vemos una mejora en todas las etapas, y se logra un resultado bastante fiel a los datos esperados cuando se obtienen resultados por encima del 85 % de correlación. Sin embargo, en caso es inapropiado indicar que el modelo pueda predecir correctamente la energía producida en esta ciudad ya que se requieren mayores pruebas con más número de épocas para evaluar correctamente si la red neuronal se desempeña mejor. Además, es necesario establecer un mecanismo con mejor capacidad de identificar los datos para evaluar que posibilidades y que problemas actualmente presenta el medidor de viento, ya que podría estar sometido a condiciones poco favorables para la captura de datos.

13. DISCUSIÓN

La evaluación de estas redes neuronales en distintas ciudades con condiciones tan diferentes –una ciudad en clima frío y en altura de la cordillera, mientras que la segunda está ubicada a una altura muy baja en la ribera del río Amazonas– permite de igual manera sin modificaciones mayores un resultado importante que debe ser evaluado en posibles otras ciudades que pertenezcan a las ZNI, ya que la estación de Paiba en la ciudad de Bogotá es usada como referencia logrando un valor de 99 % en la correlación de los datos, mientras que la ciudad de prueba Leticia logró un valor de 85 %, el cual también es un resultado alto y permite tener un punto de partida para establecer proyectos de similar alcance en territorios dentro de la ZNI con condiciones totalmente conocidas, con el fin de mejorar la calidad de los datos.

Los resultados obtenidos en ambas ciudades presentan una similitud en que la LSTM fue capaz de aprender a identificar los patrones producidos por la energía que entregaría una turbina de 400W, que produce 12V, y que cuyo valor en corriente variaría dependiendo de la velocidad de viento que la impulse. En este caso las dos ciudades presentan un valor pico de energía alrededor de los 350W, pero es muy importante destacar que la ciudad de Leticia presentó muchos valores bajos en comparación con la estación de Paiba (Bogotá). Esto como se mencionó puede deberse a múltiples factores además de únicamente las mediciones obtenidas, debido a que los datos son de una fuente externa es imposible identificar las condiciones en que estas mediciones fueron hechas y verificar si todas son capturadas de la forma más favorable que podría aumentar la posibilidad de la producción de energía. Por el contrario los datos obtenidos en la estación de Paiba, y las demás estaciones que pertenecen a la UDFJC, permiten conocer de primera mano las condiciones de instalación verificando las mejores posibilidades para obtener la mayor cantidad de energía.

En el caso de las métricas obtenidas en ambas ciudades es importante resaltar que la estación de Paiba obtuvo mejores resultados al llegar al 99 % de correlación en su mejor configuración, mientras que la ciudad de Leticia únicamente logró un valor máximo del 85 % en esta misma correlación dada por el valor de R^2 . En ambos casos los valores de error MAE obtenidos fueron bastante bajos, sin embargo nuevamente fue solo posible lograr un valor por debajo de la unidad en la mejor configuración en la estación de Paiba. Este fenómeno es posible explicarlo ya que la señal de potencia de la ciudad de Leticia tuvo muchos menos valores útiles es decir que entregaran una potencia baja, entonces la red neuronal tuvo muchos valores en cero y pocos valores que identificar, por lo cual pudo cometer más errores, y cuando se replicaron los picos de la señal el error cometido nuevamente fue más grande que al tener muchos más valores útiles como se presentó en la estación de Paiba, donde fueron muy pocos los valores en cero presentados.

Desde una perspectiva de la arquitectura de la estructura de los datos y los modelos utilizados

es importante indicar que este tipo de algoritmos tendrá un mayor tiempo de entrenamiento y ejecución cuando los grupos de datos crezcan por lo cual es importante que el procesamiento de la información y los volúmenes de datos escogidos siempre sean adecuados y representen de manera fiel el momento que se desea predecir, ya que aunque Colombia es un país que no presenta cambios climáticos tan fuertes al no tener estaciones aún se ve impactado cuando las temporadas de lluvia y sequía se intensifican por lo cual esto podría afectar de gran manera los modelos construidos y podrían causar una mayor desviación en los datos producidos.

En la misma perspectiva de los datos utilizados es importante destacar que nuevamente los datos extraídos de las estaciones propias, permiten identificar un gran número de variables e información útil no sólo para este proyecto sino que se podrían involucrar en múltiples proyectos relacionados a la caracterización climatológica de una manera más rápida frente a la obtención de datos de un origen gubernamental el cual aunque muy completo conlleva un ejercicio de mayor tiempo y de selección adecuada de las variables de interés, lo cual puede causar un retraso adicional en proyectos que requieran un desarrollo ágil con el fin de atraer mejores resultados y lograr un impacto más inmediato en proyectos de investigación.

14. CONCLUSIONES

La presente investigación permitió desarrollar unos modelos utilizados para la detección de potencial energético a través de la velocidad del viento medido que fue utilizado como una variable de entrada en el modelo de la turbina de viento PIKASOLA 400W para la producción de potencia en esta misma turbina. Con ello se logró implementar un modelo con alta eficiencia que identificó con un 99 % de correlación los valores de referencia en la ciudad de Bogotá, y permitió obtener hasta un 85 % en la ciudad de prueba la cual corresponde a un territorio plenamente ubicado dentro de las ZNI.

Esto permitió validar la hipótesis planteada donde se identificaron territorios dentro de la ZNI cuyas variaciones respecto a la referencia no fueran críticas y se logrará tener una predicción de potencial de energía acertada respecto a la potencia esperada en una turbina de viento que se tiene caracterizada y que ha sido modelada en un software para su implementación. De este resultado se logró tener un modelo claro y utilizable para la predicción de energía que podría obtenerse en una turbina similar, siempre y cuando las condiciones –principalmente del viento– sean favorables al funcionamiento, ya que fue en este caso cuando la variación de potencia se dio en valores altos que el modelo pudo identificar los patrones de mejor manera y así producir una predicción mucho más cercana a la realidad esperada.

Es importante destacar que las mayores modificaciones hechas para probar las redes neuronales en los grupos de datos fueron los parámetros de más fácil identificación como el número de épocas y la cantidad de datos que se utilizaban además de los patrones para castigar los errores, y las funciones de activación que son ampliamente conocidas en la industria lo cual permite ajustes más finos y con efectos reproducibles fácilmente. Los demás parámetros más propios de las redes neuronales fueron revisados con anterioridad y ajustados para con ello lograr un cambio positivo al introducir los cambios mencionados. Esto simplifico el proceso de prueba ya que muchos de los cambios indicados causaban resultados totalmente fuera de lo esperado y solo valores cercanos a los usados presentaron un resultado controlable y reproducible con el grupo de datos.

Este estudio se baso en las características climatológicas obtenibles de las mismas estaciones de referencia, y por eso mismo se utilizaron como características adicionales las mediciones de temperatura, humedad y presión atmosférica como contribuyentes a la velocidad del viento y la potencia obtenida, ya que otras características adicionales como identificar las horas de mayor producción de viento y los días en que se podrían dar escenarios más favorables, para este grupo de datos no añadió una respuesta favorable, por el contrario, introdujo un ruido mayor en las predicciones cambiando los valores más útiles como la misma velocidad el viento y produciendo señales más ruidosas, es decir con cambios mucho más agresivos y notorios en las mediciones de

la ciudad de Leticia principalmente donde se identificaban picos y valores mucho más altos cuando la señal esperada era un nivel casi de cero.

Finalmente, la capacidad de producción de este modelo dependerá fuertemente de las capacidades de los datos obtenidos y utilizados para su continuo entrenamiento como se mencionó, resulta mucho más favorable para el modelo tener muchos cambios en las mediciones que identificar patrones esporádicos donde los valores presentados sean altos y luego muy bajos, ya que la mayoría de valores bajos contribuye a que el modelo pueda identificar valores pico pero no que los pueda representar correctamente, por lo cual una mayor cantidad de cambios permitirá al modelo identificar que estos cambios son parte del patrón y pueden ser mejor representados cuando el grupo de datos lo describa correctamente.

15. TRABAJOS FUTUROS

Como trabajos futuros es importante resaltar que no todos las fuentes de datos son obtenidas de manera directa como se logra con las estaciones provistas por la UDFJC, ya que los mismos tamaños de datos capturados cada 10 minutos y en fechas similares para los datos gubernamentales podrían resultar en dataset más grandes y adicionalmente estos requieren un procesamiento adicional para formar los dataset con múltiples variables que si es posible obtener de las estaciones propias, por lo cual es importante resaltar que a futuro podrían implementarse mayor cantidad de estaciones en otros territorios para tener una mayor variedad de los sitios donde se capturan datos.

Adicionalmente se recomienda integrar otro tipo de turbina con un ciclo de trabajo menor ya que las velocidades máximas registradas no son suficientes para este tipo de turbina...

Otro punto importante a tener en cuenta es la posibilidad de la mezcla de diferentes tipos de algoritmos, en lugar de su uso individual para la predicción futura, ya que estas posibilidades combinadas pueden dar un mayor progreso en el procesamiento de los datos aprovechando las capacidades de diferentes algoritmos y así mismo reduciendo las debilidades. Esto por supuesto debe ser acompañado de una vigilancia muy rigurosa sobre el grupo de datos para no perder las características más importantes de los mismos como pueden ser los cambios más notorios y los valores extremos.

Un punto adicional para mejorar el alcance de este tipo de trabajos en el futuro incluye la articulación de proyectos con las entidades que producen los datos actualmente a nivel nacional para contar con su apoyo para la identificación de estos potenciales energéticos, ya que con este apoyo se podría ampliar el alcance de un proyecto subsecuente y se obtendrían datos mucho más accesibles a la comunidad académica que puedan obtenerse de diferentes zonas lejos de las ciudades principales. Así mismo contar con el apoyo de la comunidad académica permitirá mejorar el manejo de los datos y afianzará las relaciones entre instituciones.

Bibliografía

- Ai, X., Li, S., & Xu, H. (2023). Wind speed prediction model using ensemble empirical mode decomposition, least squares support vector machine and long short-term memory. *Frontiers in Energy Research*, 10. <https://doi.org/10.3389/fenrg.2022.1043867>
- Ancans, G., Stankevicius, E., Bobrovs, V., & Osis, N. (2019). Analysis on interference impact of 4G/5G in 450 MHz on digital terrestrial television broadcasting. *2019 Photonics and Electromagnetics Research Symposium - Fall, PIERS - Fall 2019 - Proceedings*, 2173-2179. <https://doi.org/10.1109/PIERS-Fall48861.2019.9021436>
- Ansary, S., Köse, B., Işıklı, İ., Mülayim, C., & Ertılav, B. (2025). Forecasting Wind Speed with Autoregressive and Long-Short Term Memory Neural Network Models. *Journal of AI*, 9, 98-121. <https://doi.org/10.61969/jai.1789834>
- Aouidi, N., Naceur, F. B., & Salah, C. B. (2026). Long-Term Energy Consumption Forecasting Using a Hybrid LSTM-XGBoost Approach, 2852-2857. <https://doi.org/10.1109/codit66093.2025.11321664>
- Band, S. S., Ameri, R., Qasem, S. N., Mehdizadeh, S., Gupta, B. B., Pai, H. T., Shahmirzadi, D., Salwana, E., & Mosavi, A. (2025). A two-stage deep learning-based hybrid model for daily wind speed forecasting. *Heliyon*, 11. <https://doi.org/10.1016/j.heliyon.2024.e41026>
- Barrera, J. D. C. (2017). *MODELO DE PREDICCIÓN MEDIANTE ANALÍTICA VISUAL DE DATOS PARA EL CONSUMO Y GENERACIÓN DE ENERGÍA ELÉCTRICA EN ZONAS NO INTERCONECTADAS USANDO REDES DE SENSORES INALÁMBRICOS* (Vol. 13). <file:///C:/Users/user/Downloads/Pedoman%20AUTP%202017.pdf%0D>
- C., E. O., B., J. E. C., & O., J. I. S. (2017). Caracterización de los potenciales de Energía Solar y Eólica para la integración de Proyectos sostenibles en Comunidades Indígenas en La Guajira Colombia. *Espacios*, 38, 11. <https://repositorio.cuc.edu.co/handle/11323/3288#.YK2I15y5QLo.mendeley>
- Cano, L., Carmona, M., Martínez, J., & Arias, P. (2022). Estimación y pronóstico de radiación solar en el valle de Aburrá - Colombia. *Revista de la Academia Colombiana de Ciencias Exactas, Físicas y Naturales*, 46, 529-549.
- Castellini, A., Bloisi, D., Blum, J., Masillo, F., & Farinelli, A. (2020). Multivariate sensor signals collected by aquatic drones involved in water monitoring: A complete dataset. *Data in Brief*, 30, 105436. <https://doi.org/10.1016/j.dib.2020.105436>
- castillo, G. C., & Sainea, A. F. R. (2024). *Análisis Predictivo de la viabilidad de la instalación para plantas de Energía Solar en Colombia mediante Machine Learning y Datos Meteorológicos*.

- Cherif, A., Cardenas, J., & Rahimi, T. (2025). Advanced and Optimized Forecasting Techniques for Wind Power Generation: A Comparative Analysis. *2025 IEEE 13th International Conference on Smart Energy Grid Engineering, SEGE 2025*, 263-269. <https://doi.org/10.1109/SEGE65970.2025.11203747>
- DelaO-Arévalo, L., Bojorges-Valdez, E., Hernández-Quintela, E., & Ramos-Betancourt, N. (2019). Comparison of image classification algorithms using Meibography Images. <https://doi.org/10.13140/RG.2.2.11493.65764>
- Devi, V. B., Prabavathi, R., Subha, P., Varshine, K. S., Shwetha, S., & Aarthi, S. (2024). Climate Prediction Using AI. *4th International Conference on Power, Energy, Control and Transmission Systems: Harnessing Power and Energy for an Affordable Electrification of India, ICPECTS 2024*. <https://doi.org/10.1109/ICPECTS62210.2024.10780047>
- Dhakal, R., Yosfovand, M., Prasai, S., Sedai, A., Pol, S., Parameswaran, S., & Moussa, H. (2022). Deep Learning Model with Probability Density Function and Feature Engineering for Short Term Wind Speed Prediction. *2022 North American Power Symposium, NAPS 2022*. <https://doi.org/10.1109/NAPS56150.2022.10012249>
- Etukuru, R. (2023). *ENHANCING FORECASTING ACCURACY THROUGH ARTIFICIAL INTELLIGENCE-DRIVEN COMPLEXITY-CONSCIOUS PREDICTION MODELING* (inf. téc.). <https://ssrn.com/abstract=4661154>
- Fennane, S., Kacimi, H., Mabchour, H., Altalqi, F., & Echchel, A. (2025). Optimizing Wind Speed Prediction: A Critical Comparison of Advanced Neural Network Architectures. *2025 International Conference on Circuit, Systems and Communication, ICCSC 2025*. <https://doi.org/10.1109/ICCSC66714.2025.11134934>
- Ferreira, Â. P., Ramos, J. G., & Fernandes, P. O. (2019). A linear regression pattern for electricity price forecasting in the Iberian electricity market Patrón de regresión lineal para la previsión de precios de electricidad del mercado eléctrico Ibérico, 117-127. <https://doi.org/10.17533/udea.redin>
- Ghani, A., Alsaedi, N., Varnamkhasti, M. J., Mohammed, H. J., & Aghajani, M. (2024). Data Mining Classification Techniques to Improve Decision-Making Processes. *International Journal of Mathematical Modelling & Computations*, 14, 363-380. <https://doi.org/10.71932/ijm.2024.1198139>
- Gordon, S. D., & Uetz, G. W. (2012). Environmental interference: Impact of acoustic noise on seismic communication and mating success. *Behavioral Ecology*, 23, 707-714. <https://doi.org/10.1093/beheco/ars016>
- Grebovic, M., Filipovic, L., Katnic, I., Vukotic, M., & Popovic, T. (2022). Overcoming Limitations of Statistical Methods with Artificial Neural Networks. *Proceedings - 2022 23rd Interna-*

- tional Arab Conference on Information Technology, ACIT 2022*. <https://doi.org/10.1109/ACIT57182.2022.9994218>
- Guevara, W. J. O. (2025). *Uso del Machine Learning en la predicción de la demanda de energía en Colombia 1* (Vol. 11). http://scioteca.caf.com/bitstream/handle/123456789/1091/RED2017-Eng-8ene.pdf?sequence=12&isAllowed=y%0Ahttp://dx.doi.org/10.1016/j.regsciurbeco.2008.06.005%0Ahttps://www.researchgate.net/publication/305320484_SISTEM_PEMBETUNGAN_TERPUSAT_STRATEGI_MELESTARI
- Lei, M., Shiyang, L., Chuanwen, J., Hongling, L., & Yan, Z. (2009, mayo). A review on the forecasting of wind speed and generated power. <https://doi.org/10.1016/j.rser.2008.02.002>
- Lorenzo, M. M. G., Rodriguez, Y., Ramón-Hernandez, A., Bello-Garcia, B., Filiberto, Y., Rosete, A., Caballero, Y., & Bello, R. (2020). Adquisición de conocimiento sobre la letalidad de la COVID-19 mediante técnicas de inteligencia artificial. *Academia de ciencias de cuba*.
- Mesa, O. A. V. (2020). *ANÁLISIS DEL RECURSO SOLAR MEDIANTE MODELOS ESTADÍSTICOS DE PREDICCIÓN DE CORTO PLAZO EN LA SABANA DE BOGOTÁ* (inf. téc.).
- Mora, J. R. R., & Julio, M. B. P. (2025). *Horizonte 2050: sistema web de análisis predictivo del consumo eléctrico per cápita global mediante modelos de regresión lineal* (inf. téc.).
- Muñoz, Y. A., & Bel, C. A. (2012). *OPTIMIZACION DE RECURSOS ENERGETICOS EN ZONAS AISLADAS MEDIANTE ESTRATEGIAS DE SUMINISTRO Y CONSUMO* [Tesis doctoral, UNIVERSIDAD POLITÉCNICA DE VALENCIA].
- Novák, A., Havel, K., & Bugaj, M. (2018). Measurement of GNSS signal interference by a flight laboratory. *Transportation Research Procedia*, 35, 271-278. <https://doi.org/10.1016/j.trpro.2018.12.011>
- Ochoa, C. M., Betancur, J. D. H., & Múnera, Ó. M. G. (2012). La valoración de proyectos de energía eólica en Colombia bajo el enfoque de opciones reales. *Cuadernos de Administracion*.
- Ortiz, J. E. A., & Mora, D. J. B. (2021). *PREDICCIÓN DEL RECURSO SOLAR DIARIO MEDIANTE TÉCNICAS DE MACHINE LEARNING PARA LA PROYECCIÓN DE GENERACIÓN DE ENERGÍA ELÉCTRICA* (inf. téc.). UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ DE CALDAS.
- Palomeque, L. A. R. (2023). *ESCUELA TÉCNICA SUPERIOR DE INGENIEROS INDUSTRIALES Y DE TELECOMUNICACIÓN* (inf. téc.). universidad de cantabria.
- Phan, Q. T., Wu, Y. K., & Phan, Q. D. (2021). A hybrid wind power forecasting model with xgboost, data preprocessing considering different nwps. *Applied Sciences (Switzerland)*, 11, 1-19. <https://doi.org/10.3390/app11031100>
- Pla, G. V. (2015). *Métodos de aprendizaje máquina aplicados a la predicción del consumo eléctrico de edificios* [Tesis doctoral, UNIVERSIDAD DE CASTILLA-LA MANCHA].

- Polak, L., Kaller, O., Klozar, L., Sebesta, J., & Kratochvil, T. (2015). Exploring and Measuring Possible Co-Existences between DVB-T2-Lite and LTE Systems in Ideal and Portable Fading Channels. *Journal of Applied Research and Technology*, 13, 32-44. [https://doi.org/10.1016/S1665-6423\(15\)30003-1](https://doi.org/10.1016/S1665-6423(15)30003-1)
- Quispe, R., & Huamani, R. (2024). Autoregressive Models for Forecasting Wind Speed in the Rural Area of Socabaya, Peru, 2022. *Revista Politecnica*, 54, 7-14. <https://doi.org/10.33333/rp.vol54n1.01>
- Ramírez-Murillo, H., Torres-Pinzón, C. A., & Forero-García, E. F. (2019). Estimación del potencial fotovoltaico mediante minería de datos en cuatro ciudades de Colombia. *TecnoLógicas*, 22, 77-97. <https://doi.org/https://doi.org/10.22430/22565337.1345>
- Rojas, M. E. A. (2015). Una Mirada a La Inteligencia Artificial. *Revista Ingeniería, Matemáticas y Ciencias de la Información*, 2, 27-31. <https://documat.unirioja.es/descarga/articulo/7894426.pdf>
- Ruiz, K. D. C. (2024). Estadístico, Predictivo y de Distribución. *apuntes de ingeniería*.
- Saldaña-Flores, R., & Rivera-Blanco, C. (2012). ASSESSMENT TO WIND POWER FOR ELECTRICITY GENERATION IN THE STATE OF VERACRUZ (MEXICO) QUETZALCOATL HERNÁNDEZ-ESCOBEDO FRANCISCO ESPINOSA-ARENAL. 79, 215-221.
- Sánchez, J. L., García Ortega, E., & Marcos, J. L. (2001). Construction and assessment of a logistic regression model applied to short-term forecasting of thunderstorms in León (Spain) [Conference on European Tornadoes and Severe Storms]. *Atmospheric Research*, 56(1), 57-71. [https://doi.org/https://doi.org/10.1016/S0169-8095\(00\)00089-2](https://doi.org/https://doi.org/10.1016/S0169-8095(00)00089-2)
- Sánchez, M. J. L. (2025). *Pronóstico de Consumo Eléctrico y Detección de Anomalías mediante Machine Learning* (inf. téc.). Universidad Nacional de Educación a Distancia.
- SEVILLA, A. G. P. (2021). *APLICACION DE TECNICAS DE MACHINE LEARNING PARA LA DESAGREGACION Y PRONOSTICO DEL PERFIL DE CARGA EN EL SECTOR INDUSTRIAL* (inf. téc.). UNIVERSIDAD POLITÉCNICA SALESIANA.
- Shah, S. A., Nadeem, U., Bennamoun, M., Sohel, F., & Togneri, R. (2017). Efficient Image Set Classification Using Linear Regression Based Image Reconstruction. *IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops, 2017-July*, 601-610. <https://doi.org/10.1109/CVPRW.2017.88>
- Skiadopoulos, K., Giannakis, K., Tsipis, A., Oikonomou, K., & Stavrakakis, I. (2020). Impact of drone route geometry on information collection in wireless sensor networks. *Ad Hoc Networks*, 106, 102220. <https://doi.org/10.1016/j.adhoc.2020.102220>
- Sm, I. U.-r., & Gesti, S. S. M. (2018). Procedimientos de planificación y optimización de las redes de comprobación técnica del espectro en la gama de frecuencias de ondas métricas y decimétricas Serie SM. 2.

- Smyth, R. P., Smith, M. R., Jousset, A. C., Despons, L., Laumond, G., Decoville, T., Cattenoz, P., Moog, C., Jossinet, F., Mougél, M., Paillart, J. C., von Kleist, M., & Marquet, R. (2018). In cell mutational interference mapping experiment (in cell MIME) identifies the 5' polyadenylation signal as a dual regulator of HIV-1 genomic RNA production and packaging. *Nucleic Acids Research*, 46, 1-16. <https://doi.org/10.1093/nar/gky152>
- Suwansukho, N., Promwong, S., & Chamchoy, M. (2017). Evaluation of DVB-T2 transmission channel in Bangkok, Thailand. *2nd Joint International Conference on Digital Arts, Media and Technology 2017: Digital Economy for Sustainable Growth, ICDAMT 2017*, 79-84. <https://doi.org/10.1109/ICDAMT.2017.7904939>
- Trespalcacios, A., Vélez, L. G., Franco, L. E., Carrasquilla, F., Palacios, Y., & Giraldo, E. (2025). Analysis of the Impact on the Spot Price of Electricity in Colombia Due to the Delay of the Ituango Hydroelectric Project. *Revista de Economía Institucional*, 27, 285-317. <https://doi.org/10.18601/01245996.v27n52.10>
- Ulloa, H., M, G., Pérez, A., Meulenert, A., & D, A. (2011). CLIMA Y RADIACIÓN SOLAR EN LAS GRANDES CIUDADES: ZONA METROPOLITANA DE GUADALAJARA. *Investigaciones Geográficas*. <http://www.redalyc.org/articulo.oa?id=17624330009>
- Walke, S., Alkrimi, J. A., Bhanja, A. K., Thakur, M., Parida, P. K., & Varma, R. A. (2023). Optimizing Predictive Analysis Through Enhanced AI Technologies. *2023 International Conference on Power Energy, Environment and Intelligent Control, PEEIC 2023*, 1649-1654. <https://doi.org/10.1109/PEEIC59336.2023.10451137>
- Xiao, Y., Lu, W., Yan, Q., & Zhang, H. (2021). Blind separation of coherent multipath signals with impulsive interference and Gaussian noise in time-frequency domain. *Signal Processing*, 178, 107750. <https://doi.org/10.1016/j.sigpro.2020.107750>
- Yan, J., Han, X., Wang, H., Ge, C., & Liu, Y. (2025). An AI-based weather prediction method for wind farms combining global forecast field and wind speed temporal transfer characteristics. *Energy*, 329. <https://doi.org/10.1016/j.energy.2025.136740>
- Zhou, X., Sun, Y., Wu, J., & Huang, X. (2026). A systematic approach to developing an effective AI-based bias correction model. *Atmospheric and Oceanic Science Letters*. <https://doi.org/10.1016/j.aosl.2026.100794>