



INVESTIGACIÓN X

PROFUNDIZACIÓN _

DESARROLLO DE UN MODELO DE PREDICCIÓN DE CONSUMO DE ENERGÍA EN COMUNIDADES ZNI A TRAVÉS DE INTELIGENCIA ARTIFICIAL

Autor

Johan Nicolás Cuellar Salinas

Director

Elvis Eduardo Gaona García, PhD

Codirector

Diego Julián Rodríguez Patarroyo, PhD

Universidad Distrital Francisco José De Caldas

Maestría en Ciencias de la Información y las Comunicaciones

Bogotá, Colombia

2025

CONTENIDO

Resumen	4
Palabras Clave	5
Introducción	6
1. Problema de investigación	8
1.1. Planteamiento	8
1.2. Justificación	11
1.3. Preguntas de investigación	14
1.3.1. Pregunta principal	14
1.3.2. Preguntas secundarias	14
2. Objetivos	15
2.1. Objetivo General	15
2.2. Objetivos Específicos	15
3. Hipótesis	16
4. Marco de Referencia	17
5. Metodología	29
6. Impacto y Resultados Esperados	34
7. Recursos y presupuesto	37
8. Cronograma	38
9. Limitaciones	42
10. Referencias	44

RESUMEN

El acceso limitado y poco fiable a la energía eléctrica en las Zonas No Interconectadas (ZNI) de Colombia representa una barrera significativa para el desarrollo socioeconómico y la calidad de vida, perpetuando la pobreza energética en muchas comunidades aisladas que dependen de sistemas diésel costosos, contaminantes e intermitentes. La planificación efectiva de soluciones energéticas sostenibles y la integración de fuentes renovables en estas zonas, en línea con la Transición Energética Justa (TEJ), requieren urgentemente una predicción precisa del consumo energético, una tarea desafiante debido a la escasez de datos históricos, los patrones de uso únicos y las condiciones operativas particulares de las ZNI. Aunque las metodologías de pronóstico han avanzado significativamente con técnicas de Aprendizaje Automático (ML) y Profundo (DL), superando a los modelos estadísticos tradicionales en el manejo de datos complejos, existe una brecha notable en su aplicación y adaptación a las características específicas de estas comunidades rurales y aisladas.

Esta tesis de maestría aborda dicha brecha proponiendo el desarrollo y la validación de un modelo predictivo de consumo energético basado en ML/DL, específicamente diseñado y adaptado para el contexto de las ZNI colombianas. La investigación se enfoca en demostrar la viabilidad de aplicar estos modelos avanzados a pesar de las limitaciones de datos, mediante la caracterización de patrones de consumo locales, la identificación de variables predictoras relevantes y la implementación de estrategias adecuadas de manejo de datos. El objetivo principal es establecer un modelo robusto cuya precisión sea suficiente para informar eficazmente la planificación operativa y el dimensionamiento de soluciones energéticas locales. Se espera que esta investigación contribuya con una herramienta útil para mejorar la gestión energética, facilitar la integración de fuentes renovables y apoyar los esfuerzos para reducir la pobreza energética en las regiones no interconectadas del país.

PALABRAS CLAVE

Predicción de Consumo Energético, Zonas No Interconectadas (ZNI), Aprendizaje Automático (Machine Learning), Aprendizaje Profundo (Deep Learning), Series de Tiempo, Comunidades Aisladas, Pobreza Energética, Escasez de Datos, Planificación Energética, Energías Renovables, Transición Energética Justa (TEJ), LSTM, Random Forest, Gradient Boosting Machine (GBM), Modelos Basados en Datos.

INTRODUCCIÓN

El progreso social y económico de una nación está intrínsecamente relacionado con la disponibilidad de fuentes confiables de energía. Aun así, lograr esta disponibilidad de forma global es un reto que no se ha logrado conseguir, y en este panorama, países en vías de desarrollo como Colombia enfrentan dificultades severas. Fuentes de energía poco predecibles, afectan de forma directa el crecimiento económico y el desarrollo de iniciativas sociales, educativas e industriales (Fasipe et al., 2024). Dentro de Colombia, las Zonas No Interconectadas (ZNI) representan un 51% del área geográfica total, allí los retos referentes a la disponibilidad de energía eléctrica son particularmente severos (Ramírez Murillo, 2023). Los residentes de estas zonas generalmente viven en pobreza energética, lo que traduce en poco acceso a fuentes consistentes de energía, la dependencia de fuentes de generación a base de diésel resulta en costos operacionales altos, problemas ambientales y comúnmente, horarios limitados de disponibilidad de servicio eléctrico, lo que directamente impide mejoras en las condiciones de vida de la población a su vez que restringe las economías locales (Bernal Suárez et al., 2024).

Afrontar estos déficits de energía, especialmente dentro del marco de las metas para la Transición Energética Justa en Colombia (TEJ), demanda una planeación meticulosa y la optimización en el despliegue de los recursos, ambas cosas dependen directamente de la habilidad para predecir de manera acertada el consumo futuro de energía (Gebre et al., 2024). Estas proyecciones son indispensables para cualquier proyecto energético, particularmente para sistemas no conectados a la red eléctrica general, donde resulta crítico evitar tanto la sobreestimación como la subestimación de las necesidades, esto con miras a lograr la viabilidad económica del proyecto y su éxito operacional (Rushman et al., 2019).

Las metodologías para proyectar el consumo energético de comunidades han avanzado más allá de los modelos estadísticos simples (Wang et al., 2021). Mientras técnicas de regresiones lineales han sido estudiadas y en algunos casos son aplicadas (Madhusudanan, 2019) comúnmente se quedan cortas al capturar dinámicas complejas y no-linealidades presentes en los datos de uso reales de energía eléctrica (Qiao et al.,

2023). Consecuentemente, las aproximaciones basadas en datos que usan Aprendizaje de Máquina (ML) y Aprendizaje Profundo (DL) han ganado terreno. Algoritmos como Support Vector Machine (SVM), Random Forest (RF), Gradient Boosting Machine (GBM) y Long Short Term Memory (LSTMs) ofrecen capacidades mejoradas para el modelamiento de patrones temporales complejos influenciados por factores diversos como el clima y la actividad de los usuarios (Cabiddu et al., 2024; Jawad et al., 2020; Wang et al., 2021). Estos métodos han mostrado ser exitosos en varios contextos, desde edificaciones individuales hasta ciudades enteras (Gellert et al., 2024). Al tiempo, incluir información meteorológica (temperatura y humedad, por ejemplo) a estos sistemas ha mostrado ser beneficioso para el mejoramiento de la predicción (Jawad et al., 2020).

Sin embargo, la predicción de consumo de energía eléctrica en asentamientos urbanos aislados dentro de las ZNI de Colombia permanece sin desarrollos significativos (Ramírez Murillo, 2023). Como se puede notar en estudios hechos en ambientes similares al colombiano, obtener datos históricos confiables de consumo en estas comunidades resulta difícil (Herraiz-Cañete et al., 2022; Rushman et al., 2019). Además, el comportamiento de consumo en estas áreas está comúnmente moldeado por prácticas culturales únicas y realidades socioeconómicas diversas (Molina et al., 2018), lo que demanda un algoritmo hecho a la medida de estas características en vez de uno general que no tenga en cuenta ninguno de los matices ya mencionados.

Por lo tanto, esta tesis de maestría, la cual contribuye a un trabajo doctoral más grande enfocado a la aplicación de IA para la estimación de potenciales energéticos, se enfoca en desarrollar un modelo de ML/DL que prediga el consumo eléctrico de forma acertada en comunidades aisladas dentro del territorio colombiano. El trabajo aquí propuesto apunta a la creación de una herramienta predictiva que incorpore las dinámicas de consumo y factores ambientales locales. El desarrollo exitoso de dicho modelo ofrecerá más información para la planeación energética local, apoyará el despliegue de tecnologías de energía renovable y contribuirá a la reducción de la pobreza energética con lo cual se espera mejorar la calidad de vida en las Zonas No Interconectadas del país.

1. PROBLEMA DE INVESTIGACIÓN

1.1. Planteamiento

El acceso universal a energía eléctrica confiable y sostenible es un pilar fundamental para el desarrollo socioeconómico y el bienestar de las comunidades a nivel global (Gebre et al., 2024). No obstante, esta meta enfrenta obstáculos significativos, especialmente en regiones geográficamente aisladas y dispersas, como es el caso de las Zonas No Interconectadas (ZNI) en Colombia. Estas zonas, que abarcan una porción considerable del territorio nacional (Ramírez Murillo, 2023), se caracterizan por una alta incidencia de pobreza energética y una dependencia generalizada de sistemas de generación basados en diésel. Estos sistemas, además de ser costosos y tener un impacto ambiental negativo, frecuentemente ofrecen un suministro intermitente y de calidad deficiente, lo cual limita las oportunidades de desarrollo y perpetúa condiciones de vulnerabilidad (Bernal Suárez et al., 2024).

Para superar este déficit energético y avanzar hacia los objetivos de la Transición Energética Justa (TEJ) en Colombia (Bernal Suárez et al., 2024), se requiere imperativamente una planeación robusta y una administración eficiente de los recursos energéticos. Un componente crítico de esta planeación es la capacidad de proyectar con precisión el consumo futuro de energía eléctrica. Una predicción acertada de la demanda no solo optimiza la operación de los sistemas existentes y la gestión de recursos (Jawad et al., 2020), sino que también es fundamental para el diseño y dimensionamiento adecuado de nuevas soluciones energéticas, especialmente aquellas basadas en fuentes renovables (Rushman et al., 2019), y para la formulación de políticas energéticas efectivas (Gellert et al., 2024). La falta de predicciones confiables, por el contrario, conduce a ineficiencias, sobrecostos y dificulta la integración de alternativas energéticas limpias (Barja-Martínez et al., 2024).

Históricamente, los métodos estadísticos tradicionales, como los modelos ARIMA, han sido utilizados para el pronóstico de demanda. Sin embargo, estos enfoques a menudo presentan dificultades para capturar la complejidad, no linealidad y las dependencias

dinámicas inherentes a los datos de consumo energético moderno (Madhusudanan, 2019; Qiao et al., 2023). En respuesta a estas limitaciones, las técnicas de Aprendizaje Automático (ML) y Aprendizaje Profundo (DL) han emergido como alternativas prometedoras, demostrando un rendimiento superior en el modelado de relaciones intrincadas y dependencias temporales en diversos contextos energéticos (Cabiddu et al., 2024; Fasipe et al., 2024). Algoritmos como LSTM, Random Forest y Gradient Boosting Machines son cada vez más empleados por su capacidad para manejar la granularidad y complejidad de los datos de consumo (Patricio et al., 2024; Wang et al., 2021).

A pesar del avance y la creciente aplicación de ML/DL en el sector energético, existe una brecha significativa en el desarrollo y adaptación de estos modelos a las condiciones específicas y desafiantes de las comunidades aisladas en las ZNI colombianas. La literatura existente tiende a enfocarse en sistemas interconectados, áreas urbanas con mayor disponibilidad de datos, o contextos geográficos y socioeconómicos diferentes. Las comunidades ZNI, por su parte, presentan un conjunto de particularidades que dificultan la aplicación directa de modelos genéricos:

- **Escasez y baja calidad de datos históricos de consumo:** La falta de mediciones sistemáticas y detalladas es una barrera fundamental (Herraiz-Cañete et al., 2022; Rushman et al., 2019).
- **Patrones de consumo únicos y variables:** El comportamiento de consumo en estas áreas está moldeado por factores culturales, socioeconómicos (como la limitada penetración de electrodomésticos), y operativos (como la intermitencia del suministro) que difieren sustancialmente de los de zonas urbanas o interconectadas (Molina et al., 2018).
- **Influencia marcada de variables locales:** Factores como las condiciones climáticas específicas de micro-regiones, la estructura de las viviendas, o las actividades productivas incipientes pueden tener un impacto desproporcionado en la demanda.

La ausencia de modelos de predicción de consumo energético que estén específicamente diseñados y validados para las ZNI colombianas constituye el problema central de esta investigación. Esta carencia tiene consecuencias directas:

- Dificulta la planificación eficiente de la expansión y mejora del suministro energético.
- Obstaculiza el dimensionamiento óptimo y la integración efectiva de sistemas de energía renovable, que son cruciales para la TEJ y la sostenibilidad en estas regiones (un aspecto directamente relevante para el proyecto doctoral del cual esta tesis forma).
- Limita la capacidad de diseñar políticas y programas de gestión de la demanda y eficiencia energética que sean verdaderamente efectivos y adaptados a las necesidades locales.
- Contribuye a la perpetuación de la pobreza energética al no proveer las herramientas necesarias para optimizar el uso de recursos escasos.

Este panorama evidencia una necesidad clara y urgente de investigar y desarrollar metodologías predictivas que puedan operar con eficacia bajo las condiciones de las ZNI. El problema aquí identificado no es meramente técnico, sino que tiene profundas implicaciones para el desarrollo sostenible y la equidad social en Colombia.

Abordar esta problemática requiere, por tanto, una investigación sistemática que explore la viabilidad y efectividad de los modelos ML/DL en este contexto particular. Se necesita un enfoque que no solo seleccione algoritmos adecuados, sino que también desarrolle estrategias para el manejo de datos limitados e incorpore las variables predictoras más relevantes para las ZNI. Esta necesidad de un modelo adaptado y validado da origen directo a las preguntas de investigación que guían este estudio, tal como se detallan en la sección 1.3.

1.2. Justificación

El acceso a fuentes confiables y sostenibles de energía es fundamental para el desarrollo social y económico, sin embargo, hay una disparidad significativa que afecta a múltiples comunidades a nivel global y de forma más específica a naciones en vías de desarrollo como Colombia (Molina et al., 2018). Colombia se enfrenta a desafíos considerables en este aspecto, mayormente en las Zonas No Interconectadas (ZNI), las cuales constituyen el 51% del territorio nacional (Ramírez Murillo, 2023) pero este tipo de comunidades suelen estar altamente afectadas por pobreza energética y acceso limitado a una fuente confiable de electricidad (Bernal Suárez et al., 2024; Ramírez Murillo, 2023). Estas regiones que abarcan (aunque no se limitan) partes de la Orinoquía, Amazonía, la Costa Pacífica y la Guajira, frecuentemente dependen de generadores diésel que son costosos y contaminantes (constituyendo el 85% de la capacidad de las ZNI y a menudo estos generadores solo proveen energía de forma intermitente, incluso existen áreas donde solo cuentan con electricidad por 6 horas al día. Esta situación dificulta la prestación de servicios básicos como salud y educación, al tiempo que limita las oportunidades de desarrollo económico y perpetúa los ciclos de pobreza (Bernal Suárez et al., 2024; Molina et al., 2018; Ramírez Murillo, 2023)

Atender este déficit energético requiere una planeación robusta y una administración de recursos eficiente (Gebre et al., 2024), Colombia persigue estos objetivos como parte de la Hoja de Ruta para Una Transición Energética Justa, la cual apunta a integrar con mayor frecuencia y efectividad fuentes de energía renovables (Ramírez Murillo, 2023) Un componente crucial para esta planeación es la predicción acertada del consumo de energía. La predicción de la demanda energética es ampliamente considerada fundamental para el manejo moderno de sistemas eléctricos (Barja-Martinez et al., 2024). Además, juega un papel importante en la operación eficiente de redes eléctricas, la optimización de la planeación por parte de empresas proveedoras de energía (servicios públicos), y el fortalecimiento de la estabilidad de la malla energética a la vez que habilita la integración efectiva de fuentes renovables de energía como la energía solar y la eólica (Hong, 2015; Jawad et al., 2020). La habilidad de predecir necesidades energéticas

futuras facilita la optimización del agendamiento de la producción, minimizando el desperdicio energético al tiempo que ayuda a prevenir sobrecargas del sistema (que generan altos costos) y ayuda a la toma informada de decisiones para el desarrollo infraestructura y políticas energéticas (Gellert et al., 2024). Por el contrario, la inadecuada predicción de consumo puede producir sobrecostos significativos debido al desbalance entre la producción y el consumo, afectando particularmente a los productores en mercados competitivos (Barja-Martinez et al., 2024; Jawad et al., 2020). Por esto, desarrollar modelos de predicción robustos y acertados es una tarea crucial para cualquier parte interesada en el sector energético, incluyendo consumidores, empresas de servicios públicos y agentes gubernamentales a cargo de la creación de políticas energéticas ambiental y económicamente sostenibles.

Métodos estadísticos tradicionales para la predicción de consumo energético, tales como las regresiones lineales (ARIMA por ejemplo), a menudo tienen problemas para capturar los patrones complejos y no lineales inherentes a los datos de consumo energético (Wang et al., 2021). Técnicas de Aprendizaje de Máquina (ML) y Aprendizaje Profundo (DL) han emergido como alternativas efectivas, pues han demostrado un rendimiento superior al modelar relaciones intrincadas entre las variables y dependencias temporales de las mismas. Algoritmos como LSTMs, Random Forests y Gradient Boosting Machines son cada vez más usados, debido principalmente a su habilidad de manejar la granularidad y complejidad de los datos de consumo energético desde distintas fuentes (Barja-Martinez et al., 2024; Fasipe et al., 2024).

Mientras las soluciones basadas en ML y DL van avanzando, existe una brecha en su aplicación en contextos como el colombiano, según se pudo encontrar, existen pocas investigaciones enfocadas en comunidades rurales aisladas, como las comunidades indígenas autóctonas de Colombia (Molina et al., 2018). Además, las comunidades en las ZNI frecuentemente carecen de datos de consumo histórico, y presentan distintos patrones de consumo, influenciados por factores culturales, poca disponibilidad de artículos eléctricos, así como condiciones ambientales únicas (Bernal Suárez et al., 2024; Molina et al., 2018; Ramírez Murillo, 2023).

Esta tesis de maestría, como parte de una investigación doctoral más amplia enfocada en predecir los potenciales de energía usando IA. La justificación de este trabajo se basa en estos pilares:

Abordar la pobreza y desigualdad energética: Proveer herramientas para un mejor manejo en las ZNI es crucial para la mejoría en los estándares de vida locales, permitiendo la diversificación de actividades económicas y la reducción de inequidades energéticas pronunciadas remarcadas en los índices nacionales.

Apoyar la transición energética sostenible: Como ya se mencionó, la predicción acertada del consumo de energía eléctrica es indispensable para la planeación efectiva y la integración de soluciones de energía renovable (solares, eólicas, biomasas, etc.), lo que resulta vital para la reducción de la dependencia del Diesel y de esta forma cumplir con los objetivos TEJ.

Mejorar la planeación y la eficiencia operacional: El modelo predictivo podría generar una valiosa perspectiva que permita la optimización del despacho de generadores existentes, la estimación de tamaños de sistemas energéticos apropiada, designación de mejores tarifas (si es aplicable en el caso específico) y la creación de campañas de eficiencia energética enfocadas y bien informadas, incluso en ambientes con pocos datos disponibles.

Contribución científica: El desarrollo y evaluación de un modelo de ML/DL para este caso específico, el cual no cuenta con investigaciones extensivas, contribuye con conocimiento novedoso al campo de predicción de consumo de energía eléctrica, sobre todo si se tiene en cuenta la calidad de los datos presentes y las características de las comunidades.

Esta investigación está justificada por la necesidad de abordar la pobreza energética desde todo campo posible y facilitar la transición energética sostenible. Al aprovechar las capacidades de los algoritmos de ML y DL, esta tesis apunta a desarrollar una herramienta útil, un modelo acertado de predicción de consumo de energía eléctrica en el contexto de comunidades pequeñas. Esta herramienta ayudará a la toma informada de decisiones, optimización de la ubicación de recursos, soporte a la integración de energías

renovables y de esta forma, como objetivo final, la mejoría de la calidad de vida de las personas en las comunidades apartadas en las que se aplique dicho modelo.

1.3. Preguntas de investigación

Para abordar de manera efectiva el desafío de la predicción del consumo energético en las Zonas No Interconectadas (ZNI) de Colombia, y considerando las limitaciones y particularidades de estas comunidades aisladas, es fundamental establecer un marco de investigación claro y enfocado. Las siguientes preguntas de investigación están diseñadas para guiar el desarrollo y la evaluación de un modelo de aprendizaje automático/profundo (ML/DL) que sea preciso, robusto y contextualmente relevante para las ZNI, contribuyendo así a una mejor planificación energética y al apoyo de la transición hacia soluciones sostenibles en estas regiones.

1.3.1. Pregunta principal

¿Cómo puede diseñarse, implementarse y validarse un modelo predictivo de consumo energético, basado en aprendizaje automático o profundo (ML/DL), que considere y se adapte a las características específicas de las comunidades aisladas dentro de las Zonas No Interconectadas (ZNI) de Colombia, como pueden ser la escasez de datos históricos, patrones de uso atípicos e intermitencia de uso y suministro?

1.3.2. Preguntas secundarias

- ¿Qué variables exógenas (ej. datos climáticos locales, información demográfica básica, características de la infraestructura energética existente, horarios de suministro) demuestran tener mayor poder predictivo para los modelos de consumo ML/DL en el entorno ZNI?
- ¿Qué estrategias de preprocesamiento, ingeniería de características, imputación de datos o potencialmente técnicas de aumento de datos (data augmentation) son más

efectivas para maximizar la utilidad de la información limitada disponible y mejorar el rendimiento de los modelos ML/DL en las ZNI?

- ¿Cómo se desempeña el modelo predictivo final bajo distintos escenarios simulados (ej. variaciones climáticas extremas, cambios en la disponibilidad de energía, introducción paulatina de nuevos electrodomésticos)?

2. OBJETIVOS

Para comprobar la hipótesis formulada y dar respuesta a las preguntas de investigación, este trabajo se propone alcanzar los siguientes objetivos:

2.1. Objetivo General

Desarrollar un modelo predictivo basado en aprendizaje automático/profundo (ML/DL) que demuestre la viabilidad de estimar con precisión útil el consumo de energía eléctrica en comunidades aisladas de las ZNI colombianas, adaptándose a las limitaciones de datos y características locales para aumentar la información disponible y relevante para la planificación y el dimensionamiento de soluciones energéticas.

2.2. Objetivos Específicos

- Establecer los requisitos funcionales y de datos específicos para el modelo predictivo ML/DL, considerando las características únicas del consumo en las ZNI y las limitaciones de información identificadas
- Seleccionar y adaptar modelos de aprendizaje automático/profundo (ej. LSTM, GBM, RF) que sean adecuadas para modelar series temporales de consumo energético.

- Validar el modelo ML/DL en términos de su capacidad para generar pronósticos de consumo que sean suficientemente precisos y detallados como para informar decisiones sobre la planificación operativa y el dimensionamiento de sistemas energéticos locales.

3. HIPÓTESIS

La presente investigación, reconociendo los desafíos únicos de la predicción de consumo en las ZNI y el potencial de los modelos ML/DL adaptados, se guía por la siguiente hipótesis fundamental:

El desarrollo y la validación rigurosa de un modelo predictivo de consumo energético, fundamentado en algoritmos de aprendizaje automático/profundo (ML/DL) y específicamente adaptado a las condiciones de datos y patrones de uso característicos de las comunidades ZNI en Colombia, demostrará la viabilidad de obtener pronósticos con la exactitud y el detalle necesarios para informar eficazmente la planificación y el dimensionamiento de sistemas energéticos locales en dichas zonas.

4. MARCO DE REFERENCIA

4.1. Estado del Arte

Los métodos de predicción de consumo energético han evolucionado considerablemente en los últimos años. Las aproximaciones iniciales dependían de técnicas simples, pero el incremento en la complejidad de los sistemas energéticos y la disponibilidad de datos más granulares ha conducido a la adopción de métodos más sofisticados (T. Hong, 2015). Métodos estadísticos fundamentales, incluyendo varias formas de regresión lineal y modelos de series de tiempo como ARIMA (Autoregressive Integrated Moving Average) y ARIMAX, aún son relevantes pues son comúnmente usados como puntos de referencia debido a sus metodologías e interpretabilidad (Almuhanha, 2024; Madhusudanan, 2019; Wang et al., 2021). Sin embargo, estos métodos tradicionales presentan limitaciones cuando deben lidiar con no-linealidades inherentes, tales como estacionalidades complejas y dependencias dinámicas presentes en los datos de consumo energético moderno (Madhusudanan, 2019; Qiao et al., 2023). Esto ha producido una amplia exploración y aplicación de técnicas de Aprendizaje de Máquina (ML por sus siglas en inglés) y Aprendizaje Profundo (DL por sus siglas en inglés). Algoritmos como Support Vector Machines (SVM) (Shapi et al., 2021), Random Forests (RF) (Dubey et al., 2024), Gradient Boosting Machines (GBM) (Wang et al., 2021), K-Nearest Neighbors (KNN) (G. Hong et al., 2022), Artificial Neural Networks (ANN) (Shapi et al., 2021), redes neuronales más avanzadas como las Recurrent Neural Networks (RNNs) específicamente Long Short-Term Memory (LSTM)(Kolluru et al., 2024; Patricio et al., 2024) son cada vez más preferidos por su capacidad de modelar patrones intrincados y dependencias temporales de amplio rango en datos de consumo energético.

Las aplicaciones prácticas de estas técnicas de predicción son diversas, se enfocan en múltiples ubicaciones geográficas, escalas de sistemas energéticos y objetivos específicos. Por ejemplo, existen múltiples trabajos que se enfocan en el hogar y los electrodomésticos usados en él, entre estos podemos encontrar el trabajo realizado por (Li et al., 2024) que usa un algoritmo de Temporal Graph Convolutional Networks (TGCN)

diseñado para aprender las posibles correlaciones entre diferentes electrodomésticos y fue probada en los conjuntos de datos AMPDS y UK-DALE. También se encuentran desarrollos como el realizado en (Patricio et al., 2024) que combina las ventajas de los algoritmos genéticos para la optimización y la predicción de series temporales de las redes neuronales tipo LSTM con lo que proponen un método para minimizar el costo de la energía en los hogares de Portugal. Sistemas básicos de regresiones lineales han sido utilizados para la predicción de uso energético residencial, aunque este trabajo fue contrastado con conjuntos de datos de la plataforma Kaggle solo logró llegar a un 66% de acierto (Vidhate & Nema, 2024). Escenarios que facilitan la generación, recolección y almacenamiento de datos de consumo tales como IoT facilitan la creación de técnicas eficientes tal como (Kolluru et al., 2024) que presenta resultados satisfactorios al predecir el consumo en el hogar, un error cuadrático medio de 0.0018 fue logrado al aprovechar las capacidades de las redes LSTM en series temporales.

De forma complementaria a los trabajos que intentan predecir el consumo en casas, existen investigaciones que apuntan a resolver el mismo problema, pero enfocándose en poblaciones enteras, es decir, comunidades, ciudades y regiones. En (Wang et al., 2021) se realizó una comparación de modelos (regresión lineal, Prophet, GBM, RF, SVM) para predecir el consumo diario de energía en áreas metropolitanas de Estados Unidos. La predicción de consumo en áreas semi remotas en el ártico fue abarcada en (Eikeland et al., 2021), allí se remarcó la dificultad de la predicción en dichas áreas al tiempo que se compararon diferentes métodos para conseguir resultados satisfactorios, modelos estadísticos como ARIMA y Prophet se comparan con métodos más complejos de ML (LSTM, GRU, ESN, CNN) en diferentes sectores y periodos de predicción, allí se demostró que según el periodo de predicción deseado se debe utilizar un algoritmo distinto, pues todos ellos presentan rendimientos diferentes altamente dependientes de dicho periodo. La tarea crítica de predecir la demanda energética para el diseño de mini redes de energía renovable en comunidades rurales aisladas fue examinada mediante un caso de estudio en Honduras (Herraiz-Cañete et al., 2022), en donde se compararon métodos estocásticos y determinísticos. En (Ma et al., 2024) se hace una aproximación global, allí se divide el mapa mundial en regiones y se utilizan datos temporales de luminosidad nocturna para predecir el consumo en cualquiera de las zonas demarcadas. En Sibiu, Rumania, se estimó el consumo energético de la ciudad al comparar métodos

estadísticos, de lógica difusa, LSTM y modelos de Markov aplicados a datos de empresas de servicios públicos que cubrían varios tipos de consumidores (Gellert et al., 2024). La influencia de parámetros meteorológicos en la predicción de consumo fue evaluado en (Jawad et al., 2020), allí se utilizaron varios modelos de ML y se aplicaron a datos obtenidos en Muzaffarabad, Pakistan, las conclusiones de este artículo resultan muy relevantes para la predicción que se está planteando en esta propuesta, pues dentro del territorio colombiano las condiciones climatológicas pueden variar sustancialmente de una región a otra.

Además de todo lo mencionado anteriormente, existen algunos otros puntos encontrados en la literatura que resultan relevantes para esta investigación:

- El Aprendizaje Federado (FL) y el FL Personalizado (FLP) han emergido como soluciones para el entrenamiento de modelos de predicción de consumo energético en hogares, estos métodos permiten hacer ajustes finos y adaptaciones de datos de poblaciones más grandes (datos globales como ejemplo) a el uso en hogares (Barja-Martinez et al., 2024)
- Plataformas de Big data como Apache Spark y Hadoop son recomendadas para el manejo de los grandes volúmenes de datos generados por sensores inteligentes y otros dispositivos IoT (Dubey et al., 2024)

Se pueden encontrar varios trabajos híbridos, en ellos se realiza una combinación de métodos la cual se apalanca en las ventajas de cada uno, por ejemplo, en (Qiao et al., 2023) se utiliza una capa de Descomposición Modal Variacional (VMD) para preprocesar series de tiempo complejas antes de alimentar una red LSTM con ellas, lo que aumenta la precisión final del sistema. Otro ejemplo es el trabajo hecho por (Guilian et al., 2023), en donde se utiliza un Algoritmo Genético para optimizar los parámetros de una red neuronal, de nuevo demostrando la efectividad que puede tener la combinación de múltiples algoritmos.

La revisión del estado del arte sobre la predicción de consumo energético y aplicaciones relacionadas muestra una clara tendencia al aprovechamiento de metodologías enfocadas en datos, en su mayoría técnicas de ML, tanto básicas como avanzadas. Modelos de Aprendizaje de Máquina Y Aprendizaje Profundo, particularmente LSTMs, CNNs y

técnicas de aumento de gradiente, en general, muestran un rendimiento superior a los métodos estadísticos clásicos, esto debido a la facilidad de los nuevos modelos de ML para adaptarse a las no linealidades inherentes a los sistemas de producción y consumo energético. Aunque se pudo ver con claridad que no existe un método que sea mejor o más acertado en toda situación, resulta claro que las investigaciones relacionadas apuntan a modelos cada vez más sofisticados basados en datos, a menudo bien ajustados a entornos específicos, que apuntan a mejorar la eficiencia, confiabilidad y sostenibilidad de los sistemas energéticos.

4.2. Marco Teórico

Zonas no Interconectadas (ZNI): Se refiere a aquellas áreas geográficas (como municipios, corregimientos o localidades) dentro de Colombia que no están enlazadas al Sistema Interconectado Nacional (SIN). Estas zonas se caracterizan por su dispersión territorial y lejanía de los principales puntos de consumo, lo que hace inviable su conexión a la red eléctrica principal del país (Ramírez Murillo, 2023)

Pobreza Energética: Describe la circunstancia en la cual un hogar sufre de un acceso insuficiente a los servicios energéticos, lo que restringe su capacidad para satisfacer las necesidades básicas que dependen de la energía (Bernal Suárez et al., 2024)

Inteligencia Artificial (IA): se define más comúnmente a través de la lente de los agentes inteligentes: sistemas que perciben su entorno y toman acciones que maximizan su probabilidad de alcanzar con éxito sus objetivos. Este enfoque moderno sintetiza diversas capacidades tradicionalmente asociadas con la inteligencia, incluyendo el razonamiento, el aprendizaje, la representación del conocimiento, la planificación, la percepción y la acción, enmarcando la IA como el estudio y diseño de dichos agentes. El campo es amplio, abarcando la lógica, la probabilidad y las matemáticas continuas, con aplicaciones que van desde dispositivos microelectrónicos hasta exploradores planetarios robóticos y sofisticados servicios en línea. La definición misma ha evolucionado; mientras que las conceptualizaciones tempranas, como la de McCarthy, se centraban en "la ciencia e

ingeniería de hacer máquinas inteligentes", la dificultad para definir formalmente la "inteligencia" ha llevado a un mayor énfasis en el comportamiento observable y la acción racional de los agentes dentro de su entorno, avanzando hacia criterios más operativos y medibles para la inteligencia (Russell & Norvig, 2020).

Aprendizaje Automático (Machine Learning, ML): es un subcampo de la Inteligencia Artificial que se ocupa del estudio y desarrollo de algoritmos que permiten a los programas informáticos mejorar automáticamente su rendimiento en una tarea específica a través de la experiencia, típicamente en forma de datos, sin ser programados explícitamente para esa tarea. Se centra en algoritmos que permiten a las computadoras aprender de los datos y tomar decisiones basadas en ellos, descubriendo patrones automáticamente y mejorando con la experiencia. El campo tiene estrechos vínculos con el reconocimiento de patrones, y a menudo se consideran facetas del mismo campo; el ML tradicionalmente surgió de la informática, mientras que el reconocimiento de patrones tiene orígenes en la ingeniería, pero ambos implican la identificación de regularidades en los datos. Las definiciones centrales a menudo enfatizan el aspecto de mejora del rendimiento obtenido a través de la experiencia o el aspecto de descubrimiento de patrones, reflejando perspectivas ligeramente diferentes, pero convergiendo en la idea central de aprender de los datos en lugar de depender únicamente de reglas predefinidas. Los principales paradigmas dentro del ML incluyen el aprendizaje supervisado (aprender de pares entrada-salida etiquetados), el aprendizaje no supervisado (encontrar patrones en datos no etiquetados) y el aprendizaje por refuerzo (aprender acciones a través de prueba y error basado en recompensas) (Mitchell, 1997).

Aprendizaje Profundo (Deep Learning, DL): es una forma de aprendizaje automático que permite a las computadoras aprender de la experiencia y comprender el mundo en términos de una jerarquía de conceptos, utilizando modelos computacionales compuestos por múltiples capas de procesamiento para aprender representaciones de datos con múltiples niveles de abstracción. Debido a que la computadora adquiere conocimiento de la experiencia, no hay necesidad de que un operador humano especifique formalmente todo el conocimiento requerido; la jerarquía de conceptos permite a la computadora aprender conceptos complicados construyéndolos a partir de otros más simples, lo que lleva a gráficos "profundos" de estas jerarquías. Es una rama especializada del ML que

enfatisa el entrenamiento de redes neuronales artificiales con múltiples capas ocultas (arquitecturas profundas). Una característica clave es su capacidad para el aprendizaje de representaciones, descubriendo automáticamente estructuras intrincadas en grandes conjuntos de datos al aprender características relevantes directamente de los datos brutos, reduciendo así la dependencia de la ingeniería manual de características. El aspecto definitorio no es simplemente la profundidad de la red, sino la capacidad de aprender esta jerarquía de representaciones, donde las capas inferiores podrían capturar características básicas y las capas superiores las combinan en conceptos más complejos y abstractos (Ian Goodfellow, Yoshua Bengio, Aaron Courville, 2018).

Big Data: se refiere a activos de información caracterizados por un volumen, velocidad y variedad tan altos que demandan formas innovadoras y rentables de procesamiento de información para mejorar la percepción, la toma de decisiones y la automatización de procesos. Inicialmente conceptualizado en torno a estas tres "V" (Volumen, Velocidad, Variedad) por analistas de Gartner, la definición a menudo se extiende para incluir otras características como Veracidad (incertidumbre o confiabilidad de los datos) y Valor (la utilidad potencial derivable de los datos). El Instituto Nacional de Estándares y Tecnología (NIST) ofrece una perspectiva tecnológicamente fundamentada, definiendo Big Data como conjuntos de datos cuyo tamaño, velocidad de adquisición o formato de representación limita la capacidad de los enfoques tradicionales de bases de datos relacionales para realizar análisis efectivos, necesitando tecnologías escalables horizontalmente. Crucialmente, el término es relativo; lo que constituye "Big Data" depende de las capacidades de las tecnologías de procesamiento disponibles en un momento dado, definido más por los desafíos que plantea a las herramientas tradicionales que por el tamaño absoluto. Si bien el marco de las 3V popularizó el término, existían conceptualizaciones anteriores, y la definición continúa evolucionando para abarcar desafíos de datos más amplios (Volk et al., 2022).

Aprendizaje Federado (Federated Learning, FL): es un entorno de aprendizaje automático donde múltiples clientes (por ejemplo, dispositivos móviles, organizaciones) entrenan colaborativamente un modelo compartido, típicamente orquestado por un servidor central, mientras mantienen sus datos de entrenamiento brutos descentralizados y localizados en los dispositivos del cliente. En lugar de agrupar los datos centralmente,

solo las actualizaciones del modelo, como los gradientes calculados o los pesos del modelo actualizados, se comunican entre los clientes y el servidor (o entre clientes en variantes descentralizadas) para su agregación. La motivación principal para el FL surge de la necesidad de abordar desafíos relacionados con la privacidad de los datos, la minimización de datos, los derechos de acceso a los datos, la eficiencia de la comunicación y las restricciones regulatorias como el GDPR, lo que lo hace particularmente adecuado para escenarios que involucren datos sensibles o distribuidos. El proceso típico implica rondas iterativas de distribución del modelo global actual a clientes seleccionados, realización de entrenamiento local en los datos del cliente, agregación segura de las actualizaciones del modelo resultantes (por ejemplo, usando Federated Averaging) y actualización del modelo global. Si bien implica computación distribuida, la distinción central del FL radica en su énfasis en la gobernanza de datos, imponiendo la restricción de que los datos brutos permanezcan locales (Kairouz et al., 2019).

Red Neuronal Artificial (RNA): a menudo llamada simplemente red neuronal, es un modelo computacional inspirado en la estructura y función de las redes neuronales biológicas, particularmente el cerebro humano. Consiste en una colección de unidades de procesamiento interconectadas, conocidas como nodos o neuronas artificiales, que típicamente se organizan en capas (una capa de entrada, una o más capas ocultas y una capa de salida). Cada conexión entre neuronas tiene un peso numérico asociado, y cada neurona típicamente aplica una función de activación a su entrada agregada (la suma ponderada de las entradas más un sesgo) para determinar su señal de salida. Las RN aprenden patrones y relaciones de los datos ajustando estos pesos de conexión a través de un proceso de entrenamiento, lo que les permite modelar dependencias complejas, a menudo no lineales, y realizar tareas como clasificación, regresión, reconocimiento de patrones y aproximación de funciones. Aunque inicialmente inspiradas en la biología, las RNA modernas se entienden mejor como potentes aproximadores de funciones matemáticas, cuya efectividad proviene de su estructura optimizada y parámetros aprendidos en lugar de una estricta fidelidad biológica. Existen diversas arquitecturas, incluyendo redes de alimentación hacia adelante (FNNs), redes convolucionales (CNNs) y redes recurrentes (RNNs) (Pan, 2024; What Is a Neural Network? | IBM, n.d.).

Redes Neuronales Recurrentes (RNNs): son una clase de redes neuronales artificiales diseñadas específicamente para procesar datos secuenciales, como series de tiempo, texto o voz, donde el orden de los elementos es crucial. A diferencia de las redes de alimentación hacia adelante que procesan las entradas de forma independiente, las RNNs cuentan con conexiones recurrentes o bucles de retroalimentación, lo que permite que la salida de una neurona (o capa) en un paso de tiempo se retroalimente como entrada para el paso de tiempo subsiguiente. Esta arquitectura cíclica permite a las RNNs mantener un estado interno o "memoria", a menudo llamado estado oculto, que captura información sobre entradas anteriores en la secuencia e influye en el procesamiento actual. El estado oculto se actualiza en cada paso de tiempo basándose tanto en la entrada actual como en el estado oculto anterior, lo que permite a la red exhibir un comportamiento temporal dinámico y aprender dependencias a lo largo del tiempo. Sin embargo, entrenar RNNs estándar en secuencias largas puede ser desafiante debido al problema del gradiente evanescente o explosivo, donde las señales de error propagadas hacia atrás en el tiempo disminuyen a cero o crecen incontrolablemente (Pan, 2024).

Redes de Memoria a Largo Corto Plazo (Long Short-Term Memory, LSTM): son un tipo especializado de arquitectura de red neuronal recurrente diseñada explícitamente para abordar las dificultades de aprender dependencias a largo plazo en datos secuenciales, particularmente los problemas del gradiente evanescente y explosivo que obstaculizan a las RNNs estándar. Introducidas por Hochreiter y Schmidhuber (1997), las LSTMs logran esta capacidad a través de una estructura interna más compleja dentro de cada unidad recurrente, centrada alrededor de un estado de celda de memoria y varios mecanismos de compuerta multiplicativos: típicamente una compuerta de entrada, una compuerta de salida y una compuerta de olvido. La celda de memoria actúa como un acumulador de información de estado, capaz de preservar señales durante largos períodos, mientras que las compuertas aprenden a regular el flujo de información, controlando cuándo entra la información a la celda (compuerta de entrada), cuándo se borra (compuerta de olvido) y cuándo influye en la salida de la red (compuerta de salida). Este control explícito sobre la retención y el flujo de la memoria permite a las LSTMs recordar u olvidar selectivamente información a través de intervalos de tiempo extendidos, haciéndolas altamente efectivas para tareas que requieren contexto de entradas pasadas

distantes, como la traducción automática, el reconocimiento de voz y la predicción de series de tiempo (Van Houdt et al., 2020).

Máquinas de Vectores de Soporte (Support Vector Machines, SVMs): son un conjunto de métodos relacionados de aprendizaje supervisado utilizados para clasificación y regresión, arraigados en la teoría del aprendizaje estadístico. Para la clasificación, la idea central es encontrar un hiperplano óptimo que separe los puntos de datos pertenecientes a diferentes clases en un espacio de características con el margen máximo posible: la distancia entre el hiperplano y los puntos de datos más cercanos de cualquier clase. Estos puntos más cercanos, que se encuentran en los límites del margen, se llaman vectores de soporte, y son críticos porque definen por sí solos la posición y orientación del hiperplano separador. Este enfoque en la maximización del margen y la dependencia de los puntos límite (vectores de soporte) es clave para la base teórica del método, buscando un buen rendimiento de generalización mediante el control de la complejidad del modelo. Las SVMs pueden manejar eficazmente datos no separables linealmente utilizando el "truco del kernel", que implica el empleo de funciones kernel (por ejemplo, polinomial, función de base radial) para mapear implícitamente los datos a un espacio de mayor dimensión donde podría existir una separación lineal, sin calcular explícitamente las coordenadas en ese espacio (Kecman, 2005).

Regresión Lineal: es una técnica estadística fundamental utilizada para modelar y analizar la relación lineal entre una variable dependiente (resultado) continua y una o más variables independientes (predictoras). El objetivo es encontrar la ecuación lineal que mejor se ajuste (una línea recta para la regresión lineal simple con un predictor, o un hiperplano para la regresión lineal múltiple) que describa cómo cambia la variable dependiente en promedio con los cambios en las variables independientes. Este "mejor ajuste" se determina típicamente utilizando el método de mínimos cuadrados, que minimiza la suma de las diferencias al cuadrado (residuos) entre los valores observados de la variable dependiente y los valores predichos por el modelo lineal. El modelo resultante (por ejemplo, $Y = \beta_0 + \beta_1 X + \epsilon$) permite cuantificar la fuerza y dirección de la relación a través de los coeficientes de regresión (β_1 , etc.) y predecir la variable de resultado basándose en los valores de los predictores. La regresión lineal sirve como un

método fundamental en estadística y análisis de datos, formando la base para muchas técnicas de modelado más complejas (Schneider et al., 2010).

Bosque Aleatorio (Random Forest, RF): es un método de aprendizaje conjunto (ensemble learning) que construye una multitud de predictores de árbol de decisión durante el entrenamiento y produce la moda de las clases (clasificación) o la predicción media (regresión) de los árboles individuales. Combina la técnica de "bagging" (bootstrap aggregating) de Breiman con la selección aleatoria de características para cultivar una colección de árboles de decisión con varianza controlada. Específicamente, cada árbol en el bosque se cultiva utilizando una muestra bootstrap (muestra aleatoria con reemplazo) de los datos de entrenamiento originales. Además, en cada nodo durante la construcción del árbol, en lugar de buscar la mejor división entre todas las características, el algoritmo busca la mejor división entre solo un subconjunto de características seleccionado aleatoriamente. Este proceso de aleatorización doble tiene como objetivo descorrelacionar los árboles individuales en el bosque, lo cual es crucial para reducir la varianza de la predicción del conjunto cuando las salidas de los árboles se promedian o se votan, lo que lleva a una mayor estabilidad y precisión de generalización en comparación con un solo árbol de decisión (Breiman, 2001).

Máquinas de Potenciación del Gradiente (Gradient Boosting Machines, GBMs): representan una potente familia de algoritmos de aprendizaje automático conjunto que construyen modelos predictivos de manera aditiva y por etapas. A diferencia de métodos como los Bosques Aleatorios que promedian modelos independientes, el boosting construye el conjunto secuencialmente, donde cada nuevo aprendiz base (típicamente un árbol de decisión) se entrena para corregir los errores cometidos por el conjunto de aprendices construidos hasta el momento. Las GBMs generalizan este procedimiento de boosting enmarcándolo como un problema de optimización numérica en el espacio de funciones, específicamente como descenso de gradiente. En cada iteración, se ajusta un nuevo aprendiz débil al gradiente negativo de una función de pérdida diferenciable elegida, evaluada con respecto a las predicciones del conjunto actual. Este nuevo aprendiz representa esencialmente un paso en la dirección que reduce máximamente la pérdida. La flexibilidad para usar diversas funciones de pérdida (por ejemplo, error cuadrático, error absoluto, pérdida logística) y diferentes tipos de aprendices débiles hace

que las GBMs sean altamente adaptables a diversas tareas de regresión y clasificación (Friedman, 2001).

Modelo Autorregresivo Integrado de Media Móvil (ARIMA): es un modelo estadístico utilizado extensamente para analizar y pronosticar datos de series de tiempo univariadas que exhiben dependencias temporales. El modelo combina tres componentes, denotados por los parámetros (p, d, q): un componente Autorregresivo (AR) de orden 'p', que modela el valor actual como una combinación lineal de 'p' valores anteriores de la serie; un componente Integrado (I) de orden 'd', que representa el grado de diferenciación requerido para hacer que la serie de tiempo sea estacionaria (es decir, eliminar tendencias o estacionalidad); y un componente de Media Móvil (MA) de orden 'q', que modela el valor actual basándose en una combinación lineal de 'q' términos de error anteriores (residuos). Los modelos ARIMA asumen linealidad y típicamente se aplican a series de tiempo estacionarias (o series hechas estacionarias mediante diferenciación). El proceso de construcción de un modelo ARIMA generalmente sigue la metodología Box-Jenkins, un ciclo iterativo que implica la identificación del modelo (utilizando herramientas como la Función de Autocorrelación (ACF) y la Función de Autocorrelación Parcial (PACF) para sugerir valores apropiados de p y q después de la diferenciación), la estimación de parámetros y la verificación diagnóstica para asegurar la adecuación del modelo (Box et al., 2015).

Prophet: es un procedimiento de pronóstico de código abierto desarrollado por el equipo Core Data Science de Facebook, implementado en R y Python, diseñado específicamente para producir pronósticos para datos de series de tiempo que exhiben múltiples patrones de estacionalidad (por ejemplo, anual, semanal, diaria) e incluyen efectos de días festivos. Se basa en un modelo de regresión aditivo descomponible, donde la serie de tiempo $y(t)$ se representa como la suma de varios componentes: un componente de tendencia $g(t)$ (modelando cambios no periódicos, a menudo usando modelos de crecimiento lineal por tramos o logístico), un componente estacional $s(t)$ (modelando cambios periódicos como efectos del día de la semana o la época del año, típicamente usando series de Fourier), y un componente de días festivos $h(t)$ (representando el impacto de eventos irregulares especificados por el usuario), más un término de error $\epsilon(t)$. Prophet está diseñado para manejar características comunes de las series de tiempo empresariales, como fuertes

efectos estacionales, múltiples períodos de datos históricos, cambios de tendencia, datos faltantes y valores atípicos, con el objetivo de proporcionar pronósticos fiables automáticamente mientras permite a los analistas ajustar el modelo utilizando parámetros intuitivos basados en el conocimiento del dominio. Su énfasis está en el ajuste flexible de tendencias, el manejo robusto de las complejidades de los datos del mundo real y la interpretabilidad para analistas que pueden no ser expertos en series de tiempo (Taylor & Letham, 2017).

5. METODOLOGÍA

La presente investigación se desarrollará bajo un enfoque cuantitativo, con un componente de tipo descriptivo-correlacional y de desarrollo tecnológico. El objetivo es diseñar, implementar y validar un modelo de aprendizaje automático/profundo (ML/DL) para la predicción del consumo de energía eléctrica en comunidades aisladas de las Zonas No Interconectadas (ZNI) de Colombia, adaptado a sus características particulares. La metodología propuesta se estructura en las siguientes fases:

Fase 1: Caracterización del Contexto, Recolección y Adecuación de Datos

Esta fase inicial es crucial para comprender la dinámica del consumo energético en las ZNI y para preparar los datos necesarios para el modelado.

1. Definición y Selección de Comunidades ZNI de Estudio: Se establecerán criterios para seleccionar un conjunto de comunidades ZNI representativas que sirvan como casos de estudio. Estos criterios podrán incluir ubicación geográfica, tamaño, actividad económica principal (si la hay), y disponibilidad de algún tipo de registro energético o variables proxy.
2. Identificación y Recolección de Variables:
 - Datos de Consumo Energético: Se explorarán estrategias para obtener datos de consumo, reconociendo la alta probabilidad de escasez o inexistencia de registros históricos detallados. Esto podría incluir datos agregados de proyectos anteriores, mediciones puntuales si son factibles, o el uso de datos de comunidades con características similares como proxy inicial, siempre reconociendo y documentando las limitaciones.
 - Variables Predictoras: Se identificarán y recolectarán variables exógenas potencialmente influyentes:
 - Climáticas: Temperatura, humedad, radiación solar, velocidad del viento, precipitación. Se buscarán datos de estaciones meteorológicas cercanas

(IDEAM u otras fuentes) o datos satelitales si las mediciones locales son inviables.

- Socioeconómicas y Demográficas: Estimaciones del número de usuarios/hogares, tipo de viviendas predominantes, actividades económicas principales (si aplica), horarios de suministro eléctrico (si es intermitente), y proxies de nivel de ingreso o posesión de electrodomésticos, basados en estudios existentes para ZNI.
 - Calendario: Día de la semana, festivos, periodos vacacionales.
3. Análisis Exploratorio de Datos (EDA): Se realizará un análisis exhaustivo de los datos recolectados para comprender sus distribuciones, identificar patrones preliminares de consumo (diarios, semanales, estacionales), evaluar la calidad de los datos, detectar valores atípicos, y cuantificar datos faltantes.
4. Preprocesamiento y Adecuación de Datos: Esta etapa es crítica dada la naturaleza de los datos esperados en ZNI e incluirá:
- Limpieza de datos (manejo de outliers).
 - Imputación de datos faltantes utilizando métodos apropiados para series temporales y las variables disponibles.
 - Transformación y normalización/escalado de variables para adecuarlas a los requerimientos de los algoritmos ML/DL.
 - Ingeniería de características (feature engineering) para crear nuevas variables predictoras relevantes a partir de las existentes (ej. variables lag, interacciones, indicadores de confort térmico basados en clima).
 - Sincronización temporal de todas las series de datos a una granularidad común (ej. horaria o diaria).

Entregables de la Fase 1: Conjuntos de datos limpios, preprocesados y estructurados para el modelado; un informe detallado del análisis exploratorio con la caracterización de los patrones de consumo y las variables; una descripción de las estrategias de adecuación de datos implementadas.

Fase 2: Desarrollo, Adaptación y Comparación de Modelos ML/DL

En esta fase se construirán y evaluarán comparativamente los modelos predictivos.

1. Selección de Algoritmos ML/DL: Con base en la revisión del estado del arte y la naturaleza de los datos, se seleccionarán al menos dos algoritmos ML/DL prometedores para la predicción de series temporales de consumo energético, como por ejemplo:
 - Redes Neuronales Recurrentes (especialmente LSTM).
 - Bosques Aleatorios (Random Forest).
 - Máquinas de Potenciación del Gradiente (GBM).
 - Se considerará también un modelo estadístico tradicional (ej. ARIMA o regresión lineal múltiple) como línea base para la comparación.
2. Diseño y Adaptación de Arquitecturas: Se definirán las arquitecturas específicas para cada modelo seleccionado, incluyendo la estructura de capas (para DL), funciones de activación, y otros parámetros relevantes. Se prestará especial atención a la adaptación de los modelos para que puedan aprender eficazmente de series de tiempo potencialmente cortas, ruidosas o con patrones irregulares.
3. Entrenamiento y Optimización de Modelos:
 - Los conjuntos de datos preprocesados se dividirán en subconjuntos de entrenamiento, validación y prueba, asegurando la independencia temporal para la evaluación.

- Se realizará un ajuste de hiperparámetros para cada modelo utilizando técnicas como búsqueda en cuadrícula (Grid Search) o búsqueda aleatoria (Random Search) sobre el conjunto de validación, con el objetivo de optimizar su rendimiento predictivo.
4. Comparación de Modelos: El rendimiento de los modelos entrenados y optimizados se evaluará comparativamente sobre el conjunto de prueba utilizando métricas estándar que se definan como las más adecuadas para evaluar el rendimiento como lo pueden ser el Error Absoluto Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE) y el Error Porcentual Absoluto Medio (MAPE)

Entregables de la Fase 2: Modelos ML/DL implementados, entrenados y optimizados; un análisis comparativo detallado del rendimiento de los diferentes modelos.

Fase 3: Validación Final, Análisis de Viabilidad y Documentación

Esta fase se centrará en la validación exhaustiva del mejor modelo o combinación de modelos y en el análisis de su aplicabilidad.

1. Validación Rigurosa del Modelo Seleccionado: El modelo que demuestre el mejor desempeño y adaptabilidad será sometido a una validación más profunda. Esto incluirá:
 - Análisis de los errores de predicción (residuos) para identificar posibles sesgos sistemáticos o situaciones donde el modelo falla.
 - Evaluación de la capacidad de generalización del modelo en diferentes subconjuntos de datos o escenarios simulados (ej. periodos con condiciones climáticas extremas, variaciones en horarios de suministro).
2. Análisis de Viabilidad y Utilidad Práctica: Se evaluará si la precisión y el detalle de los pronósticos generados por el modelo final son suficientes para cumplir con el objetivo de "informar eficazmente la planificación y el dimensionamiento de soluciones energéticas locales adaptadas a la demanda", según lo planteado en la

hipótesis. Se discutirán las implicaciones de los resultados para la toma de decisiones en el contexto ZNI.

3. Documentación y Disseminación: Los hallazgos, metodologías y el modelo final serán documentados exhaustivamente en el trabajo de tesis. Se considerará la posibilidad de generar un artículo científico y/o la implementación de una interfaz simple para visualizar las predicciones del modelo.

Entregables de la Fase 3: Modelo predictivo final validado y caracterizado; el documento final de la tesis.

6. IMPACTO Y RESULTADOS ESPERADOS

Se anticipa que esta investigación generará tanto resultados concretos como impactos potenciales significativos, contribuyendo a un proyecto doctoral más amplio enfocado en la predicción de potenciales energéticos y el dimensionamiento de soluciones renovables en comunidades sostenibles. Es crucial destacar que, si bien se espera que los productos de esta tesis de maestría sirvan como insumo fundamental para dicho dimensionamiento, la implementación final y la medición de su impacto directo en el acceso a la energía por parte de las comunidades excede el alcance de este trabajo.

Resultados Esperados (Productos Directos del Proyecto de Maestría):

- **Modelo Predictivo de Consumo ML/DL Validado:** El resultado principal será un modelo de aprendizaje automático/profundo (ML/DL) funcional, validado y adaptado para la predicción del consumo de energía eléctrica en las comunidades ZNI seleccionadas. Este modelo se caracterizará por su precisión y robustez bajo las condiciones de datos típicas de estas zonas.
- **Caracterización Detallada del Consumo Energético en ZNI:** Un análisis profundo de los patrones de consumo (perfiles diarios, semanales, estacionales) y de las variables (climáticas, socioeconómicas, operativas) que más influyen en la demanda energética de las comunidades ZNI estudiadas.
- **Análisis Comparativo de Técnicas ML/DL para ZNI:** Un estudio documentado sobre el desempeño, adaptabilidad y eficiencia de diferentes algoritmos y arquitecturas ML/DL (ej. LSTM, RF, GBM) al aplicarse al desafío específico de la predicción de consumo en ZNI con datos limitados.
- **Documento de Tesis y Base para Publicaciones:** La tesis de maestría que consolida toda la investigación, y que servirá como base para la elaboración de artículos científicos que difundan los hallazgos.

Impacto Esperado (Contribuciones Potenciales Alineadas con el Proyecto Doctoral y el Contexto ZNI):

- **Impacto Científico y Académico:**
 - Avance en la aplicación de ML/DL para la predicción de consumo energético en contextos de alta complejidad por la escasez de datos y la variabilidad de patrones, como las ZNI.

- Generación de conocimiento específico sobre los determinantes del consumo energético en comunidades aisladas colombianas, aportando a la literatura existente.
- Potencial Impacto en la Planificación y el Desarrollo Energético (como insumo para el Proyecto Doctoral y para Actores Externos):
 - Se espera que los perfiles de consumo y los pronósticos generados por el modelo de esta tesis constituyan un insumo técnico esencial para el proyecto doctoral asociado, el cual busca desarrollar un modelo de predicción de potenciales energéticos y, consecuentemente, determinar el tamaño y tipo óptimo de fuentes de energía renovable (principalmente eólica y solar) para comunidades sostenibles. La precisión en la predicción del consumo es fundamental para un dimensionamiento adecuado de dichos sistemas renovables.
 - A un nivel más amplio, los resultados y el modelo podrían ser una herramienta valiosa para las entidades gubernamentales, planificadores energéticos y desarrolladores de proyectos que trabajan en las ZNI. El conocimiento preciso de la demanda esperada es crucial para:
 - La optimización del diseño y dimensionamiento de soluciones de electrificación, incluyendo micro-redes y sistemas autónomos basados en energías renovables.
 - Mejorar la eficiencia de las inversiones y la sostenibilidad a largo plazo de los proyectos energéticos en estas zonas.
 - Facilitar la toma de decisiones informadas que contribuyan a la reducción de la pobreza energética y al mejoramiento de la calidad de vida de los habitantes de las ZNI.
- Aunque este trabajo de maestría se enfoca en el desarrollo y validación de la herramienta predictiva de consumo, se aspira a que sus resultados, al ser integrados en el marco más amplio de la investigación doctoral y potencialmente adoptados por actores relevantes, contribuyan indirectamente a la mejora del acceso y la calidad del suministro eléctrico. La verificación de este impacto directo en las decisiones políticas o de inversión, y su efecto final en las comunidades, se encuentra fuera del alcance de la presente tesis de maestría, pero se establece como una consecuencia deseada a futuro.

- El proyecto se alinea y apoya los objetivos de la Transición Energética Justa (TEJ) en Colombia, al proveer metodologías para una mejor comprensión y planificación de la demanda en regiones críticas para esta transición

7. RECURSOS Y PRESUPUESTO

Fuente de financiamiento del SICIUD de la CONVOCATORIA PR1 2025: FINANCIACIÓN DE PROYECTOS DE INVESTIGACIÓN, INVESTIGACIÓN-CREACIÓN E INNOVACIÓN DE LA UNIVERSIDAD DISTRITAL, con el proyecto INTELIGENCIA ARTIFICIAL PARA LA IDENTIFICACIÓN DE POTENCIALES ENERGÉTICOS EN COMUNIDADES NO CONECTADAS EN COLOMBIA, Código del proyecto PIICI-2024-2032.

Rubro	Financiador	Valor Especie	Valor Dinero	Rubro Total
Equipos	UDFJC	\$28,000,000.00		\$28,000,000.00
Auxiliares de Investigación	UDFJC		\$8,500,000.00	\$8,500,000.00
Equipos y Tecnologías Especializados	UDFJC		\$50,000,000.00	\$50,000,000.00
Personal	UDFJC	\$40,500,000.00	\$20,000,000.00	\$83,000,000.00
Divulgación de Resultados	UDFJC		\$60,000,000.00	\$60,000,000.00
Elementos Consumibles de Laboratorio	UDFJC		\$11,500,000.00	\$11,500,000.00
TOTAL		\$91,000,000.00	\$150,000,000.00	\$241,000,000.00

8. CRONOGRAMA

Para la consecución de los objetivos planteados y el desarrollo sistemático de las fases metodológicas descritas, se ha estructurado el siguiente plan de trabajo. Este cronograma detalla las actividades principales, los entregables esperados y la distribución temporal estimada a lo largo de un periodo de 10 meses, comenzando en mayo de 2025 y finalizando en febrero de 2026. Se busca ofrecer una guía clara para la ejecución del proyecto, permitiendo el seguimiento del progreso y la gestión eficiente del tiempo.

Fase 1: Planificación, Revisión Bibliográfica y Adquisición y Adecuación de Datos
(Duración aproximada: 5 meses)

- Meses 1 a 4:
 - Actividad Principal: Consolidación final del documento de propuesta de tesis (el que estamos elaborando actualmente) y profundización en la revisión bibliográfica de manera continua.
 - Tareas Específicas: Refinamiento detallado de objetivos y metodología, búsqueda y análisis de literatura relevante actualizada.
 - Entregable/Hito: Propuesta de tesis final aprobada y lista para registro.
 - Actividad Principal: Definición detallada de las comunidades ZNI que serán objeto de estudio y diseño del protocolo de recolección de datos.
 - Tareas Específicas: Establecimiento de criterios de selección, justificación de las comunidades elegidas, identificación de fuentes de datos (consumo, climáticos, socioeconómicos, operativos) y gestión inicial para el acceso a estos.
 - Entregable/Hito: Listado y justificación de comunidades ZNI. Protocolo de recolección de datos finalizado.
- Meses 2 a 4 (con superposición):
 - Actividad Principal: Recolección intensiva de los datos identificados.
 - Tareas Específicas: Ejecución del protocolo de recolección, contacto con entidades si es necesario, compilación de datos de diversas fuentes.

- Entregable/Hito: Base de datos brutos preliminar consolidada.
- Actividad Principal: Análisis Exploratorio de Datos (EDA) exhaustivo.
- Tareas Específicas: Identificación de patrones iniciales, evaluación de la calidad de los datos, detección de outliers y datos faltantes, diseño de estrategias de preprocesamiento y limpieza.
- Entregable/Hito: Informe detallado de EDA. Estrategias de preprocesamiento definidas.
- Meses 4 a 5 (con superposición):
 - Actividad Principal: Preprocesamiento intensivo, ingeniería de características y preparación final de los conjuntos de datos para el modelado.
 - Tareas Específicas: Aplicación de técnicas de limpieza, imputación, transformación, normalización y creación de nuevas variables predictoras. División de datos en conjuntos de entrenamiento, validación y prueba.
 - Entregable/Hito: Conjuntos de datos finales, limpios, transformados y estructurados, listos para la fase de modelado.

Fase 2: Desarrollo, Adaptación y Comparación de Modelos ML/DL (Duración aproximada: 3-4 meses, con superposición)

- Meses 4 a 5 (con superposición con Fase 1):
 - Actividad Principal: Selección y configuración detallada de arquitecturas de algoritmos ML/DL y establecimiento de un modelo base de comparación.
 - Tareas Específicas: Justificación de los algoritmos elegidos (LSTM, RF, GBM, etc.), diseño de las arquitecturas específicas, desarrollo de los scripts base para entrenamiento y evaluación.
 - Entregable/Hito: Documento de arquitecturas de modelos seleccionadas. Scripts de modelado base funcionales.
- Meses 5 a 7:
 - Actividad Principal: Ciclos iterativos de entrenamiento, optimización de hiperparámetros y evaluación preliminar del rendimiento de los modelos ML/DL.
 - Tareas Específicas: Ejecución de múltiples experimentos de entrenamiento, ajuste fino de los modelos, análisis de resultados iniciales.

- Entregable/Hito: Modelos ML/DL entrenados y con hiperparámetros optimizados.
- Meses 6 a 7 (con superposición):
 - Actividad Principal: Comparación exhaustiva del desempeño de los modelos y selección del modelo(s) final(es).
 - Tareas Específicas: Aplicación de métricas (MAE, RMSE, MAPE), análisis de robustez y complejidad.
 - Entregable/Hito: Informe técnico de comparación de modelos. Selección y justificación del modelo(s) final(es).

Fase 3: Validación, Redacción (Tesis y Artículo) y Finalización (Duración aproximada: 4 meses, con superposición)

- Meses 7 a 8:
 - Actividad Principal: Validación rigurosa del modelo(s) seleccionado(s).
 - Tareas Específicas: Análisis de errores, evaluación de capacidad de generalización, pruebas de sensibilidad con escenarios simulados.
 - Entregable/Hito: Informe de validación exhaustiva y análisis de sensibilidad del modelo.
- Meses 5 a 8 (Redacción de Artículo en paralelo):
 - Actividad Principal: Redacción progresiva del artículo científico.
 - Tareas Específicas: Desarrollo de secciones (Introducción, Metodología, Resultados, Discusión, Conclusiones) a medida que se obtienen y consolidan los resultados.
 - Entregable/Hito: Borrador completo del artículo científico listo para revisión interna.
- Meses 8 a 9 (con superposición):
 - Actividad Principal: Revisión interna del artículo, ajustes y preparación para sometimiento. Sometimiento del artículo.
 - Entregable/Hito: Artículo científico finalizado para envío. Comprobante de sometimiento.

- Meses 7 a 9 (Redacción de Tesis en paralelo):

- Actividad Principal: Redacción del documento de tesis.
- Tareas Específicas: Desarrollo de todos los capítulos, integrando la revisión bibliográfica, metodología, resultados del modelado, análisis y conclusiones.
- Entregable/Hito: Borrador completo de la tesis para revisión por los directores.
- Meses 9 a 10:
 - Actividad Principal: Revisión del documento de tesis con director/codirector e incorporación de correcciones.
 - Tareas Específicas: Ajustes basados en la retroalimentación recibida.
 - Entregable/Hito: Documento de tesis revisado y ajustado.
- Mes 10:
 - Actividad Principal: Revisión final del formato, estilo, referencias. Entrega final de la tesis y preparación para la sustentación. (Posibles revisiones menores del artículo científico si hay retroalimentación temprana).
 - Entregable/Hito: Tesis final entregada. Material para sustentación preparado.

Notas Adicionales:

- Revisión Bibliográfica: Es una tarea continua que se intensifica al inicio, pero se mantiene durante todo el proyecto.
- Artículo Científico: El proceso de revisión por pares y eventual publicación del artículo puede extenderse más allá de los 10 meses del cronograma de la tesis.
- Supervisión: Se asume una comunicación y reuniones periódicas con el director y codirector para asegurar el adecuado avance y orientación del proyecto.

9. LIMITACIONES

Si bien se espera que esta investigación aporte significativamente al campo de la predicción de consumo energético en ZNI, es fundamental reconocer ciertas limitaciones inherentes al contexto y al alcance del proyecto:

1. Disponibilidad y Calidad de los Datos de Consumo:

- La limitación más significativa radica en la dificultad para acceder a series históricas de consumo eléctrico que sean detalladas (ej. con granularidad horaria), consistentes, fiables y de suficiente longitud temporal en las comunidades ZNI. La escasez o ausencia de estos datos primarios podría requerir el uso de datos agregados, mediciones indirectas (proxies) o datos de proyectos piloto, lo que podría impactar la precisión y generalización del modelo.
- La calidad de los datos disponibles (presencia de ruido, valores atípicos, inconsistencias, datos faltantes) también representa un desafío que, aunque se abordará con técnicas de preprocesamiento, podría influir en el rendimiento final del modelo.

2. Representatividad y Generalización del Modelo:

- El estudio se centrará en un conjunto seleccionado de comunidades ZNI. Dada la heterogeneidad geográfica, cultural, socioeconómica y energética de las ZNI en Colombia, los hallazgos y el modelo desarrollado podrían no ser directamente generalizables a todas las ZNI del país sin adaptaciones o validaciones adicionales específicas para cada nuevo contexto.
- Los patrones de consumo pueden estar fuertemente influenciados por factores culturales y socioeconómicos muy locales y específicos, lo que podría limitar la transferibilidad directa del modelo a comunidades con dinámicas muy diferentes.

3. Naturaleza Dinámica del Consumo Energético:

- Los perfiles de consumo en las comunidades pueden evolucionar con el tiempo debido a diversos factores, como cambios en la disponibilidad y calidad del suministro eléctrico, la adopción de nuevos electrodomésticos, el desarrollo de actividades productivas locales, o cambios en la estructura demográfica. El modelo

desarrollado, basado en datos históricos, reflejará las condiciones existentes durante el periodo de estudio y podría requerir reentrenamiento o recalibración periódica para mantener su precisión a largo plazo.

4. Variables No Consideradas o No Medibles:

- Aunque se buscará incorporar un conjunto relevante de variables predictoras (climáticas, socioeconómicas, operativas), el modelo estará limitado por la disponibilidad y la factibilidad de medición de estas. Es posible que existan factores no contemplados o difíciles de cuantificar (ej. comportamientos sociales específicos, eventos comunitarios no registrados) que influyan en el consumo y que no sean capturados.

5. Alcance de la Validación Práctica para Planificación:

- Si bien uno de los objetivos es que el modelo genere pronósticos útiles para "informar eficazmente la planificación y el dimensionamiento de soluciones energéticas", la validación de esta utilidad en un ciclo completo de planificación e implementación de soluciones energéticas reales en las ZNI excede el alcance temporal y los recursos de una tesis de maestría. La "utilidad" se evaluará principalmente en términos de la precisión, fiabilidad y el detalle de los pronósticos generados como insumo para dichos procesos.

6. Complejidad y Recursos Computacionales:

- El desarrollo, entrenamiento y optimización de ciertos modelos de aprendizaje profundo pueden requerir una capacidad computacional considerable. Aunque se buscarán soluciones eficientes, esto podría representar una limitación dependiendo de los recursos disponibles.

7. Dependencia de la Información del Suministro:

- En ZNI donde el suministro eléctrico es altamente intermitente o racionado, los datos de consumo registrados reflejarán un consumo restringido por la oferta, y no necesariamente la demanda potencial o no satisfecha. Modelar la demanda "real" o no restringida en tales escenarios presenta una complejidad adicional que el modelo podría no resolver completamente.

10. REFERENCIAS

- Almuhanna, K. A. (2024). Home Energy Consumption Prediction Using Smart Meters in Riyadh Saudi Arabia. *2024 Conference on Renewable Energy Technologies and Modern Communications Systems: Future and Challenges*, 1–4.
<https://doi.org/10.1109/IEEECONF63577.2024.10881359>
- Barja-Martinez, S., Teng, F., Junyent-Ferre, A., & Aragues-Penalba, M. (2024). Personalized Federated Learning with Cost-Oriented Load Forecasting for Home Energy Management Systems. *IEEE Transactions on Industry Applications*.
<https://doi.org/10.1109/TIA.2024.3462668>
- Bernal Suárez, M. L., Lancheros Ramírez, P. V., Reyes Mosquera, K. O., Sánchez Cardozo, J. A., & Villegas Rodríguez, S. (2024). *INFORME SOBRE POBREZA ENERGÉTICA MULTIDIMENSIONAL EN COLOMBIA: Análisis Estratégico 2022-2023*.
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *TIME SERIES ANALYSIS: FORECASTING AND CONTROL*, 5TH EDITION, by. In *J. Time. Ser. Anal.* Wiley.
<https://www.wiley.com/en-us/Time+Series+Analysis%3A+Forecasting+and+Control%2C+5th+Edition-p-9781118675021>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324/METRICS>
- Cabiddu, S., Sanguinetti, M., De Falco, A., Manca, G., & Atzori, M. (2024). Effective Net Load Forecasting in Solar-Integrated Homes with Battery Systems. *Proceedings - 2024 IEEE International Conference on Big Data, BigData 2024*, 4643–4649.
<https://doi.org/10.1109/BIGDATA62323.2024.10826060>
- Dubey, A., Tiwari, A., Bhardwaj, A., Sivamohan, S., & Krishnaveni, S. (2024). Global Energy Consumption Patterns and Optimization using Big Data. *Proceedings of the 9th*

- International Conference on Communication and Electronics Systems, ICCES 2024*, 1025–1028. <https://doi.org/10.1109/ICCES63552.2024.10859370>
- Eikeland, O. F., Bianchi, F. M., Apostoleris, H., Hansen, M., Chiou, Y. C., & Chiesa, M. (2021). Predicting Energy Demand in Semi-Remote Arctic Locations. *Energies* 2021, Vol. 14, Page 798, 14(4), 798. <https://doi.org/10.3390/EN14040798>
- Fasipe, O. O., Olabisi, P. O., & Folorunso, A. O. (2024). Review of Energy Requirement and Load Forecasting for A Medium Agro-Based Industrial Settlement: A Case Study of Oke-Agbo and Imota Villages. *2024 IEEE 5th International Conference on Electro-Computing Technologies for Humanity (NIGERCON)*, 1–7. <https://doi.org/10.1109/NIGERCON62786.2024.10927395>
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. <https://doi.org/10.1214/Aos/1013203451>, 29(5), 1189–1232. <https://doi.org/10.1214/AOS/1013203451>
- Gebre, M. T., Hwang, J., & Biru, G. (2024). Electricity demand analysis and forecasting: The case of GADA special economic zone. *Heliyon*, 10(3), e25364. <https://doi.org/10.1016/J.HELIYON.2024.E25364>
- Gellert, A., Olaru, L. M., Florea, A., Cofaru, I. I., Fiore, U., & Palmieri, F. (2024). Estimating electricity consumption at city-level through advanced machine learning methods. *Connection Science*, 36(1), 2313852. <https://doi.org/10.1080/09540091.2024.2313852>
- Guilian, W., Linyao, Z., Tingting, L., Hao, C., Wenlong, L., Shaofang, W., Jun, Y., & Conghao, L. (2023). Forecast of total rural energy demand based on energy consumption intensity. *Frontiers in Energy Research*, 10, 1021164. <https://doi.org/10.3389/FENRG.2022.1021164/BIBTEX>
- Herraiz-Cañete, Á., Ribó-Pérez, D., Bastida-Molina, P., & Gómez-Navarro, T. (2022). Forecasting energy demand in isolated rural communities: A comparison between deterministic and stochastic approaches. *Energy for Sustainable Development*, 66, 101–116. <https://doi.org/10.1016/J.ESD.2021.11.007>

- Hong, G., Choi, G. S., Eum, J. Y., Lee, H. S., & Kim, D. D. (2022). The Hourly Energy Consumption Prediction by KNN for Buildings in Community Buildings. *Buildings* 2022, Vol. 12, Page 1636, 12(10), 1636. <https://doi.org/10.3390/BUILDINGS12101636>
- Hong, T. (2015). *Load Forecasting Case Study*.
- Ian Goodfellow, Yoshua Bengio, Aaron Courville, H. J. (2018). Deep learning. *Genetic Programming and Evolvable Machines*, 19(1–2), 305–307. https://books.google.com/books/about/Deep_Learning.html?id=Np9SDQAAQBAJ
- Jawad, M., Nadeem, M. S. A., Shim, S. O., Khan, I. R., Shaheen, A., Habib, N., Hussain, L., & Aziz, W. (2020). Machine Learning Based Cost Effective Electricity Load Forecasting Model Using Correlated Meteorological Parameters. *IEEE Access*, 8, 146847–146864. <https://doi.org/10.1109/ACCESS.2020.3014086>
- Kairouz, P., McMahan, H. B., Avent, B., Bellet, A., Bennis, M., Bhagoji, A. N., Bonawitz, K., Charles, Z., Cormode, G., Cummings, R., D'Oliveira, R. G. L., Eichner, H., El Rouayheb, S., Evans, D., Gardner, J., Garrett, Z., Gascón, A., Ghazi, B., Gibbons, P. B., ... Zhao, S. (2019). Advances and Open Problems in Federated Learning. *Foundations and Trends in Machine Learning*, 14(1–2), 1–210. <https://doi.org/10.1561/22000000083>
- Kecman, Vojislav. (2005). *Support Vector Machines – An Introduction*. https://doi.org/10.1007/10984697_1
- Kolluru, V. K., Challagundla, Y., Chintakunta, A. N., Roy, B., Bermak, A., & Renuka Devi, S. M. (2024). AI-Driven Energy Optimization: Household Power Consumption Prediction With LSTM Networks and PyTorch-Ray Tune in Smart IoT Systems. *Proceedings of the International Conference on Microelectronics, ICM*. <https://doi.org/10.1109/ICM63406.2024.10815802>
- Li, D., Xia, J., Li, J., Xiao, C., Stankovic, V., Stankovic, L., & Shi, Q. (2024). A Temporal-Spatial Graph Network with a Learnable Adjacency Matrix for Appliance-level Electricity Consumption Prediction. *IEEE Transactions on Artificial Intelligence*. <https://doi.org/10.1109/TAI.2024.3507734>

- Ma, S., Li, S., Luo, Q., Yu, Z., & Wang, Y. (2024). Revisiting the relationships between energy consumption, economic development and urban size: A global perspective using remote sensing data. *Heliyon*, 10(5), e27318. <https://doi.org/10.1016/J.HELİYON.2024.E27318>
- Madhusudanan, C. R. (2019). A Machine Learning Framework for Energy Consumption Prediction. *All Theses*. https://open.clemson.edu/all_theses/3184
- Mitchell, T. (1997). Machine Learning. In *Machine Learning* (Vol. 1, Issue Pt 1-2). McGraw Hill. <https://doi.org/10.1093/bioinformatics/btq112>
- Molina, E., Candelo-Becerra, J. E., & Ojeda-Camargo, E. (2018). Understanding Electricity Saving Behavior of Rural Indigenous Communities in La Guajira Department, Colombia. *Journal of Engineering Science and Technology Review*, 11(6), 47–53. <https://doi.org/10.25103/JESTR.112.07>
- Pan, Y. (2024). Different Types of Neural Networks and Applications: Evidence from Feedforward, Convolutional and Recurrent Neural Networks. *Highlights in Science, Engineering and Technology*, 85, 247–255. <https://doi.org/10.54097/6RN1WD81>
- Patricio, J. T., Silva, F., Lopes, R. A., Amaro, N., & Martins, J. (2024). Combining Time-Series Forecasting and Genetic Algorithm Based Optimization to Explore Energy Flexibility at Building-Level. *Proceedings of the 30th ICE IEEE/ITMC Conference on Engineering, Technology, and Innovation: Digital Transformation on Engineering, Technology and Innovation, ICE 2024*. <https://doi.org/10.1109/ICE/ITMC61926.2024.10794398>
- Qiao, J., Song, D., Jiang, R., Hao, W., & Liu, C. (2023). Research on Home Energy Consumption Prediction Method Based on SSA-VMD-LSTM. *2023 5th International Conference on Electronic Engineering and Informatics, EEI 2023*, 27–32. <https://doi.org/10.1109/EEI59236.2023.10212906>
- Ramírez Murillo, J. E. (2023). *Necesidad de una mejora regulatoria para las Zonas no Interconectadas en Colombia*. Universidad Externado de Colombia.
- Rushman, J. F., Thanarak, P., Artkla, S., & Maneechot, P. (2019). Electrical Power Demand Assessment of a Rural Community and the Forecast of Demand Growth for Rural

- Electrification in Ghana. *International Energy Journal*, 19(1).
<http://www.rericjournal.ait.ac.th/index.php/reric/article/view/2023>
- Russell, S., & Norvig, P. (2020). Artificial intelligence a modern approach Stuart J. Russell and Peter Norvig. In *Artificial intelligence : a modern approach*. Pearson.
- Schneider, A., Hommel, G., & Blettner, M. (2010). Linear Regression Analysis: Part 14 of a Series on Evaluation of Scientific Publications. *Deutsches Ärzteblatt International*, 107(44), 776. <https://doi.org/10.3238/ARZTEBL.2010.0776>
- Shapi, M. K. M., Ramli, N. A., & Awalin, L. J. (2021). Energy consumption prediction by using machine learning for smart building: Case study in Malaysia. *Developments in the Built Environment*, 5, 100037. <https://doi.org/10.1016/J.DIBE.2020.100037>
- Taylor, S. J., & Letham, B. (2017). *Forecasting at scale*.
<https://doi.org/10.7287/PEERJ.PREPRINTS.3190V2>
- Van Houdt, G., Mosquera, C., & Nápoles, G. (2020). A review on the long short-term memory model. *Artificial Intelligence Review*, 53(8), 5929–5955.
<https://doi.org/10.1007/S10462-020-09838-1>
- Vidhate, K. D., & Nema, P. (2024). Forecasting Energy Utilization in Residential Areas through Machine Learning Techniques. *Journal of Electrical Systems*, 20(1s), 743–748.
<https://doi.org/10.52783/JES.817>
- Volk, M., Staegemann, D., & Turowski, K. (2022). Providing Clarity on Big Data: Discussing Its Definition and the Most Relevant Data Characteristics. *International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management, IC3K - Proceedings*, 3, 141–148. <https://doi.org/10.5220/0011537500003335>
- Wang, Z., Hong, T., Li, H., & Ann Piette, M. (2021). Predicting city-scale daily electricity consumption using data-driven models. *Advances in Applied Energy*, 2, 100025.
<https://doi.org/10.1016/J.ADAPEN.2021.100025>
- What is a Neural Network? | IBM*. (n.d.). Retrieved May 1, 2025, from
<https://www.ibm.com/think/topics/neural-networks>

