

RESUMEN

Este trabajo presenta un modelo de visión por computadora para la detección de vendedores ambulantes en imágenes aéreas de alta resolución, empleando la arquitectura YOLOv11 y un flujo metodológico reproducible que integra preprocesamiento, etiquetado, entrenamiento, evaluación y despliegue web. Se trabaja con recortes (tiles) de 256×256 px generados a partir de ortoimágenes georreferenciadas, incorporando información auxiliar oficial para seleccionar áreas con alta probabilidad de ocurrencia. El entrenamiento se realiza mediante fine-tuning de modelos preentrenados (COCO), con diferentes configuraciones de data augmentation específicas para fotogrametría urbana. La evaluación incluye precisión, *recall*, *F1* y $mAP_{0.5/0.5 \sim 0.95}$, con resultados que evidencian un desempeño elevado y estable en escenarios con objetos pequeños, ocluidos y visualmente similares. Por último, se implementa una aplicación web (frontend liviano + backend orquestador + servicio de inferencia) que permite cargar ortoimágenes, ejecutar la detección y exportar resultados como ráster anotado y capas vectoriales (GeoPackage/GeoJSON) para uso en SIG. El enfoque contribuye a generar insumos cuantitativos para el análisis espacial del comercio ambulante, con potencial para apoyar diagnósticos urbanos y políticas públicas.

Palavras-chave: YOLOv11, Detección de objetos, Vendedores ambulantes, Aprendizaje profundo, Visión por computadora, Imágenes aéreas

LISTA DE TABELAS

Tabela 1 – Longitud de onda de la imagen PlanetScope (2025)	22
Tabela 2 – Descripción de la imagen aérea original	26
Tabela 3 – Desempeño de los modelos YOLOv11	27
Tabela 4 – Descripción de las imágenes divididas	30
Tabela 5 – Descripción de las capacidades de computación	35
Tabela 6 – Descripción de los modelos	35
Tabela 7 – Matriz de confusión	40
Tabela 8 – Descripción de las métricas de los modelos entrenados	42

SUMÁRIO

1	INTRODUCCIÓN	4
2	OBJETIVOS	7
2.0.1	<i>Objetivo general</i>	7
2.0.2	<i>Objetivos específicos</i>	7
3	JUSTIFICACIÓN	8
4	FUNDAMENTACIÓN TEÓRICA	10
4.1	Venta ambulante	10
4.2	GEOBIA	11
4.3	Modelos y arquitecturas de *deep learning* en teledetección	13
4.3.1	<i>Aplicaciones en imágenes satelitales de alta resolución espacial</i>	14
4.3.2	<i>Detección de objetos con YOLOv11</i>	14
5	TRABAJOSS RELACIONADOS	16
6	METODOLOGÍA	19
6.1	Adquisición de los datos	20
6.1.1	<i>Área de estudio</i>	20
6.1.2	<i>Descripción de los vendedores ambulantes y su localización</i>	22
6.1.3	<i>Descripción de las imagens utilizadas</i>	25
6.1.4	<i>Descripción del modelo</i>	26
6.1.5	<i>Aplicación del modelo de detección de vendedores ambulantes</i>	30
6.1.5.1	<i>Versión 1</i>	32
6.1.5.2	<i>Versión 2</i>	32
6.1.5.3	<i>Versión 3</i>	33
6.1.5.4	<i>Versión 4</i>	34
6.1.6	<i>Despliegue web</i>	35
7	RESULTADOS	40
7.1	Resultados generales	42
7.2	Detalle de los resultados del Modelo 4(v8)	42
7.2.1	<i>Resultados del despliegue web</i>	46
8	CONCLUSIONES Y TRABAJOS FUTUROS	48
	REFERENCIAS	49

1 INTRODUCCIÓN

Muchas ciudades presentan una presencia significativa de comercio ambulante, fenómeno socioeconómico con lógicas espaciales específicas y alta variabilidad temporal y espacial: concentración de flujos de peatones, proximidad a nodos de transporte, presencia de equipamientos y dinámicas de centralidad que se transforman a lo largo del tiempo. No obstante, la generación de información sistemática y actualizada sobre su distribución enfrenta límites prácticos (costos de trabajo de campo, sesgos de muestreo, restricciones de privacidad) y metodológicos, como la dificultad de escalar procedimientos manuales a la escala de la ciudad. La disponibilidad de ortoimágenes de alta resolución y la madurez de detectores modernos de objetos basados en aprendizaje profundo ofrecen hoy un camino para automatizar la identificación, cuantificación y georreferenciación de determinadas tipologías de vendedores ambulantes, proporcionando evidencias cuantitativas para el diagnóstico urbano y la gestión del espacio público.

Este estudio tiene por objetivo diseñar, entrenar, evaluar e implementar un modelo de detección de vendedores ambulantes en ortoimágenes, con foco en una tipología visualmente identificable, especialmente en puestos con sombrillas y mobiliario semifijo o fijo en la escena. La investigación adopta como estudio de caso la ciudad de Bogotá, por la disponibilidad de datos espaciales y por la diversidad de contextos urbanos que permiten observar múltiples configuraciones del fenómeno. La selección de áreas de interés se apoyó en información oficial sobre la actividad de vendedores ambulantes y en análisis espaciales exploratorios que orientaron la focalización del etiquetado, maximizando la eficiencia del esfuerzo anotador.

En cuanto a los insumos, se trabajó con una ortoimagen aérea de alta resolución, previamente georreferenciada, con correcciones radiométricas y geométricas. Dado el tamaño total del mosaico, se adoptó un procedimiento de división sistemática en bloques de 256×256 píxeles, garantizando la rastreabilidad entre píxel y coordenada por medio de la transformación afín del ráster y del sistema de referencia de coordenadas de la imagen. Esta etapa de particionamiento preparó el material para anotación e inferencia, facilitando el envío eficiente de bloques al servicio de detección y reduciendo la latencia operativa.

La construcción del conjunto de entrenamiento combinó tres estrategias: (i) selección dirigida de bloques en sectores con alta probabilidad de ocurrencia, (ii) etiquetado preciso en Roboflow según un proceso tradicional (cajas por instancia, descarte de ambigüedad) y (iii) incorporación de imágenes negativas con objetos visualmente similares para reforzar la discrimi-

nación del modelo. Se implementaron varias versiones del **dataset**, con preprocesamientos (orientación automática, redimensionamiento homogéneo, filtrado por porcentaje de imágenes con anotaciones) y **data augmentation** adaptada a la fotogrametría urbana; por ejemplo, giros de 90 grados, espejamientos, rotaciones leves, **zoom** moderado y ajustes fotométricos. El objetivo fue robustecer la generalización frente a variaciones de escala, iluminación, oclusión parcial y fondo urbano complejo.

El modelo seleccionado fue YOLOv11, una arquitectura de pasada única que mantiene la organización **backbone-neck-head** e incorpora bloques eficientes (como C3K2 y módulos de atención espacial), capaces de equilibrar precisión y velocidad en escenas con objetos pequeños. Se adoptó un esquema de **fine-tuning** sobre pesos preentrenados en COCO, ajustando las capas finales para la nueva clase objetivo. Se compararon variantes de tamaño (por ejemplo, **s** y **m**) para compatibilizar desempeño y costo computacional. El entrenamiento se condujo con divisiones estratificadas y monitoreo de curvas de pérdida y métricas, evitando **overfitting** por medio de validación y control de parada anticipada cuando fue pertinente.

La evaluación contempló métricas estándar de detección de objetos: precisión, *recall*, *F1*, $mAP_{0.5}$ y $mAP_{0.5\sim 0.95}$. Se analizaron aciertos y errores típicos más frecuentes, como falsos positivos por confundidores urbanos y falsos negativos en oclusiones o sombras, así como la sensibilidad a parámetros de confianza y a la escala de inferencia. Los resultados indicaron un desempeño elevado y estable, especialmente en escenas de alta densidad y diversidad morfológica, confirmando la viabilidad del enfoque para cartografiar, de forma masiva y consistente, la tipología seleccionada.

Para transferir el método más allá de los experimentos, se implementó una aplicación web con arquitectura ligera: interfaz en el navegador, **backend** orquestador y servicio externo de inferencia. La herramienta permite cargar ortoimágenes, procesarlas en bloques, ejecutar la detección y exportar salidas geoespaciales: ráster anotado para validación visual y capas vectoriales con centroides y atributos (clase, confianza), interoperables con SIG de escritorio y servicios OGC. Este diseño favorece la adopción por equipos técnicos y habilita su uso en tareas de diagnóstico, muestreo dirigido, planeación operativa y seguimiento temporal.

Por último, el estudio delimita alcances y limitaciones: dependencia de la fecha y calidad de las imágenes, preferencia por resoluciones submétricas, heterogeneidad de fondos urbanos y necesidad de ampliar y diversificar el conjunto de entrenamiento para favorecer la transferencia a otras ciudades. Se esbozan líneas futuras: incorporación de detectores con cajas

orientadas para escenas anisotrópicas, fusión con datos de nivel de calle y puntos de interés para enriquecer la interpretación, y evaluación multiciudad para estimar la generalización del modelo. En conjunto, el trabajo entrega una ruta metodológica completa —del dato al mapa— para producir evidencia reproducible sobre comercio ambulante y dar soporte a decisiones de política urbana basadas en datos.

2 OBJETIVOS

2.0.1 *Objetivo general*

Diseñar, entrenar, evaluar e implementar un modelo de detección de vendedores ambulantes en ortoimágenes aéreas de alta resolución, basado en YOLOv11, a fin de producir insumos geospaciales confiables que fundamenten análisis urbanos y la toma de decisiones en el sector público.

2.0.2 *Objetivos específicos*

Especificar y documentar un flujo reproducible de datos que incluya preprocesamiento con normalización, división en bloques de la imagen, georreferenciación, etiquetado y selección del conjunto de datos, utilizando ortoimágenes y fuentes oficiales auxiliares.

Realizar fine-tuning de YOLOv11 con estrategias de data augmentation adaptadas a la fotogrametría urbana y evaluar el desempeño del modelo en escenarios urbanos heterogéneos, con énfasis en objetos pequeños y posibles oclusiones.

Implementar un prototipo de servicio de inferencia mediante una aplicación web que permita cargar imágenes, ejecutar la detección automática de vendedores ambulantes y exportar resultados en formato ráster anotado y capas vectoriales, con el propósito de identificar y cuantificar concentraciones y multinúcleos de comercio informal en entornos urbanos, además de sustentar diagnósticos urbanos y la gestión del espacio público.

3 JUSTIFICACIÓN

La literatura revisada muestra que la investigación sobre la informalidad en el espacio público no es solo un ejercicio técnico, sino que posee profundas implicaciones sociales y políticas. En trabajos como el de (STRAULINO *et al.*, 2022), se destaca que la actividad comercial informal constituye una parte fundamental de la economía urbana, permitiendo el acceso a bienes y servicios para poblaciones que, de otro modo, estarían excluidas del comercio formal. De forma similar, (LIU *et al.*, 2023) evidencian que el mapeo masivo de vendedores ambulantes a escala urbana posibilita comprender patrones socioeconómicos que inciden directamente en la movilidad, el uso del espacio público y la dinámica de los barrios.

Bajo esta óptica, la investigación sobre la detección automática de vendedores ambulantes adquiere importancia estratégica: no se trata solo de reconocer objetos en imágenes, sino de generar información crítica para la toma de decisiones. La posibilidad de contar con datos periódicos y escalables sobre la ubicación y la concentración de vendedores permitiría que los municipios diseñaran políticas más equilibradas entre el derecho al trabajo de los vendedores y la necesidad de ordenamiento del espacio público.

Los estudios también muestran que la informalidad urbana es heterogénea y dinámica. El dataset StreetVendor-SLI (GARCIA-JAIMES *et al.*, 2025) refleja esta diversidad al clasificar vendedores fijos, semifijos e itinerantes, lo que abre camino a análisis más detallados sobre cómo los distintos tipos de comercio interactúan con la infraestructura urbana. Detectar estas categorías de manera sistemática, incluso en plataformas satelitales, permitiría que los gobiernos locales identificaran zonas de concentración, anticiparan conflictos de uso del espacio y planificaran intervenciones urbanas más inclusivas.

Además, la investigación tiene un claro valor en términos de equidad social. Estudios como los de (SHOU *et al.*, 2021), que recurren a proxies de movilidad peatonal, muestran que los vendedores tienden a concentrarse en áreas de gran flujo, frecuentemente asociadas a barrios de bajos ingresos o a estaciones de transporte público. Identificar estos patrones de forma objetiva, mediante visión por computadora, permitiría sustentar políticas que no criminalicen la informalidad, sino que la integren a la planificación urbana de manera más justa.

Finalmente, la posibilidad de transferir esta detección al dominio satelital representa un cambio de paradigma: pasamos de análisis locales (con cámaras o Street View) a una visión global y repetible, que puede actualizarse con cada nueva adquisición de imágenes VHR. En ese sentido, la investigación se conecta con debates más amplios sobre el derecho a la ciudad,

la gestión inclusiva del espacio público y la sostenibilidad urbana (STRAULINO *et al.*, 2022; HOFMANN; BEKKARNAYEVA, 2017).

4 FUNDAMENTACIÓN TEÓRICA

Este capítulo proporciona una comprensión de la teoría, de los conceptos y de la metodología para la detección de vendedores ambulantes aplicando técnicas de visión por computadora y modelos de **deep learning** en imágenes aéreas de alta resolución espacial.

El cuerpo de literatura revisado se apoya en teorías de visión por computadora y aprendizaje profundo, especialmente en el campo de la detección de objetos. Modelos como YOLO, SSD y Faster R-CNN han demostrado eficacia en tareas de reconocimiento en entornos urbanos, aunque presentan limitaciones cuando los objetos son pequeños y móviles. Trabajos como el de (AGBA; TAHIR, 2021) confirman la pertinencia de arquitecturas ligeras en escenarios municipales, mientras que Liu y Liu (2022) evidencian cómo la combinación de imágenes de calle a gran escala y **deep learning** permite mapear patrones espaciales del sector informal, como la aglomeración de vendedores ambulantes, revelando preferencias locacionales y respaldando políticas urbanas más eficaces.

De igual forma, los estudios de (HOFMANN; BEKKARNAYEVA, 2017) demuestran el potencial de la detección de cambios basada en objetos (OBIA) en imágenes de altísima resolución para monitorear la expansión y transformación de asentamientos informales. El enfoque evidencia cómo la segmentación jerárquica y la vinculación temporal de objetos permiten cuantificar crecimientos, contracciones y transiciones entre asentamientos formales e informales, superando las limitaciones de los análisis puramente píxel a píxel y ofreciendo un camino sólido para comprender la dinámica urbana.

4.1 Venta ambulante

El vendedor ambulante puede definirse como un agente económico del sector informal, cuya actividad consiste en ofrecer bienes y servicios en el espacio público sin estar necesariamente registrado en los sistemas formales o tributarios. Su presencia se manifiesta visualmente en las calles mediante productos expuestos, infraestructura mínima (como carritos, puestos móviles o toldos) y la interacción directa con transeúntes. A diferencia de los establecimientos fijos, el comercio ambulante se caracteriza por ser móvil, efímero y adaptativo, respondiendo a la demanda inmediata y a las dinámicas de circulación peatonal (STRAULINO *et al.*, 2022; SUN *et al.*, 2022). Históricamente, esta práctica también ha sido objeto de estigmatización social y regulatoria, representándose como actividad “desordenada” o “atrasada” frente

al ideal de ciudad moderna (ECK; RATH, 2024).

La localización de los vendedores ambulantes en las ciudades no es aleatoria, sino que sigue lógicas espaciales y socioeconómicas específicas. Las investigaciones muestran que tienden a concentrarse en calles muy concurridas por peatones, especialmente en las proximidades de sistemas de transporte, plazas y ejes comerciales centrales (SUN *et al.*, 2022). Además, en contextos como Medellín (Colombia), se observa que se instalan principalmente en barrios densamente poblados y de bajos ingresos, donde los comercios formales son menos rentables o inexistentes, desempeñando un papel sustitutivo al proveer bienes básicos para comunidades marginadas (STRAULINO *et al.*, 2022). También es común que se ubiquen cerca de áreas de comercio formal, compartiendo la misma base de consumidores, lo que puede generar tanto complementariedad como competencia. Por último, su movilidad y flexibilidad les permiten adaptarse a los intentos de control o desplazamiento por parte de las autoridades urbanas, garantizando la persistencia de su actividad en calles centrales, mercados y zonas de transformación (ECK; RATH, 2024).

4.2 GEOBIA

GEOBIA — *Geographic Object-Based Image Analysis* — es un paradigma de análisis de imágenes que sustituye la clasificación píxel a píxel por la segmentación previa de la imagen en objetos (regiones o “superpíxeles” coherentes) y la clasificación de esos objetos utilizando no solo información espectral, sino también atributos geométricos (forma, tamaño, perímetro), texturales (medidas de homogeneidad o contraste), radiométricos (bandas e índices) y contextuales (relaciones espaciales con objetos vecinos). (CHEN *et al.*, 2018) este enfoque constituye un cambio de paradigma en el teledetección porque permite que los objetos extraídos se asemejen más a entidades geográficas reales, lo que mejora la interpretabilidad y la precisión en imágenes de alta resolución. De igual manera, (YE *et al.*, 2023) destacan que GEOBIA, al integrar múltiples dimensiones de información, reduce el ruido típico de las clasificaciones por píxel y logra resultados más robustos en la detección individual de plantas o cultivos, aunque exige una elección cuidadosa de la escala de segmentación. Más recientemente, (AMESLEK *et al.*, 2024) aplicaron un enfoque híbrido que combina redes convolucionales (CNN) con GEOBIA para el conteo automático de olivos, demostrando que el refinamiento por objetos sobre la salida de la red reduce falsos positivos y eleva la precisión por encima del 99

En conjunto, estos trabajos muestran que GEOBIA, en la detección de objetos,

transforma la unidad de análisis del píxel al objeto, integrando atributos espectrales, espaciales y contextuales para alcanzar clasificaciones más interpretables, consistentes y aplicables en dominios como agricultura de precisión, cartografía forestal y cartografía urbana.

El Análisis Geográfico Basado en Objetos (GEOBIA) es un paradigma de teledetección que cambia la unidad de estudio del píxel aislado al “objeto” —un conjunto de píxeles contiguos que representan una entidad geográfica— y lo define como un flujo iterativo de segmentación multiescalar seguido de la extracción y clasificación de atributos espectrales, texturales, geométricos y relacionales; esa definición y su fundamentación conceptual son descritas de forma detallada por (CHEN *et al.*, 2018). En la práctica, GEOBIA comienza con la segmentación (elección de la escala y criterios de homogeneidad), continúa con la extracción de características (forma, tamaño, índices de vegetación, textura, elevación, etc.) y explora explícitamente las relaciones espaciales —proximidad, adyacencia, contención, patrones de vecindad— para atribuir significado semántico a los objetos y aumentar la robustez de la clasificación frente a la heterogeneidad de la superficie.

Modelar esos contextos relacionales ha demostrado mejorar sustancialmente la discriminación entre coberturas urbanas y naturales (por ejemplo, separar tejados de pavimento o distinguir manchas arbóreas en mosaicos urbanos), pues añade reglas o representaciones en grafo que complementan señales espectrales débiles o engañosas. En imágenes de resolución media (p. ej., Sentinel-2) y en condiciones de vegetación compleja, la integración de GEOBIA con clasificadores de *Machine Learning* (RF, SVM, redes neuronales) permite explotar tanto la información de objeto (forma, textura, contexto) como la espectral para generar mapas más consistentes a escala regional; esto se evidencia en aplicaciones de cartografía forestal tropical, donde métodos OBIA+ML sobre Sentinel-2 mostraron mejoras en la separación de clases con firmas similares.

A escala de detalle (UAV/VHR), GEOBIA también se combina con redes neuronales profundas para la detección individual de objetos (por ejemplo, árboles, plantas), posibilitando un flujo híbrido: (1) detección/segmentación automática mediante CNN (p. ej., Mask R-CNN o arquitecturas más ligeras) y (2) posprocesamiento por objetos que refina máscaras, elimina falsos positivos y reagrega resultados de acuerdo con índices de vegetación o morfología esperada. Estudios empíricos lo confirman: (YE *et al.*, 2023) compararon Mask R-CNN con un flujo OBIA (MDTWS) para la detección individual de repollos en imágenes UAV y reportaron que Mask R-CNN obtuvo mayor F1 y mayor eficiencia computacional, aunque señalan que OBIA ofrece

interpretabilidad y puede ser útil en escenarios con pocos datos.

4.3 Modelos y arquitecturas de *deep learning* en teledetección

Los modelos de *deep learning* transformaron el análisis de imágenes satelitales y aéreas, en particular gracias al desarrollo de las redes neuronales convolucionales (CNN). Estas redes se basan en capas convolucionales que extraen automáticamente características espaciales y espectrales de las imágenes, permitiendo identificar patrones más complejos que los alcanzados mediante enfoques estadísticos o de aprendizaje automático convencional (SAHU; DASH, 2024). Variantes más avanzadas incluyen las *Fully Convolutional Networks* (FCN), diseñadas para tareas de segmentación semántica en las que cada píxel es clasificado; y la U-Net, una arquitectura del tipo *encoder–decoder* que ha demostrado gran eficiencia en la segmentación de imágenes médicas y, más recientemente, en teledetección. Su extensión, la ResU-Net, incorpora conexiones residuales que mejoran la capacidad de entrenamiento en redes profundas, alcanzando mayor precisión en la detección de fenómenos como deslizamientos (GHORBANZADEH *et al.*, 2022).

Otro avance importante son las arquitecturas profundas como AlexNet, VGGNet, GoogleNet, ResNet y DenseNet, utilizadas en la clasificación de coberturas terrestres a partir de imágenes de alta resolución. AlexNet introdujo la idea de aumentar la profundidad de las capas convolucionales, mientras que VGGNet refinó esta propuesta con mayor profundidad y simplicidad estructural. GoogleNet incorporó módulos Inception para procesar características en múltiples escalas, y ResNet introdujo bloques residuales que permiten entrenar redes con cientos de capas sin pérdida de precisión (SAHU; DASH, 2024). Estas arquitecturas sirven de base para modelos más recientes, como las redes específicas para detección de objetos en imágenes satelitales.

En el campo de la detección de objetos se destacan dos familias: las R-CNN (*Region-based CNN*) y las YOLO (*You Only Look Once*). Las R-CNN, y su evolución Faster R-CNN, combinan la propuesta de regiones con la clasificación basada en CNN, alcanzando alta precisión en la detección de objetos como edificios, embarcaciones o aeronaves. Por su parte, los modelos YOLO (v3 a v8) tratan la detección como un problema de regresión en una sola pasada por la red, obteniendo gran velocidad y aplicabilidad en escenarios de monitoreo en tiempo real (ADEGUN *et al.*, 2023). La incorporación de mecanismos adicionales, como las *Feature Pyramid Networks* (FPN) y módulos de atención, amplió la capacidad de estas

arquitecturas para identificar objetos pequeños o con alta variabilidad de formas y texturas en contextos urbanos y naturales (YE *et al.*, 2025).

4.3.1 Aplicaciones en imágenes satelitales de alta resolución espacial

La aplicación de estas arquitecturas en imágenes de alta resolución espacial (VHR) ha permitido enfrentar problemas críticos en la planificación urbana y en la gestión de riesgos. Por ejemplo, CNN y OBIA se combinaron para detectar deslizamientos en regiones montañosas, alcanzando métricas F1 superiores al 87

En cuanto a la detección de objetos específicos, los modelos YOLO y Faster R-CNN han demostrado eficacia en la identificación de construcciones, vehículos, piscinas y cuerpos de agua en áreas urbanas, alcanzando precisiones superiores al 90

4.3.2 Detección de objetos con YOLOv11

El algoritmo **You Only Look Once** (YOLO) representó un hito en la visión por computadora al proponer la detección de objetos como un problema unificado de clasificación y regresión en una sola etapa: dividir la imagen en cuadrículas y predecir simultáneamente cajas delimitadoras y probabilidades de clase (REDMON *et al.*, 2016). Este enfoque superó las limitaciones de los detectores en dos etapas, como Faster R-CNN, que dependían de la generación previa de regiones de interés. A lo largo de sus versiones (v1–v10), YOLO incorporó mejoras arquitectónicas —desde Darknet-53 y la integración multiescala (YOLOv3), hasta los bloques CSP y PANet (YOLOv4) y la migración a PyTorch (YOLOv5)—, consolidándose como una de las familias de detectores más influyentes en aplicaciones en tiempo real (SAPKOTA *et al.*, 2025).

En este contexto, YOLOv11, desarrollado por Ultralytics en 2024, representa un avance significativo al optimizar el equilibrio entre precisión, velocidad y eficiencia computacional. Entre sus innovaciones arquitectónicas, se destacan tres componentes: (i) el bloque C3k2, que sustituye al C2f de versiones anteriores, mejorando el flujo de gradientes y reduciendo la redundancia de parámetros; (ii) el módulo C2PSA (**Parallel Spatial Attention**), incorporado en la **head** para reforzar la detección de objetos pequeños y ocluidos; y (iii) el mantenimiento del SPPF (**Spatial Pyramid Pooling–Fast**) como mecanismo robusto de agregación multiescala (JOCHER; MUNAWAR, 2025; S Nikhileswara Rao, 2024; JEGHAM *et al.*, 2025). Como resultado, YOLOv11m alcanza **mAP** superior en el conjunto COCO, utilizando cerca de un 22

YOLOv11 se distribuye en cinco variantes —*nano, small, medium, large* y *extra-large*—, permitiendo su uso desde dispositivos embebidos hasta plataformas de alto desempeño. Además, amplía sus capacidades más allá de la detección convencional, soportando tareas de segmentación de instancias, clasificación de imágenes, estimación de poses y detección de cajas delimitadoras orientadas (OBB) (JOCHER; MUNAWAR, 2025).

El entrenamiento se realiza principalmente con el conjunto de datos Microsoft COCO, usado preferentemente para detección y segmentación de objetos. Contiene 330.000 imágenes y 2,5 millones de etiquetas presentes en las imágenes. El conjunto clasifica 80 objetos diferentes como animales, vehículos, humanos, constituyendo así un *dataset* de referencia en detección de objetos (MURAT; KIRAN, 2025). Además del uso de ImageNet para clasificación y DOTA v1 para detección orientada en imágenes aéreas (JOCHER; MUNAWAR, 2025; SAPKOTA *et al.*, 2025). Esta combinación fortalece su capacidad de transferencia a dominios especializados, como la teledetección, en los que la identificación de objetos pequeños y con variación de orientación es un desafío central.

Las aplicaciones de YOLOv11 son amplias: desde la conducción autónoma y la vigilancia hasta la agricultura de precisión y el monitoreo por satélite, mostrando un desempeño notable en objetos de difícil identificación, como vehículos en tráfico intenso, defectos en manufactura o plantas individuales (SAPKOTA *et al.*, 2025). Para esta investigación, su relevancia radica en la capacidad de reconocer puestos de vendedores ambulantes en imágenes aéreas de alta resolución, que constituyen objetos pequeños, dispersos y frecuentemente ocluidos. El soporte multiescala (SPPF), la eficiencia computacional (C3k2) y la atención espacial (C2PSA) hacen de YOLOv11 una herramienta adecuada para este tipo de escenario urbano complejo.

En síntesis, YOLOv11 consolida la evolución de la serie hacia modelos más ligeros y precisos, con un diseño flexible, adaptable a distintas tareas y plataformas. Su potencial en la detección de vendedores ambulantes en imágenes aéreas se fundamenta tanto en su precisión y velocidad como en su capacidad de procesar grandes volúmenes de datos urbanos en tiempo casi real, contribuyendo así a la construcción de sistemas de monitoreo automatizado del espacio público.

5 TRABAJOS RELACIONADOS

La detección de vendedores ambulantes en imágenes aéreas y satelitales de muy alta resolución se inscribe en un campo interdisciplinario que articula los estudios urbanos sobre la informalidad, la teledetección y las técnicas avanzadas de aprendizaje profundo orientadas a la detección de objetos. En este contexto, los primeros trabajos de referencia derivan de la detección de asentamientos informales y de usos urbanos no planificados, en los cuales se demostró que las imágenes de alta resolución ofrecen un nivel de detalle capaz de capturar la complejidad morfológica de las ciudades. (BALLIM, 2016) exploró enfoques de Object-Based Image Analysis (OBIA) para identificar asentamientos informales, destacando que el análisis basado en objetos permite superar las limitaciones de los métodos basados en píxel.

De forma complementaria, (HOFMANN; BEKKARNAYEVA, 2017) aplicaron OBIA en la detección de cambios, demostrando que la segmentación basada en unidades espaciales facilita el monitoreo temporal de fenómenos urbanos. Posteriormente, (SALEM *et al.*, 2020) mostraron cómo los algoritmos de aprendizaje automático aplicados a imágenes satelitales VHR permiten mapear barrios marginales en El Cairo, integrando datos espaciales con alta precisión. Estas experiencias constituyen una referencia metodológica para el estudio de vendedores ambulantes, ya que, aunque centradas en la informalidad residencial, revelan que fenómenos urbanos heterogéneos pueden identificarse mediante técnicas avanzadas de análisis espacial.

Paralelamente a los estudios sobre asentamientos, la literatura reciente ha prestado mayor atención a los vendedores ambulantes como parte de la economía informal y su inserción en el espacio público. (Velásquez Gómez, 2018) en el caso de Medellín, resaltó el papel de la participación de los vendedores en la gestión del espacio urbano, reconociendo su función social y económica. De manera similar, (PEIMANI; KAMALIPOUR, 2025) profundizaron en el análisis de la espacialidad del comercio callejero, relacionándolo con la vitalidad urbana y las dinámicas de movilidad peatonal. Más recientemente, (PEIMANI; KAMALIPOUR, 2025) estudiaron el caso de vendedores en asentamientos informales de Hanói, mostrando cómo estas prácticas se articulan en “espacios intermedios” y en las interfaces público-privadas, configurando formas socioespaciales que responden a códigos informales de negociación y visibilidad.

Este tipo de análisis cualitativo se complementa con revisiones sistemáticas como la de (SANDHIKA *et al.*, 2024), quienes identificaron que la configuración espacial y la gestión de los vendedores son determinantes para la sostenibilidad urbana y que, sin mecanismos adecuados

de organización, surgen problemas de congestión, higiene y conflictos de uso.

En los últimos años, la literatura ha evolucionado hacia la construcción de *datasets* y métodos de detección basados en *deep learning*. (LIU; LIU, 2022) aplicaron imágenes a nivel de calle en escala urbana para analizar la distribución de vendedores en Shenzhen, mostrando patrones policéntricos y la utilidad del procesamiento masivo de datos urbanos. En la misma línea, (GARCIA-JAIME *et al.*, 2025) presentaron el *dataset* StreetVendor-SLI, con más de 2.700 imágenes a nivel de calle de Medellín etiquetadas para entrenar modelos de detección, incorporando categorías como vendedores fijos, semifijos e itinerantes, además de técnicas de anonimización para proteger la privacidad. Estos desarrollos consolidan la base empírica necesaria para el entrenamiento de modelos robustos de visión computacional aplicados al comercio informal.

En cuanto a los avances técnicos, (ADEGUN *et al.*, 2023) realizaron una revisión sobre arquitecturas de detección de objetos en imágenes satelitales, resaltando el potencial de Faster R-CNN, RetinaNet y especialmente de la familia YOLO para la detección eficiente de objetos pequeños y dispersos. Investigaciones aplicadas incluso probaron arquitecturas livianas como MobileNet-SSD en la detección de vendedores en entornos urbanos, validando su viabilidad en escenarios de monitoreo en tiempo real (AGBA; TAHIR, 2021). Estos enfoques son reforzados por estudios en otras áreas de la teledetección que exploran la complementariedad entre OBIA y *deep learning*. (GHORBANZADEH *et al.*, 2022) integraron ResU-Net con OBIA en la detección de deslizamientos, obteniendo mejoras significativas en métricas de precisión y F1-score. (AMESLEK *et al.*, 2024) combinó CNN con OBIA en imágenes de drones para detectar olivos, alcanzando precisiones cercanas al 99%, mientras que (YE *et al.*, 2023) demostraron que Mask R-CNN supera los métodos OBIA en la detección de cultivos individuales. En la misma dirección, (NASIRI *et al.*, 2023) compararon modelos basados en píxel y en objetos para la detección de tala de árboles con imágenes PlanetScope, concluyendo que los enfoques OBIA con Random Forest ofrecen mejores niveles de generalización y precisión. Aunque aplicadas a fenómenos distintos, estas experiencias confirman que la combinación de *deep learning* y OBIA constituye una estrategia prometedora para la detección de patrones espaciales complejos en imágenes de muy alta resolución.

Más recientemente, el campo ha avanzado hacia *pipelines* abiertos y reproducibles. (YE *et al.*, 2025) desarrollaron un flujo de trabajo basado en Faster R-CNN con ResNet-101 para detectar torres y postes eléctricos en imágenes WorldView-3, alcanzando métricas de precisión

superiores al 90% y publicando un conjunto abierto de anotaciones. Aunque el objetivo era la infraestructura crítica, los resultados son extrapolables al caso de los vendedores ambulantes, ya que ambos involucran objetos pequeños distribuidos en paisajes urbanos densos.

En conjunto, la literatura permite delinear un panorama claro: la detección de vendedores ambulantes mediante imágenes aéreas y *deep learning* se nutre de tres tradiciones. En primer lugar, la de la teledetección urbana aplicada a la informalidad espacial (asentamientos, barrios marginales), que aporta metodologías robustas como OBIA y ML/DL. En segundo lugar, los estudios urbanos y sociales que describen la espacialidad, las tipologías y las lógicas de los vendedores en el espacio público, orientando la definición de categorías y variables espaciales relevantes. Y, por último, los avances recientes en visión computacional, que han probado arquitecturas y flujos de trabajo para objetos pequeños en contextos complejos, ofreciendo referentes técnicos replicables. El desafío actual reside en articular estas tres líneas, de modo que se generen modelos de detección que no solo alcancen altos niveles de precisión técnica, sino que también produzcan información útil para la planificación urbana, la gestión del espacio público y el reconocimiento de la función socioeconómica del comercio informal.

6 METODOLOGÍA

Este capítulo describe la metodología empleada en el estudio de detección de vendedores ambulantes en imágenes de alta resolución espacial por medio de *deep learning* con detección de objetos. Se presentan los detalles de adquisición de los datos, preprocesamiento, modelos de *deep learning* utilizados, etiquetado de las imágenes, interpretación de las métricas de los experimentos, implementación (*deployment*) y un estudio de caso.

La investigación tiene como objetivo aplicar modelos de visión por computadora para la detección de vendedores ambulantes mediante técnicas de *deep learning* orientadas a la detección de objetos en imágenes aéreas de alta resolución espacial. Para ello, se integraron informaciones vectoriales y ráster, y se estructuró una fase experimental en cuatro componentes: (i) proceso de etiquetado, (ii) entrenamiento del modelo, (iii) implementación web y (iv) estudio de caso. El entrenamiento se realizó con el *framework* YOLOv11, en las variantes *s* y *m*; para el uso del modelo en un entorno real, se implementó una aplicación web mediante el *framework* Streamlit, posibilitando la interacción con los datos y la evaluación de la calidad del modelo. También se evaluó un caso real de utilidad del sistema.

Conforme a la subseção 6.1.5, el flujo metodológico se dividió en dos etapas. En primer lugar, se utilizó una imagen de la capital de Colombia (Bogotá) que, debido a su tamaño, fue dividida; se emplearon únicamente algunas ubicaciones geográficas distintas dentro de la ciudad, a fin de captar múltiples tipologías de vendedores ambulantes. En este estudio, se delimitó una tipología específica de vendedor: aquellos con mobiliario itinerante que, aunque clasificados como ambulantes, mantienen ubicación fija o semifija durante la jornada de trabajo, caracterizados por la presencia de sombrillas, carpas o coberturas que los protegen de las condiciones climáticas. Tales estructuras son relativamente fáciles de identificar tanto en imágenes aéreas como en vistas a nivel de calle.

Aunque estos puestos pueden ser reconocidos visualmente en imágenes aéreas por el conocimiento previo del observador sobre el sector, ese reconocimiento no es suficiente para el volumen de datos exigido en el entrenamiento y la validación del modelo. Es necesario asegurar que la sombrilla identificada en la imagen corresponda a un vendedor ambulante y no a otro objeto presente en la escena. Por esa razón, se utilizaron como referencia los datos del levantamiento de vendedores ambulantes del Censo Económico de Colombia. Esta base de información, anonimizada y con restricciones de publicación, permitió corroborar la presencia de vendedores en las áreas de interés y orientar el proceso de etiquetado de las imágenes aéreas a

partir de coordenadas geográficas (latitud y longitud). Estos datos no serán publicados en este trabajo y se emplearon exclusivamente para identificar áreas con actividad de venta ambulante y para la validación cruzada entre las imágenes y el levantamiento en campo.

Por último, a partir de los datos del Censo Económico, recolectados durante la etapa de levantamiento, se consideraron variables adicionales, como tipo de mobiliario, ubicación (fija, semifija o itinerante) y permanencia del puesto. Esta información fue fundamental para seleccionar casos con continuidad temporal, lo que permitió utilizar una imagen de alta resolución proporcionada públicamente por el Instituto Geográfico Agustín Codazzi (IGAC), así como insumos de otras fuentes gubernamentales, facilitando la anotación de los datos y el entrenamiento del modelo de detección de objetos.

6.1 Adquisición de los datos

Las imágenes empleadas en este trabajo, utilizadas para el entrenamiento del modelo, fueron obtenidas de fuentes públicas de libre acceso y de fuentes oficiales de alcaldías o de instituciones del ámbito nacional, mediante las debidas autorizaciones, las cuales pueden consultarse en los anexos de este estudio (véase ??).

En cuanto a la localización de los vendedores ambulantes —esto es, sus coordenadas geográficas y la información económica adicional sobre la actividad—, los datos se obtuvieron de la institución oficial de estadísticas, con la restricción de que su uso se limita a la identificación de concentraciones de vendedores en las ciudades en estudio y al etiquetado de las imágenes para la posterior aplicación de los modelos de *deep learning*. De conformidad con la autorización de uso, dicha información no será hecha pública en este trabajo, manteniéndose la confidencialidad y las condiciones definidas por el organismo responsable.

6.1.1 Área de estudio

La ciudad seleccionada es Bogotá, capital de Colombia, elegida por la mayor disponibilidad de datos y por la posibilidad, en la imagen empleada, de identificar áreas con mayor concentración de este segmento de la economía informal, lo que favorece la selección de sectores y de los objetos a ser etiquetados. La descripción de la imagen se encuentra en la subsección 6.1.2. En lo que respecta a la caracterización urbana, la ciudad posee una extensión geográfica de aproximadamente 307 km^2 y alberga a más de 8 millones de habitantes. Desde el punto de

el brillo de las áreas urbanas en las franjas del NIR ($0.76\text{--}0.90\mu\text{m}$) y del SWIR ($2.08\text{--}2.35\mu\text{m}$), de modo que realza firmas típicas de superficies urbanizadas.

$$UI = \frac{B_{SWIR} - B_{NIR}}{B_{SWIR} + B_{NIR}} \quad (6.1)$$

La imagen utilizada para el cálculo de este índice fue una escena del satélite PlanetScope, que presenta la ventaja de una resolución espacial de 3 metros, aunque con la limitación de no disponer de la banda de infrarrojo de ondas cortas (SWIR) (véase Table 1). Ante esta restricción espectral, el índice fue adaptado a la disponibilidad de bandas de la imagen, preservándose el propósito de realzar áreas urbanizadas.

Tabela 1 – Longitud de onda de la imagen PlanetScope (2025)

Banda	Nombre	Longitud de onda (nm)	Resolución (m)
2	Azul	465–515	3
4	Verde	547–585	3
6	Vermelho	650–680	3

Fonte: elaborado por el autor (2025).

$$UI_{adaptado} = \frac{Red - NIR}{Red + NIR} \quad (6.2)$$


Como resultado de la aplicación del índice, se observa en la Figure 2 la clasificación de las zonas de la ciudad: valores entre -0.2 y 0.21 indican un mayor grado de urbanización, mientras que las áreas con valores próximos a -1 corresponden, en general, a parques y espacios naturales — como se ve en la imagen a la derecha de la misma figura.

Hay regiones de la ciudad que presentan un índice casi homogéneo en los sectores descritos en los párrafos anteriores; por ejemplo, el sector denominado “Centro Histórico”, con escasa presencia de parques y áreas verdes, así como sectores ubicados en el noroeste y en el suroeste de la ciudad.

6.1.2 Descripción de los vendedores ambulantes y su localización

En lo que respecta a los vendedores ambulantes, en este trabajo se emplearon datos de localización provenientes del Censo Económico de 2024, con la restricción de que dicha información se utilizó exclusivamente para identificar áreas de la ciudad con mayor

Figura 2 – Índice UI (Urban Index) aplicado en la imagen del satélite PlanetScope



Fonte: elaborado por el autor (2025).

presencia de estos vendedores, caracterizar el tipo de mobiliario utilizado, registrar el año de inicio de la actividad en el espacio público y, sobre todo, ubicar a los vendedores en las imágenes. Por motivos de confidencialidad y conforme a la autorización de uso, esta información y sus coordenadas geográficas no pueden hacerse públicas. Además, se espera que, con el modelo propuesto y una imagen georreferenciada, sea posible localizar vendedores y estimar sus coordenadas geográficas de forma aproximada.

Asimismo, considerando la caracterización de la actividad en el espacio público y la revisión de la literatura, se reconocen diferentes tipologías de vendedores ambulantes (GARCIA-JAIMES *et al.*, 2025; YATMO, 2008), tales como itinerantes, fijos y semifijos. La permanencia en un mismo lugar depende, en gran medida, del tipo de producto y del mobiliario empleado. Esta investigación se enfoca en la tipología cuyo mobiliario incluye el uso de *sombrilla* como elemento de protección contra condiciones de sol y lluvia —característica recurrente en distintos contextos urbanos alrededor del mundo, como evidencian (DOVEY; RECIO, 2024; AGBA; TAHIR, 2021; PEIMANI; KAMALIPOUR, 2025)—. Dicho mobiliario es visible en imágenes aéreas de alta resolución espacial y, junto con las coordenadas (latitud y longitud) de los registros, permite confirmar que los objetivos identificados corresponden a vendedores ambulantes, y no a

otras sombrillas eventualmente presentes en la vía pública.

Figura 3 – Tipo de mobiliario de los vendedores ambulantes analizados



Fonte: elaborado por el autor (2025).

En la Figure 4 se observa la concentración de vendedores ambulantes en la ciudad. El mapa de densidad, en una escala de 0 a 1 —siendo 1 la mayor concentración de puntos—, muestra mayores cantidades de vendedores en las regiones del centro-este, noroeste y oeste, precisamente donde hay mayor densidad de estos puestos ambulantes. En el mapa, los sectores se denominan ‘Centro Histórico’, ‘Patio Bonito’, ‘Suba’ y ‘Fontibón’.

Estos múltiples núcleos son relevantes porque en esas áreas se analizaron las imágenes aéreas y la ubicación de los vendedores ambulantes. Es importante mencionar que, en 2024, fueron entrevistados 77,367 vendedores ambulantes que utilizan mobiliario del tipo carrito, permanecen en puntos fijos y trabajan en el mismo lugar desde hace más de tres años. De este modo, la confirmación de la presencia de los vendedores en las imágenes permite asegurar la


Tabela 2 – Descripción de la imagen aérea original

Propriedad	Descripción
Tamaño (GB)	532,84
Tamaño comprimido (GB)	13,2
Columnas	361 344
Filas	527 779
Tamaño de pixel	8 cm
Formato	ECW
Resolución radiométrica	8 bits
Sistema de referencia de coordenadas	WGS84

Fonte: Elaborado por el autor (2025), a partir de la información de la imagen.

Para la detección de objetos, el **YOLOv11** hace uso del conjunto de datos **COCO** (LIN *et al.*, 2014), que incluye **80 clases preentrenadas**. La tabla siguiente presenta las características de los diferentes modelos utilizados para la detección de objetos.

Figura 5 – Bandas de la imagen



Fonte: elaborado por el autor (2025).

6.1.4 Descripción del modelo

El presente trabajo utiliza el modelo YOLOv11, la iteración más reciente de la familia YOLO para detección de objetos. La principal ventaja de este modelo es haber sido concebido para realizar la detección en una sola pasada: se emplea una red neuronal que estima simultáneamente las cajas delimitadoras y las probabilidades de clase en toda la imagen, lo que agiliza el proceso de detección en comparación con métodos tradicionales más complejos.

Para la detección de objetos, YOLOv11 hace uso del conjunto de datos COCO (LIN *et al.*, 2014), que incluye 80 clases preentrenadas. La tabla siguiente presenta las características de los diferentes modelos utilizados para la detección de objetos.

Tabela 3 – Desempeño de los modelos YOLOv11

Modelo	Tamaño (píxeles)	mAP ₅₀₋₉₅	Velocidad CPU ONNX (ms)	Velocidad T4 TensorRT10 (ms)	Parámetros (M)	FLOPs (B)
YOLO11n	640	39.5	56.1 ± 0.8	1.5 ± 0.0	2.6	6.5
YOLO11s	640	47.0	90.0 ± 1.2	2.5 ± 0.0	9.4	21.5
YOLO11m	640	51.5	183.2 ± 2.0	4.7 ± 0.1	20.1	68.0
YOLO11l	640	53.4	238.6 ± 1.4	6.2 ± 0.1	25.3	86.9
YOLO11x	640	54.7	462.8 ± 6.7	11.3 ± 0.2	56.9	194.9


Fonte: Adaptado de (JOCHER; MUNAWAR, 2025)

Otro modelo de detección de objetos disponible en YOLOv11 es *YOLO11-OBB*, que prevé *cajas delimitadoras orientadas* (OBB) para objetos rotados en las imágenes. Tales cajas son útiles cuando los objetivos aparecen bajo distintos ángulos, especialmente en imágenes aéreas. Este modelo, también perteneciente a la familia YOLOv11, fue *preentrenado* con el conjunto de datos *DOTA v1*, compuesto por 14 categorías y por más de 2,806 imágenes, mayoritariamente aéreas, en las cuales se identifican, por ejemplo, aviones, embarcaciones, tanques de almacenamiento, campos de béisbol, canchas de tenis, pistas de atletismo, puertos, puentes y vehículos de gran y pequeño porte. En aplicaciones con imágenes aéreas, el uso de OBB tiende a mejorar el desempeño del detector.

Sin embargo, en este trabajo se emplearon las variantes *YOLOv11-n*, *YOLOv11-s*, *YOLOv11-m* y *YOLOv11-l*, sin necesidad de cajas orientadas. Esta decisión se deriva del flujo de etiquetado, entrenamiento e implementación, que presentó resultados satisfactorios incluso con cajas alineadas a los ejes. Además, debido a la morfología de la *sombrilla* —elemento central del mobiliario analizado—, los objetivos exhiben *invariancia aproximadamente rotacional* en la perspectiva aérea: aun rotados, preservan forma y apariencia suficientes para una detección robusta sin OBB. Los resultados de desempeño observados fueron, por lo tanto, considerados prometedores en el alcance de este estudio.

En este trabajo se emplea la arquitectura YOLOv11, desarrollada por Ultralytics, concebida para la detección de objetos en tiempo real según un esquema de pasada única (*one-stage*). En una sola inferencia, el modelo estima simultáneamente las cajas delimitadoras, las probabilidades de clase y el índice de confianza (*objectness*), lo que explica su amplia adopción en dominios como videovigilancia, conducción autónoma, diagnóstico asistido por imagen, gestión de inventarios y monitoreo ambiental y agrícola (JEGHAM *et al.*, 2025). Esta

Figura 6 – Arquitectura del modelo Yolov11



Fonte: Elaborado por el autor (2025). Adaptado de (JEGHAM *et al.*, 2025)

combinación de velocidad y precisión caracteriza a la familia YOLO y se mantiene en su undécima iteración.

La distribución de YOLOv11 por parte de Ultralytics se rige por la licencia AGPL-3.0, que exige poner a disposición del público las modificaciones del software cuando se ofrece como servicio accesible por red; Ultralytics también ofrece una licencia empresarial que elimina tales obligaciones para usos comerciales. En este estudio se utilizó la versión oficial sin modificaciones del código base, estrictamente con fines académicos y en conformidad con el régimen de licenciamiento y la documentación/repositorio oficiales (ULTRALYTICS, 2025).

Desde el punto de vista estructural, YOLOv11 conserva la organización en tres componentes —*backbone*, *neck* y *head*— que conducen el flujo de información desde la imagen de entrada hasta las predicciones finales. Antes del paso por la red, es práctica habitual aplicar normalización y redimensionamiento; durante el entrenamiento, se recurre a aumento de datos (*data augmentation*), como rotaciones, recortes y ajustes fotométricos, para mejorar la generalización (RASHEED; ZARKOOSH, 2025; JEGHAM *et al.*, 2025).

El *backbone* funciona como extractor jerárquico de características: transforma la imagen en una pirámide multiescala mediante bloques Conv2D + BatchNorm + SiLU, intercalados con unidades de mayor capacidad que preservan la eficiencia sin sacrificar la representati-

dad. Entre las novedades de YOLOv11, el bloque C3K2 sustituye al C2f de YOLOv8 adoptando un diseño CSP más ligero (menos parámetros y FLOPs con desempeño equivalente o superior); al final del **backbone**, el SPPF (**Spatial Pyramid Pooling – Fast**) agrega contexto multiescala y el C2PSA (atención espacial basada en **Cross-Stage Partial**) resalta regiones informativas, beneficiando la detección de objetos pequeños o parcialmente ocluidos (JEGHAM *et al.*, 2025).

El **neck** actúa como puente de fusión multiescala entre **backbone** y **head**: agrega y refina características de distintas resoluciones mediante **upsampling**, concatenación y nuevos bloques C3K2, incorporando nuevamente C2PSA para guiar la atención espacial durante la integración. En la práctica, el **backbone** produce mapas con reducciones 2×, 4×, 8×, 16× y 32×; el **neck** los remezcla y los entrega a la **head** en tres escalas de predicción, cada una más adecuada a un rango de tamaños de objeto (JEGHAM *et al.*, 2025).

La **head** es el módulo predictivo: a partir de los mapas multiescala del **neck**, estima las coordenadas de las cajas (centro, ancho y alto), el **objectness** y los **logits** de clase. YOLOv11 mantiene tres salidas (típicamente con **strides** 8, 16 y 32), cubriendo simultáneamente objetos pequeños, medianos y grandes; además, la **head** sigue siendo refinada con C3K2 para filtrar/condensar la información inmediatamente antes de la predicción, reduciendo falsos positivos y estabilizando los encuadres (JEGHAM *et al.*, 2025).

Desde la óptica ingenieril, una contribución reciente es la optimización para uso eficiente de recursos propuesta por (RASHEED; ZARKOOSH, 2025). Los autores parten de YOLOv11n y desarrollan seis variantes orientadas al tamaño dominante de objeto —YOLOv11-small, YOLOv11-medium, YOLOv11-large y tres combinaciones (sm, ml, sl)— que eliminan cabezas de detección y podan bloques que alimentan escalas irrelevantes al caso de uso. La selección de la variante se guía por un clasificador de tamaños que analiza las anotaciones del **dataset**. Experimentalmente, tales variantes preservan el mAP del YOLOv11 de referencia en la mayoría de los escenarios, al tiempo que reducen número de parámetros, GFLOPs, latencia de inferencia y consumo energético, sin alterar la lógica **backbone–neck–head** (RASHEED; ZARKOOSH, 2025).

En conjunto, el **pipeline** de YOLOv11 puede verse como una cadena coherente: una imagen adecuadamente normalizada y aumentada es procesada por un **backbone** que equilibra economía computacional y capacidad de representación (Conv+BN+SiLU, C3K2, SPPF, C2PSA); esa información se agrega en el **neck** con **upsample** y **concat**, nuevamente filtrada por C3K2/C2PSA, y culmina en una **head** multiescala que produce hipótesis de caja,

confianza y clase en una sola pasada. El resultado es un detector rápido, robusto a variaciones de tamaño y contexto, y adaptable a restricciones de hardware gracias a estrategias de poda y especialización guiadas por la distribución de tamaños en el **dataset** (RASHEED; ZARKOOSH, 2025; JEGHAM *et al.*, 2025). Por último, en lo relativo a **compliance** y reproducibilidad, el uso de la versión oficial sin modificaciones y en consonancia con el licenciamiento AGPL-3.0 garantiza la adhesión a las directrices establecidas por Ultralytics (ULTRALYTICS, 2025).

Por consiguiente, en el entrenamiento se emplea YOLOv11 con ***dos variantes de la serie 11*** —los modelos *s* y *m*—. De acuerdo con (RASHEED; ZARKOOSH, 2025), en imágenes aéreas los modelos YOLOv11s y YOLOv11m presentan el mejor desempeño; por lo tanto, ***son las variantes evaluadas en este estudio***.

6.1.5 Aplicación del modelo de detección de vendedores ambulantes

Una vez seleccionados el modelo y la variante preferida, se aplicó la metodología propuesta. El diagrama de flujo presentado en la Figure 7 describe el proceso desde la preparación de las imágenes hasta la aplicación del modelo y la posterior evaluación del desempeño.

Antes de ello, se describe el proceso de aplicación del algoritmo, los *datasets* probados, los procedimientos de preprocesamiento y la *data augmentation* empleada.

En total, se utilizaron cuatro imágenes extraídas de la imagen de mayor extensión. Estas cuatro áreas de la ciudad, con mayor presencia de venta ambulante, se dividieron en bloques de 256×256 píxeles (pasos P1 a P5 del diagrama de flujo), según se describe en la Table 4. Tras la división, se seleccionaron las imágenes que contenían vendedores ambulantes y objetos visualmente similares. Dichos objetos similares, aunque no fueron etiquetados, se incluyeron para indicar al modelo que la escena contiene elementos parecidos que no corresponden a puestos de venta ambulante (P6).


Tabela 4 – Descripción de las imágenes divididas

Imagen	Sector	Filas	Columnas	Área (km ²)	Tamaño (MB)	Bloques	Imágenes seleccionadas
1	Centro	14 303	21 105	1,931	863,64	4 510	117
2	Suba	14 788	20 737	1,962	877,36	4 617	69
3	Fontibón	6 446	9 510	0,390	175,38	925	24
4	Kennedy	16 342	23 760	2,485	1 008	5 796	140
5	Girardot	13 663	12 968	1,13	506,92	2 650	40
5	Tunja	10 490	8 168	0,54	325,85	1 240	30

Fonte: Elaborado por el autor (2025).

Se construyeron cuatro modelos. Los tres primeros fueron entrenados con un *dataset*

Figura 7 – Flujograma de la metodología aplicada



Fonte: Elaborado por el autor (2025). Adaptado de (JEGHAM *et al.*, 2025).

compuesto por 350 imágenes, de las cuales 44 eran negativas (es decir, sin objetos relacionados con vendedores ambulantes). El último modelo, a su vez, fue entrenado con 427 imágenes debido al acceso a un conjunto adicional de datos, totalizando 353 imágenes etiquetadas (positivas) y 74 negativas, y resultando en 1.038 instancias anotadas. Las imágenes negativas se seleccionaron con el propósito de entrenar al modelo para reconocer objetos visualmente similares que no corresponden a vendedores ambulantes. Aunque el conjunto contaba con 74 imágenes negativas, no todas fueron incluidas en las etapas de preprocesamiento y modelado; esta decisión metodológica se detallará más adelante.

6.1.5.1 Versión 1

En la primera versión del modelo, se emplearon 876 imágenes tras la aplicación de técnicas de *data augmentation*.

Preprocesamiento:

- Orientación automática: sí
- Redimensionamiento: 640×640
- Ajuste automático de contraste: ecualización de histograma

Data augmentation:

- Muestras generadas por imagen de entrenamiento: 3
- Recorte/*zoom*: 0–5%
- Rotación: $-15^\circ - +15^\circ$
- Brillo: $-10\% - +10\%$
- Desenfoque: hasta 1,px

División del conjunto de datos:

- Entrenamiento: 789 (90%)
- Validación: 70 (8%)
- Prueba: 17 (2%)

6.1.5.2 Versión 2

En la segunda versión del modelo, se emplearon 1,420 imágenes tras la aplicación de técnicas de *data augmentation* que dividían la imagen en *tiles*, lo que amplió el conjunto de datos.

Preprocesamiento:

- Orientación automática: sí
- Redimensionamiento: 640×640
- Ajuste automático de contraste: ecualización de histograma
- Mosaico (*tiles*): 2 filas $\times$ 2 columnas
- Filtro de imágenes nulas: al menos el 95% de las imágenes deben contener anotaciones

Data augmentation:

- Muestras generadas por imagen de entrenamiento: 3
- Recorte/*zoom*: 0–5%

- Rotación: $-15^{\circ} - +15^{\circ}$
- Brillo: $-10\% - +10\%$
- Desenfoque: hasta 1,px

División del conjunto de datos:

- Entrenamiento: 1,268 (90%)
- Validación: 118 (8%)
- Prueba: 34 (2%)

6.1.5.3 Versión 3

En la tercera versión, se utilizaron técnicas de *data augmentation* recomendadas para imágenes aéreas, conforme a la documentación oficial de Roboflow (NELSON, 2021). Como se observará más adelante, el desempeño fue significativo. Con estas mejoras, el *dataset* pasó a contar con 800 imágenes.

Preprocesamiento:

- Orientación automática: sí
- Redimensionamiento: 640×640
- Filtro de imágenes nulas: al menos el 95% de las imágenes deben contener anotaciones

Data augmentation:

- Muestras generadas por imagen de entrenamiento: 3
- Espejado: horizontal y vertical
- Rotación de 90° : en sentido horario, antihorario e inversión (180°)
- Recorte/zoom: 0–10
- Matiz (*hue*): $-10^{\circ} - +10^{\circ}$
- Saturación: $-20\% - +20\%$
- Brillo: $-24\% - +24\%$
- Ajuste fino de tonalidad: $-8\% - +8\%$
- Desenfoque: hasta 0.2,px

División del conjunto de datos:

- Entrenamiento: 717 (90%)
- Validación: 67 (8%)
- Prueba: 16 (2%)

6.1.5.4 Versión 4

En la cuarta versión, se añadió un conjunto adicional de imágenes debido a la disponibilidad de nuevos datos a lo largo del período de estudio, totalizando 427 imágenes; con la aplicación de *data augmentation*, esta cifra alcanzó 1.069 imágenes. Además, se modificó uno de los filtros de preprocesamiento, pasando a exigir que al menos el 50% de las imágenes contuvieran anotaciones.

Preprocesamiento:

- Orientación automática: sí
- Redimensionamiento: 640×640
- Filtro de imágenes nulas: al menos el 50% de las imágenes deben contener anotaciones

Data augmentation:

- Muestras generadas por imagen de entrenamiento: 3
- Espejado: horizontal y vertical
- Rotación de 90° : en sentido horario, antihorario e inversión (180°)
- Recorte/zoom: 0–10%
- Matiz (*hue*): $-10^\circ - +10^\circ$
- Saturación: $-20\% - +20\%$
- Brillo: $-24\% - +24\%$
- Ajuste fino de tonalidad: $-8\% - +8\%$
- Desenfoque: hasta 0.2,px

División del conjunto de datos:

- Entrenamiento: 717 (90%)
- Validación: 67 (8%)
- Prueba: 16 (2%)

Figura 8 – Ejemplo de etiquetado de la imagen



Fonte: Elaborado por el autor (2025).

Tras realizar el preprocesamiento y aplicar *data augmentation*, se desarrolló un *script* que utiliza la API de Roboflow, aprovechando modelos *preentrenados* para detección de objetos. El *script* se ejecutó en *Google Colab Pro*, con las siguientes capacidades de cómputo:

Tabela 5 – Descripción de las capacidades de computación

Propiedad	Descripción
GPU	Tesla T4 — 15 GB
Toolkit	CUDA 12.4
RAM	12,7 GB
Disco	112,6 GB

Fonte: Elaborado por el autor (2025).

Aprovechando el desempeño del *YOLOv11*, el *script* realiza un *fine-tuning*: como el modelo original está *preentrenado* en el conjunto de datos Microsoft COCO (*Common Objects in Context*), compuesto por 80 clases, ya dispone de un aprendizaje inicial, siendo necesario únicamente ajustar las capas finales para reconocer las clases específicas — en este caso, vendedores ambulantes — y actualizar los pesos de la red con las nuevas imágenes. De este modo, el proceso requiere menos datos y menor tiempo de entrenamiento.

Los tres modelos emplearon dos variantes: *YOLOv11s* y *YOLOv11m*, cada una con una configuración distinta.

Tabela 6 – Descripción de los modelos

Descripción	Modelo 1(v3)	Modelo 2(v4)	Modelo 3(v5)	Modelo 4(v8)
Versión <i>YOLOv11</i>	<i>s</i>	<i>s</i>	<i>m</i>	<i>s</i>
Tamaño del conjunto de datos	876	1 420	800	1069
Nome	bogota_v3	bogota_v4	bogota_v5	bogota_v8


Fonte: Elaborado por el autor (2025).

6.1.6 Despliegue web

Dada la capacidad del modelo para producir predicciones de alta calidad, se propone el desarrollo de una *aplicación web* para poner los resultados a disposición del público. El sistema fue concebido para operar con imágenes cuya **resolución espacial sea de 8,cm/pixel**. En caso de que el usuario disponga de imágenes de *drone* con resolución más fina, se recomienda realizar la **re-muestreo** (*resampling*) para ajustar los píxeles a 8,cm. Por otro lado, si la imagen presenta una resolución inferior (píxeles mayores que 8,cm), el **desempeño del detector** podría verse comprometido y los resultados tenderán a estar por debajo de lo esperado.

La aplicación web fue desarrollada en Streamlit con Python.

Figura 9 – Diagrama de despliegue web



Fonte: Elaborado por el autor (2025).

De acuerdo con la Figure 9, en el nivel de implementación (*deployment*), la aplicación se ejecuta como un servicio web de inferencia interactivo. La interfaz de usuario reside en el navegador y establece una sesión HTTP(S) con un servidor que hospeda la aplicación —en este caso, Streamlit Community—. Ese servidor ejecuta el código de orquestación y de pre/pós-procesamiento (lectura del ráster, corte en ladrillos/teselas, georreferenciación y exportación de resultados). La detección de objetos se delega a un servicio externo por medio de la API de Roboflow, vía solicitudes HTTP POST. Este patrón “*frontend* delgado + *backend* orquestador + servicio de IA” separa responsabilidades: el cliente muestra y solicita, el *backend* coordina y la IA especializada infiere. La cartografía generada con mapa base utiliza *web tiles* de la biblioteca Contextily (Python) y se renderiza en el servidor como figura estática.

Desde la perspectiva de arquitectura, el servidor de la aplicación es *stateless* respecto a las predicciones: cada solicitud contiene la imagen a analizar y los parámetros de inferencia (tamaño de tesela, umbral de confianza, etc.). El servidor transforma la imagen de entrada —idealmente un GeoTIFF u otro formato con metadatos geoespaciales— en una representación adecuada al modelo (teselas RGB de 8 bits comprimidas en JPEG). Cada bloque se envía a Roboflow con credenciales (API Key) y metadatos mínimos; Roboflow responde con las detecciones (cajas y sus confiabilidades) en coordenadas normalizadas o en píxeles del bloque. La latencia total resulta de la suma del tiempo de E/S del ráster, del *tiling*, de la codificación base64/JPEG, de la inferencia remota y del posprocesamiento geométrico. El sistema escala horizontalmente con facilidad.

La lógica algorítmica se organiza en dos funciones principales. El algoritmo 1,

`detect_objects_roboflow(image_np, api_key, model_id, version, conf)`, encapsula la inferencia remota: recibe un chip $H \times W \times C$ (H : altura; W : ancho; C : canales), lo codifica en formato JPEG y lo envía a la API de Roboflow. La API devuelve, para cada chip, una lista de detecciones con el centroide de la caja (x,y), su tamaño ($width,height$) en el sistema de referencia del chip (píxeles) y la confiabilidad asociada. Esta función es agnóstica a las coordenadas geográficas: se limita al mapeo “imagen $\rightarrow$ predicciones en píxeles”.

Algoritmo 1: `detect_objects_roboflow(image_np, api_key, model_id, version, conf)`

Input: `image_np` ($H \times W \times C$), `api_key`, `model_id`, `version`, `conf`

Output: Lista de predicciones (posiblemente vacía)

Entrada: chip de imagen `image_np` en RGB (8 bits);

Codificar en JPEG: $(_, buffer) \leftarrow cv2.imencode(".jpg", image_np)$;

Generar payload Base64: $b64 \leftarrow b64encode(buffer)$;

Construir la URL: $endpoint \leftarrow "https://detect.roboflow.com/" + model_id + "/" + version$;

$query \leftarrow "?api_key=" + api_key + "\&confidence=" + conf$;

Enviar solicitud HTTP POST con data = $b64$ y Content-Type = x-www-form-urlencoded;

if la respuesta indica error **then**

lanzar excepción;

end

Extraer predicciones: $preds \leftarrow resp.json().get("predictions", [])$;

return $preds$;

El algoritmo 2, `process_geotiff_to_points(...)`, compone todo el flujo geoespacial. Abre el ráster con Rasterio y recupera su transformación afín (3×3), la cual mapea los índices de píxel hacia coordenadas en el sistema de referencia de la imagen, además del respectivo CRS (por ejemplo, EPSG:31978 o EPSG:4326). A continuación, recorre la imagen en una malla de ventanas de tamaño fijo (por ejemplo, 256×256) con una superposición opcional para reducir artefactos en los bordes de las teselas. Para cada tesela, solicita detecciones a la función anterior; las cajas son entonces “elevadas” a coordenadas globales de píxel sumando los desplazamientos ($xoff,yoff$) de la tesela. Luego, se proyectan a coordenadas geográficas con `rasterio.transform.xy(transform, row, col)`, que aplica la afinidad del ráster (traslación, escala y posible rotación). Finalmente, las geometrías puntuales se empaquetan en un `GeoDataFrame` con el CRS nativo del ráster y se re proyectan a WGS84 (EPSG:4326) para su consumo en `GeoPackage/GeoJSON/SHP.zip` y visualización como mapa web estático.

Desde el punto de vista geomático, la transformación afín del ráster define la relación “píxel $\rightarrow$ coordenada” y es crucial para preservar la georreferenciación; el CRS proporciona el marco para georreferenciar los resultados de salida. La reproyección a WGS84 emplea bibliotecas como PROJ (vía pyproj/GeoPandas), garantizando que los puntos finales posean longitud y latitud. En términos de precisión, la localización de cada detección hereda: (i) la resolución espacial del ráster (tamaño de píxel); (ii) la cuantización interna del modelo (cajas en píxeles); y (iii) eventuales errores de reproyección. En general, dicha precisión es adecuada para análisis urbanos a escalas grandes (1:5.000–1:10.000), cuando se trabaja con imágenes satelitales de alta resolución (píxeles < 1 m) u ortofotos con calidad subpíxel.

En cuanto a robustez y calidad, el *tiling* impone dos consideraciones. Primero, los objetos en los bordes de las teselas pueden aparecer truncados o duplicados en ventanas adyacentes; la fusión ingenua puede generar solapamiento y duplicados al calcular centroides. Para mitigarlo, el parámetro de superposición asegura que un objeto completo aparezca al menos en una tesela; opcionalmente, puede aplicarse *Non-Maximum Suppression* (NMS) a nivel global para fusionar detecciones redundantes tras recomponer la imagen —recurso no incluido en esta lógica—. Segundo, la compresión JPEG introduce cuantización radiométrica y artefactos; en la práctica, con tasas moderadas y detección de objetos compactos, el impacto es pequeño, pero conviene preservar suficiente contraste (p. ej., normalización al percentil 98–99,5 por banda antes de escalar a 8 bits).

Desde la óptica computacional, el costo es aproximadamente lineal en el número de teselas: cada tesela implica una llamada HTTP y un *forward pass* del modelo en Roboflow. Existe, por tanto, un compromiso entre tamaño de tesela (mayor $\rightarrow$ menos llamadas, pero más memoria y E/S; menor $\rightarrow$ más llamadas, mejor localización en escenas heterogéneas) y superposición (más robustez en bordes a costa de trabajo redundante). En *datasets* urbanos con alta densidad de objetivos, se recomienda 256 píxeles sin superposición.

Por último, la fase de salida produce tres artefactos: (1) un ráster con las cajas dibujadas, útil para validación visual; (2) una capa vectorial de puntos (GeoPackage, GeoJSON o SHP.zip), que contiene los centroides de las detecciones en WGS84, interoperable con SIG de escritorio y servicios OGC; y (3) una visualización cartográfica sobre mapa base, que contextualiza espacialmente los hallazgos. Este conjunto entrega rastreabilidad (cajas sobre píxeles), interoperabilidad (geometrías en CRS estándar) y comunicabilidad (mapas listos para interpretación por equipos no técnicos).

Algoritmo 2: `process_geotiff_to_points(raster_path, api_key, model_id, version, tile_size, overlap, conf, save_chips, chips_dir)`

Input: GeoTIFF y parámetros de inferencia/*tiling*

Output: GeoDataFrame con puntos (lon, lat), clase y confianza

Inicializar listas vacías: `points`, `confs`, `classes`;

Abrir ráster: `src ← rasterio.open(raster_path)`;

Obtener transform, crs, w, h;

if `save_chips` **then**

 | crear `chips_dir` si no existe

end

for `y ← 0` **to** `h - 1` (`tile_size - overlap`) **do**

for `x ← 0` **to** `w - 1` (`tile_size - overlap`) **do**

`win ← Window(x,y,tile_size,tile_size)`;

`chip ← src.read(window=win, out_shape=(count,t,t))`;

 Reordenar `chip`: $CHW \rightarrow HWC$;

if `save_chips` **then**

 | guardar `chip_{x}_{y}.jpg` con `cv2.imwrite`

end

`preds ← detect_objects_roboflow(chip, api_key, model_id, version, conf)`;

$p \in preds (cx, cy) \leftarrow (p["x"], p["y"])$;

$(px, py) \leftarrow (x + cx, y + cy)$;

$(lon, lat) \leftarrow xy(transform, py, px)$;

`points.append(Point(lon,lat))`;

`confs.append(p["confidence"])`;

`classes.append(p["class"])`;

end

end

`gdf ← GeoDataFrame({class: classes, confidence: confs},
 geometry=points, crs=crs)`;

return `gdf`;

7 RESULTADOS

En el aprendizaje profundo, diversas métricas son ampliamente utilizadas para evaluar los modelos. La *matriz de confusión* es, sin duda, una herramienta central en la fase de evaluación, ya que muestra el número de estimaciones correctas e incorrectas en comparación con los datos reales etiquetados.

La siguiente matriz expone los valores que sirven de base para el cálculo de las métricas:

Tabela 7 – Matriz de confusión

		Resultados de la predicción	
		1	0
Resultados reales	1	Verdadero Positivo (VP)	Falso Negativo (FN)
	0	Falso Positivo (FP)	Verdadero Negativo (VN)

Fonte: Elaborado por el autor (2025).

En cuanto a la precisión, esta métrica indica cuántas de las predicciones positivas del modelo son, en realidad, positivas. En otras palabras, estima la proporción de detecciones correctas (VP) en relación con el total de detecciones positivas realizadas (VP + FP):

$$Precision = \frac{TP}{TP + FP} \quad (7.1)$$

En cuanto al *recall*, esta métrica estima la proporción de objetos reales detectados correctamente (VP) en relación con el total de objetos presentes (VP + FN). Evalúa la capacidad del modelo para encontrar todas las instancias del objeto en las imágenes:

$$Recall = \frac{TP}{TP + FN} \quad (7.2)$$

Otra métrica igualmente importante es el *F1-score*. Esta métrica combina la precisión y el *recall* para evaluar el equilibrio entre ambas en el desempeño del modelo. Se calcula como la media armónica entre la precisión y el *recall*:

$$F1 = 2 \times \frac{Precision \cdot Recall}{Precision + Recall} \quad (7.3)$$

El intervalo se sitúa entre 0 y 1, donde 1 indica un equilibrio perfecto entre la *precisión* (predicciones correctas en relación con el total de predicciones) y el *recall* (objetos detectados en relación con el total de objetos reales). Esta métrica es útil cuando se busca equilibrar la minimización de falsos positivos (alta precisión) y de falsos negativos (alto *recall*).

En el caso de que haya más de una clase, las métricas anteriores se vuelven menos directas, pues la precisión y el *recall* deben calcularse por separado para cada clase. Para superar esta limitación y obtener resultados más consistentes, se emplea la **Precisión Media** (*Average Precision* — AP). En esta métrica, se construye la curva *precisión–recall* para cada clase, y el valor del área bajo dicha curva corresponde a la AP; valores más altos de AP indican un mejor desempeño del algoritmo. (Opcionalmente, puede reportarse la **mAP**, que es el promedio de las AP calculadas sobre todas las clases.)

$$AP = \int_0^1 p(r) \quad (7.4)$$

Además de las métricas anteriores, existen otras medidas relevantes en los modelos de detección de objetos que involucran el *IoU* (*Intersection over Union*), un indicador que cuantifica el grado de superposición entre la caja delimitadora predicha por el modelo y la caja de referencia (anotación real). Con base en esto, se emplea la métrica *mAP* (*mean Average Precision*), que expresa la **precisión media** del modelo en múltiples categorías, considerando niveles específicos del índice de intersección sobre la unión. En términos prácticos, la *mAP* resulta del promedio de los valores de AP calculados para todas las clases:

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i, \quad \text{Siendo } N \text{ el número total de clases e } AP_i \text{ es la AP de la clase } i. \quad (7.5)$$

Un desglose común es reportar mAP_{50} y mAP_{50-95} . La primera, mAP_{50} , corresponde a la *mAP* calculada con un **umbral de IoU igual a 0.50**: se considera una detección correcta cuando la superposición entre la caja predicha y la real alcanza, como mínimo, el 50%. Se trata de un criterio menos estricto, por lo tanto, más sensible a detecciones fáciles.

Por su parte, mAP_{50-95} calcula la *mAP* **promediando** (haciendo el promedio) los valores de AP en **umbrales de IoU de 0.50 a 0.95**, típicamente en pasos de 0.05. De este modo, se evalúa la precisión del modelo en diferentes niveles de exigencia para la localización del objeto — cuanto mayor es el umbral de IoU, más riguroso es el criterio de acierto.

7.1 Resultados generales

De acuerdo con la Table 8, se emplearon varios modelos disponibles en el [repositorio en GitHub](#). En todos los casos, se utilizó la versión YOLOv11, en las variantes *s* y *m*, las cuales presentaron desempeños distintos. El mejor modelo requirió 54 minutos de entrenamiento, y sus resultados se presentan a continuación.

Tabela 8 – Descripción de las métricas de los modelos entrenados

Modelo	Imagenes Train	Imagenes Val	Imagenes Test	Instancias Train	epochs	Precision	Recall	F1-Score	mAP_{50}	mAP_{50-95}
Modelo 1(v3)	876	67	16	1967	100	92.3%	85.3%	88.3%	95.8%	0.684
Modelo 2(v4)	717	67	16	1967	100	88.8%	84.6%	86.64	90.8%	0.621
Modelo 3(v5)	717	67	16	1967	100	92.0%	92.1%	92.1	96.5%	0.723
Modelo 4(v8)	963	85	21	2299	100	93.2%	92.3%	91.85	96.2%	0.729

Fonte: Elaborado por el autor (2025).

7.2 Detalle de los resultados del Modelo 4(v8)

De acuerdo con la Table 8, se entrenaron más de 10 modelos; sin embargo, aquí se muestran algunos de ellos con el propósito de presentar los resultados después de modificar los parámetros de entrenamiento, preprocesamiento y aumento de datos (*data augmentation*). Algunos de los más representativos son:

En lo que respecta a la **precisión** —proporción de detecciones correctas entre todas las predicciones positivas—, el modelo presentó un desempeño elevado. Con $TP = 192$ y $FP = 16$, se obtiene:


$$Precision = \frac{TP}{TP + FP} = \frac{192}{192 + 16} = 0.93,2 \quad (7.6)$$

En lo que respecta a la **precisión** —proporción de detecciones correctas entre todas las predicciones positivas—, el modelo presentó un desempeño elevado. Con $TP = 192$ y $FP = 16$, se obtiene:

La **sensibilidad** (*recall*) —proporción de objetos correctamente detectados en relación con el total de objetos reales presentes— presentó un desempeño elevado en el mejor modelo. Con $TP = 192$ y $FN = 21$, se tiene:


$$Recall = \frac{TP}{TP + FN} = \frac{192}{192 + 21} = 0.923 \quad (7.7)$$

Figura 10 – Matriz de confusión normalizada



Fonte: elaborado por el autor (2025).

Figura 11 – Matriz de confusión



Fonte: elaborado por el autor (2025).


En términos interpretativos, el resultado indica una *baja tasa de falsos negativos*: aproximadamente 7,7% de los objetos reales no fueron detectados ($\frac{FN}{TP+FN} = 1 - \frac{21}{213} \approx 0.077$). Para aplicaciones en las que es crucial *no perder objetivos* (prioridad en el *recall*), este nivel es robusto; aun así, el análisis debe combinarse con la **F1-Score** para evaluar el equilibrio global del modelo entre errores por omisión y por comisión.

Finalmente, la métrica F_1 -score —media armónica entre la **precisión** y el **recall**— alcanzó un valor de **0,927**, evidenciando un buen equilibrio entre errores por comisión (falsos positivos) y por omisión (falsos negativos). Este resultado es consistente con los valores de *Precision* (0.932) y *Recall* (0.923), e indica que el modelo mantiene un desempeño estable en diferentes situaciones de detección, sin favorecer indebidamente solo una de las dimensiones.

$$F1 = 2 \times \frac{Precision \cdot Recall}{Precision + Recall} = 2 \times \frac{0.932 \cdot 0.923}{0.932 + 0.923} = 0.927 \quad (7.8)$$

Desde el punto de vista interpretativo, la elección de la media armónica penaliza los casos en que una de las métricas es sustancialmente inferior a la otra; así, un F_1 elevado sugiere que el clasificador no depende únicamente de una alta precisión (evitar falsos positivos) ni solo de un alto *recall* (evitar falsos negativos), sino que mantiene un *trade-off* adecuado entre ambas.

Figura 12 – Curva de F1-Score



Fonte: elaborado por el autor (2025).

La métrica $mAP_{0.5}$ —calculada con un umbral de $IoU \geq 0.5$ — expresa el promedio de las precisiones considerando, como mínimo, un 50% de superposición entre las cajas predichas y las cajas de referencia. Ampliamente aceptada como referencia en tareas de detección, esta métrica sintetiza la capacidad del modelo para combinar una buena localización con una correcta clasificación bajo un criterio de coincidencia moderadamente exigente. En el presente estudio, el modelo alcanzó un valor de **0.962** en $mAP_{0.5}$, resultado que indica un **desempeño excelente** incluso frente a variaciones de ruido, iluminación y alta heterogeneidad de la escena —con múltiples objetos no objetivo presentes además de los vendedores ambulantes. En términos prácticos, este nivel sugiere que, bajo un umbral de coincidencia del 50%, el detector mantiene una alta consistencia en la identificación y el encuadre de los objetivos.

$$mAP_{50} = \frac{1}{N} \sum_{i=1}^N AP_i = 0.962 \quad (7.9)$$

Adicionalmente, la métrica $mAP_{0.5-0.95}$ evalúa el promedio de la precisión a lo largo de múltiples umbrales de superposición —es decir, IoU variando de 0.50 a 0.95, en pasos de 0.05. Se trata de un indicador más riguroso, pues exige una **mayor exactitud espacial** en la localización de las cajas. Incluso bajo este criterio estricto, el modelo obtuvo un valor de **0.729**, evidenciando **robustez** en la detección. En términos interpretativos, la diferencia entre $mAP_{0.5}$ y $mAP_{0.5-0.95}$ es esperada: a medida que el umbral de IoU se aproxima a 0.95, pequeñas imprecisiones en el encuadre penalizan la puntuación, especialmente en objetivos *pequeños* o parcialmente ocluidos. Aun así, el valor de 0.729 indica que el detector mantiene un buen desempeño en un rango amplio de exigencias de coincidencia, conciliando el acierto de clase con la calidad del posicionamiento de las cajas.


$$mAP_{50-95} = \frac{1}{N} \sum_{i=1}^N AP_i = 0.729 \quad (7.10)$$

La evaluación de las **métricas de aprendizaje** obtenidas durante el entrenamiento, representadas en la Figure 13, a lo largo de todo el **período de entrenamiento**, indica una **convergencia estable**. Las curvas de **precisión**, **recall** y mAP_{50} muestran una mejora progresiva hasta alcanzar un nivel de **estabilización**, sin señales evidentes de *overfitting*.

Se observa que la **precisión** y el **recall** comienzan a estabilizarse a partir de la **época 80**, mientras que la **función de pérdida** (*loss*) presenta una **tendencia decreciente** consistente.

Se registra únicamente una **pequeña variación** alrededor de la **época 50**; sin embargo, en el conjunto de las épocas, el ritmo se mantuvo en descenso, lo que sugiere que el modelo **aprendió de manera progresiva y sin indicios claros de *overfitting***.

Figura 13 – Resultados del modelo



Fonte: elaborado por el autor (2025).


En la comparación de los resultados, se observa en la Figure 14 que, en la imagen de la izquierda, se muestra la **rotulación manual** realizada en 16 imágenes y, en la derecha, las **predicciones** del modelo. No se verifican discrepancias relevantes en el proceso de predicción: solo en la **primera fila** una instancia anotada no fue detectada (falso negativo), mientras que, en esa misma fila, una instancia *no rotulada* fue correctamente identificada por el modelo.

En conjunto, los resultados evidencian que el modelo produce **predicciones de alta calidad**, con errores residuales compatibles con la variabilidad de la escena y con la incertidumbre inherente a las anotaciones manuales.

7.2.1 Resultados del despliegue web

En la ??, se observa el Aplicativo web desarrollado, que permite enviar una imagen de hasta 200 MB —preferiblemente georreferenciada y menor que ese límite, con el fin de obtener resultados más rápidos y estables. El aplicativo realiza el análisis de la imagen, ejecuta las predicciones y pone a disposición los datos para su descarga, incluyendo las tablas, los archivos SIG y la propia imagen resultante.

Figura 14 – Comparación etiquetado vs predicción



Fonte: elaborado por el autor (2025).

8 CONCLUSIONES Y TRABAJOS FUTUROS

El presente estudio, modelo y herramienta web constituyen una contribución para que instituciones, equipos técnicos, tomadores de decisiones y el público interesado dispongan de un modelo y una herramienta capaces de apoyar decisiones en beneficio de los sectores populares de la economía informal, con énfasis en determinadas tipologías de vendedores ambulantes.

Los resultados aquí presentados ofrecen un aporte inicial, dado que la literatura existente sobre la detección de vendedores ambulantes se ha concentrado, en su mayoría, en *datasets* de imágenes a nivel de calle. Sin embargo, las limitaciones inherentes al mapeo y a la captura de datos en ese nivel pueden dificultar tareas de localización espacial a gran escala, actividades de muestreo y, en general, la obtención de información sistemática sobre los sectores informales —componentes esenciales de las ciudades que deben dignificar esta forma de trabajo e integrarla en la planificación y provisión de servicios urbanos para todos.

Los resultados son prometedores: desde el punto de vista de las métricas de desempeño y la evaluación, se demostró la viabilidad de identificar, a gran escala, vendedores ambulantes, detectar y cuantificar multinúcleos en una ciudad, georreferenciarlos, analizar sus dinámicas temporales y modelar escenarios. Se espera, por lo tanto, que estos datos sirvan de base para futuros análisis espaciales multicriterio en el ámbito del urbanismo, de los censos económicos y urbanos, del uso y gestión del espacio público y de iniciativas orientadas a la dignificación del trabajo informal, entre otras aplicaciones.

Persisten, no obstante, condicionantes relevantes. Idealmente, se recomienda el uso de imágenes aéreas o satelitales de alta resolución espacial (nivel submétrico), la ampliación del *dataset* y el reentrenamiento del modelo con una mayor diversidad de datos que cubran distintos contextos geográficos, siempre que sea posible. La disponibilidad recurrente de satélites y aerofotografías —frecuentemente actualizadas con fines de catastro urbano— constituye un insumo valioso para refinar el modelamiento y ofrecer a la comunidad académico-científica alternativas metodológicas que fortalezcan esta semilla de conocimiento y aplicación.

REFERENCIAS

- ADEGUN, A. A.; Fonou Dombeu, J. V.; VIRIRI, S.; ODINDI, J. State-of-the-Art Deep Learning Methods for Objects Detection in Remote Sensing Satellite Images. **Sensors**, v. 23, n. 13, p. 1–18, 2023. ISSN 14248220.
- AGBA, H. N.; TAHIR, A. Street vendor detection: Helping municipalities make decisions with actionable insights. **SIU 2021 - 29th IEEE Conference on Signal Processing and Communications Applications, Proceedings**, Institute of Electrical and Electronics Engineers Inc., jun 2021.
- AMESLEK, O.; ZAHIR, H.; LATIFI, H.; BACHAOUI, E. M. Combining OBIA, CNN, and UAV imagery for automated detection and mapping of individual olive trees. **Smart Agricultural Technology**, Elsevier, v. 9, p. 100546, dec 2024. ISSN 2772-3755.
- BALLIM, K. Detecting Informal Settlements From High Resolution. n. December, 2016.
- CHEN, G.; WENG, Q.; HAY, G. J.; HE, Y. Geographic object-based image analysis (GEOBIA): emerging trends and future opportunities. **GIScience & Remote Sensing**, Taylor & Francis, v. 55, n. 2, p. 159–182, mar 2018. ISSN 15481603. Available at: <<https://www.tandfonline-com.bdigital.udistrital.edu.co/doi/abs/10.1080/15481603.2018.1426092>>.
- DOVEY, K.; RECIO, R. B. Inventraset assemblages: The spatial logic of informal street vending, transport and settlement. **Urban Studies**, v. 61, n. 12, p. 2265–2289, 2024. ISSN 1360063X.
- ECK, E. van; RATH, J. Stigmatizing Street Vendors and Market Traders: The Case of Amsterdam from a Historical Perspective. **Journal of Urban History**, SAGE Publications Inc., v. 50, n. 6, p. 1338–1355, nov 2024. ISSN 15526771. Available at: <<https://doi.org/10.1177/00961442221140889>>.
- GARCIA-JAIMES, K.; BALLESTEROS, J. R.; BRANCH-BEDOYA, J. W. Street-level imagery dataset for the detection of informal vendors in urban environment. **Data in Brief**, Elsevier, v. 62, p. 111912, oct 2025. ISSN 2352-3409.
- GHORBANZADEH, O.; SHAHABI, H.; CRIVELLARI, A.; HOMAYOUNI, S.; BLASCHKE, T.; GHAMISI, P. Landslide detection using deep learning and object-based image analysis. **Landslides**, Springer Berlin Heidelberg, v. 19, n. 4, p. 929–939, 2022. ISSN 16125118. Available at: <<https://doi.org/10.1007/s10346-021-01843-x>>.
- HOFMANN, P.; BEKKARNAYEVA, G. Object-based change detection of informal settlements. **2017 Joint Urban Remote Sensing Event, JURSE 2017**, Institute of Electrical and Electronics Engineers Inc., may 2017.
- JEGHAM, N.; KOH, C. Y.; ABDELATTI, M.; HENDAWI, A. YOLO Evolution: A Comprehensive Benchmark and Architectural Review of YOLOv12, YOLO11, and Their Previous Versions. 2025. Available at: <<http://arxiv.org/abs/2411.00201>>.
- JOCHER, G.; MUNAWAR, R. **Ultralytics YOLO11 - Documentación de Ultralytics YOLO**. 2025. Available at: <<https://docs.ultralytics.com/es/models/yolo11/>>.
- KAMAWARA, M.; JAYAMANNA, S.; TSUJIKO, Y. Relation between social and environmental conditions in Colombo, Sri Lanka and the Urban Index estimated by

satellite remote sensing data. v. 51st, n. Kyotsu Sesshon, p. 190–191, 1996. Available at: <https://jglobal.jst.go.jp/en/detail?JGLOBAL{}_ID=200902189966290398>.

LIN, T. Y.; MAIRE, M.; BELONGIE, S.; HAYS, J.; PERONA, P.; RAMANAN, D.; DOLLÁR, P.; ZITNICK, C. L. Microsoft COCO: Common Objects in Context. **Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)**, Springer, Cham, v. 8693 LNCS, n. PART 5, p. 740–755, 2014. ISSN 1611-3349. Available at: <https://link.springer.com/chapter/10.1007/978-3-319-10602-1{}_48>.

LIU, Y.; CHEN, X.; LIU, Y.; WU, X.; CHEN, F. Mapping of Spatial Distribution of Street Vendors Based on Street-View Images and Deep-Learning Technology. **Redai dili**, Editorial Committee of Tropical Geography, v. 43, n. 6, p. 1098–1110, jun 2023. ISSN 1001-5221. Available at: <<https://doaj.org/article/6bffc503f975435ba979ac4a68a0127b>>.

LIU, Y.; LIU, Y. Detecting the city-scale spatial pattern of the urban informal sector by using the street view images: A street vendor massive investigation case. **Cities**, Pergamon, v. 131, p. 103959, dec 2022. ISSN 0264-2751.

MURAT, A. A.; KIRAN, M. S. A comprehensive review on YOLO versions for object detection. **Engineering Science and Technology, an International Journal**, Elsevier, v. 70, p. 102161, oct 2025. ISSN 2215-0986.

NASIRI, V.; HAWRYŁO, P.; JANIEC, P.; SOCHA, J. Comparing Object-Based and Pixel-Based Machine Learning Models for Tree-Cutting Detection with PlanetScope Satellite Images: Exploring Model Generalization. **International Journal of Applied Earth Observation and Geoinformation**, Elsevier B.V., v. 125, dec 2023. ISSN 1872826X.

NELSON, J. **Image Augmentations for Aerial Datasets**. 2021. Available at: <<https://blog.roboflow.com/image-augmentations-for-aerial-datasets/>>.

PEIMANI, N.; KAMALIPOUR, H. Mapping the Spatiality of Informal Street Vending. **Journal of Urbanism: International Research on Placemaking and Urban Sustainability**, Routledge, jul 2025. ISSN 17549183. Available at: <<https://www.tandfonline.com/doi/abs/10.1080/17549175.2022.2150267>>.

RASHEED, A. F.; ZARKOOSH, M. YOLOv11 optimization for efficient resource utilization. **Journal of Supercomputing**, v. 81, n. 9, jul 2025. ISSN 15730484. Available at: <<http://arxiv.org/abs/2412.14790>>.

REDMON, J.; DIVVALA, S.; GIRSHICK, R.; FARHADI, A. You only look once: Unified, real-time object detection. **Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition**, v. 2016-December, p. 779–788, 2016. ISSN 10636919.

S Nikhileswara Rao. **YOLOv11 Architecture Explained: Next-Level Object Detection with Enhanced Speed and Accuracy** | by S Nikhileswara Rao | **Medium**. 2024. Available at: <<https://medium.com/@nikhil-rao-20/yolov11-explained-next-level-object-detection-with-enhanced-speed-and-accuracy-2dbe2d376f71>>.

SAHU, M.; DASH, R. Cognitive land cover mapping: A three-layer deep learning architecture for remote sensing data classification. **Environmental Challenges**, Elsevier, v. 15, p. 100876, apr 2024. ISSN 2667-0100.

SALEM, M.; TSURUSAKI, N.; EISSA, A.; OSMAN, T. Detection of Slums from Very High-Resolution Satellite Images Using Machine Learning Algorithms: A Case Study of Fustat Area in Cairo, Egypt. **International Exchange and Innovation Conference on Engineering and Sciences**, p. 219–224, 2020. ISSN 24341436.

SANDHIKA, R. R.; SHOLIAH, A. B.; YULI, N. G. Spatial Configuration & Management Street Vendors in Public Space. **Journal of Architectural Design and Urbanism**, Department of Architecture, Faculty of Engineering, Universitas Diponegoro, Indonesia., v. 6, n. 2, p. 104–114, jun 2024. ISSN 2620-9810. Available at: <<https://ejournal2.undip.ac.id/index.php/jadu/article/view/21236>>.

SAPKOTA, R.; FLORES-CALERO, M.; QURESHI, R.; BADGUJAR, C.; NEPAL, U.; POULOSE, A.; ZENO, P.; VADDEVOLU, U. B. P.; KHAN, S.; SHOMAN, M.; YAN, H.; KARKEE, M. YOLO advances to its genesis: a decadal and comprehensive review of the You Only Look Once (YOLO) series. **Artificial Intelligence Review**, v. 58, n. 9, 2025. ISSN 15737462.

SHOU, X.; CHEN, P.; ZHENG, H. Predicting the heat map of street vendors from pedestrian flow through machine learning. **Projections - Proceedings of the 26th International Conference of the Association for Computer-Aided Architectural Design Research in Asia, CAADRIA 2021**, v. 2, p. 569–578, 2021.

STRAULINO, D.; SALDARRIAGA, J. C.; GÓMEZ, J. A.; DUQUE, J. C.; O'CLERY, N. Uncovering commercial activity in informal cities. **Royal Society Open Science**, Royal Society Publishing, v. 9, n. 11, nov 2022. ISSN 20545703.

SUN, Z.; SCOTT, I.; BELL, S.; YANG, Y.; YANG, Z. Exploring Dynamic Street Vendors and Pedestrians through the Lens of Static Spatial Configuration in Yuncheng, China. **Remote Sensing 2022, Vol. 14, Page 2065**, Multidisciplinary Digital Publishing Institute, v. 14, n. 9, p. 2065, apr 2022. ISSN 2072-4292. Available at: <<https://www.mdpi.com/2072-4292/14/9/2065/htmhttps://www.mdpi.com/2072-4292/14/9/2065>>.

ULTRALYTICS. **Ultralytics YOLO11**. 2025. 1–23 p. Available at: <<https://docs.ultralytics.com/es/tasks/detect/https://docs.ultralytics.com/es/https://docs.ultralytics.com/models/yolo11/{#}overview>>.

Velásquez Gómez, C. Participación de venteros informales de Medellín: una herramienta de ordenación del espacio público*. **Cuadernos de Vivienda y Urbanismo**, Pontificia Universidad Javeriana, v. 11, n. 21, p. 1–16, 2018. ISSN 2145-0226. Available at: <<https://revistas.javeriana.edu.co/index.php/cvyu/article/view/22096>>.

YATMO, Y. A. Street Vendors as 'Out of Place' Urban Elements. **Journal of Urban Design**, Taylor & Francis Group, v. 13, n. 3, p. 387–402, 2008. ISSN 13574809. Available at: <<https://www-tandfonline-com.bdigital.udistrital.edu.co/doi/abs/10.1080/13574800802320889>>.

YE, M.; WARD, P. J.; De Plaen, J. J.; KOKS, E. E. A deep learning pipeline to power infrastructure detection in high-resolution satellite images. **Big Earth Data**, Taylor and Francis Ltd., 2025. ISSN 25745417. Available at: <<https://www.tandfonline.com/action/journalInformation?journalCode=tbed20>>.

YE, Z.; YANG, K.; LIN, Y.; GUO, S.; SUN, Y.; CHEN, X.; LAI, R.; ZHANG, H. A comparison between Pixel-based deep learning and Object-based image analysis (OBIA) for individual

detection of cabbage plants based on UAV Visible-light images. **Computers and Electronics in Agriculture**, Elsevier, v. 209, p. 107822, jun 2023. ISSN 0168-1699.