



MODELO DE SISTEMAS MULTI-AGENTES PARA LA CONSULTA BASADA EN NIVELES DE CONFIANZA, SOBRE RECURSOS VINCULADOS MEDIANTE DATOS ABIERTOS ENLAZADOS

Autor

Camilo Alejandro Valencia Martínez
Ingeniero de Sistemas

Tutor

Paulo Alonso Gaona
PhD en Ingeniería de la Información y del Conocimiento

Universidad Distrital Francisco José De Caldas
Maestría en Ciencias de la Información y las Comunicaciones,
Modalidad investigación
Énfasis en Ingeniería de software
Bogotá, Colombia
junio de 2023

AGRADECIMIENTOS

Agradezco de manera sincera a todas las personas que han contribuido en la realización de esta tesis de grado en la Maestría en Ciencias de la Información y las Comunicaciones de la Universidad Distrital Francisco José de Caldas.

En primer lugar, quiero expresar mi profundo agradecimiento al Dr. Paulo Alonso Gaona, mi asesor de tesis. Su guía, experiencia y dedicación fueron fundamentales para el desarrollo de este trabajo. Sus comentarios y sugerencias me han ayudado a perfeccionar mi investigación y expandir mis conocimientos y lograr el objetivo planteado. Estoy sinceramente agradecido por su paciencia, apoyo constante y valiosas contribuciones.

También deseo agradecer a la Universidad Distrital Francisco José de Caldas por brindarme la oportunidad de cursar la Maestría en Ciencias de la Información y las Comunicaciones. Los recursos y el ambiente académico de la universidad han sido esenciales para el desarrollo de mi trabajo de investigación, así como el apoyo del equipo administrativo.

Asimismo, quiero reconocer y agradecer a todos los docentes de la maestría, que han compartido sus conocimientos y experiencias a lo largo de mi formación académica. Sus enseñanzas han sido una inspiración y han contribuido significativamente a mi crecimiento profesional. Me gustaría dedicar un agradecimiento especial y póstumo al profesor Jose Nelson Perez, uno de los revisores iniciales y de quien recibí algunos espacios académicos y que lamentablemente falleció durante la pandemia.

No puedo dejar de mencionar a mis familiares, quienes han sido una fuente constante de apoyo, aliento y comprensión durante todo el proceso. Sus palabras de aliento y paciencia han sido vitales para superar los desafíos que se presentaron en el camino.

CONTENIDO

Lista de Figuras.....	5
Lista de Tablas.....	6
Lista de Código	7
Capítulo I Introducción.....	8
1. Resumen	9
2. Introducción.....	10
3. Justificación	13
4. Objetivos	14
4.1 Objetivo General.....	14
4.2 Objetivos Específicos	14
Capítulo II Marco de Referencia	15
1. Marco Teórico.....	16
1.1 Web semántica	17
1.2 Lenguajes y estándares	19
1.2.1 XML.....	20
1.2.2 RDF y RDF Schema	21
1.2.3 SPARQL	22
1.2.4 OWL	23
1.3 Sistema Multi-Agentes	23
2. Estado del Arte	24
2.1 Modelos de confiabilidad y calidad de datos abiertos enlazados.....	25
2.1.1 Metodologías de evaluación de calidad para datos abiertos enlazados	25
2.1.2 Evaluación de calidad de datos enlazados dirigida por pruebas ..	30
2.2 Búsqueda, indexación y clasificación de recursos LOD	33
2.2.1 Sindice.com: Una propuesta de búsqueda por índices orientada a documentos para datos abiertos enlazados.....	33
2.2.2 Búsqueda y navegación de datos enlazados utilizando SWSE (Semantic Web Searching Engine)	35
Capítulo III Diseño y Desarrollo.....	37

1. Metodología	38
2. Implementación de Ontología para evaluación de niveles de confianza sobre recursos vinculados mediante LOD.....	45
2.1 Especificación.....	46
2.2 Conceptualización	47
2.2.1 Glosario de términos	47
2.2.2 Taxonomía de Conceptos.	48
2.2.3 Relaciones binarias entre conceptos.....	50
2.2.4 Diccionario de Conceptos	51
2.2.5 Descripción de las Relaciones Binarias Entre Conceptos.....	52
2.2.6 Descripción de Atributos y Constantes.....	53
2.2.7 Atributos de Instancia	53
2.2.8 Atributos de Clase.....	54
2.2.9 Constantes	54
2.2.10 Descripción de Axiomas Formales.....	54
2.2.11 Descripción de Reglas.....	56
2.2.12 Descripción de Instancias.....	57
2.3 Formalización e Implementación.....	57
2.3.1 Jerarquía de conceptos	57
2.3.2 Diagrama de relaciones binarias.....	58
2.3.3 Creación de atributos de clase y atributos de instancia.....	59
2.3.4 Definición de axiomas formales.....	60
2.3.5 Definición de reglas.....	61
3. Modelado y diseño del Sistema Multi-Agentes	62
3.1 Planeación	62
3.1.1 Requerimientos Funcionales	64
3.1.2 Requerimientos no funcionales.....	64
3.1.3 Arquitectura general del Sistema Multi-Agente	64
3.2 Análisis	66
3.2.1 Casos de uso	66
3.2.2 Identificación de agentes	66
3.2.3 Identificación de responsabilidades.....	67

3.2.4	Identificación de conocidos.....	68
3.2.5	Refinamiento de agentes.....	70
3.2.6	Información de despliegue de los agentes.....	72
3.3	Diseño	72
3.3.1	División/Unión/Cambio nombre agentes.	72
3.3.2	Especificación de la interacción	73
3.3.3	Definición de protocolos de interacción Ad hoc.....	74
3.3.4	Plantillas de mensajes	74
3.3.5	Descripción para registrar/consultada en páginas amarillas.....	74
3.3.6	Interacción Agentes – Recursos	74
3.3.7	Interacción Agentes – Usuarios	75
3.3.8	Comportamientos internos agentes.....	76
3.3.9	Definiendo una ontología	76
3.4	Modelado y diseño de componentes externos	77
3.4.1	Repositorio de índices JENA	77
3.4.2	Interfaz gráfica de usuario	78
Capítulo IV	Implementación y pruebas.....	79
1.	Implementación del modelo	80
1.1.1	Repositorio de índices JENA	81
1.1.2	Agente rastreador – clasificador	82
1.1.3	Interfaz gráfica de usuario	84
	Resultados y Análisis.....	86
Capítulo V	Conclusiones	88
1.	Conclusiones	89
2.	Trabajos futuros	91
3.	Bibliografía.....	92

LISTA DE FIGURAS

Figura 1: Modelo de capas propuesto por Berners-Lee para la Web Semántica (Berners-Lee, Hendler, Lassila, & others, 2001)	18
Figura 2: Estructura de un documento XML	21
Figura 3: Anatomía de una consulta SPARQL (Della Valle & Ceri, 2011).....	22
Figura 4: Dimensiones de calidad de datos enlazados 1 (Zaveri, y otros, 2013)	26
Figura 5: Metodología basada en casos de prueba para calidad de los datos 2 (Kontokostas, y otros, 2014)	32
Figura 6: Síndice, Arquitectura propuesta 3 (Oren, y otros, 2008).....	34
Figura 7: Proceso indexación (Oren, y otros, 2008)	35
Figura 8: Arquitectura SWSE (Hogan, y otros, 2011)	36
Figura 9: Importación de Ontologías, descripción de métricas de confianza sobre Protege.....	41
Figura 10: Metodología para el análisis y diseño de sistemas Multi-Agente (Nikraz, Caire, & Bahri, 2006)	44
Figura 11: Referencias a la metodología en artículos, fuente scopus	45
Figura 12: Taxonomía de conceptos	49
Figura 13: Ejemplo propiedades de anotación para validación de métricas de confianza.....	50
Figura 14. Instancia MEDRA cargada en Protege.....	57
Figura 15: Taxonomía de conceptos inferida	58
Figura 16. Clases de datasets generadas a partir de la definición de los axiomas formales.....	58
Figura 17: Relaciones binarias inferidas por protege	59
Figura 18: Pestaña Data Properties en el software protege.....	60
Figura 19. Vista de axiomas la clase BlacklistedDataset	61
Figura 20. Implementación regla confianza transitiva	62
Figura 21: Crecimiento Linked Open Data (Lod-Cloud,2022)	63

Figura 22. Crecimiento LOD	63
Figura 23: Arquitectura propuesta sistema multiagentes (Autoría propia)	65
Figura 24: Interacción entre agentes.....	68
Figura 25: Identificación agentes.....	71
Figura 26: Despliegue de agentes	72
Figura 27. Interacciones agentes buscador- clasificador.....	75
Figura 28. Interacción Usuario – agente buscador	76
Figura 29: Ontología EvalOD en Protege.....	77
Figura 30. Diagrama de contexto implementación Apache JENA en infraestructura como servicio IAAS.....	78
Figura 31. Arquitectura final desplegada	80
Figura 32. Servicios habilitados Jena sobre Ontología Evalod	81
Figura 33: Despliegue Apache Jena sobre Azure.....	82
Figura 34. Carga ontología Evalod en repositorio de índices.....	82
Figura 35: Ejecución código fuente del agente clasificador en entorno de pruebas.....	83
Figura 36. Representación del grafo de las tripletas consultadas en el repositorio de índices.....	85
Figura 37. consulta por termino de búsqueda sobre los índices almacenados	85
Figura 38. Visualización por cada conjunto de datos indicando las métricas de confianza estimadas	86

LISTA DE TABLAS

Tabla 1: Ontologías para identificación de métricas de confianza.....	38
Tabla 2: Documento de Especificación de Ontologia	46
Tabla 3: Glosario de términos	47
Tabla 4: Relaciones Binarias entre conceptos	50
Tabla 5: Diccionario de conceptos	51

Tabla 6: Descripción relaciones Binarias entre conceptos	52
Tabla 7: atributos de instancia	53
Tabla 8: Atributos de clase	54
Tabla 9: Axiomas formales	54
Tabla 10: Descripción de reglas.....	56
Tabla 12: Identificación de responsabilidades	67
Tabla 13: Responsabilidades agentes con interacción	69
Tabla 14: Tabla responsabilidades Agentes.....	71
Tabla 15: Tabla de interacción entre agentes.....	73

LISTA DE CÓDIGO

Código 1: Plantilla de consulta SPARQL (Kontokostas, y otros, 2014).....	30
Código 2: Selecciona todas las clases que son disyuntas (Kontokostas, y otros, 2014).....	31
Código 3: Patrón para ejemplificación de caso de prueba (Kontokostas, y otros, 2014).....	31

CAPÍTULO I

INTRODUCCIÓN

1. RESUMEN

Este proyecto de grado tiene como propósito contribuir en el área de Web Semántica, específicamente sobre la vinculación de datos abiertos LOD. Lo anterior mediante el desarrollo de un modelo multi agente que permita realizar un análisis semántico sobre el estado actual de recursos digitales en abierto a partir de principios definidos por Linked Open Data (LOD) (Berners-Lee, Hendler, Lassila, & others, 2001). El modelo propuesto estaría apoyado sobre una ontología que permita definir los niveles de confianza sobre recursos abiertos, soportado por propuestas que manejen niveles de confianza sobre recursos digitales, y herramientas de la Web Semántica, tales como razonadores, procesadores de ontologías y procesamiento de grafos.

Palabras Clave: Linked data; Linked open data; Knowledge extraction; Niveles de confianza; Semantic Web technology

2. INTRODUCCIÓN

La búsqueda de información en la Web presenta grandes desafíos asociados a la efectividad de los resultados obtenidos, de acuerdo con las opciones de búsqueda de cada usuario a partir de un área de conocimiento. Este gran reto por un lado se debe a que la información no se encuentra bajo un esquema estructurado donde se pueda clasificar información, debido a la gran variedad de formatos (Klyne & Carroll, 2006), lo que conlleva a unos resultados con múltiples entradas que no son acordes a la búsqueda efectuada.

La iniciativa propuesta por Tim Berners Lee (Bizer, Heath, & Berners-Lee, Bizer, Heath et al. 2009 – Linked data-the story so far, 2009) asociados a la vinculación de datos mediante Linked Data promete resolver problemas asociados con el análisis y la interoperabilidad de los datos vinculados a recursos relacionados. Es así como la Web semántica se concibe como una red extendida que posee un mayor significado donde cualquier usuario puede hallar la información que necesita de manera práctica y efectiva, esto debido a que la información se encuentra mejor definida, con mayor significado y por ende con un grado de semántica mayor (Bizer, Bizer 2009 – The emerging web, 2009). Con base en esto se pueden obtener soluciones a problemas habituales, como por ejemplo en la búsqueda y localización de información en la Web de manera relevante gracias a la utilización de una infraestructura común, mediante la cual, es posible compartir, procesar y transferir información de forma sencilla, a partir de una serie de principios de vinculación de datos definidos por (Bizer, Heath, & Berners-Lee, Bizer, Heath et al. 2009 – Linked data-the story so far, 2009).

La motivación de la siguiente propuesta de investigación es tratar de identificar los niveles de confianza que cuentan los recursos digitales basados en principios de Linked Data, mediante una representación gráfica clara y fácil de

entender apoyados a través de principios basados en Web of Trust (Richardson, Agrawal, & Domingos, 2003).

El propósito como tal es definir un mecanismo informático a través de sistemas multi-agentes para identificar niveles de confianza de contenidos digitales, para localización de materiales y recursos fiables con opciones de mejorar la capacidad de reutilización y la calidad de estos contenidos.

Con el crecimiento de Internet y la publicación de contenidos cada segundo, se hace necesario crear nuevas herramientas tecnológicas que permitan la organización de los datos para que puedan aportar mayor conocimiento y sean fácilmente consultables por los usuarios de Internet. Por esto desde 2001 surgen conceptos como la Web 3.0, Web Semántica o Web de los Datos, pero es realmente en los últimos años que se empiezan a unir esfuerzos para implementar estos conceptos, dado lo abstracto del concepto y uso de herramientas para tal fin. Estas propuestas se han visto revitalizadas por iniciativas como Open Data, que busca colocar datos de interés general públicos en Internet. Es así como organizaciones p.e. *The Open Government partnership* en 2011 (Bauer & Kaltenböck, 2011), propuesta conformada por gobiernos de diferentes países, han definido una serie de políticas para organizar, clasificar y publicar información pública sobre Internet. Otras organizaciones privadas como Wikipedia, ponen a disposición repositorios semánticos con recursos enlazados como DBpedia (Lehmann, et al., 2015). Así como estas propuestas, existen organizaciones y proyectos tales como: CKAN (Francined Herrera-Cubides, Alonso Gaona-Garcia, & Gordillo-Orjuela, 2017), DBPedia (Aslam & Aljohani, 2017) , agINFRA (Drakos, Protonotarios, & Manouselis, 2015), Europeana (Isaac & Haslhofer, 2013), entre otros, dedicadas a la publicación de datos abiertos algunos enlazados otros no, utilizando diferentes estándares, formatos, etc, dificultando el acceso a toda la información disponible. Esta heterogeneidad de estándares, formatos y métodos de consulta hace de este campo una fuente para la realización de proyectos, como el presente, el cuál plantea una posible solución a algunos de

los problemas persistentes al consultar y presentar la información obtenida de repositorios de datos abiertos enlazados.

Teniendo en cuenta que la disponibilidad de herramientas y modelos de consulta sobre la Web Semántica, repositorios de Datos Abiertos Enlazados son pocos para la consultar y evaluar la cantidad de contenidos que se publican diariamente con diferentes formatos y plataformas, esto nos lleva a plantear la siguiente pregunta:

¿Cómo a partir de un modelo basado en multi-agentes se puede facilitar la identificación de recursos abiertos bajo principios de niveles de confianza Web Of Trust sobre datos abiertos mediante especificaciones definidas en Datos Abiertos Enlazados?

3. JUSTIFICACIÓN

Ante la cantidad de información disponible en Internet y la aparición de nuevas tendencias que buscan apertura de datos de interés público a través de Internet, se hace necesarios nuevos mecanismos de búsqueda y consulta de información relevante para el usuario que la necesita. En los últimos años se han realizado esfuerzos en el desarrollo de metodologías, modelos y herramientas de consulta, clasificación y evaluación de estos contenidos sin existir aun una solución definitiva a las problemáticas que trae consigo esta nueva tendencia (Gaona García, Montenegro Marin, & Herrera Cubides, 2022), (Herrera, 2021)). Por esto se define este proyecto, cuya utilidad práctica se orienta en plantear un modelo que pueda llegar a identificar en gran medida las dificultades con los que cuentan los usuarios de la Web 3.0 que desean contar con información mediante el uso de repositorios de datos abiertos enlazados, y una forma de navegar entre repositorios sin preocuparse por la heterogeneidad de formatos y organización de contenidos y su disponibilidad.

Mientras que el volumen de información disponible crece a cada segundo, los sistemas que procesan esta información deben evolucionar al mismo nivel para lograr presentar resultados actualizados sobre una consulta realizada y que dichos resultados se clasifiquen y evalúen en términos de su completitud y relevancia. Los buscadores como google cumplen con algunas características mencionadas, pero dejan de lado el componente semántico que permite la inferencia de conocimiento y el procesamiento automático por parte de sistemas computacionales, es cuando se hace necesario desarrollar nuevas alternativas a las ya presentes. Es ahí donde se encuentra la utilidad metodológica de este proyecto que brinda un mecanismo de evaluación de Datos Abiertos Enlazados, sobre repositorios que publican sus datos bajo estos principios.

4. OBJETIVOS

4.1 OBJETIVO GENERAL

Diseñar un modelo basado en un sistema multi-agente para la clasificación de recursos vinculados basados en niveles de confianza y especificaciones Linked Open Data.

4.2 OBJETIVOS ESPECÍFICOS

- Identificar criterios de evaluación de niveles de confianza para clasificar recursos vinculados bajo especificaciones Linked Open Data.
- Definir una ontología que permita identificar los criterios de confianza sobre un recurso vinculados mediante LOD.
- Plantear modelo basado en sistema multi-agente que permita realizar clasificación de recursos vinculados.
- ¿Cómo validar el modelo mediante el uso de herramientas de consulta que permita desplegar la clasificación de recursos vinculados de acuerdo con el nivel de confianza?

CAPÍTULO II

MARCO DE REFERENCIA

1. MARCO TEÓRICO

En la actualidad existen varios ejemplos que permiten el uso de datos vinculados en diferentes áreas de conocimiento. Es así como, por ejemplo, en el campo de la educación, la vinculación de los recursos educativos de diferentes repositorios de conocimiento útil en la Web, permite el intercambio, la búsqueda y la navegación de objetos de aprendizaje (Gaona-García, Fermoso-García, & Sánchez-Alonso, 2017). Varios proyectos como Europeana (Isaac & Haslhofer, 2013), LinkedUp (LinkedUp project, s.f.), (d'Aquin, y otros, 2014), y Linked Education (Dietze, y otros, 2012), así como iniciativas para compartir datos abiertos educativos (Guy, 2016) han adoptado el enfoque de Linked Data y su objetivo responde a vincular conjuntos de datos educativos.

Sin embargo, existen dificultades para determinar la confiabilidad de los recursos que se vinculan a través de Datos Enlazados; estas dificultades se han planteado a partir de métodos de seguridad basados en firmas y certificados digitales (Search for a Dataset, s.f.) (Enayat Rajabi, Kahani Mohsen, 2012), en principios de confianza (Cubides, García, Marín, & Capera, 2019) (Gaona-García P. , Herrera-Cubides, Alonso-Echeverri, Riaño-Vargas, & Gómez-Acosta, 2018) y retos basados en privacidad y seguridad de los mismos (Kirrane, Villata, & D'Aquin, 2018) (McNett, 2020). No obstante identificar esos niveles de confianza mediante una interfaz de navegación a través de repositorios como Datahub (Cimiano, Chiarcos, McCrae, & Gracia, 2020), o nube de datos abiertos enlazados (Cimiano, Chiarcos, McCrae, & Gracia, 2020) no ha sido fácil de identificar y aplicar. Algunas propuestas como (Martin-Moncunill, Garcia, & Rajabi, 2015), han tratado de determinar interfaces que faciliten la navegación a través de Datos Enlazados en la nube de datos abiertos enlazados. Autores como (Espinosa, Garriga, Zubcoff, & Mazón, 2014), presentan alternativas de acceso a recursos vinculados mediante minería Web, obteniendo como resultado una complementación mutua entre ésta y la Web Semántica.

Asociados a niveles de confianza, en la literatura se encuentran estudios como por ejemplo (Richardson, Agrawal, & Domingos, 2003), donde se identifica la subjetividad al definir niveles de confianza por cada usuario, por ello, se proponen métodos para la asignación correcta de confianza entre usuarios. Por su parte en (Tamez, Woungang, Lilien, & Denko, 2009) plantean una solución basada en Web Semántica para el manejo de confianza en Opportunistic Sensor Networks (oppnets), que tiene como resultado un modelo para la toma de decisiones en términos de seguridad sobre este tipo de topologías. De igual forma (Golbeck, Golbeck 2006 – Trust on the world wide, 2006), definen tres objetivos fundamentales de confianza en la Web: contenido, servicios y personas. Finalmente se resalta el trabajo realizado por (Ceolin, y otros, 2016) donde se expande el concepto del origen de confianza en un sistema, agregando que no solo debe proceder de la reputación del usuario (Gordo & Soto, 2007) sino también de varios frentes, principalmente, de la procedencia como tal.

A partir de estos referentes, la siguiente propuesta se orienta a presentar un modelo multi-agentes que permita navegar sobre repositorios de Datos Abiertos Enlazados de manera gráfica, y defina un mecanismo que permita identificar si los recursos que se están navegando cumplen con un principio de confianza básico para determinar su grado de confiabilidad a partir de Web of Trust (Bizer, Heath, & Berners-Lee, Bizer, Heath et al. 2009 – Linked data-the story so far, 2009).

En los siguientes puntos se definen los conceptos clave que se utilizan en el desarrollo del documento.


1.1 WEB SEMÁNTICA

Con el crecimiento del uso de Internet y el desarrollo desmedido de páginas, aplicaciones y contenidos para este medio, también se generaron necesidades como la interoperabilidad entre plataformas, heterogeneidad y la

automatización en el procesamiento de contenidos. Es aquí donde la Web semántica empieza a jugar un papel importante en el desarrollo de estas aplicaciones, siendo promovida por las organizaciones que vigilan el cumplimiento de estándares en la web.

Que es la WEB Semántica

La Web Semántica es una Web extendida dotada de significado. Aparece en el año 2000, y busca la introducción explícita de significado de los recursos y servicios que se encuentran en la Web, también describir las relaciones que existen entre estos recursos de tal forma que estas descripciones puedan ser procesadas a nivel computacional (Castells, 2003). La Figura 1 representa el modelo de capas definido por (Berners-Lee, Hendler, Lassila, & others, 2001) para la Web semántica.



*Figura 1: Modelo de capas propuesto por Berners-Lee para la Web Semántica
(Berners-Lee, Hendler, Lassila, & others, 2001)*

La Web Semántica está dividida en capas. La primera capa está compuesta por estándares que permitan la ubicación de los recursos en Internet: URI's (*uniform resource identifier*) y formato UNICODE. XML como base sintáctica para estructurar el contenido de Internet y *namespaces* para relacionar los elementos y sus propiedades. En la tercera capa utiliza un modelo para describir las propiedades de los recursos, RDF nos provee las herramientas para describir clases, objetos propiedades, entre otros. En la siguiente capa se encuentran los modelos ontológicos, el cual nos ayuda a describir el área del conocimiento en la que estamos trabajando. Luego de estas capas tenemos una capa lógica donde se realizan consultas y aserciones sobre los modelos, y por último una capa de seguridad basada en niveles de confianza (Gordo & Soto, 2007).

Estas descripciones se representan a través de una red de nodos interconectados por una serie de clases y relaciones definidas por una ontología. El estándar más popular entre la comunidad de la Web semántica es RDF (Resource Description Framework), y es un lenguaje basado en XML, utilizado para la descripción de recursos dentro de la Web (Castells, 2003).

1.2 LENGUAJES Y ESTANDARES

En la Web semántica se utilizan lenguajes para dotar de significado a los recursos que se encuentran dentro de ésta, en diferentes niveles o capas de esta (RDF, OWL, SPARQL, WSDL, entre otros). Cada uno de estos lenguajes se utiliza ya sea para modelar o realizar consultas sobre modelos semánticos desarrollados para una determinada área del conocimiento. El uso de cada lenguaje depende de la plataforma y la arquitectura que se va a utilizar en el producto que se está desarrollando. En este capítulo se nombran algunos de los lenguajes y estándares más utilizados.

1.2.1 XML

Recibe su nombre por sus siglas en ingles **eXtensible Markup Language**, lenguaje de marcas extensible. Contrario a lo que indica su nombre, no es un lenguaje de marcar, es un conjunto de reglas para crear lenguajes de marcas, un metalenguaje. Es un sub-conjunto de SGML (Estándar Generalised Mark-up Language) desarrollado por Charles Goldfarb en 1969 (Bosch, 2001) y del cual nacieron otros lenguajes de marcas importantes para el desarrollo de Internet como HTML. La ventaja principal del XML es su extensibilidad, ya que permite la definición de etiquetas y atributos personalizados para organizar la información.

Al ser un estándar internacional, el XML ha tomado gran importancia gracias a su uso en la estructuración de información en internet, a la interoperabilidad entre diferentes sistemas de software que utilizan este estándar para comunicarse por su facilidad de transmisión, almacenamiento y visualización.

Los componentes de un documento XML son:

- **Elementos:** Pieza lógica del marcado, se representa con una cadena de texto (dato) encerrada entre etiquetas. Pueden existir elementos vacíos (
). Los elementos pueden contener atributos.
- **Instrucciones:** Ordenes especiales para ser utilizadas por la aplicación que procesa
<?xml-stylesheet type="text/css" href="estilo.css">

Las instrucciones XML. Comienzan por <? Y terminan por ?>.

- **Comentarios:** Información que no forma parte del documento. Comienzan por <!-- y terminan por -->.
- **Declaraciones de tipo:** Especifican información acerca del documento:
<!DOCTYPE persona SYSTEM "persona.dtd"> **Secciones CDATA:**
Se trata de un conjunto de caracteres que no deben ser interpretados

por el procesador. La Figura 2 ejemplifica la estructura de un documento XML.




Figura 2: Estructura de un documento XML

1.2.2 RDF y RDF Schema

"Resource Descriptoin Framework" (RDF), es un modelo estándar desarrollado por el W3C para el intercambio de datos en la Web. Se caracteriza por permitir la unión entre diferentes esquemas, y la evolución de un esquema a través del tiempo, sin necesidad de modificar los consumidores de los datos. Extiende la estructura de enlaces de la Web utilizando URIs (Uniform Resource Identifier) para nombrar las relaciones entre objetos. El elemento más importante dentro de RDF es el predicado "*rdf:type*" que describe si un recurso es de un determinado tipo (RDF Working Group, 2014).

Por otro lado, *RDF Schema* provee un vocabulario de modelado de datos extendido del vocabulario básico RDF. Este vocabulario provee los conceptos de sujeto, objeto, predicado, de tal manera que se pueden construir enunciados acerca de clases de elementos y tipos de relaciones. Provee mecanismos para describir grupos de recursos relacionados y las relaciones entre estos recursos. Los recursos que provee RDFS son utilizados para determinar características de otros recursos como el rango o el dominio de sus propiedades (Brickley & Guha, Brickley, Guha 2014 – RDF Schema 1.1, 2014).

1.2.3 SPARQL

SPARQL es un lenguaje de consulta de grafos RDF, tiene la capacidad de realizar consultas sobre patrones de grafos opcionales u obligatorios a través de sus conjunciones o disyunciones. Existen dos versiones de este lenguaje, la versión 1.0 y 1.1, siendo la 1.0 la recomendada oficialmente por el W3C (World Wide Web Consortium) para la consulta de datos sobre RDF. Las consultas SPARQL pueden devolver sets de resultados como patrones RDF. (Prud'Hommeaux, Seaborne, & others, 2008)

Como lo muestra la Figura 3 SPARQL contiene dos partes, un lenguaje de consulta sobre RDF, y un protocolo que describe como hacer las consultas y obtener los resultados.

```
Abreviaturas
PREFIX rdfs: <http://www.w3.org/2000/01/rdf-
schema#>
...
PREFIX dbpedia: <http://dbpedia.org/resource/>
select ?s ?p ?o                                Resultados
from http://dbpedia.org                Origen
where {
  ?s rdfs:label "Raiders of the Lost Ark"@en .
  ?s ?p ?o                                     Patrones de Grafo
}
order by ?s
limit 100                                     Modificadores
```

Figura 3: Anatomía de una consulta SPARQL (Della Valle & Ceri, 2011)

- **Abreviaturas:** pueden ser espacios de nombres, o cualquier dirección conveniente para abreviar una consulta.
- **Resultados:** son las variables de las cuales deseamos obtener el resultado, el origen es un URI que contiene uno o más grafos dirigidos sobre los que se realiza la consulta
- **Patrones de grafos:** es un emparejamiento de patrones, escritos en *turtle* (Lenguaje para escribir tripletas de la forma sujeto-predicado-objeto donde cada termino esta denotado por un URI), en el caso de la figura anterior consultamos cualquier sujeto (?s) , cualquier predicado (?p) y cualquier objeto (?o)

1.2.4 OWL

OWL es el último lenguaje estándar para ontologías del W3C (McGuinness, van Harmelen, & others, 2004) y se divide en 3 tipos:

- OWL-Lite: Es el lenguaje más simple sintácticamente, su intención es ser usado cuando se necesita una simple jerarquía de clases y constantes simples son necesarias.
- OWL-DL: Es mucho más expresivo que el OWL-Lite, y está basado en lógica descriptiva. Este lenguaje permite la computación automática.
- OWL-Full: es el más expresivo de los lenguajes, pero dificulta el razonamiento autónomo sobre este.
- OWL-Full: es el más expresivo de los lenguajes, pero dificulta el razonamiento autónomo sobre este.

1.3 SISTEMA MULTI-AGENTES

Son sistemas compuestos por múltiples elementos computacionales que interactúan entre si llamados agentes (Wooldridge, 2009). Un agente tiene dos características principales:

- Autonomía: un agente actúa de manera autónoma y toma sus propias decisiones para satisfacer el objetivo para el que fue programado.
- Interacción: un agente tiene un comportamiento social, e interactúa con otros agentes de diferentes formas (cooperación, coordinación, negociación, entre otros).

Un agente actúa de acuerdo con la interacción con el entorno: percepción – decisión – acción – percepción – decisión. Este actuar debe ser flexible (reactivo, proactivo y social).

En el diseño de un Sistema Multi-Agentes se debe tener en cuenta el objetivo de cada individuo y del sistema completo, que cumple con sus objetivos gracias a la interacción entre los agentes.

FIPA (Foundation for Intelligent Physical Agents) define la arquitectura que debe tener un sistema multi-agente:

- Directorio de agentes: define los agentes disponibles y su dirección.
- Directorio de servicios: registra los servicios que prestan los agentes
- Mecanismo de transporte de mensajes: Se encarga de enviar los mensajes a los agentes.
- Lenguaje de comunicación de agentes: define los posibles mensajes que pueden enviar los agentes.

2. ESTADO DEL ARTE

Desde la presentación de la propuesta de una web de contenidos enlazados realizada por Berners Lee (Bizer, Heath, & Berners-Lee, Bizer, Heath et al. 2009 – Linked data-the story so far, 2009), se abrió una amplia línea de investigación que busca mejorar en varios aspectos esta web de los datos. En este proyecto se trabajan principalmente 2 aspectos importantes de la Web de los datos. El primero es la confiabilidad de los recursos publicados mediante Datos Abiertos Enlazados y la segunda el asertividad en la búsqueda datos. A continuación, se presenta el resumen de los trabajos en que se basa el proyecto, empezando por los modelos de confiabilidad y calidad en Datos Abiertos enlazados, y posteriormente las técnicas de búsqueda indexación y recuperación de Datos Abiertos Enlazados.

2.1 MODELOS DE CONFIABILIDAD Y CALIDAD DE DATOS ABIERTOS ENLAZADOS

En el primer aspecto se identificaron 2 trabajos relevantes que tratan la calidad o confiabilidad de los sets de datos publicados mediante LOD el primero describe 21 propuestas de evaluación de calidad en datos enlazados realizadas entre 2002 y 2016, el segundo es una propuesta realizada en 2014:

2.1.1 Metodologías de evaluación de calidad para datos abiertos enlazados

En este trabajo presentado en (Zaveri, y otros, 2013), se comparan 21 propuestas filtradas de 118 artículos relevantes. Estas 21 propuestas son comparadas de acuerdo con 4 criterios:

- Terminología común relativa a calidad de datos
- 26 dimensiones de calidad de datos enlazados y su definición formal
- Métricas para cada dimensión junto con la distinción de si son objetivas o subjetivas
- Metodologías y soporte de herramientas utilizadas para evaluar la calidad




Figura 4: Dimensiones de calidad de datos enlazados 1 (Zaveri, y otros, 2013)

En la Figura 4, se muestra las 26 dimensiones y su clasificación. Las dimensiones de calidad se clasifican en:

- **Dimensiones de contexto:** Dependen del contexto de la tarea y las preferencias subjetivas del consumidor de los datos.
- **Dimensiones de confianza:** Se enfocan en la confianza o integridad de los conjuntos de datos
- **Dimensiones intrínsecas**
- **Dimensiones de accesibilidad**
- **Dinamicidad del conjunto de datos**

Teniendo en cuenta el objetivo del software realizado se hizo énfasis en el análisis de las dimensiones de confianza.

Las dimensiones de confianza son aquellas que se enfocan en la confianza o integridad de los conjuntos de datos. Las 5 dimensiones que confirman este grupo son:

- **Procedencia:** Esta dimensión se refiere a los metadatos para representar, administrar y usar información acerca del origen de los datos. Las métricas para la procedencia se pueden obtener evaluando los metadatos asociados a la fuente.
- **Verificabilidad:** Esta dimensión se refiere al grado con el que un consumidor de datos puede evaluar si conjunto de datos es correcto y como consecuencia su integridad. Puede ser medida por un tercero, si el conjunto de datos esta enlazado a la fuente o con la presencia de una firma digital.
- **Reputación:** Según Es un juicio realizado por un tercero y que determina la integridad de un autor, ya sea una persona u organización. La entidad que publica los datos debe ser identificable por algún medio. Puede ser evaluada a través de encuestas a la comunidad o enlaces externos.
- **Credibilidad:** Grado en el que se acepta la información como correcta, real, verdadera y creíble.
- **Licenciamiento:** Esta dimensión garantiza la posibilidad de reutilización de los datos por parte de un consumidor. Se puede medir a través de la descripción de permisos de reutilización.

Todas las dimensiones de confianza están relacionadas con la credibilidad y si la medida de sus métricas es alta esto implica que la credibilidad también es alta.

A continuación, se presenta un resumen de las dimensiones de confianza y sus métricas.

- **Procedencia**
 - Metadatos acerca del conjunto de datos: Presencia de título, contenido y URI del conjunto de datos (Flemming, 2010) en (Zaveri, y otros, 2013, pág. 10).
 - Calculo personalizado de recomendaciones de confianza: Usando procedencia de anotaciones de confianza en redes sociales (Golbeck & Mannes, Golbeck, Mannes 2006 – Using Trust and Provenance, 2006) en (Zaveri, y otros, 2013, pág. 10).
 - Cálculo de la integridad/confiabilidad de las sentencias RDF: Calculando un valor de confianza entre -1 (Desconfianza absoluta) y 1 (Confianza absoluta). Calculando la confianza basada métodos de calificación de usuarios o basado en opciones (Hartig, 2008) en (Zaveri, y otros, 2013, pág. 10).

- Detectar la confiabilidad y credibilidad de la persona que publica (Hartig, 2008) en (Zaveri, y otros, 2013, pág. 10).
 - Nivel de confianza para la gente que conoce la persona en un nivel de 1 a 9 (Hendler, Golbeck, & Parsia, 2006) en (Zaveri, y otros, 2013, pág. 10).
 - Cálculo de la confianza de una entidad: Construcción de redes de decisión informadas por grafos de procedencia (Gamble & Goble, 2011) en (Zaveri, y otros, 2013, pág. 10).
 - Exactitud en el cálculo de confianza entre dos entidades: Utilizando el algoritmo de propagación que utiliza técnicas estadísticas para calcular los valores de confianza entre dos entidades a través de un camino, o un algoritmo de agregación basado en un mecanismo de pesos para calcular el valor agregado de confianza sobre todos los caminos (Shekarpour & Katebi, 2010) en (Zaveri, y otros, 2013, pág. 10).
 - Adquisición de contenido de confianza de usuarios: Se basa en la asociación que transfiere confianza de entidades a recursos (Gil & Artz, Gil, Artz 2007 – Towards content trust of web, 2007) en (Zaveri, y otros, 2013, pág. 10).
 - Detección de integridad, confianza, y credibilidad de una fuente de datos: Uso de anotaciones de confianza realizadas por varios individuos para determinar la integridad, confianza y credibilidad de las fuentes (Gil & Ratnakar, Gil, Ratnakar 2002 – Trusting information sources one citizen, 2002) en (Zaveri, y otros, 2013, pág. 10).
 - Asignar valores de confianza a datos, fuentes y reglas: Utilizar ontologías de confianza que asignen valores de confianza según el contenido o los metadatos que puedan ser transferidos de datos conocidos a datos desconocidos (Jacobi, Kagal, & Khandelwal, 2011) en (Zaveri, y otros, 2013, pág. 10).
 - Determinando valores de confianza para los datos: Utilizando anotaciones para datos como blacklisting, authoritativeness, ranking y utilizar razonamiento para incorporar valores de confianza a los datos (Bonatti, Hogan, Polleres, & Sauro, 2011) en (Zaveri, y otros, 2013, pág. 10).
- **Verificabilidad**

- Verificación información de persona que publica: Indicando el autor, sus contribuyentes, el publicador de los datos y sus fuentes (Flemming, 2010) en (Zaveri, y otros, 2013, pág. 10).
- Verificación autenticidad del conjunto de datos: Si el conjunto de datos utiliza vocabulario de procedencia (Flemming, 2010) en (Zaveri, y otros, 2013, pág. 10).
- Verificación conjunta de datos es correcto: con la ayuda de terceras partes confiables e imparciales (Flemming, 2010) en (Zaveri, y otros, 2013, pág. 10).
- Verificación uso de firmas digitales: firmando un documento RDF o firmando un grafo RDF (Flemming, 2010) en (Zaveri, y otros, 2013, pág. 10).
- **Reputación**
 - Reputación del publicador: Encuesta en una comunicad acerca de otros (Bizer, Bizer 2007 – Quality driven information filtering, 2007) en (Zaveri, y otros, 2013, pág. 10).
 - Reputación del conjunto de datos: Analizando referencias en posicionamiento de páginas asignando un puntaje de reputación al conjunto de datos (Flemming, 2010) en (Zaveri, y otros, 2013, pág. 10).
- **Credibilidad**
 - Metainformación acerca de la identidad del proveedor de la información: verificar si el proveedor/contribuidor está contenido en una lista de proveedores de confianza (Gil & Artz, Gil, Artz 2007 – Towards content trust of web, 2007) en (Zaveri, y otros, 2013, pág. 10).
- **Licenciamiento**
 - Indicación de licencia en formato entendible por maquinas: Detección de indicación de licencia en la descripción void (Mendes, Mühleisen, & Bizer, 2012) en (Zaveri, y otros, 2013, pág. 10).
 - Indicación de licencia en formato entendible por humanos: Detección de licencia en la documentación del conjunto de datos o su fuente (Bizer, Bizer 2007 – Quality driven information filtering, 2007) en (Zaveri, y otros, 2013, pág. 10).
 - Permisos para usar el conjunto de datos: detección de licencia indicando si la reproducción, distribución, modificación o

redistribución es permitido (Flemming, 2010) en (Zaveri, y otros, 2013, pág. 10).

- Indicación de atribución: Detección de si el trabajo es atribuido de la misma forma como es indicado por el autor o quien licencia (Flemming, 2010) en (Zaveri, y otros, 2013, pág. 10).
- Indicación de copyleft o sharealike: Verificar si el contenido derivado tiene la misma licencia del contenido original (Flemming, 2010) en (Zaveri, y otros, 2013, pág. 10).

2.1.2 Evaluación de calidad de datos enlazados dirigida por pruebas

Descrita en (Kontokostas, y otros, 2014), esta propuesta presenta una metodología que utiliza casos de prueba para determinar la calidad de recursos de datos enlazados basados restricciones de integridad. Este modelo se caracteriza principalmente por ser automatizado y extensible a conjuntos de datos de gran tamaño.

El modelo ideado utiliza un enfoque basado en patrones para probar la calidad las bases del conocimiento RDF. Definen un patrón de prueba de calidad de los datos "Data Quality Test Pattern (DQTP)" como una tupla (V, S) donde V corresponde a un conjunto de variables de patrón definido, y S una plantilla de consulta SPARQL con los parámetros para recibir las variables de V.

```
SELECT ?s WHERE { ?s %% P1 %% ?v1 .  
2 ?s %% P2 %% ?v2 .  
3 FILTER ( ?v1 %% OP %% ?v2 ) }
```

Código 1: Plantilla de consulta SPARQL (Kontokostas, y otros, 2014)

En el fragmento de código Código 1 se muestra un ejemplo de una plantilla de consulta SPARQL donde %%v%% representa un parámetro. En el caso de esta plantilla, determina si el valor de dos propiedades P1 y P2 se mantiene con respecto a un operador OP.

Una de las ventajas que los autores destacan en este enfoque es la generación automática de casos de prueba a partir de un modelo similar al que utilizan los razonadores como *Pellet*, para verificar la calidad de los datos validando las restricciones de integridad haciendo uso de axiomas definidos en la base de conocimiento.

```
SELECT DISTINCT ?T1 ?T2 WHERE { ?T1 owl : disjointWith ?T2 . }
```

Código 2: Selecciona todas las clases que son disyuntas (Kontokostas, y otros, 2014)

La generación automática de casos de prueba consiste en dos partes, la primera de detección es una consulta SPARQL al esquema y la segunda una ejemplificación del caso de prueba para cada resultado de la primera.

```
SELECT DISTINCT ?s WHERE {  
  ?s rdf : type %% T1 %% .  
  ?s rdf : type %% T2 %% .}
```

Código 3: Patrón para ejemplificación de caso de prueba (Kontokostas, y otros, 2014)

La metodología propuesta por los autores se muestra en la Figura 5 2:




Figura 5: Metodología basada en casos de prueba para calidad de los datos 2 (Kontokostas, y otros, 2014)

A la izquierda del diagrama podemos ver la fuente de entrada de la librería de patrones. Los autores describen 5 formas de crear los casos de prueba:

1. Utilizar restricciones RDFS/OWL, utilizando casos de prueba autogenerados.
2. Enriquecimiento RDFS/OWL, cuando las colecciones de datos no cuentan con la información suficiente en el esquema se pueden sugerir axiomas de esquema con cierto nivel de confianza a través de un análisis del conjunto de datos.
3. Reutilizar casos de prueba basados en vocabularios comunes
4. Ejemplificar patrones de prueba de calidad de datos existentes
5. Crear nuevos patrones de prueba de calidad de datos existentes

En medio del diagrama se observan las diferentes formas de ejemplificación de patrones que dirigen Los casos de prueba de calidad de datos mostrados a la izquierda.

Finalmente, los autores presentan un ejemplo de la implementación de la metodología y la definición de algunos patrones que pueden ser consultados en el documento.

2.2 BÚSQUEDA, INDEXACIÓN Y CLASIFICACIÓN DE RECURSOS LOD

Existen diversas propuestas de técnicas de indexación y clasificación de datos abiertos enlazados, todas con una arquitectura similar y componentes comunes en su definición. En esta sección se describen brevemente dos de las más relevantes que permitan dar bases para llevar a cabo este proceso. En este orden de ideas, se presenta Sindice.com, una propuesta de búsqueda por índices orientada a documentos para datos abiertos enlazados realizado por (Oren, y otros, 2008); y la herramienta SWSE (*Semantic Web Searching Engine*), la cual permite realizar una búsqueda y vistazo de datos enlazados. A continuación, se describen en detalle.

2.2.1 Sindice.com: Una propuesta de búsqueda por índices orientada a documentos para datos abiertos enlazados

En el primer caso se describe la construcción del API desarrollado y publicado en sindice.com entre 2007 y 2014, que buscaba resolver la pregunta “Cómo y dónde encontrar enunciados acerca de ciertos recursos”. Este servicio permitía encontrar las fuentes de información que mencionaran un recurso permitiendo realizar búsquedas por palabra clave, Propiedad Funcional inversa o URI. La Figura 6 Presenta la arquitectura propuesta por (Oren, y otros, 2008) para un sistema de búsqueda sobre recursos LOD.




Figura 6: Síndice, Arquitectura propuesta 3 (Oren, y otros, 2008)

Esta arquitectura presenta una serie de componentes individuales organizados en tubería donde cada uno entrega un producto para que el siguiente componente lo procese y continúe el proceso.

Funcionalidad

La búsqueda: se realiza como un motor de búsqueda tradicional por palabra clave, consta de los pasos:

1. **Indexación:** Se indexan documentos o "*SPARQL Endpoints*"
2. **Búsqueda por URI:** Busca recursos con una Uri determinada y devuelve una lista de fuentes donde el recurso aparece
3. **Búsqueda por propiedad funcional inversa:** busca recursos donde se cumpla una condición de propiedad = valor y devuelve listado de ocurrencias
4. **Búsqueda textual:** encuentra los recursos que contienen un termino

Requerimientos no funcionales

1. Minimizar el tamaño de los índices

2. Reducir el número de búsquedas
3. Mantener los índices enlazados

Indexación

La indexación se realiza a través de la extracción de grafos de una fuente de indexación, chequeo de la ontología por un rastreador, y procesamiento de grafos utilizando un razonador para obtener los índices. En la Figura 7, se presenta el proceso de indexación propuesto por (Oren, y otros, 2008), se pueden identificar las tareas necesarias para obtener los índices.




Figura 7: Proceso indexación (Oren, y otros, 2008)

2.2.2 Búsqueda y navegación de datos enlazados utilizando SWSE (Semantic Web Searching Engine)

En este caso los autores describen el proceso de desarrollo de un motor de búsqueda en la web semántica, con una arquitectura similar a la propuesta en el caso anterior. La Figura 8 presenta el proceso definido en la arquitectura del motor de búsqueda propuesto por (Hogan, y otros, 2011)




Figura 8: Arquitectura SWSE (Hogan, y otros, 2011)

Como se puede ver en la Figura 8 **Error! Reference source not found.** hay una estructura con varios componentes donde cada uno realiza una tarea y entrega una salida a la entrada del siguiente. La entrada de esta aplicación es una serie de URIs semilla para realizar un rastreo en el componente rastreador, luego en el componente de consolidación se realiza una búsqueda de sinónimos y equivalencias, luego se puntúan los recursos encontrados de acuerdo con su importancia teniendo en cuenta el número de redirecciones, el componente razonador materializa nuevos datos de la semántica heredada y finalmente el indexador prepara los datos que se necesitan en la consulta desde la interfaz.

Este sistema propone una interfaz web para la consulta sobre el repositorio de índices, y una arquitectura distribuida para los componentes de rastreo consolidación, puntuación e indexación.

Con base en este contexto, la siguiente sección permite llevar a cabo el planteamiento del diseño y desarrollo de la propuesta en mención.

CAPÍTULO III

DISEÑO Y DESARROLLO

1. METODOLOGÍA

En la primera etapa del desarrollo de este proyecto, se utilizó un método cuasi experimental para llevar a cabo la consulta de recursos LOD disponibles en Internet, y así lograr identificar los metadatos asociados a las dimensiones de confianza y la evaluación de las métricas definidas para evaluación de calidad sobre repositorios Linked Open Data tal como se exponen en (Herrera-Cubides, Gaona-García, Montenegro-Marín, & Sánchez-Alonso, Improving OER descriptions to enhance their availability, reuse, and enrichment, 2022); (Gaona-García, Feroso-García, & Sánchez-Alonso, Exploring the relevance of Europeana digital resources: preliminary ideas on Europeana metadata quality, 2017)). Para llevar a cabo evaluación de métricas, se tomaron como base las dimensiones de calidad de datos enlazados definidas en (Zaveri, y otros, 2013), así como evaluación basada en reglas de inferencia propuestas por (Gaona-García P. A., Herrera-Cubides, Riaño, Alonso, & Gómez-Acosta, 2019); (Herrera-Cubides, Gaona-García, Montenegro-Marín, Arias-Caracas, & Mendoza-López, Use of fuzzy logic as a strategy to evaluate trust and accessibility of DataSet published in SPARQL Endpoints, 2018).

De los trabajos identificados en Estado del Arte, el que recopila dimensiones y métricas de confianza es el expuesto por (Zaveri, y otros, 2013). Por esto se tomaron como referencia únicamente las dimensiones de confianza y sus métricas teniendo en cuenta los objetivos definidos en el apartado 2.2.1. Para cada métrica se extrajeron los metadatos y se realizó una búsqueda y selección de ontologías que permitieran evaluar la presencia o ausencia de estos criterios, o cálculos de confianza. El resultado final de este proceso se resume en la Tabla 1:

Tabla 1: Ontologías para identificación de métricas de confianza

METADATOS	ONTOLOGIA PREDICADO	METRICAS
-----------	---------------------	----------

TÍTULO, CONTENIDO Y URI	http://purl.org/dc/terms/	Presencia de atributos Título contenido y uri utilizando la ontología de Dublin Core
RECOMENDACIONES DE CONFIANZA	http://xmlns.com/foaf/0.1/homepage	Calcula la confianza basada en la persona que emitió un concepto y sus relaciones de confianza con otras personas
INTEGRIDAD/ CONFIABILIDAD DE LAS SENTENCIAS RDF	http://trdf.sourceforge.net/trustvocab#TrustValue http://trdf.sourceforge.net/trustvocab#truster http://trdf.sourceforge.net/trustvocab#trustworthiness	Función de confianza se define por la plataforma que calificara el nivel de confianza, -1 (Desconfianza absoluta) y 1 (Confianza absoluta)
DETECTAR LA CONFIABILIDAD Y CREDIBILIDAD DE LA PERSONA QUE PUBLICA	http://xmlns.com/foaf/spec/	Se registrarán valores FOAF dentro de la plataforma extendiendo las relaciones entre datasets y autores
NIVEL DE CONFIANZA PARA LA GENTE QUE CONOCE LA PERSONA	http://xmlns.com/foaf/spec/	
CÁLCULO DE LA CONFIANZA DE UNA ENTIDAD	https://www.w3.org/TR/prov-o/ Ontología Extendida	Construcción de redes de decisión informadas por grafos de procedencia
EXACTITUD EN EL CÁLCULO DE CONFIANZA ENTRE DOS ENTIDADES	Ontología Extendida https://www.w3.org/TR/prov-o/	Microservicio Python para calcular el valor agregado de confianza
ADQUISICIÓN DE CONTENIDO DE CONFIANZA DE USUARIOS	https://www.w3.org/TR/prov-o/ Ontología Extendida	Calculo valor de confianza relaciones establecidas con Prov-o
DETECCIÓN DE INTEGRIDAD, CONFIANZA, Y CREDIBILIDAD DE UNA FUENTE DE DATOS	https://www.w3.org/TR/annotation-vocab/	Recuento anotaciones de confianza
ASIGNAR VALORES DE CONFIANZA A DATOS, FUENTES Y REGLAS	Ontología extendida	blacklisting, authoritativeness, ranking

DETERMINANDO VALORES DE CONFIANZA PARA LOS DATOS	http://xmlns.com/foaf/spec/ https://www.w3.org/TR/prov-o/	
VERIFICACIÓN INFORMACIÓN DE PERSONA QUE PUBLICA	http://xmlns.com/foaf/spec/ https://www.w3.org/TR/prov-o/	autor, sus contribuyentes, el publicador de los datos y sus fuentes
VERIFICACIÓN AUTENTICIDAD DEL CONJUNTO DE DATOS	https://www.w3.org/TR/prov-o/	Verificación contiene datos de procedencia con la ontología definida
VERIFICACIÓN, CONJUNTO DE DATOS ES CORRECTO	https://www.w3.org/TR/annotation-vocab/	Recolección anotaciones estadísticas uso/consulta
VERIFICACIÓN USO DE FIRMAS DIGITALES	https://w3c-ccg.github.io/security-vocab/ Nota: Documento se encuentra en borrador no oficial con fecha de julio de 2022	Verificar si conjunto de datos tiene firma Digital
REPUTACIÓN DEL PUBLICADOR	http://xmlns.com/foaf/spec/ https://www.w3.org/TR/prov-o/	Crawing referencias
REPUTACIÓN DEL CONJUNTO DE DATOS	https://www.w3.org/TR/prov-o/	Crawlilg de referencias
METAINFORMACIÓN ACERCA DE LA IDENTIDAD DEL PROVEEDOR DE LA INFORMACIÓN	https://www.w3.org/TR/prov-o/ , Dublin Core	Implementaciones listas: Proveedores de confianza
INDICACIÓN DE LICENCIA EN FORMATO ENTENDIBLE POR MAQUINAS	https://www.w3.org/TR/void/	Detección de indicación de licencia en la descripción void
INDICACIÓN DE LICENCIA EN FORMATO ENTENDIBLE POR HUMANOS	https://www.w3.org/TR/void/	Detección de licencia en la documentación del conjunto de datos o su fuente
PERMISOS PARA USAR EL CONJUNTO DE DATOS	https://www.w3.org/TR/void/	detección de licencia indicando si la reproducción, distribución, modificación o redistribución es permitido

INDICACIÓN DE ATRIBUCIÓN	https://www.w3.org/TR/void/	Detección de si el trabajo es atribuido de la misma forma como es indicado por el autor o quien licencia
INDICACIÓN DE COPYLEFT O SHAREALIKE	https://www.w3.org/TR/void/	Verificar si el contenido derivado tiene la misma licencia del contenido original

Las ontologías seleccionadas bajo criterios de apartado 2.2.1, se importaron como base para la integración de una nueva Ontología, la cual se cargaron en el software Protege, lo cual permitió realizar una extensión para que de manera posterior se realizara una implementación del modelo.




Figura 9: Importación de Ontologías, descripción de métricas de confianza sobre Protege

Una vez realizada la evaluación en esta fase preliminar se utilizó un método teórico propuesto por (Nikraz, Caire, & Bahri, 2006) relacionado con el análisis y síntesis de los resultados. Lo anterior para plantear un modelo Multi agentes

que permita navegar en un espacio de recursos LOD y así extraer los metadatos definidos a través de las ontologías. Posteriormente a este proceso se procede a evaluar las métricas de calidad y almacenar los resultados asociados a las evaluaciones; lo anterior con el propósito de responder a consultas de usuarios basados en calidad de los conjuntos de datos.

Con base en este proceso, para el desarrollo del modelo multi agentes se utilizó la metodología propuesta en (Nikraz, Caire, & Bahri, 2006) para desarrollo de sistemas multi agentes junto con técnicas para identificación y desarrollo de microservicios para despliegue de soluciones con arquitectura moderna basadas en nube. Teniendo en cuenta que las arquitecturas de microservicios comparten características con los sistemas multiagentes, se implementó esta arquitectura ampliamente utilizada en otros escenarios ((Kravari & Bassiliades, 2019), (Salah, Zemerly, Yeun, Al-Qutayri, & Al-Hammadi, 2017)) para en el desarrollo de software actual.

Las características que comparten los agentes inteligentes y los microservicios son:

1. **Independencia y modularidad:** Tanto los agentes inteligentes de software como los microservicios se basan en la idea de dividir un sistema en componentes independientes y autónomos. Esto permite una mayor flexibilidad y escalabilidad, ya que cada componente puede ser desarrollado, desplegado y actualizado de manera independiente.
2. **Interacción y comunicación:** Tanto los agentes inteligentes como los microservicios están diseñados para interactuar y comunicarse con otros componentes o sistemas. Los agentes inteligentes pueden comunicarse entre sí para compartir información y tomar decisiones, mientras que los microservicios se comunican a través de interfaces bien definidas para intercambiar datos y realizar operaciones.

3. **Responsabilidad y autonomía:** Tanto los agentes inteligentes como los microservicios son responsables de realizar ciertas tareas o funciones de manera autónoma. Los agentes inteligentes toman decisiones basadas en su conocimiento y objetivos, mientras que los microservicios están diseñados para realizar una funcionalidad específica de manera independiente.
4. **Adaptabilidad y aprendizaje:** Los agentes inteligentes ser adaptativos y aprender de su entorno. Los agentes inteligentes pueden ajustar su comportamiento y tomar decisiones basadas en la retroalimentación y la experiencia, mientras que los microservicios deben ser actualizados y mejorados para adaptarse a las necesidades cambiantes.
5. **Escalabilidad y distribución:** Tanto los agentes inteligentes como los microservicios pueden ser escalados horizontalmente para manejar cargas de trabajo crecientes. Esto significa que se pueden agregar más agentes o microservicios para distribuir la carga y mejorar el rendimiento del sistema.
6. **Orientación a servicios:** Los microservicios se basan en la arquitectura de servicios, donde cada microservicio se centra en ofrecer una funcionalidad específica. De manera similar, los agentes inteligentes pueden estar diseñados para ofrecer servicios especializados, como la búsqueda, la planificación o la toma de decisiones.

A continuación, la Figura 10 muestra la metodología propuesta para el diseño del sistema multiagentes.




Figura 10: Metodología para el análisis y diseño de sistemas Multi-Agente (Nikraz, Caire, & Bahri, 2006)

En la gráfica anterior se muestra la metodología seleccionada para la creación del sistema multi-agentes, donde se pueden resaltar su ciclo de vida en cascada con las mismas etapas del desarrollo de software planeación, análisis, diseño implementación y pruebas. Así mismo se pueden identificar actividades relacionadas con la construcción de microservicios como definición de casos de uso, identificación de responsabilidades, especificación de la interacción. En el

punto 9 se aborda uno de los pasos más importantes para el ejercicio y es la definición de la Ontología que soportará el modelo planteado.

Por último, se entrega un prototipo del sistema multi agente para búsqueda de recursos LOD indexados y evaluados.

2. IMPLEMENTACIÓN DE ONTOLOGÍA PARA EVALUACIÓN DE NIVELES DE CONFIANZA SOBRE RECURSOS VINCULADOS MEDIANTE LOD

En este capítulo se describen paso a paso la aplicación de la metodología Methontology (Gómez-Pérez, Fernández-López, & Corcho, 2006), utilizada el desarrollo de la ontología propuesta en este documento, así como el resultado de cada tarea desarrollada en la metodología. Se seleccionó esta metodología ya que a pesar de tener más de 20 años sigue siendo vigente y abordado en literatura por varios trabajos como (Alsanad, Chikh, & Mirza, 2019), (Abanda, Kamsu-Foguem, & Tah, 2017).




Figura 11: Referencias a la metodología en artículos, fuente scopus

La **Error! Reference source not found.** muestra las referencias a la metodología Methontology desde el año 1999 hasta hoy generada a partir del análisis de resultados de búsqueda por referencias en scopus, donde se evidencia la vigencia de la metodología.

De conformidad con esta metodología, a continuación, se definen aspectos más relevantes para su estructuración, especificación y formalización de la ontología.

2.1 ESPECIFICACIÓN.

Tabla 2: Documento de Especificación de Ontología

Documento de Especificación de Requerimientos	
Dominio	http://www.semanticweb.org/k_mil/ontologies/2021/8/EvalLOD
Fecha	24/092021
Desarrollador	Camilo A. Valencia Martínez
Propósito	Ontología para definir métricas de confianza sobre recursos de Datos Enlazados
Nivel de formalidad	Altamente Informal
Alcance	Preguntas de competencia: • ¿Cuál es nivel de confianza de un dataset publicado en internet? • ¿Cuáles son los datasets de mayor confianza de determinada temática?
Fuentes del	• https://www.dublincore.org/specifications/dublin-core/dcmi-terms/

conocimiento	• https://trdf.sourceforge.net/trustvocab.owl • https://www.w3.org/ns/prov-o-20130430 • https://www.w3.org/ns/oa# • https://xmlns.com/foaf/spec/20140114.rdf • https://www.w3.org/TR/void/
--------------	---

2.2 CONCEPTUALIZACIÓN

En esta etapa se realiza el modelado conceptual de la ontología. Se toman como fuentes de conocimiento las ontologías identificadas previamente y se complementa con la inclusión de nuevos conceptos, relaciones y reglas. Durante el desarrollo de este capítulo se explorará la construcción y visualización de la Ontología.

2.2.1 Glosario de términos

La Tabla 3 muestra los términos que se deducen de las métricas de confianza identificadas en Tabla 1.

Tabla 3: Glosario de términos

Nombre	Sinónimos	Descripción	Tipo
Dataset	Recurso	Recurso publicado mediante LOD	Concepto
Autor	Publicador	Autor que publica el dataset	Concepto
Entidad	Organización	Entidad donde se encuentra publicado el dataset	Concepto
Anotación de confianza	Registro de confianza	Registro, comentarios, o reseñas sobre el dataset	Concepto
Título		Título del dataset	Atributo
Descripción	Resumen	Descripción del dataset	Atributo

Nombre	Sinónimos	Descripción	Tipo
Valor de confianza		Valor de confianza asignado a un dataset o entidad	Atributo
Entidad de confianza		Entidad que de acuerdo con los axiomas definidos es considerada de confianza	Concepto
Dataset de confianza		Dataset que de acuerdo con los axiomas definidos es considerada de confianza	Concepto
Publicador	Autor	Quien publica un dataset	Concepto
Publica		Acción de publicar un dataset	Relación
Licencia		Tipo de licencia del dataset publicado	Relacion
Resumen	Descripción	Resumen de los datos que contiene el dataset	Atributo
Firma Digital		Método de verificación de integridad de los datasets	Concepto
Confiable		Define si una entidad o dataset son confiables o no	Atributo
Lista negra		Lista negra de publicadores de contenido de poca o ninguna confianza	Concepto
Lista de confianza		Lista de publicadores de contenido de confianza	Concepto

2.2.2 Taxonomía de Conceptos.

La Figura 12 presenta la taxonomía de conceptos identificados en las fuentes de conocimiento. El desarrollo se construye a partir del concepto dataset de la Ontología VOID.




Figura 12: Taxonomía de conceptos

Se utilizan los conceptos definidos en las ontologías identificadas para cada una de las métricas de Calidad. Las entidades que no aparecen dentro de la taxonomía están definidas como propiedades de anotación. La Figura 13 muestra las propiedades de anotación de las ontologías identificadas. Dentro de la evaluación de las métricas de confianza se valida la presencia de estas anotaciones en las instancias del conjunto de datos, tal como se refleja en figura 13.




Figura 13: Ejemplo propiedades de anotación para validación de métricas de confianza

2.2.3 Relaciones binarias entre conceptos.

Tabla 4: Relaciones Binarias entre conceptos

Concepto de origen	Nombre de la relación	Relación inversa	Concepto destino
Publicador	Publica	Es publicado por	Dataset
Persona	Comenta	Es comentado por	Dataset
Dataset	Tiene licencia	licencia	Derecho de uso
Documento	Describe	Es descrito por	Dataset
Publicador	Es	Es	Organización
Publicador	Es	Es	Persona
Lista negra	Contiene	Se encuentra en	Persona
Lista negra	Contiene	Se encuentra en	Organización
Lista de confianza	Contiene	Se encuentra en	Persona

Concepto de origen	Nombre de la relación	Relación inversa	Concepto destino
Lista de confianza	Contiene	Se encuentra en	Organización

La tabla anterior describe posibles relaciones identificadas sobre las entidades de las Ontologías que soportan las métricas de confianza.

2.2.4 Diccionario de Conceptos

La Tabla 5 muestra los conceptos principales que hacen parte de las diferentes Ontologías sobre las que se construirá Evallo. En el desarrollo se incluirán las nuevas relaciones que permitirán la evaluación de los diferentes conjuntos de datos.

Tabla 5: Diccionario de conceptos

Concepto	Atributos	Relaciones
Publicador (Agent)	wasInfluencedBy wasAttributedTo wasAssociatedWith qualifiedInfluence qualifiedDelegation agent atLocation	Publish dataset
Dataset	Classes distinct objects distinct subjects number of documents number of entities number of properties URI space	example resource of Dataset has a SPARQL endpoint at has an URI look-up endpoint at has subset number of documents number of entities number of properties number of triples open search description vocabulary

Organización	wasInfluencedBy wasAttributedTo wasAssociatedWith qualifiedInfluence qualifiedDelegation agent atLocation	Publish dataset
Persona	wasInfluencedBy wasAttributedTo wasAssociatedWith qualifiedInfluence qualifiedDelegation agent atLocation	Publish dataset
Valor de confianza	Valor	Confía

Los conceptos identificados en las ontologías con que se trabajará el modelo, sus propiedades y relaciones extraídas de Protege. Se excluyeron los conceptos que están representados en las ontologías mediante propiedades de anotación para el diseño de la ontología, pero se utilizarán para la inferencia de nuevas relaciones y en la validación.

2.2.5 Descripción de las Relaciones Binarias Entre Conceptos

La Tabla 6 describe las relaciones principales entre los conceptos del punto anterior.

Tabla 6: Descripción relaciones Binarias entre conceptos

Concepto de origen	Nombre de la relación	Cantidad del origen (máxima)	Relación inversa	Concepto destino
Publicador (Agent)	Publica	1	Es publicado por	dataset

dataset	Es valorado con	1	valora	Valor de confianza
Organización	Publica	1	Es publicado por	dataset
Persona	Califica	1	Es calificado por	dataset

2.2.6 Descripción de Atributos y Constantes

En esta tarea se describen los atributos de clase, atributos de instancia y las constantes en detalle.

2.2.7 Atributos de Instancia

Nombre del atributo de instancia	Nombre del concepto	Tipo de valor	Cardinalidad	Rango del valor
Valor de confianza	Organización, persona, dataset	String	(1,1)	Alfanumericos
Título	Dataset	String	(1,1)	Alfanumericos
Contenido, resumen	Dataset	String	(1,1)	Alfanumericos
URI	Dataset	String	(1,1)	Alfanumericos
Cantidad anotaciones de confianza	Dataset	String	(1,1)	Alfanumericos
Nombre	Persona	String	(1,1)	Alfanumericos
email	Persona	String	(1,1)	Alfanumericos
Reputación	Organización, persona	String	(1,1)	Alfanumericos
Tiene anotación de licencia	Dataset	String	(1,1)	Alfanumericos
Tiene atribución	Dataset	Xsd:boolean	(1,1)	0,1

Tabla 7: atributos de instancia

2.2.8 Atributos de Clase

La Tabla 8 describe los atributos de clase de las ontologías identificadas y Evallo. En este caso se identifica un atributo de clase que caracteriza a los dataset de confianza de acuerdo al calculo del valor de confianza.

Tabla 8: Atributos de clase

Atributos de clase	Nombre del concepto	Tipo de valor	Cardinalidad	Valores
Es confiable	Dataset de confianza	Boolean	(1,1)	true

2.2.9 Constantes

Para el modelo en desarrollo no se identificaron constantes que aportaran a la propuesta.

2.2.10 Descripción de Axiomas Formales

La Tabla 9 describe los axiomas formales que se utilizaran para evaluar el nivel de confianza de un recurso LOD. Se tomaron los axiomas que se pueden evaluar con las ontologías identificadas en Tabla 1.

Tabla 9: Axiomas formales

Dimensión de confianza	Nombre del Axioma	Descripción	Expresión	Conceptos	Atributos/Relaciones
Presencia de atributos contenido utilizando	de Titulo y uri la	Metadatos plataforma confianza	de la presencia de atributos de confianza sobre la	Contiene, Título, URL, Dataset	supports

ontología de Dublin Core	plataforma					
Calcula la confianza basada en los valores de confianza calculados en cada metrica	Dataset confianza	de	Expresión que valida si un dataset es de confianza	$\sum \text{TrustValue} / \text{No. vetricas} > 0.5$	Dataset TrustValue	TrustValue
Función de confianza se define por la organización que calificara el nivel de confianza del dataset, -1 (Desconfianza absoluta) y 1 (Confianza absoluta)	Confianza dataset	en	Persona u organización confía en un dataset	TrustValue > 0.5	Person Organization Publisher Dataset	TrustValue
Se registrarán valores FOAF dentro de la plataforma extendiendo las relaciones entre datasets y autores	Confianza por autor o publicador		Los valores de confianza se heredan los autores a los datasets	Publicador es de confianza entonces dataset es de confianza	Dataset Publisher	TrustValue
Construcción de redes de decisión informadas por grafos procedencia	Relaciones transitivas entre ppublicadores y datasets		Construcción de grafos de confianza entre publicadores, y datasets	Autor tiene múltiples datasets de confianza, otros daatasets son de confianza	Dataset Publisher Truster	Trustvalue trustworthines
Calculo valor de confianza relaciones establecidas con Prov-o	Suma valores de confianza		Sumatoria de los valores de confianza en las interacciones con otrors	Catntidad de datasets de confianza del autor/publicador		
Recuento anotaciones de confianza	Anotaciones confianza		Cuenta la cantidad de anotaciones de confianza en lazadas con el dataset	$\sum$ anotaciones de confianza	Dataset	annotations
blacklisting, authoritativeness, ranking	Validaciones listas negras		Verifica si el autor u organización está en listas negeas	Publicador o dataset esta en lista negra	Dataset Blacklist	belongsTo
Metadatos autor, sus contribuyentes, el publicador de los datos y sus fuentes	Datos procedenci		Verifica información de procedencia del dataset	Provee información procedencia	Dataset	Publisher HasAuthor
Verificación contiene datos de procedencia con la ontología definida	Datos procedenci		Verifica información de procedencia del dataset	Provee información procedencia	Dataset	Publisher HasAuthor
Recolección anotaciones estadísticas uso/consulta	Datos estadísticos del dataset		Verifica si el dataset tiene datos estadísticos	Datase tiene datos estadísticos	Dataset	Number of entities Number of triplets Number of properties
Verificar si conjunto de datos tiene firma Digital	Verificación firma digital		Se verifica si el dataset contiene una firma digital	HasDigital signature	Signature Dataset	HasSignature
Implementaciones listas: Proveedores de confianza	Contenido listas confianza	en de	Valida si el publicador este contenido en listas de confianza	El publicador este contenido en listas de confianza	Dataset Publisher whitelist	

Detección de licencia en la documentación del conjunto de datos o su fuente	Presencia info de licenciamiento	Presencia anotaciones de licenciamiento	Contiene anotaciones de dataset de licenciamiento	dcterms:access Rights
detección de licencia indicando si la reproducción, distribución, modificación o redistribución es permitido	Presencia info de licenciamiento	Presencia anotaciones de licenciamiento	Contiene anotaciones acerca de derechos de uso	dc:rights
Verificar si el contenido derivado tiene la misma licencia del contenido original	Presencia info de licenciamiento	Presencia anotaciones de licenciamiento	Contiene anotaciones de dataset de licenciamiento	dcterms:access Rights

2.2.11 Descripción de Reglas

La Tabla 10 contiene la descripción de las reglas que podrían evaluar los axiomas identificados a través de la inferencia realizada por un razonador.

Tabla 10: Descripción de reglas

Nombre de la regla	Descripción	Expresión
Metadatos plataforma de confianza	Expresión que valida la presencia de atributos de confianza sobre la plataforma	<code>dataset(?d) ^ hasAnnotation(?d, dcterms:title, ?title) ^ hasAnnotation(?d, dcterms:description, ?desc) -> datasetWithProvenance(?d)</code>
Confianza por autor o publicador	Los valores de confianza se heredan los autores a los datasets	<code>hasProvenance(?dataset) ^ not(hasProvenanceValue(?dataset)) -> MissingProvenance(?dataset)</code>
Relaciones transitivas entre publicadores y datasets	Construcción de grafos de confianza entre publicadores, y datasets	<code>Person(?p) ^ dataset(?d) ^ publishedBy(?s, ?p) ^ Trusted(?p) -> Trusted(?d)</code>
Anotaciones confianza	Cuenta la cantidad de anotaciones de confianza enlazadas con el dataset	<code>hasQualityMetadata(?dataset) ^ not(hasQualityMetadataValue(?dataset)) -> MissingQualityMetadata(?dataset)</code>
Validaciones listas negras	Verifica si el autor u organización está en listas negras	<code>Dataset(?d) ^ BlackList(?b) ^ belongsTo(?d, ?b) -></code>

		blacklistedDataset(?d)
--	--	------------------------

2.2.12 Descripción de Instancias

Se definió utilizar dos instancias de conjuntos de datos LOD que tuvieran una presencia representativa en LOD cloud. Sendo estas DBPEDIA y MEDdra. La Figura 14 muestra una instancia de la entidad Dataset.




Figura 14. Instancia MEDRA cargada en Protege

2.3 FORMALIZACIÓN E IMPLEMENTACIÓN.

En esta sección se muestra la implementación de la Ontología, y su representación gráfica utilizando el software PROTEGE 5.60 y los plugins OWLViz, OntoGraf y SWR.

2.3.1 Jerarquía de conceptos

Este diagrama muestra taxonomía de conceptos inferida después de cargar la ontología en **Protege** y ser procesada por el razonador **Pellet**. La Figura 15 contiene únicamente un extracto donde se visualizan las entidades más importantes, no contiene individuos para facilitar la visualización.



Figura 15: Taxonomía de conceptos inferida

La Figura 16 muestra un extracto de los tipos de datasets que se generaron a partir de la definición de las reglas y axiomas y no se contemplaron en los conceptos iniciales.




Figura 16. Clases de datasets generadas a partir de la definición de los axiomas formales

2.3.2 Diagrama de relaciones binarias

La Figura 17 representa las relaciones entre conceptos desplegadas en Protege. Este diagrama se omitieron las relaciones *has subclass* y *has individual*, que representan herencia y están descritas en la taxonomía de conceptos. También se ocultaron las clases que no tienen relaciones directas (Solo a través de herencia) con ninguna otra clase.




Figura 17: Relaciones binarias inferidas por protege

Para generar este diagrama se utiliza el plugin OntoGraph de Protege. Esta herramienta no permite visualizar las relaciones entre conceptos de ontologías importadas al proyecto, por lo tanto, se unieron todas las ontologías en una única a través de la opción disponible: Refactor > Merge.

2.3.3 Creación de atributos de clase y atributos de instancia.

Para agregar los atributos de clase e instancia en **Protege** se utilizó se utilizan los "Data properties". No se agregaron atributos adicionales sobre las ontologías identificadas, solo se añadieron relaciones. La Figura 18 muestra un extracto de las propiedades con propiedades del concepto dataset.




Figura 18: Pestaña Data Properties en el software protege

En caso de que dos objetos compartan una misma propiedad, el dominio no debe ser definido, ya que, al utilizar el razonador, éste va a inferir que los dos objetos son de la misma clase.

2.3.4 Definición de axiomas formales

En la pestaña Entidades se selecciona la clase sobre la cual se quiere definir el axioma, y se escribe por medio de DL-Language en los campos Equivalent To, SubClass Of, General Class Axioms. A continuación, la Figura 19 muestra la implementación del axioma relacionado con las listas negras implementado a través de las restricciones de equivalencia. Estos Axiomas solo se implementaron sobre las propiedades adHoc por las restricciones de OWL.




Figura 19. Vista de axiomas la clase BlacklistedDataset

2.3.5 Definición de reglas

Para la definición de reglas se utiliza el plugin **swrltab-plugin**, que viene por defecto con la versión 5.6 **Protege**. Se activan las pestañas SWRL y SQWRL para ingresar las reglas.

Se pueden tener reglas para definir propiedades y relaciones cuando se usa el razonador, o reglas para realizar consultas sobre los individuos de la ontología.

Las variables se definen con signo de interrogación (?x) y las reglas se deben definir de la forma:

Antecedente -> Consecuencia

La Figura 20, presenta un Ejemplo de esta regla para el axioma relacionado con la presencia en listas negras de los conjuntos de datos enlazados:




Figura 20. Implementación regla confianza transitiva

Una vez establecidos estos criterios para creación de reglas en la definición de la ontología, la siguiente sección se presenta el proceso de modelado y diseño del sistema multi-agente.

3. MODELADO Y DISEÑO DEL SISTEMA MULTI-AGENTES

3.1 PLANEACIÓN

Dentro de la metodología no existe una definición formal de la etapa de planeación, por lo tanto, se realizó un análisis de requerimientos que permita suplir este apartado, tal como se define en cualquier proyecto de software. Resolviendo la pregunta indicada por la metodología y teniendo en cuenta que la nube de Datos abiertos enlazados está en constante crecimiento (ver Figura 21) se seleccionó un modelo basado en agentes inteligentes, dadas sus características de autonomía e interacción. Los agentes tienen la responsabilidad de mantener la evaluación de confiabilidad de recursos a

través el tiempo y mantener disponible los resultados para la consulta por parte del usuario.




Figura 21: Crecimiento Linked Open Data (Lod-Cloud,2022)

La Figura 22 Muestra el crecimiento de los conjuntos de datos publicados mediante LOD.




Figura 22. Crecimiento LOD

A partir de este crecimiento se identificó que el portal tiene todos los enlaces a los conjuntos de datos y se realizará la indexación de contenidos a partir de este: <https://lod-cloud.net/>.

3.1.1 Requerimientos Funcionales

- En sistema debe rastrear automática y periódicamente la nube de datos enlazados para indexar los recursos disponibles
- El sistema debe clasificar los recursos según niveles de confianza teniendo en cuenta métrica de calidad de confianza
- El sistema debe registrar los datos de procedencia de los recursos rastreados y permitir definir niveles de confianza para las entidades de procedencia.
- El sistema debe permitir a los usuarios calificar los recursos encontrados para evaluar las métricas subjetivas de las dimensiones de confianza.
- El sistema debe permitir consultar el estado de rastreo e indexación de recursos.
- El sistema debe permitir añadir fuentes de rastreo de recursos

3.1.2 Requerimientos no funcionales

- El sistema debe responder las consultas de los usuarios en menos de 5 segundos.
- El sistema debe presentar los resultados de búsqueda de forma amigable, el usuario debe llegar al recurso solicitado en máximo de 2 clics.

3.1.3 Arquitectura general del Sistema Multi-Agente

Como se mencionó anteriormente para el despliegue se planteó una arquitectura de microservicios tal como se presenta en la Figura 23, homologando el comportamiento de un agente a un microservicio y así utilizar una arquitectura moderna basada en nube, utilizando microservicios serverless, componentes y SAAS e IAAS sobre la nube de Microsoft Azure.




Figura 23: Arquitectura propuesta sistema multiagentes (Autoría propia)

La arquitectura se compone de una instancia de apache Jena desplegada como IAAS (Infrastructure as a service) sobre una máquina virtual en Azure para cargar la ontología y almacenar los datasets indexados como individuos de la clase Dataset definida en la Ontología. Se desplegaron tres agentes sobre Azure functions apps como microservicios serverless. Se desplegó un Api Management service para publicar el listado de servicios Rest de los agentes y por último un application service para el despliegue de la interfaz web.

3.2 ANÁLISIS

3.2.1 Casos de uso

Se identificaron 3 actores, plasmados en el diagrama de casos de uso:

- Un usuario que realiza búsquedas en el Sistema Multi-Agente
- Un rastreador de recursos que rastrea la nube de datos abiertos enlazados y almacena los índices de los recursos encontrados
- Un clasificador de evalúa el nivel de confianza y lo registra




Figura 4: Diagrama de casos de uso del sistema (Autoría propia)

3.2.2 Identificación de agentes

A diferencia de la notación de UML, en la identificación de agentes se discriminan las personas y los sistemas de cómputo. En el diagrama, las personas se representan con el actor como en los casos de uso, y los otros sistemas se representan con cuadrados.




Figura 5: Identificación de agentes (Autoría propia)

3.2.3 Identificación de responsabilidades

En este paso se elaboró una tabla de responsabilidades derivada de los casos de uso identificados en el paso 3.2.1.

Tabla 11: Identificación de responsabilidades

Tipo de Agente	Responsabilidades
Agente rastreador	Rastrear la nube de datos abiertos enlazados y obtener recursos
Agente clasificador	Clasificar recursos indexados Recuperar recursos solicitados del repositorio central Almacenar índices de recursos en un repositorio central
Agente	Obtiene la consulta del usuario

buscador	Devuelve resultados de búsqueda Devuelve recurso al usuario
-----------------	--

3.2.4 Identificación de conocidos

En este pase se identifica la interacción necesaria entre los agentes, se actualiza el diagrama de identificación de agentes con las relaciones y aparecen nuevas responsabilidades.




Figura 24: Interacción entre agentes

En la Figura 24 se modela la interacción entre los agentes identificados. Un usuario que desea encontrar un dataset interactúa con un agente que realiza la búsqueda sobre los índices almacenados a través del agente clasificador y un agente rastreador realiza el barrido de los datasets sobre un repositorio definido.

Tabla 12: Responsabilidades agentes con interacción

Tipo de Agente	Responsabilidades
Agente rastreador	Rastrear la nube de datos abiertos enlazados y obtener recursos
	Informar la obtención de un recurso al agente clasificador pertinente
Agente clasificador	Clasificar recursos indexados
	Recuperar recursos solicitados del repositorio centra
	Presentar recursos a agentes buscadores
	Actualizar información de consulta del recurso
	Modificar clasificación según uso del recurso
	Almacenar índices de recursos en un repositorio central
Agente buscador	Obtiene la consulta del usuario
	Devuelve resultados de búsqueda
	Devuelve recurso al usuario
	Solicitar recurso a un agente clasificador
	Informar al agente clasificador acerca de la efectividad de la búsqueda

3.2.5 Refinamiento de agentes

En este paso se aplican algunas consideraciones a los agentes identificados, relativas a los aspectos descritos en seguida:

- **Soporte:**

En el paso anterior ya se ha tenido en alguna información necesaria para que los agentes realicen su función. El agente rastreador requiere un listado de urls semilla para realizar el rastreo, el agente clasificador requiere la información provista por el rastreador y las reglas para realizar la clasificación de los recursos, además de información de calificación provista por el usuario.

- **Descubrimiento:**

Para que conocer que agentes se encuentran activos y que servicios prestan se añadió un agente de directorio para implementar un mecanismo de páginas amarillas para descubrir nuevos servicios.

- **Monitoreo:**

Para realizar tareas de monitoreo se definió un agente monitor de rastreo que se encarga de recopilar los errores en los agentes y de verificar el estado global del rastreo.




Figura 25: Identificación agentes

Tabla 13: Tabla responsabilidades Agentes

Tipo de Agente	Responsabilidades
Agente rastreador	Rastrear la nube de datos abiertos enlazados a partir de un listado de url semilla y obtener recursos
	Informar la obtención de un recurso al agente clasificador pertinente
Agente clasificador	Clasificar recursos indexados
	Recuperar recursos solicitados del repositorio central
	Presentar recursos a agentes buscadores
	Actualizar información de consulta del recurso
	Modificar clasificación según uso del recurso
	Almacenar índices de recursos en un repositorio central
Agente buscador	Recibe la consulta del usuario
	Devuelve resultados de búsqueda
	Devuelve recurso al usuario
	Solicitar recurso a un agente clasificador
	Informar al agente clasificador acerca de la de la búsqueda
Agente	Registrar los servicios de agentes conectados al sistema

directorio	
Agente monitor	Monitorear el estado de indexación, clasificación y aparición de errores

3.2.6 Información de despliegue de los agentes




Figura 26: Despliegue de agentes

3.3 DISEÑO

3.3.1 División/Unión/Cambio nombre agentes.

En este paso no se modificaron los agentes obtenidos en la fase de análisis ya que los agentes que se diseñarán conservan el equilibrio entre la cantidad de agentes y la complejidad de cada agente.

3.3.2 Especificación de la interacción

Especificar las interacciones en una tabla con:

- Nombre de la interacción
- Responsabilidad de la tabla de responsabilidades de la fase de análisis
- Protocolo de interacción
- El rol del agente en la interacción (I- Iniciador, R- Respondiente)

Tabla 14: Tabla de interacción entre agentes

Interacción	Resp	Protocolo Interacción	Role	Con	Cuando
Buscar termino	1	HTTP GET	I	Agente buscador	El usuario envía un término de búsqueda
Obtener resultados búsqueda	2	HTTP GET	R	Agente clasificador	El agente recibe un término para búsqueda
Devolver recurso a agente buscador	3	HTTP GET	I	Agente clasificador	El agente clasificador recupera la información

3.3.3 Definición de protocolos de interacción Ad hoc

Teniendo en cuenta que el sistema multiagentes se implementará a través de una arquitectura de microservicios, en ninguna de las interacciones utilizará el protocolo FIPA Request, en cambio se utilizarán los protocolos AD HOC Basados en HTTP (GET, POST, PUT).

3.3.4 Plantillas de mensajes

El intercambio de mensajes se basa principalmente en consultas SPARQL realizadas sobre protocolos HTTPS entre los diferentes componentes.

3.3.5 Descripción para registrar/consultada en páginas amarillas.

De acuerdo con la se debería utilizar un API Gateway como directorio de servicios para intercambio de mensajes con la capacidad de describir los servicios con especificación OpenAPI.

3.3.6 Interacción Agentes – Recursos

La Figura 27 muestra el diagrama de secuencia con la integración entre los agentes buscador y clasificador donde el buscador solicita los datos indexados asociados a un término de búsqueda.




Figura 27. Interacciones agentes buscador- clasificador

3.3.7 Interacción Agentes – Usuarios

Los Usuarios interactuarán únicamente con el Agente buscador como se muestra en el diagrama de secuencia de la Figura 28.




Figura 28. Interacción Usuario – agente buscador

3.3.8 Comportamientos internos agentes

La metodología utilizada (Nikraz, Caire, & Bahri, 2006) define cuatro tipos de comportamientos: **OneShotBehaviour**, **CyclicBehaviour**, **TickerBehaviour**, **WakerBehaviour**. A continuación, se describen los comportamientos de cada agente identificado:

- El Agente buscador tiene un comportamiento CyclicBehaviour este activo, recibiendo un término de búsqueda del usuario retorna la respuesta y queda escuchando nuevamente.
- Los agentes rastreador y clasificador tienen un comportamiento TickerBehaviour, ejecutan siempre la misma actividad de rastreo de conjuntos de datos y clasificación de acuerdo con atributos de confianza.

3.3.9 Definiendo una ontología

Se define como Ontología a utilizar la desarrollada en el capítulo anterior (EvaLOD). Como se muestra en la Figura 29. Esta Ontología unió diferentes

vocabularios para que los Agentes evalúen la presencia o ausencia de metadatos de confianza y calculen valores de confianza para indexar los datasets como individuos sobre la misma ontología. El modelado se realizó utilizando la aplicación Protege versión 5.




Figura 29: Ontología EvaLOD en Protege

3.4 MODELADO Y DISEÑO DE COMPONENTES EXTERNOS

Para todo el de componentes se utilizó el planteó de nube de Microsoft Azure. Aunque se seleccionó este servicio de nube se podría los componentes son portables y se pueden desplegar en otras nubes.

3.4.1 Repositorio de índices JENA

Se definió JENA como repositorio de índices para almacenamiento de ontología. Se plantea la implementación como arquitectura como servicio sobre una máquina virtual, integrando un proxy reverso para enturar el tráfico https hacia el servidor JENA que expone los servicios sobre HTTP.




Figura 30. Diagrama de contexto implementación Apache JENA en infraestructura como servicio IAAS

3.4.2 Interfaz gráfica de usuario

Se diseñará una interfaz basada en HTML5 y CSS3. La interacción con los agentes definidos se realizará a través del consumo de servicios con Javascript para enviar terminos de búsqueda, recepción y presentación de los resultados de búsqueda de los conjuntos de datos.

CAPÍTULO IV

IMPLEMENTACIÓN Y

PRUEBAS

1. IMPLEMENTACIÓN DEL MODELO

Para realizar la implementación del modelo se desplegó parte de la arquitectura sobre Microsoft Azure. Al realizar la implementación se identificaron algunas limitaciones o capacidades que no se tenían contempladas en el diseño obteniendo como resultado la arquitectura de la Figura 31.




Figura 31. Arquitectura final desplegada

Todos los artefactos desarrollados se encuentran en el repositorio GIT:

<https://github.com/CamiloValencia/Evallo>

Dentro de los principales hallazgos y limitaciones se pueden destacar:

1. En la arquitectura planteada se tenía un servicio de API Management como directorios de los servicios de los agentes o microservicios, pero este presentó problemas al exponer servicios con consultas sparql, se realizó la implementación y se registraron los servicios, pero no se utilizó en la comunicación entre agentes.
2. Inicialmente se plantearon tres agentes, buscador, clasificador y rastreador. El buscador se eliminó al identificar capacidades adicionales de búsqueda basada en SPARQL sobre el repositorio de índices JENA. El rastreador y clasificador se unieron en uno solo al encontrar las limitaciones de OWL para realizar inferencias sobre propiedades de Anotación, teniendo que realizar la clasificación al momento de rastrear los conjuntos de datos.
3. Se identificaron dos repositorios de datos, uno para la ontología con las reglas y axiomas para la validación de reglas de confianza y una base de datos orientada a grafos para almacenamiento de los datasets. Jena tiene ambas capacidades por lo que se utilizaron los servicios de esta como lo muestra la Figura 32. En lugar de tener dos repositorios.




Figura 32. Servicios habilitados Jena sobre Ontología Evalod

1.1.1 Repositorio de índices JENA

En primer lugar, se desplegó el servicio de Apache Jena sobre la máquina virtual, como se ve en la Figura 33 se configuró el servicio sobre protocolo

https, se utilizó el almacenamiento local de la máquina para almacenamiento de la ontología y las tripletas que almacenaran las instancias y los metadatos de los conjuntos de datos indexados.




Figura 33: Despliegue Apache Jena sobre Azure

La Figura 34 muestra el cargue inicial de la Ontología con 3000 tripletas de los vocabularios identificados, que definen los metadatos de confianza identificados.




Figura 34. Carga ontología Evalod en repositorio de índices


1.1.2 Agente rastreador – clasificador

Se implementó un agente rastreador en Python desplegado sobre una función de MS Azure que se ejecuta semanalmente y realiza un Webscraping sobre los conjuntos de datos publicados en <https://lod-cloud.net>, crea los conjuntos de datos en el repositorio de índices y les asigna las propiedades necesarias para evaluar la calidad del set de datos.

En las pruebas se identificó que solo se pueden extraer las propiedades título, descripción, publicador, autor y en algunos casos Licencia o endpoint SPARQL, como lo muestra el siguiente fragmento del log de la salida del agente rastreador:

```
{'hasLicense': False, 'hasSPARQLEndpoint': True, 'title': 'Institutional research plans ', 'descripcion': 'Institutional research plans of R&D from http://www.isvav.cz/ .', 'author': 'Petr Škoda', 'publisher': 'http://linked.opendata.cz/resource/dataset/vavai/research-plans', 'sparql_endpoint': 'http://linked.opendata.cz/sparql'}
```

La Figura 35 muestra la ejecución de las pruebas del agente rastreador-clasificador y como rastrea las url de los conjuntos de datos de LOD Cloud e imprime el resultado de las propiedades mostradas en el fragmento anterior.



```
+ Code + Text
if(dataset['hasSPARQLEndpoint']):
    stats['hasSparqlEndpoint']+= stats['hasSparqlEndpoint']+1
if(dataset['hasSPARQLEndpoint']):
    stats['hasLicense']+= stats['hasLicense']+1
stats['total']+= stats['total']+1
print(stats['total'])

print(stats)
else:
    print('Error al acceder al portal LODCLOUD')

---
license
publisher non present
sparql non present
('hasLicense': False, 'hasSPARQLEndpoint': False, 'title': 'statusnet-hackerposse-com ', 'descripcion': 'StatusNet instance hosted at http://hackerposse.com', 'author': '', 'url': 'https://lod-cloud.net/dataset/statusnet-hackerposse-com ')
Instance stored successfully.
1
sparql non present
('hasLicense': True, 'hasSPARQLEndpoint': False, 'license': 'http://www.geonames.org/licenses/cc-by/', 'title': 'GeoNames Semantic Web ', 'descripcion': 'The GeoNames Ontology makes it possible to add geospatial semantic information', 'author': '', 'url': 'https://lod-cloud.net/dataset/statusnet-geonames ')
Instance stored successfully.
2
license
publisher non present
sparql non present
('hasLicense': False, 'hasSPARQLEndpoint': False, 'title': 'statusnet-gomerttronic-com ', 'descripcion': 'StatusNet instance hosted at http://gomerttronic.com', 'author': '', 'url': 'https://lod-cloud.net/dataset/statusnet-gomerttronic-com ')
Instance stored successfully.
3
license
publisher non present
sparql non present
('hasLicense': False, 'hasSPARQLEndpoint': False, 'title': 'statusnet-illikefreedom-ro ', 'descripcion': 'StatusNet instance hosted at http://illikefreedom.ro', 'author': '', 'url': 'https://lod-cloud.net/dataset/statusnet-illikefreedom-ro ')
Instance stored successfully.
4
license
publisher non present
sparql non present
('hasLicense': False, 'hasSPARQLEndpoint': False, 'title': 'statusnet-jonkman-ca ', 'descripcion': 'StatusNet instance hosted at http://jonkman.ca', 'author': '', 'url': 'https://lod-cloud.net/dataset/statusnet-jonkman-ca ')
Instance stored successfully.
5
license
publisher non present
sparql non present
('hasLicense': False, 'hasSPARQLEndpoint': False, 'title': 'statusnet-morrbtoun-de ', 'descripcion': 'StatusNet instance hosted at http://morrbtoun.de', 'author': '', 'url': 'https://lod-cloud.net/dataset/statusnet-morrbtoun-de ')
Instance stored successfully.
6
```

Figura 35: Ejecución código fuente del agente clasificador en entorno de pruebas

De las pruebas del agente rastreador clasificador-rastreador se pudieron obtener las siguientes estadísticas de presencia de licencia y endpoint SPARQL:

```
{'total': 1253, 'hasLicense': 215, 'hasSparqlEndpoint': 493, 'errorsCount': 1}
```

De acuerdo con la muestra indexada el 61% de los conjuntos de datos publicados en LOD Cloud no tienen un endpoint SPARQL y por lo tanto dificulta realizar las consultas sobre los metadatos de confianza en gran parte de la nube de datos abiertos enlazados. Por este motivo el agente rastreador - clasificador realiza una extracción inicial de metadatos y una clasificación basada en los datos:

Titulo, descripción, enlace al endpoint sparql, Licencia, autor y publicador.

Posteriormente se debe implemetar un nuevo agente clasificador para realizar una segunda evaluación de calidad basada en el punto sparql de cada conjunto de datos.

1.1.3 Interfaz gráfica de usuario

Se implementó una interfaz en HTML 5 para la visualización y consulta de los datos indexados. Se utilizaron hojas de estilo de Bootstrap JS para la maquetación de la interfaz.

Se utilizó la librería **D3.js** (<https://d3js.org/>) para presentar el grafo que representa las búsquedas de los recursos sobre la Ontología desarrollada. La Figura 36 el resultado de búsqueda de conjuntos de datos relacionados con geografía, se visualiza un listado de conjuntos de datos con titulo, descripción, enlace a los detalles y enlace a la fuente. A la derecha se visualiza el grafo con los nodos que tienen punto SPARQL en verde y los que no en rojo.




Figura 36. Representación del grafo de las tripletas consultadas en el repositorio de índices

Para la consulta sobre el repositorio de índices se utilizó una llamada al api del repositorio de índices con las consultas para traer la totalidad de las tripletas y las tripletas que coincidan con un término de búsqueda.

```
PREFIX rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#>
PREFIX rdfs: <http://www.w3.org/2000/01/rdf-schema#>

SELECT ?subject ?predicate ?object
WHERE {
  ?subject ?predicate ?object .
  FILTER (
    CONTAINS(LCASE(str(?subject)), "your_search_term") ||
    CONTAINS(LCASE(str(?predicate)), "your_search_term") ||
    CONTAINS(LCASE(str(?object)), "your_search_term")
  )
}
```

Figura 37. consulta por termino de búsqueda sobre los índices almacenados

La Figura 37 muestra la consulta SPARQL utilizada para realizar las consultas en la interfaz.

La segunda interfaz mostrada en la Figura 38 permite visualizar la evaluación de las métricas de confianza definidas por un conjunto de datos específico, resultado de la búsqueda de la pantalla anterior




Figura 38. Visualización por cada conjunto de datos indicando las métricas de confianza estimadas

RESULTADOS Y ANÁLISIS

Se logró la implementación parcial de la herramienta basada en agentes para medir la calidad de conjuntos de datos publicados mediante LOD. A pesar del crecimiento de la nube de datos abiertos enlazados aún existen bastantes restricciones a nivel de tecnología para rastrear todos los conjuntos de datos y estandarizar la forma preliminar de consumir, leer y calcular métricas asociadas a calidad de estos.

Durante el desarrollo de este trabajo se encontraron sets de datos que no tienen puntos de consulta SPRQL, o no estaban en formatos OWL o RDF. Cuando se planteó el trabajo de investigación se tenía la hipótesis de que todos los conjuntos de datos iban a poder ser rastreados a través de un RDF Crawling, pero al probar con el primer repositorio no se logró realizar, por lo tanto, se desarrolló un webscrapper para realizar la operación.

Por otro lado, también se tenía la hipótesis de que se podría realizar el cálculo de las métricas de confianza a través de la inferencia sobre las propiedades, se identificaron las posibles métricas y los vocabularios que se pueden utilizar para definirlos como Dublin Core, desafortunadamente gran parte de estos vocabularios definen los atributos como anotaciones y esto no permite la inferencia a través de axiomas formales o reglas semánticas por restricción de OWL. Esto requirió realizar estas asociaciones con un proceso externo dentro del agente que realiza el rastreo.

Las métricas identificadas son una excelente estrategia para medición de calidad de conjuntos de datos ya que no solamente aplican a a calidad sobre conjuntos de datos LOD sino que se pueden implementar para cualquier modelo de calidad de datos en catálogos empresariales teniendo en cuenta que es una necesidad real de las organizaciones. Lo que más se destaca de esta propuesta es la identificación de esas métricas y la propuesta de evaluación de estas métricas.

CAPÍTULO V

CONCLUSIONES

1. CONCLUSIONES

Dentro del primer objetivo planteado: Identificar métodos de evaluación de niveles de confianza para aplicar sobre recursos bajo especificaciones Datos Abiertos Enlazados, se lograron extraer los métodos de evaluación de diferente publicación dentro de la que podemos destacar (Zaveri, y otros, 2013). Se definieron las métricas más relevantes acordes al objetivo y una propuesta de evaluación que se validó en la implementación de los objetivos 2 y 3. Estas métricas tienen un impacto considerable ya que pueden aplicarse a cualquier conjunto de datos incluso para la validación de calidad sobre catálogos de datos empresariales.

Frente al segundo objetivo, definir una ontología para comunicación entre agentes, que contenga las reglas necesarias para evaluar un recurso abierto. Se identificaron las ontologías que contienen los conceptos y propiedades requeridas para evaluar las métricas. Se construyó un modelo a partir de las 6 Ontologías descritas en la Tabla 2, donde se demuestra que ya existen vocabularios contruidos y de uso general como Dublín Core, que permiten ejecutar la evaluación de métricas de confianza propuestas por diferentes autores a través de la definición de reglas semánticas. Las tecnologías actuales no permiten evaluar la confianza a través de inferencia con estas Ontologías.

Varios axiomas se plantearon sobre ontologías existentes que definen metadatos de confianza sobre propiedades de anotación. El uso de axiomas sobre estas propiedades está restringido por OWL y por el uso de SWRL.

El rastreo de los conjuntos de datos enlazados se hace complejo teniendo en cuenta que no todas las organizaciones publican estos conjuntos de manera estandarizada ni en los mismos lenguajes. El proyecto implemento un webscrapper por facilitar el consumo de conjuntos de datos publicados en portales web sin depender de formatos complejos, se identificaron conjuntos de datos publicados en RDF, otros en OWL, otros en APIs personalizados en

Arquitecturas REST, en trabajos futuros se podrían añadir otros portales de datos abiertos.

Se implementó una interfaz web de consulta que muestra los datasets rastreados junto con su valor de confianza calculado satisfaciendo el objetivo de implementar una herramienta de visualización de consultas sobre Datos Abiertos Enlazados que presente la información a usuarios según su nivel de confianza. Con esto se confirman las capacidades de visualización utilizando HTML 5 y Javascript para facilitar la navegación sobre este tipo de información.

Por último, podemos concluir que aún se debe realizar un gran esfuerzo para garantizar la interoperabilidad ya que hoy se deben realizar desarrollos Ad Hoc para cada entidad u organización que publica estos conjuntos de datos. Considero que la complejidad de los conceptos y herramientas habilitados por la web semántica requieren una curva de aprendizaje demasiado extensa, generando poca evolución de las herramientas, poca documentación técnica y falta de especialistas en esta área del conocimiento. Con la evolución de las capacidades de cómputo y otras técnicas como Machine Learning específicamente los **grandes modelos de lenguaje** que han mostrado excelentes resultados en los últimos dos años en la extracción, síntesis y presentación de conocimiento, se debería reevaluar o reorientar la inversión en web semántica teniendo en cuenta que ya no es necesario dotar la web de significado desde la publicación puesto que con los modelos mencionados se podrá extraer el significado o conocimiento requerido publicado con estándares de web 1.0 y 2.0.

2. TRABAJOS DERIVADOS

Durante el desarrollo de este trabajo se realizaron dos publicaciones:

- 2017 - Ontological model based on web of trust to analyze the use of resources in learning environment – **Cat B**
<http://revistas.ustabuca.edu.co/index.php/ITECKNE/article/view/1629>
- 2022 - Design of a trust system for e-commerce platforms based on quality dimensions for linked open datasets
<https://www.jisem-journal.com/download/design-of-a-trust-system-for-e-commerce-platforms-based-on-quality-dimensions-for-linked-open-12741.pdf>

El primero trabaja la definición de un modelo ontológico basado en web semántica de confianza para analizar el uso de recursos de aprendizaje. El segundo trabajó la aplicación del modelo de confianza definido en este trabajo a plataformas de E-commerce.

3. TRABAJOS FUTUROS

Se plantean tres líneas principales para el desarrollo de trabajos futuros:

La primera orientada a la evolución técnica de la herramienta de evaluación de métricas de confianza incluyendo nuevos agentes para realizar scrapper sobre otros repositorios de datos abiertos enlazados. Adicionalmente implementar un nuevo agente para realizar un crawler sobre los puntos de acceso SPARQ de los conjuntos de datos y realizar una segunda evaluación de las métricas de calidad.

La segunda la generación de una metodología de cálculo de niveles de confianza sobre cualquier tipo de dato, publicado o no a través de LOD, que utilice las métricas identificadas ya que puede tener gran valor en el ámbito empresarial. La tercera es el planteamiento de un desarrollo basado en herramientas de Machine Learning para evaluación de las métricas definidas en este trabajo sobre cualquier tipo de recurso publicado en la web o en documentos electrónicos.

4. BIBLIOGRAFÍA

- Abanda, F., Kamsu-Foguem, B., & Tah, J. (2017). *BIM – New rules of measurement ontology for construction cost estimation* (Vol. 20). Obtenido de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85018348612&doi=10.1016%2fj.jestch.2017.01.007&partnerID=40&md5=fd3f13219cde27d8fd1cca734a55d06d>
- Alsanad, A., Chikh, A., & Mirza, A. (2019). *A Domain Ontology for Software Requirements Change Management in Global Software Development Environment* (Vol. 7). Obtenido de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85065128605&doi=10.1109%2fACCESS.2019.2909839&partnerID=40&md5=134ade025e02d61d68db3b35220e2eb0>
- Aslam, M., & Aljohani, N. (2017). SPedia: a central hub for the linked open data of scientific publications. , *13(1)*, 128-147. IGI Global.
- Bauer, F., & Kaltenböck, M. (2011). Linked open data: The essentials. *Edition mono/monochrom, Vienna*.

- Berners-Lee, T., Hendler, J., Lassila, O., & others. (2001). The semantic web. *Scientific american*, 284(5), págs. 28–37.
- Bizer, C. (2007). *Quality driven information filtering: in the context of web based information systems*. VDM Publishing.
- Bizer, C. (2009). The emerging web of linked data. *IEEE intelligent systems*, 24(5), págs. 87–92.
- Bizer, C., Heath, T., & Berners-Lee, T. (2009). Linked data-the story so far. *Semantic Services, Interoperability and Web Applications: Emerging Concepts*, págs. 205–227.
- Bonatti, P. A., Hogan, A., Polleres, A., & Sauro, L. (2011). Robust and scalable linked data reasoning incorporating provenance and trust annotations. *Web Semantics: Science, Services and Agents on the World Wide Web*, 9(2), págs. 165–201.
- Bosch, M. (2001). Documentos y lenguaje de marcado: conceptos, problemas y tendencias. *El profesional de la información*, 10(11), págs. 4–9.
- Brickley, D., & Guha, R. (2014). RDF Schema 1.1. W3C Recommendation (25 February 2014). *World Wide Web Consortium*.
- Brickley, D., & Guha, R. V. (2000). Resource Description Framework (RDF) Schema Specification 1.0: W3C Candidate Recommendation 27 March 2000.
- Castells, P. (2003). La web semántica. *Sistemas interactivos y colaborativos en la web*, págs. 195–212.
- Ceolin, D., Groth, P., Maccatrozzo, V., Fokkink, W., van Hage, W. R., & Nottamkandath, A. (2016). Combining User Reputation and Provenance

Analysis for Trust Assessment. *Journal of Data and Information Quality (JDIQ)*, 7(1-2), pág. 6.

Cimiano, P., Chiarcos, C., McCrae, J., & Gracia, J. (2020). Discovery of language resources. 263-279. Springer.

Cubides, J., García, P., Marín, C., & Capera, Á. (2019). Confidence level evaluation of LOD resources on CKAN instances. *13(2)*, 2. Universidad Distrital Francisco José de Caldas.

d'Aquin, M., Dietze, S., Drachsler, H., Guy, M., Herder, E., & Parodi, E. (2014). Building the open elements of an open data competition. *D-lib Magazine*, 20(5), pág. 3.

d'Aquin, M., Drachsler, H., Herder, E., Dietze, S., Guy, M., & Parodi, E. (2014). Building the open elements of an open data competition. *20(5-6)*.

Della Valle, E., & Ceri, S. (2011). Querying the semantic web: SPARQL. En *Handbook of Semantic Web Technologies* (págs. 299–363). Springer.

Dietze, S., Sanchez-Alonso, S., Ebner, H., Yu, H., Giordano, D., Marenzi, I., & Nunes, B. (2013). Interlinking educational resources and the web of data: A survey of challenges and approaches. *47(1)*.

Dietze, S., Yu, H. Q., Giordano, D., Kaldoudi, E., Dovrolis, N., & Taibi, D. (2012). Linked Education: interlinking educational Resources and the Web of Data.

Drakos, A., Protonotarios, V., & Manouselis, N. (2015). agINFRA: A research data hub for agriculture, food and the environment. *4*.

Enayat Rajabi, Kahani Mohsen, S. (2012). Trustworthiness of Linked Data Using PKI. .

- Espinosa, R., Garriga, L., Zubcoff, J., & Mazón, J.-N. (2014). Linked Open Data mining for democratization of big data . 17-19.
- Flemming, A. (2010). Quality characteristics of linked data publishing datasources. *Master's thesis, Humboldt-Universität of Berlin*.
- Francined Herrera-Cubides, J., Alonso Gaona-Garcia, P., & Gordillo-Orjuela, K. (2017). A View of the Web of Data. Case Study: Use of Services CKAN. 22(1).
- Gamble, M., & Goble, C. (2011). Quality, trust, and utility of scientific data on the web: Towards a joint model.
- Gaona García, P. A., Montenegro Marin, C. E., & Herrera Cubides, J. F. (2022). *Enriquecimiento de recursos educativos: un enfoque aplicado a la web semántica y datos abiertos*. Bogotá: Universidad Distrital Francisco José de Caldas).
- Gaona-García, P. A., Herrera-Cubides, J. F., Riaño, K., Alonso, J. I., & Gómez-Acosta, A. (2019). *A Fuzzy Logic Model Based on Web of Trust to Access Linked Open Data Resources* (Vol. 25). American Scientific Publishers.
- Gaona-García, P., Fermoso-García, A., & Sánchez-Alonso, S. (2017). Exploring the relevance of Europeana digital resources: preliminary ideas on Europeana metadata quality. 40(1), 59-69. Escuela Interamericana de Bibliotecología-Universidad de Antioquia.
- Gaona-García, P., Herrera-Cubides, J., Alonso-Echeverri, J., Riaño-Vargas, K., & Gómez-Acosta, A. (2018). A fuzzy logic system to evaluate levels of trust on linked open data resources. (86), 40-53. Universidad de Antioquia.
- García, M. Á. (s.f.). *es.dbpedia.org*. Recuperado el 22 de 10 de 2016, de <http://es.dbpedia.org/>

- García, P., García, A., & Alonso, S. (2017). *Exploring the relevance of Europeana digital resources: Preliminary ideas on Europeana metadata quality* (Vol. 40).
- Gil, Y., & Artz, D. (2007). Towards content trust of web resources. *Web Semantics: Science, Services and Agents on the World Wide Web*, 5(4), págs. 227–239.
- Gil, Y., & Ratnakar, V. (2002). Trusting information sources one citizen at a time. *The Semantic Web—ISWC 2002*, págs. 162–176.
- Golbeck, J. (2006). Trust on the world wide web: a survey. *Foundations and Trends in Web Science*, 1(2), págs. 131–197.
- Golbeck, J., & Mannes, A. (2006). Using Trust and Provenance for Content Filtering on the Semantic Web.
- Gómez-Pérez, A., Fernández-López, M., & Corcho, O. (2006). *Ontological Engineering: with examples from the areas of Knowledge Management, e-Commerce and the Semantic Web*. : Springer Science & Business Media.
- Gordo, E., & Soto, J. (2007). Autenticidad basada en la Web Semántica de confianza.
- Guy, M. (2016). The open education working group: bringing people, projects and data together. , 166-187. Springer.
- Hartig, O. (2008). Trustworthiness of data on the web.
- Haslhofer, B., & Isaac, A. (2011). data. europeana. eu: The europeana linked open data pilot.

- Hendler, J., Golbeck, J., & Parsia, B. (2006). Trust networks on the Semantic Web. *Proceedings of Cooperative Intelligent Agents, August*, págs. 27–29.
- Herrera, J. F. (2021). *METAMODELO PARA VINCULACIÓN DE RECURSOS EDUCATIVOS ABIERTOS MEDIANTE ESPECIFICACIONES LOD Y BASADO EN PRINCIPIOS DE CONFIANZA*. Bogotá: Universidad Distrital "Francisco José de Caldas".
- Herrera-Cubides, J. F., Gaona-García, P. A., Montenegro-Marín, C. E., & Sánchez-Alonso, S. (2022). *Improving OER descriptions to enhance their availability, reuse, and enrichment* (Vol. 27). Springer.
- Herrera-Cubides, J. F., Gaona-García, P. A., Montenegro-Marín, C. E., Arias-Caracas, E., & Mendoza-López, D. F. (2018). *Use of fuzzy logic as a strategy to evaluate trust and accessibility of DataSet published in SPARQL Endpoints*. Universidad Libre.
- Hogan, A., Harth, A., Umbrich, J., Kinsella, S., Polleres, A., & Decker, S. (2011). Searching and browsing Linked Data with SWSE. *Web Semantics: Science, Services and Agents on the World Wide Web*, 9(4), págs. 365–401.
- Hogan, A., Umbrich, J., Harth, A., Cyganiak, R., Polleres, A., & Decker, S. (2012). An empirical survey of linked data conformance. *Web Semantics: Science, Services and Agents on the World Wide Web*, 14, págs. 14–44.
- Isaac, A., & Haslhofer, B. (2013). Europeana linked open data–data. *europeana. eu*. 4(3), 291–297. IOS Press.
- Jacobi, I., Kagal, L., & Khandelwal, A. (2011). Rule-based trust assessment on the semantic web.

- Kirrane, S., Villata, S., & D'Aquin, M. (2018). Privacy, security and policies: A review of problems and solutions with semantic web technologies. , 9(2).
- Klyne, G., & Carroll, J. J. (2006). Resource description framework (RDF): Concepts and abstract syntax.
- Kontokostas, D., Westphal, P., Auer, S., Hellmann, S., Lehmann, J., Cornelissen, R., & Zaveri, A. (2014). Test-driven evaluation of linked data quality. En C.-W. Chung, A. Broder, K. Shim, & T. Suel. New York, New York, USA: ACM Press.
- Kravari, K., & Bassiliades, N. (2019). *StoRM: A social agent-based trust model for the internet of things adopting microservice architecture* (Vol. 94).
- Lehmann, J., Isele, R., Jakob, M., Jentzsch, A., Kontokostas, D., Mendes, P., . . . Bizer, C. (2015). DBpedia - A large-scale, multilingual knowledge base extracted from Wikipedia. 6(2).
- LinkedUp project, Linking Web Data for Education.* (s.f.). Recuperado el 22 de 9 de 2016, de <http://linkedup-project.eu>
- Martin-Moncunill, D., Garcia, P. A., & Rajabi, E. (2015). Navigating through the Linking Open Data cloud datasets: Preliminary ideas of a visual search tool based on its defined domains.
- Martin-Moncunill, D., Garcia, P. A., & Rajabi, E. (s.f.). Navigating through the Linking Open Data cloud datasets: Preliminary ideas of a visual search tool based on its defined domains.
- McGuinness, D. L., van Harmelen, F., & others. (2004). OWL web ontology language overview. *W3C recommendation*, 10(10), pág. 2004.
- McNett, M. (2020). Protecting the data: Security and privacy . 87-99. Elsevier.

- Mendes, P. N., Mühleisen, H., & Bizer, C. (2012). Sieve: linked data quality assessment and fusion.
- Nikraz, M., Caire, G., & Bahri, P. A. (2006). A methodology for the analysis and design of multi-agent systems using JADE.
- Oren, E., Delbru, R., Catasta, M., Cyganiak, R., Stenzhorn, H., & Tummarello, G. (2008). Sindice. com: a document-oriented lookup index for open linked data. *International Journal of Metadata, Semantics and Ontologies*, 3(1), págs. 37–52.
- Prud'Hommeaux, E., Seaborne, A., & others. (2008). SPARQL query language for RDF. *W3C recommendation*, 15.
- RDF Working Group. (2014). *RDF - Semantic Web Standards*. Recuperado el 24 de 9 de 2016, de <https://www.w3.org/RDF/>
- Richardson, M., Agrawal, R., & Domingos, P. (2003). Trust management for the semantic web.
- Salah, T., Zemerly, M., Yeun, C., Al-Qutayri, M., & Al-Hammadi, Y. (2017). *The evolution of distributed systems towards microservices architecture*.
- Schmachtenberg, M., Bizer, C., & Paulheim, H. (2014). Adoption of the linked data best practices in different topical domains.
- Schmachtenberg, M., Bizer, C., Jentzsch, A., Cyganiak, R. (s.f.). *The Linking Open Data cloud diagram*. Recuperado el 31 de 8 de 2017, de <http://lod-cloud.net/>
- Search for a Dataset - the Datahub*. (s.f.). Recuperado el 22 de 9 de 2016, de <https://datahub.io/dataset?tags=lod>

- Shekarpour, S., & Katebi, S. D. (2010). Modeling and evaluation of trust with an extension in semantic web. *Web Semantics: Science, Services and Agents on the World Wide Web*, 8(1), págs. 26–36.
- Sikos, L. F. (2015). *Mastering structured data on the Semantic Web*. [Berkeley, CA]: Apress.
- Tamez, E. B., Woungang, I., Lilien, L., & Denko, M. K. (2009). Trust management in opportunistic networks.
- The Linking Open Data cloud diagram*. (s.f.). Recuperado el 22 de 9 de 2016, de <http://lod-cloud.net/>
- Tim Berners-Lee. (27/07/2006). *Linked Data - Design Issues*. Recuperado el 29 de 8 de 2017, de <https://www.w3.org/DesignIssues/LinkedData.html>
- Valencia Martínez, C. A. (2016). *Definición de un Modelo Ontológico, que Facilite la Medición de Niveles de Usabilidad de Herramientas en Plataformas LCMS Mediante SNA (Social Network Analysis)*.
- Wooldridge, M. J. (2009). *An introduction to multiagent systems* (2nd ed. ed.). Chichester, U.K.: John Wiley & Sons.
- Ying, J. J.-C., Lu, E. H.-C., Lee, W.-C., Weng, T.-C., & Tseng, V. S. (s.f.). Mining user similarity from semantic trajectories. En X. Zhou, W.-C. Lee, W.-C. Peng, & X. Xie.
- Zaveri, A., Rula, A., Maurino, A., Pietrobon, R., Lehmann, J., & Auer, S. (2013). Quality assessment methodologies for linked open data. Under review.